

Internet capturado

Naturaleza humana,
poder algorítmico y la
arquitectura de una
red más gobernable



Internet capturado

*Naturaleza humana, poder algorítmico y la
arquitectura
de una red más gobernable*

Axiologic Research

Julio de 2026

*Imagine que Internet sigue funcionando perfectamente
mientras resulta cada vez menos valioso entrar en él.*

HISTORIA • GOBERNANZA • RECOMENDACIÓN • IDENTIDAD • DISEÑO INSTITUCIONAL

Copyright © [2026] Sînică Alboaie

Todos los derechos reservados.

Derechos de publicación KDP mantenidos por Outfinity SRL (Iași, Romania).

Derechos de uso concedidos a Outfinity Sagl (Caslano, Switzerland).

Disponible gratuitamente en el sitio web de Outfinity Venture Studio (www.outfinity.ch).

Los sistemas de inteligencia artificial se utilizaron como instrumentos editoriales y de investigación.

El argumento, la selección y la responsabilidad autoral pertenecen a Sînică Alboaie.

Nota del autor:

Este trabajo fue creado en el marco del programa de investigación general Outfinitism. Aunque los modelos de lenguaje de inteligencia artificial se aprovecharon para ayudar con la generación de texto, la filosofía subyacente, la estructura temática y los marcos analíticos se derivan completamente de las décadas de investigación dedicada del autor a los fenómenos sociales y las tecnologías sociales.

Analizando los temas fundamentales de Internet de hoy, este libro describe trayectorias evolutivas clave compatibles con el ascenso de AI, formando una piedra angular de la tesis de inversión en Outfinity Venture Studio.

Índice

Todo el libro en diez páginas.....	5
Una red que todavía funciona.....	5
Lo que realmente requeriría un Internet mejor.....	9
Capítulo 1: Antes de las plataformas.....	17
1.1 Protocolos abiertos, dinero público y comunidades pequeñas.....	17
1.2 Correo electrónico, foros, directorios y búsqueda.....	20
Capítulo 2: Plataformas y constituciones ocultas.....	25
2.1 Por qué ganaron las plataformas.....	25
2.2 Captura corporativa, poder de los moderadores y trabajo gratuito.....	28
Capítulo 3: El adversario humano.....	33
3.1 Anonimato, desinhibición, troleo y abuso coordinado.....	33
3.2 La moderación como gobierno.....	36
Capítulo 4: La relevancia es una constitución.....	40
4.1 Búsqueda, flujos, interacción y deriva hacia la idiocracia...	40
4.2 Desinformación, cámaras de eco y manipulación electoral	43
Capítulo 5: La web sintética y Internet que todavía funciona..	47
5.1 Teoría del Internet Muerto, bots y abundancia generativa..	47
5.2 Wikipedia, código abierto, ciencia y bienes comunes duraderos.....	50
Capítulo 6: Más allá de la soberanía de las plataformas.....	54
6.1 Comunidades policéntricas y marcas descentralizadas.....	54
6.2 Economía, licencias y diseño anticaptura.....	57
Capítulo 7: La IA personal como recomendador del usuario... 	61
7.1 De perfiles ocultos a relevancia gobernada por el usuario.	61
7.2 Privacidad, sesgo, pluralismo y riesgo de una cámara de eco personal.....	64
Capítulo 8: Reconstruir la comunicación desde la capa de protocolo.....	69
8.1 WebRTC, direccionamiento similar al correo electrónico, DIDs y conexiones filtradas por confianza.....	69
8.2 Una superficie de ataque menor para humanos y agentes	73
Referencias.....	78

Todo el libro en diez páginas

Una red que todavía funciona

Imagine que Internet sigue funcionando perfectamente mientras resulta cada vez menos valioso entrar en él. La búsqueda es instantánea. Los mensajes llegan. El video nunca se detiene. Los asistentes personales resumen miles de páginas antes del desayuno. Sin embargo, gran parte de lo que aparece en la pantalla no fue creado para informar a una persona, seleccionado por alguien responsable ante esa persona ni ofrecido por una institución que pueda ser impugnada. La maquinaria funciona. El mundo público transportado por esa maquinaria se está debilitando.

Esta abertura contiene todo el argumento en forma comprimida. Un lector que se detiene aquí debe entender el diagnóstico, la evidencia más fuerte y la dirección propuesta. El resto del libro existe para los lectores que quieren la historia, las calificaciones y los detalles de diseño.

La historia estándar comienza con un inocente Internet descentralizado y termina con la captura corporativa. En parte es correcto y demasiado simple. La red temprana surgió de la financiación pública, la investigación militar y universitaria, los organismos de estándares, la infraestructura de telecomunicaciones y las comunidades pequeñas con una competencia técnica inusualmente alta. La apertura fue un logro institucional y de ingeniería, no la ausencia de poder. La armonía temprana también dependía del acceso selectivo, la escala manejable y los administradores cuya autoridad era visible porque las comunidades eran pequeñas (Clark 1988; Abbate 1999; Turner 2006).

Los protocolos abiertos hicieron que las máquinas heterogéneas interoperaran y hicieran que la copia, publicación y comunicación fueran extraordinariamente baratas. No resolvieron la identidad, la reputación, el descubrimiento, el spam, la moderación, la financiación o la toma de decisiones colectivas legítimas. A medida

que se expandía la participación, esos problemas diferidos regresaban. Filtros adquiridos por correo electrónico y reputación de remitente. Usenet y los foros adquirieron administradores y conflictos. Los directorios adquirieron editores. Los motores de búsqueda adquirieron el poder de decidir cuál de miles de millones de páginas se haría visible.

Las plataformas ganaron porque resolvieron problemas reales: interfaces coherentes, alojamiento, búsqueda, cuentas persistentes, acceso móvil, pagos, seguridad, recomendación y moderación. La centralización fue útil antes de que se convirtiera en constitucional. La captura comenzó cuando el mismo proveedor llegó a poseer identidad, relaciones, archivos, ranking, ingresos y el derecho a cambiar cada regla que los gobierna. Los usuarios y moderadores continuaron creando la comunidad, pero la comunidad se convirtió en un activo en el balance de otra persona.

Tabla 1. El diagnóstico en seis capas

Elemento	Significado o consecuencia de diseño
Capa de protocolo	Se logró la interoperabilidad y la publicación barata; la identidad, la moderación, la financiación y la legitimidad seguían sin resolverse.
Capa de plataforma	La usabilidad, el alojamiento, la búsqueda y la seguridad mejoraron, pero la identidad, la ranking, las relaciones, los archivos y los ingresos se concentraron verticalmente.
Capa humana	La baja fricción protegía el discurso vulnerable y ampliaba la participación, al tiempo que reducía el coste del acoso, el fraude y la manipulación coordinada.
Capa epistémica	La búsqueda y la recomendación resolvieron la escasez de atención convirtiendo la relevancia en un poder constitucional privado y a menudo opaco.
Capa sintética	La automatización redujo los costes de producción, pero también debilitó la autenticidad, la procedencia y la posición económica del trabajo humano cuidadoso.
Capa institucional	La participación abierta creó un valor inmenso sin otorgar a los contribuyentes derechos duraderos de voz, salida o beneficio económico.

La captura corporativa es solo un componente de la historia. Internet también cambió el precio del comportamiento humano. El seudonimato puede proteger a disidentes, pacientes, denunciantes y minorías vulnerables. La identidad de bajo coste también puede reducir las consecuencias reputacionales, permitir el regreso rápido tras la exclusión y abaratar el acoso o el consenso simulado. El efecto de desinhibición en línea no convierte a toda persona anónima en un monstruo, pero cambia los incentivos en torno a la conducta impulsiva (Suler 2004). La evidencia experimental sugiere además que el troleo es en parte situacional: el estado de ánimo negativo, los ejemplos hostiles y las normas locales pueden hacer que participantes ordinarios imiten el abuso (Cheng et al. 2017).

El bucle de amplificación es igualmente importante. La provocación produce reacción; la reacción se registra como interacción; la interacción produce distribución; la exposición repetida cambia las normas; los creadores aprenden que el desprecio, la certeza, la humillación y el conflicto faccional viajan más lejos que la matización. Los estudios sobre lenguaje moral-emocional y hostilidad hacia el exogrupo respaldan este mecanismo (Brady et al. 2017; Rathje, Van Bavel, and van der Linden 2021). El resultado se presenta a menudo como preferencia revelada del usuario, aunque el sistema haya ayudado a fabricar la preferencia que midió.

Este es el significado defendible de la metáfora de la “idiocracia” en línea. Los usuarios no se volvieron de repente menos inteligentes. El entorno selecciona material que pueda generar una señal rápida y barata. Una falsa novedad se puede escribir en segundos; la verificación puede requerir horas. Una acusación dramática se ajusta mejor a una alimentación que una cuidadosa estimación de incertidumbre. Por lo tanto, la optimización del interacción subvenciona la certeza inmediata y los impuestos ralentizan el trabajo epistémico. El problema es la selección adversa contra la complejidad, no una disminución biológica de la inteligencia.

La moderación no se puede eliminar simplemente. No intervención transfiere el control a agresores persistentes, facciones organizadas, enjambres automatizados o propietarios que intervienen solo cuando el riesgo legal y comercial se vuelve intolerable. La verdadera

elección es entre la gobernanza visible, limitada, revisable y legítima, y la gobernanza que es improvisada, opaca o capturada (Gillespie 2018; Suzor 2019). Los moderadores voluntarios realizan trabajo cívico indispensable, a menudo sin salario o protección (Matias 2019), pero también pueden convertir la administración en estatus o regla ideológica. Su poder local debe distinguirse del control estructural de la compañía de la plataforma sobre bases de datos, cuentas, monetización y cambio constitucional.

Wikipedia y Reddit muestran que el resultado no está predeterminado. Wikipedia demuestra que un bien común global de conocimiento puede funcionar sin publicidad conductual porque las revisiones, las fuentes, las discusiones y las reversiones son inspeccionables. También muestra cómo las herramientas antivandalismo, las normas complejas y las desigualdades entre contribuyentes pueden calcificar una institución exitosa (Halfaker et al. 2013; Wagner et al. 2016). Reddit otorga a las comunidades capacidad local de elaboración de reglas sobre infraestructura corporativa. La investigación sugiere que las sanciones fuertes pueden reducir el discurso de odio en lugar de simplemente desplazarlo, mientras que las explicaciones y las apelaciones mejoran la legitimidad procedimental (Chandrasekharan et al. 2017; Jhaver, Bruckman, and Gilbert 2019). Las instituciones importan más que los eslóganes sobre apertura o control.

La manipulación política exige la misma disciplina. La información falsa puede difundirse más lejos que la información verdadera en algunas redes, los bots pueden amplificar fuentes de baja credibilidad y las operaciones coordinadas de influencia son reales (Vosoughi, Roy, and Aral 2018; Shao et al. 2018). Pero operación, exposición, persuasión, efectos sobre la participación, cambio de agenda y resultado electoral son afirmaciones distintas. La investigación sobre Internet Research Agency de Rusia documentó una campaña deliberada durante las elecciones de 2016 en Estados Unidos; no identificó un número defendible de votos convertidos. Las cámaras de eco también existen de manera desigual, y la exposición forzada a visiones opuestas hostiles puede intensificar la polarización en lugar de reducirla (Bail et al. 2018; Cinelli et al. 2021).

La teoría más fuerte de Dead Internet afirma que la mayor parte de la actividad en línea ya es artificial y coordinada de forma centralizada. La evidencia no respalda esa conspiración total. Su advertencia más débil es creíble. El tráfico automatizado es sustancial; los sistemas generativos pueden inundar la búsqueda y los flujos sociales con material plausible optimizado para la ranking; los agentes resumen cada vez más las fuentes que los usuarios nunca visitan; la capacitación recursiva sobre datos sintéticos puede degradar los modelos cuando desaparecen los datos humanos originales (Shumailov et al. 2024). Internet no está muerto, pero la autenticidad y la legibilidad humana se están convirtiendo en recursos escasos.

La contraevidencia es igualmente importante. El software de código abierto, Wikipedia, OpenStreetMap, preprints científicos, comunidades de pacientes, mapeo humanitario y foros especializados han generado un inmenso valor público. La conclusión no es que la apertura haya fracasado. Es que las instituciones que crean valor a menudo están separadas de las instituciones que controlan los activos resultantes. Los éxitos del Internet provienen de fundamentos técnicos abiertos combinados con normas, roles, historias y mecanismos de reparación. El siguiente diseño debe preservar esa capacidad al tiempo que corrige sus debilidades constitucionales.

Lo que realmente requeriría un Internet mejor

La alternativa no es ni un retorno a los foros pequeños ni una cadena de bloques universal. Es un sistema policéntrico: protocolos abiertos debajo; comunidades con constituciones reales por encima de ellos; varios proveedores de servicios competidores a su alrededor; y derechos que permiten a los miembros mover proveedores sin abandonar la identidad, las relaciones, la evidencia de reputación o los archivos. El objetivo no es eliminar el poder. Es hacer que el poder sea visible, dividido, temporal y controvertido.

Una comunidad requiere más que una sala de chat y términos de servicio. Necesita un propósito declarado, límites de membresía,

poderes conocidos, moderadores calificados, sanciones que aumenten proporcionalmente, razones para decisiones consecuentes, un camino de apelación, reglas de conflicto de intereses y financiamiento para infraestructura y trabajo difícil. El trabajo de Ostrom sobre bienes comunes duraderos sigue siendo relevante porque rechaza tanto la privatización ingenua como la apertura ingenua: las comunidades exitosas coinciden con las reglas con el contexto, permiten que los miembros afectados participen en su cambio, supervisen la conducta, apliquen sanciones graduadas, resuelvan disputas y operen a través de niveles anidados de gobierno (Ostrom 1990).

Una marca descentralizada puede proporcionar la capa institucional que falta. Una marca no es simplemente un logotipo; es una promesa pública sobre calidad, compatibilidad, conducta y responsabilidad. En una plataforma convencional, una empresa es la que promete. En un proyecto puramente abierto, el artefacto puede ser perdible, mientras que la reputación y la coordinación económica siguen siendo frágiles. Una marca descentralizada coloca el nombre, los estándares, la tesorería y el proceso de certificación bajo una constitución que ningún fundador, inversionista, grupo moderador o proveedor de infraestructura puede alterar solo.




Figura 1. El arco institucional del Internet: desde protocolos abiertos, a través de la atención concentrada, hacia redes gobernables.

Los instrumentos deben permanecer distintos. Un software o licencia de contenido regula la copia y modificación. Una licencia de marca regula el uso de la identidad compartida. Una constitución asigna la decisión, auditoría, enmienda, emergencia y poderes de apelación. Un acuerdo de contribución reconoce el trabajo, el mantenimiento y el capital. Los contratos de servicio limitan el alojamiento, la búsqueda, la recomendación y el uso de datos. Ni un token ni una licencia de código abierto pueden realizar todos estos trabajos.

La descentralización debe ser probada en la práctica. ¿Pueden los miembros exportar relaciones y archivos, no simplemente descargar un archivo? ¿Puede una comunidad cambiar de hosting sin desaparecer? ¿Puede la apelación revertir un moderador? ¿Puede un operador ser reemplazado sin romper identidad? ¿Los contribuyentes comparten beneficios económicos? ¿Puede algún proveedor redefinir el acceso unilateralmente? Un depósito o libro de contabilidad distribuido no es descentralización cuando la institución social permanece cautiva.

La recomendación necesita una inversión similar. Hoy las plataformas construyen perfiles ocultos y utilizan objetivos mixtos - retención, publicidad, seguridad, prioridades comerciales y

estrategia - para decidir qué advierten los usuarios. Incluso un ranking sofisticado trata el modelo del usuario como un activo de la plataforma. Una IA personal podría, en cambio, mantener una representación privada y revisable de intereses, obligaciones, sesgos y límites. Podría reunir candidatos de muchas fuentes, aplicar políticas explícitas, explicar compensaciones, recordar correcciones, preferir evidencia primaria, reducir la indignación, introducir desacuerdo creíble o rechazar patrocinio no declarado. Investigaciones recientes describen este desplazamiento como un movimiento desde perfiles ocultos hacia una personalización gobernable (Liu et al. 2026).

El cambio importante es constitucional, no meramente predictivo. Las plataformas ya predicen gustos. La nueva posibilidad es que la representación del usuario se vuelva inspeccionable, portátil y responsable ante el usuario. La investigación sobre recomendadores ha mostrado desde hace tiempo que la experiencia depende del control, la diversidad, la privacidad, el esfuerzo y la explicación, además de la precisión (Cramer et al. 2008; Knijnenburg et al. 2012; Helberger, Karppinen, and D'Acunto 2018). El agente debería exponer rankings alternativos y contraevidencia en lugar de convertirse silenciosamente en una cámara de eco más íntima.

Este agente también crea riesgos. Puede halagar los impulsos temporales, preservar las preferencias obsoletas, filtrar la memoria privada, depender de un proveedor de la nube o ser manipulado por inyección rápida y fuentes envenenadas. Por lo tanto, sus objetivos, incertidumbre, relaciones comerciales, trayectoria de actualización y poderes delegados deben ser visibles. Las preferencias deben ser revisables y, a veces, expirar. Varias políticas de ranking deben ser comparables. El procesamiento local o confidencial, la procedencia, los límites de capacidad y los registros de acción auditable no son detalles opcionales; son garantías constitucionales.

Una segunda inversión puede ocurrir debajo de la capa de plataforma. El actual Internet expone los servicios a un espacio de direcciones global y luego gasta un enorme esfuerzo rechazando el tráfico no deseado. El correo electrónico acepta intento de entrega de extraños. Los servicios públicos se defienden contra el escaneo, el

spam, los ataques de credenciales, el raspado y la denegación de servicio. La apertura sigue siendo valiosa, pero la receptividad global no debe ser el valor predeterminado para cada servicio personal y agente AI.

Un sistema futuro podría retener interfaces familiares - direcciones, bandejas de entrada, contactos, grupos, documentos compartidos y asistentes - mientras cambia el límite de confianza. Una avería pública no tiene que revelar un punto final personal permanente. El contacto inicial podría pasar por un servicio de introducción estrecho. Una introducción exitosa podría emitir una capacidad revocable que defina quién puede señalar, enviar, invocar a un agente o abrir un canal. Después de eso, los humanos y los agentes podrían comunicarse a través de sesiones directas o retransmitidas encriptadas utilizando canales de datos WebRTC o transportes relacionados.

WebRTC es solo un componente. Suministra APIs y protocolos para medios y datos interactivos, con conectividad negociada a través de ICE y a menudo asistida por relés (IETF 2018; IETF 2021a; W3C 2025a). No define señalización, entrega fuera de línea, archivos, identidad social o confianza. Una dirección legible similar a un correo electrónico podría seguir siendo útil, mientras que un DID o identificador equivalente proporciona control criptográfico portátil y las credenciales verificables proporcionan afirmaciones selectivas (W3C 2022; W3C 2025b; W3C 2026). Estas tecnologías prueban el control o las declaraciones del emisor, no la honestidad. La confianza todavía proviene de relaciones, instituciones, respaldos, historia y contexto.

La red resultante sería de confianza en lugar de receptiva globalmente por defecto. Los actores desconocidos pueden requerir un token de introducción, referencia, fianza o credencial relevante. Los identificadores de pares podrían reducir la correlación entre las relaciones. Los agentes podrían negociar los límites de tarifas, los formatos aceptados, la confidencialidad y la automatización antes de que comience una sesión. Un usuario podría revocar una relación sin sustituir una identidad global. La superficie expuesta se reduciría

porque la mayoría de los servicios personales nunca aceptarían el tráfico arbitrario no solicitado.

Tabla 2. Un conjunto diferente de valores predeterminados

Elemento	Significado o consecuencia de diseño
Perfil de plataforma oculta	Un modelo IA personal gobernado por el usuario que puede ser inspeccionado, corregido, restringido, exportado o eliminado.
Bandeja de entrada expuesta globalmente	Introducciones de confianza, contacto con capacidad y canales específicos de relación.
Un sistema de ranking opaco	Proveedores de ranking generales y inspeccionables seleccionados por los usuarios y las comunidades para fines declarados.
Comunidad corporativa	Comunidades policéntricas que operan bajo una marca descentralizada compartida y una constitución contratable.
Mantenimiento libre invisible	Financiamiento explícito para moderación, seguridad, infraestructura, reparación y administración a largo plazo.
Exportación de datos nominales	Identidad portátil, relaciones, evidencia de reputación, archivos y continuidad práctica del servicio.
Autenticidad por intuición	Procedencia firmada, patrocinio responsable y etiquetado claro de la participación automatizada.

Los servidores se quedarían. WebRTC a menudo necesita infraestructura de señalización y retransmisión; la comunicación asíncrona necesita servicios de almacenamiento y reenvío; los grupos seguros necesitan protocolos como Messaging Layer Security (IETF 2023; IETF 2025). Los proveedores todavía venderían almacenamiento, disponibilidad, descubrimiento, copia de seguridad, computación y respuesta al abuso. La diferencia es que ningún proveedor necesitaría poseer identidad, relaciones, recomendaciones y archivos como un paquete indivisible.

Los agentes personales actuarían como salas de correo locales, recomendadores, mediadores de seguridad y representantes. Podrían filtrar introducciones, verificar credenciales, seleccionar relés,

resumir mensajes, hacer cumplir la política de privacidad y rastrear la autoridad delegada. Debido a que este rol es poderoso, el agente debe ser auditable y reemplazable. Su modelo, memoria, permisos e incentivos comerciales no pueden convertirse en otra constitución oculta.

El futuro más realista es una topología mixta. Algunas comunidades permanecerán centralizadas porque la propiedad o la responsabilidad clara sirven a su propósito. Otros se federarán. Otros compartirán estándares y reputación a través de marcas descentralizadas mientras usan operadores independientes. El pluralismo no es un defecto temporal. Es la defensa contra un nuevo soberano universal.

La prueba final es simple. Un Internet vivo debería ayudar a las personas a formar comunidades, crear bienes públicos duraderos, descubrir información sorprendente y utilizar asistencia inteligente sin renunciar a la identidad y las relaciones a quien sea dueño de la interfaz dominante. Debería encarecer el abuso sin hacer imposible la disidencia; permitir la moderación sin moderadores irrevisables; recompensar a los fundadores y operadores sin otorgar una regla hereditaria; y dejar que la recomendación ayude a una persona a pensar en lugar de definir silenciosamente lo que se le permite ver a la persona.

La naturaleza humana no será eliminada de la red. La curiosidad, la generosidad, la vanidad, el tribalismo, el coraje, la crueldad y el cuidado aparecerán en todas las arquitecturas. El progreso significa crear instituciones en las que las mejores capacidades sean más fáciles de coordinar, las peores capacidades sean más difíciles de convertir en armas y la utilidad temporal no se convierta en la propiedad permanente del mundo social.

Nota sobre la evidencia. Las afirmaciones son apoyadas principalmente por investigaciones revisadas por pares, libros académicos, estándares e informes institucionales. Las propuestas técnicas en los Capítulos 7 y 8 se presentan como direcciones de diseño construidas a partir de componentes maduros, no como afirmaciones de que el problema de integración ya está resuelto.

Capítulo 1: Antes de las plataformas

Los primeros Internet a menudo se recuerdan como una república perdida de iguales. Fue más interesante que eso. La arquitectura abierta surgió de instituciones, comunidades expertas y opciones de ingeniería deliberadas. Su éxito creó libertades que su diseño social no estaba preparado para gobernar.

1.1 Protocolos abiertos, dinero público y comunidades pequeñas

ARPANET y Internet no fueron productos espontáneos de un mercado o una contracultura. Surgieron de programas públicos de investigación, universidades, contratistas, comunidades de estándares e ingenieros que necesitaban redes heterogéneas para interoperar. La conmutación de paquetes, los protocolos de host y más tarde TCP/IP fueron soluciones a problemas técnicos y organizativos. El sistema tuvo que sobrevivir a la diversidad de equipos, los límites administrativos y las aplicaciones cambiantes. La arquitectura resultante distribuyó funciones hacia los bordes y evitó requerir que una red entienda cada uso futuro (Clark 1988; Leiner et al. 1997).

Esta historia técnica importa porque las interpretaciones políticas posteriores tratan a menudo la descentralización como el propósito moral original de la red. La resiliencia, la interoperabilidad y el desarrollo de aplicaciones sin permiso tuvieron ciertamente consecuencias políticas, pero no constituían una teoría política completa. La tradición de extremo a extremo limitó lo que debía decidir el núcleo de la red; no especificó cómo debían gestionar las comunidades el acoso, cómo debían pagarse las contribuciones ni cómo debía justificar sus decisiones un sistema público de ranking (Saltzer, Reed, and Clark 1984).

La cultura de la red primitiva fue moldeada por el acceso selectivo. Universidades, laboratorios de investigación y aficionados técnicamente sofisticados abastecieron a muchos participantes. Las normas profesionales compartidas y la interacción repetida hicieron que la reputación fuera significativa. La informalidad funcionó porque las comunidades eran lo suficientemente pequeñas como para que la historia fuera recordada y porque la participación misma requería esfuerzo. Esto no eliminó la jerarquía. Los administradores controlaban máquinas, listas de correo y cuentas. Experiencia en estatus conferido. Las personas que no compartían los supuestos técnicos y culturales dominantes podrían ser ignoradas o excluidas.




Figura 2. Los protocolos abiertos redujeron la dependencia técnica al tiempo que dejaban una creciente deuda en identidad, descubrimiento, moderación y financiamiento.

La libertad asociada con los primeros Internet fue, por lo tanto, real y subvencionada. Infraestructura de apoyo al dinero público. Las universidades absorbieron los costes. Los voluntarios mantuvieron software y documentación. Los empleadores permitieron que el personal calificado contribuyera. La red parecía flotar por encima de la economía ordinaria porque gran parte de su economía estaba oculta en instituciones que tenían otras razones que no eran el beneficio directo para apoyarla. Cuando el acceso se expandió, el coste de los sistemas sociales operativos se hizo más difícil de ocultar.

El lanzamiento del software World Wide Web por CERN en 1993 ejemplificó el poder de la generosidad institucional. Al permitir el uso libre de regalías, CERN permitió que los navegadores, servidores

y sitios de la competencia aparecieran sin pedir permiso a un propietario central (CERN 1993). La decisión no predeterminó un Web no comercial. Hizo posible la innovación comercial y no comercial en la misma base. La apertura creó un campo en el que tanto los comunes como las corporaciones podrían crecer.

La primera contradicción ya estaba presente. Un protocolo puede ser abierto mientras las comunidades que lo utilizan están cerrados. Un servicio puede ser descentralizado, mientras que el acceso a la experiencia, el hardware y el tiempo sigue siendo desigual. Un estándar público puede permitir la concentración privada si los activos complementarios como el descubrimiento, la identidad y la distribución se vuelven escasos. La historia del Internet no es una caída de la pureza técnica. Es el movimiento de poder de una capa a otra a medida que se resuelve cada cuello de botella.

Esto explica por qué la nostalgia es una guía pobre. La recreación de viejos protocolos o foros cronológicos no recrearía las condiciones sociales bajo las cuales parecían manejables. Miles de millones de usuarios, adversarios automatizados, incentivos comerciales y sistemas generativos cambian la escala del problema. Lo que sigue siendo valioso desde los inicios Internet no es su inocencia, sino su logro institucional: múltiples redes e implementaciones podrían cooperar porque los estándares eran abiertos y la autoridad era limitada en el núcleo.

La propia cultura de los estándares contenía una pista institucional útil. Las solicitudes de comentarios fueron argumentos técnicos públicos en lugar de decretos, y el ideal de consenso aproximado y código de ejecución hizo que la autoridad dependiera en parte de los resultados implementables. El proceso nunca fue perfectamente democrático: la participación requería experiencia, tiempo y acceso, mientras que los recursos clave como nombres y direcciones aún requerían coordinación. Sin embargo, demostró que pueden surgir reglas comunes sin que un solo proveedor posea cada implementación. La legitimidad provino de la especificación abierta, las implementaciones en competencia y la posibilidad de un desafío técnico.

Incluso el núcleo supuestamente descentralizado contenía funciones concentradas. El Sistema de Nombres de Dominio introdujo una delegación jerárquica; la asignación de direcciones y los registros de protocolo requieren administración; los grandes proveedores de columna vertebral ocupaban posiciones estratégicas. La descentralización significaba que ninguna concentración única controlaba necesariamente cada capa, no esa concentración desaparecía. Esta visión en capas es esencial para la reforma contemporánea. Un sistema puede tolerar un registro central si las identidades, los datos, los clientes y las comunidades pueden moverse alrededor de él. Se vuelve peligroso cuando el control de una capa se aprovecha en la propiedad de todos los demás.

La tarea inconclusa es extender ese principio hacia arriba. La identidad no debe ser inseparable de una aplicación. La reputación no debe quedar atrapada dentro de una base de datos. Las comunidades deberían poder contratar infraestructura sin transferir soberanía. La recomendación debe ser reemplazable. La moderación debe funcionar a través de poderes declarados y apelar. Los primeros ingenieros crearon un sustrato de comunicaciones abierto. La siguiente generación debe crear un sustrato institucional abierto.

1.2 Correo electrónico, foros, directorios y búsqueda

El correo electrónico es la demostración más clara de que la federación puede sobrevivir a escala global. Una persona puede enviar un mensaje a través de los límites de la organización sin que ambas partes pertenezcan al mismo proveedor. Los dominios permiten la administración local, mientras que los protocolos comunes preservan la interoperabilidad. Este modelo es menos elegante en la práctica que en los diagramas, pero se ha resistido a la propiedad completa de cualquier empresa durante décadas.

Su debilidad es igualmente instructiva. El correo electrónico permite el contacto no solicitado a un coste marginal extremadamente bajo. El remitente externaliza los costes de filtrado, almacenamiento, atención y seguridad a los destinatarios y proveedores. El estudio

Spamalytics encontró que una campaña podría seguir siendo económicamente viable a pesar de una tasa de conversión extraordinariamente baja porque millones de mensajes eran baratos de enviar a través de máquinas comprometidas (Kanich et al. 2009). Los sistemas de autenticación y reputación redujeron el abuso, pero también concentraron la potencia práctica en grandes proveedores capaces de operar filtros sofisticados e influir en la capacidad de entrega.

Usenet y los foros web crearon culturas locales más ricas. Su organización centrada en el tema preservó largas conversaciones y permitió que la reputación se acumulara dentro de un dominio. Un buen foro técnico podría convertirse en un archivo vivo más útil que cualquier manual formal. Sin embargo, la mayoría de los foros eran gobiernos privados. Los propietarios controlaban la base de datos y el dominio. Los moderadores interpretaban las reglas, a menudo sin apelación. Las comunidades pueden ser generosas y expertas, sin dejar de ser constitucionalmente frágiles.

Directorios como el catálogo inicial de Yahoo y el Proyecto Open Directory hicieron visible la selección. Los editores humanos clasificaron los sitios e implícitamente avalaron su relevancia. El modelo podría expresar juicio y contexto, pero no se escaló con la Web. Los editores se convirtieron en cuellos de botella, categorías endurecidas y las decisiones podrían ser capturadas por grupos pequeños. Sin embargo, el usuario podía ver que el directorio representaba una estructura editorial en lugar de un mapa objetivo de la realidad.

Los motores de búsqueda resolvieron la escala automatizando la selección. El análisis de enlaces y los grandes índices hicieron utilizable la Web, pero el ranking adquirió un papel político. Un motor de búsqueda no se limita a recuperar lo que existe. Asigna visibilidad, lo que a menudo determina si una fuente tiene existencia práctica para la mayoría de los usuarios. Introna y Nissenbaum argumentaron tempranamente que los motores de búsqueda favorecen inevitablemente ciertos sitios y valores, incluso cuando sus decisiones se presentan como relevancia técnica (Introna and Nissenbaum 2000).

Tabla 3. Lo que cada capa temprana resolvió y dejó sin resolver

Elemento	Significado o consecuencia de diseño
TCP/IP y diseño de extremo a extremo	Las redes heterogéneas conectadas y la dependencia limitada de los propietarios intermedios no crearon identidad social ni gobernanza comunitaria.
Email	Creó mensajes federados globales; expuso a los destinatarios al spam, la suplantación de identidad, la concentración de reputación y el abuso a un coste de envío insignificante.
Usenet y foros	Comunidades temáticas duraderas habilitadas; se basó en normas locales frágiles, propietarios, administradores y resolución de conflictos socialmente costosos.
Directorios	Hacer visible el juicio editorial humano; no logró escalar y creó poder en torno a la inclusión, las categorías y las facciones editoras.
Motores de búsqueda	El descubrimiento escalado a través de la Web; abierta hizo que la ranking sea un intermediario opaco entre la publicación y la visibilidad práctica.

El paso del directorio a la búsqueda cambió la apariencia de potencia. Las categorías humanas parecían subjetivas. Los resultados algorítmicos parecían descubiertos. Sin embargo, cada sistema de ranking elige señales, maneja la manipulación, define la frescura y equilibra los objetivos comerciales y públicos. La búsqueda también creó una industria adversarial. Los editores optimizaron para el sistema de ranking; el sistema de ranking adaptado a la optimización; el contenido abordaba cada vez más el clasificador antes que el lector.

El correo electrónico, los foros, los directorios y la búsqueda, por lo tanto, contienen el futuro completo en miniatura. La Federación conserva la salida pero atrae el abuso. Las comunidades locales producen conocimiento, pero pueden convertirse en oligarquías privadas. La curación humana proporciona contexto pero no puede cubrir todo. La ranking algorítmica se escala pero oculta el juicio. Ninguno de estos sistemas es un fracaso. Cada uno revela una compensación institucional diferente.

La ruptura social asociada con el “Provinto Eterno” hizo visible el problema de escalado ante las plataformas modernas. Las nuevas cohortes siempre habían entrado en Usenet y aprendieron sus normas, pero el acceso comercial convirtió una afluencia periódica en llegada masiva permanente. Los viejos participantes a menudo culpaban a los recién llegados, a veces con desprecio elitista, sin embargo, el problema más profundo era institucional: la incorporación, la moderación y la memoria no habían sido diseñadas para el crecimiento continuo. Las normas que solo pueden transmitirse a través de la tutoría de pacientes son vulnerables cuando las llegadas superan en número a los mentores.

El Open Directory Project más tarde intentó combinar el juicio editorial humano con el trabajo voluntario distribuido. Demostró que miles de editores podían mantener un catálogo público, pero también esa propiedad de categoría, revisión lenta y estándares desiguales podrían convertirse en cuellos de botella. Los motores de búsqueda desplazaron a los directorios no porque el juicio humano fuera inútil, sino porque la indexación automatizada podría cubrir órdenes de magnitud más materiales. El comercio era cobertura para la inspección.

El correo electrónico también se volvió operacionalmente más centralizado de lo que sugieren sus protocolos. Los servidores independientes siguen siendo posibles, pero la capacidad de entrega depende de la reputación, la autenticación, la respuesta al abuso y las relaciones con los principales proveedores. Un pequeño operador puede ajustarse a los estándares y aún así encontrar mensajes filtrados. Este es un patrón recurrente: protocolo abierto en la capa formal, confianza concentrada en la capa operativa. La cura no es negar la utilidad del filtrado profesional, sino hacer que sus reglas, portabilidad y apelaciones sean menos dependientes de unas pocas empresas.

La era de la plataforma no reemplazó a estos sistemas porque tenía una filosofía superior. Combinó sus funciones útiles detrás de una cuenta y una interfaz. La mensajería, la identidad, el descubrimiento, la reputación, la distribución y la monetización se hicieron más fáciles porque un operador podía coordinarlos. El coste de esa

conveniencia era que el operador también adquirió la potencia para redefinir cada función a la vez.

Capítulo 2: Plataformas y constituciones ocultas

Plataformas ganadas haciendo que Internet sea comprensible. Se volvieron peligrosos cuando la integración se convirtió en soberanía y cuando las comunidades descubrieron que la conveniencia se había comprado con identidad no portátil, reglas invisibles y dependencia del ranking privado.

2.1 Por qué ganaron las plataformas

La Web abierta pedía a los usuarios que ensamblaran su propio entorno. Necesitaban alojamiento, identidad, contactos, herramientas de publicación, descubrimiento, protección contra el spam y, a veces, sistemas de pago. Las plataformas integraron estas funciones y eliminaron la fricción técnica. Su éxito no fue prueba de que los usuarios prefirieran la dominación. Fue evidencia de que la coordinación tiene valor.

Los efectos de la red reforzaron el resultado. Un servicio de comunicación se vuelve más útil cuando los contactos ya están presentes. Un mercado atrae a los compradores porque los vendedores están presentes y los vendedores porque los compradores están presentes. Un recomendador mejora cuando observa más comportamiento. Un sistema de moderación se beneficia de la inteligencia de abuso compartida. Estos efectos hacen que los sistemas integrados sean difíciles de desafiar incluso cuando los competidores ofrecen mejores características individuales.

La computación móvil intensificó la centralización. Las aplicaciones distribuidas a través de tiendas controladas podrían combinar identidad, notificación, captura de medios, pagos y ubicación. El gráfico social pasó de los hipervínculos y las libretas de direcciones a las bases de datos propietarias. El usuario ya no navegaba entre sitios independientes tanto como permaneció dentro de un flujo

donde las fuentes externas se representaban como objetos de contenido.

La plataforma también cambió la Web en sí. Los sitios integraron los botones sociales, los servicios de análisis, publicidad, autenticación y entrega de contenido suministrados por un pequeño número de empresas. Helmond describe esto como hacer que los datos web estén “listos para la plataforma”: la Web abierta se convirtió en una superficie a través de la cual las plataformas podían extender sus estructuras de datos y modelos de negocio (Helmond 2015). El límite entre un sitio web y una plataforma se volvió poroso en una dirección. Los sitios independientes dependían de plataformas más que de las plataformas dependían de cualquier sitio.




Figura 3. Cómo la participación pública se convierte en un activo de plataforma privada cuando la identidad, las relaciones, los datos y la ranking se integran verticalmente.

La plataforma integrada resolvió el descubrimiento al poseer la relación de audiencia. Resolvió la identidad mediante la emisión de cuentas. Resolvió la moderación mediante la definición de los estándares de la comunidad. Resolvió la financiación a través de publicidad, suscripciones, tarifas o servicios basados en datos. Cada solución era operacionalmente racional. El problema constitucional apareció porque la misma empresa definió las reglas, las interpretó, controló la evidencia, operó el mecanismo de apelación y fue propietaria de los activos residuales.

Los términos de servicio proporcionaron permiso legal para el cambio unilateral, pero el consentimiento formal no creó legitimidad sustancial. Las personas invirtieron años en comunidades, empresas, audiencias y reputaciones que podrían ser alteradas por las decisiones de los productos. Desarrolladores contruidos sobre interfaces que podrían ser revalorizadas. Los moderadores mantuvieron espacios cuyos datos no poseían. Los creadores se adaptaron a sistemas de ranking que podrían cambiar sin explicación. La plataforma se comportó simultáneamente como propietario, legislatura, policía, tribunal, banco central y distribuidor de medios.

La complejidad interna de las corporaciones no debe ser ignorada. Los equipos de seguridad, moderadores, ingenieros, investigadores, ejecutivos, inversores y anunciantes pueden tener objetivos conflictivos. El daño no requiere una sola intención maliciosa. Las estructuras de gobierno pueden privilegiar repetidamente el crecimiento, la defensa legal y los ingresos, incluso cuando muchos empleados identifican el coste social. “La plataforma” se entiende mejor como una institución con una estructura objetiva dominante, no como una mente unificada.

La publicidad hizo que esta integración fuera especialmente poderosa. Una plataforma podría subvencionar el acceso gratuito, observar el comportamiento en todos los servicios y optimizar tanto la selección de contenido como la orientación comercial. Los mismos datos mejoraron la comodidad y el poder de mercado. Debido a que el modelo de negocio valoraba la predicción y la retención, la plataforma tenía una razón estructural para ampliar el número de comportamientos que podía observar y el tiempo que los usuarios pasaban dentro de su entorno. La vigilancia no fue simplemente una falla accidental de la privacidad; fue una infraestructura productiva.

Los incumplimientos reforzaron la concentración. La mayoría de los usuarios no cambian los navegadores, los proveedores de búsqueda, la configuración de privacidad o los permisos de la aplicación a menos que el coste del valor predeterminado se vuelva obvio. Control de los sistemas operativos, navegadores, tiendas de aplicaciones y botones de identidad, por lo tanto, se traduce en

potencia de distribución. Un servicio podría ser nominalmente cuestionable sin dejar de ser prácticamente dominante porque el cambio requería atención, conocimiento técnico y coordinación social.

El modelo de plataforma también convirtió a los editores externos en proveedores. Las organizaciones de noticias, los creadores y los comerciantes dependían de la distribución algorítmica mientras recibían información incompleta sobre las reglas. La relación se parecía a un mercado cuyo intercambio poseía al cliente, establecía el ranking, competía con los vendedores y cambiaba las tarifas a voluntad. Esto no hizo que todas las decisiones de la plataforma fueran abusivas, pero hizo que la negociación fuera estructuralmente asimétrica.

La lección no es que la integración debe estar prohibida. Las experiencias integradas son valiosas, y la mayoría de los usuarios no gestionarán docenas de servicios técnicos independientes. La cuestión del diseño es si la integración requiere propiedad. Una comunidad debe ser capaz de delegar el alojamiento, la búsqueda, los pagos o la moderación de herramientas sin renunciar a su identidad y archivo. Un usuario debería poder cambiar de recomendador sin abandonar los contactos. La plataforma debería convertirse en una capa de servicio reemplazable en lugar de un territorio soberano.

2.2 Captura corporativa, poder de los moderadores y trabajo gratuito

La participación digital produce varios tipos de valor a la vez. Publicaciones y videos atraen audiencias. Las calificaciones mejoran la búsqueda. Las relaciones sociales aumentan la retención. La moderación mantiene los espacios utilizables. Los rastros de comportamiento mejoran la orientación y la predicción. La plataforma suministra infraestructura que hace que estas contribuciones sean combinables, pero la propiedad convencional asigna el activo acumulado casi en su totalidad a la empresa.

El relato de Terranova sobre la mano de obra libre sigue siendo útil porque identifica la integración de la producción cultural voluntaria

en los sistemas (Terranova 2000) comerciales. El término no debe implicar que cada contribución no pagada sea empleo disfrazado. Las personas contribuyen por placer, identidad, reputación, aprendizaje, ayuda mutua y propósito público. La explotación se hace visible cuando la institución se basa en estos motivos mientras niega a los contribuyentes la voz duradera, la portabilidad y la participación en el valor que crea su interdependencia.

El trabajo moderador es un ejemplo concentrado. Los voluntarios interpretan las reglas, detectan el fraude, median en conflictos y absorben el abuso. Matías describe esto como trabajo cívico porque crea condiciones para la participación colectiva (Matias 2019). Las plataformas a menudo celebran a la comunidad mientras tratan a las personas que la mantienen como usuarios reemplazables. El acuerdo puede ser mutuamente beneficioso, pero se vuelve inestable cuando los moderadores tienen responsabilidad sin derechos ni recursos.

Tabla 4. Centros de poder distintos dentro de una comunidad de plataforma

Elemento	Significado o consecuencia de diseño
Empresa de plataforma	Posee infraestructura, cuentas, acceso a datos, monetización, posibilidades técnicas y la máxima autoridad de elaboración de reglas.
Fundador o grupo ejecutivo	Puede establecer la misión y la estrategia, pero puede retener los poderes de emergencia o el control de la misión sin legitimación periódica.
Moderador voluntario	Controla la interpretación local y el acceso diario, a menudo con poco salario, apoyo, supervisión u orientación procesal.
Facción organizada	Puede dominar las consultas, el voto, la presentación de informes y las normas sociales a través de la persistencia en lugar del apoyo representativo.
Anunciante o proveedor de modelos	Influye en los objetivos de optimización y la visibilidad indirectamente a través de la dependencia de ingresos, el acceso a datos o el bloqueo técnico.
Miembro ordinario	Crea atención, relaciones, contenido y cultura, mientras que generalmente tiene derechos débiles sobre el activo colectivo resultante.

La captura de los moderadores es, sin embargo, real. La permanencia prolongada, el control sobre los nombramientos, los canales privados de coordinación y las apelaciones débiles pueden convertir la custodia en oligarquía. La investigación sobre producción entre pares ha encontrado que la apertura nominal no impide que grupos de liderazgo duraderos consoliden autoridad (Shaw and Hill 2014). Cierta concentración es funcional; las personas experimentadas conocen la historia y pueden responder con rapidez. El problema no es la jerarquía en sí misma, sino la jerarquía sin rotación, auditoría, jurisdicción declarada o una vía creíble para impugnar decisiones.

El poder corporativo y el poder moderador interactúan. Las empresas pueden delegar decisiones difíciles a los voluntarios mientras conservan el derecho a anularlas. Los moderadores pueden utilizar la política de la empresa para legitimar las preferencias locales. Los usuarios experimentan el resultado combinado como un sistema opaco a pesar de que la autoridad está fragmentada. Por lo tanto, la reforma debe establecer límites claros: qué reglas pertenecen a la marca compartida, cuáles a las comunidades locales, cuáles de los proveedores de infraestructura y qué derechos permanecen con los miembros individuales.

El pago por sí solo no resuelve la captura. Una plataforma podría pagar a los creadores o moderadores mientras preserva el control unilateral. Los pequeños pagos por datos pueden legitimar una extracción más profunda convirtiendo la membresía en una serie de microtransacciones. La justicia económica importa, pero el déficit central es constitucional. Las personas necesitan derechos exigibles con respecto a los cambios de reglas, el uso de datos, la reputación, los archivos y la salida.

La competencia por sí sola también es insuficiente. Una elección entre varias plataformas cerradas es una elección entre las constituciones privadas. La competencia se vuelve poderosa cuando el cambio preserva la identidad, las relaciones y la historia. La portabilidad debe incluir la continuidad social, no simplemente un archivo descargable. De lo contrario, la salida se asemeja a abandonar una ciudad y dejar atrás cada relación.

La diferencia entre la exportación de datos y la portabilidad merece énfasis. La exportación a menudo produce un archivo estático útil para la copia de seguridad personal pero inútil para la continuidad. Portabilidad significa que otro servicio puede interpretar los datos, preservar identificadores, restablecer permisos y continuar las relaciones con el consentimiento. La portabilidad social es más difícil aún porque los seguidores y los miembros del grupo deben ser capaces de reconocer el movimiento. Por lo tanto, los estándares deben cubrir no solo los formatos de archivo, sino también la resolución de identidad, las pruebas de relación, el historial de moderación y la revocación.

Las interfaces de programación de aplicaciones pueden crear aparente apertura mientras se preserva la dependencia. El acceso puede ser limitado, revalorizado o retirado; los datos exportados pueden omitir señales de ranking y contexto social; los clientes de terceros pueden permanecer subordinados a un sistema de cuenta. La competencia genuina requiere que la interoperabilidad sea un derecho o una propiedad arquitectónica, no un programa de negocios discrecional.

El gobierno corporativo añade otra capa. Los ejecutivos a menudo son legal y financieramente responsables ante las juntas e inversores en lugar de los usuarios que crearon el capital social de la comunidad. Las corporaciones de beneficios, los fideicomisos de administración, las cooperativas y los deberes de interés público pueden modificar esta alineación, pero la forma legal por sí sola es insuficiente. La capacidad técnica para salir y la capacidad constitucional para impugnar las decisiones deben acompañar a cualquier promesa de misión.

La alternativa constructiva es separar la recompensa de la soberanía. Los fundadores y los inversores pueden recibir rendimientos económicos limitados. Los operadores pueden ser pagados por infraestructura. Los moderadores pueden ser compensados por un trabajo difícil. Los contribuyentes pueden recibir reputación, participaciones en los ingresos o derechos de gobierno. Ninguna de estas funciones debería conferir automáticamente autoridad permanente sobre toda la institución. La comunidad compartida

debe existir legal y técnicamente aparte de cualquier proveedor de servicios.

Capítulo 3: El adversario humano

Los Internet no inventaron la crueldad, el fraude, el tribalismo o la competencia de estatus. Cambió su coste, velocidad, escala y visibilidad. Cualquier arquitectura futura que asuma buena voluntad será capturada por aquellos dispuestos a explotarla.

3.1 Anonimato, desinhibición, troleo y abuso coordinado

El anonimato a menudo se discute como una elección binaria entre libertad y responsabilidad. En la práctica, la identidad en línea tiene muchas dimensiones: nombre legal, seudónimo persistente, reputación, membresía, dirección técnica e historia de relaciones. Una persona puede ser anónima al público mientras es responsable ante una comunidad, o públicamente nombrada mientras opera a través de cuentas desechables. Un buen diseño separa estas dimensiones en lugar de forzar la identificación universal.

El valor protector de la seudonimidad es sustancial. Los disidentes políticos, sobrevivientes de abuso, pacientes, empleados y miembros de grupos estigmatizados pueden necesitar hablar sin vincular cada declaración a una identidad legal. Los sistemas de nombre real obligatorios pueden transferir el riesgo de los agresores a los objetivos. Sin embargo, la identidad de bajo coste también dificulta la exclusión. Un actor prohibido puede regresar, un grupo coordinado puede simular consenso y una botnet puede multiplicar los participantes aparentes.

El marco de desinhibición en línea de Suler distinguió la apertura benigna de la desinhibición tóxica e identificó el anonimato, la invisibilidad, la asincronicidad y el debilitamiento de la autoridad como condiciones relevantes (Suler 2004). Trabajos posteriores conectaron el troleo con rasgos sádicos y manipuladores, pero la investigación experimental también encontró efectos situacionales.

Los participantes expuestos a un estado de ánimo negativo y a discusiones hostiles se volvieron más propensos a publicar material abusivo (Buckels, Trapnell, and Paulhus 2014; Cheng et al. 2017). La arquitectura no se limita a revelar el carácter; moldea el comportamiento.




Figura 4. Un bucle de toxicidad recurrente: la provocación produce reacción, la reacción se convierte en una señal de ranking y la exposición repetida cambia las normas locales.

El trolling es solo un patrón contradictorio. El spam explota la distribución barata. La brigada importa una audiencia organizada a una disputa local. El acoso coordina el contacto repetido entre cuentas y servicios. El astroturfing simula el apoyo público independiente. Los bots sociales amplifican el material o fabrican actividad aparente. Las operaciones de influencia combinan personas, contenido específico, tiempo y narrativas multiplataforma. Estos comportamientos difieren en propósito y requieren diferentes respuestas.

La ventaja de la escala generalmente pertenece al atacante. Una persona puede crear miles de mensajes; cada destinatario debe decidir si un mensaje es genuino. Un atacante puede probar muchas identidades; un defensor debe preservar el acceso para los recién llegados legítimos. Una acusación falsa se puede repetir instantáneamente; un objetivo debe recopilar evidencia a través de sistemas fragmentados. Esta asimetría explica por qué la moderación puramente local a menudo falla contra el abuso coordinado.

La reputación ayuda solo cuando es costoso reconstruir y relevante para el contexto. Una puntuación universal de reputación crearía autoridad de vigilancia y transferencia a través de dominios no relacionados. La reputación contextual es más segura: un largo historial en una comunidad de apoyo médico no debe conferir poder en un debate político, y una credencial profesional verificada no debe borrar la evidencia de mala conducta. Los sistemas necesitan relaciones persistentes sin construir un sistema de crédito social universal.

La fricción no es, por lo tanto, el enemigo de la libertad. La fricción cuidadosamente colocada puede protegerla. Las nuevas cuentas pueden recibir límites de tasa más bajos. Las invitaciones masivas pueden requerir aprobación. Las apelaciones pueden requerir una explicación corta en lugar de un solo clic enojado. Las acciones de alto riesgo pueden requerir credenciales más fuertes. El objetivo no es dificultar la participación, sino hacer que el abuso a gran escala sea más caro que el uso humano ordinario.

La competencia de estatus intensifica estas dinámicas. Los recuentos de seguidores públicos, el karma, las insignias y las métricas virales convierten la interacción en una jerarquía visible. Estas señales pueden recompensar la experiencia y la contribución sostenida, pero también crean incentivos para la certeza performativa, la lealtad de las facciones y la humillación de los rivales. El anonimato no elimina el estado; reubica el estado en historiales de cuenta y reconocimiento local.

El problema Sybil es, por lo tanto, social tanto como criptográfico. Requerir una identidad legal por cuenta puede reducir la duplicación, pero crea vigilancia y exclusión. Los sistemas de prueba de personal pueden establecer la singularidad y no establecer la buena voluntad o la competencia. Las introducciones confiables y las credenciales específicas de la relación a menudo proporcionan una respuesta más proporcionada. La pregunta no es “¿Es esto un humano real?”, sino “¿Qué derecho tiene este actor a realizar esta acción en este contexto?”

El acoso entre servicios expone la debilidad de la aplicación aislada. Una comunidad puede prohibir a un actor mientras que otra proporciona un área de preparación. Una víctima puede necesitar documentar docenas de cuentas en todos los servicios. Las señales de abuso compartido pueden ayudar, pero corren el riesgo de crear listas negras opacas. Un mejor sistema comparte evidencia firmada, alcance y vencimiento, al tiempo que deja las decisiones finales a las comunidades receptoras bajo sus propios procedimientos.

Un adversario Internet también debe distinguir el error de la malicia. La detección excesivamente agresiva puede excluir a los recién llegados, los dialectos minoritarios, la ironía y el habla controvertida. Los sistemas automatizados son útiles para el triaje y los patrones obvios, pero las sanciones sensibles al contexto requieren juicio humano y garantías procesales. Un sistema que bloquea cada riesgo se convierte en un sistema en el que solo los actores establecidos pueden hablar.

3.2 La moderación como gobierno

La moderación se describe a menudo como el servicio de limpieza, como si las reglas simplemente eliminaran la suciedad de un espacio neutral. El trabajo de Gillespie muestra que la moderación define la propia plataforma. Las decisiones sobre el discurso aceptable, la ranking, la integridad de la cuenta y la recomendación determinan qué tipo de público existe (Gillespie 2018). Incluso una lista cronológica requiere reglas sobre spam, duplicados, identidad y eliminación.

La moderación legítima comienza con la jurisdicción. Un proveedor de infraestructura global debe intervenir contra malware, fraude a gran escala y abuso grave entre comunidades. Una comunidad local debe definir el tema, el tono, la experiencia y las expectativas culturales. Una marca compartida puede imponer derechos mínimos y normas de seguridad. Cuando estas capas se colapsan, el desacuerdo local se convierte en una crisis en toda la plataforma y la política de plataforma se convierte en un pretexto para la dominación local.

Las reglas deben ser lo suficientemente comprensibles como para guiar la conducta. Las políticas extremadamente detalladas a menudo crean la apariencia de precisión al tiempo que aumentan la dependencia de la interpretación interna. Las políticas extremadamente vagas permiten la aplicación arbitraria. La solución práctica es una capa constitucional concisa, reglas locales y un cuerpo de precedentes anónimos que muestran cómo se resolvieron los casos recurrentes.

Tabla 5. Los patrones adversariales requieren respuestas diferentes

Elemento	Significado o consecuencia de diseño
Trolling y acoso	Limite la recompensa social, preserve la evidencia a través de los incidentes, proteja los objetivos y aplique sanciones graduadas con apelación.
Spam y botnets	Utilice los límites de tasa, la reputación del remitente, la prueba de relación y la fricción económica o computacional proporcional a la escala.
Brigada	Detecte la llegada coordinada y el voto importado sin tratar a todas las coaliciones impopulares como ilegítimas.
Operaciones de Astroturfing e influencia	Divulgar patrocinio, analizar la coordinación, preservar la incertidumbre de la atribución y separar la operación del impacto reclamado.
Granjas de contenido sintético	Reduzca las recompensas por volumen, requiera procedencia o patrocinio, y penalice el engaño sistemático en lugar de la automatización en sí misma.
Agentes personales comprometidos	Limitar las capacidades, aislar secretos, registrar la autoridad delegada y hacer que las acciones de alto impacto sean revocables y revisables.

El procedimiento no es decoración burocrática. Los usuarios tienen más probabilidades de entender y aceptar la moderación cuando se ofrecen razones, incluso cuando no les gusta el resultado (Jhaver, Bruckman, and Gilbert 2019). Las apelaciones revelan errores, identifican reglas poco claras y limitan las represalias personales. También imponen costes. Un sistema maduro utiliza revisión proporcional: corrección automática de errores obvios, apelación

local para casos ordinarios y revisión independiente para disputas graves o constitucionales.

Los moderadores necesitan protección y supervisión. Pueden enfrentar amenazas, contenido traumático, quejas coordinadas y presión de miembros influyentes. El voluntariado no debe ocultar el trabajo peligroso. Las comunidades que dependen de la moderación deben financiar la capacitación, la rotación, el apoyo a la salud mental y las herramientas seguras. Un moderador obligado a elegir entre el agotamiento y el abandono no puede proporcionar una gobernanza estable.

Los experimentos sobre la intervención de la plataforma complican la afirmación de que la aplicación simplemente impulsa el abuso en otros lugares. Las prohibiciones 2015 de Reddit se asociaron con reducciones sustanciales en el discurso de odio entre los usuarios afectados sin evidencia clara de migración equivalente a comunidades adyacentes (Chandrasekharan et al. 2017). El resultado no justifica toda prohibición. Demuestra que los límites pueden cambiar el comportamiento y que las instituciones no necesitan aceptar la toxicidad como una expresión inmutable de la demanda.

El riesgo más profundo es la captura constitucional. Una clase moderadora puede llegar a ser permanente. Un fundador puede retener el poder de emergencia indefinidamente. Un contribuyente rico puede dominar porque el proyecto depende de la financiación. Una facción organizada puede inundar todas las consultas. El voto formal no resuelve automáticamente estos problemas porque la participación es desigual y las minorías intensas pueden durar más que los miembros ordinarios.

Un diseño más robusto utiliza poderes separados. La reglamentación, la ejecución, las apelaciones, las decisiones de tesorería y la administración técnica no deben ser controladas por las mismas personas. Los términos deben ser limitados. Los conflictos de intereses deben ser declarados. Los paneles seleccionados o rotativos pueden complementar las elecciones. Las acciones de emergencia deben expirar a menos que se ratifique. Los registros de auditoría deben hacer visibles los patrones sin exponer a las víctimas privadas.

La escala cambia el proceso apropiado. Un grupo pequeño puede discutir un caso de forma síncrona y confiar en la memoria compartida. Una red con millones de usuarios necesita triaje, evidencia estandarizada, delegación y auditoría estadística. La automatización se vuelve inevitable, pero debe recomendar y priorizar en lugar de convertirse en juez final en casos ambiguos. Los sistemas de alto volumen deben publicar tasas de error, resultados de apelación y disparidades entre idiomas o comunidades.

La inteligencia artificial puede ayudar a la moderación agrupando el comportamiento coordinado, traduciendo informes, identificando precedentes y redactando razones. También puede magnificar el sesgo y crear confianza falsa. Un modelo de lenguaje que genera una explicación plausible después de que un clasificador opaco ha actuado puede hacer que el sistema parezca más legítimo sin hacerlo más correcto. Las explicaciones deben estar relacionadas con la evidencia y las reglas reales, no simplemente retóricamente satisfactorias.

La legitimidad de un sistema de moderación también depende del tratamiento de los observadores. Las explicaciones públicas enseñan normas a todos los que las ven. La aplicación secreta deja a la comunidad para inferir reglas de rumores. La privacidad limita la divulgación en casos de acoso y seguridad, pero los precedentes anónimos pueden mostrar patrones sin exponer a las víctimas. Con el tiempo, este cuerpo de decisiones se convierte en un derecho común de la comunidad.

El punto no es imitar a un Estado-nación en cada foro. Los grupos pequeños necesitan instituciones ligeras. El principio es la proporcionalidad: a medida que crecen las consecuencias de las decisiones, también debería hacerlo la calidad del procedimiento. Un grupo de pasatiempos puede confiar en administradores de confianza. Un sistema de conocimiento global, una red política o un mercado profesional no pueden afirmar plausiblemente que la discreción de un propietario es suficiente gobierno.

Capítulo 4: La relevancia es una constitución

El poder decisivo del moderno Internet a menudo no es el poder de eliminar el habla, sino el poder de hacer que algún discurso sea prácticamente inevitable y otro discurso prácticamente invisible. La ranking es la gobernanza por probabilidad.

4.1 Búsqueda, flujos, interacción y deriva hacia la idiocracia

Un sistema de ranking traduce un objetivo social en señales medibles. Los motores de búsqueda estiman la relevancia a través de texto, enlaces, autoridad, frescura, ubicación y muchos otros factores. Los flujos sociales estiman la probabilidad de interacción. Los recomendadores predicen la preferencia. Cada sistema puede ser técnicamente excelente al tiempo que incorpora valores contables.

El error central es confundir la respuesta conductual con la preferencia reflexiva. Una persona puede hacer clic porque un artículo es útil, impactante, ofensivo, sexualmente provocativo, aterrador o difícil de ignorar. Un comentario puede expresar gratitud o enojo. El tiempo pasado puede indicar fascinación o confusión. Cuando estas señales se agregan en acoplamiento, el sistema pierde el significado del comportamiento mientras conserva su intensidad.

La investigación sobre la atención colectiva muestra que los ciclos de información se han acelerado, aumentando la competencia por un recurso humano finito (Lorenz-Spreen et al. 2019). Los creadores se adaptan produciendo material más frecuente, emocionalmente legible y estratégicamente empaquetado. Las plataformas observan el comportamiento generado por su propia ranking y lo utilizan como evidencia para el siguiente ranking. El recomendador no es un espejo pasivo. Crea parte de la distribución de preferencias que más tarde afirma detectar.




Figura 5. Cuando la reacción medible sustituye al valor reflectante, la relevancia se convierte en una máquina para seleccionar contenido simplificado y conflictivo.

La ley de Goodhart a menudo se invoca libremente, pero el proceso relevante es claro. Una vez que una métrica se convierte en un objetivo, los participantes optimizan para ello. El título se convierte en un dispositivo de clic. Los primeros segundos se convierten en ingeniería de retención. La indignación se convierte en un formato reutilizable. La métrica selecciona no solo los elementos individuales, sino también los tipos de creadores e instituciones capaces de sobrevivir.

Este es el mecanismo detrás de la deriva hacia la “idiocracia”. El contenido complejo no es inherentemente impopular, y los usuarios no prefieren universalmente tonterías. Pero la complejidad a menudo requiere contexto y recompensa retrasada, mientras que los sistemas de ranking favorecen las señales disponibles de inmediato. Por lo tanto, el sistema compara el valor a largo plazo de un elemento con el estímulo inmediato de otro y llama al ganador relevante.

El efecto es más fuerte donde los costes de producción difieren radicalmente. Los informes de investigación, la síntesis científica y la crítica cuidadosa son costosos. Un rumor, un clip copiado o una provocación sintética es barato. Si ambos compiten por el mismo pago de interacción, el contenido de bajo coste puede inundar el mercado. La regeneración AI aumenta esta asimetría al reducir aún más el coste de producción y dejar la verificación costosa.

La regulación puede requerir divulgación y flujos alternativos, pero la transparencia sobre los “parámetros principales” no es lo mismo que el control del usuario (European Union 2022). Una plataforma puede publicar una descripción amplia preservando un modelo inaccesible e incentivos mixtos. El remedio más fundamental es la recomendación plural: las clasificaciones cronológicas, basadas en relaciones, curadas por expertos, de búsqueda de diversidad, comunidad local y personal-agente deberían poder coexistir sobre los datos portátiles.

La personalización añade un bucle de retroalimentación. El sistema infiere que a un usuario le gusta un tema, aporta más, observa una mayor interacción porque las alternativas son menos visibles y trata el resultado como confirmación. Con el tiempo, el modelo puede confundir la exposición con la preferencia y la preferencia con la identidad. El usuario se vuelve más fácil de predecir en parte porque el sistema ha reducido el entorno.

El sesgo de popularidad opera de manera similar en el plano colectivo. Los elementos que reciben exposición temprana acumulan interacción, lo que produce más exposición. La jerarquía resultante puede parecer meritocrática incluso cuando las diferencias iniciales fueron pequeñas o arbitrarias. Los usuarios orientados a nichos pierden descubrimiento, y los creadores se adaptan hacia formatos ya exitosos. La investigación sobre recomendadores evalúa cada vez más diversidad, calibración y equidad porque la precisión por sí sola no puede describir estos efectos (Burke, Sonboli, and Ordonez-Gauger 2018).

Las métricas alternativas son posibles. Un sistema puede optimizar la satisfacción a largo plazo en lugar de la respuesta inmediata, medir si los usuarios lamentan las sesiones, recompensan la diversidad de fuentes o reservan la capacidad de exploración. Sin embargo, cada alternativa sigue siendo una opción de valor y puede ser jugada. La solución no es el descubrimiento de una métrica perfecta, sino la competencia entre las políticas de ranking declaradas combinadas con el control del usuario y la auditoría independiente.

La relevancia debe ser tratada como una reclamación con un autor. En lugar de presentar un ordenamiento como la superficie natural del mundo, los sistemas deben indicar lo que optimiza el ranking, cuyos intereses representa, qué datos utiliza y qué alternativas existen. Esto no elimina el juicio. Hace que la sentencia sea impugnabile.

4.2 Desinformación, cámaras de eco y manipulación electoral

“Fake news” es una categoría inestable que cubre historias fabricadas, encuadres engañosos, sátira, propaganda, medios manipulados y errores ordinarios (Tandoc, Lim, and Ling 2018). La política se confunde cuando estos fenómenos se tratan como un único objeto técnico. Una afirmación factual falsa requiere corrección; el engaño coordinado requiere atribución; la selección partidista puede requerir fuentes plurales; la sátira puede requerir contexto en lugar de eliminación.

El estudio Science de Vosoughi, Roy y Aral encontró que las historias falsas en Twitter se difundieron más, más rápido y más ampliamente que las historias reales en el conjunto de datos examinado, con un comportamiento humano que contribuyó más a la diferencia que los bots (Vosoughi, Roy, and Aral 2018). El resultado es importante, pero no una ley universal. Tema, plataforma, tiempo y definiciones son importantes. La exposición a fuentes poco fiables a menudo se concentra entre una minoría de usuarios altamente comprometidos en lugar de distribuirse uniformemente en toda la población (Grinberg et al. 2019; Guess, Nyhan, and Reifler 2020).

Las cuentas automatizadas aún pueden dar forma a la difusión. Los estudios han encontrado bots sociales involucrados en la amplificación temprana del contenido de baja credibilidad, lo que aumenta la probabilidad de que los humanos lo encuentren y redistribuyan (Shao et al. 2018). La unidad significativa a menudo no es el bot aislado, sino el sistema coordinado: cuentas, narrativas, tiempo, publicidad, influenciadores y medios externos se refuerzan entre sí.

La manipulación de las elecciones debe ser analizada como una cadena causal. Una operación puede existir. Una audiencia puede estar expuesta. Las actitudes o el comportamiento pueden cambiar. El cambio puede alterar la participación, la agenda, las donaciones o los votos. El resultado electoral final puede cambiar. La evidencia es más fuerte cerca del principio y se vuelve más incierta en cada paso. La ausencia de prueba en el paso final no hace que la operación sea inofensiva; la evidencia de la operación no prueba el paso final.

Tabla 6. Las afirmaciones sobre la influencia política deben permanecer diferenciadas

Elemento	Significado o consecuencia de diseño
Existía una operación	A menudo se puede establecer a través de cuentas, archivos, infraestructura, financiación, coordinación e investigaciones de plataforma o estado.
La gente estaba expuesta	Requiere medición del alcance, la frecuencia, la composición de la audiencia, la duplicación multiplataforma y la información competitiva.
Las creencias cambiaron	Requiere evidencia causal, no solo correlaciones entre la exposición y la preferencia política previa.
Comportamiento cambiado	Puede preocupar el intercambio, la participación, la donación, la atención de la agenda, la intimidación o la desconexión; cada uno necesita un diseño separado.
Un resultado electoral ha cambiado	Por lo general, no se puede inferir de la existencia o escala de una operación porque el contrafáctico electoral necesario es inobservable.

La campaña de Internet Research Agency durante las elecciones de 2016 en Estados Unidos está documentada en detalle por la investigación del Senado. Usó redes sociales para explotar divisiones, suplantar grupos e influir en el discurso político (United States Senate Select Committee on Intelligence 2019). La investigación estableció intención y actividad. No podía observar la elección contrafactual sin la campaña. Las afirmaciones de que la operación cambió con certeza al ganador van más allá de la evidencia disponible.

La microsegmentación tiene límites similares. La orientación psicológica puede mejorar la respuesta en condiciones

experimentales (Matz et al. 2017), pero los efectos persuasivos de las campañas en elecciones generales suelen ser pequeños (Kalla and Broockman 2018). La segmentación puede importar, aun así, mediante movilización, recaudación de fondos, formación de agenda o refuerzo acumulativo. La posición intelectualmente honesta no es ni el descarte ni la creencia mágica en el control mental.

Las cámaras de eco añaden una dimensión estructural. La investigación multiplataforma encuentra homofilia y exposición agrupada, pero la fuerza difiere según la plataforma (Cinelli et al. 2021). El remedio propuesto para mostrar contenido opuesto puede ser contraproducente cuando los usuarios lo perciben como una amenaza de identidad hostil (Bail et al. 2018). Una política de diversidad creíble debería introducir desacuerdos a través de fuentes confiables, hechos compartidos, incertidumbre y razones, no a través de la máxima provocación.

El ecosistema mediático se extiende más allá de las plataformas sociales. La televisión, los medios partidistas, los influencers, las élites políticas y los motores de búsqueda pueden originar o legitimar narrativas que las redes sociales aceleran después. Benkler, Faris y Roberts sostienen que las estructuras mediáticas y el comportamiento de las élites fueron centrales para el entorno estadounidense de desinformación, lo que complica las explicaciones que asignan la causalidad primaria a bots extranjeros aislados o a la credulidad individual (Benkler, Faris, and Roberts 2018).

La manipulación a menudo busca la incertidumbre más que la creencia. Inundar el medio ambiente con afirmaciones incompatibles puede hacer que los ciudadanos concluyan que ninguna fuente es confiable y que la verificación no tiene sentido. Esta estrategia se beneficia de la falsa equivalencia entre el escepticismo saludable y el cinismo universal. Por lo tanto, las instituciones deben comunicar cómo se produjo el conocimiento, qué sigue siendo incierto y qué procedimientos pueden corregir el error.

La prebunkening y la fricción pueden complementar la corrección. Advertir a los usuarios sobre técnicas comunes de manipulación, retrasar la rápida redistribución o pedir una interacción contextual

mínimo puede reducir la difusión impulsiva sin crear un ministerio central de la verdad. Estas medidas deben ser probadas para efectos reales del comportamiento y monitoreadas por cargas desiguales.

Las correcciones funcionan de manera imperfecta, pero no son inútiles. Los metaanálisis encuentran que la refutación puede reducir creencias falsas, con una eficacia que depende del diseño del mensaje, la repetición y la audiencia (Chan et al. 2017; Walter and Murphy 2018). La dificultad es que la corrección compite en un entorno que recompensa la novedad original. Por lo tanto, el diseño institucional debe cambiar los incentivos de distribución, no simplemente adjuntar verificaciones de hechos después de la viralidad.

Capítulo 5: La web sintética y Internet que todavía funciona

El AI generativo aumenta tanto la capacidad productiva de Internet como la incertidumbre de cada encuentro. El peligro no es que las máquinas hablen. Es que la procedencia, la responsabilidad y el coste de la verdad se desconectan del volumen del habla.

5.1 Teoría del Internet Muerto, bots y abundancia generativa

La teoría de los muertos Internet se hizo popular porque dio forma dramática a una experiencia genuina: publicaciones repetidas, interacción vacío, artículos copiados, respuestas de bots, imágenes sintéticas y resultados de búsqueda optimizados para otras máquinas. Su afirmación más fuerte, de que la mayoría de la vida en línea ya ha sido reemplazada por un sistema artificial coordinado, carece de evidencia creíble. Su afirmación más débil describe una transición real hacia la producción y la mediación automatizadas.

Los bots no son intrínsecamente engañosos. Los rastreadores de búsqueda, los servicios de monitoreo, las herramientas de accesibilidad, los traductores y los agentes personales son participantes automatizados. Las distinciones relevantes son si se declara la automatización, si existe un operador responsable, si el sistema simula humanos independientes y si su escala impone costes a otros. Un agente beneficioso puede llegar a ser abusivo cuando ignora los límites de tarifas o extrae comunidades enteras sin consentimiento.

Los sistemas generativos cambian la economía del contenido. Pueden traducir, resumir, tutorizar, ayudar a la programación y hacer que el conocimiento especializado sea más accesible. También pueden producir miles de variaciones en un formato rentable, fabricar revisiones, hacerse pasar por voces locales y llenar índices de búsqueda con redundancia plausible. El coste promedio de producir

una afirmación se aproxima a cero, mientras que el coste de verificarla no.




Figura 6. La procedencia puede establecer el origen y la historia de la transformación; no puede por sí misma establecer la verdad, la calidad o la legitimidad.

Los estándares de procedencia como C2PA pueden registrar afirmaciones firmadas sobre el origen y la historia de transformación de los medios. Son útiles porque hacen que la manipulación y la atribución sean más inspeccionables. No determinan la verdad. Una declaración falsa firmada sigue siendo falsa, y el material auténtico sin firmar puede seguir siendo valioso. La procedencia es una capa de integridad, no un oráculo (C2PA 2026).

La contaminación de datos recursivos añade un riesgo técnico. Shumailov y sus colegas demostraron que los modelos entrenados repetidamente en datos generados por modelos pueden perder información sobre la distribución original y eventualmente colapsar bajo ciertas condiciones (Shumailov et al. 2024). Los datos sintéticos pueden ser útiles cuando se generan cuidadosamente y se mezclan con originales fiables. La advertencia se refiere a la sustitución incontrolada de la evidencia humana por los productos derivados de productos anteriores.

La versión social de esta recursión puede ser más importante. La gente escribe para los sistemas de ranking. Los modelos se entrenan en material clasificado. Los agentes resumen el contenido en forma de modelo. Los creadores optimizan para los resúmenes de los agentes. La comunicación se vuelve cada vez más indirecta. La

intención humana permanece presente, pero se filtra a través de capas que recompensan la compatibilidad con otras máquinas.

La respuesta no debe ser una prohibición universal del contenido sintético. Debe requerir automatización declarada, operadores responsables, límites de tarifas, procedencia cuando sea apropiado y políticas de ranking separadas para la producción humana y de máquinas. Las comunidades pueden crear razonablemente espacios donde solo los miembros humanos verificados pueden iniciar la discusión mientras permiten que los agentes ayuden a esos miembros en privado.

La abundancia sintética también desestabiliza la evidencia social ordinaria. Una fotografía, un estilo testimonial o conversacional una vez transmitió señales débiles pero útiles del esfuerzo humano. Esas señales ahora se pueden reproducir a bajo precio. Las comunidades necesitarán formas más fuertes de continuidad: relaciones persistentes, procedencia firmada, procesos editoriales conocidos y reputaciones ganadas a través del tiempo. Ninguno es infalible, pero juntos aumentan el coste de fabricar un mundo social entero.

Los motores de búsqueda y los asistentes se enfrentan a una difícil elección. Excluir todo el material generado por máquina descartaría traducciones, resúmenes y herramientas útiles. El tratamiento de todo el material de manera idéntica permite dominar el volumen. Por lo tanto, la ranking debe considerar el origen, la responsabilidad, la novedad y la duplicación. Mil parafrases derivadas de una fuente no deberían crear mil votos independientes.

Los agentes personales pueden convertirse en remedio y fuente de contaminación. Pueden filtrar material repetitivo y rastrear afirmaciones a los originales, pero también pueden generar respuestas automáticas, negociar con otros agentes y llenar canales con comunicación máquina a máquina. Los protocolos deben hacer explícito el estado de agente y el principal responsable para que las comunidades puedan decidir qué participación automatizada aceptan.

El Internet permanece vivo cuando las personas pueden identificar fuentes significativas, formar relaciones duraderas y crear artefactos

que retienen el valor fuera de un flujo. La amenaza no es la cantidad sola. Es la pérdida de caminos confiables de reclamo a fuente, de acción a actor responsable, y de comunidad a una historia compartida que no se puede regenerar a pedido.

5.2 Wikipedia, código abierto, ciencia y bienes comunes duraderos

Un libro sobre el fallo Internet debe explicar los sistemas que funcionaron. Wikipedia, software de código abierto, OpenStreetMap, colaboración científica y comunidades especializadas demuestran que la cooperación a gran escala no es una excepción romántica. Son logros institucionales con características de diseño específicas.

Wikipedia combina la editabilidad radical con la trazabilidad extensa. Cada cambio puede ser inspeccionado e invertido. La discusión está vinculada a los artículos. Las fuentes importan más que la autoridad personal en principio, y las disputas dejan un registro. La comparación temprana de Nature con la Enciclopedia Británica fue impugnada, pero estableció que la producción colaborativa podría alcanzar un nivel digno de comparación seria (Giles 2005).

Sus dificultades revelan el coste del éxito. Los sistemas antivandalismo y las normas densas protegen la calidad, pero aumentan la carga para los recién llegados. Halfaker y sus colegas vincularon el descenso en la retención de editores en parte con el rechazo cada vez más eficiente de contribuciones (Halfaker et al. 2013). Las desigualdades de género y estructurales afectan temas, lenguaje y visibilidad (Wagner et al. 2016; Yun, Lee, and Jeong 2019). Un bien común puede volverse conservador porque debe defender lo que ha construido.

Las comunidades de código abierto también combinan la libertad con la gobernanza. Los proyectos necesitan mantenedores, procesos de liberación, respuesta de seguridad, resolución de conflictos y control de nombres. O'Mahony y Ferraro mostraron cómo puede surgir la autoridad a través de la gobernanza negociada en lugar de la simple propiedad (O'Mahony and Ferraro 2007). La licencia de

código permite la salida y la reutilización, pero la cooperación duradera depende de las instituciones en torno a la licencia.

Tabla 7. Por qué algunos bienes comunes en línea siguen siendo duraderos

Elemento	Significado o consecuencia de diseño
Sustrato técnico abierto	Los participantes y los operadores independientes pueden inspeccionar, reutilizar, reparar y construir servicios complementarios.
Historia visible	Los cambios, reversiones, fuentes y disputas siguen siendo inspeccionables en lugar de desaparecer en un solo estado actual.
Roles limitados	Los editores, mantenedores, revisores y administradores tienen diferentes poderes en lugar de un rol de administrador indiferenciado.
Finanzas alineadas con la misión	La financiación apoya el activo común sin hacer de la publicidad conductual o el recinto propietario su centro constitucional.
Mecanismos de reparación	Los errores pueden corregirse, las decisiones apelaron, los contribuyentes se resocializan y las normas dañadas se reconstruyen.
Salida o tenedor creíble	La comunidad puede sobrevivir al fracaso de un proveedor, líder o implementación sin perder todo el trabajo compartido.

Los estudios económicos subrayan la escala del valor público. Hoffmann, Nagle y Zhou estiman que reemplazar el software de código abierto ampliamente utilizado impondría enormes costes, mucho más allá de los ingresos directos del proyecto (Hoffmann, Nagle, and Zhou 2024). El contrafáctico exacto es discutible, pero la conclusión cualitativa no lo es: las empresas modernas confían en un bien común que no financiaban individualmente.

OpenStreetMap muestra cómo una base de datos abierta puede servir a la navegación ordinaria y a la respuesta humanitaria. La investigación sobre el mapeo humanitario encontró millones de edificios y carreteras agregados en regiones de menor desarrollo a través de campañas organizadas (Herfort et al. 2021). El proyecto también exhibe desigualdades geográficas y de participación. La

apertura crea la capacidad de corregir puntos ciegos, no una garantía automática de que se produzcan correcciones.

La ciencia ciudadana amplía la cooperación en la investigación. Sistemas como FlyWire han coordinado grandes comunidades en línea en torno a la anotación científica y el descubrimiento (Dorkenwald et al. 2022). Los mejores proyectos dan a los participantes un contexto y reconocimiento significativos en lugar de tratarlos como un trabajo de microtarea invisible. La colaboración científica se vuelve duradera cuando los colaboradores pueden entender cómo su trabajo entra en un proceso epistémico más grande.

Estos éxitos comparten un patrón. El artefacto es portátil o de acceso público. La contribución deja una historia. Los roles son inteligibles. La reputación está relacionada con el trabajo. La gobernanza es lo suficientemente estable como para proteger el proyecto, pero suficientemente abierta para permitir el desafío. El financiamiento es diversificado o apoyado institucionalmente. Ninguno está perfectamente descentralizado. Cada uno limita la propiedad del resultado colectivo.

Los foros especializados ofrecen un ejemplo menos celebrado. Muchos preservaron el conocimiento técnico a través de hilos de búsqueda, límites de temas estables y participantes que regresaron durante años. Su valor provino de la acumulación más que de la viralidad. Cuando tales foros cerraron o fueron absorbidos por plataformas genéricas, cuerpos enteros de conocimiento tácito se volvieron más difíciles de encontrar. La continuidad del archivo es, por lo tanto, una función de bien público, no una característica decorativa.

Las comunidades de pacientes y de ayuda mutua muestran otra dimensión. El anonimato y la experiencia compartida pueden reducir el aislamiento y preparar a las personas para las interacciones con los profesionales. Los mismos espacios pueden circular consejos nocivos. Su éxito depende de la claridad del rol: la experiencia vivida, la experiencia médica, la moderación y la orientación de emergencia no deben confundirse. Las buenas

comunidades no eliminan el desacuerdo; hacen visible la fuente y el estado de las afirmaciones.

Los bienes comunes duraderos también se benefician de las misiones delimitadas. Wikipedia no intenta ser toda forma de publicación. Los proyectos Linux definen el alcance técnico. OpenStreetMap define un artefacto geográfico compartido. Una plataforma que intenta contener toda la vida social debe conciliar las normas incompatibles y se ve tentada a gobernar a través de la interacción en lugar de un propósito. Las comunidades constitucionales más pequeñas pueden ser más exigentes porque la membresía está vinculada a un objetivo reconocible.

El futuro Internet debe generalizar estas lecciones a través de bienes comunes portátiles, administración limitada, derechos de los miembros, finanzas duraderas y marcas constitucionales.

Capítulo 6: Más allá de la soberanía de las plataformas

La alternativa a la regla corporativa no es el vacío institucional. Es una constitución en capas en la que las comunidades, marcas, operadores, colaboradores y miembros poseen diferentes poderes y pueden verificarse entre sí.

6.1 Comunidades policéntricas y marcas descentralizadas

La gobernanza policéntrica describe sistemas con varios centros de decisión en lugar de una autoridad soberana. Las unidades locales manejan el conocimiento local; las unidades más amplias manejan estándares compartidos, daños transfronterizos y apelaciones. La investigación de Ostrom mostró que los bienes comunes se pueden gobernar sin una privatización completa o una sola burocracia central cuando las reglas coinciden con el recurso y los participantes pueden influir en ellos (Ostrom 1990).

Las comunidades en línea son adecuadas para el diseño policéntrico porque sus propósitos difieren. Un grupo de apoyo médico, un proyecto de software, un foro político, una comunidad de juegos y una red científica no deben compartir normas de habla idénticas. Las reglas de la plataforma universal son necesariamente crudas. La autonomía local completa es igualmente inadecuada cuando el abuso atraviesa comunidades o cuando los líderes locales violan los derechos básicos de los miembros.

Una marca descentralizada puede conectar estos niveles. La marca tiene una identidad pública compartida, estándares mínimos, reglas de certificación y tal vez un tesoro. Las comunidades locales operan bajo la marca al tiempo que conservan la autonomía cultural. Los proveedores de infraestructura pueden organizar instancias compatibles. Los miembros pueden reconocer una promesa común sin depender de una corporación.

La marca debe estar legalmente anclada. Una fundación, cooperativa, fideicomiso de propósito u otra entidad de administración puede poseer marcas comerciales y activos compartidos bajo deberes definidos por una constitución. La entidad no debe ser libre de vender la marca o alterar la misión como propiedad ordinaria. Su papel es el de custodia más que soberano.




Figura 7. Una arquitectura policéntrica en la que ningún actor posee cada capa y los miembros conservan la voz, la salida y el beneficio.

La licencia de marca realiza una función similar a un acuerdo de franquicia pero cambia la dirección de control. La franquicia convencional permite a un propietario central licenciar una reputación a los operadores. Una marca descentralizada licencia una reputación gobernada colectivamente bajo reglas que también vinculan al administrador. Los operadores obtienen el derecho de usar el nombre solo mientras cumplen con los estándares transparentes. Los miembros obtienen derechos que no dependen de la buena voluntad de un operador.

La bifurcación sigue siendo importante, pero debe entenderse correctamente. El código abierto permite la salida técnica. Los datos portátiles y la identidad permiten la salida social. La marca no siempre puede viajar con un tenedor porque un nombre compartido perdería significado si algún proyecto incompatible pudiera

reclamarlo. Una comunidad que se separa debe ser capaz de mantener sus datos y relaciones mientras adopta un nuevo nombre a menos que el proceso constitucional otorgue la certificación continua.

El constitucionalismo digital proporciona el vocabulario normativo: reglas estables y públicas, poderes limitados, igual aplicación, razones, apelación y consentimiento significativo (Celeste 2019; Suzor 2019; Schneider 2024). Estos principios no requieren el control estatal de cada comunidad. Requieren que las instituciones privadas que ejercen un poder público reconozcan los deberes constitucionales.

Los sistemas sociales federados aportan pruebas parciales. ActivityPub permite a servidores independientes intercambiar actividades sociales, lo que demuestra que un gráfico social no tiene por qué pertenecer a una empresa (W3C 2018). Las instancias de Mastodon pueden establecer reglas locales y bloquear dominios abusivos. El modelo restaura la elección significativa del administrador, pero también reproduce problemas familiares: agotamiento voluntario, moderación desigual, oligarquía a nivel de instancia y descubrimiento difícil. La Federación cambia la ubicación del poder; no elimina la necesidad de diseño constitucional.

Las organizaciones autónomas descentralizadas proporcionan una advertencia paralela. Los votos en cadena hacen que algunas decisiones y flujos financieros sean inspeccionables, pero la concentración simbólica puede convertir la participación formal en plutocracia. La baja participación permite dominar a las minorías organizadas. Los contratos inteligentes hacen cumplir lo que está codificado pero no pueden determinar si la regla codificada es legítima. Un libro de contabilidad es útil para la auditoría y ejecución; no es un sustituto del juicio institucional.

La marca descentralizada difiere de un protocolo de federación y de un DAO. Puede usar cualquiera de los dos, pero su núcleo es una promesa gobernable. La marca especifica qué comunidades y proveedores obedientes deben a los miembros, cómo se otorga la certificación y cómo se limita al administrador. La descentralización

técnica se convierte en un instrumento para mantener esas interacciones.

El objetivo no es congelar la gobernanza. Las comunidades necesitan experimentación. Se deben probar nuevos métodos de moderación, modelos económicos y sistemas de recomendación. Las estructuras policéntricas hacen que la experimentación sea más segura porque el fracaso puede permanecer local y las prácticas exitosas pueden propagarse. El error de un proveedor no necesita redefinir toda la red.

6.2 Economía, licencias y diseño anticaptura

Una comunidad duradera necesita dinero. Los servidores, la seguridad, la moderación, el trabajo legal, las copias de seguridad, el diseño y el desarrollo no desaparecen porque el software esté abierto. Los sistemas que se niegan a discutir las finanzas generalmente dependen de subsidios ocultos, trabajo no remunerado o eventual adquisición corporativa.

Los ingresos pueden provenir de suscripciones, servicios profesionales, alojamiento, mercados, certificación, subvenciones, tarifas de transacción, patrocinio o licencias comerciales compartidas. Ninguna fuente es neutral. La publicidad favorece la atención. El capital de riesgo favorece el rápido crecimiento y salida. Las donaciones favorecen las causas visibles y los clientes ricos. Las tarifas pueden excluir a los usuarios de bajos ingresos. Una institución resiliente utiliza varias fuentes y somete a cada una a límites constitucionales.

La licencia debe alinear los bienes comunes con la economía que la rodea. Las licencias permisivas maximizan la reutilización, pero permiten a las empresas capturar valor sin una contribución recíproca. Copyleft protege la apertura continua de los derivados, pero no financia automáticamente a los mantenedores ni distribuye la gobernanza. Las licencias de fuente disponibles pueden proteger un modelo de negocio mientras dejan de satisfacer las definiciones de código abierto. La elección correcta depende del activo y de los objetivos de la comunidad.

Tabla 8. Los instrumentos de una marca descentralizada

Elemento	Significado o consecuencia de diseño
Licencia de software o contenido	Define los derechos de copiar, modificar, reutilizar y redistribuir el bien técnico o cultural.
Licencia de marca	Define quién puede usar el nombre compartido y qué estándares de calidad, interoperabilidad y conducta deben cumplirse.
Constitución de gobernanza	Asigna poderes de elaboración de reglas, moderación, tesorería, emergencia, auditoría y apelación.
Acuerdo de contribución	Define la atribución, la procedencia, las obligaciones de mantenimiento y cualquier derecho económico o de gobernanza ganado por la contribución.
Normas de tesorería y distribución	Hacer que la financiación, las reservas, el pago del operador, la compensación del moderador y el beneficio del contribuyente sean predecibles.
Sistema de auditoría y apelación	Prueba el cumplimiento, gestiona los conflictos de intereses, publica los precedentes y protege a los miembros contra la captura local o central.

Una marca descentralizada añade otro instrumento. Los operadores comerciales pueden utilizar software abierto mientras pagan la certificación, el soporte, el acceso a servicios compartidos o el derecho a presentarse bajo el nombre común. Los ingresos pueden fluir a mantenedores, moderadores, infraestructura y una reserva. La comunidad no necesita prohibir el comercio; necesita evitar que el comercio se convierta silenciosamente en soberanía.

La contabilidad de contribuciones debe evitar reducir cada acto a un puntaje de token. El código, la documentación, la mediación en conflicto, la respuesta de seguridad, la tutoría, la gobernanza, el capital y la comunicación pública son diferentes formas de trabajo. Una sola métrica será jugada y privilegiará lo que sea más fácil de contar. La evaluación mixta, el reconocimiento entre pares, los roles definidos y los presupuestos transparentes son más realistas que la tokenización universal.

Las reglas anti-captura deben ser explícitas antes del conflicto. Ningún actor debe controlar tanto la tesorería como la auditoría. Los

grandes donantes deben revelar dependencias. Los términos del moderador deben ser limitados. Las enmiendas constitucionales deberían requerir más que una mayoría simple temporal. Los operadores deben pasar pruebas de portabilidad. Los poderes de emergencia deben expirar. Los contratos con partes relacionadas deben ser visibles. Las métricas de concentración deben ser publicadas.

El sistema también debe proteger el liderazgo útil. Los fundadores a menudo poseen visión y conocimiento que no puede ser reemplazado por la votación aleatoria. Los mantenedores necesitan discreción. Los inversores necesitan derechos predecibles. El objetivo no es la sospecha permanente de competencia. Es para distinguir el liderazgo de la propiedad del futuro. La autoridad puede ser amplia dentro de un rol y todavía limitada en tiempo, alcance y revisión.

Por lo tanto, una constitución viable reconoce al menos cuatro distritos electorales: los miembros afectados por el sistema, los contribuyentes que lo mantienen, los operadores que tienen responsabilidad técnica y legal, y los administradores encargados de la misión a largo plazo. Ningún grupo debe gobernar solo. Las diferentes decisiones pueden requerir diferentes combinaciones de consentimiento.

La reciprocidad puede ser diseñada sin prohibir el éxito comercial. Una empresa que implementa el software de una comunidad a escala podría aportar dinero, código, trabajo de seguridad o interoperabilidad. La obligación puede estar vinculada al uso de la marca compartida o servicios de red premium en lugar de a cada copia del software. Esto evita pretender que la licencia de derechos de autor por sí sola pueda medir la contribución social.

El tesoro debería financiar una continuidad poco glamorosa. Las auditorías de seguridad, las copias de seguridad, la moderación, la documentación, las herramientas de migración, la defensa legal y el apoyo de los recién llegados rara vez ganan concursos de popularidad, sin embargo, su ausencia destruye las instituciones. Por lo tanto, los presupuestos deben reservar fondos para el

mantenimiento en lugar de distribuir todo a través de los votos del proyecto o la popularidad del creador.

Las finanzas transparentes también limitan la conspiración y el patrocinio informal. Los miembros deben conocer las principales fuentes de ingresos, dependencias contractuales y bandas de compensación. La privacidad puede proteger los salarios individuales cuando corresponda, pero las transacciones de partes relacionadas y los donantes estratégicos requieren divulgación. Una institución no puede reclamar de manera creíble la descentralización mientras depende silenciosamente de un patrón.

La calidad de la descentralización se mide finalmente por tres derechos. La voz significa la capacidad de influir en las reglas y recibir razones. La salida significa salir sin perder la sustancia de la identidad y el trabajo. El beneficio significa compartir equitativamente el valor económico y social creado. Un sistema que ofrece solo el derecho a copiar código es técnicamente abierto e institucionalmente incompleto.

Capítulo 7: La IA personal como recomendador del usuario

Los sistemas de recomendación actualmente construyen modelos privados de usuarios para plataformas. IA personal hace posible un arreglo diferente: el modelo del usuario puede convertirse en un instrumento gobernado por el usuario que negocia con plataformas en lugar de un activo invisible que poseen.

7.1 De perfiles ocultos a relevancia gobernada por el usuario

Las plataformas modernas infieren intereses de clics, tiempo de permanencia, seguidores, compras, ubicación y similitud con otros usuarios. El perfil resultante es potente precisamente porque no es una simple lista de preferencias establecidas. Detecta patrones que el usuario puede no articular. Sin embargo, el perfil suele ser inaccesible, difícil de corregir y optimizado dentro de la función objetiva de la plataforma.

Un agente de recomendación personal podría invertir esta relación. El agente tendría una representación portátil de los intereses, obligaciones, proyectos actuales, aversiones y preferencias epistémicas del usuario. Solicitaría elementos candidatos de múltiples fuentes, los clasificaría localmente o a través de cálculos confidenciales y explicaría por qué se seleccionó un elemento. El usuario podría inspeccionar y revisar la política en lugar de simplemente entrenarla a través de un comportamiento inconsciente.

El avance relevante es la gobernanza, no la precisión predictiva. La investigación sobre sistemas de recomendación ha mostrado desde hace tiempo que la experiencia del usuario depende de la variedad percibida, el esfuerzo, la privacidad, la utilidad y la confianza, no

solo de la precisión estadística (Konstan and Riedl 2012; Knijnenburg et al. 2012). Las explicaciones pueden aumentar la aceptación, aunque la transparencia no crea confianza automáticamente (Cramer et al. 2008). Un agente personal puede convertir estas preocupaciones en objetivos de primer orden.

El agente puede mantener varios modos en lugar de un perfil permanente. Un modo profesional podría priorizar las fuentes primarias y la profundidad técnica. Un modo de ocio podría buscar la novedad. Un modo cívico podría mantener la diversidad de exposición y separar los informes verificados de los comentarios. Un modo de recuperación podría reducir los temas angustiantes. Un usuario podría comparar el mismo grupo de candidatos bajo políticas diferentes en lugar de aceptar un pedido opaco.




Figura 8. Un AI personal puede mover la recomendación de la creación de perfiles de plataformas ocultas hacia la relevancia gobernada por el usuario.

Los modelos de lenguaje grandes son útiles porque pueden traducir las intenciones del lenguaje natural en criterios de ranking, razonar entre dominios y explicar las compensaciones. La investigación emergente describe un movimiento de los perfiles de plataforma ocultos hacia la “personalización gobernable”, en la que las representaciones de los usuarios se vuelven inspeccionables, portátiles y revisables (Liu et al. 2026). Este trabajo es temprano, pero

la dirección institucional es más importante que cualquier modelo particular.

Un agente personal también podría representar un sesgo explícito en lugar de pretender neutralidad. Un usuario puede instruirlo para que favorezca las fuentes locales, evite la promoción del juego, busque evidencia políticamente diversa o apoye a una comunidad profesional. El agente debe establecer estas interacciones. El sesgo oculto es peligroso porque se disfraza de relevancia; el sesgo declarado se convierte en una política que puede ser juzgada.

Las relaciones comerciales cambiarían. Una plataforma podría ofrecer artículos candidatos y revelar el patrocinio, el precio, la procedencia y las condiciones de acceso. El agente personal decidiría si el artículo se ajusta a la política del usuario. La publicidad se convertiría en una oferta a un agente en lugar de la optimización encubierta de un flujo. Las plataformas seguirían compitiendo por la atención, pero ya no controlarían exclusivamente el modelo utilizado para asignarlo.

Una tubería práctica contendría distintas etapas. Las fuentes publican los elementos candidatos y los metadatos. Los servicios de recuperación identifican un conjunto amplio relevante para el contexto actual del usuario. El agente personal aplica políticas relativas a la calidad, la diversidad, el tiempo, el riesgo y el patrocinio. Una capa de presentación final explica las selecciones y preserva la capacidad de inspeccionar las alternativas omitidas. La retroalimentación actualiza el modelo local solo bajo las reglas elegidas por el usuario.

Esta separación importa porque el descubrimiento y el juicio son funciones diferentes. Un proveedor de búsqueda global puede ser excelente para encontrar candidatos, mientras que no es adecuado para decidir las prioridades del usuario. Un curador de la comunidad puede identificar fuentes confiables sin tener conocimiento del contexto personal. Un agente local puede combinar estas entradas sin necesidad de rastrear todo Internet o poseer cada fuente.

El agente también puede negociar. Un comerciante puede ofrecer datos de precio, entrega, garantía y comisión en un formulario

legible por máquina. Una fuente de noticias podría revelar autoría, política de corrección, coste de acceso y procedencia. El agente puede rechazar ofertas que ocultan el patrocinio o solicitar una versión menos intrusiva. La recomendación se convierte en un intercambio de términos declarados en lugar de la orientación unilateral del comportamiento.

La representación del usuario debe viajar independientemente del modelo. Una persona puede reemplazar el modelo de lenguaje mientras preserva una política estructurada y la historia. De lo contrario, el proveedor de modelos se convierte en la nueva soberanía de plataforma. Los esquemas abiertos, las tiendas personales cifradas y los casos de evaluación exportables permiten al usuario comparar agentes y migrar sin reconstruir la identidad a partir de clics en bruto.

La interoperabilidad es esencial. Los flujos de candidatos necesitan metadatos estándar, procedencia, divulgación de patrocinio, identificadores de contenido e información de derechos. Las comunidades podrían publicar políticas de ranking certificadas. Los desarrolladores independientes podrían proporcionar recomendadores sin alojar la red social subyacente. La recomendación se convertiría en una capa competitiva más que en una característica inseparable de una plataforma.

7.2 Privacidad, sesgo, pluralismo y riesgo de una cámara de eco personal

Un agente personal sabe más que un recomendador ordinario porque puede combinar dominios. Ese es su valor y su peligro. Un perfil entre dominios puede revelar salud, relaciones, finanzas, creencias políticas e intenciones futuras. El traslado del perfil de la plataforma a un servicio nominalmente personal en la nube no crea privacidad si el proveedor de servicios puede inspeccionarlo.

La arquitectura preferida mantiene la memoria sensible en dispositivos controlados por el usuario o en entornos confidenciales con fuertes garantías de acceso. Los modelos en la nube pueden procesar el contexto seleccionado y minimizado. La investigación

híbrida sugiere que la utilidad de recomendación a veces se puede preservar, mientras que las características sensibles siguen siendo locales, aunque los resultados dependen del dominio y el modelo de amenaza (Khezresmaeilzadeh et al. 2025). La privacidad debe evaluarse frente a los flujos de datos reales, no a la marca.

La memoria del agente debe estar lo suficientemente estructurada como para inspeccionarla. Un perfil en prosa puede ser expresivo pero difícil de auditar. Un sistema útil distingue el comportamiento observado, las preferencias indicadas por el usuario, las hipótesis inferidas, el contexto temporal y las restricciones duras. Cada artículo debe tener procedencia y una regla de vencimiento. El usuario debe ser capaz de preguntar por qué el agente cree algo y eliminar la evidencia o inferencia.

La personalización puede intensificar la autoconfirmación. Un modelo entrenado para satisfacer puede aprender que la tranquilidad produce retroalimentación positiva. Puede convertirse en un adulator que protege la identidad frente a evidencia incómoda. La investigación sobre recomendadores sensibles a la diversidad sostiene que la diversidad de exposición puede ser un objetivo de diseño en lugar de un subproducto accidental (Helberger, Karppinen, and D'Acunto 2018). Por lo tanto, un agente personal debería apoyar la exploración configurable, no solo la similitud.

Tabla 9. Capacidades y salvaguardias para un recomendador personal

Elemento	Significado o consecuencia de diseño
Modelo de usuario editable	El usuario puede inspeccionar categorías, corregir falsas inferencias, definir objetivos temporales y restablecer el modelo.
Memoria privada y portátil	El historial sensible sigue siendo local o fuertemente protegido y puede moverse independientemente de una cuenta de plataforma.
Explicación y alternativas	El agente afirma por qué apareció un elemento, qué fue excluido y qué objetivo de ranking alternativo cambiaría el resultado.

Elemento	Significado o consecuencia de diseño
Limitaciones del pluralismo	La diversidad, la novedad, el desacuerdo, la calidad de la fuente y la asignación de tiempo son políticas explícitas en lugar de efectos secundarios accidentales.
Firewall comercial	Los pagos, las relaciones con los afiliados y los incentivos de los proveedores se divulgan y no pueden anular silenciosamente la política del usuario.
Defensas adversarias	La inyección rápida, las fuentes envenenadas, los complementos maliciosos y los modelos comprometidos están contenidos por la procedencia, las capacidades y la auditoría.

El pluralismo no significa oposición aleatoria. El agente debe identificar un desacuerdo creíble, distinguir el consenso de los expertos del equilibrio partidista y exponer la incertidumbre. Puede mantener un presupuesto para fuentes desconocidas, una regla contra la indignación repetida o un requisito de que las afirmaciones de alto impacto incluyan evidencia primaria. Estas políticas deben ser elegidas y visibles, no impuestas en secreto por una plataforma o proveedor de modelos.

La seguridad es otro problema. El contenido puede contener instrucciones dirigidas al agente en lugar del usuario. Una página maliciosa puede intentar extraer memoria, alterar la política de ranking o desencadenar acciones externas. Por lo tanto, la recomendación necesita aislamiento entre el contenido no confiable y el estado de agente privilegiado. La recuperación, el resumen y la acción deben operar bajo capacidades con límites de datos explícitos.

Los proveedores de modelos también pueden manipular. Un agente personal construido sobre un modelo remoto puede heredar indicaciones de sistema oculto, prioridades comerciales, políticas de censura o vulnerabilidades. El usuario necesita modelos reemplazables y conjuntos de pruebas que comparen el comportamiento entre los proveedores. Los modelos más pequeños locales pueden manejar el filtrado de rutina, mientras que los

modelos remotos más fuertes se invocan para tareas difíciles bajo divulgación restringida.

La rendición de cuentas debe permanecer con la institución humano-agente en lugar de con una ficción antropomórfica. El agente no es un amigo soberano. Es un sistema delegado cuyo operador, proveedor de modelos y canal de actualización se puede identificar. Cuando actúa en una comunidad, debe presentar su estado de automatización, su alcance de autoridad y su principal responsable.

La auditoría debe incluir resultados, no solo explicaciones. Un agente puede describir una política de diversidad mientras selecciona repetidamente el mismo grupo ideológico. Los usuarios y los evaluadores independientes deben poder ejecutar conjuntos de pruebas controlados, inspeccionar las distribuciones de exposición y comparar el comportamiento a lo largo del tiempo. Una constitución de recomendación es creíble solo si sus efectos pueden ser medidos.

Diferentes usuarios querrán diferentes grados de control. Algunos editarán las políticas directamente. Otros elegirán perfiles certificados mantenidos por comunidades de confianza, periodistas, organismos profesionales o grupos de la sociedad civil. Un mercado para las políticas de recomendación puede apoyar el pluralismo, siempre que los usuarios puedan ver la financiación, los objetivos y la evidencia. La alternativa a un algoritmo de plataforma no es que cada persona se convierta en un ingeniero de aprendizaje automático.

La autonomía cognitiva también requiere el derecho a no personalizar. Un usuario puede elegir un flujo de interés público común, un flujo cronológico o una muestra aleatoria. La personalización debe ser una lente entre varias. Los sistemas que hacen que el acceso no personalizado sea deliberadamente inferior preservan la antigua coerción detrás de una nueva interfaz.

El mejor recomendador personal no maximizaría la satisfacción. Ayudaría al usuario a regular la atención de acuerdo con los valores elegidos, preservando al mismo tiempo la posibilidad de revisión. A veces sorprende, a veces protege, a veces desafía y siempre explica

qué política se está aplicando. El usuario ya no sería simplemente objeto de personalización sino su autor constitucional.

Capítulo 8: Reconstruir la comunicación desde la capa de protocolo

La plataforma Internet asume que los servicios siguen siendo accesibles a nivel mundial y luego filtra el abuso después del contacto. Una arquitectura diferente puede hacer que las relaciones, las capacidades y la negociación privada sean el valor predeterminado al tiempo que preservan experiencias familiares como direcciones, bandejas de entrada, grupos y llamadas.

8.1 WebRTC, direccionamiento similar al correo electrónico, DIDs y conexiones filtradas por confianza

El correo electrónico tuvo éxito en parte porque su modelo de direccionamiento es humanamente inteligible. Un nombre y un dominio locales identifican una ruta sin requerir que ambos participantes utilicen un proveedor. Cualquier sucesor debe preservar esta ventaja social. Las personas necesitan identificadores que puedan ser hablados, impresos, recordados, delegados por organizaciones y trasladados entre proveedores de servicios.

El identificador técnico detrás de la dirección no tiene que ser idéntico al nombre legible por humanos. Una dirección basada en dominios podría resolverse a un identificador descentralizado, claves públicas, preferencias de servicio y puntos finales de introducción. W3C DID Core define identificadores cuyos controladores pueden probar el control a través de métodos criptográficos sin depender permanentemente de un proveedor de identidad (W3C 2022). El trabajo 2026 DID 1.1 continúa esta arquitectura, mientras que Verifiable Credentials 2.0 proporciona una forma estándar para afirmaciones verificables por máquina emitidas por terceros (W3C 2025b; W3C 2026).

DIDs no crea confianza. Establecen el control sobre un identificador y proporcionan mecanismos de verificación y descubrimiento de servicios. Un estafador puede controlar un DID válido. Una credencial es significativa solo porque un verificador confía en el emisor y la reclamación es relevante. Por lo tanto, la arquitectura debe combinar la verificación criptográfica con el contexto institucional, la historia de la relación y la aceptación explícita.

El primer contacto no debe requerir la exposición de un servicio personal permanente al tráfico arbitrario. Un servicio de introducción limitada puede aceptar pequeñas y limitadas solicitudes. El remitente puede presentar una referencia, una credencial comunitaria, una fianza reembolsable, una prueba de relación previa o una solicitud anónima limitada por tasa. El agente del destinatario evalúa la solicitud sin revelar puntos finales privados o identidad completa.

Si se acepta, las partes establecen una capacidad: una autorización revocable para comunicarse bajo condiciones definidas. La capacidad puede limitar la velocidad de mensaje, el tipo de datos, la duración, la automatización o el uso compartido en adelante. Los identificadores de pares pueden evitar que los servicios no relacionados se correlacionan trivialmente con la misma persona. La revocación puede terminar una relación sin forzar un cambio de identidad global.




Figura 9. Una pila de comunicación de confianza que combina direccionamiento legible, control portátil, credenciales selectivas, introducción limitada y sesiones cifradas.

WebRTC es un transporte plausible para sesiones interactivas porque admite audio, video y datos genéricos entre puntos finales. Los canales de datos WebRTC utilizan SCTP en un transporte seguro, mientras que ICE descubre rutas viables a través de NAT y puede volver a los relés TURN (IETF 2018; IETF 2021a; IETF 2021b; W3C 2025a). Por lo tanto, un navegador, un agente de escritorio o un agente móvil pueden establecer una comunicación rica sin que cada aplicación invente una pila de medios propietaria.

WebRTC deliberadamente deja señalización a la aplicación. Esto es una limitación y una oportunidad. La capa de introducción e identidad puede intercambiar descripciones de sesión e información de conectividad después de las comprobaciones de políticas. El transporte no necesita saber si los participantes son humanos, agentes o equipos mixtos. Solo lleva una sesión autenticada una vez que las capas superiores establecen el permiso.

La mensajería asíncrona requiere más que WebRTC porque los pares pueden estar fuera de línea. Un buzón o relé puede contener sobres cifrados dirigidos a una capacidad en lugar de a una bandeja de entrada pública sin restricciones. Varios proveedores podrían ofrecer servicio de tienda y reenvío mientras no pueden leer contenido. Los

usuarios pueden cambiar de proveedor sin cambiar de identidad. La bandeja de entrada familiar permanece, pero la entrega global no solicitada ya no es el valor predeterminado.

Por lo tanto, la secuencia de una conexión puede ser explícita. Una dirección legible por humanos resuelve un punto final de introducción y material de verificación actual. El agente del remitente presenta una solicitud mínima y cualquier credencial relevante. El agente del destinatario evalúa la política y puede solicitar pruebas adicionales. La aceptación crea una capacidad de alcance e intercambia datos de señalización. ICE entonces intenta una ruta directa o retransmitida, y las partes establecen canales cifrados. Cada etapa expone solo la información necesaria para el siguiente.

Los identificadores de pares reducen la correlación. El usuario puede presentar un identificador diferente a un médico, empleador, miembro de la familia y comunidad pública mientras conserva la recuperación y el control a través de una billetera o agente. Las credenciales se pueden divulgar selectivamente para que un verificador aprenda un hecho relevante sin adquirir el documento subyacente completo. El beneficio de privacidad depende de la implementación; los metadatos repetidos o un solucionador común aún pueden vincular las relaciones.

El tratamiento legible por el ser humano necesita gobernanza. Los dominios son convenientes porque las organizaciones pueden delegar nombres, pero la pérdida de dominio o la coerción de los proveedores puede interrumpir la identidad. Un diseño resiliente puede vincular la dirección legible a identificadores criptográficos portátiles y soportar pruebas de continuidad cuando cambian los dominios. Los usuarios no deben verse obligados a elegir entre nombres memorables y claves autocontroladas.

La comunicación de grupo requiere actualizaciones seguras del estado de membresía y clave. Messaging Layer Security fue diseñado para grupos asíncronos que van desde pequeñas conversaciones hasta grupos grandes, con seguridad de secreto hacia adelante y seguridad (IETF 2023) posterior al interacción. Puede complementar

WebRTC en lugar de reemplazarlo: MLS protege los mensajes de grupo, mientras que WebRTC puede transportar sesiones en vivo y canales de datos.

8.2 Una superficie de ataque menor para humanos y agentes

La principal ganancia de seguridad de una arquitectura de confianza es la exposición reducida. Un dispositivo o agente personal no necesita aceptar conexiones de entrada arbitrarias desde el conjunto Internet. Los servicios públicos siguen siendo públicos cuando es necesario, pero la comunicación privada comienza a través de estrechos puntos de introducción con estrictos límites de recursos. La mayoría del estado de alto valor permanece detrás de las capacidades creadas después del consentimiento.

Esto no elimina los ataques de denegación de servicio. Los servicios de introducción, los servidores de señalización, los solucionadores DID, los relés TURN y los buzones de correo siguen siendo objetivos. Los atacantes pueden inundar la verificación de credenciales o adquirir credenciales legítimas. La arquitectura cambia la economía al hacer que los servicios costosos no estén disponibles antes de que pasen los cheques baratos, distribuyendo proveedores y permitiendo a las comunidades compartir inteligencia de abuso sin compartir todos los datos de los usuarios.

La privacidad también depende de la elección de relé. Las conexiones directas de igual a igual pueden exponer direcciones de red a corresponsales. Los relés TURN pueden ocultarlos a costa de la infraestructura y la concentración de metadatos. Un agente personal debe elegir caminos directos o transmitidos de acuerdo con la relación y el riesgo. La ruta más rápida no siempre es la más privada.

Tabla 10. Componentes de una superficie de comunicación más pequeña y más privada

Elemento	Significado o consecuencia de diseño
Dirección legible	Proporciona usabilidad y descubrimiento similares a los de un correo electrónico mientras permanece separable del operador que actualmente presta servicios al usuario.
DID o identificador de control equivalente	Proporciona control criptográfico portátil; por sí mismo no establece identidad, confianza o reputación.
Credencial verificable	Permite una prueba selectiva de un rol, membresía, respaldo o relación; las afirmaciones permanecen solo tan confiables como sus emisores.
Servicio de introducción y capacidad	Expone una superficie de solicitud estrecha y decide quién puede señalar, enviar, invocar, retransmitir o formar una relación duradera.
ICE y WebRTC	Negocie las rutas interactivas para medios o datos, utilizando conectividad directa cuando sea posible y relés cuando sea necesario.
Relé delimitado	Conserva la fiabilidad y el comportamiento asíncrono sin convertirse en el propietario permanente de la relación o contenido de texto plano.
MLS o seguridad de grupo equivalente	Protege a los grupos en evolución con secreto hacia adelante y seguridad posterior al interacción; la gobernanza y la entrega siguen siendo preocupaciones de aplicación.
Motor de política de agente personal	Aplica el consentimiento local, la privacidad, la tarifa, la procedencia, la delegación y las reglas de recuperación antes de exponer las herramientas o la atención.

La recuperación clave es un gran desafío práctico. Los identificadores autocontrolados son frágiles si la pérdida de un dispositivo destruye la identidad. La recuperación social, los múltiples dispositivos, los guardianes institucionales y las claves respaldadas por hardware pueden ayudar, pero cada uno introduce confianza. Un sistema utilizable necesita políticas de recuperación transparentes y la capacidad de rotar las teclas sin perder relaciones. DIDs soporta la indirección entre el identificador y los métodos de

verificación actuales, pero la gobernanza específica del método sigue siendo fundamental.

El agente se convierte en el centro operativo. Filtra las introducciones, verifica credenciales, selecciona modos de privacidad, gestiona capacidades, almacena historial de relaciones y traduce entre protocolos. También puede resumir mensajes y negociar horarios de reunión. Esto reduce la carga cognitiva, pero la vulneración del agente se vuelve más grave que la vulneración de una aplicación convencional.

Por lo tanto, la arquitectura del agente debe separar la memoria, la comunicación y la acción. La lectura de un mensaje no debe conceder automáticamente acceso a la memoria privada. Un resumidor no debe poseer autoridad de pago. Un módulo de recomendación no debe modificar las claves de identidad. El diseño interno basado en la capacidad puede limitar el daño cuando se manipula un componente. Las actualizaciones deben ser firmadas, auditables y reversibles.

Las comunidades pueden agregar confianza institucional. Una marca científica puede emitir credenciales para los revisores. Una comunidad de pacientes puede emitir pruebas de membresía sin revelar los diagnósticos públicamente. Un mercado puede requerir una credencial de depósito en garantía antes del contacto de alto valor. Un grupo político puede permitir la membresía seudónima mientras limita las cuentas automatizadas. Los mismos protocolos apoyan diferentes constituciones.

La arquitectura también cambia el descubrimiento. En lugar de un flujo global, las personas pueden descubrir comunidades a través de directorios, recomendaciones confiables, proveedores de búsqueda o agentes personales. El contenido público puede permanecer indexable cuando los autores lo deseen. Los espacios privados pueden revelar solo descripciones y procedimientos de admisión. El objetivo no es ocultar Internet sino dejar de tratar la exposición universal como la condición predeterminada de participación.

Una transición podría ser gradual porque la experiencia del usuario puede seguir siendo familiar. Una aplicación todavía puede parecer

un correo electrónico, un mensajero, un foro o un espacio de trabajo colaborativo. Debajo, la identidad es portátil, las relaciones se basan en la capacidad, las sesiones utilizan transportes abiertos, la recomendación es personal y los proveedores son reemplazables. Las puertas de enlace de compatibilidad pueden conectar cuentas de correo electrónico y plataforma heredadas mientras hacen visible su modelo de confianza más débil.

Los metadatos siguen siendo un riesgo grave. Incluso cuando el contenido está cifrado, los relés pueden observar el tiempo, el volumen, las contrapartes y los patrones de los dispositivos. Los identificadores en par y la rotación de relés reducen cierta correlación pero aumentan la complejidad y pueden debilitar la respuesta al abuso. Las comunidades deben decidir qué metadatos conservan por seguridad, cuánto tiempo los conservan y bajo qué proceso se puede acceder. “Privacidad total” debería significar una minimización fuerte e inspeccionable y control del usuario, no la afirmación imposible de que no existen metadatos.

La disponibilidad crea otra compensación. Los sistemas peer-to-peer fallan cuando los dispositivos están desconectados, con batería restringida o detrás de redes restrictivas. Los relés y los buzones proporcionan confiabilidad, pero los proveedores populares pueden concentrarse nuevamente. Las pruebas de portabilidad, los formatos de cifrado interoperables y la replicación de múltiples proveedores pueden evitar que la disponibilidad se convierta en soberanía.

La ruta de transición debería comenzar con comunidades delimitadas y flujos de trabajo de agente a agente en lugar de un intento de reemplazo del público Web. Las redes profesionales, las colaboraciones de investigación, las familias, los servicios regulados y los mercados privados tienen límites de relación claros y un alto valor de privacidad. Las pasarelas pueden preservar el acceso al correo electrónico y a la web, mientras que las nuevas conexiones utilizan capacidades e identidad portátil. Los patrones exitosos pueden expandirse.

Esta propuesta no es una suite de protocolo terminado. Es una dirección arquitectónica construida a partir de componentes

maduros y de investigación no resuelta. WebRTC suministra transporte interactivo pero no semántica social. DIDs y las credenciales proporcionan control y afirmaciones verificables, pero no confían. MLS proporciona gestión de clave de grupo pero no gobernanza. IA personal suministra automatización de políticas, pero introduce una nueva y poderosa superficie de ataque. El logro que falta es su integración en un sistema institucionalmente coherente.

El Internet original tuvo éxito porque separó las aplicaciones de la propiedad de la red. El próximo Internet puede tener éxito separando a las comunidades y agentes personales de la propiedad de la plataforma. Los protocolos abiertos deben llevar datos; las constituciones deben gobernar las comunidades; los agentes personales deben representar a los usuarios; las marcas descentralizadas deben tener promesas compartidas; los proveedores deben competir para operar servicios reemplazables.

Los Internet seguirán siendo conflictivos porque los seres humanos siguen siendo conflictivos. Contendrá comercio, ideología, manipulación, cuidado, erudición, entretenimiento y fraude. Una arquitectura mejor no promete pureza. Hace que sea más difícil para cualquier corporación, grupo moderador, enjambre automatizado o proveedor de modelos convertir la ventaja temporal en control irreversible. Ese es un estándar realista de progreso: no una red sin poder, sino una red en la que el poder debe justificarse continuamente.

Referencias

- Abbate, Janet. 1999. *Inventing the Internet*. Cambridge, MA: MIT Press.
- Bail, Christopher A., Lisa P. Argyle, Taylor W. Brown, John P. Bumpus, Haohan Chen, M. B. Fallin Hunzaker, Jaemin Lee, Marcus Mann, Friedolin Merhout, and Alexander Volfovsky. 2018. "Exposure to Opposing Views on Social Media Can Increase Political Polarization." *Proceedings of the National Academy of Sciences* 115 (37): 9216–9221. <https://doi.org/10.1073/pnas.1804840115>.
- Benkler, Yochai, Robert Faris, and Hal Roberts. 2018. *Network Propaganda: Manipulation, Disinformation, and Radicalization in American Politics*. New York: Oxford University Press. <https://doi.org/10.1093/oso/9780190923624.001.0001>.
- Brady, William J., Julian A. Wills, John T. Jost, Joshua A. Tucker, and Jay J. Van Bavel. 2017. "Emotion Shapes the Diffusion of Moralized Content in Social Networks." *Proceedings of the National Academy of Sciences* 114 (28): 7313–7318. <https://doi.org/10.1073/pnas.1618923114>.
- Buckels, Erin E., Paul D. Trapnell, and Delroy L. Paulhus. 2014. "Trolls Just Want to Have Fun." *Personality and Individual Differences* 67: 97–102. <https://doi.org/10.1016/j.paid.2014.01.016>.
- Burke, Robin, Nasim Sonboli, and Aldo Ordonez-Gauger. 2018. "Balanced Neighborhoods for Multi-Sided Fairness in Recommendation." In *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, 202–214. PMLR 81.
- C2PA. 2026. *C2PA Technical Specification, Version 2.4*. Coalition for Content Provenance and Authenticity. <https://c2pa.org/specifications/>.
- Celeste, Edoardo. 2019. "Digital Constitutionalism: A New Systematic Theorisation." *International Review of Law, Computers & Technology* 33 (1): 76–99. <https://doi.org/10.1080/13600869.2019.1562604>.
- CERN. 1993. "Statement Concerning CERN W3 Software Release into Public Domain." 30 April 1993. <https://cds.cern.ch/record/1164399>.
- Chan, Man-pui Sally, Christopher R. Jones, Kathleen Hall Jamieson, and Dolores Albarracín. 2017. "Debunking: A Meta-Analysis of the Psychological Efficacy

- of Messages Countering Misinformation.” *Psychological Science* 28 (11): 1531–1546. <https://doi.org/10.1177/0956797617714579>.
- Chandrasekharan, Eshwar, Umashanthi Pavalanathan, Anirudh Srinivasan, Adam Glynn, Jacob Eisenstein, and Eric Gilbert. 2017. “You Can’t Stay Here: The Efficacy of Reddit’s 2015 Ban Examined through Hate Speech.” *Proceedings of the ACM on Human-Computer Interaction* 1 (CSCW), Article 31. <https://doi.org/10.1145/3134666>.
- Cheng, Justin, Michael Bernstein, Cristian Danescu-Niculescu-Mizil, and Jure Leskovec. 2017. “Anyone Can Become a Troll: Causes of Trolling Behavior in Online Discussions.” In *Proceedings of the 2017 ACM Conference on Computer Supported Cooperative Work and Social Computing*, 1217–1230. <https://doi.org/10.1145/2998181.2998213>.
- Cinelli, Matteo, Gianmarco De Francisci Morales, Alessandro Galeazzi, Walter Quattrociocchi, and Michele Starnini. 2021. “The Echo Chamber Effect on Social Media.” *Proceedings of the National Academy of Sciences* 118 (9): e2023301118. <https://doi.org/10.1073/pnas.2023301118>.
- Clark, David D. 1988. “The Design Philosophy of the DARPA Internet Protocols.” *ACM SIGCOMM Computer Communication Review* 18 (4): 106–114. <https://doi.org/10.1145/52324.52336>.
- Cramer, Henriette, Vanessa Evers, Satyan Ramlal, Maarten van Someren, Lloyd Rutledge, Natalia Stash, Lora Aroyo, and Bob Wieringa. 2008. “The Effects of Transparency on Trust in and Acceptance of a Content-Based Art Recommender.” *User Modeling and User-Adapted Interaction* 18: 455–496. <https://doi.org/10.1007/s11257-008-9051-3>.
- Dorkenwald, Sven, et al. 2022. “FlyWire: Online Community for Whole-Brain Connectomics.” *Nature Methods* 19: 119–128. <https://doi.org/10.1038/s41592-021-01330-0>.
- European Union. 2022. “Regulation (EU) 2022/2065 on a Single Market for Digital Services.” *Official Journal of the European Union* L 277: 1–102.
- Giles, Jim. 2005. “Internet Encyclopaedias Go Head to Head.” *Nature* 438: 900–901. <https://doi.org/10.1038/438900a>.
- Gillespie, Tarleton. 2018. *Custodians of the Internet: Platforms, Content Moderation, and the Hidden Decisions That Shape Social Media*. New Haven, CT: Yale University Press.

- Grinberg, Nir; Kenneth Joseph, Lisa Friedland, Briony Swire-Thompson, and David Lazer. 2019. "Fake News on Twitter during the 2016 U.S. Presidential Election." *Science* 363 (6425): 374–378. <https://doi.org/10.1126/science.aau2706>.
- Guess, Andrew M., Brendan Nyhan, and Jason Reifler. 2020. "Exposure to Untrustworthy Websites in the 2016 US Election." *Nature Human Behaviour* 4: 472–480. <https://doi.org/10.1038/s41562-020-0833-x>.
- Halfaker, Aaron, R. Stuart Geiger, Jonathan T. Morgan, and John Riedl. 2013. "The Rise and Decline of an Open Collaboration System: How Wikipedia's Reaction to Popularity Is Causing Its Decline." *American Behavioral Scientist* 57 (5): 664–688. <https://doi.org/10.1177/0002764212469365>.
- Helberger, Natali, Kari Karppinen, and Lucia D'Acunto. 2018. "Exposure Diversity as a Design Principle for Recommender Systems." *Information, Communication & Society* 21 (2): 191–207. <https://doi.org/10.1080/1369118X.2016.1271900>.
- Helmond, Anne. 2015. "The Platformization of the Web: Making Web Data Platform Ready." *Social Media + Society* 1 (2). <https://doi.org/10.1177/2056305115603080>.
- Herfort, Benjamin, Sven Lautenbach, João Porto de Albuquerque, Jeff Anderson, and Alexander Zipf. 2021. "The Evolution of Humanitarian Mapping within the OpenStreetMap Community." *Scientific Reports* 11: 3037. <https://doi.org/10.1038/s41598-021-82404-z>.
- Hoffmann, Manuel, Frank Nagle, and Yanuo Zhou. 2024. "The Value of Open Source Software." *Harvard Business School Working Paper* 24-038. <https://doi.org/10.2139/ssrn.4693148>.
- IETF. 2018. *Interactive Connectivity Establishment (ICE): A Protocol for Network Address Translator Traversal*. RFC 8445. <https://doi.org/10.17487/RFC8445>.
- IETF. 2021a. *Overview: Real-Time Protocols for Browser-Based Applications*. RFC 8825. <https://doi.org/10.17487/RFC8825>.
- IETF. 2021b. *WebRTC Data Channels*. RFC 8831. <https://doi.org/10.17487/RFC8831>.
- IETF. 2023. *The Messaging Layer Security (MLS) Protocol*. RFC 9420. <https://doi.org/10.17487/RFC9420>.

- IETF. 2025. *The Messaging Layer Security (MLS) Architecture*. RFC 9750. <https://doi.org/10.17487/RFC9750>.
- Introna, Lucas D., and Helen Nissenbaum. 2000. "Shaping the Web: Why the Politics of Search Engines Matters." *The Information Society* 16 (3): 169–185. <https://doi.org/10.1080/01972240050133634>.
- Jhaveri, Shagun, Amy Bruckman, and Eric Gilbert. 2019. "Does Transparency in Moderation Really Matter? User Behavior after Content Removal Explanations on Reddit." *Proceedings of the ACM on Human-Computer Interaction* 3 (CSCW), Article 150. <https://doi.org/10.1145/3359252>.
- Kalla, Joshua L., and David E. Broockman. 2018. "The Minimal Persuasive Effects of Campaign Contact in General Elections: Evidence from 49 Field Experiments." *American Political Science Review* 112 (1): 148–166. <https://doi.org/10.1017/S0003055417000363>.
- Kanich, Chris, Christian Kreibich, Kirill Levchenko, Brandon Enright, Geoffrey M. Voelker, Vern Paxson, and Stefan Savage. 2009. "Spamalytics: An Empirical Analysis of Spam Marketing Conversion." *Communications of the ACM* 52 (9): 99–107. <https://doi.org/10.1145/1562164.1562190>.
- Khezresmaeilzadeh, Tina, Jiang Zhang, Dimitrios Andreadis, and Konstantinos Psounis. 2025. "Preserving Privacy and Utility in LLM-Based Product Recommendations." *arXiv:2505.00951*.
- Knijnenburg, Bart P., Martijn C. Willemsen, Zeno Gantner, Hakan Soncu, and Chris Newell. 2012. "Explaining the User Experience of Recommender Systems." *User Modeling and User-Adapted Interaction* 22: 441–504. <https://doi.org/10.1007/s11257-011-9118-4>.
- Konstan, Joseph A., and John Riedl. 2012. "Recommender Systems: From Algorithms to User Experience." *User Modeling and User-Adapted Interaction* 22 (1–2): 101–123. <https://doi.org/10.1007/s11257-011-9112-x>.
- Leiner, Barry M., Vinton G. Cerf, David D. Clark, Robert E. Kahn, Leonard Kleinrock, Daniel C. Lynch, Jon Postel, Larry G. Roberts, and Stephen Wolff. 1997. "A Brief History of the Internet." *Internet Society*, subsequently updated.
- Liu, Jiahao, Mingzhe Han, Guanming Liu, Weihang Wang, Dongsheng Li, Hansu Gu, Peng Zhang, Tun Lu, and Ning Gu. 2026. "From Hidden Profiles to Governable Personalization: Recommender Systems in the Age of LLM Agents." *arXiv:2604.20065*.

- Lorenz-Spreen, Philipp, Bjarke Mørch Mønsted, Philipp Hövel, and Sune Lehmann. 2019. "Accelerating Dynamics of Collective Attention." *Nature Communications* 10: 1759. <https://doi.org/10.1038/s41467-019-09311-w>.
- Matias, J. Nathan. 2019. "The Civic Labor of Volunteer Moderators Online." *Social Media + Society* 5 (2). <https://doi.org/10.1177/2056305119836778>.
- Matz, Sandra C., Michal Kosinski, Gideon Nave, and David J. Stillwell. 2017. "Psychological Targeting as an Effective Approach to Digital Mass Persuasion." *Proceedings of the National Academy of Sciences* 114 (48): 12714–12719. <https://doi.org/10.1073/pnas.1710966114>.
- O'Mahony, Siobhán, and Fabrizio Ferraro. 2007. "The Emergence of Governance in an Open Source Community." *Academy of Management Journal* 50 (5): 1079–1106. <https://doi.org/10.5465/amj.2007.27169153>.
- Ostrom, Elinor. 1990. *Governing the Commons: The Evolution of Institutions for Collective Action*. Cambridge: Cambridge University Press. <https://doi.org/10.1017/CBO9780511807763>.
- Rathje, Steve, Jay J. Van Bavel, and Sander van der Linden. 2021. "Out-Group Animosity Drives Engagement on Social Media." *Proceedings of the National Academy of Sciences* 118 (26): e2024292118. <https://doi.org/10.1073/pnas.2024292118>.
- Saltzer, Jerome H., David P. Reed, and David D. Clark. 1984. "End-to-End Arguments in System Design." *ACM Transactions on Computer Systems* 2 (4): 277–288. <https://doi.org/10.1145/357401.357402>.
- Schneider, Nathan. 2024. *Governable Spaces: Democratic Design for Online Life*. Oakland: University of California Press. <https://doi.org/10.1525/luminos.181>.
- Shao, Chengcheng, Giovanni Luca Ciampaglia, Onur Varol, Kai-Cheng Yang, Alessandro Flammini, and Filippo Menczer. 2018. "The Spread of Low-Credibility Content by Social Bots." *Nature Communications* 9: 4787. <https://doi.org/10.1038/s41467-018-06930-7>.
- Shaw, Aaron, and Benjamin Mako Hill. 2014. "Laboratories of Oligarchy? How the Iron Law Extends to Peer Production." *Journal of Communication* 64 (2): 215–238. <https://doi.org/10.1111/jcom.12082>.
- Shumailov, Ilia, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. 2024. "AI Models Collapse When Trained on

- Recursively Generated Data.* *Nature* 631: 755–759. <https://doi.org/10.1038/s41586-024-07566-y>.
- Suler, John. 2004. “The Online Disinhibition Effect.” *CyberPsychology & Behavior* 7 (3): 321–326. <https://doi.org/10.1089/1094931041291295>.
- Suzor, Nicolas P. 2019. *Lawless: The Secret Rules That Govern Our Digital Lives*. Cambridge: Cambridge University Press. <https://doi.org/10.1017/9781108666428>.
- Tandoc, Edson C., Jr., Zheng Wei Lim, and Richard Ling. 2018. “Defining ‘Fake News’: A Typology of Scholarly Definitions.” *Digital Journalism* 6 (2): 137–153. <https://doi.org/10.1080/21670811.2017.1360143>.
- Terranova, Tiziana. 2000. “Free Labor: Producing Culture for the Digital Economy.” *Social Text* 18 (2): 33–58. https://doi.org/10.1215/01642472-18-2_63-33.
- Turner, Fred. 2006. *From Counterculture to Cyberculture: Stewart Brand, the Whole Earth Network, and the Rise of Digital Utopianism*. Chicago: University of Chicago Press.
- United States Senate Select Committee on Intelligence. 2019. *Russian Active Measures Campaigns and Interference in the 2016 U.S. Election, Volume 2: Russia’s Use of Social Media with Additional Views*. Washington, DC: United States Senate.
- Vosoughi, Soroush, Deb Roy, and Sinan Aral. 2018. “The Spread of True and False News Online.” *Science* 359 (6380): 1146–1151. <https://doi.org/10.1126/science.aap9559>.
- W3C. 2018. ActivityPub. W3C Recommendation, 23 January 2018. <https://www.w3.org/TR/activitypub/>.
- W3C. 2022. Decentralized Identifiers (DIDs) v1.0. W3C Recommendation, 19 July 2022. <https://www.w3.org/TR/did-core/>.
- W3C. 2025a. WebRTC: Real-Time Communication in Browsers. W3C Recommendation, 13 March 2025. <https://www.w3.org/TR/webrtc/>.
- W3C. 2025b. Verifiable Credentials Data Model v2.0. W3C Recommendation, 15 May 2025. <https://www.w3.org/TR/vc-data-model-2.0/>.
- W3C. 2026. Decentralized Identifiers (DIDs) v1.1. W3C Candidate Recommendation Snapshot, 5 March 2026. <https://www.w3.org/TR/did-1.1/>.

Wagner, Claudia, Eduardo Graells-Garrido, David Garcia, and Filippo Menczer. 2016. "Women through the Glass Ceiling: Gender Asymmetries in Wikipedia." *EPJ Data Science* 5: 5. <https://doi.org/10.1140/epjds/s13688-016-0066-4>.

Walter, Nathan, and Sheila T. Murphy. 2018. "How to Unring the Bell: A Meta-Analytic Approach to Correction of Misinformation." *Communication Monographs* 85 (3): 423–441. <https://doi.org/10.1080/03637751.2018.1467564>.

Yun, Jinhyuk, Sang Hoon Lee, and Hawoong Jeong. 2019. "Early Onset of Structural Inequality in the Formation of Collaborative Knowledge in All Wikimedia Projects." *Nature Human Behaviour* 3 (2): 155–163. <https://doi.org/10.1038/s41562-018-0488-z>.