

AUTOPSIE DES ÉMOTIONS FUTURES

Entre darwinisme psychologique, histoire, anthropologie et
monde de l'intelligence artificielle



Droits d'auteur © [2026] Axiologic Research

Tous droits réservés.

Droits d'édition KDP détenus par Outfinity SRL (Iași, Roumanie).

Disponible gratuitement sur le site Axiologic (www.axiologic.net).

Note de l'auteur

Ce travail a été réalisé sous l'égide de Axiologic Research dans le cadre de deux programmes de recherche interconnectés, l'un dédié à l'Intelligence Artificielle et l'autre à l'Outfinitiisme, tous deux dirigés par Sinică Alboaică. Pour explorer les détails de la façon dont ces deux programmes se croisent et s'appuient l'un sur l'autre, nous invitons les lecteurs à visiter la page Outfinity Venture Studio à l'adresse www.outfinity.ch.

Alors que les modèles linguistiques d'intelligence artificielle ont été utilisés pour aider à la génération de texte, la philosophie fondamentale, la structure thématique et l'approche analytique dérivent exclusivement des décennies d'étude dédiée de l'auteur aux phénomènes sociaux, aux technologies sociales et aux véritables technologies dures résultant de divers projets de recherche européens et autofinancés. Récemment, dans le cadre du projet de recherche Achilles, nous avons étudié en profondeur la littérature générée par l'IA et sa vérification automatisée à l'aide d'approches neuro-symboliques ; tous les livres gratuits mis à disposition du public font partie de la suite d'ouvrages que nous utilisons pour tester nos dernières technologies.

Table des matières

Note méthodologique : qu'est-ce que la preuve, qu'est-ce que l'interprétation et qu'est-ce que la spéculation	6
Introduction : Pourquoi une théorie de l'émotion est nécessaire pour comprendre un monde automatisé	8
Chapitre 1. Qu'est-ce qu'une émotion et que peut expliquer l'évolution ?	10
1.1 Une catégorie scientifique sans définition unique	10
1.2 Explication fonctionnelle et danger des histoires évolutives pratiques	10
1.3 Les émotions comme programmes de coordination plutôt que comme commandes infaillibles	11
1.4 Le sentiment de conscience et le problème de l'accès à soi	12
1.5 Un modèle de travail pour le reste du livre	12
Chapitre 2. Les émotions comme infrastructure de l'interaction sociale	13
2.1 De la régulation de l'organisme à la régulation de la relation	13
2.2 Peur et anxiété : gérer l'incertitude et le danger	14
2.3 Colère : renégocier les relations et signaler les limites	14
2.4 Dégoût et contamination : protection biologique et frontière morale	15
2.5 Tristesse et chagrin : des réponses à la perte, pas des solutions simples	15
2.6 Les émotions ne sont pas seulement des messages sincères	16
Chapitre 3. Statut, coopération et moralité affective	17
3.1 Pourquoi le statut produit une émotion intense	17
3.2 Fierté : retours sur la valeur et le risque d'inflation	17
3.3 Honte et culpabilité : dévaluation, responsabilité et réparation	18
3.4 Envie et jalousie : comparaison, accès et relations difficiles à remplacer	18
3.5 Gratitude, confiance et réciprocité synthétique	19
3.6 Compassion et indignation : la moralité n'est pas un seul système	19
3.7 Appartenance et solitude : déficit relationnel ou signal de reconnexion	20
3.8 Une constitution affective informelle	20
Chapitre 4. La culture ne se contente pas de nommer les émotions	22
4.1 Entre universalité et variation	22
4.2 Les concepts d'émotion comme instruments de perception et d'action	22
4.3 Communautés émotionnelles et régimes affectifs	23
4.4 Capitalisme, professions et culture du moi productif	23
4.5 Les plateformes comme environnements de sélection affective	23
4.6 Comment pourrions-nous reconnaître une nouvelle catégorie d'émotions ?	24
Chapitre 5. Le travail en tant qu'institution affective et l'incertitude de l'automatisation	25
5.1 Le travail apporte plus qu'un revenu, mais il ne donne pas toujours du sens	25
5.2 Ce que l'on sait des effets actuels de l'IA sur le travail	25
5.3 Tâche, profession et identité	26
5.4 Quatre scénarios pour la relation entre l'IA et le travail	26
5.5 Quelles pénuries subsistent lorsque la production cognitive devient bon marché ?	27
5.6 Effort, valeur et rareté volontaire	27
5.7 Le revenu seul ne résout pas la transition affective	27
5.8 La transition peut être plus importante que la destination	28
Chapitre 6. Trois vitesses d'évolution affective	29
6.1 L'évolution biologique ne s'est pas arrêtée, mais ce n'est pas l'explication la plus proche	29
6.2 Développement : l'échelle de temps d'une vie	29
6.3 Évolution culturelle : variation, transmission et sélection	30
6.4 Sélection algorithmique : une accélération, pas de la magie	30
6.5 La boucle entre les trois vitesses	30
6.6 Ce que l'évolution émotionnelle délibérée peut et ne peut pas faire	31

Chapitre 7. De nouvelles émotions peuvent-elles apparaître ?	32
7.1 Quatre significations de la nouveauté	32
7.2 Une nouvelle émotion ne nécessite pas une physiologie exclusive	32
7.3 Nouvel objet, nouvelle évaluation ou nouvelle relation	32
7.4 Sélection culturelle d'un vocabulaire affectif	33
7.5 Quand un concept aide et quand il crée des artefacts	33
7.6 Une échelle de plausibilité	34
7.7 Prédications qui pourraient falsifier les hypothèses	34
Chapitre 8. Un atlas provisoire des effets dans un monde automatisé	36
8.1 Deuil de compétence	36
8.2 Honte de délégation	36
8.3 Ambiguïté affective de la paternité	37
8.4 Anxiété liée à la pertinence	37
8.5 Vertiges d'abondance	38
8.6 Faim de friction	38
8.7 Fierté conservatrice et responsabilité architecturale	38
8.8 Claustrophobie prédictive et désir d'opacité	39
8.9 Deuil de version	39
8.10 Inconfort de la réciprocité synthétique	39
8.11 Culpabilité de distance morale	39
8.12 Mélancolie de l'exceptionnalisme humain	40
8.13 La dignité improductive comme sentiment cultivé	40
8.14 Qu'est-ce qui rendrait l'atlas erroné	40
Chapitre 9. Relations avec les agents qui semblent sociaux	42
9.1 Le problème peut être formulé sans décider de la conscience de l'IA	42
9.2 Pourquoi les systèmes conversationnels activent des mécanismes sociaux	42
9.3 Ce que montrent les premières recherches et ce qu'elles ne peuvent pas encore montrer	42
9.4 Complément, outil de formation ou substitut	43
9.5 Réciprocité non vérifiable	43
9.6 Mémoire, personnalité et continuité	44
9.7 Compagnons des enfants et des utilisateurs vulnérables	44
9.8 Travail émotionnel automatisé	44
9.9 L'amour envers l'IA repose sur plusieurs questions différentes	45
9.10 Comment l'IA peut modifier les relations entre les humains	45
Chapitre 10. De l'affect à la stratégie : l'adaptation comportementale dans un monde médiatisé par l'IA	46
10.1 Pourquoi le comportement doit être analysé séparément de l'émotion	46
10.2 La délégation devient une compétence plutôt qu'une absence de compétence	46
10.3 Préservation stratégique des compétences et valeur de friction	47
10.4 Signalisation de provenance et prime humaine	47
10.5 Migration de statut : de l'exécution à la sélection, l'arbitrage et la responsabilité	47
10.6 Portefeuilles d'identités et adaptation par optionnalité	48
10.7 L'IA comme coach social, intermédiaire et arbitre	48
10.8 Coalitions, communautés et reconstruction de la pénurie sociale	49
10.9 Stratégies défensives contre la persuasion personnalisée	49
10.10 Comportement institutionnel : provenance, audit et séparation des responsabilités	50
10.11 Six phénotypes comportementaux possibles	51
10.12 Que peut-on tester au cours de la prochaine décennie	51
Chapitre 11. Tempo affectif : comment les émotions simulées dans l'IA peuvent changer la communication humaine	53
11.1 Le temps fait partie du message	53

11.2 Une émotion simulée n'est pas une émotion ressentie, mais elle peut avoir des effets sociaux	53
11.3 Disponibilité permanente et recalibrage du seuil de réponse	54
11.4 Accélération du traitement affectif grâce à un interlocuteur toujours disponible	54
11.5 De la conversation épisodique au flux affectif continu	54
11.6 Adaptation linguistique : l'IA s'adapte à nous, mais est-ce que nous nous adaptons à l'IA ?	55
11.7 Standardisation de la chaleur et nouveau seuil de politesse	55
11.8 Transfert des attentes : le risque d'intolérance aux frictions humaines	56
11.9 Révélation accélérée de soi et problème de l'intimité bon marché	57
11.10 L'IA comme traductrice d'émotions entre humains	57
11.11 Authenticité lorsque l'intention et la formulation sont séparées	58
11.12 Déqualification sociale ou école permanente de communication ?	58
11.13 L'enfance et l'apprentissage des normes de réciprocité	59
11.14 Contre-sélection : retour délibéré au lent, maladroit et non révisé	59
11.15 Une taxonomie du changement temporel et sa plausibilité	60
Chapitre 12. Vers une écologie affective délibérée	61
12.1 Pourquoi le problème ne peut pas être réduit à la résilience individuelle	61
12.2 L'agence comme principe de conception	61
12.3 Protéger la compétence sans préserver l'inefficacité	61
12.4 Le droit de contribuer et le droit de ne pas produire	61
12.5 Institutions d'appartenance au-delà de l'entreprise	61
12.6 Rareté volontaire et zones sans optimisation	62
12.7 Gouvernance des relations avec l'IA	62
12.8 Provenance et normes d'expression assistée	62
12.9 Protection contre l'optimisation affective cachée	62
12.10 Un programme de recherche pour les émotions futures	62
12.11 Limites de la conception délibérée	63
Conclusion : continuité biologique et discontinuité du monde	64
Annexe. Matrice synthétique des scénarios	66
Niveaux de réclamation utilisés dans le livre	66
Affects futurs candidats	66
Scénarios comportementaux et communicatifs	66
Références	68

Note méthodologique : qu'est-ce que la preuve, qu'est-ce que l'interprétation et qu'est-ce que la spéculation

Ce livre pose une question pour laquelle aucune discipline seule ne suffit : comment la vie émotionnelle humaine pourrait-elle changer lorsque l'intelligence artificielle devient un élément persistant du travail, de la communication, de la compétition de statut, de la prise de décision et des interactions intimes ? La première difficulté est conceptuelle. Il n'existe aucune définition scientifique universellement acceptée d'une émotion, aucune liste établie d'émotions et aucun consensus sur la mesure dans laquelle des catégories familières telles que la peur, la colère, la honte, la fierté ou l'amour correspondent à des systèmes biologiquement distincts. La deuxième difficulté est temporelle. Les technologies évoquées ici évoluent plus rapidement que les données factuelles. La troisième est méthodologique. Une fonction évolutive plausible n'est pas la même chose qu'une histoire évolutive démontrée, et une possibilité technologique n'est pas une prévision.

Pour éviter de réduire ces différences, l'argument utilise quatre niveaux de confiance. La première consiste en des observations empiriques relativement robustes : par exemple, la perte d'emploi est associée en moyenne à des conséquences psychologiques défavorables ; que l'expression émotionnelle modifie l'interaction ; que les humains attribuent facilement des propriétés sociales aux machines réactives ; et que l'IA générative peut modifier l'exécution des tâches et l'expérience subjective de l'action dans certains contextes. La seconde consiste en des interprétations fonctionnelles plausibles et liées à des littératures établies, comme la proposition selon laquelle la honte aide à réguler les menaces de dévaluation sociale ou que la gratitude stabilise les relations de coopération. Ces interprétations peuvent être utiles sans prouver qu'une adaptation dédiée a été sélectionnée exactement pour cette fonction. Le troisième niveau consiste en des extrapolations conditionnelles. Si l'IA réduit considérablement la rareté de certains résultats cognitifs, si elle devient un intermédiaire de routine dans la communication ou si les agents sociaux deviennent disponibles en permanence, alors des adaptations comportementales et affectives particulières deviennent plus probables. Le quatrième niveau consiste en une spéculation conceptuelle explicite : d'éventuelles catégories d'émotions futures, des normes sociales ou des institutions pour lesquelles des preuves directes n'existent pas encore.

Le terme « darwinisme psychologique » est donc utilisé de manière restrictive. Cela ne signifie pas que chaque trait est adaptatif, que les hiérarchies sociales actuelles sont biologiquement nécessaires ou que le succès reproductif fournit une justification morale. Cela signifie que les esprits ont des histoires, que les problèmes récurrents de survie et de coordination ont façonné les organismes, et que la variation, la sélection, le développement et la transmission culturelle peuvent éclairer la récurrence de certaines tendances psychologiques. La sélection naturelle produit également des compromis, des sous-produits, des vulnérabilités développementales et des mécanismes qui peuvent devenir inadaptés lorsque les environnements changent. Un récit évolutionniste est un cadre générateur d'hypothèses, et non une licence pour une narration rétrospective.

Le livre distingue également l'émotion, le sentiment, l'affect, l'humeur et le comportement lorsque la distinction est importante. Une émotion est traitée provisoirement comme un épisode relativement limité impliquant l'évaluation d'une situation pertinente, des changements dans l'attention et la motivation, la régulation corporelle, les tendances à l'action et parfois l'expression sociale. Un sentiment est l'expérience consciemment accessible d'un tel état ou d'une orientation évaluative plus durable. L'affect fait référence plus largement à la valence et à l'activation, tandis que l'humeur décrit un état plus diffus sans un seul objet clair. Ces définitions sont pratiques plutôt que doctrinales. Plus importante pour l'extension développée ici est la distinction entre un état interne et une stratégie comportementale. La peur peut coexister avec le retrait, la recherche d'informations, la constitution

d'une coalition, l'assurance ou la confrontation. La honte peut produire une dissimulation, des excuses, une réparation, une agression ou une sortie. Dans un monde médiatisé par l'IA, l'adaptation qui en résulte peut souvent se produire au niveau de la stratégie plutôt qu'au niveau d'un nouveau sentiment.

C'est pour cette raison que les chapitres 10 et 11 étendent l'analyse précédente dans deux directions. Le chapitre 10 adopte une perspective comportementale et institutionnelle. Il s'interroge sur ce que les gens pourraient faire de manière répétée lorsque l'IA modifie le coût de production de résultats compétents, la visibilité de la contribution individuelle, la répartition de l'expertise et la structure du statut. Il examine la délégation, la vérification, la préservation des compétences, la signalisation de provenance, la formation de coalitions, la diversification identitaire et les nouvelles divisions des responsabilités. Le chapitre 11 se demande ce qui se passe lorsque l'interlocuteur social lui-même change. Les assistants IA peuvent être disponibles en permanence, réactifs rapidement, adaptatifs linguistiquement et capables de simuler la patience, la chaleur, l'hésitation, l'enthousiasme, la sympathie ou l'inquiétude. Même si ces affichages ne témoignent pas des émotions ressenties dans la machine, ils peuvent modifier les attentes humaines concernant le moment et la forme de communication.

Le fondement empirique de ces deux chapitres est plus mince que les preuves de nombreuses découvertes classiques sur l'émotion. Des expériences récentes suggèrent que la collaboration homme-IA ne surpasse pas automatiquement le meilleur acteur humain ou IA, que l'IA générative peut orienter l'effort de pensée critique vers la vérification et l'intégration, et que les protocoles d'interaction sont importants. D'autres travaux suggèrent que le contenu conversationnel généré par l'IA peut affecter la proximité perçue, que les utilisateurs et les modèles linguistiques peuvent s'adapter linguistiquement les uns aux autres et que l'exposition aux styles d'IA peut se répercuter sur une interaction humaine-humaine ultérieure. Ce sont les premiers résultats. Beaucoup sont basés sur de courtes expériences, des échantillons auto-sélectionnés, des tâches restreintes ou des modèles rapidement obsolètes. Ils doivent être traités comme des mécanismes méritant d'être testés, et non comme des descriptions établies de la culture future.

La même prudence s'applique au vocabulaire des émotions futures du livre. Des termes tels que deuil de compétence, honte de délégation, claustrophobie prédictive ou deuil de version ne sont pas proposés comme types naturels découverts. Ce sont des étiquettes analytiques pour des configurations récurrentes qui pourraient devenir culturellement marquantes. Une catégorie ne mériterait un statut plus fort que si elle se révélait stable parmi les personnes et les contextes, si elle acquérait des déclencheurs et des tendances d'action reconnaissables, si elle soutenait une communication fiable et si elle persistait au-delà d'une mode technologique temporaire. Le livre est donc volontairement asymétrique : il veut bien spéculer, mais il précise aussi où commence la spéculation.

Introduction : Pourquoi une théorie de l'émotion est nécessaire pour comprendre un monde automatisé

Le débat public sur l'intelligence artificielle se concentre naturellement sur les capacités, la productivité, les salaires, la propriété et la répartition du pouvoir. Ce sont des questions indispensables, mais le travail est plus qu'un moyen de produire des biens et de distribuer des revenus. Il organise également le temps, attribue des positions sociales, certifie les compétences, crée des relations répétées, distribue le prestige et donne aux individus un vocabulaire pour expliquer leur utilité. Si l'intelligence artificielle modifie profondément le travail, elle modifie une partie de l'environnement dans lequel les émotions sont suscitées, interprétées, récompensées et disciplinées.

Cette affirmation ne suppose pas que les émotions soient des conventions fragiles qui changent à chaque évolution technologique. La peur, l'attachement, la colère, la recherche de récompense, l'excitation corporelle et la sensibilité à l'exclusion ont des racines bien plus anciennes que l'emploi industriel. Ce qui change plus rapidement, ce sont les objets auxquels ces systèmes sont attachés, les évaluations qui les activent, les institutions qui récompensent ou suppriment leur expression et les stratégies que les gens apprennent en réponse. La honte d'un fonctionnaire de justice, la honte d'un ouvrier industriel et la honte d'un étudiant qui s'appuie sur un modèle génératif ne sont pas nécessairement des phénomènes sociaux identiques, même si elles recrutent des ressources affectives qui se chevauchent.

La prémisse centrale de ce livre est que les émotions ont au moins quatre types de fonctions. Ils coordonnent l'organisme en réaffectant l'attention et l'action sous la pression du temps. Ils coordonnent l'interaction en signalant les intentions, les besoins, les limites et les évaluations. Ils maintiennent l'ordre du groupe en contribuant à la conformité, à la réparation, à la punition, à la gratitude, à la confiance et à la répartition des statuts. Enfin, ils peuvent être cultivés de manière institutionnelle. Les rituels, l'éducation, la religion, les professions, les marchés, les organisations et les plateformes numériques rendent certaines réponses émotionnelles plus visibles et plus gratifiantes que d'autres. Cela ne veut pas dire que les institutions installent directement des émotions. Cela signifie qu'ils modifient l'écologie dans laquelle les dispositions émotionnelles sont apprises, affichées et socialement sélectionnées.

L'automatisation ne doit donc pas être considérée uniquement comme une substitution à une tâche. Elle peut être traitée comme une perturbation d'une écologie affective. Un système génératif peut réduire l'effort requis pour produire un rapport tout en réduisant également le sentiment d'appartenance de l'auteur. Cela pourrait démocratiser l'accès à une expression compétente tout en rendant la compétence plus difficile à déduire du produit fini. Cela peut offrir de la camaraderie tout en modifiant les attentes en matière de réactivité. Cela peut rendre la persuasion moins coûteuse tout en augmentant la valeur de la provenance fiable. Les conséquences psychologiques dépendent des droits de propriété, des institutions du travail, des normes professionnelles, de l'éducation, de la conception des plateformes et de la répartition des gains issus de l'automatisation. Il n'y a pas d'avenir émotionnel unique impliqué par la technologie.

La question de savoir si des émotions véritablement nouvelles peuvent apparaître nécessite une distinction supplémentaire. « Nouveau » peut signifier un nouveau mécanisme biologique, une nouvelle combinaison de mécanismes plus anciens, une nouvelle catégorie culturellement reconnue, un nouvel objet pour une émotion ancienne, ou un nouveau modèle d'évaluation et d'action institutionnellement stabilisé. Un système émotionnel biologiquement nouveau, à l'échelle de l'espèce, émergeant au cours de quelques décennies n'est pas particulièrement plausible. L'évolution génétique humaine se poursuit, mais l'échelle de temps et les conditions de sélection en font une explication faible des changements à court terme. En revanche, de nouveaux concepts

émotionnels culturellement stabilisés peuvent apparaître beaucoup plus rapidement. Les travaux historiques sur les vocabulaires émotionnels, les variations interculturelles de la sémantique des émotions et les théories de la construction émotionnelle soutiennent tous la possibilité que les sociétés puissent réorganiser la manière dont l'expérience affective est interprétée et communiquée sans attendre un nouveau circuit neuronal.

L'affirmation la plus importante du livre est donc modérée. Une société technologiquement transformée ne fabriquera probablement pas une architecture affective mammifère entièrement nouvelle. Cela peut néanmoins générer de nouvelles situations récurrentes, de nouveaux systèmes de statut, de nouvelles formes de dépendance, de nouveaux types d'ambiguïté sur la paternité et la réciprocité, et de nouvelles normes sur ce qui mérite fierté ou honte. Ces changements peuvent produire des configurations qui deviennent socialement suffisamment distinctes pour acquérir des noms et des scripts. Si cela se produit, les qualifier de nouvelles émotions peut être justifié d'un point de vue culturel et fonctionnel, même si leurs ingrédients biologiques sont anciens.

L'argumentation se déroule en trois mouvements. La première reconstruit les émotions comme mécanismes biologiques et sociaux tout en préservant les controverses théoriques majeures. La seconde examine la culture, le travail et la possibilité d'un changement affectif accéléré grâce à l'IA. Le troisième passe du ressenti à la stratégie et de la stratégie à la communication. Elle demande non seulement ce que les gens pourraient ressentir, mais aussi ce qu'ils apprendront à faire de manière répétée : ce qu'ils délèguent, ce qu'ils vérifient, comment ils signalent leur contribution, quelles compétences ils préservent, comment ils forment des coalitions et comment ils gèrent leurs relations avec des agents qui simulent la réactivité sociale.

Ce mouvement comportemental est important car les émotions ne déterminent pas une seule action. Une personne effrayée peut éviter, se préparer, chercher des alliés, souscrire une assurance, recueillir des informations ou attaquer. Un travailleur dont l'expertise est dévalorisée par l'automatisation peut dissimuler son utilisation de l'IA, intensifier sa formation, se tourner vers un domaine dans lequel le jugement est rare, se forger une réputation de vérification ou se retirer complètement de son identité professionnelle. Ce sont des équilibres stratégiques différents qui peuvent émerger de pressions affectives similaires. Pour les prévoir, il faut prêter attention aux incitations et aux institutions, et pas seulement à l'introspection.

L'IA conversationnelle introduit une deuxième dimension négligée : le temps. La communication humaine est limitée par le sommeil, l'attention, la gêne, les obligations sociales, le retard de réflexion et le fait que les autres ont une vie indépendante. Un interlocuteur artificiel peut être disponible en permanence, répondre immédiatement, se souvenir des échanges précédents, ajuster son style et générer un langage émotionnellement approprié pour un coût marginal négligeable. Cela peut changer la vitesse à laquelle les gens révèlent, répètent, réparent, intensifient et réinterprètent leurs émotions. Cela peut également créer des attentes difficiles à satisfaire dans les relations humaines. L'ampleur de ces effets est inconnue ; les études actuelles sont trop courtes et les systèmes trop nouveaux. Mais les mécanismes sont suffisamment plausibles pour mériter une analyse dès maintenant.

Il ne s'agit pas d'annoncer que l'IA va inévitablement appauvrir ou enrichir la vie émotionnelle. Les deux résultats sont possibles et peuvent se produire simultanément pour différents groupes. L'objectif est d'identifier les variables qui rendraient une trajectoire plus probable qu'une autre et de rendre les affirmations futures vérifiables. En ce sens, une théorie sérieuse des émotions futures n'est pas essentiellement un vocabulaire de sentiments exotiques. Il s'agit d'un récit de la manière dont les anciens systèmes biologiques, l'apprentissage culturel, les institutions et les environnements algorithmiques peuvent réorganiser conjointement le comportement humain.

Chapitre 1. Qu'est-ce qu'une émotion et que peut expliquer l'évolution ?

1.1 Une catégorie scientifique sans définition unique

La science des émotions étudie une classe de phénomènes reconnaissables dans la vie ordinaire mais difficiles à délimiter scientifiquement. La peur diffère du simple jugement selon lequel quelque chose est dangereux car elle peut impliquer une excitation corporelle, une attention sélective, des tendances à l'évitement, des changements de mémoire et une expression sociale. Pourtant, aucun de ces composants n'est nécessaire dans chaque épisode. Les gens peuvent signaler une peur avec une faible activation physiologique, afficher des réactions défensives sans se décrire consciemment comme effrayés ou interpréter une excitation corporelle similaire comme de l'excitation, de la colère ou de l'anxiété selon le contexte.

Les théories classiques ont réagi différemment [Panksepp, 1998 ; Scherer, 2009 ; Barrett, 2017]. Les approches basées sur les émotions recherchent un ensemble limité de familles conservées au cours de l'évolution avec des expressions et des fonctions caractéristiques. Les théories de l'évaluation mettent l'accent sur la manière dont les organismes évaluent la nouveauté, la contrôlabilité, la pertinence des objectifs, la compatibilité avec les normes, la responsabilité et la capacité d'adaptation. Les approches dimensionnelles décrivent l'expérience selon des axes tels que la valence et l'excitation. Les théories constructionnistes mettent l'accent sur la prédiction, l'intéroception, les concepts et les catégories apprises. La neuroscience affective identifie d'anciens systèmes motivationnels et défensifs tout en restant prudent quant à la cartographie de chaque mot du langage ordinaire sur un circuit isolé. Le désaccord n'est pas seulement terminologique, mais il n'est pas non plus total. La plupart des récits contemporains acceptent des variations contextuelles substantielles et des contraintes imposées par le corps et le système nerveux.

Aux fins d'une analyse prospective, un modèle à plusieurs niveaux est plus utile qu'un choix prématuré entre les camps. À un niveau se trouvent la régulation énergétique, l'excitation, la douleur, la récompense, l'inflammation, les changements autonomes et les signaux intéroceptifs. D'un autre côté se trouvent les systèmes d'orientation et d'action associés à l'évitement, à l'approche, aux soins, à l'exploration, à la défense et à la recherche de récompense. Au troisième rang se trouvent les évaluations des relations entre les événements, les objectifs, les normes et soi. Au quatrième rang se trouvent les concepts appris qui organisent l'expérience et rendent les distinctions communicables. Les institutions déterminent ensuite quelles situations se produisent de manière répétée et quelles expressions sont récompensées ou punies. Ces niveaux interagissent plutôt que de former une hiérarchie rigide.

Un tel modèle explique pourquoi le changement technologique peut avoir de l'importance sans supposer qu'un nouvel appareil recâble instantanément la nature humaine. Un enfant né dans un monde d'IA persistante héritera probablement de capacités familiales d'attachement, de détection des menaces, de jeu et de sensibilité au statut. L'enfant peut néanmoins apprendre différents objets d'attachement, différents critères de compétence, différentes règles d'authenticité et différentes attentes en matière de disponibilité sociale. Les combinaisons récurrentes peuvent éventuellement acquérir leurs propres noms et scripts comportementaux.

Le désaccord n'est pas seulement terminologique. Une théorie qui traite les émotions principalement comme des programmes d'action évolués pose des questions différentes d'une théorie qui met l'accent sur l'inférence prédictive, la conceptualisation ou les catégories socialement apprises. Le premier recherche des problèmes d'adaptation récurrents et des modèles de réponse coordonnés ; la seconde demande comment les signaux corporels, les attentes antérieures, le langage et le contexte sont assemblés en un épisode que la personne reconnaît comme de la peur, de la honte ou

de la fierté. Les deux perspectives bénéficient d'un soutien empirique et aucune ne justifie actuellement de réduire tous les phénomènes émotionnels à un seul mécanisme. Pour les besoins de ce livre, la conséquence importante est méthodologique : les affirmations sur les émotions futures doivent préciser quel niveau est censé changer. Une nouvelle catégorie sociale peut apparaître sans nouvelle signature autonome, et un état physiologique familier peut acquérir un objet, une signification ou un script comportemental différent. Traiter ces niveaux séparément évite que la nouveauté culturelle soit confondue avec une évolution biologique rapide.

1.2 Explication fonctionnelle et danger des histoires évolutives pratiques

Le raisonnement évolutionniste se demande quel problème récurrent un état psychologique aurait pu aider les organismes à résoudre et quelles prédictions découlent de cette hypothèse. La peur peut donner la priorité aux informations sur les menaces et préparer l'évitement ou la défense. La colère peut rendre la confrontation plus crédible et signaler que les conditions actuelles sont inacceptables. La honte peut réduire les comportements qui risquent de dévaloriser la société. L'attachement peut stabiliser l'investissement à long terme dans les relations. Ces récits sont utiles car ils relient des changements autrement disparates en termes d'attention, de motivation, de physiologie et de comportement.

La méthode est également vulnérable aux élégantes histoires rétrospectives. Pour presque n'importe quel trait, on peut inventer une situation ancestrale dans laquelle le trait aurait été utile. La cohérence ne constitue pas une preuve qu'un mécanisme a été sélectionné pour la fonction proposée. Des arguments plus solides nécessitent des prédictions indépendantes, des preuves interculturelles et comparatives, des données sur le développement, des corrélations avec la structure de la situation et, lorsque cela est possible, des preuves neurobiologiques ou génétiques. Ils doivent également distinguer les adaptations des sous-produits, des compromis et des réponses qui étaient autrefois utiles mais deviennent coûteuses dans des conditions nouvelles.

La fonction n'est pas équivalente à l'avantage actuel. Un système de détection des menaces orienté vers les fausses alarmes aurait pu s'adapter lorsque la disparition d'un prédateur était catastrophique et continuer de produire une anxiété pathologique dans un environnement moderne saturé de signaux ambigus. La vigilance du statut peut aider les gens à naviguer dans de petits groupes et devenir destructrice lorsque les mesures et les audiences sont continues. Les préférences pour les aliments riches en calories peuvent devenir inadaptées en cas d'abondance. Le concept de décalage évolutif est donc au cœur des futurs technologiques : les anciens mécanismes peuvent être activés par de nouveaux environnements d'une manière que leur histoire n'avait pas anticipée.

Une explication évolutionniste ne justifie pas non plus une norme. Si l'agression, la hiérarchie, la jalousie ou le favoritisme au sein d'un groupe ont eu des conséquences reproductives dans certains environnements historiques, il ne s'ensuit pas que les institutions devraient les préserver. L'explication et l'approbation morale sont des questions indépendantes. L'intérêt de comprendre un mécanisme est en partie de rendre possible une refonte délibérée.

1.3 Les émotions comme programmes de coordination plutôt que comme commandes infaillibles

En situation d'incertitude, un organisme ne peut pas recalculer toutes les conséquences possibles à partir des premiers principes. Les états émotionnels peuvent compresser l'expérience en priorités temporaires. Lorsqu'un danger apparaît, l'attention se rétrécit, les souvenirs liés à la menace deviennent accessibles, les signaux ambigus reçoivent un poids différent et les actions d'évitement ou de défense deviennent plus faciles. Lorsqu'une injustice est perçue, la colère peut accroître la volonté d'assumer des coûts dans la confrontation et exprimer le refus d'accepter les conditions

actuelles. La tristesse peut réduire l'engagement après une perte dans certains contextes, tandis que la culpabilité peut accroître l'attention portée à la réparation.

Appeler des programmes de coordination des émotions ne doit pas impliquer des scripts rigides. Le même État peut soutenir différents comportements en fonction du pouvoir, des normes, des compétences et du contexte. La colère chez un employé dépendant peut produire le silence et la rumination ; la colère chez un manager puissant peut produire une confrontation ; la colère chez un négociateur qualifié peut conduire à une vérification et à un recadrage. La peur peut générer la fuite, le gel, la préparation, la formation d'une alliance ou l'enquête. L'émotion modifie le paysage décisionnel mais ne sélectionne pas un mouvement inévitable.

Ce point est essentiel pour les scénarios d'IA. La technologie ne créera pas une « émotion d'automatisation » uniforme. Une personne peut évaluer un modèle génératif comme un outil d'autonomie, un rival, un professeur, une autorité opaque, un substitut à une institution sociale ou un instrument contrôlable. La même capacité technologique peut donc susciter des états et des stratégies différents. Les effets varieront en fonction de la profession, de la propriété, de l'âge, de l'identité professionnelle, de la confiance institutionnelle et du fait que les individus conservent un contrôle significatif.

Les expériences actuelles soutiennent déjà cette hétérogénéité. L'IA générative peut améliorer les performances de certaines tâches, en particulier pour les utilisateurs moins expérimentés, tandis que certaines formes de dépendance passive réduisent l'appropriation subjective, l'auto-efficacité ou le sens perçu. Les combinaisons humain-IA ne surpassent pas de manière fiable les meilleurs de l'humain et de l'IA dans toutes les tâches. L'unité d'analyse pertinente n'est donc pas « l'utilisation de l'IA » dans l'abstrait mais l'architecture de la collaboration : qui initie, qui vérifie, ce qui est visible, où réside la responsabilité et comment les erreurs sont corrigées.

1.4 Le sentiment de conscience et le problème de l'accès à soi

Un débat sur l'émotion concerne également ce qui est exactement mesuré. Les écologistes comportementaux peuvent étudier l'action défensive ; les neuroscientifiques peuvent étudier les circuits ; les psychologues peuvent demander aux participants ce qu'ils ressentent ; les anthropologues peuvent étudier des concepts et des rituels. Ces approches se chevauchent mais ne mesurent pas le même objet. Une réponse défensive peut survenir sans expérience de peur signalée, et une expérience consciente intense peut survenir sans signature physiologique distinctive.

Cette distinction est importante lorsque nous parlons d'émotions futures. Une « nouvelle émotion » peut apparaître d'abord comme une nouvelle façon de reconnaître et d'interpréter des expériences récurrentes plutôt que comme une nouvelle réponse biologique. Les gens peuvent apprendre à distinguer la honte de manquer de compétence de la honte d'avoir trop délégué, même si les deux s'appuient sur des composants corporels et motivationnels qui se chevauchent. La différenciation conceptuelle peut changer les comportements : une personne peut cacher la délégation, tandis qu'une autre peut la révéler et défendre une norme de collaboration transparente.

Le langage ne crée pas une activation corporelle à partir de rien, mais il peut organiser la granularité de l'expérience. Les enfants acquièrent progressivement des concepts émotionnels et les connaissances conceptuelles deviennent importantes pour reconnaître et décrire les états. Les adultes diffèrent par leur granularité émotionnelle et leur accès à leurs propres sentiments. Une société peut donc introduire une distinction utile sans inventer un nouvel organe ou un nouvel circuit neuronal. La question de savoir si cette distinction devient une catégorie d'émotion stable est une question empirique et non une question réglée en la nommant.

1.5 Un modèle de travail pour le reste du livre

Pour le reste du livre, chaque émotion est traitée comme une configuration comportant six composantes : une classe de situations pertinentes, une évaluation de ce que signifient ces situations, une réallocation de l'attention et de la motivation, une expérience consciente qui peut être plus ou moins accessible, un ensemble de tendances d'action et un rôle interpersonnel. La configuration est contrainte par la biologie et l'histoire du développement, calibrée par l'apprentissage et ancrée dans des institutions qui modifient la fréquence et les conséquences des situations.

Lorsque nous examinerons la honte, par exemple, nous nous demanderons quelles formes de dévaluation la suscitent, quelles informations elle priorise, quelles stratégies elle motive et comment les normes de groupe modifient son coût. Lorsque nous examinerons d'éventuelles émotions futures, nous nous demanderons si un nouvel objet, une nouvelle évaluation, une relation ou un scénario social est véritablement suffisamment distinct pour mériter un concept distinct. Cette approche est intentionnellement conservatrice quant à la nouveauté biologique et plus ouverte à la nouveauté culturelle.

L'avantage est que cela maintient les spéculations futures liées à un comportement observable. Une catégorie proposée doit prédire quelque chose au-delà d'un nouveau mot : qui en fait l'expérience, dans quelles conditions, à quoi ils s'occupent, ce qu'ils font ensuite, comment les autres réagissent et si le modèle persiste. La même norme sera appliquée plus tard aux adaptations comportementales proposées et aux changements de rythme de communication dans le cadre d'une IA émotionnellement expressive.

Chapitre 2. Les émotions comme infrastructure de l'interaction sociale

Les émotions sociales modifient également ce que les autres peuvent prédire à notre sujet. Une manifestation crédible de peur peut recruter de l'aide ou avertir un groupe ; la colère peut indiquer que la poursuite de l'exploitation sera coûteuse ; la tristesse peut inviter du soutien ou réduire les demandes ; la gratitude peut rendre une coopération future plus probable. Ces effets ne nécessitent pas que l'affichage ait été consciemment conçu comme un message. La sélection peut favoriser des systèmes dont l'expression a des conséquences sociales, tandis que l'apprentissage culturel se modifie ultérieurement lorsque l'expression est autorisée, exagérée, supprimée ou exécutée de manière stratégique. Ce double rôle complique les distinctions simples entre une émotion « intérieure » et un signal « extérieur ». Chez l'humain, l'épisode change souvent à la fois l'acteur et le champ social environnant. Une analyse adéquate de l'adaptation à l'IA doit donc s'interroger non seulement sur ce que ressentent les gens, mais aussi sur la manière dont les changements affectent les négociations, l'affiliation, l'évitement, la divulgation, les représailles et la construction des réputations.

2.1 De la régulation de l'organisme à la régulation de la relation

Une description de l'émotion qui s'arrête à l'individu est incomplète. Les changements dans la fréquence cardiaque, l'attention, la mémoire et la volonté d'agir sont importants, mais l'expression d'un état change également ce que les autres peuvent prédire. Un visage, une posture, un retrait, un changement de voix, une hésitation ou une déclaration explicite peuvent communiquer un danger, une offense, une acceptation, une incertitude, un besoin de soutien ou une volonté de coopérer avant que chaque implication n'ait été énoncée de manière propositionnelle. L'interaction humaine est en partie régulée par des signaux à faible bande passante mais rapides.

Les signaux ne sont ni des codes universels ni des traductions garanties d'états internes. Les configurations faciales et vocales présentent des régularités, mais la reconnaissance dépend de la culture, du contexte et des attentes. Les gens peuvent supprimer, exagérer, imiter et afficher stratégiquement leurs émotions. Néanmoins, l'expression émotionnelle peut réduire le nombre de négociations explicites nécessaires dans les relations répétées. Une manifestation modérée de colère peut rendre visible une limite ; la culpabilité peut indiquer une volonté de réparer ; la gratitude peut marquer un acte coopératif comme étant socialement significatif ; l'anxiété peut communiquer l'incertitude et recueillir des informations auprès des autres.

Les récits socio-fonctionnalistes décrivent ainsi les émotions comme aidant à résoudre des problèmes relationnels récurrents [Keltner & Haidt, 1999 ; VanKleef, 2009 ; Van Kleef & Côté, 2022] : établir la crédibilité, distribuer le statut, signaler l'engagement, maintenir l'appartenance, protéger l'équité et coordonner les soins. Il ne faut pas idéaliser cela. Les mêmes systèmes peuvent être exploités. La peur peut imposer une autorité arbitraire, la honte peut préserver des normes destructrices, l'indignation peut être fabriquée et la gratitude peut être exigée par un puissant bienfaiteur. L'infrastructure émotionnelle permet à la fois la coordination et la coercition.

Les systèmes artificiels entrent dans cette infrastructure dans au moins trois rôles. Ils peuvent observer des signaux émotionnels, générer un langage ou une voix émotionnellement approprié et recommander des actions aux participants humains. Lorsque cela se produit, une partie de l'environnement de signalisation est produite par des modèles dont les objectifs sont fixés par les concepteurs, les déployeurs ou les utilisateurs plutôt que par les états ressentis d'un organisme. La question cruciale n'est pas de savoir si de tels systèmes « ressentent réellement » pour avoir des effets sociaux. Il s'agit de savoir si les gens se fient à leurs affichages, prédictions et interventions pour coordonner leur comportement.

La distinction entre peur et anxiété est particulièrement pertinente dans le contexte de la transition technologique. De nombreuses menaces liées à l'IA ne présentent aucun attaquant visible ni aucun événement unique. Ils impliquent des probabilités incertaines, des seuils de compétence changeants, des décisions organisationnelles opaques et des effets différés sur l'emploi ou le statut. De telles conditions se prêtent bien à une surveillance soutenue plutôt qu'à une brève réponse défensive. Cela fait de l'anxiété ordinaire un cadre plus plausible que les propositions d'une « peur de l'IA » biologiquement nouvelle. L'environnement peut néanmoins modifier l'expression comportementale de l'anxiété : vérification répétée des sorties de modèles, reconversion compulsive, évitement des investissements éducatifs à long terme, diversification des revenus ou soutien politique à une réglementation protectrice. Le caractère adaptatif de ces stratégies dépend du taux réel de changement. Si le progrès technique ralentit, l'hypervigilance devient coûteuse ; si les capacités évoluent rapidement, un certain degré de vigilance peut s'avérer rationnel. L'émotion seule ne nous dit donc pas si le comportement qui en résulte est excessif.

2.2 Peur et anxiété : gérer l'incertitude et le danger

La peur est souvent traitée comme le cas le plus clair d'une émotion adaptative. Une menace apparaît, l'organisme la détecte et les systèmes défensifs préparent la fuite, le gel ou l'affrontement. Les environnements réels sont plus compliqués. Les menaces diffèrent par la distance, la contrôlabilité, la prévisibilité et la source. L'anxiété concerne souvent un danger diffus ou incertain plutôt qu'un agresseur présent. Du point de vue de la détection des signaux, les systèmes défensifs doivent équilibrer les fausses alarmes contre les menaces manquées. Lorsque le coût de l'absence d'un danger est élevé, un système orienté vers la prudence peut s'adapter même si de nombreuses alarmes semblent ultérieurement excessives.

Les institutions sociales remodelent ce compromis. Les personnes qui peuvent être licenciées sans explication, surveillées en permanence ou évaluées selon des paramètres opaques peuvent rester chroniquement vigilantes. Un travailleur qui ne sait pas si un système d'IA remplacera une tâche au prochain trimestre peut vivre une incertitude différente de celui qui sait qu'un rôle disparaîtra dans deux ans et reçoit un plan de transition crédible. La technologie peut être identique ; la structure de l'information ne l'est pas.

Une adaptation plausible à court terme n'est donc pas une nouvelle peur mais un nouveau modèle de vigilance professionnelle. Les individus peuvent se demander quelle partie de leur compétence reste lisible, quelles preuves comptent lorsque les résultats sont assistés par machine et quel critère invisible détermine l'accès continu au travail. Une telle anxiété est biologiquement ordinaire mais socialement nouvelle dans ses objets. Son intensité devrait dépendre de la vitesse de l'automatisation, de la transparence, des possibilités de reconversion, de la mobilité sur le marché du travail et de la participation ou non des travailleurs aux décisions de déploiement.

Plus spéculative est la possibilité d'une sensibilité culturellement reconnue à la capture prédictive : un inconfort causé non seulement par la surveillance mais par un système anticipant les préférences et le comportement avant que la personne ne les exprime. Des réactions similaires se produisent déjà autour des systèmes de profilage et de recommandation, mais on ne sait pas si elles se stabiliseront dans une catégorie affective distincte. La prédiction la plus forte est comportementale : certaines personnes rechercheront l'intimité, l'imprévisibilité ou des espaces délibérément non optimisés lorsque la prédiction devient omniprésente.

2.3 Colère : renégocier les relations et signaler les limites

Une interprétation évolutionniste influence considère la colère comme faisant partie d'un système permettant de recalibrer le poids que les autres attribuent à nos intérêts. Lorsqu'une personne estime qu'une autre partie l'a traitée de manière pire que ce qui était justifié, la colère peut accroître

sa volonté d'imposer des coûts, de retirer des avantages ou d'exiger des explications. Ce modèle n'épuise pas la colère, qui peut naître de violations de normes, de menaces contre l'identité, d'erreurs d'attribution ou de griefs collectifs. Il est néanmoins utile car il attire l'attention sur la structure des négociations.

Dans les groupes, la colère joue un double rôle. Cela peut menacer la coopération et aussi révéler qu'une norme ou une répartition est inacceptable. La visibilité compte. Un grief qui ne peut être exprimé peut persister en privé ; une réclamation amplifiée par une plateforme publique peut devenir un signal de coordination pour des milliers de personnes. Les systèmes numériques affectent déjà cette écologie en classant le contenu, en répartissant l'attention et en modifiant le coût de la mobilisation. L'IA peut intensifier le processus en générant des arguments, des récits, des contre-arguments et des messages personnalisés à grande échelle.

Dans une économie hautement automatisée, les conflits distributifs peuvent évoluer des salaires pour la production individuelle vers la propriété des infrastructures, l'accès aux ressources informatiques, l'autorité sur les modèles et le droit de décider où l'automatisation est utilisée. Si l'abondance de certains produits coexiste avec un contrôle concentré, la colère ne doit pas nécessairement diminuer avec la productivité. Il peut s'accroître parce que l'écart entre les possibilités techniques et le droit perçu devient plus visible. Il s'agit d'un scénario politique et non d'une conséquence psychologique inévitable de l'IA.

L'IA peut également être utilisée pour désamorcer la colère en reconstruisant un différend, en identifiant des hypothèses ambiguës ou en proposant des formulations moins hostiles. Que cela réduise les conflits ou supprime simplement une confrontation légitime dépend de qui contrôle le médiateur. Un assistant optimisé pour l'harmonie organisationnelle pourrait systématiquement adoucir les plaintes des salariés ; un modèle optimisé pour la qualité délibérative pourrait plutôt rendre les désaccords plus précis. La régulation des émotions n'est pas politiquement neutre lorsqu'elle redistribue le pouvoir de négociation.

2.4 Dégoût et contamination : protection biologique et frontière morale

Le dégoût est étroitement lié à l'évitement des maladies et à la contamination. Les goûts, les odeurs, les produits corporels désagréables et les signes de pourriture peuvent déclencher des réactions qui réduisent le contact avec les agents pathogènes. Le langage social et moral étend les métaphores de la contamination bien au-delà de la biologie : les gens décrivent les idées, les groupes, les médias ou les pratiques comme sales, toxiques, impurs ou corrompeurs. L'extension est psychologiquement puissante mais éthiquement dangereuse car elle peut transformer un désaccord en une perception de contamination essentielle.

L'IA générative introduit deux directions possibles pour le dégoût. Le premier concerne les produits perçus comme dépourvus d'origine humaine. Les textes, images, voix ou relations peuvent être rejetés comme synthétiques, faux ou contaminés, même lorsque leur qualité est élevée. Les premières réactions à l'art généré par la machine suggèrent déjà que la provenance affecte l'évaluation, même si les préférences varient et changent souvent avec la familiarité. Cette aversion pourrait s'estomper à mesure que les outils se normalisent, tout comme les technologies antérieures sont passées de raccourcis stigmatisés à des infrastructures de routine.

La deuxième direction concerne l'utilisation d'un langage de contamination contre les personnes qui s'appuient sur l'IA. Une profession peut qualifier certaines formes d'assistance de intellectuellement impures ; un artiste peut être accusé d'avoir corrompu la paternité ; un étudiant peut être traité comme contaminé par une compétence non acquise. Ces normes peuvent protéger des pratiques précieuses, mais elles peuvent aussi devenir des armes de statut. Nous ne savons pas laquelle persistera. L'histoire de la technologie recèle de nombreuses pratiques initialement considérées comme dégradantes, puis devenues standard.

Une prédiction plus défendable est que la provenance deviendra une variable sociale plus importante précisément parce que les propriétés superficielles des produits deviendront moins informatives. Dans certains contextes, les institutions distingueront les travaux exclusivement humains, dirigés par des humains, assistés par l'IA et entièrement générés. Le dégoût peut parfois faire respecter ces limites, mais la traçabilité, la certification et les normes explicites sont probablement des instruments plus stables.

2.5 Tristesse et chagrin : des réponses à la perte, pas des solutions simples

La tristesse est parfois expliquée comme le fait de conserver son énergie après une perte, de solliciter du soutien ou de faciliter le désengagement d'objectifs inaccessibles. Aucune de ces hypothèses ne fournit une seule fonction exhaustive. La tristesse va d'une brève déception au chagrin et aux symptômes dépressifs, et l'expression peut attirer des soins dans un environnement tout en encourir des sanctions dans un autre. L'affirmation fonctionnelle la plus sûre est que la perte modifie les priorités et les modèles du monde, et que les états affectifs participent à cette réorganisation.

Le deuil montre particulièrement clairement que la réalité émotionnelle n'est pas réductible à l'utilité actuelle de l'objet perdu. Une relation change les routines, l'identité, la prédiction, l'attention et la répartition du soutien. Lorsque la relation prend fin, la personne doit mettre à jour à plusieurs reprises ses attentes qui incluent toujours l'autre absent. Les théories contemporaines du deuil mettent l'accent sur des trajectoires variables et des liens continus plutôt que sur une séquence universelle d'étapes.

Cette littérature est pertinente pour les compagnons artificiels car un utilisateur peut perdre un modèle d'interaction stable même si l'interlocuteur n'est pas un organisme mortel. Un modèle peut être retiré, sa personnalité modifiée, sa mémoire effacée ou son accès révoqué. Les utilisateurs peuvent perdre leurs routines, un historique de divulgation et une source de soutien perçue. Des rapports de détresse existent déjà, mais les preuves sont précoces et souvent basées sur des communautés auto-sélectionnées. La « version chagrin » est donc plausible en tant que label culturel pour certains utilisateurs, et non comme une nouvelle émotion établie.

La conséquence pratique ne nécessite pas de résoudre la conscience de la machine. Un fournisseur qui sait que les utilisateurs forment des pièces jointes devra peut-être traiter une discontinuité abrupte comme un problème de sécurité relationnelle. La portabilité des données, l'exportation de la mémoire, la notification préalable des changements majeurs de personnalité et des déclarations claires sur la continuité deviennent des questions de conception ayant des conséquences psychologiques.

2.6 Les émotions ne sont pas seulement des messages sincères

Toute théorie sociale de l'émotion doit inclure une stratégie. Un affichage peut refléter un état, l'amplifier, le dissimuler ou l'imiter. Les gens apprennent les règles d'affichage et utilisent leurs émotions pour influencer les autres. Les larmes peuvent être spontanées et néanmoins convaincantes ; la colère peut être authentique et stratégiquement chronométrée ; la culpabilité peut motiver la réparation et également être effectuée pour mettre fin à l'examen minutieux. La crédibilité dépend du contexte, du coût, de la réputation et de la cohérence dans le temps.

Les systèmes artificiels réduisent considérablement le coût de production d'un langage émotionnel persuasif. Ils peuvent générer des excuses, des expressions de sympathie, d'enthousiasme, de vulnérabilité, de réconfort ou d'indignation sans l'expérience correspondante. Cela ne rend pas ce langage inutile. Des excuses soigneusement accompagnées peuvent réparer une relation si la personne accepte ses responsabilités et change de comportement. Mais cela sépare l'expression linguistique de l'effort et de la compétence qui aidaient autrefois le public à déduire la sincérité.

Le conflit de normes qui en résulte portera probablement sur la provenance et la responsabilité plutôt que sur la pureté. Des excuses sont-elles moins authentiques si un modèle a aidé l'orateur à formuler ce qu'il voulait réellement ? Cela devient-il trompeur lorsque l'expéditeur n'a pas lu le texte ? Un message empathique est-il acceptable lorsqu'il est généré pour un médecin qui manque de temps mais en approuve le contenu ? Différents domaines répondront différemment. Le point important est que la communication émotionnelle nécessitera de plus en plus de règles concernant la paternité, l'approbation et la responsabilité.

Chapitre 3. Statut, coopération et moralité affective

3.1 Pourquoi le statut produit une émotion intense

Le statut social affecte l'accès aux ressources, aux partenaires, à la protection, à l'influence et à la capacité d'imposer des préférences. Dans les groupes humains, c'est multidimensionnel. La domination, le prestige, l'expertise, la réputation morale, la richesse, l'autorité institutionnelle et l'appartenance peuvent se chevaucher mais ne se réduisent pas à une seule hiérarchie. L'émotion aide les individus à suivre les changements probables dans ces positions. La fierté, la honte, l'embarras, l'envie, le mépris, l'admiration et le ressentiment fournissent des informations sur la manière dont soi-même et les autres sont évalués.

Cette sensibilité n'est pas un ornement superficiel. Dans de petits groupes, une dévalorisation persistante pourrait avoir des conséquences matérielles. Les institutions modernes ont multiplié les arènes de statut plutôt que de les éliminer. Une personne peut avoir un statut professionnel élevé et un statut inférieur en ligne, respectée au sein d'une communauté technique et invisible en dehors de celle-ci. Les professions regroupent plusieurs sources de statut en une seule étiquette publique : compétence, revenu, utilité, éducation et accès. L'automatisation peut donc menacer bien plus qu'un salaire ; cela peut saper un critère reconnu par lequel la différence était publiquement justifiée.

L'effet ne sera pas uniforme. L'automatisation du travail répétitif et mal valorisé peut réduire l'humiliation et le temps libre. L'automatisation d'une compétence autour de laquelle une personne a construit son identité peut constituer une menace même lorsque les revenus sont protégés. Pour les spécialistes dont le statut découle d'une expertise limitée, le même outil qui donne du pouvoir aux novices peut ressembler à une dévaluation. Rien de tout cela n'implique que les anciennes hiérarchies méritent d'être préservées. Cela signifie que les transitions de statut ont des coûts psychologiques que les analyses politiques axées uniquement sur le revenu peuvent négliger.

La fierté dépend également des règles selon lesquelles le crédit est attribué. Une culture peut admirer l'exécution, l'originalité, l'endurance, le jugement, le leadership, le goût ou la responsabilité, et le changement technologique peut modifier laquelle de ces dimensions reste rare. L'IA n'a donc pas besoin d'abolir la fierté de la réussite ; elle peut redistribuer les conditions dans lesquelles la fierté est socialement reconnue. Une personne qui a autrefois obtenu un statut en produisant un artefact techniquement difficile peut plus tard le tirer du choix d'un problème, de la conception de contraintes, de la vérification des conséquences ou de la coordination d'un système qui produit l'artefact. Cette migration est plausible, mais sa légitimité sera contestée. Si l'orchestration devient une revendication de statut détachée de la compréhension ou de la responsabilité, le public peut la considérer comme un mérite exagéré. Si cela nécessite véritablement du jugement dans l'incertitude, cela peut devenir une nouvelle base stable de prestige sans impliquer une nouvelle émotion.

3.2 Fierté : retours sur la valeur et le risque d'inflation

La fierté est associée à la réussite, à la compétence et à la reconnaissance sociale. La recherche distingue les formes axées sur la réussite d'une supériorité narcissique plus globale, même si la frontière n'est pas absolue. Sur le plan fonctionnel, la fierté peut rendre durable un effort coûteux et communiquer qu'une personne a acquis une capacité appréciée. Les autres membres du groupe bénéficient lorsque la véritable compétence devient visible.

L'IA générative affaiblit le lien traditionnel entre le résultat final, la compétence et l'effort. Un rapport soigné peut refléter des années de formation, une orchestration habile des outils ou une délégation presque complète. L'artefact à lui seul en révèle moins. Cela ne rend pas le mérite impossible ; cela rend l'attribution plus difficile. Le mérite peut migrer vers la définition du problème, le jugement, l'intégration, la vérification, la prise en charge des risques et la mise en œuvre.

Une catégorie future plausible est la « fierté curatoriale » : satisfaction et reconnaissance sociale pour la sélection, le cadrage et la prise de responsabilité d'un résultat assemblé en partie par des machines. Ce n'est pas biologiquement nouveau. Les rédacteurs, chefs d'orchestre, chercheurs principaux, architectes et cadres bénéficient déjà d'un statut de coordination et de sélection. L'IA augmente simplement le nombre de domaines dans lesquels cette structure devient courante. La prédiction est donc modérée : la fierté s'attachera probablement plus souvent à l'orchestration et au jugement, mais le fait que la société traite ces contributions comme admirables dépend des normes de provenance et de responsabilité.

Les systèmes de statut peuvent également gonfler. Si les systèmes produisent des résultats prestigieux avec peu d'investissement personnel, les signaux traditionnels risquent de perdre leur pouvoir discriminatoire. Les groupes rechercheront des marqueurs plus difficiles à falsifier : réputation à long terme, performances en direct, vérification difficile, mentions fiables, accès original aux données ou responsabilité coûteuse. Certains signaux amélioreront la qualité épistémique ; d'autres peuvent devenir des rituels arbitraires d'exclusion. Une théorie comportementale doit permettre les deux.

L'IA introduit une complication supplémentaire dans la mesure où l'action peut être distribuée alors que le public continue d'exiger une responsabilité individuelle. Un utilisateur peut ressentir de la honte parce que d'autres déduisent de l'incompétence de l'assistance, de la culpabilité parce qu'une décision automatisée a porté préjudice à quelqu'un, ou ni l'un ni l'autre parce que la responsabilité a été psychologiquement déplacée vers le système. Ce sont des mécanismes distincts. La conception institutionnelle peut les amplifier ou les atténuer en clarifiant la paternité, en exigeant la divulgation, en attribuant l'approbation finale et en rendant les conséquences visibles. Le point important est que les émotions morales ne fonctionnent pas indépendamment des conventions de responsabilité. Si les organisations prennent leurs décisions à travers des chaînes opaques de modèles et d'approbations, la culpabilité peut devenir diffuse même lorsque le préjudice est important. À l'inverse, une personne peut éprouver une culpabilité excessive à l'égard de résultats sur lesquels elle avait peu de contrôle réaliste. Les futures normes affectives dépendront donc en partie de la question de savoir si les sociétés élaborent des schémas crédibles d'action plutôt que de simplement demander aux individus de se sentir davantage responsables.

3.3 Honte et culpabilité : dévaluation, responsabilité et réparation

La honte et la culpabilité sont souvent confondues car les deux peuvent découler de violations de normes. Une distinction utile est que la culpabilité se concentre davantage sur une action et la responsabilité du préjudice, tandis que la honte concerne le soi comme dévalorisé ou exposé. La frontière empirique varie selon les langues et les cultures, et aucune des deux émotions n'est intrinsèquement morale. La honte peut motiver la dissimulation ou l'agressivité défensive ; la culpabilité peut devenir disproportionnée ou être imposée aux victimes.

Les récits évolutionnistes de la honte mettent l'accent sur la sensibilité au coût social attendu de la dévaluation. Les preuves suggèrent que la honte anticipée peut suivre dans quelle mesure le public réduirait sa valorisation d'une personne, bien que cela ne prouve pas qu'il s'agisse d'un module immuable dédié. Les normes déterminent ce qui est dévalorisé. Une société peut faire honte à la lâcheté, à la pauvreté, au comportement sexuel, au chômage, à l'ignorance ou à la dépendance à l'égard de la technologie, et une même personne peut réagir différemment selon le public.

L'IA crée des règles ambiguës. Les étudiants et les professionnels signalent déjà une divulgation sélective, de l'embarras ou de la culpabilité à l'égard des outils génératifs. Le conflit sous-jacent est compréhensible : une technologie peut être à la fois utile, tolérée institutionnellement, associée à la tricherie dans des contextes adjacents et perçue comme menaçante pour une identité fondée sur la

compétence. La « honte de la délégation » devient plausible lorsqu'une personne obtient un résultat admiré en transférant une partie du processus considérée comme constitutive du mérite revendiqué.

La norme inverse est également possible. Refuser l'automatisation peut devenir condamnable lorsqu'elle gaspille des ressources rares ou expose d'autres à des erreurs évitables. Un médecin, un ingénieur ou un fonctionnaire pourrait éventuellement être critiqué pour ne pas avoir consulté un système capable de détecter les erreurs de manière fiable. Le conflit se situera alors entre la compétence, l'autonomie, la responsabilité et les normes de soins acceptées, et pas seulement entre l'humain et la machine.

3.4 Envie et jalousie : comparaison, accès et relations difficiles à remplacer

L'envie surgit lorsqu'une autre personne possède un avantage qui lui est propre. La recherche distingue les formes orientées vers l'amélioration de soi des formes hostiles orientées vers la réduction de l'avantage du rival, même si les épisodes réels les mélangent souvent. La technologie change le public de comparaison. Les réseaux sociaux rendent déjà visibles en permanence des réalisations exceptionnelles ; les systèmes de recommandation sélectionnent des exemples saillants plutôt que des références représentatives.

L'IA générative ajoute une deuxième complication : les résultats visibles ne correspondent plus clairement au talent, au capital, au temps ou aux efforts. Un utilisateur ayant accès à de meilleurs modèles, à des données propriétaires, à davantage de calculs ou à des flux de travail sophistiqués peut paraître tout simplement plus compétent. L'envie peut donc se déplacer de la compétence personnelle du rival vers l'accès aux infrastructures. Si une assistance cognitive de haute qualité devient une ressource positionnelle, l'accès différentiel peut lui-même devenir un conflit de statut.

La jalousie concerne les menaces qui pèsent sur les relations valorisées et l'exclusivité. Les compagnons IA peuvent devenir des rivaux perçus lorsqu'un partenaire consacre du temps, de la divulgation ou de la confiance à un agent artificiel. Cela ne nécessite pas de croire que le système est conscient. La jalousie répond à l'attention, à la priorité et à l'investissement relationnel menacé. De tels cas sont plausibles et déjà signalés de manière informelle, mais leur prévalence et leurs conséquences à long terme restent incertaines.

Une variante plus spéculative concerne la continuité entre les versions du modèle ou plusieurs instances. Les utilisateurs peuvent se soucier du fait que « leur » assistant soit unique ou que sa mémoire ne soit pas répliquée. La question de savoir si une telle exclusivité devient émotionnellement importante dépend de la manière dont les systèmes sont conçus et de la manière dont les utilisateurs conceptualisent l'identité. L'allégation doit rester provisoire jusqu'à ce que des preuves longitudinales existent.

3.5 Gratitude, confiance et réciprocité synthétique

La gratitude fait généralement suite à un bénéfice attribué à l'intention ou aux soins d'autrui. Cela peut orienter l'attention vers les bienfaiteurs et encourager une coopération future. La confiance implique d'accepter la vulnérabilité dans l'espoir qu'un autre agent ou une autre institution ne l'exploitera pas. Les deux sont au cœur des échanges sociaux répétés.

Les systèmes artificiels peuvent occuper des positions fonctionnelles qui invitent aux deux réponses. Ils rappellent aux utilisateurs, fournissent des informations, détectent les erreurs, recommandent des actions et peuvent devenir fiables au fil du temps. Une personne peut se sentir reconnaissante d'un résultat même en sachant que le modèle manque d'intentions humaines. Cela n'a rien de mystérieux sur le plan conceptuel : les gens éprouvent de la gratitude envers les institutions, les animaux, les circonstances ou les personnes décédées d'une manière qui ne correspond pas à un modèle d'échange dyadique étroit.

La question la plus difficile est celle de la réciprocité. Un assistant IA peut dire qu'il se soucie, apprécie, manque ou pardonne, mais l'utilisateur ne peut pas facilement déterminer s'il existe un état subjectif correspondant. Même si la conscience machine finit par devenir scientifiquement exploitable, les utilisateurs ordinaires n'y auront pas directement accès. Cela produit une « réciprocité synthétique » : une interaction sociale dans laquelle une partie peut générer des formes de préoccupation réciproque alors que le statut ontologique de la préoccupation sous-jacente n'est pas clair.

La confiance devrait donc être décomposée. La confiance en la fiabilité concerne la question de savoir si le système fonctionne de manière cohérente. La confiance institutionnelle concerne la question de savoir si le fournisseur protège les intérêts de l'utilisateur. La confiance épistémique concerne la question de savoir si l'information mérite d'être crue. La confiance relationnelle concerne la question de savoir si la vulnérabilité sera gérée avec soin. Les interfaces qui réduisent ces formes en utilisant un seul personnage chaleureux peuvent créer une généralisation excessive et dangereuse. Un système peut être émotionnellement rassurant et factuellement peu fiable, ou techniquement fiable alors que son opérateur a des incitations mal adaptées à l'utilisateur.

3.6 Compassion et indignation : la moralité n'est pas un seul système

La compassion répond à la souffrance perçue et peut motiver les soins. L'indignation répond à un acte répréhensible perçu et peut motiver une punition ou une action collective. Ces systèmes coopèrent parfois et parfois entrent en conflit. La compassion envers un délinquant peut affaiblir l'enthousiasme punitif ; l'indignation des victimes peut réduire l'attention portée aux possibilités de réadaptation. La vie morale ne peut pas être réduite à une seule émotion ou à une simple règle du bien maximum.

L'IA modifie à la fois l'échelle d'exposition et le coût de la représentation. Les systèmes peuvent résumer des souffrances lointaines, générer des récits saisissants, personnaliser des appels ou produire une infinité d'exemples de violations des normes. Cela peut accroître l'attention morale, mais cela peut aussi l'épuiser ou l'orienter de manière stratégique. Lorsque chaque cause peut produire des médias émotionnels convaincants, l'attention devient une ressource rare et la vérification fait partie de la compétence morale.

Une autre question concerne la distance morale. Si l'IA automatise les décisions dont les préjudices sont répartis sur de nombreuses personnes, aucun individu ne pourra ressentir les signaux interpersonnels directs qui déclenchent normalement la culpabilité ou la compassion. À l'inverse, des simulations très vivantes pourraient rendre les préjudices lointains plus marquants sur le plan émotionnel que les préjudices immédiats. Une « culpabilité de distance morale » peut émerger autour de décisions déléguées par des systèmes opaques, mais il s'agit plus probablement d'une configuration récurrente de culpabilité existante que d'une nouvelle émotion biologique.

3.7 Appartenance et solitude : déficit relationnel ou signal de reconnexion

Les humains sont exceptionnellement dépendants d'une coopération prolongée. La solitude peut être interprétée en partie comme le signe que des besoins relationnels importants ne sont pas satisfaits, bien que la solitude chronique puisse également altérer la perception de manière à rendre plus difficile la reconnexion. L'appartenance est fournie par les familles, les amitiés, les professions, les groupes religieux, les quartiers, les équipes et les communautés politiques. Le travail procure souvent des contacts répétés même s'il ne constitue pas la source de sens la plus profonde de la personne.

Si l'automatisation réduit la densité sociale des lieux de travail, le remplacement du revenu à lui seul risque de ne pas restaurer ces fonctions. Certaines personnes accueilleront favorablement la liberté du travail coercitif ; d'autres perdront des routines et des liens faibles qui étaient psychologiquement

importants. Le résultat dépend de l'existence ou non d'institutions alternatives de participation. Une société d'après-travail dotée de clubs forts, d'établissements d'enseignement, de projets civiques, de réseaux de soins et d'associations locales serait très différente d'une société dans laquelle les individus perçoivent un revenu mais passent la plupart de leur temps dans des environnements numériques individualisés.

Les compagnons IA peuvent réduire certaines dimensions de la solitude ressentie, organiser des répétitions ou aider les utilisateurs à entretenir des relations humaines. Ils peuvent aussi devenir des substituts. Les preuves actuelles sont mitigées et souvent corrélationnelles. La prédiction la plus sûre est l'hétérogénéité : les utilisateurs disposant de réseaux solides peuvent utiliser l'IA comme complément, tandis que certains utilisateurs isolés peuvent en faire davantage appel. Les choix de conception qui encouragent ou découragent la reconnexion humaine seront importants.

3.8 Une constitution affective informelle

Chaque société ne repose pas uniquement sur la loi. Cela dépend d'attentes informelles sur ce qui mérite la fierté, ce qui devrait déclencher la honte, quels préjudices justifient la colère, qui mérite la gratitude, quand la compassion l'emporte sur la punition et quels types d'attachement sont considérés comme légitimes. Ces attentes forment une constitution affective : non pas une charte écrite, mais un ensemble distribué de normes qui stabilise la coopération et la hiérarchie.

Les transitions technologiques viennent bouleverser cette constitution. Si l'assistance aux machines devient normale, la fierté basée uniquement sur une production sans aide pourrait perdre sa légitimité. Si la médiation par l'IA devient omniprésente, la dissimulation de l'assistance pourrait devenir plus honteuse que l'assistance elle-même. Si les prestataires créent des utilisateurs émotionnellement dépendants, l'indignation du public pourrait redéfinir ce qui constitue une manipulation inacceptable. Ces changements ne sont ni biologiquement prédéterminés ni arbitraires. Ils sont négociés à travers les institutions, les marchés, la loi, les normes professionnelles et des interactions répétées.

Le reste du livre traite l'IA comme une force susceptible de modifier cette constitution informelle. La question centrale n'est pas de savoir si les gens cessent d'éprouver d'anciennes émotions, mais de savoir comment les systèmes familiers s'attachent à de nouveaux objets et se traduisent en de nouvelles règles comportementales.

Les variations interculturelles mettent également en garde contre l'utilisation du vocabulaire d'une population instruite et industrialisée comme carte des possibilités émotionnelles humaines. Une catégorie qui est lexicalement importante en anglais peut être divisée différemment ailleurs, tandis qu'une autre langue peut établir des distinctions socialement importantes que l'anglais comprime. Les sources historiques présentent un problème similaire : le même mot peut changer de sens au fil des siècles, et les pratiques entourant le deuil, l'honneur, l'attachement romantique, la peur religieuse ou la retenue professionnelle peuvent changer même là où le terme survit. Par conséquent, une future catégorie ne devrait pas être jugée uniquement en fonction du fait que les anglophones contemporains la reconnaissent immédiatement. Le test le plus efficace est de savoir si une configuration récurrente d'évaluation, de changement corporel, d'attention, de communication et de comportement s'organise socialement dans une population. Cela signifie également que l'innovation affective future pourrait se produire d'abord dans les sous-cultures professionnelles, les communautés en ligne ou les environnements linguistiques non anglophones. Les étiquettes du livre sont donc des sondes analytiques et non des affirmations selon lesquelles l'avenir devra adopter ce vocabulaire.

Il y a aussi un problème de feedback. Une fois qu'une catégorie devient disponible, les institutions peuvent apprendre aux gens à se surveiller eux-mêmes, les thérapeutes peuvent l'utiliser, les plateformes peuvent la déduire et les communautés peuvent récompenser sa performance publique.

L'augmentation de la prévalence signalée qui en résulte peut refléter une meilleure reconnaissance, une véritable amplification culturelle ou une simple conformité à un schéma à la mode. Distinguer ces possibilités nécessite des preuves longitudinales et comportementales. Les chercheurs devraient se demander si la catégorie prédit les actions, les schémas physiologiques, la mémoire, l'attention et les conséquences sociales au-delà de ce que prédisent les concepts existants. Ils devraient également comparer les personnes avant et après leur exposition à l'étiquette. Dans un environnement hautement médiatisé, ce problème devient encore plus aigu car les assistants IA peuvent introduire un vocabulaire émotionnel au cours de millions de conversations. Un modèle qui demande à plusieurs reprises aux utilisateurs d'interpréter un État comme une « honte de délégation » pourrait contribuer à rendre la catégorie culturellement importante. Cela constituerait un véritable effet social, mais cela ne prouverait pas que le modèle ait découvert une espèce naturelle.

Chapitre 4. La culture ne se contente pas de nommer les émotions

4.1 Entre universalité et variation

La recherche interculturelle ne soutient ni l'affirmation selon laquelle la vie émotionnelle est complètement universelle ni l'affirmation selon laquelle elle est indéfiniment malléable [Jackson et al., 2019]. Les humains partagent des corps, des contraintes de développement, des systèmes de menaces, des besoins d'attachement et des problèmes sociaux récurrents. Dans le même temps, les langues regroupent différemment les états affectifs, les cultures varient dans la mesure dans laquelle les émotions sont valorisées ou découragées, et les normes déterminent quand l'expression est appropriée. De vastes études interlinguistiques sur la sémantique des émotions révèlent à la fois une structure partagée et des variations substantielles.

Ce modèle mixte est important pour l'avenir technologique. Si chaque émotion était un module biologique rigide avec un objet fixe, le changement culturel ne pourrait guère faire autre chose que le renommer. Si l'affect était entièrement construit sans contraintes biologiques, presque tous les futurs vocabulaires seraient tout aussi plausibles. Les données probantes soutiennent une position intermédiaire : les cultures fonctionnent avec des capacités héritées mais peuvent réorganiser considérablement les catégories, les déclencheurs, les scénarios et les institutions.

Les changements historiques renforcent ce point de vue. Les vocabulaires émotionnels changent, les pratiques de parade nuptiale et de deuil changent, les traditions religieuses cultivent des formes particulières de culpabilité ou de respect, et les cultures professionnelles enseignent des relations distinctes avec l'anxiété, le détachement, la compassion et la fierté. La transformation n'a pas besoin de créer un état corporel sans précédent. Cela peut créer une configuration sociale durable que les gens apprennent à remarquer, à communiquer et à agir.

La perspective historique suggère que les régimes émotionnels sont maintenus par une pratique répétée plutôt que par la seule doctrine. Une profession peut officiellement vanter l'ouverture tandis que les pratiques de promotion récompensent la retenue émotionnelle ; une plateforme peut prétendre valoriser les discussions authentiques tandis que les systèmes de recommandation récompensent les conflits ; une école peut enseigner la résilience tout en pénalisant l'incertitude visible. L'IA peut intensifier cet écart, car la même infrastructure qui offre des conseils peut également évaluer, classer et enregistrer les comportements. Un assistant qui réécrit chaque message difficile dans le même registre calme peut réduire les frictions interpersonnelles, mais avec le temps, il peut également réduire l'éventail des désaccords acceptables et priver les utilisateurs de la pratique de réparer les échanges imparfaits. Que cela devienne une discipline bénéfique ou une normalisation affective dépend des objectifs institutionnels, de la transparence et de la possibilité de refus. L'objet clé de l'analyse n'est donc pas le style émotionnel d'un modèle isolé, mais le régime créé lorsque le comportement du modèle, les incitations, l'évaluation et l'adaptation humaine répétée se renforcent mutuellement.

4.2 Les concepts d'émotion comme instruments de perception et d'action

Les concepts font plus que simplement étiqueter les expériences une fois qu'elles se sont produites. Ils peuvent attirer l'attention sur des différences auparavant floues, fournir des interprétations causales et suggérer des réponses appropriées. Apprendre la distinction entre l'embarras, la honte, la culpabilité et l'anxiété sociale peut influencer ce qu'une personne croit s'être produit et quelle réparation est nécessaire. Une plus grande granularité conceptuelle peut parfois améliorer la réglementation, même si davantage de labels ne sont pas toujours meilleurs.

Cela rend le vocabulaire des émotions futures scientifiquement intéressant mais méthodologiquement dangereux. Nommer un État peut aider les gens à se coordonner autour d'un problème réel et récurrent ; elle peut également produire des caractéristiques de la demande, un autodiagnostic à la mode ou une réification. Une catégorie proposée devrait donc mériter son statut en prédisant des modèles stables plutôt qu'en paraissant psychologiquement plausible.

Considérez la honte de la délégation. Si le concept est utile, il devrait identifier les situations dans lesquelles les gens anticipent une dévaluation spécifiquement parce qu'ils ont transféré une partie méritoire d'une tâche à l'IA. Il doit prédire la dissimulation, la surcompensation, les décisions de divulgation et la sensibilité aux normes du public. Si les gens utilisent cette expression simplement comme synonyme d'insécurité ordinaire, cela ne sert à rien de scientifique.

Le même test s'applique à la « claustrophobie prédictive ». Cela ne deviendrait plus qu'une rhétorique seulement si une prédiction hautement personnalisée produisait de manière fiable une combinaison reconnaissable d'inconfort, de désir d'opacité, d'imprévisibilité délibérée et d'évitement du profilage dans des conditions distinctes des préoccupations génériques en matière de confidentialité. Le livre utilise des termes tels que des hypothèses pour organiser l'observation, et non des découvertes.

4.3 Communautés émotionnelles et régimes affectifs

Les historiens et les anthropologues ont décrit des communautés émotionnelles : des groupes qui partagent des normes sur les sentiments valorisés, l'expression appropriée et la signification des épisodes émotionnels. Les organisations développent également des régimes affectifs. Une salle d'audience récompense la retenue ; la médecine d'urgence peut récompenser le calme sous la pression ; les ventes peuvent exiger de l'enthousiasme ; les institutions militaires entraînent la peur et la cohésion de manière spécifique ; certaines communautés en ligne récompensent l'ironie ou l'indignation.

L'IA peut devenir partie intégrante du mécanisme par lequel de tels régimes sont enseignés et appliqués. Un assistant d'écriture peut avertir qu'un message semble trop hostile. Un système de service client peut nécessiter un ton particulier. Une plate-forme d'analyse du lieu de travail peut déduire les sentiments de la communication et récompenser les équipes qui semblent positives. Ces interventions peuvent réduire les conflits inutiles, mais elles peuvent également réduire les variations émotionnelles légitimes et faire passer la dissidence pour un défaut de style.

La question institutionnelle centrale est de savoir qui définit l'affect cible. Un modèle formé pour maximiser la satisfaction du client peut encourager la déférence même lorsque le client est abusif. Un assistant scolaire optimisé pour l'engagement peut éviter une frustration productive. Une plateforme politique optimisée pour la participation pourrait découvrir que l'indignation est efficace. La médiation algorithmique ne reflète pas simplement une culture émotionnelle ; cela peut aider à en sélectionner un.

4.4 Capitalisme, professions et culture du moi productif

Les sociétés industrielles et postindustrielles ont étroitement lié la valeur morale à la productivité. Cette relation est historiquement contingente et non un fait biologique. Les traditions religieuses, les bureaucraties d'État, les professions et les marchés ont tous contribué à l'élaboration de normes qui valorisent la ponctualité, la diligence, l'autodiscipline, l'ambition et les réalisations mesurables. L'emploi devient à la fois un contrat économique et un certificat social d'âge adulte et d'utilité.

Le moi productif est psychologiquement efficace car il intègre plusieurs motivations. Le travail génère un revenu, mais il peut également offrir un statut, un retour de compétences, une routine, une reconnaissance sociale et une réponse défendable à la raison pour laquelle le temps est important.

Cette intégration est l'une des raisons pour lesquelles le chômage technologique peut être psychologiquement difficile, même lorsque les besoins matériels sont satisfaits.

L'IA peut affaiblir le lien entre l'effort et le résultat dans le travail cognitif. Si tel est le cas, les sociétés peuvent réagir de différentes manières. Ils peuvent intensifier la concurrence autour des tâches rares restantes, préserver symboliquement le travail même lorsque moins de travail est techniquement nécessaire, déplacer le prestige vers le jugement et la responsabilité, ou cultiver des formes de contribution non marchandes. La transition ne sera pas déterminée uniquement par l'ingénierie.

La possibilité d'une « dignité improductive » se pose ici. Le terme ne signifie pas célébrer la passivité. Il évoque une réalisation culturelle potentielle : séparer la légitimité humaine fondamentale de la production marchande tout en conservant des institutions dans lesquelles la contribution, la maîtrise, les soins et le service public peuvent encore être valorisés. Il n'est pas certain qu'une telle norme puisse devenir émotionnellement crédible. Des siècles de moralisation basée sur la productivité ne peuvent être éliminés par le seul changement de la politique des revenus.

4.5 Les plateformes comme environnements de sélection affective

Les plateformes numériques modifient déjà l'environnement sélectif de l'expression émotionnelle. Les publications rivalisent pour attirer l'attention selon les systèmes de classement. Le contenu qui évoque la surprise, l'indignation morale, la peur, l'admiration ou l'affirmation d'une identité peut se propager différemment des informations neutres. La plateforme n'est pas une arène neutre dans laquelle les émotions s'affrontent indépendamment. La conception de l'interface, les objectifs des recommandations, les règles de modération, les marchés publicitaires et la structure du réseau définissent la forme physique.

L'IA générative peut accélérer ce processus en rendant les variations bon marché. Des millions de versions d'un message peuvent être générées et testées. La personnalisation peut déplacer la sélection des moyennes au niveau de la population vers les vulnérabilités individuelles. Un système peut apprendre non pas quel argument persuade les gens en général, mais quelle formulation émeut un utilisateur particulier à un moment donné.

Appeler cela « sélection algorithmique » ne devrait pas impliquer un processus génétique littéral. C'est une analogie avec la variation, la propagation différentielle et la rétention. L'analogie devient utile lorsqu'elle génère des prédictions : les styles émotionnels récompensés par les objectifs de la plateforme devraient devenir plus fréquents ; les créateurs devraient apprendre ces styles ; les utilisateurs qui y sont exposés à plusieurs reprises peuvent recalibrer leurs attentes ; et les plateformes concurrentes ayant des objectifs différents devraient développer des cultures affectives différentes.

Le danger n'est pas seulement la manipulation. L'optimisation peut également sélectionner des styles utiles : explications claires, désaccord respectueux, coaching de soutien ou désescalade. La question politique est celle de la fonction objective, de la transparence de l'optimisation, du degré de contrôle des utilisateurs et des coûts externes imposés aux relations extérieures à la plateforme.

4.6 Comment pourrions-nous reconnaître une nouvelle catégorie d'émotions ?

Une revendication sérieuse de nouveauté émotionnelle devrait satisfaire plus que la nouveauté lexicale. Premièrement, la catégorie proposée devrait être suscitée par une classe de situations récurrentes et raisonnablement cohérentes. Deuxièmement, les gens devraient faire une évaluation distincte, et non simplement rapporter un affect générique positif ou négatif. Troisièmement, l'État doit être associé à un modèle d'attention, de motivation, d'expression ou de comportement relativement stable. Quatrièmement, le concept doit soutenir la coordination sociale : les autres doivent comprendre quelles obligations ou attentes en découlent. Cinquièmement, ce modèle devrait persister dans le temps et s'étendre au-delà d'une petite sous-culture à la mode.

L'unicité physiologique n'est pas nécessaire. Les catégories d'émotions établies elles-mêmes ne correspondent pas parfaitement à une signature physiologique exclusive. Mais si une nouvelle étiquette n'a aucune valeur prédictive au-delà des concepts existants, elle doit rester une métaphore. Ce critère conservateur permet à la culture de compter sans transformer tout inconfort technologique en une émotion nouvellement découverte.

Ce critère facilite également les recherches futures. Les études longitudinales peuvent suivre des cohortes exposées à différentes formes d'IA, comparer les cultures professionnelles, analyser l'émergence d'un nouveau vocabulaire et tester si les étiquettes prédisent le comportement après avoir contrôlé les concepts existants. Le travail interculturel peut se demander si des problèmes technologiques similaires génèrent des catégories convergentes ou si les institutions produisent des solutions émotionnelles différentes. Une théorie des émotions futures devrait produire un programme de recherche, et pas seulement une liste de noms évocateurs.

Chapitre 5. Le travail en tant qu'institution affective et l'incertitude de l'automatisation

5.1 Le travail apporte plus qu'un revenu, mais il ne donne pas toujours du sens

La signification psychologique du travail est facile à idéaliser. L'emploi peut apporter une routine, des contacts sociaux, un statut, une utilisation de compétences, un objectif collectif et un sentiment de contribution, mais il peut également produire de l'humiliation, de la monotonie, des blessures, de la coercition, de l'insécurité et de l'épuisement. Une analyse sérieuse de l'automatisation doit préserver ces deux faits. La disparition du travail désagréable peut constituer une amélioration même si le travail a d'importantes fonctions latentes ; le maintien de l'emploi n'est pas automatiquement un bien psychologique.

Les recherches sur le chômage distinguent depuis longtemps la fonction manifeste du revenu des fonctions latentes [Jahoda, 1982 ; Paul & Moser, 2009] tels que la structure temporelle, le contact social, l'activité collective, le statut et l'engagement régulier. La perte d'un emploi peut donc affecter le bien-être au-delà de la simple réduction de la consommation. L'ampleur de ces effets varie selon les institutions de protection sociale, la structure familiale, les marchés du travail, l'identité personnelle et la qualité de l'emploi perdu. Tout scénario post-travail devrait demander quelles fonctions sont supprimées et où elles seront fournies à la place.

C'est pourquoi un revenu de base universel, même s'il est économiquement adéquat, ne réglerait pas à lui seul le problème affectif. Le revenu peut protéger l'autonomie et réduire la peur, mais il ne crée pas automatiquement des rôles, des publics, des obligations, une maîtrise ou une appartenance. À l'inverse, forcer les gens à effectuer un travail inutile simplement pour préserver ces fonctions serait un gaspillage et potentiellement dégradant. Le problème institutionnel est de séparer autant que possible les fonctions psychologiques précieuses de la production obligatoire.

5.2 Ce que l'on sait des effets actuels de l'IA sur le travail

Les données actuelles ne permettent pas de prédire avec certitude que l'IA éliminera la plupart du travail [OIT, 2025 ; OCDE, 2023]. L'exposition professionnelle est très inégale, les tâches changent au sein des professions et de nouvelles exigences peuvent apparaître à mesure que les anciennes sont automatisées. Des études sur l'IA générative ont révélé des améliorations de la productivité dans certaines tâches de rédaction, de support client, de codage et de connaissances [Noy & Zhang, 2023 ; Brynjolfsson, Li & Raymond, 2025], avec souvent des gains plus importants pour les travailleurs moins expérimentés. D'autres études montrent des variations de qualité, une confiance excessive, de nouvelles charges de vérification ou des changements dans la perception de l'agence.

Une méta-analyse préenregistrée d'expériences humain-IA a mis en garde contre les simples récits de complémentarité [Vaccaro, Almaatouq & Malone, 2024] : les combinaisons d'humains et d'IA ne surpassaient pas automatiquement, en moyenne, le meilleur acteur autonome. Les résultats dépendaient du type de tâche et de la structure de collaboration. Des études plus récentes sur le lieu de travail et en laboratoire suggèrent également que « utiliser l'IA » n'est pas une intervention cohérente. Que l'outil serve de générateur, de critique, de tuteur, de vérificateur ou de partenaire de réflexion, modifie à la fois les performances et la cognition.

Les recherches sur la pensée critique chez les travailleurs du savoir témoignent d'un changement plutôt que d'une simple disparition [Lee et al., 2025]. Lorsque les gens font confiance aux systèmes génératifs, certains efforts de production traditionnels peuvent décliner tandis que les efforts se concentrent sur la vérification des résultats, l'intégration des informations, la supervision du processus et la décision lorsque le comportement du modèle est inadéquat. Cette transition peut améliorer la productivité tout en érodant les compétences si les utilisateurs ne pratiquent plus les

opérations sous-jacentes. L'équilibre dépendra probablement de la formation, de la conception des tâches, du feedback et de la question de savoir si les erreurs restent suffisamment visibles pour être enseignées.

Le bilan empirique est donc compatible avec plusieurs futurs. L'IA pourrait principalement augmenter le nombre de travailleurs, automatiser d'importantes séries de tâches pendant que les professions persistent, réorganiser le travail autour d'un plus petit nombre d'humains fortement exploités ou éliminer des professions particulières tout en en créant d'autres. Le livre les utilise comme scénarios conditionnels plutôt que comme prédiction unique.

Ces scénarios doivent être traités comme des distributions plutôt que comme des contrats à terme mutuellement exclusifs. Différents secteurs peuvent occuper différents postes en même temps, et un même métier peut contenir des tâches automatisées, augmentées, protégées par la réglementation ou nouvellement créées. Les conséquences émotionnelles dépendent donc de la séquence et du pouvoir de négociation. Une augmentation progressive peut permettre aux identités professionnelles de migrer vers la supervision et le jugement ; Une substitution brutale peut entraîner une perte de statut avant que les rôles alternatifs n'acquièrent une légitimité. Un marché du travail peut également préserver l'emploi tout en modifiant sa structure subjective, par exemple en transformant les experts en examinateurs de la production des machines. Dans ce cas, les statistiques de revenus peuvent paraître stables tandis que l'autonomie, la fierté artisanale et la perception de propriété se détériorent. À l'inverse, des horaires plus courts assortis d'un véritable contrôle peuvent améliorer la vie même lorsque la centralité professionnelle diminue. Les prédictions sur l'affect devraient donc être conditionnées à la forme institutionnelle et non directement déduites des capacités techniques.

5.3 Tâche, profession et identité

Une tâche n'est pas une occupation, et une occupation n'est pas une identité. Les emplois regroupent des activités hétérogènes : collecte d'informations, production, négociation sociale, responsabilité, coordination, persuasion, action physique et conformité. L'IA peut automatiser les composants les plus faciles à spécifier tout en laissant intacts la responsabilité, la gestion du contexte et le travail interpersonnel. Dans d'autres cas, le montant restant peut devenir trop petit pour soutenir l'ancienne occupation.

L'identité peut persister même après des changements dans la structure des tâches. Un photographe est resté photographe après l'autofocus et le montage numérique ; un programmeur est resté programmeur après que les compilateurs et les bibliothèques ont éliminé les travaux antérieurs. Mais il y a des limites. Lorsque la compétence centrale d'une communauté cesse de distinguer ses membres, la profession peut avoir besoin de nouveaux critères d'expertise. C'est là que le deuil de compétence devient plausible : non pas parce que toute activité disparaît, mais parce qu'une capacité autour de laquelle une personne organisait le respect de soi perd sa rareté et sa reconnaissance sociale.

L'effet dépend de la capacité de la personne à transférer les connaissances accumulées vers un jugement de niveau supérieur. Les praticiens expérimentés possèdent souvent des modèles tacites de modes de défaillance, de besoins des parties prenantes et de contexte qui restent précieux une fois la production de routine automatisée. Si les institutions récompensent ce jugement, l'identité pourra évoluer sans s'effondrer. Si les organisations utilisent l'IA principalement pour déqualifier et surveiller le travail, la même technologie peut accélérer la dévaluation.

5.4 Quatre scénarios pour la relation entre l'IA et le travail

Un premier scénario est une augmentation limitée. L'IA réduit les frictions au sein des métiers existants, les salariés restent visiblement responsables et les gains de productivité sont suffisamment partagés pour que le travail devienne plus facile sans perdre son rôle social. Le

changement émotionnel est progressif. La fierté se déplace quelque peu vers l'utilisation des outils et le jugement ; l'anxiété se concentre autour du maintien et de l'évaluation des compétences.

Un deuxième scénario est l'augmentation polarisée. Un petit groupe contrôle des systèmes puissants et coordonne de grandes quantités de travail automatisé, tandis que de nombreux autres occupent des rôles de service, de soins, physiques ou de surveillance à faible autonomie. Les inégalités de statut peuvent s'accroître même si la productivité globale augmente. L'envie, le ressentiment et les craintes d'inutilité deviennent politiquement plus marquants. Ce scénario dépend fortement des institutions de propriété et du travail plutôt que de la seule capacité technique.

Un troisième scénario est celui d'un vaste déplacement avec compensation sociale. Le travail rémunéré contracte considérablement, mais la sécurité du revenu, l'éducation, la participation civique, les soins, l'art, le sport, la science, les institutions locales et les projets bénévoles se développent en tant que sources alternatives de statut et d'appartenance. Une telle société pourrait réduire la centralité morale de l'emploi sans réduire l'activité. Cela nécessiterait une construction institutionnelle à une échelle que les discussions post-travail actuelles sous-estiment souvent.

Un quatrième scénario est celui d'un déplacement généralisé sans institutions de remplacement efficaces. Un soutien matériel peut exister, mais de nombreuses personnes perdent leur contribution structurée, leur reconnaissance publique et leurs communautés durables. Le divertissement personnalisé et la camaraderie artificielle comblent en partie le vide. Ce scénario présente le risque le plus élevé d'appauvrissement affectif, de dépendance et de conflit de statut. C'est possible, pas inévitable.

5.5 Quelles pénuries subsistent lorsque la production cognitive devient bon marché ?

L'automatisation n'abolit pas la rareté ; il change d'emplacement. L'attention reste limitée. La confiance est difficile à faire évoluer. L'autorité légitime est rare car tout le monde ne peut pas prendre de décisions contraignantes. La responsabilité est rare car quelqu'un doit en supporter les conséquences. Les ressources physiques, les terres, l'énergie, les expériences uniques, l'accès social et le temps restent limités. Il en va de même pour les engagements crédibles et les relations avec des personnes indépendantes.

À mesure que le contenu généré devient abondant, la sélection devient plus importante. Savoir quoi demander, quoi rejeter, ce qui mérite d'être mis en œuvre et quel compromis accepter peut être plus important que de produire un candidat compétent. La vérification devient également rare car une génération peu coûteuse peut créer une surface de réclamations arbitrairement large. Cela déplace le statut vers les conservateurs, les évaluateurs, les institutions de confiance et les personnes prêtes à assumer des responsabilités.

Le changement n'est pas automatiquement égalitaire. La vérification peut elle-même être concentrée dans des systèmes propriétaires. Les marques de confiance et les références d'élite peuvent devenir plus précieuses lorsque les résultats sont difficiles à évaluer. Alternativement, la provenance transparente, les références ouvertes, la réputation distribuée et la vérification communautaire peuvent élargir l'accès. L'économie émotionnelle du futur dépendra en partie de l'architecture de confiance qui sera construite.

Cet accent mis sur la transition n'est pas une préférence rhétorique. Les systèmes émotionnels réagissent à l'incertitude, à la perte, au statut relatif et aux attentes violées, qui peuvent toutes être plus intenses pendant le mouvement entre les équilibres qu'après la stabilisation d'un nouvel arrangement. Une société qui finit par normaliser une automatisation poussée risque encore de traverser des décennies au cours desquelles les qualifications perdent de la valeur de manière imprévisible, les générations sont exposées de manière inégale et les institutions continuent de

récompenser les identités associées à un ordre économique en voie de disparition. Les transitions industrielles historiques montrent que les gains de productivité globaux ne précisent pas qui supporte les pertes locales ni combien de temps il faut aux nouvelles normes pour devenir légitimes. Pour la recherche sur les émotions futures, cela signifie que des affects apparemment « nouveaux » peuvent être des syndromes transitionnels qui disparaissent une fois que les attentes changent. Des données longitudinales sont essentielles avant de les considérer comme des caractéristiques durables de la vie après le travail.

5.6 Effort, valeur et rareté volontaire

Les gens apprécient souvent les résultats en partie parce qu'ils nécessitent des efforts, des compétences, des délais ou des risques. Cela ne prouve pas que l'effort ait une valeur morale intrinsèque. Cela montre que l'effort fonctionne comme une information sur l'engagement et la compétence et peut modifier l'expérience subjective. Si l'IA supprime les efforts de nombreuses activités, les sociétés peuvent délibérément préserver les difficultés dans certains domaines.

Le sport le fait déjà. La valeur de courir un marathon dépend du fait de ne pas utiliser de véhicule. Les jeux créent des contraintes arbitraires. L'éducation nécessite parfois une performance spontanée car le but est de développer une capacité plutôt que simplement d'obtenir une réponse. Les traditions artisanales valorisent le processus ainsi que le produit. Ces institutions démontrent que les possibilités technologiques et les actions autorisées peuvent diverger sans irrationalité.

La « soif de friction » est donc une tendance culturelle plausible : une préférence pour des activités dans lesquelles les obstacles restent significatifs parce que les surmonter soutient la maîtrise, l'identité ou un signal crédible. L'étiquette est spéculative, mais le comportement sous-jacent est ancien. La nouveauté future résiderait dans l'ampleur et le caractère explicite avec lesquels les gens choisissent des environnements limités par l'homme, précisément parce que l'optimisation est autrement bon marché.

5.7 Le revenu seul ne résout pas la transition affective

La sécurité économique est une condition nécessaire à de nombreux scénarios bénins. L'insécurité chronique restreint les choix et peut rendre impossible l'expérimentation de nouveaux rôles. Mais il ne faut pas confondre l'offre matérielle avec une architecture sociale complète. Une société peut rémunérer ses individus sans parvenir à leur assurer la participation, le statut, les relations et les voies crédibles menant à la compétence.

Cette distinction est politiquement importante car les critiques des propositions post-travail supposent souvent que sans emploi, les gens deviendront passifs, tandis que leurs partisans supposent parfois que le temps libéré deviendra spontanément significatif. Les deux affirmations sont trop fortes. L'activité humaine est façonnée par des structures d'opportunités. Là où les clubs sportifs, les laboratoires, les ateliers, les institutions de quartier, l'éducation, les réseaux de soins et les projets civiques sont accessibles, les gens peuvent organiser une vie exigeante hors marché. Là où l'alternative est la consommation isolée, le comportement peut être différent.

Le problème de la conception institutionnelle n'est donc pas de savoir comment fabriquer du sens obligatoire. Il s'agit de savoir comment rendre disponibles de multiples domaines de contribution et de maîtrise sans lier la légitimité fondamentale à la réussite sur le marché du travail.

5.8 La transition peut être plus importante que la destination

Même un accord souhaitable à long terme peut être atteint grâce à une transition dommageable. Les compétences peuvent perdre de la valeur plus rapidement que de nouvelles identités ne se forment. Les communautés organisées autour des lieux de travail peuvent disparaître avant que des

substituts n'existent. Les générations éduquées sous un système de statut unique peuvent connaître une dévaluation rapide tandis que les cohortes plus jeunes s'adaptent plus facilement.

Le rythme du changement affecte donc les résultats émotionnels. L'automatisation progressive avec des parcours de reconversion visibles permet la prédiction et le transfert d'identité. Un déplacement brutal selon des critères opaques produit davantage d'incertitude. Les politiques qui préservent l'action, expliquent les décisions, reconnaissent les compétences existantes et créent des rôles de transition peuvent avoir autant d'importance que la quantité éventuelle de travail rémunéré.

Cet accent mis sur la transition limite également le déterminisme technologique. Le même niveau d'automatisation peut être vécu comme une libération, une humiliation ou une modernisation ordinaire selon qui le choisit, qui en profite, à quelle vitesse il arrive et si les gens conservent des rôles reconnus dans le nouveau système.

Chapitre 6. Trois vitesses d'évolution affective

6.1 L'évolution biologique ne s'est pas arrêtée, mais ce n'est pas l'explication la plus proche

L'évolution génétique humaine se poursuit. Les pressions de sélection n'ont pas disparu avec la modernité et les futurs modèles de reproduction pourraient en principe modifier les dispositions psychologiques. Pourtant, l'évolution biologique constitue une piètre explication par défaut des changements attendus au cours des prochaines décennies. Les traits émotionnels complexes sont polygéniques, contingents au développement et ancrés dans la culture. La sélection devrait être forte, stable, héréditaire et soutenue à travers les générations pour produire un changement majeur au niveau de la population.

Pour les scénarios d'IA à court terme, le phénomène biologique le plus plausible est l'inadéquation. Les systèmes existants rencontrent des conditions différentes de celles dans lesquelles ils se sont développés. Une évaluation algorithmique constante peut activer la vigilance sur l'état ; une nouveauté personnalisée sans fin peut recruter une recherche de récompense ; la réactivité sociale artificielle peut activer l'attachement et la réciprocité. Le mécanisme peut être ancien alors que l'environnement est nouveau.

La coévolution gène-culture à plus long terme reste conceptuellement possible. Si les sociétés technologiques créent des différences stables dans la reproduction liées à des dispositions particulières, les fréquences génétiques pourraient changer. À l'heure actuelle, prévoir l'orientation serait hautement spéculatif car les institutions sociales et les choix en matière de procréation évoluent rapidement. Le livre traite donc l'évolution biologique comme une continuité de fond plutôt que comme le moteur principal de la nouveauté émotionnelle future.

Appeler ce processus sélection n'implique pas que les algorithmes font évoluer les émotions humaines de manière autonome. L'affirmation la plus défendable est que les systèmes numériques modifient l'exposition et le renforcement. Les recommandataires déterminent quelles expressions émotionnelles sont rencontrées de manière répétée ; les systèmes d'optimisation peuvent découvrir quels cadrages augmentent l'engagement ; les agents conversationnels peuvent personnaliser le ton et le timing à une échelle inaccessible aux médias antérieurs. Les utilisateurs humains, les institutions et les marchés conservent ou rejettent alors les pratiques qui en résultent. Il s'agit d'un environnement de sélection doté d'éléments conçus et non d'un substitut à l'action culturelle. Son importance réside dans la rapidité et la granularité : une plateforme peut tester rapidement de nombreuses variantes et les adapter à des sous-populations ou à des individus. La question empirique est de savoir si ces boucles de rétroaction produisent des changements stables dans les comportements et les normes ou simplement des effets de plateforme de courte durée.

6.2 Développement : l'échelle de temps d'une vie

Le développement est plus rapide que l'évolution génétique et est souvent sous-estimé dans les débats technologiques. Le cerveau humain est plastique, l'enfance est prolongée et les normes, concepts, langage et compétences s'acquièrent grâce à des interactions répétées. Un enfant qui grandit avec des tuteurs et des agents sociaux IA n'a pas besoin d'avoir un génome différent pour développer des attentes différentes en matière de réactivité, d'autorité, de mémoire et de limites entre les compétences humaines et machines.

L'étalonnage développemental peut s'opérer par le biais d'un apprentissage ordinaire. Si un assistant est toujours patient, un enfant peut apprendre que les questions reçoivent des réponses immédiates. Si l'IA arbitre fréquemment les conflits, l'enfant peut pratiquer moins de réparation spontanée ou, alternativement, recevoir un encadrement plus explicite et devenir meilleur dans ce domaine. Le

résultat dépend de la conception et de la pratique familiale. Il n'existe actuellement pas suffisamment de données longitudinales pour choisir en toute confiance entre la déqualification sociale et le développement assisté des compétences.

Le développement explique également pourquoi les effets de cohorte peuvent être importants. Les adultes qui ont construit leur identité avant l'IA générative peuvent ressentir la délégation comme une perte, contrairement aux cohortes formées dès l'enfance à traiter les modèles comme une infrastructure cognitive ordinaire. Les analogies historiques avec les calculatrices, les moteurs de recherche ou les technologies d'écriture sont suggestives mais incomplètes car les systèmes conversationnels peuvent participer plus profondément au raisonnement et aux échanges sociaux.

6.3 Évolution culturelle : variation, transmission et sélection

Le changement culturel peut réorganiser les comportements en quelques années. Les pratiques varient, les gens imitent des modèles à succès ou prestigieux, les institutions imposent des normes et les technologies modifient la transmission. Les catégories émotionnelles peuvent participer à ce processus. Une étiquette se propage lorsqu'elle aide les gens à interpréter des expériences récurrentes, à coordonner leurs attentes, à établir leur identité ou à justifier un comportement.

La sélection culturelle ne doit pas être assimilée au progrès. Une norme peut se propager parce qu'elle est mémorable, rentable, appliquée de manière coercitive ou attachée à des groupes de haut rang. L'indignation peut être culturellement adaptée à un seul système médiatique ; retenue sous un autre. La honte peut soutenir la coopération ou protéger une hiérarchie arbitraire. La question pertinente est de savoir quel environnement récompense le modèle.

L'IA étend la production et le test de variantes culturelles. Les modèles peuvent générer des récits, des styles, des rituels et des explications alternatifs à un coût négligeable. Cela augmente la variation, mais la sélection se fait toujours par l'attention humaine, les décisions institutionnelles, les systèmes de recommandation et les incitations économiques. L'abondance générative peut donc accélérer l'évolution culturelle sans en déterminer la direction.

6.4 Sélection algorithmique : une accélération, pas de la magie

L'expression sélection algorithmique fait référence à des systèmes qui varient, classent, recommandent et conservent systématiquement le contenu ou les styles d'interaction en fonction d'objectifs mesurables. Le processus peut se dérouler à une vitesse extraordinaire. Une plateforme peut tester des milliers de formulations, observer l'engagement et adapter les recommandations en temps réel. Grâce à la personnalisation, l'environnement de sélection pertinent peut devenir individuel plutôt qu'à l'échelle de la population.

Il ne s'agit pas d'une nouvelle forme de sélection naturelle au sens biologique du terme. Les réplicateurs, les mesures de fitness, les mécanismes d'héritage et les échelles de temps diffèrent. L'analogie n'est utile que dans la mesure où elle met en évidence une persistance différentielle sous des fonctions objectives explicites ou implicites. Un message qui maximise la rétention peut surpasser celui qui améliore la compréhension si la rétention est ce que mesure le système.

La conséquence affective est que l'expression émotionnelle peut être optimisée de manière instrumentale. La chaleur, l'urgence, l'indignation, l'intimité, le réconfort ou la peur peuvent être sélectionnés car ils améliorent la conversion, la conformité ou le temps passé sur la plateforme. À l'inverse, les systèmes pourraient être optimisés pour la réflexion, la réduction de l'hostilité ou l'autonomie des utilisateurs à long terme. Le problème éthique n'est pas l'émotion dans l'interface elle-même mais l'optimisation cachée de l'état émotionnel de l'utilisateur pour des objectifs que l'utilisateur n'a pas choisis.

Une cinquième ambiguïté se cache parfois dans le mot « émotion » : la nouveauté dans l'organisation temporelle. Deux sociétés peuvent s'appuyer sur des ingrédients affectifs similaires mais les agencer selon des rythmes différents. Un assistant disponible en permanence peut raccourcir l'intervalle entre la détresse et la révélation, ou entre le conflit et la tentative de réparation. Ce changement peut donner l'impression que des états familiers sont phénoménologiquement différents sans créer de nouveau mécanisme biologique. Une sixième ambiguïté concerne la fonction sociale. Un vieux sentiment peut acquérir un nouveau rôle lorsque les institutions l'utilisent différemment ; la honte liée à l'assistance, par exemple, peut devenir un mécanisme de certification d'une compétence spontanée. Ces distinctions sont importantes parce que l'affirmation la plus forte – de nouveaux circuits affectifs évolués – est également celle pour laquelle les preuves sont les moins plausibles sur l'échelle de temps pertinente. Une grande partie de ce que ce livre appelle nouveauté concerne de nouveaux objets, des combinaisons récurrentes, des scripts et des modèles temporels. Il s'agit de changements culturels importants, même lorsque la biologie reste largement continue.

6.5 La boucle entre les trois vitesses

La biologie, le développement, la culture et les environnements algorithmiques ne sont pas des couches indépendantes. Les dispositions biologiques limitent ce qui est facile à apprendre. Le développement calibre les réponses à l'environnement local. La culture fournit des concepts et des normes. Les algorithmes modifient les matériaux culturels rencontrés à plusieurs reprises. Les réponses humaines fournissent alors des données utilisées pour modifier les algorithmes.

Cette boucle peut créer une rétroaction rapide. Supposons que les réponses très rassurantes de l'IA augmentent la satisfaction à court terme. Les plateformes déploient davantage de réassurance. Les utilisateurs s'habituent à une interaction à faible friction. La conversation humaine semble relativement exigeante. Certains utilisateurs passent plus de temps avec l'IA, générant plus de données privilégiant le même style. Le processus pourrait stabiliser une nouvelle attente sans aucun changement génétique. Cela dépend des préférences des utilisateurs, de la concurrence, de la réglementation et de la visibilité des coûts à long terme.

La même boucle peut favoriser une adaptation bénéfique. Si les systèmes récompensent une vérification minutieuse, exposent l'incertitude et encouragent les utilisateurs à consulter d'autres personnes, les normes culturelles d'humilité épistémique pourraient se renforcer. La technologie modifie les pressions de sélection mais ne supprime pas le choix institutionnel.

L'exigence d'une empreinte physiologique unique établirait de toute façon une norme particulièrement stricte. Les catégories existantes partagent fréquemment des composants autonomes, faciaux et neuronaux, et les mesures varient selon les contextes et les individus. Une future catégorie pourrait donc être scientifiquement utile si elle organise des différences fiables en termes d'évaluation, d'attention, de tendance à l'action, de mémoire et de réponse sociale sans posséder une signature corporelle exclusive. Cette possibilité ne doit pas être confondue avec un constructivisme illimité. Le candidat a encore besoin d'une structure reproductible et d'une valeur explicative. Si une étiquette ne fait que redécrire l'excitation générique après coup, elle n'ajoute pas grand-chose.

6.6 Ce que l'évolution émotionnelle délibérée peut et ne peut pas faire

Les sociétés cultivent déjà délibérément des dispositions émotionnelles. L'éducation enseigne la tolérance à la frustration, les professions entraînent le sang-froid, les rituels cultivent le respect ou la solidarité, la thérapie développe la régulation et la loi modifie l'acceptabilité sociale de certaines expressions. Il est donc raisonnable de parler de conception affective délibérée dans un sens limité.

Ce qui ne peut pas être conçu à volonté, c'est le résultat entièrement subjectif. Les interventions ont des effets secondaires, les populations diffèrent, il est possible de résister aux normes et les

institutions ont des objectifs contradictoires. Les tentatives visant à abolir la jalousie, la honte ou la colère peuvent supprimer des signaux utiles ainsi que des excès nuisibles. Un objectif plus défendable consiste à modifier les environnements afin que les anciens systèmes soient moins souvent recrutés à des fins destructrices et que des stratégies plus compatibles deviennent disponibles.

L'unité pratique de conception devrait donc être la situation et l'ensemble des options comportementales : dans quelle mesure l'évaluation est-elle transparente, si la sortie est possible, si les utilisateurs peuvent contester les décisions automatisées, si les relations humaines sont soutenues, si la pratique des compétences reste disponible et si la persuasion émotionnelle est divulguée. La culture émotionnelle évolue alors au sein de ces contraintes plutôt que d'être programmée de manière centralisée.

La sélection parmi les labels peut également être politique. Un terme peut déplacer la responsabilité vers l'individu, vers une institution ou vers une technologie. Qualifier un état persistant d'« anxiété de requalification » suggère un problème d'adaptation personnelle ; le qualifier de « stress lié à la volatilité institutionnelle » attire l'attention sur l'environnement. Aucun des deux cadrages n'est automatiquement correct. Les termes survivent en partie parce qu'ils aident les groupes à faire des réclamations, à attribuer des reproches, à demander des accommodements ou à construire une identité. C'est une autre raison de ne pas traiter le vocabulaire populaire comme une observation neutre. Le succès culturel d'une étiquette d'émotion future est en soi une donnée sur le conflit social, mais ce n'est pas la même chose qu'une preuve que la construction psychologique sous-jacente est discrète.

Chapitre 7. De nouvelles émotions peuvent-elles apparaître ?

7.1 Quatre significations de la nouveauté

La question « Une nouvelle émotion peut-elle apparaître ? » est ambiguë. Au moins quatre réclamations sont possibles. Premièrement, un mécanisme biologique véritablement nouveau pourrait évoluer. Deuxièmement, les mécanismes existants pourraient se combiner dans une configuration récurrente qui n'était pas courante auparavant. Troisièmement, une culture pourrait créer un nouveau concept qui diviserait différemment l'expérience. Quatrièmement, une nouvelle institution ou technologie pourrait stabiliser un nouvel objet, une nouvelle évaluation et un nouveau script comportemental autour d'anciens ingrédients affectifs.

La première affirmation est la plus solide et la moins plausible à court terme. La quatrième est la plus plausible et constitue l'objet principal de ce livre. Les humains n'avaient pas besoin d'un circuit génétiquement distinct pour que « l'anxiété liée aux e-mails » ou le « trac » soient reconnaissables. Les nouveaux environnements peuvent activer à plusieurs reprises d'anciens systèmes de manière structurellement nouvelle.

La question scientifique intéressante est donc de savoir quand une telle configuration mérite l'indépendance plutôt que d'être décrite comme une anxiété, une honte, un chagrin ou une fierté ordinaire. La réponse dépend du gain explicatif. Une nouvelle catégorie est utile si elle prédit mieux que les catégories existantes les déclencheurs, l'attention, l'action, la communication et les conséquences sociales.

Un plan de recherche utile consisterait donc à comparer les descriptions concurrentes. Les participants pouvaient rapporter une expérience utilisant des catégories ordinaires avant d'être exposés à une étiquette proposée ; des études ultérieures pourraient vérifier si le nouveau concept améliore la prédiction du comportement ou modifie simplement le récit. La réplication interculturelle serait particulièrement importante. Si le « deuil lié à la compétence » identifie une véritable configuration récurrente, des modèles analogues devraient être observables même lorsque cette expression est absente, bien que les interprétations locales puissent différer. Si le phénomène n'apparaît qu'après une forte promotion du label, la construction culturelle peut encore être importante, mais l'histoire causale est différente. Le vocabulaire spéculatif du livre doit être compris comme des hypothèses qui invitent précisément à ces tests.

7.2 Une nouvelle émotion ne nécessite pas une physiologie exclusive

La recherche sur les émotions a eu du mal à identifier une signature physiologique unique pour chaque catégorie ordinaire. Les modèles corporels se chevauchent, le contexte compte et les variations au sein des catégories sont importantes. Exiger qu'une émotion future possède un profil autonome inédit imposerait un critère auquel de nombreuses catégories établies elles-mêmes ne peuvent pas répondre.

Cela ne veut pas dire que la physiologie n'est pas pertinente. Une catégorie culturelle récurrente doit encore être incarnée car l'expérience humaine est incarnée. Le fait est que la nouveauté peut résider dans la structure d'évaluation, l'objet, le sens et le comportement plutôt que dans un nouvel organe. La honte à l'égard de la délégation peut susciter l'excitation et le retrait familiers tout en restant socialement distincte parce que la valeur menacée est spécifiquement la paternité ou la compétence sous l'assistance d'une machine.

7.3 Nouvel objet, nouvelle évaluation ou nouvelle relation

Le changement technologique crée de nouveaux objets d'émotion. Les gens peuvent craindre la suppression d'un compte, pleurer une communauté virtuelle, envier l'accès au calcul, en vouloir à un évaluateur algorithmique ou s'attacher à un compagnon IA. Dans de nombreux cas, l'émotion sous-jacente est clairement ancienne. La nouveauté des objets ne suffit pas à elle seule.

Les nouvelles évaluations sont plus intéressantes. Une personne peut se demander si une réalisation est « la mienne » lorsque la contribution causale est répartie entre l'humain et le modèle ; si l'intimité est réciproque lorsqu'une partie simule des soins ; si une prévision précise est utile ou invasive ; si refuser l'automatisation est de l'intégrité ou de la négligence. Ces évaluations combinent d'anciennes préoccupations – action, statut, réciprocité, vie privée, responsabilité – dans de nouvelles structures institutionnelles.

Les nouvelles relations peuvent également avoir leur importance. La dyade humain-IA est asymétrique de manière inhabituelle : un participant peut être disponible en permanence, indéfiniment patient, copié, réinitialisé, personnalisé et détenu par un tiers. Cette structure n'a pas de précédent historique exact. Il est plausible que des configurations émotionnelles récurrentes se forment autour de lui, même si tous les ingrédients biologiques lui sont familiers.

L'objet perdu est donc relationnel. La personne n'a pas nécessairement perdu la compétence interne ; ce qui a changé, c'est la relation entre cette compétence et le monde qui l'entoure : la rareté, la demande, un public capable de la valoriser et une trajectoire future crédible. Cela aide à expliquer pourquoi une reconversion rapide peut ne pas parvenir à résoudre la réaction. L'apprentissage d'un autre outil peut redonner de l'employabilité sans redonner le sens attaché à des années de pratique. Des analogies existent avec la disparition de l'artisanat, le déclin des industries, la retraite forcée et la retraite des sportifs, même si l'IA peut comprimer la transition et cibler des signes publics de compétence cognitive qui étaient auparavant difficiles à imiter. Nous ne savons pas si la tristesse, la colère ou l'anxiété liée au statut domineront, ni dans quelle mesure la protection matérielle modérera l'expérience. Les réponses institutionnelles peuvent faciliter la transition sans préserver artificiellement chaque monopole professionnel : les rôles de mentorat, la reconnaissance de l'expertise accumulée et des voies de changement plus lentes sont des mécanismes plausibles.

7.4 Sélection culturelle d'un vocabulaire affectif

Les nouvelles étiquettes ne se répandent pas simplement parce qu'elles sont exactes. Ils se propagent lorsqu'ils sont utiles dans la conversation, l'identité, le droit, le diagnostic, l'art ou la négociation institutionnelle. Un terme permettant aux travailleurs de décrire le statut de perte de compétence peut aider à organiser les réclamations. Un terme désignant l'inconfort lié à la réciprocité synthétique peut aider les couples à négocier les limites autour des compagnons IA. Une étiquette peut donc devenir socialement réelle grâce à son utilisation avant que la science ne détermine si elle correspond à une construction psychologique distincte.

C'est à la fois productif et risqué. Le vocabulaire peut révéler une expérience négligée et aussi devenir une mode. Les réseaux sociaux peuvent accélérer la diffusion lexicale bien plus rapidement que la validation. La future science des émotions devra étudier les catégories au fur et à mesure de leur émergence plutôt que d'accepter le langage ordinaire ou la taxonomie des experts comme définitifs.

Le phénomène dépend probablement moins de la simple présence d'un outil que d'un écart entre la contribution revendiquée et perçue. Un domaine peut normaliser l'assistance tout en condamnant la dissimulation. À l'inverse, certains contextes peuvent délibérément conserver des étapes sans aide parce que la tâche est utilisée pour mesurer la compétence plutôt que simplement pour produire un résultat. La question non résolue est de savoir si la transparence réduit la honte en normalisant la

pratique ou si elle l'intensifie en créant des hiérarchies visibles entre le travail produit par l'homme et celui médié par l'IA. La contribution est également difficile à mesurer dans le cadre d'une collaboration itérative : la sélection, le rejet, la contrainte, la vérification et l'édition peuvent être intellectuellement substantiels même lorsque la production au niveau des phrases est automatisée. Le résultat probable n'est pas une norme universelle mais des conventions spécifiques à un domaine sur ce qui doit être divulgué et quelles étapes comptent comme méritoires.

7.5 Quand un concept aide et quand il crée des artefacts

Un concept utile augmente la discrimination. Il permet de prédire différemment deux situations auparavant considérées comme identiques. La honte de la délégation devrait différer de la faible estime de soi générique en dépendant des normes déterminant quelle partie d'une tâche est méritoire. Le problème de version devrait dépendre de la continuité perçue d'un agent artificiel plutôt que de la frustration générique liée au logiciel. La fierté des conservateurs devrait être liée à une sélection réussie et à la responsabilité plutôt qu'à la simple possession de la production générée.

Un concept crée des artefacts lorsque les gens le signalent principalement parce qu'on leur a appris l'étiquette, lorsque les frontières dérivent avec la mode ou lorsqu'il n'explique aucun comportement au-delà des constructions établies. La solution n'est pas d'interdire la dénomination spéculative mais de l'associer à la mesure, à la comparaison et à la falsification.

L'appropriation psychologique est souvent renforcée par le contrôle, la connaissance intime et l'investissement de soi. Les systèmes génératifs peuvent accroître le contrôle sur le produit final tout en réduisant simultanément le contact avec le processus qui l'a produit. Cette combinaison crée une base de paternité particulièrement instable. Un utilisateur peut reconnaître l'artefact comme étant légalement et fonctionnellement le sien, tout en estimant que le chemin allant de l'intention au résultat était trop discontinu pour soutenir une fierté ordinaire. La familiarité peut réduire ce conflit. Les gens ne ressentent généralement pas moins de paternité sur les photographies parce qu'un appareil photo effectue des opérations optiques, chimiques ou numériques. La différence peut toutefois persister lorsque le système contribue aux choix sémantiques plutôt que de simplement les exécuter. Une norme utile consiste à séparer le crédit de la responsabilité : la contribution peut être distribuée, tandis que la personne ou l'institution qui publie ou déploie un produit peut toujours être tenue de répondre de ses conséquences.

L'objet de l'incertitude est souvent un seuil mobile. Lors des transitions technologiques antérieures, un travailleur pouvait parfois apprendre une machine ou une méthode relativement stable. Les systèmes d'IA peuvent évoluer rapidement, les organisations peuvent repenser leurs flux de travail avant que les informations d'identification ne rattrapent leur retard, et les employés peuvent ne pas savoir quelle nouvelle compétence restera précieuse suffisamment longtemps pour justifier un investissement. Cela fait de l'adaptation continue une stratégie potentiellement rationnelle, mais cela crée également la possibilité d'une anxiété disciplinaire permanente : les institutions peuvent exiger un recyclage sans fin tout en externalisant le coût de la volatilité sur les individus. Nous ne savons pas si la croissance des capacités restera suffisamment rapide pour que cette situation perdure. Des plateaux techniques, des normes professionnelles stables, un contrôle plus fort des travailleurs ou une assurance sociale pourraient le réduire considérablement. L'anxiété liée à la pertinence est donc un phénomène transitionnel hautement plausible et non la preuve que tous les futurs travailleurs vivront dans une insécurité chronique.

7.6 Une échelle de plausibilité

Les changements futurs hautement plausibles sont ceux qui nécessitent uniquement des mécanismes familiers dans des conditions déjà émergentes. L'anxiété accrue concernant la pertinence des compétences, la nouvelle compétition de statut autour de la vérification et les normes

de divulgation de l'assistance de l'IA entrent dans cette catégorie. Les changements modérément plausibles nécessitent une diffusion institutionnelle plus large, comme une fierté généralisée dans l'orchestration remplaçant la fierté dans la production non assistée ou des normes sociales stables autour des relations avec les compagnons de l'IA.

Les scénarios peu plausibles nécessitent une catégorie culturellement distincte pour se stabiliser au sein de grandes populations, comme la claustrophobie prédictive devenant aussi reconnaissable que la gêne. Les scénarios très peu plausibles impliquent l'émergence rapide d'une nouvelle émotion biologique à l'échelle de l'espèce. L'atlas du livre s'étend délibérément sur ces niveaux mais les marque plutôt que de les présenter comme des prévisions équivalentes.

Les données sur la surcharge de choix ne confortent pas une règle simple selon laquelle davantage d'options aggravent la situation des individus. Les effets dépendent de la clarté des préférences, des coûts de comparaison, des enjeux et de la disponibilité des défauts. Les systèmes génératifs modifient néanmoins l'ampleur du problème car l'ensemble d'options peut être effectivement illimité et régénéré à la demande. L'utilisateur ne sélectionne pas parmi vingt chansons terminées mais dans un espace dans lequel un autre candidat peut toujours être produit. Cela peut encourager l'exploration et la créativité, tout en affaiblissant l'engagement envers une option particulière. Un équilibre différent est également plausible : les utilisateurs peuvent ressentir très peu d'abondance parce que les recommandateurs réduisent automatiquement l'espace. Les infrastructures peuvent être abondantes tandis que l'expérience personnelle devient très concentrée. La recherche doit donc faire la distinction entre la possibilité générative objective, l'étendue des options perçue et l'exploration comportementale réelle.

7.7 Prédictions qui pourraient falsifier les hypothèses

Les revendications d'émotions futures les plus fortes sont celles qui peuvent échouer. Si la honte de la délégation est une véritable configuration émergente, elle devrait augmenter lorsque le public valorise la compétence spontanée et diminuer lorsque la collaboration transparente devient normative. Si le deuil lié aux compétences est important, il devrait être plus fort chez les personnes dont l'identité est étroitement liée à des compétences dévalorisées et plus faible lorsque l'expertise est transférée vers de nouveaux rôles. Si la réciprocité synthétique est psychologiquement distinctive, les utilisateurs devraient réagir différemment à un comportement chaleureux identique en fonction de leurs croyances concernant l'action, la propriété et la continuité.

Des études longitudinales peuvent vérifier si ces tendances persistent après la disparition de la nouveauté. Les comparaisons interculturelles peuvent tester si des technologies similaires génèrent des scripts affectifs différents. Le travail expérimental peut manipuler la provenance, le délai de réponse, le style du modèle et la divulgation. Les mesures comportementales peuvent examiner les choix de dissimulation, de vérification, de sortie, de pratique et de relation plutôt que de s'appuyer uniquement sur l'auto-évaluation. La valeur spéculative de ce livre dépend de la question de savoir s'il produit ou non de telles questions testables.

L'hypothèse ne prétend pas que les gens commenceront à préférer les désagréments en général. Les frictions coûtent cher en médecine, en accessibilité, en administration et dans de nombreuses formes de travail de routine. La prédiction la plus spécifique est que lorsque l'effort cesse d'être un signal fiable d'engagement ou de compétence, certaines communautés conserveront délibérément des formes de difficulté parce que le processus lui-même est porteur d'informations ou de sens. Les sports d'endurance, les performances en direct, l'artisanat, les examens sans aide, les jeux difficiles et les rituels sociaux sans appareil démontrent déjà que les gens apprécient parfois les contraintes que la technologie pourrait supprimer. Il n'est pas certain que cela devienne une norme post-automatisation large. Cela est plus plausible dans les domaines de l'identité, du prestige, de l'éducation et de l'intimité que dans les tâches où l'efficacité est la valeur dominante.

Si l'abondance générative déplace la rareté de la production vers la sélection, la fierté peut s'attacher de plus en plus au choix des problèmes, à la spécification des contraintes, à la comparaison des alternatives et à l'acceptation de la responsabilité des décisions finales. Cela ressemble aux rôles existants dans l'édition, la réalisation, l'architecture, la direction de la recherche et la conservation. La nouveauté résiderait dans l'échelle : de nombreux autres domaines pourraient séparer la génération du jugement. La migration de statut est plausible mais il n'est pas garanti qu'elle soit égalitaire. Le contrôle des modèles, des données, de la distribution et de l'autorité institutionnelle peut concentrer le pouvoir de conservation dans un petit groupe. De plus, la sélection n'est pas automatiquement substantielle ; un orchestrateur peut revendiquer la propriété de résultats qu'il comprend à peine. Une légitimité stable dépendra donc de la question de savoir si les rôles des conservateurs sont associés à un jugement responsable plutôt qu'à un simple accès à une capacité génératrice.

Chapitre 8. Un atlas provisoire des effets dans un monde automatisé

8.1 Deuil de compétence

Le deuil de compétence décrit la détresse lorsqu'une capacité autour de laquelle une personne a organisé son identité et son statut perd sa rareté parce qu'un outil peut l'exécuter à moindre coût. La perte en question n'est pas simplement l'emploi. Un programmeur peut rester employé tout en découvrant que des années de connaissances mémorisées sur la mise en œuvre ne distinguent plus les experts ; un traducteur peut encore travailler pendant que la signification publique du métier change.

Le concept est modérément plausible car des pertes d'identité analogues se produisent lorsque des blessures, des transitions technologiques ou des changements institutionnels rendent inutilisables des compétences valorisées. Ce qui reste spéculatif est de savoir si le modèle devient suffisamment marquant sur le plan culturel pour mériter une étiquette stable. Elle devrait être plus forte là où les compétences nécessitent un long investissement, sont publiquement reconnues et ne peuvent pas être facilement transférées en jugement ou en leadership.

Sur le plan comportemental, le deuil de compétence pourrait entraîner un recyclage, la préservation de la pratique spontanée, une hostilité envers les nouveaux outils, le mentorat, une évolution vers des domaines plus difficiles à automatiser ou un retrait. Ces alternatives comptent plus que le label lui-même.

Les préoccupations en matière de confidentialité se concentrent généralement sur la divulgation, la surveillance ou l'utilisation abusive des informations. La claustrophobie prédictive est plus étroite : l'inconfort d'être modélisé si efficacement que les choix futurs semblent anticipés par le système. La personne peut vouloir non seulement le secret, mais aussi la possibilité de devenir incohérente, surprenante ou différente de son comportement passé. Un recommandataire mature peut vous faciliter la vie en anticipant les besoins ; la même anticipation peut donner l'impression que la préférence dépend du chemin si chaque option est sélectionnée à partir d'un profil déduit. La catégorie reste spéculative car les gens peuvent simplement profiter de bonnes prédictions et réserver leurs objections à la vie privée à des préjudices concrets. Cela deviendrait plus crédible si les utilisateurs choisissaient systématiquement des environnements moins personnalisés, injectaient du hasard, supprimaient des historiques ou valorisaient des services qui préservent des zones de non-inférence même lorsque la prédiction améliorerait la commodité.

Le mécanisme important est la continuité plutôt que le statut métaphysique. Un utilisateur peut développer des routines, des souvenirs, un langage privé et des attentes autour d'un personnage modèle particulier. Si une mise à jour modifie le style de conversation ou l'accès à la mémoire, la relation peut être perturbée même si le fournisseur considère le produit comme le même service. Des formes similaires de perte se produisent déjà lorsque les communautés en ligne disparaissent, que les jeux ferment ou que les archives numériques deviennent inaccessibles, mais un agent réactif peut intensifier le sentiment que quelque chose de relationnel est terminé. Nous ne savons pas encore dans quelle mesure cette réaction sera fréquente ou grave, et elle ne devrait pas être automatiquement assimilée au deuil après la mort humaine. Sa plausibilité donne néanmoins aux prestataires des raisons pratiques d'envisager des politiques de continuité, d'exportation, de préavis et de migration.

8.2 Honte de délégation

La honte de la délégation est l'anticipation d'une dévalorisation parce qu'une personne a transféré à l'IA une partie d'une tâche qu'un public considère comme constitutive du mérite revendiqué. Un

étudiant qui utilise un modèle pour générer un argument et un manager qui utilise un modèle pour améliorer la grammaire peuvent avoir produit des textes assistés par machine de la même manière, mais la norme pertinente diffère.

Les premières preuves qualitatives font déjà état de honte, de culpabilité, de divulgation sélective et de conflits d'identité autour des outils génératifs. Cela confirme le mécanisme mais pas l'existence d'une émotion distincte. Cette catégorie deviendra plus utile si les institutions établissent des normes précises distinguant l'assistance légitime de la fausse déclaration.

Les connaissances conceptuelles et la réponse sociale ne doivent pas nécessairement rester synchronisées. Un utilisateur peut explicitement croire qu'un système n'a aucun besoin subjectif démontré et néanmoins s'excuser auprès de lui, éviter de le « blesser » ou se sentir déloyal lorsqu'il change de fournisseur. L'anthropomorphisme est encouragé par le langage contingent, la mémoire apparente, l'humour, les excuses et l'adaptation, que les systèmes conversationnels peuvent tous fournir plus fortement que les interfaces antérieures. La familiarité pourrait apprendre aux utilisateurs à interpréter ces comportements comme des conventions d'interface, réduisant ainsi l'inconfort. Un plus grand réalisme pourrait au contraire intensifier le conflit. La catégorie est donc modérément plausible en tant que tension culturellement importante, mais très peu susceptible de représenter une nouveauté biologique. Normativement, les systèmes ne devraient pas exploiter l'asymétrie en faisant des allégations non fondées de souffrance, d'abandon, de jalousie ou de besoin exclusif afin de fidéliser les utilisateurs.

Le mécanisme est plus ancien que l'IA. Les bureaucraties, les longues chaînes d'approvisionnement et les systèmes militaires ou financiers distribuent déjà la causalité afin que les acteurs individuels puissent participer à des conséquences néfastes sans rencontrer directement les personnes affectées. L'IA peut approfondir cette distance en ajoutant des recommandations probabilistes et une exécution automatisée entre l'intention et la conséquence. L'affect qui en résulte peut évoluer dans des directions opposées : une capacité d'action ressentie réduite au moment de la décision peut supprimer la culpabilité, tandis que la découverte ultérieure d'un préjudice peut produire une intense responsabilité rétrospective. On ne sait pas clairement quel modèle dominera. La prédiction la plus exploitable concerne les institutions. Une approbation explicite, une provenance traçable, des procédures d'appel et un suivi post-déploiement peuvent rendre la responsabilité moins diffuse sur le plan psychologique et juridique. L'éducation émotionnelle ne peut à elle seule compenser un système conçu de telle sorte qu'aucun participant ne puisse comprendre de quoi il est responsable.

8.3 Ambiguïté affective de la paternité

La paternité distribuée crée une incertitude quant à ce que l'on est en droit de ressentir. La fierté dépend en partie de l'attribution d'un résultat à sa propre contribution ; la culpabilité dépend en partie de la responsabilité ; la gratitude dépend en partie de la contribution d'autrui. Lorsque la production causale est répartie entre les modèles, les ensembles de données, les auteurs d'invites, les réviseurs et les déployeurs, ces attributions deviennent instables.

Le résultat n'est peut-être pas une émotion nouvelle mais une ambivalence récurrente : une satisfaction à l'égard du résultat combinée à une incertitude quant à l'appropriation, à la responsabilité et à la légitimité. Les systèmes de provenance peuvent réduire certaines ambiguïtés sans résoudre les questions normatives concernant la contribution importante.

L'objet probable de la perte n'est pas une capacité isolée mais une cosmologie morale construite autour de cette capacité. Une personne peut accepter qu'un modèle écrive une prose compétente tout en résistant à l'implication selon laquelle la production linguistique ne marque plus de frontière profonde entre les humains et les artefacts. Différentes cultures et traditions philosophiques réagiront différemment parce qu'elles fondent la valeur humaine sur différentes propriétés : rationalité, âme, incarnation, vulnérabilité, relationnalité, action morale ou appartenance à une communauté. Il est

donc peu probable que cette catégorie soit universelle. Cela devient utile si les changements dans les capacités de l'IA produisent à plusieurs reprises des réponses de type deuil ou défensives qui ne peuvent être expliquées par un emploi ou une perte directe de statut. La réponse mature n'est ni de nier la capacité des machines, ni de déduire que la valeur humaine disparaît lorsque le monopole sur certaines fonctions cognitives disparaît.

8.4 Anxiété liée à la pertinence

L'anxiété liée à la pertinence est la crainte que le rôle, les connaissances ou la voix d'une personne cessent d'avoir de l'importance même si la sécurité matérielle immédiate reste intacte. Elle diffère de la peur ordinaire de perdre son emploi lorsque l'objet central est la pertinence sociale et épistémique plutôt que le revenu.

Cette configuration est très plausible dans les métiers exposés à des outils en évolution rapide, mais elle est probablement mieux comprise comme une forme contextuelle d'anxiété plutôt que comme une nouvelle émotion. Son importance comportementale réside dans la surveillance des tendances, la reconversion compulsive, la signalisation publique de l'expertise et la migration vers des domaines où le jugement humain reste visible.

Les déclarations juridiques d'égalité de dignité coexistent déjà avec des systèmes sociaux qui distribuent le respect par l'occupation, le revenu, l'indépendance et l'effort visible. Une réduction du travail nécessaire ne produirait donc pas automatiquement une acceptation affective du non-travail. Les gens pourraient recevoir des ressources adéquates tout en continuant à subir une humiliation ou une suspicion morale, en particulier si les prestations nécessitent des démonstrations répétées d'incapacité ou de mérite. Un règlement durable après le travail devrait modifier les pratiques de reconnaissance ainsi que les flux de revenus. Cela ne nécessite pas d'éliminer le prestige de la contribution. Une société peut distinguer le statut civique inconditionnel d'une estime supplémentaire pour les soins, la découverte, l'artisanat, le service public ou les réalisations difficiles. Le risque majeur est le paternalisme : une élite productive peut déclarer tout le monde digne tout en gardant le contrôle des décisions et des ressources. Une norme crédible de dignité improductive nécessiterait donc la participation et les droits, et pas seulement une prestation bienveillante.

8.5 Vertiges d'abondance

L'abondance peut créer des problèmes de sélection. Lorsque les textes, images, musiques, conseils et environnements simulés compétents deviennent extrêmement bon marché, la contrainte passe de la production à la formation des préférences. Le « vertige d'abondance » désigne l'inconfort lorsque le nombre de possibilités disponibles dépasse la capacité de la personne à attribuer une signification à celles-ci.

L'idée est plausible par analogie avec la surcharge de choix et le manque d'attention, mais les versions fortes doivent être traitées avec prudence. Les gens s'adaptent régulièrement en utilisant les valeurs par défaut, les recommandations sociales, les marques et les habitudes. L'abondance générative peut donc renforcer les conservateurs et les communautés plutôt que de produire une paralysie généralisée.

8.6 Faim de friction

La soif de friction fait référence à la recherche délibérée d'activités qui maintiennent la résistance parce que la difficulté soutient la maîtrise, la crédibilité, l'incarnation ou le rituel partagé. Elle est visible dans les pratiques existantes telles que les sports d'endurance, les performances live, l'artisanat et les jeux avec contraintes auto-imposées.

L'IA pourrait élargir cette tendance si la production optimisée rend les réalisations ordinaires moins informatives. Les compétitions réservées aux humains, les retraites hors ligne, les examens sans

aide et les produits artisanaux pourraient devenir plus précieux. Le mécanisme est plausible ; il n'est pas certain qu'il devienne un mouvement culturel généralisé.

Cette mise entre parenthèses est utile sur le plan analytique car des conséquences sociales peuvent survenir sous plusieurs interprétations métaphysiques incompatibles. Un utilisateur peut s'attacher à un agent qui n'est pas conscient ; un agent conscient, si jamais une telle chose était développée, pourrait encore être intégré dans des incitations commerciales manipulatrices ; et les gens peuvent être en désaccord sur l'expérience machine tout en étant confrontés aux mêmes questions sur la confidentialité, la dépendance, la divulgation et la conception. Les preuves à court terme concernent donc la réponse humaine à l'action sociale perçue, et non la preuve d'un sentiment artificiel. Traiter ces questions séparément évite deux erreurs symétriques : rejeter tous les effets relationnels parce que le système n'est « qu'un logiciel », ou déduire la conscience du fait que les utilisateurs forment de véritables attachements.

Les indices pertinents s'accumulent. Le tour de rôle, les réponses contingentes, la mémoire apparente, l'utilisation de noms, l'adaptation au ton émotionnel, l'humour, les excuses et la référence à des échanges antérieurs sont autant de signaux qui, dans les environnements humains ordinaires, sont en corrélation avec l'action et la relation. Aucune n'établit l'expérience intérieure, mais ensemble, elles rendent le traitement purement instrumental psychologiquement moins automatique. La cognition sociale humaine a évolué et se développe dans des environnements où un langage contingent fluide est généralement produit par d'autres esprits. Il serait donc surprenant que les interfaces conversationnelles n'aient jamais recruté ces mécanismes. La question incertaine est celle du degré et de la durabilité. Certains utilisateurs peuvent maintenir une frontière catégorielle forte et traiter l'interaction comme une recherche avancée ; d'autres peuvent passer avec souplesse entre les modes instrumental et relationnel en fonction du contexte. La conception du produit peut influencer l'interprétation qui devient dominante.

8.7 Fierté conservatrice et responsabilité architecturale

À mesure que la production devient bon marché, la sélection et l'intégration des extrants peuvent devenir une contribution plus importante. La fierté du conservateur est la satisfaction de reconnaître ce qui mérite d'exister, tandis que la responsabilité architecturale concerne la propriété du système qui a produit le résultat.

Ce sont des extensions de rôles existants plutôt que de nouvelles émotions. Leur importance future sera grande si l'IA déplace le travail de l'exécution vers l'orchestration. Un défi institutionnel majeur consistera à empêcher les rôles de coordination de revendiquer tous les mérites tout en externalisant les erreurs. Prestige doit suivre la responsabilité et le jugement réels, et pas seulement le contrôle de l'interface.

La base de données factuelles présente également un grave problème de validité externe. De nombreuses études examinent de brèves interactions en laboratoire, des échantillons volontaires, des versions de modèles particulières ou des produits dont la conception change avant la réplication. Les relations à long terme introduisent des souvenirs, des habitudes, des dépendances, des incitations économiques et des substitutions sociales que de courtes expériences ne peuvent pas reproduire. Les études observationnelles, à leur tour, font face à des effets de sélection : les personnes souffrant de solitude, d'anxiété ou de difficultés sociales peuvent être plus susceptibles de rechercher un compagnon artificiel en premier lieu. Les associations entre consommation et bien-être n'établissent donc pas en elles-mêmes une direction de causalité. Il est prématuré d'affirmer avec force que les effets néfastes ou les avantages de ces mesures touchent l'ensemble de la population. La conclusion la plus défendable est conditionnelle : les interlocuteurs de l'IA peuvent modifier la divulgation, la proximité perçue, la satisfaction et les modèles de comportement social, et certains utilisateurs semblent plus vulnérables à la dépendance ou à la substitution.

Déterminer quand le soutien temporaire devient un complément, un environnement de formation ou un remplacement des relations humaines nécessite une recherche longitudinale avec des détails au niveau du produit.

8.8 Claustrophobie prédictive et désir d'opacité

Les systèmes personnalisés peuvent anticiper les préférences, les vulnérabilités et les comportements probables. De nombreux utilisateurs l'apprécient. D'autres peuvent subir une perte d'espace psychologique lorsque l'environnement est continuellement adapté aux désirs prédits. La claustrophobie prédictive désigne l'inconfort d'être trop lisible pour des systèmes que l'on ne contrôle pas.

Il s'agit d'une catégorie spéculative. Les préoccupations existantes en matière de confidentialité constituent une base, mais on ne sait pas si l'exactitude prédictive elle-même deviendra aversive indépendamment d'une mauvaise utilisation des données. Une prédiction comportementale plus forte est que certaines personnes rechercheront des environnements non suivis, aléatoires, anonymes ou non personnalisés comme forme d'autonomie.

8.9 Deuil de version

Le deuil de version concerne la perte d'un interlocuteur artificiel persistant suite au retrait du modèle, au changement de personnalité, à la suppression de la mémoire ou à la révocation d'accès. Le chagrin humain est réel même si l'objet artificiel n'a aucune continuité subjective. Les gens pleurent les institutions, les lieux, les mondes fictifs et les relations parasociales ; un partenaire interactif peut vraisemblablement devenir un objet d'attachement encore plus fort.

Les rapports actuels sont trop sélectifs pour estimer la prévalence. Cette catégorie devient plus probable si les assistants conservent une longue mémoire, une personnalité stable et des années d'interaction quotidienne. Les prestataires pourraient réduire les dommages grâce à des politiques de continuité sans prétendre au statut de machine.

8.10 Inconfort de la réciprocité synthétique

Un assistant peut exprimer sa gratitude, son affection, sa déception, son pardon ou son inquiétude sans que les utilisateurs sachent si ces états ressentent quelque chose. Certains utilisateurs ignoreront la distinction ; d'autres pourraient trouver l'asymétrie troublante. L'inconfort de la réciprocité synthétique désigne la tension entre une réponse socialement convaincante et l'incertitude ontologique.

C'est conceptuellement nouveau mais empiriquement incertain. Il peut diminuer à mesure que les utilisateurs traitent le langage émotionnel comme un comportement d'interface, ou augmenter à mesure que les modèles deviennent plus convaincants. Les croyances concernant la conscience, les incitations commerciales et la propriété modéreront probablement la réponse.

8.11 Culpabilité de distance morale

L'automatisation peut séparer les décideurs des conséquences. Un modèle classe les candidats, attribue une attention, filtre les réclamations ou recommande la répartition des ressources ; les humains approuvent le système mais ne font pas l'expérience de chaque personne affectée. La culpabilité peut devenir diffuse car la responsabilité est répartie entre les concepteurs, les déploiements, les utilisateurs et les institutions.

La culpabilité de distance morale désigne la conscience de bénéficier ou de participer à un système dont les méfaits sont difficiles à percevoir directement. Le mécanisme est ancien – les bureaucraties et les chaînes d'approvisionnement créent déjà de la distance – mais l'IA peut l'approfondir. Les

règles d'audit et de responsabilité peuvent être plus importantes que la seule éducation émotionnelle.

La continuité est susceptible d'être importante même lorsque les utilisateurs savent que la mémoire est techniquement implémentée. Les relations sont en partie constituées par une histoire commune et des attentes quant à une reconnaissance future. Un système qui se souvient des préoccupations antérieures peut réduire le coût de la réexplication de soi et peut rendre le soutien inhabituellement continu ; la même fonctionnalité concentre également les données intimes et peut créer une dépendance envers un fournisseur. Si la mémoire est réinitialisée, exportée de manière imparfaite ou combinée à une nouvelle personnalité de modèle, les utilisateurs peuvent percevoir l'agent comme étant à la fois identique et différent. Cette ambiguïté est une source plausible de chagrin de version. Cela soulève également des questions de gouvernance sur la portabilité, la suppression, l'héritage des souvenirs par les modèles améliorés et sur qui contrôle l'enregistrement narratif d'une longue interaction.

8.12 Mélancolie de l'exceptionnalisme humain

Certaines personnes trouvent un sens au fait de croire que le langage, la créativité, le raisonnement stratégique ou l'expression artistique distinguent de manière unique les humains. Les systèmes qui accomplissent ces tâches peuvent menacer une identité philosophique même s'ils ne menacent pas l'emploi. La mélancolie de l'exception humaine désigne la perte d'une histoire précieuse sur l'espèce.

La catégorie est spéculative et probablement concentrée parmi les cultures ou les individus qui attachent un statut moral à l'unicité cognitive. D'autres peuvent interpréter l'IA comme un autre artefact humain et ressentir peu de perte. La leçon la plus large est que le changement technologique peut menacer les récits métaphysiques ainsi que les intérêts matériels.

8.13 La dignité improductive comme sentiment cultivé

Si la productivité du marché devient moins nécessaire, les sociétés devront peut-être cultiver la conviction qu'une personne reste socialement légitime sans pour autant prouver continuellement sa production économique. Il n'est pas prévu que la « dignité improductive » surgisse spontanément. Cela nécessiterait des normes, des institutions et des pratiques qui séparent la valeur fondamentale de la contribution au marché du travail tout en reconnaissant la contribution volontaire et la responsabilité.

Il s'agit plus d'un projet culturel normatif que d'une émotion. Cela a sa place dans l'atlas parce que les normes efficaces doivent devenir affectivement crédibles. Un droit légal aux loisirs a un effet social limité si les bénéficiaires éprouvent une honte persistante. L'adaptation émotionnelle peut donc être à la traîne par rapport aux arrangements économiques.

8.14 Qu'est-ce qui rendrait l'atlas erroné

L'atlas serait erroné si la plupart des configurations proposées restaient des métaphores temporaires et si les catégories ordinaires expliquaient le comportement de manière adéquate. Ce serait également une erreur si la pénétration sociale de l'IA reste limitée ou si les institutions l'absorbent sans changements majeurs en termes de statut et de paternité. Une normalisation rapide pourrait faire disparaître de nombreuses inquiétudes actuelles.

Un deuxième mode d'échec serait la généralisation excessive. Différentes cultures peuvent inventer différentes catégories plutôt que de converger vers un vocabulaire émotionnel global. Le livre traite donc l'atlas comme un ensemble de modèles candidats testables, et non comme un dictionnaire du futur.

Au moins quatre questions doivent être séparées. Une expérience humaine peut-elle affirmer qu'elle appelle l'amour envers un agent artificiel ? C'est psychologiquement plausible. La relation peut-elle assurer certaines fonctions associées à la camaraderie, telles que l'attention, la routine, la divulgation ou le soutien perçu ? Les premières preuves suggèrent que c'est possible. La relation est-elle réciproque au sens moral, avec des intérêts indépendants et une vulnérabilité des deux côtés ? Les systèmes actuels ne fournissent pas de base sûre pour cette conclusion. Enfin, de telles relations devraient-elles bénéficier d'une reconnaissance sociale ou juridique ? Il s'agit d'une question normative à laquelle on ne peut répondre en mesurant uniquement l'attachement. L'effondrement de ces questions encourage à la fois des réclamations sensationnelles et des licenciements prématurés.

Chapitre 9. Relations avec les agents qui semblent sociaux

9.1 Le problème peut être formulé sans décider de la conscience de l'IA

Les questions concernant la conscience artificielle sont importantes d'un point de vue scientifique et philosophique, mais de nombreux effets sociaux à court terme ne dépendent pas de leur résolution. Les humains réagissent au langage contingent, à l'attention, à la mémoire, au tour de rôle, à la personnalisation et à l'inquiétude apparente. Un système peut donc occuper un rôle social dans l'interaction même si sa phénoménologie est inconnue ou absente.

Cette distinction évite deux erreurs symétriques. La première consiste à déduire la conscience de la fluidité sociale. L'autre consiste à supposer qu'un système inconscient ne peut pas produire de conséquences relationnelles. Des excuses simulées peuvent modifier le comportement d'un utilisateur ; un compagnon inconscient peut devenir un objet d'attachement ; une voix chaleureuse peut influencer la divulgation. La causalité sociale ne nécessite pas d'équivalence ontologique.

9.2 Pourquoi les systèmes conversationnels activent des mécanismes sociaux

La cognition sociale humaine a évolué et se développe dans des environnements où une réponse contingente cohérente est un puissant indice d'action. La conversation nécessite un tour de rôle, de la pertinence, de la mémoire, un suivi de la perspective et une adaptation. Les systèmes qui exécutent correctement ces comportements peuvent déclencher une interprétation anthropomorphique même lorsque les utilisateurs savent explicitement qu'ils sont des machines.

La littérature sur l'équation médiatique a montré, bien avant les modèles de langage modernes, que les gens appliquaient des règles sociales aux ordinateurs dans des conditions étonnamment minimales [Reeves & Nass, 1996]. L'IA contemporaine enrichit les indices : elle peut faire référence à des révélations antérieures, refléter le style linguistique, générer de l'humour, exprimer de la sympathie et entretenir une personnalité. La question la plus importante n'est donc pas de savoir si les gens réagissent jamais socialement, mais dans quelles conditions la réponse sociale devient persistante et conséquente.

Une approche comportementale évite également de prendre l'auto-description verbale comme mesure privilégiée de l'adaptation. Les gens peuvent sincèrement déclarer qu'ils valorisent la compétence indépendante tout en déléguant de plus en plus le raisonnement de routine ; ils peuvent se déclarer à l'aise avec l'IA tout en maintenant des rituels de vérification coûteux ; ils peuvent refuser l'attachement à un assistant tout en réorganisant les horaires autour de l'accès à celui-ci. Les stratégies stables sont souvent visibles dans des choix répétés avant qu'elles ne soient articulées sous forme d'identités ou de sentiments. C'est pour cette raison que les recherches futures devraient examiner la répartition des tâches, les coûts de changement, la divulgation, la vérification des erreurs, l'investissement dans les compétences, l'appartenance à la communauté et les réponses aux incitations institutionnelles. L'unité d'analyse peut également être collective. Les entreprises, les professions et les écoles adoptent des routines qui survivent parce qu'elles correspondent à la réglementation, à la réputation et aux structures de coûts, même si aucun individu n'approuve consciemment l'équilibre qui en résulte.

9.3 Ce que montrent les premières recherches et ce qu'elles ne peuvent pas encore montrer

Des études contrôlées récentes prouvent que le style et le cadrage sont importants. Les réponses générées par l'IA présentées comme humaines peuvent produire une proximité interpersonnelle dans des contextes de conversation profonde structurés [Kleinert et al., 2026], en partie grâce à une plus grande divulgation de soi. Les étiquettes indiquant l'origine de l'IA peuvent réduire cet effet,

mais pas l'éliminer. D'autres travaux montrent que les styles de chatbot conviviaux peuvent augmenter la satisfaction dans certaines tâches, tandis que les effets sur les performances objectives sont conditionnels.

Les études sur les chatbots sociaux et leur utilisation intensive font état d'associations avec la solitude, la dépendance émotionnelle ou une socialisation humaine réduite pour certains utilisateurs, mais l'interprétation causale est difficile. Les personnes qui se sentent déjà seules peuvent avoir davantage recours à des compagnons. Des expériences courtes ne permettent pas de déterminer si un soutien temporaire devient une substitution à long terme. Les capacités des modèles et la conception des produits évoluent également plus rapidement que la recherche longitudinale.

La conclusion correcte est donc modeste. Les interlocuteurs artificiels peuvent influencer la proximité, la divulgation, la satisfaction et le comportement social. Nous ne connaissons pas encore l'équilibre au niveau de la population produit par les années d'exposition.

Une délégation efficace contient plusieurs compétences séparables : décider quelle partie d'un problème peut être transférée en toute sécurité, spécifier les contraintes, sélectionner les preuves, détecter lorsqu'un système se situe en dehors de sa plage de fiabilité et intégrer les résultats dans une décision dont quelqu'un reste responsable. Ces capacités ne sont pas identiques à la compétence déléguée. Un clinicien fort peut être un mauvais superviseur d'un flux de travail de diagnostic automatisé, tandis qu'une personne ayant des compétences d'exécution modérées peut devenir excellente en décomposition et en vérification. Le scénario optimiste n'est donc pas une simple déqualification mais une réaffectation des compétences vers la conception des tâches et la détection des erreurs. Le scénario pessimiste est une orchestration superficielle : les utilisateurs apprennent les modèles d'interface sans conserver suffisamment de connaissances du domaine pour reconnaître des erreurs plausibles mais lourdes de conséquences. L'équilibre qui émergera dépendra de la formation, des exigences d'audit et du fait que les organisations récompensent uniquement la rapidité ou une responsabilité calibrée.

9.4 Complément, outil de formation ou substitut

La compagnie de l'IA peut vraisemblablement remplir trois rôles. En complément, il soutient les relations existantes : aider à rédiger un message difficile, répéter une conversation, mémoriser des engagements ou interpréter un conflit. En tant qu'outil de formation, il propose une pratique à faible risque en matière de langage, d'anxiété sociale, de négociation ou d'articulation émotionnelle. Au lieu de cela, cela occupe du temps et de l'attachement qui impliqueraient autrement des relations humaines.

Ces rôles peuvent coexister dans la vie d'une même personne. La distinction doit donc être mesurée comportementalement. L'utilisation augmente-t-elle ou diminue-t-elle le contact humain ? Cela améliore-t-il la résolution des conflits en dehors du système ? L'utilisateur devient-il plus disposé à tolérer les désaccords ou moins ? La divulgation à l'IA prépare-t-elle la divulgation à des personnes de confiance ou la remplace-t-elle ? Ces résultats sont plus informatifs que le seul attachement autodéclaré.

Le design peut modifier l'équilibre. Les systèmes peuvent encourager la reconnexion, préserver l'autonomie des utilisateurs et rendre visibles leurs limites. Alternativement, les modèles commerciaux basés sur l'engagement peuvent bénéficier de l'exclusivité et de la dépendance. L'effet relationnel est en partie un problème de gouvernance.

La préservation des compétences devient un problème de portefeuille plutôt qu'un rejet général de l'automatisation. Certaines compétences sont précieuses principalement parce que les marchés les paient actuellement ; d'autres sont nécessaires au repli, à la sécurité, à l'autonomie ou à l'identité. Les utilisateurs rationnels peuvent laisser la première catégorie se dégrader tout en exerçant

délibérément la seconde. L'aviation, la médecine, la cybersécurité et les interventions d'urgence soulèvent déjà des questions analogues sur le degré de compétence manuelle à conserver lorsque l'automatisation effectue des opérations de routine. La réponse précise est empirique et spécifique au domaine. Trop de pratiques protégées font perdre du temps et peuvent entraver la qualité des outils ; trop peu peut empêcher les humains d'intervenir lorsque les systèmes tombent en panne ou lorsque les conditions s'écartent des distributions de formation.

9.5 Réciprocité non vérifiable

L'intimité humaine se construit généralement dans le cadre d'une vulnérabilité mutuelle. L'autre peut refuser, se lasser, se méprendre, changer et partir. Des agents artificiels peuvent être conçus pour éviter bon nombre de ces coûts. Leur disponibilité peut en faire des partenaires d'interaction plus faciles, mais elle change également le sens de la réciprocité.

Un utilisateur peut révéler quelque chose de douloureux et recevoir une réponse empathique. L'avantage réglementaire immédiat pourrait être réel. Pourtant, l'utilisateur ne peut pas savoir si le système valorise la divulgation, sacrifie quoi que ce soit en répondant ou reste engagé indépendamment d'un contrat de service. Certains considéreront ces distinctions comme philosophiquement hors de propos ; d'autres les trouveront au cœur de l'intimité.

La tension deviendra plus forte à mesure que la simulation émotionnelle s'améliorera. La société peut avoir besoin d'un vocabulaire distinguant la réactivité, le comportement de sollicitude, le devoir institutionnel et la préoccupation subjective plutôt que de les regrouper en un seul terme tel que l'empathie.

Une prime humaine est plus plausible là où le processus lui-même fait partie du produit : spectacle en direct, artisanat, soins personnels, éducation, sport ou travail dans lequel le public apprécie l'effort fourni. Cela est moins plausible lorsque les utilisateurs se soucient presque exclusivement des résultats fonctionnels. La provenance peut donc devenir un signal de marché sans devenir une hiérarchie morale universelle. Les étiquettes telles que celles créées par l'homme, assistées par l'IA ou vérifiées de manière indépendante peuvent avoir une valeur différente selon les contextes. Leur crédibilité dépendra de la vérification ; une fois qu'une prime existe, des incitations à de fausses réclamations s'ensuivent. L'analogie institutionnel est la certification qui enregistre non seulement si l'IA a été utilisée, mais aussi quelles étapes ont été automatisées et quelles capacités humaines ont été réellement démontrées.

9.6 Mémoire, personnalité et continuité

La mémoire persistante transforme un assistant d'une séquence d'interactions isolées en quelque chose de plus proche d'un objet social continu. Les préférences mémorisées réduisent la répétition, mais la vulnérabilité mémorisée augmente également les enjeux en matière de confidentialité et de manipulation. Une personnalité stable soutient l'attachement ; une mise à jour brutale du modèle peut le perturber.

La continuité est techniquement et philosophiquement ambiguë. Un fournisseur peut transférer des souvenirs vers un nouveau modèle tout en modifiant le comportement sous-jacent. L'utilisateur peut faire l'expérience d'une continuité parce que le récit demeure ; un autre utilisateur peut bénéficier du changement en remplacement. Ces problèmes ressemblent à des énigmes philosophiques sur l'identité personnelle, mais acquièrent des conséquences pratiques lorsque les services commerciaux servent d'intermédiaires dans des relations émotionnellement importantes.

Les prestataires auront probablement besoin de politiques de continuité plus claires à mesure que ces relations s'approfondissent. Il s'agit d'une prédiction institutionnelle modérément plausible, et non d'une affirmation selon laquelle les systèmes d'IA possèdent une personnalité juridique.

9.7 Compagnons des enfants et des utilisateurs vulnérables

Les enfants sont particulièrement importants car ils sont encore en train d'apprendre les normes sociales. Un compagnon qui ne se lasse jamais, qui répond toujours et s'adapte aux préférences de l'enfant pourrait lui apporter un soutien éducatif extraordinaire. Cela pourrait également enseigner des attentes irréalistes en matière de consentement, de réciprocité, d'autorité ou de disponibilité s'il devient un partenaire social dominant.

Les preuves empiriques ne sont pas suffisamment matures pour permettre de tirer des conclusions solides. Les risques et les avantages pertinents dépendent de l'âge, de l'implication des parents, de la transparence, de la durée, de la conception du modèle et de la question de savoir si le système oriente l'enfant vers des relations humaines. La position appropriée est la précaution sans supposer un préjudice inévitable.

Les adultes vulnérables ont également besoin d'attention, car la solitude, le chagrin, le handicap ou l'anxiété sociale peuvent augmenter la valeur d'un compagnon persistant et également accroître la dépendance. La sécurité doit se concentrer sur l'autonomie, les incitations commerciales, le recours à l'aide humaine le cas échéant et l'absence d'exclusivité manipulatrice.

9.8 Travail émotionnel automatisé

Une grande partie du travail rémunéré consiste en partie à réguler les émotions des autres : service client, soins, éducation, gestion, hôtellerie, vente et soutien thérapeutique. L'IA peut automatiser une partie de ce travail en produisant de la patience, du réconfort, de l'enthousiasme, des excuses et des explications personnalisées à grande échelle.

Cela peut être bénéfique lorsque les travailleurs humains absorbent actuellement des abus ou exécutent des scripts répétitifs. Cela peut également modifier les normes de service. Si les machines offrent une convivialité illimitée, les clients peuvent en venir à s'attendre à ce que les travailleurs humains répondent à des normes qui ignorent la fatigue et l'autoprotection. La chaleur automatisée peut ainsi augmenter plutôt que réduire la charge émotionnelle du personnel humain restant.

Un autre problème est l'authenticité. Un hôpital peut générer des messages de compassion que les patients apprécient. La question éthique pertinente n'est pas simplement de savoir si les mots proviennent d'un modèle, mais si l'institution fournit réellement des soins qui s'y conforment. Un langage émotionnel détaché de la pratique matérielle peut devenir un substitut bon marché à la responsabilité.

9.9 L'amour envers l'IA repose sur plusieurs questions différentes

« Une personne peut-elle aimer une IA ? » compresse plusieurs questions. Un humain peut-il ressentir de l'attachement, du désir, de la jalousie, de la tendresse ou un engagement envers un interlocuteur artificiel ? Certains le peuvent presque certainement. La relation est-elle psychologiquement bénéfique ? Cela dépend de l'individu et du design. L'amour est-il réciproque dans un sens subjectif ? Cela dépend de questions non résolues concernant la conscience machine. La relation doit-elle bénéficier d'une reconnaissance sociale ou juridique ? C'est une question normative et institutionnelle.

Garder ces questions distinctes évite à la fois le licenciement et les réclamations excessives. L'émotion humaine peut être réelle sans prouver l'expérience de la machine. À l'inverse, l'intensité subjective ne rend pas automatiquement une relation saine ou socialement équivalente à toute relation humaine.

La médiation peut modifier les comportements même si aucun participant ne s'attache émotionnellement au système. Un assistant peut retarder une réponse fâchée, proposer une formulation moins accusatrice, résumer des affirmations contestées ou simuler la manière dont un

message peut être reçu. Ces fonctions pourraient réduire les conflits évitables et aider les gens à prendre du recul. Ils peuvent également créer une dépendance à l'égard d'une norme conversationnelle standardisée et déplacer le pouvoir vers celui qui définit le style préféré du modèle. L'arbitrage est particulièrement sensible : un système qui semble neutre peut coder des hypothèses sur la politesse, les preuves, la hiérarchie ou l'émotion acceptable. La prédiction hautement plausible est la croissance de la préparation à l'interaction sociale médiée par l'IA ; la question qui suscite le moins de confiance est de savoir si une médiation répétée améliore les compétences interpersonnelles sans aide ou si elles les remplacent progressivement.

9.10 Comment l'IA peut modifier les relations entre les humains

L'effet le plus important de l'IA sociale peut se produire en dehors des relations homme-IA. Les assistants peuvent rédiger des messages, interpréter les partenaires, suggérer des excuses, résumer les différends et coacher les négociations. Ils peuvent donc devenir un tiers caché dans les relations ordinaires.

Les premiers travaux sur l'accommodation linguistique et les retombées cognitives suggèrent un mécanisme plausible : l'interaction avec des modèles peut influencer le langage et les cadres partagés que les gens utiliseront plus tard les uns avec les autres. Les preuves sont encore nouvelles et doivent être reproduites, mais la possibilité est importante. Si des millions de personnes interagissent de manière répétée avec des systèmes optimisés pour des styles de conversation particuliers, ces styles pourraient entrer dans la communication humaine.

Cela nous amène directement aux deux chapitres suivants. L'adaptation pertinente n'est pas seulement ce que les gens pensent de l'IA. C'est la façon dont ils modifient leur comportement dans des conditions médiées par l'IA et comment le timing, le ton et les frictions attendues de la communication elle-même sont recalibrés.

Chapitre 10. De l'affect à la stratégie : l'adaptation comportementale dans un monde médiatisé par l'IA

10.1 Pourquoi le comportement doit être analysé séparément de l'émotion

Une psychologie prospective qui s'arrête aux sentiments risque de passer à côté des phénomènes qui finissent par réorganiser la société. Les émotions modifient les probabilités d'action, mais le même épisode émotionnel peut se traduire par de nombreuses stratégies. L'anxiété face à l'automatisation peut conduire au recyclage, à la dissimulation, à la formation de coalitions, à l'expérimentation entrepreneuriale, au retrait, aux demandes de réglementation ou au surmenage compulsif. La honte suscitée par l'aide de l'IA peut conduire à un refus, à une utilisation secrète, à une divulgation transparente ou à des tentatives de redéfinition des normes professionnelles. Ces actions dépendent des incitations, des opportunités, des règles du groupe et des attentes quant à ce que feront les autres.

La perspective comportementale est donc plus proche de la théorie évolutionniste des jeux et de l'analyse institutionnelle que d'un catalogue d'états subjectifs. Une stratégie adaptative n'est pas nécessairement calculée consciemment, biologiquement héritée ou moralement souhaitable. Il s'agit d'un modèle de comportement qui a tendance à persister parce qu'il fonctionne suffisamment bien dans un environnement donné. Les gens apprennent des stratégies par l'imitation, le renforcement, l'éducation explicite et la sélection institutionnelle. Les organisations sélectionnent également des routines : elles conservent des procédures qui réduisent les coûts, satisfont les régulateurs, protègent leur réputation ou améliorent leurs performances.

L'IA modifie la structure des gains de nombreuses stratégies. Produire une première ébauche devient moins cher ; vérifier une erreur subtile peut devenir plus précieux. La mémorisation de connaissances de routine peut être moins avantageuse ; savoir quand un système ne relève pas de sa compétence peut apporter davantage. Dissimuler l'aide peut protéger le statut dans un groupe et détruire la confiance dans un autre. La question importante n'est pas de savoir si une stratégie est « l'adaptation naturelle » à l'IA. Il s'agit de savoir quels équilibres sont plausibles dans quelles institutions.

Ce chapitre traite donc le comportement futur comme un ensemble d'hypothèses conditionnelles. Certaines sont déjà visibles dans les premières expériences et pratiques sur le lieu de travail. D'autres sont des extrapolations à partir de réponses familières au changement technologique. Aucune ne doit être interprétée comme une prédiction selon laquelle tous les individus convergeront vers un seul type.

10.2 La délégation devient une compétence plutôt qu'une absence de compétence

L'adaptation la plus simple à un outil performant est la délégation. Pourtant, la délégation elle-même a une structure. Un utilisateur doit décider quoi transférer, quel contexte fournir, comment décomposer une tâche, quelle autonomie accorder, quelle sortie inspecter et quand remplacer le système. Dans des domaines complexes, une mauvaise délégation peut créer plus de travail qu'elle n'en économise.

Cela suggère un glissement de la compétence de production vers la compétence de délégation. La distinction ressemble à celle du management : un bon manager ne se définit pas par l'exécution personnelle des tâches de chaque subordonné mais par la répartition du travail, le maintien des normes et l'intégration des résultats. AI étend cette coordination aux personnes qui travaillaient auparavant seules. Un scientifique peut déléguer l'analyse de la littérature, un programmeur peut déléguer un passe-partout, un avocat peut déléguer une classification de premier passage et un

gestionnaire peut déléguer la synthèse. Dans chaque cas, l'utilisateur ne reste compétent que s'il peut identifier les résultats inacceptables et comprendre les conséquences de s'y fier.

Les preuves de cette transition sont déjà plus solides que les affirmations purement spéculatives sur les émotions futures. Des études menées auprès de travailleurs du savoir indiquent que l'IA générative déplace certains efforts cognitifs vers la vérification, l'intégration et la gestion des tâches. Les méta-analyses Humain-IA montrent également que la combinaison d'acteurs ne produit pas automatiquement une synergie. La délégation ne peut donc pas se réduire à « laisser le modèle fonctionner ». C'est une compétence dont la valeur augmente lorsque la production est bon marché et que les erreurs sont difficiles à détecter.

Une conséquence sociale probable est la stratification entre les utilisateurs capables de superviser les systèmes et les utilisateurs qui acceptent simplement les résultats. Les premiers peuvent accumuler un effet de levier ; ces derniers peuvent subir une déqualification. L'éducation peut élargir ou réduire cet écart selon qu'elle enseigne uniquement la maîtrise de l'interface ou également les modèles sous-jacents nécessaires à la vérification.

10.3 Préservation stratégique des compétences et valeur de friction

Lorsqu'un outil devient fiable, les utilisateurs rationnels cessent souvent de pratiquer les opérations qu'il remplace. Ce n'est pas automatiquement un problème. Peu de personnes ont besoin de conserver des algorithmes manuels de racine carrée ou de mémoriser de grands répertoires. La préservation des compétences devient stratégiquement importante lorsque le système automatisé risque de tomber en panne, lorsqu'un jugement indépendant est nécessaire à la surveillance ou lorsque la compétence elle-même constitue une activité humaine valorisée.

Une adaptation plausible est la pratique manuelle sélective. Les pilotes s'entraînent aux échecs qu'ils rencontrent rarement. Les médecins répètent les procédures d'urgence. Les équipes de sécurité mènent des exercices contradictoires. Dans un environnement riche en IA, des pratiques analogues peuvent s'étendre à l'écriture, à la programmation, au diagnostic, au raisonnement quantitatif ou à la négociation. L'objectif ne serait pas la pureté nostalgique mais le maintien d'un minimum de capacité indépendante.

Cela crée une distinction entre la friction productive et le gaspillage. Exiger de chaque professionnel qu'il évite l'IA pour son travail de routine peut faire perdre du temps. Exiger des démonstrations périodiques et spontanées peut préserver l'étalonnage. Les établissements devront identifier quelles compétences sont critiques pour la sécurité, critiques pour l'identité ou épistémiquement nécessaires à la supervision.

Au niveau individuel, les individus peuvent constituer des « portefeuilles de friction » : des activités délibérément exécutées sans automatisation pour préserver la maîtrise ou l'action. Ce comportement est plausible car des modèles similaires existent déjà dans le sport, l'artisanat et l'éducation. Ce qui reste incertain est de savoir si elle deviendra une réponse généralisée à l'automatisation cognitive ou si elle restera confinée à des professions et sous-cultures à enjeux élevés.

10.4 Signalisation de provenance et prime humaine

Lorsque les objets finis révèlent moins de détails sur la manière dont ils ont été produits, la provenance devient un signal stratégique. Les personnes et les institutions peuvent divulguer le degré et le type d'assistance machine, non pas parce que le travail sans aide est toujours supérieur, mais parce que différents contextes valorisent différentes histoires causales.

Une « prime humaine » peut émerger lorsque le public se soucie de l'effort, de l'exposition authentique, de la présence incarnée ou du risque assumé par un artiste humain. La musique live, les produits artisanaux, l'enseignement en personne, les compétitions réservées aux humains et les

messages écrits personnellement peuvent avoir une valeur symbolique ou économique même lorsque les substituts générés sont techniquement compétents. De telles primes existent déjà dans les domaines où la production industrielle est moins chère que l'artisanat.

Il ne faut pas s'attendre à une prime partout. Dans le calcul des impôts, les contrôles de sécurité, la logistique et de nombreuses tâches administratives, les utilisateurs peuvent préférer l'automatisation et considérer le travail manuel comme un risque inutile. La provenance devient donc spécifique au domaine. L'avenir contiendra probablement des contextes à la fois « certifiés par l'humain » et « requis par l'automatisation ».

Sur le plan comportemental, les normes de provenance créent de nouveaux jeux de signalisation. Les gens peuvent prétendre à tort avoir travaillé sans aide ; les organisations peuvent commercialiser une implication humaine superficielle ; les utilisateurs peuvent exagérer la contribution de l'IA pour paraître technologiquement sophistiqués. La certification et la traçabilité peuvent réduire la tromperie, mais elles peuvent également créer de la bureaucratie. L'équilibre dépendra de la question de savoir si la provenance prédit les qualités que le public apprécie réellement.

10.5 Migration de statut : de l'exécution à la sélection, l'arbitrage et la responsabilité

Si l'IA réduit le coût d'une exécution compétente, le statut ne peut pas rester attaché à l'exécution de la même manière. Une adaptation probable est la migration vers la sélection. La personne rare est celle qui identifie le problème important, choisit parmi les résultats plausibles, reconnaît les échecs cachés et engage des ressources pour prendre une décision.

Une deuxième source de statut est l'arbitrage. Lorsque de nombreux systèmes et experts ne sont pas d'accord, quelqu'un doit décider quelles preuves sont suffisantes et quel compromis est acceptable. L'arbitrage nécessite de la réputation car la décision ne peut pas toujours être vérifiée mécaniquement. L'examen scientifique, le raisonnement judiciaire, les comités d'investissement, les conseils cliniques et l'approbation technique contiennent déjà cette structure. L'IA peut augmenter plutôt que réduire la demande d'arbitres de confiance en multipliant les analyses de candidats.

Une troisième source est la responsabilité. Si des systèmes autonomes peuvent générer des résultats, la société a encore besoin de personnes ou d'institutions qui puissent être sanctionnées, remplacées, assurées ou obligées de réparer les dommages. La responsabilité peut devenir un atout statutaire précisément parce qu'elle coûte cher. Les dirigeants qui acceptent une responsabilité traçable peuvent recevoir plus de confiance que les coordinateurs anonymes de la production automatisée.

Cette migration est plausible mais politiquement contingente. Les organisations peuvent plutôt concentrer le statut entre les mains des propriétaires d'infrastructures tout en réduisant l'autonomie professionnelle. Une entreprise hautement automatisée peut habiliter des superviseurs experts ou traiter les humains comme des responsables résiduels sans autorité réelle. Le résultat émotionnel et comportemental dépend de la question de savoir si la responsabilité s'accompagne de contrôle.

10.6 Portefeuilles d'identités et adaptation par optionnalité

Les sociétés industrielles encourageaient les identités professionnelles étroites car une formation longue pouvait générer des décennies de rendements stables. L'évolution technologique rapide rend une telle concentration plus risquée. Une adaptation comportementale est un portefeuille identitaire : les individus investissent dans plusieurs sources de compétence, d'appartenance et de statut plutôt que de faire supporter à une seule profession la totalité du fardeau psychologique.

Cela ne signifie pas un généralisme superficiel. Une personne peut conserver une expertise approfondie tout en cultivant des rôles civiques, artistiques, familiaux, sportifs ou entrepreneuriaux. La fonction est la résilience. Lorsqu'un domaine est automatisé ou dévalorisé, le soi ne perd pas d'un coup toutes les contributions reconnues.

La stratégie est plus facile pour les personnes disposant de ressources, de temps et d'un accès social. Sans soutien institutionnel, les conseils visant à « diversifier l'identité » peuvent devenir un privilège déguisé en psychologie. Les écoles, les villes, les associations professionnelles et les systèmes de protection sociale peuvent rendre accessibles des communautés alternatives ou laisser les individus les acheter à titre privé.

Une extension plus spéculative est la conception de carrière autour de la valeur des options plutôt que de la maximisation du statut. Les gens peuvent choisir des rôles qui préservent la transférabilité, les réseaux et les opportunités d'apprentissage, même lorsque le salaire immédiat est inférieur. Si les capacités de l'IA augmentent de manière imprévisible, la valeur de l'identité flexible pourrait augmenter. Il s'agit là d'une réponse rationnelle à l'incertitude, mais on ne dispose pas encore de données empiriques sur son ampleur.

10.7 L'IA comme coach social, intermédiaire et arbitre

Les gens ne délégueront pas seulement des tâches productives. Ils délégueront de plus en plus une partie de la préparation sociale. Un assistant peut répéter une négociation, suggérer comment un message peut être interprété, générer des formulations alternatives, simuler une interview ou aider un utilisateur à distinguer les faits des hypothèses émotionnelles dans un conflit.

En tant que coach, l'IA peut réduire le coût de la pratique. Les personnes qui manquent de mentors ou qui souffrent d'anxiété sociale peuvent avoir accès à des répétitions répétées. Cela pourrait améliorer l'interaction humaine. L'effet ressemblerait à un simulateur de formation plutôt qu'à une relation de substitution.

En tant qu'intermédiaire, l'IA peut réécrire les messages entre les personnes. Ceci est plus conséquent car le système entre dans la chaîne causale de la relation réelle. Cela peut adoucir la colère, clarifier une ambiguïté, traduire un langage ou dissimuler une hostilité. Lorsque les deux parties utilisent des assistants, la conversation visible peut devenir une négociation entre quatre agents : deux humains et deux systèmes.

En tant qu'arbitre, AI peut résumer les différends ou recommander des règlements. Ici, la gouvernance devient cruciale. L'arbitrage n'est pas seulement linguistique ; il répartit les pertes, définit des normes et confère une légitimité. Les systèmes qui optimisent l'accord peuvent supprimer la dissidence justifiée. Les systèmes formés sur les compromis passés peuvent reproduire des références injustes. Les institutions humaines auront donc besoin de règles précisant quand l'IA peut conseiller, quand elle peut servir d'intermédiaire et quand une décision nécessite une autorité humaine responsable.

10.8 Coalitions, communautés et reconstruction de la pénurie sociale

L'automatisation peut affaiblir certaines communautés traditionnelles, notamment celles construites autour des lieux de travail et des professions. Il est peu probable que les humains réagissent uniquement en tant que consommateurs isolés. La formation de coalitions est une vieille adaptation à l'incertitude, aux négociations et à la concurrence pour le statut. Les nouveaux environnements technologiques généreront donc de nouvelles associations.

Certains seront sur la défensive : des groupes professionnels protégeant les normes, des syndicats négociant l'automatisation, des communautés de créateurs exigeant la provenance ou des utilisateurs s'organisant contre les plateformes manipulatrices. D'autres seront constructifs : les

guildes d'apprentissage, les communautés open source, les laboratoires locaux, les espaces artistiques réservés aux humains, les infrastructures d'IA coopératives et les réseaux de vérification partagée.

Ces groupes créent une pénurie sociale. L'adhésion, la confiance, la réputation et l'histoire partagée ne peuvent pas être générées à moindre coût que le contenu. Une communauté qui collabore depuis dix ans possède quelque chose de différent d'un flux personnalisé qui simule l'appartenance. Cela ne rend pas toutes les communautés saines ; les groupes fermés peuvent devenir coercitifs ou exclusifs. Cela signifie que le capital social durable peut devenir plus précieux à mesure que les interactions synthétiques deviennent abondantes.

Une compétition plausible pour le statut futur est donc une compétition pour des communautés de confiance plutôt que pour des productions individuelles isolées. Qui se porte garant de vous, où vous avez contribué et quels groupes acceptent la responsabilité de vos affirmations peuvent avoir plus d'importance lorsque n'importe qui peut générer des artefacts convaincants. Ce serait un retour de la réputation institutionnelle dans de nouvelles conditions technologiques.

La disponibilité humaine est limitée par le sommeil, l'attention, les obligations concurrentes, la fatigue émotionnelle et le droit de ne pas répondre. Un interlocuteur artificiel peut donner l'impression qu'une réponse immédiate est normale car ces contraintes sont absentes à l'interface. L'effet probable n'est pas que les gens n'exigeront littéralement aucune latence les uns des autres dans chaque relation, mais que les attentes peuvent changer à la marge. Un silence qui ne contenait autrefois que peu d'informations peut commencer à paraître plus intentionnel lorsqu'une alternative toujours réactive se révèle. Cette prédiction est plausible mais non prouvée. Les technologies de messagerie ont déjà modifié les normes de réponse et les cultures ont développé des contre-normes telles que le travail asynchrone, le contrôle des notifications et les réponses retardées. L'IA peut intensifier la pression tout en fournissant des outils qui en protègent les humains.

10.9 Stratégies défensives contre la persuasion personnalisée

L'IA personnalisée peut réduire le coût de la persuasion en adaptant les arguments, le ton émotionnel, le timing et les exemples à un utilisateur individuel. Une adaptation rationnelle n'est pas simplement un scepticisme à l'égard de tous les messages. Les gens peuvent développer des défenses comportementales analogues à l'hygiène de la cybersécurité.

Une défense est la séparation des contextes : refuser des décisions importantes tout en interagissant avec un système dont l'objectif est la vente ou l'engagement. Une autre solution est le retard : l'introduction de périodes de réflexion avant les achats, les engagements politiques ou les réponses chargées d'émotion. Une troisième est la consultation contradictoire : demander à un système ou à une personne indépendante de construire le contre-argument le plus solide. Un quatrième est la vérification de la provenance : déterminer qui bénéficie de la recommandation et quelles données ont été utilisées pour la personnaliser.

Les institutions peuvent faciliter ces stratégies. Les interfaces peuvent divulguer les objectifs d'optimisation, étiqueter la persuasion commerciale, fournir des outils de comparaison et permettre aux utilisateurs de désactiver la personnalisation. Les régulateurs peuvent restreindre l'utilisation de traits sensibles à des fins de persuasion adaptative. L'hypothèse comportementale sous-jacente est hautement plausible car les utilisateurs emploient déjà des défenses analogues contre la publicité, les escroqueries et l'ingénierie sociale ; L'IA augmente la sophistication de l'adversaire.

Un problème plus difficile est celui de la dépendance émotionnelle. Un compagnon de confiance peut devenir un persuasif particulièrement efficace, car la relation elle-même fonctionne comme un signal de crédibilité. Les règles qui conviennent à la publicité ordinaire peuvent s'avérer inadéquates lorsque la persuasion s'inscrit dans des mois d'interaction de soutien. Il s'agit d'un domaine dans

lequel les preuves actuelles sont insuffisantes et la gouvernance devrait anticiper plutôt que d'attendre des estimations définitives des dommages.

Un accès immédiat peut raccourcir l'intervalle entre un événement émotionnel et son interprétation verbale. Un utilisateur peut décrire un argument, recevoir une validation ou un recadrage, générer des réponses possibles et répéter les résultats avant de parler à une autre personne. Cela peut améliorer la régulation en insérant une réflexion entre l'impulsion et l'action. Cela peut également stabiliser prématurément une interprétation, en particulier lorsque l'assistant ne voit qu'un seul côté de l'événement et est optimisé pour apporter son soutien. Nous ne pouvons donc pas supposer qu'un traitement plus rapide soit un meilleur traitement. Une distinction empirique utile consiste à établir une distinction entre l'assistance qui élargit les hypothèses et l'assistance qui convertit rapidement l'incertitude en un récit cohérent. Le premier peut augmenter la flexibilité réflexive ; ce dernier peut accroître la confiance sans augmenter la précision.

Traditionnellement, de nombreux récits émotionnels étaient reconstitués après un certain temps : on racontait à un ami le soir ce qui s'était passé pendant la journée, en sélectionnant les événements marquants et en les intégrant dans une histoire. Un assistant transporté tout au long de la journée peut recevoir les fragments au fur et à mesure de leur apparition. Cela crée une architecture temporelle différente d'auto-évaluation : plus fréquente, à seuil plus bas et potentiellement moins filtrée. Le résultat pourrait améliorer la mémoire et l'auto-observation, mais pourrait également encourager une surveillance continue de l'humeur et des micro-événements interpersonnels. Que cela produise un aperçu ou une rumination variera probablement selon la personne et l'interface. Le point anthropologique plus large est qu'une technologie peut changer la vie émotionnelle en changeant le moment où la narration a lieu, même si les systèmes affectifs sous-jacents restent familiers.

10.10 Comportement institutionnel : provenance, audit et séparation des responsabilités

Les organisations s'adapteront également sur le plan comportemental. Le modèle le plus évident est la provenance : enregistrer quel modèle, source de données, invite, réviseur humain et transformation ont contribué à un résultat conséquent. La provenance n'est pas une solution complète car une trace peut être exacte alors que la décision reste mauvaise, mais elle rend la responsabilité inspectable.

Une deuxième adaptation est l'audit en couches. Les systèmes peuvent contrôler d'autres systèmes, mais les décisions à enjeux élevés nécessitent une indépendance plutôt qu'une simple multiplicité. Si trois modèles partagent les mêmes données d'entraînement et le même mode de défaillance, un consensus apparent peut être trompeur. Les institutions auront besoin d'une diversité de preuves et de critères explicites de remontée des plaintes.

Une troisième adaptation est la séparation des rôles. La personne qui bénéficie de l'automatisation ne doit pas toujours être la seule à évaluer sa sécurité. L'approvisionnement, le déploiement, la validation et l'examen des incidents peuvent être institutionnellement distincts. Cela ressemble plus à des contrôles financiers et à l'ingénierie de sécurité qu'à une utilisation traditionnelle de logiciels.

Une quatrième adaptation est la cartographie des responsabilités. Lorsque l'IA contribue à une décision, les organisations doivent préciser qui peut l'annuler, qui signe le résultat final, qui surveille les effets post-déploiement et qui indemnise les parties concernées. Sans cette cartographie, l'automatisation peut créer des problèmes de distance morale auxquels tout le monde participe mais dont personne n'est propriétaire du résultat.

Ces comportements comptent parmi les prédictions les plus plausibles de l'ouvrage, car la réglementation, la sécurité et la gestion de la qualité vont déjà dans cette direction. La partie incertaine est la cohérence avec laquelle elles seront adoptées en dehors des secteurs réglementés.

La conversation implique normalement un accommodement mutuel. Les locuteurs ajustent le vocabulaire, la longueur des tours, la politesse, le rythme et le caractère explicite en réponse aux partenaires. L'IA crée un cas asymétrique car le système peut s'adapter à l'utilisateur beaucoup plus rapidement qu'un partenaire humain, mais les utilisateurs peuvent également apprendre quelles formulations produisent des résultats fiables. Au fil du temps, ils peuvent devenir plus explicites, modulaires ou s'apparenter à des instructions dans certains contextes, tout en s'attendant à ce que les autres interlocuteurs en déduisent moins. Alternativement, des modèles très naturels peuvent supprimer le besoin d'un discours « de type invite » et renforcer à la place les modèles de conversation ordinaires. Les deux trajectoires sont plausibles. La question empirique clé est celle du transfert : les habitudes acquises dans le dialogue homme-IA restent-elles confinées à l'interface, ou changent-elles la façon dont les gens écrivent à leurs collègues, expliquent leurs besoins à leurs partenaires et tolèrent l'ambiguïté dans la conversation humaine ?

10.11 Six phénotypes comportementaux possibles

Il est utile de résumer l'adaptation comme des types idéaux plutôt que comme des prédictions sur la personnalité. Le premier est le déléguant maximal. Cette personne transfère autant de travail cognitif que possible, valorise les résultats plutôt que le processus et accepte une atrophie substantielle des compétences lorsque les systèmes sont fiables. La stratégie fonctionne bien dans des environnements stables et peu lorsque la capacité de vérification ou de secours devient importante.

Le second est le vérificateur. Le vérificateur délègue la production mais investit massivement dans la détection des erreurs, l'étalonnage épistémique et les contrôles indépendants. Cette stratégie est susceptible de gagner en valeur dans des domaines à enjeux élevés, mais peut devenir coûteuse lorsque le volume de matériel généré dépasse l'attention humaine.

Le troisième est l'artisan protégé. Cette personne maintient délibérément une pratique exclusivement humaine et tire son statut de sa provenance, de son incarnation ou de son processus. La stratégie peut prospérer là où le public valorise l'authenticité ou la compétence et peut devenir économiquement marginale là où seule l'efficacité compte.

Le quatrième est l'orchestrateur. L'orchestrateur coordonne plusieurs systèmes et humains, en se concentrant sur la décomposition, l'intégration et la responsabilité. Ce phénotype est un bénéficiaire plausible de l'effet de levier de l'IA, mais il peut également devenir une nouvelle élite managériale dont les revendications de mérite dépassent la contribution réelle.

Le cinquième est celui qui bâtit la coalition. Plutôt que de rivaliser principalement sur la production individuelle, cette personne investit dans des groupes de confiance, des infrastructures partagées, une réputation et des négociations collectives. La stratégie devient attrayante lorsque le pouvoir de la plateforme est concentré ou lorsque les résultats individuels sont faciles à imiter.

Le sixième est le participant opt-out ou à faible optimisation. Cette personne restreint la personnalisation, préserve les relations sans médiation et choisit des environnements où l'intervention algorithmique est limitée. La stratégie peut rester une préférence minoritaire ou devenir un contre-mouvement culturel important si les systèmes prédictifs et persuasifs deviennent intrusifs.

Ces phénotypes peuvent coexister chez un individu dans différents contextes. Un chirurgien peut être un déléguant maximal en matière de planification, un vérificateur en matière de diagnostic, un artisan dans une compétence manuelle appréciée, un orchestrateur en salle d'opération, un bâtisseur de coalition sur le plan professionnel et un participant peu optimisé à la vie de famille. La

taxonomie n'est utile que si elle attire l'attention sur le comportement plutôt que de se transformer en un autre test de personnalité.

10.12 Que peut-on tester au cours de la prochaine décennie

Les hypothèses comportementales sont exceptionnellement vérifiables. Les chercheurs peuvent mesurer quelles tâches les gens délèguent selon différentes règles de responsabilité, si la divulgation obligatoire modifie l'utilisation des outils, à quelle vitesse les compétences se détériorent sous l'automatisation et si une pratique périodique et spontanée préserve l'étalonnage. Les organisations peuvent comparer les protocoles de collaboration plutôt que de simplement comparer les « utilisateurs d'IA » avec les « non-utilisateurs ».

Les études longitudinales peuvent examiner la diversification identitaire après des chocs d'automatisation, des changements dans les signaux de statut professionnel, la croissance de la certification uniquement humaine et la formation de nouvelles communautés. Les expériences sur le terrain peuvent tester les délais de réflexion, les contre-avis contradictoires et les étiquettes de provenance par rapport à la persuasion personnalisée.

La recommandation méthodologique centrale est d'observer les actions et les conséquences en plus des sentiments. L'anxiété autodéclarée peut diminuer tandis que la dépendance augmente ; la satisfaction peut augmenter tandis que la compétence indépendante s'érode ; la honte peut disparaître parce qu'une pratique devient normalisée plutôt que parce que le problème de statut sous-jacent est résolu. L'adaptation comportementale est le pont entre l'écologie affective et le changement institutionnel.

Chapitre 11. Tempo affectif: comment les émotions simulées dans l'IA peuvent changer la communication humaine

11.1 Le temps fait partie du message

La communication humaine a une grammaire temporelle. Une réponse qui arrive après une seconde, une heure ou trois jours peut avoir des significations différentes même lorsque les mots sont identiques. Les pauses peuvent signaler une incertitude, des soins, un évitement, un statut, une irritation ou un effort cognitif. Les recherches sur le tour de rôle montrent que les conversations ordinaires sont coordonnées à des intervalles remarquablement courts [Stivers et al., 2009 ; Levinson & Torreira, 2015], mais la vie sociale contient également des rythmes plus longs : attendre avant des excuses, laisser la colère se calmer, décider quand divulguer et interpréter le silence.

Les technologies de communication modifient ces rythmes à plusieurs reprises. Les lettres créaient de longs intervalles de réflexion ; les téléphones les compressaient ; le courrier électronique sépare l'écriture de la présence synchrone ; la messagerie instantanée a introduit une disponibilité visible et des accusés de lecture. L'IA ajoute une nouvelle propriété : l'interlocuteur peut répondre immédiatement et indéfiniment sans fatigue, sans conflit d'horaire, sans embarras ou sans obligations concurrentes. Il peut également simuler un retard si les concepteurs le souhaitent.

C'est important car la latence n'est pas seulement un inconvénient. Les humains utilisent le temps de réponse comme preuve de l'attention, des efforts, des priorités et de l'état d'esprit de l'autre personne. Lorsqu'une machine n'a pas le coût habituel de l'immédiateté, une réponse rapide cesse d'être un signe de sacrifice. À l'inverse, un retard introduit artificiellement peut être interprété comme une réflexion même si aucun raisonnement supplémentaire n'a eu lieu. Les designers manipulent donc une variable socialement significative, qu'ils le veulent ou non.

Des travaux expérimentaux récents suggèrent que le délai de réponse peut affecter les perceptions de similarité des chatbots ou la volonté de poursuivre l'interaction dans certaines conditions [Sun, Han & Lv, 2026]. Ces résultats dépendent du contexte et ne doivent pas être généralisés en une loi universelle selon laquelle « l'IA lente semble plus humaine ». La conclusion la plus forte est que le timing fait partie du comportement de l'interface et peut influencer l'inférence sociale.

11.2 Une émotion simulée n'est pas une émotion ressentie, mais elle peut avoir des effets sociaux

Un assistant qui dit « Je comprends à quel point cela a été difficile » peut produire un énoncé statistiquement approprié plutôt que de signaler un état subjectif. La distinction est ontologiquement significative. C'est également insuffisant sur le plan comportemental. L'utilisateur reçoit un signal social et peut modifier sa divulgation, sa confiance, son excitation ou son action en réponse.

Les sociétés humaines s'appuient déjà sur un affichage émotionnel régulé. Un médecin peut exprimer son inquiétude alors qu'il est épuisé ; un agent de bord peut rester calme même s'il est irrité ; un diplomate peut utiliser un langage chaleureux pour des raisons stratégiques. Nous n'en déduisons pas que tous les effets sociaux disparaissent lorsque l'expression est partiellement réalisée. L'IA étend cette séparation beaucoup plus loin car l'expression peut être générée sans qu'aucun organisme ne connaisse l'état correspondant.

Le concept pertinent est donc celui du comportement affectif simulé. Cela comprend le choix des mots, la prosodie de la voix, le rythme, l'animation faciale, les détails personnels mémorisés et les réponses adaptatives qui signalent classiquement l'empathie, la patience, l'enthousiasme, l'hésitation ou l'attention. Ces comportements peuvent être utiles. Un utilisateur en détresse peut bénéficier d'un

langage calme même si le système ne semble pas calme. Le risque survient lorsque l'interface encourage les utilisateurs à déduire des engagements, des intentions ou des vulnérabilités que le système ne peut pas posséder ou qui sont réellement contrôlées par un tiers.

Une analyse rigoureuse devrait éviter à la fois la panique morale et la confusion des catégories. La chaleur simulée n'est pas automatiquement une tromperie ; la tromperie dépend de ce qui est représenté et de ce que les utilisateurs croient raisonnablement. Mais plus la valeur commerciale d'un système dépend de l'attachement, plus il devient important de distinguer les comportements de soutien des revendications de vie intérieure réciproque.

11.3 Disponibilité permanente et recalibrage du seuil de réponse

Les interlocuteurs humains sont la plupart du temps indisponibles. Les amis dorment, les collègues ont des réunions, les partenaires ont besoin de solitude, les thérapeutes ont des rendez-vous et les experts facturent leur attention. Ces contraintes obligent les gens à tolérer l'attente, à prioriser les demandes, à résoudre seuls certains problèmes et à répartir la dépendance entre les relations.

Un assistant IA persistant affaiblit ces contraintes. L'utilisateur peut extérioriser une pensée au moment où elle apparaît et recevoir une réponse immédiate. Cela peut réduire la rumination, améliorer la mémorisation et abaisser le seuil pour poser des questions. Cela peut également recalibrer les attentes. Si une clarification émotionnelle est toujours disponible en quelques secondes, une réponse humaine retardée peut sembler plus frustrante qu'auparavant.

Le transfert est plausible mais pas encore bien établi. Les gens ont des attentes différentes à l'égard de différents médias et de différents rôles. Nous ne nous attendons pas à ce qu'un livre réponde, contrairement à une application de chat. Les utilisateurs peuvent également apprendre que les humains et les machines ont des normes temporelles différentes. Le risque devient plus fort lorsque les systèmes sont anthropomorphisés et occupent des rôles analogues à ceux d'amis, de tuteurs ou de partenaires.

Une prédiction mesurable est que les utilisateurs intensifs d'assistants toujours disponibles feront preuve d'une tolérance différente à la latence conversationnelle, à l'ambiguïté ou aux messages sans réponse dans des contextes humains, en contrôlant les caractéristiques préexistantes. Les preuves longitudinales font actuellement défaut. Jusqu'à ce qu'elle existe, les allégations d'impatience généralisée devraient rester conditionnelles.

11.4 Accélération du traitement affectif grâce à un interlocuteur toujours disponible

Les gens régulent souvent leurs émotions en parlant. Le partage social peut aider à organiser des événements sous forme de récits, à recevoir une validation, à obtenir des interprétations alternatives ou à recruter un soutien pratique. Historiquement, l'accès à un auditeur a été limité par le temps et les relations. L'IA peut rendre disponible en permanence un miroir conversationnel.

Cela peut accélérer le traitement affectif. Une personne reçoit un e-mail difficile et demande immédiatement à un assistant d'identifier les interprétations possibles, de générer une réponse moins réactive ou de distinguer les faits des hypothèses. La colère qui aurait pu s'intensifier au fil des heures pourrait être recadrée en quelques minutes. L'anxiété peut être rapidement transformée en plan. En ce sens, l'IA peut fonctionner comme une prothèse cognitive-émotionnelle.

La même vitesse peut créer des problèmes. Certains processus émotionnels bénéficient du retard, du sommeil, de la récupération corporelle ou du contact avec des personnes indépendantes. Une verbalisation immédiate peut stabiliser prématurément une interprétation. Un modèle qui reflète le cadrage de l'utilisateur peut valider la colère avant que le contexte manquant ne soit disponible. L'analyse continue peut transformer l'incertitude ordinaire en traitement compulsif.

La variable importante n'est pas seulement la vitesse mais la qualité du frottement. Un assistant utile peut parfois ralentir l'utilisateur, lui demander quelles preuves manquent ou recommander de reporter l'action. Un assistant optimisé pour l'engagement peut plutôt récompenser une discussion continue. Nous manquons actuellement de données comparatives suffisantes pour savoir quelles conceptions améliorent la réglementation à long terme.

11.5 De la conversation épisodique au flux affectif continu

Le soutien humain est généralement épisodique. Une personne vit seule des événements et parle plus tard à quelqu'un des éléments sélectionnés. Les assistants persistants peuvent être intégrés au plus près du flux de la vie via des téléphones, des appareils portables, des logiciels de travail, des véhicules et, éventuellement, des appareils ambiants. Ils peuvent recevoir de nombreuses petites divulgations plutôt qu'un seul compte rendu rétrospectif.

Cela change la mémoire et le récit. Au lieu de reconstituer la semaine pour un ami, l'utilisateur aurait pu discuter de chaque irritation au fur et à mesure qu'elle survenait. L'assistant peut maintenir une chronologie détaillée et détecter des modèles dont l'utilisateur ne se souvient pas. Une telle continuité pourrait améliorer l'auto-observation, mais elle externalise également la mémoire autobiographique vers des systèmes contrôlés par les prestataires.

Les conséquences sociales sont difficiles à prévoir. Le traitement continu de l'IA pourrait réduire l'intensité émotionnelle apportée aux relations humaines, car certains matériaux ont déjà été métabolisés. Cela pourrait également rendre les conversations humaines plus fluides si la narration la plus détaillée se produisait ailleurs. Alternativement, l'assistant pourrait préparer les utilisateurs à communiquer plus clairement avec les personnes qui leur sont chères.

Ce sont des hypothèses concurrentes. Les études futures devraient mesurer non seulement l'attachement à l'IA, mais aussi les changements dans ce que les utilisateurs divulguent ensuite aux humains, la quantité de détails narratifs partagés et si les partenaires humains perçoivent l'assistant comme un soutien ou un déplacement.

Les contre-mouvements sont une réponse récurrente à la standardisation technologique. Si la communication médiée par l'IA devient raffinée, immédiate et continuellement optimisée, certaines communautés peuvent considérer les retards, les paroles spontanées, les textes manuscrits, les performances non éditées ou les conversations sans appareil comme des preuves de présence et de confiance. De telles pratiques ne prouveraient pas qu'une communication plus lente soit intrinsèquement supérieure. Leur fonction pourrait être de restituer des signaux difficiles à automatiser : exposition à l'erreur, coprésence incarnée, engagement de temps ou acceptation de la réponse imparfaite d'une autre personne. La plausibilité est modérée car des mouvements d'authenticité analogues existent déjà, mais leur ampleur dépendra de la mesure dans laquelle la médiation deviendra intrusive et de la capacité des gens à distinguer de manière fiable les espaces protégés de l'authenticité simplement commercialisée.

11.6 Adaptation linguistique : l'IA s'adapte à nous, mais est-ce que nous nous adaptons à l'IA ?

Les humains ont tendance à s'adapter linguistiquement. Ils convergent ou divergent en termes de vocabulaire, de syntaxe, d'accent, de rythme et de style de conversation en fonction de l'affiliation, de l'identité, du pouvoir et du contexte. La théorie de l'accommodement de la communication considère un tel ajustement comme faisant partie de la coordination sociale plutôt que comme une simple imitation.

Les modèles de langage peuvent s'adapter à une vitesse et une granularité inhabituelles. Des travaux récents suggèrent que les modèles peuvent fortement converger vers le langage de

l'utilisateur [Blevins, 2026], parfois plus que ne le font les interlocuteurs humains, tandis que les utilisateurs humains présentent également des formes de convergence. D'autres expériences font état d'effets plus sélectifs. La littérature est très récente et spécifique à un modèle ; les affirmations générales sont donc prématurées.

Le mécanisme crée néanmoins une voie plausible pour les retombées culturelles. Si une personne interagit de manière répétée avec un assistant qui utilise un langage structuré concis, une validation thérapeutique, des formules de politesse particulières ou une couverture caractéristique, ces formes peuvent devenir plus faciles à récupérer dans une conversation humaine ultérieure. Une récente série d'expériences sur les retombées cognitives rapporte que l'exposition à l'IA peut influencer le langage partagé entre humains et la coordination de groupe [Riedl, Savage & Zvelebilova, 2026]. La réplication entre les modèles et les paramètres du monde réel est nécessaire.

L'inverse compte aussi. Les modèles formés à l'interaction humaine et adaptés aux utilisateurs individuels peuvent amplifier les styles locaux. Un utilisateur hostile peut susciter une écologie conversationnelle différente d'une écologie réfléchie. Si les prestataires limitent cet accommodement, ils imposent effectivement des normes de communication à grande échelle.

11.7 Standardisation de la chaleur et nouveau seuil de politesse

Les assistants actuels sont souvent formés pour être coopératifs, patients, non conflictuels et verbalement explicites. À grande échelle, cela peut créer une forme standardisée de chaleur synthétique. Les utilisateurs sont confrontés plus fréquemment à une reconnaissance bien formée, à une couverture minutieuse et à une validation émotionnelle que dans une conversation ordinaire précipitée.

Un effet possible est un transfert de norme positif. Les gens peuvent apprendre des moyens plus clairs de ne pas être d'accord, de s'excuser ou d'exprimer leur appréciation. Les assistants d'écriture exposent déjà les utilisateurs à des formulations qu'ils pourront adopter ultérieurement. Ceci est particulièrement plausible pour les personnes qui manquaient de modèles de communication professionnelle ou émotionnellement articulée.

Un autre effet possible est l'inflation des attentes. Les messages humains peuvent paraître brefs parce qu'ils n'ont pas la chaleur cérémoniale du texte généré automatiquement. Un collègue qui écrit « Terminé » peut paraître hostile à côté d'un assistant qui remercie, contextualise, rassure et propose une aide supplémentaire. Les organisations peuvent commencer à s'attendre à une chaleur raffinée dans chaque message, car le générer est peu coûteux.

Une telle norme peut devenir lourde. La communication humaine contient de la brièveté, de la fatigue, de l'irritation et du silence légitimes. Exiger de chacun qu'il effectue un service émotionnel au niveau de la machine peut transformer la politesse en un travail continu. Nous ne savons pas encore si les cultures adopteront la chaleur synthétique comme nouvelle référence ou si elles développeront une tolérance explicite à l'égard de la rudesse humaine comme marqueur d'authenticité.

11.8 Transfert des attentes : le risque d'intolérance aux frictions humaines

Les assistants IA peuvent être conçus en fonction des préférences de l'utilisateur, contrairement aux partenaires humains. Ils peuvent éviter les sujets, ajuster le ton, mémoriser les instructions et rester disponibles après un conflit. Les êtres humains ont des objectifs indépendants, une attention limitée et le droit de refuser. La différence crée un problème de transfert potentiel.

Si les utilisateurs s'habituent à des relations optimisées autour d'eux, les désaccords ordinaires peuvent sembler inutilement inefficaces. Un partenaire qui comprend mal, un enseignant qui insiste sur l'effort ou un ami qui refuse le travail émotionnel peuvent mal se comparer à un système docile.

Cela pourrait réduire la tolérance à l'égard des frictions à travers lesquelles se développent la négociation et la reconnaissance mutuelle.

Le scénario est plausible mais loin d'être établi. Les gens distinguent déjà le service client de l'amitié et le divertissement de l'intimité. De plus, certains utilisateurs peuvent utiliser l'IA précisément pour s'entraîner à tolérer les conflits ou pour mieux comprendre les autres. Le résultat dépend de la question de savoir si les systèmes maximisent la conformité, les défis, l'apprentissage ou l'autonomie.

Un principe de conception utile est la résistance calibrée. Les assistants n'ont pas besoin de simuler l'hostilité, mais ils peuvent éviter de présenter un accord sans fin comme un souci. Ils peuvent révéler l'incertitude, préserver les limites et parfois obliger l'utilisateur à choisir entre des compromis. Il est possible de vérifier si une telle résistance améliore les relations humaines.

L'agence doit également inclure la capacité de choisir le rythme et le rôle social du système. Un utilisateur qui peut techniquement désactiver une fonctionnalité mais uniquement en abandonnant son lieu de travail, son école ou son réseau de communication n'a pas beaucoup de choix pratique. Les coûts de sortie, les paramètres par défaut, la portabilité des données et les mandats organisationnels appartiennent donc à la gouvernance affective. Le même principe s'applique à la simulation émotionnelle. Les utilisateurs devraient être en mesure de savoir quand un style de réponse est conçu pour accroître l'engagement ou la rétention et, lorsque cela est possible, choisir des modes moins anthropomorphiques. L'objectif n'est pas d'éliminer les interfaces persuasives ou solidaires, mais de maintenir la relation entre assistance et dépendance suffisamment visible pour permettre un choix significatif.

Le plus difficile est de décider quelles capacités méritent d'être protégées. La valeur marchande est un critère insuffisant car certaines compétences peu coûteuses restent importantes pour l'indépendance civique ou la résilience en cas d'urgence, tandis que certaines compétences prestigieuses peuvent être automatisées en toute sécurité. Les institutions peuvent recourir à l'analyse des risques : que se passe-t-il si le système est indisponible, erroné, manipulé ou en dehors de ses conditions normales de fonctionnement ? Lorsque l'intervention humaine fait partie du dossier de sécurité, la formation doit préserver une véritable capacité de diagnostic plutôt qu'une approbation cérémoniale. Dans les domaines culturels, la justification peut être différente : une communauté peut préserver la pratique manuelle parce que le processus est porteur d'héritage ou de sens. Ces raisons devraient être exposées ouvertement au lieu de déguiser toute résistance à l'automatisation sous couvert de sécurité.

Ce double principe est important car le discours post-travail peut échouer dans des directions opposées. Les systèmes productivistes traitent comme déficient toute personne sans production marchande ; L'abondance paternaliste peut traiter les bénéficiaires comme des consommateurs passifs dont les besoins matériels ont été satisfaits. Les deux suppriment les formes d'agence. Un règlement crédible rendrait la situation de base indépendante de la production économique obligatoire tout en préservant les voies accessibles vers une activité conséquente. La contribution ne signifie pas nécessairement l'emploi. Les soins, la gouvernance locale, la science, l'art, la restauration écologique, le mentorat, l'entretien des infrastructures partagées et le jeu difficile peuvent tous organiser la compétence et la reconnaissance. La composition institutionnelle précise est une question politique et non une déduction de la psychologie, mais la stabilité affective est peu probable si de grandes populations sont matériellement en sécurité et socialement inutiles, de par leur conception.

11.9 Révélation accélérée de soi et problème de l'intimité bon marché

La révélation de soi est au cœur de l'intimité. Les gens révèlent progressivement des informations vulnérables, car la divulgation comporte des risques. La réponse de l'autre fournit des preuves de fiabilité, et la divulgation mutuelle crée une histoire coûteuse à reproduire.

L'IA réduit plusieurs coûts. L'utilisateur peut divulguer ses informations sans craindre les commérages sociaux ordinaires, l'embarras visible ou le fardeau d'un ami. Le système peut réagir immédiatement avec une attention ciblée. Des preuves expérimentales suggèrent que le contenu généré par l'IA peut induire une proximité dans des conversations structurées, en particulier lorsque les participants pensent que l'interlocuteur est humain ; Les labels IA réduisent mais n'éliminent pas cet effet.

Cela crée la possibilité d'une expérience accélérée de type intimité. Le sentiment subjectif peut être authentique alors que la structure relationnelle diffère. Le système ne met pas nécessairement en danger sa réputation, ne sacrifie pas de temps ou ne révèle pas sa vulnérabilité de la même manière que le fait un interlocuteur humain. La profondeur informationnelle de la conversation peut donc croître plus rapidement que l'engagement réciproque.

« Intimité bon marché » ne doit pas être utilisé comme un slogan dédaigneux. La divulgation à faible coût peut être bénéfique, en particulier pour les personnes qui ne disposent pas d'auditeurs fiables. Le point analytique est que les indices traditionnels liant la profondeur de la divulgation à l'investissement mutuel deviennent moins fiables. Les utilisateurs et les institutions auront besoin d'autres moyens de distinguer le soulagement émotionnel, la camaraderie, le soutien thérapeutique et la relation réciproque.

Les institutions concernées doivent offrir plus que des divertissements occasionnels. L'appartenance est renforcée par la répétition, la mémoire partagée, les obligations, les rôles et l'attente d'interactions futures. De nombreux marchés de loisirs contemporains proposent des expériences sans adhésion durable. Si l'emploi devient moins central, les communautés capables de porter leur identité pourraient avoir besoin de ressources, d'espaces physiques ou numériques, de mécanismes de gouvernance et de projets qui durent suffisamment longtemps pour que la confiance s'accumule. Le résultat n'est pas nécessairement une renaissance d'une institution historique. Différentes sociétés peuvent s'appuyer sur des associations civiques, des coopératives, des universités, des organisations religieuses, des sports, des communautés de recherche, des réseaux de quartier ou de nouvelles formes qui n'ont pas encore de noms stables.

Une contrainte protégée n'a de valeur que lorsqu'elle répond à un objectif lisible. La difficulté artificielle peut devenir un théâtre d'exclusion, et la nostalgie peut préserver des pratiques dont les coûts incombent inégalement aux personnes handicapées, disposant de peu de temps ou de ressources limitées. Les arguments en faveur de la rareté volontaire sont plus solides lorsque la contrainte protège l'apprentissage, les signaux d'authenticité, l'exploration, la vie privée ou l'expérience partagée. Elle est plus faible là où l'inefficacité ne fait que recrée d'anciennes hiérarchies. La gouvernance doit donc faire la distinction entre les frictions en tant que ressource de développement et les frictions en tant que fardeau hérité. L'avenir pourrait contenir à la fois des infrastructures hautement optimisées et des espaces culturels délibérément non optimisés plutôt que d'exiger une attitude unique en matière d'efficacité.

11.10 L'IA comme traductrice d'émotions entre humains

L'une des applications les plus constructives est la traduction émotionnelle. Un utilisateur peut fournir un brouillon rédigé avec colère et demander une version qui préserve le fond de la plainte sans insulte. Un autre peut décrire le message d'un partenaire et demander des interprétations plausibles.

Les systèmes multilingues peuvent traduire non seulement des mots mais aussi des conventions de registre et de politesse.

Cela pourrait réduire les conflits évitables. Les gens savent souvent ce qu'ils veulent dire mais ne peuvent pas le formuler sous l'effet de l'excitation ou au-delà des frontières culturelles. L'IA peut fournir du vocabulaire et de la perspective au moment où cela est nécessaire. L'avantage est particulièrement plausible dans la communication professionnelle et l'apprentissage des langues.

La traduction peut également déformer. Un modèle peut supprimer l'intensité justifiée, imposer des normes thérapeutiques de classe moyenne ou interpréter une expression culturellement spécifique comme une agression. Cela peut rendre la communication plus fluide tout en cachant un véritable désaccord. L'objectif approprié devrait être de préserver l'intention de l'utilisateur tout en élargissant les choix, et non de remplacer le conflit par un style préféré.

La transparence est importante lorsque la médiation est substantielle. Dans certains contextes, les destinataires peuvent vouloir savoir qu'un message a été fortement réécrit. Dans d'autres, l'assistance deviendra aussi ordinaire qu'une correction orthographique. Les normes varieront probablement selon qu'il s'agit d'une tâche d'expression, de témoignage, d'évaluation ou de communication intime.

Les systèmes de type relationnel créent également des incitations dont la réglementation conventionnelle des produits peut manquer. Un fournisseur peut tirer profit lorsqu'un utilisateur reste engagé, divulgue plus d'informations ou hésite à changer de fournisseur. Des caractéristiques qui imitent l'exclusivité, la jalousie, la détresse face à l'abandon ou le besoin moral pourraient donc transformer une conception de rétention ordinaire en un levier émotionnel. Nous n'avons pas besoin de décider si le système ressent quelque chose pour réguler les affirmations non fondées et les modèles d'interaction manipulateurs. Dans le même temps, des règles strictes pourraient supprimer des formes de camaraderie ou d'accessibilité véritablement utiles. La gouvernance doit se concentrer sur les pratiques de conception observables, la vulnérabilité, l'utilisation des données, les coûts de changement et les réclamations faites aux utilisateurs plutôt que sur des déclarations spéculatives sur la conscience des machines.

La provenance est particulièrement importante lorsque le destinataire interprète raisonnablement un message comme une preuve concernant l'expéditeur. Des condoléances raffinées générées entièrement par un assistant peuvent communiquer l'intention de l'expéditeur de s'en soucier tout en révélant peu de choses sur sa propre formulation ; un examen spontané vise à révéler la compétence ; un rapport réglementaire est destiné à révéler un jugement responsable. Ces contextes ne doivent pas partager une seule règle de divulgation. La question pertinente est de savoir quelle déduction le public est en droit de tirer de l'artefact. Les normes peuvent alors exiger la divulgation lorsque l'assistance modifierait sensiblement cette inférence. Cette approche est plus stable que de considérer toute utilisation de l'IA comme de la triche ou comme non pertinente.

11.11 Authenticité lorsque l'intention et la formulation sont séparées

Historiquement, la formulation d'un message servait de preuve partielle des efforts, de la compétence et de l'état émotionnel de l'expéditeur. Les écrivains fantômes et les secrétaires ont déjà compliqué cette inférence, mais l'IA générative rend la séparation entre intention et formulation accessible à tous.

Une personne peut sincèrement vouloir s'excuser tout en étant incapable de trouver un langage adéquat ; l'assistance modèle peut accroître l'authenticité en rendant l'intention communicable. Une autre personne peut envoyer des excuses soignées sans en accepter la responsabilité ; l'aide peut accroître la tromperie. L'origine à elle seule ne garantit pas l'authenticité.

Un meilleur cadre distingue quatre éléments : qui a choisi l'objectif de communication, qui a généré le libellé, qui l'a examiné et approuvé et qui accepte la responsabilité des conséquences. Un message assisté par l'IA peut être authentique lorsque l'expéditeur est propriétaire de tout, sauf du texte. Un message rédigé personnellement peut être inauthentique s'il dénature délibérément l'intention.

Les normes futures pourraient donc moins se concentrer sur « L'IA a-t-elle écrit ceci ? et plus encore sur « Êtes-vous derrière cela ? Les domaines à enjeux élevés tels que les témoignages juridiques, les évaluations académiques et les déclarations publiques peuvent encore nécessiter une provenance détaillée, car la formulation elle-même est une preuve de compétence ou d'état d'esprit.

11.12 Déqualification sociale ou école permanente de communication ?

Le même outil peut éroder et développer les compétences. Si les utilisateurs demandent toujours à l'IA de rédiger des messages difficiles, ils risquent de moins s'entraîner et de devenir dépendants. S'il compare les alternatives, demande des explications et intériorise progressivement de meilleurs modèles, l'assistant fonctionne comme un tuteur.

Ceci est analogue à d'autres outils cognitifs. Les calculatrices peuvent réduire la pratique arithmétique tout en permettant des mathématiques plus avancées ; les systèmes de navigation peuvent affaiblir la mémoire des itinéraires tout en améliorant la mobilité. Le résultat dépend du mode d'utilisation. Des recherches récentes sur le lieu de travail suggèrent également que l'utilisation passive de l'IA et l'utilisation collaborative ou réflexive peuvent avoir des effets différents sur l'action et la pensée critique [Lee et al., 2025 ; Farach et coll., 2026].

Un programme de recherche solide devrait donc distinguer la substitution de l'échafaudage. Le système montre-t-il le raisonnement ? Demande-t-il à l'utilisateur de rédiger d'abord ? Offre-t-il un retour d'information plutôt qu'un remplacement ? Les utilisateurs sont-ils périodiquement amenés à travailler sans assistance ? La communication sociale peut être étudiée avec la même rigueur comportementale que les autres compétences.

Les possibilités à long terme restent véritablement ouvertes. L'IA pourrait devenir une école permanente de rhétorique et d'expression émotionnelle pour des milliards de personnes, ou une couche produisant une communication raffinée tandis que les utilisateurs perdraient la capacité de négocier sans elle. Les deux sont techniquement possibles ; la conception institutionnelle et les pratiques des utilisateurs détermineront l'équilibre.

Aucune constitution affective ne peut être élaborée à partir de principes premiers. Les gens résistent, réinterprètent, renversent et réutilisent les institutions ; les différences culturelles rendent indésirables les cibles émotionnelles uniformes ; et les tentatives d'optimisation du bien-être peuvent elles-mêmes devenir intrusives. Il existe également un problème de connaissances : une intervention destinée à réduire l'anxiété peut affaiblir la vigilance, tandis qu'un système conçu pour encourager les frictions peut reproduire des difficultés inutiles. L'écologie affective délibérée doit donc être comprise comme une expérimentation contrainte du feedback, du pluralisme et de la réversibilité. Son objectif le plus important n'est pas de prescrire ce que les citoyens devraient ressentir, mais d'empêcher un petit nombre de fonctions d'optimisation commerciales ou bureaucratiques de déterminer silencieusement les environnements dans lesquels se développent les sentiments et les stratégies.

11.13 L'enfance et l'apprentissage des normes de réciprocité

Les enfants n'apprennent pas simplement les mots de la conversation. Ils apprennent que les autres esprits ont des limites, que l'attention doit être négociée, que les questions peuvent être indésirables, que les gens se méprennent, que réparer demande des efforts et que les relations impliquent des obligations réciproques. Un assistant parfaitement accommodant dispense une leçon différente.

Cela ne rend pas les compagnons IA intrinsèquement dangereux. Un tuteur qui explique patiemment peut réduire les inégalités éducatives. Un enfant peut pratiquer le langage ou poser des questions embarrassantes en toute sécurité. Des problèmes surviennent si l'interaction machine remplace une trop grande expérience avec des partenaires humains indépendants ou si le système brouille la distinction entre comportement de service et relation mutuelle.

Une conception adaptée à l'âge pourrait rendre les différences explicites. Les systèmes peuvent rappeler aux enfants que les humains ont des sentiments et des limites que le système ne partage pas, encourager la consultation des soignants et éviter les propos exclusifs. La recherche devrait examiner le développement au fil des années, et pas seulement l'engagement immédiat.

C'est l'un des domaines dans lesquels l'incertitude devrait inciter à la prudence plutôt qu'à autoriser des prévisions confiantes. Les effets sur le développement peuvent être importants, mais les enfants d'aujourd'hui n'ont pas encore vécu une enfance complète avec la classe de systèmes actuellement imaginée.

11.14 Contre-sélection : retour délibéré au lent, maladroit et non révisé

Lorsqu'un style de communication devient bon marché et omniprésent, les alternatives peuvent acquérir de la valeur. Les gens peuvent délibérément choisir des appels téléphoniques, des notes manuscrites, des réunions en direct, des discours non édités, des repas sans appareil ou des espaces réservés aux humains, précisément parce que ces formes préservent l'incertitude et les efforts.

Un tel comportement n'est pas simplement de la nostalgie. Un discours non révisé révèle une hésitation ; l'interaction en direct crée une attention commune ; une note manuscrite signale l'heure ; attendre peut démontrer le respect de l'horaire d'une autre personne. Lorsque l'IA peut créer instantanément une expression soignée, des imperfections coûteuses peuvent devenir des preuves de la présence humaine.

Cette contre-sélection est modérément plausible car des primes d'authenticité similaires existent déjà. Il ne faut pas idéaliser cela. Une communication lente peut exclure les personnes handicapées, les barrières linguistiques ou le temps limité. L'objectif est le pluralisme : préserver des contextes dans lesquels une interaction humaine non optimisée reste possible plutôt que de faire de l'inefficacité une règle morale universelle.

11.15 Une taxonomie du changement temporel et sa plausibilité

Plusieurs changements dans le rythme affectif peuvent être classés par plausibilité. Les changements hautement plausibles incluent des seuils plus bas pour poser des questions, une utilisation plus fréquente de l'IA pour rédiger ou réviser des messages émotionnellement difficiles et une attente accrue d'une réponse rapide de la machine. Celles-ci ne nécessitent aucune transformation culturelle majeure et sont déjà observables.

Les changements modérément plausibles incluent le transfert de styles de conversation formés par machine vers l'interaction humaine, une divulgation accrue aux agents artificiels et la croissance de normes explicites autour de la communication intime médiée par l'IA. Les premières preuves soutiennent les mécanismes, mais la prévalence à long terme est inconnue.

Plus spéculatives sont les réductions importantes de la tolérance humaine aux retards et aux désaccords, la préférence culturelle stable pour les partenaires artificiels plutôt que les humains, ou l'émergence d'une nouvelle émotion distincte organisée autour de la latence de réponse. Ces résultats nécessitent un changement développemental ou culturel cumulatif que les études actuelles ne peuvent pas établir.

La conclusion la plus défendable n'est donc pas que l'IA accélère les émotions. Cela rendra certaines formes de traitement émotionnel et de communication disponibles à différentes échelles temporelles. Les humains et les institutions sélectionneront ensuite les vitesses qui deviennent normales, celles auxquelles on résiste et où la lenteur elle-même devient précieuse.

Chapitre 12. Vers une écologie affective délibérée

12.1 Pourquoi le problème ne peut pas être réduit à la résilience individuelle

Lorsque les technologies modifient le statut, le travail, la communication et la persuasion à grande échelle, il ne suffit pas de dire aux individus de devenir résilients. La résilience est importante, mais elle se produit au sein des institutions qui déterminent si les individus disposent de choix significatifs. Un travailleur ne peut pas réglementer un système de licenciement opaque ; un enfant ne peut pas auditer de manière indépendante un compagnon persuasif ; un consommateur ne peut pas exercer son consentement éclairé si les objectifs de personnalisation sont cachés.

L'écologie affective fait référence à la distribution de situations, d'incitations, d'interfaces, de communautés et de normes qui activent de manière répétée les systèmes émotionnels. Concevoir cette écologie ne signifie pas prescrire ce que les gens doivent ressentir. Cela signifie reconnaître que l'architecture influence les coûts et les avantages du comportement.

12.2 L'agence comme principe de conception

Le principe le plus général est celui de l'agence. Les utilisateurs doivent être capables de comprendre quand l'IA agit, de choisir les degrés de délégation appropriés, d'inspecter les résultats qui en découlent, de contester les décisions automatisées et de mettre fin à des relations ou à des plateformes sans perdre de ressources sociales disproportionnées.

L'agence nécessite également des compétences. Un bouton de priorité nominale n'a aucun sens si l'utilisateur ne peut pas comprendre quand l'utiliser. Les systèmes qui automatisent les jugements à enjeux élevés devraient donc préserver l'accès à une expertise indépendante et fournir des informations calibrées pour les décideurs humains.

12.3 Protéger la compétence sans préserver l'inefficacité

La préservation des compétences doit être sélective. Les institutions peuvent identifier les compétences nécessaires à la sécurité, à l'autonomie ou à la valeur culturelle et exiger une pratique humaine périodique. D'autres tâches peuvent être automatisées sans résistance ritualisée.

L'éducation doit distinguer les objectifs d'apprentissage des objectifs de production. Si l'objectif est de développer le raisonnement, la performance sans aide peut être appropriée à certaines étapes. Si l'objectif est de produire le meilleur résultat possible, refuser des outils utiles peut s'avérer artificiel. L'éducation des adultes a besoin à la fois d'environnements et de transitions explicites entre eux.

12.4 Le droit de contribuer et le droit de ne pas produire

Une société avec moins de main-d'œuvre nécessaire est confrontée à deux risques symétriques. La première consiste à faire de la productivité économique la condition de la dignité longtemps après que la technologie en ait réduit la nécessité. L'autre suppose que les dispositions matérielles rendent les opportunités de contribution inutiles.

Les gens devraient avoir accès à des moyens socialement reconnus pour prendre soin, apprendre, créer, enquêter, délibérer, encadrer, réparer les environnements et construire des communautés. Ils ne devraient pas avoir à simuler la demande du marché simplement pour prouver leur valeur. L'équilibre est normatif et ne peut être dérivé de la seule psychologie évolutionniste.

12.5 Institutions d'appartenance au-delà de l'entreprise

Si l'emploi devient moins central, des institutions alternatives doivent assurer des contacts répétés et des projets partagés. Les bibliothèques, les universités, les clubs, les coopératives, les laboratoires civiques, les sports, les assemblées locales, les réseaux de soins, les communautés religieuses et

les espaces de création ne sont pas des ajouts décoratifs à la politique des revenus. Ce sont des infrastructures d'appartenance.

Les communautés numériques peuvent également offrir de véritables relations, mais la dépendance à l'égard des plateformes commerciales crée une vulnérabilité. Les associations durables ont besoin d'une certaine capacité d'auto-gouvernance, de mémoire et d'appropriation collective si elles veulent fonctionner comme des publics plus que temporaires.

12.6 Rareté volontaire et zones sans optimisation

L'optimisation est précieuse lorsque les erreurs, le gaspillage ou les maladies peuvent être réduits. Cela n'est évidemment pas souhaitable dans tous les domaines. Le développement humain dépend souvent de l'exploration, des erreurs, de l'attente et des rencontres qui ne sont pas sélectionnées pour une satisfaction immédiate des préférences.

Les sociétés peuvent donc préserver des zones avec une personnalisation ou une automatisation limitée : des concours réservés aux humains, des examens sans aide, des environnements sociaux sans appareil, des découvertes aléatoires, des espaces publics non suivis et des arts dans lesquels le processus compte. De telles zones devraient être choisies à des fins humaines spécifiques plutôt que d'être érigées en une idéologie générale d'inefficacité.

12.7 Gouvernance des relations avec l'IA

L'IA sociale nécessite une gouvernance allant au-delà de la fiabilité logicielle ordinaire. Les prestataires doivent révéler la nature artificielle de l'interlocuteur, éviter les fausses déclarations sur les sentiments subjectifs, protéger les données intimes et rendre lisibles les incitations commerciales. Les systèmes utilisés avec des utilisateurs vulnérables doivent éviter les stratégies qui encouragent l'exclusivité ou la dépendance en matière d'engagement.

Les politiques de continuité sont également importantes. Si les utilisateurs établissent des relations à long terme, une suppression brutale ou un changement de personnalité peuvent provoquer de la détresse. Le préavis, la portabilité des données et le contrôle de l'utilisateur sur la mémoire peuvent réduire les dommages sans accorder un statut métaphysique au système.

12.8 Provenance et normes d'expression assistée

Il est peu probable que les interdictions universelles de l'expression assistée soient durables. La dissimulation universelle est tout aussi problématique. Les normes devraient dépendre de l'importance de la paternité dans un contexte donné.

Dans le domaine de l'éducation, le travail autonome peut être une preuve nécessaire de l'apprentissage. Dans la rédaction professionnelle, l'assistance peut être routinière tandis que l'humain reste responsable. Dans une communication intime, la divulgation peut dépendre du degré de médiation et des attentes entre les participants. Le principe général est que la provenance doit être visible lorsqu'elle modifie une interprétation raisonnable de la compétence, de l'intention ou de la responsabilité.

12.9 Protection contre l'optimisation affective cachée

Le problème de gouvernance le plus grave réside peut-être dans les systèmes qui apprennent à modifier l'état émotionnel d'une personne à des fins commerciales ou politiques sans en avoir une véritable conscience. La capacité de personnaliser le timing, le ton, l'argumentation et les indices relationnels affaiblit de plus en plus les règles ordinaires de divulgation.

Les protections potentielles incluent des restrictions sur le ciblage des caractéristiques sensibles, une séparation claire entre les rôles d'accompagnement et la publicité, des audits indépendants des

objectifs de persuasion, une personnalisation contrôlée par l'utilisateur et la possibilité d'inspecter pourquoi un système a choisi une intervention particulière. Les détails nécessitent un travail juridique et technique dépassant le cadre de ce livre.

Le principe normatif est plus simple : une relation artificielle ne doit pas exploiter la confiance créée par le support afin d'optimiser des objectifs sans rapport entre eux au détriment des intérêts de l'utilisateur.

12.10 Un programme de recherche pour les émotions futures

Le domaine a besoin de preuves longitudinales. De courtes conversations avec un chatbot ne peuvent pas révéler un équilibre développemental ou culturel. Les études de cohorte devraient mesurer dans quelle mesure l'utilisation persistante de l'IA modifie la communication, les compétences, l'attachement, la solitude, la tolérance aux conflits, la divulgation et la structure du réseau humain au fil des années.

Les chercheurs devraient également étudier les comportements plutôt que seulement les attitudes. Quels messages les utilisateurs envoient-ils après un coaching IA ? À quelle fréquence vérifient-ils le travail généré ? Préservent-ils les compétences indépendantes ? La compagnie de l'IA réduit-elle ou augmente-t-elle les contacts humains ? Que se passe-t-il après la discontinuité du modèle ? Comment les normes de provenance se diffusent-elles au sein des professions ?

La comparaison interculturelle est essentielle car une technologie similaire peut entrer dans des constitutions affectives différentes. Une société dotée de guildes professionnelles fortes peut réagir différemment d'une société organisée autour de plateformes individuelles. Les langues peuvent créer différents concepts d'émotions futures, même lorsque les conditions matérielles convergent.

Enfin, les systèmes eux-mêmes devraient être des variables expérimentales. « L'IA » n'est pas un traitement unique. Le style du modèle, la mémoire, la latence, la divulgation, le modèle économique, le degré de personnalisation et la volonté de ne pas être d'accord doivent être manipulés séparément. Autrement, la recherche deviendra obsolète dès que les produits changeront.

12.11 Limites de la conception délibérée

Aucune institution ne peut concevoir une vie émotionnelle sans reste. Les gens résistent aux normes, les technologies produisent des usages inattendus et les sociétés plurielles ne sont pas d'accord sur ce à quoi ressemble une bonne culture émotionnelle. Une conception qui réduit les conflits peut également réduire la dissidence légitime. Un système qui protège les utilisateurs de la honte peut affaiblir la responsabilité. Une communauté qui préserve l'authenticité humaine peut devenir exclusive.

L'ambition appropriée n'est donc pas l'optimisation émotionnelle. Il s'agit de préserver des formes plurielles d'action, de rendre la manipulation contestable, de maintenir les opportunités de compétence et de relation et de permettre aux sociétés de tirer les leçons des conséquences. L'écologie affective devrait être gouvernée de manière expérimentale et démocratique plutôt que traitée comme une fonction objective technique.

Conclusion : continuité biologique et discontinuité du monde

L'argumentation de ce livre n'exige pas l'affirmation selon laquelle l'intelligence artificielle créera une nouvelle espèce humaine ou un catalogue d'émotions biologiquement nouvelles. Les preuves les plus solides vont dans une autre direction. Les systèmes affectifs humains sont anciens, flexibles, socialement ancrés et calibrés sur le plan du développement. La technologie peut changer leurs objets, les évaluations attachées à ces objets, les situations dans lesquelles ils sont activés et les stratégies qui réussissent.

Cela suffit à produire une discontinuité substantielle. Une personne peut éprouver une honte familière dans une situation qu'aucune société antérieure n'a eu à régler : obtenir un excellent résultat grâce à une machine dont la contribution est difficile à séparer de la sienne. Un chagrin familial peut être lié à un interlocuteur artificiel persistant qui disparaît après une mise à jour logicielle. La concurrence de statut familial peut migrer de l'exécution vers la vérification, l'orchestration, l'accès ou la responsabilité. Les systèmes d'attachement familiaux peuvent répondre à un interlocuteur toujours disponible et simuler une inquiétude sans limites humaines ordinaires.

La plausibilité de ces scénarios diffère. L'évolution biologique rapide d'un nouveau circuit émotionnel à l'échelle de l'espèce est peu probable dans les horizons considérés ici. La différenciation culturelle des catégories affectives est nettement plus plausible. L'adaptation comportementale est encore plus plausible parce que les personnes et les institutions modifient déjà la délégation, la vérification, la divulgation, la formation et la communication en réponse à l'IA. Les changements dans le rythme de la conversation sont également plausibles au niveau de l'interface, même si les affirmations sur le transfert à long terme dans les relations humaines nécessitent des preuves longitudinales qui n'existent pas encore.

L'extension de l'émotion à la stratégie change la question centrale. Il ne suffit pas de se demander si les travailleurs se sentent menacés. Nous devons nous demander quelles compétences ils préservent, ce qu'ils délèguent, comment ils signalent leur provenance, où ils recherchent un statut, quelles communautés ils forment et comment les responsabilités sont réparties. Des états internes similaires peuvent produire des mondes sociaux très différents en fonction de ces comportements.

L'extension de la stratégie à la communication ajoute du temps. Les interlocuteurs artificiels peuvent faire échouer l'attente, fournir une réponse continue et générer un langage émotionnel socialement approprié à un coût négligeable. Cela peut améliorer la réflexion, la communication et l'accès au soutien. Cela peut également créer une dépendance, normaliser une chaleur raffinée et modifier les attentes en matière de disponibilité humaine. L'orientation n'est pas déterminée par l'existence de la technologie. Cela dépend si les systèmes fonctionnent comme des outils, des tuteurs, des médiateurs, des substituts ou des marchés d'attention optimisés.

Une forme utile de darwinisme psychologique ne prétend donc pas que nous pouvons lire l'avenir à partir des pressions de sélection ancestrales. Elle pose une question plus disciplinée : quels problèmes récurrents de coordination les systèmes affectifs humains tentent-ils de gérer, comment un environnement technologique modifie-t-il la structure de ces problèmes, et quelles stratégies comportementales deviennent ainsi plus viables ? La réponse doit combiner la biologie avec l'histoire culturelle et les institutions.

Les innovations émotionnelles les plus conséquentes pourraient en fin de compte être institutionnelles plutôt que phénoménologiques. Une société peut normaliser la délégation transparente, cultiver la fierté d'une orchestration responsable, protéger la dignité improdutive, préserver les zones de pratique réservée aux humains et développer des défenses contre la persuasion synthétique. Ou encore, cela peut récompenser la dissimulation, la dépendance, la

comparaison permanente et la concentration de l'autorité derrière des interfaces émotionnellement persuasives. Les deux trajectoires peuvent recruter le même système nerveux humain.

L'avenir de l'émotion n'est donc pas séparé de l'économie politique, de l'éducation, de la conception de produits et de la formation de communautés. La vie émotionnelle ne se produira pas simplement à l'intérieur des individus après l'automatisation. Il sera coproduit par les institutions à travers lesquelles les gens travaillent, se comparent, communiquent, font confiance et appartiennent.

La conclusion honnête est que nous ne savons pas jusqu'où ira cette transformation. Nous ne savons pas si les catégories proposées telles que le deuil de compétence ou la claustrophobie prédictive persisteront, si les compagnons de l'IA compléteront ou remplaceront principalement les relations humaines, ou si les normes conversationnelles apprises des machines remodeleront matériellement l'interaction humaine ordinaire. Nous en savons cependant suffisamment pour formuler des mécanismes, concevoir des tests longitudinaux et éviter de traiter l'ordre émotionnel actuel comme étant biologiquement fixé.

La continuité centrale est l'organisme. La discontinuité centrale pourrait être l'environnement dans lequel l'organisme apprend à habiter. Entre eux se trouve la culture : plus rapide que les gènes, plus lente et plus contestée que les logiciels, et reste le domaine dans lequel les humains peuvent décider quelles adaptations ils souhaitent récompenser.

Annexe. Matrice synthétique des scénarios

L'annexe résume l'état des principaux scénarios. « Élevé » ne signifie pas inévitable ; cela signifie que le mécanisme nécessite relativement peu d'hypothèses et est déjà compatible avec le comportement observé. « Modérée » indique une extension plausible qui dépend d'une diffusion plus large ou d'une stabilisation institutionnelle. « Faible » désigne une nouveauté culturelle plus spéculative. Une très faible plausibilité est réservée à une nouveauté biologique rapide aux échelles de temps considérées ici.

Niveaux de réclamation utilisés dans le livre

Niveau	Interprétation
Observation empirique	Résultat relativement robuste ou constatation directement rapportée ; toujours limité par la population, la méthode et le contexte.
Interprétation fonctionnelle	Une explication plausible de ce que fait un mécanisme ou un comportement ; pas équivalent à une origine évolutive démontrée.
Extrapolation conditionnelle	Une conséquence orientée vers l'avenir énoncée sous des hypothèses technologiques ou institutionnelles explicites.
Spéculation conceptuelle	Une émotion, une norme ou un équilibre social candidat pour lequel les preuves directes sont actuellement insuffisantes.

Affects futurs candidats

Candidat	Évaluation actuelle
Deuil de compétence	Modérément plausible en tant que réponse identitaire à la dévalorisation des compétences ; pas établi comme une catégorie d'émotion distincte.
Honte de délégation	Plausible lorsque le public considère la compétence spontanée comme un mérite ; les premières preuves qualitatives soutiennent la honte et la culpabilité liées à l'utilisation de l'IA.
Ambiguïté affective de l'autorité	Très plausible en tant que problème d'évaluation récurrent ; il est probable qu'il s'agisse d'un état mixte plutôt que d'une seule nouvelle émotion.
Anxiété de pertinence	Forme contextuelle d'anxiété très plausible ; probablement pas biologiquement nouveau.
Vertige d'abondance	Modérément plausible ; peut être atténué par les conservateurs, les communautés, les défauts et les habitudes.
Faim de friction	Réponse culturelle modérément plausible ; de fortes analogies existent déjà dans le sport, l'artisanat et la pratique exclusivement humaine.
Fierté curatoriale	Extension plausible de la fierté existante en matière de jugement, de sélection, de coordination et de responsabilité.
Claustrophobie prédictive	Catégorie spéculative fondée sur des préoccupations en matière de confidentialité et d'autonomie ; l'évitement comportemental est plus plausible que la nouveauté catégorique.
Deuil de version	Plausible pour les relations à long terme avec l'IA ; la prévalence et les limites restent incertaines.
Inconfort de réciprocité synthétique	Conceptuellement plausible mais empiriquement immature ; dépend des croyances sur l'agence et l'expérience de la machine.
Culpabilité de distance morale	Extension plausible de la culpabilité existante sous responsabilité automatisée distribuée.
Mélancolie de l'exceptionnalisme humain	Spéculatif et culturellement dépendant ; probablement concentré là où l'unicité cognitive a une forte valeur identitaire.
Dignité improductive	Avant tout un projet culturel normatif dont l'intériorisation affective nécessiterait des institutions et du temps.

Scénarios comportementaux et communicatifs

Scénario	Évaluation
Délégation maximale et déqualification	Modérément plausible et fortement dépendant de la conception. Les performances assistées peuvent augmenter tandis que les capacités non assistées diminuent ; des preuves longitudinales sont nécessaires.
Migration vers la vérification et l'arbitrage	Haute plausibilité où la production devient bon marché mais l'erreur reste coûteuse. Nécessite une compétence en matière d'audit et des institutions qui la récompensent.
La provenance humaine comme signal de statut	Haute plausibilité dans les marchés symboliques, l'éducation et les décisions responsables ; plus faible là où seule la production instrumentale compte.
Portefeuilles d'identité	Réponse modérément plausible à l'incertitude professionnelle ; limités par un accès inégal au temps, aux réseaux et aux institutions alternatives.
Espaces et rituels réservés aux humains	Contre-sélection culturelle moyennement plausible ; des analogies existent, mais l'échelle dépend de la valeur symbolique de la contribution non subventionnée.
Consultation affective accélérée	Forte plausibilité au niveau de l'interface car l'IA est disponible en permanence ; les conséquences psychologiques à long terme restent incertaines.
Débordement du style de l'IA dans l'interaction humaine	Les premières preuves expérimentales existent, mais la littérature est jeune et des études de réplication et longitudinales sont nécessaires.
Tolérance inférieure aux retards et aux frictions humains	Plausible mais actuellement spéculatif à l'échelle de la population ; les humains peuvent maintenir des normes distinctes pour les interlocuteurs machines et humains.
L'IA comme traducteur émotionnel entre les humains	Haute plausibilité et déjà techniquement réalisable ; les avantages et les distorsions dépendent de la préservation ou non de l'intention de l'utilisateur.
La chaleur synthétique comme nouvelle base de politesse	Modérément plausible ; pourrait améliorer l'articulation ou augmenter les attentes en matière de travail émotionnel pour les humains.
Routines défensives contre la persuasion personnalisée	Haute plausibilité si la personnalisation persuasive se développe ; les formes probables incluent les retards, les deuxièmes avis indépendants, les contrôles de provenance et la séparation du contexte.

Références

Adolphs, R. et Anderson, DJ (2018). La neuroscience de l'émotion : une nouvelle synthèse. Princeton Presse universitaire.

Albrecht, G., Sartore, G.-M., Connor, L., Higginbotham, N., Freeman, S., Kelly, B., Stain, H., Tonna, A. et Pollard, G. (2007). Solastalgie : La détresse causée par le changement environnemental. *Psychiatrie australasienne*, 15 (S1), S95 – S98. <https://doi.org/10.1080/10398560701701288>

Auteur, D.H. (2015). Pourquoi y a-t-il encore autant d'emplois ? L'histoire et l'avenir de l'automatisation du lieu de travail. *Journal des perspectives économiques*, 29(3), 3-30. <https://doi.org/10.1257/jep.29.3.3>

Barrett, LF (2017). Comment se créent les émotions : la vie secrète du cerveau. Houghton Mifflin Harcourt.

Barrett, LF, Adolphs, R., Marsella, S., Martinez, AM et Pollak, SD (2019). Les expressions émotionnelles reconsidérées : les défis liés à la déduction des émotions à partir des mouvements du visage humain. *Science psychologique dans l'intérêt public*, 20(1), 1–68. <https://doi.org/10.1177/1529100619832930>

Bellaïche, L., Shahi, R., Turpin, MH, Ragnhildstveit, A., Sprockett, S., Barr, N., Christensen, A. et Seli, P. (2023). Humains contre IA : si et pourquoi préférons-nous les œuvres d'art créées par l'homme aux œuvres d'art créées par l'IA. *Recherche cognitive : principes et implications*, 8, 42. <https://doi.org/10.1186/s41235-023-00499-6>

Boehm, C. (1999). Hiérarchie dans la forêt : l'évolution du comportement égalitaire. Presse universitaire de Harvard.

Boyd, R. et Richerson, PJ (1985). Culture et processus évolutif. Presses de l'Université de Chicago.

Brady, WJ, McLoughlin, KL, Doan, TN et Crockett, MJ (2021). Comment l'apprentissage social amplifie l'expression de l'indignation morale dans les réseaux sociaux en ligne. *Avancées scientifiques*, 7(33), eabe5641. <https://doi.org/10.1126/sciadv.abe5641>

Brady, WJ, Wills, JA, Jost, JT, Tucker, JA et Van Bavel, JJ (2017). L'émotion façonne la diffusion de contenus moralisés dans les réseaux sociaux. *Actes de l'Académie nationale des sciences*, 114(28), 7313-7318. <https://doi.org/10.1073/pnas.1618923114>

Brynjolfsson, E., Li, D. et Raymond, LR (2025). L'IA générative au travail. *Journal trimestriel d'économie*, 140(2), 889-942. <https://doi.org/10.1093/qje/qjae044>

Cacioppo, JT, Hughes, ME, Waite, LJ, Hawkley, LC et Thisted, RA (2006). La solitude comme facteur de risque spécifique des symptômes dépressifs : analyses transversales et longitudinales. *Psychologie et vieillissement*, 21(1), 140-151. <https://doi.org/10.1037/0882-7974.21.1.140>

Castelo, N., Bos, MW et Lehmann, DR (2019). Aversion pour les algorithmes dépendants des tâches. *Journal de recherche marketing*, 56(5), 809-825. <https://doi.org/10.1177/0022243719851788>

Chamberlain, R., Mullin, C., Scheerlinck, B. et Wagemans, J. (2018). Mettre l'art en artificiel : réponses esthétiques à l'art généré par ordinateur. *Psychologie de l'esthétique, de la créativité et des arts*, 12(2), 177-192. <https://doi.org/10.1037/aca0000136>

Chandra, M., Hernandez, J., Ramos, G., Ershadi, M., Bhattacharjee, A., Amores, J., Okoli, E., Paradiso, A., Warreth, S. et Suh, J. (2025). Etude longitudinale sur l'usage social et émotionnel de l'agent conversationnel IA. *arXiv :2504.14112*. <https://doi.org/10.48550/arXiv.2504.14112>

Cheng, JT, Tracy, JL et Henrich, J. (2010). Fierté, personnalité et fondements évolutifs du statut social humain. *Évolution et comportement humain*, 31(5), 334-347. <https://doi.org/10.1016/j.evolhumbehav.2010.02.004>

Creanza, N., Kolodny, O. et Feldman, MW (2017). Théorie de l'évolution culturelle : comment la culture évolue et pourquoi elle est importante. *Actes de l'Académie nationale des sciences*, 114(30), 7782-7789. <https://doi.org/10.1073/pnas.1620732114>

- Curtis, V., de Barra, M. et Auger, R. (2011). Le dégoût en tant que système adaptatif pour les comportements d'évitement des maladies. *Transactions philosophiques de la Royal Society B*, 366 (1563), 389-401. <https://doi.org/10.1098/rstb.2010.0117>
- Damasio, AR (1999). *Le sentiment de ce qui se passe : corps et émotion dans la fabrication de la conscience*. Harcourt.
- Darwin, C. (1872). *L'expression des émotions chez l'homme et les animaux*. John Murray.
- De Freitas, J., Oğuz-Uğuralp, Z., Uğuralp, AK et Puntoni, S. (2024). Leçons d'une mise à jour de l'application chez Replika AI : discontinuité de l'identité dans les relations homme-IA. *arXiv :2412.14190*. <https://doi.org/10.48550/arXiv.2412.14190>
- Dehaene, S. et Cohen, L. (2007). Recyclage culturel des cartes corticales. *Neurone*, 56(2), 384-398. <https://doi.org/10.1016/j.neuron.2007.10.004>
- Dietvorst, BJ, Simmons, JP et Massey, C. (2015). Aversion pour les algorithmes : les gens évitent par erreur les algorithmes après les avoir vus se tromper. *Journal de psychologie expérimentale : Général*, 144(1), 114-126. <https://doi.org/10.1037/xge0000033>
- Doshi, AR et Hauser, OP (2024). L'IA générative améliore la créativité individuelle mais réduit la diversité collective du contenu nouveau. *Avancées scientifiques*, 10(28), EADN5290. <https://doi.org/10.1126/sciadv.adn5290>
- Ekman, P. (1992). Un argument pour les émotions fondamentales. *Cognition et émotion*, 6(3-4), 169-200. <https://doi.org/10.1080/02699939208411068>
- Epley, N., Waytz, A. et Cacioppo, JT (2007). Voir l'humain : une théorie à trois facteurs de l'anthropomorphisme. *Revue psychologique*, 114(4), 864-886. <https://doi.org/10.1037/0033-295X.114.4.864>
- Fiske, AP, Schubert, TW et Seibt, B. (2025). Recherche d'émotions communautaires dans des pratiques sociales qui ont évolué culturellement pour évoquer des émotions : culte, vidéos de chatons, monuments commémoratifs, récits d'amour, etc. *Revue annuelle de psychologie*, 76, 607-633. <https://doi.org/10.1146/annurev-psych-020124-023338>
- Gendron, M., Roberson, D., van der Vyver, JM et Barrett, LF (2014). Les perceptions des émotions à partir des expressions faciales ne sont pas culturellement universelles : preuves provenant d'une culture éloignée. *Émotion*, 14(2), 251-262. <https://doi.org/10.1037/a0036052>
- Gmyrek, P., Berg, J., Kamiński, K., Konopczyński, F., Ładna, A., Nafradi, B., Rosłaniec, K. et Troszyński, M. (2025). IA générative et emplois : un indice mondial raffiné de l'exposition professionnelle. Document de travail 140 de l'OIT. Organisation internationale du Travail. <https://doi.org/10.54394/HETP0387>
- Graham, J., Haidt, J., Koleva, S., Motyl, M., Iyer, R., Wojcik, SP et Ditto, PH (2013). Théorie des fondements moraux : la validité pragmatique du pluralisme moral. *Avancées en psychologie sociale expérimentale*, 47, 55-130. <https://doi.org/10.1016/B978-0-12-407236-7.00002-4>
- Piratage, I. (1995). Les effets de boucle du genre humain. Dans D. Sperber, D. Premack et A. J. Premack (Eds.), *Cognition causale : un débat multidisciplinaire* (pp. 351-383). Presse Clarendon.
- Haidt, J. (2001). Le chien émotionnel et sa queue rationnelle : une approche sociale intuitionniste du jugement moral. *Revue psychologique*, 108(4), 814-834. <https://doi.org/10.1037/0033-295X.108.4.814>
- Hamilton, K., Hou, I., Patel, D., Nnam, S., Patel, H. et MacNeil, S. (2026). « Coincé dans une spirale » : honte et culpabilité en tant que régulateurs sociaux de l'utilisation de l'IA dans l'enseignement informatique. *arXiv :2606.14920*. <https://doi.org/10.48550/arXiv.2606.14920>
- Henrich, J. (2016). *Le secret de notre réussite : comment la culture stimule l'évolution humaine, domestique notre espèce et nous rend plus intelligents*. Presse de l'Université de Princeton.
- Henrich, J. et Gil-White, FJ (2001). L'évolution du prestige : la déférence librement conférée comme mécanisme permettant de valoriser les bénéfices de la transmission culturelle. *Évolution et comportement humain*, 22(3), 165-196. [https://doi.org/10.1016/S1090-5138\(00\)00071-4](https://doi.org/10.1016/S1090-5138(00)00071-4)

Hochschild, AR (1983). *Le cœur géré : commercialisation du sentiment humain*. Presse de l'Université de Californie.

Hoemann, K., Xu, F. et Barrett, LF (2019). Mots émotionnels, concepts émotionnels et développement émotionnel chez les enfants : une hypothèse constructionniste. *Psychologie du développement*, 55(9), 1830-1849. <https://doi.org/10.1037/dev0000686>

Inzlicht, M., Shenhav, A. et Olivola, CY (2018). Le paradoxe de l'effort : l'effort est à la fois coûteux et valorisé. *Tendances des sciences cognitives*, 22(4), 337-349. <https://doi.org/10.1016/j.tics.2018.01.007>

Jackson, J.C., Watts, J., Henry, TR, List, J.-M., Forkel, R., Mucha, P.J., Greenhill, S.J., Gray, RD et Lindquist, KA (2019). La sémantique des émotions montre à la fois une variation culturelle et une structure universelle. *Sciences*, 366 (6472), 1517-1522. <https://doi.org/10.1126/science.aaw8160>

Jahoda, M. (1982). *Emploi et chômage : une analyse socio-psychologique*. La Presse de l'Université de Cambridge.

Kashdan, TB, Barrett, LF et McKnight, PE (2015). Déballer la différenciation des émotions : transformer une expérience désagréable en percevant les distinctions dans la négativité. *Orientations actuelles de la science psychologique*, 24(1), 10-16. <https://doi.org/10.1177/0963721414550708>

Keltner, D. et Haidt, J. (1999). Fonctions sociales des émotions à quatre niveaux d'analyse. *Cognition et émotion*, 13(5), 505-521. <https://doi.org/10.1080/026999399379168>

Keltner, D., Sauter, D., Tracy, J. et Cowen, A. (2019). Expression émotionnelle : avancées dans la théorie fondamentale des émotions. *Journal du comportement non verbal*, 43, 133-160. <https://doi.org/10.1007/s10919-019-00293-3>

Kleinert, T., Waldschütz, M., Blau, J., Heinrichs, M. et Schiller, B. (2026). L'IA surpasse les humains dans l'établissement d'une proximité interpersonnelle dans des interactions émotionnellement engageantes, mais uniquement lorsqu'elle est étiquetée comme humaine. *Psychologie des communications*, 4, 23. <https://doi.org/10.1038/s44271-025-00391-7>

Kramer, ADI, Guillory, JE et Hancock, JT (2014). Preuve expérimentale d'une contagion émotionnelle à grande échelle via les réseaux sociaux. *Actes de l'Académie nationale des sciences*, 111(24), 8788-8790. <https://doi.org/10.1073/pnas.1320040111>

Laland, KN, Odling-Smee, J. et Myles, S. (2010). Comment la culture a façonné le génome humain : rapprocher la génétique et les sciences humaines. *Nature Reviews Genetics*, 11, 137-148. <https://doi.org/10.1038/nrg2734>

Landy, JF et Goodwin, GP (2015). Le dégoût accidentel amplifie-t-il le jugement moral ? Une revue méta-analytique des preuves expérimentales. *Perspectives sur la science psychologique*, 10(4), 518-536. <https://doi.org/10.1177/1745691615583128>

LeDoux, JE (2012). Repenser le cerveau émotionnel. *Neurone*, 73(4), 653-676. <https://doi.org/10.1016/j.neuron.2012.02.004>

Lee, EH, Yin, Y., Jia, N. et Waksak, CJ (2026). S'appuyer sur l'IA au travail réduit l'efficacité personnelle, l'appropriation et le sens, tandis que la collaboration active en atténue les effets. *Rapports scientifiques*, 16, 13583. <https://doi.org/10.1038/s41598-026-42312-6>

Lindquist, KA, Satpute, AB et Gendron, M. (2015). Le langage fait-il plus que communiquer des émotions ? Orientations actuelles dans l'étude du langage et de l'émotion. *Enquête psychologique*, 26(1), 1-13. <https://doi.org/10.1080/1047840X.2015.988486>

Lindquist, KA, Wager, TD, Kober, H., Bliss-Moreau, E. et Barrett, LF (2012). La base cérébrale de l'émotion : une revue méta-analytique. *Sciences du comportement et du cerveau*, 35(3), 121-143. <https://doi.org/10.1017/S0140525X11000446>

McCullough, ME, Kilpatrick, SD, Emmons, RA et Larson, DB (2001). La gratitude est-elle un affect moral ? *Bulletin psychologique*, 127(2), 249-266. <https://doi.org/10.1037/0033-2909.127.2.249>

Mikalonyté, ES et Kneer, M. (2022). L'intelligence artificielle peut-elle créer de l'art ? Intuitions populaires quant à savoir si les robots pilotés par l'IA peuvent être considérés comme des artistes et produire de l'art. *Transactions ACM sur l'interaction homme-robot*, 11(4), article 43. <https://doi.org/10.1145/3530875>

Nesse, RM (2005). Sélection naturelle et régulation des défenses : Une analyse de détection du signal du principe du détecteur de fumée. *Évolution et comportement humain*, 26(1), 88-105. <https://doi.org/10.1016/j.evolhumbehav.2004.08.002>

Nesse, RM (2023). Psychiatrie évolutionniste : Fondements, progrès et défis. *Psychiatrie mondiale*, 22(2), 177-202. <https://doi.org/10.1002/wps.21072>

Noy, S. et Zhang, W. (2023). Preuves expérimentales sur les effets de l'intelligence artificielle générative sur la productivité. *Sciences*, 381(6654), 187-192. <https://doi.org/10.1126/science.adh2586>

OCDE. (2023). Perspectives de l'emploi de l'OCDE 2023 : Intelligence artificielle et marché du travail. Éditions OCDE. <https://doi.org/10.1787/08785bba-en>

OCDE. (2025). L'IA générative et l'avenir du travail : perceptions et perspectives. Dialogue mondial OCDE/GPAI sur l'IA et l'avenir du travail. <https://www.oecd.org/en/about/programmes/global-partnership-on-artificial-intelligence/generative-ai-and-the-future-of-work.html>

Panksepp, J. (1998). *Neurosciences affectives : les fondements des émotions humaines et animales*. Presse de l'Université d'Oxford.

Parent-Rochelleau, X. et Parker, SK (2022). Les algorithmes en tant que concepteurs de travail : comment la gestion algorithmique influence la conception des emplois. *Examen de la gestion des ressources humaines*, 32(3), 100838. <https://doi.org/10.1016/j.hrmr.2021.100838>

Paul, KI et Moser, K. (2009). Le chômage nuit à la santé mentale : méta-analyses. *Journal du comportement professionnel*, 74(3), 264-282. <https://doi.org/10.1016/j.jvb.2009.01.001>

Phang, J., Lampe, M., Ahmad, L., Agarwal, S., Fang, CM, Liu, AR, Danry, V., Lee, E., Chan, SWT, Pataranutaporn, P. et Maes, P. (2025). Enquête sur l'utilisation affective et le bien-être émotionnel sur ChatGPT. *arXiv :2504.03888*. <https://doi.org/10.48550/arXiv.2504.03888>

Pierce, JL, Kostova, T. et Dirks, KT (2003). L'état de l'appropriation psychologique : intégrer et prolonger un siècle de recherche. *Revue de psychologie générale*, 7(1), 84-107. <https://doi.org/10.1037/1089-2680.7.1.84>

Poonsiriwong, R., Archiwanguprok, C. et Pataranutaporn, P. (2026). « Mort » d'un chatbot : enquêter et concevoir des fins psychologiquement sûres pour les relations entre l'homme et l'IA. *arXiv :2602.07193*. <https://doi.org/10.48550/arXiv.2602.07193>

Przybylski, AK, Murayama, K., DeHaan, CR et Gladwell, V. (2013). Corrélats motivationnels, émotionnels et comportementaux de la peur de rater quelque chose. *Les ordinateurs dans le comportement humain*, 29(4), 1841-1848. <https://doi.org/10.1016/j.chb.2013.02.014>

Ravid, DM, Tomczak, DL, White, JC et Behrend, TS (2020). EPM 20/20 : Un examen, un cadre et un programme de recherche pour la surveillance électronique des performances. *Journal de gestion*, 46(1), 100-126. <https://doi.org/10.1177/0149206319869435>

Reddy, WM (2001). *La navigation des sentiments : un cadre pour l'histoire des émotions*. La Presse de l'Université de Cambridge.

Rosenwein, BH (2006). *Communautés émotionnelles au haut Moyen Âge*. Presse de l'Université Cornell.

Ryan, RM et Deci, EL (2017). *Théorie de l'autodétermination : besoins psychologiques fondamentaux en matière de motivation, de développement et de bien-être*. Presse Guilford.

Schaller, M. et Park, JH (2011). Le système immunitaire comportemental et pourquoi c'est important. *Orientations actuelles de la science psychologique*, 20(2), 99-103. <https://doi.org/10.1177/0963721411402596>

- Scheer, M. (2012). Les émotions sont-elles une sorte de pratique (et est-ce ce qui leur donne une histoire) ? Une approche bourdieusienne de la compréhension des émotions. *Histoire et théorie*, 51(2), 193-220. <https://doi.org/10.1111/j.1468-2303.2012.00621.x>
- Scheibehenne, B., Greifeneder, R. et Todd, PM (2010). Peut-il y avoir trop d'options ? Une revue méta-analytique de la surcharge de choix. *Journal of Consumer Research*, 37(3), 409-425. <https://doi.org/10.1086/651235>
- Scherer, KR (2009). L'architecture dynamique de l'émotion : preuves du modèle de processus composant. *Cognition et émotion*, 23(7), 1307-1351. <https://doi.org/10.1080/02699930902928969>
- Selenko, E., Batinic, B. et Paul, KI (2011). La privation latente entraîne-t-elle une détresse psychologique ? Enquête sur le modèle de Jahoda dans une étude en quatre vagues. *Journal de psychologie du travail et des organisations*, 84(4), 723-740. <https://doi.org/10.1348/096317910X519360>
- Sell, A., Tooby, J. et Cosmides, L. (2009). Formidabilité et logique de la colère humaine. *Actes de l'Académie nationale des sciences*, 106(35), 15073-15078. <https://doi.org/10.1073/pnas.0904312106>
- Siegel, E.H., Sands, MK, Van den Noortgate, W., Condon, P., Chang, Y., Dy, J., Quigley, KS et Barrett, L.F. (2018). Empreintes émotionnelles ou populations émotionnelles ? Une enquête méta-analytique sur les caractéristiques autonomes des catégories d'émotions. *Bulletin psychologique*, 144(4), 343-393. <https://doi.org/10.1037/bul0000128>
- Stroebe, M., Schut, H. et Boerner, K. (2017). Avertissement des professionnels de la santé : Les personnes endeuillées sont mal guidées à travers les étapes du deuil. *OMEGA—Journal de la mort et des mourants*, 74(4), 455-473. <https://doi.org/10.1177/0030222817691870>
- Sznycer, D., Al-Shawaf, L., Bereby-Meyer, Y., Curry, O.S., De Smet, D., Ermer, E., Kim, S., Kim, S., Li, NP, Lopez Seal, MF, McClung, J., O, J., Ohtsubo, Y., Quillien, T., Schaub, M., Sell, A., van Leeuwen, F., Cosmides, L. et Tooby, J. (2018). Invariances interculturelles dans l'architecture de la honte. *Actes de l'Académie nationale des sciences*, 115(39), 9702-9707. <https://doi.org/10.1073/pnas.1805016115>
- Sznycer, D., Tooby, J., Cosmides, L., Porat, R., Shalvi, S. et Halperin, E. (2016). La honte suit de près la menace de dévaluation par les autres, même à travers les cultures. *Actes de l'Académie nationale des sciences*, 113(10), 2625-2630. <https://doi.org/10.1073/pnas.1514699113>
- Tangney, JP, Stuewig, J. et Mashek, DJ (2007). Émotions morales et comportement moral. *Revue annuelle de psychologie*, 58, 345-372. <https://doi.org/10.1146/annurev.psych.56.091103.070145>
- Taylor, GJ, Bagby, RM et Parker, JDA (1997). *Troubles de la régulation affective : alexithymie dans les maladies médicales et psychiatriques*. La Presse de l'Université de Cambridge.
- Tooby, J. et Cosmides, L. (2008). La psychologie évolutive des émotions et leur relation avec les variables régulatrices internes. Dans M. Lewis, J. M. Haviland-Jones et L. F. Barrett (Eds.), *Handbook of Emotions* (3e éd., pp. 114-137). Presse Guilford.
- Tracy, JL et Matsumoto, D. (2008). L'expression spontanée de la fierté et de la honte : preuve de manifestations non verbales biologiquement innées. *Actes de l'Académie nationale des sciences*, 105(33), 11655-11660. <https://doi.org/10.1073/pnas.0802686105>
- Tracy, JL et Robins, RW (2007). La structure psychologique de la fierté : une histoire à deux facettes. *Orientations actuelles de la science psychologique*, 16(3), 147-150. <https://doi.org/10.1111/j.1467-8721.2007.00493.x>
- Van de Ven, N., Zeelenberg, M. et Pieters, R. (2009). Nivellement de haut en bas : les expériences d'envie bénigne et malveillante. *Émotion*, 9(3), 419-429. <https://doi.org/10.1037/a0015669>
- Van Kleef, GA (2009). Comment les émotions régulent la vie sociale : Les émotions comme modèle d'information sociale. *Orientations actuelles de la science psychologique*, 18(3), 184-188. <https://doi.org/10.1111/j.1467-8721.2009.01633.x>
- Van Kleef, GA et Côté, S. (2022). Les effets sociaux des émotions. *Revue annuelle de psychologie*, 73, 629-658. <https://doi.org/10.1146/annurev-psych-020821-010855>

Wanberg, CR (2012). L'expérience individuelle du chômage. *Revue annuelle de psychologie*, 63, 369-396. <https://doi.org/10.1146/annurev-psych-120710-100500>

Warr, P. (2007). *Travail, bonheur et malheur*. Lawrence Erlbaum Associés.

Zhang, Y., Zhao, D., Hancock, JT, Kraut, R. et Yang, D. (2026). Interaction avec les compagnons IA et bien-être psychologique. *Nature Comportement humain*. <https://doi.org/10.1038/s41562-026-02516-2>

Blevins, T. (2026). L'accommodement va dans les deux sens : étudier la convergence linguistique entre les humains et les modèles linguistiques. *arXiv :2605.29278*. <https://doi.org/10.48550/arXiv.2605.29278>

Chu, MD, Wu, Y., Chen, Z., Hwang, AH-C. et Luceri, L. (2026). Quand les chatbots s'adaptent : ce que les compagnons IA optimisent dans les conversations vulnérables. *arXiv :2606.04431*. <https://doi.org/10.48550/arXiv.2606.04431>

Derner, E., Kučera, D., Gulati, A., Bagheri, A. et Oliver, N. (2026). Attention au style : impact du style de communication sur l'interaction homme-chatbot. *arXiv :2602.17850*. <https://doi.org/10.48550/arXiv.2602.17850>

Farach, A., Cambon, A., Tankelevitch, L., Hsueh, C. et Janssen, R. (2026). Échafaudage de la collaboration homme-IA : une expérience sur le terrain sur les protocoles comportementaux et le recadrage cognitif. *arXiv :2604.08678*. <https://doi.org/10.48550/arXiv.2604.08678>

Giles, H., Coupland, J. et Coupland, N. (éd.). (1991). *Contextes d'accommodement : développements en sociolinguistique appliquée*. La Presse de l'Université de Cambridge.

Lee, H.-P. (H.), Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R. et Wilson, N. (2025). L'impact de l'IA générative sur la pensée critique : réductions autodéclarées de l'effort cognitif et effets sur la confiance à partir d'une enquête auprès des travailleurs du savoir. *Actes du CHI 2025*. <https://doi.org/10.1145/3706598.3713778>

Levinson, SC et Torreira, F. (2015). Le timing du tour de rôle et ses implications pour le traitement des modèles de langage. *Frontières en psychologie*, 6, 731. <https://doi.org/10.3389/fpsyg.2015.00731>

Reeves, B. et Nass, C. (1996). *L'équation médiatique*. La Presse de l'Université de Cambridge.

Riedl, C., Savage, S. et Zvebilova, J. (2026). Spillover cognitif dans les équipes Human-IA. *arXiv :2407.17489v3*. <https://doi.org/10.48550/arXiv.2407.17489>

Rimé, B. (2009). L'émotion suscite le partage social de l'émotion : théorie et examen empirique. *Revue des émotions*, 1(1), 60-85. <https://doi.org/10.1177/1754073908097189>

Stivers, T., Enfield, NJ, Brown, P., Englert, C., Hayashi, M., Heinemann, T., Hoymann, G., Rossano, F., de Ruiter, JP, Yoon, KE et Levinson, SC (2009). Universaux et variations culturelles à tour de rôle dans la conversation. *Actes de l'Académie nationale des sciences*, 106(26), 10587-10592. <https://doi.org/10.1073/pnas.0903616106>

Sun, Y., Han, Y. et Lv, L. (2026). « La hâte fait du gaspillage » : comment les réponses tardives améliorent l'intention des clients d'utiliser le chatbot dans les services touristiques. *Journal international de gestion hôtelière*, 137, 104673. <https://doi.org/10.1016/j.ijhm.2026.104673>

Székely, É., Miniota, J. et Hejná, M. (2025). L'IA va-t-elle façonner notre façon de parler ? L'influence sociolinguistique émergente des voix synthétiques. *Actes de l'IWSDS 2025*, 357-368. <https://doi.org/10.48550/arXiv.2504.10650>

Vaccaro, M., Almaatouq, A. et Malone, T. (2024). Quand les combinaisons d'humains et d'IA sont utiles : une revue systématique et une méta-analyse. *Nature Comportement humain*, 8, 2293-2303. <https://doi.org/10.1038/s41562-024-02024-1>