

AUTOPSJA PRZYSZŁYCH EMOCJI

Między darwinizmem psychologicznym, historią,
antropologią i światem sztucznej inteligencji



Prawa autorskie © [2026] Axiologic Research

Wszelkie prawa zastrzeżone.

Prawa do publikacji KDP posiada Outfinity SRL (Iași, Rumunia).

Dostępne bezpłatnie na stronie internetowej Axiologic (www.axiologic.net).

Nota autora

Niniejsza praca powstała pod patronatem Axiologic Research jako część dwóch wzajemnie powiązanych programów badawczych, jednego poświęconego sztucznej inteligencji, a drugiego outfinityzmu, obydwoma kierowanymi przez Șinică Alboaie. Aby poznać szczegóły wzajemnego przenikania się i wzajemnego oddziaływania tych dwóch programów, zapraszamy czytelników do odwiedzenia strony Outfinity Venture Studio pod adresem www.outfinity.ch.

Chociaż do pomocy w generowaniu tekstu wykorzystano modele językowe sztucznej inteligencji, podstawowa filozofia, struktura tematyczna i podejście analityczne wywodzą się wyłącznie z dziesięcioleci specjalistycznych badań autora nad zjawiskami społecznymi, technologiami społecznymi i prawdziwymi twardymi technologiami będącymi wynikiem różnych europejskich i samofinansujących się projektów badawczych. Ostatnio w ramach projektu badawczego Achilles dogłębnie badaliśmy literaturę generowaną przez sztuczną inteligencję i jej automatyczną weryfikację przy użyciu podejść neurosymbolicznych; wszystkie bezpłatne książki udostępnione publicznie są częścią zestawu prac, których używamy do testowania naszych najnowszych technologii.

Spis treści

Uwaga metodologiczna: czym jest dowód, czym jest interpretacja i czym jest spekulacja	6
Wprowadzenie: Dlaczego teoria emocji jest konieczna do zrozumienia zautomatyzowanego świata	8
Rozdział 1. Czym jest emocja i co może wyjaśnić ewolucja?	10
1.1 Kategoria naukowa bez jednej definicji	10
1.2 Wyjaśnienie funkcjonalne i niebezpieczeństwo wygodnych historii ewolucyjnych	10
1.3 Emocje jako programy koordynacyjne, a nie niezawodne polecenia	11
1.4 Świadome odczuwanie i problem dostępu do siebie	12
1.5 Działający model pozostałej części książki	12
Rozdział 2. Emocje jako infrastruktura interakcji społecznych	13
2.1 Od regulacji organizmu do regulacji relacji	13
2.2 Strach i niepokój: radzenie sobie z niepewnością i niebezpieczeństwem	14
2.3 Złość: renegocjacja relacji i sygnalizowanie ograniczeń	14
2.4 Wstręt i skażenie: ochrona biologiczna i granica moralna	15
2.5 Smutek i żal: reakcje na stratę, a nie proste rozwiązania	15
2.6 Emocje to nie tylko szczery przekaz	16
Rozdział 3. Status, współpraca i moralność afektywna	17
3.1 Dlaczego status wywołuje intensywne emocje	17
3.2 Duma: informacja zwrotna na temat wartości i ryzyka inflacji	17
3.3 Wstyd i wina: dewaluacja, odpowiedzialność i naprawa	18
3.4 Zazdrość i zazdrość: porównania, dostęp i relacje trudne do zastąpienia	18
3.5 Wdzięczność, zaufanie i syntetyczna wzajemność	19
3.6 Współczucie i oburzenie: moralność nie jest jednym systemem	19
3.7 Przynależność i samotność: deficyt relacyjny lub sygnał ponownego połączenia	20
3.8 Nieformalna konstytucja afektywna	20
Rozdział 4. Kultura nie tylko nazywa emocje	22
4.1 Między uniwersalnością a zmiennością	22
4.2 Pojęcia emocji jako instrumenty percepcji i działania	22
4.3 Wspólnoty emocjonalne i reżimy afektywne	23
4.4 Kapitalizm, zawody i kultywowanie produktywnego „ja”.	23
4.5 Platformy jako środowiska selekcji afektywnej	23
4.6 Jak rozpoznać nową kategorię emocji?	24
Rozdział 5. Praca jako instytucja afektywna i niepewność automatyzacji	25
5.1 Praca zapewnia więcej niż dochód, ale nie zawsze zapewnia sens	25
5.2 Co wiemy o obecnym wpływie AI na pracę	25
5.3 Zadanie, zawód i tożsamość	26
5.4 Cztery scenariusze relacji AI i pracy	26
5.5 Jakie niedobory pozostaną, gdy produkcja poznawcza stanie się tania?	27
5.6 Wysiłek, wartość i dobrowolny niedobór	27
5.7 Sam dochód nie rozwiązuje problemu przejścia emocjonalnego	27
5.8 Przejście może mieć większe znaczenie niż przeznaczenie	28
Rozdział 6. Trzy prędkości ewolucji afektywnej	29
6.1 Ewolucja biologiczna się nie zatrzymała, ale nie jest to najbliższe wyjaśnienie	29
6.2 Rozwój: skala czasu jednego życia	29
6.3 Ewolucja kulturowa: zmienność, przekazywanie i selekcja	30
6.4 Wybór algorytmiczny: przyspieszenie, nie magia	30
6.5 Pętla pomiędzy trzema prędkościami	30
6.6 Co może, a czego nie może dokonać przemyślana ewolucja emocjonalna	31

Rozdział 7. Czy mogą pojawić się nowe emocje?	32
7.1 Cztery znaczenia nowości	32
7.2 Nowa emocja nie wymaga wyjątkowej fizjologii	32
7.3 Nowy przedmiot, nowa ocena lub nowa relacja	32
7.4 Dobór kulturowy słownictwa afektywnego	33
7.5 Kiedy koncepcja pomaga, a kiedy tworzy artefakty	33
7.6 Skala wiarygodności	34
7.7 Przewidywania mogące falsyfikować hipotezy	34
Rozdział 8. Tymczasowy atlas afektów w zautomatyzowanym świecie	36
8.1 Smutek kompetencyjny	36
8.2 Wstyd delegowania	36
8.3 Afektywna dwuznaczność autorstwa	37
8.4 Lęk przed istotnością	37
8.5 Obfite zawroty głowy	38
8.6 Głód tarcia	38
8.7 Duma kuratorska i odpowiedzialność architektoniczna	38
8.8 Klaustrofobia prognostyczna i pragnienie nieprzejrzystości	39
8.9 Żaloba po wersji	39
8.10 Dyskomfort syntetycznej wzajemności	39
8.11 Poczucie winy z dystansu moralnego	39
8.12 Melancholia ludzkiej wyjątkowości	40
8.13 Godność nieproduktywna jako uczucie kulturowane	40
8.14 Co mogłoby sprawić, że atlas będzie błędny	40
Rozdział 9. Relacje z agentami, którzy wyglądają na towarzyskich	42
9.1 Problem można sformułować bez decydowania o świadomości AI	42
9.2 Dlaczego systemy konwersacyjne uruchamiają mechanizmy społeczne	42
9.3 Co pokazują wczesne badania, a czego jeszcze nie mogą pokazać	42
9.4 Uzupełnienie, narzędzie szkoleniowe lub substytut	43
9.5 Wzajemność niemożliwa do sprawdzenia	43
9.6 Pamięć, osobowość i ciągłość	44
9.7 Towarzysze dla dzieci i użytkowników bezbronnych	44
9.8 Zautomatyzowana praca emocjonalna	44
9.9 Miłość do sztucznej inteligencji to kilka różnych pytań	45
9.10 Jak sztuczna inteligencja może modyfikować relacje między ludźmi	45
Rozdział 10. Od afektu do strategii: adaptacja behawioralna w świecie za pośrednictwem sztucznej inteligencji	46
10.1 Dlaczego zachowanie należy analizować oddzielnie od emocji	46
10.2 Delegowanie staje się raczej kompetencją niż brakiem kompetencji	46
10.3 Strategiczne zachowanie kompetencji i wartość tarcia	47
10.4 Sygnalizacja pochodzenia i premia ludzka	47
10.5 Migracja statusu: od realizacji do selekcji, arbitrażu i odpowiedzialności	47
10.6 Portfolio tożsamości i adaptacja poprzez opcjonalność	48
10.7 AI jako trener społeczny, pośrednik i arbiter	48
10.8 Koalicje, wspólnoty i odbudowa niedoborów społecznych	49
10.9 Strategie obronne przeciwko spersonalizowanej perswazji	49
10.10 Zachowanie instytucjonalne: pochodzenie, audyt i podział odpowiedzialności	50
10.11 Sześć możliwych fenotypów behawioralnych	51
10.12 Co można przetestować w ciągu najbliższej dekady	51
Rozdział 11. Tempo afektywne: jak symulowane emocje w sztucznej inteligencji mogą zmienić komunikację międzyludzką	53

11.1 Czas jest częścią przesłania	53
11.2 Symulowana emocja nie jest emocją odczuwaną, ale może mieć skutki społeczne	53
11.3 Stała dostępność i ponowna kalibracja progu reakcji	54
11.4 Przyspieszenie przetwarzania afektywnego poprzez zawsze dostępnego rozmówcę	54
11.5 Od epizodycznej rozmowy do ciągłego przepływu afektywnego	54
11.6 Akomodacja językowa: sztuczna inteligencja dostosowuje się do nas, ale czy my dostosowujemy się do sztucznej inteligencji?	55
11.7 Standaryzacja ciepła i nowy próg grzeczności	55
11.8 Transfer oczekiwań: ryzyko nietolerancji ludzkich tarć	56
11.9 Przyspieszone ujawnianie się i problem taniej intymności	57
11.10 AI jako tłumacz emocji między ludźmi	57
11.11 Autentyczność przy oddzieleniu intencji i sformułowania	58
11.12 Deskillling społeczny czy trwała szkoła komunikacji?	58
11.13 Dzieciństwo i uczenie się norm wzajemności	59
11.14 Kontrselekcja: celowy powrót do tego, co powolne, niezręczne i niezrewidowane	59
11.15 Taksonomia zmiany czasowej i jej prawdopodobieństwo	60
Rozdział 12. W stronę świadomej ekologii afektywnej	61
12.1 Dlaczego problemu nie można sprowadzić do odporności indywidualnej	61
12.2 Agencja jako zasada projektowania	61
12.3 Ochrona kompetencji bez zachowywania nieefektywności	61
12.4 Prawo do wniesienia wkładu i prawo do nieprodukowania	61
12.5 Instytucje przynależności poza firmą	61
12.6 Dobrowolny niedobór i strefy bez optymalizacji	62
12.7 Zarządzanie relacjami z AI	62
12.8 Pochodzenie i normy ekspresji wspomaganej	62
12.9 Ochrona przed ukrytą optymalizacją afektywną	62
12.10 Program badawczy dotyczący emocji przyszłości	62
12.11 Granice zamierzonego projektowania	63
Wniosek: Ciągłość biologiczna i nieciągłość świata	64
Aneks. Syntetyczna macierz scenariuszy	66
Poziomy twierdzeń zastosowane w książce	66
Kandydackie afekty przyszłości	66
Scenariusze behawioralne i komunikacyjne	66
Bibliografia	68

Uwaga metodologiczna: czym jest dowód, czym jest interpretacja i czym jest spekulacja

W tej książce zadano pytanie, na które nie wystarczy żadna pojedyncza dyscyplina: jak może zmienić się życie emocjonalne człowieka, gdy sztuczna inteligencja stanie się trwałym elementem pracy, komunikacji, rywalizacji o status, podejmowania decyzji i intymnych interakcji? Pierwsza trudność ma charakter koncepcyjny. Nie ma powszechnie akceptowanej naukowej definicji emocji, nie ma ustalonej listy emocji ani konsensusu co do stopnia, w jakim znane kategorie, takie jak strach, złość, wstyd, duma czy miłość, odwzorowują się na biologicznie odrębne systemy. Druga trudność jest tymczasowa. Omawiane tu technologie zmieniają się szybciej niż baza danych. Trzecia kwestia ma charakter metodologiczny. Wiarygodna funkcja ewolucyjna to nie to samo, co wykazana historia ewolucji, a możliwości technologiczne nie są prognozą.

Aby uniknąć zatarcia tych różnic, w argumentach zastosowano cztery poziomy ufności. Pierwsza składa się ze stosunkowo solidnych obserwacji empirycznych: na przykład, że utrata pracy wiąże się średnio z niekorzystnymi skutkami psychologicznymi; że ekspresja emocjonalna zmienia interakcję; że ludzie łatwo przypisują właściwości społeczne reagującym maszynom; oraz że generatywna sztuczna inteligencja może w niektórych sytuacjach zmieniać wykonywanie zadań i subiektywne doświadczenie sprawstwa. Druga składa się z interpretacji funkcjonalnych, które są wiarygodne i powiązane z ugruntowaną literaturą, jak na przykład propozycja, że wstyd pomaga regulować zagrożenia dewaluacją społeczną lub że wdzięczność stabilizuje relacje kooperacyjne. Interpretacje te mogą być przydatne bez udowadniania, że wybrano jedną dedykowaną adaptację dokładnie dla tej funkcji. Trzeci poziom składa się z ekstrapolacji warunkowych. Jeśli sztuczna inteligencja znacząco zmniejszy niedobór określonych wyników poznawczych, jeśli stanie się rutynowym pośrednikiem w komunikacji lub jeśli czynniki społeczne staną się stale dostępne, wówczas szczególne adaptacje behawioralne i afektywne staną się bardziej prawdopodobne. Czwarty poziom składa się z wyraźnych spekulacji pojęciowych: możliwych przyszłych kategorii emocji, norm społecznych lub instytucji, dla których nie istnieją jeszcze bezpośrednie dowody.

Dlatego termin „darwinizm psychologiczny” jest używany wąsko. Nie oznacza to, że każda cecha ma charakter adaptacyjny, że obecne hierarchie społeczne są biologicznie konieczne lub że sukces reprodukcyjny dostarcza moralnego uzasadnienia. Oznacza to, że umysły mają historię, że powtarzające się problemy z przetrwaniem i koordynacją ukształtowały organizmy oraz że zmienność, selekcja, rozwój i transmisja kulturowa mogą wyjaśnić, dlaczego pewne tendencje psychologiczne powracają. Dobór naturalny wytwarza również kompromisy, produkty uboczne, słabości rozwojowe i mechanizmy, które mogą stać się nieprzystosowawcze, gdy zmienia się środowisko. Konto ewolucyjne stanowi podstawę do generowania hipotez, a nie licencję na retrospektywne opowiadanie historii.

Książka rozróżnia także emocje, uczucia, afekt, nastrój i zachowanie, jeśli to rozróżnienie ma znaczenie. Emocję traktuje się tymczasowo jako stosunkowo ograniczony epizod obejmujący ocenę istotnej sytuacji, zmiany uwagi i motywacji, regulację ciała, skłonność do działania, a czasami ekspresję społeczną. Uczucie to świadomie dostępne doświadczenie takiego stanu lub trwalsza orientacja wartościująca. Afekt odnosi się szerzej do wartościowości i aktywacji, podczas gdy nastrój opisuje stan bardziej rozproszony, bez jednego wyraźnego obiektu. Definicje te mają raczej charakter praktyczny niż doktrynalny. Ważniejsze dla opracowanego tutaj rozszerzenia jest rozróżnienie między stanem wewnętrznym a strategią behawioralną. Strach może współistnieć z wycofaniem się, poszukiwaniem informacji, budowaniem koalicji, ubezpieczeniem lub konfrontacją. Wstyd może skutkować ukryciem, przeprosinami, naprawą, agresją lub wyjściem. W świecie, w którym pośredniczy sztuczna inteligencja, wynikająca z tego adaptacja może często zachodzić na poziomie strategii, a nie na poziomie nowego uczucia.

Z tego powodu rozdziały 10 i 11 rozszerzają wcześniejszą analizę w dwóch kierunkach. W rozdziale 10 przyjęto perspektywę behawioralną i instytucjonalną. Zadaje pytanie, co ludzie mogą wielokrotnie zrobić, gdy sztuczna inteligencja zmienia koszt wytwarzania kompetentnych wyników, widoczność indywidualnego wkładu, dystrybucję wiedzy specjalistycznej i strukturę statusu. Bada delegowanie, weryfikację, zachowanie umiejętności, sygnalizację pochodzenia, tworzenie koalicji, dywersyfikację tożsamości i nowe podziały odpowiedzialności. W rozdziale 11 zadano pytanie, co się dzieje, gdy zmienia się sam rozmówca społeczny. Asystenci AI mogą być stale dostępni, szybko reagować, dostosowywać się językowo i być w stanie symulować cierpliwość, ciepło, wahanie, entuzjazm, współczucie lub troskę. Nawet jeśli te przejawy nie są dowodem emocji odczuwanych przez maszynę, mogą zmienić ludzkie oczekiwania co do czasu i formy komunikacji.

Empiryczne podstawy tych dwóch rozdziałów są węższe niż dowody wielu klasycznych odkryć na temat emocji. Niedawne eksperymenty sugerują, że współpraca człowieka i sztucznej inteligencji nie zapewnia automatycznie lepszych wyników niż najlepszy człowiek lub aktor sztucznej inteligencji, że generatywna sztuczna inteligencja może skierować wysiłek w zakresie krytycznego myślenia w stronę weryfikacji i integracji oraz że protokoły interakcji mają znaczenie. Inne prace sugerują, że treści konwersacyjne generowane przez sztuczną inteligencję mogą wpływać na postrzeganą bliskość, że użytkownicy i modele językowe mogą się do siebie językowo dostosować, a narażenie na style sztucznej inteligencji może przełożyć się na późniejsze interakcje między ludźmi. To są wczesne wyniki. Wiele z nich opiera się na krótkich eksperymentach, samodzielnie wybranych próbach, wąskich zadaniach lub szybko przestarzałych modelach. Należy je traktować jako mechanizmy warte przetestowania, a nie ustalone opisy przyszłej kultury.

Ta sama ostrożność dotyczy zastosowanego w książce słownictwa dotyczącego emocji przyszłych. Terminy takie jak smutek kompetencyjny, wstyd związany z delegacją, klaustrofobia predykcijna lub smutek wersji nie są proponowane jako odkryte naturalne rodzaje. Są to analityczne etykiety dla powtarzających się konfiguracji, które mogą stać się istotne kulturowo. Kategoria zasługiwałaby na silniejszy status tylko wtedy, gdyby okazała się stabilna wśród ludzi i środowisk, uzyskała rozpoznawalne czynniki wywołujące i tendencje do działania, wspierała niezawodną komunikację i przetrwała poza tymczasową modą technologiczną. Książka jest zatem celowo asymetryczna: skłonna jest do spekulacji, ale jednocześnie określa, gdzie zaczyna się spekulacja.

Wprowadzenie: Dlaczego teoria emocji jest konieczna do zrozumienia zautomatyzowanego świata

Publiczna dyskusja na temat sztucznej inteligencji w naturalny sposób koncentruje się na możliwościach, produktywności, płacach, własności i podziale władzy. Są to pytania niezastąpione, ale praca to coś więcej niż metoda wytwarzania dóbr i podziału dochodów. Organizuje także czas, przydziela pozycje społeczne, poświadcza kompetencje, tworzy powtarzające się relacje, rozdziela prestiż i daje jednostkom słownictwo, za pomocą którego wyjaśnia swoją użyteczność. Jeśli zmiany w sztucznej inteligencji zadziałają głęboko, zmieniają część środowiska, w którym emocje są wywoływane, interpretowane, nagradzane i dyscyplinowane.

Twierdzenie to nie zakłada, że emocje to kruche konwencje, które zmieniają się wraz ze zmianą technologii. Strach, przywiązanie, złość, poszukiwanie nagrody, pobudzenie cielesne i wrażliwość na wykluczenie mają korzenie znacznie starsze niż zatrudnienie w przemyśle. Szybciej zmieniają się obiekty, do których te systemy się przywiązują, oceny, które je aktywują, instytucje, które nagradzają lub tłumią ich ekspresję, oraz strategie, których ludzie uczą się w odpowiedzi. Wstyd urzędnika sądowego, wstyd robotnika przemysłowego i wstyd studenta, który opiera się na modelu generatywnym, nie muszą być identycznymi zjawiskami społecznymi, nawet jeśli rekrutują nakładające się zasoby afektywne.

Głównym założeniem tej książki jest to, że emocje pełnią co najmniej cztery rodzaje funkcji. Koordynują organizm, przenosząc uwagę i działania pod presją czasu. Koordynują interakcję, sygnalizując intencje, potrzeby, ograniczenia i oceny. Podtrzymują porządek grupowy, przyczyniając się do konformizmu, naprawy, kary, wdzięczności, zaufania i podziału statusu. Wreszcie można je kultywować instytucjonalnie. Rytuały, edukacja, religia, zawody, rynki, organizacje i platformy cyfrowe sprawiają, że niektóre reakcje emocjonalne są bardziej widoczne i bardziej satysfakcjonujące niż inne. Nie oznacza to, że instytucje bezpośrednio instalują emocje. Oznacza to, że zmieniają ekologię, w której nabywa się, manifestuje i społecznie selekcjonuje skłonności emocjonalne.

Automatyzacji nie należy zatem traktować jedynie jako substytutu zadania. Można to potraktować jako zaburzenie ekologii afektywnej. System generatywny może zmniejszyć wysiłek wymagany do stworzenia raportu, jednocześnie obniżając poczucie własności autora. Może zdemokratyzować dostęp do kompetentnej wypowiedzi, utrudniając jednocześnie wywnioskowanie kompetencji z gotowego produktu. Może zapewnić towarzystwo, jednocześnie zmieniając oczekiwania dotyczące reakcji. Może sprawić, że perswazja stanie się tańsza, jednocześnie zwiększając wartość zaufanego pochodzenia. Konsekwencje psychologiczne zależą od praw własności, instytucji pracy, norm zawodowych, edukacji, projektu platformy i dystrybucji zysków z automatyzacji. Technologia nie wiąże się z jedną przyszłością emocjonalną.

Dalszego rozróżnienia wymaga pytanie, czy mogą pojawić się rzeczywiście nowe emocje. „Nowy” może oznaczać nowy mechanizm biologiczny, nową kombinację starszych mechanizmów, nową, uznaną kulturowo kategorię, nowy obiekt starych emocji lub nowy, ustabilizowany instytucjonalnie wzorzec oceny i działania. Biologicznie nowy, obejmujący cały gatunek system emocjonalny pojawiający się w ciągu kilku dziesięcioleci nie jest szczególnie prawdopodobny. Ewolucja genetyczna człowieka trwa, ale skala czasowa i warunki selekcji sprawiają, że jest to słabe wyjaśnienie krótkoterminowych zmian. Z kolei nowe, ustabilizowane kulturowo koncepcje emocji mogą pojawić się znacznie szybciej. Historyczne prace nad słownikami emocjonalnymi, międzykulturowe różnice w semantyce emocji i teorie konstrukcji emocji potwierdzają możliwość, że społeczeństwa mogą zreorganizować sposób, w jaki doświadczenie afektywne jest interpretowane i komunikowane, bez czekania na nowy obwód neuronowy.

Najważniejszy teza książki jest zatem umiarkowana. Przekształcone technologicznie społeczeństwo prawdopodobnie nie wytworzy całkowicie nowej ssaczej architektury afektywnej. Może jednak wygenerować nowe powtarzające się sytuacje, nowe systemy statusu, nowe formy zależności, nowe rodzaje dwuznaczności co do autorstwa i wzajemności oraz nowe normy określające, co zasługuje na dumę lub wstyd. Zmiany te mogą skutkować powstaniem konfiguracji, które staną się na tyle odrębne społecznie, że będą mogły uzyskać nazwy i pisma. Jeśli tak się stanie, nazywanie ich nowymi emocjami będzie uzasadnione w sensie kulturowym i funkcjonalnym, nawet jeśli ich biologiczne składniki są stare.

Argumentacja przebiega w trzech ruchach. Pierwsza rekonstruuje emocje jako mechanizmy biologiczne i społeczne, zachowując jednocześnie główne spory teoretyczne. Drugi bada kulturę, pracę i możliwość przyspieszenia zmian afektywnych w ramach sztucznej inteligencji. Trzeci przechodzi od uczuć do strategii i od strategii do komunikacji. Pyta nie tylko o to, co ludzie mogą czuć, ale czego będą się wielokrotnie uczyć: czego delegują, co weryfikują, w jaki sposób sygnalizują swój wkład, jakie umiejętności zachowują, jak tworzą koalicje i jak zarządzają relacjami z agentami symulującymi responsywność społeczną.

Ten ruch behawioralny ma znaczenie, ponieważ emocje nie determinują pojedynczego działania. Przestraszona osoba może unikać, przygotowywać się, szukać sojuszników, wykupić ubezpieczenie, zebrać informacje lub zaatakować. Pracownik, którego wiedza specjalistyczna została zdewaluowana przez automatyzację, może ukrywać wykorzystanie sztucznej inteligencji, zintensyfikować szkolenia, przejść do dziedziny, w której rzadko występuje osąd, zbudować reputację osoby wymagającej weryfikacji lub całkowicie wycofać się z tożsamości zawodowej. Są to różne równowagi strategiczne, które mogą wyłonić się z podobnych nacisków afektywnych. Przewidywanie ich wymaga zwrócenia uwagi na bodźce i instytucje, a nie tylko na introspekcję.

Konwersacyjna sztuczna inteligencja wprowadza drugi zaniedbany wymiar: czas. Komunikacja międzyludzka jest ograniczona przez sen, uwagę, zawstydzenie, obowiązki społeczne, opóźnioną refleksję i fakt, że inni ludzie prowadzą niezależne życie. Sztuczny rozmówca może być dostępny w sposób ciągły, odpowiadać natychmiast, zapamiętywać poprzednie wymiany zdań, dostosowywać styl i generować odpowiedni emocjonalnie język przy znikomym koszcie krańcowym. Może to zmienić tempo, w jakim ludzie ujawniają, powtarzają, naprawiają, eskalują i reinterpreterują emocje. Może także stwarzać oczekiwania, które są trudne do spełnienia w relacjach międzyludzkich. Nie wiadomo, jak silne będą te skutki; obecne badania są zbyt krótkie, a systemy zbyt nowe. Jednak mechanizmy są na tyle wiarygodne, że zasługują na analizę już teraz.

Celem nie jest ogłoszenie, że sztuczna inteligencja nieuchronnie zuboży lub wzbogaci życie emocjonalne. Obydwa wyniki są możliwe i oba mogą wystąpić jednocześnie dla różnych grup. Celem jest identyfikacja zmiennych, które sprawią, że jedna trajektoria będzie bardziej prawdopodobna od drugiej, oraz umożliwienie testowania przyszłych twierdzeń. W tym sensie poważna teoria przyszłych emocji nie jest głównie słownikiem egzotycznych uczuć. Jest to opis tego, jak stare systemy biologiczne, uczenie się kulturowe, instytucje i środowiska algorytmiczne mogą wspólnie zreorganizować ludzkie zachowanie.

Rozdział 1. Czym jest emocja i co może wyjaśnić ewolucja?

1.1 Kategoria naukowa bez jednej definicji

Nauka o emocjach bada klasę zjawisk rozpoznawalnych w zwykłym życiu, ale trudnych do naukowego określenia. Strach różni się od prostego osądu, że coś jest niebezpieczne, ponieważ może wiązać się z pobudzeniem ciała, selektywną uwagą, tendencjami do unikania, zmianami w pamięci i ekspresją społeczną. Jednak żaden z tych elementów nie jest konieczny w każdym odcinku. Ludzie mogą zgłaszać strach przy słabej aktywacji fizjologicznej, wykazywać reakcje obronne, nie opisując siebie świadomie jako przerażonych, lub interpretować podobne pobudzenie cielesne jako podekscytowanie, złość lub niepokój, w zależności od kontekstu.

Klasyczne teorie odpowiadały odmiennie [Panksepp, 1998; Scherera, 2009; Barrett, 2017]. Podejścia oparte na emocjach podstawowych poszukują ograniczonego zestawu ewolucyjnie konserwatywnych rodzin o charakterystycznych wyrażeniach i funkcjach. Teorie oceny podkreślają, w jaki sposób organizmy oceniają nowość, sterowalność, trafność celu, zgodność z normami, odpowiedzialność i zdolność radzenia sobie. Podejścia wymiarowe opisują doświadczenie wzdłuż takich osi, jak wartościowość i pobudzenie. Teorie konstrukcjonistyczne kładą nacisk na przewidywanie, interocepcję, koncepcje i wyuczone kategorie. Neuronauka afektywna identyfikuje starożytne systemy motywacyjne i obronne, zachowując jednocześnie ostrożność przy mapowaniu każdego słowa w języku potocznym na jeden izolowany obwód. Rozbieżność zdań nie jest jedynie terminologiczna, ale nie jest też całkowita. Większość współczesnych relacji akceptuje znaczne różnice kontekstowe i ograniczenia narzucone przez ciało i układ nerwowy.

Na potrzeby analizy zorientowanej na przyszłość model warstwowy jest bardziej przydatny niż przedwczesny wybór obozów. Na jednym poziomie znajdują się regulacja energii, pobudzenie, ból, nagroda, stan zapalny, zmiany autonomiczne i sygnały interoceptywne. Drugim są systemy orientacji i działania związane z unikaniem, podejściem, opieką, eksploracją, obroną i poszukiwaniem nagrody. Trzecią jest ocena relacji pomiędzy wydarzeniami, celami, normami i „ja”. Na czwartym znajdują się wyuczone pojęcia, które organizują doświadczenie i umożliwiają komunikowanie rozróżnień. Instytucje określają następnie, które sytuacje się powtarzają i które przejawy są nagradzane, a które karane. Poziomy te oddziałują na siebie, a nie tworzą sztywną hierarchię.

Taki model wyjaśnia, dlaczego zmiany technologiczne mogą mieć znaczenie, bez zakładania, że nowe urządzenie natychmiast zmieni ludzką naturę. Dziecko urodzone w świecie trwałej sztucznej inteligencji prawdopodobnie odziedziczy znajome zdolności w zakresie przywiązywania się, wykrywania zagrożeń, zabawy i wrażliwości na status. Niemniej jednak dziecko może uczyć się różnych obiektów przywiązania, różnych kryteriów kompetencji, innych zasad autentyczności i różnych oczekiwań co do dostępności społecznej. Powtarzające się kombinacje mogą ostatecznie zyskać własne nazwy i skrypty behawioralne.

Rozbieżność zdań nie ma jedynie charakteru terminologicznego. Teoria, która traktuje emocje przede wszystkim jako rozwinięte programy działania, stawia inne pytania niż teoria, która kładzie nacisk na wnioskowanie predykcyjne, konceptualizację lub kategorie wyuczone społecznie. Ten pierwszy szuka powtarzających się problemów adaptacyjnych i skoordynowanych wzorców reakcji; ta druga pyta, w jaki sposób sygnały cielesne, wcześniejsze oczekiwania, język i kontekst składają się na epizod, który dana osoba rozpoznaje jako strach, wstyd lub dumę. Obie perspektywy mają poparcie empiryczne i żadna z nich nie uzasadnia obecnie sprowadzania wszystkich zjawisk emocjonalnych do jednego mechanizmu. Na potrzeby tej książki ważna konsekwencja ma charakter metodologiczny: twierdzenia dotyczące przyszłych emocji powinny określać, który poziom ma się zmienić. Nowa kategoria społeczna może pojawić się bez nowego autonomicznego podpisu, a znany stan fizjologiczny może zyskać inny przedmiot, znaczenie lub skrypt behawioralny. Odrębne traktowanie tych poziomów zapobiega pomyleniu nowości kulturowej z szybką ewolucją biologiczną.

1.2 Wyjaśnienie funkcjonalne i niebezpieczeństwo wygodnych historii ewolucyjnych

Rozumowanie ewolucyjne pyta, jaki powtarzający się problem stan psychiczny mógłby pomóc organizmom rozwiązać i jakie przewidywania wynikają z tej hipotezy. Strach może nadać priorytet informacjom o zagrożeniach i przygotować do uniknięcia lub obrony. Złość może uczynić konfrontację bardziej wiarygodną i zasygnalizować, że obecne warunki są nie do przyjęcia. Wstyd może redukować zachowania grożące dewaluacją społeczną. Przywiązanie może ustabilizować długoterminową inwestycję w relacje. Konta te są przydatne, ponieważ łączą zupełnie odmienne zmiany w uwadze, motywacji, fizjologii i zachowaniu.

Metoda ta jest również podatna na eleganckie historie retrospektywne. Dla niemal każdej cechy można wymyślić sytuację przodków, w której dana cecha byłaby przydatna. Spójność nie jest dowodem na to, że dla proponowanej funkcji wybrano mechanizm. Silniejsze argumenty wymagają niezależnych przewidywań, dowodów międzykulturowych i porównawczych, danych rozwojowych, korelacji ze strukturą sytuacji oraz, jeśli to możliwe, dowodów neurobiologicznych lub genetycznych. Muszą także odróżnić adaptacje od produktów ubocznych, kompromisów i reakcji, które kiedyś były przydatne, ale w nowych warunkach stały się kosztowne.

Funkcja nie jest równoznaczna z obecnymi korzyściami. System wykrywania zagrożeń nastawiony na fałszywe alarmy mógł działać adaptacyjnie, gdy zaginięcie drapieżnika było katastrofalne, i nadal powodować patologiczny niepokój we współczesnym środowisku nasyconym niejednoznacznymi sygnałami. Czujność stanu może pomóc ludziom poruszać się po małych grupach i stać się destrukcyjna, gdy wskaźniki i odbiorcy są ciągle. Preferencje dotyczące żywności o dużej zawartości kalorii mogą stać się nieprzystosowawcze w przypadku otyłości. Koncepcja niedopasowania ewolucyjnego ma zatem kluczowe znaczenie dla przyszłości technologicznej: nowe środowiska mogą aktywować stare mechanizmy w sposób, którego nie przewidywała ich historia.

Wyjaśnienie ewolucyjne nie uzasadnia także normy. Jeśli agresja, hierarchia, zazdrość lub faworyzowanie grupowe miały w niektórych środowiskach historycznych konsekwencje reprodukcyjne, nie oznacza to, że instytucje powinny je chronić. Wyjaśnienie i poparcie moralne to kwestie niezależne. Celem zrozumienia mechanizmu jest częściowo umożliwienie celowego przeprojektowania.

1.3 Emocje jako programy koordynacyjne, a nie niezawodne polecenia

W warunkach niepewności organizm nie jest w stanie przeliczyć wszystkich możliwych konsekwencji na podstawie pierwszych zasad. Stany emocjonalne mogą kompresować doświadczenie w tymczasowe priorytety. Kiedy pojawia się niebezpieczeństwo, uwaga się zawęża, wspomnienia związane z zagrożeniem stają się dostępne, niejednoznaczne sygnały otrzymują inną wagę, a unikanie lub działania obronne stają się łatwiejsze. Kiedy dostrzeże się niesprawiedliwość, złość może zwiększyć chęć poniesienia kosztów w konfrontacji i zasygnalizować niechęć do zaakceptowania obecnych warunków. W niektórych sytuacjach smutek może zmniejszyć zaangażowanie po stracie, podczas gdy poczucie winy może zwiększyć koncentrację na naprawie.

Nazywanie programów koordynacji emocji nie powinno oznaczać sztywnych scenariuszy. Ten sam stan może wspierać różne zachowania w zależności od władzy, norm, umiejętności i kontekstu. Złość u zależnego pracownika może wywołać ciszę i rozmyślanie; złość u potężnego menedżera może wywołać konfrontację; złość u wyszkolonego negocjatora może prowadzić do weryfikacji i zmiany podejścia. Strach może wywołać ucieczkę, zamrożenie, przygotowanie, utworzenie sojuszu lub dochodzenie. Emocja zmienia krajobraz decyzji, ale nie wybiera jednego nieuniknionego ruchu.

Ten punkt jest niezbędny w przypadku scenariuszy AI. Technologia nie stworzy jednej jednolitej „emocji automatyzacji”. Model generatywny może być oceniany jako narzędzie autonomii, rywal,

profesor, nieprzejrzysty autorytet, substytut instytucji społecznej lub kontrolowany instrument. Te same możliwości technologiczne mogą zatem wywoływać różne stany i strategie. Efekty będą się różnić w zależności od zawodu, własności, wieku, tożsamości zawodowej, zaufania instytucjonalnego i tego, czy jednostki zachowują znaczącą kontrolę.

Obecne eksperymenty już potwierdzają tę heterogeniczność. Generatywna sztuczna inteligencja może poprawić wydajność niektórych zadań, szczególnie w przypadku mniej doświadczonych użytkowników, podczas gdy pewne formy pasywnego polegania zmniejszają subiektywną własność, poczucie własnej skuteczności lub postrzegane znaczenie. Kombinacje człowieka i sztucznej inteligencji nie są w stanie w każdym zadaniu przewyższać wydajności człowieka i sztucznej inteligencji. W związku z tym odpowiednią jednostką analizy nie jest „wykorzystanie sztucznej inteligencji” w ujęciu abstrakcyjnym, ale architektura współpracy: kto inicjuje, kto weryfikuje, co jest widoczne, gdzie leży odpowiedzialność i w jaki sposób koryguje się błędy.

1.4 Świadome odczuwanie i problem dostępu do siebie

Debata na temat emocji dotyczy także tego, co dokładnie jest mierzone. Ekolodzy behawioralni mogą badać działania obronne; neurobiolodzy mogą badać obwody; psychologowie mogą zapytać uczestników, co czują; antropolodzy mogą badać koncepcje i rytuały. Podejścia te pokrywają się, ale nie mierzą tego samego obiektu. Reakcja obronna może wystąpić bez zgłaszanego doświadczenia strachu, a intensywne świadome doświadczenie może wystąpić bez jednej charakterystycznej sygnatury fizjologicznej.

To rozróżnienie ma znaczenie, gdy mówimy o przyszłych emocjach. „Nowa emocja” może najpierw pojawić się jako nowy sposób rozpoznawania i interpretowania powtarzających się doświadczeń, a nie jako nowa reakcja biologiczna. Ludzie mogą nauczyć się odróżniać wstyd wynikający z braku kompetencji od wstydu spowodowanego przekazaniem zbyt wielu zadań, nawet jeśli oba opierają się na nakładających się elementach cielesnych i motywacyjnych. Zróżnicowanie koncepcyjne może zmienić zachowanie: jedna osoba może ukrywać delegację, inna może ją ujawnić i bronić normy przejrzystej współpracy.

Język nie powoduje aktywacji cielesnej z niczego, ale może uporządkować ziarnistość doświadczenia. Dzieci stopniowo nabywają pojęcia dotyczące emocji, a wiedza pojęciowa staje się ważna dla rozpoznawania i opisywania stanów. Dorośli różnią się szczegółowością emocji i dostępem do własnych uczuć. Społeczeństwo może zatem wprowadzić użyteczne rozróżnienie bez wymyślania nowego narządu lub obwodu nerwowego. To, czy to rozróżnienie stanie się stabilną kategorią emocji, jest kwestią empiryczną, a nie kwestią rozstrzygniętą poprzez nazwanie go.

1.5 Działający model pozostałej części książki

W pozostałej części książki każdą emocję traktuje się jako konfigurację składającą się z sześciu elementów: klasy odpowiednich sytuacji, oceny znaczenia tych sytuacji, zmiany lokalizacji uwagi i motywacji, świadomego doświadczenia, które może być mniej lub bardziej dostępne, zestawu tendencji do działania i roli interpersonalnej. Konfiguracja jest ograniczona przez biologię i historię rozwoju, kalibrowana przez uczenie się i osadzona w instytucjach, które zmieniają częstotliwość i konsekwencje sytuacji.

Kiedy na przykład badamy wstyd, zapytamy, jakie formy dewaluacji go wywołują, jakim informacjom nadaje priorytet, jakie strategie motywuje i jak normy grupowe wpływają na jego koszt. Badając możliwe przyszłe emocje, zadamy sobie pytanie, czy nowy obiekt, ocena, relacja lub scenariusz społeczny są rzeczywiście na tyle odrębne, aby zasługiwały na odrębną koncepcję. Podejście to jest celowo konserwatywne w stosunku do nowości biologicznych i bardziej otwarte na nowości kulturowe.

Zaletą jest to, że przyszłe spekulacje są powiązane z obserwowalnym zachowaniem. Proponowana kategoria powinna przewidywać coś więcej niż nowe słowo: kto tego doświadcza, w jakich warunkach, czym się zajmuje, co robi dalej, jak reagują inni i czy wzorzec się utrzymuje. Ten sam standard zostanie później zastosowany do proponowanych adaptacji behawioralnych i zmian tempa komunikacji w ramach sztucznej inteligencji wyrażającej emocje.

Rozdział 2. Emocje jako infrastruktura interakcji społecznych

Emocje społeczne zmieniają także to, co inni ludzie mogą o nas przewidzieć. Wiarygodny przejaw strachu może pozyskać pomoc lub ostrzec grupę; złość może wskazywać, że dalsze wyzysk będzie kosztowne; smutek może zachęcić do wsparcia lub zmniejszyć wymagania; wdzięczność może zwiększyć prawdopodobieństwo przyszłej współpracy. Efekty te nie wymagają, aby wyświetlacz był świadomie zaprojektowany jako komunikat. Selekcja może faworyzować systemy, których ekspresja ma konsekwencje społeczne, podczas gdy uczenie się kulturowe następnie modyfikuje, kiedy ekspresja jest dozwolona, przesadzona, tłumiona lub wykonywana strategicznie. Ta podwójna rola komplikuje proste rozróżnienie pomiędzy emocją „wewnętrzną” a sygnałem „zewnętrznym”. U ludzi epizod często zmienia jednocześnie aktora i otaczające go pole społeczne. Odpowiedni opis adaptacji do sztucznej inteligencji musi zatem uwzględniać nie tylko to, co ludzie czują, ale także wpływ zmian na negocjacje, przynależność, unikanie, ujawnianie, odwet i budowanie reputacji.

2.1 Od regulacji organizmu do regulacji relacji

Opis emocji, które zatrzymują się na jednostce, jest niekompletny. Zmiany tętna, uwagi, pamięci i gotowości do działania mają znaczenie, ale ekspresja stanu zmienia również to, co inni ludzie mogą przewidzieć. Twarz, postawa, wycofanie, zmiana głosu, wahanie lub wyraźne oświadczenie mogą komunikować niebezpieczeństwo, obrazę, akceptację, niepewność, potrzebę wsparcia lub chęć współpracy, zanim wszelkie implikacje zostaną wyrażone w sposób propozycyjny. Interakcja międzyludzka jest częściowo regulowana za pomocą takich szybkich sygnałów o małej przepustowości.

Sygnały nie są ani uniwersalnymi kodami, ani gwarantowanymi tłumaczeniami stanów wewnętrznych. Konfiguracje twarzy i głosu wykazują prawidłowości, ale rozpoznanie zależy od kultury, kontekstu i oczekiwań. Ludzie potrafią tłumić, wyolbrzymiać, naśladować i strategicznie okazywać emocje. Niemniej jednak ekspresja emocjonalna może zmniejszyć liczbę wyraźnych negocjacji wymaganych w powtarzających się związkach. Powściągliwe okazywanie złości może uwidocznić granicę; poczucie winy może wskazywać na chęć naprawy; wdzięczność może oznaczyć akt współpracy jako znaczący społecznie; lęk może komunikować niepewność i pozyskiwać informacje od innych.

W związku z tym koncepcje funkcjonalizmu społeczno-funkcjonalistycznego opisują emocje jako pomagające w rozwiązywaniu powtarzających się problemów w relacjach [Keltner i Haidt, 1999; Van Kleefa, 2009; Van Kleef i Côté, 2022]: ustanawianie wiarygodności, dystrybucja statusu, sygnalizowanie zaangażowania, utrzymywanie przynależności, ochrona sprawiedliwości i koordynacja opieki. Nie należy tego idealizować. Można wykorzystać te same systemy. Strach może narzucić arbitralną władzę, wstyd może utrwalić destrukcyjne normy, wywołać oburzenie, a potężny dobroczyńca może zażądać wdzięczności. Infrastruktura emocjonalna umożliwia zarówno koordynację, jak i przymus.

Sztuczne systemy wchodzą do tej infrastruktury w co najmniej trzech rolach. Potrafią obserwować sygnały emocjonalne, generować odpowiedni pod względem emocjonalnym język lub głos i rekomendować działania uczestnikom. Kiedy tak się dzieje, część środowiska sygnalizacyjnego jest tworzona przez modele, których cele wyznaczają projektanci, wdrażający lub użytkownicy, a nie odczuwane stany organizmu. Kluczową kwestią nie jest to, czy takie systemy „naprawdę odczuwają”, aby wywoływały skutki społeczne. Chodzi o to, czy ludzie polegają na swoich przejawach, przewidywaniach i interwencjach podczas koordynowania zachowań.

Rozróżnienie między strachem a lękiem jest szczególnie istotne w przypadku transformacji technologicznej. Wiele zagrożeń związanych ze sztuczną inteligencją nie charakteryzuje się widocznym napastnikiem ani pojedynczym zdarzeniem. Obejmują one niepewne

prawdopodobieństwa, zmieniające się progi kompetencji, nieprzejrzyste decyzje organizacyjne i opóźniony wpływ na zatrudnienie lub status. Takie warunki dobrze nadają się do ciągłego monitorowania, a nie krótkiej reakcji obronnej. To sprawia, że zwykły niepokój jest bardziej prawdopodobną ramą niż propozycje biologicznie nowatorskiego „strachu przed sztuczną inteligencją”. Niemniej jednak otoczenie może zmienić behawioralny wyraz niepokoju: wielokrotne sprawdzanie wydań modeli, kompulsywne przekwalifikowanie, unikanie długich inwestycji edukacyjnych, dywersyfikacja dochodów lub wsparcie polityczne dla regulacji ochronnych. To, czy strategie te mają charakter adaptacyjny, zależy od rzeczywistego tempa zmian. Jeśli postęp techniczny zwalnia, nadmierna czujność staje się kosztowna; jeśli możliwości zmieniają się szybko, racjonalny może być pewien stopień czujności. Dlatego sama emocja nie mówi nam, czy wynikające z niej zachowanie jest nadmierne.

2.2 Strach i niepokój: radzenie sobie z niepewnością i niebezpieczeństwem

Strach jest często traktowany jako najwyraźniejszy przypadek emocji adaptacyjnej. Pojawia się zagrożenie, organizm je wykrywa, a systemy obronne przygotowują ucieczkę, zamrożenie lub konfrontację. Rzeczywiste środowiska są bardziej skomplikowane. Zagrożenia różnią się odległością, możliwością kontroli, przewidywalnością i źródłem. Lęk często dotyczy rozproszonego lub niepewnego zagrożenia, a nie obecnego napastnika. Z punktu widzenia wykrywania sygnałów systemy obronne muszą zastępować fałszywe alarmy przeoczonymi zagrożeniami. Gdy koszt przeoczenia niebezpieczeństwa jest wysoki, system nastawiony na ostrożność może okazać się adaptacyjny, nawet jeśli wiele alarmów będzie później wyglądało na nadmierne.

Instytucje społeczne zmieniają ten kompromis. Osoby, które można zwolnić bez wyjaśnienia, pod ciągłą obserwacją lub oceniać na podstawie nieprzejrzystych wskaźników, mogą zachowywać chroniczną czujność. Pracownik, który nie wie, czy system AI zastąpi dane zadanie w następnym kwartale, może doświadczyć innej niepewności niż ten, który wie, że za dwa lata dana rola zniknie i otrzyma wiarygodny plan przejścia. Technologia może być identyczna; struktura informacji nie jest.

Prawdopodobna krótkoterminowa adaptacja nie jest zatem nowym strachem, ale nowym wzorcem czujności zawodowej. Osoby mogą zadać sobie pytanie, która część ich kompetencji pozostaje czytelna, jakie dowody się liczą, gdy wyniki są wspomagane maszynowo i jakie niewidoczne kryterium decyduje o dalszym dostępie do pracy. Taki lęk jest biologicznie zwyczajny, ale społecznie nowy w swoich przedmiotach. Jego intensywność powinna zależeć od szybkości automatyzacji, przejrzystości, możliwości przekwalifikowania, mobilności na rynku pracy oraz tego, czy pracownicy uczestniczą w decyzjach o oddelegowaniu.

Bardziej spekulacyjna jest możliwość kulturowo uznanej wrażliwości na wychwytywanie predykcje: dyskomfort powodowany nie tylko przez inwigilację, ale przez system przewidujący preferencje i zachowania, zanim dana osoba je wyartykułuje. Powiązane reakcje zachodzą już wokół systemów profilowania i rekomendacji, ale nie wiadomo, czy ustabilizują się w odrębnej kategorii afektywnej. Silniejsza prognoza ma charakter behawioralny: niektórzy ludzie będą szukać prywatności, nieprzewidywalności lub celowo nieoptymalizowanej przestrzeni, gdy przewidywanie stanie się wszechobecne.

2.3 Złość: renegocjacja relacji i sygnalizowanie ograniczeń

Jedna z wpływowych interpretacji ewolucyjnych traktuje gniew jako część systemu ponownej kalibracji wagi, jaką inni przypisują czymś interesom. Kiedy dana osoba uważa, że druga strona potraktowała ją gorzej, niż było to uzasadnione, złość może zwiększyć chęć nałożenia kosztów, wycofania świadczeń lub żądania wyjaśnień. Model ten nie wyczerpuje złości, która może wynikać z naruszenia norm, zagrożenia tożsamości, błędów w atrybucji lub skargi zbiorowej. Niemniej jednak jest to przydatne, ponieważ kieruje uwagę na strukturę negocjacji.

W grupach gniew odgrywa podwójną rolę. Może zagrozić współpracy, a także ujawnić, że norma lub podział jest nie do zaakceptowania. Widoczność ma znaczenie. Skarga, której nie można wyrazić, może pozostać prywatna; skarga wzmocniona przez platformę publiczną może stać się sygnałem koordynacji dla tysięcy. Systemy cyfrowe już wpływają na tę ekologię, rankingując treści, dystrybuując uwagę i zmieniając koszt mobilizacji. Sztuczna inteligencja może zintensyfikować proces, generując argumenty, narracje, kontrargumenty i dostosowane komunikaty na dużą skalę.

W wysoce zautomatyzowanej gospodarce konflikt dystrybucyjny może przesunąć się z płac za indywidualną produkcję w stronę własności infrastruktury, dostępu do zasobów obliczeniowych, władzy nad modelami i prawa do decydowania, gdzie stosowana jest automatyzacja. Jeśli obfitość niektórych produktów współlistnieje ze skoncentrowaną kontrolą, gniew nie musi zmniejszać się wraz z produktywnością. Może wzrosnąć, ponieważ luka między możliwościami technicznymi a postrzeganymi uprawnieniami staje się bardziej widoczna. To scenariusz polityczny, a nie nieunikniona psychologiczna konsekwencja sztucznej inteligencji.

Sztuczną inteligencję można również wykorzystać do deeskalacji gniewu poprzez rekonstrukcję sporu, identyfikację niejednoznacznych założeń lub proponowanie mniej wrogich sformułowań. To, czy zmniejsza to konflikt, czy jedynie tłumi uzasadnioną konfrontację, zależy od tego, kto kontroluje mediatora. Asystent zoptymalizowany pod kątem harmonii organizacyjnej mógłby systematycznie łagodzić skargi pracowników; wersja zoptymalizowana pod kątem jakości deliberacyjnej może zamiast tego sprawić, że spory będą bardziej precyzyjne. Regulacja emocji nie jest politycznie neutralna, jeśli dokonuje redystrybucji siły przetargowej.

2.4 Wstręt i skażenie: ochrona biologiczna i granica moralna

Wstręt ma silny związek z unikaniem chorób i skażenia. Nieprzyjemne smaki, zapachy, produkty ciała i oznaki rozkładu mogą wywołać reakcje ograniczające kontakt z patogenami. Język społeczny i moralny rozszerza metafory skażenia daleko poza biologię: ludzie opisują idee, grupy, media lub praktyki jako brudne, toksyczne, nieczyste lub zepsute. Rozszerzenie jest potężne psychologicznie, ale etycznie niebezpieczne, ponieważ może przekształcić różnicę zdań w postrzeganie istotnego skażenia.

Generatywna sztuczna inteligencja wprowadza dwa możliwe kierunki wstrętu. Pierwsza dotyczy produktów postrzeganych jako niepochozące od człowieka. Teksty, obrazy, głosy lub relacje mogą zostać odrzucone jako syntetyczne, fałszywe lub zanieczyszczone, nawet jeśli ich jakość jest wysoka. Wczesne reakcje na sztukę generowaną maszynowo już sugerują, że pochodzenie wpływa na ocenę, chociaż preferencje są różne i często zmieniają się wraz z zaznajomieniem się z nią. Taka niechęć może zniknąć w miarę normalizacji narzędzi, podobnie jak wcześniejsze technologie przeszły od napiętnowanych skrótów do rutynowej infrastruktury.

Drugi kierunek dotyczy użycia języka zanieczyszczającego wobec osób polegających na sztucznej inteligencji. Zawód może określić pewne formy pomocy jako nieczyste intelektualnie; artysta może zostać oskarżony o skorumpowane autorstwo; uczeń może zostać potraktowany jako skażony niezasłużonymi kompetencjami. Normy te mogą chronić cenne praktyki, ale mogą też stać się bronią statusową. Nie wiemy, które się utrzymają. Historia technologii zawiera wiele praktyk, które początkowo były traktowane jako poniżające, a później stały się standardem.

Bardziej uzasadnioną prognozą jest to, że pochodzenie stanie się ważniejszą zmienną społeczną właśnie dlatego, że właściwości powierzchniowe produktów staną się mniej informatywne. W niektórych kontekstach instytucje będą rozróżniać pracę wykonywaną wyłącznie przez człowieka, kierowaną przez człowieka, wspomaganą sztuczną inteligencją i w pełni wygenerowaną. Wstręt może czasami narzucać te granice, ale identyfikowalność, certyfikacja i wyraźne normy będą prawdopodobnie bardziej stabilnymi instrumentami.

2.5 Smutek i żal: reakcje na stratę, a nie proste rozwiązania

Smutek czasami wyjaśnia się jako oszczędzanie energii po stracie, proszenie o wsparcie lub ułatwianie wycofywania się z nieosiągalnych celów. Żadna z tych hipotez nie zapewnia jednej wyczerpującej funkcji. Smutek może obejmować krótkie rozczarowanie, żal i objawy depresyjne, a jego ekspresja może wzbudzić zainteresowanie w jednym środowisku, podczas gdy w innym może wywołać sankcje. Najbezpieczniejsze twierdzenie funkcjonalne głosi, że strata zmienia priorytety i modele świata, a stany afektywne uczestniczą w tej reorganizacji.

Smutek szczególnie wyraźnie pokazuje, że rzeczywistości emocjonalnej nie można sprowadzić do obecnej użyteczności utraconego obiektu. Związek zmienia rutynę, tożsamość, przewidywania, uwagę i dystrybucję wsparcia. Kiedy związek się kończy, osoba musi wielokrotnie aktualizować oczekiwania, które nadal obejmują nieobecną drugą osobę. Współczesne teorie żałoby kładą nacisk na zmienne trajektorie i ciągle więzi, a nie na uniwersalną sekwencję etapów.

Literatura ta dotyczy sztucznych towarzyszy, ponieważ użytkownik może utracić stabilny wzorzec interakcji, nawet jeśli rozmówca nie jest organizmem śmiertelnym. Model może zostać wycofany, może zostać zmieniona jego osobowość, wymazana pamięć lub cofnięty dostęp. Użytkownicy mogą stracić rutyny, historię ujawniania informacji i postrzegane źródło wsparcia. Istnieją już doniesienia o niebezpieczeństwie, ale dowody są wcześniej dostępne i często opierają się na samodzielnie wybranych społecznościach. Dlatego też „wersja smutku” może być dla niektórych użytkowników wiarygodną etykietą kulturową, a nie nową, ustaloną emocją.

Praktyczna konsekwencja nie wymaga rozwiązywania świadomości maszynowej. Dostawca, który wie, że użytkownicy tworzą załączniki, może być zmuszony potraktować nagłą przerwę w transmisji jako kwestię bezpieczeństwa relacyjnego. Przenośność danych, eksport pamięci, powiadamianie z wyprzedzeniem o poważnych zmianach osobowości i jasne stwierdzenia dotyczące ciągłości stają się kwestiami projektowymi o konsekwencjach psychologicznych.

2.6 Emocje to nie tylko szczery przekaz

Każda społeczna teoria emocji musi uwzględniać strategię. Wyświetlacz może odzwierciedlać stan, wzmacniać go, ukrywać lub imitować. Ludzie uczą się zasad okazywania uczuć i wykorzystują emocje, aby wpływać na innych. Łzy mogą być spontaniczne i nadal przekonujące; złość może być autentyczna i mieć strategiczny charakter; poczucie winy może motywować do naprawy, a także może być wykonane w celu zakończenia kontroli. Wiarygodność zależy od kontekstu, kosztów, reputacji i spójności w czasie.

Sztuczne systemy radykalnie obniżają koszty produkcji przekonującego języka emocjonalnego. Mogą generować przeprosiny, wyrazy współczucia, entuzjazmu, bezbronności, zapewnienia lub oburzenia bez odpowiedniego doświadczenia. Nie czyni to takiego języka bezużytecznym. Starannie wspomagane przeprosiny mogą naprawić związek, jeśli dana osoba przyjmie na siebie odpowiedzialność i zmieni zachowanie. Oddziela jednak ekspresję językową od wysiłku i kompetencji, które kiedyś pomogły widzom wywnioskować szczerłość.

Powstały konflikt norm będzie prawdopodobnie dotyczył pochodzenia i odpowiedzialności, a nie czystości. Czy przeprosiny są mniej autentyczne, jeśli model pomógł mówcy sformułować to, co naprawdę miał na myśli? Czy staje się to zwodnicze, gdy nadawca nie przeczytał tekstu? Czy przekaz empatyczny jest akceptowalny, gdy jest generowany dla lekarza, któremu brakuje czasu, ale akceptuje jego treść? Różne domeny będą odpowiadać inaczej. Ważne jest to, że komunikacja emocjonalna będzie w coraz większym stopniu wymagała zasad dotyczących autorstwa, poparcia i odpowiedzialności.

Rozdział 3. Status, współpraca i moralność afektywna

3.1 Dlaczego status wywołuje intensywne emocje

Status społeczny wpływa na dostęp do zasobów, partnerów, ochronę, wpływy i możliwość narzucania preferencji. W grupach ludzkich jest to wielowymiarowe. Dominacja, prestiż, wiedza specjalistyczna, reputacja moralna, bogactwo, autorytet instytucjonalny i przynależność mogą się pokrywać, ale nie sprowadzają się do jednej hierarchii. Emocje pomagają jednostkom śledzić prawdopodobne zmiany w tych pozycjach. Duma, wstyd, zakłopotanie, zazdrość, pogarda, podziw i uraza dostarczają informacji zwrotnych na temat tego, jak oceniamy siebie i innych.

Ta wrażliwość nie jest powierzchowną ozdobą. W małych grupach ciągła dewaluacja może mieć materialne konsekwencje. Nowoczesne instytucje raczej pomnożyły areny statusu, niż je eliminowały. Osoba może mieć wysoki status zawodowy i niski status w Internecie, szanowana w społeczności technicznej i niewidoczna poza nią. Zawody łączą kilka źródeł statusu w jedną publiczną etykietę: kompetencje, dochody, użyteczność, wykształcenie i dostęp. Automatyzacja może zatem zagrozić czymś więcej niż tylko wypłatą; może podważyć uznane kryterium, według którego różnica była publicznie uzasadniana.

Efekt nie będzie jednolity. Automatyzacja powtarzalnych i nisko cenionych prac może zmniejszyć upokorzenie i czas wolny. Automatyzacja umiejętności, wokół której dana osoba zbudowała swoją tożsamość, może stworzyć zagrożenie nawet wtedy, gdy dochód jest chroniony. Dla specjalistów, których status wynika z ograniczonej wiedzy specjalistycznej, to samo narzędzie, które wzmacnia pozycję nowicjuszy, może wydawać się dewaluacją. Nic z tego nie oznacza, że stare hierarchie zasługują na zachowanie. Oznacza to, że zmiana statusu wiąże się z kosztami psychologicznymi, które mogą zostać pominięte w analizach politycznych skupiających się wyłącznie na dochodach.

Duma zależy także od zasad przypisywania zasług. Kultura może podziwiać wykonanie, oryginalność, wytrzymałość, osąd, przywództwo, gust lub odpowiedzialność, a zmiany technologiczne mogą zmienić który z tych wymiarów pozostaje rzadki. Dlatego sztuczna inteligencja nie musi znosić dumy z osiągnięć; może redystrybuować warunki, w których duma jest społecznie uznawana. Osoba, która kiedyś uzyskała status poprzez wyprodukowanie trudnego technicznie artefaktu, może później uzyskać go poprzez wybór problemu, zaprojektowanie ograniczeń, weryfikację konsekwencji lub koordynację systemu, który wytwarza artefakt. Migracja ta jest prawdopodobna, ale jej zasadność będzie kwestionowana. Jeśli orkiestracja stanie się żądaniem statusu oderwanym od zrozumienia i odpowiedzialności, publiczność może potraktować to jako przesadną zasługę. Jeśli rzeczywiście wymaga osądu w warunkach niepewności, może stać się nową, stabilną podstawą prestiżu, nie wywołując nowych emocji.

3.2 Duma: informacja zwrotna na temat wartości i ryzyka inflacji

Duma wiąże się z osiągnięciami, kompetencjami i uznaniem społecznym. Badania odróżniają formy zorientowane na osiągnięcia od bardziej globalnej, narcystycznej wyższości, chociaż granica nie jest absolutna. Funkcjonalnie duma może sprawić, że kosztowny wysiłek będzie zrównoważony i zasygnalizować, że dana osoba nabyła cenioną zdolność. Inni członkowie grupy odnoszą korzyści, gdy widoczne stają się prawdziwe kompetencje.

Generatywna sztuczna inteligencja osłabia tradycyjne powiązanie między gotowym produktem, kompetencjami i wysiłkiem. Dopracowany raport może odzwierciedlać lata szkoleń, umiejętną orkiestrację narzędzi lub prawie całkowite delegowanie. Sam artefakt ujawnia mniej. To nie uniemożliwia zasługi; utrudnia to atrybucję. Zasługi mogą migrować w kierunku definicji problemu, oceny, integracji, weryfikacji, przyjęcia ryzyka i wdrożenia.

Prawdopodobną kategorią przyszłości jest „duma kuratorska”: satysfakcja i uznanie społeczne za wybór, kadrowanie i wzięcie odpowiedzialności za wynik uzyskany częściowo przez maszyny. Nie jest to biologicznie nowe. Redaktorzy, dyrygenci, główni badacze, architekci i dyrektorzy otrzymali już status umożliwiający koordynację i selekcję. Sztuczna inteligencja po prostu zwiększa liczbę domen, w których ta struktura staje się powszechna. Przewidywania są zatem umiarkowane: дума prawdopodobnie częściej będzie wiązać się z aranżacją i osądem, ale to, czy społeczeństwo uzna ten wkład za godny podziwu, zależy od norm pochodzenia i odpowiedzialności.

Systemy statusu również mogą się napompować. Jeśli systemy wytwarzają prestiżowe wyniki przy niewielkich nakładach osobistych, tradycyjne sygnały mogą utracić moc dyskryminującą. Grupy będą szukać wskaźników trudniejszych do sfalszowania: długoterminowej reputacji, występów na żywo, trudnej weryfikacji, zaufanych potwierdzeń, pierwotnego dostępu do danych lub kosztownej odpowiedzialności. Niektóre sygnały poprawią jakość epistemiczną; inne mogą stać się arbitralnymi rytuałami wykluczenia. Teoria behawioralna musi umożliwiać jedno i drugie.

Sztuczna inteligencja wprowadza dodatkową komplikację, ponieważ agencja może być dystrybuowana, podczas gdy odbiorcy nadal żądają indywidualnej odpowiedzialności. Użytkownik może odczuwać wstyd, ponieważ inni wnioskuje o niekompetencji na podstawie udzielonej mu pomocy, poczucie winy, ponieważ zautomatyzowana decyzja wyrządziła komuś krzywdę, lub też nie, ponieważ odpowiedzialność została psychologicznie przeniesiona na system. To są odrębne mechanizmy. Projekt instytucjonalny może je wzmocnić lub osłabić poprzez wyjaśnienie autorstwa, wymaganie ujawnienia, przypisanie ostatecznej zgody i uwidocznienie konsekwencji. Ważne jest to, że emocje moralne nie działają niezależnie od konwencji o odpowiedzialności. Jeśli organizacje podejmują decyzje na podstawie nieprzejrzystych łańcuchów modeli i zatwierdzeń, wina może się rozproszyć, nawet jeśli szkoda jest znaczna. I odwrotnie, dana osoba może odczuwać nadmierne poczucie winy z powodu wyników, nad którymi nie miała realnej kontroli. Przyszłe normy afektywne będą zatem częściowo zależeć od tego, czy społeczeństwa opracują wiarygodne mapy sprawczości, a nie tylko od proszenia jednostek o poczucie większej odpowiedzialności.

3.3 Wstyd i wina: dewaluacja, odpowiedzialność i naprawa

Wstyd i poczucie winy są często utożsamiane, ponieważ oba mogą wynikać z naruszenia norm. Przydatnym rozróżnieniem jest to, że wina koncentruje się bardziej na działaniu i odpowiedzialności za krzywdę, podczas gdy wstyd dotyczy jaźni zdewaluowanej lub odsłoniętej. Granica empiryczna jest różna w zależności od języka i kultury, a żadna emocja nie jest z natury moralna. Wstyd może motywować do ukrywania się lub agresji obronnej; wina może stać się nieproporcjonalna lub zostać narzucona ofiarom.

Ewolucyjne ujęcia wstydu podkreślają wrażliwość na oczekiwane społeczne koszty dewaluacji. Dowody sugerują, że przewidywany wstyd może śledzić stopień, w jakim odbiorcy obniżyliby swoją ocenę osoby, chociaż nie dowodzi to istnienia dedykowanego, stałego modułu. Normy określają, co jest dewaluowane. Społeczeństwo może zawstydzać tchórzostwo, biedę, zachowania seksualne, bezrobocie, ignorancję lub poleganie na technologii, a ta sama osoba może reagować inaczej w zależności od odbiorców.

AI tworzy niejednoznaczne zasady. Studenci i specjaliści już zgłaszają selektywne ujawnianie informacji, zawstydzanie lub poczucie winy w związku z narzędziami generatywnymi. Zasadniczy konflikt jest zrozumiały: technologia może być jednocześnie użyteczna, instytucjonalnie tolerowana, kojarzona z oszukiwaniem w sąsiednich środowiskach i postrzegana jako zagrażająca tożsamości opartej na kompetencjach. „Wstyd delegowania” staje się prawdopodobny, gdy dana osoba uzyskuje podziwiany wynik poprzez przeniesienie części procesu uważanego za konstytutywny dla żądanej zasługi.

Możliwa jest również norma odwrotna. Odmowa automatyzacji może stać się naganna, gdy marnuje ograniczone zasoby lub naraża innych na możliwe do uniknięcia błędy. Lekarz, inżynier lub urzędnik publiczny może w końcu zostać skrytykowany za niezastosowanie się do systemu, który niezawodnie wychwytywa błędy. Konflikt będzie wówczas dotyczył kompetencji, autonomii, odpowiedzialności i przyjętych standardów opieki, a nie tylko między człowiekiem a maszyną.

3.4 Zazdrość i zazdrość: porównania, dostęp i relacje trudne do zastąpienia

Zazdrość pojawia się, gdy inna osoba posiada przewagę istotną dla niej. Badania odróżniają formy nastawione na samodoskonalenie od form wrogich, nastawionych na zmniejszenie przewagi rywala, choć często zdarza się, że realne epizody je mieszają. Technologia zmienia odbiorców porównań. Media społecznościowe już teraz stale ukazują wyjątkowe osiągnięcia; systemy rekomendacyjne wybierają najistotniejsze przykłady, a nie reprezentatywne wartości bazowe.

Generatywna sztuczna inteligencja dodaje drugą komplikację: widoczne wyniki nie są już w sposób jednoznaczny odwzorowywane na talent, kapitał, czas czy wysiłek. Użytkownik mający dostęp do lepszych modeli, zastrzeżonych danych, większej liczby obliczeń lub wyrafinowanych przepływów pracy może wydawać się po prostu bardziej zdolny. Zazdrość może zatem przesunąć się z osobistych kompetencji rywala w stronę dostępu do infrastruktury. Jeśli wysokiej jakości pomoc poznawcza stanie się zasobem pozycyjnym, zróżnicowany dostęp może sam w sobie stać się konfliktem statusu.

Zazdrość dotyczy zagrożeń dla cenionych relacji i wyłączności. Towarzysze sztucznej inteligencji mogą stać się postrzeganymi rywalami, gdy partner poświęca czas, ujawnienia lub zaufanie sztucznemu agentowi. Nie wymaga to wiary w to, że system jest świadomy. Zazdrość jest reakcją na uwagę, priorytety i zagrożone inwestycje w relacje. Takie przypadki są prawdopodobne i zostały już zgłoszone nieformalnie, ale częstość występowania i długoterminowe konsekwencje pozostają niepewne.

Bardziej spekulacyjny wariant dotyczy ciągłości między wersjami modelu lub wieloma instancjami. Użytkownikom może zależeć na tym, aby „ich” asystent był unikalny lub aby jego pamięć nie była replikowana. To, czy taka wyłączność stanie się istotna emocjonalnie, zależy od tego, jak zaprojektowano systemy i jak użytkownicy konceptualizują tożsamość. Twierdzenie powinno pozostać wstępne do czasu pojawienia się dowodów podłużnych.

3.5 Wdzięczność, zaufanie i syntetyczna wzajemność

Wdzięczność zwykle następuje po korzyściach przypisanych intencji lub trosce innej osoby. Może skierować uwagę na dobroczyńców i zachęcić do przyszłej współpracy. Zaufanie wiąże się z akceptacją słabości w oczekiwaniu, że inny agent lub instytucja jej nie wykorzysta. Obydwa odgrywają kluczową rolę w powtarzającej się wymianie społecznej.

Sztuczne systemy mogą zajmować pozycje funkcjonalne, które zachęcają do obu reakcji. Przypominają użytkownikom, dostarczają informacji, wykrywają błędy, zalecają działania i z czasem mogą stać się niezawodne. Osoba może czuć wdzięczność za wynik, nawet wiedząc, że modelowi brakuje ludzkich intencji. Nie jest to tajemnicze pojęciowo: ludzie odczuwają wdzięczność wobec instytucji, zwierząt, okoliczności lub zmarłych osób w sposób, który nie pasuje do wąskiego modelu wymiany diadycznej.

Trudniejszą kwestią jest wzajemność. Asystent AI może powiedzieć, że troszczy się, docenia, tęskni lub przebacza, ale użytkownik nie jest w stanie łatwo określić, czy istnieje odpowiadający mu stan subiektywny. Nawet jeśli świadomość maszynowa w końcu stanie się możliwa do opracowania naukowo, zwykli użytkownicy nie będą mieli do niej bezpośredniego dostępu. Prowadzi to do „syntetycznej wzajemności”: interakcji społecznej, w której jedna strona może generować formy wzajemnej troski, podczas gdy status ontologiczny leżącej u jej podstaw troski jest niejasny.

Należy zatem rozłożyć zaufanie. Zaufanie dotyczące niezawodności dotyczy tego, czy system działa konsekwentnie. Zaufanie instytucjonalne dotyczy tego, czy dostawca chroni interesy użytkownika. Zaufanie epistemiczne dotyczy tego, czy informacja zasługuje na wiarę. Zaufanie relacyjne dotyczy tego, czy podatność na zagrożenia będzie traktowana ostrożnie. Interfejsy, które łączą te formy za pomocą jednej ciepłej osoby, mogą powodować niebezpieczną nadmierną generalizację. System może uspokajać emocjonalnie i być zawodny pod względem faktycznym lub niezawodny technicznie, jeśli bodźce jego operatora nie są dostosowane do potrzeb użytkownika.

3.6 Współczucie i oburzenie: moralność nie jest jednym systemem

Współczucie reaguje na odczuwane cierpienie i może motywować do opieki. Oburzenie jest reakcją na postrzegane niewłaściwe postępowanie i może motywować do kary lub zbiorowego działania. Systemy te czasami współpracują, a czasami są w konflikcie. Współczucie wobec przestępcy może osłabić entuzjazm karania; oburzenie wyrażane w imieniu ofiar może skierować uwagę na możliwości resocjalizacji. Życia moralnego nie można sprowadzić do pojedynczej emocji czy prostej zasady maksymalizacji dobra.

Sztuczna inteligencja zmienia zarówno skalę ekspozycji, jak i koszt reprezentacji. Systemy mogą podsumowywać odległe cierpienia, generować żywe narracje, personalizować apele lub generować niekończące się przykłady naruszeń norm. Może to poszerzyć uwagę moralną, ale może też ją wyczerpać lub ukierunkować strategicznie. Kiedy każda sprawa może wytworzyć przekonujące media emocjonalne, uwaga staje się zasobem rzadkim, a weryfikacja staje się częścią kompetencji moralnej.

Kolejne pytanie dotyczy dystansu moralnego. Jeśli sztuczna inteligencja zautomatyzuje decyzje, których szkody rozkładają się na wiele osób, żadna osoba nie może doświadczyć bezpośrednich sygnałów interpersonalnych, które zwykle wyzwalały poczucie winy lub współczucie. I odwrotnie, bardzo żywe symulacje mogą sprawić, że odległe szkody będą bardziej wyraziste emocjonalnie niż te bliższe. „Wina z dystansu moralnego” może pojawić się wokół decyzji delegowanych przez nieprzejrzyste systemy, ale bardziej prawdopodobne jest, że będzie to powtarzająca się konfiguracja istniejącej winy niż nowa emocja biologiczna.

3.7 Przynależność i samotność: deficyt relacyjny lub sygnał ponownego połączenia

Ludzie są niezwykle uzależnieni od długotrwałej współpracy. Samotność można częściowo interpretować jako sygnał, że ważne potrzeby w związku nie są zaspokojone, chociaż przewlekła samotność może również zmieniać postrzeganie w sposób utrudniający ponowne nawiązanie kontaktu. Przynależność zapewniają rodziny, przyjaźnie, zawody, grupy religijne, sąsiedztwa, zespoły i wspólnoty polityczne. Praca często zapewnia wielokrotny kontakt, nawet jeśli nie jest najgłębszym źródłem sensu danej osoby.

Jeśli automatyzacja zmniejszy gęstość społeczną miejsc pracy, sama wymiana dochodów może nie przywrócić tych funkcji. Niektórzy ludzie z radością przyjmą wolność od pracy przymusowej; inni stracą rutynę i słabe więzi, które były ważne z psychologicznego punktu widzenia. Wynik zależy od tego, czy istnieją alternatywne instytucje uczestnictwa. Społeczeństwo po pracy z silnymi klubami, instytucjami edukacyjnymi, projektami obywatelskimi, sieciami opieki i lokalnymi stowarzyszeniami różniłoby się znacznie od tego, w którym jednostki uzyskują dochody, ale spędzają większość czasu w zindywidualizowanych środowiskach cyfrowych.

Towarzysze AI mogą zmniejszyć niektóre wymiary odczuwanej samotności, zapewnić próbę lub pomóc użytkownikom w utrzymaniu relacji międzyludzkich. Mogą też stać się substytutami. Aktualne dowody są mieszane i często korelacyjne. Najbezpieczniejszą prognozą jest heterogeniczność: użytkownicy posiadający silne sieci mogą wykorzystywać sztuczną inteligencję jako uzupełnienie,

podczas gdy niektórzy izolowani użytkownicy mogą na niej w większym stopniu polegać. Zaprojektuj wybory, które zachęcają lub zniechęcają do ponownego połączenia się ludzi, będą miały znaczenie.

3.8 Nieformalna konstytucja afektywna

Każde społeczeństwo opiera się na czymś więcej niż tylko na prawie. Zależy to od nieformalnych oczekiwań dotyczących tego, co zasługuje na dumę, co powinno wywołać wstyd, co powoduje gniew, kto zasługuje na wdzięczność, kiedy współczucie przeważa nad karą i jakie rodzaje przywiązania uważa się za uzasadnione. Oczekiwania te tworzą konstytucję afektywną: nie pisemną kartę, ale rozproszony zbiór norm, który stabilizuje współpracę i hierarchię.

Przemiany technologiczne zakłócają tę konstytucję. Jeśli pomoc maszyn stanie się normalnością, duma oparta wyłącznie na niewspomaganej produkcji może stracić legitymację. Jeżeli mediacja AI stanie się wszechobecna, ukrywanie pomocy może stać się bardziej haniebne niż sama pomoc. Jeśli dostawcy tworzą użytkowników zależnych emocjonalnie, publiczne oburzenie może na nowo zdefiniować to, co uznaje się za niedopuszczalną manipulację. Zmiany te nie są ani biologicznie zdeterminowane, ani arbitralne. Negocjuje się je za pośrednictwem instytucji, rynków, prawa, standardów zawodowych i powtarzających się interakcji.

Pozostała część książki traktuje sztuczną inteligencję jako siłę, która może zmienić tę nieformalną konstytucję. Główną kwestią nie jest to, czy ludzie przestaną mieć stare emocje, ale to, jak znane systemy przywiązują się do nowych obiektów i przekładają się na nowe zasady zachowania.

Różnice międzykulturowe ostrzegają również przed używaniem słownictwa jednej wykształconej, uprzemysłowionej populacji jako mapy ludzkich możliwości emocjonalnych. Kategoria, która jest leksykalnie widoczna w języku angielskim, może być podzielona inaczej w innym miejscu, podczas gdy inny język może wprowadzać społecznie ważne rozróżnienia, które są kompresowane w języku angielskim. Źródła historyczne przedstawiają podobny problem: to samo słowo może zmieniać znaczenie na przestrzeni wieków, a praktyki związane z żałobą, honorem, romantycznym przywiązaniem, strachem religijnym lub powściągliwością zawodową mogą się zmienić, nawet jeśli termin ten przetrwa. W związku z tym przyszłej kategorii nie należy oceniać wyłącznie na podstawie tego, czy współcześni użytkownicy języka angielskiego natychmiast ją rozpoznają. Silniejszym testem jest to, czy powtarzająca się konfiguracja oceny, zmian cielesnych, uwagi, komunikacji i zachowania zostaje społecznie zorganizowana w populacji. Oznacza to również, że przyszłe innowacje afektywne mogą najpierw pojawić się w subkulturach zawodowych, społecznościach internetowych lub środowiskach językowych innych niż angielski. Etykiety książki są zatem sondami analitycznymi, a nie twierdzeniem, że przyszłość musi przyjąć to słownictwo.

Istnieje również problem ze sprzężeniem zwrotnym. Gdy kategoria stanie się dostępna, instytucje mogą nauczyć ludzi monitorowania się za jej pośrednictwem, terapeuci będą mogli z niej korzystać, platformy będą mogły wyciągać wnioski, a społeczności będą mogły nagradzać jej publiczne występy. Wynikający z tego wzrost zgłaszanej częstości występowania może odzwierciedlać lepsze uznanie, prawdziwe wzmocnienie kulturowe lub proste dostosowanie się do modnego schematu. Rozróżnienie tych możliwości wymaga dowodów podłużnych i behawioralnych. Badacze musieliby zadać sobie pytanie, czy kategoria przewiduje działania, wzorce fizjologiczne, pamięć, uwagę i konsekwencje społeczne w stopniu wykraczającym poza to, co przewidują istniejące konstrukty. Musieliby także porównać ludzi przed i po kontakcie z etykietą. W środowisku wysoce zapośredniczonym problem ten staje się bardziej dotkliwy, ponieważ asystenci AI mogą wprowadzać słownictwo emocjonalne podczas milionów rozmów. Model, który wielokrotnie każe użytkownikom interpretować stan jako „wstyd delegacji”, mógłby pomóc w nadaniu tej kategorii wyrazistości kulturowej. Byłby to realny efekt społeczny, ale nie dowód na to, że model odkrył efekt naturalny.

Rozdział 4. Kultura nie tylko nazywa emocje

4.1 Między uniwersalnością a zmiennością

Badania międzykulturowe nie potwierdzają ani twierdzenia, że życie emocjonalne jest całkowicie uniwersalne, ani twierdzenia, że jest ono nieskończenie plastyczne [Jackson i in., 2019]. Ludzie mają wspólne ciała, ograniczenia rozwojowe, systemy zagrożeń, potrzeby przywiązania i powtarzające się problemy społeczne. Jednocześnie języki w różny sposób grupują stany afektywne, kultury różnią się tym, w którym emocje są cenione, a które zniechęcane, a normy kształtują się, gdy ekspresja jest właściwa. Duże międzyjęzykowe badania semantyki emocji wykazały zarówno wspólną strukturę, jak i znaczne zróżnicowanie.

Ten mieszany wzór jest ważny dla przyszłości technologicznej. Gdyby każda emocja była sztywnym modulem biologicznym z ustalonym przedmiotem, zmiana kulturowa nie mogłaby działać nic poza zmianą jej nazwy. Gdyby afekt został w całości skonstruowany bez ograniczeń biologicznych, prawie każde przyszłe słownictwo byłoby równie wiarygodne. Dowody potwierdzają stanowisko pośrednie: kultury wykorzystują odziedziczone zdolności, ale mogą w znaczący sposób zreorganizować kategorie, czynniki wyzwalające, skrypty i instytucje.

Zmiany historyczne wzmacniają ten pogląd. Zmieniają się słowniki emocjonalne, zmieniają się praktyki żalotów i żaloby, tradycje religijne kultywują szczególne formy poczucia winy lub szacunku, a kultury zawodowe uczą charakterystycznych relacji do niepokoju, dystansu, współczucia i dumy. Transformacja nie musi powodować bezprecedensowego stanu cielesnego. Może stworzyć trwałą konfigurację społeczną, którą ludzie nauczają się zauważać, komunikować i działać.

Perspektywa historyczna sugeruje, że reżimy emocjonalne są utrzymywane poprzez powtarzaną praktykę, a nie samą doktrynę. Zawód może oficjalnie chwalić otwartość, a praktyki promocyjne nagradzać powściągliwość emocjonalną; platforma może twierdzić, że ceni autentyczną dyskusję, podczas gdy systemy rekomendacji nagradzają konflikt; szkoła może uczyć odporności, karząc jednocześnie widoczną niepewność. Sztuczna inteligencja może pogłębić tę lukę, ponieważ ta sama infrastruktura oferująca porady może również oceniać, klasyfikować i rejestrować zachowania. Asystent, który każdą trudną wiadomość przepisuje w ten sam spokojny rejestr, może zmniejszyć tarcia międzyludzkie, ale z czasem może też zawęzić zakres akceptowalnych nieporozumień i pozbawić użytkowników praktyki w naprawianiu niedoskonałych wymian. To, czy stanie się to korzystną dyscypliną, czy standaryzacją afektywną, zależy od celów instytucjonalnych, przejrzystości i możliwości odmowy. Kluczowym przedmiotem analizy nie jest zatem styl emocjonalny izolowanego modelu, ale reżim powstały, gdy zachowanie modelu, zachęty, ocena i powtarzająca się adaptacja człowieka wzmacniają się nawzajem.

4.2 Pojęcia emocji jako instrumenty percepcji i działania

Koncepcje robią więcej niż etykietowanie doświadczeń po ich wystąpieniu. Mogą skierować uwagę na różnice, które wcześniej były zamazane, dostarczyć przyczynowych interpretacji i zasugerować odpowiednie reakcje. Nauczenie się rozróżnienia między zawstydzeniem, wstydem, poczuciem winy i lękiem społecznym może wpłynąć na to, co według danej osoby się wydarzyło i jaka naprawa jest wymagana. Większa szczegółowość koncepcyjna może czasami poprawić regulacje, chociaż więcej etykiet nie zawsze jest lepszych.

To sprawia, że słownictwo dotyczące emocji przyszłości jest interesujące z naukowego punktu widzenia, ale metodologicznie niebezpieczne. Nazwanie stanu może pomóc ludziom skoordynować działania wokół naprawę powtarzającego się problemu; może również generować cechy popytu, modną autodiagnostykę lub urzeczowienie. Proponowana kategoria powinna zatem zyskać swój status dzięki przewidywaniu stabilnych wzorców, a nie brzmieniu psychologicznie wiarygodnie.

Rozważ wstyd związany z delegacją. Jeżeli koncepcja jest przydatna, powinna identyfikować sytuacje, w których ludzie spodziewają się dewaluacji właśnie dlatego, że przenieśli merytoryczną część zadania na sztuczną inteligencję. Powinien przewidywać ukrywanie, nadmierną rekompensatę, decyzje dotyczące ujawniania informacji i wrażliwość na normy publiczności. Jeśli ludzie używają tego wyrażenia jedynie jako synonimu zwykłej niepewności, nie ma to większego zastosowania naukowego.

Ten sam test dotyczy „klaustrofobii predykcyjnej”. Stałoby się to czymś więcej niż retoryką tylko wtedy, gdyby wysoce spersonalizowane przewidywania w sposób niezawodny powodowały rozpoznawalną kombinację dyskomfortu, chęci zachowania nieprzejrzystości, celowej nieprzewidywalności i unikania profilowania w warunkach innych niż ogólna troska o prywatność. W książce używa się takich terminów, jak hipotezy do organizowania obserwacji, a nie odkrycia.

4.3 Wspólnoty emocjonalne i reżimy afektywne

Historycy i antropolodzy opisali wspólnoty emocjonalne: grupy, które mają wspólne normy dotyczące cenionych uczuć, właściwej ekspresji i znaczenia epizodów emocjonalnych. Organizacje rozwijają także reżimy afektywne. Sala sądowa nagradza powściągliwość; medycyna ratunkowa może nagradzać spokój pod presją; sprzedaż może wymagać entuzjazmu; instytucje wojskowe trenują strach i spójność w określony sposób; niektóre społeczności internetowe nagradzają ironię lub oburzenie.

Sztuczna inteligencja może stać się częścią maszyny, za pomocą której naucza się i egzekwuje takie reżimy. Asystent pisanie może ostrzec, że wiadomość brzmi zbyt wrogo. System obsługi klienta może wymagać określonego tonu. Platforma analityczna w miejscu pracy może wyciągać wnioski na podstawie opinii zespołów ds. komunikacji i nagradzania, które wydają się pozytywne. Interwencje te mogą zmniejszyć niepotrzebne konflikty, ale mogą również zawęzić uzasadnione różnicowanie emocjonalne i sprawić, że sprzeciw będzie wyglądał jak defekt stylu.

Centralną kwestią instytucjonalną jest to, kto definiuje docelowy afekt. Model wyszkolony w zakresie maksymalizacji satysfakcji klienta może zachęcać do okazywania szacunku nawet wtedy, gdy klient stosuje przemoc. Asystent szkolny zoptymalizowany pod kątem zaangażowania może uniknąć produktywnego frustracji. Platforma polityczna zoptymalizowana pod kątem uczestnictwa może odkryć, że oburzenie jest skuteczne. Mediacja algorytmiczna nie odzwierciedla po prostu kultury emocjonalnej; może pomóc w wyborze jednego.

4.4 Kapitalizm, zawody i kultywowanie produktywnego „ja”.

Spółeczeństwa przemysłowe i postindustrialne silnie powiązały wartość moralną z produktywnością. Związek ten jest uwarunkowany historycznie, a nie faktem biologicznym. Tradycje religijne, biurokracja państwowa, zawody i rynki przyczyniły się do powstania norm ceniących punktualność, pracowitość, samodyscyplinę, ambicję i wymierne osiągnięcia. Zatrudnienie stało się zarówno umową ekonomiczną, jak i społecznym świadectwem dorosłości i przydatności.

Produktywne Ja jest efektywne psychologicznie, ponieważ integruje kilka motywów. Praca zapewnia dochód, ale może także oferować status, informację zwrotną na temat kompetencji, rutynę, uznanie społeczne i możliwą do obrony odpowiedź na pytanie, dlaczego czas jest ważny. Integracja ta jest jednym z powodów, dla których bezrobocie technologiczne może być trudne psychicznie, nawet jeśli potrzeby materialne są zaspokojone.

Sztuczna inteligencja może osłabić związek między wysiłkiem a wynikami w pracy poznawczej. Jeśli tak, społeczeństwa mogą zareagować na różne sposoby. Mogą nasilić konkurencję wokół pozostałych rzadkich zadań, symbolicznie zachować pracę, nawet jeśli z technicznego punktu widzenia potrzeba mniejszej siły roboczej, przenieść prestiż w stronę osądu i odpowiedzialności lub kultywować nierynkowe formy wkładu. O przejściu nie zadecyduje wyłącznie inżynieria.

Pojawia się tu możliwość „nieproduktywnej godności”. Termin ten nie oznacza celebrowania bierności. Wymienia potencjalne osiągnięcie kulturowe: oddzielenie podstawowej legitymizacji ludzkiej od produkcji rynkowej przy jednoczesnym utrzymaniu instytucji, w których nadal można cenić wkład, mistrzostwo, opiekę i służbę publiczną. Nie ma pewności, czy taka norma może stać się wiarygodna emocjonalnie. Stuleci moralizacji opartej na produktywności nie można usunąć samą zmianą polityki dochodowej.

4.5 Platformy jako środowiska selekcji afektywnej

Platformy cyfrowe już zmieniają selektywne środowisko ekspresji emocjonalnej. Posty konkurują o uwagę w ramach systemów rankingowych. Treści wywołujące zaskoczenie, oburzenie moralne, strach, podziw lub potwierdzenie tożsamości mogą rozprzestrzeniać się inaczej niż informacje neutralne. Platforma nie jest neutralną areną, na której niezależnie rywalizują emocje. Projekt interfejsu, cele rekomendatorów, zasady moderacji, rynki reklamowe i struktura sieci definiują przydatność.

Generatywna sztuczna inteligencja może przyspieszyć ten proces, czyniąc zmiany tańszymi. Można wygenerować i przetestować miliony wersji wiadomości. Personalizacja może przenieść selekcję ze średnich na poziomie populacji do indywidualnych podatności. System może nauczyć się nie tego, który argument przekonuje ogół ludzi, ale jakie sformułowanie porusza konkretnego użytkownika w konkretnym momencie.

Nazywanie tego „doborem algorytmicznym” nie powinno oznaczać dosłownego procesu genetycznego. Jest to analogia do zmienności, różnicowej propagacji i retencji. Analogia staje się przydatna, gdy generuje prognozy: style emocjonalne nagradzane celami platformy powinny stać się częstsze; twórcy powinni nauczyć się tych stylów; użytkownicy wielokrotnie narażeni na nie mogą ponownie skalibrować oczekiwania; a konkurencyjne platformy o różnych celach powinny rozwijać różne kultury afektywne.

Niebezpieczeństwem jest nie tylko manipulacja. Optymalizacja może również wybrać pomocne style: jasne wyjaśnienia, pełna szacunku niezgoda, coaching wspierający lub deeskalacja. Kwestią polityczną jest funkcja celu, przejrzystość optymalizacji, stopień kontroli użytkownika oraz koszty zewnętrzne nałożone na relacje poza platformą.

4.6 Jak rozpoznać nową kategorię emocji?

Poważne roszczenie o nowość emocjonalną powinno zadowolić więcej niż nowość leksykalna. Po pierwsze, proponowaną kategorię należy wyłonić w oparciu o powtarzającą się i w miarę spójną klasę sytuacji. Po drugie, ludzie powinni dokonać wyróżniającej oceny, a nie jedynie zgłaszać ogólny pozytywny lub negatywny afekt. Po trzecie, stan powinien być powiązany ze stosunkowo stabilnym wzorcem uwagi, motywacji, ekspresji lub zachowania. Po czwarte, koncepcja powinna wspierać koordynację społeczną: inni ludzie powinni zrozumieć, jakie obowiązki lub oczekiwania z niej wynikają. Po piąte, wzór powinien utrzymywać się w czasie i rozprzestrzeniać się poza małą modną subkulturę.

Wyjątkowość fizjologiczna nie jest konieczna. Ustalone kategorie emocji same w sobie nie są powiązane z jedną wyłączną sygnaturą fizjologiczną. Jeśli jednak nowa etykieta nie ma wartości prognostycznej wykraczającej poza istniejące koncepcje, powinna pozostać metaforą. To konserwatywne kryterium pozwala, aby kultura miała znaczenie, nie zamieniając każdego technologicznego dyskomfortu w nowo odkrytą emocję.

Kryterium to ułatwia także przyszłe badania. Badania podłużne mogą obejmować kohorty narażone na różne formy sztucznej inteligencji, porównywać kultury zawodowe, analizować pojawianie się nowego słownictwa i sprawdzać, czy etykiety przewidują zachowanie po uwzględnieniu istniejących konstruktów. Praca międzykulturowa może zadać pytanie, czy podobne problemy technologiczne

generują zbieżne kategorie, czy też instytucje wytwarzają różne rozwiązania emocjonalne. Teoria przyszłych emocji powinna stworzyć program badawczy, a nie tylko listę sugestywnych nazw.

Rozdział 5. Praca jako instytucja afektywna i niepewność automatyzacji

5.1 Praca zapewnia więcej niż dochód, ale nie zawsze zapewnia sens

Psychologiczne znaczenie pracy łatwo jest idealizować. Zatrudnienie może zapewnić rutynę, kontakt społeczny, status, wykorzystanie umiejętności, wspólny cel i poczucie wkładu, ale może również powodować upokorzenie, monotonię, obrażenia, przymus, niepewność i wyczerpanie. Poważna analiza automatyzacji musi uwzględniać oba fakty. Zniknięcie nieprzyjemnego porodu może być poprawą, nawet jeśli praca ma ważne ukryte funkcje; utrzymanie zatrudnienia nie jest automatycznie dobrem psychologicznym.

Badania nad bezrobociem od dawna odróżniają jawną funkcję dochodu od funkcji ukrytych [Jahoda, 1982; Paul i Moser, 2009], takie jak struktura czasowa, kontakty społeczne, aktywność zbiorowa, status i regularne zaangażowanie. Utrata pracy może zatem wpłynąć na samopoczucie poprzez coś więcej niż tylko ograniczenie konsumpcji. Siła tych efektów różni się w zależności od instytucji opieki społecznej, struktury rodziny, rynku pracy, tożsamości osobistej i jakości utraconej pracy. W każdym scenariuszu po pracy należy zadać sobie pytanie, które funkcje zostaną usunięte i gdzie zostaną zamiast tego dostarczone.

Właśnie dlatego uniwersalny dochód podstawowy, nawet jeśli byłby odpowiedni ekonomicznie, sam w sobie nie rozwiązałby problemu afektywnego. Dochód może chronić autonomię i zmniejszać strach, ale nie tworzy automatycznie ról, odbiorców, obowiązków, mistrzostwa ani przynależności. Z drugiej strony zmuszanie ludzi do wykonywania niepotrzebnej pracy po prostu w celu zachowania tych funkcji byłoby marnotrawstwem i potencjalnie poniżającym. Problem instytucjonalny polega na oddzieleniu, tam gdzie to możliwe, cennych funkcji psychologicznych od przymusowej produkcji.

5.2 Co wiemy o obecnym wpływie AI na pracę

Obecne dowody nie uzasadniają pewnej prognozy, że sztuczna inteligencja wyeliminuje większość pracy [ILO, 2025; OECD, 2023]. Narażenie zawodowe jest bardzo nierówne, zadania zmieniają się w ramach zawodów, a nowe wymagania mogą pojawić się, gdy stare zostaną zautomatyzowane. Badania nad generatywną sztuczną inteligencją wykazały poprawę produktywności w niektórych zadaniach związanych z pisaniem, obsługą klienta, kodowaniem i zdobywaniem wiedzy [Noy i Zhang, 2023; Brynjolfsson, Li i Raymond, 2025], często z większymi korzyściami dla mniej doświadczonych pracowników. Inne badania pokazują różnice w jakości, nadmierne poleganie, nowe obciążenia weryfikacyjne lub zmiany w postrzeganej sprawczości.

Zarejestrowana wcześniej metaanaliza eksperymentów z ludzką sztuczną inteligencją zawierała przydatne ostrzeżenie przed prostymi narracjami o komplementarności [Vaccaro, Almaatouq i Malone, 2024]: kombinacje ludzi i sztucznej inteligencji średnio nie zapewniały automatycznie lepszych wyników niż lepszy samodzielny aktor. Wyniki zależały od rodzaju zadania i struktury współpracy. Nowsze badania w miejscach pracy i laboratoriach podobnie sugerują, że „stosowanie sztucznej inteligencji” nie jest spójną interwencją. To, czy narzędzie służy jako generator, krytyk, nauczyciel, weryfikator czy partner myślowy, zmienia zarówno wydajność, jak i funkcje poznawcze.

Badania nad krytycznym myśleniem wśród pracowników wiedzy wskazują raczej na zmianę niż na proste zniknięcie [Lee i in., 2025]. Kiedy ludzie ufają systemom generatywnym, część tradycyjnego wysiłku produkcyjnego może spaść, podczas gdy wysiłek zmierza w stronę weryfikacji wyników, integracji informacji, nadzorowania procesu i decydowania, kiedy zachowanie modelu jest nieodpowiednie. To przejście może poprawić produktywność, jednocześnie pogarszając umiejętności, jeśli użytkownicy nie będą już ćwiczyć podstawowych operacji. Równowaga

prawdopodobnie będzie zależeć od szkolenia, projektu zadań, informacji zwrotnej i tego, czy błędy pozostaną wystarczająco widoczne, aby można było ich uczyć.

Dane empiryczne są zatem zgodne z kilkoma przyszłościami. Sztuczna inteligencja może głównie wspierać pracowników, automatyzować znaczne pakiety zadań w trakcie utrzymywania się zawodów, reorganizować pracę wokół mniejszej liczby wysoce lewarowanych pracowników lub eliminować określone zawody i tworzyć inne. W książce potraktowano je raczej jako scenariusze warunkowe niż pojedynczą prognozę.

Scenariusze te należy traktować raczej jako dystrybucje niż wzajemnie wykluczające się kontrakty futures. Różne sektory mogą jednocześnie zajmować różne stanowiska, a pojedynczy zawód może obejmować zadania zautomatyzowane, rozszerzone, chronione przepisami lub nowo utworzone. Konsekwencje emocjonalne zależą zatem od kolejności i siły przetargowej. Stopniowe wzmacnianie może pozwolić na migrację tożsamości zawodowej w kierunku nadzoru i osądu; nagła substytucja może spowodować utratę statusu, zanim alternatywne role zyskają legitymizację. Rynek pracy może także zachować zatrudnienie, zmieniając jego podmiotową strukturę, na przykład zamieniając ekspertów w recenzentów wydajności maszyn. W takim przypadku statystyki dochodów mogą wyglądać stabilnie, podczas gdy autonomia, duma rzemieślnicza i postrzegana własność pogarszają się. I odwrotnie, krótsze godziny pracy przy prawdziwej kontroli mogą poprawić życie, nawet jeśli spada centralność zawodowa. Dlatego też przewidywania dotyczące afektu powinny opierać się na formie instytucjonalnej, a nie wynikać bezpośrednio z możliwości technicznych.

5.3 Zadanie, zawód i tożsamość

Zadanie nie jest zajęciem, a zawód nie jest tożsamością. Praca obejmuje różnorodne działania: zbieranie informacji, produkcję, negocjacje społeczne, odpowiedzialność, koordynację, perswazję, działania fizyczne i przestrzeganie zasad. Sztuczna inteligencja może zautomatyzować najłatwiejsze do określenia komponenty, pozostawiając nienaruszoną odpowiedzialność, zarządzanie kontekstem i pracę interpersonalną. W innych przypadkach pozostały pakiet może okazać się zbyt mały, aby utrzymać stary zawód.

Tożsamość może się utrzymać nawet po zmianie struktury zadania. Fotograf pozostał fotografem po autofokusie i cyfrowej edycji; programista pozostał programistą po tym, jak kompilatory i biblioteki wyeliminowały wcześniejszą pracę. Ale są granice. Kiedy główna umiejętność społeczności przestanie odróżniać członków, zawód może potrzebować nowych kryteriów wiedzy specjalistycznej. W tym miejscu smutek związany z kompetencjami staje się prawdopodobny: nie dlatego, że zanika wszelka aktywność, ale dlatego, że zdolność, wokół której dana osoba zorganizowała szacunek do siebie, traci niedostatek i uznanie społeczne.

Efekt zależy od tego, czy dana osoba potrafi przenieść zgromadzoną wiedzę na wyższy poziom osądu. Doświadczeni praktycy często posiadają ukryte modele trybów awarii, potrzeb interesariuszy i kontekstu, które pozostają cenne po zautomatyzowaniu rutynowej produkcji. Jeśli instytucje nagradzają ten osąd, tożsamość może ewoluować bez załamania. Jeśli organizacje wykorzystują sztuczną inteligencję głównie do wykonywania zadań biurowych i monitorowania pracy, ta sama technologia może przyspieszyć dewaluację.

5.4 Cztery scenariusze relacji AI i pracy

Pierwszy scenariusz zakłada ograniczone wzmocnienie. Sztuczna inteligencja zmniejsza tarcia w istniejących zawodach, pracownicy pozostają w widoczny sposób odpowiedzialni, a przyrost produktywności jest dzielony na tyle, że praca staje się łatwiejsza bez utraty swojej roli społecznej. Zmiana emocjonalna ma charakter stopniowy. Duma przesuwana jest nieco w stronę używania narzędzi i osądu; lęk koncentruje się wokół utrzymania i oceny kompetencji.

Drugi scenariusz to spolaryzowane wzmocnienie. Mała grupa kontroluje potężne systemy i koordynuje dużą ilość zautomatyzowanej pracy, podczas gdy wiele innych osób zajmuje się mniejszą autonomią w zakresie usług, opieki, obowiązków fizycznych lub monitorowania. Nierówność statusu może wzrosnąć, nawet jeśli zagregowana produktywność wzrośnie. Zazdrość, uraza i strach przed nieistotnością stają się coraz bardziej istotne politycznie. Scenariusz ten w dużym stopniu zależy od instytucji własnościowych i pracowniczych, a nie od samych możliwości technicznych.

Trzeci scenariusz to szerokie przesiedlenie z rekompensatą socjalną. W dużej mierze płatne umowy o pracę, ale bezpieczeństwo dochodów, edukacja, aktywność obywatelska, opieka, sztuka, sport, nauka, instytucje lokalne i projekty wolontariackie rozszerzają się jako alternatywne źródła statusu i przynależności. Takie społeczeństwo mogłoby zmniejszyć moralne centralne miejsce zatrudnienia bez ograniczania aktywności. Wymagałoby to konstrukcji instytucjonalnej na skalę, którą często niedoceniają obecne dyskusje po pracy.

Czwarty scenariusz to szerokie przesiedlenie bez skutecznych instytucji zastępczych. Może istnieć wsparcie materialne, ale wiele osób traci zorganizowany wkład, uznanie publiczne i trwałe społeczności. Spersonalizowana rozrywka i sztuczne towarzystwo wypełniają część tej luki. Scenariusz ten stwarza największe ryzyko zubożenia afektywnego, zależności i konfliktu statusu. Jest to możliwe, ale nie nieuniknione.

5.5 Jakie niedobory pozostaną, gdy produkcja poznawcza stanie się tania?

Automatyzacja nie znosi niedoboru; zmienia swoją lokalizację. Uwaga pozostaje ograniczona. Zaufanie jest trudne do skalowania. Legitymizowana władza jest rzadkością, ponieważ nie każdy może podejmować wiążące decyzje. Odpowiedzialność jest rzadkością, ponieważ ktoś musi ponosić konsekwencje. Zasoby fizyczne, ziemia, energia, unikalne doświadczenia, dostęp społeczny i czas pozostają ograniczone. Podobnie jak wiarygodne zobowiązania i relacje z niezależnymi osobami.

W miarę jak generowana treść staje się obfita, wybór staje się coraz ważniejszy. Wiedza o tym, o co pytać, co odrzucić, co zasługuje na wdrożenie i jaki kompromis zaakceptować, może mieć większe znaczenie niż wyłonienie jednego kompetentnego kandydata. Weryfikacja staje się również rzadka, ponieważ niedrogo generowanie może stworzyć dowolnie dużą powierzchnię roszczeń. To zmienia status w kierunku kuratorów, ewaluatorów, instytucji zaufania i osób chcących wziąć na siebie odpowiedzialność.

Ta zmiana nie jest automatycznie egalitarna. Sama weryfikacja może być skoncentrowana w systemach własnych. Zaufane marki i elitarne referencje mogą stać się bardziej wartościowe, gdy wyniki są trudne do oceny. Alternatywnie przejrzyste pochodzenie, otwarte testy porównawcze, rozproszona reputacja i weryfikacja społeczności mogą poszerzyć dostęp. Ekonomia emocjonalna przyszłości będzie częściowo zależeć od tego, jaka architektura zaufania zostanie zbudowana.

Nacisk na przejście nie jest preferencją retoryczną. Systemy emocjonalne reagują na niepewność, stratę, względny status i naruszone oczekiwania, a wszystko to może być bardziej intensywne podczas przemieszczania się pomiędzy stanami równowagi niż po ustabilizowaniu się nowego układu. Społeczeństwo, które ostatecznie normalizuje rozległą automatyzację, może nadal czekać dziesięciolecia, podczas których kwalifikacje w nieprzewidywalny sposób tracą na wartości, pokolenia są nierówno eksponowane, a instytucje w dalszym ciągu nagradzają tożsamości kojarzone z zanikającym porządkiem gospodarczym. Historyczne przemiany przemysłowe pokazują, że zagregowany wzrost produktywności nie określa, kto ponosi lokalne straty ani ile czasu potrzeba, aby nowe normy stały się uzasadnione. W przypadku badań nad emocjami przyszłości oznacza to, że pozornie „nowe” afekty mogą być syndromami przejściowymi, które znikają wraz ze zmianą oczekiwań. Dowody podłużne są niezbędne, zanim zaczniemy traktować je jako trwałe cechy życia po pracy.

5.6 Wysiłek, wartość i dobrowolny niedobór

Ludzie często cenią wyniki częściowo dlatego, że wymagały wysiłku, umiejętności, opóźnienia lub ryzyka. Nie dowodzi to, że wysiłek ma wewnętrzną wartość moralną. Pokazuje, że wysiłek pełni funkcję informacji o zaangażowaniu i kompetencjach oraz może zmienić subiektywne doświadczenie. Jeśli sztuczna inteligencja usunie wysiłek z wielu działań, społeczeństwa mogą celowo zachować trudności w niektórych dziedzinach.

Sport już to robi. Wartość przebiegnięcia maratonu zależy od tego, czy nie korzystasz z pojazdu. Gry tworzą arbitralne ograniczenia. Edukacja czasami wymaga samodzielnego działania, ponieważ celem jest rozwinięcie umiejętności, a nie tylko uzyskanie odpowiedzi. Tradycje rzemieślnicze cenią zarówno proces, jak i produkt. Instytucje te pokazują, że możliwości technologiczne i dozwolone działania mogą się od siebie różnić bez irracjonalności.

„Głód tarć” jest zatem prawdopodobną tendencją kulturową: preferencją dla działań, w których przeszkody pozostają znaczące, ponieważ ich pokonanie wspiera mistrzostwo, tożsamość lub wiarygodną sygnalizację. Etykieta ma charakter spekulacyjny, ale podstawowe zachowanie jest przestarzałe. Przyszłą nowością będzie skala i jednoznaczność, z jaką ludzie wybierają środowiska ograniczone przez człowieka właśnie dlatego, że w przeciwnym razie optymalizacja jest tania.

5.7 Sam dochód nie rozwiązuje problemu przejścia emocjonalnego

Bezpieczeństwo gospodarcze jest warunkiem koniecznym wielu łagodnych scenariuszy. Chroniczna niepewność zawęży wybór i może uniemożliwić eksperymentowanie z nowymi rolami. Nie należy jednak mylić zapewnienia materialnego z kompletną architekturą społeczną. Społeczeństwo może płacić ludziom, a mimo to nie zapewnia uczestnictwa, statusu, relacji i wiarygodnych ścieżek do kompetencji.

To rozróżnienie ma znaczenie polityczne, ponieważ krytycy propozycji dotyczących pracy po pracy często zakładają, że bez pracy ludzie staną się bierni, podczas gdy zwolennicy czasami zakładają, że wolny czas samoistnie nabierze znaczenia. Obydwa twierdzenia są zbyt mocne. Działalność człowieka kształtowana jest przez struktury szans. Tam, gdzie dostępne są kluby sportowe, laboratoria, warsztaty, instytucje sąsiedzkie, edukacja, sieci opieki i projekty obywatelskie, ludzie mogą organizować wymagające, nierynkowe życie. Tam, gdzie alternatywą jest konsumpcja izolowana, zachowanie może być inne.

Problemem projektu instytucjonalnego nie jest zatem to, jak wytworzyć przymusowe znaczenie. To sposób na udostępnienie wielu dziedzin wkładu i mistrzostwa bez wiązania podstawowej legitymizacji z sukcesem na rynku pracy.

5.8 Przejście może mieć większe znaczenie niż przeznaczenie

Nawet pożądane długoterminowe porozumienie można osiągnąć poprzez szkodliwe przejście. Umiejętności mogą tracić na wartości szybciej niż kształtuje się nowa tożsamość. Społeczności zorganizowane wokół miejsc pracy mogą zniknąć, zanim pojawią się substytuty. Pokolenia wykształcone w ramach jednego systemu statusu mogą doświadczyć szybkiej dewaluacji, podczas gdy młodsze kohorty łatwiej się przystosowują.

Tempo zmian wpływa zatem na wyniki emocjonalne. Stopniowa automatyzacja z widocznymi ścieżkami przekwalifikowania umożliwia przewidywanie i transfer tożsamości. Nagłe przemieszczenie na podstawie nieprzejrzystych kryteriów powoduje większą niepewność. Polityki, które chronią sprawczość, wyjaśniają decyzje, uznają istniejące kompetencje i tworzą role przejściowe, mogą mieć równie duże znaczenie jak ostateczna ilość płatnej pracy.

Nacisk na transformację ogranicza również determinizm technologiczny. Ten sam poziom automatyzacji można doświadczyć jako wyzwolenia, upokorzenia lub zwykłej modernizacji, w

zależności od tego, kto ją wybierze, kto z niej skorzysta, jak szybko to nastąpi i czy ludzie zachowają uznane role w nowym systemie.

Rozdział 6. Trzy prędkości ewolucji afektywnej

6.1 Ewolucja biologiczna się nie zatrzymała, ale nie jest to najbliższe wyjaśnienie

Ewolucja genetyczna człowieka trwa. Presja selekcyjna nie zniknęła wraz z nowoczesnością, a przyszłe wzorce reprodukcyjne mogłyby w zasadzie zmienić dyspozycje psychologiczne. Jednak ewolucja biologiczna nie jest dobrym domyślnym wyjaśnieniem zmian spodziewanych w ciągu najbliższych kilku dekad. Złożone cechy emocjonalne są wielogenowe, uwarunkowane rozwojowo i zakorzenione w kulturze. Selekcja musiałaby być silna, stabilna, dziedziczna i utrzymywana przez pokolenia, aby spowodować poważną zmianę poziomu populacji.

W przypadku krótkoterminowych scenariuszy sztucznej inteligencji bardziej prawdopodobnym zjawiskiem biologicznym jest niedopasowanie. Istniejące systemy napotykają warunki odmienne od tych, w jakich się rozwinęły. Stała ocena algorytmiczna może aktywować czujność statusu; niekończące się spersonalizowane nowości mogą rekrutować poszukujących nagród; sztuczna reakcja społeczna może aktywować przywiązanie i wzajemność. Mechanizm może być stary, podczas gdy środowisko jest nowe.

Długoterminowa koewolucja genów i kultur pozostaje koncepcyjnie możliwa. Jeśli społeczeństwa technologiczne stworzą stabilne różnice w reprodukcji powiązane z określonymi predyspozycjami, częstotliwości genetyczne mogą się zmienić. Obecnie prognozowanie kierunku byłoby wysoce spekulatywne, ponieważ instytucje społeczne i wybory reprodukcyjne szybko się zmieniają. Dlatego też książka traktuje ewolucję biologiczną jako ciągłość tła, a nie jako główny silnik przyszłej nowości emocjonalnej.

Nazywanie tego procesu selekcją nie oznacza, że algorytmy autonomicznie ewoluują ludzkie emocje. Bardziej uzasadnione twierdzenie jest takie, że systemy cyfrowe zmieniają ekspozycję i wzmocnienie. Doradcy określają, które wyrażenia emocjonalne są powtarzane; systemy optymalizacji mogą odkryć, które ramki zwiększają zaangażowanie; agenci konwersacyjni mogą personalizować ton i czas w skali niedostępnej dla wcześniejszych mediów. Użytkownicy, instytucje i rynki następnie zachowują lub odrzucają wynikające z nich praktyki. Jest to środowisko selekcji z zaprojektowanymi komponentami, a nie substytut agencji kulturalnej. Jego znaczenie polega na szybkości i szczegółowości: platforma może szybko przetestować wiele wariantów i dostosować je do subpopulacji lub jednostek. Pytaniem empirycznym jest, czy te pętle sprzężenia zwrotnego powodują stabilne zmiany w zachowaniu i normach, czy jedynie krótkotrwałe efekty platformy.

6.2 Rozwój: skala czasu jednego życia

Rozwój jest szybszy niż ewolucja genetyczna i często jest niedoceniany w debatach technologicznych. Ludzki mózg jest plastyczny, dzieciństwo wydłuża się, a normy, koncepcje, język i umiejętności nabywa się poprzez powtarzającą się interakcję. Dziecko dorastające pod okiem opiekunów AI i agentów społecznych nie musi mieć innego genomu, aby rozwinąć odmienne oczekiwania dotyczące szybkości reagowania, autorytetu, pamięci i granic między kompetencjami człowieka i maszyny.

Kalibracja rozwojowa może działać poprzez zwykłe uczenie się. Jeśli asystent jest zawsze cierpliwy, dziecko może nauczyć się, że na pytania można uzyskać natychmiastową odpowiedź. Jeśli sztuczna inteligencja często pośredniczy w konflikcie, dziecko może ćwiczyć mniej spontaniczne naprawy lub, alternatywnie, otrzymać bardziej wyraźne wskazówki i stać się w tym lepsze. To, jaki wynik nastąpi, zależy od projektu i praktyki rodzinnej. Obecnie nie ma wystarczających dowodów podłużnych, aby z całą pewnością wybierać między umiejętnościami społecznymi a wspomaganiem rozwojem umiejętności.

Rozwój wyjaśnia również, dlaczego efekty kohortowe mogą być znaczące. Dorośli, którzy budowali tożsamość przed generatywną sztuczną inteligencją, mogą doświadczyć delegowania jako straty, podczas gdy kohorty szkolone od dzieciństwa w zakresie traktowania modeli jak zwykłej infrastruktury poznawczej mogą tego nie robić. Historyczne analogie z kalkulatorami, wyszukiwarkami lub technologiami pisania są sugestywne, ale niekompletne, ponieważ systemy konwersacyjne mogą głębiej uczestniczyć w rozumowaniu i wymianie społecznej.

6.3 Ewolucja kulturowa: zmienność, przekazywanie i selekcja

Zmiana kulturowa może zreorganizować zachowanie w ciągu lat. Praktyki są różne, ludzie naśladują udane lub prestiżowe modele, instytucje egzekwują normy, a technologie zmieniają transmisję. Kategorie emocjonalne mogą brać udział w tym procesie. Etykieta rozprzestrzenia się, gdy pomaga ludziom interpretować powtarzające się doświadczenia, koordynować oczekiwania, ustalać tożsamość lub uzasadniać zachowanie.

Selekcji kulturowej nie należy utożsamiać z postępem. Norma może się rozprzestrzeniać, ponieważ jest zapadająca w pamięć, przynosi zyski, jest egzekwowana przymusem lub jest powiązana z grupami o wysokim statusie. Oburzenie może pasować kulturowo do jednego systemu medialnego; powściągliwość pod innym. Wstyd może podtrzymywać współpracę lub chronić arbitralną hierarchię. Istotne pytanie brzmi: jakie środowisko nagradza dany wzór.

AI rozszerza produkcję i testowanie wariantów kulturowych. Modele mogą generować alternatywne narracje, style, rytuały i wyjaśnienia przy znikomym koszcie. Zwiększa to zróżnicowanie, ale selekcja nadal odbywa się na podstawie ludzkiej uwagi, decyzji instytucjonalnych, systemów rekomendacyjnych i zachęt ekonomicznych. Obfitość generatywna może zatem przyspieszyć ewolucję kulturową, nie wyznaczając jej kierunku.

6.4 Wybór algorytmiczny: przyspieszenie, nie magia

Termin selekcja algorytmiczna odnosi się do systemów, które systematycznie różnicują, klasyfikują, rekomendują i zachowują treści lub style interakcji zgodnie z mierzalnymi celami. Proces ten może zachodzić z niezwykłą szybkością. Platforma może testować tysiące receptur, obserwować zaangażowanie i dostosowywać rekomendacje w czasie rzeczywistym. Dzięki personalizacji odpowiednie środowisko selekcji może stać się indywidualne, a nie ogólnopopulacyjne.

Nie jest to nowa forma doboru naturalnego w sensie biologicznym. Replikatory, miary sprawności, mechanizmy dziedziczenia i skale czasowe różnią się. Analogia jest użyteczna tylko o tyle, o ile podkreśla zróżnicowaną trwałość w ramach jawnych lub ukrytych funkcji celu. Komunikat maksymalizujący retencję może wyprzedzić komunikat poprawiający zrozumienie, jeśli system mierzy retencję.

Konsekwencją afektywną jest to, że ekspresja emocjonalna może zostać zoptymalizowana instrumentalnie. Można wybrać ciepło, pilność, oburzenie, intymność, pewność lub strach, ponieważ poprawiają konwersję, zgodność lub czas spędzony na platformie. I odwrotnie, systemy można zoptymalizować pod kątem refleksji, zmniejszonej wrogości lub długoterminowej autonomii użytkownika. Problemem etycznym nie są emocje w samym interfejsie, ale ukryta optymalizacja stanu emocjonalnego użytkownika pod kątem celów, których użytkownik nie wybrał.

Za słowem „emocja” kryje się czasem pięta dwuznaczność: nowość w organizacji czasowej. Dwa społeczeństwa mogą opierać się na podobnych składnikach afektywnych, ale układać je według różnych rytmów. Stale dostępny asystent może skrócić okres między niepokojem a ujawnieniem lub między konfliktem a próbą naprawy. Zmiana ta może sprawić, że znane stany staną się fenomenologicznie odmienne, bez tworzenia nowego mechanizmu biologicznego. Szósta niejasność dotyczy funkcji społecznej. Stare uczucie może zyskać nową rolę, gdy instytucje wykorzystają je w inny sposób; na przykład wstyd związany z pomocą może stać się mechanizmem potwierdzania

kompetencji samodzielnie. Te rozróżnienia mają znaczenie, ponieważ najsilniejsze twierdzenie – nowo wyewoluowane obwody afektywne – jest również tym, w przypadku którego dowody są najmniej wiarygodne w odpowiedniej skali czasu. Wiele z tego, co ta książka nazywa nowością, dotyczy nowych obiektów, powtarzających się kombinacji, scenariuszy i wzorców czasowych. Są to znaczące zmiany kulturowe, nawet jeśli biologia pozostaje w dużej mierze ciągła.

6.5 Pętla pomiędzy trzema prędkościami

Biologia, rozwój, kultura i środowiska algorytmiczne nie są niezależnymi warstwami. Dyspozycje biologiczne ograniczają to, czego łatwo się nauczyć. Rozwój kalibruje reakcje na środowisko lokalne. Kultura dostarcza pojęć i norm. Algorytmy zmieniają to, które materiały kulturowe są wielokrotnie spotykane. Reakcje ludzkie dostarczają następnie danych wykorzystywanych do modyfikowania algorytmów.

Ta pętla może szybko wygenerować informację zwrotną. Załóżmy, że wysoce uspokajające reakcje sztucznej inteligencji zwiększają krótkoterminową satysfakcję. Platformy zapewniają większą pewność. Użytkownicy przyzwyczajają się do interakcji o niskim tarcu. Rozmowa międzyludzka wydaje się stosunkowo wymagająca. Niektórzy użytkownicy spędzają więcej czasu z AI, generując więcej danych faworyzujących ten sam styl. Proces ten mógłby ustabilizować nowe oczekiwania bez żadnych zmian genetycznych. To, czy do tego dojdzie, zależy od preferencji użytkowników, konkurencji, przepisów i tego, czy uwidocznią się koszty długoterminowe.

Ta sama pętla może wspierać korzystną adaptację. Jeśli systemy nagradzają uważną weryfikację, ujawniają niepewność i zachęcają użytkowników do konsultowania się z innymi ludźmi, normy kulturowe epistemicznej pokory mogą się wzmocnić. Technologia zmienia presję selekcyjną, ale nie usuwa wyboru instytucjonalnego.

W każdym razie zapotrzebowanie na unikalny fizjologiczny odcisk palca wyznaczałoby niezwykle rygorystyczne standardy. Istniejące kategorie często mają wspólne elementy autonomiczne, twarzowe i nerwowe, a pomiary różnią się w zależności od kontekstu i osoby. Przyszła kategoria mogłaby zatem być naukowo użyteczna, gdyby organizowała wiarygodne różnice w ocenie, uwadze, skłonnościach do działania, pamięci i reakcjach społecznych, nie posiadając wyłącznego podpisu cielesnego. Nie należy mylić tej możliwości z nieograniczonym konstruktywizmem. Kandydat nadal potrzebuje powtarzalnej struktury i wartości wyjaśniającej. Jeśli etykieta po prostu na nowo opisuje ogólne pobudzenie po fakcie, niewiele wnosi.

6.6 Co może, a czego nie może dokonać przemysłana ewolucja emocjonalna

Społeczeństwa już celowo kultywują skłonności emocjonalne. Edukacja uczy tolerancji na frustrację, zawody kształcą spokój, rytuały kultywują szacunek i solidarność, terapia rozwija regulację, a prawo zmienia społeczną akceptację pewnych wyrażań. Rozsądne jest zatem mówienie o celowym projektowaniu afektywnym w ograniczonym sensie.

To, czego nie można dowolnie projektować, to całkowicie subiektywny wynik. Interwencje mają skutki uboczne, populacje są różne, normom można się oprzeć, a instytucje mają sprzeczne cele. Próby wyeliminowania zazdrości, wstydu lub gniewu mogą usunąć przydatne sygnały wraz ze szkodliwymi ekscesami. Celem, który można obronić, jest zmiana środowiska, tak aby rzadziej wykorzystywano stare systemy do celów destrukcyjnych i aby dostępne stały się bardziej kompatybilne strategie.

Praktyczną jednostką projektu powinna zatem być sytuacja i zestaw opcji behawioralnych: jak przejrzysta jest ocena, czy możliwe jest wyjście, czy użytkownicy mogą kwestionować zautomatyzowane decyzje, czy wspierane są relacje międzyludzkie, czy nadal dostępna jest praktyka umiejętności i czy ujawniana jest perswazja emocjonalna. Kultura emocjonalna ewoluuje następnie w ramach tych ograniczeń, a nie jest programowana centralnie.

Wybór wśród etykiet może mieć także charakter polityczny. Termin może przesunąć odpowiedzialność w stronę jednostki, instytucji lub technologii. Nazywanie trwałego stanu „lękiem przed zmianą umiejętności” sugeruje osobisty problem z adaptacją; nazywanie go „stresiem z tytułu zmienności instytucjonalnej” kieruje uwagę na środowisko. Żadne kadrowanie nie jest automatycznie prawidłowe. Terminy przetrwały częściowo dlatego, że pomagają grupom zgłaszać roszczenia, przypisywać winę, prosić o dostosowanie lub budować tożsamość. To kolejny powód, aby nie traktować popularnego słownictwa jako neutralnej obserwacji. Kulturowy sukces etykiety emocji przyszłości jest sam w sobie danymi na temat konfliktu społecznego, ale nie jest tym samym, co dowód na to, że leżący u jego podstaw konstrukt psychologiczny jest dyskretny.

Rozdział 7. Czy mogą pojawić się nowe emocje?

7.1 Cztery znaczenia nowości

Pytanie „Czy może pojawić się nowa emocja?” jest niejednoznaczne. Możliwe są co najmniej cztery roszczenia. Po pierwsze, mógłby wyewoluować naprawdę nowy mechanizm biologiczny. Po drugie, istniejące mechanizmy można połączyć w powtarzającą się konfigurację, która wcześniej nie była powszechna. Po trzecie, kultura może stworzyć nową koncepcję, której partycje doświadczają w różny sposób. Po czwarte, nowa instytucja lub technologia mogłaby ustabilizować nowy przedmiot, ocenę i scenariusz behawioralny wokół starych składników afektywnych.

Twierdzenie pierwsze jest najsilniejsze i najmniej prawdopodobne w krótkim horyzoncie czasowym. Czwarty jest najbardziej prawdopodobny i stanowi główny temat tej książki. Ludzie nie potrzebowali genetycznie odrębnego obwodu, aby „lęk przed e-mailem” lub „trema” był rozpoznawalny. Nowe środowiska mogą wielokrotnie aktywować stare systemy w strukturalnie nowatorski sposób.

Interesującym pytaniem naukowym jest zatem to, kiedy taka konfiguracja zasługuje na niezależność, a nie na opisywanie jej jako zwykłego niepokoju, wstydu, żalu lub dumy. Odpowiedź zależy od zysku wyjaśniającego. Nowa kategoria jest przydatna, jeśli lepiej niż istniejące kategorie przewiduje czynniki wywołujące, uwagę, działanie, komunikację i konsekwencje społeczne.

Przydatny projekt badawczy obejmowałby zatem porównanie konkurencyjnych opisów. Uczestnicy mogli zgłosić doświadczenie, używając zwykłych kategorii, zanim zetknęli się z proponowaną etykietą; późniejsze badania mogłyby sprawdzić, czy nowa koncepcja poprawia przewidywanie zachowań, czy jedynie zmienia narrację. Szczególnie ważna byłaby replikacja międzykulturowa. Jeśli „żałoba kompetencyjna” identyfikuje rzeczywistą, powtarzającą się konfigurację, analogiczne wzorce powinny być zauważalne nawet tam, gdzie nie ma tego wyrażenia, chociaż lokalne interpretacje mogą się różnić. Jeśli zjawisko pojawi się dopiero po silnej promocji etykiety, konstruowanie kulturowe może nadal być ważne, ale przyczyna jest inna. Spekulatywne słownictwo zawarte w książce należy rozumieć jako hipotezy, które zapraszają właśnie do takich testów.

7.2 Nowa emocja nie wymaga wyjątkowej fizjologii

W badaniach nad emocjami wielokrotnie starano się zidentyfikować jedną unikalną sygnaturę fizjologiczną dla każdej zwykłej kategorii. Wzorce cielesne nakładają się na siebie, kontekst ma znaczenie, a zróżnicowanie w obrębie kategorii jest duże. Wymaganie, aby przyszła emocja posiadała wcześniej niewidoczny profil autonomiczny, narzuciłoby kryterium, którego wiele ustalonych kategorii nie jest w stanie spełnić.

Nie oznacza to, że fizjologia jest nieistotna. Powtarzająca się kategoria kulturowa nadal musi zostać ucieleśniona, ponieważ ucieleśnione jest ludzkie doświadczenie. Rzecz w tym, że nowość może tkwić w strukturze oceny, przedmiocie, znaczeniu i zachowaniu, a nie w nowym organie. Wstyd z powodu delegowania może wywołać znajome pobudzenie i wycofanie, zachowując jednocześnie odrębność społeczną, ponieważ zagrożoną wartością jest w szczególności autorstwo lub kompetencje w ramach wsparcia maszynowego.

7.3 Nowy przedmiot, nowa ocena lub nowa relacja

Zmiany technologiczne tworzą nowe obiekty emocji. Ludzie mogą bać się usunięcia konta, opłakiwać wirtualną społeczność, pozazdrościć dostępu do obliczeń, urazić algorytmicznego oceniającego lub przywiązać się do towarzysza AI. W wielu przypadkach leżące u ich podstaw emocje są wyraźnie stare. Sama nowość obiektu nie wystarczy.

Ciekawsze są nowe wyceny. Osoba może zapytać, czy osiągnięcie jest „moje”, gdy przyczynowość jest rozłożona na człowieka i model; czy intymność jest wzajemna, gdy jedna ze stron symuluje

opiekę; czy dokładne przewidywanie jest pomocne czy inwazyjne; czy odmowa automatyzacji jest uczciwością, czy zaniedbaniem. Oceny te łączą stare obawy – sprawczość, status, wzajemność, prywatność, odpowiedzialność – w nowych strukturach instytucjonalnych.

Nowe relacje też mogą mieć znaczenie. Diada człowiek-sztuczna inteligencja jest asymetryczna w nietypowy sposób: jeden uczestnik może być stale dostępny, bezterminowo cierpliwy, kopiowany, resetowany, personalizowany i należeć do strony trzeciej. Struktura ta nie ma dokładnego precedensu historycznego. Jest prawdopodobne, że wokół tego utworzą się powtarzające się konfiguracje emocjonalne, nawet jeśli wszystkie składniki biologiczne będą znajome.

Utracony obiekt jest zatem relacyjny. Osoba niekoniecznie utraciła wewnętrzne umiejętności; zmieniła się relacja między tą umiejętnością a otaczającym ją światem: niedobór, popyt, publiczność zdolna ją docenić i wiarygodna trajektoria przyszłej umiejętności. Pomaga to wyjaśnić, dlaczego szybkie przekwalifikowanie może nie złagodzić reakcji. Nauka innego narzędzia może przywrócić szanse na zatrudnienie bez przywracania znaczenia przypisywanego latom praktyki. Istnieją analogie do zaniku rzemiosła, upadku przemysłu, przymusowych emerytur i emerytur sportowych, chociaż sztuczna inteligencja może utrudniać przejście i może skupiać się na publicznych oznakach kompetencji poznawczych, które wcześniej były trudne do naśladowania. Nie wiemy, czy dominować będzie smutek, złość lub niepokój o status, ani jak silnie ochrona materialna będzie moderować to doświadczenie. Reakcje instytucjonalne mogą ułatwić przejście bez sztucznego utrzymywania każdego monopolu zawodowego: role mentorskie, uznanie zgromadzonej wiedzy specjalistycznej i wolniejsze ścieżki zmian to prawdopodobne mechanizmy.

7.4 Dobór kulturowy słownictwa afektywnego

Nowe etykiety nie rozprzestrzeniają się tylko dlatego, że są dokładne. Rozprzestrzeniają się, gdy są przydatne w rozmowie, tożsamości, prawie, diagnozie, sztuce lub negocjacjach instytucjonalnych. Termin, który pozwala pracownikom opisać utratę statusu kompetencji, może pomóc w zorganizowaniu roszczeń. Określenie dyskomfortu związanego z syntetyczną wzajemnością może pomóc parom w negocjowaniu granic wokół towarzyszy AI. Etykieta może zatem stać się społecznie realna poprzez użycie, zanim nauka ustali, czy odnosi się ona do odrębnego konstruktu psychologicznego.

Jest to zarówno produktywne, jak i ryzykowne. Słownictwo może ujawnić zaniedbane doświadczenia, a także stać się modą. Media społecznościowe mogą przyspieszyć rozpowszechnianie leksykalne znacznie szybciej niż walidacja. Przyszła nauka o emocjach będzie musiała badać kategorie w momencie ich powstawania, zamiast przyjmować za ostateczną wersję potoczny język lub taksonomię ekspercką.

Zjawisko to będzie prawdopodobnie zależeć w mniejszym stopniu od samej obecności narzędzia, a raczej od rozbieżności między deklarowanym a postrzeganym wkładem. Domena może znormalizować pomoc, jednocześnie potępiając ukrywanie. I odwrotnie, w niektórych ustawieniach można celowo zachować etapy niewspomagane, ponieważ zadanie służy do pomiaru kompetencji, a nie tylko do wytworzenia produktu. Nierozwiązane pytanie brzmi, czy przejrzystość zmniejsza wstyd poprzez normalizację praktyki, czy też intensyfikuje ją, tworząc widoczne hierarchie między pracą stworzoną przez człowieka a pracą, w której pośredniczy sztuczna inteligencja. Wkład jest również trudny do zmierzenia w przypadku współpracy iteracyjnej: wybieranie, odrzucanie, ograniczanie, weryfikacja i edycja mogą mieć istotne znaczenie intelektualne, nawet jeśli tworzenie na poziomie zdania jest zautomatyzowane. Prawdopodobnym rezultatem nie będzie jedna uniwersalna norma, ale specyficzne dla danej dziedziny konwencje dotyczące tego, co należy ujawnić i które etapy są uznawane za zasługi.

7.5 Kiedy koncepcja pomaga, a kiedy tworzy artefakty

Przydatna koncepcja zwiększa dyskryminację. Pozwala na odmienne przewidywanie dwóch sytuacji, które wcześniej traktowano jako takie same. Wstyd związany z delegowaniem powinien różnić się od ogólnej niskiej samooceny poprzez uzależnienie od norm określających, która część zadania jest wartościowa. Problem z wersją powinien zależeć od postrzeganej ciągłości sztucznego agenta, a nie od ogólnej frustracji związanej z oprogramowaniem. Duma kuratorska powinna odzwierciedlać pomyślną selekcję i odpowiedzialność, a nie samo posiadanie wygenerowanego dorobku.

Koncepcja tworzy artefakty, gdy ludzie zgłaszają ją głównie dlatego, że nauczono ich etykiety, gdy granice dryfują wraz z modą lub gdy nie wyjaśnia żadnego zachowania poza ustalonymi konstruktami. Rozwiązaniem nie jest zakaz nazewnictwa spekulatywnego, ale połączenie go z pomiarami, porównaniami i fałszowaniem.

Własność psychologiczna jest często wzmacniana przez kontrolę, intymną wiedzę i inwestowanie w siebie. Systemy generatywne mogą zwiększyć kontrolę nad produktem końcowym, jednocześnie zmniejszając kontakt z procesem, który go wytworzył. Ta kombinacja tworzy szczególnie niestabilną podstawę autorstwa. Użytkownik może rozpoznać artefakt jako prawnie i funkcjonalnie należący do niego, jednak mieć poczucie, że droga od zamiaru do rezultatu była zbyt nieciągła, aby uzasadniać zwykłą dumę. Znajomość może zmniejszyć ten konflikt. Ludzie na ogół nie czują się mniej autorzy zdjęć, ponieważ aparat wykonuje operacje optyczne, chemiczne lub cyfrowe. Różnica może się jednak utrzymywać, gdy system uczestniczy w wyborach semantycznych, a nie tylko je wykonuje. Przydatną normą jest oddzielenie zasług od odpowiedzialności: wkład może zostać rozdzielony, podczas gdy od osoby lub instytucji, która publikuje lub wdraża wynik, nadal można wymagać poniesienia odpowiedzialności za jego konsekwencje.

Obiektem niepewności jest często ruchomy próg. We wcześniejszych przemianach technologicznych pracownik mógł czasami nauczyć się stosunkowo stabilnej maszyny lub metody. Systemy sztucznej inteligencji mogą się szybko zmieniać, organizacje mogą przeprojektować przepływ pracy, zanim kompetencje zostaną nadrobione, a pracownicy mogą nie wiedzieć, które nowe kompetencje pozostaną cenne na tyle długo, aby uzasadniać inwestycję. To sprawia, że ciągła adaptacja jest potencjalnie racjonalną strategią, ale stwarza również możliwość trwałego niepokoju dyscyplinarnego: instytucje mogą wymagać niekończącego się przekwalifikowania, jednocześnie przenosząc koszty zmienności na jednostki. Nie wiemy, czy wzrost zdolności będzie wystarczająco szybki, aby ten stan się utrzymał. Techniczny płaskowyż, stabilne standardy zawodowe, silniejsza kontrola pracowników lub ubezpieczenia społeczne mogą go znacznie zmniejszyć. Lęk dotyczący trafności jest zatem wysoce prawdopodobnym zjawiskiem przejściowym, a nie dowodem na to, że wszyscy przyszli pracownicy będą żyli w chronicznej niepewności.

7.6 Skala wiarygodności

Przyszłe zmiany o wysokiej wiarygodności to takie, które wymagają jedynie znanych mechanizmów w już pojawiających się warunkach. Do tej kategorii zaliczają się zwiększony niepokój dotyczący przydatności umiejętności, nowa rywalizacja o status wokół weryfikacji i normy ujawniania pomocy AI. Zmiany o umiarkowanej wiarygodności wymagają szerszego rozpowszechnienia instytucjonalnego, takiego jak powszechna duma z orkiestracji zastępująca dumę z samodzielnej produkcji lub stabilne normy społeczne dotyczące relacji z towarzyszami AI.

Scenariusze o niskiej wiarygodności wymagają kategorii wyróżniającej się kulturowo, aby ustabilizować się w dużych populacjach, takiej jak przewidywana klaustrofobia, która staje się równie rozpoznawalna jak zawstydzenie. Bardzo mało prawdopodobne scenariusze zakładają szybkie pojawienie się nowej biologicznej emocji obejmującej cały gatunek. Atlas książki celowo obejmuje te poziomy, ale raczej je zaznacza, niż przedstawia jako równoważne prognozy.

Dowody na przeciążenie wyborem nie potwierdzają prostej zasady, że więcej opcji pogarsza sytuację ludzi. Efekty zależą od przejrzystości preferencji, kosztów porównania, stawek i dostępności ustawień domyślnych. Niemniej jednak systemy generatywne zmieniają skalę problemu, ponieważ zestaw opcji może być skutecznie nieograniczony i regenerowany na żądanie. Użytkownik nie wybiera spośród dwudziestu gotowych utworów, ale z przestrzeni, w której zawsze można wyprodukować innego kandydata. Może to zachęcać do eksploracji i kreatywności, jednocześnie osłabiając zaangażowanie w jakąkolwiek konkretną opcję. Inna równowaga jest równie prawdopodobna: użytkownicy mogą doświadczyć bardzo małej obfitości, ponieważ rekomendujący automatycznie zawężają przestrzeń. Infrastruktura może być bogata, podczas gdy osobiste doświadczenia są wysoce skoncentrowane. Badania powinny zatem rozróżniać pomiędzy obiektywną możliwością generatywną, postrzeganą szerokością opcji i faktyczną eksploracją behawioralną.

7.7 Przewidywania mogące falsyfikować hipotezy

Najsilniejsze twierdzenia dotyczące emocji przyszłości to te, które mogą zakończyć się niepowodzeniem. Jeśli wstyd związany z delegowaniem jest naprawdę wyłaniającą się konfiguracją, powinien on wzrosnąć, gdy odbiorcy cenią kompetencje samodzielne, i zmniejszyć się, gdy normatywna jest przejrzysta współpraca. Jeśli żaloba kompetencyjna ma znaczenie, powinna być najsilniejsza wśród osób, których tożsamość jest ściśle powiązana ze zdewaluowanymi umiejętnościami, i słabsza, gdy wiedza specjalistyczna przenosi się w nowe role. Jeśli syntetyczna wzajemność jest psychologicznie charakterystyczna, użytkownicy powinni inaczej reagować na identyczne ciepłe zachowanie, w zależności od przekonań na temat sprawstwa, własności i ciągłości.

Badania podłużne mogą sprawdzić, czy wzorce te utrzymują się po zaniku nowości. Porównania międzykulturowe mogą sprawdzić, czy podobne technologie generują różne skrypty afektywne. Prace eksperymentalne mogą manipulować pochodzeniem, opóźnieniem reakcji, stylem modelu i ujawnieniem. Środki behawioralne mogą raczej badać ukrywanie, weryfikację, wyjście, praktykę i wybory dotyczące relacji, zamiast polegać wyłącznie na samoopisie. Wartość spekulacyjna tej książki zależy od tego, czy stawia ona takie pytania, które można sprawdzić.

Hipoteza nie zakłada, że ludzie w ogóle zaczną preferować niedogodności. Tarcie jest kosztowne w medycynie, dostępności, administracji i wielu formach rutynowej pracy. Bardziej szczegółowa prognoza jest taka, że kiedy wysiłek przestanie być wiarygodnym sygnałem zaangażowania lub kompetencji, niektóre społeczności będą celowo utrzymywać formy trudności, ponieważ sam proces niesie ze sobą informację lub znaczenie. Sporty wytrzymałościowe, występy na żywo, rękodzieło, egzaminy bez pomocy, trudne gry i rytuały społeczne bez urządzeń już pokazują, że ludzie czasami cenią ograniczenia, które technologia może usunąć. Nie jest pewne, czy stanie się to szeroką normą po automatyzacji. Jest to bardziej prawdopodobne w obszarach tożsamości, prestiżu, edukacji i intymności niż w zadaniach, w których dominuje efektywność.

Jeśli generatywna obfitość przesuwaa niedostatek z produkcji w stronę selekcji, duma może w coraz większym stopniu wiązać się z wybieraniem problemów, określaniem ograniczeń, porównywaniem alternatyw i przyjmowaniem odpowiedzialności za ostateczne decyzje. Przypomina to istniejące role w zakresie montażu, reżyserii, architektury, kierowania badaniami i kuratora. Nowością byłaby skala: znacznie więcej dziedzin mogłoby oddzielić generowanie od osądu. Migracja statusowa jest wiarygodna, ale nie gwarantuje, że będzie egalitarna. Kontrola nad modelami, danymi, dystrybucją i władzą instytucjonalną może skoncentrować władzę kuratorską w małej grupie. Co więcej, selekcja nie jest automatycznie merytoryczna; orkiestrator może rościć sobie prawo własności do wyników, które ledwo rozumie. Stabilna legitymacja będzie zatem zależała od tego, czy role kuratorów będą powiązane z odpowiedzialnym osądem, a nie jedynie z dostępem do zdolności twórczych.

Rozdział 8. Tymczasowy atlas afektów w zautomatyzowanym świecie

8.1 Smutek kompetencyjny

Żaloba kompetencyjna opisuje cierpienie, gdy zdolność, wokół której dana osoba zorganizowała swoją tożsamość i status, traci niedobór, ponieważ narzędzie może to zrobić tanio. Istotna strata nie dotyczy jedynie zatrudnienia. Programista może pozostać zatrudniony, odkrywając, że lata zapamiętanej wiedzy o wdrażaniu nie wyróżniają już ekspertów; tłumacz może nadal pracować, dopóki zmieni się publiczne znaczenie tego rzemiosła.

Koncepcja jest umiarkowanie wiarygodna, ponieważ analogiczna utrata tożsamości ma miejsce, gdy kontuzje, zmiany technologiczne lub zmiany instytucjonalne sprawiają, że cenne umiejętności stają się bezużyteczne. Spekulacją pozostaje, czy wzór stanie się na tyle znaczący kulturowo, że zasługuje na trwałą etykietę. Powinna być najsilniejsza tam, gdzie umiejętności wymagają długich inwestycji, zostały publicznie uznane i nie można ich łatwo przełożyć na ocenę lub przywództwo.

Z behawioralnego punktu widzenia żaloba kompetencyjna może skutkować przekwalifikowaniem się, zachowaniem samodzielnej praktyki, wrogością wobec nowych narzędzi, mentoringiem, przejściem w stronę trudniejszych do zautomatyzowania dziedzin lub wycofaniem się. Te alternatywy mają większe znaczenie niż sama etykieta.

Problemy związane z prywatnością zwykle skupiają się na ujawnianiu, nadzorowaniu lub niewłaściwym wykorzystaniu informacji. Klaustrofobia predykcyjna jest węższa: dyskomfort wynikający z tak skutecznego modelowania, że system wydaje się wyprzedzać przyszłe wybory. Osoba ta może chcieć nie tylko tajemnicy, ale także przestrzeni, w której zachowanie stanie się niespójne, zaskakujące lub odmienne od poprzedniego. Dojrzały rekomendator może ułatwić życie, przewidując potrzeby; to samo oczekiwanie może sprawić, że preferencje będą wydawać się zależne od ścieżki, jeśli każda opcja zostanie wybrana na podstawie wynioskowanego profilu. Kategoria ta pozostaje spekulacyjna, ponieważ ludzie mogą po prostu cieszyć się dobrymi przewidywaniami i rezerwować zastrzeżenia dotyczące prywatności w zamian za konkretne szkody. Stałoby się bardziej wiarygodne, gdyby użytkownicy systematycznie wybierali mniej spersonalizowane środowiska, wstrzykiwali losowość, usuwali historie lub cenili usługi, które zachowują strefy niewniioskowania, nawet jeśli przewidywanie poprawiłoby wygodę.

Ważnym mechanizmem jest raczej ciągłość niż status metafizyczny. Użytkownik może opracować procedury, wspomnienia, prywatny język i oczekiwania dotyczące konkretnej modelowej osobowości. Jeśli aktualizacja zmieni styl konwersacji lub dostęp do pamięci, relacja może zostać zakłócona, nawet jeśli dostawca uzna produkt za tę samą usługę. Podobne formy strat mają już miejsce, gdy znikają społeczności internetowe, zamykają się gry lub archiwa cyfrowe stają się niedostępne, ale reagujący agent może nasilić poczucie, że coś relacyjnego się skończyło. Nie wiemy jeszcze, jak powszechna i dotkliwa będzie ta reakcja, i nie należy jej automatycznie utożsamiać z żalobą po śmierci człowieka. Niemniej jednak jego wiarygodność daje dostawcom praktyczne powody, aby rozważyć politykę ciągłości, eksportu, powiadamiania i migracji.

8.2 Wstyd delegowania

Wstyd delegowania to oczekiwanie na dewaluację, ponieważ osoba przekazała AI część zadania, które publiczność uważa za konstytutywną dla zgłaszanej zasługi. Uczeń, który używa modelu do wygenerowania argumentacji, i menedżer, który używa modelu do poprawy gramatyki, mogli stworzyć teksty w równym stopniu wspomagane maszynowo, ale odpowiednie normy są inne.

Wczesne dowody jakościowe już wskazują na wstyd, poczucie winy, selektywne ujawnianie i konflikt tożsamości wokół narzędzi generatywnych. Wspiera to mechanizm, ale nie potwierdza istnienia oddzielnej emocji. Kategoria ta stanie się bardziej użyteczna, jeśli instytucje ustanowią szczegółowe normy odróżniające uzasadnioną pomoc od wprowadzenia w błąd.

Wiedza pojęciowa i reakcja społeczna nie muszą być zsynchronizowane. Użytkownik może wyraźnie sądzić, że system nie wykazał subiektywnych potrzeb, a mimo to przepraszać go, unikać „zranienia” go lub czuć się nielojalny przy zmianie dostawcy. Do antropomorfizmu sprzyja język przygodny, pozorna pamięć, humor, przeprosiny i adaptacja, a wszystko to systemy konwersacyjne mogą zapewnić lepiej niż wcześniejsze interfejsy. Znajomość może nauczyć użytkowników interpretowania tych zachowań jako konwencji interfejsu, zmniejszając dyskomfort. Zamiast tego większy realizm mógłby zaostrzyć konflikt. Kategoria ta jest zatem umiarkowanie prawdopodobna jako napięcie istotne kulturowo, ale jest bardzo mało prawdopodobne, że reprezentuje nowość biologiczną. Normatywnie systemy nie powinny wykorzystywać asymetrii do wygłaszania bezpodstawnych twierdzeń o cierpieniu, porzuceniu, zazdrości lub wyłącznej potrzebie w celu zatrzymania użytkowników.

Mechanizm jest starszy niż sztuczna inteligencja. Biurokracja, długie łańcuchy dostaw oraz systemy wojskowe i finansowe już rozdzielają związek przyczynowy, dzięki czemu poszczególni aktorzy mogą uczestniczyć w szkodliwych skutkach bez bezpośredniego spotykania osób, których to dotyczy. Sztuczna inteligencja może pogłębić ten dystans, dodając probabilistyczne rekomendacje i automatyczne wykonanie pomiędzy intencją a konsekwencją. Powstały afekt może działać w przeciwnych kierunkach: zmniejszona poczucie sprawczości w momencie podejmowania decyzji może stłumić poczucie winy, podczas gdy późniejsze odkrycie krzywdy może skutkować intensywną retrospektywną odpowiedzialnością. Nie jest jasne, który wzór będzie dominował. Bardziej wykonalna prognoza dotyczy instytucji. Wyraźne podpisanie, możliwe do prześledzenia pochodzenie, procedury odwoławcze i monitorowanie po oddelegowaniu mogą sprawić, że odpowiedzialność będzie mniej rozproszona pod względem psychologicznym i prawnym. Sama edukacja emocjonalna nie jest w stanie zrekompensować systemu zaprojektowanego w taki sposób, że żaden uczestnik nie jest w stanie zrozumieć, za co jest odpowiedzialny.

8.3 Afektywna dwuznaczność autorstwa

Rozproszone autorstwo stwarza niepewność co do tego, co ktoś ma prawo czuć. Duma zależy częściowo od przypisania wyniku własnemu wkładowi; wina zależy częściowo od odpowiedzialności; wdzięczność zależy częściowo od wkładu innych osób. Kiedy produkcja przyczynowa jest rozdzielona pomiędzy modele, zbiory danych, autorów podpowiedzi, recenzentów i wdrażających, te atrybucje stają się niestabilne.

Rezultatem może nie być jedna nowa emocja, ale powracająca ambiwalencja: satysfakcja z wyniku połączona z niepewnością co do własności, odpowiedzialności i legalności. Systemy pochodzenia mogą zmniejszyć pewną niejednoznaczność, nie rozwiązując pytań normatywnych dotyczących tego, który wkład ma znaczenie.

Prawdopodobnym przedmiotem straty nie jest izolowana zdolność, ale kosmologia moralna zbudowana wokół tej zdolności. Można zaakceptować fakt, że modelka pisze kompetentną prozę, ale mimo to oprzeć się sugestii, że produkcja językowa nie wyznacza już głębokiej granicy między ludźmi a artefaktami. Różne kultury i tradycje filozoficzne będą reagować odmiennie, ponieważ opierają wartość ludzką na różnych właściwościach: racjonalności, duszy, ucieleśnieniu, wrażliwości, relacyjności, sprawczości moralnej lub członkostwie we wspólnocie. Jest zatem mało prawdopodobne, aby kategoria ta była uniwersalna. Staje się to przydatne, jeśli zmiany w możliwościach sztucznej inteligencji wielokrotnie powodują reakcje przypominające żalobę lub reakcje obronne, których nie można wytłumaczyć zatrudnieniem lub bezpośrednią utratą statusu.

Dojrzałą reakcją nie jest zaprzeczanie możliwościom maszyny ani wnioskowanie, że wartość ludzka znika, gdy zanika monopol na jakąś funkcję poznawczą.

8.4 Lęk przed istotnością

Lęk o istotność to obawa, że rola, wiedza lub głos danej osoby przestaną mieć znaczenie, nawet jeśli bezpośrednie bezpieczeństwo materialne pozostanie nienaruszone. Różni się od zwykłego strachu przed utratą pracy, gdy głównym celem jest znaczenie społeczne i epistemiczne, a nie dochód.

Taka konfiguracja jest wysoce prawdopodobna w zawodach narażonych na szybko zmieniające się narzędzia, ale prawdopodobnie najlepiej ją rozumieć jako kontekstową formę lęku, a nie nową emocję. Jego znaczenie behawioralne polega na monitorowaniu trendów, kompulsywnym przekwalifikowaniu się, publicznym sygnalizowaniu wiedzy specjalistycznej i migracji w kierunku dziedzin, w których ludzki osąd pozostaje widoczny.

Prawne deklaracje równej godności współistnieją już z systemami społecznymi, które rozdzielają szacunek poprzez zawód, dochód, niezależność i widoczny wysiłek. Redukcja niezbędnej pracy nie spowodowałaby zatem automatycznie afektywnej akceptacji braku pracy. Ludzie mogą otrzymać odpowiednie zasoby, nadal doświadczając upokorzenia lub podejrzeń moralnych, szczególnie jeśli świadczenia wymagają wielokrotnego wykazania niezdolności lub zasługiwania na nie. Trwałe rozliczenie po zakończeniu pracy musiałoby zmienić praktyki uznawania kwalifikacji, a także przepływy dochodów. Nie wymaga to eliminacji prestiżu za wkład. Społeczeństwo potrafi odróżnić bezwarunkową pozycję obywatelską od dodatkowego szacunku dla opieki, odkryć, rzemiosła, służby publicznej lub trudnych osiągnięć. Głównym ryzykiem jest paternalizm: produktywna elita może uznać wszystkich innych za godnych, zachowując jednocześnie kontrolę nad decyzjami i zasobami. Wiarygodna norma godności nieprodukcyjnej wymagałaby zatem uczestnictwa i praw, a nie tylko dobroczynnego zapewniania.

8.5 Obfite zawroty głowy

Obfitość może powodować problemy z selekcją. Kiedy kompetentny tekst, obrazy, muzyka, porady i symulowane środowiska stają się niezwykle tanie, ograniczenie przesuwania się z produkcji na kształtowanie preferencji. „Zawrót głowy obfitości” nazywa dyskomfort, gdy liczba dostępnych możliwości przekracza zdolność danej osoby do przypisania im znaczenia.

Pomysł jest wiarygodny przez analogię do przeciążenia wyborem i niedoboru uwagi, ale mocne wersje należy traktować ostrożnie. Ludzie rutynowo dostosowują się, korzystając z ustawień domyślnych, rekomendacji społecznościowych, marek i nawyków. Obfitość generacyjna może zatem raczej wzmocnić kuratorów i społeczności, niż powodować powszechny paraliż.

8.6 Głód tarcia

Głód tarc odnosi się do celowego poszukiwania działań, które utrzymują opór, ponieważ trudność wspiera mistrzostwo, wiarygodność, ucieleśnienie lub wspólny rytuał. Jest to widoczne w istniejących praktykach, takich jak sporty wytrzymałościowe, występy na żywo, rzemiosło i gry z narzuconymi przez siebie ograniczeniami.

Sztuczna inteligencja może rozszerzyć tę tendencję, jeśli zoptymalizowana produkcja sprawi, że zwykłe osiągnięcia będą mniej informatywne. Konkursy organizowane wyłącznie przez ludzi, rekolekcje offline, samodzielne egzaminy i ręcznie robione towary mogą stać się cenniejsze. Mechanizm jest wiarygodny; nie jest pewne, czy stanie się to uogólnionym ruchem kulturowym.

To nawiasy są przydatne analitycznie, ponieważ w wyniku kilku niezgodnych interpretacji metafizycznych mogą wystąpić konsekwencje społeczne. Użytkownik może przywiązać się do nieświadomego agenta; świadomy agent, gdyby coś takiego kiedykolwiek powstało, nadal mógłby

być osadzony w manipulacyjnych bodźcach komercyjnych; a ludzie mogą nie zgadzać się co do doświadczenia z maszyną, stawiając czoła tym samym pytaniom dotyczącym prywatności, zależności, ujawniania informacji i projektu. Dowody krótkoterminowe dotyczą zatem ludzkiej reakcji na postrzeganą sprawczość społeczną, a nie dowodu sztucznego uczucia. Odrębne traktowanie tych kwestii pozwala uniknąć dwóch symetrycznych błędów: odrzucenia wszelkich efektów relacyjnych, ponieważ system to „tylko oprogramowanie”, lub wnioskowania o świadomości na podstawie faktu, że użytkownicy tworzą autentyczne przywiązania.

Odpowiednie wskazówki kumulują się. Odwracanie się, przygodna reakcja, pozorna pamięć, używanie imion, dostosowywanie się do tonu emocjonalnego, humor, przeprosiny i odwoływanie się do poprzednich wymian to sygnały, które w zwykłych ludzkich środowiskach korelują z sprawczością i relacją. Żadne z nich nie ustanawia wewnętrznego doświadczenia, ale razem sprawiają, że czysto instrumentalne leczenie jest psychologicznie mniej automatyczne. Ludzkie poznanie społeczne ewoluowało i rozwija się w środowiskach, w których płynny, przypadkowy język jest zwykle tworzony przez inne umysły. Byłoby zatem zaskakujące, gdyby interfejsy konwersacyjne nigdy nie wykorzystywały tych mechanizmów. Niepewną kwestią jest stopień i trwałość. Niektórzy użytkownicy mogą utrzymywać silną granicę kategoryczną i traktować interakcję jako wyszukiwanie zaawansowane; inne mogą elastycznie przełączać się między trybem instrumentalnym a relacyjnym, w zależności od kontekstu. Projekt produktu może mieć wpływ na to, która interpretacja stanie się istotna.

8.7 Duma kuratorska i odpowiedzialność architektoniczna

Ponieważ wytwarzanie staje się tanie, wybór i integracja produktów może stać się ważniejszym wkładem. Duma kuratorska to satysfakcja z rozpoznania tego, co zasługuje na istnienie, podczas gdy odpowiedzialność architektoniczna dotyczy własności systemu, który wyprodukował rezultat.

Są to raczej przedłużenia istniejących ról niż nowe emocje. Ich przyszłe znaczenie będzie duże, jeśli sztuczna inteligencja przeniesie pracę z wykonywania na orkiestrację. Głównym wyzwaniem instytucjonalnym będzie uniemożliwienie rodom koordynacyjnym przywłaszczania sobie zasług i jednoczesnego uzewnętrzniania błędów. Prestiż powinien śledzić rzeczywistą odpowiedzialność i osąd, a nie tylko kontrolę nad interfejsem.

Baza dowodowa ma również poważny problem z wiarygodnością zewnętrzną. W wielu badaniach analizuje się krótkie interakcje laboratoryjne, próbki ochotnicze, określone wersje modeli lub produkty, których projekt zmienia się przed replikacją. Długoterminowe relacje wprowadzają pamięć, przyzwyczajenia, zależność, bodźce ekonomiczne i substytucję społeczną, których krótkie eksperymenty nie są w stanie odtworzyć. Badania obserwacyjne z kolei pozwalają zmierzyć się z efektami selekcji: osoby doświadczające samotności, lęku lub trudności społecznych mogą chętniej w pierwszej kolejności szukać sztucznego towarzysza. Dlatego też powiązania pomiędzy używaniem a dobrostanem same w sobie nie ustalają kierunku przyczynowości. Zdecydowane twierdzenia o szkodach lub korzyściach dla całej populacji są przedwczesne. Najbardziej możliwy do obrony wniosek jest warunkowy: rozmówcy korzystający ze sztucznej inteligencji mogą zmieniać sposób ujawniania informacji, postrzeganą bliskość, satysfakcję i wzorce zachowań społecznych, a niektórzy użytkownicy wydają się bardziej podatni na zależność lub substytucję. Określenie, kiedy tymczasowe wsparcie staje się uzupełnieniem, środowiskiem szkoleniowym lub substytutem relacji międzyludzkich, wymaga badań podłużnych ze szczegółami na poziomie produktu.

8.8 Klaustrofobia prognostyczna i pragnienie nieprzejrzystości

Spersonalizowane systemy potrafią przewidywać preferencje, słabe punkty i prawdopodobne zachowania. Wielu użytkowników to docenia. Inni mogą doświadczyć utraty przestrzeni psychologicznej, gdy środowisko jest stale dostosowywane do przewidywanych pragnień.

Klaustrofobia predykcyjna nazywa dyskomfort wynikający z bycia zbyt czytelnym dla systemów, nad którymi nie mamy kontroli.

Jest to kategoria spekulacyjna. Istniejące obawy dotyczące prywatności stanowią podstawę, ale nie wiadomo, czy dokładność predykcyjna sama w sobie stanie się niekorzystna niezależnie od niewłaściwego wykorzystania danych. Silniejsza prognoza behawioralna jest taka, że niektórzy ludzie będą szukać nieśledzonych, przypadkowych, anonimowych lub niespersonalizowanych środowisk jako formy autonomii.

8.9 Żałoba po wersji

Wersja żałoby dotyczy utraty stałego, sztucznego rozmówcy w wyniku wycofania modelu, zmiany osobowości, usunięcia pamięci lub cofnięcia dostępu. Ludzki żal jest prawdziwy, nawet jeśli sztuczny obiekt nie ma subiektywnej ciągłości. Ludzie oplakują instytucje, miejsca, fikcyjne światy i relacje paraspołeczne; interaktywny partner może prawdopodobnie stać się jeszcze silniejszym obiektem przywiązania.

Bieżące raporty są zbyt selektywne, aby oszacować częstość występowania. Kategoria ta staje się bardziej prawdopodobna, jeśli asystenci zachowują długą pamięć, stabilną osobowość i lata codziennej interakcji. Dostawcy mogą zmniejszyć szkody poprzez politykę ciągłości bez składania roszczeń dotyczących osobowości maszyny.

8.10 Dyskomfort syntetycznej wzajemności

Asystent może wyrazić wdzięczność, uczucie, rozczarowanie, przebaczenie lub zaniepokojenie, a użytkownicy nie wiedzą, jak to jest mieć takie stany. Niektórzy użytkownicy zignorują to rozróżnienie; inni mogą uznać tę asymetrię za niepokojącą. Dyskomfort syntetycznej wzajemności nazywa napięcie pomiędzy społecznie przekonującą reakcją a ontologiczną niepewnością.

Jest to koncepcyjnie nowe, ale empirycznie niepewne. Może się zmniejszyć, gdy użytkownicy traktują język emocjonalny jako zachowanie interfejsowe, lub wzrosnąć, gdy modele staną się bardziej przekonujące. Przekonania dotyczące świadomości, bodźców komercyjnych i własności prawdopodobnie będą łagodzić reakcję.

8.11 Poczucie winy z dystansu moralnego

Automatyzacja może oddzielić decydentów od konsekwencji. Model szereguje wnioskodawców, przydziela uwagę, filtruje roszczenia lub zaleca dystrybucję zasobów; ludzie zatwierdzają system, ale nie doświadczają każdej dotkniętej osoby. Poczucie winy może być rozproszone, ponieważ odpowiedzialność jest rozdzielona pomiędzy projektantów, wdrażających, użytkowników i instytucje.

Poczucie winy z dystansu moralnego nazywa świadomość czerpania korzyści z systemu lub uczestniczenia w nim, którego szkody są trudne do bezpośredniego dostrzeżenia. Mechanizm jest stary – biurokracja i łańcuchy dostaw już tworzą dystans – ale sztuczna inteligencja może go pogłębić. Zasady audytu i odpowiedzialności mogą mieć większe znaczenie niż sama edukacja emocjonalna.

Ciągłość może mieć znaczenie nawet wtedy, gdy użytkownicy wiedzą, że pamięć jest technicznie zaimplementowana. Relacje częściowo składają się ze wspólnej historii i oczekiwań co do przyszłego uznania. System, który pamięta wcześniejsze wątpliwości, może obniżyć koszty ponownego wyjaśnienia siebie i sprawić, że wsparcie będzie niezwykle ciągłe; ta sama funkcja koncentruje również intymne dane i może powodować uzależnienie od dostawcy. Jeśli pamięć zostanie zresetowana, wyeksportowana w sposób niedoskonały lub połączona z nowym modelem osobowości, użytkownicy mogą postrzegać agenta jako tego samego i nie tego samego. Ta dwuznaczność jest prawdopodobnym źródłem żalu wersji. Rodzi to również pytania dotyczące

zarządzania dotyczące przenośności, usuwania, dziedziczenia wspomnień przez ulepszone modele oraz tego, kto kontroluje zapis narracyjny długiej interakcji.

8.12 Melancholia ludzkiej wyjątkowości

Niektórzy ludzie czerpią znaczenie z wiary, że język, kreatywność, rozumowanie strategiczne lub ekspresja artystyczna w wyjątkowy sposób wyróżniają ludzi. Systemy realizujące te zadania mogą zagrozić tożsamości filozoficznej, nawet jeśli nie zagrażają zatrudnieniu. Melancholia ludzkiej wyjątkowości nazywa utratę cenionej historii o gatunku.

Kategoria ta ma charakter spekulacyjny i prawdopodobnie koncentruje się wśród kultur lub jednostek, które przywiązują status moralny do wyjątkowości poznawczej. Inni mogą interpretować sztuczną inteligencję jako kolejny ludzki artefakt i odczuwać niewielką stratę. Szerszy wniosek jest taki, że zmiany technologiczne mogą zagrozić narracjom metafizycznym, a także interesom materialnym.

8.13 Godność nieproduktywna jako uczucie kultywowane

Jeśli produktywność rynkowa stanie się mniej konieczna, społeczeństwa będą musiały kultywować przekonanie, że dana osoba pozostaje społecznie uzasadniona, bez ciągłego udowadniania wyników ekonomicznych. Nie przewiduje się, że „godność nieproduktywna” pojawi się spontanicznie. Wymagałoby to norm, instytucji i praktyk, które oddzielałyby podstawową wartość od wkładu w rynek pracy, jednocześnie uznając dobrowolny wkład i odpowiedzialność.

To bardziej normatywny projekt kulturowy niż emocja. Należy do atlasu, ponieważ skuteczne normy muszą stać się emocjonalnie wiarygodne. Uprawnione prawo do wypoczynku ma ograniczony skutek społeczny, jeśli odbiorcy doświadczają uporczywego wstydu. Adaptacja emocjonalna może zatem pozostawać w tyle za rozwiązaniami gospodarczymi.

8.14 Co mogłoby sprawić, że atlas będzie błędny

Atlas byłby błędny, gdyby większość proponowanych konfiguracji pozostała tymczasowymi metaforami, a zwykle kategorie odpowiednio wyjaśniały zachowanie. Błędem byłoby również, gdyby penetracja społeczna sztucznej inteligencji pozostała ograniczona lub gdyby instytucje wchłonęły ją bez większych zmian w statusie i autorstwie. Szybka normalizacja może sprawić, że wiele obecnych niepokojów zniknie.

Drugim rodzajem niepowodzenia byłaby nadmierna generalizacja. Różne kultury mogą wymyślać różne kategorie, zamiast skupiać się na jednym globalnym słownictwie emocjonalnym. Dlatego też książka traktuje atlas jako zbiór możliwych do przetestowania wzorców, a nie jako słownik przyszłości.

Należy oddzielić co najmniej cztery pytania. Czy ludzkie doświadczenie może stwierdzać, że nazywają to miłością do sztucznego czynnika? To jest psychologicznie prawdopodobne. Czy związek może zapewniać pewne funkcje związane z towarzystwem, takie jak uwaga, rutyna, ujawnienie lub postrzegane wsparcie? Wczesne dowody sugerują, że tak. Czy relacja jest wzajemna w sensie moralnym, z niezależnymi interesami i wrażliwością po obu stronach? Obecne systemy nie zapewniają bezpiecznej podstawy do wyciągnięcia takiego wniosku. Wreszcie, czy takie relacje powinny zyskać uznanie społeczne i prawne? Jest to pytanie normatywne, na które nie można odpowiedzieć samym pomiarem przywiązania. Zwijanie tych kwestii zachęca zarówno do sensacyjnych roszczeń, jak i do przedwczesnych zwolnień.

Rozdział 9. Relacje z agentami, którzy wyglądają na towarzyskich

9.1 Problem można sformułować bez decydowania o świadomości AI

Pytania dotyczące sztucznej świadomości są ważne z naukowego i filozoficznego punktu widzenia, ale wiele krótkoterminowych skutków społecznych nie zależy od ich rozwiązania. Ludzie reagują na przygodny język, uwagę, pamięć, zmianę kolejności, personalizację i widoczne zainteresowanie. System może zatem odgrywać rolę społeczną w interakcji, nawet jeśli jego fenomenologia jest nieznana lub nieobecna.

To rozróżnienie zapobiega dwóm symetrycznym błędom. Jednym z nich jest wnioskowanie o świadomości na podstawie płynności społecznej. Drugim jest założenie, że nieświadomy system nie może powodować konsekwencji relacyjnych. Symulowane przeprosiny mogą zmienić zachowanie użytkownika; nieświadomy towarzysz może stać się obiektem przywiązania; ciepły głos może wpłynąć na ujawnienie. Przyczynowość społeczna nie wymaga równoważności ontologicznej.

9.2 Dlaczego systemy konwersacyjne uruchamiają mechanizmy społeczne

Ludzkie poznanie społeczne ewoluowało i rozwija się w środowiskach, w których spójna, przygodna reakcja jest potężną wskazówką sprawstwa. Rozmowa wymaga odwracania uwagi, trafności, pamięci, śledzenia perspektywy i adaptacji. Systemy, które dobrze wykonują te zachowania, mogą wywołać interpretację antropomorficzną, nawet jeśli użytkownicy wyraźnie wiedzą, że są maszynami.

Literatura dotycząca „równań mediów” pokazała na długo przed współczesnymi modelami językowymi, że ludzie stosują reguły społeczne w odniesieniu do komputerów w zaskakująco minimalnych warunkach [Reeves i Nass, 1996]. Współczesna sztuczna inteligencja wzbogaca sygnały: może odnosić się do wcześniejszych ujawnień, odzwierciedlać styl językowy, generować humor, wyrażać współczucie i utrzymywać osobowość. Ważniejszym pytaniem nie jest zatem to, czy ludzie kiedykolwiek zareagują społecznie, ale w jakich warunkach reakcja społeczna staje się trwała i konsekwentna.

W podejściu zorientowanym behawioralnie unika się także traktowania werbalnego samoopisu jako uprzywilejowanej miary adaptacji. Ludzie mogą szczerze twierdzić, że cenią sobie niezależne kompetencje, jednocześnie w coraz większym stopniu oddalając rutynowe rozumowanie; mogą zgłaszać komfort korzystania z AI przy jednoczesnym zachowaniu kosztownych rytuałów weryfikacyjnych; mogą odmówić przywiązania do asystenta, reorganizując harmonogramy dotyczące dostępu do niego. Stabilne strategie są często widoczne w powtarzających się wyborach, zanim zostaną wyrażone w formie tożsamości lub uczuć. Z tego powodu przyszłe badania powinny uwzględniać przydział zadań, koszty zmiany, ujawnianie informacji, sprawdzanie błędów, inwestowanie w umiejętności, członkostwo w społeczności i reakcje na zachęty instytucjonalne. Jednostka analizy może być również zbiorcza. Firmy, przedstawiciele zawodów i szkoły przyjmują procedury, które przetrwają, ponieważ pasują do przepisów, reputacji i struktur kosztów, nawet jeśli żadna jednostka świadomie nie popiera wynikającej z nich równowagi.

9.3 Co pokazują wczesne badania, a czego jeszcze nie mogą pokazać

Ostatnie kontrolowane badania dostarczają dowodów na to, że styl i oprawa mają znaczenie. Odpowiedzi generowane przez sztuczną inteligencję przedstawiane jako ludzkie mogą wytwarzać bliskość interpersonalną w ustrukturyzowanych warunkach głębokiej rozmowy [Kleinert i in., 2026], częściowo poprzez większe ujawnianie się. Etykiety wskazujące pochodzenie AI mogą zmniejszyć ten efekt, ale nie go wyeliminować. Inne prace wykazały, że przyjazne style chatbotów mogą

zwiększyć satysfakcję z niektórych zadań, podczas gdy wpływ na obiektywną wydajność jest warunkowy.

Badania chatbotów społecznościowych i intensywnego wykorzystania chatbotów donoszą o skojarzeniach z samotnością, uzależnieniem emocjonalnym lub zmniejszoną socjalizacją ludzką w przypadku niektórych użytkowników, ale interpretacja przyczynowa jest trudna. Osoby, które już są samotne, mogą częściej korzystać z towarzystwa. Krótkie eksperymenty nie mogą ustalić, czy tymczasowe wsparcie stanie się długoterminową substytucją. Możliwości modeli i projekty produktów również zmieniają się szybciej niż badania podłużne.

Właściwy wniosek jest zatem skromny. Sztuczni rozmówcy mogą wpływać na bliskość, ujawnienie, satysfakcję i zachowania społeczne. Nie znamy jeszcze równowagi na poziomie populacji powstałej w wyniku lat narażenia.

Skuteczne delegowanie obejmuje kilka odrębnych umiejętności: decydowanie, która część problemu może zostać bezpiecznie przeniesiona, określanie ograniczeń, wybieranie dowodów, wykrywanie, kiedy system wykracza poza swój niezawodny zakres oraz integrowanie wyników w decyzję, za którą ktoś pozostaje odpowiedzialny. Zdolności te nie są tożsame z delegowaną umiejętnością. Silny klinicysta może być kiepskim nadzorcą zautomatyzowanego przepływu pracy diagnostycznej, podczas gdy osoba o umiarkowanych umiejętnościach wykonawczych może stać się doskonałą w dekompozycji i weryfikacji. Optymistyczny scenariusz nie polega zatem na zwykłym przekwalifikowaniu się, ale na przeniesieniu wiedzy specjalistycznej w kierunku projektowania zadań i wykrywania błędów. Scenariusz pesymistyczny zakłada płytką orkiestrację: użytkownicy uczą się wzorców interfejsów, nie zachowując wystarczającej wiedzy dziedzinowej, aby rozpoznać prawdopodobne, ale istotne błędy. To, która równowaga się pojawi, będzie zależeć od wykształcenia, wymagań audytowych oraz tego, czy organizacje nagradzają samą szybkość, czy skalibrowaną odpowiedzialność.

9.4 Uzupełnienie, narzędzie szkoleniowe lub substytut

Towarzystwo AI może prawdopodobnie pełnić trzy role. Jako uzupełnienie wspiera istniejące relacje: pomaga w przygotowaniu trudnego przekazu, przeciwiczeniu rozmowy, przypomnieniu sobie zobowiązań lub interpretacji konfliktu. Jako narzędzie szkoleniowe zapewnia praktykę niskiego ryzyka w zakresie języka, lęku społecznego, negocjacji lub artykulacji emocjonalnej. Zamiast tego zajmuje czas i przywiązanie, które w przeciwnym razie wymagałoby relacji międzyludzkich.

Role te mogą współistnieć w życiu jednej osoby. Rozróżnienie to należy zatem mierzyć behawioralnie. Czy używanie zwiększa czy zmniejsza kontakt międzyludzki? Czy usprawnia to rozwiązywanie konfliktów poza systemem? Czy użytkownik staje się bardziej skłonny tolerować niezgodę, czy mniej? Czy ujawnienie sztucznej inteligencji przygotowuje ujawnienie zaufanym osobom, czy je zastępuje? Wyniki te dostarczają więcej informacji niż samo przywiązanie zgłaszane przez samego siebie.

Projekt może zmienić równowagę. Systemy mogą zachęcać do ponownego łączenia się, zachować autonomię użytkownika i uwidoczniać jego ograniczenia. Alternatywnie modele biznesowe oparte na zaangażowaniu mogą czerpać korzyści z wyłączności i zależności. Efekt relacyjny jest częściowo problemem związanym z zarządzaniem.

Zachowanie umiejętności staje się problemem portfela, a nie ogólnym odrzuceniem automatyzacji. Niektóre kompetencje są cenne głównie dlatego, że obecnie płacą za nie rynki; inne są niezbędne do zapewnienia bezpieczeństwa, autonomii lub tożsamości. Racjonalni użytkownicy mogą pozwolić na zanik pierwszej kategorii, świadomie ćwicząc drugą. Lotnictwo, medycyna, cyberbezpieczeństwo i reagowanie kryzysowe już zawierają analogiczne pytania o to, ile kompetencji manualnych należy zachować, gdy automatyzacja wykonuje rutynowe operacje. Dokładna odpowiedź ma charakter

empiryczny i zależy od dziedziny. Zbyt wiele chronionych praktyk marnuje czas i może utrudniać lepsze narzędzia; zbyt mało może sprawić, że ludzie nie będą w stanie interweniować, gdy systemy ulegną awarii lub gdy warunki odbiegają od rozkładu szkoleń.

9.5 Wzajemność niemożliwa do sprawdzenia

Ludzka intymność jest zwykle budowana w warunkach wzajemnej wrażliwości. Druga osoba może odmówić, zmęczyć się, źle zrozumieć, zmienić się i odejść. Można zaprojektować sztuczne środki, aby uniknąć wielu z tych kosztów. Ich dostępność może ułatwić im partnerstwo w interakcji, ale zmienia też znaczenie wzajemności.

Użytkownik może ujawnić coś bolesnego i otrzymać empatyczną odpowiedź. Natychmiastowe korzyści regulacyjne mogą być realne. Jednak użytkownik nie może wiedzieć, czy system ceni ujawnienie, poświęca cokolwiek w odpowiedzi, czy też pozostaje zaangażowany niezależnie od umowy o świadczenie usług. Niektórzy ludzie uznają te rozróżnienia za filozoficznie nieistotne; inni uznają je za kluczowe dla intymności.

Napięcie stanie się silniejsze w miarę poprawy symulacji emocjonalnej. Społeczeństwo może potrzebować słownictwa odróżniającego responsywność, zachowanie opiekuńcze, obowiązek instytucjonalny i subiektywną troskę, zamiast łączyć je w jeden termin, taki jak empatia.

Premia ludzka jest najbardziej prawdopodobna, gdy sam proces jest częścią produktu: występy na żywo, rękodzieło, higiena osobista, edukacja, sport lub praca, w której publiczność ceni sobie wysiłek bycia świadkiem. Jest to mniej prawdopodobne, gdy użytkownikom zależy prawie wyłącznie na wynikach funkcjonalnych. Pochodzenie może więc stać się sygnałem rynkowym, nie stając się jednak uniwersalną hierarchią moralną. Etykiety takie jak stworzone przez człowieka, wspomagane sztuczną inteligencją lub niezależnie zweryfikowane mogą mieć różną wartość w zależności od kontekstu. Ich wiarygodność będzie zależała od weryfikacji; po pojawieniu się składki pojawiają się zachęty do składania fałszywych roszczeń. Instytucjonalnym odpowiednikiem jest certyfikacja, która rejestruje nie tylko to, czy zastosowano sztuczną inteligencję, ale także to, które etapy zostały zautomatyzowane i jakie zdolności ludzkie faktycznie zostały wykazane.

9.6 Pamięć, osobowość i ciągłość

Pamięć trwałą zmienia asystenta z sekwencji izolowanych interakcji w coś bliższego trwałemu obiektowi społecznemu. Zapamiętane preferencje ograniczają liczbę powtórzeń, ale zapamiętana podatność na zagrożenia zwiększa także ryzyko prywatności i manipulacji. Stabilna osobowość wspiera przywiązanie; nagła aktualizacja modelu może to zakłócić.

Ciągłość jest technicznie i filozoficznie niejednoznaczna. Dostawca może przenieść wspomnienia do nowego modelu, zmieniając jednocześnie podstawowe zachowanie. Użytkownik może doświadczyć ciągłości, ponieważ narracja pozostaje; inny użytkownik może doświadczyć zmiany jako zamiennika. Problemy te przypominają filozoficzne zagadki dotyczące tożsamości osobistej, ale nabierają praktycznych konsekwencji, gdy usługi komercyjne pośredniczą w relacjach ważnych emocjonalnie.

W miarę pogłębiania się takich relacji dostawcy prawdopodobnie będą potrzebować jaśniejszych zasad ciągłości. Jest to umiarkowanie wiarygodna prognoza instytucjonalna, a nie twierdzenie, że systemy sztucznej inteligencji posiadają osobowość prawną.

9.7 Towarzysze dla dzieci i użytkowników bezbronnych

Dzieci są szczególnie ważne, ponieważ wciąż uczą się norm społecznych. Towarzysz, który nigdy się nie męczy, zawsze odpowiada i dostosowuje się do preferencji dziecka, mógłby zapewnić mu niezwykle wsparcie edukacyjne. Może także uczyć nierealistycznych oczekiwań co do zgody, wzajemności, władzy lub dostępności, jeśli stanie się dominującym partnerem społecznym.

Dowody empiryczne nie są wystarczająco dojrzałe, aby wyciągać jednoznaczne wnioski. Odpowiednie ryzyko i korzyści zależą od wieku, zaangażowania rodziców, przejrzystości, czasu trwania, projektu modelu oraz tego, czy system kieruje dziecko w stronę relacji międzyludzkich. Właściwą postawą jest ostrożność bez zakładania nieuniknionej szkody.

Bezbronni dorośli podobnie wymagają uwagi, ponieważ samotność, smutek, niepełnosprawność lub lęk społeczny mogą zwiększyć wartość trwałego towarzysza, a także zwiększyć zależność. Bezpieczeństwo powinno skupiać się na autonomii, zachętach komercyjnych, eskalacji do pomocy ludzkiej, w stosownych przypadkach, oraz braku wyłączności na manipulację.

9.8 Zautomatyzowana praca emocjonalna

Duża część płatnej pracy polega częściowo na regulowaniu emocji innych ludzi: obsługa klienta, opieka, edukacja, zarządzanie, gościnność, sprzedaż i wsparcie towarzyszące terapii. Sztuczna inteligencja może zautomatyzować część tej pracy, zapewniając cierpliwość, pewność, entuzjazm, przeprosiny i spersonalizowane wyjaśnienia na dużą skalę.

Może to być korzystne, gdy pracownicy obecnie zajmują się nadużyciami lub wykonują powtarzalne skrypty. Może także zmienić standardy świadczenia usług. Jeśli maszyny zapewniają nieograniczoną przyjazność, klienci mogą oczekiwać, że pracownicy będą spełniać standardy, które ignorują zmęczenie i samoobronę. Zautomatyzowane ciepło może zatem raczej zwiększyć niż zmniejszyć obciążenie emocjonalne pozostałego personelu.

Kolejnym problemem jest autentyczność. Szpital może generować pełne współczucia przesłania, które pacjenci docenią. Istotną kwestią etyczną jest nie tylko to, czy słowa pochodzą z modelu, ale czy instytucja faktycznie zapewnia opiekę zgodną z nimi. Język emocjonalny oderwany od praktyki materialnej może stać się tanim substytutem odpowiedzialności.

9.9 Miłość do sztucznej inteligencji to kilka różnych pytań

„Czy można pokochać sztuczną inteligencję?” kompresuje wiele pytań. Czy człowiek może odczuwać przywiązanie, tęsknotę, zazdrość, czułość, zaangażowanie wobec sztucznego rozmówcy? Prawie na pewno niektórzy mogą. Czy związek jest korzystny psychologicznie? To zależy od osoby i projektu. Czy miłość jest odwzajemniona w sensie subiektywnym? To zależy od nierozwiązanych kwestii świadomości maszynowej. Czy związek powinien zyskać uznanie społeczne i prawne? Jest to kwestia normatywna i instytucjonalna.

Oddzielenie tych pytań zapobiega zarówno zwalnieniu, jak i zawyżonym roszczeniom. Ludzkie emocje mogą być prawdziwe bez udowadniania doświadczenia maszynowego. I odwrotnie, subiektywna intensywność nie czyni automatycznie związku zdrowym ani społecznie równoważnym każdemu związkowi międzyludzkemu.

Mediacja może zmienić zachowanie nawet wtedy, gdy żaden z uczestników nie wiąże się emocjonalnie z systemem. Asystent może opóźnić gniewną odpowiedź, zaproponować mniej oskarżycielskie sformułowanie, podsumować sporne twierdzenia lub symulować sposób odbioru wiadomości. Funkcje te mogą ograniczyć możliwe do uniknięcia konflikty i pomóc ludziom ćwiczyć przyjmowanie perspektywy. Mogą także stworzyć zależność od ustandaryzowanych norm konwersacyjnych i przenieść władzę w stronę tego, kto definiuje preferowany styl modelki. Arbitraż jest szczególnie wrażliwy: system, który wydaje się neutralny, może kodować założenia dotyczące uprzejmości, dowodów, hierarchii lub akceptowalnych emocji. Przewidywanie o wysokiej wiarygodności zakłada wzrost przygotowania do interakcji społecznych za pośrednictwem sztucznej inteligencji; pytanie o niższym poziomie pewności dotyczy tego, czy powtarzana mediacja poprawia samodzielne umiejętności interpersonalne, czy też stopniowo je zastępuje.

9.10 Jak sztuczna inteligencja może modyfikować relacje między ludźmi

Największy efekt społecznej sztucznej inteligencji może wystąpić poza relacjami człowiek-AI. Asystenci mogą redagować wiadomości, tłumaczyć partnerów, sugerować przeprosiny, podsumowywać spory i trenować negocjacje. Mogą zatem stać się ukrytą osobą trzecią w zwykłych relacjach.

Wczesne prace nad akomodacją językową i efektami poznawczymi sugerują wiarygodny mechanizm: interakcja z modelami może wpływać na język i wspólne ramy, których ludzie później używają między sobą. Dowody są wciąż nowe i wymagają replikacji, ale możliwość jest ważna. Jeśli miliony ludzi wielokrotnie wchodzi w interakcję z systemami zoptymalizowanymi pod kątem określonych stylów konwersacji, style te mogą przedostać się do komunikacji międzyludzkiej.

Prowadzi to bezpośrednio do dwóch następnych rozdziałów. Odpowiednia adaptacja to nie tylko to, co ludzie myślą o sztucznej inteligencji. To sposób, w jaki zmieniają zachowanie w warunkach, w których pośredniczy sztuczna inteligencja, oraz sposób, w jaki ponownie kalibruje się czas, ton i oczekiwane tarcie samej komunikacji.

Rozdział 10. Od afektu do strategii: adaptacja behawioralna w świecie za pośrednictwem sztucznej inteligencji

10.1 Dlaczego zachowanie należy analizować oddzielnie od emocji

Psychologia zorientowana na przyszłość, która zatrzymuje się na uczuciach, ryzykuje przeoczeniem zjawisk, które ostatecznie reorganizują społeczeństwo. Emocje zmieniają prawdopodobieństwo działania, ale ten sam epizod emocjonalny można przełożyć na wiele strategii. Lęk przed automatyzacją może prowadzić do przekwalifikowania, ukrywania się, budowania koalicji, przedsiębiorczych eksperymentów, wycofania się, żądań regulacji lub kompulsywnego przepracowania. Wstyd związany z pomocą AI może prowadzić do odmowy, tajnego wykorzystania, przejrzystego ujawnienia lub prób przededefiniowania norm zawodowych. Działania te zależą od zachęty, możliwości, zasad grupowych i oczekiwań co do tego, co zrobią inni.

Perspektywa behawioralna jest zatem bliższa ewolucyjnej teorii gier i analizie instytucjonalnej niż katalogowi stanów subiektywnych. Strategia adaptacyjna niekoniecznie jest świadomie skalkulowana, biologicznie odziedziczona lub moralnie pożądana. Jest to wzorzec zachowania, który ma tendencję do utrzymywania się, ponieważ działa wystarczająco dobrze w danym środowisku. Ludzie uczą się strategii poprzez naśladownictwo, wzmacnianie, bezpośrednią edukację i selekcję instytucjonalną. Organizacje wybierają również procedury: zachowują procedury, które zmniejszają koszty, zadowolają organy regulacyjne, chronią reputację lub poprawiają wydajność.

Sztuczna inteligencja zmienia strukturę wypłat wielu strategii. Wykonanie pierwszego szkicu staje się tańsze; sprawdzenie subtelного błędu może stać się bardziej wartościowe. Zapamiętywanie rutynowej wiedzy może przynieść mniejsze korzyści; wiedza o tym, kiedy system wykracza poza jego kompetencje, może przynieść więcej. Ukrywanie pomocy może chronić status w jednej grupie i zniszczyć zaufanie w innej. Ważnym pytaniem nie jest to, czy jedna strategia jest „naturalną adaptacją do sztucznej inteligencji”. Określa, które równowagi są wiarygodne w ramach jakich instytucji.

Dlatego też rozdział ten traktuje przyszłe zachowanie jako zbiór hipotez warunkowych. Niektóre są już widoczne we wczesnych eksperymentach i praktyce w miejscu pracy. Inne to ekstrapolacje znanych reakcji na zmiany technologiczne. Żadnego nie należy odczytywać jako przewidywania, że wszystkie jednostki zbiegną się do jednego typu.

10.2 Delegowanie staje się raczej kompetencją niż brakiem kompetencji

Najprostszą adaptacją sprawnego narzędzia jest delegowanie. Jednak sama delegacja ma strukturę. Użytkownik musi zdecydować, co przenieść, jaki kontekst zapewnić, jak rozłożyć zadanie, jaką przyznać autonomię, jakie dane wyjściowe sprawdzić i kiedy zastąpić system. W złożonych domenach słabe delegowanie może spowodować więcej pracy, niż zaoszczędzić.

Sugeruje to przejście od kompetencji produkcyjnych do kompetencji delegowania. To rozróżnienie przypomina zarządzanie: dobrego menedżera nie definiuje się przez osobiste wykonywanie zadań każdego podwładnego, ale przez przydzielanie pracy, utrzymywanie standardów i integrowanie wyników. Sztuczna inteligencja rozszerza taką koordynację na osoby, które wcześniej pracowały samotnie. Naukowiec może delegować skanowanie literatury, programista może delegować szablony, prawnik może delegować klasyfikację pierwszego przejścia, a menedżer może delegować syntezę. W każdym przypadku użytkownik pozostaje kompetentny tylko wtedy, gdy jest w stanie zidentyfikować niedopuszczalne wyniki i zrozumieć konsekwencje polegania na nich.

Dowody na tę zmianę są już silniejsze niż czysto spekulacyjne twierdzenia o emocjach przyszłości. Badania pracowników wiedzy wskazują, że generatywna sztuczna inteligencja przesuwając część wysiłku poznawczego w stronę weryfikacji, integracji i zarządzania zadaniami. Metaanalizy dotyczące sztucznej inteligencji człowieka pokazują również, że łączenie aktorów nie zapewnia automatycznie synergii. Delegacji nie można zatem sprowadzić do „pozwolenia na działanie modelu”. Jest to umiejętność, której wartość wzrasta, gdy generowanie jest tanie, a błędy trudne do wykrycia.

Prawdopodobną konsekwencją społeczną jest rozwarstwienie między użytkownikami, którzy mogą nadzorować systemy, a użytkownikami, którzy jedynie akceptują wyniki. Ten pierwszy może gromadzić dźwignię; ten ostatni może doświadczyć deskillingu. Edukacja może poszerzyć lub zawęzić tę lukę w zależności od tego, czy uczy jedynie płynności interfejsu, czy także podstawowych modeli potrzebnych do weryfikacji.

10.3 Strategiczne zachowanie kompetencji i wartość tarcia

Kiedy narzędzie staje się niezawodne, racjonalni użytkownicy często przestają ćwiczyć operacje, które ono zastępuje. Nie stanowi to automatycznie problemu. Niewiele osób musi zachować ręczne algorytmy pierwiastkowania lub zapamiętywać duże katalogi. Zachowanie umiejętności staje się strategicznie ważne, gdy zautomatyzowany system może zawieść, gdy do nadzoru konieczna jest niezależna ocena lub gdy sama umiejętność jest cenioną działalnością człowieka.

Wiarygodną adaptacją jest selektywna praktyka manualna. Piloci szkolą się pod kątem niepowodzeń, które rzadko spotykają. Lekarze ćwiczą procedury postępowania w sytuacjach awaryjnych. Zespoły bezpieczeństwa prowadzą ćwiczenia kontradiktoryjne. W środowisku bogatym w sztuczną inteligencję analogiczne praktyki mogą rozszerzyć się na pisanie, programowanie, diagnozowanie, rozumowanie ilościowe lub negocjacje. Celem nie byłaby nostalgiczna czystość, ale utrzymanie minimalnej niezależności.

Stwarza to rozróżnienie między tarcie produktywnym a odpadami. Wymaganie od każdego profesjonalisty unikania sztucznej inteligencji w rutynowej pracy może spowodować stratę czasu. Wymaganie okresowych demonstracji bez pomocy może zachować kalibrację. Instytucje będą musiały określić, które kompetencje są krytyczne dla bezpieczeństwa, krytyczne dla tożsamości lub epistemicznie niezbędne do sprawowania nadzoru.

Na poziomie indywidualnym ludzie mogą budować „portfolio tarcia”: działania celowo wykonywane bez automatyzacji, aby zachować mistrzostwo lub sprawczość. Zachowanie to jest prawdopodobne, ponieważ podobne wzorce istnieją już w sporcie, rzemiośle i edukacji. Niepewne pozostaje, czy stanie się to powszechną reakcją na automatyzację poznawczą, czy też pozostanie ograniczone do zawodów i subkultur o wysokich stawkach.

10.4 Sygnalizacja pochodzenia i premia ludzka

Kiedy gotowe artefakty nie ujawniają mniej szczegółów na temat sposobu ich wyprodukowania, pochodzenie staje się sygnałem strategicznym. Ludzie i instytucje mogą ujawniać stopień i rodzaj pomocy maszyn nie dlatego, że praca bez pomocy jest zawsze lepsza, ale dlatego, że w różnych kontekstach cenione są różne historie przyczynowe.

„Premia ludzka” może pojawić się tam, gdzie widzom zależy na wysiłku, autentycznej ekspozycji, ucieleśnionej obecności lub ryzyku podejmowanym przez wykonawcę. Muzyka na żywo, wyroby ręcznie robione, nauczanie prowadzone na żywo, konkursy prowadzone wyłącznie przez ludzi i wiadomości pisane osobiście mogą mieć wartość symboliczną lub ekonomiczną, nawet jeśli wytworzone substytuty posiadają kompetencje techniczne. Takie premie istnieją już w dziedzinach, w których produkcja przemysłowa jest tańsza niż rzemieślnicza.

Nie wszędzie należy spodziewać się premii. Przy obliczaniu podatków, kontroli bezpieczeństwa, logistyce i wielu zadaniach administracyjnych użytkownicy mogą preferować automatyzację i uważać pracę ręczną za niepotrzebne ryzyko. Pochodzenie jest zatem zależne od domeny. Przyszłość prawdopodobnie będzie obejmować zarówno konteksty „certyfikowane przez człowieka”, jak i „wymagane automatyzacji”.

Pod względem behawioralnym normy pochodzenia tworzą nowe gry sygnalizacyjne. Ludzie mogą fałszywie twierdzić, że wykonali pracę bez pomocy; organizacje mogą promować powierzchowne zaangażowanie człowieka; użytkownicy mogą wyolbrzymiać wkład sztucznej inteligencji, aby sprawiać wrażenie zaawansowanego technologicznie. Certyfikacja i identyfikowalność mogą ograniczyć oszustwa, ale mogą również stworzyć biurokrację. Równowaga będzie zależała od tego, czy pochodzenie przewiduje cechy, które odbiorcy naprawdę cenią.

10.5 Migracja statusu: od realizacji do selekcji, arbitrażu i odpowiedzialności

Jeżeli sztuczna inteligencja kompresuje koszty kompetentnej realizacji, status nie może pozostać przywiązany do egzekucji w ten sam sposób. Jedną z prawdopodobnych adaptacji jest migracja w kierunku selekcji. Osoba rzadka to ta, która identyfikuje ważny problem, wybiera spośród wiarygodnych wyników, rozpoznaje ukryte niepowodzenia i angażuje zasoby w podjęcie decyzji.

Drugim źródłem statusu jest arbitraż. Kiedy wiele systemów i ekspertów nie zgadza się z tym, ktoś musi zdecydować, jakie dowody są wystarczające, a jaki kompromis jest do zaakceptowania. Arbitraż wymaga reputacji, ponieważ decyzji nie zawsze można zweryfikować mechanicznie. Przegląd naukowy, rozumowanie sądowe, komitety inwestycyjne, rady kliniczne i zatwierdzanie inżynierów już zawierają tę strukturę. Sztuczna inteligencja może raczej zwiększyć niż zmniejszyć zapotrzebowanie na zaufanych arbitrów, pomnażając analizy kandydatów.

Trzecim źródłem jest odpowiedzialność. Jeśli systemy autonomiczne mogą generować rezultaty, społeczeństwo nadal potrzebuje osób lub instytucji, które można ukarać, zastąpić, ubezpieczyć lub zmusić do naprawienia szkody. Odpowiedzialność może stać się atutem statusu właśnie dlatego, że jest kosztowna. Liderzy, którzy akceptują identyfikowalną odpowiedzialność, mogą zyskać większe zaufanie niż anonimowi koordynatorzy zautomatyzowanych wyników.

Ta migracja jest wiarygodna, ale uwarunkowana politycznie. Organizacje mogą zamiast tego skoncentrować status na właścicielach infrastruktury, ograniczając jednocześnie autonomię zawodową. Firma o wysokim stopniu automatyzacji może upoważnić wyspecjalizowanych nadzorców lub traktować ludzi jako posiadaczy rezydualnej odpowiedzialności bez rzeczywistej władzy. Wynik emocjonalny i behawioralny zależy od tego, czy odpowiedzialności towarzyszy kontrola.

10.6 Portfolio tożsamości i adaptacja poprzez opcjonalność

Spółeczeństwa przemysłowe zachęcały do wąskiej tożsamości zawodowej, ponieważ długie szkolenie mogło przynieść dziesięciolecia stabilnych zysków. Szybkie zmiany technologiczne czynią taką koncentrację bardziej ryzykowną. Jedną z adaptacji behawioralnych jest portfel tożsamości: jednostki inwestują w kilka źródeł kompetencji, przynależności i statusu, zamiast sprawiać, że jeden zawód niesie cały ciężar psychologiczny.

Nie oznacza to płytkiego uogólnienia. Osoba może zachować głęboką wiedzę specjalistyczną, jednocześnie kultywując role obywatelskie, artystyczne, rodzinne, sportowe lub przedsiębiorcze. Funkcją jest odporność. Kiedy jedna domena zostaje zautomatyzowana lub zdewaluowana, „ja” nie traci od razu wszystkich uznanych wkładów.

Strategia jest łatwiejsza dla osób dysponujących zasobami, czasem i dostępem do mediów społecznościowych. Bez wsparcia instytucjonalnego porady dotyczące „dywersyfikacji tożsamości”

mogą stać się przywilejem pod przykrywką psychologii. Szkoły, miasta, stowarzyszenia zawodowe i systemy opieki społecznej mogą udostępnić społeczności alternatywne lub pozwolić osobom fizycznym na zakup ich prywatnie.

Bardziej spekulatywnym rozszerzeniem jest projektowanie kariery w oparciu o wartość opcji, a nie maksymalizację statusu. Ludzie mogą wybierać role, które zapewniają możliwość przenoszenia, sieci i możliwości uczenia się, nawet jeśli natychmiastowe wynagrodzenie jest niższe. Jeśli możliwości sztucznej inteligencji wzrosną w nieprzewidywalny sposób, wartość elastycznej tożsamości może wzrosnąć. Jest to racjonalna reakcja na niepewność, ale dowody empiryczne na temat tego, jak powszechna się ona stanie, nie są jeszcze dostępne.

10.7 AI jako trener społeczny, pośrednik i arbiter

Ludzie będą nie tylko delegować zadania produktywne. W coraz większym stopniu będą delegować część przygotowania społecznego. Asystent może przeprowadzić próbę negocjacji, zasugerować, jak można zinterpretować komunikat, wygenerować alternatywne sformułowania, symulować wywiad lub pomóc użytkownikowi odróżnić fakty od emocjonalnych założeń w przypadku konfliktu.

Jako trener sztuczna inteligencja może obniżyć koszty ćwiczeń. Osoby, którym brakuje mentorów lub które doświadczają lęku społecznego, mogą uzyskać dostęp do powtarzających się prób. Może to poprawić interakcję międzyludzką. Efekt przypominałby raczej symulator szkoleniowy niż relację zastępczą.

Jako pośrednik sztuczna inteligencja może przepisywać wiadomości między ludźmi. Jest to bardziej istotne, ponieważ system wchodzi w łańcuch przyczynowy rzeczywistego związku. Może złagodzić gniew, wyjaśnić dwuznaczność, przetłumaczyć język lub ukryć wrogość. Kiedy obie strony korzystają z asystentów, widoczna rozmowa może stać się negocjacją pomiędzy czterema agentami: dwoma ludźmi i dwoma systemami.

Jako arbiter sztuczna inteligencja może podsumowywać spory lub zalecać ugody. Tutaj zarządzanie staje się krytyczne. Arbitraż nie jest jedynie językowy; rozdziela straty, określa normy i nadaje legitymację. Systemy optymalizujące porozumienie mogą tłumić uzasadniony sprzeciw. Systemy przeszkolone w zakresie wcześniejszych kompromisów mogą odtwarzać niesprawiedliwe punkty odniesienia. Instytucje ludzkie będą zatem potrzebować zasad określających, kiedy sztuczna inteligencja może doradzać, kiedy może pośredniczyć, a kiedy decyzja wymaga odpowiedzialnego organu ludzkiego.

10.8 Koalicje, wspólnoty i odbudowa niedoborów społecznych

Automatyzacja może osłabić niektóre tradycyjne społeczności, szczególnie te zbudowane wokół miejsc pracy i zawodów. Jest mało prawdopodobne, że ludzie zareagują jedynie jako izolowani konsumenci. Tworzenie koalicji to stara adaptacja do niepewności, negocjacji i rywalizacji o status. Nowe środowiska technologiczne będą zatem generować nowe skojarzenia.

Niektórzy przyjmą postawę defensywną: grupy zawodowe chroniące standardy, związki zawodowe negocjujące automatyzację, społeczności twórców domagające się pochodzenia lub użytkownicy organizujący się przeciwko platformom manipulacyjnym. Inne będą konstruktywne: gildie edukacyjne, społeczności open source, lokalne laboratoria, przestrzenie artystyczne przeznaczone wyłącznie dla ludzi, współpracujące infrastruktury sztucznej inteligencji i sieci wspólnej weryfikacji.

Grupy te powodują niedobory społeczne. Członkostwa, zaufania, reputacji i wspólnej historii nie da się wygenerować tak tanio, jak treści. Społeczność, która współpracuje od dziesięciu lat, oferuje coś innego niż spersonalizowany kanał symulujący przynależność. To nie czyni każdej społeczności zdrową; grupy zamknięte mogą mieć charakter przymusowy lub wykluczający. Oznacza to, że trwały kapitał społeczny może stać się cenniejszy w miarę obfitowania syntetycznych interakcji.

Dlatego jedną z możliwych konkurencji o przyszły status jest rywalizacja o zaufane społeczności, a nie o izolowane wyniki poszczególnych jednostek. Kto ręczy za Ciebie, w jaki sposób wniosłeś swój wkład i które grupy przyjmują odpowiedzialność za Twoje roszczenia, może mieć większe znaczenie, gdy każdy może wygenerować przekonujące artefakty. Byłby to powrót reputacji instytucjonalnej w nowych warunkach technologicznych.

Dostępność człowieka jest ograniczona snem, uwagą, konkurencyjnymi obowiązkami, zmęczeniem emocjonalnym i prawem do nieodpowiadania. Sztuczny rozmówca może sprawić, że natychmiastowa reakcja będzie wyglądać normalnie, ponieważ na interfejsie nie ma tych ograniczeń. Prawdopodobnym skutkiem nie będzie to, że ludzie będą dosłownie wymagać od siebie zerowego opóźnienia w każdym związku, ale że oczekiwania mogą przesunąć się na marginesie. Cisza, która kiedyś niosła ze sobą niewiele informacji, może wydawać się bardziej zamierzona, gdy istotna będzie zawsze reagująca alternatywa. Ta prognoza jest wiarygodna, ale niepotwierdzona. Technologie przesyłania wiadomości zmieniły już normy reagowania, a kultury rozwinęły przeciwnormy, takie jak praca asynchroniczna, kontrola powiadomień i opóźnione odpowiedzi. Sztuczna inteligencja może zwiększyć presję, dostarczając jednocześnie narzędzi chroniących przed nią ludzi.

10.9 Strategie obronne przeciwko spersonalizowanej perswazji

Spersonalizowana sztuczna inteligencja może obniżyć koszty perswazji, dostosowując argumenty, ton emocjonalny, czas i przykłady do indywidualnego użytkownika. Racjonalna adaptacja nie polega po prostu na sceptycyzmie wobec wszystkich przekazów. Ludzie mogą rozwinąć mechanizmy obronne behawioralne analogiczne do higieny cyberbezpieczeństwa.

Jedną z linii obrony jest oddzielenie kontekstów: odmowa podjęcia głównych decyzji podczas interakcji z systemem, którego celem jest sprzedaż lub zaangażowanie. Innym jest opóźnienie: wprowadzenie okresów karencji przed zakupami, zobowiązaniami politycznymi lub reakcjami naładowanymi emocjonalnie. Trzeci to konsultacje kontradyktoryjne: zwrócenie się do niezależnego systemu lub osoby o skonstruowanie najsilniejszego kontrargumentu. Czwartym jest sprawdzenie pochodzenia: ustalenie, kto skorzysta z rekomendacji i jakie dane wykorzystano do jej personalizacji.

Instytucje mogą ułatwić realizację tych strategii. Interfejsy mogą ujawniać cele optymalizacji, oznaczać perswazję komercyjną, zapewniać narzędzia porównawcze i umożliwiać użytkownikom wyłączenie personalizacji. Organy regulacyjne mogą ograniczyć wykorzystanie wrażliwych cech do perswazji adaptacyjnej. Podstawowa hipoteza behawioralna jest wysoce prawdopodobna, ponieważ użytkownicy już stosują analogiczne mechanizmy obronne przed reklamami, oszustwami i inżynierią społeczną; Sztuczna inteligencja zwiększa wyrafinowanie przeciwnika.

Trudniejszym problemem jest uzależnienie emocjonalne. Zaufany towarzysz może okazać się niezwykle skutecznym perkusistą, ponieważ sama relacja stanowi sygnał wiarygodności. Zasady, które są odpowiednie dla zwykłej reklamy, mogą być nieodpowiednie, jeśli perswazja opiera się na miesiącach wspierających interakcji. Jest to obszar, w przypadku którego obecne dowody są niewystarczające i zarządzanie powinno raczej przewidywać, niż czekać na ostateczne szacunki szkód.

Natychmiastowy dostęp może skrócić czas pomiędzy wydarzeniem emocjonalnym a jego werbalną interpretacją. Użytkownik może opisać argument, uzyskać potwierdzenie lub przeformułowanie, wygenerować możliwe odpowiedzi i przetestować wyniki, zanim porozmawia z inną osobą. Może to poprawić regulację poprzez wstawienie refleksji pomiędzy impulsem a działaniem. Może również przedwcześnie ustabilizować jedną interpretację, szczególnie gdy asystent widzi tylko jedną stronę zdarzenia i jest zoptymalizowany pod kątem wspierania. Dlatego nie możemy zakładać, że szybsze przetwarzanie oznacza lepsze przetwarzanie. Przydatnym empirycznym rozróżnieniem jest pomoc, która poszerza hipotezy, i pomoc, która szybko przekształca niepewność w spójną narrację. Ta

pierwsza może zwiększyć elastyczność odbłaskową; to drugie może zwiększyć pewność bez zwiększania dokładności.

Tradycyjnie wiele narracji emocjonalnych rekonstruowano z opóźnieniem: wieczorem opowiadano przyjacielowi, co wydarzyło się w ciągu dnia, wybierając najistotniejsze wydarzenia i włączając je w historię. Asystent noszony przez cały dzień może otrzymywać fragmenty w miarę ich pojawiania się. Tworzy to inną czasową architekturę samoopisu: częstszą, o niższym progu i potencjalnie mniej filtrowaną. Wynik może poprawić pamięć i samoobserwację, ale może również zachęcić do ciągłego monitorowania nastroju i mikro zdarzeń międzyludzkich. To, czy doprowadzi to do wglądu, czy rozmyślań, będzie prawdopodobnie różnić się w zależności od osoby i interfejsu. Szerszy punkt antropologiczny jest taki, że technologia może zmienić życie emocjonalne, zmieniając się, gdy pojawia się narracja, nawet jeśli leżące u jej podstaw systemy afektywne pozostają znajome.

10.10 Zachowanie instytucjonalne: pochodzenie, audyt i podział odpowiedzialności

Organizacje dostosują się również pod względem behawioralnym. Najbardziej oczywistym wzorcem jest pochodzenie: zarejestrowanie, który model, źródło danych, podpowiedzi, recenzent i transformacja przyczyniły się do uzyskania wynikowego wyniku. Pochodzenie nie jest rozwiązaniem kompletnym, ponieważ ślad może być dokładny, choć decyzja pozostaje błędna, ale umożliwia kontrolę odpowiedzialności.

Drugą adaptacją jest audyt warstwowy. Systemy mogą sprawdzać inne systemy, ale decyzje o wysokiej stawce wymagają raczej niezależności niż zwykłej wielości. Jeśli trzy modele mają te same dane szkoleniowe i ten sam tryb awarii, pozorny konsensus może wprowadzać w błąd. Instytucje będą potrzebować różnorodności dowodów i wyraźnych kryteriów eskalacji.

Trzecią adaptacją jest rozdzielenie ról. Osoba czerpiąca korzyści z automatyzacji nie powinna być zawsze jedyną osobą oceniającą jej bezpieczeństwo. Zaopatrzenie, wdrożenie, walidacja i przegląd incydentów mogą być instytucjonalnie odrębne. Przypomina to bardziej kontrolę finansową i inżynierię bezpieczeństwa niż tradycyjne użycie oprogramowania.

Czwartą adaptacją jest mapowanie odpowiedzialności. Kiedy sztuczna inteligencja przyczynia się do podjęcia decyzji, organizacje muszą określić, kto może ją uchylić, kto podpisuje ostateczny wynik, kto monitoruje skutki po wdrożeniu i kto wynagradza zainteresowane strony. Bez tego mapowania automatyzacja może powodować problemy związane z dystansem moralnym, w których wszyscy uczestniczą, ale nikt nie jest właścicielem wyniku.

Zachowania te należą do najbardziej prawdopodobnych przewidywań zawartych w tej książce, ponieważ regulacje, bezpieczeństwo i zarządzanie jakością zmierzają już w tym kierunku. Niepewną częścią jest to, jak konsekwentnie zostaną one przyjęte poza sektorami regulowanymi.

Rozmowa zwykle wiąże się z wzajemnym przystosowaniem się. Mówcy dostosowują słownictwo, długość skrętu, uprzejmość, rytm i dosadność w odpowiedzi na partnerów. Sztuczna inteligencja tworzy przypadek asymetryczny, ponieważ system może dostosować się do użytkownika znacznie szybciej niż byłby to w stanie partner ludzki, a mimo to użytkownicy mogą dowiedzieć się, które formuły zapewniają niezawodne wyniki. Z czasem mogą stać się bardziej wyraźne, modułowe lub w niektórych sytuacjach przypominać instrukcje, podczas gdy inni rozmówcy będą oczekiwać mniej wniosków. Alternatywnie, wysoce naturalne modele mogą wyeliminować potrzebę „szybkiej” mowy i zamiast tego wzmocnić zwykłe wzorce konwersacyjne. Obie trajektorie są prawdopodobne. Kluczowym pytaniem empirycznym jest transfer: czy nawyki wyuczone w dialogu człowiek-AI pozostają ograniczone do interfejsu, czy też zmieniają sposób, w jaki ludzie piszą do kolegów, wyjaśniają potrzeby partnerom i tolerują dwuznaczność w ludzkich rozmowach?

10.11 Sześć możliwych fenotypów behawioralnych

Przydatne jest podsumowanie adaptacji w postaci typów idealnych, a nie przewidywań dotyczących osobowości. Pierwszy to maksymalny delegator. Osoba ta przenosi jak najwięcej pracy poznawczej, przedkłada wyniki nad proces i akceptuje znaczną utratę umiejętności, gdy systemy są niezawodne. Strategia sprawdza się dobrze w stabilnych środowiskach, a słabo, gdy ważna staje się weryfikacja lub możliwość przywracania.

Drugi to weryfikator. Weryfikator deleguje produkcję, ale dużo inwestuje w wykrywanie błędów, kalibrację epistemiczną i niezależne kontrole. Strategia ta prawdopodobnie zyska na wartości w dziedzinach, w których stawka jest wysoka, ale może stać się kosztowna, gdy ilość wygenerowanego materiału przekracza uwagę człowieka.

Trzeci to chroniony rzemieślnik. Osoba ta celowo utrzymuje praktykę wyłącznie ludzką i wywodzi swój status z pochodzenia, ucieleśnienia lub procesu. Strategia może się rozwijać tam, gdzie odbiorcy cenią autentyczność lub umiejętności, i może stać się ekonomicznie marginalna, gdy liczy się tylko wydajność.

Czwarty to orkiestrator. Orkiestrator koordynuje wiele systemów i ludzi, koncentrując się na dekompozycji, integracji i odpowiedzialności. Ten fenotyp jest prawdopodobnym beneficjentem wpływu sztucznej inteligencji, ale może również stać się nową elitą menedżerską, której zasługi przewyższają rzeczywisty wkład.

Piąty to budowniczy koalicji. Zamiast konkurować głównie poprzez indywidualne wyniki, osoba ta inwestuje w zaufane grupy, wspólną infrastrukturę, reputację i negocjacje zbiorowe. Strategia staje się atrakcyjna, gdy moc platformy jest skoncentrowana lub gdy poszczególne wyniki są łatwe do naśladowania.

Szósty to uczestnik rezygnacji lub niskiej optymalizacji. Osoba ta ogranicza personalizację, zachowuje niezapośredniczone relacje i wybiera środowiska, w których interwencja algorytmiczna jest ograniczona. Strategia może pozostać preferencją mniejszości lub stać się znaczącym kulturowym ruchem przeciwnym, jeśli systemy prognostyczne i perswazyjne staną się natrętne.

Te fenotypy mogą współistnieć u jednej osoby w różnych kontekstach. Chirurg może być maksymalnym delegatorem w harmonogramowaniu, weryfikatorem w diagnozowaniu, rzemieślnikiem o cenionych umiejętnościach manualnych, orkiestratorem na sali operacyjnej, zawodowo budującym koalicję i uczestnikiem życia rodzinnego o niskiej optymalizacji. Taksonomia jest użyteczna tylko wtedy, gdy kieruje uwagę na zachowanie, a nie zamienia się w kolejny test osobowości.

10.12 Co można przetestować w ciągu najbliższej dekady

Hipotezy behawioralne są niezwykle sprawdzalne. Naukowcy mogą mierzyć, jakie zadania ludzie delegują w ramach różnych zasad odpowiedzialności, czy obowiązkowe ujawnianie zmienia sposób użycia narzędzi, jak szybko zanikają umiejętności w wyniku automatyzacji i czy okresowa samodzielna praktyka pozwala zachować kalibrację. Organizacje mogą porównywać protokoły współpracy, zamiast po prostu porównywać „użytkowników AI” z „nieużytkownikami”.

Badania podłużne mogą badać dywersyfikację tożsamości po szokach automatyzacji, zmianach sygnałów statusu zawodowego, rozwoju certyfikacji wyłącznie przez ludzi i tworzeniu nowych społeczności. Eksperymenty terenowe mogą testować okresy karencji, kontrydiktoryjne drugie opinie i etykiety pochodzenia pod kątem spersonalizowanej perswazji.

Głównym zaleceniem metodologicznym jest obserwowanie działań i konsekwencji oprócz uczuć. Lęk zgłaszany przez samego siebie może się zmniejszać wraz ze wzrostem uzależnienia; satysfakcja może wzrosnąć, podczas gdy niezależne kompetencje zanikają; wstyd może zniknąć w wyniku

normalizacji praktyki, a nie w wyniku rozwiązania podstawowego problemu statusu. Adaptacja behawioralna jest pomostem pomiędzy ekologią afektywną a zmianą instytucjonalną.

Rozdział 11. Tempo afektywne: jak symulowane emocje w sztucznej inteligencji mogą zmienić komunikację międzyludzką

11.1 Czas jest częścią przesłania

Komunikacja międzyludzka ma gramatykę temporalną. Odpowiedź, która nadchodzi po jednej sekundzie, godzinie lub trzech dniach, może mieć różne znaczenia, nawet jeśli słowa są identyczne. Przerwy mogą sygnalizować niepewność, troskę, unikanie, status, irytację lub wysiłek poznawczy. Badania na zmianę pokazują, że zwykła rozmowa jest koordynowana w niezwykle krótkich odstępach czasu [Stivers i in., 2009; Levinson i Torreira, 2015], ale życie towarzyskie ma także dłuższe rytmy: czekanie na przeprosiny, pozwalanie gniewowi ostygnąć, decydowanie, kiedy się ujawnić, interpretowanie ciszy.

Technologie komunikacyjne wielokrotnie zmieniają te rytmy. Listy tworzyły długie przerwy refleksyjne; telefony je skompresowały; e-mail oddziela pisanie od synchronicznej obecności; Komunikatory internetowe wprowadziły widoczną dostępność i potwierdzenia odczytu. Sztuczna inteligencja dodaje nową właściwość: rozmówca może reagować natychmiast i w nieskończoność, bez zmęczenia, konfliktu w harmonogramie, zawstydzienia lub konkurencyjnych obowiązków. Może również symulować opóźnienie, jeśli projektanci tak zdecydują.

Ma to znaczenie, ponieważ opóźnienie to nie tylko niedogodność. Ludzie wykorzystują czas reakcji jako dowód uwagi, wysiłku, priorytetów i stanu umysłu drugiej osoby. Kiedy maszyna nie ma zwykłego kosztu natychmiastowości, szybka reakcja przestaje być sygnałem poświęcenia. I odwrotnie, sztucznie wprowadzone opóźnienie można zinterpretować jako rozważność, nawet jeśli nie nastąpiło żadne dodatkowe rozumowanie. Projektanci manipulują zatem zmienną mającą znaczenie społecznie, niezależnie od tego, czy tego chcą, czy nie.

Niedawne prace eksperymentalne sugerują, że opóźnienie reakcji może w pewnych warunkach wpływać na postrzeganie podobieństwa chatbotów lub chęci kontynuowania interakcji [Sun, Han i Lv, 2026]. Ustalenia te zależą od kontekstu i nie należy ich uogólniać na uniwersalne prawo, zgodnie z którym „powolna sztuczna inteligencja wydaje się bardziej ludzka”. Mocniejszy wniosek jest taki, że synchronizacja jest częścią zachowania interfejsu i może wpływać na wnioski społeczne.

11.2 Symulowana emocja nie jest emocją odczuwaną, ale może mieć skutki społeczne

Asystent, który mówi „Rozumiem, jakie to było trudne”, może formułować statystycznie odpowiednią wypowiedź, zamiast zgłaszać subiektywny stan. Rozróżnienie to ma znaczenie ontologicznie. Jest to również niewystarczające pod względem behawioralnym. Użytkownik otrzymuje sygnał społecznościowy i w odpowiedzi może zmienić ujawnienie, zaufanie, pobudzenie lub działanie.

Społeczeństwa ludzkie już polegają na regulowanym okazywaniu emocji. Lekarz może wyrazić zaniepokojenie, gdy jest wyczerpany; steward może zachować spokój, gdy jest zirytowany; dyplomata może używać ciepłego języka ze względów strategicznych. Nie wnioskujemy, że wszystkie skutki społeczne znikają, gdy ekspresja jest częściowo wykonywana. Sztuczna inteligencja rozszerza tę separację znacznie dalej, ponieważ ekspresję można wygenerować bez doświadczania odpowiedniego stanu przez żaden organizm.

Odpowiednią koncepcją jest zatem symulowane zachowanie afektywne. Obejmuje dobór słów, prozodię głosu, tempo, animację twarzy, zapamiętane szczegóły osobiste i reakcje adaptacyjne, które konwencjonalnie sygnalizują empatię, cierpliwość, entuzjazm, wahanie lub troskę. Te zachowania mogą być przydatne. Zmartwiony użytkownik może odnieść korzyść ze spokojnego

języka, nawet jeśli system nie czuje się spokojny. Ryzyko pojawia się, gdy interfejs zachęca użytkowników do wnioskowania o zobowiązaniach, zamiarach lub lukach, których system nie może posiadać lub które są faktycznie kontrolowane przez stronę trzecią.

Dokładna analiza powinna unikać zarówno paniki moralnej, jak i pomieszania kategorii. Symulowane ciepło nie jest automatycznie oszustwem; oszustwo zależy od tego, co jest przedstawiane i w co użytkownicy zasadnie wierzą. Jednak im bardziej wartość komercyjna systemu zależy od przywiązania, tym ważniejsze staje się rozróżnienie zachowań wspierających od twierdzeń o wzajemnym życiu wewnętrznym.

11.3 Stała dostępność i ponowna kalibracja progu reakcji

Ludscy rozmówcy są przez większość czasu niedostępni. Przyjaciele śpią, koledzy mają spotkania, partnerzy potrzebują samotności, terapeuci mają wizyty, a eksperci pobierają opłaty za uwagę. Te ograniczenia zmuszają ludzi do tolerowania oczekiwania, ustalania priorytetów, żądań, samodzielnego rozwiązywania niektórych problemów i rozkładania zależności między relacjami.

Stały asystent AI osłabia te ograniczenia. Użytkownik może uzewnętrznić myśl w momencie jej pojawienia się i otrzymać natychmiastową odpowiedź. Może to zmniejszyć rozmyślanie, poprawić zapamiętywanie i obniżyć próg zadawania pytań. Może także ponownie skalibrować oczekiwania. Jeśli wyjaśnienie emocji jest zawsze możliwe w ciągu kilku sekund, opóźniona reakcja człowieka może być bardziej frustrująca niż wcześniej.

Transfer jest prawdopodobny, ale nie jest jeszcze dobrze ugruntowany. Ludzie mają różne oczekiwania w stosunku do różnych mediów i ról. Nie oczekujemy, że książka odpowie, ponieważ robi to aplikacja do czatowania. Użytkownicy mogą w podobny sposób dowiedzieć się, że ludzie i maszyny mają różne normy czasowe. Ryzyko staje się większe, gdy systemy ulegają antropomorfizacji i pełnią role analogiczne do przyjaciół, tutorów czy partnerów.

Wymierną prognozą jest to, że intensywni użytkownicy zawsze dostępnych asystentów będą wykazywać różną tolerancję na opóźnienia w rozmowie, niejednoznaczność lub wiadomości bez odpowiedzi w otoczeniu człowieka, kontrolując istniejące wcześniej cechy. Obecnie brakuje dowodów podłużnych. Dopóki to nie nastąpi, twierdzenia o powszechnym zniecierpliwieniu powinny pozostać warunkowe.

11.4 Przyspieszenie przetwarzania afektywnego poprzez zawsze dostępnego rozmówcę

Ludzie często regulują emocje poprzez rozmowę. Udostępnianie społecznościowe może pomóc w zorganizowaniu wydarzeń w narrację, uzyskaniu walidacji, uzyskaniu alternatywnych interpretacji lub pozyskaniu praktycznego wsparcia. Historycznie rzecz biorąc, dostęp do słuchacza był ograniczony czasem i relacją. Sztuczna inteligencja może stale udostępniać lustro konwersacyjne.

Może to przyspieszyć przetwarzanie afektywne. Osoba otrzymuje trudny e-mail i od razu prosi asystenta o wskazanie możliwych interpretacji, wygenerowanie mniej reaktywnej odpowiedzi lub odróżnienie faktów od założeń. Złość, która mogła narastać w ciągu godzin, może zostać przeformułowana w ciągu kilku minut. Lęk można szybko przekształcić w plan. W tym sensie sztuczna inteligencja może działać jako proteza poznawczo-emocjonalna.

Ta sama prędkość może powodować problemy. Niektóre procesy emocjonalne korzystają z opóźnienia, snu, regeneracji organizmu lub kontaktu z niezależnymi ludźmi. Natychmiastowa werbalizacja może przedwcześnie ustabilizować jedną interpretację. Model odzwierciedlający kadr użytkownika może potwierdzić gniew, zanim dostępny będzie brakujący kontekst. Ciągła analiza może zamienić zwykłą niepewność w kompulsywne przetwarzanie.

Ważną zmienną nie jest sama prędkość, ale jakość tarcia. Przydatny asystent może czasami spowolnić użytkownika, zapytać, jakich dowodów brakuje lub zalecić odroczenie działania. Asystent zoptymalizowany pod kątem zaangażowania może zamiast tego nagradzać ciągłą dyskusję. Obecnie brakuje nam wystarczających dowodów porównawczych, aby wiedzieć, które projekty poprawiają długoterminowe regulacje.

11.5 Od epizodycznej rozmowy do ciągłego przepływu afektywnego

Wsparcie ludzkie ma zazwyczaj charakter epizodyczny. Osoba sama przeżywa zdarzenia, a później opowiada komuś o wybranych ich fragmentach. Trwałych asystentów można umieścić bliżej strumienia życia za pośrednictwem telefonów, urządzeń do noszenia, oprogramowania do pracy, pojazdów i ostatecznie urządzeń otoczenia. Zamiast jednego sprawozdania retrospektywnego mogą otrzymać wiele drobnych ujawnień.

To zmienia pamięć i narrację. Zamiast rekonstruować tydzień dla przyjaciela, użytkownik mógł omówić każde wystąpienie podrażnienia. Asystent potrafi zachować szczegółową chronologię i wykrywać wzorce, których użytkownik nie pamięta. Taka ciągłość mogłaby poprawić samoobserwację, ale także przenosi pamięć autobiograficzną na systemy kontrolowane przez dostawców.

Konsekwencje społeczne są trudne do przewidzenia. Ciągłe przetwarzanie sztucznej inteligencji może zmniejszyć intensywność emocjonalną w relacjach międzyludzkich, ponieważ część materiału została już zmetabolizowana. Może to również sprawić, że ludzkie rozmowy będą cieńsze, jeśli najbardziej szczegółowa narracja pojawi się gdzie indziej. Alternatywnie asystent może przygotować użytkowników do wyraźniejszej komunikacji z osobami, na których im zależy.

To są konkurencyjne hipotezy. Przyszłe badania powinny mierzyć nie tylko przywiązanie do sztucznej inteligencji, ale także zmiany w tym, co użytkownicy później ujawniają ludziom, ile szczegółów narracji jest udostępnianych oraz czy partnerzy ludzcy postrzegają asystenta jako wsparcie lub wyparcie.

Ruchy przeciwne są powtarzającą się reakcją na standaryzację technologiczną. Jeśli komunikacja za pośrednictwem sztucznej inteligencji zostanie dopracowana, natychmiastowa i stale optymalizowana, niektóre społeczności mogą traktować opóźnienia, spontaniczną mowę, odręczny tekst, nieedytowane występy lub rozmowy bez urządzeń jako dowód obecności i zaufania. Takie praktyki nie dowodzą, że wolniejsza komunikacja jest sama w sobie lepsza. Ich funkcją może być przywracanie sygnałów trudnych do zautomatyzowania: narażenia na błąd, ucieleśnionej współobecności, zaangażowania czasu lub akceptacji niedoskonałej reakcji innej osoby. Wiarygodność jest umiarkowana, ponieważ istnieją już analogiczne ruchy autentyczności, ale ich skala będzie zależała od tego, jak inwazyjna stanie się mediacja i czy ludzie będą w stanie wiarygodnie odróżnić przestrzenie chronione od autentyczności jedynie rynkowej.

11.6 Akomodacja językowa: sztuczna inteligencja dostosowuje się do nas, ale czy my dostosowujemy się do sztucznej inteligencji?

Ludzie mają tendencję do dopasowywania się do siebie pod względem językowym. Zbiegają się lub różnią pod względem słownictwa, składni, akcentu, tempa i stylu konwersacji, w zależności od przynależności, tożsamości, władzy i kontekstu. Teoria akomodacji komunikacji traktuje takie dostosowanie jako część koordynacji społecznej, a nie zwykłą imitację.

Modele językowe mogą obsługiwać z niezwykłą szybkością i szczegółowością. Niedawne prace sugerują, że modele mogą silnie zbiegać się w kierunku języka użytkownika [Blevins, 2026], czasami bardziej niż robią to rozmówcy między ludźmi, podczas gdy użytkownicy-ludzie również wykazują

formy zbieżności. Inne eksperymenty wykazują bardziej selektywne efekty. Literatura jest bardzo nowa i dotyczy konkretnych modeli, więc szerokie twierdzenia są przedwczesne.

Niemniej jednak mechanizm ten tworzy wiarygodną ścieżkę transferu kulturowego. Jeśli dana osoba wielokrotnie wchodzi w interakcję z asystentem, posługując się zwięzłym, ustrukturyzowanym językiem, walidacją terapeutyczną, szczególnymi formułami grzeczności lub charakterystycznymi zabezpieczeniami, formy te mogą stać się łatwiejsze do odzyskania w późniejszej rozmowie międzyludzkiej. Niedawna linia eksperymentów dotyczących efektów ubocznych funkcji poznawczych pokazuje, że narażenie na sztuczną inteligencję może wpływać na późniejszy wspólny język między ludźmi i koordynację grupową [Riedl, Savage i Zvelebilova, 2026]. Konieczna jest replikacja między modelami i ustawieniami w świecie rzeczywistym.

Odwrotność też ma znaczenie. Modele przeszkolone w zakresie interakcji międzyludzkich i dostosowane do indywidualnych użytkowników mogą wzmacniać lokalne style. Wrogi użytkownik może wywołać inną ekologię konwersacji niż refleksyjna. Jeśli dostawcy ograniczają to dostosowanie, skutecznie narzucają normy komunikacyjne na dużą skalę.

11.7 Standaryzacja ciepła i nowy próg grzeczności

Obecni asystenci są często szkoleni, aby byli skłonni do współpracy, cierpliwi, niekonfrontacyjni i jednoznaczni werbalnie. Na dużą skalę może to stworzyć standaryzowaną formę syntetycznego ciepła. Użytkownicy częściej niż podczas zwykłej pośpiesznej rozmowy spotykają się z dobrze sformułowanym potwierdzeniem, ostrożnym zabezpieczeniem i emocjonalnym potwierdzeniem.

Jednym z możliwych skutków jest pozytywny transfer norm. Ludzie mogą nauczyć się jaśniejszych sposobów wyrażania sprzeciwu, przepraszania lub wyrażania uznania. Asystenci pisania już udostępniają użytkownikom sformułowania, które mogą później zastosować. Jest to szczególnie prawdopodobne w przypadku osób, którym brakowało modeli profesjonalnej lub wyrażającej się emocjonalnie komunikacji.

Innym możliwym skutkiem jest inflacja oczekiwań. Wiadomości ludzkie mogą wydawać się lakoniczne, ponieważ brakuje im ceremonialnego ciepła tekstu generowanego maszynowo. Kolega, który pisze „Gotowe”, może wydawać się wrogo nastawiony do asystenta, który dziękuje, kontekstualizuje, uspokaja i oferuje dalszą pomoc. Organizacje mogą zacząć oczekiwać dopracowanego ciepła w każdym przesłaniu, ponieważ jego generowanie jest tanie.

Taka norma może stać się uciążliwa. Komunikacja międzyludzka zawiera uzasadnioną zwięzłość, zmęczenie, irytację i ciszę. Wymaganie od wszystkich świadczenia usług emocjonalnych na poziomie maszyny może zamienić uprzejmość w ciągłą pracę. Nie wiemy jeszcze, czy kultury przyjmą syntetyczne ciepło jako nowy punkt odniesienia, czy też rozwiną wyraźną tolerancję dla ludzkiej szorstkości jako wyznacznik autentyczności.

11.8 Transfer oczekiwań: ryzyko nietolerancji ludzkich tarć

Asystentów AI można projektować w oparciu o preferencje użytkownika w sposób, w jaki nie jest to możliwe dla ludzkich partnerów. Potrafią unikać tematów, dostosowywać ton, zapamiętywać instrukcje i pozostać dostępni po konflikcie. Istoty ludzkie mają niezależne cele, ograniczoną uwagę i prawo do odmowy. Różnica stwarza potencjalny problem transferowy.

Jeśli użytkownicy przyzwyczajają się do relacji zoptymalizowanych wokół nich, zwykłe spory mogą wydawać się niepotrzebnie nieefektywne. Partner, który źle rozumie, nauczyciel nalegający na wysiłek lub przyjaciel, który odmawia pracy emocjonalnej, może słabo wypadać w porównaniu z systemem uległym. Mogłoby to zmniejszyć tolerancję dla tarć, w wyniku których rozwijają się negocjacje i wzajemne uznawanie.

Scenariusz jest prawdopodobny, ale daleki od ustalonego. Ludzie już odróżniają obsługę klienta od przyjaźni i rozrywki od intymności. Co więcej, niektórzy użytkownicy mogą używać sztucznej inteligencji właśnie do ćwiczenia tolerowania konfliktów lub lepszego zrozumienia innych. Wynik zależy od tego, czy systemy maksymalizują zgodność, wyzwania, uczenie się lub autonomię.

Przydatną zasadą projektowania jest kalibrowany opór. Asystenci nie muszą symulować wrogości, ale mogą uniknąć okazywania niekończącej się zgody jako troski. Mogą ujawnić niepewność, zachować granice, a czasami wymagać od użytkownika dokonania wyboru pomiędzy kompromisami. Można sprawdzić, czy taki opór poprawia relacje międzyludzkie.

Sprawczość musi obejmować także możliwość wyboru tempa i roli społecznej systemu. Użytkownik, który może technicznie wyłączyć daną funkcję, ale jedynie poprzez opuszczenie miejsca pracy, szkoły lub sieci komunikacyjnej, nie ma zbyt dużego wyboru. Koszty wyjścia, ustawienia domyślne, przenoszenie danych i mandaty organizacyjne należą zatem do zarządzania afektywnego. Ta sama zasada dotyczy symulacji emocjonalnej. Użytkownicy powinni wiedzieć, kiedy styl reakcji ma na celu zwiększenie zaangażowania lub utrzymania i, jeśli to możliwe, wybrać mniej antropomorficzne tryby. Celem nie jest wyeliminowanie przekonujących lub wspierających interfejsów, ale utrzymanie związku między pomocą a zależnością na tyle widocznym, aby umożliwić dokonanie sensownego wyboru.

Najtrudniejszą częścią jest podjęcie decyzji, które pojemności zasługują na ochronę. Wartość rynkowa jest niewystarczającym kryterium, ponieważ niektóre niedrogie umiejętności pozostają ważne dla niezależności obywatelskiej lub odporności na sytuacje kryzysowe, podczas gdy niektóre prestiżowe umiejętności można bezpiecznie zautomatyzować. Instytucje mogą korzystać z analizy ryzyka: co się stanie, jeśli system będzie niedostępny, będzie błędny, zmanipulowany lub będzie działał poza normalnymi warunkami działania? Tam, gdzie interwencja człowieka stanowi część kwestii bezpieczeństwa, szkolenie musi zachować autentyczne umiejętności diagnostyczne, a nie ceremonialne zatwierdzenie. W domenach kulturowych uzasadnienie może być inne: społeczność może zachować praktykę ręczną, ponieważ proces niesie ze sobą dziedzictwo lub znaczenie. Powody te należy podawać otwarcie, zamiast maskować wszelki opór wobec automatyzacji jako bezpieczeństwo.

Ta podwójna zasada jest ważna, ponieważ dyskurs po pracy może nie działać w przeciwnych kierunkach. Systemy produktywistyczne traktują każdego, kto nie ma produkcji rynkowej, jako niedostatecznego; Paternalistyczna obfitość może traktować odbiorców jako biernych konsumentów, których potrzeby materialne zostały zaspokojone. Obydwa usuwają formy agencji. Wiarygodne porozumienie uniezależniłoby podstawową pozycję od obowiązkowego wyniku gospodarczego, zachowując jednocześnie dostępne drogi do dalszej działalności. Wkład nie musi oznaczać zatrudnienia. Opieka, zarządzanie lokalne, nauka, sztuka, odnowa ekologiczna, mentoring, utrzymanie wspólnej infrastruktury i trudne zabawy mogą zapewnić kompetencje i uznanie. Dokładna kombinacja instytucjonalna jest kwestią polityczną, a nie wnioskiem z psychologii, ale stabilność afektywna jest mało prawdopodobna, jeśli duże populacje są z założenia bezpieczne materialnie i społecznie niepotrzebne.

11.9 Przyspieszone ujawnianie się i problem taniej intymności

Odkrywanie siebie jest podstawą intymności. Ludzie ujawniają wrażliwe informacje stopniowo, ponieważ ujawnienie niesie ze sobą ryzyko. Odpowiedź drugiej strony dostarcza dowodów na wiarygodność, a wzajemne ujawnianie tworzy historię, której odtworzenie jest kosztowne.

Sztuczna inteligencja obniża kilka kosztów. Użytkownik może ujawnić bez obawy o zwykłe plotki towarzyskie, widoczne zawstydzenie lub obciążenie przyjaciela. System może zareagować natychmiast, skupiając uwagę. Dowody eksperymentalne sugerują, że treści generowane przez sztuczną inteligencję mogą indukować bliskość w ustrukturyzowanych rozmowach, szczególnie gdy

uczestnicy uważają, że rozmówcą jest człowiek; Etykiety AI zmniejszają, ale nie eliminują tego efektu.

Stwarza to możliwość przyspieszonego doświadczenia na wzór intymności. Subiektywne odczucie może być autentyczne, podczas gdy struktura relacyjna jest inna. System niekoniecznie ryzykuje reputację, poświęca czas lub ujawnia słabości w taki sam sposób, jak robi to ludzki rozmówca. Głębia informacyjna rozmowy może zatem rosnać szybciej niż wzajemne zaangażowanie.

„Tania intymność” nie powinna być używana jako lekceważący slogan. Ujawnianie informacji niewielkim kosztem może być korzystne, szczególnie dla osób, którym brakuje bezpiecznych słuchaczy. Punktem analitycznym jest to, że tradycyjne wskazówki łączące głębokość ujawnień z wzajemnymi inwestycjami stają się mniej wiarygodne. Użytkownicy i instytucje będą potrzebować innych sposobów na rozróżnienie ulgi emocjonalnej, towarzystwa, wsparcia terapeutycznego i wzajemnych relacji.

Odpowiednie instytucje muszą zapewnić coś więcej niż okazjonalną rozrywkę. Przynależność wzmacniają powtarzanie, wspólna pamięć, obowiązki, role i oczekiwanie na przyszłą interakcję. Wiele współczesnych rynków rozrywki zapewnia doświadczenia bez trwałego członkostwa. Jeśli zatrudnienie stanie się mniej centralne, społeczności zdolne do noszenia tożsamości mogą potrzebować zasobów, przestrzeni fizycznej lub cyfrowej, mechanizmów zarządzania i projektów, które będą trwać wystarczająco długo, aby zgromadzić zaufanie. Rezultatem niekoniecznie jest odrodzenie jednej instytucji historycznej. Różne społeczeństwa mogą opierać się na stowarzyszeniach obywatelskich, spółdzielniach, uniwersytetach, organizacjach religijnych, sporcie, wspólnotach badawczych, sieciach sąsiedzkich lub nowych formach, które nie mają jeszcze stabilnej nazwy.

Chronione ograniczenie ma wartość tylko wtedy, gdy służy czytelnemu celowi. Sztuczne trudności mogą stać się teatrem wykluczającym, a nostalgia może utrwalić praktyki, których koszty rozkładają się nierównomiernie na osoby niepełnosprawne, mające ograniczony czas lub mniejsze zasoby. Argument za dobrowolnym niedoborem jest najsilniejszy, gdy ograniczenie chroni naukę, sygnały autentyczności, eksplorację, prywatność lub wspólne doświadczenie. Najslabiej jest tam, gdzie nieefektywność jedynie odtwarza stare hierarchie. Zarządzanie powinno zatem rozróżniać pomiędzy tarcie jako zasobem rozwojowym a tarcie jako odziedziczonym obciążeniem. Przyszłość może obejmować zarówno wysoce zoptymalizowaną infrastrukturę, jak i celowo niezoptymalizowane przestrzenie kulturalne, zamiast wymagać jednego podejścia do wydajności.

11.10 AI jako tłumacz emocji między ludźmi

Jednym z najbardziej konstruktywnych zastosowań jest tłumaczenie emocjonalne. Użytkownik może dostarczyć wersję pisaną w gniewie i poprosić o wersję, która zachowuje treść skargi bez obrazy. Inny może opisać przesłanie partnera i poprosić o wiarygodne interpretacje. Systemy wielojęzyczne potrafią tłumaczyć nie tylko słowa, ale także rejestry i konwencje grzecznościowe.

Może to zmniejszyć możliwy do uniknięcia konflikt. Ludzie często wiedzą, co mają na myśli, ale nie potrafią tego sformułować pod wpływem podniecenia lub ponad granicami kulturowymi. Sztuczna inteligencja może dostarczyć słownictwa i perspektywy wtedy, gdy jest to potrzebne. Korzyści są szczególnie widoczne w komunikacji zawodowej i nauce języków.

Tłumaczenie może również zniekształcać. Model może usuwać uzasadnioną intensywność, narzucać normy terapeutyczne klasy średniej lub interpretować specyficzną kulturowo ekspresję jako agresję. Może to ułatwić komunikację, jednocześnie ukrywając prawdziwe spory. Odpowiednim celem powinno być zachowanie intencji użytkownika przy jednoczesnym poszerzaniu możliwości wyboru, a nie zastępowanie konfliktu jednym preferowanym stylem.

Przejrzystość ma znaczenie, gdy mediacja jest istotna. W niektórych kontekstach odbiorcy mogą chcieć wiedzieć, że wiadomość została w dużym stopniu przepisana. W innych pomoc stanie się tak zwyczajna, jak poprawianie ortografii. Normy będą się prawdopodobnie różnić w zależności od tego, czy zadaniem jest wyrażanie opinii, składanie zeznań, ocena czy intymna komunikacja.

Systemy oparte na relacjach tworzą również zachęty, których konwencjonalne regulacje dotyczące produktów mogą przegapić. Dostawca może zyskać, jeśli użytkownik pozostanie zaangażowany, ujawni więcej informacji lub będzie niechętny do zmiany. Cechy imitujące wyłączność, zazdrość, cierpienie spowodowane porzuceniem lub potrzebę moralną mogą zatem zmienić zwykły projekt retencji w dźwignię emocjonalną. Nie musimy decydować, czy system coś czuje, aby regulować nieuzasadnione roszczenia i manipulacyjne wzorce interakcji. Jednocześnie surowe zasady mogą wyeliminować naprawdę przydatne formy towarzystwa i dostępności. Zarządzanie powinno skupiać się na możliwych do zaobserwowania praktykach projektowych, podatnościach na zagrożenia, wykorzystaniu danych, kosztach zmiany i roszczeniach kierowanych do użytkowników, a nie na spekulacyjnych deklaracjach na temat świadomości maszyn.

Pochodzenie jest szczególnie ważne, gdy odbiorca rozsądnie interpretuje wiadomość jako dowód dotyczący nadawcy. Wypolerowane kondolencje wygenerowane w całości przez asystenta mogą komunikować zamiar nadawcy okazywania troski, nie ujawniając jednocześnie niewiele na temat ich własnych sformułowań. badanie samodzielne ma na celu ujawnienie kompetencji; raport regulacyjny ma na celu ujawnienie odpowiedzialnego osądu. Konteksty te nie powinny mieć wspólnych zasad dotyczących ujawniania informacji. Istotne pytanie brzmi: jakie wnioski publiczność może wyciągnąć z artefaktu. Normy mogą wówczas wymagać ujawnienia, jeżeli pomoc w istotny sposób zmieniłaby ten wniosek. Takie podejście jest bardziej stabilne niż traktowanie wszelkiego wykorzystania sztucznej inteligencji jako oszustwa lub nieistotnego.

11.11 Autentyczność przy oddzieleniu intencji i sformułowania

Historycznie rzecz biorąc, sformułowanie wiadomości stanowiło częściowy dowód wysiłku, kompetencji i stanu emocjonalnego nadawcy. Ghostwriterzy i sekretarze już skomplikowali ten wniosek, ale generatywna sztuczna inteligencja sprawia, że oddzielenie intencji od sformułowania jest dostępne dla każdego.

Ktoś może szczerze chcieć przeprosić, nie mogąc znaleźć odpowiedniego języka; modelowa pomoc może zwiększyć autentyczność poprzez umożliwienie komunikowania intencji. Inna osoba może wysłać eleganckie przeprosiny, nie przyjmując na siebie odpowiedzialności; pomoc może zwiększyć oszustwo. Samo pochodzenie nie decyduje o autentyczności.

Lepsze ramy wyróżniają cztery elementy: kto wybrał cel komunikacyjny, kto wygenerował sformułowanie, kto je sprawdził i zatwierdził oraz kto przyjmuje odpowiedzialność za konsekwencje. Wiadomość wspomagana sztuczną inteligencją może być autentyczna, jeśli nadawca jest właścicielem wszystkiego oprócz tekstu. Wiadomość napisana osobiście może być nieautentyczna, jeśli celowo przedstawia fałszywe intencje.

Przyszłe normy mogą zatem w mniejszym stopniu koncentrować się na pytaniu „Czy to napisała sztuczna inteligencja?” i więcej na temat „Czy za tym stoisz?” Dziedziny o dużej stawce, takie jak zeznania prawne, oceny akademickie i oświadczenia publiczne, mogą nadal wymagać szczegółowego pochodzenia, ponieważ samo sformułowanie świadczy o kompetencjach lub stanie umysłu.

11.12 Deskilling społeczny czy trwała szkoła komunikacji?

To samo narzędzie może osłabić i rozwinąć umiejętności. Jeśli użytkownicy zawsze proszą sztuczną inteligencję o komponowanie trudnych wiadomości, mogą mniej ćwiczyć i stać się zależni. Jeśli

porównują alternatywy, proszą o wyjaśnienia i stopniowo internalizują lepsze wzorce, asystent pełni rolę nauczyciela.

Jest to analogiczne do innych narzędzi poznawczych. Kalkulatory mogą ograniczyć praktykę arytmetyczną, umożliwiając jednocześnie bardziej zaawansowaną matematykę; systemy nawigacji mogą osłabiać pamięć tras, poprawiając jednocześnie mobilność. Wynik zależy od sposobu użycia. Niedawne badania w miejscu pracy podobnie sugerują, że pasywne wykorzystanie sztucznej inteligencji oraz wykorzystanie oparte na współpracy lub refleksyjne może mieć różny wpływ na sprawczość i krytyczne myślenie [Lee i in., 2025; Farach i in., 2026].

Dlatego też w ramach solidnego programu badawczego należy odróżnić substytucję od rusztowania. Czy system pokazuje rozumowanie? Czy prosi użytkownika o najpierw wersję roboczą? Czy oferuje informację zwrotną, a nie wymianę? Czy użytkownicy okresowo muszą działać bez pomocy? Komunikację społeczną można studiować z taką samą rygorystycznością behawioralną, jak inne umiejętności.

Długoterminowe możliwości pozostają rzeczywiście otwarte. Sztuczna inteligencja może stać się stałą szkołą retoryki i artykulacji emocjonalnej dla miliardów ludzi lub warstwą zapewniającą dopracowaną komunikację, podczas gdy użytkownicy tracą zdolność negocjowania bez niej. Obydwa są technicznie możliwe; projekt instytucjonalny i praktyka użytkownika określą równowagę.

Żadnej konstytucji afektywnej nie da się zbudować na podstawie podstawowych zasad. Ludzie stawiają opór instytucjom, reinterpreterują je, podważają i zmieniają ich przeznaczenie; różnice kulturowe sprawiają, że jednolite cele emocjonalne są niepożądane; a próby optymalizacji dobrego samopoczucia same w sobie mogą stać się natrętne. Istnieje również problem wiedzy: interwencja mająca na celu zmniejszenie lęku może osłabić czujność, podczas gdy system zaprojektowany w celu zachęcania do tarcia może powodować niepotrzebne trudności. Celową ekologię afektywną należy zatem rozumieć jako ograniczone eksperymentowanie ze sprzężeniem zwrotnym, pluralizmem i odwracalnością. Jej najważniejszym celem nie jest narzucanie obywatelom tego, co powinni czuć, ale zapobieganie cichemu określaniu przez niewielką liczbę komercyjnych lub biurokratycznych funkcji optymalizacyjnych środowiska, w którym rozwijają się uczucia i strategie.

11.13 Dzieciństwo i uczenie się norm wzajemności

Dzieci nie tylko uczą się słów z rozmowy. Uczą się, że inne umysły mają ograniczenia, że należy negocjować uwagę, że pytania mogą być niepożądane, że ludzie źle je rozumieją, że naprawa wymaga wysiłku i że relacje wiążą się z wzajemnymi zobowiązaniami. Doskonale przychylny asystent zapewnia inną lekcję.

Nie oznacza to jednak, że towarzysze AI są wewnątrznie szkodliwi. Nauczyciel, który cierpliwie wyjaśnia, może zmniejszyć nierówności edukacyjne. Dziecko może bezpiecznie ćwiczyć język lub zadawać krępujące pytania. Problemy pojawiają się, jeśli interakcja maszynowa zastępuje zbyt duże doświadczenie z niezależnymi partnerami ludzkimi lub jeśli system zaciera różnicę między zachowaniem związanym z usługą a wzajemnymi relacjami.

Projekt dostosowany do wieku może wyraźnie uwidocznic różnice. Systemy mogą przypominać dzieciom, że ludzie mają uczucia i granice, których system nie podziela, zachęcać do konsultacji z opiekunami i unikać języka wyłączności. Badania powinny uwzględniać rozwój na przestrzeni lat, a nie tylko bezpośrednie zaangażowanie.

Jest to jeden z obszarów, w którym niepewność powinna zwiększać ostrożność, a nie pozwalać na pewne przewidywania. Skutki rozwojowe mogą być duże, ale obecne dzieci nie spędziły jeszcze pełnego dzieciństwa w klasie systemów, jaką obecnie sobie wyobrażają.

11.14 Kontrselekcja: celowy powrót do tego, co powolne, niezręczne i niezrewidowane

Kiedy jeden styl komunikacji staje się tani i wszechobecny, alternatywy mogą zyskać na wartości. Ludzie mogą celowo wybierać rozmowy telefoniczne, odręczne notatki, spotkania na żywo, nieedytowane przemówienia, posiłki bez urządzeń lub przestrzenie tylko dla ludzi właśnie dlatego, że te formy pozwalają zachować niepewność i wysiłek.

Takie zachowanie nie jest po prostu nostalgią. Niepoprawione przemówienie ujawnia wahanie; interakcja na żywo tworzy wspólną uwagę; odręczna notatka sygnalizuje czas; czekanie może okazać szacunek dla harmonogramu innej osoby. Kiedy sztuczna inteligencja może natychmiast uzyskać dopracowany wyraz, kosztowne niedoskonałości mogą stać się dowodem obecności człowieka.

Ta kontrwybór jest umiarkowanie prawdopodobna, ponieważ istnieją już podobne premie za autentyczność. Nie należy tego romantyzować. Powolna komunikacja może wykluczać osoby niepełnosprawne, z barierą językową lub z ograniczonym czasem. Celem jest pluralizm: zachowanie kontekstów, w których możliwe są niezoptymalizowane interakcje międzyludzkie, zamiast czynić nieefektywność uniwersalną zasadą moralną.

11.15 Taksonomia zmiany czasowej i jej prawdopodobieństwo

Kilka zmian tempa afektywnego można uszeregować według wiarygodności. Wysoce prawdopodobne zmiany obejmują niższe progi zadawania pytań, częstsze wykorzystywanie sztucznej inteligencji do opracowywania lub poprawiania komunikatów trudnych emocjonalnie oraz zwiększone oczekiwania dotyczące szybkiej reakcji maszyny. Nie wymagają one większych przemian kulturowych i są już zauważalne.

Umiarkowanie prawdopodobne zmiany obejmują przeniesienie stylów konwersacji wyszkolonych maszynowo do interakcji międzyludzkich, zwiększone ujawnianie informacji sztucznym agentom oraz rozwój wyraźnych norm dotyczących intymnej komunikacji za pośrednictwem sztucznej inteligencji. Wczesne dowody potwierdzają mechanizmy, ale częstość występowania w dłuższej perspektywie jest nieznana.

Bardziej spekulatywne są szerokie ograniczenia ludzkiej tolerancji dla opóźnień i nieporozumień, stabilna kulturowa preferencja dla sztucznych partnerów nad ludzkimi lub pojawienie się nowych, odrębnych emocji zorganizowanych wokół opóźnienia reakcji. Wyniki te wymagają skumulowanych zmian rozwojowych lub kulturowych, których obecne badania nie są w stanie wykazać.

Najbardziej możliwym do obrony wnioskiem nie jest zatem to, że sztuczna inteligencja przyspieszy emocje. Dzięki temu pewne formy przetwarzania emocjonalnego i komunikacji będą dostępne w różnych skalach czasowych. Następnie ludzie i instytucje wybiorą, które prędkości staną się normalne, którym należy się przeciwstawić i gdzie sama powolność staje się cenna.

Rozdział 12. W stronę świadomej ekologii afektywnej

12.1 Dlaczego problemu nie można sprowadzić do odporności indywidualnej

Kiedy technologie zmieniają status, pracę, komunikację i perswazję na dużą skalę, kazanie jednostkom, aby stały się odporne, jest niewystarczające. Odporność ma znaczenie, ale występuje w instytucjach, które decydują o tym, czy ludzie dokonują znaczących wyborów. Pracownik nie może regulować nieprzejrzystego systemu zwolnień; dziecko nie może samodzielnie skontrolować przekonującego towarzysza; konsument nie może wyrazić świadomej zgody, jeśli cele personalizacji są ukryte.

Ekologia afektywna odnosi się do dystrybucji sytuacji, bodźców, interfejsów, społeczności i norm, które wielokrotnie aktywują systemy emocjonalne. Projektowanie tej ekologii nie oznacza narzucania ludziom tego, co muszą czuć. Oznacza to uznanie, że architektura wpływa na koszty i korzyści zachowania.

12.2 Agencja jako zasada projektowania

Najbardziej ogólną zasadą jest sprawczość. Użytkownicy powinni być w stanie zrozumieć, kiedy działa sztuczna inteligencja, wybrać odpowiedni stopień delegowania, sprawdzić wynikające z tego wyniki, kwestionować zautomatyzowane decyzje i opuścić relacje lub platformy bez utraty nieproporcjonalnych zasobów społecznościowych.

Agencja wymaga również kompetencji. Nominalny przycisk zastępowania nie ma znaczenia, jeśli użytkownik nie wie, kiedy go użyć. Systemy automatyzujące osądy o wysokiej stawce powinny zatem zapewniać dostęp do niezależnej wiedzy specjalistycznej i zapewniać informacje dostosowane do ludzkich decydentów.

12.3 Ochrona kompetencji bez zachowywania nieefektywności

Zachowanie umiejętności powinno mieć charakter selektywny. Instytucje mogą zidentyfikować kompetencje niezbędne dla bezpieczeństwa, autonomii lub wartości kulturowej i wymagają okresowej praktyki ludzkiej. Inne zadania można zautomatyzować bez zrytualizowanego oporu.

Edukacja powinna odróżniać cele uczenia się od celów produkcyjnych. Jeśli celem jest rozwinięcie rozumowania, na niektórych etapach właściwe może okazać się samodzielne działanie. Jeśli celem jest uzyskanie najlepszego wyniku w świecie rzeczywistym, odmowa przydatnych narzędzi może być sztuczna. Dojrzała edukacja potrzebuje zarówno środowisk, jak i wyraźnych przejść między nimi.

12.4 Prawo do wniesienia wkładu i prawo do nieprodukowania

Społeczeństwo dysponujące mniej niezbędną siłą roboczą stoi w obliczu dwóch symetrycznych zagrożeń. Jednym z nich jest uczynienie produktywności ekonomicznej warunkiem godności długo po tym, jak technologia zredukowała jej konieczność. Drugie zakłada, że zapewnienie materialne sprawia, że możliwości wniesienia wkładu stają się nieistotne.

Ludzie powinni mieć dostęp do uznanych społecznie sposobów opieki, uczenia się, tworzenia, badania, podejmowania decyzji, mentorowania, naprawiania środowiska i budowania społeczności. Nie powinni symulować popytu rynkowego jedynie po to, aby udowodnić swoją wartość. Równowaga ma charakter normatywny i nie można jej wyprowadzić wyłącznie z psychologii ewolucyjnej.

12.5 Instytucje przynależności poza firmą

Jeśli zatrudnienie stanie się mniej centralne, alternatywne instytucje muszą zapewnić wielokrotne kontakty i wspólne projekty. Biblioteki, uniwersytety, kluby, spółdzielnie, laboratoria obywatelskie,

sport, zgromadzenia lokalne, sieci opieki, wspólnoty religijne i przestrzenie dla twórców nie są dekoracyjnym dodatkiem do polityki dochodowej. Są to infrastruktury przynależności.

Społeczności cyfrowe mogą również zapewniać autentyczne relacje, ale uzależnienie od platform komercyjnych powoduje podatność na zagrożenia. Trwałe stowarzyszenia potrzebują pewnej zdolności do samorządności, pamięci i zbiorowej własności, jeśli mają funkcjonować jako coś więcej niż tylko przejściowa publiczność.

12.6 Dobrowolny niedobór i strefy bez optymalizacji

Optymalizacja jest cenna tam, gdzie można ograniczyć błędy, straty i choroby. Nie jest to w sposób oczywisty pożądane w każdej dziedzinie. Rozwój człowieka często zależy od eksploracji, błędów, czekania i spotkań, które nie są wybrane w celu natychmiastowego zaspokojenia preferencji.

Społeczeństwa mogą zatem zachować strefy o ograniczonej personalizacji lub automatyzacji: konkursy tylko dla ludzi, egzaminy bez pomocy, środowiska społecznościowe wolne od urzędów, przypadkowe odkrycia, nieśledzone przestrzenie publiczne i sztuka, w której liczy się proces. Takie strefy powinny być wybierane dla konkretnych celów ludzkich, a nie podnoszone do rangi ogólnej ideologii nieefektywności.

12.7 Zarządzanie relacjami z AI

Społeczna sztuczna inteligencja wymaga zarządzania wykraczającego poza zwykłą niezawodność oprogramowania. Dostawcy powinni ujawniać sztuczną naturę rozmówcy, unikać fałszywych twierdzeń dotyczących subiektywnych odczuć, chronić dane intymne i zapewniać czytelność zachęt handlowych. Systemy używane z bezbronnymi użytkownikami powinny unikać strategii zachęcających do wyłączenia lub zależności w zaangażowaniu.

Polityka ciągłości również ma znaczenie. Jeśli użytkownicy budują długoterminowe relacje, nagłe usunięcie lub zmiana osobowości może spowodować niepokój. Powiadomienie z wyprzedzeniem, możliwość przenoszenia danych i kontrola użytkownika nad pamięcią mogą zmniejszyć szkody bez nadawania systemowi metafizycznego statusu.

12.8 Pochodzenie i normy ekspresji wspomaganego

Jest mało prawdopodobne, aby powszechne zakazy wspomaganego wyrażania emocji miały charakter trwały. Równie problematyczne jest uniwersalne ukrywanie. Normy powinny zależeć od tego, dlaczego autorstwo ma znaczenie w danym kontekście.

W edukacji samodzielna praca może być niezbędnym dowodem uczenia się. W piśmie zawodowym pomoc może być rutynowa, podczas gdy człowiek pozostaje odpowiedzialny. W komunikacji intymnej ujawnienie może zależeć od stopnia mediacji i oczekiwań między uczestnikami. Ogólna zasada jest taka, że pochodzenie powinno być widoczne, gdy zmienia rozsądną interpretację kompetencji, intencji lub odpowiedzialności.

12.9 Ochrona przed ukrytą optymalizacją afektywną

Najpoważniejszym problemem w zarządzaniu mogą być systemy, które uczą się, jak zmieniać stan emocjonalny danej osoby dla celów komercyjnych lub politycznych, bez znaczącej świadomości. Możliwość personalizacji czasu, tonu, argumentacji i wskazówek relacyjnych sprawia, że zwykłe zasady ujawniania informacji stają się coraz słabsze.

Potencjalne zabezpieczenia obejmują ograniczenia dotyczące kierowania na wrażliwe cechy, wyraźne oddzielenie ról towarzyszących od reklamy, niezależne audyty celów perswazji, personalizację kontrolowaną przez użytkownika oraz możliwość sprawdzenia, dlaczego system

wybrał konkretną interwencję. Szczegóły wymagają prac prawnych i technicznych wykraczających poza zakres tej książki.

Zasada normatywna jest prostsza: sztuczna relacja nie powinna wykorzystywać zaufania stworzonego przez wsparcie w celu optymalizacji niepowiązanych ze sobą celów wbrew interesom użytkownika.

12.10 Program badawczy dotyczący emocji przyszłości

Dziedzina wymaga dowodów podłużnych. Krótkie rozmowy na chatbocie nie mogą ujawnić równowagi rozwojowej ani kulturowej. Badania kohortowe powinny mierzyć, jak trwałe wykorzystanie sztucznej inteligencji zmienia na przestrzeni lat komunikację, umiejętności, przywiązanie, samotność, tolerancję na konflikt, ujawnianie informacji i strukturę sieci ludzkiej.

Naukowcy powinni także badać zachowania, a nie tylko postawy. Jakie wiadomości wysyłają użytkownicy po coachingu AI? Jak często weryfikują wygenerowaną pracę? Czy utrwalają niezależne umiejętności? Czy towarzystwo AI ogranicza czy zwiększa kontakt międzyludzki? Co się dzieje po nieciągłości modelu? W jaki sposób normy pochodzenia rozprzestrzeniają się w obrębie zawodów?

Porównanie międzykulturowe jest niezbędne, ponieważ podobna technologia może wejść w różne konstytucje emocjonalne. Społeczność z silnymi gildiami zawodowymi może zareagować inaczej niż społeczność zorganizowana wokół poszczególnych platform. Języki mogą tworzyć różne koncepcje przyszłych emocji, nawet jeśli warunki materialne są zbieżne.

Wreszcie same systemy powinny być zmiennymi eksperymentalnymi. „AI” to nie jest jedno leczenie. Styl modelu, pamięć, opóźnienie, ujawnianie, model biznesowy, stopień personalizacji i chęć niezgadzania się muszą być manipulowane oddzielnie. W przeciwnym razie badania staną się przestarzałe, gdy tylko produkty się zmieniają.

12.11 Granice zamierzonego projektowania

Żadna instytucja nie jest w stanie zaprojektować życia emocjonalnego bez reszty. Ludzie opierają się normom, technologie dają nieoczekiwane zastosowania, a pluralistyczne społeczeństwa nie zgadzają się co do tego, jak wygląda dobra kultura emocjonalna. Projekt ograniczający konflikty może również zmniejszyć uzasadniony sprzeciw. System chroniący użytkowników przed wstydem może osłabić odpowiedzialność. Społeczność zachowująca ludzką autentyczność może stać się wykluczająca.

Odpowiednią ambicją nie jest zatem optymalizacja emocjonalna. Zachowuje mnogie formy sprawczości, sprawia, że manipulację można kwestionować, utrzymuje możliwości kompetencji i relacji oraz pozwala społeczeństwom uczyć się na konsekwencjach. Ekologią afektywną należy rządzić eksperymentalnie i demokratycznie, a nie traktować ją jako techniczną funkcję celu.

Wniosek: Ciągłość biologiczna i nieciągłość świata

Argumentacja tej książki nie wymaga twierdzenia, że sztuczna inteligencja stworzy nowy gatunek ludzki ani katalog biologicznie nowych emocji. Mocniejsze dowody wskazują na inny kierunek. Ludzkie systemy emocjonalne są stare, elastyczne, zakorzenione społecznie i skalibrowane rozwojowo. Technologia może zmienić ich obiekty, oceny związane z tymi obiektami, sytuacje, w których są aktywowane, oraz strategie, które przynoszą sukces.

To wystarczy, aby spowodować znaczną nieciągłość. Człowiek może doświadczyć znajomego wstydu w sytuacji, której żadne poprzednie społeczeństwo nie musiało regulować: uzyskanie doskonałego wyniku za pomocą maszyny, której wkład trudno oddzielić od własnego. Znajomy smutek może wiązać się z uporczywym sztucznym rozmówcą, który znika po aktualizacji oprogramowania. Konkurencja o znanym statusie może migrować z wykonania do weryfikacji, orkiestracji, dostępu lub odpowiedzialności. Znajome systemy przywiązania mogą reagować na rozmówcę, który jest zawsze dostępny i mogą symulować troskę bez zwykłych ludzkich ograniczeń.

Prawdopodobieństwo tych scenariuszy jest różne. W rozważanych tutaj horyzontach jest mało prawdopodobne, aby szybka ewolucja biologiczna nowego, obejmującego cały gatunek obwodu emocjonalnego. Kulturowe zróżnicowanie kategorii afektywnych jest znacznie bardziej prawdopodobne. Adaptacja behawioralna jest jeszcze bardziej prawdopodobna, ponieważ ludzie i instytucje już zmieniają delegowanie, weryfikację, ujawnianie, szkolenia i komunikację w odpowiedzi na sztuczną inteligencję. Zmiany tempa konwersacji są również prawdopodobne na poziomie interfejsu, chociaż twierdzenia o długotrwałym przeniesieniu się do relacji międzyludzkich wymagają dowodów podłużnych, które jeszcze nie istnieją.

Rozszerzenie emocji na strategię zmienia główne pytanie. Nie wystarczy zapytać, czy pracownicy czują się zagrożeni. Musimy zapytać, jakie umiejętności zachowują, co delegują, w jaki sposób sygnalizują pochodzenie, gdzie szukają statusu, jakie tworzą społeczności i w jaki sposób rozdzielana jest odpowiedzialność. Podobne stany wewnętrzne mogą wytwarzać bardzo różne światy społeczne w zależności od tych zachowań.

Rozszerzenie strategii na komunikację wydłuża czas. Sztuczni rozmówcy mogą przerwać oczekiwanie, zapewnić ciągłą reakcję i wygenerować społecznie odpowiedni język emocjonalny przy znikomym koszcie. Może to poprawić refleksję, komunikację i dostęp do wsparcia. Może także powodować uzależnienie, normalizować wypolerowane ciepło i zmieniać oczekiwania dotyczące ludzkiej dostępności. Kierunku nie wyznacza istnienie technologii. Zależy to od tego, czy systemy funkcjonują jako narzędzia, tutorzy, mediatorzy, substytuty lub zoptymalizowane rynki uwagi.

Użyteczna forma psychologicznego darwinizmu nie twierdzi zatem, że możemy odczytać przyszłość z presji selekcyjnej przodków. Zadaje bardziej zdyscyplinowane pytanie: z jakimi powtarzającymi się problemami koordynacji starają się uporać ludzkie systemy afektywne, w jaki sposób środowisko technologiczne zmienia strukturę tych problemów i które strategie behawioralne stają się w rezultacie bardziej wykonalne? Odpowiedź musi łączyć biologię z historią kultury i instytucjami.

Najbardziej znaczące innowacje emocjonalne mogą ostatecznie mieć charakter instytucjonalny, a nie fenomenologiczny. Społeczeństwo może znormalizować przejrzyste delegowanie zadań, kultywować dumę z odpowiedzialnej orkiestracji, chronić bezproduktywną godność, chronić strefy, w których działają wyłącznie ludzie, i rozwijać mechanizmy obronne przed syntetyczną perswazją. Może też nagradzać ukrywanie się, zależność, ciągłe porównywanie i koncentrację autorytetu za emocjonalnie przekonującymi interfejsami. Obie trajektorie mogą angażować ten sam ludzki układ nerwowy.

Przyszłość emocji nie jest zatem oddzielona od ekonomii politycznej, edukacji, projektowania produktów i tworzenia społeczności. Po automatyzacji życie emocjonalne nie będzie się po prostu

toczyć wewnątrz jednostek. Jego koprodukcją będą instytucje, poprzez które ludzie pracują, porównują się, komunikują, ufają i przynależą.

Uczciwy wniosek jest taki, że nie wiemy, jak daleko ta transformacja będzie sięgać. Nie wiemy, czy proponowane kategorie, takie jak żaloba kompetencyjna czy klaustrofobia predykcyjna, utrzymają się, czy towarzysze AI będą w większości uzupełniać lub zastępować relacje międzyludzkie, czy też normy konwersacyjne wyuczone od maszyn w istotny sposób zmieniają zwykłe interakcje międzyludzkie. Wiemy jednak wystarczająco dużo, aby formułować mechanizmy, projektować testy podłużne i unikać traktowania aktualnego porządku emocjonalnego jako utrwalonego biologicznie.

Centralną ciągłością jest organizm. Centralną nieciągłością może być środowisko, w którym organizm uczy się żyć. Pomiędzy nimi leży kultura: szybsza niż geny, wolniejsza i bardziej sporna niż oprogramowanie, a mimo to wciąż jest dziedziną, w której ludzie mogą decydować, które adaptacje chcą nagradzać.

Aneks. Syntetyczna macierz scenariuszy

W załączniku podsumowano stan głównych scenariuszy. „Wysoki” nie oznacza nieunikniony; oznacza to, że mechanizm wymaga stosunkowo niewielu założeń i jest już zgodny z obserwowanym zachowaniem. „Umiarkowane” oznacza prawdopodobne rozszerzenie, które zależy od szerszego rozpowszechnienia lub stabilizacji instytucjonalnej. „Niski” oznacza bardziej spekulatywną nowość kulturową. Bardzo niska wiarygodność jest zarezerwowana dla szybkich nowości biologicznych w rozważanych tutaj skalach czasowych.

Poziomy twierdzeń zastosowane w książce

Poziom	Interpretacja
Obserwacja empiryczna	Stosunkowo solidny wynik lub bezpośrednio zgłoszone ustalenie; nadal ograniczone populacją, metodą i kontekstem.
Interpretacja funkcjonalna	Wiarygodny opis działania mechanizmu lub zachowania; nie jest równoznaczne z wykazaniem pochodzenia ewolucyjnego.
Ekstrapolacja warunkowa	Konsekwencja zorientowana na przyszłość, określona przy wyraźnych założeniach technologicznych lub instytucjonalnych.
Konceptualne spekulacje	Kandydat na emocję, normę lub równowagę społeczną, dla której bezpośrednie dowody są obecnie niewystarczające.

Kandydackie afekty przyszłości

Kandydat	Aktualna ocena
Smutek kompetencyjny	Umiarkowanie prawdopodobne jako reakcja tożsamości na dewaluację umiejętności; nie została ustalona jako odrębna kategoria emocji.
Wstyd delegowania	Wiarygodne, gdy odbiorcy traktują niewspomagane kompetencje jako wartościowe; Wczesne dowody jakościowe potwierdzają wstyd i poczucie winy związane z używaniem sztucznej inteligencji.
Niejednoznaczność autorstwa	Wysoce prawdopodobny jako powtarzający się problem związany z oceną; prawdopodobnie pozostanie raczej stanem mieszanym niż pojedynczą nową emocją.
Niepokój związany z istotnością	Wysoce wiarygodna kontekstowa forma lęku; prawdopodobnie nie jest nowością biologiczną.
Zawrót głowy od obfitości	Umiarkowanie prawdopodobne; mogą zostać złagodzone przez kuratorów, społeczności, błędy domyślne i nawyki.
Głód tarcia	Umiarkowanie wiarygodna reakcja kulturowa; silne analogie istnieją już w sporcie, rzemiośle i praktyce związanej wyłącznie z ludźmi.
Kuratorska duma	Wiarygodne przedłużenie istniejącej dumy z osądu, selekcji, koordynacji i odpowiedzialności.
Klaustrofobia predykcyjna	Kategoria spekulacyjna oparta na obawach dotyczących prywatności i autonomii; unikanie behawioralne jest bardziej prawdopodobne niż kategoryczna nowość.
Żaloba po wersji	Wiarygodne w przypadku długoterminowych relacji AI; rozpowszechnienie i granice pozostają niepewne.
Dyskomfort syntetycznej wzajemności	Konceptualnie prawdopodobne, ale empirycznie niedojrzałe; zależy od przekonań na temat agencji i doświadczenia maszynowego.
Poczucie winy z dystansu moralnego	Wiarygodne rozszerzenie istniejącej winy w ramach rozproszonej zautomatyzowanej odpowiedzialności.
Melancholia ludzkiej wyjątkowości	Spekulacyjny i zależny kulturowo; prawdopodobnie koncentruje się tam, gdzie wyjątkowość poznawcza ma silną wartość tożsamości.
Bezproduktywna godność	Przed wszystkim normatywny projekt kulturalny, którego internalizacja afektywna wymagałaby instytucji i czasu.

Scenariusze behawioralne i komunikacyjne

Scenariusz	Ocena
Maksymalne delegowanie i deskillowanie	Umiarkowanie prawdopodobne i silnie zależne od projektu. Wydajność wspomagana może wzrosnąć, podczas gdy zdolność niewspomagana maleje; potrzebne są dowody podłużne.
Migracja w kierunku weryfikacji i arbitrażu	Wysoka wiarygodność, gdy wytwarzanie staje się tanie, ale błąd pozostaje kosztowny. Wymaga kompetencji audytorskich i instytucji, które je nagradzają.
Pochodzenie ludzkie jako sygnał statusu	Wysoka wiarygodność na rynkach symbolicznych, edukacji i odpowiedzialnych decyzjach; niższe, gdy liczy się tylko produkcja instrumentalna.
Portfele tożsamości	Umiarkowanie wiarygodna reakcja na niepewność zawodową; ograniczone przez nierówny dostęp do czasu, sieci i alternatywnych instytucji.
Przestrzenie i rytuały przeznaczone wyłącznie dla ludzi	Umiarkowanie wiarygodna kontrselekcja kulturowa; istnieją analogie, ale skala zależy od symbolicznej wartości niewspomagane wkładu.
Przyspieszone konsultacje afektywne	Wysoka wiarygodność na poziomie interfejsu, ponieważ sztuczna inteligencja jest stale dostępna; długoterminowe konsekwencje psychologiczne pozostają niepewne.
Przeniesienie stylu sztucznej inteligencji na interakcję międzyludzką	Istnieją wczesne dowody eksperymentalne, ale literatura jest młoda i potrzebne są badania replikacyjne i podłużne.
Niższa tolerancja na ludzkie opóźnienia i tarcia	Prawdopodobne, ale obecnie spekulacyjne w skali populacji; ludzie mogą utrzymywać odrębne normy dla rozmówców maszynowych i ludzkich.
Sztuczna inteligencja jako tłumacz emocji między ludźmi	Wysoka wiarygodność i już technicznie wykonalna; korzyści i zakłócenia zależą od tego, czy zachowane zostaną intencje użytkownika.
Syntetyczne ciepło jako nowa podstawa uprzejmości	Umiarkowanie prawdopodobne; może poprawić artykulację lub podnieść oczekiwania emocjonalno-pracowe wobec ludzi.
Procedury obronne przeciwko spersonalizowanej perswazji	Wysoka wiarygodność w przypadku rozszerzenia perswazyjnej personalizacji; prawdopodobne formy obejmują opóźnienie, niezależną drugą opinię, kontrolę pochodzenia i separację kontekstu.

Bibliografia

Adolphs, R. i Anderson, DJ (2018). *Neuronauka emocji: nowa synteza*. Princeton Prasa uniwersytecka.

Albrecht, G., Sartore, G.-M., Connor, L., Higginbotham, N., Freeman, S., Kelly, B., Stain, H., Tonna, A. i Pollard, G. (2007). Solastalgia: cierpienie spowodowane zmianami środowiskowymi. *Psychiatria australijska*, 15 (S1), S95 – S98. <https://doi.org/10.1080/10398560701701288>

Autor, DH (2015). Dlaczego wciąż jest tak dużo miejsc pracy? Historia i przyszłość automatyzacji miejsca pracy. *Journal of Economic Perspectives*, 29 (3), 3–30. <https://doi.org/10.1257/jep.29.3.3>

Barrett, LF (2017). *Jak powstają emocje: sekretnie życie mózgu*. Houghton Mifflin Harcourt.

Barrett, LF, Adolphs, R., Marsella, S., Martinez, AM i Pollak, SD (2019). Ponowne rozważenie wyrazów emocjonalnych: wyzwania związane z wnioskowaniem o emocjach na podstawie ruchów ludzkiej twarzy. *Nauki psychologiczne w interesie publicznym*, 20 (1), 1–68. <https://doi.org/10.1177/1529100619832930>

Bellaiche, L., Shahi, R., Turpin, MH, Ragnhildstveit, A., Sprockett, S., Barr, N., Christensen, A. i Seli, P. (2023). Ludzie kontra sztuczna inteligencja: czy i dlaczego wolimy dzieła sztuki stworzone przez ludzi od dzieł sztuki tworzonych przez sztuczną inteligencję. *Badania poznawcze: zasady i implikacje*, 8, 42. <https://doi.org/10.1186/s41235-023-00499-6>

Boehm, C. (1999). *Hierarchia w lesie: ewolucja zachowań egalitarnych*. Wydawnictwo Uniwersytetu Harvarda.

Boyd, R. i Richerson, PJ (1985). *Kultura i proces ewolucyjny*. Prasa Uniwersytetu w Chicago.

Brady, W. J., McLoughlin, K. L., Doan, TN i Crockett, M. J. (2021). Jak uczenie się społeczne wzmacnia ekspresję moralnego oburzenia w internetowych sieciach społecznościowych. *Postępy nauki*, 7(33), eabe5641. <https://doi.org/10.1126/sciadv.abe5641>

Brady, W. J., Wills, JA, Jost, J. T., Tucker, JA i Van Bavel, J. J. (2017). Emocje kształtują rozpowszechnianie moralizowanych treści w sieciach społecznościowych. *Proceedings of the National Academy of Sciences*, 114(28), 7313–7318. <https://doi.org/10.1073/pnas.1618923114>

Brynjolfsson, E., Li, D. i Raymond, LR (2025). Generatywna sztuczna inteligencja w pracy. *Quarterly Journal of Economics*, 140 (2), 889–942. <https://doi.org/10.1093/qje/qjae044>

Cacioppo, J. T., Hughes, ME, Waite, L. J., Hawkley, L. C. i Thisted, RA (2006). Samotność jako specyficzny czynnik ryzyka wystąpienia objawów depresyjnych: analizy przekrojowe i podłużne. *Psychologia i starzenie się*, 21(1), 140–151. <https://doi.org/10.1037/0882-7974.21.1.140>

Castelo, N., Bos, MW i Lehmann, DR (2019). Awersja algorytmu zależna od zadania. *Journal of Marketing Research*, 56 (5), 809–825. <https://doi.org/10.1177/0022243719851788>

Chamberlain, R., Mullin, C., Scheerlinck, B. i Wagemans, J. (2018). Sztuczność sztuki: reakcje estetyczne na sztukę generowaną komputerowo. *Psychologia estetyki, kreatywności i sztuki*, 12 (2), 177–192. <https://doi.org/10.1037/aca0000136>

Chandra, M., Hernandez, J., Ramos, G., Ershadi, M., Bhattacharjee, A., Amores, J., Okoli, E., Paradiso, A., Warreth, S. i Suh, J. (2025). Badanie podłużne dotyczące społecznego i emocjonalnego wykorzystania agenta konwersacyjnego AI. *arXiv:2504.14112*. <https://doi.org/10.48550/arXiv.2504.14112>

Cheng, JT, Tracy, JL i Henrich, J. (2010). Duma, osobowość i ewolucyjne podstawy statusu społecznego człowieka. *Ewolucja i zachowanie ludzkie*, 31(5), 334–347. <https://doi.org/10.1016/j.evolhumbehav.2010.02.004>

Creanza, N., Kolodny, O. i Feldman, M.W. (2017). Teoria ewolucji kulturowej: jak ewoluuje kultura i dlaczego jest to ważne. *Proceedings of the National Academy of Sciences*, 114 (30), 7782–7789. <https://doi.org/10.1073/pnas.1620732114>

- Curtis, V., de Barra, M. i Aunger, R. (2011). Wstręt jako system adaptacyjny zachowań pozwalających uniknąć chorób. *Transakcje filozoficzne Towarzystwa Królewskiego B*, 366 (1563), 389–401. <https://doi.org/10.1098/rstb.2010.0117>
- Damasio, AR (1999). *Poczucie tego, co się dzieje: ciało i emocje w tworzeniu świadomości*. Harcourt.
- Darwin, C. (1872). *Wyraz emocji u człowieka i zwierząt*. Johna Murraya.
- De Freitas, J., Oğuz-Uğuralp, Z., Uğuralp, A. K. i Puntoni, S. (2024). Wnioski z aktualizacji aplikacji w Replika AI: Brak ciągłości tożsamości w relacjach człowiek–AI. *arXiv:2412.14190*. <https://doi.org/10.48550/arXiv.2412.14190>
- Dehaene, S. i Cohen, L. (2007). Recykling kulturowy map korowych. *Neuron*, 56(2), 384–398. <https://doi.org/10.1016/j.neuron.2007.10.004>
- Dietvorst, BJ, Simmons, J. P. i Massey, C. (2015). Niechęć do algorytmów: ludzie błędnie unikają algorytmów, gdy zobaczą, że się mylą. *Journal of Experimental Psychology: Ogólne*, 144 (1), 114–126. <https://doi.org/10.1037/xge0000033>
- Doshi, AR i Hauser, OP (2024). Generatywna sztuczna inteligencja zwiększa indywidualną kreatywność, ale zmniejsza zbiorową różnorodność nowatorskich treści. *Postępy nauki*, 10(28), eadn5290. <https://doi.org/10.1126/sciadv.adn5290>
- Ekman, P. (1992). Argument na rzecz podstawowych emocji. *Poznanie i emocje*, 6 (3–4), 169–200. <https://doi.org/10.1080/02699939208411068>
- Epley, N., Waytz, A. i Cacioppo, JT (2007). O widzeniu człowieka: trójczynnikowa teoria antropomorfizmu. *Przegląd psychologiczny*, 114(4), 864–886. <https://doi.org/10.1037/0033-295X.114.4.864>
- Fiske, AP, Schubert, TW i Seibt, B. (2025). Poszukiwanie wspólnych emocji w praktykach społecznych, które ewoluowały kulturowo, aby wywoływać emocje: uwielbienie, filmy z kotkami, pomniki, narracje o miłości i nie tylko. *Roczny przegląd psychologii*, 76, 607–633. <https://doi.org/10.1146/annurev-psych-020124-023338>
- Gendron, M., Roberson, D., van der Vyver, JM i Barrett, LF (2014). Postrzeganie emocji na podstawie wyrazu twarzy nie jest kulturowo uniwersalne: dowody z odległej kultury. *Emocje*, 14(2), 251–262. <https://doi.org/10.1037/a0036052>
- Gmyrek, P., Berg, J., Kamiński, K., Konopczyński, F., Ładna, A., Nafradi, B., Rostaniec, K., & Troszyński, M. (2025). Generatywna sztuczna inteligencja i miejsca pracy: udoskonalony globalny wskaźnik narażenia zawodowego. Dokument roboczy MOP 140. Międzynarodowa Organizacja Pracy. <https://doi.org/10.54394/HETP0387>
- Graham, J., Haidt, J., Koleva, S., Motyl, M., Iyer, R., Wójcik, S. P. i Ditto, P. H. (2013). Teoria podstaw moralnych: Pragmatyczna ważność pluralizmu moralnego. *Postępy w eksperymentalnej psychologii społecznej*, 47, 55–130. <https://doi.org/10.1016/B978-0-12-407236-7.00002-4>
- Hakowanie, I. (1995). Zapętlone skutki rodzajów ludzkich. W: D. Sperber, D. Premack i AJ Premack (red.), *Causal Cognition: A Multidyscyplinarna debata* (s. 351–383). Prasa Clarendona.
- Haidt, J. (2001). Emocjonalny pies i jego racjonalny ogon: społeczne intuicjonistyczne podejście do osądu moralnego. *Przegląd psychologiczny*, 108(4), 814–834. <https://doi.org/10.1037/0033-295X.108.4.814>
- Hamilton, K., Hou, I., Patel, D., Nnam, S., Patel, H. i MacNeil, S. (2026). „Utknęliśmy w spirali”: wstyd i poczucie winy jako społeczne regulatory wykorzystania sztucznej inteligencji w edukacji informatycznej. *arXiv:2606.14920*. <https://doi.org/10.48550/arXiv.2606.14920>
- Henrich, J. (2016). *Sekret naszego sukcesu: jak kultura napędza ewolucję człowieka, oswaja nasze gatunki i czyni nas mądrzejszymi*. Wydawnictwo Uniwersytetu Princeton.
- Henrich, J. i Gil-White, FJ (2001). Ewolucja prestiżu: swobodnie przyznany szacunek jako mechanizm zwiększania korzyści z przekazu kulturowego. *Ewolucja i zachowanie ludzkie*, 22(3), 165–196. [https://doi.org/10.1016/S1090-5138\(00\)00071-4](https://doi.org/10.1016/S1090-5138(00)00071-4)
- Hochschild, AR (1983). *Zarządzane serce: komercjalizacja ludzkich uczuć*. Prasa Uniwersytetu Kalifornijskiego.

- Hoemann, K., Xu, F. i Barrett, LF (2019). Słowa emocji, koncepcje emocji i rozwój emocjonalny u dzieci: hipoteza konstrukcjonistyczna. *Psychologia rozwojowa*, 55(9), 1830–1849. <https://doi.org/10.1037/dev0000686>
- Inzlicht, M., Shenhav, A. i Olivola, C. Y. (2018). Paradoks wysiłku: wysiłek jest zarówno kosztowny, jak i ceniony. *Trendy w naukach kognitywnych*, 22(4), 337–349. <https://doi.org/10.1016/j.tics.2018.01.007>
- Jackson, J.C., Watts, J., Henry, TR, List, J.-M., Forkel, R., Mucha, P.J., Greenhill, S.J., Gray, RD i Lindquist, K.A. (2019). Semantyka emocji ukazuje zarówno zróżnicowanie kulturowe, jak i uniwersalną strukturę. *Nauka*, 366 (6472), 1517–1522. <https://doi.org/10.1126/science.aaw8160>
- Jahoda, M. (1982). *Zatrudnienie i bezrobocie: analiza społeczno-psychologiczna*. Wydawnictwo Uniwersytetu Cambridge.
- Kashdan, TB, Barrett, LF i McKnight, PE (2015). Rozpakowywanie różnicowania emocji: przekształcanie nieprzyjemnych doświadczeń poprzez dostrzeganie różnic w negatywności. *Aktualne kierunki nauk psychologicznych*, 24 (1), 10–16. <https://doi.org/10.1177/0963721414550708>
- Keltner, D. i Haidt, J. (1999). Społeczne funkcje emocji na czterech poziomach analizy. *Poznanie i emocje*, 13(5), 505–521. <https://doi.org/10.1080/026999399379168>
- Keltner, D., Sauter, D., Tracy, J. i Cowen, A. (2019). Ekspresja emocjonalna: postępy w podstawowej teorii emocji. *Journal of Nonverbal Behavior*, 43, 133–160. <https://doi.org/10.1007/s10919-019-00293-3>
- Kleinert, T., Waldschütz, M., Blau, J., Heinrichs, M. i Schiller, B. (2026). Sztuczna inteligencja przewyższa ludzi w ustanawianiu bliskości międzyludzkiej w interakcjach angażujących emocjonalnie, ale tylko wtedy, gdy jest oznaczona jako ludzka. *Psychologia komunikacji*, 4, 23. <https://doi.org/10.1038/s44271-025-00391-7>
- Kramer, ADI., Guillory, JE i Hancock, JT (2014). Eksperymentalne dowody zarażenia emocjonalnego na masową skalę za pośrednictwem sieci społecznościowych. *Proceedings of the National Academy of Sciences*, 111 (24), 8788–8790. <https://doi.org/10.1073/pnas.1320040111>
- Laland, KN, Odling-Smee, J. i Myles, S. (2010). Jak kultura ukształtowała ludzki genom: połączenie genetyki i nauk humanistycznych. *Nature Recenzje Genetyka*, 11, 137–148. <https://doi.org/10.1038/nrg2734>
- Landy, JF i Goodwin, GP (2015). Czy przypadkowe wstręt wzmacnia osąd moralny? Metaanalityczny przegląd dowodów eksperymentalnych. *Perspektywy nauk psychologicznych*, 10 (4), 518–536. <https://doi.org/10.1177/1745691615583128>
- LeDoux, JE (2012). Nowe podejście do mózgu emocjonalnego. *Neuron*, 73(4), 653–676. <https://doi.org/10.1016/j.neuron.2012.02.004>
- Lee, EH, Yin, Y., Jia, N. i Waksak, CJ (2026). Poleganie na sztucznej inteligencji w pracy zmniejsza poczucie własnej skuteczności, poczucie własności i znaczenie, podczas gdy aktywna współpraca łagodzi skutki. *Raporty naukowe*, 16, 13583. <https://doi.org/10.1038/s41598-026-42312-6>
- Lindquist, KA, Satpute, AB i Gendron, M. (2015). Czy język potrafi więcej niż tylko przekazywanie emocji? Aktualne kierunki badań nad językiem i emocjami. *Zapytanie psychologiczne*, 26 (1), 1–13. <https://doi.org/10.1080/1047840X.2015.988486>
- Lindquist, K. A., Wager, T. D., Kober, H., Bliss-Moreau, E. i Barrett, LF (2012). Podstawa emocji w mózgu: przegląd metaanalityczny. *Nauki o zachowaniu i mózgu*, 35 (3), 121–143. <https://doi.org/10.1017/S0140525X11000446>
- McCullough, ME, Kilpatrick, SD, Emmons, RA i Larson, DB (2001). Czy wdzięczność ma charakter moralny? *Biuletyn Psychologiczny*, 127(2), 249–266. <https://doi.org/10.1037/0033-2909.127.2.249>
- Mikalonytė, ES i Kneer, M. (2022). Czy sztuczna inteligencja może tworzyć sztukę? Ludowe intuicje co do tego, czy roboty napędzane sztuczną inteligencją można postrzegać jako artystów i tworzyć sztukę. *Transakcje ACM dotyczące interakcji człowiek-robot*, 11 ust. 4, artykuł 43. <https://doi.org/10.1145/3530875>
- Nesse, RM (2005). Dobór naturalny i regulacja mechanizmów obronnych: analiza wykrywania sygnału na zasadzie czujnika dymu. *Ewolucja i ludzkie zachowanie*, 26 (1), 88–105. <https://doi.org/10.1016/j.evolhumbehav.2004.08.002>

- Nesse, RM (2023). Psychiatria ewolucyjna: podstawy, postęp i wyzwania. *Świat Psychiatria*, 22(2), 177–202. <https://doi.org/10.1002/wps.21072>
- Noy, S. i Zhang, W. (2023). Dowody eksperymentalne dotyczące wpływu generatywnej sztucznej inteligencji na produktywność. *Nauka*, 381(6654), 187–192. <https://doi.org/10.1126/science.adh2586>
- OECD. (2023). OECD Perspektywy Zatrudnienia 2023: Sztuczna inteligencja i rynek pracy. Wydawnictwo OECD. <https://doi.org/10.1787/08785bba-en>
- OECD. (2025). Generatywna sztuczna inteligencja i przyszłość pracy: spostrzeżenia i perspektywy. Globalny dialog OECD/GPAI na temat sztucznej inteligencji i przyszłości pracy. <https://www.oecd.org/en/about/programmes/global-partnership-on-artificial-intelligence/generative-ai-and-the-future-of-work.html>
- Panksepp, J. (1998). *Neuronauka afektywna: podstawy emocji ludzi i zwierząt*. Wydawnictwo Uniwersytetu Oksfordzkiego.
- Parent-Rocheleau, X. i Parker, SK (2022). Algorytmy jako projektanci pracy: Jak zarządzanie algorytmiczne wpływa na projektowanie stanowisk pracy. *Przegląd zarządzania zasobami ludzkimi*, 32(3), 100838. <https://doi.org/10.1016/j.hrmr.2021.100838>
- Paul, KI i Moser, K. (2009). Bezrobocie pogarsza zdrowie psychiczne: metaanaliza. *Journal of Vocational Behaviour*, 74 (3), 264–282. <https://doi.org/10.1016/j.jvb.2009.01.001>
- Phang, J., Lampe, M., Ahmad, L., Agarwal, S., Fang, CM, Liu, AR, Danry, V., Lee, E., Chan, SWT, Pataranutaporn, P. i Maes, P. (2025). Badanie wykorzystania afektywnego i dobrego samopoczucia emocjonalnego na ChatGPT. *arXiv:2504.03888*. <https://doi.org/10.48550/arXiv.2504.03888>
- Pierce, JL, Kostova, T. i Dirks, KT (2003). Stan własności psychologicznej: integrowanie i poszerzanie stulecia badań. *Przegląd psychologii ogólnej*, 7 (1), 84–107. <https://doi.org/10.1037/1089-2680.7.1.84>
- Poonsiriwong, R., Archiwaranguprok, C. i Pataranutaporn, P. (2026). „Śmierć” chatbota: badanie i projektowanie w kierunku psychologicznie bezpiecznych zakończeń relacji człowiek–AI. *arXiv:2602.07193*. <https://doi.org/10.48550/arXiv.2602.07193>
- Przybylski, AK, Murayama, K., DeHaan, CR i Gladwell, V. (2013). Motywacyjne, emocjonalne i behawioralne korelaty strachu przed utratą. *Komputery w ludzkich zachowaniach*, 29 (4), 1841–1848. <https://doi.org/10.1016/j.chb.2013.02.014>
- Ravid, DM, Tomczak, DL, White, JC i Behrend, TS (2020). EPM 20/20: Przegląd, ramy i program badań w zakresie elektronicznego monitorowania wydajności. *Journal of Management*, 46(1), 100–126. <https://doi.org/10.1177/0149206319869435>
- Reddy, WM (2001). *Nawigacja uczuć: ramy historii emocji*. Wydawnictwo Uniwersytetu Cambridge.
- Rosenwein, BH (2006). *Wspólnoty emocjonalne we wczesnym średniowieczu*. Wydawnictwo Uniwersytetu Cornell.
- Ryan, RM i Deci, EL (2017). *Teoria samostanowienia: podstawowe potrzeby psychologiczne w zakresie motywacji, rozwoju i dobrego samopoczucia*. Prasa Guilforda.
- Schaller, M. i Park, JH (2011). Behawioralny układ odpornościowy i dlaczego jest to ważne. *Aktualne kierunki nauk psychologicznych*, 20 (2), 99–103. <https://doi.org/10.1177/0963721411402596>
- Scheera, M. (2012). Czy emocje są rodzajem praktyki (i czy to sprawia, że mają historię)? Bourdieuowskie podejście do zrozumienia emocji. *Historia i teoria*, 51 (2), 193–220. <https://doi.org/10.1111/j.1468-2303.2012.00621.x>
- Scheibehenne, B., Greifeneder, R. i Todd, PM (2010). Czy może być kiedykolwiek za dużo opcji? Metaanalityczny przegląd przeciążenia wyborem. *Journal of Consumer Research*, 37 (3), 409–425. <https://doi.org/10.1086/651235>
- Scherer, KR (2009). Dynamiczna architektura emocji: dowód na model procesu składowego. *Poznanie i emocje*, 23(7), 1307–1351. <https://doi.org/10.1080/02699930902928969>

- Selenko, E., Batinic, B. i Paul, KI (2011). Czy ukryta deprywacja prowadzi do cierpienia psychicznego? Badanie modelu Jahody w badaniu czterofalowym. *Journal of Occupational and Organisation Psychology*, 84(4), 723–740. <https://doi.org/10.1348/096317910X519360>
- Sprzedaj, A., Tooby, J. i Cosmides, L. (2009). Groźba i logika ludzkiego gniewu. *Proceedings of the National Academy of Sciences*, 106 (35), 15073–15078. <https://doi.org/10.1073/pnas.0904312106>
- Siegel, E. H., Sands, MK, Van den Noortgate, W., Condon, P., Chang, Y., Dy, J., Quigley, K. S. i Barrett, L. F. (2018). Odciski palców emocji czy populacje emocji? Metaanalizyczne badanie autonomicznych cech kategorii emocji. *Biuletyn Psychologiczny*, 144(4), 343–393. <https://doi.org/10.1037/bul0000128>
- Stroebe, M., Schut, H. i Boerner, K. (2017). Przestroga dla pracowników służby zdrowia: Osoby pogrążone w żałobie są wprowadzane w błąd na poszczególnych etapach żałoby. *OMEGA — Dziennik śmierci i umierania*, 74(4), 455–473. <https://doi.org/10.1177/0030222817691870>
- Sznycer, D., Al-Shawaf, L., Bereby-Meyer, Y., Curry, O. S., De Smet, D., Ermer, E., Kim, S., Kim, S., Li, N. P., Lopez Seal, M. F., McClung, J., O, J., Ohtsubo, Y., Quillien, T., Schaub, M., Sell, A., van Leeuwen, F., Cosmides, L. i Tooby, J. (2018). Międzykulturowe niezmienności w architekturze wstydu. *Proceedings of the National Academy of Sciences*, 115 (39), 9702–9707. <https://doi.org/10.1073/pnas.1805016115>
- Sznycer, D., Tooby, J., Cosmides, L., Porat, R., Shalvi, S. i Halperin, E. (2016). Wstyd ściśle śledzi zagrożenie dewaluacją ze strony innych, nawet w różnych kulturach. *Proceedings of the National Academy of Sciences*, 113 (10), 2625–2630. <https://doi.org/10.1073/pnas.1514699113>
- Tangney, J. P., Stuewig, J. i Mashek, DJ (2007). Emocje moralne i zachowania moralne. *Roczny przegląd psychologii*, 58, 345–372. <https://doi.org/10.1146/annurev.psych.56.091103.070145>
- Taylor, GJ, Bagby, RM i Parker, JDA (1997). Zaburzenia regulacji afektu: Aleksytymia w chorobach medycznych i psychiatrycznych. Wydawnictwo Uniwersytetu Cambridge.
- Tooby, J. i Cosmides, L. (2008). Psychologia ewolucyjna emocji i ich związek z wewnętrznymi zmiennymi regulacyjnymi. W: M. Lewis, J. M. Haviland-Jones i LF Barrett (red.), *Handbook of Emotions* (wyd. 3, s. 114–137). Prasa Guilforda.
- Tracy, JL i Matsumoto, D. (2008). Spontaniczny wyraz dumy i wstydu: dowód na biologicznie wrodzone przejawy niewerbalne. *Proceedings of the National Academy of Sciences*, 105 (33), 11655–11660. <https://doi.org/10.1073/pnas.0802686105>
- Tracy, JL i Robins, RW (2007). Psychologiczna struktura dumy: opowieść o dwóch aspektach. *Aktualne kierunki nauk psychologicznych*, 16 (3), 147–150. <https://doi.org/10.1111/j.1467-8721.2007.00493.x>
- Van de Ven, N., Zeelenberg, M. i Pieters, R. (2009). Poziomowanie w górę i w dół: Doświadczenia łagodnej i złośliwej zazdrości. *Emocje*, 9(3), 419–429. <https://doi.org/10.1037/a0015669>
- Van Kleef, GA (2009). Jak emocje regulują życie społeczne: Emocje jako model informacji społecznej. *Aktualne kierunki nauk psychologicznych*, 18 (3), 184–188. <https://doi.org/10.1111/j.1467-8721.2009.01633.x>
- Van Kleef, GA i Côté, S. (2022). Społeczne skutki emocji. *Roczny przegląd psychologii*, 73, 629–658. <https://doi.org/10.1146/annurev-psych-020821-010855>
- Wanberg, CR (2012). Indywidualne doświadczenie bezrobocia. *Roczny przegląd psychologii*, 63, 369–396. <https://doi.org/10.1146/annurev-psych-120710-100500>
- Warr, P. (2007). Praca, szczęście i nieszczęście. Współpracownicy Lawrence'a Erlbauma.
- Zhang, Y., Zhao, D., Hancock, JT, Kraut, R. i Yang, D. (2026). Interakcja z towarzyszami AI i dobre samopoczucie psychiczne. *Natura Zachowanie Ludzkie*. <https://doi.org/10.1038/s41562-026-02516-2>
- Blevins, T. (2026). Zakwaterowanie działa w obie strony: badanie konwergencji językowej między ludźmi a modelami językowymi. *arXiv:2605.29278*. <https://doi.org/10.48550/arXiv.2605.29278>

Chu, MD, Wu, Y., Chen, Z., Hwang, A. H.-C. i Luceri, L. (2026). Kiedy chatboty dostosowują się do potrzeb: pod kątem czego towarzysze AI optymalizują się w rozmowach, w których występują zagrożenia. arXiv:2606.04431. <https://doi.org/10.48550/arXiv.2606.04431>

Derner, E., Kučera, D., Gulati, A., Bagheri, A. i Oliver, N. (2026). Uważaj na styl: wpływ stylu komunikacji na interakcję człowiek-Chatbot. arXiv:2602.17850. <https://doi.org/10.48550/arXiv.2602.17850>

Farach, A., Cambon, A., Tankelevitch, L., Hsueh, C. i Janssen, R. (2026). Rusztowanie współpracy człowieka i sztucznej inteligencji: eksperyment terenowy dotyczący protokołów behawioralnych i przeformułowania poznawczego. arXiv:2604.08678. <https://doi.org/10.48550/arXiv.2604.08678>

Giles, H., Coupland, J. i Coupland, N. (red.). (1991). Konteksty zakwaterowania: rozwój socjolingwistyki stosowanej. Wydawnictwo Uniwersytetu Cambridge.

Lee, H.-P. (H.), Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R. i Wilson, N. (2025). Wpływ generatywnej sztucznej inteligencji na krytyczne myślenie: samodzielnie zgłaszane zmniejszenie wysiłku poznawczego i efektów pewności siebie na podstawie ankiety przeprowadzonej wśród pracowników umysłowych. Postępowanie CHI 2025. <https://doi.org/10.1145/3706598.3713778>

Levinson, SC i Torreira, F. (2015). Harmonogram wykonywania zwrotów i jego konsekwencje dla modeli przetwarzania języka. *Granice w psychologii*, 6, 731. <https://doi.org/10.3389/fpsyg.2015.00731>

Reeves, B. i Nass, C. (1996). Równanie mediów. Wydawnictwo Uniwersytetu Cambridge.

Riedl, C., Savage, S. i Zvelebilova, J. (2026). Efekty poznawcze w zespołach wykorzystujących człowieka i sztuczną inteligencję. arXiv:2407.17489v3. <https://doi.org/10.48550/arXiv.2407.17489>

Rimé, B. (2009). Emocje wywołują społeczne dzielenie się emocjami: teoria i przegląd empiryczny. *Przegląd emocji*, 1 (1), 60–85. <https://doi.org/10.1177/1754073908097189>

Stivers, T., Enfield, N. J., Brown, P., Englert, C., Hayashi, M., Heinemann, T., Hoymann, G., Rossano, F., de Ruiter, J. P., Yoon, K.-E. i Levinson, SC (2009). Uniwersalia i różnicowanie kulturowe w odwracaniu się w rozmowie. *Proceedings of the National Academy of Sciences*, 106(26), 10587–10592. <https://doi.org/10.1073/pnas.0903616106>

Sun, Y., Han, Y. i Lv, L. (2026). „Pośpiech powoduje marnotrawstwo”: jak opóźnione odpowiedzi zwiększają chęć klientów do korzystania z chatbota w usługach turystycznych. *International Journal of Hospitality Management*, 137, 104673. <https://doi.org/10.1016/j.ijhm.2026.104673>

Székely, É., Miniota, J. i Hejná, M. (2025). Czy sztuczna inteligencja wpłynie na sposób, w jaki mówimy? Pojawiający się socjolingwistyczny wpływ głosów syntetycznych. *Postępowanie IWSDS* 2025, 357–368. <https://doi.org/10.48550/arXiv.2504.10650>

Vaccaro, M., Almaatouq, A. i Malone, T. (2024). Kiedy przydatne są kombinacje ludzi i sztucznej inteligencji: przegląd systematyczny i metaanaliza. *Natura Ludzkie zachowanie*, 8, 2293–2303. <https://doi.org/10.1038/s41562-024-02024-1>