

Przechwycony Internet

Natura ludzka, władza
algorytmiczna i
architektura sieci
bardziej podatnej na
zarządzanie



Przechwycony Internet

*Natura ludzka, władza algorytmiczna i
architektura
sieci bardziej podatnej na zarządzanie*

Axiologic Research

lipiec 2026

*Wyobraźmy sobie, że Internet nadal działa doskonale, a
jednocześnie staje się stopniowo coraz mniej wart
odwiedzania.*

HISTORIA • ZARZĄDZANIE • REKOMENDACJA • TOŻSAMOŚĆ • PROJEKTOWANIE
INSTYTUCJONALNE

Prawa autorskie © [2026] Sînică Alboaie

Wszelkie prawa zastrzeżone.

Prawa wydawnicze KDP należą do Outfinity SRL (Iași, Rumunia).

Prawa użytkowania udzielone Outfinity Sagl (Caslano, Szwajcaria).

Dostępne bezpłatnie na stronie Outfinity Venture Studio (www.outfinity.ch).

Systemy sztucznej inteligencji zostały wykorzystane jako narzędzia redakcyjne i badawcze.

Argumentacja, dobór materiału i odpowiedzialność autorska należą do Sînică Alboaie.

Nota autora:

Praca ta powstała w ramach nadrzędnego programu badawczego Outfinitism. Choć modele językowe sztucznej inteligencji zostały wykorzystane jako wsparcie w generowaniu tekstu, leżąca u podstaw filozofia, struktura tematyczna i ramy analityczne wynikają w całości z wieloletnich, konsekwentnych badań autora nad zjawiskami społecznymi i technologiami społecznymi.

Analizując podstawowe problemy dzisiejszego internetu, książka ta zarysowuje kluczowe trajektorie ewolucyjne zgodne z rozwojem AI, tworząc jeden z fundamentów tezy inwestycyjnej Outfinity Venture Studio.

Spis treści

Cała książka w dziesięciu stronach.....	5
Sieć, która nadal działa.....	5
Czego naprawdę wymagałby lepszy Internet.....	9
Rozdział 1: Przed platformami.....	16
1.1 Otwarte protokoły, pieniądze publiczne i małe społeczności.....	16
1.2 E-mail, fora, katalogi i wyszukiwanie.....	19
Rozdział 2: Platformy i ukryte konstytucje.....	23
2.1 Dlaczego platformy zwyciężyły.....	23
2.2 Przechwycenie korporacyjne, władza moderatorów i darmowa praca.....	26
Rozdział 3: Ludzki przeciwnik.....	30
3.1 Anonimowość, odhamowanie, trolling i skoordynowane nadużycia..	30
3.2 Moderacja jako rządzenie.....	33
Rozdział 4: Trafność jest konstytucją.....	37
4.1 Wyszukiwanie, strumienie treści, zaangażowanie i dryf ku idiokracji	37
4.2 Dezinformacja, komory echa i manipulacja wyborami.....	40
Rozdział 5: Syntetyczna sieć i Internet, który nadal działa.....	44
5.1 Teoria martwego Internetu, boty i generatywna obfitość.....	44
5.2 Wikipedia, open source, nauka i trwałe dobra wspólne.....	47
Rozdział 6: Poza suwerennością platform.....	51
6.1 Społeczności policentryczne i zdecentralizowane marki.....	51
6.2 Ekonomia, licencjonowanie i projektowanie odporne na przechwycenie.....	54
Rozdział 7: Osobista AI jako rekomender użytkownika.....	58
7.1 Od ukrytych profili do trafności zarządzanej przez użytkownika...	58
7.2 Prywatność, stronnictwo, pluralizm i ryzyko osobistej komory echa.....	61
Rozdział 8: Odbudowa komunikacji od warstwy protokołów.....	65
8.1 WebRTC, adresowanie podobne do e-maila, DID-y i połączenia bramkowane zaufaniem.....	65
8.2 Mniejsza powierzchnia ataku dla ludzi i agentów.....	68
Bibliografia.....	73

Cała książka w dziesięciu stronach

Sieć, która nadal działa

Wyobraźmy sobie, że Internet nadal działa doskonale, a jednocześnie staje się stopniowo coraz mniej wart odwiedzenia. Wyszukiwanie jest natychmiastowe. Wiadomości dochodzą. Wideo nigdy się nie zatrzymuje. Osobiści asystenci streszczają tysiące stron przed śniadaniem. A jednak znaczna część tego, co pojawia się na ekranie, nie została stworzona po to, by poinformować człowieka, nie została wybrana przez kogokolwiek odpowiedzialnego przed tym człowiekiem ani zaoferowana przez instytucję, którą można zakwestionować. Maszyna działa. Świat publiczny niesiony przez tę maszynę ulega rozrzedzeniu.

Ten początek zawiera całą argumentację w formie skondensowanej. Czytelnik, który zatrzyma się tutaj, powinien zrozumieć diagnozę, najmocniejsze dowody i proponowany kierunek. Reszta książki istnieje dla czytelników, którzy chcą poznać historię, zastrzeżenia i szczegóły projektowe.

Standardowa opowieść zaczyna się od niewinnego, zdecentralizowanego Internetu, a kończy na przechwyceniu przez korporacje. Jest częściowo prawdziwa i zbyt prosta. Wczesna sieć wyrosła z finansowania publicznego, badań wojskowych i uniwersyteckich, organów normalizacyjnych, infrastruktury telekomunikacyjnej oraz małych społeczności o niezwykle wysokich kompetencjach technicznych. Otwartość była osiągnięciem instytucjonalnym i inżynierskim, a nie brakiem władzy. Wczesna harmonia zależała również od selektywnego dostępu, możliwej do opanowania skali i administratorów, których autorytet był widoczny, ponieważ społeczności były małe (Clark 1988; Abbate 1999; Turner 2006).

Otwarte protokoły sprawiły, że heterogeniczne maszyny mogły współdziałać, a kopiowanie, publikowanie i komunikacja stały się nadzwyczaj tanie. Nie rozwiązały kwestii tożsamości, reputacji, odkrywania treści, spamu, moderacji, finansowania ani uprawnionego zbiorowego podejmowania decyzji. W miarę rozszerzania się uczestnictwa te odłożone problemy powróciły. E-mail zyskał filtry i reputację nadawców. Usenet i fora zyskały administratorów oraz konflikty. Katalogi zyskały redaktorów. Wyszukiwarki zyskały władzę decydowania, które spośród miliardów stron stanęły się widoczne.

Platformy zwyciężyły, ponieważ rozwiązywały rzeczywiste problemy: spójne interfejsy, hosting, wyszukiwanie, trwałe konta, dostęp mobilny, płatności, bezpieczeństwo, rekomendację i moderację. Centralizacja była użyteczna, zanim stała się konstytucyjna. Przechwycenie zaczęło się wtedy, gdy ten sam dostawca zaczął posiadać tożsamość, relacje, archiwa, ranking, przychody i prawo do zmiany każdej reguły, która nimi rządzi. Użytkownicy i moderatorzy nadal tworzyli społeczność, ale społeczność stała się aktywem w bilansie kogoś innego.

Tabela 1. Diagnoza w sześciu warstwach

Element	Znaczenie lub konsekwencja projektowa
Warstwa protokołu	Osiągnięto interoperacyjność i taną publikację; tożsamość, moderacja, finansowanie i legitymizacja pozostały nierozwiązane.
Warstwa platformy	Użyteczność, hosting, wyszukiwanie i bezpieczeństwo uległy poprawie, ale tożsamość, ranking, relacje, archiwa i przychody zostały skoncentrowane pionowo.
Warstwa ludzka	Niskie tarcie chroniło wrażliwą wypowiedź i poszerzało uczestnictwo, jednocześnie obniżając koszt nękania, oszustwa i skoordynowanej manipulacji.
Warstwa epistemiczna	Wyszukiwanie i rekomendacja rozwiązały problem niedoboru uwagi, przekształcając trafność w prywatną i często nieprzejrzystą władzę konstytucyjną.
Warstwa syntetyczna	Automatyzacja obniżyła koszty produkcji, ale osłabiła również autentyczność, proveniencję i pozycję ekonomiczną starannej pracy ludzkiej.

Element	Znaczenie lub konsekwencja projektowa
Warstwa instytucjonalna	Otwarte uczestnictwo stworzyło ogromną wartość, nie przyznając jednak niezawodnie uczestnikom trwałych praw głosu, wyjścia ani korzyści ekonomicznej.

Przechwycenie korporacyjne jest tylko jednym składnikiem tej historii. Internet zmienił również cenę ludzkiego zachowania. Pseudonimowość może chronić dysydentów, pacjentów, sygnalistów i wrażliwe mniejszości. Tania tożsamość może jednak także zmniejszać konsekwencje reputacyjne, pozwalać na szybki powrót po wykluczeniu i obniżać koszt nękania albo symulowanego konsensusu. Efekt odhamowania online nie zmienia każdej anonimowej osoby w potwora, ale zmienia bodźce wokół impulsywnego działania (Suler 2004). Dowody eksperymentalne sugerują ponadto, że trolling jest częściowo sytuacyjny: negatywny nastrój, wrogie przykłady i lokalne normy mogą sprawić, że zwykli uczestnicy będą naśladować nadużycia (Cheng et al. 2017).

Równie ważna jest pętla amplifikacji. Prowokacja wywołuje reakcję; reakcja jest rejestrowana jako zaangażowanie; zaangażowanie daje dystrybucję; powtarzana ekspozycja zmienia normy; twórcy uczą się, że pogarda, pewność, upokorzenie i konflikt frakcyjny niosą się dalej niż zastrzeżenia. Badania nad językiem moralno-emocjonalnym i wrogością wobec grup obcych wspierają ten mechanizm (Brady et al. 2017; Rathje, Van Bavel, and van der Linden 2021). Wynik bywa przedstawiany jako ujawniona preferencja użytkownika, chociaż system pomógł wytworzyć preferencję, którą mierzył.

To jest możliwe do obrony znaczenie metafory internetowej „Idiocracy”. Użytkownicy nie stali się nagle mniej inteligentni. Środowisko selekcionuje materiał zdolny wygenerować tani, szybki sygnał. Fałszywą nowość można napisać w kilka sekund; weryfikacja może wymagać godzin. Dramatyczne oskarżenie pasuje do strumienia treści lepiej niż ostrożna ocena niepewności. Optymalizacja zaangażowania subsydiuje zatem natychmiastową pewność i opodatkowuje powolną pracę epistemiczną. Problemem jest negatywna selekcja przeciw złożoności, a nie biologiczny spadek inteligencji.

Moderacji nie można po prostu usunąć. Nieinterwencja przekazuje kontrolę uporczywym agresorom, zorganizowanym frakcjom, automatycznym rojom albo właścicielom, którzy interweniują dopiero wtedy, gdy ryzyko prawne i handlowe staje się nie do zniesienia. Rzeczywisty wybór dotyczy zarządzania widocznego, ograniczonego, poddającego się przeglądowi i legitymizowanego oraz zarządzania improwizowanego, nieprzejrzystego lub przechwyconego (Gillespie 2018; Suzor 2019). Moderatorzy-wolontariusze wykonują niezbędną pracę obywatelską, często bez wynagrodzenia i ochrony (Matias 2019), ale mogą też przekształcić opiekę w status albo rządu ideologiczne. Ich lokalną władzę należy odróżniać od strukturalnej kontroli firmy platformowej nad bazami danych, kontami, monetyzacją i zmianą konstytucyjną.

Wikipedia i Reddit pokazują, że wynik nie jest z góry przesądzony. Wikipedia dowodzi, że globalne dobro wspólne wiedzy może działać bez reklamy behawioralnej, ponieważ rewizje, źródła, dyskusje i odwrócenia zmian są możliwe do inspekcji. Pokazuje również, jak narzędzia antywandalistyczne, złożone normy i nierówności wśród kontrybutorów mogą skostnieć udaną instytucję (Halfaker et al. 2013; Wagner et al. 2016). Reddit przyznaje społecznościom lokalne stanowienie reguł na infrastrukturze korporacyjnej. Badania sugerują, że silne sankcje mogą ograniczać mowę nienawiści, a nie tylko ją przesuwać, zaś uzasadnienia i odwołania poprawiają legitymizację proceduralną (Chandrasekharan et al. 2017; Jhaver, Bruckman, and Gilbert 2019). Instytucje znaczą więcej niż slogany o otwartości lub kontroli.

Manipulacja polityczna wymaga tej samej dyscypliny. Fałszywe informacje mogą w niektórych sieciach rozchodzić się dalej niż prawdziwe, boty mogą wzmacniać źródła o niskiej wiarygodności, a skoordynowane operacje wpływu są rzeczywiste (Vosoughi, Roy, and Aral 2018; Shao et al. 2018). Jednak operacja, ekspozycja, perswazja, skutki dla frekwencji, zmiana agendy i wynik wyborczy to różne twierdzenia. Dochodzenie w sprawie rosyjskiej Internet Research Agency udokumentowało celową kampanię podczas wyborów w Stanach Zjednoczonych w 2016 roku; nie wskazało możliwości

obrony liczby przekonwertowanych głosów. Komory echa również istnieją nierównomiernie, a wymuszona ekspozycja na wrogie poglądy przeciwne może nasilać, a nie zmniejszać polaryzację (Bail et al. 2018; Cinelli et al. 2021).

Najsilniejsze wersje teorii martwego Internetu twierdzą, że większość aktywności online jest już sztuczna i centralnie skoordynowana. Dowody nie wspierają takiego totalnego spisku. Wiarygodne jest jej słabsze ostrzeżenie. Ruch automatyczny jest znaczący; systemy generatywne mogą zalewać wyszukiwarki i strumienie społeczne wiarygodnie brzmiącym materiałem zoptymalizowanym pod ranking; agenci coraz częściej streszczają źródła, których użytkownicy nigdy nie odwiedzają; rekurencyjne trenowanie na danych syntetycznych może degradować modele, gdy znikają pierwotne dane ludzkie (Shumailov et al. 2024). Internet nie jest martwy, ale autentyczność i ludzka czytelność stają się zasobami rzadkimi.

Równie ważne są kontrdowody. Oprogramowanie open-source, Wikipedia, OpenStreetMap, preprinty naukowe, społeczności pacjentów, mapowanie humanitarne i fora specjalistyczne wytworzyły ogromną wartość publiczną. Wniosek nie brzmi, że otwartość zawiodła. Brzmi on tak: instytucje tworzące wartość są często oddzielone od instytucji kontrolujących powstałe aktywa. Sukcesy Internetu wynikały z otwartych fundamentów technicznych połączonych z normami, rolami, historiami i mechanizmami naprawy. Następny projekt musi zachować tę zdolność, korygując zarazem jej słabości konstytucyjne.


Czego naprawę wymagałby lepszy Internet

Alternatywą nie jest ani powrót do małych forów, ani uniwersalny blockchain. Jest nią system policentryczny: otwarte protokoły pod spodem; społeczności z realnymi konstytucjami nad nimi; kilku konkurujących dostawców usług wokół nich; oraz prawa pozwalające członkom zmieniać dostawców bez porzucania tożsamości, relacji, dowodów reputacji ani archiwów. Celem nie jest

eliminacja władzy. Celem jest uczynienie władzy widoczną, podzieloną, tymczasową i zaskarżalną.

Społeczność wymaga czegoś więcej niż pokoju rozmów i regulaminu usługi. Potrzebuje określonego celu, granic członkostwa, znanych kompetencji, kwalifikowanych moderatorów, sankcji eskalujących proporcjonalnie, uzasadnień dla decyzji o znaczących skutkach, ścieżki odwoławczej, reguł konfliktu interesów oraz finansowania infrastruktury i trudnej pracy. Prace Ostrom nad trwałymi dobrami wspólnymi pozostają istotne, ponieważ odrzucają zarówno naiwną prywatyzację, jak i naiwną otwartość: skuteczne społeczności dopasowują reguły do kontekstu, pozwalają dotkniętym członkom uczestniczyć w ich zmianie, monitorują zachowanie, stosują stopniowane sankcje, rozwiązują spory i działają poprzez zagnieżdżone poziomy zarządzania (Ostrom 1990).

Zdecentralizowana marka może zapewnić brakującą warstwę instytucjonalną. Marka nie jest jedynie logo; jest publiczną obietnicą dotyczącą jakości, kompatybilności, postępowania i odpowiedzialności. W konwencjonalnej platformie właścicielem tej obietnicy jest jedna firma. W czysto otwartym projekcie artefakt może być forkowalny, podczas gdy reputacja i koordynacja ekonomiczna pozostają kruche. Zdecentralizowana marka umieszcza nazwę, standardy, skarbiec i proces certyfikacji pod konstytucją, której żaden założyciel, inwestor, grupa moderatorów ani dostawca infrastruktury nie może zmienić samodzielnie.



Rysunek 1. Instytucjonalny łuk Internetu: od otwartych protokołów, przez skoncentrowaną uwagę, ku sieciom podatnym na zarządzanie.

Instrumenty muszą pozostać rozdzielone. Licencja na oprogramowanie lub treść reguluje kopiowanie i modyfikację. Licencja marki reguluje użycie wspólnej tożsamości. Konstytucja przydziela uprawnienia decyzyjne, audytowe, zmian, sytuacji nadzwyczajnych i odwołań. Umowa kontrybucyjna uznaje pracę, utrzymanie i kapitał. Umowy usługowe ograniczają hosting, wyszukiwanie, rekomendację i użycie danych. Ani token, ani licencja open-source nie mogą wykonywać wszystkich tych zadań.

Decentralizację trzeba testować w praktyce. Czy członkowie mogą eksportować relacje i archiwa, a nie tylko pobrać plik? Czy społeczność może zmienić hosting bez zniknięcia? Czy odwołanie może uchylić decyzję moderatora? Czy operator może zostać zastąpiony bez naruszenia tożsamości? Czy kontrybutorzy współdzielą korzyści ekonomiczne? Czy jakkolwiek dostawca może jednostronnie przededefiniować dostęp? Repozytorium albo rozproszony rejestr nie są decentralizacją, jeśli instytucja społeczna pozostaje uwięziona.

Rekomendacja wymaga podobnego odwrócenia. Dziś platformy budują ukryte profile i używają mieszanych celów - retencji, reklamy, bezpieczeństwa, priorytetów handlowych i strategii - aby decydować,

co użytkownicy zauważą. Nawet wyrafinowany ranking traktuje model użytkownika jako aktywo platformy. Osobista AI mogłaby zamiast tego utrzymywać prywatną, poddającą się rewizji reprezentację zainteresowań, zobowiązań, uprzedzeń i ograniczeń. Mogłaby zbierać kandydatów z wielu źródeł, stosować jawne polityki, wyjaśniać kompromisy, pamiętać korekty, preferować dowody pierwotne, redukować oburzenie, wprowadzać wiarygodną niezgodę albo odrzucać nieujawniony sponsoring. Najnowsze badania opisują tę zmianę jako ruch od ukrytych profili ku personalizacji podatnej na zarządzanie (Liu et al. 2026).

Ważna zmiana jest konstytucyjna, nie jedynie predykcyjna. Platformy już przewidują gust. Nowa możliwość polega na tym, że reprezentacja użytkownika staje się możliwa do inspekcji, przenośna i odpowiedzialna przed użytkownikiem. Badania nad systemami rekomendacyjnymi od dawna pokazują, że doświadczenie zależy nie tylko od dokładności, lecz także od kontroli, różnorodności, prywatności, wysiłku i wyjaśnienia (Cramer et al. 2008; Knijnenburg et al. 2012; Helberger, Karppinen, and D'Acunto 2018). Agent powinien ujawniać alternatywne rankingi i kontrdowody, zamiast po cichu stawiać się bardziej intymną komorą echa.

Taki agent tworzy również ryzyka. Może schlebiać chwilowym impulsom, zachowywać przestarzałe preferencje, ujawniać prywatną pamięć, zależeć od dostawcy chmurowego albo zostać zmanipulowany przez prompt injection i zatrute źródła. Dlatego jego cele, niepewność, relacje handlowe, ścieżka aktualizacji i delegowane uprawnienia muszą być widoczne. Preferencje powinny być możliwe do rewizji i czasem wygasać. Kilka polityk rankingowych powinno dać się porównać. Lokalne lub poufne przetwarzanie, proweniencja, limity zdolności i audytowalne dzienniki działań nie są opcjonalnymi szczegółami; są zabezpieczeniami konstytucyjnymi.

Drugie odwrócenie może nastąpić poniżej warstwy platform. Obecny Internet wystawia usługi na globalną przestrzeń adresową, a następnie poświęca ogromny wysiłek na odrzucanie niechcianego ruchu. E-mail przyjmuje próby doręczenia od obcych. Usługi publiczne bronią się przed skanowaniem, spamem, atakami na poświadczenia, scrapowaniem i odmową usługi. Otwartość pozostaje

cenna, ale globalna receptywność nie powinna być domyślna dla każdej usługi osobistej i każdego agenta AI.

Przyszły system mógłby zachować znajome interfejsy - adresy, skrzynki odbiorcze, kontakty, grupy, dokumenty współdzielone i asystentów - zmieniając jednocześnie granicę zaufania. Adres publiczny nie musi ujawniać trwałego osobistego punktu końcowego. Pierwszy kontakt mógłby przechodzić przez wąską usługę wprowadzenia. Udań wprowadzenie mogłoby wydać odwoływalną zdolność określającą, kto może sygnalizować, wysyłać, wywoływać agenta albo otworzyć kanał. Następnie ludzie i agenci mogliby komunikować się przez szyfrowane sesje bezpośrednie lub przekazywane, korzystając z kanałów danych WebRTC albo pokrewnych transportów.

WebRTC jest tylko jednym składnikiem. Dostarcza interfejsy API i protokoły dla interaktywnych mediów i danych, z łącznością negocjowaną przez ICE i często wspieraną przez przełączniki (IETF 2018; IETF 2021a; W3C 2025a). Nie definiuje sygnalizacji, doręczania offline, archiwów, tożsamości społecznej ani zaufania. Czytelny adres podobny do e-maila może pozostać użyteczny, podczas gdy DID albo równoważny identyfikator zapewnia przenośną kontrolę kryptograficzną, a Verifiable Credentials zapewniają selektywne deklaracje (W3C 2022; W3C 2025b; W3C 2026). Technologie te dowodzą kontroli albo oświadczeń wystawcy, nie uczciwości. Zaufanie nadal pochodzi z relacji, instytucji, rekomendacji, historii i kontekstu.

Powstała sieć byłaby domyślnie bramkowana zaufaniem, a nie globalnie receptywna. Nieznani aktorzy mogliby wymagać tokena wprowadzenia, polecenia, kaucji albo odpowiedniego poświadczenia. Identyfikatory parowe mogłyby ograniczać korelację między relacjami. Agenci mogliby negocjować limity szybkości, akceptowane formaty, poufność i automatyzację przed rozpoczęciem sesji. Użytkownik mógłby odwołać jedną relację bez zastępowania globalnej tożsamości. Powierzchnia wystawiona na atak zmniejszyłaby się, ponieważ większość usług osobistych nigdy nie przyjmowałaby arbitralnego niezamówionego ruchu.

Tabela 2. Inny zestaw ustawień domyślnych

Element	Znaczenie lub konsekwencja projektowa
Ukryty profil platformowy	Model osobistej AI zarządzany przez użytkownika, który można kontrolować, korygować, ograniczać, eksportować lub usunąć.
Globalnie wystawiona skrzynka odbiorcza	Wprowadzenia bramkowane zaufaniem, kontakt ograniczony zdolnością i kanały specyficzne dla relacji.
Jeden nieprzejrzysty system rankingowy	Pluralistyczni, możliwi do inspekcji dostawcy rankingów wybierani przez użytkowników i społeczności do zadeklarowanych celów.
Spółeczność korporacyjna	Spółeczności policentryczne działające pod wspólną zdecentralizowaną marką i zaskarżalną konstytucją.
Niewidzialne darmowe utrzymanie	Jawne finansowanie moderacji, bezpieczeństwa, infrastruktury, naprawy i długoterminowej opieki.
Nominalny eksport danych	Przenośna tożsamość, relacje, dowody reputacji, archiwa i praktyczna ciągłość usługi.
Autentyczność na wycucie	Podpisana proveniencja, odpowiedzialny sponsoring i jasne oznaczanie automatycznego uczestnictwa.

Serwery pozostałyby. WebRTC często potrzebuje infrastruktury sygnalizacyjnej i przekaźnikowej; komunikacja asynchroniczna potrzebuje usług store-and-forward; bezpieczne grupy potrzebują protokołów takich jak Messaging Layer Security (IETF 2023; IETF 2025). Dostawcy nadal sprzedawaliby przechowywanie, dostępność, odkrywanie, kopie zapasowe, obliczenia i reakcję na nadużycia. Różnica polega na tym, że żaden dostawca nie musiałby posiadać tożsamości, relacji, rekomendacji i archiwów jako jednego niepodzielnego pakietu.

Osobiści agenci działali by jako lokalne kancelarie pocztowe, rekomendery, mediatorzy bezpieczeństwa i reprezentanci. Mogliby filtrować wprowadzenia, weryfikować poświadczenia, wybierać przekaźniki, streszczać wiadomości, egzekwować politykę prywatności i śledzić delegowane uprawnienia. Ponieważ ta rola jest potężna, agent musi być audytowalny i wymienialny. Jego model,

pamięć, uprawnienia i bodźce handlowe nie mogą stać się kolejną ukrytą konstytucją.

Najbardziej realistyczna przyszłość ma topologię mieszaną. Niektóre społeczności pozostaną scentralizowane, ponieważ jasna własność lub odpowiedzialność służy ich celowi. Inne będą federacyjne. Jeszcze inne będą współdzielić standardy i reputację przez zdecentralizowane marki, korzystając z niezależnych operatorów. Pluralizm nie jest tymczasową wadą. Jest obroną przed nowym uniwersalnym suwerenem.

Ostateczny test jest prosty. Żywy Internet powinien pomagać ludziom tworzyć społeczności, wytwarzać trwałe dobra publiczne, odkrywać zaskakujące informacje i korzystać z inteligentnej pomocy bez oddawania tożsamości i relacji temu, kto posiada dominujący interfejs. Powinien czynić nadużycia kosztownymi, nie czyniąc sprzeciwu niemożliwym; dopuszczać moderację bez niepodlegających przeglądowi moderatorów; nagradzać założycieli i operatorów bez przyznawania władzy dziedzicznej; oraz pozwalać rekomendacji pomagać człowiekowi myśleć, zamiast po cichu definiować, co wolno mu zobaczyć.

Natura ludzka nie zostanie usunięta z sieci. Ciekawość, hojność, próżność, trybalizm, odwaga, okrucieństwo i troska pojawiają się w każdej architekturze. Postęp oznacza budowanie instytucji, w których lepsze zdolności łatwiej koordynować, gorsze zdolności trudniej uzbroić, a tymczasowa użyteczność nie staje się trwałą własnością świata społecznego.

***Nota o dowodach.** Twierdzenia są wspierane przede wszystkim przez badania recenzowane, książki akademickie, standardy i raporty instytucjonalne. Propozycje techniczne w rozdziałach 7 i 8 przedstawiono jako kierunki projektowe zbudowane z dojrzałych komponentów, a nie jako twierdzenia, że problem integracji został już rozwiązany.*

Rozdział 1: Przed platformami

Wczesny Internet bywa pamiętany jako utracona republika równych. Był ciekawszy niż to. Otwarta architektura wyłoniła się z instytucji, wspólnot eksperckich i świadomych wyborów inżynierskich. Jej sukces stworzył wolności, których jej projekt społeczny nie był przygotowany zarządzać.


1.1 Otwarte protokoły, pieniądze publiczne i małe społeczności

ARPANET i Internet nie były spontanicznymi produktami rynku ani kontrkultury. Wyłoniły się z publicznych programów badawczych, uniwersytetów, wykonawców, wspólnot normalizacyjnych i inżynierów, którzy potrzebowali współdziałania heterogenicznych sieci. Komutacja pakietów, protokoły hostów, a później TCP/IP były rozwiązaniami problemów technicznych i organizacyjnych. System musiał przetrwać różnorodność sprzętu, granice administracyjne i zmieniające się zastosowania. Powstała architektura rozdzielała funkcje ku brzegom i unikała wymagania, aby jedna sieć rozumiała każde przyszłe użycie (Clark 1988; Leiner et al. 1997).

Ta historia techniczna ma znaczenie, ponieważ późniejsze interpretacje polityczne często traktują decentralizację jako pierwotny moralny cel sieci. Odporność, interoperacyjność i rozwój aplikacji bez pozwolenia z pewnością miały konsekwencje polityczne, ale nie stanowiły kompletnej teorii politycznej. Tradycja end-to-end ograniczała to, o czym powinien decydować rdzeń sieci; nie określała, jak społeczności powinny radzić sobie z nękaniami, jak należy płacić kontrybutorom ani jak publiczny system rankingowy powinien uzasadniać swoje wybory (Saltzer, Reed, and Clark 1984).

Kulturę wczesnej sieci kształtował selektywny dostęp. Uniwersytety, laboratoria badawcze i technicznie wyrafinowani amatorzy dostarczali wielu uczestników. Wspólne normy zawodowe i powtarzalna interakcja czyniły reputację znaczącą. Nieformalność działała, ponieważ społeczności były wystarczająco małe, by

pamiętać historię, i ponieważ samo uczestnictwo wymagało wysiłku. Nie eliminowało to hierarchii. Administratorzy kontrolowali maszyny, listy mailingowe i konta. Ekspertyza dawała status. Ludzie, którzy nie podzielali dominujących założeń technicznych i kulturowych, mogli być ignorowani lub wykluczani.



Rysunek 2. Otwarte protokoły zmniejszyły zależność techniczną, pozostawiając rosnący dług w zakresie tożsamości, odkrywania, moderacji i finansowania.

Wolność kojarzona z wczesnym Internetem była więc zarówno realna, jak i subsydiowana. Pieniądze publiczne wspierały infrastrukturę. Uniwersytety absorbowały koszty. Wolontariusze utrzymywali oprogramowanie i dokumentację. Pracodawcy pozwalali wykwalifikowanym pracownikom wносить wkład. Sieć zdawała się unosić ponad zwykłą ekonomią, ponieważ znaczna część jej gospodarki była ukryta w instytucjach, które miały powody inne niż bezpośredni zysk, by ją wspierać. Gdy dostęp się rozszerzył, koszt prowadzenia systemów społecznych stał się trudniejszy do ukrycia.

Udostępnienie oprogramowania World Wide Web przez CERN w 1993 roku unaocznilo siłę instytucjonalnej hojności. Pozwalając na użycie wolne od opłat licencyjnych, CERN umożliwił pojawienie się konkurujących przeglądarek, serwerów i stron bez pytania centralnego właściciela o zgodę (CERN 1993). Decyzja ta nie przesądziła o niekomercyjnej sieci Web. Uczyniła możliwą innowację komercyjną i niekomercyjną na tej samej bazie. Otwartość stworzyła pole, na którym mogły rosnąć zarówno dobra wspólne, jak i korporacje.

Pierwsza sprzeczność była już obecna. Protokół może być otwarty, podczas gdy społeczności, które go używają, są zamknięte. Usługa może być zdecentralizowana, podczas gdy dostęp do ekspertyzy, sprzętu i czasu pozostaje nierówny. Standard publiczny może umożliwić koncentrację prywatną, jeśli aktywa komplementarne, takie jak odkrywanie, tożsamość i dystrybucja, stają się rzadkie. Historia Internetu nie jest upadkiem z czystości technicznej. Jest przemieszczaniem się władzy z jednej warstwy do drugiej, gdy kolejne wąskie gardła zostają rozwiązane.

To wyjaśnia, dlaczego nostalgia jest słabym przewodnikiem. Odtworzenie starych protokołów albo chronologicznych forów nie odtworzyłoby warunków społecznych, w których wydawały się możliwe do opanowania. Miliardy użytkowników, zautomatyzowani przeciwnicy, bodźce handlowe i systemy generatywne zmieniają skalę problemu. To, co pozostaje wartościowe z wczesnego Internetu, nie jest jego niewinnością, lecz jego osiągnięciem instytucjonalnym: wiele sieci i implementacji mogło współpracować, ponieważ standardy były otwarte, a władza w rdzeniu była ograniczona.

Sama kultura standardów zawierała użyteczną wskazówkę instytucjonalną. Requests for Comments były publicznymi argumentami technicznymi, a nie dekretemi, zaś idea rough consensus and running code sprawiała, że autorytet zależał częściowo od wyników możliwych do zaimplementowania. Proces nigdy nie był doskonale demokratyczny: uczestnictwo wymagało ekspertyzy, czasu i dostępu, podczas gdy kluczowe zasoby, takie jak nazwy i adresy, nadal wymagały koordynacji. Pokazał jednak, że wspólne reguły mogą powstawać bez jednego dostawcy posiadającego każdą implementację. Legitymizacja pochodziła z otwartej specyfikacji, konkurujących implementacji i możliwości technicznego zakwestionowania.

Nawet rzekomo zdecentralizowany rdzeń zawierał funkcje skoncentrowane. Domain Name System wprowadził delegację hierarchiczną; przydział adresów i rejestry protokołów wymagały opieki; duzi dostawcy szkieletowi zajmowali strategiczne pozycje. Decentralizacja oznaczała, że żadna pojedyncza koncentracja niekoniecznie kontrolowała każdą warstwę, a nie że koncentracja

zniknęła. To warstwowe ujęcie jest niezbędne dla współczesnej reformy. System może tolerować centralny rejestr, jeśli tożsamości, dane, klienci i społeczności mogą go obchodzić. Staje się niebezpieczny, gdy kontrola jednej warstwy zostaje wykorzystana do przejęcia własności wszystkich pozostałych.

Niedokończonym zadaniem jest rozszerzenie tej zasady ku górze. Tożsamość nie powinna być nierozzerwalna z jedną aplikacją. Reputacja nie powinna być uwięziona w jednej bazie danych. Społeczności powinny móc wynajmować infrastrukturę bez przekazywania suwerenności. Rekomendacja powinna być wymienialna. Moderacja powinna działać przez zadeklarowane kompetencje i odwołanie. Wcześni inżynierowie stworzyli otwarte podłoże komunikacyjne. Następne pokolenie musi stworzyć otwarte podłoże instytucjonalne.

1.2 E-mail, fora, katalogi i wyszukiwanie

E-mail jest najjaśniejszym dowodem, że federacja może przetrwać w skali globalnej. Człowiek może wysłać wiadomość ponad granicami organizacji bez przynależności obu stron do tego samego dostawcy. Domeny pozwalają na administrację lokalną, podczas gdy wspólne protokoły zachowują interoperacyjność. W praktyce model ten jest mniej elegancki niż na diagramach, ale przez dekady opierał się pełnemu przejściu przez jedną firmę.

Jego słabość jest równie pouczająca. E-mail pozwala na niezamówiony kontakt przy skrajnie niskim koszcie krańcowym. Nadawca przerzuca koszty filtrowania, przechowywania, uwagi i bezpieczeństwa na odbiorców i dostawców. Badanie Spamalytics wykazało, że kampania mogła pozostawać ekonomicznie opłacalna mimo nadzwyczaj niskiego współczynnika konwersji, ponieważ miliony wiadomości były tanie do wysłania przez przejęte maszyny (Kanich et al. 2009). Systemy uwierzytelniania i reputacji ograniczyły nadużycia, ale skoncentrowały też praktyczną władzę u dużych dostawców zdolnych obsługiwać zaawansowane filtry i wpływać na dostarczalność.

Usenet i fora internetowe tworzyły bogatsze kultury lokalne. Ich organizacja wokół tematów zachowywała długie rozmowy i pozwalała reputacji narastać w ramach domeny. Dobre forum techniczne mogło stać się żywym archiwum użyteczniejszym niż jakikolwiek formalny podręcznik. Jednak większość forów była prywatnymi rządami. Właściciele kontrolowali bazę danych i domenę. Moderatorzy interpretowali reguły, często bez odwołania. Społeczności mogły być hojne i eksperckie, pozostając konstytucyjnie kruche.

Katalogi, takie jak wczesny katalog Yahoo i Open Directory Project, czyniły selekcję widoczną. Redaktorzy-ludzie klasyfikowali strony i pośrednio ręczyli za ich trafność. Model mógł wyrażać osąd i kontekst, ale nie skalował się wraz z siecią Web. Redaktorzy stawali się wąskimi gardłami, kategorie twardniały, a decyzje mogły zostać przechwycone przez małe grupy. Mimo to użytkownik widział, że katalog reprezentuje strukturę redakcyjną, a nie obiektywną mapę rzeczywistości.

Wyszukiwarki rozwiązały skalę poprzez automatyzację selekcji. Analiza linków i duże indeksy uczyniły sieć Web użyteczną, ale ranking uzyskał rolę polityczną. Wyszukiwarka nie tylko odzyskuje to, co istnieje. Przydziela widoczność, która często decyduje, czy źródło ma praktyczne istnienie dla większości użytkowników. Introna i Nissenbaum wcześniej argumentowali, że wyszukiwarki nieuchronnie faworyzują pewne strony i wartości, nawet gdy ich wybory są przedstawiane jako techniczna trafność (Introna and Nissenbaum 2000).

Tabela 3. Co każda wczesna warstwa rozwiązała i pozostawiła nierozwiązane

Element	Znaczenie lub konsekwencja projektowa
TCP/IP i projekt end-to-end	Połączyły heterogeniczne sieci i ograniczyły zależność od właścicieli pośrednich; nie stworzyły tożsamości społecznej ani zarządzania społecznościami.
E-mail	Stworzył globalne wiadomości federacyjne; wystawił odbiorców na spam, spoofing, koncentrację reputacji i nadużycia przy znikomym koszcie wysłania.

Element	Znaczenie lub konsekwencja projektowa
Usenet i fora	Umożliwiły trwałe społeczności tematyczne; opierały się na kruchych normach lokalnych, właścicielach, administratorach i społecznie kosztownym rozwiązywaniu konfliktów.
Katalogi	Uczyniły ludzki osąd redakcyjny widocznym; nie skalowały się i tworzyły władzę wokół włączenia, kategorii i frakcji redaktorów.
Wyszukiwarki	Skalowały odkrywanie w otwartej sieci Web; uczyniły ranking nieprzejrzystym pośrednikiem między publikacją a praktyczną widocznością.

Przejsie od katalogu do wyszukiwania zmieniło wygląd władzy. Kategorie ludzkie wyglądały subiektywnie. Wyniki algorytmiczne wyglądały na odkryte. Jednak każdy system rankingowy wybiera sygnały, radzi sobie z manipulacją, definiuje świeżość i równoważy cele handlowe oraz publiczne. Wyszukiwanie stworzyło również branżę antagonistyczną. Wydawcy optymalizowali pod system rankingowy; system rankingowy dostosowywał się do optymalizacji; treść coraz częściej zwracała się najpierw do klasyfikatora, a dopiero potem do czytelnika.

E-mail, fora, katalogi i wyszukiwanie zawierają więc całą przyszłość w miniaturze. Federacja zachowuje wyjście, ale przyciąga nadużycia. Społeczności lokalne wytwarzają wiedzę, ale mogą stać się prywatnymi oligarchiami. Kuratorstwo ludzkie dostarcza kontekstu, ale nie może objąć wszystkiego. Ranking algorytmiczny skaluje się, ale ukrywa osąd. Żaden z tych systemów nie jest porażką. Każdy ujawnia inny kompromis instytucjonalny.

Rozpad społeczny kojarzony z „Eternal September” ujawnił problem skalowania przed nowoczesnymi platformami. Nowe kohorty zawsze wchodziły do Usenetu i uczyły się jego norm, ale dostęp komercyjny przekształcił okresowy napływ w trwałe masowe przybywanie. Dawni uczestnicy często obwiniali nowicjuszy, czasem z elitarną pogardą, lecz głębszy problem był instytucjonalny: onboarding, moderacja i pamięć nie zostały zaprojektowane dla ciągłego wzrostu. Normy, które można przekazać wyłącznie przez cierpliwy mentoring, są wrażliwe, gdy przybysze przewyższają liczebnie mentorów.

Open Directory Project później próbował połączyć ludzki osąd redakcyjny z rozproszoną pracą wolontariuszy. Udowodnił, że tysiące redaktorów może utrzymywać publiczny katalog, ale również że własność kategorii, powolny przegląd i nierówne standardy mogą stać się wąskimi gardłami. Wyszukiwarki wyparły katalogi nie dlatego, że ludzki osąd był bezużyteczny, lecz dlatego, że automatyczne indeksowanie mogło objąć materiał o rzędy wielkości większy. Transakcją była szerokość pokrycia w zamian za możliwość inspekcji.

E-mail stał się również operacyjnie bardziej scentralizowany, niż sugerują jego protokoły. Niezależne serwery pozostają możliwe, lecz dostarczalność zależy od reputacji, uwierzytelniania, reakcji na nadużycia i relacji z głównymi dostawcami. Mały operator może spełniać standardy, a mimo to odkryć, że wiadomości są filtrowane. To powracający wzorzec: otwarty protokół na warstwie formalnej, skoncentrowane zaufanie na warstwie operacyjnej. Lekarstwem nie jest zaprzeczanie użyteczności profesjonalnego filtrowania, lecz uczynienie jego reguł, przenośności i odwołań mniej zależnymi od kilku firm.

Era platform nie zastąpiła tych systemów dlatego, że miała wyższą filozofię. Połączyła ich użyteczne funkcje za jednym kontem i jednym interfejsem. Wiadomości, tożsamość, odkrywanie, reputacja, dystrybucja i monetyzacja stały się łatwiejsze, ponieważ jeden operator mógł je koordynować. Kosztem tej wygody było to, że operator uzyskał również władzę jednoczesnego przededefiniowania każdej funkcji.

Rozdział 2: Platformy i ukryte konstytucje

Platformy zwyciężyły, czyniąc Internet zrozumiałym. Stały się niebezpieczne, gdy integracja zmieniła się w suwerenność, a społeczności odkryły, że wygodę kupiono za nieprzenośną tożsamość, niewidzialne reguły i zależność od prywatnego rankingu.

2.1 Dlaczego platformy zwyciężyły


Otwarta sieć Web wymagała od użytkowników samodzielnego złożenia własnego środowiska. Potrzebowali hostingu, tożsamości, kontaktów, narzędzi publikowania, odkrywania, ochrony przed spamem i czasem systemów płatności. Platformy zintegrowały te funkcje i usunęły tarcie techniczne. Ich sukces nie dowodził, że użytkownicy preferowali dominację. Był dowodem, że koordynacja ma wartość.

Efekty sieciowe wzmocniły ten rezultat. Usługa komunikacyjna staje się użyteczniejsza, gdy kontakty są już obecne. Rynek przyciąga kupujących, ponieważ są sprzedający, i sprzedających, ponieważ są kupujący. Rekomender poprawia się, gdy obserwuje więcej zachowań. System moderacji korzysta ze wspólnej wiedzy o nadużyciach. Efekty te sprawiają, że zintegrowane systemy trudno zakwestionować, nawet gdy konkurenci oferują lepsze pojedyncze funkcje.

Komputery mobilne nasiliły centralizację. Aplikacje dystrybuowane przez kontrolowane sklepy mogły łączyć tożsamość, powiadomienia, przechwytywanie mediów, płatności i lokalizację. Graf społeczny przeniósł się z hiperłączy i książek adresowych do własnościowych baz danych. Użytkownik nie tyle nawigował między niezależnymi stronami, ile pozostawał wewnątrz strumienia treści, gdzie źródła zewnętrzne renderowano jako obiekty treści.

Platformizacja zmieniła także samą sieć Web. Strony osadzały przyciski społecznościowe, analitykę, reklamę, uwierzytelnianie i

usługi dostarczania treści dostarczane przez niewielką liczbę firm. Helmond opisuje to jako uczynienie danych webowych „gotowymi na platformę”: otwarta sieć Web stała się powierzchnią, przez którą platformy mogły rozszerzać swoje struktury danych i modele biznesowe (Helmond 2015). Granica między stroną internetową a platformą stała się przepuszczalna w jednym kierunku. Niezależne strony zależały od platform bardziej niż platformy od jakiejkolwiek pojedynczej strony.



Rysunek 3. Jak uczestnictwo publiczne staje się prywatnym aktywem platformy, gdy tożsamość, relacje, dane i ranking są zintegrowane pionowo.

Zintegrowana platforma rozwiązała odkrywanie poprzez posiadanie relacji z odbiorcami. Rozwiązała tożsamość przez wydawanie kont. Rozwiązała moderację przez definiowanie standardów społeczności. Rozwiązała finansowanie przez reklamę, subskrypcje, opłaty albo usługi oparte na danych. Każde rozwiązanie było operacyjnie racjonalne. Problem konstytucyjny pojawił się, ponieważ ta sama firma definiowała reguły, interpretowała je, kontrolowała dowody, obsługiwała mechanizm odwoławczy i posiadała aktywa rezydualne.

Regulaminy usług dawały prawne pozwolenie na jednostronną zmianę, ale formalna zgoda nie tworzyła materialnej legitymizacji. Ludzie inwestowali lata w społeczności, firmy, publiczności i reputacje, które mogły zostać zmienione decyzjami produktowymi. Deweloperzy budowali na interfejsach, których cena mogła zostać zmieniona. Moderatorzy utrzymywali przestrzenie, których danych

nie posiadali. Twórcy dostosowywali się do systemów rankingowych, które mogły zmienić się bez wyjaśnienia. Platforma zachowywała się jednocześnie jak właściciel gruntu, ustawodawca, policja, sąd, bank centralny i dystrybutor mediów.

Nie należy ignorować wewnętrznej złożoności korporacji. Zespoły bezpieczeństwa, moderatorzy, inżynierowie, badacze, kadra kierownicza, inwestorzy i reklamodawcy mogą mieć sprzeczne cele. Szkoda nie wymaga jednej złośliwej intencji. Struktury zarządzania mogą wielokrotnie uprzywilejowywać wzrost, obronność prawną i przychody, nawet gdy wielu pracowników rozpoznaje koszt społeczny. „Platformę” najlepiej więc rozumieć jako instytucję o dominującej strukturze celów, a nie jako jednolity umysł.

Reklama czyniła tę integrację szczególnie potężną. Platforma mogła subsydiować darmowy dostęp, obserwować zachowania między usługami i optymalizować zarówno selekcję treści, jak i targetowanie komercyjne. Te same dane poprawiały wygodę i siłę rynkową. Ponieważ model biznesowy cenił predykcję i retencję, platforma miała strukturalny powód, by rozszerzać liczbę zachowań, które mogła obserwować, oraz czas spędzany przez użytkowników w jej środowisku. Nadzór nie był tylko przypadkową porażką prywatności; był infrastrukturą produkcyjną.

Ustawienia domyślne wzmacniały koncentrację. Większość użytkowników nie zmienia przeglądarkę, dostawców wyszukiwania, ustawień prywatności ani uprawnień aplikacji, dopóki koszt domyślności nie stanie się oczywisty. Kontrola nad systemami operacyjnymi, przeglądarkami, sklepami z aplikacjami i przyciskami tożsamości przekładała się więc na władzę dystrybucyjną. Usługa mogła być nominalnie zaskarżalna, pozostając praktycznie dominująca, ponieważ zmiana wymagała uwagi, wiedzy technicznej i koordynacji społecznej.

Model platformowy przekształcił również zewnętrznych wydawców w dostawców. Organizacje informacyjne, twórcy i kupcy zależeli od dystrybucji algorytmicznej, otrzymując niepełną informację o regułach. Relacja przypominała rynek, którego giełda posiada klienta, ustala ranking, konkuruje ze sprzedawcami i dowolnie

zmienia opłaty. Nie czyniło to każdej decyzji platformy nadużyciem, ale czyniło negocjacje strukturalnie asymetrycznymi.

Lekcja nie brzmi, że integracja musi być zakazana. Zintegrowane doświadczenia są wartościowe, a większość użytkowników nie będzie zarządzać dziesiątkami niezależnych usług technicznych. Pytanie projektowe brzmi, czy integracja wymaga własności. Społeczność powinna móc delegować hosting, wyszukiwanie, płatności albo narzędzia moderacji bez oddawania swojej tożsamości i archiwum. Użytkownik powinien móc zmienić rekomender bez porzucania kontaktów. Platforma powinna stać się wymienialną warstwą usługową, a nie suwerennym terytorium.

2.2 Przechwycenie korporacyjne, władza moderatorów i darmowa praca

Uczestnictwo cyfrowe wytwarza kilka rodzajów wartości naraz. Posty i filmy przyciągają publiczność. Oceny poprawiają wyszukiwanie. Relacje społeczne zwiększają retencję. Moderacja utrzymuje przestrzeń w stanie używalności. Ślady behawioralne poprawiają targetowanie i predykcję. Platforma dostarcza infrastrukturę, dzięki której wkłady te można łączyć, ale konwencjonalna własność przypisuje nagromadzone aktywo niemal w całości firmie.

Ujęcie darmowej pracy u Terranovej pozostaje użyteczne, ponieważ identyfikuje włączanie dobrowolnej produkcji kulturowej do systemów komercyjnych (Terranova 2000). Termin ten nie powinien sugerować, że każdy nieopłacony wkład jest ukrytym zatrudnieniem. Ludzie wnoszą wkład dla przyjemności, tożsamości, reputacji, nauki, wzajemnej pomocy i celu publicznego. Wyzysk staje się widoczny, gdy instytucja polega na tych motywach, odmawiając kontrybutorom trwałego głosu, przenośności i udziału w wartości tworzonej przez ich współzależność.

Praca moderatorów jest przykładem skoncentrowanym. Wolontariusze interpretują reguły, wykrywają oszustwa, mediują konflikty i absorbują nadużycia. Matias opisuje to jako pracę obywatelską, ponieważ tworzy warunki zbiorowego uczestnictwa

(Matias 2019). Platformy często celebrować społeczność, traktując ludzi, którzy ją utrzymują, jako wymieniających użytkowników. Układ może być wzajemnie korzystny, ale staje się niestabilny, gdy moderatorzy ponoszą odpowiedzialność bez praw i zasobów.

Tabela 4. Odrębne centra władzy wewnątrz społeczności platformowej

Element	Znaczenie lub konsekwencja projektowa
Firma platformowa	Posiada infrastrukturę, konta, dostęp do danych, monetyzację, techniczne affordancje i ostateczną władzę stanowienia reguł.
Założyciel albo grupa kierownicza	Może ustalać misję i strategię, ale może też zatrzymywać uprawnienia nadzwyczajne albo kontrolę misji bez okresowej legitymizacji.
Moderator-wolontariusz	Kontroluje lokalną interpretację i codzienny dostęp, często przy niewielkim wynagrodzeniu, wsparciu, nadzorze albo wskazówkach proceduralnych.
Zorganizowana frakcja	Może dominować konsultacje, głosowania, zgłoszenia i normy społeczne przez wytrwałość, a nie reprezentatywne poparcie.
Reklamodawca albo dostawca modelu	Wpływa pośrednio na cele optymalizacji i widoczność przez zależność przychodową, dostęp do danych albo techniczne uzależnienie.
Zwykły członek	Tworzy uwagę, relacje, treść i kulturę, zwykle posiadając słabe prawa do powstałego aktywa zbiorowego.

Przechwycenie moderacji jest jednak realne. Długi staż, kontrola nad nominacjami, prywatne kanały koordynacji i słabe odwołania mogą przekształcić opiekę w oligarchię. Badania nad produkcją partnerską wykazały, że nominalna otwartość nie zapobiega utrwalaniu władzy przez trwałe grupy przywódcze (Shaw and Hill 2014). Pewna koncentracja jest funkcjonalna; doświadczeni ludzie znają historię i mogą reagować szybko. Problemem nie jest sama hierarchia, lecz hierarchia bez rotacji, audytu, zadeklarowanej jurysdykcji albo wiarygodnego sposobu zakwestionowania decyzji.

Władza korporacyjna i władza moderatorów oddziałują na siebie. Firmy mogą delegować trudne decyzje wolontariuszom, zachowując

prawo do ich uchylania. Moderatorzy mogą używać polityki firmy do legitymizowania lokalnych preferencji. Użytkownicy doświadczają połączonego wyniku jako jednego nieprzejrzystego systemu, chociaż władza jest rozproszona. Reforma musi zatem ustanowić jasne granice: które reguły należą do wspólnej marki, które do społeczności lokalnych, które do dostawców infrastruktury i które prawa pozostają przy indywidualnych członkach.

Sama płatność nie rozwiązuje przechwycenia. Platforma mogłaby płacić twórcom albo moderatorom, zachowując jednostronną kontrolę. Drobne płatności za dane mogą legitymizować głębszą ekstrakcję, przekształcając członkostwo w serię mikrotransakcji. Sprawiedliwość ekonomiczna ma znaczenie, ale centralny deficyt jest konstytucyjny. Ludzie potrzebują egzekwowalnych praw dotyczących zmian reguł, użycia danych, reputacji, archiwów i wyjścia.

Sama konkurencja również nie wystarcza. Wybór między kilkoma zamkniętymi platformami jest wyborem między prywatnymi konstytucjami. Konkurencja staje się potężna wtedy, gdy zmiana zachowuje tożsamość, relacje i historię. Przenośność musi obejmować ciągłość społeczną, a nie tylko pobieralne archiwum. Inaczej wyjście przypomina opuszczenie miasta i pozostawienie każdej relacji za sobą.

Różnica między eksportem danych a przenośnością zasługuje na podkreślenie. Eksport często tworzy statyczne archiwum użyteczne jako kopia osobista, ale bezużyteczne dla ciągłości. Przenośność oznacza, że inna usługa może zinterpretować dane, zachować identyfikatory, odtworzyć uprawnienia i kontynuować relacje za zgodą. Przenośność społeczna jest jeszcze trudniejsza, ponieważ obserwujący i członkowie grup muszą móc rozpoznać przeniesienie. Standardy muszą zatem obejmować nie tylko formaty plików, lecz także rozstrzyganie tożsamości, dowody relacji, historię moderacji i odwołanie.

Interfejsy programowania aplikacji mogą tworzyć pozorną otwartość, zachowując zależność. Dostęp może być ograniczany, przeceniany albo wycofywany; eksportowane dane mogą pomijać sygnały rankingowe i kontekst społeczny; klienci stron trzecich mogą

pozostawać podporządkowani jednemu systemowi kont. Rzeczywista zaskarżalność wymaga, aby interoperacyjność była prawem albo własnością architektury, a nie uznaniowym programem biznesowym.

Ład korporacyjny dodaje kolejną warstwę. Kadra kierownicza jest często prawnie i finansowo odpowiedzialna przed radami i inwestorami, a nie przed użytkownikami, którzy stworzyli kapitał społeczny społeczności. Spółki pożytku publicznego, trusty opiekuńcze, spółdzielnie i obowiązki interesu publicznego mogą modyfikować to ustawienie, lecz sama forma prawna jest niewystarczająca. Techniczna możliwość wyjścia i konstytucyjna możliwość kwestionowania decyzji muszą towarzyszyć każdej obietnicy misji.

Konstruktywna alternatywa polega na rozdzieleniu nagrody od suwerenności. Założyciele i inwestorzy mogą otrzymywać ograniczone zwroty ekonomiczne. Operatorzy mogą być opłacani za infrastrukturę. Moderatorzy mogą otrzymywać wynagrodzenie za trudną pracę. Kontrybutorzy mogą otrzymywać reputację, udziały w przychodach albo prawa zarządcze. Żadna z tych ról nie powinna automatycznie nadawać trwałej władzy nad całą instytucją. Wspólna społeczność musi istnieć prawnie i technicznie poza jakimkolwiek pojedynczym dostawcą usług.

Rozdział 3: Ludzki przeciwnik

Internet nie wynalazł okrucieństwa, oszustwa, trybalizmu ani rywalizacji o status. Zmienił ich koszt, szybkość, skalę i widoczność. Każda przyszła architektura zakładająca dobrą wolę zostanie przechwycona przez tych, którzy są gotowi ją wykorzystać.


3.1 Anonimowość, odhamowanie, trolling i skoordynowane nadużycia

Anonimowość bywa omawiana jako binarny wybór między wolnością a odpowiedzialnością. W praktyce tożsamość online ma wiele wymiarów: nazwisko prawne, trwały pseudonim, reputację, członkostwo, adres techniczny i historię relacji. Osoba może być anonimowa wobec publiczności, a jednocześnie rozliczalna przed społecznością, albo publicznie nazwana, a jednocześnie działać przez konta jednorazowe. Dobry projekt rozdziela te wymiary, zamiast wymuszać uniwersalną identyfikację.

Wartość ochronna pseudonimowości jest znaczna. Dysydenci polityczni, osoby po przemocy, pacjenci, pracownicy i członkowie stygmatyzowanych grup mogą potrzebować mówić bez łączenia każdej wypowiedzi z tożsamością prawną. Obowiązkowe systemy prawdziwego nazwiska mogą przenosić ryzyko z agresorów na cele. Jednak tania tożsamość utrudnia również wykluczenie. Zbanowany aktor może wrócić, skoordynowana grupa może symulować konsensus, a botnet może zwielokrotnić pozornych uczestników.

Rama odhamowania online Sulera odróżniała łagodną otwartość od toksycznego odhamowania i wskazywała anonimowość, niewidzialność, asynchroniczność oraz osłabiony autorytet jako istotne warunki (Suler 2004). Późniejsze prace łączyły trolling z cechami sadystycznymi i manipulacyjnymi, ale badania eksperymentalne wykazały również efekty sytuacyjne. Uczestnicy wystawieni na negatywny nastrój i wrogą dyskusję częściej publikowali materiał obraźliwy (Buckels, Trapnell, and Paulhus 2014;

Cheng et al. 2017). Architektura nie tylko ujawnia charakter; kształtuje zachowanie.



Rysunek 4. Powtarzalna pętla toksyczności: prowokacja wywołuje reakcję, reakcja staje się sygnałem rankingowym, a powtarzana ekspozycja zmienia lokalne normy.

Trolling jest tylko jednym wzorcem antagonistycznym. Spam wykorzystuje taną dystrybucję. Brigading importuje zorganizowaną publiczność do lokalnego sporu. Nękanie koordynuje powtarzalny kontakt przez konta i usługi. Astroturfing symuluje niezależne poparcie publiczne. Boty społeczne wzmacniają materiał albo wytwarzają pozorną aktywność. Operacje wpływu łączą osoby, treści targetowane, timing i narracje międzyplatformowe. Zachowania te różnią się celem i wymagają różnych odpowiedzi.

Przewaga skali zwykle należy do atakującego. Jedna osoba może stworzyć tysiące wiadomości; każdy odbiorca musi zdecydować, czy jedna wiadomość jest autentyczna. Atakujący może testować wiele tożsamości; obrońca musi zachować dostęp dla prawowitych nowych uczestników. Fałszywe oskarżenie można natychmiast powtórzyć; cel musi zebrać dowody w rozproszonych systemach. Ta asymetria wyjaśnia, dlaczego czysto lokalna moderacja często zawodzi wobec skoordynowanych nadużyć.

Reputacja pomaga tylko wtedy, gdy jej odbudowa jest kosztowna i gdy jest istotna dla kontekstu. Uniwersalny wynik reputacji stworzyłby nadzór i przenosił władzę między niepowiązanymi

domenami. Reputacja kontekstowa jest bezpieczniejsza: długi dorobek w społeczności wsparcia medycznego nie powinien nadawać władzy w debacie politycznej, a zweryfikowane poświadczenie zawodowe nie powinno wymazywać dowodów nadużycia. Systemy potrzebują trwałych relacji bez konstruowania uniwersalnego systemu kredytu społecznego.

Tarcie nie jest więc wrogiem wolności. Starannie umieszczone tarcie może ją chronić. Nowe konta mogą otrzymywać niższe limity szybkości. Masowe zaproszenia mogą wymagać poręczenia. Odwołania mogą wymagać krótkiego wyjaśnienia zamiast jednego gniewnego kliknięcia. Działania wysokiego ryzyka mogą wymagać silniejszych poświadczeń. Celem nie jest utrudnianie uczestnictwa, lecz uczynienie nadużyć na dużą skalę droższymi niż zwykłe użycie ludzkie.

Rywalizacja o status nasila te dynamiki. Publiczne liczby obserwujących, karma, odznaki i metryki wiralności przekształcają interakcję w widoczną hierarchię. Sygnały te mogą nagradzać ekspertyzę i trwały wkład, ale tworzą również bodźce do performatywnej pewności, lojalności frakcyjnej i upokarzania rywali. Anonimowość nie usuwa statusu; przenosi status do historii kont i lokalnego rozpoznania.

Problem Sybilla jest zatem równie społeczny, jak kryptograficzny. Wymaganie jednej tożsamości prawnej na konto może ograniczyć duplikację, ale tworzy nadzór i wykluczenie. Systemy proof-of-personhood mogą ustanowić unikalność, nie ustanawiając dobrej woli ani kompetencji. Zaufane wprowadzenia i poświadczenia specyficzne dla relacji często dają bardziej proporcjonalną odpowiedź. Pytanie nie brzmi „Czy to prawdziwy człowiek?”, lecz „Jakie prawo ma ten aktor, by wykonać to działanie w tym kontekście?”.

Nękanie między usługami ujawnia słabość izolowanego egzekwowania. Jedna społeczność może zbanować aktora, podczas gdy inna zapewnia mu obszar przygotowawczy. Ofiara może potrzebować udokumentować dziesiątki kont w różnych usługach. Wspólne sygnały nadużyć mogą pomóc, ale ryzykują stworzenie

nieprzejrzystych czarnych list. Lepszy system współdzieli podpisane dowody, zakres i wygaśnięcie, pozostawiając ostateczne decyzje społecznościom odbierającym, zgodnie z ich własnymi procedurami.

Antagonistyczny Internet musi również odróżniać błąd od złośliwości. Nadmiernie agresywne wykrywanie może wykluczać nowych uczestników, dialekty mniejszościowe, ironię i wypowiedzi kontrowersyjne. Systemy automatyczne są użyteczne do triage'u i oczywistych wzorców, ale sankcje wrażliwe na kontekst wymagają ludzkiego osądu i zabezpieczeń proceduralnych. System blokujący każde ryzyko staje się systemem, w którym mówić mogą tylko aktorzy już ustabilizowani.

3.2 Moderacja jako rządzenie

Moderacja jest często opisywana jako utrzymywanie porządku, jak gdyby reguły jedynie usuwały brud z neutralnej przestrzeni. Praca Gillespiego pokazuje, że moderacja definiuje samą platformę. Decyzje o dopuszczalnej wypowiedzi, rankingu, integralności kont i rekomendacji określają, jaki rodzaj publiczności istnieje (Gillespie 2018). Nawet lista chronologiczna wymaga reguł dotyczących spamu, duplikatów, tożsamości i usuwania.

Legitymizowana moderacja zaczyna się od jurysdykcji. Globalny dostawca infrastruktury powinien interweniować przeciw złośliwemu oprogramowaniu, oszustwom na dużą skalę i poważnym nadużyciom międzyspołecznościowym. Lokalna społeczność powinna definiować temat, ton, ekspertyzę i oczekiwania kulturowe. Wspólna marka może narzucać minimalne prawa i standardy bezpieczeństwa. Gdy warstwy te zostają złane, lokalna niezgoda staje się kryzysem całej platformy, a polityka platformy pretekstem do lokalnej dominacji.

Reguły muszą być na tyle zrozumiałe, aby kierować zachowaniem. Skrajnie szczegółowe polityki często tworzą pozór precyzji, zwiększając zależność od interpretacji insiderskiej. Skrajnie niejasne polityki pozwalają na arbitralne egzekwowanie. Rozwiązanie praktyczne to zwięzła warstwa konstytucyjna, reguły lokalne i

korpus zanonimizowanych precedensów pokazujących, jak rozwiązano powtarzające się sprawy.

Tabela 5. Wzorce antagonistyczne wymagają różnych odpowiedzi

Element	Znaczenie lub konsekwencja projektowa
Trolling i nękanie	Ograniczaj nagrodę społeczną, zachowuj dowody między incydentami, chroń cele i stosuj stopniowane sankcje z odwołaniem.
Spam i botnety	Stosuj limity szybkości, reputację nadawcy, dowód relacji oraz tarcie ekonomiczne lub obliczeniowe proporcjonalne do skali.
Brigading	Wykrywaj skoordynowane przybycie i importowane głosowanie, nie traktując każdej niepopularnej koalicji jako nielegitymizowanej.
Astrourfing i operacje wpływu	Ujawniaj sponsoring, analizuj koordynację, zachowuj niepewność atrybucji i oddzielaj operację od deklarowanego wpływu.
Farmy treści syntetycznych	Zmniejszaj nagrody za wolumen, wymagaj proveniencji lub sponsoringu i karz systematyczne oszustwo, a nie samą automatyzację.
Przejęci agenci osobowi	Ograniczaj zdolności, izoluj sekrety, rejestruj delegowane uprawnienia i czyni działania o dużym wpływie odwoływalnymi i przeglądalnymi.

Procedura nie jest dekoracją biurokratyczną. Użytkownicy częściej rozumieją i akceptują moderację, gdy otrzymują uzasadnienia, nawet jeśli nie podoba im się wynik (Jhaver, Bruckman, and Gilbert 2019). Odwołania ujawniają błędy, wskazują niejasne reguły i ograniczają osobisty odwet. Nakładają również koszt. Dojrzały system stosuje przegląd proporcjonalny: automatyczną korektę oczywistych pomyłek, lokalne odwołanie w zwykłych sprawach oraz niezależny przegląd w sporach poważnych albo konstytucyjnych.

Moderatorzy potrzebują ochrony tak samo jak nadzoru. Mogą mierzyć się z groźbami, traumatycznymi treściami, skoordynowanymi skargami i presją wpływowych członków. Wolontariat nie powinien ukrywać niebezpiecznej pracy. Społeczności zależne od moderacji powinny finansować szkolenie,

rotację, wsparcie zdrowia psychicznego i bezpieczne narzędzia. Moderator zmuszony wybierać między wypaleniem a porzuceniem nie może zapewnić stabilnego zarządzania.

Eksperymenty dotyczące interwencji platform komplikują twierdzenie, że egzekwowanie jedynie przenosi nadużycia gdzie indziej. Bany Reddita z 2015 roku wiązały się ze znacznymi redukcjami mowy nienawiści wśród dotkniętych użytkowników bez jasnych dowodów równoważnej migracji do społeczności sąsiednich (Chandrasekharan et al. 2017). Wynik nie uzasadnia każdego bana. Pokazuje, że granice mogą zmieniać zachowanie i że instytucje nie muszą akceptować toksyczności jako niezmiennego wyrazu popytu.

Najgłębszym ryzykiem jest przechwycenie konstytucyjne. Klasa moderatorów może stać się trwała. Założyciel może zachować władzę nadzwyczajną bezterminowo. Zamożny kontrybutor może dominować, ponieważ projekt zależy od finansowania. Zorganizowana frakcja może zalewać każdą konsultację. Formalne głosowanie nie rozwiązuje automatycznie tych problemów, ponieważ uczestnictwo jest nierówne, a intensywne mniejszości mogą przetrwać zwykłych członków.

Bardziej odporne projektowanie używa podziału władz. Stanowienie reguł, egzekwowanie, odwołania, decyzje skarbcza i administracja techniczna nie powinny być kontrolowane przez tych samych ludzi. Kadencje powinny być ograniczone. Konflikty interesów powinny być ujawniane. Panele losowane lub rotacyjne mogą uzupełniać wybory. Działania nadzwyczajne powinny wygasać, jeśli nie zostaną ratyfikowane. Dzienniki audytowe powinny czynić wzorce widocznymi bez ujawniania prywatnych ofiar.

Skala zmienia właściwy proces. Mała grupa może omówić sprawę synchronicznie i polegać na wspólnej pamięci. Sieć z milionami użytkowników potrzebuje triage'u, standaryzowanych dowodów, delegacji i audytu statystycznego. Automatyzacja staje się nieunikniona, ale powinna rekomendować i priorytetyzować, zamiast po cichu stawiać się ostatecznym sędzią w sprawach niejednoznacznych. Systemy wysokiego wolumenu powinny

publikować stopy błędów, wyniki odwołań i dysproporcje między językami lub społecznościami.

Sztuczna inteligencja może wspierać moderację przez klastrowanie skoordynowanych zachowań, tłumaczenie zgłoszeń, identyfikowanie precedensów i szkicowanie uzasadnień. Może też wzmacniać stronniczość i tworzyć fałszywą pewność. Model językowy, który generuje przekonujące wyjaśnienie po działaniu nieprzejrzystego klasyfikatora, może sprawić, że system wygląda bardziej legitymizowanie, nie czyniąc go bardziej poprawnym. Wyjaśnienia muszą być połączone z rzeczywistymi dowodami i regułami, a nie tylko retorycznie satysfakcjonujące.

Legitymizacja systemu moderacji zależy również od traktowania obserwatorów. Wyjaśnienia publiczne uczą norm wszystkich, którzy je widzą. Tajne egzekwowanie pozostawia społeczność w sytuacji wnioskowania o regułach z plotek. Prywatność ogranicza ujawnianie w sprawach nękania i bezpieczeństwa, ale zanonimizowane precedensy mogą pokazywać wzorce bez odsłaniania ofiar. Z czasem ten korpus decyzji staje się prawem zwyczajowym społeczności.

Nie chodzi o naśladowanie państwa narodowego na każdym forum. Małe grupy potrzebują lekkich instytucji. Zasadą jest proporcjonalność: im większe konsekwencje decyzji, tym wyższa powinna być jakość procedury. Grupa hobbystyczna może polegać na zaufanych opiekunach. Globalny system wiedzy, sieć polityczna albo rynek zawodowy nie mogą wiarygodnie twierdzić, że uznanie właściciela jest wystarczającym rządem.

Rozdział 4: Trafność jest konstytucją


Rozstrzygająca władza nowoczesnego Internetu często nie jest władzą usuwania wypowiedzi, lecz władzą czynienia pewnych wypowiedzi praktycznie nieuniknionymi, a innych praktycznie niewidzialnymi. Ranking jest rządzeniem przez prawdopodobieństwo.

4.1 Wyszukiwanie, strumienie treści, zaangażowanie i dryf ku idiokracji

System rankingowy tłumaczy cel społeczny na mierzalne sygnały. Wyszukiwarki szacują trafność przez tekst, linki, autorytet, świeżość, lokalizację i wiele innych czynników. Strumienie społecznościowe szacują prawdopodobieństwo interakcji. Rekomendery przewidują preferencję. Każdy system może być technicznie doskonały, a zarazem osadzać wartości podlegające sporowi.

Centralnym błędem jest mylenie reakcji behawioralnej z refleksyjną preferencją. Człowiek może kliknąć, ponieważ element jest użyteczny, szokujący, obraźliwy, seksualnie prowokacyjny, przerażający albo trudny do zignorowania. Komentarz może wyrażać wdzięczność albo gniew. Spędzony czas może oznaczać fascynację albo dezorientację. Gdy sygnały te zostają zagregowane jako zaangażowanie, system traci znaczenie zachowania, zachowując jego intensywność.

Badania nad uwagą zbiorową pokazują, że cykle informacyjne przyspieszyły, zwiększając konkurencję o skończony zasób ludzki (Lorenz-Spreen et al. 2019). Twórcy dostosowują się, produkując materiał częstszy, emocjonalnie czytelny i strategicznie opakowany. Platformy następnie obserwują zachowanie wytworzone przez własny ranking i używają go jako dowodu dla następnego rankingu. Rekomender nie jest biernym lustrem. Tworzy część rozkładu preferencji, który później twierdzi, że wykrywa.



Rysunek 5. Gdy mierzalna reakcja zastępuje wartość refleksyjną, trafność staje się maszyną selekcji treści uproszczonych i konfliktowych.

Prawo Goodharta jest często przywoływane luźno, ale właściwy proces jest jasny. Gdy metryka staje się celem, uczestnicy optymalizują pod nią. Tytuł staje się urządzeniem kliknięcia. Pierwsze sekundy stają się inżynierią retencji. Oburzenie staje się formatem wielokrotnego użytku. Metryka selekcjonuje nie tylko pojedyncze elementy, lecz także typy twórców i instytucji zdolnych przetrwać.

To mechanizm stojący za dryfem ku „Idiocracy”. Treść złożona nie jest z natury niepopularna, a użytkownicy nie preferują powszechnie nonsensu. Jednak złożoność często wymaga kontekstu i opóźnionej nagrody, podczas gdy systemy rankingowe faworyzują sygnały dostępne natychmiast. System porównuje więc długoterminową wartość jednego elementu z natychmiastowym bodźcem innego i nazywa zwycięzcę trafnym.

Efekt jest najsilniejszy tam, gdzie koszty produkcji różnią się radykalnie. Dziennikarstwo śledcze, synteza naukowa i staranna krytyka są kosztowne. Plotka, skopiowany klip albo syntetyczna prowokacja są tanie. Jeśli oba konkurują o tę samą płatność za zaangażowanie, treść niskokosztowa może zalać rynek. Generatywna AI zwiększa tę asymetrię, dalej obniżając koszt produkcji, podczas gdy weryfikacja pozostaje droga.

Regulacja może wymagać ujawniania informacji i alternatywnych strumieni treści, ale przejrzystość dotycząca „głównych parametrów” nie jest tym samym co kontrola użytkownika (European Union 2022). Platforma może opublikować szeroki opis, zachowując niedostępny model i mieszane bodźce. Bardziej fundamentalnym lekarstwem jest pluralistyczna rekomendacja: chronologiczne, oparte na relacjach, kuratorowane przez ekspertów, poszukujące różnorodności, lokalno-społecznościowe i osobisto-agentowe rankingi powinny móc współistnieć nad przenośnymi danymi.

Personalizacja dodaje pętlę sprzężenia zwrotnego. System wnioskuje, że użytkownik lubi temat, dostarcza go więcej, obserwuje wzmożoną interakcję, ponieważ alternatywy są mniej widoczne, i traktuje rezultat jako potwierdzenie. Z czasem model może pomylić ekspozycję z preferencją, a preferencję z tożsamością. Użytkownik staje się łatwiejszy do przewidzenia częściowo dlatego, że system zawęził środowisko.

Stronniczość popularności działa podobnie na poziomie zbiorowym. Elementy otrzymujące wczesną ekspozycję kumulują interakcję, co daje większą ekspozycję. Powstała hierarchia może wyglądać meritokratycznie, nawet gdy różnice początkowe były małe albo arbitralne. Użytkownicy niszowi tracą odkrywanie, a twórcy dostosowują się do formatów już udanych. Badania nad rekomenderami coraz częściej oceniają różnorodność, kalibrację i sprawiedliwość, ponieważ sama dokładność nie potrafi opisać tych efektów (Burke, Sonboli, and Ordonez-Gauger 2018).

Alternatywne metryki są możliwe. System może optymalizować długoterminową satysfakcję zamiast natychmiastowej reakcji, mierzyć, czy użytkownicy załują sesji, nagradzać różnorodność źródeł albo rezerwować pojemność na eksplorację. Jednak każda alternatywa pozostaje wyborem wartości i może zostać ograna. Rozwiązaniem nie jest odkrycie doskonałej metryki, lecz konkurencja między zadeklarowanymi politykami rankingowymi połączona z kontrolą użytkownika i niezależnym audytem.

Trafność należy traktować jako twierdzenie mające autora. Zamiast przedstawiać jeden porządek jako naturalną powierzchnię świata,

systemy powinny wskazywać, co ranking optymalizuje, czyje interesy reprezentuje, jakich danych używa i jakie alternatywy istnieją. Nie usuwa to osądu. Czyni osąd zaskarżalnym.

4.2 Dezinformacja, komory echa i manipulacja wyborami

„Fake news” jest kategorią niestabilną, obejmującą sfabrykowane historie, mylące ramowanie, satyrę, propagandę, media zmanipulowane i zwykłe błędy (Tandoc, Lim, and Ling 2018). Polityka staje się zdezorientowana, gdy zjawiska te traktuje się jako jeden obiekt techniczny. Fałszywe twierdzenie faktyczne wymaga korekty; skoordynowane oszustwo wymaga atrybucji; selekcja partyjna może wymagać pluralistycznych źródeł; satyra może wymagać kontekstu, a nie usunięcia.

Badanie Science autorstwa Vosoughi, Roy i Aral wykazało, że fałszywe historie na Twitterze rozchodziły się w analizowanym zbiorze dalej, szybciej i szerzej niż historie prawdziwe, przy czym zachowanie ludzkie przyczyniało się do różnicy bardziej niż boty (Vosoughi, Roy, and Aral 2018). Wynik jest ważny, ale nie jest prawem uniwersalnym. Temat, platforma, czas i definicje mają znaczenie. Ekspozycja na niewiarygodne źródła jest często skoncentrowana wśród mniejszości silnie zaangażowanych użytkowników, a nie równomiernie rozłożona w populacji (Grinberg et al. 2019; Guess, Nyhan, and Reifler 2020).

Konta automatyczne nadal mogą kształtować dyfuzję. Badania wykazały udział botów społecznych we wczesnym wzmacnianiu treści o niskiej wiarygodności, zwiększając prawdopodobieństwo, że ludzie je napotkają i przekażą dalej (Shao et al. 2018). Znaczącą jednostką często nie jest izolowany bot, lecz system skoordynowany: konta, narracje, timing, reklama, influencerzy i media zewnętrzne wzajemnie się wzmacniają.

Manipulację wyborczą należy analizować jako łańcuch przyczynowy. Operacja może istnieć. Publiczność może być wystawiona. Postawy lub zachowania mogą się zmienić. Zmiana może zmienić frekwencję, agendę, darowizny albo głosy. Ostateczny wynik wyborów może się

zmienić. Dowody są najsilniejsze blisko początku i stają się coraz bardziej niepewne na każdym kroku. Brak dowodu na ostatnim etapie nie czyni operacji nieszkodliwą; dowód operacji nie dowodzi ostatniego etapu.

Tabela 6. Twierdzenia o wpływie politycznym muszą pozostać rozdzielone

Element	Znaczenie lub konsekwencja projektowa
Operacja istniała	Często można to ustalić przez konta, archiwa, infrastrukturę, finansowanie, koordynację oraz dochodzenia platform albo państw.
Ludzie byli wystawieni	Wymaga pomiaru zasięgu, częstotliwości, składu publiczności, duplikacji międzyplatformowej i konkurujących informacji.
Przekonania się zmieniły	Wymaga dowodów przyczynowych, a nie tylko korelacji między ekspozycją a wcześniejszą preferencją polityczną.
Zachowanie się zmieniło	Może dotyczyć udostępniania, frekwencji, darowizn, uwagi agendy, zastraszenia albo wycofania; każde wymaga odrębnego projektu.
Wynik wyborów się zmienił	Zwykle nie można tego wywnioskować z istnienia albo skali operacji, ponieważ konieczny kontrfaktyczny scenariusz wyborczy jest nieobserwowalny.

Kampania Internet Research Agency podczas wyborów w Stanach Zjednoczonych w 2016 roku została szczegółowo udokumentowana przez dochodzenie Senatu. Wykorzystywała media społecznościowe do eksploatowania podziałów, podszywania się pod grupy i wpływania na dyskurs polityczny (United States Senate Select Committee on Intelligence 2019). Dochodzenie ustaliło zamiar i aktywność. Nie mogło obserwować kontrfaktycznych wyborów bez kampanii. Twierdzenia, że operacja z pewnością zmieniła zwycięzcę, wykraczają poza dostępne dowody.

Mikrotargetowanie ma podobne ograniczenia. Targetowanie psychologiczne może poprawiać reakcję w warunkach eksperymentalnych (Matz et al. 2017), ale efekty perswazyjne kampanii w wyborach powszechnych są często małe (Kalla and Broockman 2018). Targetowanie może nadal mieć znaczenie przez

mobilizację, pozyskiwanie funduszy, formowanie agendy albo kumulatywne wzmacnianie. Intelktualnie uczciwe stanowisko nie jest ani lekceważeniem, ani magiczną wiarą w kontrolę umysłu.

Komory echa dodają wymiar strukturalny. Badania międzyplatformowe wskazują na homofilię i skupioną ekspozycję, ale siła różni się zależnie od platformy (Cinelli et al. 2021). Proponowane lekarstwo polegające na pokazywaniu treści przeciwnych może przynieść skutek odwrotny, gdy użytkownicy odbierają je jako wrogie zagrożenie tożsamościowe (Bail et al. 2018). Wiarygodna polityka różnorodności powinna wprowadzać niezgodę przez zaufane źródła, wspólne fakty, niepewność i racje, a nie przez maksymalną prowokację.

Ekosystem medialny wykracza poza platformy społeczne. Telewizja, media partyjne, influencerzy, elity polityczne i wyszukiwarki mogą zapoczątkowywać albo legitymizować narracje, które sieci społeczne następnie przyspieszają. Benkler, Faris i Roberts argumentują, że struktury medialne i zachowanie elit były centralne dla amerykańskiego środowiska dezinformacji, komplikując ujęcia przypisujące pierwotną przyczynowość izolowanym zagranicznym botom albo indywidualnej łatwowierności (Benkler, Faris, and Roberts 2018).

Manipulacja często szuka niepewności, a nie przekonania. Zalewanie środowiska niezgodnymi twierdzeniami może sprawić, że obywatele uznają, iż żadne źródło nie jest godne zaufania, a weryfikacja jest bezcelowa. Strategia ta korzysta z fałszywej równoważności między zdrowym sceptycyzmem a uniwersalnym cynizmem. Instytucje powinny więc komunikować, jak wytworzono wiedzę, co pozostaje niepewne i które procedury mogą skorygować błąd.

Prebunking i tarcie mogą uzupełniać korektę. Ostrzeganie użytkowników przed typowymi technikami manipulacji, opóźnianie szybkiego udostępniania albo proszenie o minimalne zaangażowanie kontekstowe mogą ograniczać impulsywną dyfuzję bez tworzenia centralnego ministerstwa prawdy. Środki te powinny być testowane pod kątem rzeczywistych efektów behawioralnych i monitorowane pod względem nierównych obciążeń.

Korekty działają niedoskonale, ale nie są daremne. Metaanalizy pokazują, że debunking może ograniczać fałszywe przekonania, przy skuteczności zależnej od projektu komunikatu, powtórzenia i publiczności (Chan et al. 2017; Walter and Murphy 2018). Trudność polega na tym, że korekta konkuruje w środowisku nagradzającym pierwotną nowość. Projekt instytucjonalny musi więc zmienić bodźce dystrybucyjne, a nie tylko dopisywać fact-checki po wiralności.

Rozdział 5: Syntetyczna sieć i Internet, który nadal działa

Generatywna AI zwiększa zarówno zdolność produkcyjną Internetu, jak i niepewność każdego spotkania. Niebezpieczeństwo nie polega na tym, że maszyny mówią. Polega na tym, że proveniencja, odpowiedzialność i koszt prawdy odrywają się od wolumenu wypowiedzi.


5.1 Teoria martwego Internetu, boty i generatywna obfitość

Teoria martwego Internetu stała się popularna, ponieważ nadała dramatyczną formę rzeczywistemu doświadczeniu: powtarzanym postom, pustemu zaangażowaniu, kopiowanym artykułom, odpowiedziom botów, syntetycznym obrazom i wynikiem wyszukiwania zoptymalizowanym dla innych maszyn. Jej najsilniejsze twierdzenie, że większość życia online została już zastąpiona przez skoordynowany system sztuczny, nie ma wiarygodnych dowodów. Jej słabsze twierdzenie opisuje realne przejście ku produkcji i mediacji zautomatyzowanej.

Boty nie są z natury zwodnicze. Crawlery wyszukiwarek, usługi monitorujące, narzędzia dostępności, tłumacze i agenci osobiści są uczestnikami zautomatyzowanymi. Istotne rozróżnienia dotyczą tego, czy automatyzacja jest zadeklarowana, czy istnieje odpowiedzialny operator, czy system symuluje niezależnych ludzi i czy jego skala nakłada koszty na innych. Pożyteczny agent może stać się nadużyciem, gdy ignoruje limity szybkości albo ekstrahuje całe społeczeństwo bez zgody.

Systemy generatywne zmieniają ekonomię treści. Mogą tłumaczyć, streszczać, uczyć, wspierać programowanie i czynić wiedzę specjalistyczną bardziej dostępną. Mogą także produkować tysiące wariantów zyskownego formatu, fabrykować recenzje, podszywać się pod lokalne głosy i wypełniać indeksy wyszukiwania wiarygodną

redundancją. Przeciętny koszt wytworzenia twierdzenia zbliża się do zera, podczas gdy koszt jego sprawdzenia nie.



Rysunek 6. Proweniencja może ustalić pochodzenie i historię przekształceń; sama nie może ustalić prawdy, jakości ani legitymizacji.

Standardy proveniencji, takie jak C2PA, mogą rejestrować podpisane twierdzenia o pochodzeniu i historii przekształceń mediów. Są użyteczne, ponieważ czynią manipulację i atrybucję bardziej możliwymi do inspekcji. Nie określają prawdy. Podpisane fałszywe oświadczenie pozostaje fałszywe, a niepodpisany materiał autentyczny może pozostać wartościowy. Proweniencja jest warstwą integralności, a nie wyrocznią (C2PA 2026).

Rekurencyjne zanieczyszczenie danych dodaje ryzyko techniczne. Shumailov i współpracownicy pokazali, że modele trenowane wielokrotnie na danych wygenerowanych przez modele mogą tracić informację o pierwotnym rozkładzie i w pewnych warunkach ostatecznie się załamać (Shumailov et al. 2024). Dane syntetyczne mogą być użyteczne, gdy są starannie generowane i mieszane z wiarygodnymi oryginałami. Ostrzeżenie dotyczy niekontrolowanego zastępowania dowodów ludzkich wynikami pochodzącymi z wcześniejszych wyników.

Spółeczna wersja tej rekurencji może być ważniejsza. Ludzie piszą dla systemów rankingowych. Modele trenują na materiale ukształtowanym przez ranking. Agenci streszczają treści ukształtowane przez modele. Twórcy następnie optymalizują pod streszczenia agentów. Komunikacja staje się coraz bardziej

pośrednia. Intencja ludzka pozostaje obecna, ale jest filtrowana przez warstwy nagradzające kompatybilność z innymi maszynami.

Odpowiedzią nie powinien być powszechny zakaz treści syntetycznych. Powinna ona wymagać zadeklarowanej automatyzacji, odpowiedzialnych operatorów, limitów szybkości, proveniencji tam, gdzie właściwe, oraz odrębnych polityk rankingowych dla produkcji ludzkiej i maszynowej. Społeczności mogą rozsądnie tworzyć przestrzenie, w których tylko zweryfikowani członkowie-ludzie mogą inicjować dyskusję, nadal pozwalając agentom wspierać tych członków prywatnie.

Syntetyczna obfitość destabilizuje również zwykłe dowody społeczne. Fotografia, świadectwo albo styl rozmowy kiedyś niosły słabe, ale użyteczne sygnały wysiłku ludzkiego. Sygnały te można teraz tanio reprodukować. Społeczności będą potrzebować silniejszych form ciągłości: trwałych relacji, podpisanej proveniencji, znanych procesów redakcyjnych i reputacji zdobytej w czasie. Żadna nie jest nieomylna, ale razem podnoszą koszt fabrykowania całego świata społecznego.

Wyszukiwarki i asystenci stoją przed trudnym wyborem. Wykluczenie całego materiału generowanego maszynowo odrzuciłoby użyteczne tłumaczenia, streszczenia i narzędzia. Traktowanie całego materiału identycznie pozwala wolumenowi dominować. Ranking powinien więc uwzględniać pochodzenie, odpowiedzialność, nowość i duplikację. Tysiąc parafraz pochodzących z jednego źródła nie powinno tworzyć tysiąca niezależnych głosów.

Agenci osobiści mogą stać się zarówno lekarstwem, jak i źródłem zanieczyszczenia. Mogą filtrować powtarzalny materiał i śledzić twierdzenia do oryginałów, ale mogą też generować automatyczne odpowiedzi, negocjować z innymi agentami i wypełniać kanały komunikacją maszyna-maszyna. Protokoły powinny czynić status agenta i odpowiedzialnego mocodawcę jawnymi, aby społeczności mogły decydować, jakie uczestnictwo automatyczne akceptują.

Internet pozostaje żywy, gdy ludzie mogą identyfikować znaczące źródła, tworzyć trwałe relacje i wytwarzać artefakty zachowujące

wartość poza strumieniem treści. Zagrożeniem nie jest sama ilość. Jest nim utrata wiarygodnych ścieżek od twierdzenia do źródła, od działania do odpowiedzialnego aktora i od społeczności do wspólnej historii, której nie można wygenerować na żądanie.

5.2 Wikipedia, open source, nauka i trwałe dobra wspólne

Książka o porażce Internetu musi wyjaśnić systemy, które działały. Wikipedia, oprogramowanie open-source, OpenStreetMap, współpraca naukowa i społeczności wyspecjalizowane pokazują, że współpraca na dużą skalę nie jest romantycznym wyjątkiem. Są to osiągnięcia instytucjonalne o konkretnych cechach projektowych.

Wikipedia łączy radykalną edytowalność z rozległą śledzalnością. Każdą zmianę można sprawdzić i odwrócić. Dyskusja jest powiązana z artykułami. W zasadzie źródła znaczą więcej niż osobisty autorytet, a spory pozostawiają zapis. Wczesne porównanie *Nature* z *Encyclopaedia Britannica* było kwestionowane, ale ustaliło, że produkcja współpracy może osiągnąć poziom godny poważnego porównania (Giles 2005).

Jej trudności ujawniają koszt sukcesu. Systemy antywandalistyczne i gęste normy chronią jakość, ale zwiększają obciążenie nowych uczestników. Halfaker i współpracownicy powiązali spadek retencji redaktorów częściowo z coraz skuteczniejszym odrzucaniem wkładów (Halfaker et al. 2013). Nierówności płciowe i strukturalne wpływają na tematy, język i widoczność (Wagner et al. 2016; Yun, Lee, and Jeong 2019). Dobro wspólne może stać się konserwatywne, ponieważ musi bronić tego, co zbudowało.

Społeczności open-source podobnie łączą wolność z zarządzaniem. Projekty potrzebują opiekunów, procesów wydań, reakcji bezpieczeństwa, rozwiązywania konfliktów i kontroli nazw. O'Mahony i Ferraro pokazali, jak autorytet może wyłaniać się przez negocjowane zarządzanie, a nie prostą własność (O'Mahony and Ferraro 2007). Licencja kodu umożliwia wyjście i ponowne użycie, ale trwała współpraca zależy od instytucji wokół licencji.

Tabela 7. Dlaczego niektóre dobra wspólne online pozostają trwałe

Element	Znaczenie lub konsekwencja projektowa
Otwarte techniczne podłoże	Uczestnicy i niezależni operatorzy mogą kontrolować, ponownie używać, naprawiać i budować usługi komplementarne.
Widoczna historia	Zmiany, odwrócenia, źródła i spory pozostają możliwe do inspekcji, zamiast znikać w jednym stanie bieżącym.
Ograniczone role	Redaktorzy, opiekunowie, recenzenci i stewardzi posiadają różne uprawnienia zamiast jednej nierozróżnionej roli administratora.
Finanse zgodne z misją	Finansowanie wspiera wspólne aktywo, nie czyniąc reklamy behawioralnej ani własnościowego zamknięcia jego centrum konstytucyjnym.
Mechanizmy naprawy	Błędy można korygować, od decyzji się odwoływać, kontrybutorów ponownie socjalizować, a uszkodzone normy odbudowywać.
Wiarygodne wyjście albo fork	Społeczność może przetrwać porażkę jednego dostawcy, lidera albo implementacji bez utraty całego wspólnego dzieła.

Badania ekonomiczne podkreślają skalę wartości publicznej. Hoffmann, Nagle i Zhou szacują, że zastąpienie powszechnie używanego oprogramowania open-source narzuciłoby ogromne koszty, dalece wykraczające poza bezpośrednie przychody projektów (Hoffmann, Nagle, and Zhou 2024). Dokładny scenariusz kontrfaktyczny jest dyskusyjny, ale wniosek jakościowy nie: nowoczesne firmy polegają na dobru wspólnym, którego indywidualnie nie sfinansowały.

OpenStreetMap pokazuje, jak otwarta baza danych może służyć zwykłej nawigacji i reakcji humanitarnej. Badania nad mapowaniem humanitarnym wykazały miliony budynków i dróg dodanych w regionach o niższym poziomie rozwoju przez zorganizowane kampanie (Herfort et al. 2021). Projekt ujawnia również nierówności geograficzne i uczestnictwa. Otwartość tworzy zdolność korygowania ślepych plam, a nie automatyczną gwarancję, że korekty nastąpią.

Nauka obywatelska rozszerza współpracę na badania. Systemy takie jak FlyWire koordynowały duże społeczności online wokół anotacji i odkryć naukowych (Dorkenwald et al. 2022). Najlepsze projekty dają uczestnikom znaczący kontekst i uznanie, zamiast traktować ich jak niewidzialną pracę mikrozadaniową. Współpraca naukowa staje się trwała, gdy kontrybutorzy mogą zrozumieć, jak ich praca wchodzi w większy proces epistemiczny.

Te sukcesy dzielą wzorzec. Artefakt jest przenośny albo publicznie dostępny. Wkład pozostawia historię. Role są zrozumiałe. Reputacja jest powiązana z pracą. Zarządzanie jest dostatecznie stabilne, by chronić projekt, a jednocześnie dostatecznie otwarte, by pozwolić na zakwestionowanie. Finansowanie jest zróżnicowane albo wspierane instytucjonalnie. Żaden z nich nie jest doskonale zdecentralizowany. Każdy ogranicza własność wyniku zbiorowego.

Fora specjalistyczne stanowią mniej celebrowany przykład. Wiele z nich zachowało wiedzę techniczną dzięki przeszukiwalnym wątkom, stabilnym granicom tematycznym i uczestnikom powracającym przez lata. Ich wartość pochodziła z akumulacji, a nie wiralności. Gdy takie fora zamykano albo wchłaniano w platformy ogólne, całe zasoby wiedzy milczącej stawały się trudniejsze do znalezienia. Ciągłość archiwalna jest więc funkcją dobra publicznego, a nie cechą dekoracyjną.

Społeczności pacjentów i wzajemnej pomocy pokazują inny wymiar. Anonimowość i wspólne doświadczenie mogą zmniejszać izolację i przygotowywać ludzi do interakcji z profesjonalistami. Te same przestrzenie mogą rozpowszechniać szkodliwe rady. Ich sukces zależy od jasności ról: doświadczenie przeżyte, ekspertyza medyczna, moderacja i wskazówki awaryjne nie powinny być mylone. Dobre społeczności nie eliminują niezgody; czynią źródło i status twierdzeń widocznymi.

Trwałe dobra wspólne korzystają również z ograniczonych misji. Wikipedia nie próbuje być każdą formą publikowania. Projekty Linux definiują zakres techniczny. OpenStreetMap definiuje wspólny artefakt geograficzny. Platforma próbująca zawrzeć całe życie społeczne musi pogodzić niezgodne normy i ulega pokusie rządzenia

przez zaangażowanie zamiast przez cel. Mniejsze społeczności konstytucyjne mogą być bardziej wymagające, ponieważ członkostwo wiąże się z rozpoznawalnym celem.

Przyszły Internet powinien uogólnić te lekcje przez przenośne dobra wspólne, ograniczoną opiekę, prawa członków, trwałe finansowanie i marki konstytucyjne.

Rozdział 6: Poza suwerennością platform

Alternatywą dla rządów korporacyjnych nie jest instytucjonalna pustka. Jest nią warstwowa konstytucja, w której społeczności, marki, operatorzy, kontrybutorzy i członkowie posiadają różne uprawnienia i mogą się wzajemnie kontrolować.


6.1 Społeczności policentryczne i zdecentralizowane marki

Zarządzanie policentryczne opisuje systemy z kilkoma centrami decyzyjnymi zamiast jednej suwerennej władzy. Jednostki lokalne obsługują wiedzę lokalną; jednostki szersze obsługują wspólne standardy, szkody przekraczające granice i odwołania. Badania Ostrom pokazały, że dobrami wspólnymi można zarządzać bez pełnej prywatyzacji albo jednej centralnej biurokracji, gdy reguły odpowiadają zasobowi, a uczestnicy mogą na nie wpływać (Ostrom 1990).

Społeczności online nadają się do projektowania policentrycznego, ponieważ ich cele się różnią. Grupa wsparcia medycznego, projekt oprogramowania, forum polityczne, społeczność gry i sieć naukowa nie powinny dzielić identycznych norm wypowiedzi. Uniwersalne reguły platformowe są z konieczności zgrubne. Pełna autonomia lokalna jest równie niewystarczająca, gdy nadużycia przekraczają społeczności albo gdy lokalni liderzy naruszają podstawowe prawa członków.

Zdecentralizowana marka może połączyć te poziomy. Marka utrzymuje wspólną tożsamość publiczną, minimalne standardy, reguły certyfikacji i być może skarbiec. Społeczności lokalne działają pod marką, zachowując autonomię kulturową. Dostawcy infrastruktury mogą hostować zgodne instancje. Członkowie mogą rozpoznawać wspólną obietnicę bez zależności od jednej korporacji.

Marka musi być prawnie zakotwiczona. Fundacja, spółdzielnia, trust celowy albo inny podmiot opiekuńczy może posiadać znaki towarowe i wspólne aktywa w ramach obowiązków zdefiniowanych przez konstytucję. Podmiot nie powinien mieć swobody sprzedaży marki albo zmiany misji jak zwykłej własności. Jego rola jest opiekuńcza, a nie suwerenna.



Rysunek 7. Architektura policentryczna, w której żaden aktor nie posiada każdej warstwy, a członkowie zachowują głos, wyjście i korzyść.

Licencja marki pełni funkcję podobną do umowy franczyzowej, ale zmienia kierunek kontroli. Konwencjonalna franczyza pozwala centralnemu właścicielowi licencjonować reputację operatorom. Zdecentralizowana marka licencjonuje reputację zarządzaną zbiorowo na zasadach, które wiążą również stewarda. Operatorzy uzyskują prawo używania nazwy tylko tak długo, jak spełniają przejrzyste standardy. Członkowie uzyskują prawa niezależne od dobrej woli jednego operatora.

Forkowanie pozostaje ważne, ale należy je rozumieć poprawnie. Otwarty kod pozwala na wyjście techniczne. Przenośne dane i tożsamość pozwalają na wyjście społeczne. Marka nie zawsze może podróżować z forkiem, ponieważ wspólna nazwa straciłaby znaczenie, gdyby każdy niezgodny projekt mógł się na nią powołać. Oddzielająca się społeczność powinna móc zachować swoje dane i

relacje, przyjmując nową nazwę, chyba że proces konstytucyjny przyzna dalszą certyfikację.

Konstytucjonalizm cyfrowy dostarcza słownika normatywnego: stabilne i publiczne reguły, ograniczone kompetencje, równe stosowanie, uzasadnienia, odwołanie i znaczącą zgodę (Celeste 2019; Suzor 2019; Schneider 2024). Zasady te nie wymagają kontroli państwa nad każdą społecznością. Wymagają, aby instytucje prywatne wykonujące władzę podobną do publicznej uznawały obowiązki konstytucyjne.

Federacyjne systemy społeczne dostarczają częściowych dowodów. ActivityPub pozwala niezależnym serwerom wymieniać aktywności społeczne, pokazując, że graf społeczny nie musi należeć do jednej firmy (W3C 2018). Instancje Mastodona mogą ustanawiać lokalne reguły i blokować domeny nadużywające. Model przywraca znaczący wybór administratora, ale odtwarza również znane problemy: wypalenie wolontariuszy, nierówną moderację, oligarchię na poziomie instancji i trudne odkrywanie. Federacja zmienia lokalizację władzy; nie usuwa potrzeby projektowania konstytucyjnego.

Zdecentralizowane organizacje autonomiczne dostarczają równoległego ostrzeżenia. Głosowania on-chain czynią niektóre decyzje i przepływy finansowe możliwymi do inspekcji, lecz koncentracja tokenów może przekształcić formalne uczestnictwo w plutokrację. Niska frekwencja pozwala zorganizowanym mniejszościom dominować. Smart kontrakty egzekwują to, co zakodowano, ale nie mogą ustalić, czy zakodowana reguła jest legitymizowana. Rejestr jest użyteczny do audytu i wykonania; nie zastępuje osądu instytucjonalnego.

Zdecentralizowana marka różni się od protokołu federacji i od DAO. Może używać jednego albo drugiego, ale jej rdzeniem jest obietnica poddająca się zarządzaniu. Marka określa, co zgodne społeczności i dostawcy są winni członkom, jak przyznaje się certyfikację i jak ogranicza się stewarda. Decentralizacja techniczna staje się jednym instrumentem utrzymywania tych zobowiązań.

Celem nie jest zamrożenie zarządzania. Społeczności potrzebują eksperymentowania. Należy testować nowe metody moderacji, modele ekonomiczne i systemy rekomendacji. Struktury policentryczne czynią eksperymentowanie bezpieczniejszym, ponieważ porażka może pozostać lokalna, a skuteczne praktyki mogą się rozprzestrzeniać. Błąd jednego dostawcy nie musi przededefiniować całej sieci.

6.2 Ekonomia, licencjonowanie i projektowanie odporne na przechwycenie

Trwała społeczność potrzebuje pieniędzy. Serwery, bezpieczeństwo, moderacja, praca prawna, kopie zapasowe, projektowanie i rozwój nie znikają dlatego, że oprogramowanie jest otwarte. Systemy odmawiające rozmowy o finansach zwykle zależą od ukrytej subwencji, nieopłaconej pracy albo późniejszego przejęcia korporacyjnego.

Przychody mogą pochodzić z subskrypcji, usług profesjonalnych, hostingu, rynków, certyfikacji, grantów, opłat transakcyjnych, sponsoringu albo wspólnego licencjonowania komercyjnego. Żadne źródło nie jest neutralne. Reklama faworyzuje uwagę. Kapitał wysokiego ryzyka faworyzuje szybki wzrost i wyjście. Darowizny faworyzują widoczne cele i zamożnych patronów. Opłaty mogą wykluczać użytkowników o niskich dochodach. Odporna instytucja używa kilku źródeł i poddaje każde ograniczeniom konstytucyjnym.

Licencjonowanie powinno dostosowywać dobro wspólne do gospodarki wokół niego. Licencje permisywne maksymalizują ponowne użycie, ale pozwalają firmom przechwytywać wartość bez wzajemnego wkładu. Copyleft chroni dalszą otwartość utworów pochodnych, ale nie finansuje automatycznie opiekunów ani nie dystrybuje zarządzania. Licencje source-available mogą chronić model biznesowy, przestając spełniać definicje open source. Właściwy wybór zależy od aktywa i celów społeczności.

Tabela 8. Instrumenty zdecentralizowanej marki

Element	Znaczenie lub konsekwencja projektowa
Licencja na oprogramowanie lub treść	Definiuje prawa do kopiowania, modyfikowania, ponownego używania i redystrybucji aktywa technicznego albo kulturowego.
Licencja marki	Definiuje, kto może używać wspólnej nazwy i jakie standardy jakości, interoperacyjności oraz postępowania muszą być spełnione.
Konstytucja zarządzania	Przydziela uprawnienia stanowienia reguł, moderacji, skarbca, sytuacji nadzwyczajnych, audytu i odwołań.
Umowa kontrybucyjna	Definiuje atrybucję, proveniencję, obowiązki utrzymania oraz wszelkie prawa ekonomiczne lub zarządcze uzyskane przez wkład.
Skarbiec i reguły dystrybucji	Czynią finansowanie, rezerwy, płatności dla operatorów, wynagrodzenie moderatorów i korzyści kontrybutorów przewidywalnymi.
System audytu i odwołań	Testuje zgodność, zarządza konfliktami interesów, publikuje precedensy i chroni członków przed przechwyceniem lokalnym albo centralnym.

Zdecentralizowana marka dodaje kolejny instrument. Operatorzy komercyjni mogą używać otwartego oprogramowania, płacąc za certyfikację, wsparcie, dostęp do usług wspólnych albo prawo przedstawiania się pod wspólną nazwą. Przychody mogą płynąć do opiekunów, moderatorów, infrastruktury i rezerwy. Społeczność nie musi zakazywać handlu; musi zapobiec temu, by handel po cichu stał się suwerennością.

Rozliczanie wkładów musi unikać redukcji każdego działania do wyniku tokenowego. Kod, dokumentacja, mediacja konfliktów, reakcja bezpieczeństwa, mentoring, zarządzanie, kapitał i komunikacja publiczna są różnymi formami pracy. Pojedyncza metryka zostanie ograna i uprzywilejuje to, co najłatwiejsze do policzenia. Ocena mieszana, uznanie partnerskie, zdefiniowane role i przejrzyste budżety są bardziej realistyczne niż uniwersalna tokenizacja.

Reguły przeciw przechwyceniu powinny być jawne przed konfliktem. Żaden aktor nie powinien kontrolować jednocześnie skarbcza i audytu. Dużi darczyńcy powinni ujawniać zależności. Kadencje moderatorów powinny być ograniczone. Poprawki konstytucyjne powinny wymagać więcej niż tymczasowej zwykłej większości. Operatorzy powinni przechodzić testy przenośności. Uprawnienia nadzwyczajne powinny wygasać. Umowy z podmiotami powiązanymi powinny być widoczne. Metryki koncentracji powinny być publikowane.

System musi również chronić użyteczne przywództwo. Założyciele często posiadają wizję i wiedzę, których nie da się zastąpić losowym głosowaniem. Opiekunowie potrzebują uznania. Inwestorzy potrzebują przewidywalnych praw. Celem nie jest trwała podejrzliwość wobec kompetencji. Jest nim odróżnienie przywództwa od własności przyszłości. Autorytet może być szeroki w ramach roli, a mimo to ograniczony w czasie, zakresie i przeglądzie.

Wykonalna konstytucja rozpoznaje więc co najmniej cztery elektoraty: członków dotkniętych przez system, kontrybutorów, którzy go utrzymują, operatorów ponoszących odpowiedzialność techniczną i prawną oraz stewardów odpowiedzialnych za długoterminową misję. Żadna grupa nie powinna rządzić sama. Różne decyzje mogą wymagać różnych kombinacji zgody.

Wzajemność można zaprojektować bez zakazywania sukcesu komercyjnego. Firma wdrażająca oprogramowanie społeczności na dużą skalę mogłaby wносить pieniądze, kod, pracę bezpieczeństwa albo interoperacyjność. Obowiązek może być powiązany z użyciem wspólnej marki albo usług premium sieci, a nie z każdą kopią oprogramowania. Pozwala to uniknąć udawania, że samo licencjonowanie praw autorskich może mierzyć wkład społeczny.

Skarbiec powinien finansować nieefektowną ciągłość. Audyty bezpieczeństwa, kopie zapasowe, moderacja, dokumentacja, narzędzia migracji, obrona prawna i wsparcie nowicjuszy rzadko wygrywają konkursy popularności, lecz ich brak niszczy instytucje. Budżety powinny więc rezerwować środki na utrzymanie, zamiast

dystrybuować wszystko przez głosowania projektowe albo popularność twórców.

Przejrzyste finanse ograniczają również spiski i nieformalny patronat. Członkowie powinni znać główne źródła przychodów, zależności kontraktowe i przedziały wynagrodzeń. Prywatność może chronić indywidualne płace tam, gdzie to właściwe, ale transakcje z podmiotami powiązanymi i strategiczni darczyńcy wymagają ujawnienia. Instytucja nie może wiarygodnie twierdzić, że jest zdecentralizowana, jeśli po cichu zależy od jednego patrona.

Jakość decentralizacji mierzy się ostatecznie trzema prawami. Głos oznacza zdolność wpływania na reguły i otrzymywania uzasadnień. Wyjście oznacza odejście bez utraty substancji własnej tożsamości i pracy. Korzyść oznacza sprawiedliwy udział w tworzonej wartości ekonomicznej i społecznej. System oferujący wyłącznie prawo kopiowania kodu jest technicznie otwarty i instytucjonalnie niekompletny.

Rozdział 7: Osobista AI jako rekomender użytkownika

Systemy rekomendacyjne obecnie budują prywatne modele użytkowników dla platform. Osobista AI umożliwia inny układ: model użytkownika może stać się instrumentem zarządzanym przez użytkownika, który negocjuje z platformami, a nie niewidzialnym aktywnym przez nie posiadanym.

7.1 Od ukrytych profili do trafności zarządzanej przez użytkownika


Nowoczesne platformy wnioskują zainteresowania z kliknięć, czasu przebywania, obserwowań, zakupów, lokalizacji i podobieństwa do innych użytkowników. Powstały profil jest potężny właśnie dlatego, że nie jest prostą listą zadeklarowanych preferencji. Wykrywa wzorce, których użytkownik może nie artykułować. Jednak profil jest zwykle niedostępny, trudny do skorygowania i optymalizowany w ramach funkcji celu platformy.

Osobisty agent rekomendacyjny mógłby odwrócić tę relację. Agent przechowywałby przenośną reprezentację zainteresowań użytkownika, jego zobowiązań, bieżących projektów, awersji i preferencji epistemicznych. Pobierałby elementy kandydujące z wielu źródeł, rankingował je lokalnie albo przez poufne obliczenia i wyjaśniał, dlaczego dany element został wybrany. Użytkownik mógłby kontrolować i rewidować politykę, zamiast jedynie trenować ją przez nieświadome zachowanie.

Istotnym postępem jest zarządzanie, a nie dokładność predykcji. Badania nad systemami rekomendacyjnymi od dawna pokazują, że doświadczenie użytkownika zależy od postrzeganej różnorodności, wysiłku, prywatności, użyteczności i zaufania, a nie tylko od dokładności statystycznej (Konstan and Riedl 2012; Knijnenburg et al. 2012). Wyjaśnienia mogą zwiększać akceptację, choć przejrzystość

nie tworzy automatycznie zaufania (Cramer et al. 2008). Osobisty agent może uczynić te kwestie celami pierwszej klasy.

Agent mógłby utrzymywać kilka trybów zamiast jednego trwałego profilu. Tryb zawodowy mógłby priorytetowo traktować źródła pierwotne i głębię techniczną. Tryb czasu wolnego mógłby szukać nowości. Tryb obywatelski mógłby utrzymywać różnorodność ekspozycji i oddzielać zweryfikowane reporterstwo od komentarza. Tryb regeneracji mógłby ograniczać tematy niepokojące. Użytkownik mógłby porównać tę samą pulę kandydatów według różnych polityk, zamiast akceptować jeden nieprzejrzysty porządek.



Rysunek 8. Osobista AI może przesunąć rekomendację od ukrytego profilowania platformowego ku trafności zarządzanej przez użytkownika.

Duże modele językowe są użyteczne, ponieważ potrafią przekładać intencje w języku naturalnym na kryteria rankingowe, rozumować między domenami i wyjaśniać kompromisy. Powstające badania opisują ruch od ukrytych profili platformowych ku „personalizacji podatnej na zarządzanie”, w której reprezentacje użytkownika stają się możliwe do inspekcji, przenośne i rewidowalne (Liu et al. 2026). Prace te są wczesne, ale kierunek instytucjonalny jest ważniejszy niż jakikolwiek konkretny model.

Osobisty agent mógłby również reprezentować jawną stronnicość, zamiast udawać neutralność. Użytkownik mógłby polecić mu

faworyzowanie źródeł lokalnych, unikanie promocji hazardu, poszukiwanie politycznie różnorodnych dowodów albo wspieranie społeczności zawodowej. Agent powinien deklarować te zobowiązania. Ukryta stronniczość jest niebezpieczna, ponieważ maskuje się jako trafność; stronniczość zadeklarowana staje się polityką, którą można ocenić.

Relacje handlowe uległyby zmianie. Platforma mogłaby oferować elementy kandydujące i ujawniać sponsoring, cenę, proveniencję i warunki dostępu. Osobisty agent decydowałby, czy element pasuje do polityki użytkownika. Reklama stałaby się ofertą dla agenta, a nie ukrytą optymalizacją strumienia treści. Platformy nadal konkurowałyby o uwagę, ale nie kontrolowałyby już wyłącznie modelu używanego do jej przydzielania.

Praktyczny pipeline zawierałby odrębne etapy. Źródła publikują elementy kandydujące i metadane. Usługi wyszukiwania wskazują szeroki zbiór istotny dla bieżącego kontekstu użytkownika. Osobisty agent stosuje polityki dotyczące jakości, różnorodności, czasu, ryzyka i sponsoringu. Końcowa warstwa prezentacji wyjaśnia wybory i zachowuje możliwość kontroli pominiętych alternatyw. Informacja zwrotna aktualizuje model lokalny tylko według reguł wybranych przez użytkownika.

To rozdzielenie ma znaczenie, ponieważ odkrywanie i osąd są różnymi funkcjami. Globalny dostawca wyszukiwania może być doskonały w znajdowaniu kandydatów, a nieodpowiedni do decydowania o priorytetach użytkownika. Kurator społecznościowy może identyfikować zaufane źródła, nie znając kontekstu osobistego. Agent lokalny może łączyć te wejścia bez potrzeby crawlowania całego Internetu albo posiadania każdego źródła.

Agent może również negocjować. Kupiec mógłby oferować dane o cenie, dostawie, gwarancji i prowizji w formie czytelnej dla maszyny. Źródło informacyjne mogłoby ujawniać autorstwo, politykę korekt, koszt dostępu i proveniencję. Agent może odrzucić oferty ukrywające sponsoring albo zażądać mniej inwazyjnej wersji. Rekomendacja staje się wymianą zadeklarowanych warunków, a nie jednostronnym targetowaniem behawioralnym.

Reprezentacja użytkownika powinna podróżować niezależnie od modelu. Osoba może zastąpić model językowy, zachowując ustrukturyzowaną politykę i historię. Inaczej dostawca modelu staje się nowym suwerenem platformowym. Otwarte schematy, szyfrowane magazyny osobiste i eksportowalne przypadki ewaluacyjne pozwalają użytkownikowi porównywać agentów i migrować bez odbudowywania tożsamości z surowych kliknięć.

Interoperacyjność jest niezbędna. Strumienie kandydatów potrzebują standardowych metadanych, proveniencji, ujawnienia sponsoringu, identyfikatorów treści i informacji o prawach. Społeczności mogłyby publikować certyfikowane polityki rankingowe. Niezależni deweloperzy mogliby dostarczać rekomendery bez hostowania bazowej sieci społecznej. Rekomendacja stałaby się konkurencyjną warstwą, a nie nierozdzielną funkcją platformy.

7.2 Prywatność, stronniczość, pluralizm i ryzyko osobistej komory echa

Osobisty agent wie więcej niż zwykły rekomender, ponieważ może łączyć domeny. To jest jego wartość i jego niebezpieczeństwo. Profil międzydomenowy może ujawniać zdrowie, relacje, finanse, przekonania polityczne i przyszłe zamiary. Przeniesienie profilu z platformy do nominalnie osobistej usługi chmurowej nie tworzy prywatności, jeśli dostawca usługi może go kontrolować.

Preferowana architektura utrzymuje wrażliwą pamięć na urządzeniach kontrolowanych przez użytkownika albo w środowiskach poufnych z silnymi gwarancjami dostępu. Modele chmurowe mogą przetwarzać wybrany, zminimalizowany kontekst. Badania hybrydowe sugerują, że użyteczność rekomendacji można czasem zachować, gdy cechy wrażliwe pozostają lokalne, choć wyniki zależą od domeny i modelu zagrożeń (Khezresmaeilzadeh et al. 2025). Prywatność trzeba oceniać wobec rzeczywistych przepływów danych, a nie brandingu.

Pamięć agenta powinna być na tyle ustrukturyzowana, by dało się ją kontrolować. Profil prozatorski może być ekspresyjny, ale trudny do

audytu. Użyteczny system odróżnia zachowanie zaobserwowane, preferencje zadeklarowane przez użytkownika, hipotezy wywnioskowane, kontekst tymczasowy i twarde ograniczenia. Każdy element powinien mieć proveniencję i regułę wygaśnięcia. Użytkownik powinien móc zapytać, dlaczego agent w coś wierzy, i usunąć dowód albo wniosek.

Personalizacja może nasilać samopotwierdzenie. Model trenowany do zadowalania może nauczyć się, że uspokajanie daje pozytywną informację zwrotną. Może stać się pochlebcą chroniącym tożsamość przed niewygodnymi dowodami. Badania nad rekomenderami wrażliwymi na różnorodność argumentują, że różnorodność ekspozycji może być celem projektowym, a nie przypadkowym produktem ubocznym (Helberger, Karppinen, and D'Acunto 2018). Osobisty agent powinien więc wspierać konfigurowalną eksplorację, a nie tylko podobieństwo.

Tabela 9. Zdolności i zabezpieczenia osobistego rekomendera

Element	Znaczenie lub konsekwencja projektowa
Edytowalny model użytkownika	Użytkownik może kontrolować kategorie, korygować fałszywe wnioski, definiować cele tymczasowe i resetować model.
Prywatna i przenośna pamięć	Wrażliwa historia pozostaje lokalna albo silnie chroniona i może przenosić się niezależnie od konta platformy.
Wyjaśnienie i alternatywy	Agent stwierdza, dlaczego element się pojawił, co wykluczono i który alternatywny cel rankingowy zmieniłby wynik.
Ograniczenia pluralizmu	Różnorodność, nowość, niezgoda, jakość źródeł i alokacja czasu są jawnymi politykami, a nie przypadkowymi skutkami ubocznymi.
Zapora handlowa	Płatności, relacje afiliacyjne i bodźce dostawców są ujawniane i nie mogą po cichu uchylać polityki użytkownika.
Obrony antagonistyczne	Prompt injection, zatrute źródła, złośliwe pluginy i przejęte modele są ograniczane przez proveniencję, zdolności i audyt.

Pluralizm nie oznacza losowej opozycji. Agent powinien identyfikować wiarygodną niezgodę, odróżniać konsensus ekspercki od równowagi partyjnej i ujawniać niepewność. Może utrzymywać budżet na nieznane źródła, regułę przeciw powtarzanemu oburzeniu albo wymóg, by twierdzenia o dużym wpływie zawierały dowody pierwotne. Polityki te powinny być wybierane i widoczne, a nie potajemnie narzucane przez platformę albo dostawcę modelu.

Bezpieczeństwo jest kolejnym problemem. Treść może zawierać instrukcje skierowane do agenta, a nie do użytkownika. Złośliwa strona może próbować wydobyć pamięć, zmienić politykę rankingową albo wywołać działania zewnętrzne. Rekomendacja potrzebuje zatem izolacji między niezaufaną treścią a uprzywilejowanym stanem agenta. Pobieranie, streszczanie i działanie powinny odbywać się w ramach zdolności z jawnymi granicami danych.

Dostawcy modeli również mogą manipulować. Osobisty agent zbudowany na modelu zdalnym może dziedziczyć ukryte prompty systemowe, priorytety handlowe, polityki cenzury albo podatności. Użytkownik potrzebuje wymienialnych modeli i zestawów testowych porównujących zachowanie między dostawcami. Lokalne mniejsze modele mogą obsługiwać rutynowe filtrowanie, podczas gdy silniejsze modele zdalne są wywoływane dla trudnych zadań przy ograniczonym ujawnieniu.

Odpowiedzialność powinna pozostać przy instytucji człowiek-agent, a nie przy antropomorficznej fikcji. Agent nie jest suwerennym przyjacielem. Jest systemem delegowanym, którego operator, dostawca modelu i kanał aktualizacji mogą zostać zidentyfikowani. Gdy działa w społeczności, powinien przedstawiać swój status automatyzacji, zakres uprawnień i odpowiedzialnego mocodawcę.

Audyt musi obejmować wyniki, a nie tylko wyjaśnienia. Agent może opisywać politykę różnorodności, a jednocześnie wielokrotnie wybierać ten sam klaster ideologiczny. Użytkownicy i niezależni ewaluatorzy powinni móc uruchamiać kontrolowane zestawy testowe, kontrolować rozkłady ekspozycji i porównywać zachowanie

w czasie. Konstytucja rekomendacji jest wiarygodna tylko wtedy, gdy jej skutki można mierzyć.

Różni użytkownicy będą chcieli różnych stopni kontroli. Niektórzy będą edytować polityki bezpośrednio. Inni wybiorą certyfikowane profile utrzymywane przez zaufane społeczności, dziennikarzy, organy zawodowe albo grupy społeczeństwa obywatelskiego. Rynek polityk rekomendacyjnych może wspierać pluralizm, pod warunkiem że użytkownicy widzą finansowanie, cele i dowody. Alternatywą dla jednego algorytmu platformowego nie jest to, że każda osoba staje się inżynierem uczenia maszynowego.

Autonomia poznawcza wymaga również prawa do braku personalizacji. Użytkownik może wybrać wspólny strumień interesu publicznego, strumień chronologiczny albo próbkę losową. Personalizacja powinna być jedną soczewką pośród kilku. Systemy, które czynią dostęp niepersonalizowany celowo gorszym, zachowują stary przymus za nowym interfejsem.

Najlepszy osobisty rekomender nie maksymalizowałby satysfakcji. Pomagałby użytkownikowi zarządzać uwagą zgodnie z wybranymi wartościami, zachowując możliwość rewizji. Czasem zaskakiwałby, czasem chronił, czasem kwestionował i zawsze wyjaśniał, którą politykę stosuje. Użytkownik nie byłby już jedynie obiektem personalizacji, lecz jej autorem konstytucyjnym.

Rozdział 8: Odbudowa komunikacji od warstwy protokołów

Internet platformowy zakłada, że usługi pozostają globalnie osiągalne, a następnie filtruje nadużycia po kontakcie. Inna architektura może uczynić relacje, zdolności i prywatną negocjację domyślnością, zachowując znajome doświadczenia, takie jak adresy, skrzynki odbiorcze, grupy i połączenia.

8.1 WebRTC, adresowanie podobne do e-maila, DID-y i połączenia bramkowane zaufaniem

E-mail odniósł sukces częściowo dlatego, że jego model adresowania jest zrozumiały dla ludzi. Nazwa lokalna i domena identyfikują trasę bez wymagania, aby obaj uczestnicy używali jednego dostawcy. Każdy następca powinien zachować tę przewagę społeczną. Ludzie potrzebują identyfikatorów, które można wypowiedzieć, wydrukować, zapamiętać, delegować przez organizacje i przenosić między dostawcami usług.


Identyfikator techniczny stojący za adresem nie musi być identyczny z nazwą czytelną dla człowieka. Adres oparty na domenie mógłby rozwiązywać się do zdecentralizowanego identyfikatora, kluczy publicznych, preferencji usługowych i punktów końcowych wprowadzenia. W3C DID Core definiuje identyfikatory, których kontrolerzy mogą dowodzić kontroli metodami kryptograficznymi bez trwałej zależności od jednego dostawcy tożsamości (W3C 2022). Prace DID 1.1 z 2026 roku kontynuują tę architekturę, podczas gdy Verifiable Credentials 2.0 zapewnia standardową formę twierdzeń wystawianych przez strony trzecie i weryfikowalnych maszynowo (W3C 2025b; W3C 2026).

DID-y nie tworzą zaufania. Ustanawiają kontrolę nad identyfikatorem i zapewniają mechanizmy weryfikacji oraz

odkrywania usług. Oszust może kontrolować ważny DID. Poświadczenie jest znaczące tylko dlatego, że weryfikator ufa wystawcy, a twierdzenie jest istotne. Architektura musi więc łączyć weryfikację kryptograficzną z kontekstem instytucjonalnym, historią relacji i jawną akceptacją.

Pierwszy kontakt nie powinien wymagać wystawienia trwałej usługi osobistej na arbitralny ruch. Ograniczona usługa wprowadzenia może przyjmować małe, ograniczone żądania. Nadawca może przedstawić polecenie, poświadczenie społeczności, zwrotną kaucję, dowód wcześniejszej relacji albo limitowane anonimowe żądanie. Agent odbiorcy ocenia żądanie bez ujawniania prywatnych punktów końcowych albo pełnej tożsamości.

Jeśli zostanie zaakceptowane, strony ustanawiają zdolność: odwoływalne upoważnienie do komunikacji na określonych warunkach. Zdolność może ograniczać częstotliwość wiadomości, typ danych, czas trwania, automatyzację albo dalsze udostępnianie. Identyfikatory parowe mogą zapobiegać trywialnemu korelowaniu tej samej osoby przez niepowiązane usługi. Odwołanie może zakończyć jedną relację bez wymuszania globalnej zmiany tożsamości.



Rysunek 9. Stos komunikacyjny bramkowany zaufaniem, łączący czytelne adresowanie, przenośną kontrolę, selektywne poświadczenia, ograniczone wprowadzenie i szyfrowane sesje.

WebRTC jest wiarygodnym transportem dla sesji interaktywnych, ponieważ obsługuje audio, wideo i ogólne dane między punktami końcowymi. Kanały danych WebRTC używają SCTP nad zabezpieczonym transportem, podczas gdy ICE odkrywa możliwe ścieżki przez NAT-y i może awaryjnie korzystać z przekaźników TURN (IETF 2018; IETF 2021a; IETF 2021b; W3C 2025a). Przeglądarka, agent desktopowy albo agent mobilny mogą więc ustanowić bogatą komunikację bez wymyślania przez każdą aplikację własnościowego stosu medialnego.

WebRTC celowo pozostawia sygnalizację aplikacji. Jest to ograniczenie i szansa. Warstwa wprowadzenia i tożsamości może wymieniać opisy sesji oraz informacje o łączności po kontrolach polityki. Transport nie musi wiedzieć, czy uczestnicy są ludźmi, agentami czy zespołami mieszanymi. Przenosi jedynie uwierzytelnioną sesję, gdy wyższe warstwy ustanowią pozwolenie.

Komunikacja asynchroniczna wymaga czegoś więcej niż WebRTC, ponieważ uczestnicy mogą być offline. Skrzynka albo przekaźnik mogą przechowywać zaszyfrowane koperty adresowane do zdolności, a nie do nieograniczonej publicznej skrzynki odbiorczej. Kilku dostawców mogłoby oferować usługę store-and-forward bez możliwości czytania treści. Użytkownicy mogliby zmieniać dostawców bez zmiany tożsamości. Znajoma skrzynka odbiorcza pozostaje, ale niezamówione globalne doręczenie nie jest już domyślne.

Sekwencja połączenia może więc być jawna. Adres czytelny dla człowieka rozwiązuje się do punktu końcowego wprowadzenia i aktualnego materiału weryfikacyjnego. Agent nadawcy przedstawia minimalne żądanie i wszelkie istotne poświadczenia. Agent odbiorcy ocenia politykę i może poprosić o dodatkowy dowód. Akceptacja tworzy zdolność o określonym zakresie i wymienia dane sygnalizacyjne. ICE następnie próbuje ścieżki bezpośredniej albo przekazywanej, a strony ustanawiają kanały szyfrowane. Każdy etap ujawnia tylko informacje potrzebne do następnego.

Identyfikatory parowe ograniczają korelację. Użytkownik może przedstawiać inny identyfikator lekarzowi, pracodawcy, członkowi

rodziny i społeczności publicznej, zachowując odzyskiwanie i kontrolę przez jeden portfel albo agenta. Poświadczenia można ujawniać selektywnie, tak aby weryfikator poznał istotny fakt bez uzyskania pełnego dokumentu bazowego. Korzyść prywatności zależy od implementacji; powtarzane metadane albo wspólny resolver nadal mogą łączyć relacje.

Adresowanie czytelne dla człowieka potrzebuje zarządzania. Domeny są wygodne, ponieważ organizacje mogą delegować nazwy, ale utrata domeny albo przymus dostawcy mogą zakłócić tożsamość. Odporny projekt może powiązać czytelny adres z przenośnymi identyfikatorami kryptograficznymi i wspierać dowody ciągłości, gdy domeny się zmieniają. Użytkownicy nie powinni być zmuszani do wyboru między zapamiętywalnymi nazwami a samokontrolowanymi kluczami.

Komunikacja grupowa wymaga bezpiecznego stanu członkostwa i aktualizacji kluczy. Messaging Layer Security zaprojektowano dla grup asynchronicznych od małych rozmów po duże grupy, z forward secrecy i post-compromise security (IETF 2023). Może uzupełniać WebRTC, a nie go zastępować: MLS chroni wiadomości grupowe, podczas gdy WebRTC może przenosić sesje na żywo i kanały danych.

8.2 Mniejsza powierzchnia ataku dla ludzi i agentów

Główną korzyścią bezpieczeństwa architektury bramkowanej zaufaniem jest ograniczona ekspozycja. Urządzenie osobiste albo agent nie muszą przyjmować arbitralnych połączeń przychodzących z całego Internetu. Usługi publiczne pozostają publiczne tam, gdzie to konieczne, ale komunikacja prywatna zaczyna się przez wąskie punkty wprowadzenia z ostrymi limitami zasobów. Większość stanu wysokiej wartości pozostaje za zdolnościami utworzonymi po zgodzie.

Nie eliminuje to ataków odmowy usługi. Usługi wprowadzenia, serwery sygnalizacyjne, resolvery DID, przekaźniki TURN i skrzynki pozostają celami. Atakujący mogą zalewać weryfikację poświadczeń albo uzyskiwać prawowite poświadczenia. Architektura zmienia

ekonomię, czyniąc kosztowne usługi niedostępnymi przed przejściem tanich kontroli, rozpraszając dostawców i pozwalając społecznościom współdzielić wiedzę o nadużyciach bez współdzielenia wszystkich danych użytkowników.

Prywatność zależy również od wyboru przekąźnika. Bezpośrednie połączenia peer-to-peer mogą ujawniać adresy sieciowe korespondentom. Przekąźniki TURN mogą je ukrywać kosztem infrastruktury i koncentracji metadanych. Osobisty agent powinien wybierać ścieżki bezpośrednie albo przekazywane zgodnie z relacją i ryzykiem. Najszybsza trasa nie zawsze jest najbardziej prywatna.

Tabela 10. Składniki mniejszej i bardziej prywatnej powierzchni komunikacyjnej

Element	Znaczenie lub konsekwencja projektowa
Czytelny adres	Zapewnia użyteczność i odkrywanie podobne do e-maila, pozostając odłączalnym od operatora aktualnie obsługującego użytkownika.
DID albo równoważny identyfikator kontroli	Zapewnia przenośną kontrolę kryptograficzną; sam nie ustanawia tożsamości, zaufania ani reputacji.
Verifiable credential	Pozwala selektywnie dowodzić roli, członkostwa, rekomendacji albo relacji; twierdzenia pozostają tak wiarygodne, jak ich wystawcy.
Usługa wprowadzenia i zdolności	Wystawia wąską powierzchnię żądań i decyduje, kto może sygnalizować, wysyłać, wywoływać, przekazywać albo tworzyć trwałą relację.
ICE i WebRTC	Negocjują interaktywne ścieżki dla mediów albo danych, używając łączności bezpośredniej tam, gdzie to możliwe, i przekąźników tam, gdzie konieczne.
Ograniczony przekąźnik	Zachowuje niezawodność i zachowanie asynchroniczne bez stawiania się trwałym właścicielem relacji albo treści jawnej.
MLS albo równoważne bezpieczeństwo grupowe	Chroni ewoluujące grupy przez forward secrecy i post-compromise security; zarządzanie i doręczanie pozostają kwestiami aplikacji.
Silnik polityki agenta osobistego	Stosuje lokalną zgodę, prywatność, limity, proveniencję, delegację i reguły odzyskiwania przed wystawieniem narzędzi albo uwagi.

Odzyskiwanie kluczy jest dużym wyzwaniem praktycznym. Samokontrolowane identyfikatory są kruche, jeśli utrata urządzenia niszczy tożsamość. Odzyskiwanie społeczne, wiele urządzeń, opiekunowie instytucjonalni i klucze wspierane sprzętowo mogą pomóc, ale każde wprowadza zaufanie. Użyteczny system potrzebuje przejrzystych polityk odzyskiwania i możliwości rotacji kluczy bez utraty relacji. DID-y wspierają indirection między identyfikatorem a aktualnymi metodami weryfikacji, ale zarządzanie specyficzne dla metody pozostaje krytyczne.

Agent staje się centrum operacyjnym. Filtruje wprowadzenia, weryfikuje poświadczenia, wybiera tryby prywatności, zarządza zdolnościami, przechowuje historię relacji i tłumaczy między protokołami. Może również streszczać wiadomości i negocjować terminy spotkań. Zmniejsza to obciążenie poznawcze, ale kompromitacja agenta staje się poważniejsza niż kompromitacja konwencjonalnej aplikacji.

Architektura agenta powinna więc rozdzielać pamięć, komunikację i działanie. Odczytanie wiadomości nie powinno automatycznie przyznawać dostępu do pamięci prywatnej. Streszczacz nie powinien posiadać uprawnień płatniczych. Moduł rekomendacji nie powinien modyfikować kluczy tożsamości. Wewnętrzny projekt oparty na zdolnościach może ograniczać szkody, gdy jeden komponent zostanie zmanipulowany. Aktualizacje powinny być podpisane, audytowalne i odwracalne.

Społeczności mogą dodawać zaufanie instytucjonalne. Marka naukowa może wydawać poświadczenia recenzentom. Społeczność pacjentów może wydawać dowody członkostwa bez publicznego ujawniania diagnoz. Rynek może wymagać poświadczenia escrow przed kontaktem wysokiej wartości. Grupa polityczna może dopuszczać członkostwo pseudonimowe, ograniczając konta automatyczne. Te same protokoły wspierają różne konstytucje.

Architektura zmienia również odkrywanie. Zamiast jednego globalnego strumienia treści ludzie mogą odkrywać społeczności przez katalogi, zaufane rekomendacje, dostawców wyszukiwania albo agentów osobistych. Treść publiczna może pozostać

indeksowalna, gdy autorzy tak wybiorą. Przestrzenie prywatne mogą ujawniać tylko opisy i procedury przyjęcia. Celem nie jest ukrycie Internetu, lecz zaprzestanie traktowania uniwersalnej ekspozycji jako domyślnego warunku uczestnictwa.

Przejście mogłoby być stopniowe, ponieważ doświadczenie użytkownika może pozostać znajome. Aplikacja nadal może wyglądać jak e-mail, komunikator, forum albo współdzielona przestrzeń pracy. Pod spodem tożsamość jest przenośna, relacje są oparte na zdolnościach, sesje używają otwartych transportów, rekomendacja jest osobista, a dostawcy są wymienialni. Bramki kompatybilności mogą łączyć dziedziczony e-mail i konta platformowe, jednocześnie czyniąc widocznym ich słabszy model zaufania.

Metadane pozostają poważnym ryzykiem. Nawet gdy treść jest szyfrowana, przekazniki mogą obserwować timing, wolumen, kontrahentów i wzorce urzędzeń. Identyfikatory parowe i rotacja przekazników ograniczają pewne korelacje, ale zwiększają złożoność i mogą osłabić reakcję na nadużycia. Społeczności muszą decydować, które metadane zachowują dla bezpieczeństwa, jak długo je zachowują i według jakiej procedury można uzyskać do nich dostęp. „Całkowita prywatność” powinna oznaczać silną, możliwą do inspekcji minimalizację i kontrolę użytkownika, a nie niemożliwe twierdzenie, że żadne metadane nie istnieją.

Dostępność tworzy kolejny kompromis. Systemy peer-to-peer zawodzą, gdy urządzenia są offline, ograniczone baterią albo za restrykcyjnymi sieciami. Przekazniki i skrzynki zapewniają niezawodność, ale popularni dostawcy mogą ponownie się skoncentrować. Testy przenośności, interoperacyjne formaty szyfrowania i replikacja wielodostawcza mogą powstrzymać dostępność przed stanieniem się suwerennością.

Ścieżka przejścia powinna zacząć się od ograniczonych społeczności i przepływów agent-agent, a nie od próby zastąpienia publicznej sieci Web. Sieci zawodowe, współprace badawcze, rodziny, usługi regulowane i prywatne rynki mają jasne granice relacji i wysoką wartość prywatności. Bramki mogą zachować dostęp do e-maila i

sieci Web, podczas gdy nowe połączenia używają zdolności i przenośnej tożsamości. Udań wzorce mogą następnie się rozszerzać. Propozycja ta nie jest gotowym zestawem protokołów. Jest kierunkiem architektonicznym zbudowanym z dojrzałych komponentów i nierozwiązanych badań. WebRTC dostarcza transport interaktywny, ale nie semantykę społeczną. DID-y i poświadczenia dostarczają weryfikowalną kontrolę i twierdzenia, ale nie zaufanie. MLS dostarcza zarządzanie kluczami grupowymi, ale nie zarządzanie społeczne. Osobista AI dostarcza automatyzację polityki, ale wprowadza potężną nową powierzchnię ataku. Brakującym osiągnięciem jest ich integracja w instytucjonalnie spójny system.

Pierwotny Internet odniósł sukces, ponieważ oddzielił aplikacje od własności sieci. Następny Internet może odnieść sukces, oddzielając społeczności i agentów osobistych od własności platform. Otwarte protokoły powinny przenosić dane; konstytucje powinny zarządzać społecznościami; agenci osobiści powinni reprezentować użytkowników; zdecentralizowane marki powinny utrzymywać wspólne obietnice; dostawcy powinni konkurować w obsłudze wymieniających usług.

Internet pozostanie konfliktowy, ponieważ ludzie pozostają konfliktowi. Będzie zawierał handel, ideologię, manipulację, troskę, naukę, rozrywkę i oszustwo. Lepsza architektura nie obiecuje czystości. Utrudnia jakiegokolwiek jednej korporacji, grupie moderatorów, automatycznemu rojowi albo dostawcy modelu przekształcenie tymczasowej przewagi w nieodwracalną kontrolę. To realistyczny standard postępu: nie sieć bez władzy, lecz sieć, w której władza musi nieustannie uzasadniać samą siebie.

Bibliografia

- Abbate, Janet. 1999. *Inventing the Internet*. Cambridge, MA: MIT Press.
- Bail, Christopher A., Lisa P. Argyle, Taylor W. Brown, John P. Bumpus, Haohan Chen, M. B. Fallin Hunzaker, Jaemin Lee, Marcus Mann, Friedolin Merhout, and Alexander Volfovsky. 2018. "Exposure to Opposing Views on Social Media Can Increase Political Polarization." *Proceedings of the National Academy of Sciences* 115 (37): 9216–9221. <https://doi.org/10.1073/pnas.1804840115>.
- Benkler, Yochai, Robert Faris, and Hal Roberts. 2018. *Network Propaganda: Manipulation, Disinformation, and Radicalization in American Politics*. New York: Oxford University Press. <https://doi.org/10.1093/oso/9780190923624.001.0001>.
- Brady, William J., Julian A. Wills, John T. Jost, Joshua A. Tucker, and Jay J. Van Bavel. 2017. "Emotion Shapes the Diffusion of Moralized Content in Social Networks." *Proceedings of the National Academy of Sciences* 114 (28): 7313–7318. <https://doi.org/10.1073/pnas.1618923114>.
- Buckels, Erin E., Paul D. Trapnell, and Delroy L. Paulhus. 2014. "Trolls Just Want to Have Fun." *Personality and Individual Differences* 67: 97–102. <https://doi.org/10.1016/j.paid.2014.01.016>.
- Burke, Robin, Nasim Sonboli, and Aldo Ordonez-Gauger. 2018. "Balanced Neighborhoods for Multi-Sided Fairness in Recommendation." In *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, 202–214. PMLR 81.
- C2PA. 2026. *C2PA Technical Specification, Version 2.4*. Coalition for Content Provenance and Authenticity. <https://c2pa.org/specifications/>.
- Celeste, Edoardo. 2019. "Digital Constitutionalism: A New Systematic Theorisation." *International Review of Law, Computers & Technology* 33 (1): 76–99. <https://doi.org/10.1080/13600869.2019.1562604>.
- CERN. 1993. "Statement Concerning CERN W3 Software Release into Public Domain." 30 April 1993. <https://cds.cern.ch/record/1164399>.
- Chan, Man-pui Sally, Christopher R. Jones, Kathleen Hall Jamieson, and Dolores Albarracín. 2017. "Debunking: A Meta-Analysis of the Psychological Efficacy

- of Messages Countering Misinformation.” *Psychological Science* 28 (11): 1531–1546. <https://doi.org/10.1177/0956797617714579>.
- Chandrasekharan, Eshwar, Umashanthi Pavalanathan, Anirudh Srinivasan, Adam Glynn, Jacob Eisenstein, and Eric Gilbert. 2017. “You Can’t Stay Here: The Efficacy of Reddit’s 2015 Ban Examined through Hate Speech.” *Proceedings of the ACM on Human-Computer Interaction* 1 (CSCW), Article 31. <https://doi.org/10.1145/3134666>.
- Cheng, Justin, Michael Bernstein, Cristian Danescu-Niculescu-Mizil, and Jure Leskovec. 2017. “Anyone Can Become a Troll: Causes of Trolling Behavior in Online Discussions.” In *Proceedings of the 2017 ACM Conference on Computer Supported Cooperative Work and Social Computing*, 1217–1230. <https://doi.org/10.1145/2998181.2998213>.
- Cinelli, Matteo, Gianmarco De Francisci Morales, Alessandro Galeazzi, Walter Quattrociocchi, and Michele Starnini. 2021. “The Echo Chamber Effect on Social Media.” *Proceedings of the National Academy of Sciences* 118 (9): e2023301118. <https://doi.org/10.1073/pnas.2023301118>.
- Clark, David D. 1988. “The Design Philosophy of the DARPA Internet Protocols.” *ACM SIGCOMM Computer Communication Review* 18 (4): 106–114. <https://doi.org/10.1145/52324.52336>.
- Cramer, Henriette, Vanessa Evers, Satyan Ramlal, Maarten van Someren, Lloyd Rutledge, Natalia Stash, Lora Aroyo, and Bob Wieringa. 2008. “The Effects of Transparency on Trust in and Acceptance of a Content-Based Art Recommender.” *User Modeling and User-Adapted Interaction* 18: 455–496. <https://doi.org/10.1007/s11257-008-9051-3>.
- Dorkenwald, Sven, et al. 2022. “FlyWire: Online Community for Whole-Brain Connectomics.” *Nature Methods* 19: 119–128. <https://doi.org/10.1038/s41592-021-01330-0>.
- European Union. 2022. “Regulation (EU) 2022/2065 on a Single Market for Digital Services.” *Official Journal of the European Union* L 277: 1–102.
- Giles, Jim. 2005. “Internet Encyclopaedias Go Head to Head.” *Nature* 438: 900–901. <https://doi.org/10.1038/438900a>.
- Gillespie, Tarleton. 2018. *Custodians of the Internet: Platforms, Content Moderation, and the Hidden Decisions That Shape Social Media*. New Haven, CT: Yale University Press.

- Grinberg, Nir; Kenneth Joseph, Lisa Friedland, Briony Swire-Thompson, and David Lazer. 2019. "Fake News on Twitter during the 2016 U.S. Presidential Election." *Science* 363 (6425): 374–378. <https://doi.org/10.1126/science.aau2706>.
- Guess, Andrew M., Brendan Nyhan, and Jason Reifler. 2020. "Exposure to Untrustworthy Websites in the 2016 US Election." *Nature Human Behaviour* 4: 472–480. <https://doi.org/10.1038/s41562-020-0833-x>.
- Halfaker, Aaron, R. Stuart Geiger, Jonathan T. Morgan, and John Riedl. 2013. "The Rise and Decline of an Open Collaboration System: How Wikipedia's Reaction to Popularity Is Causing Its Decline." *American Behavioral Scientist* 57 (5): 664–688. <https://doi.org/10.1177/0002764212469365>.
- Helberger, Natali, Kari Karppinen, and Lucia D'Acunto. 2018. "Exposure Diversity as a Design Principle for Recommender Systems." *Information, Communication & Society* 21 (2): 191–207. <https://doi.org/10.1080/1369118X.2016.1271900>.
- Helmond, Anne. 2015. "The Platformization of the Web: Making Web Data Platform Ready." *Social Media + Society* 1 (2). <https://doi.org/10.1177/2056305115603080>.
- Herfort, Benjamin, Sven Lautenbach, João Porto de Albuquerque, Jeff Anderson, and Alexander Zipf. 2021. "The Evolution of Humanitarian Mapping within the OpenStreetMap Community." *Scientific Reports* 11: 3037. <https://doi.org/10.1038/s41598-021-82404-z>.
- Hoffmann, Manuel, Frank Nagle, and Yanuo Zhou. 2024. "The Value of Open Source Software." *Harvard Business School Working Paper* 24-038. <https://doi.org/10.2139/ssrn.4693148>.
- IETF. 2018. *Interactive Connectivity Establishment (ICE): A Protocol for Network Address Translator Traversal*. RFC 8445. <https://doi.org/10.17487/RFC8445>.
- IETF. 2021a. *Overview: Real-Time Protocols for Browser-Based Applications*. RFC 8825. <https://doi.org/10.17487/RFC8825>.
- IETF. 2021b. *WebRTC Data Channels*. RFC 8831. <https://doi.org/10.17487/RFC8831>.
- IETF. 2023. *The Messaging Layer Security (MLS) Protocol*. RFC 9420. <https://doi.org/10.17487/RFC9420>.

- IETF. 2025. *The Messaging Layer Security (MLS) Architecture*. RFC 9750. <https://doi.org/10.17487/RFC9750>.
- Introna, Lucas D., and Helen Nissenbaum. 2000. "Shaping the Web: Why the Politics of Search Engines Matters." *The Information Society* 16 (3): 169–185. <https://doi.org/10.1080/01972240050133634>.
- Jhaver; Shagun, Amy Bruckman, and Eric Gilbert. 2019. "Does Transparency in Moderation Really Matter? User Behavior after Content Removal Explanations on Reddit." *Proceedings of the ACM on Human-Computer Interaction* 3 (CSCW), Article 150. <https://doi.org/10.1145/3359252>.
- Kalla, Joshua L., and David E. Broockman. 2018. "The Minimal Persuasive Effects of Campaign Contact in General Elections: Evidence from 49 Field Experiments." *American Political Science Review* 112 (1): 148–166. <https://doi.org/10.1017/S0003055417000363>.
- Kanich, Chris, Christian Kreibich, Kirill Levchenko, Brandon Enright, Geoffrey M. Voelker, Vern Paxson, and Stefan Savage. 2009. "Spamalytics: An Empirical Analysis of Spam Marketing Conversion." *Communications of the ACM* 52 (9): 99–107. <https://doi.org/10.1145/1562164.1562190>.
- Khezresmaeilzadeh, Tina, Jiang Zhang, Dimitrios Andreadis, and Konstantinos Psounis. 2025. "Preserving Privacy and Utility in LLM-Based Product Recommendations." arXiv:2505.00951.
- Knijnenburg, Bart P., Martijn C. Willemsen, Zeno Gantner, Hakan Soncu, and Chris Newell. 2012. "Explaining the User Experience of Recommender Systems." *User Modeling and User-Adapted Interaction* 22: 441–504. <https://doi.org/10.1007/s11257-011-9118-4>.
- Konstan, Joseph A., and John Riedl. 2012. "Recommender Systems: From Algorithms to User Experience." *User Modeling and User-Adapted Interaction* 22 (1–2): 101–123. <https://doi.org/10.1007/s11257-011-9112-x>.
- Leiner, Barry M., Vinton G. Cerf, David D. Clark, Robert E. Kahn, Leonard Kleinrock, Daniel C. Lynch, Jon Postel, Larry G. Roberts, and Stephen Wolff. 1997. "A Brief History of the Internet." Internet Society, subsequently updated.
- Liu, Jiahao, Mingzhe Han, Guanming Liu, Weihang Wang, Dongsheng Li, Hansu Gu, Peng Zhang, Tun Lu, and Ning Gu. 2026. "From Hidden Profiles to Governable Personalization: Recommender Systems in the Age of LLM Agents." arXiv:2604.20065.

- Lorenz-Spreen, Philipp, Bjarke Mørch Mønsted, Philipp Hövel, and Sune Lehmann. 2019. "Accelerating Dynamics of Collective Attention." *Nature Communications* 10: 1759. <https://doi.org/10.1038/s41467-019-09311-w>.
- Matias, J. Nathan. 2019. "The Civic Labor of Volunteer Moderators Online." *Social Media + Society* 5 (2). <https://doi.org/10.1177/2056305119836778>.
- Matz, Sandra C., Michal Kosinski, Gideon Nave, and David J. Stillwell. 2017. "Psychological Targeting as an Effective Approach to Digital Mass Persuasion." *Proceedings of the National Academy of Sciences* 114 (48): 12714–12719. <https://doi.org/10.1073/pnas.1710966114>.
- O'Mahony, Siobhán, and Fabrizio Ferraro. 2007. "The Emergence of Governance in an Open Source Community." *Academy of Management Journal* 50 (5): 1079–1106. <https://doi.org/10.5465/amj.2007.27169153>.
- Ostrom, Elinor. 1990. *Governing the Commons: The Evolution of Institutions for Collective Action*. Cambridge: Cambridge University Press. <https://doi.org/10.1017/CBO9780511807763>.
- Rathje, Steve, Jay J. Van Bavel, and Sander van der Linden. 2021. "Out-Group Animosity Drives Engagement on Social Media." *Proceedings of the National Academy of Sciences* 118 (26): e2024292118. <https://doi.org/10.1073/pnas.2024292118>.
- Saltzer, Jerome H., David P. Reed, and David D. Clark. 1984. "End-to-End Arguments in System Design." *ACM Transactions on Computer Systems* 2 (4): 277–288. <https://doi.org/10.1145/357401.357402>.
- Schneider, Nathan. 2024. *Governable Spaces: Democratic Design for Online Life*. Oakland: University of California Press. <https://doi.org/10.1525/luminos.181>.
- Shao, Chengcheng, Giovanni Luca Ciampaglia, Onur Varol, Kai-Cheng Yang, Alessandro Flammini, and Filippo Menczer. 2018. "The Spread of Low-Credibility Content by Social Bots." *Nature Communications* 9: 4787. <https://doi.org/10.1038/s41467-018-06930-7>.
- Shaw, Aaron, and Benjamin Mako Hill. 2014. "Laboratories of Oligarchy? How the Iron Law Extends to Peer Production." *Journal of Communication* 64 (2): 215–238. <https://doi.org/10.1111/jcom.12082>.
- Shumailov, Ilia, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. 2024. "AI Models Collapse When Trained on

- Recursively Generated Data.* *Nature* 631: 755–759. <https://doi.org/10.1038/s41586-024-07566-y>.
- Suler, John. 2004. “The Online Disinhibition Effect.” *CyberPsychology & Behavior* 7 (3): 321–326. <https://doi.org/10.1089/1094931041291295>.
- Suzor, Nicolas P. 2019. *Lawless: The Secret Rules That Govern Our Digital Lives*. Cambridge: Cambridge University Press. <https://doi.org/10.1017/9781108666428>.
- Tandoc, Edson C., Jr., Zheng Wei Lim, and Richard Ling. 2018. “Defining ‘Fake News’: A Typology of Scholarly Definitions.” *Digital Journalism* 6 (2): 137–153. <https://doi.org/10.1080/21670811.2017.1360143>.
- Terranova, Tiziana. 2000. “Free Labor: Producing Culture for the Digital Economy.” *Social Text* 18 (2): 33–58. https://doi.org/10.1215/01642472-18-2_63-33.
- Turner, Fred. 2006. *From Counterculture to Cyberculture: Stewart Brand, the Whole Earth Network, and the Rise of Digital Utopianism*. Chicago: University of Chicago Press.
- United States Senate Select Committee on Intelligence. 2019. *Russian Active Measures Campaigns and Interference in the 2016 U.S. Election, Volume 2: Russia’s Use of Social Media with Additional Views*. Washington, DC: United States Senate.
- Vosoughi, Soroush, Deb Roy, and Sinan Aral. 2018. “The Spread of True and False News Online.” *Science* 359 (6380): 1146–1151. <https://doi.org/10.1126/science.aap9559>.
- W3C. 2018. ActivityPub. W3C Recommendation, 23 January 2018. <https://www.w3.org/TR/activitypub/>.
- W3C. 2022. Decentralized Identifiers (DIDs) v1.0. W3C Recommendation, 19 July 2022. <https://www.w3.org/TR/did-core/>.
- W3C. 2025a. WebRTC: Real-Time Communication in Browsers. W3C Recommendation, 13 March 2025. <https://www.w3.org/TR/webrtc/>.
- W3C. 2025b. Verifiable Credentials Data Model v2.0. W3C Recommendation, 15 May 2025. <https://www.w3.org/TR/vc-data-model-2.0/>.
- W3C. 2026. Decentralized Identifiers (DIDs) v1.1. W3C Candidate Recommendation Snapshot, 5 March 2026. <https://www.w3.org/TR/did-1.1/>.

Wagner, Claudia, Eduardo Graells-Garrido, David Garcia, and Filippo Menczer. 2016. "Women through the Glass Ceiling: Gender Asymmetries in Wikipedia." *EPJ Data Science* 5: 5. <https://doi.org/10.1140/epjds/s13688-016-0066-4>.

Walter, Nathan, and Sheila T. Murphy. 2018. "How to Unring the Bell: A Meta-Analytic Approach to Correction of Misinformation." *Communication Monographs* 85 (3): 423–441. <https://doi.org/10.1080/03637751.2018.1467564>.

Yun, Jinhyuk, Sang Hoon Lee, and Hawoong Jeong. 2019. "Early Onset of Structural Inequality in the Formation of Collaborative Knowledge in All Wikimedia Projects." *Nature Human Behaviour* 3 (2): 155–163. <https://doi.org/10.1038/s41562-018-0488-z>.