

A Internet Capturada

Natureza Humana,
Poder Algorítmico e a
Arquitetura de uma
Rede Mais Governável



A Internet Capturada

*Natureza Humana, Poder Algorítmico e a
Arquitetura
de uma Rede Mais Governável*

Axiologic Research

Julho de 2026

*Imagine que a Internet continua a funcionar
perfeitamente enquanto se torna progressivamente
menos digna de ser visitada.*

HISTÓRIA • GOVERNAÇÃO • RECOMENDAÇÃO • IDENTIDADE • DESENHO
INSTITUCIONAL

Copyright © [2026] Sînică Alboaie

Todos os direitos reservados.

Direitos de publicação KDP detidos por Outfinity SRL (Iași, Romania).

Direitos de utilização concedidos a Outfinity Sagl (Caslano, Switzerland).

Disponível gratuitamente no website da Outfinity Venture Studio (www.outfinity.ch).

Foram utilizados sistemas de inteligência artificial como instrumentos editoriais e de investigação.

O argumento, a seleção e a responsabilidade autoral pertencem a Sînică Alboaie.

Nota do Autor:

Esta obra foi criada no âmbito do programa de investigação abrangente Outfinitism. Embora modelos linguísticos de inteligência artificial tenham sido utilizados para auxiliar a geração de texto, a filosofia subjacente, a estrutura temática e os quadros analíticos derivam inteiramente de décadas de investigação dedicada do autor sobre fenómenos sociais e tecnologias sociais.

Ao analisar os problemas fundamentais da Internet atual, este livro delineia trajetórias evolutivas essenciais compatíveis com a ascensão da IA, formando uma pedra angular da tese de investimento da Outfinity Venture Studio.

Índice

O Livro Inteiro em Dez Páginas.....	5
Uma Rede Que Ainda Funciona.....	5
O Que Uma Internet Melhor Exigiria de Facto.....	9
Capítulo 1: Antes das Plataformas.....	16
1.1 Protocolos Abertos, Dinheiro Público e Pequenas Comunidades.....	16
1.2 Email, Fóruns, Diretórios e Pesquisa.....	19
Capítulo 2: Plataformas e Constituições Ocultas.....	23
2.1 Porque Venceram as Plataformas.....	23
2.2 Captura Corporativa, Poder dos Moderadores e Trabalho Gratuito.....	26
Capítulo 3: O Adversário Humano.....	30
3.1 Anonimato, Desinibição, Trolling e Abuso Coordenado.....	30
3.2 Moderação como Governo.....	33
Capítulo 4: A Relevância É uma Constituição.....	37
4.1 Pesquisa, Feeds, Envolvimento e a Deriva para a Idiocracy.....	37
4.2 Desinformação, Câmaras de Eco e Manipulação Eleitoral.....	40
Capítulo 5: A Web Sintética e a Internet Que Ainda Funciona.....	44
5.1 Teoria da Internet Morta, Bots e Abundância Generativa.....	44
5.2 Wikipedia, Open Source, Ciência e Bens Comuns Duradouros.....	47
Capítulo 6: Para Além da Soberania das Plataformas.....	51
6.1 Comunidades Policêntricas e Marcas Descentralizadas.....	51
6.2 Economia, Licenciamento e Desenho Anticaptura.....	54
Capítulo 7: A IA Pessoal como Recomendador do Utilizador.....	58
7.1 De Perfis Ocultos à Relevância Governada pelo Utilizador.....	58
7.2 Privacidade, Viés, Pluralismo e o Risco de uma Câmara de Eco Pessoal...	61
Capítulo 8: Reconstruir a Comunicação a Partir da Camada de Protocolo....	65
8.1 WebRTC, Endereçamento Semelhante ao Email, DIDs e Ligações Condicionadas pela Confiança.....	65
8.2 Uma Superfície de Ataque Menor para Humanos e Agentes.....	69
Referências.....	74

O Livro Inteiro em Dez Páginas

Uma Rede Que Ainda Funciona

Imagine que a Internet continua a funcionar perfeitamente enquanto se torna progressivamente menos digna de ser visitada. A pesquisa é instantânea. As mensagens chegam. O vídeo nunca para. Assistentes pessoais resumem milhares de páginas antes do pequeno-almoço. No entanto, grande parte do que aparece no ecrã não foi criada para informar uma pessoa, selecionada por alguém responsável perante essa pessoa, nem oferecida por uma instituição que possa ser contestada. A maquinaria funciona. O mundo público transportado pela maquinaria está a rarefazer-se.

Esta abertura contém todo o argumento em forma comprimida. Um leitor que pare aqui deverá compreender o diagnóstico, a evidência mais forte e a direção proposta. O resto do livro existe para leitores que desejem a história, as qualificações e os detalhes de desenho.

A narrativa padrão começa com uma Internet descentralizada inocente e termina com a captura corporativa. Está parcialmente certa e é demasiado simples. A rede inicial surgiu de financiamento público, investigação militar e universitária, organismos de normalização, infraestrutura de telecomunicações e pequenas comunidades com competência técnica invulgarmente elevada. A abertura foi uma conquista institucional e de engenharia, não a ausência de poder. A harmonia inicial também dependia de acesso seletivo, escala manejável e administradores cuja autoridade era visível porque as comunidades eram pequenas (Clark 1988; Abbate 1999; Turner 2006).

Protocolos abertos fizeram máquinas heterogêneas interoperar e tornaram a cópia, a publicação e a comunicação extraordinariamente baratas. Não resolveram identidade, reputação, descoberta, spam, moderação, financiamento nem tomada de decisão coletiva legítima. À medida que a participação se expandiu, esses problemas adiados regressaram. O email adquiriu filtros e reputação

de remetente. Usenet e fóruns adquiriram administradores e conflito. Diretórios adquiriram editores. Motores de pesquisa adquiriram o poder de decidir quais, entre milhares de milhões de páginas, se tornariam visíveis.

As plataformas venceram porque resolveram problemas reais: interfaces coerentes, alojamento, pesquisa, contas persistentes, acesso móvel, pagamentos, segurança, recomendação e moderação. A centralização foi útil antes de se tornar constitucional. A captura começou quando o mesmo fornecedor passou a possuir identidade, relações, arquivos, ranking, receita e o direito de alterar todas as regras que os governavam. Utilizadores e moderadores continuaram a criar a comunidade, mas a comunidade tornou-se um ativo no balanço de outra pessoa.

Tabela 1. O diagnóstico em seis camadas

Elemento		Significado ou consequência de desenho
Camada de protocolo	de	Foram alcançadas interoperabilidade e publicação barata; identidade, moderação, financiamento e legitimidade permaneceram por resolver.
Camada de plataforma	de	Usabilidade, alojamento, pesquisa e segurança melhoraram, mas identidade, ranking, relações, arquivos e receita tornaram-se verticalmente concentrados.
Camada humana		A baixa fricção protegeu discurso vulnerável e alargou a participação, reduzindo também o custo do assédio, da fraude e da manipulação coordenada.
Camada epistémica		A pesquisa e a recomendação resolveram a escassez de atenção transformando a relevância num poder constitucional privado e frequentemente opaco.
Camada sintética		A automação reduziu custos de produção, mas também enfraqueceu autenticidade, proveniência e a posição económica do trabalho humano cuidadoso.
Camada institucional		A participação aberta criou valor imenso sem conceder de modo fiável aos contribuidores direitos duradouros de voz, saída ou benefício económico.

A captura corporativa é apenas uma componente da história. A Internet também alterou o preço do comportamento humano. A

pseudonímia pode proteger dissidentes, pacientes, denunciadores e minorias vulneráveis. Identidade de baixo custo também pode reduzir consequências reputacionais, permitir o regresso rápido após exclusão e tornar mais barato o assédio ou o consenso simulado. O efeito de desinibição online não transforma todas as pessoas anónimas num monstro, mas altera os incentivos em torno da conduta impulsiva (Suler 2004). Evidência experimental sugere ainda que o trolling é em parte situacional: humor negativo, exemplos hostis e normas locais podem levar participantes comuns a imitar abuso (Cheng et al. 2017).

O ciclo de amplificação é igualmente importante. A provocação produz reação; a reação é registada como envolvimento; o envolvimento produz distribuição; a exposição repetida altera normas; os criadores aprendem que desprezo, certeza, humilhação e conflito faccional circulam mais longe do que qualificação. Estudos sobre linguagem moral-emocional e hostilidade ao grupo externo apoiam este mecanismo (Brady et al. 2017; Rathje, Van Bavel, and van der Linden 2021). O resultado é muitas vezes apresentado como preferência revelada do utilizador, embora o sistema tenha ajudado a fabricar a preferência que mediu.

Este é o significado defensável da metáfora da “Idiocracy” online. Os utilizadores não se tornaram subitamente menos inteligentes. O ambiente seleciona material que consegue gerar um sinal barato e rápido. Uma novidade falsa pode ser escrita em segundos; a verificação pode exigir horas. Uma acusação dramática adapta-se melhor a um feed do que uma estimativa cuidadosa de incerteza. A otimização do envolvimento subsidia, portanto, a certeza imediata e taxa o trabalho epistémico lento. O problema é a seleção adversa contra a complexidade, não um declínio biológico da inteligência.

A moderação não pode simplesmente ser removida. A não intervenção transfere controlo para agressores persistentes, fações organizadas, exames automatizados ou proprietários que intervêm apenas quando o risco legal e comercial se torna intolerável. A verdadeira escolha é entre uma governação visível, delimitada, revisível e legítima, e uma governação improvisada, opaca ou capturada (Gillespie 2018; Suzor 2019). Moderadores voluntários

realizam trabalho cívico indispensável, muitas vezes sem remuneração nem proteção (Matias 2019), mas também podem transformar a custódia em estatuto ou domínio ideológico. O seu poder local deve ser distinguido do controlo estrutural da empresa da plataforma sobre bases de dados, contas, monetização e mudança constitucional.

Wikipedia e Reddit mostram que o resultado não é predeterminado. A Wikipedia demonstra que um bem comum global de conhecimento pode funcionar sem publicidade comportamental porque revisões, fontes, discussões e reversões são inspecionáveis. Também mostra como ferramentas antivivificação, normas complexas e desigualdades entre contribuidores podem calcificar uma instituição bem-sucedida (Halfaker et al. 2013; Wagner et al. 2016). O Reddit concede às comunidades poder local de criação de regras sobre infraestrutura corporativa. A investigação sugere que sanções fortes podem reduzir o discurso de ódio em vez de apenas deslocá-lo, enquanto explicações e recursos melhoram a legitimidade procedimental (Chandrasekharan et al. 2017; Jhaver, Bruckman, and Gilbert 2019). As instituições importam mais do que slogans sobre abertura ou controlo.

A manipulação política exige a mesma disciplina. Informação falsa pode difundir-se mais longe do que informação verdadeira em algumas redes, bots podem amplificar fontes de baixa credibilidade, e operações de influência coordenadas são reais (Vosoughi, Roy, and Aral 2018; Shao et al. 2018). Mas operação, exposição, persuasão, efeitos na participação, mudança de agenda e resultado eleitoral são afirmações diferentes. A investigação sobre a Internet Research Agency da Rússia documentou uma campanha deliberada durante a eleição dos Estados Unidos de 2016; não identificou um número defensável de votos convertidos. Câmaras de eco também existem de modo desigual, e a exposição forçada a visões opostas hostis pode intensificar, em vez de reduzir, a polarização (Bail et al. 2018; Cinelli et al. 2021).

As versões mais fortes da Teoria da Internet Morta afirmam que a maior parte da atividade online já é artificial e coordenada centralmente. A evidência não apoia essa conspiração total. O seu

aviso mais fraco é credível. O tráfego automatizado é substancial; sistemas generativos podem inundar pesquisa e feeds sociais com material plausível otimizado para ranking; agentes resumem cada vez mais fontes que os utilizadores nunca visitam; treino recursivo sobre dados sintéticos pode degradar modelos quando os dados humanos originais desaparecem (Shumailov et al. 2024). A Internet não está morta, mas a autenticidade e a legibilidade humana estão a tornar-se recursos escassos.

A contraevidência é igualmente importante. Software open-source, Wikipedia, OpenStreetMap, preprints científicos, comunidades de pacientes, mapeamento humanitário e fóruns especializados geraram imenso valor público. A conclusão não é que a abertura falhou. É que as instituições que criam valor estão frequentemente separadas das instituições que controlam os ativos resultantes. Os êxitos da Internet vieram de fundamentos técnicos abertos combinados com normas, papéis, histórias e mecanismos de reparação. O próximo desenho deve preservar essa capacidade enquanto corrige as suas fragilidades constitucionais.

O Que Uma Internet Melhor Exigiria de Facto

A alternativa não é nem um regresso a pequenos fóruns nem uma blockchain universal. É um sistema policêntrico: protocolos abertos por baixo; comunidades com constituições reais por cima; vários fornecedores de serviço concorrentes em seu redor; e direitos que permitem aos membros mudar de fornecedor sem abandonar identidade, relações, evidência reputacional ou arquivos. O objetivo não é eliminar o poder. É tornar o poder visível, dividido, temporário e contestável.

Uma comunidade exige mais do que uma sala de chat e termos de serviço. Precisa de um propósito declarado, limites de pertença, poderes conhecidos, moderadores qualificados, sanções que escalem proporcionalmente, razões para decisões consequentes, uma via de recurso, regras de conflito de interesses e financiamento para infraestrutura e trabalho difícil. O trabalho de Ostrom sobre bens comuns duradouros continua relevante porque rejeita tanto a

privatização ingênua como a abertura ingênua: comunidades bem-sucedidas ajustam regras ao contexto, permitem que os membros afetados participem na sua alteração, monitorizam conduta, aplicam sanções graduadas, resolvem disputas e operam através de níveis aninhados de governação (Ostrom 1990).

Uma marca descentralizada pode fornecer a camada institucional em falta. Uma marca não é apenas um logótipo; é uma promessa pública sobre qualidade, compatibilidade, conduta e responsabilidade. Numa plataforma convencional, uma empresa possui essa promessa. Num projeto puramente aberto, o artefacto pode ser bifurcável, enquanto reputação e coordenação económica permanecem frágeis. Uma marca descentralizada coloca o nome, os padrões, a tesouraria e o processo de certificação sob uma constituição que nenhum fundador, investidor, grupo de moderadores ou fornecedor de infraestrutura pode alterar sozinho.




Figura 1. O arco institucional da Internet: dos protocolos abertos, através da atenção concentrada, rumo a redes governáveis.

Os instrumentos devem permanecer distintos. Uma licença de software ou conteúdo governa cópia e modificação. Uma licença de marca governa o uso da identidade partilhada. Uma constituição aloca poderes de decisão, auditoria, alteração, emergência e recurso. Um acordo de contribuição reconhece trabalho, manutenção e

capital. Contratos de serviço restringem alojamento, pesquisa, recomendação e uso de dados. Nem um token nem uma licença open-source podem desempenhar todos estes papéis.

A descentralização deve ser testada na prática. Podem os membros exportar relações e arquivos, não apenas descarregar um ficheiro? Pode uma comunidade mudar de alojamento sem desaparecer? Pode um recurso reverter um moderador? Pode um operador ser substituído sem quebrar a identidade? Os contribuidores partilham benefícios económicos? Pode qualquer fornecedor redefinir o acesso unilateralmente? Um repositório ou livro-razão distribuído não é descentralização quando a instituição social permanece cativa.

A recomendação precisa de uma inversão semelhante. Hoje, as plataformas constroem perfis ocultos e usam objetivos mistos - retenção, publicidade, segurança, prioridades comerciais e estratégia - para decidir aquilo que os utilizadores notam. Mesmo ranking sofisticado trata o modelo do utilizador como ativo da plataforma. Uma IA pessoal poderia, em vez disso, manter uma representação privada e revisível de interesses, obrigações, enviesamentos e limites. Poderia recolher candidatos de muitas fontes, aplicar políticas explícitas, explicar compromissos, recordar correções, preferir evidência primária, reduzir indignação, introduzir desacordo credível ou rejeitar patrocínio não divulgado. Investigação recente descreve esta mudança como movimento de perfis ocultos para personalização governável (Liu et al. 2026).

A mudança importante é constitucional, não meramente preditiva. As plataformas já predizem gosto. A nova possibilidade é que a representação do utilizador se torne inspecionável, portátil e responsável perante o utilizador. A investigação sobre recomendadores mostrou há muito que a experiência depende de controlo, diversidade, privacidade, esforço e explicação, além de precisão (Cramer et al. 2008; Knijnenburg et al. 2012; Helberger, Karppinen, and D'Acunto 2018). O agente deve expor rankings alternativos e contraevidência, em vez de se tornar silenciosamente uma câmara de eco mais íntima.

Esse agente também cria riscos. Pode lisonjear impulsos temporários, preservar preferências obsoletas, vaziar memória privada, depender de um fornecedor cloud ou ser manipulado por prompt injection e fontes envenenadas. Os seus objetivos, incerteza, relações comerciais, caminho de atualização e poderes delegados devem, portanto, ser visíveis. As preferências devem ser revisíveis e por vezes expirar. Várias políticas de ranking devem ser comparáveis. Processamento local ou confidencial, proveniência, limites de capacidade e registos de ação auditáveis não são detalhes opcionais; são salvaguardas constitucionais.

Uma segunda inversão pode ocorrer abaixo da camada de plataforma. A Internet atual expõe serviços a um espaço global de endereços e depois despende enorme esforço a rejeitar tráfego indesejado. O email aceita tentativas de entrega vindas de estranhos. Serviços públicos defendem-se contra varrimento, spam, ataques a credenciais, scraping e negação de serviço. A abertura continua valiosa, mas a recetividade global não deve ser o padrão para todos os serviços pessoais e agentes de IA.

Um sistema futuro poderia preservar interfaces familiares - endereços, caixas de entrada, contactos, grupos, documentos partilhados e assistentes - enquanto altera a fronteira de confiança. Um endereço público não precisa de revelar um endpoint pessoal permanente. O contacto inicial poderia passar por um serviço estreito de introdução. Uma introdução bem-sucedida poderia emitir uma capacidade revogável que defina quem pode sinalizar, enviar, invocar um agente ou abrir um canal. Depois disso, humanos e agentes poderiam comunicar através de sessões encriptadas diretas ou retransmitidas usando canais de dados WebRTC ou transportes relacionados.

WebRTC é apenas uma componente. Fornece APIs e protocolos para meios e dados interativos, com conectividade negociada através de ICE e frequentemente assistida por relays (IETF 2018; IETF 2021a; W3C 2025a). Não define sinalização, entrega offline, arquivos, identidade social ou confiança. Um endereço legível semelhante ao email poderia continuar útil, enquanto um DID ou identificador equivalente fornece controlo criptográfico portátil e Verifiable

Credentials fornecem alegações seletivas (W3C 2022; W3C 2025b; W3C 2026). Estas tecnologias provam controlo ou declarações de emissores, não honestidade. A confiança continua a vir de relações, instituições, endossos, história e contexto.

A rede resultante seria condicionada pela confiança, em vez de globalmente recetiva por defeito. Atores desconhecidos poderiam exigir um token de introdução, referência, caução ou credencial relevante. Identificadores por par poderiam reduzir correlação entre relações. Agentes poderiam negociar limites de taxa, formatos aceites, confidencialidade e automação antes do início de uma sessão. Um utilizador poderia revogar uma relação sem substituir uma identidade global. A superfície exposta diminuiria porque a maioria dos serviços pessoais nunca aceitaria tráfego arbitrário não solicitado.

Tabela 2. Um conjunto diferente de padrões

Elemento	Significado ou consequência de desenho
Perfil oculto da plataforma	Um modelo de IA pessoal governado pelo utilizador que pode ser inspecionado, corrigido, restringido, exportado ou eliminado.
Caixa de entrada exposta globalmente	Introduções condicionadas pela confiança, contacto delimitado por capacidades e canais específicos de relação.
Um sistema opaco de ranking	Fornecedores plurais e inspecionáveis de ranking, selecionados por utilizadores e comunidades para fins declarados.
Comunidade corporativa	Comunidades policêntricas que operam sob uma marca descentralizada partilhada e uma constituição contestável.
Manutenção gratuita invisível	Financiamento explícito para moderação, segurança, infraestrutura, reparação e custódia de longo prazo.
Exportação nominal de dados	Identidade portátil, relações, evidência reputacional, arquivos e continuidade prática de serviço.
Autenticidade por intuição	Proveniência assinada, patrocínio responsável e rotulagem clara de participação automatizada.

Os servidores permaneceriam. WebRTC muitas vezes precisa de sinalização e infraestrutura de relay; comunicação assíncrona precisa de serviços de armazenamento e reencaminhamento; grupos seguros precisam de protocolos como Messaging Layer Security (IETF 2023; IETF 2025). Fornecedores continuariam a vender armazenamento, disponibilidade, descoberta, backup, computação e resposta a abuso. A diferença é que nenhum fornecedor precisaria de possuir identidade, relações, recomendação e arquivos como um único pacote indivisível.

Agentes pessoais atuariam como salas de correio locais, recomendadores, mediadores de segurança e representantes. Poderiam filtrar introduções, verificar credenciais, selecionar relays, resumir mensagens, aplicar política de privacidade e acompanhar autoridade delegada. Porque este papel é poderoso, o agente deve ser auditável e substituível. O seu modelo, memória, permissões e incentivos comerciais não podem tornar-se outra constituição oculta.

O futuro mais realista é uma topologia mista. Algumas comunidades permanecerão centralizadas porque propriedade clara ou responsabilidade jurídica serve o seu propósito. Outras federar-se-ão. Outras partilharão padrões e reputação através de marcas descentralizadas enquanto usam operadores independentes. O pluralismo não é um defeito temporário. É a defesa contra um novo soberano universal.

O teste final é simples. Uma Internet viva deve ajudar as pessoas a formar comunidades, criar bens públicos duradouros, descobrir informação surpreendente e usar assistência inteligente sem entregar identidade e relações a quem quer que possua a interface dominante. Deve tornar o abuso caro sem tornar a dissidência impossível; permitir moderação sem moderadores irrevisíveis; recompensar fundadores e operadores sem conceder domínio hereditário; e deixar que a recomendação ajude uma pessoa a pensar, em vez de definir silenciosamente o que essa pessoa tem autorização para ver.

A natureza humana não será removida da rede. Curiosidade, generosidade, vaidade, tribalismo, coragem, crueldade e cuidado

aparecerão em todas as arquiteturas. Progresso significa construir instituições em que as melhores capacidades sejam mais fáceis de coordenar, as piores capacidades sejam mais difíceis de instrumentalizar, e a utilidade temporária não se torne propriedade permanente do mundo social.

***Nota sobre a evidência.** As afirmações são apoiadas principalmente por investigação revista por pares, livros académicos, normas e relatórios institucionais. As propostas técnicas dos Capítulos 7 e 8 são apresentadas como direções de desenho construídas a partir de componentes maduros, não como afirmações de que o problema de integração já está resolvido.*

Capítulo 1: Antes das Plataformas

A Internet inicial é muitas vezes recordada como uma república perdida de iguais. Foi mais interessante do que isso. A arquitetura aberta emergiu de instituições, comunidades de especialistas e escolhas deliberadas de engenharia. O seu êxito criou liberdades que o seu desenho social não estava preparado para governar.

1.1 Protocolos Abertos, Dinheiro Público e Pequenas Comunidades

ARPANET e a Internet não foram produtos espontâneos de um mercado ou de uma contracultura. Emergiram de programas públicos de investigação, universidades, contratantes, comunidades de normalização e engenheiros que precisavam que redes heterogêneas interoperassem. Comutação de pacotes, protocolos de anfitrião e, mais tarde, TCP/IP foram soluções para problemas técnicos e organizacionais. O sistema tinha de sobreviver à diversidade de equipamentos, fronteiras administrativas e aplicações em mudança. A arquitetura resultante distribuiu funções para as extremidades e evitou exigir que uma rede compreendesse todos os usos futuros (Clark 1988; Leiner et al. 1997).

Esta história técnica importa porque interpretações políticas posteriores tratam frequentemente a descentralização como o propósito moral original da rede. Resiliência, interoperabilidade e desenvolvimento de aplicações sem permissão certamente tiveram consequências políticas, mas não constituíam uma teoria política completa. A tradição end-to-end restringiu o que o núcleo da rede deveria decidir; não especificou como as comunidades deveriam lidar com assédio, como os contribuidores deveriam ser pagos, ou como um sistema público de ranking deveria justificar as suas escolhas (Saltzer, Reed, and Clark 1984).

A cultura da rede inicial foi moldada por acesso seletivo. Universidades, laboratórios de investigação e amadores tecnicamente sofisticados forneceram muitos participantes. Normas profissionais partilhadas e interação repetida tornavam a reputação significativa. A informalidade funcionava porque as comunidades eram suficientemente pequenas para que a história fosse lembrada e porque a participação em si exigia esforço. Isto não eliminou hierarquia. Administradores controlavam máquinas, listas de correio e contas. A especialização conferia estatuto. Pessoas que não partilhavam os pressupostos técnicos e culturais dominantes podiam ser ignoradas ou excluídas.




Figura 2. Protocolos abertos reduziram a dependência técnica enquanto deixavam uma dívida crescente em identidade, descoberta, moderação e financiamento.

A liberdade associada à Internet inicial era, portanto, real e subsidiada. Dinheiro público sustentava infraestrutura. Universidades absorviam custos. Voluntários mantinham software e documentação. Empregadores permitiam que pessoal qualificado contribuísse. A rede parecia flutuar acima da economia ordinária porque grande parte da sua economia estava escondida em instituições que tinham razões diferentes do lucro direto para a apoiar. Quando o acesso se expandiu, o custo de operar sistemas sociais tornou-se mais difícil de ocultar.

A disponibilização do software World Wide Web pelo CERN em 1993 exemplificou o poder da generosidade institucional. Ao permitir uso livre de royalties, o CERN possibilitou que browsers, servidores e

sites concorrentes surgissem sem pedir permissão a um proprietário central (CERN 1993). A decisão não predeterminou uma Web não comercial. Tornou possível inovação comercial e não comercial sobre a mesma base. A abertura criou um campo em que bens comuns e corporações podiam crescer.

A primeira contradição já estava presente. Um protocolo pode ser aberto enquanto as comunidades que o usam são fechadas. Um serviço pode ser descentralizado enquanto o acesso a especialização, hardware e tempo permanece desigual. Uma norma pública pode permitir concentração privada se ativos complementares como descoberta, identidade e distribuição se tornarem escassos. A história da Internet não é uma queda da pureza técnica. É o movimento do poder de uma camada para outra à medida que cada estrangulamento é resolvido.

Isto explica porque a nostalgia é um mau guia. Recriar protocolos antigos ou fóruns cronológicos não recriaria as condições sociais sob as quais pareciam manejáveis. Milhares de milhões de utilizadores, adversários automatizados, incentivos comerciais e sistemas generativos alteram a escala do problema. O que permanece valioso da Internet inicial não é a sua inocência, mas a sua conquista institucional: múltiplas redes e implementações podiam cooperar porque os padrões eram abertos e a autoridade era limitada no núcleo.

A própria cultura de normalização continha uma pista institucional útil. Requests for Comments eram argumentos técnicos públicos, não decretos, e o ideal de consenso aproximado e código em funcionamento fazia a autoridade depender em parte de resultados implementáveis. O processo nunca foi perfeitamente democrático: a participação exigia especialização, tempo e acesso, enquanto recursos-chave como nomes e endereços ainda precisavam de coordenação. Ainda assim, demonstrou que regras comuns podem emergir sem um único fornecedor possuir cada implementação. A legitimidade vinha de especificação aberta, implementações concorrentes e possibilidade de contestação técnica.

Mesmo o núcleo supostamente descentralizado continha funções concentradas. O Domain Name System introduziu delegação hierárquica; alocação de endereços e registos de protocolos exigiam custódia; grandes fornecedores de backbone ocupavam posições estratégicas. Descentralização significava que nenhuma concentração única controlava necessariamente todas as camadas, não que a concentração desaparecesse. Esta visão em camadas é essencial para a reforma contemporânea. Um sistema pode tolerar um registo central se identidades, dados, clientes e comunidades puderem mover-se em seu redor. Torna-se perigoso quando o controlo de uma camada é alavancado para a propriedade de todas as outras.

A tarefa inacabada é estender esse princípio para cima. A identidade não deve ser inseparável de uma aplicação. A reputação não deve ficar presa dentro de uma base de dados. As comunidades devem poder contratar infraestrutura sem transferir soberania. A recomendação deve ser substituível. A moderação deve operar através de poderes declarados e recurso. Os primeiros engenheiros criaram um substrato aberto de comunicações. A próxima geração deve criar um substrato institucional aberto.

1.2 Email, Fóruns, Diretórios e Pesquisa

O email é a demonstração mais clara de que a federação pode sobreviver à escala global. Uma pessoa pode enviar uma mensagem através de fronteiras organizacionais sem que ambas as partes pertençam ao mesmo fornecedor. Domínios permitem administração local enquanto protocolos comuns preservam interoperabilidade. Este modelo é menos elegante na prática do que nos diagramas, mas resistiu durante décadas à apropriação completa por qualquer empresa única.

A sua fraqueza é igualmente instrutiva. O email permite contacto não solicitado a custo marginal extremamente baixo. O remetente externaliza custos de filtragem, armazenamento, atenção e segurança para destinatários e fornecedores. O estudo Spamalytics concluiu que uma campanha podia manter-se economicamente

viável apesar de uma taxa de conversão extraordinariamente baixa, porque milhões de mensagens eram baratas de enviar através de máquinas comprometidas (Kanich et al. 2009). Sistemas de autenticação e reputação reduziram abuso, mas também concentraram poder prático em grandes fornecedores capazes de operar filtros sofisticados e influenciar a entregabilidade.

Usenet e fóruns web criaram culturas locais mais ricas. A sua organização centrada em tópicos preservava conversas longas e permitia que a reputação se acumulasse dentro de um domínio. Um bom fórum técnico podia tornar-se um arquivo vivo mais útil do que qualquer manual formal. Contudo, a maioria dos fóruns eram governos privados. Proprietários controlavam a base de dados e o domínio. Moderadores interpretavam regras, muitas vezes sem recurso. Comunidades podiam ser generosas e especializadas, permanecendo constitucionalmente frágeis.

Diretórios como o catálogo inicial do Yahoo e o Open Directory Project tornavam a seleção visível. Editores humanos classificavam sites e implicitamente garantiam relevância. O modelo podia expressar juízo e contexto, mas não escalava com a Web. Editores tornavam-se estrangulamentos, categorias endureciam e decisões podiam ser capturadas por pequenos grupos. Ainda assim, o utilizador podia ver que o diretório representava uma estrutura editorial, não um mapa objetivo da realidade.

Motores de pesquisa resolveram a escala automatizando a seleção. Análise de links e grandes índices tornaram a Web utilizável, mas o ranking adquiriu um papel político. Um motor de pesquisa não recupera meramente o que existe. Aloca visibilidade, o que muitas vezes determina se uma fonte tem existência prática para a maioria dos utilizadores. Introna e Nissenbaum argumentaram cedo que motores de pesquisa favorecem inevitavelmente alguns sites e valores, mesmo quando as suas escolhas são apresentadas como relevância técnica (Introna and Nissenbaum 2000).

Tabela 3. O que cada camada inicial resolveu e deixou por resolver

Elemento	Significado ou consequência de desenho
TCP/IP e desenho end-to-end	Ligou redes heterogêneas e limitou a dependência de proprietários intermediários; não criou identidade social nem governação comunitária.
Email	Criou mensagens federadas globais; expôs destinatários a spam, spoofing, concentração reputacional e abuso a custo de envio negligenciável.
Usenet e fóruns	Permitiu comunidades temáticas duradouras; dependia de normas locais frágeis, proprietários, administradores e resolução de conflitos socialmente custosa.
Diretórios	Tornou visível o juízo editorial humano; não escalou e criou poder em torno de inclusão, categorias e fações de editores.
Motores de pesquisa	Escalou a descoberta em toda a Web aberta; tornou o ranking um intermediário opaco entre publicação e visibilidade prática.

A passagem de diretório para pesquisa mudou a aparência do poder. Categorias humanas pareciam subjetivas. Resultados algorítmicos pareciam descobertos. Contudo, todo sistema de ranking escolhe sinais, lida com manipulação, define atualidade e equilibra objetivos comerciais e públicos. A pesquisa também criou uma indústria adversarial. Publicadores otimizaram para o sistema de ranking; o sistema de ranking adaptou-se à otimização; o conteúdo passou cada vez mais a dirigir-se ao classificador antes do leitor.

Email, fóruns, diretórios e pesquisa contêm, portanto, todo o futuro em miniatura. A federação preserva a saída, mas atrai abuso. Comunidades locais produzem conhecimento, mas podem tornar-se oligarquias privadas. A curadoria humana fornece contexto, mas não consegue cobrir tudo. O ranking algorítmico escala, mas oculta julgamento. Nenhum destes sistemas é um fracasso. Cada um revela uma troca institucional diferente.

A rutura social associada ao “Eternal September” tornou visível o problema de escala antes das plataformas modernas. Novas coortes sempre tinham entrado na Usenet e aprendido as suas normas, mas o acesso comercial converteu um afluxo periódico numa chegada massiva permanente. Participantes antigos culpavam

frequentemente os recém-chegados, por vezes com desprezo elitista, mas o problema mais profundo era institucional: onboarding, moderação e memória não tinham sido desenhados para crescimento contínuo. Normas que só podem ser transmitidas por mentoria paciente são vulneráveis quando as chegadas superam os mentores.

O Open Directory Project tentou mais tarde combinar juízo editorial humano com trabalho voluntário distribuído. Provou que milhares de editores podiam manter um catálogo público, mas também que propriedade de categorias, revisão lenta e padrões desiguais podiam tornar-se estrangulamentos. Motores de pesquisa deslocaram diretórios não porque o juízo humano fosse inútil, mas porque a indexação automatizada podia cobrir ordens de grandeza mais material. A troca foi cobertura por inspecionabilidade.

O email também se tornou operacionalmente mais centralizado do que os seus protocolos sugerem. Servidores independentes continuam possíveis, mas a entregabilidade depende de reputação, autenticação, resposta a abuso e relações com grandes fornecedores. Um pequeno operador pode cumprir padrões e ainda assim ver mensagens filtradas. Este é um padrão recorrente: protocolo aberto na camada formal, confiança concentrada na camada operacional. A cura não é negar a utilidade da filtragem profissional, mas tornar as suas regras, portabilidade e recursos menos dependentes de poucas empresas.

A era das plataformas não substituiu estes sistemas por ter uma filosofia superior. Combinou as suas funções úteis por trás de uma conta e uma interface. Mensagens, identidade, descoberta, reputação, distribuição e monetização tornaram-se mais fáceis porque um operador podia coordená-las. O custo dessa conveniência foi que o operador também adquiriu o poder de redefinir todas as funções de uma só vez.

Capítulo 2: Plataformas e Constituições Ocultas

As plataformas venceram ao tornar a Internet compreensível. Tornaram-se perigosas quando a integração se converteu em soberania e quando as comunidades descobriram que a conveniência tinha sido comprada com identidade não portátil, regras invisíveis e dependência de ranking privado.

2.1 Porque Venceram as Plataformas

A Web aberta pedia aos utilizadores que montassem o seu próprio ambiente. Precisavam de alojamento, identidade, contactos, ferramentas de publicação, descoberta, proteção contra spam e, por vezes, sistemas de pagamento. As plataformas integraram estas funções e removeram fricção técnica. O seu sucesso não foi prova de que os utilizadores preferiam dominação. Foi evidência de que a coordenação tem valor.

Efeitos de rede reforçaram o resultado. Um serviço de comunicação torna-se mais útil quando os contactos já estão presentes. Um mercado atrai compradores porque há vendedores e vendedores porque há compradores. Um recomendador melhora quando observa mais comportamento. Um sistema de moderação beneficia de inteligência partilhada sobre abuso. Estes efeitos tornam sistemas integrados difíceis de desafiar mesmo quando concorrentes oferecem melhores funcionalidades individuais.

A computação móvel intensificou a centralização. Aplicações distribuídas através de lojas controladas podiam combinar identidade, notificações, captura multimédia, pagamentos e localização. O grafo social passou de hiperligações e livros de endereços para bases de dados proprietárias. O utilizador deixou de navegar tanto entre sites independentes e passou a permanecer dentro de um feed em que fontes externas eram apresentadas como objetos de conteúdo.

A platformização também mudou a própria Web. Sites incorporaram botões sociais, analytics, publicidade, autenticação e serviços de entrega de conteúdo fornecidos por um pequeno número de empresas. Helmond descreve isto como tornar os dados da web “platform ready”: a Web aberta tornou-se uma superfície através da qual as plataformas podiam estender as suas estruturas de dados e modelos de negócio (Helmond 2015). A fronteira entre um website e uma plataforma tornou-se porosa numa direção. Sites independentes dependiam mais das plataformas do que as plataformas dependiam de qualquer site único.




Figura 3. Como a participação pública se torna um ativo privado de plataforma quando identidade, relações, dados e ranking são verticalmente integrados.

A plataforma integrada resolveu a descoberta ao possuir a relação com a audiência. Resolveu a identidade ao emitir contas. Resolveu a moderação ao definir padrões comunitários. Resolveu o financiamento através de publicidade, subscrições, taxas ou serviços orientados por dados. Cada solução era operacionalmente racional. O problema constitucional surgiu porque a mesma empresa definia as regras, interpretava-as, controlava a evidência, operava o mecanismo de recurso e possuía os ativos residuais.

Os termos de serviço forneceram permissão legal para mudança unilateral, mas o consentimento formal não criou legitimidade substantiva. As pessoas investiram anos em comunidades, negócios, audiências e reputações que podiam ser alteradas por decisões de

produto. Programadores construíram sobre interfaces que podiam ser reprecificadas. Moderadores mantiveram espaços cujos dados não possuíam. Criadores adaptaram-se a sistemas de ranking que podiam mudar sem explicação. A plataforma comportava-se simultaneamente como senhorio, legislatura, polícia, tribunal, banco central e distribuidor de media.

A complexidade interna das corporações não deve ser ignorada. Equipas de segurança, moderadores, engenheiros, investigadores, executivos, investidores e anunciantes podem ter objetivos conflitantes. O dano não exige uma intenção maliciosa única. Estruturas de governação podem privilegiar repetidamente crescimento, defensabilidade jurídica e receita, mesmo quando muitos trabalhadores identificam o custo social. “A plataforma” é, portanto, melhor compreendida como uma instituição com uma estrutura objetiva dominante, não como uma mente unificada.

A publicidade tornou esta integração especialmente poderosa. Uma plataforma podia subsidiar acesso gratuito, observar comportamento através de serviços e otimizar tanto seleção de conteúdo como segmentação comercial. Os mesmos dados melhoravam conveniência e poder de mercado. Porque o modelo de negócio valorizava predição e retenção, a plataforma tinha uma razão estrutural para expandir o número de comportamentos que podia observar e o tempo que os utilizadores passavam no seu ambiente. A vigilância não foi apenas uma falha acidental de privacidade; foi infraestrutura produtiva.

Os padrões por defeito reforçaram a concentração. A maioria dos utilizadores não muda browsers, fornecedores de pesquisa, definições de privacidade ou permissões de aplicações a menos que o custo do padrão se torne óbvio. O controlo de sistemas operativos, browsers, lojas de aplicações e botões de identidade traduziu-se, portanto, em poder de distribuição. Um serviço podia ser nominalmente contestável enquanto permanecia praticamente dominante porque a mudança exigia atenção, conhecimento técnico e coordenação social.

O modelo de plataforma também converteu publicadores externos em fornecedores. Organizações noticiosas, criadores e comerciantes dependiam de distribuição algorítmica enquanto recebiam informação incompleta sobre as regras. A relação assemelhava-se a um mercado cuja bolsa possuía o cliente, definia o ranking, competia com vendedores e alterava taxas à vontade. Isto não tornou abusiva cada decisão de plataforma, mas tornou a negociação estruturalmente assimétrica.

A lição não é que a integração deva ser proibida. Experiências integradas são valiosas, e a maioria dos utilizadores não irá gerir dezenas de serviços técnicos independentes. A questão de desenho é se a integração exige propriedade. Uma comunidade deve poder delegar alojamento, pesquisa, pagamentos ou ferramentas de moderação sem entregar a sua identidade e arquivo. Um utilizador deve poder mudar de recomendador sem abandonar contactos. A plataforma deve tornar-se uma camada de serviço substituível, em vez de um território soberano.

2.2 Captura Corporativa, Poder dos Moderadores e Trabalho Gratuito

A participação digital produz vários tipos de valor ao mesmo tempo. Publicações e vídeos atraem audiências. Avaliações melhoram a pesquisa. Relações sociais aumentam a retenção. A moderação mantém os espaços utilizáveis. Rastros comportamentais melhoram segmentação e predição. A plataforma fornece infraestrutura que torna estas contribuições combináveis, mas a propriedade convencional atribui o ativo acumulado quase inteiramente à empresa.

A análise de Terranova sobre trabalho gratuito continua útil porque identifica a integração da produção cultural voluntária em sistemas comerciais (Terranova 2000). O termo não deve implicar que toda contribuição não remunerada seja emprego disfarçado. As pessoas contribuem por prazer, identidade, reputação, aprendizagem, ajuda mútua e propósito público. A exploração torna-se visível quando a instituição depende desses motivos enquanto nega aos

contribuidores voz duradoura, portabilidade e participação no valor que a sua interdependência cria.

O trabalho de moderação é um exemplo concentrado. Voluntários interpretam regras, detetam fraude, mediam conflito e absorvem abuso. Matias descreve isto como trabalho cívico porque cria condições para participação coletiva (Matias 2019). As plataformas muitas vezes celebram a comunidade enquanto tratam as pessoas que a mantêm como utilizadores substituíveis. O arranjo pode ser mutuamente benéfico, mas torna-se instável quando moderadores suportam responsabilidade sem direitos ou recursos.

Tabela 4. Centros distintos de poder dentro de uma comunidade de plataforma

Elemento	Significado ou consequência de desenho
Empresa da plataforma	Possui infraestrutura, contas, acesso a dados, monetização, affordances técnicas e autoridade última de criação de regras.
Fundador ou grupo executivo	Pode definir missão e estratégia, mas pode reter poderes de emergência ou controlo da missão sem legitimação periódica.
Moderador voluntário	Controla interpretação local e acesso diário, muitas vezes com pouca remuneração, apoio, supervisão ou orientação procedimental.
Fação organizada	Pode dominar consultas, votação, denúncia e normas sociais através de persistência, não de apoio representativo.
Anunciante ou fornecedor de modelo	Influencia indiretamente alvos de otimização e visibilidade através de dependência de receita, acesso a dados ou lock-in técnico.
Membro ordinário	Cria atenção, relações, conteúdo e cultura, embora detenha geralmente direitos fracos sobre o ativo coletivo resultante.

A captura por moderadores é, contudo, real. Longa permanência, controlo sobre nomeações, canais privados de coordenação e recursos fracos podem transformar custódia em oligarquia. Investigação sobre produção entre pares concluiu que a abertura nominal não impede grupos de liderança duradouros de

consolidarem autoridade (Shaw and Hill 2014). Alguma concentração é funcional; pessoas experientes conhecem a história e podem responder rapidamente. O problema não é a hierarquia em si, mas hierarquia sem rotação, auditoria, jurisdição declarada ou um meio credível de contestar decisões.

Poder corporativo e poder dos moderadores interagem. Empresas podem delegar decisões difíceis a voluntários enquanto retêm o direito de as substituir. Moderadores podem usar a política da empresa para legitimar preferências locais. Utilizadores experienciam o resultado combinado como um sistema opaco, embora a autoridade esteja fragmentada. A reforma deve, portanto, estabelecer fronteiras claras: quais regras pertencem à marca partilhada, quais às comunidades locais, quais aos fornecedores de infraestrutura e quais direitos permanecem com membros individuais.

O pagamento por si só não resolve a captura. Uma plataforma poderia pagar criadores ou moderadores preservando controlo unilateral. Pequenos pagamentos por dados podem legitimar extração mais profunda ao converter pertença numa série de microtransações. A justiça económica importa, mas o défice central é constitucional. As pessoas precisam de direitos executáveis relativos a mudanças de regras, uso de dados, reputação, arquivos e saída.

A concorrência por si só também é insuficiente. Uma escolha entre várias plataformas fechadas é uma escolha entre constituições privadas. A concorrência torna-se poderosa quando a mudança preserva identidade, relações e história. A portabilidade deve incluir continuidade social, não apenas um arquivo descarregável. Caso contrário, a saída assemelha-se a abandonar uma cidade e deixar para trás todas as relações.

A diferença entre exportação de dados e portabilidade merece ênfase. A exportação produz frequentemente um arquivo estático útil para backup pessoal mas inútil para continuidade. Portabilidade significa que outro serviço consegue interpretar os dados, preservar identificadores, restabelecer permissões e continuar relações com consentimento. A portabilidade social é ainda mais difícil porque

seguidores e membros de grupos devem conseguir reconhecer a mudança. Os padrões devem, portanto, cobrir não apenas formatos de ficheiro, mas resolução de identidade, provas de relação, histórico de moderação e revogação.

Interfaces de programação de aplicações podem criar abertura aparente enquanto preservam dependência. O acesso pode ser limitado, reprecificado ou retirado; dados exportados podem omitir sinais de ranking e contexto social; clientes de terceiros podem permanecer subordinados a um sistema único de contas. A contestabilidade genuína exige que a interoperabilidade seja um direito ou uma propriedade arquitetural, não um programa de negócio discricionário.

A governação corporativa acrescenta outra camada. Executivos são muitas vezes legal e financeiramente responsáveis perante conselhos e investidores, não perante utilizadores que criaram o capital social da comunidade. Sociedades de benefício, trusts de custódia, cooperativas e deveres de interesse público podem modificar este alinhamento, mas a forma jurídica isolada é insuficiente. A capacidade técnica de sair e a capacidade constitucional de contestar decisões devem acompanhar qualquer promessa de missão.

A alternativa construtiva é separar recompensa de soberania. Fundadores e investidores podem receber retornos económicos delimitados. Operadores podem ser pagos por infraestrutura. Moderadores podem ser compensados por trabalho difícil. Contribuidores podem receber reputação, quotas de receita ou direitos de governação. Nenhum destes papéis deve conferir automaticamente autoridade permanente sobre toda a instituição. A comunidade partilhada deve existir legal e tecnicamente separada de qualquer fornecedor de serviço único.

Capítulo 3: O Adversário Humano

A Internet não inventou crueldade, fraude, tribalismo ou competição por estatuto. Alterou o seu custo, velocidade, escala e visibilidade. Qualquer arquitetura futura que assuma boa vontade será capturada por aqueles dispostos a explorá-la.

3.1 Anonimato, Desinibição, Trolling e Abuso Coordenado

O anonimato é frequentemente discutido como uma escolha binária entre liberdade e responsabilidade. Na prática, a identidade online tem muitas dimensões: nome legal, pseudónimo persistente, reputação, pertença, endereço técnico e histórico de relações. Uma pessoa pode ser anónima perante o público e responsável perante uma comunidade, ou publicamente identificada enquanto opera através de contas descartáveis. Um bom desenho separa estas dimensões em vez de impor identificação universal.

O valor protetor da pseudonímia é substancial. Dissidentes políticos, sobreviventes de abuso, pacientes, trabalhadores e membros de grupos estigmatizados podem precisar de falar sem ligar cada declaração a uma identidade legal. Sistemas obrigatórios de nome real podem transferir risco dos agressores para os alvos. Contudo, identidade de baixo custo também torna a exclusão difícil. Um ator banido pode regressar, um grupo coordenado pode simular consenso, e uma botnet pode multiplicar participantes aparentes.

O quadro de desinibição online de Suler distinguiu abertura benigna de desinibição tóxica e identificou anonimato, invisibilidade, assincronicidade e autoridade enfraquecida como condições relevantes (Suler 2004). Trabalhos posteriores ligaram trolling a traços sádicos e manipuladores, mas investigação experimental também encontrou efeitos situacionais. Participantes expostos a humor negativo e discussão hostil tornaram-se mais propensos a

publicar material abusivo (Buckels, Trapnell, and Paulhus 2014; Cheng et al. 2017). A arquitetura não revela apenas caráter; molda comportamento.




Figura 4. Um ciclo recorrente de toxicidade: a provocação produz reação, a reação torna-se sinal de ranking, e a exposição repetida altera normas locais.

O trolling é apenas um padrão adversarial. O spam explora distribuição barata. Brigading importa uma audiência organizada para uma disputa local. O assédio coordena contacto repetido através de contas e serviços. Astroturfing simula apoio público independente. Bots sociais amplificam material ou fabricam atividade aparente. Operações de influência combinam personas, conteúdo direcionado, timing e narrativas entre plataformas. Estes comportamentos diferem em propósito e exigem respostas diferentes.

A vantagem de escala pertence geralmente ao atacante. Uma pessoa pode criar milhares de mensagens; cada destinatário deve decidir se uma mensagem é genuína. Um atacante pode testar muitas identidades; um defensor deve preservar acesso para recém-chegados legítimos. Uma alegação falsa pode ser repetida instantaneamente; um alvo deve recolher evidência através de sistemas fragmentados. Esta assimetria explica por que a moderação puramente local falha frequentemente contra abuso coordenado.

A reputação ajuda apenas quando é custosa de reconstruir e relevante para o contexto. Uma pontuação universal de reputação

criaria vigilância e transferiria autoridade entre domínios não relacionados. A reputação contextual é mais segura: um longo histórico numa comunidade de apoio médico não deve conferir poder num debate político, e uma credencial profissional verificada não deve apagar evidência de má conduta. Sistemas precisam de relações persistentes sem construir um sistema universal de crédito social.

A fricção, portanto, não é inimiga da liberdade. Fricção cuidadosamente posicionada pode protegê-la. Contas novas podem receber limites de taxa mais baixos. Convites em massa podem exigir endosso. Recursos podem exigir uma breve explicação em vez de um único clique irado. Ações de alto risco podem exigir credenciais mais fortes. O objetivo não é dificultar a participação, mas tornar o abuso em larga escala mais caro do que o uso humano ordinário.

A competição por estatuto intensifica estas dinâmicas. Contagens públicas de seguidores, karma, distintivos e métricas virais transformam a interação numa hierarquia visível. Estes sinais podem recompensar especialização e contribuição sustentada, mas também criam incentivos para certeza performativa, lealdade faccional e humilhação de rivais. O anonimato não remove estatuto; realocaliza o estatuto em históricos de conta e reconhecimento local.

O problema Sybil é, portanto, tão social quanto criptográfico. Exigir uma identidade legal por conta pode reduzir duplicação, mas cria vigilância e exclusão. Sistemas de proof-of-personhood podem estabelecer unicidade enquanto falham em estabelecer boa vontade ou competência. Introduções confiáveis e credenciais específicas de relação oferecem muitas vezes uma resposta mais proporcional. A questão não é “Este é um humano real?”, mas “Que direito tem este ator de realizar esta ação neste contexto?”

O assédio entre serviços expõe a fraqueza da aplicação isolada. Uma comunidade pode banir um ator enquanto outra fornece uma área de preparação. Uma vítima pode precisar de documentar dezenas de contas através de serviços. Sinais partilhados de abuso podem ajudar, mas arriscam criar listas negras opacas. Um sistema melhor partilha

evidência assinada, escopo e expiração, deixando as decisões finais às comunidades recetoras segundo os seus próprios procedimentos.

Uma Internet adversarial também deve distinguir erro de malícia. Detecção demasiado agressiva pode excluir recém-chegados, dialetos minoritários, ironia e discurso controverso. Sistemas automatizados são úteis para triagem e padrões óbvios, mas sanções sensíveis ao contexto exigem julgamento humano e salvaguardas procedimentais. Um sistema que bloqueia todo risco torna-se um sistema em que apenas atores estabelecidos podem falar.

3.2 Moderação como Governo

A moderação é frequentemente descrita como arrumação, como se as regras apenas removessem sujidade de um espaço de outro modo neutro. O trabalho de Gillespie mostra que a moderação define a própria plataforma. Decisões sobre discurso aceitável, ranking, integridade de contas e recomendação determinam que tipo de público existe (Gillespie 2018). Mesmo uma lista cronológica exige regras sobre spam, duplicados, identidade e remoção.

A moderação legítima começa com jurisdição. Um fornecedor global de infraestrutura deve intervir contra malware, fraude em larga escala e abuso grave entre comunidades. Uma comunidade local deve definir tópico, tom, especialização e expectativas culturais. Uma marca partilhada pode impor direitos mínimos e padrões de segurança. Quando estas camadas colapsam, desacordo local torna-se crise de plataforma e política de plataforma torna-se pretexto para dominação local.

As regras devem ser suficientemente compreensíveis para orientar conduta. Políticas extremamente detalhadas criam frequentemente aparência de precisão enquanto aumentam dependência de interpretação interna. Políticas extremamente vagas permitem aplicação arbitrária. A solução prática é uma camada constitucional concisa, regras locais e um corpo de precedentes anonimizados que mostre como casos recorrentes foram resolvidos.

Tabela 5. Padrões adversariais exigem respostas diferentes

Elemento	Significado ou consequência de desenho
Trolling e assédio	Limitar recompensa social, preservar evidência entre incidentes, proteger alvos e aplicar sanções graduadas com recurso.
Spam e botnets	Usar limites de taxa, reputação de remetente, prova de relação e fricção económica ou computacional proporcional à escala.
Brigading	Detetar chegada coordenada e votação importada sem tratar toda coligação impopular como ilegítima.
Astroturfing e operações de influência	Divulgar patrocínio, analisar coordenação, preservar incerteza de atribuição e separar operação de impacto alegado.
Quintas de conteúdo sintético	Reduzir recompensas por volume, exigir proveniência ou patrocínio e penalizar engano sistemático, não a automação em si.
Agentes pessoais comprometidos	Restringir capacidades, isolar segredos, registar autoridade delegada e tornar ações de alto impacto revogáveis e revisíveis.

O procedimento não é decoração burocrática. Utilizadores são mais propensos a compreender e aceitar moderação quando razões são fornecidas, mesmo quando não gostam do resultado (Jhaver, Bruckman, and Gilbert 2019). Recursos revelam erros, identificam regras pouco claras e restringem retaliação pessoal. Também impõem custo. Um sistema maduro usa revisão proporcional: correção automática para erros óbvios, recurso local para casos ordinários e revisão independente para disputas graves ou constitucionais.

Moderadores precisam de proteção além de supervisão. Podem enfrentar ameaças, conteúdo traumático, queixas coordenadas e pressão de membros influentes. O voluntariado não deve ocultar trabalho perigoso. Comunidades que dependem de moderação devem financiar formação, rotação, apoio à saúde mental e ferramentas seguras. Um moderador forçado a escolher entre burnout e abandono não consegue fornecer governação estável.

Experiências sobre intervenção de plataformas complicam a afirmação de que a aplicação apenas desloca o abuso para outro lado. Os bans do Reddit em 2015 foram associados a reduções substanciais no discurso de ódio entre utilizadores afetados, sem evidência clara de migração equivalente para comunidades adjacentes (Chandrasekharan et al. 2017). O resultado não justifica todos os bans. Demonstra que fronteiras podem mudar comportamento e que instituições não precisam de aceitar toxicidade como expressão imutável da procura.

O risco mais profundo é a captura constitucional. Uma classe de moderadores pode tornar-se permanente. Um fundador pode reter poder de emergência indefinidamente. Um contribuidor rico pode dominar porque o projeto depende de financiamento. Uma fação organizada pode inundar todas as consultas. A votação formal não resolve automaticamente estes problemas porque a participação é desigual e minorias intensas podem durar mais do que membros ordinários.

Um desenho mais robusto usa poderes separados. Criação de regras, aplicação, recursos, decisões de tesouraria e administração técnica não devem ser controlados pelas mesmas pessoas. Mandatos devem ser limitados. Conflitos de interesse devem ser declarados. Painéis selecionados aleatoriamente ou rotativos podem complementar eleições. Ações de emergência devem expirar salvo ratificação. Registos de auditoria devem tornar padrões visíveis sem expor vítimas privadas.

A escala altera o processo apropriado. Um pequeno grupo pode discutir um caso sincronicamente e confiar em memória partilhada. Uma rede com milhões de utilizadores precisa de triagem, evidência padronizada, delegação e auditoria estatística. A automação torna-se inevitável, mas deve recomendar e priorizar em vez de se tornar silenciosamente juiz final em casos ambíguos. Sistemas de alto volume devem publicar taxas de erro, resultados de recursos e disparidades entre línguas ou comunidades.

A inteligência artificial pode auxiliar a moderação ao agrupar comportamento coordenado, traduzir denúncias, identificar

precedentes e redigir razões. Também pode ampliar viés e criar falsa confiança. Um modelo linguístico que gera uma explicação plausível depois de um classificador opaco ter agido pode fazer o sistema parecer mais legítimo sem o tornar mais correto. Explicações devem estar ligadas a evidência e regras reais, não apenas ser retoricamente satisfatórias.

A legitimidade de um sistema de moderação também depende do tratamento dos observadores. Explicações públicas ensinam normas a todos que as veem. Aplicação secreta deixa a comunidade inferir regras a partir de rumores. A privacidade limita a divulgação em casos de assédio e segurança, mas precedentes anonimizados podem mostrar padrões sem expor vítimas. Com o tempo, este corpo de decisões torna-se uma common law da comunidade.

O objetivo não é imitar um Estado-nação em todos os fóruns. Pequenos grupos precisam de instituições leves. O princípio é a proporcionalidade: à medida que as consequências das decisões crescem, também deve crescer a qualidade do procedimento. Um grupo de passatempo pode confiar em custodiante confiáveis. Um sistema global de conhecimento, rede política ou mercado profissional não pode plausivelmente afirmar que a discrição de um proprietário é governo suficiente.

Capítulo 4: A Relevância É uma Constituição

O poder decisivo da Internet moderna não é frequentemente o poder de remover discurso, mas o poder de tornar algum discurso praticamente inevitável e outro praticamente invisível. Ranking é governação por probabilidade.

4.1 Pesquisa, Feeds, Envolvimento e a Deriva para a Idiocracy

Um sistema de ranking traduz um objetivo social em sinais mensuráveis. Motores de pesquisa estimam relevância através de texto, links, autoridade, atualidade, localização e muitos outros fatores. Feeds sociais estimam a probabilidade de interação. Recomendadores predizem preferência. Cada sistema pode ser tecnicamente excelente e ainda assim incorporar valores contestáveis.

O erro central é confundir resposta comportamental com preferência refletida. Uma pessoa pode clicar porque um item é útil, chocante, ofensivo, sexualmente provocador, assustador ou difícil de ignorar. Um comentário pode expressar gratidão ou raiva. Tempo gasto pode indicar fascínio ou confusão. Quando estes sinais são agregados em envolvimento, o sistema perde o significado do comportamento enquanto retém a sua intensidade.

A investigação sobre atenção coletiva mostra que os ciclos de informação aceleraram, aumentando a competição por um recurso humano finito (Lorenz-Spreen et al. 2019). Criadores adaptam-se produzindo material mais frequente, emocionalmente legível e estrategicamente empacotado. Plataformas observam então o comportamento gerado pelo seu próprio ranking e usam-no como evidência para o ranking seguinte. O recomendador não é um espelho passivo. Cria parte da distribuição de preferências que depois afirma detetar.




Figura 5. Quando reação mensurável substitui valor refletido, a relevância torna-se uma máquina de seleção de conteúdo simplificado e conflituoso.

A lei de Goodhart é muitas vezes invocada de forma vaga, mas o processo relevante é claro. Quando uma métrica se torna alvo, os participantes otimizam para ela. O título torna-se um dispositivo de clique. Os segundos iniciais tornam-se engenharia de retenção. A indignação torna-se um formato reutilizável. A métrica seleciona não apenas itens individuais, mas os tipos de criadores e instituições capazes de sobreviver.

Este é o mecanismo por trás da deriva para a “Idiocracy”. Conteúdo complexo não é inerentemente impopular, e os utilizadores não preferem universalmente disparate. Mas a complexidade exige frequentemente contexto e recompensa retardada, enquanto sistemas de ranking favorecem sinais disponíveis imediatamente. O sistema compara, portanto, o valor de longo prazo de um item com o estímulo imediato de outro e chama relevante ao vencedor.

O efeito é mais forte quando os custos de produção diferem radicalmente. Reportagem investigativa, síntese científica e crítica cuidadosa são caras. Um rumor, clip copiado ou provocação sintética é barato. Se ambos competem pelo mesmo pagamento por envolvimento, conteúdo de baixo custo pode inundar o mercado. A IA generativa aumenta esta assimetria ao reduzir ainda mais o custo de produção enquanto deixa a verificação cara.

A regulação pode exigir divulgação e feeds alternativos, mas transparência sobre “parâmetros principais” não é o mesmo que controlo do utilizador (European Union 2022). Uma plataforma pode publicar uma descrição ampla enquanto preserva um modelo inacessível e incentivos mistos. O remédio mais fundamental é recomendação plural: rankings cronológicos, baseados em relações, curados por especialistas, orientados para diversidade, de comunidade local e de agente pessoal devem poder coexistir sobre dados portáteis.

A personalização acrescenta um ciclo de feedback. O sistema infere que um utilizador gosta de um tópico, fornece mais desse tópico, observa interação aumentada porque alternativas são menos visíveis, e trata o resultado como confirmação. Com o tempo, o modelo pode confundir exposição com preferência e preferência com identidade. O utilizador torna-se mais fácil de predizer em parte porque o sistema estreitou o ambiente.

O viés de popularidade opera de modo semelhante no nível coletivo. Itens que recebem exposição precoce acumulam interação, o que produz mais exposição. A hierarquia resultante pode parecer meritocrática mesmo quando diferenças iniciais foram pequenas ou arbitrárias. Utilizadores orientados para nichos perdem descoberta, e criadores adaptam-se a formatos já bem-sucedidos. A investigação sobre recomendadores avalia cada vez mais diversidade, calibração e equidade porque a precisão isolada não descreve estes efeitos (Burke, Sonboli, and Ordonez-Gauger 2018).

Métricas alternativas são possíveis. Um sistema pode otimizar satisfação de longo prazo em vez de resposta imediata, medir se os utilizadores lamentam sessões, recompensar diversidade de fontes ou reservar capacidade para exploração. Contudo, toda alternativa continua a ser uma escolha de valor e pode ser manipulada. A solução não é a descoberta de uma métrica perfeita, mas concorrência entre políticas de ranking declaradas combinada com controlo do utilizador e auditoria independente.

A relevância deve ser tratada como uma afirmação com autor. Em vez de apresentar uma ordenação como a superfície natural do

mundo, os sistemas devem declarar o que o ranking otimiza, que interesses representa, que dados usa e que alternativas existem. Isto não remove julgamento. Torna o julgamento contestável.

4.2 Desinformação, Câmaras de Eco e Manipulação Eleitoral

“Fake news” é uma categoria instável que cobre histórias fabricadas, enquadramentos enganosos, sátira, propaganda, media manipulados e erros ordinários (Tandoc, Lim, and Ling 2018). A política torna-se confusa quando estes fenómenos são tratados como um único objeto técnico. Uma alegação factual falsa exige correção; engano coordenado exige atribuição; seleção partidária pode exigir fontes plurais; sátira pode exigir contexto em vez de remoção.

O estudo da Science por Vosoughi, Roy e Aral concluiu que histórias falsas no Twitter se difundiram mais longe, mais depressa e mais amplamente do que histórias verdadeiras no conjunto de dados examinado, com o comportamento humano a contribuir mais para a diferença do que bots (Vosoughi, Roy, and Aral 2018). O resultado é importante, mas não uma lei universal. Tópico, plataforma, tempo e definições importam. A exposição a fontes não fiáveis concentra-se muitas vezes numa minoria de utilizadores altamente envolvidos, em vez de se distribuir uniformemente pela população (Grinberg et al. 2019; Guess, Nyhan, and Reifler 2020).

Contas automatizadas ainda podem moldar difusão. Estudos encontraram bots sociais envolvidos na amplificação inicial de conteúdo de baixa credibilidade, aumentando a probabilidade de humanos o encontrarem e redistribuírem (Shao et al. 2018). A unidade significativa não é frequentemente o bot isolado, mas o sistema coordenado: contas, narrativas, timing, publicidade, influenciadores e media externos reforçam-se mutuamente.

A manipulação eleitoral deve ser analisada como uma cadeia causal. Uma operação pode existir. Uma audiência pode ser exposta. Atitudes ou comportamento podem mudar. A mudança pode alterar participação, agenda, donativos ou votos. O resultado eleitoral final pode mudar. A evidência é mais forte perto do início e torna-se mais

incerta a cada passo. A ausência de prova no passo final não torna a operação inofensiva; evidência da operação não prova o passo final.

Tabela 6. Afirmações sobre influência política devem permanecer distintas

Elemento	Significado ou consequência de desenho
Existiu uma operação	Pode frequentemente ser estabelecida através de contas, arquivos, infraestrutura, financiamento, coordenação e investigações de plataformas ou estatais.
As pessoas foram expostas	Exige medição de alcance, frequência, composição da audiência, duplicação entre plataformas e informação concorrente.
Crenças mudaram	Exige evidência causal, não apenas correlações entre exposição e preferência política prévia.
Comportamento mudou	Pode dizer respeito a partilha, participação eleitoral, donativo, atenção à agenda, intimidação ou desmobilização; cada um precisa de um desenho separado.
Um resultado eleitoral mudou	Geralmente não pode ser inferido da existência ou escala de uma operação porque o contrafactual eleitoral necessário é inobservável.

A campanha da Internet Research Agency durante a eleição dos Estados Unidos de 2016 está documentada em detalhe pela investigação do Senado. Usou redes sociais para explorar divisões, personificar grupos e influenciar o discurso político (United States Senate Select Committee on Intelligence 2019). A investigação estabeleceu intenção e atividade. Não pôde observar a eleição contrafactual sem a campanha. Afirmações de que a operação mudou certamente o vencedor excedem a evidência disponível.

O microtargeting tem limites semelhantes. A segmentação psicológica pode melhorar resposta em condições experimentais (Matz et al. 2017), mas os efeitos de persuasão de campanhas em eleições gerais são muitas vezes pequenos (Kalla and Broockman 2018). A segmentação ainda pode importar através de mobilização, angariação de fundos, formação de agenda ou reforço cumulativo. A posição intelectualmente honesta não é nem rejeição nem crença mágica em controlo mental.

Câmaras de eco acrescentam uma dimensão estrutural. Investigação entre plataformas encontra homofilia e exposição agrupada, mas a força difere por plataforma (Cinelli et al. 2021). O remédio proposto de mostrar conteúdo oposto pode sair pela culatra quando utilizadores o percebem como ameaça hostil à identidade (Bail et al. 2018). Uma política credível de diversidade deve introduzir desacordo através de fontes confiáveis, factos partilhados, incerteza e razões, não através de provocação máxima.

O ecossistema mediático estende-se para além das plataformas sociais. Televisão, meios partidários, influenciadores, elites políticas e motores de pesquisa podem originar ou legitimar narrativas que redes sociais depois aceleram. Benkler, Faris e Roberts argumentam que estruturas mediáticas e comportamento das elites foram centrais para o ambiente americano de desinformação, complicando relatos que atribuem causalidade primária a bots estrangeiros isolados ou credulidade individual (Benkler, Faris, and Roberts 2018).

A manipulação procura frequentemente incerteza em vez de crença. Inundar o ambiente com afirmações incompatíveis pode levar cidadãos a concluir que nenhuma fonte é confiável e que a verificação é inútil. Esta estratégia beneficia da falsa equivalência entre ceticismo saudável e cinismo universal. As instituições devem, portanto, comunicar como o conhecimento foi produzido, o que permanece incerto e que procedimentos podem corrigir erro.

Prebunking e fricção podem complementar correção. Avisar utilizadores sobre técnicas comuns de manipulação, atrasar a repartilha rápida ou pedir envolvimento contextual mínimo pode reduzir difusão impulsiva sem criar um ministério central da verdade. Estas medidas devem ser testadas quanto a efeitos comportamentais reais e monitorizadas quanto a encargos desiguais.

As correções funcionam imperfeitamente, mas não são inúteis. Meta-análises concluem que o debunking pode reduzir crenças falsas, com eficácia dependente do desenho da mensagem, repetição e audiência (Chan et al. 2017; Walter and Murphy 2018). A dificuldade é que a correção compete num ambiente que recompensa a novidade original. O desenho institucional deve,

portanto, alterar incentivos de distribuição, não apenas anexar fact-checks após a viralidade.

Capítulo 5: A Web Sintética e a Internet Que Ainda Funciona

A IA generativa aumenta tanto a capacidade produtiva da Internet como a incerteza de cada encontro. O perigo não é que as máquinas falem. É que proveniência, responsabilidade e custo da verdade se desprendam do volume do discurso.

5.1 Teoria da Internet Morta, Bots e Abundância Generativa

A Teoria da Internet Morta tornou-se popular porque deu forma dramática a uma experiência genuína: publicações repetidas, envolvimento vazio, artigos copiados, respostas de bots, imagens sintéticas e resultados de pesquisa otimizados para outras máquinas. A sua afirmação mais forte, de que a maior parte da vida online já foi substituída por um sistema artificial coordenado, carece de evidência credível. A sua afirmação mais fraca descreve uma transição real para produção e mediação automatizadas.

Bots não são inerentemente enganosos. Crawlers de pesquisa, serviços de monitorização, ferramentas de acessibilidade, tradutores e agentes pessoais são participantes automatizados. As distinções relevantes são se a automação é declarada, se existe um operador responsável, se o sistema simula humanos independentes e se a sua escala impõe custos a outros. Um agente benéfico pode tornar-se abusivo quando ignora limites de taxa ou extrai comunidades inteiras sem consentimento.

Sistemas generativos alteram a economia do conteúdo. Podem traduzir, resumir, ensinar, ajudar na programação e tornar conhecimento especializado mais acessível. Também podem produzir milhares de variações de um formato lucrativo, fabricar avaliações, personificar vozes locais e encher índices de pesquisa com redundância plausível. O custo médio de produzir uma asserção aproxima-se de zero, enquanto o custo de a verificar não.




Figura 6. A proveniência pode estabelecer origem e histórico de transformação; por si só, não pode estabelecer verdade, qualidade ou legitimidade.

Padrões de proveniência como C2PA podem registrar afirmações assinadas sobre a origem e o histórico de transformação de media. São úteis porque tornam adulteração e atribuição mais inspecionáveis. Não determinam a verdade. Uma declaração falsa assinada continua falsa, e material autêntico não assinado pode continuar valioso. A proveniência é uma camada de integridade, não um oráculo (C2PA 2026).

A contaminação recursiva de dados acrescenta um risco técnico. Shumailov e colegas mostraram que modelos treinados repetidamente em dados gerados por modelos podem perder informação sobre a distribuição original e eventualmente colapsar sob certas condições (Shumailov et al. 2024). Dados sintéticos podem ser úteis quando cuidadosamente gerados e misturados com originais fiáveis. O aviso diz respeito à substituição não controlada de evidência humana por outputs derivados de outputs anteriores.

A versão social desta recursão pode ser mais importante. Pessoas escrevem para sistemas de ranking. Modelos treinam em material ranqueado. Agentes resumem conteúdo moldado por modelos. Criadores otimizam então para resumos de agentes. A comunicação torna-se cada vez mais indireta. A intenção humana permanece presente, mas é filtrada por camadas que recompensam compatibilidade com outras máquinas.

A resposta não deve ser uma proibição universal de conteúdo sintético. Deve exigir automação declarada, operadores responsáveis, limites de taxa, proveniência quando apropriado e políticas de ranking separadas para produção humana e maquínica. Comunidades podem razoavelmente criar espaços em que apenas membros humanos verificados possam iniciar discussão, ao mesmo tempo que permitem que agentes auxiliem esses membros em privado.

A abundância sintética também desestabiliza a evidência social ordinária. Uma fotografia, testemunho ou estilo conversacional transportava antes sinais fracos mas úteis de esforço humano. Esses sinais podem agora ser reproduzidos de forma barata. Comunidades precisarão de formas mais fortes de continuidade: relações persistentes, proveniência assinada, processos editoriais conhecidos e reputações ganhas ao longo do tempo. Nenhuma é infalível, mas em conjunto aumentam o custo de fabricar um mundo social inteiro.

Motores de pesquisa e assistentes enfrentam uma escolha difícil. Excluir todo material gerado por máquina descartaria traduções, resumos e ferramentas úteis. Tratar todo material de modo idêntico permite que o volume domine. O ranking deve, portanto, considerar origem, responsabilidade, novidade e duplicação. Mil paráfrases derivadas de uma única fonte não devem criar mil votos independentes.

Agentes pessoais podem tornar-se tanto remédio como fonte de poluição. Podem filtrar material repetitivo e rastrear afirmações até aos originais, mas também podem gerar respostas automáticas, negociar com outros agentes e preencher canais com comunicação máquina-a-máquina. Protocolos devem tornar explícitos o estatuto de agente e o principal responsável, para que comunidades decidam que participação automatizada aceitam.

A Internet permanece viva quando as pessoas conseguem identificar fontes significativas, formar relações duradouras e criar artefactos que retêm valor fora de um feed. A ameaça não é apenas quantidade. É a perda de caminhos fiáveis da afirmação à fonte, da ação ao ator

responsável e da comunidade a uma história partilhada que não possa ser regenerada a pedido.

5.2 Wikipedia, Open Source, Ciência e Bens Comuns Duradouros

Um livro sobre falhas da Internet deve explicar os sistemas que funcionaram. Wikipedia, software open-source, OpenStreetMap, colaboração científica e comunidades especializadas demonstram que a cooperação em larga escala não é uma exceção romântica. São conquistas institucionais com características específicas de desenho.

A Wikipedia combina editabilidade radical com rastreabilidade extensa. Cada alteração pode ser inspecionada e revertida. A discussão está ligada aos artigos. Fontes importam mais do que autoridade pessoal em princípio, e disputas deixam registo. A comparação inicial da Nature com a Encyclopaedia Britannica foi contestada, mas estabeleceu que a produção colaborativa podia atingir um nível digno de comparação séria (Giles 2005).

As suas dificuldades revelam o custo do sucesso. Sistemas antivialização e normas densas protegem qualidade, mas aumentam o peso sobre recém-chegados. Halfaker e colegas ligaram o declínio na retenção de editores em parte à rejeição cada vez mais eficiente de contribuições (Halfaker et al. 2013). Desigualdades de género e estruturais afetam tópicos, linguagem e visibilidade (Wagner et al. 2016; Yun, Lee, and Jeong 2019). Um bem comum pode tornar-se conservador porque precisa de defender o que construiu.

Comunidades open-source combinam igualmente liberdade com governação. Projetos precisam de mantenedores, processos de lançamento, resposta de segurança, resolução de conflitos e controlo de nomes. O'Mahony e Ferraro mostraram como a autoridade pode emergir através de governação negociada, não de simples propriedade (O'Mahony and Ferraro 2007). A licença de código permite saída e reutilização, mas a cooperação duradoura depende das instituições em torno da licença.

Tabela 7. Porque alguns bens comuns online permanecem duradouros

Elemento	Significado ou consequência de desenho
Substrato técnico aberto	Participantes e operadores independentes podem inspecionar, reutilizar, reparar e construir serviços complementares.
Histórico visível	Alterações, reversões, fontes e disputas permanecem inspecionáveis em vez de desaparecerem num único estado atual.
Papéis delimitados	Editores, mantenedores, revisores e custodiante detêm poderes diferentes em vez de um papel indiferenciado de administrador.
Finanças alinhadas com a missão	O financiamento sustenta o ativo comum sem tornar publicidade comportamental ou enclausuramento proprietário o seu centro constitucional.
Mecanismos de reparação	Erros podem ser corrigidos, decisões recorridas, contribuidores ressocializados e normas danificadas reconstruídas.
Saída ou fork credível	A comunidade pode sobreviver à falha de um fornecedor, líder ou implementação sem perder toda a obra partilhada.

Estudos económicos sublinham a escala do valor público. Hoffmann, Nagle e Zhou estimam que substituir software open-source amplamente usado importaria custos enormes, muito além da receita direta dos projetos (Hoffmann, Nagle, and Zhou 2024). O contrafactual exato é debatível, mas a conclusão qualitativa não: empresas modernas dependem de um bem comum que não financiaram individualmente.

OpenStreetMap mostra como uma base de dados aberta pode servir navegação ordinária e resposta humanitária. Investigação sobre mapeamento humanitário encontrou milhões de edifícios e estradas acrescentados em regiões de menor desenvolvimento através de campanhas organizadas (Herfort et al. 2021). O projeto também exhibe desigualdades geográficas e de participação. A abertura cria a capacidade de corrigir pontos cegos, não uma garantia automática de que correções ocorram.

A ciência cidadã estende a cooperação à investigação. Sistemas como FlyWire coordenaram grandes comunidades online em torno de anotação e descoberta científicas (Dorkenwald et al. 2022). Os melhores projetos dão aos participantes contexto e reconhecimento significativos, em vez de os tratar como trabalho invisível de microtarefas. A colaboração científica torna-se duradoura quando os contribuidores conseguem compreender como o seu trabalho entra num processo epistémico maior.

Estes êxitos partilham um padrão. O artefacto é portátil ou publicamente acessível. A contribuição deixa histórico. Os papéis são inteligíveis. A reputação relaciona-se com o trabalho. A governação é suficientemente estável para proteger o projeto e suficientemente aberta para permitir contestação. O financiamento é diversificado ou institucionalmente apoiado. Nenhum é perfeitamente descentralizado. Cada um limita a propriedade do resultado coletivo.

Fóruns especializados oferecem um exemplo menos celebrado. Muitos preservaram conhecimento técnico através de tópicos pesquisáveis, limites temáticos estáveis e participantes que regressavam durante anos. O seu valor vinha da acumulação, não da viralidade. Quando esses fóruns fecharam ou foram absorvidos por plataformas genéricas, corpos inteiros de conhecimento tácito tornaram-se mais difíceis de encontrar. A continuidade arquivística é, portanto, uma função de bem público, não uma característica decorativa.

Comunidades de pacientes e de ajuda mútua mostram outra dimensão. Anonimato e experiência partilhada podem reduzir isolamento e preparar pessoas para interações com profissionais. Os mesmos espaços podem circular conselhos nocivos. O seu sucesso depende de clareza de papéis: experiência vivida, especialização médica, moderação e orientação de emergência não devem ser confundidas. Boas comunidades não eliminam desacordo; tornam visíveis a fonte e o estatuto das afirmações.

Bens comuns duradouros também beneficiam de missões delimitadas. A Wikipedia não tenta ser toda forma de publicação. Projetos Linux definem escopo técnico. OpenStreetMap define um

artefacto geográfico partilhado. Uma plataforma que tenta conter toda a vida social deve reconciliar normas incompatíveis e fica tentada a governar através do envolvimento, não do propósito. Comunidades constitucionais menores podem ser mais exigentes porque a pertença está ligada a um objetivo reconhecível.

A Internet futura deve generalizar estas lições através de bens comuns portáteis, custódia delimitada, direitos dos membros, financiamento duradouro e marcas constitucionais.

Capítulo 6: Para Além da Soberania das Plataformas

A alternativa ao domínio corporativo não é vazio institucional. É uma constituição em camadas na qual comunidades, marcas, operadores, contribuidores e membros possuem poderes diferentes e podem controlar-se mutuamente.

6.1 Comunidades Policêntricas e Marcas Descentralizadas

A governação policêntrica descreve sistemas com vários centros de decisão, em vez de uma autoridade soberana única. Unidades locais lidam com conhecimento local; unidades mais amplas lidam com padrões partilhados, danos transfronteiriços e recursos. A investigação de Ostrom mostrou que bens comuns podem ser governados sem privatização completa nem uma burocracia central única quando as regras correspondem ao recurso e os participantes podem influenciá-las (Ostrom 1990).

Comunidades online são adequadas ao desenho policêntrico porque os seus propósitos diferem. Um grupo de apoio médico, projeto de software, fórum político, comunidade de jogo e rede científica não devem partilhar normas de discurso idênticas. Regras universais de plataforma são necessariamente grosseiras. Autonomia local completa é igualmente inadequada quando o abuso atravessa comunidades ou quando líderes locais violam direitos básicos dos membros.

Uma marca descentralizada pode ligar estes níveis. A marca detém uma identidade pública partilhada, padrões mínimos, regras de certificação e talvez uma tesouraria. Comunidades locais operam sob a marca enquanto retêm autonomia cultural. Fornecedores de infraestrutura podem alojar instâncias conformes. Membros podem reconhecer uma promessa comum sem depender de uma corporação.

A marca deve estar juridicamente ancorada. Uma fundação, cooperativa, trust de propósito ou outra entidade de custódia pode deter marcas registradas e ativos partilhados sob deveres definidos por uma constituição. A entidade não deve ser livre para vender a marca ou alterar a missão como propriedade ordinária. O seu papel é custodial, não soberano.




Figura 7. Uma arquitetura policêntrica em que nenhum ator possui todas as camadas e os membros retêm voz, saída e benefício.

A licença de marca desempenha uma função semelhante a um contrato de franchising, mas muda a direção do controlo. O franchising convencional permite a um proprietário central licenciar uma reputação a operadores. Uma marca descentralizada licencia uma reputação coletivamente governada sob regras que também vinculam o custodiante. Operadores ganham o direito de usar o nome apenas enquanto cumprem padrões transparentes. Membros ganham direitos que não dependem da boa vontade de um operador.

O fork continua importante, mas deve ser compreendido corretamente. Código aberto permite saída técnica. Dados e identidade portáteis permitem saída social. A marca nem sempre pode viajar com um fork porque um nome partilhado perderia significado se qualquer projeto incompatível pudesse reivindicá-lo. Uma comunidade separada deve poder manter os seus dados e

relações enquanto adota um novo nome, salvo se o processo constitucional conceder certificação continuada.

O constitucionalismo digital fornece o vocabulário normativo: regras estáveis e públicas, poderes delimitados, aplicação igual, razões, recurso e consentimento significativo (Celeste 2019; Suzor 2019; Schneider 2024). Estes princípios não exigem controlo estatal de todas as comunidades. Exigem que instituições privadas que exercem poder semelhante ao público reconheçam deveres constitucionais.

Sistemas sociais federados fornecem evidência parcial. ActivityPub permite que servidores independentes troquem atividades sociais, demonstrando que um grafo social não precisa de pertencer a uma empresa (W3C 2018). Instâncias Mastodon podem estabelecer regras locais e bloquear domínios abusivos. O modelo restaura escolha significativa de administrador, mas também reproduz problemas familiares: burnout voluntário, moderação desigual, oligarquia ao nível da instância e descoberta difícil. A federação muda a localização do poder; não remove a necessidade de desenho constitucional.

Organizações autónomas descentralizadas fornecem um aviso paralelo. Votos on-chain tornam algumas decisões e fluxos financeiros inspecionáveis, mas a concentração de tokens pode transformar participação formal em plutocracia. Baixa participação permite que minorias organizadas dominem. Smart contracts executam o que está codificado, mas não conseguem determinar se a regra codificada é legítima. Um livro-razão é útil para auditoria e execução; não substitui julgamento institucional.

A marca descentralizada difere de um protocolo de federação e de uma DAO. Pode usar qualquer um deles, mas o seu núcleo é uma promessa governável. A marca especifica o que comunidades e fornecedores conformes devem aos membros, como a certificação é concedida e como o custodiante é restringido. A descentralização técnica torna-se um instrumento para manter esses compromissos.

O objetivo não é congelar a governação. Comunidades precisam de experimentação. Novos métodos de moderação, modelos económicos e sistemas de recomendação devem ser testados. Estruturas

policêntricas tornam a experimentação mais segura porque a falha pode permanecer local e práticas bem-sucedidas podem difundir-se. O erro de um fornecedor não precisa de redefinir toda a rede.

6.2 Economia, Licenciamento e Desenho Anticaptura

Uma comunidade duradoura precisa de dinheiro. Servidores, segurança, moderação, trabalho jurídico, backups, desenho e desenvolvimento não desaparecem porque o software é aberto. Sistemas que se recusam a discutir finanças dependem geralmente de subsídio oculto, trabalho não remunerado ou aquisição corporativa eventual.

A receita pode vir de subscrições, serviços profissionais, alojamento, mercados, certificação, bolsas, taxas de transação, patrocínio ou licenciamento comercial partilhado. Nenhuma fonte é neutra. Publicidade favorece atenção. Capital de risco favorece crescimento rápido e saída. Donativos favorecem causas visíveis e patronos ricos. Taxas podem excluir utilizadores de baixo rendimento. Uma instituição resiliente usa várias fontes e submete cada uma a limites constitucionais.

O licenciamento deve alinhar o bem comum com a economia em seu redor. Licenças permissivas maximizam reutilização, mas permitem que empresas capturem valor sem contribuição recíproca. Copyleft protege a abertura continuada de derivados, mas não financia automaticamente mantenedores nem distribui governação. Licenças source-available podem proteger um modelo de negócio enquanto deixam de satisfazer definições open-source. A escolha correta depende do ativo e dos objetivos da comunidade.

Tabela 8. Os instrumentos de uma marca descentralizada

Elemento	Significado ou consequência de desenho
Licença de software ou conteúdo	Define direitos de copiar, modificar, reutilizar e redistribuir o ativo técnico ou cultural.

Elemento	Significado ou consequência de desenho
Licença de marca	Define quem pode usar o nome compartilhado e que padrões de qualidade, interoperabilidade e conduta devem ser cumpridos.
Constituição de governação	Aloca poderes de criação de regras, moderação, tesouraria, emergência, auditoria e recurso.
Acordo de contribuição	Define atribuição, proveniência, obrigações de manutenção e quaisquer direitos económicos ou de governação obtidos por contribuição.
Regras de tesouraria e distribuição	Tornam previsíveis financiamento, reservas, pagamento de operadores, compensação de moderadores e benefício de contribuidores.
Sistema de auditoria e recurso	Testa conformidade, gere conflitos de interesse, publica precedentes e protege membros contra captura local ou central.

Uma marca descentralizada acrescenta outro instrumento. Operadores comerciais podem usar software aberto pagando por certificação, suporte, acesso a serviços partilhados ou o direito de se apresentarem sob o nome comum. A receita pode fluir para mantenedores, moderadores, infraestrutura e uma reserva. A comunidade não precisa de proibir comércio; precisa de impedir que o comércio se torne silenciosamente soberania.

A contabilidade de contribuições deve evitar reduzir cada ato a uma pontuação de token. Código, documentação, mediação de conflitos, resposta de segurança, mentoria, governação, capital e comunicação pública são formas diferentes de trabalho. Uma métrica única será manipulada e privilegiará aquilo que é mais fácil de contar. Avaliação mista, reconhecimento pelos pares, papéis definidos e orçamentos transparentes são mais realistas do que tokenização universal.

Regras anticaptura devem ser explícitas antes do conflito. Nenhum ator deve controlar simultaneamente tesouraria e auditoria. Grandes doadores devem divulgar dependências. Mandatos de moderadores devem ser limitados. Emendas constitucionais devem exigir mais do que uma maioria simples temporária. Operadores devem passar

testes de portabilidade. Poderes de emergência devem expirar. Contratos com partes relacionadas devem ser visíveis. Métricas de concentração devem ser publicadas.

O sistema também deve proteger liderança útil. Fundadores possuem frequentemente visão e conhecimento que não podem ser substituídos por votação aleatória. Mantenedores precisam de discrição. Investidores precisam de direitos previsíveis. O objetivo não é suspeita permanente da competência. É distinguir liderança de propriedade do futuro. A autoridade pode ser ampla dentro de um papel e ainda assim limitada no tempo, escopo e revisão.

Uma constituição funcional reconhece, portanto, pelo menos quatro círculos: membros afetados pelo sistema, contribuidores que o mantêm, operadores que assumem responsabilidade técnica e jurídica, e custodiante encarregados da missão de longo prazo. Nenhum grupo deve governar sozinho. Decisões diferentes podem exigir combinações diferentes de consentimento.

A reciprocidade pode ser desenhada sem proibir sucesso comercial. Uma empresa que implanta em escala o software de uma comunidade pode contribuir dinheiro, código, trabalho de segurança ou interoperabilidade. A obrigação pode ser ligada ao uso da marca partilhada ou de serviços de rede premium, em vez de a cada cópia do software. Isto evita fingir que o licenciamento por direitos de autor consegue, por si só, medir contribuição social.

A tesouraria deve financiar continuidade pouco glamorosa. Auditorias de segurança, backups, moderação, documentação, ferramentas de migração, defesa jurídica e apoio a recém-chegados raramente vencem concursos de popularidade, mas a sua ausência destrói instituições. Orçamentos devem, portanto, reservar fundos para manutenção em vez de distribuir tudo por votos de projeto ou popularidade de criadores.

Finanças transparentes também limitam conspiração e patronagem informal. Membros devem conhecer grandes fontes de receita, dependências contratuais e bandas de compensação. A privacidade pode proteger salários individuais quando apropriado, mas transações com partes relacionadas e doadores estratégicos exigem

divulgação. Uma instituição não pode reivindicar descentralização de forma credível enquanto depende silenciosamente de um único patrono.

A qualidade da descentralização é finalmente medida por três direitos. Voz significa a capacidade de influenciar regras e receber razões. Saída significa partir sem perder a substância da própria identidade e trabalho. Benefício significa partilhar de modo justo o valor económico e social criado. Um sistema que oferece apenas o direito de copiar código é tecnicamente aberto e institucionalmente incompleto.

Capítulo 7: A IA Pessoal como Recomendador do Utilizador

Os sistemas de recomendação constroem atualmente modelos privados dos utilizadores para plataformas. A IA pessoal torna possível um arranjo diferente: o modelo do utilizador pode tornar-se um instrumento governado pelo utilizador que negocia com plataformas, em vez de um ativo invisível possuído por elas.

7.1 De Perfis Ocultos à Relevância Governada pelo Utilizador

Plataformas modernas inferem interesses a partir de cliques, tempo de permanência, follows, compras, localização e semelhança com outros utilizadores. O perfil resultante é poderoso precisamente porque não é uma lista simples de preferências declaradas. Deteta padrões que o utilizador pode não articular. Contudo, o perfil é geralmente inacessível, difícil de corrigir e otimizado dentro da função objetivo da plataforma.

Um agente pessoal de recomendação poderia inverter esta relação. O agente manteria uma representação portátil dos interesses, obrigações, projetos atuais, aversões e preferências epistémicas do utilizador. Solicitaria itens candidatos de múltiplas fontes, ordená-los-ia localmente ou através de computação confidencial e explicaria por que um item foi selecionado. O utilizador poderia inspecionar e rever a política, em vez de apenas treiná-la através de comportamento inconsciente.

O avanço relevante é governação, não precisão preditiva. A investigação sobre sistemas de recomendação mostrou há muito que a experiência do utilizador depende de variedade percebida, esforço, privacidade, utilidade e confiança, não apenas de precisão estatística (Konstan and Riedl 2012; Knijnenburg et al. 2012). Explicações podem aumentar aceitação, embora transparência não crie confiança

automaticamente (Cramer et al. 2008). Um agente pessoal pode tornar estas preocupações objetivos de primeira classe.

O agente poderia manter vários modos em vez de um perfil permanente. Um modo profissional poderia priorizar fontes primárias e profundidade técnica. Um modo de lazer poderia procurar novidade. Um modo cívico poderia manter diversidade de exposição e separar reportagem verificada de comentário. Um modo de recuperação poderia reduzir tópicos perturbadores. Um utilizador poderia comparar o mesmo conjunto de candidatos sob políticas diferentes, em vez de aceitar uma ordenação opaca única.




Figura 8. Uma IA pessoal pode deslocar a recomendação de perfis ocultos de plataforma para relevância governada pelo utilizador.

Grandes modelos linguísticos são úteis porque conseguem traduzir intenções em linguagem natural em critérios de ranking, raciocinar entre domínios e explicar compromissos. Investigação emergente descreve uma passagem de perfis ocultos de plataforma para “governable personalization”, em que representações de utilizadores se tornam inspecionáveis, portáteis e revisíveis (Liu et al. 2026). Este trabalho é inicial, mas a direção institucional é mais importante do que qualquer modelo particular.

Um agente pessoal também poderia representar viés explícito em vez de fingir neutralidade. Um utilizador poderia instruí-lo a favorecer

fontes locais, evitar promoção de jogo, procurar evidência politicamente diversa ou apoiar uma comunidade profissional. O agente deve declarar esses compromissos. Viés oculto é perigoso porque se disfarça de relevância; viés declarado torna-se uma política que pode ser julgada.

As relações comerciais mudariam. Uma plataforma poderia oferecer itens candidatos e divulgar patrocínio, preço, proveniência e condições de acesso. O agente pessoal decidiria se o item se ajusta à política do utilizador. Publicidade tornar-se-ia uma oferta a um agente, não otimização encoberta de um feed. As plataformas continuariam a competir por atenção, mas deixariam de controlar exclusivamente o modelo usado para a alocar.

Um pipeline prático conteria etapas distintas. Fontes publicam itens candidatos e metadados. Serviços de recuperação identificam um conjunto amplo relevante para o contexto atual do utilizador. O agente pessoal aplica políticas relativas a qualidade, diversidade, tempo, risco e patrocínio. Uma camada final de apresentação explica seleções e preserva a possibilidade de inspecionar alternativas omitidas. O feedback atualiza o modelo local apenas segundo regras escolhidas pelo utilizador.

Esta separação importa porque descoberta e julgamento são funções diferentes. Um fornecedor global de pesquisa pode ser excelente a encontrar candidatos e inadequado para decidir prioridades do utilizador. Um curador comunitário pode identificar fontes confiáveis sem conhecer o contexto pessoal. Um agente local pode combinar estes inputs sem precisar de rastrear toda a Internet nem possuir todas as fontes.

O agente também pode negociar. Um comerciante pode oferecer preço, entrega, garantia e dados de comissão em formato legível por máquina. Uma fonte noticiosa pode divulgar autoria, política de correções, custo de acesso e proveniência. O agente pode rejeitar ofertas que ocultem patrocínio ou solicitar uma versão menos intrusiva. A recomendação torna-se uma troca de termos declarados, em vez de segmentação comportamental unilateral.

A representação do utilizador deve viajar independentemente do modelo. Uma pessoa pode substituir o modelo linguístico preservando uma política estruturada e histórico. Caso contrário, o fornecedor do modelo torna-se o novo soberano de plataforma. Esquemas abertos, repositórios pessoais encriptados e casos de avaliação exportáveis permitem ao utilizador comparar agentes e migrar sem reconstruir identidade a partir de cliques brutos.

A interoperabilidade é essencial. Feeds de candidatos precisam de metadados padrão, proveniência, divulgação de patrocínio, identificadores de conteúdo e informação sobre direitos. Comunidades poderiam publicar políticas certificadas de ranking. Programadores independentes poderiam fornecer recomendadores sem alojar a rede social subjacente. A recomendação tornar-se-ia uma camada competitiva, não uma funcionalidade inseparável de uma plataforma.

7.2 Privacidade, Viés, Pluralismo e o Risco de uma Câmara de Eco Pessoal

Um agente pessoal sabe mais do que um recomendador ordinário porque consegue combinar domínios. Esse é o seu valor e o seu perigo. Um perfil transversal pode revelar saúde, relações, finanças, crenças políticas e intenções futuras. Transferir o perfil da plataforma para um serviço cloud nominalmente pessoal não cria privacidade se o fornecedor do serviço puder inspecioná-lo.

A arquitetura preferida mantém memória sensível em dispositivos controlados pelo utilizador ou em ambientes confidenciais com fortes garantias de acesso. Modelos cloud podem processar contexto selecionado e minimizado. Investigação híbrida sugere que a utilidade da recomendação pode por vezes ser preservada enquanto características sensíveis permanecem locais, embora os resultados dependam do domínio e do modelo de ameaça (Khezresmaeilzadeh et al. 2025). A privacidade deve ser avaliada contra fluxos reais de dados, não contra branding.

A memória do agente deve ser suficientemente estruturada para inspeção. Um perfil em prosa pode ser expressivo, mas difícil de

auditar. Um sistema útil distingue comportamento observado, preferências declaradas pelo utilizador, hipóteses inferidas, contexto temporário e restrições rígidas. Cada item deve ter proveniência e uma regra de expiração. O utilizador deve poder perguntar por que o agente acredita em algo e eliminar a evidência ou inferência.

A personalização pode intensificar a autoconfirmação. Um modelo treinado para satisfazer pode aprender que tranquilização produz feedback positivo. Pode tornar-se um sicofanta que protege a identidade de evidência inconveniente. Investigação sobre recomendadores sensíveis à diversidade argumenta que diversidade de exposição pode ser objetivo de desenho, não apenas subproduto accidental (Helberger, Karppinen, and D'Acunto 2018). Um agente pessoal deve, portanto, apoiar exploração configurável, não apenas semelhança.

Tabela 9. Capacidades e salvaguardas para um recomendador pessoal

Elemento	Significado ou consequência de desenho
Modelo de utilizador editável	O utilizador pode inspecionar categorias, corrigir inferências falsas, definir objetivos temporários e reiniciar o modelo.
Memória privada e portátil	Histórico sensível permanece local ou fortemente protegido e pode mover-se independentemente de uma conta de plataforma.
Explicação e alternativas	O agente declara por que um item apareceu, o que foi excluído e que objetivo alternativo de ranking mudaria o resultado.
Restrições de pluralismo	Diversidade, novidade, desacordo, qualidade da fonte e alocação de tempo são políticas explícitas, não efeitos colaterais accidentais.
Firewall comercial	Pagamentos, relações de afiliado e incentivos de fornecedores são divulgados e não podem sobrepor-se silenciosamente à política do utilizador.
Defesas adversariais	Prompt injection, fontes envenenadas, plugins maliciosos e modelos comprometidos são contidos por proveniência, capacidades e auditoria.

Pluralismo não significa oposição aleatória. O agente deve identificar desacordo credível, distinguir consenso especializado de equilíbrio partidário e expor incerteza. Pode manter um orçamento para fontes desconhecidas, uma regra contra indignação repetida ou um requisito de que afirmações de alto impacto incluam evidência primária. Estas políticas devem ser escolhidas e visíveis, não impostas secretamente por uma plataforma ou fornecedor de modelo.

A segurança é outro problema. Conteúdo pode conter instruções dirigidas ao agente em vez de ao utilizador. Uma página maliciosa pode tentar extrair memória, alterar política de ranking ou acionar ações externas. A recomendação precisa, portanto, de isolamento entre conteúdo não confiável e estado privilegiado do agente. Recuperação, resumo e ação devem operar sob capacidades com fronteiras explícitas de dados.

Fornecedores de modelos também podem manipular. Um agente pessoal construído sobre um modelo remoto pode herdar prompts de sistema ocultos, prioridades comerciais, políticas de censura ou vulnerabilidades. O utilizador precisa de modelos substituíveis e suítes de teste que comparem comportamento entre fornecedores. Modelos locais menores podem tratar filtragem rotineira, enquanto modelos remotos mais fortes são invocados para tarefas difíceis sob divulgação restringida.

A responsabilidade deve permanecer com a instituição humano-agente, não com uma ficção antropomórfica. O agente não é um amigo soberano. É um sistema delegado cujo operador, fornecedor de modelo e canal de atualização podem ser identificados. Quando atua numa comunidade, deve apresentar o seu estatuto de automação, escopo de autoridade e principal responsável.

A auditoria deve incluir resultados, não apenas explicações. Um agente pode descrever uma política de diversidade enquanto seleciona repetidamente o mesmo agrupamento ideológico. Utilizadores e avaliadores independentes devem poder executar conjuntos de teste controlados, inspecionar distribuições de exposição e comparar comportamento ao longo do tempo. Uma

constituição de recomendação só é credível se os seus efeitos puderem ser medidos.

Utilizadores diferentes quererão diferentes graus de controlo. Alguns editarão políticas diretamente. Outros escolherão perfis certificados mantidos por comunidades confiáveis, jornalistas, organismos profissionais ou grupos da sociedade civil. Um mercado de políticas de recomendação pode apoiar pluralismo, desde que os utilizadores consigam ver financiamento, objetivos e evidência. A alternativa a um algoritmo único de plataforma não é que cada pessoa se torne engenheiro de machine learning.

A autonomia cognitiva também exige o direito de não personalizar. Um utilizador pode escolher um feed comum de interesse público, uma sequência cronológica ou uma amostra aleatória. A personalização deve ser uma lente entre várias. Sistemas que tornam o acesso não personalizado deliberadamente inferior preservam a velha coerção por trás de uma nova interface.

O melhor recomendador pessoal não maximizaria satisfação. Ajudaria o utilizador a governar a atenção segundo valores escolhidos, preservando a possibilidade de revisão. Por vezes surpreenderia, por vezes protegeria, por vezes desafiaria, e explicaria sempre que política está a aplicar. O utilizador deixaria de ser meramente o objeto da personalização e tornar-se-ia o seu autor constitucional.

Capítulo 8: Reconstruir a Comunicação a Partir da Camada de Protocolo

A Internet das plataformas assume que os serviços permanecem globalmente alcançáveis e depois filtra abuso após o contacto. Uma arquitetura diferente pode tornar relações, capacidades e negociação privada o padrão, preservando experiências familiares como endereços, caixas de entrada, grupos e chamadas.

8.1 WebRTC, Endereçamento Semelhante ao Email, DIDs e Ligações Condicionadas pela Confiança

O email teve êxito em parte porque o seu modelo de endereçamento é humanamente inteligível. Um nome local e domínio identificam uma rota sem exigir que ambos os participantes usem um fornecedor. Qualquer sucessor deve preservar esta vantagem social. As pessoas precisam de identificadores que possam ser ditos, impressos, lembrados, delegados por organizações e movidos entre fornecedores de serviço.

O identificador técnico por trás do endereço não precisa de ser idêntico ao nome legível por humanos. Um endereço baseado em domínio poderia resolver para um identificador descentralizado, chaves públicas, preferências de serviço e endpoints de introdução. W3C DID Core define identificadores cujos controladores podem provar controlo através de métodos criptográficos sem depender permanentemente de um fornecedor de identidade (W3C 2022). O trabalho DID 1.1 de 2026 continua esta arquitetura, enquanto Verifiable Credentials 2.0 fornece uma forma padrão para alegações verificáveis por máquina emitidas por terceiros (W3C 2025b; W3C 2026).

DIDs não criam confiança. Estabelecem controlo sobre um identificador e fornecem mecanismos de verificação e descoberta de serviços. Um burlão pode controlar um DID válido. Uma credencial só é significativa porque um verificador confia no emissor e a alegação é relevante. A arquitetura deve, portanto, combinar verificação criptográfica com contexto institucional, histórico de relação e aceitação explícita.

O primeiro contacto não deve exigir a exposição de um serviço pessoal permanente a tráfego arbitrário. Um serviço limitado de introdução pode aceitar pedidos pequenos e restringidos. O remetente pode apresentar uma referência, uma credencial comunitária, uma caução reembolsável, prova de relação prévia ou um pedido anónimo com limite de taxa. O agente do destinatário avalia o pedido sem revelar endpoints privados ou identidade completa.

Se aceite, as partes estabelecem uma capacidade: uma autorização revogável para comunicar sob condições definidas. A capacidade pode limitar taxa de mensagens, tipo de dados, duração, automação ou partilha posterior. Identificadores por par podem impedir que serviços não relacionados correlacionem trivialmente a mesma pessoa. A revogação pode terminar uma relação sem forçar uma mudança de identidade global.




Figura 9. Uma pilha de comunicação condicionada pela confiança que combina endereçamento legível, controlo portátil, credenciais seletivas, introdução delimitada e sessões encriptadas.

WebRTC é um transporte plausível para sessões interativas porque suporta áudio, vídeo e dados genéricos entre endpoints. Canais de dados WebRTC usam SCTP sobre transporte seguro, enquanto ICE descobre caminhos viáveis através de NATs e pode recorrer a relays TURN (IETF 2018; IETF 2021a; IETF 2021b; W3C 2025a). Um browser, agente desktop ou agente móvel pode, portanto, estabelecer comunicação rica sem que cada aplicação invente uma pilha multimédia proprietária.

WebRTC deixa deliberadamente a sinalização à aplicação. Isto é uma limitação e uma oportunidade. A camada de introdução e identidade pode trocar descrições de sessão e informação de conectividade após verificações de política. O transporte não precisa de saber se os participantes são humanos, agentes ou equipas mistas. Apenas transporta uma sessão autenticada quando camadas superiores estabelecem permissão.

Mensagens assíncronas exigem mais do que WebRTC porque pares podem estar offline. Uma caixa de correio ou relay pode guardar envelopes encriptados endereçados a uma capacidade, não a uma caixa de entrada pública irrestrita. Vários fornecedores poderiam oferecer serviço de armazenamento e reencaminhamento sem

conseguir ler conteúdo. Utilizadores poderiam mudar de fornecedor sem mudar de identidade. A caixa de entrada familiar permanece, mas a entrega global não solicitada deixa de ser o padrão.

A sequência de uma ligação pode, portanto, ser explícita. Um endereço legível por humanos resolve para um endpoint de introdução e material atual de verificação. O agente do remetente apresenta um pedido mínimo e qualquer credencial relevante. O agente do destinatário avalia política e pode pedir prova adicional. A aceitação cria uma capacidade com escopo e troca dados de sinalização. ICE tenta então um caminho direto ou retransmitido, e as partes estabelecem canais encriptados. Cada etapa expõe apenas a informação necessária para a seguinte.

Identificadores por par reduzem correlação. O utilizador pode apresentar um identificador diferente a um médico, empregador, familiar e comunidade pública, preservando recuperação e controlo através de uma carteira ou agente. Credenciais podem ser divulgadas seletivamente para que um verificador conheça um facto relevante sem adquirir o documento subjacente completo. O benefício de privacidade depende da implementação; metadados repetidos ou um resolvidor comum ainda podem ligar relações.

O endereçamento legível por humanos precisa de governação. Domínios são convenientes porque organizações podem delegar nomes, mas perda de domínio ou coerção por fornecedor pode perturbar identidade. Um desenho resiliente pode vincular o endereço legível a identificadores criptográficos portáteis e suportar provas de continuidade quando domínios mudam. Utilizadores não devem ser forçados a escolher entre nomes memoráveis e chaves autocontroladas.

Comunicação de grupo exige estado de pertença seguro e atualizações de chaves. Messaging Layer Security foi desenhado para grupos assíncronos que vão de pequenas conversas a grandes grupos, com forward secrecy e segurança pós-compromisso (IETF 2023). Pode complementar WebRTC em vez de o substituir: MLS protege mensagens de grupo, enquanto WebRTC pode transportar sessões ao vivo e canais de dados.

8.2 Uma Superfície de Ataque Menor para Humanos e Agentes

O principal ganho de segurança de uma arquitetura condicionada pela confiança é a exposição reduzida. Um dispositivo ou agente pessoal não precisa de aceitar ligações de entrada arbitrárias de toda a Internet. Serviços públicos permanecem públicos quando necessário, mas comunicação privada começa através de pontos estreitos de introdução com limites estritos de recursos. A maior parte do estado de alto valor permanece atrás de capacidades criadas após consentimento.

Isto não elimina ataques de negação de serviço. Serviços de introdução, servidores de sinalização, resolvedores DID, relays TURN e caixas de correio continuam alvos. Atacantes podem inundar verificação de credenciais ou adquirir credenciais legítimas. A arquitetura altera a economia ao tornar serviços caros indisponíveis antes de verificações baratas passarem, distribuir fornecedores e permitir que comunidades partilhem inteligência de abuso sem partilhar todos os dados dos utilizadores.

A privacidade também depende da escolha de relay. Ligações peer-to-peer diretas podem expor endereços de rede a correspondentes. Relays TURN podem escondê-los ao custo de infraestrutura e concentração de metadados. Um agente pessoal deve escolher caminhos diretos ou retransmitidos segundo relação e risco. A rota mais rápida nem sempre é a mais privada.

Tabela 10. Componentes de uma superfície de comunicação menor e mais privada

Elemento	Significado ou consequência de desenho
Endereço legível	Fornece usabilidade e descoberta semelhantes ao email enquanto permanece separável do operador que serve atualmente o utilizador.
DID ou identificador de controlo equivalente	Fornece controlo criptográfico portátil; por si só, não estabelece identidade, confiança ou reputação.
Credencial verificável	Permite prova seletiva de papel, pertença, endosso ou relação; as alegações continuam tão confiáveis quanto os seus emissores.

Elemento	Significado ou consequência de desenho
Serviço de introdução e capacidades	Expõe uma superfície estreita de pedidos e decide quem pode sinalizar, enviar, invocar, retransmitir ou formar uma relação duradoura.
ICE e WebRTC	Negociam caminhos interativos para media ou dados, usando conectividade direta quando possível e relays quando necessário.
Relay delimitado	Preserva fiabilidade e comportamento assíncrono sem se tornar proprietário permanente da relação ou do conteúdo em texto claro.
MLS ou segurança de grupo equivalente	Protege grupos em evolução com forward secrecy e segurança pós-compromisso; governação e entrega permanecem preocupações da aplicação.
Motor de política do agente pessoal	Aplica regras locais de consentimento, privacidade, taxa, proveniência, delegação e recuperação antes de expor ferramentas ou atenção.

A recuperação de chaves é um grande desafio prático. Identificadores autocontrolados são frágeis se a perda de um dispositivo destruir a identidade. Recuperação social, múltiplos dispositivos, guardiões institucionais e chaves apoiadas por hardware podem ajudar, mas cada uma introduz confiança. Um sistema utilizável precisa de políticas transparentes de recuperação e da capacidade de rodar chaves sem perder relações. DIDs suportam indireção entre identificador e métodos atuais de verificação, mas a governação específica de método permanece crítica.

O agente torna-se o centro operacional. Filtra introduções, verifica credenciais, seleciona modos de privacidade, gere capacidades, armazena histórico de relações e traduz entre protocolos. Pode também resumir mensagens e negociar horários de reuniões. Isto reduz carga cognitiva, mas o comprometimento do agente torna-se mais grave do que o comprometimento de uma aplicação convencional.

A arquitetura do agente deve, portanto, separar memória, comunicação e ação. Ler uma mensagem não deve conceder automaticamente acesso a memória privada. Um resumidor não

deve possuir autoridade de pagamento. Um módulo de recomendação não deve modificar chaves de identidade. Desenho interno baseado em capacidades pode limitar danos quando um componente é manipulado. Atualizações devem ser assinadas, auditáveis e reversíveis.

Comunidades podem acrescentar confiança institucional. Uma marca científica pode emitir credenciais para revisores. Uma comunidade de pacientes pode emitir provas de pertença sem revelar diagnósticos publicamente. Um mercado pode exigir uma credencial de escrow antes de contacto de alto valor. Um grupo político pode permitir pertença pseudónima enquanto limita contas automatizadas. Os mesmos protocolos suportam constituições diferentes.

A arquitetura também altera a descoberta. Em vez de um feed global, as pessoas podem descobrir comunidades através de diretórios, recomendações confiáveis, fornecedores de pesquisa ou agentes pessoais. Conteúdo público pode permanecer indexável quando os autores escolhem. Espaços privados podem revelar apenas descrições e procedimentos de admissão. O objetivo não é esconder a Internet, mas deixar de tratar exposição universal como a condição padrão de participação.

Uma transição poderia ser gradual porque a experiência do utilizador pode permanecer familiar. Uma aplicação pode continuar a parecer email, mensageiro, fórum ou espaço de trabalho colaborativo. Por baixo, a identidade é portátil, as relações são baseadas em capacidades, as sessões usam transportes abertos, a recomendação é pessoal e os fornecedores são substituíveis. Gateways de compatibilidade podem ligar email legado e contas de plataforma enquanto tornam visível o seu modelo de confiança mais fraco.

Os metadados permanecem um risco sério. Mesmo quando o conteúdo é encriptado, relays podem observar timing, volume, contrapartes e padrões de dispositivo. Identificadores por par e rotação de relays reduzem alguma correlação, mas aumentam complexidade e podem enfraquecer resposta a abuso. Comunidades

devem decidir que metadados retêm por segurança, por quanto tempo os retêm e sob que processo podem ser acedidos. “Privacidade total” deve significar minimização forte e inspecionável e controlo do utilizador, não a afirmação impossível de que nenhum metadado existe.

A disponibilidade cria outra troca. Sistemas peer-to-peer falham quando dispositivos estão offline, limitados por bateria ou atrás de redes restritivas. Relays e caixas de correio fornecem fiabilidade, mas fornecedores populares podem concentrar novamente. Testes de portabilidade, formatos interoperáveis de encriptação e replicação multi-fornecedor podem impedir que disponibilidade se torne soberania.

O caminho de transição deve começar por comunidades delimitadas e fluxos agente-a-agente, em vez de tentar substituir a Web pública. Redes profissionais, colaborações de investigação, famílias, serviços regulados e mercados privados têm fronteiras claras de relação e alto valor de privacidade. Gateways podem preservar acesso a email e web enquanto novas ligações usam capacidades e identidade portátil. Padrões bem-sucedidos podem então expandir-se.

Esta proposta não é uma suíte de protocolos acabada. É uma direção arquitetural construída a partir de componentes maduros e investigação por resolver. WebRTC fornece transporte interativo, mas não semântica social. DIDs e credenciais fornecem controlo e alegações verificáveis, mas não confiança. MLS fornece gestão de chaves de grupo, mas não governação. IA pessoal fornece automação de políticas, mas introduz uma nova superfície de ataque poderosa. A conquista em falta é a sua integração num sistema institucionalmente coerente.

A Internet original teve êxito porque separou aplicações da propriedade da rede. A próxima Internet pode ter êxito ao separar comunidades e agentes pessoais da propriedade das plataformas. Protocolos abertos devem transportar dados; constituições devem governar comunidades; agentes pessoais devem representar utilizadores; marcas descentralizadas devem deter promessas

partilhadas; fornecedores devem competir para operar serviços substituíveis.

A Internet permanecerá conflituosa porque os seres humanos permanecem conflituosos. Conterá comércio, ideologia, manipulação, cuidado, erudição, entretenimento e fraude. Uma arquitetura melhor não promete pureza. Torna mais difícil que qualquer corporação, grupo de moderadores, enxame automatizado ou fornecedor de modelo converta vantagem temporária em controlo irreversível. Esse é um padrão realista de progresso: não uma rede sem poder, mas uma rede na qual o poder deve justificar-se continuamente.

Referências

- Abbate, Janet. 1999. *Inventing the Internet*. Cambridge, MA: MIT Press.
- Bail, Christopher A., Lisa P. Argyle, Taylor W. Brown, John P. Bumpus, Haohan Chen, M. B. Fallin Hunzaker, Jaemin Lee, Marcus Mann, Friedolin Merhout, and Alexander Volfovsky. 2018. "Exposure to Opposing Views on Social Media Can Increase Political Polarization." *Proceedings of the National Academy of Sciences* 115 (37): 9216–9221. <https://doi.org/10.1073/pnas.1804840115>.
- Benkler, Yochai, Robert Faris, and Hal Roberts. 2018. *Network Propaganda: Manipulation, Disinformation, and Radicalization in American Politics*. New York: Oxford University Press. <https://doi.org/10.1093/oso/9780190923624.001.0001>.
- Brady, William J., Julian A. Wills, John T. Jost, Joshua A. Tucker, and Jay J. Van Bavel. 2017. "Emotion Shapes the Diffusion of Moralized Content in Social Networks." *Proceedings of the National Academy of Sciences* 114 (28): 7313–7318. <https://doi.org/10.1073/pnas.1618923114>.
- Buckels, Erin E., Paul D. Trapnell, and Delroy L. Paulhus. 2014. "Trolls Just Want to Have Fun." *Personality and Individual Differences* 67: 97–102. <https://doi.org/10.1016/j.paid.2014.01.016>.
- Burke, Robin, Nasim Sonboli, and Aldo Ordonez-Gauger. 2018. "Balanced Neighborhoods for Multi-Sided Fairness in Recommendation." In *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, 202–214. PMLR 81.
- C2PA. 2026. *C2PA Technical Specification, Version 2.4*. Coalition for Content Provenance and Authenticity. <https://c2pa.org/specifications/>.
- Celeste, Edoardo. 2019. "Digital Constitutionalism: A New Systematic Theorisation." *International Review of Law, Computers & Technology* 33 (1): 76–99. <https://doi.org/10.1080/13600869.2019.1562604>.
- CERN. 1993. "Statement Concerning CERN W3 Software Release into Public Domain." 30 April 1993. <https://cds.cern.ch/record/1164399>.
- Chan, Man-pui Sally, Christopher R. Jones, Kathleen Hall Jamieson, and Dolores Albarracín. 2017. "Debunking: A Meta-Analysis of the Psychological Efficacy

- of Messages Countering Misinformation.” *Psychological Science* 28 (11): 1531–1546. <https://doi.org/10.1177/0956797617714579>.
- Chandrasekharan, Eshwar, Umashanthi Pavalanathan, Anirudh Srinivasan, Adam Glynn, Jacob Eisenstein, and Eric Gilbert. 2017. “You Can’t Stay Here: The Efficacy of Reddit’s 2015 Ban Examined through Hate Speech.” *Proceedings of the ACM on Human-Computer Interaction* 1 (CSCW), Article 31. <https://doi.org/10.1145/3134666>.
- Cheng, Justin, Michael Bernstein, Cristian Danescu-Niculescu-Mizil, and Jure Leskovec. 2017. “Anyone Can Become a Troll: Causes of Trolling Behavior in Online Discussions.” In *Proceedings of the 2017 ACM Conference on Computer Supported Cooperative Work and Social Computing*, 1217–1230. <https://doi.org/10.1145/2998181.2998213>.
- Cinelli, Matteo, Gianmarco De Francisci Morales, Alessandro Galeazzi, Walter Quattrociocchi, and Michele Starnini. 2021. “The Echo Chamber Effect on Social Media.” *Proceedings of the National Academy of Sciences* 118 (9): e2023301118. <https://doi.org/10.1073/pnas.2023301118>.
- Clark, David D. 1988. “The Design Philosophy of the DARPA Internet Protocols.” *ACM SIGCOMM Computer Communication Review* 18 (4): 106–114. <https://doi.org/10.1145/52324.52336>.
- Cramer, Henriette, Vanessa Evers, Satyan Ramlal, Maarten van Someren, Lloyd Rutledge, Natalia Stash, Lora Aroyo, and Bob Wieringa. 2008. “The Effects of Transparency on Trust in and Acceptance of a Content-Based Art Recommender.” *User Modeling and User-Adapted Interaction* 18: 455–496. <https://doi.org/10.1007/s11257-008-9051-3>.
- Dorkenwald, Sven, et al. 2022. “FlyWire: Online Community for Whole-Brain Connectomics.” *Nature Methods* 19: 119–128. <https://doi.org/10.1038/s41592-021-01330-0>.
- European Union. 2022. “Regulation (EU) 2022/2065 on a Single Market for Digital Services.” *Official Journal of the European Union* L 277: 1–102.
- Giles, Jim. 2005. “Internet Encyclopaedias Go Head to Head.” *Nature* 438: 900–901. <https://doi.org/10.1038/438900a>.
- Gillespie, Tarleton. 2018. *Custodians of the Internet: Platforms, Content Moderation, and the Hidden Decisions That Shape Social Media*. New Haven, CT: Yale University Press.

- Grinberg, Nir; Kenneth Joseph, Lisa Friedland, Briony Swire-Thompson, and David Lazer. 2019. "Fake News on Twitter during the 2016 U.S. Presidential Election." *Science* 363 (6425): 374–378. <https://doi.org/10.1126/science.aau2706>.
- Guess, Andrew M., Brendan Nyhan, and Jason Reifler. 2020. "Exposure to Untrustworthy Websites in the 2016 US Election." *Nature Human Behaviour* 4: 472–480. <https://doi.org/10.1038/s41562-020-0833-x>.
- Halfaker, Aaron, R. Stuart Geiger, Jonathan T. Morgan, and John Riedl. 2013. "The Rise and Decline of an Open Collaboration System: How Wikipedia's Reaction to Popularity Is Causing Its Decline." *American Behavioral Scientist* 57 (5): 664–688. <https://doi.org/10.1177/0002764212469365>.
- Helberger, Natali, Kari Karppinen, and Lucia D'Acunto. 2018. "Exposure Diversity as a Design Principle for Recommender Systems." *Information, Communication & Society* 21 (2): 191–207. <https://doi.org/10.1080/1369118X.2016.1271900>.
- Helmond, Anne. 2015. "The Platformization of the Web: Making Web Data Platform Ready." *Social Media + Society* 1 (2). <https://doi.org/10.1177/2056305115603080>.
- Herfort, Benjamin, Sven Lautenbach, João Porto de Albuquerque, Jeff Anderson, and Alexander Zipf. 2021. "The Evolution of Humanitarian Mapping within the OpenStreetMap Community." *Scientific Reports* 11: 3037. <https://doi.org/10.1038/s41598-021-82404-z>.
- Hoffmann, Manuel, Frank Nagle, and Yanuo Zhou. 2024. "The Value of Open Source Software." *Harvard Business School Working Paper* 24-038. <https://doi.org/10.2139/ssrn.4693148>.
- IETF. 2018. *Interactive Connectivity Establishment (ICE): A Protocol for Network Address Translator Traversal*. RFC 8445. <https://doi.org/10.17487/RFC8445>.
- IETF. 2021a. *Overview: Real-Time Protocols for Browser-Based Applications*. RFC 8825. <https://doi.org/10.17487/RFC8825>.
- IETF. 2021b. *WebRTC Data Channels*. RFC 8831. <https://doi.org/10.17487/RFC8831>.
- IETF. 2023. *The Messaging Layer Security (MLS) Protocol*. RFC 9420. <https://doi.org/10.17487/RFC9420>.

- IETF. 2025. *The Messaging Layer Security (MLS) Architecture*. RFC 9750. <https://doi.org/10.17487/RFC9750>.
- Introna, Lucas D., and Helen Nissenbaum. 2000. "Shaping the Web: Why the Politics of Search Engines Matters." *The Information Society* 16 (3): 169–185. <https://doi.org/10.1080/01972240050133634>.
- Jhaveri, Shagun, Amy Bruckman, and Eric Gilbert. 2019. "Does Transparency in Moderation Really Matter? User Behavior after Content Removal Explanations on Reddit." *Proceedings of the ACM on Human-Computer Interaction* 3 (CSCW), Article 150. <https://doi.org/10.1145/3359252>.
- Kalla, Joshua L., and David E. Broockman. 2018. "The Minimal Persuasive Effects of Campaign Contact in General Elections: Evidence from 49 Field Experiments." *American Political Science Review* 112 (1): 148–166. <https://doi.org/10.1017/S0003055417000363>.
- Kanich, Chris, Christian Kreibich, Kirill Levchenko, Brandon Enright, Geoffrey M. Voelker, Vern Paxson, and Stefan Savage. 2009. "Spamalytics: An Empirical Analysis of Spam Marketing Conversion." *Communications of the ACM* 52 (9): 99–107. <https://doi.org/10.1145/1562164.1562190>.
- Khezresmaeilzadeh, Tina, Jiang Zhang, Dimitrios Andreadis, and Konstantinos Psounis. 2025. "Preserving Privacy and Utility in LLM-Based Product Recommendations." *arXiv:2505.00951*.
- Knijnenburg, Bart P., Martijn C. Willemsen, Zeno Gantner, Hakan Soncu, and Chris Newell. 2012. "Explaining the User Experience of Recommender Systems." *User Modeling and User-Adapted Interaction* 22: 441–504. <https://doi.org/10.1007/s11257-011-9118-4>.
- Konstan, Joseph A., and John Riedl. 2012. "Recommender Systems: From Algorithms to User Experience." *User Modeling and User-Adapted Interaction* 22 (1–2): 101–123. <https://doi.org/10.1007/s11257-011-9112-x>.
- Leiner, Barry M., Vinton G. Cerf, David D. Clark, Robert E. Kahn, Leonard Kleinrock, Daniel C. Lynch, Jon Postel, Larry G. Roberts, and Stephen Wolff. 1997. "A Brief History of the Internet." *Internet Society*, subsequently updated.
- Liu, Jiahao, Mingzhe Han, Guanming Liu, Weihang Wang, Dongsheng Li, Hansu Gu, Peng Zhang, Tun Lu, and Ning Gu. 2026. "From Hidden Profiles to Governable Personalization: Recommender Systems in the Age of LLM Agents." *arXiv:2604.20065*.

- Lorenz-Spreen, Philipp, Bjarke Mørch Mønsted, Philipp Hövel, and Sune Lehmann. 2019. "Accelerating Dynamics of Collective Attention." *Nature Communications* 10: 1759. <https://doi.org/10.1038/s41467-019-09311-w>.
- Matias, J. Nathan. 2019. "The Civic Labor of Volunteer Moderators Online." *Social Media + Society* 5 (2). <https://doi.org/10.1177/2056305119836778>.
- Matz, Sandra C., Michal Kosinski, Gideon Nave, and David J. Stillwell. 2017. "Psychological Targeting as an Effective Approach to Digital Mass Persuasion." *Proceedings of the National Academy of Sciences* 114 (48): 12714–12719. <https://doi.org/10.1073/pnas.1710966114>.
- O'Mahony, Siobhán, and Fabrizio Ferraro. 2007. "The Emergence of Governance in an Open Source Community." *Academy of Management Journal* 50 (5): 1079–1106. <https://doi.org/10.5465/amj.2007.27169153>.
- Ostrom, Elinor. 1990. *Governing the Commons: The Evolution of Institutions for Collective Action*. Cambridge: Cambridge University Press. <https://doi.org/10.1017/CBO9780511807763>.
- Rathje, Steve, Jay J. Van Bavel, and Sander van der Linden. 2021. "Out-Group Animosity Drives Engagement on Social Media." *Proceedings of the National Academy of Sciences* 118 (26): e2024292118. <https://doi.org/10.1073/pnas.2024292118>.
- Saltzer, Jerome H., David P. Reed, and David D. Clark. 1984. "End-to-End Arguments in System Design." *ACM Transactions on Computer Systems* 2 (4): 277–288. <https://doi.org/10.1145/357401.357402>.
- Schneider, Nathan. 2024. *Governable Spaces: Democratic Design for Online Life*. Oakland: University of California Press. <https://doi.org/10.1525/luminos.181>.
- Shao, Chengcheng, Giovanni Luca Ciampaglia, Onur Varol, Kai-Cheng Yang, Alessandro Flammini, and Filippo Menczer. 2018. "The Spread of Low-Credibility Content by Social Bots." *Nature Communications* 9: 4787. <https://doi.org/10.1038/s41467-018-06930-7>.
- Shaw, Aaron, and Benjamin Mako Hill. 2014. "Laboratories of Oligarchy? How the Iron Law Extends to Peer Production." *Journal of Communication* 64 (2): 215–238. <https://doi.org/10.1111/jcom.12082>.
- Shumailov, Ilia, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. 2024. "AI Models Collapse When Trained on

- Recursively Generated Data.” Nature* 631: 755–759. <https://doi.org/10.1038/s41586-024-07566-y>.
- Suler, John. 2004. “The Online Disinhibition Effect.” *CyberPsychology & Behavior* 7 (3): 321–326. <https://doi.org/10.1089/1094931041291295>.
- Suzor, Nicolas P. 2019. *Lawless: The Secret Rules That Govern Our Digital Lives*. Cambridge: Cambridge University Press. <https://doi.org/10.1017/9781108666428>.
- Tandoc, Edson C., Jr., Zheng Wei Lim, and Richard Ling. 2018. “Defining ‘Fake News’: A Typology of Scholarly Definitions.” *Digital Journalism* 6 (2): 137–153. <https://doi.org/10.1080/21670811.2017.1360143>.
- Terranova, Tiziana. 2000. “Free Labor: Producing Culture for the Digital Economy.” *Social Text* 18 (2): 33–58. https://doi.org/10.1215/01642472-18-2_63-33.
- Turner, Fred. 2006. *From Counterculture to Cyberculture: Stewart Brand, the Whole Earth Network, and the Rise of Digital Utopianism*. Chicago: University of Chicago Press.
- United States Senate Select Committee on Intelligence. 2019. *Russian Active Measures Campaigns and Interference in the 2016 U.S. Election, Volume 2: Russia’s Use of Social Media with Additional Views*. Washington, DC: United States Senate.
- Vosoughi, Soroush, Deb Roy, and Sinan Aral. 2018. “The Spread of True and False News Online.” *Science* 359 (6380): 1146–1151. <https://doi.org/10.1126/science.aap9559>.
- W3C. 2018. ActivityPub. W3C Recommendation, 23 January 2018. <https://www.w3.org/TR/activitypub/>.
- W3C. 2022. Decentralized Identifiers (DIDs) v1.0. W3C Recommendation, 19 July 2022. <https://www.w3.org/TR/did-core/>.
- W3C. 2025a. WebRTC: Real-Time Communication in Browsers. W3C Recommendation, 13 March 2025. <https://www.w3.org/TR/webrtc/>.
- W3C. 2025b. Verifiable Credentials Data Model v2.0. W3C Recommendation, 15 May 2025. <https://www.w3.org/TR/vc-data-model-2.0/>.
- W3C. 2026. Decentralized Identifiers (DIDs) v1.1. W3C Candidate Recommendation Snapshot, 5 March 2026. <https://www.w3.org/TR/did-1.1/>.

Wagner, Claudia, Eduardo Graells-Garrido, David Garcia, and Filippo Menczer. 2016. "Women through the Glass Ceiling: Gender Asymmetries in Wikipedia." *EPJ Data Science* 5: 5. <https://doi.org/10.1140/epjds/s13688-016-0066-4>.

Walter, Nathan, and Sheila T. Murphy. 2018. "How to Unring the Bell: A Meta-Analytic Approach to Correction of Misinformation." *Communication Monographs* 85 (3): 423–441. <https://doi.org/10.1080/03637751.2018.1467564>.

Yun, Jinhyuk, Sang Hoon Lee, and Hawoong Jeong. 2019. "Early Onset of Structural Inequality in the Formation of Collaborative Knowledge in All Wikimedia Projects." *Nature Human Behaviour* 3 (2): 155–163. <https://doi.org/10.1038/s41562-018-0488-z>.