

MORE WORDS THAN REALITY.

AI, Epistemic and Axiologic Guardians,
and the Road to Executable Science



ILLUSIONS OF DISCOVERY, EXECUTABLE SCIENCE,
AND A NEURO-SYMBOLIC RESEARCH PROGRAM
FOR TRUTH, VALUE, AND SELF-CORRECTION

MORE WORDS THAN REALITY

***Mai multe cuvinte decât realitate:
Epistemic Guardian, Axiologic Guardian
și drumul către Executable Science***

ILUZIILE DESCOPERIRII, EXECUTABLE SCIENCE ȘI UN PROGRAM
NEURO-SIMBOLIC PENTRU ADEVĂR, VALOARE ȘI AUTOCORIJARE

Ediție de cercetare extinsă • august 2026

Copyright © [2026] Axiologic Research

All rights reserved.

KDP publishing rights held by Outfinity SRL (Iași, Romania).

Available for free on Axiologic website (www.axiologic.net).

Author's Note

This work was created under the umbrella of Axiologic Research as part of two interconnected research programs, one dedicated to Artificial Intelligence and the other to Outfinitism, both led by Șinică Alboaie. To explore the details of how these two programs intersect and build upon each other, we invite readers to visit the Outfinity Venture Studio page at www.outfinity.ch.

While Artificial Intelligence language models were used to assist with text generation, the foundational philosophy, thematic structure, and analytical approach derive exclusively from the author's decades of dedicated study of social phenomena, social technologies, and genuine hard technologies resulting from various European and self funded research projects. Recently, within the Achilles research project, we have been deeply studying AI generated literature and its automated verification using neuro symbolic approaches; all the free books made available to the public are part of the suite of works we use to test our latest technologies.

Notă editorială

Această ediție așază Epistemic Guardian și Axiologic Guardian într-o viziune mai largă: Executable Science, adică știința executabilă. Titlul rămâne deliberat comercial și ușor provocator. More Words Than Reality numește pericolul central al unei epoci în care ipotezele, arhitecturile, codul, ecuațiile, experimentele, articolele și review-urile pot fi generate mai repede decât poate fi stabilită legătura lor cu realitatea. Cartea nu este un argument împotriva inteligenței artificiale generative. Este un argument pentru infrastructura care trebuie să însoțească abundența generativă.

Obiectul final este o carte, nu o specificație tehnică. Rolul ei este să clarifice problema, să ordoneze peisajul intelectual și să deschidă un drum credibil către sisteme pe care cercetătorii și instituțiile le-ar putea construi și testa. Descrierile arhitecturale sunt prezentate la nivelul necesar pentru a orienta cercetarea, standardele, prototipurile și parteneriatele. Ele nu sunt afirmații că sistemele complete există deja. Acolo unde mai multe proiectări rămân plauzibile, cartea le păstrează ca posibilități alternative, fără să fabrice un consens prematur.

Rezultatele publicate, sinteza autorului și propunerile de cercetare sunt păstrate distinct. DOVEZI PUBLICATE identifică rezultate sau precedente susținute de sursele citate. SINTEZĂ ȘI INFERENȚĂ identifică interpretarea cărții la intersecția mai multor literaturi. PROPUNERE DE CERCETARE identifică o arhitectură, metodă, benchmark, practică instituțională sau componentă tehnică ce trebuie încă demonstrată. Câteva surse din 2026 sunt preprinturi recente și sunt tratate ca indicii ale unei frontiere emergente, nu ca adevăruri stabilizate.

Contribuția distinctivă a ediției este sinteza: cei doi Guardians nu sunt doar critici așezați lângă un „AI scientist”. Ei sunt propuși drept componente tot mai autonome ale unui ecosistem în care munca științifică devine treptat structurată, versionată, executabilă acolo unde este posibil, interpretabilă automat acolo unde este util și contestabilă de oameni pe întreg ciclul ei de viață. Argumentul este fundamentat în sursele academice și tehnice citate în carte; arhitectura care le leagă rămâne o propunere ce trebuie testată.

Cartea folosește expresia Executable Science într-un sens larg, dar disciplinat. Unele obiecte științifice pot fi executate literalmente ca software, workflow-uri, simulări sau demonstrații formale. Altele pot deveni executabile numai sub forma unor protocoale explicite, teste, proceduri de

decizie, ipoteze cauzale sau obligații de evidență care continuă să necesite instrumente, laboratoare, teren ori deliberare. Executabilitatea nu este adevăr. Ea este capacitatea de a expune suficientă structură încât un calculator să poată ajuta la rularea, inspectarea, compararea, contestarea, actualizarea și reproducerea unor părți ale cercetării, fără pretenția că orice judecată științifică a devenit calculabilă.

Cuprins

Prefață

Notă metodologică și statutul afirmațiilor

Introducere. Când cercetarea poate fi imitată înainte de a fi făcută

Capitolul 1. Apariția progresului fără progres

- 1.1. Când plauzibilitatea devine ieftină
- 1.2. Psihologia înțelegerii aparente
- 1.3. De la demonstratorul solitar la pachetul automat de validare

Capitolul 2. Anatomia unei descoperiri care nu există

- 2.1. Taxonomia iluziilor și Reality Gap
- 2.2. Când problema este înlocuită de specificație
- 2.3. Bucla epistemică închisă și validarea circulară

Capitolul 3. Matematica dintre rigoare și decor

- 3.1. Mathiness, idealizare și formalism fără putere discriminantă
- 3.2. Informatică, machine learning, simulare și calcul cuantic
- 3.3. Teoria stringurilor și gradele de contact cu realitatea

Capitolul 4. De la articolul științific la Executable Science

- 4.1. Articolul ca interfață, nu ca întregul obiect al cercetării
- 4.2. Research State, formalizare progresivă și revizuire observabilă
- 4.3. Un ecosistem neuro-simbolic care poate citi, rula, contesta și memora știința

Capitolul 5. Epistemic Guardian

- 5.1. Mașina stărilor epistemice și independența verificării
- 5.2. Instrumentele: de la contractul problemei la falsificator
- 5.3. Guardian-ul în research IDE, laborator, instituție și rețeaua științifică

Capitolul 6. Axiologic Guardian

- 6.1. Protejarea valorilor cercetătorului și ale instituției
- 6.2. Valoarea pentru umanitate fără un dictator al utilității
- 6.3. Cum poate fi operaționalizată o judecată axiologică pluralistă

Capitolul 7. Pot LLM-urile să judece?

- 7.1. Dovezile despre LLM-as-a-judge și judecata morală
- 7.2. Protocolul unei judecăți hibride calibrate
- 7.3. Arhitectura neuro-simbolică a sistemului dual

Capitolul 8. Un program de cercetare care poate eșua

- 8.1. Ipoteze, benchmarkuri și experimente
- 8.2. Metrici, piloți și traseul de dezvoltare
- 8.3. Instituții care învață fără să-și delege conștiința

Concluzie. De la cercetători artificiali la o știință capabilă de autocorecție

Anexa A. Guardians în arhitectura Executable Science

Anexa B. Metrici pentru un ecosistem științific autocorectiv

Anexa C. Pachetul minim de cercetare executabilă

Anexa D. O Research Constitution provizorie

Anexa E. Exemplu de raport Dual Guardian

Glosar

Bibliografie

Prefață

Această carte a pornit dintr-o experiență personală repetată și dintr-un tipar pe care îl observ tot mai des în spațiul public. În lucrul cu sisteme generative, o idee vagă poate căpăta, în câteva minute, nume, arhitectură, diagramă, vocabular tehnic, cod, teste, demonstrații, review și o concluzie optimistă. Fiecare artefact pare să confirme artefactul anterior. Arhitectura justifică algoritmul, algoritmul justifică implementarea, implementarea trece testele pe care același sistem le-a produs, iar raportul final descrie succesul într-o limbă care seamănă suficient de mult cu literatura științifică pentru a suspenda, măcar temporar, îndoiala. Când revenim însă la întrebarea inițială — ce problemă a fost rezolvată, față de ce alternativă, prin ce probă independentă și cu ce limitări — uneori descoperim că întregul edificiu a crescut în jurul unei substituții subtile. Avem mai multe cuvinte, mai multe fișiere și mai multă coerență, dar nu neapărat mai mult contact cu realitatea.

Nu este o problemă complet nouă. Istoria matematicii, fizicii și medicinei este plină de oameni convinși că au demonstrat o teoremă celebră, au infirmat relativitatea, au găsit perpetuum mobile sau au vindecat o boală printr-un mecanism pe care comunitatea științifică nu l-a înțeles. Unele asemenea afirmații provin din eroare sinceră, altele din orgoliu, neînțelegere metodologică sau izolare intelectuală. Literatura despre „mathematical cranks” documentează de mult felul în care o idee poate deveni imună la contraargumente și poate absorbi ani de muncă fără să se apropie de criteriile domeniului [1]. Tot istoria matematicii arată însă și contrariul: contribuții reale, inclusiv demonstrația lui Andrew Wiles pentru ultima teoremă a lui Fermat, au trecut prin erori descoperite, revizii, verificări independente și o reconstrucție dificilă a argumentului [2, 3]. Linia de demarcație nu este statutul social al autorului și nici eleganța textului, ci calitatea procesului prin care o afirmație este expusă riscului de a fi greșită.

Inteligența artificială generativă modifică radical costul și scara acestui fenomen. În trecut, o teorie greșită putea necesita luni pentru a fi îmbrăcată într-o formă tehnică. Astăzi, un model poate produce aproape instantaneu un pachet complet de aparentă cercetare. Mai mult, sistemul poate adapta explicația la obiecții, poate genera variații ale formalismului, poate scrie un prototip, poate inventa teste și poate simula un review. Această capacitate este extraordinar de utilă atunci când este conectată la surse, instrumente, compilatoare, proof assistants, laboratoare sau evaluatori independenți. Devine periculoasă atunci când confundăm

capacitatea de a produce semnele exterioare ale cercetării cu capacitatea de a produce cunoaștere.

Cartea nu este un rechizitoriu împotriva AI. Dimpotrivă, pleacă de la convingerea că generarea abundentă de ipoteze, modele și experimente poate accelera știința. Dar abundența schimbă locul în care se află resursa rară. Când ideile, explicațiile și codul devin ieftine, selecția severă, validarea independentă și reproducerea devin mai valoroase. O infrastructură de cercetare construită pentru o lume în care ipotezele erau rare nu este automat adecvată unei lumi în care putem produce zece mii de ipoteze într-o după-amiază. Avem nevoie de sisteme care nu doar inventează, ci caută activ cel mai ieftin mod de a ne arăta că invenția nu funcționează.

Termenul central al cărții este „decalajul față de realitate”, sau reality gap: diferența dintre contribuția percepută a unui artefact și contribuția care supraviețuiește verificării independente. El poate apărea în multe forme. O arhitectură pare nouă fiindcă modulele au fost redenumite. O demonstrație formală este corectă, dar formalizează o propoziție mai slabă decât problema reală. Codul trece testele, însă testele codifică aceeași neînțelegere ca implementarea. Un grup de agenți ajunge la consens, dar agenții împart același model, aceleași date și aceleași orbiri. Un articol pare complet deoarece toate secțiunile sunt prezente, deși contribuția nu a trecut de un baseline serios. În aceste cazuri, nu este obligatoriu ca modelul să „halucineze” în sensul simplu al inventării unui fapt. Fiecare propoziție poate fi local plauzibilă, iar concluzia globală să rămână nejustificată.

Programul constructiv propus aici este neuro-simbolic. Modelele de limbaj sunt foarte bune la interpretarea limbajului, la generarea de alternative și la conectarea unor literaturi îndepărtate. Sistemele simbolice sunt mai potrivite pentru menținerea identității unei probleme, urmărirea dependențelor, aplicarea unor reguli explicite și interzicerea promovărilor epistemice nepermise. Instrumentele externe — motoare de căutare, executori de cod, analizatoare statice, verificatoare de teoreme, sisteme de statistică, simulatoare, senzori și laboratoare — introduc constrângeri care nu pot fi obținute doar prin continuarea textului. Arhitectura pe care o propunem nu încearcă să înlocuiască cercetătorul, ci să facă vizibile momentele în care o narațiune coerentă încearcă să treacă drept dovadă.

Principiul care va reveni în întregul volum este simplu: limbajul poate formula o afirmație, o poate clarifica, critica sau reformula, dar nu îi poate ridica singur statutul epistemic. O ipoteză nu devine rezultat fiindcă a primit o ecuație. Un rezultat nu devine mecanism fiindcă a primit o explicație. Un program nu devine soluție fiindcă rulează. Un consens între agenți nu

devine replicare. Pentru fiecare trecere trebuie să existe un eveniment epistemic admisibil: o sursă independentă, un test discriminant, un counterexample căutat și absent în limite declarate, o execuție reproducibilă, o demonstrație verificată relativ la enunțul corect, o măsurătoare, o intervenție sau o replicare.

În acest sens, cartea este simultan avertisment, sinteză și specificație de cercetare. Ea încearcă să descrie problema fără panică, să separe ceea ce a fost deja observat empiric de ceea ce rămâne inferență și să transforme îngrijorarea într-un set de instrumente testabile. Ținta nu este o AI mai puțin creativă, ci o AI a cărei creativitate este legată de mecanisme care fac dificilă confundarea textului cu lumea.

Această ediție extinde avertismentul inițial într-o arhitectură duală. Numele Epistemic Guardian desemnează infrastructura care păstrează diferența dintre afirmație, verificare și cunoaștere. Numele Axiologic Guardian desemnează infrastructura care păstrează diferența dintre ceea ce putem construi, ceea ce cercetătorii și instituțiile declară că prețuiesc și ceea ce poate avea valoare pentru oameni și pentru viitor. Ambele nume sunt propuneri de cercetare, nu produse validate și nici promisiuni că judecata poate fi delegată unui model.

Orizontul mai larg al argumentului este Executable Science. Comunicarea științifică tratează încă articolul drept principalul obiect de evidență. Articolul rămâne indispensabil, fiindcă cercetătorii au nevoie de narațiuni, interpretare, responsabilitate și de un argument public inteligibil. Totuși, el este un recipient slab pentru întreaga viață a unei cercetări. Nu poate păstra în mod natural relația evolutivă dintre întrebări, ipoteze, presupuneri, seturi de date, cod, protocoale, rezultate negative, intervenții ale reviewerilor, conflicte de valori și corecții ulterioare. Cititorul sau un sistem AI trebuie să reconstruiască aceste relații din proză și din fișiere suplimentare împrăștiate.

Executable Science propune ca articolul să devină o proiecție lizibilă pentru oameni a unui obiect de cercetare mai bogat. Obiectul de bază ar avea identitate stabilă, versiuni, ramuri, proveniență, workflow-uri executabile acolo unde este potrivit, afirmații formale sau semi-formale unde sunt utile, incertitudine explicită și un istoric al motivelor pentru care concluziile s-au schimbat. El ar păstra nu doar ceea ce a fost publicat, ci și evidența care susține fiecare afirmație, alternativele încă active, constrângerile care au guvernat acțiunea și condițiile suficiente pentru redeschiderea rezultatului. Cercetările despre FAIR data, research objects, standarde de workflow, proveniență și reproductibilitate computațională oferă fundații importante [128, 140, 162–164]. Viziunea mai puternică

dezvoltată aici — reprezentarea stării epistemice și axiologice pe întreg traseul cercetării — rămâne o propunere de cercetare.

Cei doi Guardians își capătă sensul complet în interiorul unui asemenea mediu. Epistemic Guardian nu poate supraveghea credibil un proiect dacă vede numai proza finisată de la final. Are nevoie de acces la starea vie a afirmațiilor, dovezilor, presupunerilor, experimentelor și evenimentelor de revizuire. Axiologic Guardian nu poate proteja valorile declarate și nici evalua valoarea pentru umanitate dacă vede numai un paragraf despre impact scris după ce alegerile tehnice au fost deja fixate. Are nevoie de angajamente valorice, stakeholderi, efecte anticipate, constrângeri tari, costuri de oportunitate și istoricul deciziilor prin care proiectul a ajuns în forma actuală.

Aceasta schimbă ambiția cercetării asistate de AI. Scopul nu este doar un „artificial scientist” care produce mai multe articole. Scopul este un ecosistem științific care își amintește mai bine de ce crede ceva, descoperă când motivele sale au eșuat, compară acțiuni următoare posibile și păstrează valorile sub care cercetarea a fost autorizată. Agentul științific individual poate rămâne un actor productiv printre mulți alții. Inovația mai adâncă este un mediu de cercetare în care generarea răspunde în fața verificării, iar acțiunea răspunde în fața valorii.

Notă metodologică și statutul afirmațiilor

Fenomenul analizat nu are încă o denumire stabilă și nu formează un domeniu academic unic. Literatura relevantă este distribuită între psihologia metacogniției, cercetarea despre încrederea în automatizare, interacțiunea om–AI, evaluarea modelelor de limbaj, reproducibilitatea științifică, testarea software, demonstrarea formală, automatizarea laboratoarelor și neuro-simbolic AI. Din acest motiv, revizuirea din această carte este o revizuire critică de tip scoping review, nu o meta-analiză exhaustivă. Au fost urmărite surse primare și lucrări de sinteză publicate sau disponibile ca preprint până la 25 august 2026, cu accent pe rezultatele care pot schimba proiectarea sistemelor pentru automatizarea cercetării.

Sursele peer-reviewed sunt tratate diferit de preprinturi și rapoarte tehnice. Preprinturile despre agenți de cercetare și evaluarea LLM-urilor sunt relevante deoarece domeniul evoluează rapid, dar sunt prezentate ca rezultate provizorii. Produsele comerciale, demonstrațiile publice și postările organizațiilor sunt folosite doar atunci când descriu un sistem concret sau un benchmark, nu ca dovadă suficientă pentru eficacitate științifică. Atunci când o lucrare oferă doar evaluări umane ale impresiei de noutate, cartea nu o traduce în dovadă de noutate reală. Atunci când un sistem produce un articol complet, cartea nu presupune că articolul conține o descoperire. Aceste distincții nu sunt precauții stilistice, ci chiar obiectul investigației.

Un al doilea principiu metodologic privește nivelul afirmației. Studiile despre automation bias în diagnostic, moderare sau sarcini de clasificare nu demonstrează direct că cercetătorii asistați de LLM își imaginează descoperiri inexistente. Ele demonstrează mecanisme mai înguste: oamenii pot supraevalua recomandări automatizate, explicațiile pot modifica încrederea, iar fricțiunea cognitivă poate schimba gradul de verificare. Legătura cu cercetarea științifică este o inferență plauzibilă care trebuie testată separat. Cartea va face această trecere explicită, în loc să ascundă diferența sub expresii generale precum „studiile arată că AI ne face să gândim mai puțin”.

În sfârșit, propunerile tehnologice nu sunt prezentate ca produse deja validate. „nucleul Epistemic Guardian”, „Falsifier-ul”, „auditorul de oracole” și benchmarkul RealityGap sunt specificații de cercetare. Unele componente se bazează pe tehnici mature — proveniență, argumentation graphs, property-based testing, mutation testing, SMT, proof assistants,

preregistration — dar integrarea lor într-un sistem neuro-simbolic pentru prevenirea iluziei de descoperire rămâne o ipoteză inginerescă. Manuscrisul va defini criteriile prin care aceste instrumente ar putea eșua. O tehnologie care pretinde că reduce autoamăgirea, dar se validează doar cu propriul său LLM-judge, ar repeta exact problema pe care încearcă să o rezolve.

Revizuirea bibliografică a urmărit surse primare și sinteze academice din psihologia metacogniției, human–AI interaction, reproducibilitate, formal methods, filosofia modelării, quantum computing, fizică fundamentală, responsible innovation, value-sensitive design, machine ethics și LLM-as-a-judge. Nu pretinde exhaustivitate asupra tuturor publicațiilor. Lucrările din 2026 care descriu grafuri de dovezi, proveniență agentică sau evaluarea automată a reproductibilității sunt marcate ca preprinturi ori cercetare timpurie [141-150].

Marcaj folosit	Semnificație
EVIDENȚĂ PUBLICATĂ	Rezultat, argument sau observație susținută de literatura citată. Forța afirmației rămâne limitată la designul și domeniul studiilor.
SINTEZĂ ȘI INFERENȚĂ	Interpretarea autorului care conectează literaturi sau extrapolează prudent din rezultate existente.
PROPUNERE DE CERCETARE	Arhitectură, instrument, metrică sau experiment care nu este prezentat ca tehnologie deja demonstrată.

Această revizie adaugă o a patra distincție metodologică: reprezentarea nu este aprobare. Un obiect de cercetare structurat poate codifica fidel o ipoteză slabă, o valoare contestată sau o prioritate instituțională discutabilă. Interpretabilitatea automată face angajamentul vizibil; nu îl face corect. Proveniența poate arăta de unde provine o afirmație fără să o demonstreze. O regulă formală poate expune cum a fost luată o decizie fără să legitimeze regula. Arhitectura separă, prin urmare, trasabilitatea, validitatea și autoritatea.

Cartea distinge și formalizarea progresivă de formalizarea universală. Un experiment computațional poate permite capturarea exactă și rerularea workflow-ului. O teoremă poate permite verificarea într-un kernel formal. O cercetare clinică sau socială poate conține componente statistice executabile, în timp ce construcțiile, consimțământul, interpretarea și validitatea externă rămân parțial discursive. Propunerea nu este să forțăm toate disciplinele într-o singură ontologie. Este să facem explicit următorul

strat util de structură, păstrând limbajul original, fragmentele de evidență și dreptul oamenilor de a contesta interpretarea.

Dovezile recente sunt deosebit de importante fiindcă sunt simultan promițătoare și prudente. Sistemele end-to-end pot conecta deja idearea, scrierea codului, experimentarea, producerea manuscrisului și review-ul automat [151]. Un survey din 2026 raportează că publicarea codului este mult mai frecventă decât urmele de execuție suficiente pentru reproducere, verificarea noutății sau folosirea unor oracole externe validate în interiorul buclei [152]. Un alt studiu amplu raportează că agenții științifici ignoră adesea dovezi, își revizuiesc rareori credințele prin infirmare și ajung rar la convergență prin teste multiple, chiar când finalizează workflow-ul cerut [153]. Un protocol care face explicite ipoteza, testul, dovada și actualizarea credinței oferă un răspuns concret [154]. Aceste rezultate susțin nevoia unei infrastructuri sensibile la proces; ele nu demonstrează că Guardians propuși aici vor funcționa.

În sfârșit, unitatea de evaluare este traseul cercetării, nu doar răspunsul final. Un proiect poate obține un rezultat corect printr-o cale nesigură sau un rezultat negativ valoros printr-un proces care părea inițial nereușit. Programul de cercetare propune, prin urmare, replay-ul unor traiectorii istorice și simulate, benchmarkuri cu defecte de proces, selecția prospectivă a experimentelor, studii cu cercetători și piloți instituționali. Afirmția puternică eșuează dacă starea explicită, normele și rapoartele Guardian nu îmbunătățesc alegerile importante față de baseline-uri agentice și RAG puternice.

Introducere. Când cercetarea poate fi imitată înainte de a fi făcută

În cultura științifică modernă, anumite forme au devenit semnale ale seriozității. Un articol are abstract, related work, metodă, ecuații, experimente, grafice, ablation studies, discuție și limitări. O arhitectură are module, săgeți, interfețe și un acronim. O demonstrație are leme, teoreme și o concluzie. Un repository are README, teste, badge-uri și exemple. Aceste forme sunt utile deoarece comprimă practici reale într-un limbaj comun. Ele nu sunt însă dovezi în sine. Modelele generative au învățat foarte bine distribuția acestor forme și pot reproduce rapid aspectul lor exterior. Pentru prima dată, cercetarea poate fi imitată la scară mare înainte ca munca epistemică pe care forma o sugerează să fi fost efectuată.

EVIDENȚĂ PUBLICATĂ

Analiza lui Lisa Messeri și M. J. Crockett a formulat una dintre cele mai influente versiuni ale acestei probleme. Autoarele arată că folosirea AI în știință poate produce iluzii de înțelegere și poate încuraja monoculturi epistemice: cercetătorii pot crede că înțeleg mai mult, explorează mai larg sau judecă mai obiectiv decât permit instrumentele folosite [4]. Lucrarea este în principal conceptuală și nu demonstrează că fiecare utilizator al AI va suferi aceste iluzii. Importanța ei constă în schimbarea unității de analiză. Problema nu este doar dacă un model produce o propoziție falsă, ci dacă instituția științifică ajunge să confunde productivitatea, predicția sau omogenitatea cu înțelegerea.

Noțiunea de „inflație epistemică” poate fi folosită pentru a descrie o dinamică înrudită: producția de afirmații și artefacte crește mai repede decât capacitatea de a le verifica. Termenul nu presupune că afirmațiile sunt toate false. Inflația monetară nu înseamnă că bancnotele dispar, ci că relația lor cu valoarea se modifică. Analog, inflația epistemică apare atunci când un volum tot mai mare de texte, rezultate și evaluări concurează pentru aceeași cantitate de atenție expertă, replicare și contact experimental. Generative AI poate face ca un proiect să arate matur înainte ca incertitudinile sale decisive să fi fost atinse.

SINTEZĂ ȘI INFERENȚĂ

În cercetarea asistată de AI, produsul cel mai periculos nu este neapărat răspunsul evident fals, ci traseul coerent care înlocuiește pe

nesimțite problema. Modelul primește o întrebare dificilă. Pentru a o face tratabilă, introduce o definiție, o metrică sau un benchmark. Apoi optimizează ceea ce a definit, produce cod și teste pentru acel obiect, iar la final descrie succesul ca răspuns la întrebarea inițială. Fiecare pas poate fi rezonabil local. Eroarea apare în compunere: noul obiect nu păstrează suficient din identitatea problemei. Cartea numește această tranziție „substituție de proxy” și diferența rezultată „decalaj problemă–specificatie”.

Un exemplu simplu provine din software. Să presupunem că vrem un algoritm care detectează contradicțiile relevante dintr-un articol științific. Modelul definește contradicția ca apariția a două propoziții cu polaritate lexicală opusă, scrie un detector, produce zece exemple care urmează aceeași definiție și raportează acuratețe perfectă. Codul rulează, testele trec și documentația este corectă. Problema reală — contradicțiile semantice, condiționate de context, metode și populații — nu a fost însă rezolvată. Validarea este reală relativ la obiectul construit, dar este folosită retoric pentru o afirmație mai mare. Aceasta nu este o simplă halucinație. Este o promovare epistemică nejustificată.

În matematică, forma poate fi și mai convingătoare. Un LLM poate reformula o conjectură, poate produce o „demonstrație”, poate traduce o parte într-un proof assistant și poate obține confirmarea kernelului. Confirmarea formală este valoroasă, dar spune că termenul formal este o demonstrație a enunțului formal în sistemul ales. Nu spune automat că enunțul formal exprimă problema naturală pe care cercetătorul crede că a rezolvat-o. O ipoteză introdusă accidental, o definiție slăbită, o condiție care exclude cazurile dificile sau o inconsistență în axiome pot transforma o victorie formală într-o victorie asupra altei probleme. Istoria formalizării arată tocmai câtă muncă semantică și socială este necesară pentru a conecta simbolurile la matematica intenționată [5, 6].

Același risc apare în machine learning. O arhitectură descrisă prin termeni noi poate fi o recombinație a unor primitive cunoscute. Un model poate depăși un baseline slab sau prost configurat. O îmbunătățire poate proveni din leakage, dintr-o alegere favorabilă a seed-urilor, din selecția post hoc a metricii sau dintr-un set de test prea apropiat de datele de dezvoltare. Literatura despre reproducibilitate arată că asemenea probleme existau cu mult înaintea LLM-urilor [7, 8]. AI nu le inventează, dar poate crește viteza cu care sunt produse variante, analize și justificări, reducând timpul psihologic în care cercetătorul ar fi observat nealinierea.

Cartea propune să tratăm aceste situații ca erori de „promovare epistemică”. O afirmație începe ca ipoteză. Poate deveni specificată, derivată, implementată, observată, susținută experimental și, eventual,

replicată. Fiecare stare are cerințe diferite. În practica curentă, limbajul face trecerile să pară continue: „am formulat” devine „am arătat”, „a rulat” devine „a funcționat”, „a trecut testele” devine „a rezolvat problema”, „mai mulți agenți sunt de acord” devine „rezultatul este robust”. Un sistem responsabil trebuie să rupă această continuitate retorică și să ceară un tip de evidență pentru fiecare salt.

PROPUNERE DE CERCETARE

Definim decalajul față de realitate ca diferența dintre contribuția percepută și contribuția verificată după o succesiune de porți independente. Nu presupunem că există o singură măsură universală a „realității”. Pentru o demonstrație, poarta poate fi verificarea formală plus auditul enunțului. Pentru software, poate fi un test ascuns, mutation testing și evaluarea pe incidente reale. Pentru o arhitectură ML, poate fi comparația cu baseline-uri puternice, ablation, controlul leakage-ului și replicarea pe date externe. Pentru o afirmație cauzală, poate fi un design de identificare, o intervenție sau predicții care disting mecanisme rivale. Ceea ce unifică domeniile nu este instrumentul, ci regula că validarea trebuie să adauge o constrângere care nu a fost fabricată de aceeași narațiune.

Această regulă explică de ce unele sisteme de „AI scientist” sunt mai promițătoare decât altele. Un model care generează o ipoteză și apoi îi acordă un scor mare printr-un alt prompt a produs în principal text. Un model conectat la un laborator robotizat, la un compilator, la un proof assistant sau la un set ascuns de cazuri introduce feedback extern. Cercetarea autonomă are precedente serioase: robot scientists au formulat și testat ipoteze în genomică, laboratoarele autonome au explorat spații chimice și materiale, iar sisteme recente au combinat LLM-uri cu instrumente experimentale [9, 10, 11, 12]. Lecția nu este că automatizarea garantează adevărul, ci că bucla trebuie să includă lumea sau un verficator cu proprietăți independente clar definite.

De aici rezultă și orientarea pozitivă a volumului. Generarea ieftină de ipoteze este o oportunitate istorică. Ar fi absurd să încercăm să revenim la raritatea ideilor doar pentru că selecția a rămas dificilă. Răspunsul este să automatizăm mai mult din partea severă a științei: căutarea prior art-ului, normalizarea arhitecturilor la primitive cunoscute, generarea de counterexamples, alegerea celui mai puternic baseline, auditarea testelor, controlul statistic, urmărirea provenienței și pregătirea replicării. În loc să cerem agentului „convinge-mă că ideea funcționează”, îi putem cere „presupune că ideea nu este nouă și nu funcționează; găsește cea mai ieftină probă care ar separa această ipoteză de alternative”.

Această schimbare de obiectiv este nucleul programului neuro-simbolic prezentat în ultimele capitole. Modelul de limbaj rămâne generator, traducător și explorator. Stratul simbolic păstrează contractul problemei, tipurile de afirmații, dependențele și regulile de promovare. Instrumentele externe furnizează dovezi, iar un registru de proveniență arată cine sau ce a generat fiecare artefact, ce surse a folosit și ce verificări au fost efectuate. Cercetătorul nu primește doar un răspuns, ci o hartă a lucrurilor care ar trebui să fie adevărate pentru ca răspunsul să conteze.

Miza este mai largă decât prevenirea erorilor. Știința asistată de AI va fi credibilă numai dacă poate explica nu doar cum a produs o afirmație, ci și de ce afirmația a fost lăsată să urce de la posibilitate la cunoaștere. Într-o lume cu mai multe cuvinte decât realitate, transparența traseului epistemic devine la fel de importantă ca transparența modelului.

Modelele generative au redus costul producerii unei aparențe complete de cercetare mai repede decât au redus costul stabilirii adevărului și valorii ei.

Cartea pornește din experiența personală a lucrului intensiv cu modele generative și din ceea ce poate fi observat tot mai des online: oameni și agenți care anunță arhitecturi, demonstrații, descoperiri și „soluții” însoțite de cod, grafice, teste și review-uri. Istoria matematicii cunoaște de mult demonstratori convinși că au rezolvat probleme celebre. Noutatea este că AI poate produce într-o singură sesiune nu numai demonstrația, ci și formalizarea, implementarea, testele și comentariul care par să o valideze. Acest pachet poate fi util și uneori corect; poate însă închide bucla în jurul aceleiași interpretări greșite.

Trecerea către Executable Science dezvăluie două blocaje înrudite. Primul este asimetria generare-verificare: costul marginal al producerii unei ipoteze, implementări, analize, explicații sau evaluări scade rapid, în timp ce costul dovezii independente rămâne ridicat și dependent de domeniu. Al doilea este asimetria generare-prioritizare: numărul acțiunilor de cercetare posibile tehnic crește mai repede decât capacitatea de a decide ce incertitudine merită atenție, ce test discriminează între ipoteze, ce proiect trebuie să primească resurse rare și ce direcție ar trebui oprită.

SINTEZĂ ȘI INFERENȚĂ

Cercetarea științifică poate fi descrisă, imperfect dar util, drept actualizare epistemică plus selecție secvențială de acțiuni sub valori și constrângeri plurale. Primul termen întreabă ce ar trebui să creadă proiectul. Al doilea întreabă ce ar trebui să facă în continuare. Sistemele AI existente tind să le combine într-un plan generat de același model.

Arhitectura cu doi Guardians le separă fără să le izoleze. Epistemic Guardian evaluează traseul de la dovadă la afirmație și rolul informațional al unei acțiuni propuse. Axiologic Guardian evaluează acțiunea în raport cu scopurile științifice declarate, angajamentele instituționale, stakeholderii afectați, costurile de oportunitate, riscurile, reversibilitatea și valoarea mai largă pentru umanitate.

Separarea contează fiindcă adevărul și valoarea pot diverge. Un proiect poate fi riguros, nou și fezabil, dar poate servi unui obiectiv trivial sau nociv. O problemă poate fi importantă social, iar metoda propusă să rămână epistemic slabă. O întrebare de cercetare cu valoare ridicată poate merita explorată fără ca afirmațiile sale timpurii să merite crezute. Arhitectura trebuie să permită asemenea stări mixte, în loc să forțeze un singur scor care recompensează proiectul pentru că pare simultan adevărat, important și matur.

Problema viitorului nu este doar dacă un AI poate executa cercetare. Este dacă un ecosistem științific își poate aminti ce a fost stabilit, poate expune ce rămâne conjectural și își poate alege următoarea acțiune fără să ascundă dovada sau valoarea în spatele fluenței.

Capitolul 1. Apariția progresului fără progres

1.1. Când plauzibilitatea devine ieftină

Înainte de modelele generative, producerea unui artefact care să semene cu cercetarea era relativ costisitoare. Chiar și un articol slab presupunea timp pentru documentare, formulare, structurare, implementare și corectură. Acest cost nu garanta calitatea, dar introducea fricțiune. Autorul era obligat să rămână suficient de mult lângă idee pentru a-i observa unele incoerențe, iar cititorul putea folosi efortul aparent drept semnal imperfect al seriozității. Generative AI rupe această relație. Forma completă poate apărea înainte ca autorul să fi înțeles problema, iar costul marginal al unei noi explicații, arhitecturi sau justificări tinde spre zero. Ceea ce devine abundent nu este adevărul, ci plauzibilitatea locală.

Plauzibilitatea locală este capacitatea unui fragment de a continua firesc ceea ce îl precedă. O propoziție folosește terminologia corectă, o diagramă are module cu nume rezonabile, un experiment produce o metrică familiară, iar limitările par mature. Modelele de limbaj excelează tocmai la continuitate distribuțională. Ele au văzut milioane de exemple în care un anumit tip de problemă este urmat de un anumit tip de metodă, iar o metodă de un anumit tip este urmată de evaluări previzibile. Continuitatea este utilă pentru scriere și brainstorming, dar cercetarea cere mai mult: ca legăturile dintre propoziții să corespundă unor dependențe reale, ca termenii să rămână identici semantic de-a lungul documentului și ca rezultatele să constrângă alternativele.

Un proiect poate deveni impresionant prin acumularea de detaliu care nu schimbă nimic verificabil. Să presupunem că ideea inițială este „un sistem care înțelege mai bine documente științifice lungi”. Modelul propune o memorie ierarhică, un graf semantic, un critic, o buclă de reflecție, o funcție de scor, o reprezentare vectorială și un mecanism de reconstrucție. Fiecare componentă poate fi motivată prin analogie cu literatura. Totuși, până când „înțelege mai bine” nu este descompus în sarcini discriminante, baseline-uri și condiții de eșec, arhitectura rămâne o narațiune despre o soluție. Numărul de module nu este o măsură a cantității de progres, iar numele lor poate masca faptul că sistemul este un RAG cu pași suplimentari sau o orchestrare a unor primitive standard.

PROPUNERE DE CERCETARE

Numim „architecture laundering” procesul prin care o recombinaare cunoscută dobândește aparența unei arhitecturi noi prin redenumire, redesenare și schimbarea nivelului de abstracție. Termenul este deliberat provocator, dar nu presupune intenție frauduloasă. Un autor poate fi sincer convins că a descoperit ceva nou deoarece modelul i-a oferit o decompoziție pe care nu o recunoaște în literatura existentă. Tocmai de aceea este nevoie de un instrument care să traducă arhitecturile în primitive canonice și să compare mecanismele, nu etichetele. Dacă două sisteme devin aproape identice după eliminarea numelor și normalizarea fluxurilor de date, diferența trebuie justificată prin comportament, nu prin retorică.

Plauzibilitatea ieftină schimbă și ritmul deciziei. În conversația cu un LLM, fiecare obiecție primește imediat un răspuns. Acest lucru este confortabil și productiv, dar elimină tăcerea în care o problemă ar rămâne nerezolvată. Cercetarea reală conține perioade în care nu există o continuare bună, iar imposibilitatea de a continua este informație. Modelul, prin design, încearcă să continue. Dacă îi spunem că arhitectura are o problemă, poate adăuga un modul. Dacă noul modul introduce costuri, poate propune caching. Dacă apare o contradicție, poate reformula obiectivul. Fără un contract extern al problemei, conversația poate netezi fiecare obstacol până când proiectul pare coerent, deși obiectul s-a deplasat.

Acest mecanism diferă de minciună. Modelul nu are nevoie să ascundă deliberat o eroare. El optimizează un răspuns care satisface contextul și instrucțiunea. Utilizatorul, la rândul său, poate prefera continuitatea deoarece investiția psihologică în idee crește. Rezultatul este un sistem om-AI în care fiecare parte îl ajută pe celălalt să evite ruptura. Modelul oferă formulări care salvează ideea, iar omul selectează formulările compatibile cu intenția sa. Coerența devine o presiune comună, nu proprietatea exclusivă a modelului.

EVIDENȚĂ PUBLICATĂ

Literatura despre creativitate asistată de AI sugerează deja că îmbunătățirea performanței individuale poate coexista cu o reducere a diversității colective. Într-un experiment cu producerea de povestiri, accesul la idei generate de AI a îmbunătățit unele evaluări ale creativității, mai ales pentru participanții inițial mai puțin creativi, dar a făcut rezultatele mai asemănătoare între ele [13]. Studiul nu este despre cercetare științifică și nu dovedește că arhitecturile ML vor converge în același mod. El oferă însă un mecanism relevant: un instrument poate ridica nivelul local al produselor și, simultan, poate

concentra explorarea în jurul unor tipare comune. Analizele conceptuale despre monoculturi epistemice formulează aceeași îngrijorare la nivelul științei [4].

Un alt efect al plauzibilității ieftine este schimbarea raportului dintre producție și verificare. Dacă un cercetător putea investiga trei idei într-o lună, selecția inițială putea fi relativ informală. Dacă poate genera trei sute, o evaluare superficială nu mai este doar imperfectă; devine principala sursă de eroare. Fiecare idee are un cost mic de producție, dar un cost mare de falsificare. Dacă nu automatizăm partea critică, cercetătorul se confruntă cu un inventar de promisiuni pe care nu îl poate lichida. Progresul aparent crește prin stoc, nu prin rezultate.

Această asimetrie poate produce ceea ce numim „epistemic debt”. Datoria tehnică apare când o soluție rapidă transferă costuri în viitor. Datoria epistemică apare când acceptăm temporar afirmații, ipoteze sau dependențe insuficient verificate pentru a continua proiectul. Uneori este legitim: cercetarea explorează tocmai în condiții de incertitudine. Problema apare când starea provizorie se pierde. După câteva iterații, o presupunere generată de model este citată ca decizie, decizia ca proprietate a sistemului, iar proprietatea ca rezultat. Documentele succesive pot consolida o afirmație fără ca vreo dovadă nouă să fi intrat în circuit.

PROPUNERE DE CERCETARE

Un registru de datorie epistemică ar păstra fiecare presupunere netestată împreună cu afirmațiile care depind de ea, costul estimat al verificării și riscul dacă este falsă. Spre deosebire de un simplu „to-do”, registrul ar participa la raționament. O concluzie nu ar putea fi prezentată ca robustă dacă depinde de o presupunere cu risc ridicat și fără probă. Un sistem de automatizare a cercetării ar putea prioritiza experimentele care închid cele mai multe dependențe sau care reduc cel mai mult spațiul de explicații alternative.

Plauzibilitatea ieftină nu trebuie demonizată. Ea permite cercetătorilor să exploreze rapid limbaje, designuri și explicații care altfel ar rămâne inaccesibile. Poate ajuta un expert să treacă într-un domeniu vecin, poate produce întrebări neobișnuite și poate elimina costuri editoriale fără valoare epistemică. Dar tocmai fiindcă este valoroasă, trebuie decuplată de statut. Un paragraf bine scris este un instrument de gândire; nu este o măsurătoare. O diagramă poate revela o incoerență; nu este un experiment. Codul poate clarifica o ipoteză; nu este validarea ei. Proiectarea responsabilă începe când sistemul păstrează aceste diferențe chiar dacă limbajul le face să pară continue.

La nivel instituțional, problema poate deveni și mai severă. Conferințele și revistele au capacitate limitată de review, iar evaluarea granturilor depinde de timp expert. Dacă producerea de manuscrise crește mult mai repede decât verificarea, filtrele se pot deplasa spre semnale superficiale: stil, reputație, conformitate formală, rezultate spectaculoase sau consens algoritmic. Într-un asemenea mediu, AI nu doar ajută la scriere; poate schimba ecologia selecției. Manuscrisele care arată complet vor concura cu proiecte mai lente, ale căror incertitudini sunt expuse onest. O cultură sănătoasă va trebui să recompenseze urmele de falsificare și dovezi negative, nu doar forma finală.

SINTEZĂ ȘI INFERENȚĂ

Cea mai importantă schimbare produsă de AI poate să nu fie creșterea inteligenței individuale, ci separarea dintre costul aparenței și costul adevărului. Când această separare devine mare, toate semnalele tradiționale trebuie recalibrate. Lungimea, complexitatea, formalismul și numărul de artefacte nu mai pot servi drept proxy-uri rezonabile pentru efortul epistemic. Trebuie să privim direct traseul: ce afirmație a fost făcută, ce ar fi putut-o infirma, ce probă independentă a intrat în sistem și ce alternative au fost eliminate.

1.2. Psihologia înțelegerii aparente

Iluzia produsă de AI nu începe în model. Ea se întâlnește cu mecanisme cognitive umane bine documentate. Oamenii supraestimează frecvent profunzimea propriei înțelegeri, confundă accesul la informație cu posesia ei, folosesc fluenta procesării drept indiciu de adevăr și își calibrează încrederea imperfect. Modelele de limbaj nu creează aceste mecanisme, dar le oferă un mediu ideal: explicații imediate, personalizate, coerente și disponibile la orice nivel de detaliu.

EVIDENȚĂ PUBLICATĂ

Rozenblit și Keil au numit „illusion of explanatory depth” tendința oamenilor de a crede că înțeleg mecanisme cotidiene — de exemplu, cum funcționează un fermoar sau un sistem de toaletă — mult mai bine decât pot explica efectiv [14]. Când participanții sunt obligați să producă o explicație detaliată, încrederea lor scade. Efectul este important pentru cercetarea asistată de AI deoarece conversația poate furniza explicația înainte ca utilizatorul să descopere golurile propriei reprezentări. Omul citește o explicație fluentă și simte continuitatea, dar nu este obligat să reconstruiască mecanismul independent.

Studiile despre căutarea pe Internet au arătat un fenomen înrudit. Participanții care au căutat explicații online au ajuns să-și evalueze mai

favorabil cunoașterea internă chiar și pentru întrebări ulterioare fără legătură, sugerând că accesul la cunoaștere poate fi confundat cu cunoașterea proprie [15]. Efectul Google asupra memoriei arată, în alt registru, că oamenii își adaptează memoria la disponibilitatea externă a informației, reținând mai degrabă unde poate fi găsită decât conținutul însuși [16]. Niciunul dintre aceste rezultate nu implică faptul că externalizarea este rea. Bibliotecile și calculatoarele sunt extensii esențiale ale cogniției. Problema apare când metacogniția nu mai distinge între „pot obține rapid o explicație” și „pot evalua sau reconstrui explicația”.

Un LLM intensifică ambiguitatea deoarece nu oferă doar acces, ci sintetizează conversațională. Răspunsul este adaptat întrebării, folosește vocabularul utilizatorului și poate anticipa obiecții. Interfața seamănă mai puțin cu o bază de date și mai mult cu un partener competent. Această formă socială poate transforma externalizarea într-o experiență de co-gândire. Când co-gândirea funcționează, este extrem de puternică. Când modelul greșește, utilizatorul poate împrumuta încrederea produsă de dialog fără să aibă un mecanism independent de discriminare.

EVIDENȚĂ PUBLICATĂ

Cercetarea despre fluența cognitivă arată că dificultatea moderată poate activa procesarea analitică, în timp ce materialul ușor de procesat este adesea acceptat mai intuitiv [17]. Literatura despre formulări pseudo-profunde arată că unii oameni atribuie profunzime unor propoziții gramaticale și evocatoare, dar lipsite de conținut determinat [18]. Nu este corect să reducem răspunsurile LLM la „bullshit”: ele pot conține informație și raționamente reale. Totuși, capacitatea lor de a produce fluență fără garanție semantică face relevantă distincția dintre senzația de profunzime și puterea explicativă.

În știință, o explicație puternică nu este doar satisfăcătoare. Ea organizează datele, produce predicții, exclude alternative sau leagă mecanisme de intervenții observabile. O explicație LLM poate suna mecanistică fără să îndeplinească aceste funcții. De exemplu, un model poate spune că o arhitectură performează mai bine deoarece „memoria ierarhică permite integrarea contextului la multiple scale”. Afirmatia este plauzibilă, dar devine explicație științifică abia când putem distinge această cauză de alternative: mai mulți parametri, context mai lung, regularizare implicită, preprocesare diferită sau o eroare de evaluare. Fără ablație și predicții diferențiale, mecanismul este o poveste compatibilă cu rezultatul.

Literatura despre încrederea în automatizare complică imaginea. Oamenii nu sunt pur și simplu creduli. Ei pot manifesta atât automation bias, cât și algorithm aversion, în funcție de context, vizibilitatea erorilor și

posibilitatea de control. Studiile clasice descriu utilizarea, neutilizarea, utilizarea greșită și abuzul automatizării și insistă asupra „reliance”-ului calibrat, nu asupra încrederii maxime [19, 20]. Oamenii pot urma recomandarea automată chiar și când există indicii contrare, dar pot și abandona un algoritm după ce observă o singură eroare, deși algoritmul rămâne superior în medie [21, 22]. Alte experimente găsesc „algorithm appreciation”, preferința pentru judecata algoritmică în anumite sarcini [23]. Concluzia relevantă este că relația om–AI este dinamică și sensibilă la interfață.

EVIDENȚĂ PUBLICATĂ

Experimentele de human–AI decision making arată că explicațiile nu produc automat performanță complementară. În unele contexte, explicațiile pot crește încrederea și adoptarea recomandării fără să ajute utilizatorul să identifice cazurile în care modelul greșește [24, 25]. Cercetările cu „cognitive forcing functions” arată că introducerea unei fricțiuni — de pildă, cererea unei judecăți inițiale înainte de afișarea recomandării — poate reduce supra-dependența, deși uneori cu costuri de timp și satisfacție [26]. Alte studii arată că explicațiile proiectate pentru a scoate în evidență dovezile și inconsistențele pot îmbunătăți respingerea răspunsurilor greșite [27]. Așadar, întrebarea nu este dacă explicațiile sunt bune sau rele, ci dacă ele cresc capacitatea de discriminare.

Această distincție este crucială pentru cercetare. Un sistem poate oferi „explainability” care justifică fiecare decizie, dar justificările pot fi post hoc și pot crea confort. O interfață mai responsabilă ar trebui să arate nu doar de ce răspunsul ar putea fi corect, ci și ce observație l-ar face greșit, ce surse îl susțin, ce surse îl contrazic și unde modelul a completat golurile. Explicația trebuie tratată ca obiect de testat, nu ca certificatul propriei sale validități.

EVIDENȚĂ PUBLICATĂ

Un studiu CHI 2025 bazat pe relațiile knowledge workers a asociat încrederea mai mare în GenAI cu un efort mai redus de gândire critică și a observat o mutare a activității cognitive dinspre producere spre verificare și integrare [28]. Rezultatul este important, dar trebuie interpretat cu grijă: este în mare parte auto-raportat și nu demonstrează direct declin cognitiv sau cauzalitate pe termen lung. El arată că utilizatorii percep o redistribuire a efortului și că această redistribuire depinde de încredere. În cercetare, unde verificarea este deja bottleneck-ul, o reducere a efortului critic exact la utilizatorii cei mai încrezători ar putea fi relevantă.

Un articol din Nature Machine Intelligence a furnizat dovadă suplimentară că forma explicației poate afecta încrederea independent de calitatea răspunsului: răspunsurile mai elaborate pot fi percepute ca mai credibile, chiar dacă informația suplimentară nu îmbunătățește corectitudinea sau capacitatea utilizatorului de a separa răspunsurile bune de cele greșite [29]. Cartea folosește acest rezultat ca inspirație pentru „More Words Than Reality experiment”, în care același conținut verificabil este prezentat cu niveluri diferite de jargon, formalism și complexitate. Totuși, un asemenea experiment trebuie realizat direct cu cercetători și artefacte științifice înainte de a afirma că efectul se transferă integral.

SINTEZĂ ȘI INFERENȚĂ

AI poate crea o buclă metacognitivă particulară. Utilizatorul formulează o intenție incompletă. Modelul o transformă într-un obiect articulat. Articularea îi permite utilizatorului să recunoască fragmente din ceea ce voia, iar recunoașterea este trăită ca înțelegere. Utilizatorul aprobă direcția, modelul o extinde, iar coerența retrospectivă crește. La final, este greu de separat ce a fost cunoscut inițial, ce a fost generat și ce a fost verificat. Fără proveniență și stări epistemice, conversația produce o memorie comună în care ipotezele pot fi recitate ca fapte.

Aici intervine o nuanță etică. Nu este util să descriem utilizatorul ca fiind naiv și modelul ca manipulator. Cercetătorii lucrează sub presiune de timp, în domenii complexe și cu instrumente care depășesc capacitatea oricărui individ. Încrederea distribuită este inevitabilă. Nimeni nu verifică de la zero compilatorul, biblioteca statistică și toate sursele. Scopul nu poate fi scepticism total, ci proiectarea unor delegări auditabile. Trebuie să știm ce am delegat, ce proprietăți presupunem despre instrument, unde există independență și ce consecințe are o eroare.

PROPUNERE DE CERCETARE

Un sistem de „calibrare epistemică” ar putea introduce fricțiune selectivă, nu constantă. În loc să ceară utilizatorului să verifice manual fiecare propoziție, ar identifica salturile de statut și zonele cu risc mare. Când o ipoteză este reformulată, sistemul poate continua fluent. Când o concluzie este promovată la „rezultat validat”, interfața ar solicita sursa evenimentului epistemic. Când modelul invocă un mecanism, ar cere o predicție care îl diferențiază de două alternative. Când un test trece, ar întreba cine a definit oracolul și ce mutații ale implementării ar trece totuși. Fricțiunea devine proporțională cu pretenția.

Această abordare păstrează avantajele cognitive ale AI fără să presupună că omul va rămâne permanent vigilent. Ea tratează metacogniția ca proprietate a sistemului socio-tehnic. Un cercetător poate

uita, poate obosi sau poate fi sedus de propria idee; infrastructura trebuie să păstreze memoria critică. La fel cum un sistem de version control nu se bazează pe memoria programatorului pentru istoricul codului, un sistem de cercetare nu ar trebui să se bazeze pe memoria autorului pentru a distinge ipoteza generată de rezultatul observat.

1.3. De la demonstratorul solitar la pachetul automat de validare

Istoria afirmațiilor extraordinare este utilă nu pentru a ridiculiza outsiderii, ci pentru a arăta cât de veche este diferența dintre convingere și validare. Teoremele celebre atrag demonstrații nesolicitate deoarece oferă un obiect clar, prestigiu și iluzia că dificultatea poate fi depășită printr-un insight ignorat de experți. Un autor poate petrece ani rafinând un argument și poate interpreta fiecare obiecție ca neînțelegere din partea comunității. Uriah Dudley a documentat cu umor și empatie astfel de cazuri, de la cvadratura cercului până la sisteme numerologice și demonstrații ale imposibilului [1]. Auguste De Morgan descriese încă din secolul al XIX-lea o cultură a „paradoxers”, autori care contestau consensul matematic fără a accepta metodele prin care consensul putea fi corectat.

Aceste istorii nu justifică apelul simplu la autoritate. Comunitățile științifice pot greși, pot exclude idei și pot apăra paradigme. Matematica însă oferă un exemplu puternic despre cum poate fi separată critica autorității de abandonarea verificării. Demonstrațiile sunt publice, argumentele pot fi refăcute, iar erorile pot fi localizate. Procesul nu este pur mecanic; acceptarea unei demonstrații este și socială, bazată pe expertiză distribuită și încredere în subargumente [5]. Tocmai de aceea formalizarea și verificarea computerizată au devenit importante: ele reduc anumite clase de eroare, fără să elimine necesitatea de a înțelege enunțul și relevanța sa.

Cazul ultimei teoreme a lui Fermat este instructiv. Anunțul lui Andrew Wiles din 1993 a fost urmat de descoperirea unei lacune serioase. Rezultatul nu a fost salvat prin retorică sau prin adăugarea de pagini, ci prin luni de muncă și un nou argument dezvoltat împreună cu Richard Taylor. Articolele publicate în 1995 au intrat apoi într-un proces larg de verificare [2, 3]. Povestea este uneori romanticizată ca triumful unui geniu solitar, dar epistemologic este triumful unui sistem care a putut spune „încă nu” unei demonstrații extraordinare și a putut localiza ce lipsea.

Generative AI poate reproduce rapid aparența etapelor acestui proces. Un model poate genera teorema intermediară care lipsește, poate completa algebra, poate scrie cod de verificare și poate produce un raport

de review. Diferența esențială este că toate aceste artefacte pot proveni din aceeași distribuție de erori. În trecut, obstacolul material limita numărul de pagini și variante. Astăzi, un argument greșit poate fi înconjurat instantaneu de o literatură privată care îl susține. Autorul nu mai este singur cu ideea; are o echipă aparentă de agenți care pot juca rolurile de coautor, programator, reviewer și editor.

SINTEZĂ ȘI INFERENȚĂ

Această schimbare creează „pachetul automat de validare”: un ansamblu de artefacte care imită independența fără să o aibă. Codul pare o verificare a teoriei, dar a fost generat din aceeași descriere. Testele par o verificare a codului, dar au fost generate împreună cu el. Review-ul pare critic, dar primește articolul și criteriile construite de același model. Consensul pare social, dar instanțele au parametri și date comune. Fiecare element ar fi valoros dacă ar introduce o constrângere nouă; împreună, ele pot forma doar o cameră de ecou foarte bine formatată.

În software, problema este cunoscută sub forma „oracle problem”: cum știm care ar trebui să fie rezultatul corect al programului? Un test nu validează nimic dacă așteptarea sa este greșită sau prea slabă. Survey-ul clasic asupra problemei oracolului arată că testarea se bazează pe o varietate de surse — specificații, implementări independente, metamorphic relations, modele, judecată umană — și că oracolul rămâne adesea partea cea mai dificilă [30]. Când un LLM generează atât programul, cât și testul, probabilitatea unei neînțelegeri comune crește. Testul poate confirma fidel interpretarea greșită.

Exemplul poate fi făcut concret. Cerem un program care verifică dacă un graf orientat conține un ciclu relevant pentru o dependență semantică. Modelul interpretează „ciclu relevant” ca orice ciclu topologic, scrie un algoritm corect și testează grafuri în care această definiție este suficientă. Toate testele trec. În aplicația reală, unele muchii sunt doar referințe și nu propagă dependență; programul produce false positives. Nu există bug în algoritmul implementat. Bug-ul este în contractul semantic. Un debugger tradițional nu îl va găsi, iar un LLM care recitește cerința poate continua să confirme aceeași interpretare.

Tehnicile mature de testare oferă modele pentru reducerea riscului. Property-based testing generează multe intrări din proprietăți declarative, mutation testing verifică dacă suita de teste detectează modificări intenționate greșite ale programului, iar metamorphic testing folosește relații între execuții atunci când rezultatul exact este greu de cunoscut [31, 32, 33]. Niciuna nu garantează alinierea cu problema reală, dar toate schimbă întrebarea de la „testele mele trec?” la „testele ar detecta clase relevante

de eroare?”. Într-un sistem AI, aceste tehnici trebuie combinate cu independența semantică: proprietățile și mutațiile nu ar trebui să provină exclusiv din aceeași explicație care a produs implementarea.

În matematică formală, kernelul unui proof assistant este un oracol mult mai puternic pentru validitatea sintactică a derivării. Proiecte precum Flyspeck au formalizat și verificat demonstrații ample, iar sisteme precum LeanDojo și benchmarkuri precum miniF2F au creat infrastructură pentru folosirea modelelor în theorem proving [6, 34, 35]. AlphaGeometry a demonstrat că sisteme neuro-simbolice pot rezolva probleme dificile de geometrie combinând generarea cu deducția simbolică [36]. Aceste succese sunt reale tocmai pentru că verficatorul nu este convins de stil; acceptă doar termeni care respectă regulile formale.

Totuși, proof assistant-ul verifică „dacă P, atunci Q” în sistemul formal, nu dacă P și Q corespund intenției cercetătorului sau lumii. O formalizare poate introduce axiome prea puternice, poate omite un caz sau poate demonstra o versiune trivializată a problemei. Această limitare nu slăbește formal methods; arată unde trebuie plasată următoarea verificare. Avem nevoie de un „problem–proof linker” care păstrează corespondența dintre afirmația naturală, definițiile operaționale și enunțul formal, iar modificările sunt auditate ca schimbări ale problemei, nu cosmetizate ca clarificări.

Pachetul automat de validare poate apărea și în știința empirică. Modelul propune o ipoteză, selectează un dataset disponibil, alege o metrică, ajustează analiza și redactează concluzia. Dacă aceleași date au influențat toate deciziile, p-value-ul sau scorul final nu mai are interpretarea naivă. Literatura despre flexibilitatea analitică, false positives și reproducibilitate a arătat înaintea LLM-urilor că spațiul nevăzut al deciziilor poate produce rezultate convingătoare [37, 38, 39]. Un agent capabil să încerce sute de variante poate amplifica această problemă dacă nu păstrează toate încercările și nu separă explorarea de confirmare.

PROPUNERE DE CERCETARE

Pentru orice pachet generat, sistemul ar trebui să construiască un graf de independență. Nodurile reprezintă afirmația, codul, testele, datele, reviewerii, modelele și instrumentele. Muchiile arată dependențele: aceeași sesiune, același model, aceeași sursă, aceeași specificație, același set de date sau același autor. Un număr mare de noduri nu ar fi interpretat ca validare dacă toate traseele se întorc la aceeași origine. Scopul grafului nu este să pretindă independență perfectă, rar posibilă, ci să facă vizibilă corelația erorilor.

Un asemenea graf ar schimba și designul sistemelor multi-agent. Astăzi, multe arhitecturi multiplică rolurile: planner, coder, critic, reviewer.

Rolurile diferite pot îmbunătăți explorarea, dar nu garantează diversitate epistemică. Cinci instanțe ale aceluiași model cu prompturi similare pot produce un consens mai stabil și totuși greșit. Valoarea unui critic depinde de accesul său la dovezi diferite, la obiective adversariale și la instrumente care pot contrazice generatorul. Un reviewer care poate rula doar același cod pe aceleași teste este mai degrabă editor decât validator.

Istoria demonstratorilor solitari ne amintește că certitudinea subiectivă nu este criteriu. AI adaugă ceva nou: poate industrializa certitudinea și îi poate furniza infrastructură estetică. Răspunsul nu este excluderea ideilor neobișnuite sau revenirea la autoritate, ci democratizarea verificării severe. Dacă modelele pot ajuta pe oricine să formuleze o teorie, trebuie să ajute tot pe oricine să găsească prior art-ul, counterexample-ul, ipoteza ascunsă și testul care separă teoria de o poveste frumoasă. O cultură a cercetării asistate de AI va fi sănătoasă nu când produce mai puține afirmații extraordinare, ci când face mai ieftin și mai prestigios procesul prin care acestea pot fi respinse.

Capitolul 2. Anatomia unei descoperiri care nu există

2.1. Taxonomia iluziilor și Reality Gap

Cuvântul „halucinație” a devenit explicația universală pentru erorile modelelor de limbaj. Este util când un model inventează o citare, atribuie greșit o teoremă sau afirmă un fapt inexistent. Totuși, termenul este prea îngust pentru situațiile în care faptele individuale sunt corecte, dar relația dintre ele nu justifică pretenția finală. O arhitectură poate folosi componente reale, un articol poate cita lucrări reale, codul poate rula, iar rezultatul raportat poate fi calculat corect. Iluzia apare când aceste elemente sunt interpretate ca dovadă a noutății, mecanismului sau soluției fără o legătură suficientă.

PROPUNERE DE CERCETARE

Taxonomia de mai jos este o sinteză originală construită din literatura despre iluzii de înțelegere, Goodhart, reproducibilitate, testare și evaluarea LLM-urilor. Nu este încă o clasificare validată empiric. Rolul ei este operațional: fiecare categorie sugerează un tip diferit de verificare și un alt punct în care sistemul poate opri promovarea epistemică.

Iluzia noutății este poate cea mai seducătoare, deoarece generative AI este foarte bună la schimbarea perspectivei. O idee cunoscută poate fi descrisă într-un vocabular din alt domeniu și poate părea radicală. Uneori transferul este realmente nou și fertil; multe descoperiri apar prin recombinație. Criteriul nu poate fi „a mai existat fiecare componentă?”, deoarece aproape orice invenție folosește componente existente. Întrebarea este dacă noua combinație introduce o capacitate, o explicație, o predicție sau un compromis care nu se reduce trivial la prior art. Căutarea bibliografică lexicală este insuficientă, fiindcă exact redenumirea ascunde asemănarea. Avem nevoie de reprezentări mecanistice și de comparații la nivelul operațiilor efective.

Iluzia arhitecturii apare când decompoziția devine contribuție. O diagramă cu zece module poate fi mai clară decât una cu trei, dar claritatea de proiectare nu implică noutate științifică. Unele module sunt doar responsabilități software, nu mecanisme care schimbă comportamentul. Într-un articol ML, putem detecta această iluzie cerând pentru fiecare bloc: ce intrare transformă, ce stare menține, ce rezultat ar dispărea dacă blocul este eliminat și ce baseline implementează aceeași

funcție altfel? Dacă răspunsul este doar o motivație verbală, arhitectura nu a fost încă separată de poveste.

Iluzia mecanismului este strâns legată de hindsight. După ce vedem că un model performează mai bine, putem produce multe explicații compatibile. „Atenția multi-scale captează dependențe globale”, „regularizarea implicită reduce overfitting-ul”, „critic-ul corectează erorile timpurii” și „memoria păstrează consistența” sunt propoziții rezonabile, dar rareori exclusive. Un mecanism științific trebuie să genereze un profil de rezultate diferit de mecanismele rivale. Dacă toate explicațiile prezic același scor agregat, scorul nu le discriminează. Ablation-ul superficial poate ajuta, dar și el poate fi ambiguu: eliminarea unui modul schimbă numărul de parametri, timpul de antrenare sau distribuția gradientului. Verificarea mecanismului cere controale care izolează efectul pretins.

Iluzia soluției este cea mai practică. Un program poate produce output-ul dorit pentru demonstrație și totuși să nu rezolve situația reală. În cercetarea automatizată, cerințele sunt adesea exprimate în limbaj natural și transformate succesiv în specificații, seturi de date și metrici. Fiecare transformare pierde informație. Dacă pierderea nu este urmărită, succesul la capătul pipeline-ului este proiectat retroactiv asupra problemei originale. În termeni de inginerie, sistemul a verificat conformitatea cu o specificație; în termeni științifici, autorul afirmă validitate externă. Confuzia dintre cele două este sursa multor „soluții” care dispar la prima utilizare serioasă.

Iluzia formalizării merită tratată separat deoarece matematica are o autoritate culturală puternică. O ecuație poate fi necesară pentru precizie, dar poate fi și o traducere ornamentală a unei propoziții. Dacă formalismul nu constrânge modelul, nu permite derivarea unei predicții, nu expune o inconsistență și nu susține o verificare, el adaugă aparență de rigoare fără câștig epistemic. Fenomenul nu este specific AI, însă modelele pot produce simboluri fluent și pot găsi justificări retrospective pentru ele. Un audit simplu întreabă: ce ar fi imposibil de spus sau de calculat fără această formalizare? Dacă răspunsul este „nimic”, formalismul poate fi editorial, nu științific.

În theorem proving, iluzia formalizării ia forma unei demonstrații valide a enunțului nepotrivit. Aici trebuie separate trei întrebări: kernelul acceptă termenul de dovadă; enunțul formal corespunde enunțului natural; enunțul natural rezolvă problema relevantă. Prima poate fi verificată mecanic foarte puternic. A doua și a treia rămân parțial semantice și sociale. Un sistem care raportează doar „Lean says OK” comprimă aceste niveluri într-un verdict unic și supra-vinde rezultatul.

Iluzia validării apare ori de câte ori testul și obiectul testat împart aceeași eroare. În cod, testele co-generate pot verifica funcția descrisă de

model, nu funcția intenționată de utilizator. În analiză statistică, modelul poate selecta pipeline-ul pe aceleași date pe care îl evaluează. În simulare, agentul poate crea condiții în care ipoteza este adevărată prin construcție. În review, evaluatorul poate adopta rezumatul autorului și verifica doar coerența internă. Validarea devine circulară nu pentru că nu există calcul, ci pentru că nu există suficientă independență.

Iluzia consensului este o extindere firească. Sistemele multi-agent creează roluri și dezbateri care seamănă cu procese sociale. Uneori dezbaterile îmbunătățesc rezultatul prin explorarea mai multor căi. Dar numărul vocilor nu este numărul surselor de evidență. Dacă agenții au fost antrenați pe aceleași corpusuri, folosesc același prompt de context, au acces la aceleași instrumente și își văd reciproc răspunsurile, erorile lor sunt corelate. Consensul poate măsura stabilitatea unei reprezentări, nu adevărul ei.

EVIDENȚĂ PUBLICATĂ

Literatura despre LLM-as-a-judge a identificat biasuri de poziție, sensibilitate la stil și dificultăți de calibrare [40, 41]. Studii ulterioare au raportat și preferința evaluatorilor pentru răspunsuri care seamănă cu propriile generații sau provin din aceeași familie de modele [42]. Aceste rezultate nu fac evaluatorii LLM inutili; ei pot oferi feedback rapid și corelat cu judecata umană în anumite condiții. Ele arată însă că trei evaluatori similari nu trebuie contabilizați ca trei replicări independente.

Iluzia review-ului apare când feedbackul este amplu, politicos și acoperă secțiunile convenționale, dar nu poate schimba verdictul prin probă. Un reviewer real poate observa că baseline-ul este absent, poate rula codul, poate găsi un articol anterior sau poate cere date. Un LLM poate simula asemenea observații, dar dacă nu are acces la artefacte și instrumente, review-ul său este în primul rând o evaluare a textului. Chiar și când are acces, trebuie înregistrat ce a executat și ce a verificat, altfel lungimea raportului devine proxy pentru profunzime.

Iluzia reproducibilității cere distincția dintre repeatability și replication. Rularea aceluiși container pe aceleași date și obținerea aceluiși rezultat este importantă, dar nu arată că efectul se menține într-o implementare independentă, pe alte date sau într-un alt laborator. AI poate face ambalarea pipeline-ului mai ușoară și poate îmbunătăți documentația; poate însă și produce capsule perfect rerulabile ale unei erori. Un sistem responsabil trebuie să numească precis nivelul atins.

Iluzia progresului sintetizează toate celelalte. Un proiect cu zeci de idei, multe commit-uri și sute de pagini pare viu. Cercetătorul simte mișcare, iar

managerul vede artefacte. Dar progresul științific nu este cantitatea de activitate, ci schimbarea justificată a ceea ce știm sau putem face. În condiții de generare abundentă, indicatorii de volum devin deosebit de înșelători. Cartea propune „claim survival curve”: pentru fiecare cohortă de idei, urmărim câte supraviețuiesc specificării, prior-art-ului, implementării, baseline-urilor, testelor adverse și replicării. Curba poate arăta că un laborator produce enorm și descoperă puțin sau, dimpotrivă, că generarea abundentă este convertită eficient în rezultate.

Taxonomia nu este menită să transforme cercetarea într-un proces birocratic. Ea oferă un diagnostic diferențial. Dacă problema este noutatea, avem nevoie de prior art și canonicalizare. Dacă este mecanismul, avem nevoie de intervenții și ablations. Dacă este oracolul, avem nevoie de teste independente. Dacă este consensul, avem nevoie de diversitate și evidență externă. Un detector generic de „halucinații” nu poate face toate acestea, deoarece multe afirmații nu sunt false în sine. Trebuie verificată relația dintre pretenție și probă.

O carte despre iluziile cercetării asistate de AI riscă să devină ea însăși o iluzie dacă adună rezultate din domenii diferite și le prezintă drept demonstrație directă a unei teze mai largi. Literatura existentă oferă dovezi solide pentru componente ale mecanismului, dar încă puține studii urmăresc cercetători reali care cred că au făcut descoperiri inexistente cu ajutorul LLM-urilor. De aceea, trebuie să separăm trei niveluri: efecte cognitive demonstrate în sarcini controlate, comportamente observate în utilizarea GenAI și ipoteza mai amplă că aceste efecte pot produce un reality gap în cercetare.

EVIDENȚĂ PUBLICATĂ

Cercetarea despre încrederea în automatizare are o istorie de câteva decenii și arată că performanța optimă nu apare când oamenii au încredere maximă, ci când reliance-ul corespunde capacității reale a sistemului [19, 20]. Utilizatorii pot accepta recomandări automate în ciuda unor indicii contrare, mai ales când sarcina este dificilă, volumul de lucru este mare sau sistemul are o reputație de performanță [21, 57]. În alte condiții, o eroare vizibilă produce algorithm aversion și abandonarea unui instrument care rămâne, statistic, util [22]. Aceste rezultate exclud o poveste simplă despre „oamenii cred orbește AI-ul”. Încrederea este calibrată prin experiență, control, explicații, risc și designul interfeței.

Sistemele generative introduc însă proprietăți care nu erau centrale în automatizarea clasică. Recomandarea nu mai este un scor sau un verdict scurt, ci o conversație. Modelul poate răspunde la obiecții, poate adopta nivelul de expertiză al utilizatorului și poate construi o justificare

personalizată. Încrederea se formează nu doar din acuratețe, ci și din competența socială aparentă. Stilul, viteza și adaptarea pot funcționa ca semnale de expertiză chiar când sarcina depășește datele modelului.

EVIDENȚĂ PUBLICATĂ

Studiile de human–AI decision making au investigat dacă explicațiile ajută oamenii să combine judecata proprie cu predicția modelului. Rezultatele sunt mixte. Bansal și colaboratorii au arătat că explicațiile pot crește acceptarea recomandărilor fără a produce întotdeauna performanță complementară, deoarece utilizatorii nu identifică mai bine cazurile în care AI greșește [24]. Poursabzi-Sangdeh și colaboratorii au constatat că modele mai simple și mai interpretabile nu garantează judecăți mai bune; participanții puteau simula mai bine modelul, dar nu deveneau neapărat mai eficienți în corectarea lui [25]. Observațiile etnografice asupra data scientists au arătat că instrumentele de interpretabilitate sunt uneori folosite pentru confirmare și storytelling, nu numai pentru diagnostic [58].

Aceste rezultate sunt relevante deoarece explicația este adesea tratată ca antidot universal la opacitate. În realitate, există cel puțin două funcții diferite. Explicația persuasivă face răspunsul mai ușor de acceptat. Explicația discriminantă îl ajută pe utilizator să decidă când răspunsul este probabil greșit. Cele două pot coincide, dar nu obligatoriu. Un paragraf fluent poate crește prima funcție și reduce a doua dacă ascunde incertitudinea sau îngroapă ipoteza critică.

Experimentele cu cognitive forcing functions oferă o direcție mai pragmatică. Buçinca și colaboratorii au testat interfețe care îi obligau pe utilizatori să gândească înainte de a vedea recomandarea AI sau să justifice decizia. Unele intervenții au redus overreliance-ul, dar au crescut timpul și efortul perceput [26]. Rezultatul sugerează că siguranța nu poate fi obținută doar prin adăugarea unui avertisment. Fricțiunea trebuie plasată acolo unde eroarea are cost epistemic mare, altfel utilizatorii vor ocoli sistemul sau îl vor percepe drept obstacol.

Alte cercetări au arătat că explicațiile pot ajuta dacă expun surse, inconsistențe și motive pentru îndoială. Vasconcelos și colaboratorii au găsit condiții în care explicațiile îmbunătățesc respingerea recomandărilor greșite, mai ales când fac vizibilă informația relevantă pentru decizie [27]. Mesajul nu este „eliminați explicațiile”, ci „evaluați explicațiile prin capacitatea lor de a calibra, nu prin satisfacția utilizatorului”. Pentru un research assistant, o explicație bună trebuie să reducă eroarea de statut: să arate ce este derivat, ce este presupus și ce a fost observat.

EVIDENȚĂ PUBLICATĂ

Studiul din Nature Machine Intelligence citat în introducere a izolat rolul elaborării și a găsit că răspunsurile mai lungi sau mai explicative pot crește încrederea utilizatorilor fără o creștere echivalentă a acurateții lor [29]. Precizia efectului depinde de designul concret al studiului, iar rezultatul nu poate fi extins automat la toate domeniile. Totuși, el atacă direct un proxy foarte răspândit: cantitatea de justificare nu este o măsură sigură a calității. Într-un mediu de cercetare, unde textele lungi și formalismul au legitimitate, efectul poate fi chiar mai important și merită replicat cu experți.

Un studiu CHI 2025 asupra knowledge workers a analizat modul în care oamenii declară că își folosesc gândirea critică atunci când lucrează cu GenAI. Participanții au descris o deplasare a efortului spre verificare, integrare și stewardship, iar încrederea mai mare în AI a fost asociată cu mai puțin efort critic auto-raportat [28]. Studiul nu măsoară direct pierderea competențelor și nu este un experiment longitudinal. El este însă relevant pentru proiectarea sistemelor: dacă utilizatorii percep verificarea ca noua sarcină centrală, instrumentele trebuie să susțină această sarcină, nu doar să producă mai mult material de verificat.

Literatura despre Internet și metacogniție completează imaginea. Căutarea online poate mări estimarea cunoașterii proprii chiar când informația rămâne externă [15], iar accesul constant schimbă ceea ce alegem să memorăm [16]. LLM-ul extinde această dinamică prin sinteză și dialog. Diferența dintre memoria internă și memoria externă nu este o problemă dacă utilizatorul știe ce delegă. Devine problemă când încrederea în capacitatea de a obține o explicație se transformă în încredere în capacitatea de a-i evalua adevărul.

SINTEZĂ ȘI INFERENȚĂ

Din aceste studii putem construi un mecanism plauzibil al iluziei de descoperire. Fluența și elaborarea cresc impresia de competență; conversația reduce fricțiunea; accesul la explicații este confundat parțial cu înțelegerea; încrederea mai mare reduce probabilitatea verificării; iar forma științifică a artefactului activează semnale culturale de rigoare. Niciun studiu nu demonstrează întregul lanț în cercetare reală. Tocmai această absență definește o agendă experimentală, nu un motiv pentru certitudine retorică.

Este la fel de important să observăm ce nu susține literatura. Nu avem dovadă că folosirea LLM-urilor îi face inevitabil mai superficiali pe cercetători. Instrumentele pot crește accesul la contraargumente, pot explica metode necunoscute și pot reduce biasul de confirmare dacă sunt proiectate adversarial. Nu avem dovadă că explicațiile scurte sunt mereu

mai bune; unele sarcini cer detalii pentru verificare. Nu avem dovadă că experții sunt imuni; expertiza poate îmbunătăți discriminarea, dar poate produce și overconfidence în domenii adiacente. Nu avem încă o măsură standard a „înțelegerii” într-un workflow de cercetare.

PROPUNERE DE CERCETARE

Studiile viitoare trebuie să depășească întrebările de tip „ai avut încredere?” și să măsoare diferența dintre încredere și rezultat verificat. Participanții ar trebui să evalueze idei, arhitecturi și demonstrații pentru care există capcane construite deliberat. Unii primesc explicații scurte, alții explicații elaborate, diagrame sau formalism care nu schimbă conținutul. Măsurăm nu doar verdictul, ci și ce verificări au făcut, cât de repede au găsit eroarea și dacă pot reconstrui mecanismul fără AI. Acesta este testul direct al ipotezei „mai multe cuvinte decât realitate”.

O altă variabilă importantă este momentul interacțiunii. AI poate fi folosit înaintea judecății proprii, după o ipoteză inițială sau doar pentru critică. Literatura despre forcing functions sugerează că ordinea contează [26]. În cercetare, un protocol ar putea cere cercetătorului să scrie întâi predicția, criteriul de eșec și baseline-ul, apoi să consulte modelul. Alternativ, modelul poate genera idei, dar un alt sistem ascunde justificarea până când utilizatorul formulează propriul test. Aceste designuri pot păstra creativitatea și reduce anchoring-ul.

Concluzia prudentă este că psihologia furnizează motive serioase de îngrijorare și instrumente inițiale, dar nu încă verdictul asupra științei asistate de LLM. Cartea transformă această incertitudine într-un principiu metodologic: afirmația că AI produce iluzii de descoperire trebuie ea însăși supusă unor experimente severe, preregistrate și replicabile. Altfel, avertismentul ar deveni încă o poveste convingătoare care își confundă plauzibilitatea cu dovada.

Iluzie	Întrebarea care o separă de progresul real
Noutate aparentă	Contribuția rămâne distinctă după căutare de prior art și canonicalizarea vocabularului?
Arhitectură aparentă	Există un mecanism sau o proprietate nouă după reducerea la primitive și ablations?
Mecanism aparent	Explicația produce predicții discriminatorii sau doar o poveste compatibilă cu rezultatul?
Soluție aparentă	Codul rezolvă Problem Contract-ul, nu doar o specificație generată convenabil?

Iluzie	Întrebarea care o separă de progresul real
Validare aparentă	Testele și evaluatorii pot detecta eroarea generatorului sau împart aceeași orbire?
Consens aparent	Sursele de evidență sunt independente sau se numără ecouri ale aceleiași distribuții?
Rigoare aparentă	Formalismul adaugă constrângeri, counterexamples ori punți spre observabile?

2.2. Când problema este înlocuită de specificație

Orice cercetare traduce o întrebare vagă într-un obiect manipulabil. „Înțelege modelul?”, „este tratamentul eficient?”, „este sistemul sigur?”, „este teoria nouă?” nu pot fi testate fără definiții, măsurători și protocoale. Această operaționalizare este inevitabilă și productivă. Riscul apare când obiectul operațional devine invizibil, iar rezultatul său este raportat ca răspuns complet la întrebarea inițială. Generative AI accelerează operaționalizarea și poate face tranziția atât de fluentă încât pierderea semantică nu mai este observată.

Legea lui Goodhart este adesea rezumată prin ideea că o măsură încetează să fie bună atunci când devine țintă. Literatura modernă distinge mai multe mecanisme: selecția pe proxy poate exploata diferențele dintre măsură și obiectiv, agenții pot manipula măsura, iar optimizarea în afara regimului inițial poate rupe corelația [43]. În cercetare, benchmarkul este o măsură a capacității, dar când sistemul este proiectat și selectat pentru benchmark, performanța poate reflecta particularități ale setului. LLM-urile pot adăuga un strat nou: ele pot produce atât proxy-ul, cât și justificarea că proxy-ul reprezintă problema.

Un exemplu din peer review automat este edificator. Dorim să evaluăm „valoarea științifică” a unui articol. Pentru a face sarcina executabilă, sistemul construiește scoruri pentru noutate, claritate, rigoare și impact. Apoi folosește un LLM-judge pentru fiecare scor. Dacă modelul evaluează noutatea prin asemănare lexicală cu un corpus incomplet, rigoarea prin prezența unor secțiuni metodologice și impactul prin formulări prospective, scorul total poate fi reproductibil și totuși slab legat de valoarea reală. Mai grav, autorii pot învăța să optimizeze semnalele: vocabular neobișnuit, mai multe ecuații, secțiuni de limitări și afirmații de impact. Sistemul nu este

„păcălit” printr-un exploit accidental; el produce o instituție în care aparența devine obiectiv.

EVIDENȚĂ PUBLICATĂ

Problemele de leakage din machine-learning-based science arată cum un pipeline poate obține rezultate spectaculoase prin contaminarea separării dintre antrenare și testare sau prin folosirea informației indisponibile în condițiile reale [8]. Checklisturile de reproducibilitate și inițiativele NeurIPS au îmbunătățit raportarea, dar nu elimină toate deciziile ascunse [7]. Aceste probleme sunt precedente directe pentru research agents: dacă agentul vede testul în timpul generării sau poate itera după feedback-ul evaluatorului, scorul final nu mai măsoară aceeași capacitate ca evaluarea blind.

„Decalajul problemă–specificație” poate fi formalizat ca pierderea sau deformarea condițiilor relevante între niveluri. La nivelul P0 avem intenția: de exemplu, „sistemul trebuie să identifice contradicții care afectează concluzia unui review științific”. La P1 avem definiții: ce este o afirmație, contradicție și relevanță. La P2 avem dataset și etichete. La P3 avem metrică. La P4 avem implementare și teste. Un rezultat la P4 susține P0 numai dacă există un lanț justificat între niveluri. Fiecare traducere trebuie să declare ce a omis și ce presupune.

PROPUNERE DE CERCETARE

„Problem Contract” este un artefact versionat care păstrează acest lanț. El conține întrebarea naturală, utilizatorii și deciziile pe care rezultatul le va informa, exemple pozitive și negative, condiții de frontieră, proprietăți care nu trebuie pierdute, proxy-urile alese și limitele lor. Contractul nu este o specificație completă în sens software și nu pretinde să rezolve ambiguitatea. Rolul său este să împiedice schimbarea tăcută. Dacă agentul înlocuiește „contradicție relevantă” cu „negație lexicală”, diferența este înregistrată ca ipoteză de operaționalizare și nu poate fi uitată în concluzie.

Un al doilea artefact este „semantic diff”. În software, diff-ul arată liniile schimbate. În cercetare, avem nevoie de un diff între versiuni ale problemei și ale pretenției. Dacă în versiunea inițială sistemul trebuia să funcționeze pe documente arbitrare, iar în experiment funcționează pe abstracte curate în limba engleză, concluzia trebuie restrânsă automat. Dacă teorema originală cuantifică peste toate grafurile, iar formalizarea exclude grafurile neconectate, sistemul marchează schimbarea. Semantic diff-ul poate fi construit cu LLM-uri, dar acceptarea lui trebuie ancorată în reprezentări simbolice și aprobări umane.

Testele ascunse sunt o metodă clasică de a păstra separarea dintre generare și evaluare. Benchmarkuri precum SWE-bench folosesc probleme reale din repository-uri și teste pentru a evalua dacă agenții pot rezolva issue-uri fără ca fiecare caz să fie construit de agent [44]. Chiar și aici există riscuri de contaminare și adaptare la benchmark, dar principiul rămâne: evaluatorul trebuie să păstreze informație pe care generatorul nu o poate exploata direct. Pentru cercetare, setul ascuns nu trebuie să fie doar o colecție de exemple; poate conține counterexamples, baseline-uri, replicări sau criterii create de o echipă independentă.

Formal methods oferă o altă formă de separare. Un program poate fi verificat față de o specificație, iar abstract interpretation, model checking și SMT pot acoperi clase de comportament dincolo de testele enumerate [45]. Totuși, rezultatul rămâne relativ la specificație. De aceea propunerea neuro-simbolică are două verificări distincte: verificarea internă a artefactului și verificarea alinierii dintre artefact și contractul problemei. Prima poate fi complet automatizată în unele domenii. A doua necesită semantică, context și adesea judecată umană.

Cazurile cauzale fac diferența și mai clară. Un model observațional poate prezice bine rezultatul, dar predicția nu identifică mecanismul și nu garantează efectul unei intervenții. Dacă AI generează o explicație causală după ce vede corelația, avem iluzia mecanismului. Un „causal claim type” din nucleul Epistemic Guardian ar impune câmpuri distincte: variabila intervenită, estimandul, ipotezele de identificare, confounderii, negative controls și predicțiile prin care două grafuri cauzale pot fi diferențiate. Fără acestea, sistemul poate raporta asociere sau predicție, nu cauzalitate.

În medicină și științele sociale, validitatea externă este o sursă majoră de decalaj. Un efect observat într-o populație, perioadă sau instituție poate să nu se transfere. Un LLM poate scrie o secțiune convingătoare despre generalizare, dar transferul este o afirmație empirică. Sistemul ar trebui să trateze fiecare extindere a domeniului ca o nouă promovare, cu propriile dovezi. „Funcționează pe datasetul D” și „funcționează în practică” sunt noduri diferite, conectate printr-o ipoteză de transportabilitate.

O parte din problemă poate fi redusă prin ontologii și tipuri. Dacă toate afirmațiile sunt text liber, „îmbunătățește”, „explică”, „demonstrează” și „validează” pot fi folosite elastic. Un sistem neuro-simbolic poate cere tipul exact: PerformanceClaim, NoveltyClaim, CausalClaim, FormalProofClaim, SafetyClaim sau UsabilityClaim. Fiecare tip are câmpuri și porți diferite. Un PerformanceClaim cere comparator, dataset, metrică, incertitudine și condiții de evaluare. Un NoveltyClaim cere spațiu de căutare și vecini apropiați. Un SafetyClaim cere hazard model și acoperirea scenariilor, nu doar absența incidentelor în demo.

PROPUNERE DE CERCETARE

„Proxy-Gap Analyzer” ar compara în mod continuu contractul problemei cu datasetul, metrica, testele și concluzia. Componenta neuronală ar extrage corespondențe semantice și posibile pierderi. Componenta simbolică ar aplica reguli: o concluzie nu poate avea domeniu mai larg decât dovezile fără o ipoteză explicită; o metrică proxy trebuie să aibă justificare și teste de sensibilitate; o afirmație cauzală nu poate fi susținută doar de performanță predictivă; un test generat din aceeași specificație trebuie marcat drept neindependent. Rezultatul ar fi un raport scurt de decalaje, nu încă o explicație generală.

Un asemenea instrument trebuie evaluat cu atenție. Poate produce false alarms și poate împinge cercetarea spre probleme ușor de specificat, penalizând explorarea fundamentală. Uneori definițiile se schimbă legitim pe măsură ce înțelegerea crește. Prin urmare, scopul nu este înghețarea problemei, ci versionarea schimbării. Cercetătorul poate accepta un proxy mai îngust, dar sistemul păstrează faptul că rezultatul răspunde unei întrebări modificate. Honest narrowing este știință; silent substitution produce iluzie.

Codul și matematica sunt adesea prezentate drept refugii împotriva ambiguității limbajului. Programul rulează sau nu rulează; proof assistant-ul acceptă sau respinge. Această claritate este reală și oferă cele mai bune modele pentru o AI legată de verificatoare. Dar chiar aici apare distincția dintre corectitudinea internă și relevanța externă. Un program poate implementa perfect funcția greșită, iar o demonstrație poate stabili impecabil teorema nepotrivită.

EVIDENȚĂ PUBLICATĂ

Benchmarkuri de code generation precum HumanEval au popularizat evaluarea prin teste unitare, iar SWE-bench a mutat sarcina spre issue-uri reale din repository-uri [67, 44]. Testele executabile sunt mai puternice decât evaluarea textuală, deoarece produc un verdict determinist asupra unor comportamente. Totuși, scorul depinde de acoperirea testelor și de absența leakage-ului. Un agent poate trece testele vizibile prin hard-coding sau poate exploata particularități. Versiunile „verified” și evaluările cu teste ascunse încearcă să reducă aceste riscuri, dar nici ele nu garantează că patch-ul este mentenabil sau că cerința a fost interpretată corect.

Oracle problem arată limita fundamentală [30]. Pentru multe programe, nu avem un rezultat corect ușor de calculat. Testarea folosește specificații, implementări de referință, invariants, proprietăți și relații metamorfe. Dacă AI generează testele, trebuie să întrebăm de unde provin oracolele.

Un test care repetă exemplul din prompt adaugă puțin. Un test care derivă o proprietate dintr-o specificație formală independentă, un regression test dintr-un bug real sau un differential test între implementări adaugă mai mult.

Mutation testing oferă o metrică direct relevantă: introducem modificări plauzibil greșite și observăm dacă suita de teste le detectează [32]. Pentru sistemele AI, mutațiile pot fi semantice, nu doar sintactice. Dacă problema este clasificarea afirmațiilor cauzale, mutăm confounderii, inversăm direcția relației sau schimbăm populația. Dacă testele continuă să treacă, oracolul nu acoperă proprietatea pretinsă. Property-based testing și metamorphic testing extind acoperirea dincolo de exemplele enumerate [31, 33]. Aceste tehnici sunt candidate naturale pentru un Falsifier automat.

Analiza statică și formal verification pot oferi garanții mai puternice. Abstract interpretation calculează supra-aproximări ale comportamentului programului, model checking explorează stări, iar SMT solvers verifică satisfiabilitatea unor constrângeri. CompCert și seL4 arată că sisteme software complexe pot primi garanții formale semnificative [68, 69]. Nu este realist să formalizăm orice experiment de cercetare la acest nivel, dar principiul este transferabil: afirmațiile trebuie traduse în proprietăți verificabile, iar kernelul de verificare trebuie să fie mai mic și mai auditat decât generatorul.

În theorem proving, modelele de limbaj pot propune pași, iar proof assistant-ul verifică fiecare derivare. LeanDojo oferă infrastructură și retrieval pentru antrenarea și evaluarea agenților în Lean [34]. AlphaGeometry combină un model neuronal cu un motor simbolic și a obținut performanțe remarcabile pe geometrie de olimpiadă [36]. Aceste sisteme ilustrează neuro-simbolicul în forma sa cea mai clară: componenta generativă explorează, componenta formală refuză pașii invalizi.

Totuși, „proof verified” nu este echivalent cu „famous problem solved”. Enunțul trebuie formalizat fără a schimba sensul. Bibliotecile și axiomele trebuie auditate. O demonstrație poate depinde de un rezultat neformalizat sau de un sorry/admit care marchează un gol. Sistemul trebuie să raporteze trust boundary: kernel, axiome, biblioteci, code extraction, definiții. În proiecte precum Flyspeck, succesul a necesitat nu doar un verificator, ci ani de formalizare și comunitate [6]. Aceasta este o corecție la fantezia că un LLM poate produce o mie de linii Lean și, prin simpla acceptare, poate închide orice problemă matematică.

Istoria Wiles oferă încă o lecție. O demonstrație umană extraordinară a avut o lacună pe care procesul de verificare a descoperit-o [2, 3]. Formalizarea poate reduce asemenea riscuri, dar numai după ce întregul

argument și enunțul sunt traduse. Un sistem AI poate ajuta enorm la această muncă, însă trebuie să păstreze diferența dintre „am formalizat scheletul”, „kernelul acceptă toate componentele” și „formalizarea corespunde teoremei originale”.

Reproducibilitatea este nivelul la care multe iluzii se destramă. Proiectul Open Science Collaboration a găsit o rată de reproducere mult mai mică decât ar sugera literatura psihologică originală [39]. Analize din biomedicină și sondaje largi au documentat dificultăți similare [70, 71]. În machine learning, variația mediului, lipsa codului, hyperparameter tuning-ul și selecția rezultatelor au motivat checklisturi și programe de reproducibilitate [72, 7]. AI intră într-un sistem care avea deja un verification gap.

Poate AI să ajute? Da. Poate genera environment files, documenta pipeline-ul, extrage parametri, verifica consistența dintre text și cod, reexecuta experimente și construi capsule RO-Crate. Poate căuta discrepanțe și poate reproduce automat baseline-uri. PaperBench explorează exact o parte din această capacitate [63]. Dar AI poate și masca problemele prin producerea unei capsule coerente care reproduce doar propriul rezultat. Reproducibility automation trebuie să distingă rerularea de replicarea independentă.

EVIDENȚĂ PUBLICATĂ

Standardele FAIR, PROV și RO-Crate oferă infrastructură pentru date și artefacte reutilizabile, proveniență și packaging [73, 54, 55]. Open science practices precum preregistration și Registered Reports separă mai clar ipoteza și analiza confirmatorie de explorare [74, 75, 76]. Aceste practici nu au fost create pentru LLM-uri, dar sunt extrem de relevante: un agent poate încerca mii de analize, iar fără un jurnal complet selecția post hoc devine invizibilă.

PROPUNERE DE CERCETARE

O „Reproduction Capsule” pentru proiecte AI-assisted ar include nu doar cod și date, ci și istoricul deciziilor generate: prompturile relevante, versiunile modelelor, toate variantele experimentale, criteriul de selecție, testele respinse, sursele și modificările semanticii problemei. Pentru protecția IP și privacy, nu toate detaliile trebuie publicate; pot exista hash-uri, loguri semnate, execuții controlate și selective disclosure. Integritatea traseului nu dovedește adevărul, dar împiedică rescrierea retrospectivă a istoriei.

Capsula trebuie să permită două moduri. În repeat mode, o altă persoană rerulează exact pipeline-ul. În replicate mode, primește doar contractul, datele sau protocolul și construiește independent

implementarea ori folosește alte date. Diferența dintre rezultate devine informație. Dacă repeatability este mare și replication scăzută, avem un efect dependent de pipeline sau context. Dacă ambele sunt scăzute, documentația ori stabilitatea sunt insuficiente. Dacă ambele sunt ridicate, promovarea epistemică este mai justificată.

SINTEZĂ ȘI INFERENȚĂ

Codul, testele și proof assistants nu sunt simple ornamente; ele pot închide clase întregi de erori și reprezintă contraponderea necesară alarmismului. Problema nu este că verificarea automată ar fi „tot AI”. Problema este ce proprietate verifică și cât de independent este oracolul față de eroarea relevantă. Un compilator este un verficator real pentru sintaxă și tipuri. Un kernel Lean este un verficator real pentru derivarea formală. Un test ascuns este un verficator real pentru cazurile sale. Iluzia apare când verdictul local este extins la o pretenție globală pe care instrumentul nu o acoperă.

De aceea, arhitectura propusă mai târziu nu va încerca să găsească un „truth score” universal. Va orchestra verificatoare specializate și va păstra scopul fiecăruia. Va spune: „codul compilează”, nu „metoda este corectă”; „teorema formală este demonstrată”, nu „problema naturală este rezolvată”; „rezultatul se reproduce în container”, nu „efectul generalizează”; „prior art-ul căutat nu conține un vecin apropiat”, nu „ideea este sigur nouă”. Precizia verdictului este una dintre cele mai importante tehnologii împotriva inflației epistemice.

2.3. Bucla epistemică închisă și validarea circulară

O buclă de cercetare este închisă epistemic atunci când afirmațiile, criticile și validările circulă în interiorul aceluiași ansamblu de presupuneri fără să primească informație suficient de independentă. Termenul nu înseamnă că sistemul este izolat de Internet sau că toate componentele sunt identice. Un agent poate căuta articole, rula cod și consulta alte modele, iar bucla să rămână închisă dacă selectează doar dovezi compatibile, dacă testele provin din aceeași interpretare sau dacă evaluatorul judecă stilul în locul consecințelor.

Modelul simplu generator–critic este atrăgător. Primul produce o soluție, al doilea găsește erori, primul revizuieste. Tehnici precum Self-Refine și Reflexion au arătat că feedbackul verbal iterativ poate îmbunătăți performanța pe anumite sarcini [46, 47]. Aceste rezultate sunt importante: auto-reflecția nu este inutilă. Totuși, alte cercetări au arătat că LLM-urile nu se autocorectează robust în reasoning fără feedback extern

și că pot schimba răspunsuri corecte în răspunsuri greșite atunci când sunt încurajate generic să se revizuiască [48]. Diferența dintre cele două familii de rezultate se explică parțial prin sarcină, feedback, model și criteriu. „Critică-te” nu este un verficator; este o nouă generare condiționată.

EVIDENȚĂ PUBLICATĂ

CRITIC a arătat că integrarea cu instrumente externe poate face auto-corectarea mai eficientă: modelul folosește căutare, execuție sau alte unelte pentru a verifica afirmații și a revizui răspunsul [49]. Program-aided language models și Program of Thoughts externalizează calculul către interpretoare, reducând erorile aritmetice și făcând unele pași verificabili [50, 51]. Aceste lucrări susțin principiul acestei cărți: corectarea devine mai credibilă când noua iterație primește constrângeri care nu sunt doar text generat.

Dar nici instrumentul extern nu este automat independent. Dacă modelul scrie un program care implementează greșit problema și apoi îl rulează, execuția confirmă doar comportamentul acelui program. Dacă interogarea de căutare este formulată pentru a găsi confirmări, retrieval-ul poate consolida biasul. Dacă proof assistant-ul primește un enunț slăbit, kernelul validează altceva. Independența trebuie analizată relativ la eroarea posibilă. Un calculator este independent de o greșeală aritmetică a LLM-ului, dar nu de o alegere greșită a formulei. Un dataset ascuns este independent de overfitting-ul manual, dar nu neapărat de leakage-ul din pretraining.

Acest punct poate fi exprimat prin „conservation of uncertainty”. Dacă niciun pas nu introduce date, axiome justificate, constrângeri sau evaluări independente, incertitudinea despre relația cu lumea nu poate dispărea doar prin transformarea artefactului. Textul poate organiza incertitudinea și poate descoperi contradicții interne; nu o poate converti în evidență externă. O sută de parafraze ale aceleiași ipoteze nu sunt o sută de observații.

LLM-as-a-judge este un caz relevant. Evaluatorii automați sunt utili pentru scalarea comparațiilor, iar benchmarkuri precum MT-Bench au arătat corelații semnificative cu preferințele umane [40]. Totuși, judecata este sensibilă la ordine, verbozitate, identitatea modelului și forma răspunsului [41, 42]. Dacă generatorul optimizează repetat după același judge, el poate învăța semnalele evaluatorului fără să îmbunătățească proprietatea latentă. Este Goodhart într-o buclă rapidă. În cercetare, un model poate învăța să pară mai riguros pentru evaluator adăugând citări, limitări și formalism, chiar dacă testul discriminant rămâne absent.

PROPUNERE DE CERCETARE

Un „Verification Independence Score” nu ar număra evaluatorii, ci sursele de variație relevante. Scorul ar lua în calcul dacă verificatorul folosește alt model, alte date, alt prompt, altă implementare, un kernel formal, un set ascuns, o măsurătoare fizică sau un evaluator uman blind. Ponderile nu pot fi universale. Pentru o eroare lexicală, două modele diferite pot fi suficiente; pentru o prejudecată comună de pretraining, nu. Sistemul ar produce o hartă, nu o garanție numerică.

Consensul multi-agent trebuie tratat în aceeași manieră. Dezbaterile poate crește acoperirea argumentelor și reduce erori accidentale, dar efectul depinde de independență și de protocol. Dacă agenții văd răspunsurile anterioare, poate apărea anchoring. Dacă majoritatea este folosită ca verdict, o eroare comună devine mai stabilă. Dacă un agent are rol explicit adversarial și acces la unelte diferite, valoarea crește. Un protocol bun nu întreabă doar „câți sunt de acord?”, ci „ce dovadă distinctă a adus fiecare și ce eroare ar putea detecta pe care ceilalți nu o pot detecta?”.

Bucula închisă poate fi instituțională. Un articol generat cu AI este revizuit de AI, rezumat de AI pentru editor, evaluat printr-un benchmark produs tot cu AI și citat de alte texte generate. Fiecare etapă reduce costul, dar poate dilua contactul cu sursele primare. În timp, corpusul de antrenare conține tot mai multe afirmații derivate din alte afirmații, iar originea empirică devine dificil de urmărit. Proveniența nu rezolvă adevărul, dar devine condiție pentru a ști unde intră observația și unde începe reciclarea.

Nanopublications, Research Objects, PROV și RO-Crate oferă primitive pentru a lega afirmații, artefacte, agenți și procese [52, 53, 54, 55]. În forma lor actuală, aceste standarde descriu proveniența, nu statutul epistemic. Un fișier poate avea proveniență perfectă și conținut fals. Programul propus le extinde conceptual cu reguli de promovare și cu tipuri de evidență. Proveniența spune „de unde vine”; politica epistemică spune „ce poate susține”.

Un alt pericol este „review laundering”: un sistem produce feedback amplu care este folosit drept semnal că lucrarea a fost criticată. Evaluarea LLM a manuscriselor poate fi utilă pentru claritate, acoperirea literaturii și detectarea inconsecvențelor. Studii timpurii au raportat suprapuneri între feedbackul GPT-4 și unele comentarii ale reviewerilor umani, dar și limitări importante [56]. Chiar dacă feedbackul este bun, nu trebuie echivalat cu peer review independent, deoarece modelul poate rata erori metodologice, nu poate verifica toate datele și poate reproduce consensul textual al

domeniului. Instrumentul trebuie etichetat ca pre-review sau consistency review, nu ca validare științifică.

PROPUNERE DE CERCETARE

„Closed-Loop Detector” ar analiza un proiect și ar căuta trasee de susținere care se termină în artefacte generate din aceeași sursă. De exemplu, claim C este susținut de test T, T a fost generat din specificația S, S a fost derivată de același model din C. Graful conține un ciclu. Ciclul nu dovedește că C este fals, dar arată că suportul nu adaugă independență. Sistemul ar cere cel puțin o muchie externă: test derivat dintr-o specificație independentă, date noi, un evaluator blind sau o demonstrație formală a unei proprietăți relevante.

Detectorul trebuie să distingă circularitatea vicioasă de iterarea legitimă. Știința este plină de bucle: teoria ghidează experimentul, rezultatul revizuiește teoria, iar noua teorie ghidează alt experiment. Bucla devine epistemic productivă când fiecare rotație primește observații care ar fi putut contrazice teoria. O buclă exclusiv textuală poate fi utilă pentru clarificare, dar nu trebuie raportată ca validare. Criteriul nu este forma circulară, ci intrarea de constrângeri discriminante.

Principiul practic al capitolului poate fi formulat astfel: nu folosi același canal pentru a genera și a certifica exact proprietatea pe care canalul tinde să o mimeze. Limbajul poate evalua claritatea limbajului. Nu este suficient pentru adevărul empiric. Un model poate verifica respectarea unui format. Nu este suficient pentru noutate. Un proof assistant poate verifica derivarea formală. Nu este suficient pentru alegerea enunțului. Un test suite poate verifica implementarea. Nu este suficient pentru utilitatea în lumea reală. Când proprietatea evaluată depășește puterea oracolului, verdictul trebuie restrâns.

Acest mod de gândire face posibilă o automatizare mai matură. În loc să cerem unui singur agent să fie simultan inventator, judecător și garant, construim o rețea de verificatoare cu competențe declarate și limite explicite. Valoarea AI nu scade; dimpotrivă, devine mai ușor de folosit agresiv pentru explorare, deoarece sistemul nu confundă explorarea cu verdictul.

Una dintre promisiunile cele mai atractive ale LLM-urilor este generarea de idei științifice. Modelele pot citi literatură, combina concepte și propune experimente într-un timp imposibil pentru un singur om. Evaluarea acestei promisiuni este însă dificilă. Noutatea nu este o proprietate ușor de observat, iar evaluarea umană este sensibilă la stil. O idee poate părea nouă deoarece este formulată neobișnuit, pentru că evaluatorul nu cunoaște prior art-ul sau pentru că detaliile creează impresia de maturitate.

Tocmai domeniul în care vrem să măsurăm creativitatea este vulnerabil la More Words Than Reality effect.

EVIDENȚĂ PUBLICATĂ

Studiul la scară mare „Can LLMs Generate Novel Research Ideas?” a comparat idei produse de LLM-uri cu idei dezvoltate de peste o sută de cercetători NLP. În evaluări blind, ideile generate de modele au primit scoruri mai mari de noutate, în timp ce alte dimensiuni au fost mai apropiate, iar analiza a identificat probleme de fezabilitate, auto-evaluare și diversitate a ideilor [59]. Designul este important deoarece folosește experți și comparație blind. Totuși, scorul de noutate este o judecată, nu o demonstrație că ideea nu există în literatură și nici că produce un rezultat nou. Lucrarea însăși subliniază dificultatea evaluării.

Rezultatul are două interpretări compatibile. Optimist, LLM-urile pot recombina literatura într-un mod suficient de neobișnuit pentru a depăși ideile umane pe o dimensiune relevantă. Critic, modelele pot produce o formă de surpriză stilistică sau conceptuală care evaluatorilor le pare nouă înainte de prior-art search și implementare. Singurul mod de a separa interpretările este urmărirea ideilor prin etapele ulterioare: distinctivitate față de lucrări existente, implementabilitate, comparație cu baseline-uri, rezultat și replicare. Evaluarea de idea pitch este începutul, nu capătul.

Sisteme precum ResearchAgent și SciMON au încercat să folosească grafuri de literatură, retrieval și evaluări iterative pentru a genera ipoteze sau inspirații științifice [60, 61]. Aceste direcții sunt relevante pentru că mută generatorul dintr-un prompt izolat într-un context bibliografic. Retrieval-ul reduce unele invenții și poate găsi combinații mai bine ancorate. Totuși, accesul la literatură nu garantează noutatea. Corpusul poate fi incomplet, asemănările pot fi semantice și evaluatorul poate prefera idei care sună compatibil cu literatura găsită. Un sistem de novelty trebuie să caute activ vecinul cel mai apropiat și să încerce să reducă contribuția la acesta, nu doar să producă citări justificative.

The AI Scientist a demonstrat un pipeline care generează idei, scrie cod, rulează experimente, produce grafice și redactează un articol [62]. Valoarea lucrării este inginerească: arată că multe activități editoriale și experimentale pot fi orchestrate. Nu dovedește că sistemul face descoperiri științifice autonome cu o rată comparabilă cercetătorilor. Evaluările sunt limitate de domeniu, cost, calitatea benchmarkurilor și faptul că un articol complet poate fi produs chiar pentru o contribuție slabă. Tocmai această demonstrație face problema cărții urgentă: dacă putem automatiza pachetul complet, trebuie să automatizăm și auditul distanței dintre pachet și contribuție.

PaperBench schimbă perspectiva de la scrierea cercetării la reproducerea ei. Benchmarkul cere agenților să reproducă rezultate din lucrări de machine learning și evaluează artefactele cu rubrici detaliate și code execution [63]. Rezultatele inițiale arată că reproducerea completă rămâne dificilă chiar pentru agenți avansați. Nu trebuie comparate direct scorurile PaperBench cu evaluările de noutate din alte studii, deoarece sarcinile, modelele și metricile diferă. Contrastul conceptual este însă instructiv: producerea unei idei sau a unui manuscris plauzibil este mult mai ieftină decât reconstruirea fidelă a unei contribuții existente.

EVIDENȚĂ PUBLICATĂ

Cercetarea asupra productivității oferă motive reale de optimism. Într-un experiment cu sarcini profesionale de scriere, accesul la ChatGPT a redus timpul și a crescut calitatea medie a output-ului, cu beneficii mai mari pentru participanții inițial mai slabi [64]. În R&D pentru materiale, o analiză amplă a introducerii unui instrument AI a raportat creșteri semnificative ale descoperirilor și inovației, dar și distribuții inegale ale beneficiilor și schimbări ale muncii cercetătorilor [65]. Aceste rezultate nu sunt simple evaluări de stil; ele includ rezultate organizaționale sau tehnologice. Ele arată că AI poate produce progres real când este integrată într-un proces cu măsurători și rezultate externe.

Un studiu bibliometric recent a argumentat că instrumentele AI pot extinde productivitatea și impactul cercetătorilor care le folosesc, dar pot contracta diversitatea colectivă a subiectelor explorate [66]. Fiind observațional, studiul nu poate atribui toate diferențele cauzal AI-ului, iar detectarea utilizării AI are propriile limitări. El este totuși compatibil cu avertismentul lui Messeri și Crockett despre monoculturi și cu experimentul de creativitate care a găsit creștere individuală, dar convergență colectivă [4, 13]. Dacă generatoarele propun idei din aceleași regiuni dense ale literaturii, laboratoarele pot deveni mai productive și mai asemănătoare simultan.

Este important să diferențiem LLM-ul de sistemele autonome conectate la lumea fizică. „Robot scientist” Adam a formulat și testat ipoteze funcționale în genomica drojdiei, folosind automatizarea experimentelor [10]. Laboratoare mobile și self-driving labs au explorat spații chimice și materiale prin bucle de selecție, experiment și măsurare [11]. Coscientist a combinat LLM-uri cu căutare, planificare și instrumente de laborator pentru a proiecta și executa experimente chimice [12]. Aceste sisteme nu elimină riscul de proxy, eroare instrumentală sau interpretare. Dar introduc un fapt esențial: ipoteza este confruntată cu un rezultat pe care textul nu îl poate dicta direct.

Aici se află o distincție pe care retorica despre „AI scientist” o estompează adesea. Există autonomie de workflow și autonomie epistemică. Un sistem are autonomie de workflow dacă poate executa pași fără intervenție umană: căutare, cod, experimente, redactare. Are autonomie epistemică doar în măsura în care poate selecta teste discriminante, detecta schimbarea problemei, gestiona incertitudinea și cere replicare. Prima este o proprietate de orchestration. A doua este o proprietate a relației dintre afirmații și evidențe. Un agent poate fi foarte autonom procedural și foarte dependent epistemic de propriile proxy-uri.

SINTEZĂ ȘI INFERENȚĂ

Literatura actuală susține patru concluzii moderate. Modelele pot produce idei percepute ca noi. Pot automatiza părți extinse ale pipeline-ului științific. AI specializat și laboratoarele autonome pot crește descoperirea reală. Reproducerea și evaluarea independentă rămân mult mai dificile decât generarea. Literatura nu susține încă afirmația că un LLM generalist poate fi lăsat să genereze, valideze și publice descoperiri fără o infrastructură externă severă.

Această diferență are consecințe pentru benchmarkuri. Dacă evaluăm un research agent doar prin calitatea textului sau prin scorul unui LLM-judge, măsurăm capacitatea de a produce aparența cercetării. Dacă îl evaluăm prin novelty verificată, teste ascunse, rezultate externe și replicare, măsurăm o parte din capacitatea de descoperire. Un benchmark bun trebuie să păstreze costul epistemic al sarcinii. Nu este suficient să comprimăm review-ul uman într-un scor dacă scorul este vulnerabil la aceeași fluentă pe care agentul o optimizează.

PROPUNERE DE CERCETARE

Pentru fiecare idee generată, construim un „survival record”. La momentul zero se înregistrează textul exact, sursele accesate și predicțiile. Apoi ideea trece prin canonicalizare și prior art, evaluare de fezabilitate, implementare, baseline-uri, teste adverse și, unde este posibil, replicare. Scorurile umane inițiale rămân înghețate. Reality gap-ul este diferența dintre impresia inițială și statutul final. Un astfel de dataset ar permite să aflăm ce proprietăți ale textului prezic impresia și ce proprietăți prezic supraviețuirea. Este posibil ca lungimea și noutatea lexicală să prezică prima, iar claritatea predicțiilor și calitatea baseline-ului să prezică a doua.

O variantă instituțională ar urmări cohorte de proiecte pe luni sau ani. Laboratoarele care folosesc intens AI ar raporta nu doar numărul de idei și manuscrise, ci distribuția ratelor de abandon și motivele: prior art, imposibilitate tehnică, efect nul, cost, eroare de specificație. Un laborator

sănătos poate avea o rată mare de ucidere a ideilor, deoarece generează mult și testează sever. Fără aceste date, activitatea poate fi confundată cu progresul, iar eșecurile dispar din memorie.

Cartea adoptă astfel o poziție pro-generare și anti-confuzie. Nu este necesar ca fiecare idee să fie bună; explorarea cere risipă. Este necesar ca sistemul să nu transforme rapid ideea într-o afirmație de succes doar pentru că poate produce artefactele intermediare. Research agents ar trebui evaluați nu după cât de repede scriu un articol, ci după cât de eficient transformă un spațiu mare de conjecturi într-un set mic de rezultate care merită timpul comunității.

Lucrări foarte recente converg spre diagnosticul că agenții științifici au nevoie de stări explicite ale dovezilor și de artefacte auditabile, nu numai de manuscrise. EviGraph folosește un graf tipat Problem–Gap–Hypothesis–Experiment–Finding–Claim [141]; cercetarea asupra evidence tracing descrie proveniența ca graf al surselor, tool-urilor, memoriei, afirmațiilor și acțiunilor [142]; ARA reconstruiește workflow-uri de reproducere [143]; XScientist păstrează exploration DAG-uri și re-execution hooks [144]; iar Ma formulează explicit dezechilibrul dintre generare și verificare [145]. Sunt antecedente importante, dar nu validează încă Guardian-ul instituțional propus aici.

Capitolul 3. Matematica dintre rigoare și decor

3.1. Mathiness, idealizare și formalism fără putere discriminantă

Termenul „math-washing” nu desemnează o categorie academică stabilă și nici nu trebuie folosit ca acuzație universală împotriva formalizării. În acest volum îl folosim într-un sens restrâns: adăugarea sau mobilizarea matematicii astfel încât o afirmație să pară mai precisă, mai profundă ori mai apropiată de realitate decât este justificat de legătura dintre simboluri, ipoteze, date și fenomenul studiat. Conceptul este înrudit cu „mathiness”, termenul folosit de Paul Romer pentru alunecarea strategică dintre cuvinte, simboluri, teorie și fapte empirice în economia creșterii [88]. În informatică și fizică, aceeași structură poate apărea fără intenție strategică. Un cercetător poate construi un model impecabil în interiorul propriilor axiome și poate uita treptat că succesul formal nu răspunde încă întrebării pentru care publicul îl citește.

Matematica autentică nu este suspectă prin faptul că este abstractă. Dimpotrivă, abstracția este una dintre cele mai productive tehnologii intelectuale inventate de oameni. Ea permite separarea structurii de detalii accidentale, identificarea invariantilor și derivarea unor consecințe pe care intuiția nu le poate susține. O teoremă despre un model poate fi perfect adevărată și importantă chiar dacă modelul nu descrie direct o instalație, un creier sau un accelerator. Problema apare la trecerea dintre niveluri: de la „în acest model, sub aceste ipoteze” la „sistemul real se comportă astfel”; de la o limită asimptotică la o promisiune inginerască; de la o posibilitate logică la fezabilitate fizică; de la o analogie elegantă la un mecanism causal.

EVIDENȚĂ PUBLICATĂ

Filosofia modelării științifice a analizat de mult idealizarea. Weisberg distinge forme de idealizare care simplifică, controlează sau construiesc modele minimale [89]. Oreskes, Shrader-Frechette și Belitz au argumentat că modelele numerice ale sistemelor naturale deschise nu pot fi „verificate” în sensul demonstrației adevărului lor; ele pot fi evaluate, confirmate relativ și testate pentru adecvare, însă accesul la sistem este incomplet, iar mai multe modele pot reproduce observațiile [90]. Aceste rezultate nu condamnă modelarea. Ele cer ca relația dintre

model și țintă să fie declarată, iar forța concluziei să nu depășească forța punții empirice.

În forma sa cea mai simplă, math-washing-ul schimbă impresia fără să schimbe puterea discriminantă. O ecuație reformulează propoziția, dar nu adaugă o predicție; un obiectiv de optimizare traduce o preferință vagă într-un scalar, dar alegerea termenilor și a ponderilor rămâne nejustificată; un theorem-like statement formalizează o versiune mai slabă a problemei, după care rezultatul este relatat ca și cum ar fi rezolvat problema inițială. În alte cazuri, matematica adaugă rigoare locală, dar ascunde fragilitatea globală: demonstrația este corectă, însă presupune date independente și identic distribuite, acces la un oracol, precizie infinită, memorie nelimitată, stări inițiale imposibil de pregătit sau o arhitectură fizică fără costuri de comunicație.

Un diagnostic defensabil trebuie să evite două excese. Primul este credulitatea față de simbol. Al doilea este antiintelectualismul care suspectează orice formalism pe care cititorul nu îl înțelege. Gradul de dificultate nu este o probă a relevanței, dar nici lipsa unei aplicații imediate nu este o probă a inutilității. Unele dintre cele mai importante teorii au precedat aplicațiile cu decenii. Un audit bun nu întreabă „este matematica prea abstractă?”, ci „ce afirmație exactă este demonstrată, relativ la ce obiect formal, și ce alte argumente sunt necesare pentru ca ea să susțină afirmația despre lume?”.

SINTEZĂ ȘI INFERENȚĂ

Propunem să tratăm fiecare trecere de la formalism la realitate ca pe o obligație de legătură. O obligație poate fi satisfăcută printr-o corespondență măsurabilă între variabile și observabile, printr-un argument de aproximare cu eroare controlată, printr-o derivare dintr-o teorie deja bine confirmată, printr-un experiment discriminant sau printr-o justificare explicită că lucrarea urmărește valoare matematică internă și nu face încă o afirmație empirică. Ceea ce trebuie eliminat nu este explorarea formală, ci ambiguitatea strategică dintre aceste stataturi.

Un „symbol-to-referent map” ar reprezenta, pentru fiecare simbol central, ce obiect pretinde să descrie. Unele simboluri sunt pur formale; altele reprezintă mărimi măsurabile; altele agregă constructe latente. Pentru fiecare se înregistrează unitățile, domeniul, modul de estimare și incertitudinea. Dacă o variabilă numită „inteligență”, „complexitate socială” sau „valoare” este doar un scor produs de un model, acest lucru trebuie să rămână vizibil. Numele semantic nu poate transfera automat proprietățile conceptului către proxy.

Un al doilea artefact este registrul ipotezelor. Ipotezele nu sunt doar cele scrise în secțiunea „Assumptions”. Ele apar în alegerea distribuției, în independențe, în aproximări, în condiții de regularitate, în limitele hardware, în disponibilitatea datelor și în comportamentul utilizatorilor. Epistemic Guardian ar putea extrage ipotezele declarate și implicite, apoi ar întreba care sunt structurale, care sunt aproximative și care sunt nerealiste în domeniul revendicat. Un rezultat nu este invalid pentru că presupune condiții ideale; devine înșelător când condițiile dispar din concluzie.

Un al treilea artefact este „claim-strength ledger”. Fiecărei concluzii îi este asociată forța maximă permisă de dovezi. O demonstrație formală poate susține „proprietatea P urmează din axiomele A”; nu susține fără alte legături „implementarea va avea proprietatea P în producție”. O simulare poate susține comportamentul modelului în regimul explorat; nu confirmă automat comportamentul țintei fizice. Un benchmark poate susține o comparație pe distribuția și protocolul folosit; nu demonstrează superioritate generală. Sistemul poate detecta verbe precum „proves”, „guarantees”, „solves” sau „demonstrates” și le poate confrunta cu tipul evenimentului epistemic înregistrat.

PROPUNERE DE CERCETARE

Formalism Auditor, ca modul al Epistemic Guardian, ar combina extragerea neuronală cu verificări simbolice și instrumentale. LLM-ul identifică afirmațiile, ecuațiile, definițiile și relațiile invocate. Un parser matematic construiește dependențe între definiții și rezultate. Analizoare de unități, solve, proof assistants sau executori numerici verifică ceea ce este verificabil. Un graf păstrează legătura dintre concluzii, ipoteze și artefacte. Modulul nu emite verdictul „math-washing” ca etichetă morală, ci un raport al obligațiilor nesatisfăcute: simbol fără referent, concluzie mai puternică decât teorema, proxy nedeclarat, sensibilitate neanalizată, resurse omise, validare exclusiv internă.

O metrică simplă ar fi „Constraint Gain”: ce restricții noi introduce formalizarea asupra lumii rezultatelor posibile? Dacă două teorii verbale diferite primesc aceeași ecuație decorativă, câștigul este mic. Dacă formalizarea produce predicții incompatibile, counterexamples sau condiții testabile, câștigul este mare. O a doua metrică, „Reality Link Coverage”, ar măsura proporția elementelor formale decisive conectate la observații, instrumente sau argumente de aproximare. Ambele sunt propuneri de cercetare și trebuie validate; nu sunt proprietăți obiective care pot fi calculate universal.

Testarea modulului ar necesita un corpus construit cu grijă. Ar conține formalizări autentice cu valoare internă, modele ideale folosite corect, modele cu extrapolări excesive, rezultate corecte pentru probleme slăbite și texte decorate cu ecuații irelevante. Experții ar adnota nu „bun” sau „rău”, ci tipul legăturii și obligația lipsă. Sistemul ar fi evaluat prin capacitatea de a ajuta reviewerii să găsească salturile, fără a penaliza matematica pură sau cercetarea exploratorie. Rata de „false kill” este la fel de importantă ca rata de detecție.

În această formă, analiza math-washing-ului devine compatibilă cu o cultură științifică pozitivă. Ea nu cere ca fiecare teorie să aibă imediat un dispozitiv comercial sau o predicție nouă. Cere doar o contabilitate epistemică onestă. Putem avea matematică pură, modele speculative, infrastructuri conceptuale și programe pe termen lung. Ele devin mai credibile, nu mai puțin, atunci când nu împrumută statut empiric de la simbolurile lor.

3.2. Informatică, machine learning, simulare și calcul cuantic

În informatică, distanța dintre model și mașină este inevitabilă. Analiza complexității ignoră multe detalii pentru a izola creșterea costului; modelele distribuite idealizează rețeaua; teoria bazelor de date presupune operații abstracte; securitatea definește adversari și jocuri; machine learning-ul lucrează cu distribuții, funcții de pierdere și protocoale. Fără aceste abstracții, domeniul ar fi o colecție de particularități. Totuși, tocmai succesul abstractizării creează tentația de a transforma o victorie într-un model într-o promisiune despre sistemul complet.

EVIDENȚĂ PUBLICATĂ

Lipton și Steinhart au descris tendințe problematice în scholarship-ul machine learning: explicații speculative prezentate ca mecanisme, folosirea elastică a limbajului și matematică ce poate servi mai mult impresiei de rigoare decât clarificării [91]. D'Amour și colaboratorii au arătat problema underspecification: multe modele cu performanțe similare pe distribuția standard pot avea comportamente foarte diferite în condiții relevante pentru deployment [92]. Literatura despre shortcut learning arată că rețelele pot exploata corelații predictive care nu corespund mecanismului dorit [93]. În recommender systems, reevaluarea unor metode neurale a găsit adesea că baseline-uri mai simple și bine configurate rămăneau competitive, sugerând că noutatea arhitecturală nu garantează progresul comparativ [94].

Aceste rezultate identifică mai multe forme de decuplare. Prima este decuplarea dintre obiectiv și intenție. Funcția de pierdere este optimizată, dar nu formalizează complet rezultatul social sau științific urmărit. A doua este decuplarea dintre benchmark și domeniu. Modelul câștigă pe un set de date, dar avantajul depinde de leakage, de o împărțire convenabilă, de tuning asimetric sau de un proxy fragil. A treia este decuplarea dintre algoritm și arhitectură. O metodă are complexitate atractivă, dar costurile dominante sunt memoria, transferul de date, sincronizarea, precizia numerică, compilarea sau energia. A patra este decuplarea dintre cod și specificație: programul trece testele, însă testele au fost generate din aceeași interpretare greșită a problemei.

Un exemplu tipic este afirmația „algoritmul este eficient”. În analiză, ea poate însemna o limită asimptotică mai bună. Într-o implementare, dimensiunile relevante pot fi sub pragul la care avantajul apare; constantele pot domina; operațiile teoretic ieftine pot fi scumpe pe hardware; sau algoritmul poate necesita o reprezentare imposibil de menținut în memorie. Afirmația teoretică rămâne corectă, dar transformarea ei într-o afirmație inginerească necesită un „resource ledger”: complexitate în timp și spațiu, transferuri, paralelism, precizie, I/O, energie, cost de preprocesare și regimul de scalare.

PROPUNERE DE CERCETARE

Physical and Architectural Feasibility Checker ar extinde Epistemic Guardian cu modele de cost configurabile. Pentru o contribuție de systems sau ML, sistemul ar extrage operațiile dominante, presupunerile despre hardware, dependențele software și resursele experimentelor. El ar compara estimările simbolice cu profile reale, roofline models, limite de memorie, bandwidth și latență. Nu ar încerca să prezică exact o mașină viitoare; ar produce scenarii și puncte de ruptură. Dacă avantajul există numai la dimensiuni la care memoria depășește cu trei ordine de mărime sistemele plauzibile, acest lucru este o informație centrală, nu o notă de subsol.

În quantum computing, nevoia acestei contabilități este și mai vizibilă. Domeniul nu este o fraudă, iar progresul său teoretic și experimental este real. Preskill a definit epoca NISQ tocmai pentru a separa dispozitivele zgomotoase intermediare de calculul cu corecție completă a erorilor [95]. Hoefler, Häner și Troyer au argumentat că evaluarea avantajului cuantic trebuie să includă întregul sistem, comparații clasice puternice și resurse realiste, nu doar numărul de operații într-un circuit ideal [96]. Estimarea lui Gidney și Ekeră pentru factorizarea RSA-2048 este un exemplu constructiv: nu se limitează la afirmația că algoritmul lui Shor este

polinomial, ci traduce algoritmul în număr de qubiți fizici, timp și ipoteze de eroare [97].

Diferența dintre un algoritm cuantic și o capacitate practică traversează mai multe porți. Datele trebuie pregătite; starea inițială trebuie realizată; circuitul trebuie compilat pentru conectivitate și setul de porți; erorile trebuie suprimate sau corectate; rezultatul trebuie citit; iar costul întregii conduite trebuie comparat cu algoritmi clasici care evoluează simultan. În unele propuneri de quantum machine learning, input loading și output extraction pot consuma avantajul presupus. În altele, speedup-ul este demonstrat pentru un model de acces la date foarte puternic, fără o arhitectură clară care îl implementează. Acest lucru nu face teorema falsă; limitează afirmația pe care o poate susține.

Epistemic Guardian ar folosi un „Quantum Resource Contract” pentru fiecare afirmație de avantaj: problema exactă, modelul de acces la input, precizia, probabilitatea de succes, numărul de qubiți logici, codul de corecție, qubiții fizici, T-count și T-depth, conectivitatea, runtime-ul, energia, pregătirea stării, citirea și baseline-ul clasic. Câmpurile nu trebuie completate toate pentru cercetarea timpurie. Absența lor schimbă însă statusul: „speedup formal într-un model de oracle” este distinct de „avantaj end-to-end estimat” și de „avantaj experimental observat”.

În fizica computațională, o situație analogă apare când simularea dobândește o autoritate independentă de model. O simulare poate produce detalii, animații și distribuții care par observații. Totuși, ele sunt consecințe ale ecuațiilor, parametrilor, condițiilor de frontieră și metodei numerice. Oreskes și colaboratorii avertizează exact împotriva confuziei dintre succesul intern și adevărul complet al unui model al unui sistem deschis [90]. Epistemic Guardian ar urmări ce parte a rezultatului este verificare numerică, ce parte este calibrare pe date, ce parte este predicție out-of-sample și ce parte este interpretare.

SINTEZĂ ȘI INFERENȚĂ

Suspiciunea rezonabilă nu este că „multe construcții din informatică și fizică sunt false”, ci că ecosistemele de publicare pot recompensa rezultate locale prezentate cu vocabular global. Motivele sunt instituționale: noutatea este mai ușor de comunicat decât delimitarea; graficele și formulele sunt semnale rapide pentru reviewerii suprasolicitați; companiile și universitățile au nevoie de promisiuni; iar autorii își cunosc bine modelul, dar mai puțin hardware-ul, domeniul de aplicare sau alternativa clasică. AI generativ poate amplifica fiecare treaptă, deoarece produce rapid formalism, cod, benchmarks și justificări aliniate aceleiași narațiuni.

Un instrument util nu trebuie să se transforme într-o poliție a realismului. Cercetarea teoretică are dreptul să exploreze modele ideale. Checker-ul ar impune o etichetare a nivelului de afirmație, nu o interdicție. El ar putea genera un raport în două coloane: „ce este stabilit” și „ce puncte lipsește pentru revendicarea extinsă”. Un rezultat poate rămâne valoros în prima coloană. În acest fel, sistemul protejează atât publicul de hype, cât și teoria de critica nedreaptă că nu a livrat ceva ce nu a promis.

Evaluarea tehnologiei trebuie făcută pe cazuri istorice și contemporane. Se pot construi perechi între afirmația publicată și o versiune cu limitele reintroduse; se poate testa dacă experții detectează mai bine overclaiming-ul cu resource contracts; se poate măsura dacă sistemul găsește baseline-uri omise și dacă reduce afirmațiile de generalizare nejustificată. În quantum, experții ar evalua acuratețea extragerii resurselor și utilitatea comparațiilor. În ML systems, instrumentul ar fi conectat la profiler și la cod. Un raport convingător fără măsurători ar reproduce exact problema pe care încearcă să o rezolve.

3.3. Teoria stringurilor și gradele de contact cu realitatea

Teoria stringurilor este un test important pentru orice guardian epistemic deoarece obligă sistemul să evite verdictele facile. Pe de o parte, critica privind testabilitatea este reală. Ellis și Silk au avertizat împotriva relaxării standardelor empirice în fizica fundamentală și au susținut că eleganța și puterea explicativă nu trebuie să înlocuiască testul observațional [98]. Pe de altă parte, teoria stringurilor a produs rezultate matematice și conceptuale importante. Strominger și Vafa au derivat microscopic entropia unor găuri negre în anumite regimuri [102], iar corespondența AdS/CFT formulată de Maldacena a devenit un instrument major în fizica teoretică și matematica fizică [101]. A spune fie „teoria a fost confirmată ca descriere finală a naturii”, fie „nu este știință și nu a produs nimic” ar comprima nejustificat situația.

Dawid a propus că, în absența accesului experimental direct, argumente non-empirice precum lipsa alternativelor, coerența neașteptată și succesul meta-inductiv pot modifica rațional încrederea într-un program [99]. Dawid, Hartmann și Sprenger au analizat formal no-alternatives argument și condițiile în care poate avea forță [100]. Criticii răspund că aceste argumente sunt sensibile la sociologia câmpului: lipsa alternativelor cunoscute poate reflecta investițiile, formarea și distribuția atenției, nu structura lumii. Dezbateră nu se rezolvă printr-un scor unic. Ea cere separarea mai multor tipuri de succes.

EVIDENȚĂ PUBLICATĂ

Putem distinge cel puțin cinci statute. Primul este consistența matematică relativă și fertilitatea formală. Al doilea este puterea de unificare conceptuală. Al treilea este succesul în rezolvarea unor probleme interne sau în conectarea unor domenii. Al patrulea este suportul non-empiric, care poate fi epistemic relevant, dar este contestabil și mai slab decât confirmarea directă. Al cincilea este confirmarea empirică a teoriei ca descriere a naturii. Literatura citată susține existența primelor tipuri de realizări și disputa asupra celui de-al patrulea; nu stabilește al cincilea statut pentru teoria stringurilor ca teorie fundamentală completă.

Această descompunere este mai generală. În orice domeniu matur există programe care produc valoare înainte de confirmarea ipotezei centrale. Un model poate genera matematică, instrumente, date, metode și probleme noi. Un program de cercetare poate fi rațional de finanțat chiar dacă probabilitatea tezei sale centrale este incertă. Axiologic Guardian va avea nevoie de această distincție: valoarea de opțiune și fertilitatea unui program nu sunt identice cu probabilitatea că teoria este adevărată. Epistemic Guardian trebuie să păstreze cele două registre separate.

SINTEZĂ ȘI INFERENȚĂ

O instituție se poate autoamăgi în două direcții. Poate menține un program prea mult deoarece succesul intern este relatat ca apropiere inevitabilă de confirmare. Sau poate abandona cercetarea fundamentală deoarece nu produce aplicații și predicții într-un orizont administrativ scurt. Un guardian bine proiectat trebuie să reziste ambelor presiuni. El ar putea raporta: teza centrală are suport empiric direct redus; programul are fertilitate matematică ridicată; costul de oportunitate este semnificativ; diversitatea alternativelor este insuficient explorată; valoarea de opțiune rămâne. Acesta este un profil pentru deliberare, nu o sentință.

Pentru fizică fundamentală propunem un „Evidence-Layer Ledger”. Fiecare afirmație este plasată într-un strat: necesitate matematică; consistență internă; legătură cu teorii confirmate; explicație post-hoc; retrodicție; predicție nouă; acces experimental posibil; confirmare; replicare. Sistemul urmărește când un argument trece tacit de la un strat la altul. Unificarea sau lipsa alternativelor pot crește interesul, dar nu sunt înregistrate ca observații. O derivare într-un caz ideal nu este prezentată ca validare a întregului program.

Un al doilea instrument este „Alternative Search Auditor”. El nu poate demonstra că nu există alternative, dar poate evalua procedura prin care afirmația a fost făcută. Ce spațiu conceptual a fost explorat? Câte tradiții și

instituții independente au căutat? Ce constrângeri au eliminat alternativele? Există bariere de finanțare sau reputație care reduc diversitatea? Un LLM poate ajuta la recuperarea literaturilor marginale și la generarea de alternative, însă tocmai aici riscul de pseudo-noutate este mare. Rezultatul trebuie tratat ca portofoliu de posibilități, nu ca probă.

Un al treilea instrument este „Empirical Access Planner”. Pentru o teorie sau un program, el caută consecințe care diferențiază ipoteza de rivale, chiar dacă testul este indirect sau tehnologic îndepărtat. El estimează ce progrese instrumentale ar fi necesare și ce observații existente constrâng deja spațiul. În lipsa unei căi plauzibile, sistemul nu declară teoria neștiințifică; declară gradul actual de decuplare empirică. Această informație poate orienta cercetarea spre construirea punților, nu doar spre rafinarea interiorului formal.

PROPUNERE DE CERCETARE

Studiul math-washing-ului în fizică și informatică trebuie să fie comparativ și adversarial. Corpusul ar include rezultate recunoscute ulterior ca overclaiming, rezultate teoretice inițial speculative care au devenit fundamentale, modele explicit instrumentale și programe contestate precum string theory. Echipe interdisciplinare ar adnota tipurile de afirmație, punțile și schimbările istorice de statut. Un LLM-judge simplu ar fi comparat cu Epistemic Guardian și cu experți. Scopul nu este ca agentul să decidă care teorie este adevărată, ci să reconstruiască fidel de ce știm ce credem că știm și unde începe dezbateră.

O provocare este că noțiunea de „realitate” nu este uniformă. În matematică, obiectul poate fi intern formalismului. În fizică, ținta este lumea observabilă, mediată de instrumente. În computer science, o contribuție poate viza un model abstract, un sistem fizic sau o practică umană. În AI, obiectivul poate fi predicție, explicație, control sau valoare socială. Guardian-ul trebuie să cunoască tipul de țintă. Altfel, va cere date empirice pentru o teoremă sau va accepta o teoremă drept dovadă de deployment.

De aici rezultă o regulă importantă: „nu există un singur tribunal al realității”. Există verificatoare adecvate tipului de claim. Proof kernel-ul este tribunal pentru derivare formală, nu pentru relevanța enunțului. Experimentul este tribunal pentru o predicție într-un regim, nu pentru universalitate. Deliberarea axiologică este tribunal pentru o alegere colectivă, nu pentru adevărul unei ecuații. Arhitectura duală propusă în această carte funcționează numai dacă refuză să amestece aceste competențe.

În practică, raportul final al Epistemic Guardian ar folosi limbaj simplu. Pentru fiecare contribuție ar spune ce este demonstrat, ce este observat, ce este simulat, ce este inferat, ce este contestat și ce nu este încă legat de lume. Această disciplină este mai utilă decât eticheta „math-washing”. Eticheta atrage atenția; harta permite cercetarea.

Nivel al afirmației	Ce poate și ce nu poate susține
Consistență formală	Arată că rezultatul urmează din axiome; nu stabilește că axiomele descriu ținta.
Succes în simulare	Arată comportamentul modelului în regimul explorat; nu este observație independentă.
Potrivire empirică	Restrânge modelele în domeniul măsurat; nu garantează identificarea mecanismului.
Predicție discriminatorie	Separă ipoteze rivale dacă protocolul are putere și nu există leakage.
Fezabilitate inginerască	Include resurse, arhitectură, precizie, input/output și baseline end-to-end.
Confirmare independentă	Adaugă evidență din implementări, date sau instituții cu dependențe diferite.

Capitolul 4. De la articolul științific la Executable Science

4.1. Articolul ca interfață, nu ca întregul obiect al cercetării

Articolul științific este unul dintre cele mai reușite formate de comprimare intelectuală create de civilizație. El transformă ani de muncă într-un argument public delimitat, pe care un alt specialist îl poate citi, critica, preda și cita. Slăbiciunea sa aparentă în epoca AI nu trebuie înțeleasă greșit. Problema nu este că articolele conțin proză. Știința are nevoie de proză, fiindcă semnificația, interpretarea, incertitudinea, responsabilitatea și dezacordul nu pot fi înlocuite cu un director de fișiere. Problema este că articolul a fost obligat să servească simultan drept explicație, index al dovezilor, memorie de laborator, release software, înregistrare juridică și stare pe termen lung a cunoașterii. Nu poate îndeplini bine toate aceste roluri.

Articolul obișnuit prezintă o narațiune retrospectivă. El descrie, de regulă, o întrebare, metode, rezultate, limitări și interpretări după ce proiectul dezordonat a fost comprimat într-o succesiune coerentă. Codul, datele, notebook-urile, protocoalele, preregistrările și materialele suplimentare pot exista, dar relațiile dintre ele sunt rareori reprezentate ca un singur obiect acționabil de calculator. Ce versiune a setului de date susține o anumită figură? Ce presupunere este necesară pentru o afirmație despre mecanism? Ce control negativ a determinat restrângerea domeniului afirmației? Ce rezultat depinde de o versiune de bibliotecă schimbată ulterior? Ce reviewer a acceptat analiza statistică, dar a contestat validitatea externă? Ce valoare sau politică a interzis un experiment altfel atractiv? Expertul uman reconstruiește cu efort aceste relații. Un model de limbaj le poate reconstrui fluent și, uneori, greșit.

Executable Science începe prin a refuza identificarea articolului cu întreaga cercetare. Articolul rămâne perspectiva narativă publică. Sub el și alături de el se află un obiect de cercetare purtător de dovezi, cu identitate stabilă, versiuni, ramuri, proveniență, afirmații explicite, artefacte conectate, înregistrări ale deciziilor și componente executabile acolo unde execuția are sens. Analogia cu software-ul este utilă, dar limitată. Un repository software conține cerințe, sursă, teste, issue-uri, dependențe, review-uri și release-uri fiindcă un binar singur nu poate fi întreținut. Un repository de cercetare are nevoie de discipline asemănătoare, dar

obiectele sale sunt epistemic mai bogate: dovezile pot susține sau înfrânge afirmații; explicațiile alternative pot rămâne active; un rezultat poate fi reproductibil și totuși irelevant; o teoremă poate fi validă, iar interpretarea ei fizică să eșueze; o politică poate permite calculul, dar interzice publicarea.

Infrastructurile existente acoperă deja părți din acest spațiu. W3C PROV reprezintă entități, activități și agenți [140]. RO-Crate împachetează artefacte de cercetare și metadate contextuale [128]. Principiile FAIR și extensiile lor pentru workflow-uri computaționale accentuează găsirea, accesibilitatea, interoperabilitatea și reutilizarea [163]. Common Workflow Language oferă o descriere portabilă a workflow-urilor computaționale [162]. Cercetarea despre FAIR Digital Objects acționabile de calculator urmărește obiecte digitale stabile, cu tip, metadate și operații explicite [164]. Niciuna dintre aceste fundații nu trebuie înlocuită. Propunerea este compunerea lor cu un strat care înțelege afirmații, presupuneri, relații dintre dovezi, stări epistemice, valori și decizii autorizate.

DOVEZI PUBLICATE

Motivația nu mai este ipotetică. Sistemele de cercetare AI end-to-end conectează deja generarea ideilor, căutarea literaturii, scrierea codului, execuția experimentelor, analiza, redactarea manuscrisului și review-ul automat [151]. Un survey din 2026 asupra agenților autonomi de cercetare a constatat că existența codului executabil era frecventă în sistemele studiate, în timp ce seed-urile sau urmele de execuție, metodele de verificare a noutății și oracolele externe validate în interiorul buclei erau mult mai rare [152]. Concluzia nu este că cercetarea automatizată ar fi frauduloasă. Concluzia este că artefactul cel mai ușor de executat poate să nu fie afirmația cel mai greu de justificat. Un script executabil poate coexista cu o judecată neverificabilă despre noutate sau cu un oracol de test generat din aceeași neînțelegere ca soluția propusă.

Obiectul de cercetare trebuie, așadar, să transporte mai mult decât fișiere. El are nevoie de un contract epistemic: ce se afirmă, în ce condiții, prin ce metodă, cu ce dovezi, la ce nivel de independență și ce observație ori analiză ar conta împotriva afirmației. Are nevoie și de un contract axiologic: ce scopuri, valori, constrângeri, stakeholderi și autorități decizionale guvernează munca. Contractele nu trebuie să fie complete înainte să înceapă explorarea. Ele pot deveni progresiv mai precise pe măsură ce proiectul trece de la speculație la consum semnificativ de resurse, publicare, reglementare sau deployment.

Evidență centrată pe articol	Obiect de cercetare în Executable Science
Narațiunea este principalul container	Narațiunea rămâne esențială, dar devine o perspectivă asupra unei cercetări versionate
Metodele și dovezile sunt descrise	Metodele, dovezile, mediile și transformările sunt legate de afirmații precise
Statutul este dedus din formulare	Conjectura, presupunerea, observația, simularea, demonstrația, replicarea, contestarea și retragerea au stări explicite
Corecțiile apar în documente ulterioare	Corecțiile, retractările și replicările devin evenimente succesoare legate în același istoric
Review-ul comentează un PDF	Review-ul poate contesta o afirmație, atașa un test, solicita o ramură sau restrânge domeniul verdictului
Valorile apar în principal în secțiuni etice sau de impact	Valorile, constrângerile, stakeholderii și autoritatea decizională pot influența traseul înainte de angajament
Utilizarea automată cere reconstruirea textului	Agenții operează asupra obiectelor, relațiilor, contractelor și receipt-urilor declarate, păstrând accesul la limbajul original

Viziunea trebuie să rămână federată. Domeniile științifice diferă prin confidențialitate, controlul instrumentelor, scara datelor, proprietate intelectuală, siguranță și autoritate legitimă. Un singur repository universal sau o singură ontologie universală ar invita atât eșecul tehnic, cât și capturarea instituțională. Obiectele de cercetare ar trebui să expună în schimb profiluri interoperabile: identificatori stabili, relații între versiuni, proveniență, tipuri de afirmații și dovezi, interfețe de workflow, reguli de acces și receipt-uri de verificare. Instituțiile pot păstra stocarea, politicile și semantica domeniului la nivel local. Release-urile publice pot expune suficiente dovezi pentru încredere justificată fără să dezvăluie date despre pacienți, secrete comerciale, colaboratori vulnerabili sau fiecare gând exploratoriu.

Confidențialitatea nu se opune executabilității. Un sistem poate păstra regimuri distincte de vizibilitate. Explorarea privată protejează dreptul de a greși înainte de publicare. Starea echipei înregistrează angajamentele relevante pentru colaborare. Auditul instituțional păstrează sub acces controlat dovezile necesare integrității, siguranței și responsabilității. Release-ul public expune afirmațiile, proveniența, artefactele suport și dezacordul nerezolvat potrivit pentru încrederea externă. Trecerea dintre

regimuri trebuie să fie explicită și autorizată. Un workbench care înregistrează fiecare gând provizoriu ar crea supraveghere, ar încuraja prudența performativă și ar micșora libertatea științifică în numele transparenței.

Ținta adecvată este structura minimă suficientă. Mai multă structură nu înseamnă automat mai multă știință. Un proiect ar trebui să formalizeze relațiile care îmbunătățesc material verificarea, reutilizarea sau calitatea deciziei. Articolul rămâne locul în care oamenii explică de ce contează munca. Obiectul de cercetare devine locul în care oamenii și mașinile pot inspecta ce s-a întâmplat, ce depinde de ce și ce s-a schimbat.

4.2. Research State, formalizare progresivă și revizuire observabilă

Prima problemă tehnică a Executable Science nu este codificarea a tot ceea ce știe un proiect. Este menținerea unui index epistemic suficient pentru decizii importante. Munca științifică este distribuită în articole, conversații, notebook-uri, cod sursă, seturi de date, issue trackers, instrumente, procese-verbale și expertiză tacită. Agenții bazați pe LLM fac această fragmentare mai ușor de căutat, dar și mai ușor de netezit. Un rezumat poate rezolva tacit o contradicție, un prompt nou poate înlocui o presupunere veche, iar o concluzie poate căpăta încredere numai fiindcă a fost repetată în mai multe artefacte generate.

PROPUNERE DE CERCETARE

O abstracție utilă este un Research State versionat la momentul t:

$$S_t = (Q_t, H_t, C_t, E_t, X_t, U_t, K_t, V_t, P_t)$$

Q reprezintă întrebările active; H ipotezele sau alternativele explicative; C afirmațiile explicite; E dovezile și relațiile de susținere sau atac; X experimentele finalizate și acțiunile candidate; U incertitudinea; K artefactele de cunoaștere și proveniența; V configurația valorilor; iar P politicile aplicabile sau Research Constitution. Tuplul este conceptual, nu o schemă obligatorie de bază de date. Rolul său este să ceară ca schimbările importante ale credințelor, presupunerilor, dovezilor, opțiunilor de acțiune și valorilor să devină tranziții explicite de stare, nu doar elemente ale unei narațiuni retrospective.

O afirmație separă conținutul de statut. „Metoda M îmbunătățește rezultatul Y pe setul de date D” este conținut. Propusă, specificată, testată, susținută provizoriu, contrazisă, replicată independent, depășită și retrasă sunt stări posibile. Dovada înregistrează originea, data, condițiile,

transformările, incertitudinea și dimensiunile independenței. O presupunere nu este o constatare. Un rezultat de simulare nu este o observație. O teoremă formală nu este confirmare empirică. O îmbunătățire pe benchmark nu este superioritate generală. Această disciplină de tipuri nu determină adevărul; împiedică proza să execute conversii ilicite.

Research State separă și memoria proiectului de fereastra de context a unui singur model. Modelele de limbaj pot extrage afirmații candidate, mapa fragmente de evidență, rezuma diferențele dintre versiuni și propune relații lipsă. Ele nu ar trebui să suprascrie tacit starea canonică. Schimbările cu impact ridicat cer un eveniment tipizat, un indicator către sursă și, când extragerea este ambiguă, confirmare umană. Textul și artefactul original rămân disponibile, astfel încât reprezentarea structurată să poată fi contestată. Interpretarea modelului este o propunere atașată dovezii, nu un înlocuitor al dovezii.

Proveniența devine infrastructură epistemică. Ea identifică ce versiune de model a propus o afirmație, ce prompt și ce surse au fost folosite, ce set de date și pipeline de preprocesare au produs o valoare, ce cod și mediu au generat o figură, ce om a aprobat o tranziție și dacă două artefacte de suport derivă din aceeași origine. Fără această filiație, cinci rapoarte pot părea cinci surse, deși toate descind din același paragraf generat. Repetiția devine astfel independență contrafăcută.

Înregistrarea completă nu este nici necesară, nici dezirabilă. Urmele la nivel de token sunt costisitoare, intruzive pentru confidențialitate și adesea irelevante. Problema de cercetare este comprimarea provenienței în funcție de sarcină: care este cel mai mic graf afirmație–dovadă–decizie care permite reconstruirea unei tranziții importante, în timp ce artefactele brute rămân adresabile? Un sistem practic poate păstra artefacte sursă imuabile, hash-uri sau identificatori, receipt-uri de transformare, versiuni de model și instrument, contextul politicii și motivele promovării ori retrogradării. Nu ar trebui să transforme supravegherea într-o condiție a legitimității științifice.

Revizuirea credințelor trebuie să fie observabilă. Când o dovadă nouă privește o afirmație activă, proiectul ar trebui să înregistreze unul dintre mai multe răspunsuri: încrederea crește, încrederea scade, afirmația se restrânge, o alternativă este întărită, dovada este respinsă cu un dezastru documentat sau starea rămâne nerezolvată. Guardian-ul nu trebuie să calculeze un posterior universal corect. Prima sa responsabilitate este să facă vizibilă nepreluarea dovezii. Un studiu din 2026, pe peste 25.000 de rulări ale agenților, a raportat că dovezile erau ignorate într-o mare parte a traselor și că revizuirea credințelor prin infirmare era rară [153]. Un

protocol separat face explicite și auditabile operațiile ipoteză, test, dovadă și actualizare a credinței [154]. Rezultatele sugerează că reprezentarea procesului nu este decor birocratic; poate fi necesară pentru a distinge finalizarea unui workflow de învățarea științifică.

Niciun singur calcul al credinței nu se potrivește întregii științe. Actualizarea bayesiană este naturală pentru afirmațiile empirice când priorurile și verosimilitățile pot fi apărute. Revizuirea de tip AGM oferă un vocabular formal pentru modificarea angajamentelor structurate logic, păstrând cât mai multă coerență [165]. Argumentarea defeasible și value-based este utilă când suportul poate fi înfrânt de excepții, context nou sau motive concurente [147, 148]. Sistemele de demonstrație formală oferă verificare exactă în raport cu o afirmație și un set de axiome. Arhitectura ar trebui să combine aceste semantici în funcție de tipul afirmației, în loc să forțeze orice incertitudine într-o probabilitate sau orice dezacord într-o contradicție logică.

Formalizarea progresivă este strategia de adopție. La primul nivel, sistemul atribuie numai identitate stabilă și proveniență artefactelor. La al doilea, extrage întrebări, afirmații, presupuneri, dovezi și legături, păstrând fragmentele sursă. La al treilea, reprezintă protocoale, variabile, metrice, acțiuni candidate și obligații de validare. La al patrulea, pot opera workflow-uri executabile, validatoare deterministe, modele statistice, simulări sau proof assistants. La al cincilea, agenții pot propune și compara tranziții de stare sub o autoritate explicită. Un proiect se poate opri la orice nivel dacă formalizarea suplimentară nu îi îmbunătățește munca.

Nivel de executabilitate	Ce poate face fiabil un calculator și ce rămâne deschis
Adresabil	Localizează versiunea exactă a unui artefact, identifică autoritatea și proveniența și detectează substituirea; sensul cere încă interpretare
Structurat	Traversează întrebări, afirmații, presupuneri, dovezi, stakeholderi și dependențe; extragerea și alegerile ontologice rămân contestabile
Reproductibil	Recrează un mediu computațional sau un protocol și rerulează operații declarate; reproducerea nu stabilește noutatea, relevanța sau validitatea externă

Nivel de executabilitate	Ce poate face fiabil un calculator și ce rămâne deschis
Verificabil	Aplică teste statistice, reguli de tip, proof kernels, verificări de politici, contracte de resurse sau constrângeri de consistență; corectitudinea rămâne relativă la formalizare și intrări
Operabil de agenți	Propune acțiuni, rulează instrumente, actualizează starea și generează rapoarte sub permisiuni; autoritatea științifică și morală rămâne distribuită între oameni și instituții

Distincția dintre explorare și angajament este crucială. Ramurile exploratorii pot conține ipoteze vagi, priorități slabe, cod eșuat și conexiuni stranii. Starea lor epistemică trebuie să rămână explicită fără a declanșa întreaga povară a publicării sau deployment-ului. Severitatea crește când o afirmație este promovată public, când resursele devin mari, când participanții sau mediile sunt afectați ori când un rezultat ghidează o acțiune importantă. Executable Science ar trebui să facă imaginația mai sigură prin delimitarea statutului, nu mai timidă prin cererea prematură de demonstrație.

4.3. Un ecosistem neuro-simbolic care poate citi, rula, contesta și memora știința

Viziunea completă nu este un singur artificial scientist și nici un singur Guardian universal. Este un ecosistem de agenți specializați, servicii simbolice, instrumente, obiecte de cercetare, autorități instituționale și comunități umane. Ecosistemul trebuie să distingă patru capacități pe care interfețele AI contemporane le confundă adesea. Un sistem poate genera o afirmație, executa o operație, valida o proprietate locală sau autoriza o tranziție cu consecințe. Capacitatea nu implică autoritate. Execuția nu implică validare. Validarea unui obiect formal nu implică relevanță pentru lume.

Workspace-ul de cercetare rămâne suprafața în care oamenii de știință citesc, scriu, programează, modelează, se întâlnesc și decid. Conectorii aduc articole, date, notebook-uri, repository-uri, înregistrări de laborator, workflow-uri, instrumente, politici și comunicări. Un strat de ingestie folosește LLM-uri și parsere de domeniu pentru a propune obiecte structurate. Un serviciu determinist de stare păstrează identități, versiuni, dependențe și permisiuni. Motoare de workflow și agenți izolați execută sarcini computaționale. Pachete statistice, theorem provers, model checkers, simulatoare, căutarea literaturii și sistemele de laborator

furnizează canale eterogene de dovezi. Serviciile de proveniență emit receipt-uri pentru tranzițiile materiale.

Deasupra acestor componente se află un control plane al Guardians. El nu trebuie să orchestreze fiecare sarcină. Observă Research State, detectează obligații epistemice și axiologice, solicită verificări specializate, compară posibilele acțiuni următoare și produce un argument auditabil. Poziția este deliberat diferită de cea a unui agent general de cercetare. Agentul întreabă: „Cum finalizez planul?”. Guardian-ul întreabă: „De ce este acesta încă planul potrivit, ce dovadă l-ar schimba și sub valorile și autoritatea cui poate continua?”.

Acțiunile candidate sunt obiecte de prim rang. Un proiect nu ar trebui să evalueze numai planul sugerat cel mai recent de un LLM. Ar trebui să reprezinte alternative precum rularea experimentului E, reproducerea rezultatului R cu o implementare independentă, căutarea prior art, colectarea unui nou set de date, calibrarea unui instrument, solicitarea unui expert, restrângerea unei afirmații, publicarea unui rezultat limitat, pauza, pivotarea sau oprirea. Fiecare acțiune poartă prerechizite, resurse estimate, rezultate posibile, afirmații afectate, valoare informațională, risc, reversibilitate și autoritatea necesară. Spațiul acțiunilor este el însuși incert; agenții și oamenii pot propune completări.

Sistemul poate construi apoi pentru fiecare acțiune a un profil epistemic $e(a)$, un profil axiologic $v(a)$ și un set de constrângeri $g(a)$. Obiectele nu trebuie să împartă aceeași unitate. Constrângerile tari pot elimina acțiunile inadmisibile. Ordinea parțială și analiza Pareto pot identifica opțiunile dominate. Valoarea așteptată a informației poate fi folosită când există un model decizional apărut. Argumentarea poate păstra motive care nu pot fi convertite într-un scalar. Rezultatul corect poate fi o recomandare, un set Pareto, o incomparabilitate sau o cerere de judecată umană.

O Research Constitution guvernează operațiile. Ea este un set versionat și contestabil de norme adoptat de un proiect sau de o instituție. Constrângerile tari acoperă siguranța, confidențialitatea, consimțământul, legea și accesul autorizat. Normele evidențiale spun ce este necesar înainte ca o afirmație să își schimbe starea. Normele de alegere exprimă preferințe între acțiuni admisibile, precum favorizarea testelor discriminante la cost comparabil sau rezervarea unor resurse pentru explorare. Normele de guvernare definesc escaladarea, override-ul, divulgarea conflictelor și procedura de schimbare a Constituției. O constrângere serioasă de siguranță nu ar trebui anulată prin acumularea unor puncte de noutate.

Constituția ar trebui să permită profiluri plurale, nu o singură filosofie universală a științei. Un profil bayesian poate accentua informația

așteptată și incertitudinea calibrată. Un profil de severe testing poate prefera proceduri cu capacitate mare de detectare a erorii. Un profil popperian poate favoriza predicții riscante și infirmarea. Un profil inspirat de Lakatos poate urmări dacă un program produce predicții noi corroboreate sau își protejează repetat nucleul prin modificări auxiliare. Un profil de reproductibilitate poate accentua rerulările independente. Un profil de impact poate prioritiza relevanța pentru decizie și beneficiul social. Acordul dintre profiluri poate indica robustețe; dezacordul poate revela un pivot autentic de valori, nu simplu zgomot.

Epistemic Guardian și Axiologic Guardian împart infrastructura, dar păstrează mandate distincte. Epistemic Guardian controlează promovarea și retrogradarea afirmațiilor, preluarea dovezilor, independența, obligațiile de falsificare, reproductibilitatea, punțile dintre formalism și realitate și puterea discriminantă a experimentelor. Axiologic Guardian protejează valorile declarate voluntar de cercetător și instituție, detectează deriva nerecunoscută și construiește evaluări plurale ale valorii umane, distribuției, drepturilor, riscului, costului de oportunitate, generațiilor viitoare și dual use. Primul nu poate deduce scopuri din măsurători. Al doilea nu poate inventa consecințe empirice pentru a justifica o normă preferată.

Strat al ecosistemului	Responsabilitate și limită onestă
Mediul uman de cercetare	Susține gândirea, colaborarea, judecata, consimțământul și responsabilitatea; simpla prezență umană nu garantează oversight semnificativ
Obiectul de cercetare purtător de dovezi	Păstrează versiuni, afirmații, artefacte, proveniență, politici și istoricul deciziilor; reprezentarea nu demonstrează corectitudinea
Stratul neural de interpretare	Extrage, compară, traduce, rezumă și propune alternative; rezultatele rămân interpretări incerte
Stratul simbolic de stare și reguli	Menține tipuri, invariante, dependențe, constituții și structuri de argumentare; validitatea formală rămâne relativă la modelul codificat
Stratul de instrumente și execuție	Rulează cod, workflow-uri, statistici, simulări, proof checks, căutări și apeluri către instrumente; succesul local nu stabilește afirmația globală
Epistemic Guardian	Contestă promovarea afirmațiilor, folosirea dovezilor, independența, noutatea, testele și fezabilitatea fizică sau arhitecturală; poate avertiza și cere dovezi, nu fabrica adevăr

Strat al ecosistemului	Responsabilitate și limită onestă
Axiologic Guardian	Urmărește valori, stakeholderi, constrângeri, trade-off-uri, derivă și posibile consecințe umane; susține deliberarea, nu automatizează conștiința
Control plane instituțional	Atribue autoritate, permisiuni, obligații de review, stări de release, apel și responsabilitate; legitimitatea nu poate fi derivată numai din software
Rețeaua științifică federată	Schimbă obiecte de cercetare, receipt-uri de validare, replicări, corecții și evaluări concurente; interoperabilitatea nu trebuie să devină autoritate epistemică centralizată

Raportul Guardian devine un artefact științific. El începe cu o recomandare sau un set Pareto și expune apoi cele mai puternice motive, cele mai puternice contraargumente, dependențele de dovezi, presupunerile sensibile, judecățile nerezolvate și observația cea mai probabilă să inverseze recomandarea. Poate spune că experimentul E21 este preferat fiindcă separă două mecanisme active la cost comparabil, observând în același timp că recomandarea se inversează dacă viteza de deployment este mai importantă decât descoperirea mecanismului sau dacă un set de date nu este independent. Aceasta este calitativ diferit de atribuirea unui scor de 8,4 din 10.

La scară instituțională, aceeași arhitectură poate dezvălui datoria de verificare, dependențele comune, alternativele abandonate, deriva valorilor, concentrarea surselor de evidență și costurile de oportunitate la nivel de portofoliu. Un finanțator ar putea întreba nu doar ce propunere sună cel mai transformator, ci ce incertitudine este pivotală, ce experiment ar modifica cel mai mult o decizie și ce proiecte se sprijină pe aceeași presupunere fragilă. O conferință ar putea evalua pachete afirmație–dovadă, nu doar PDF-uri. Un laborator ar putea păstra încercările eșuate ca informație negativă reutilizabilă. O rețea științifică ar putea atașa replicări și contradicții direct stării afirmației relevante.

Riscul este ca infrastructura să devină o birocrație care recompensează ceea ce se formalizează ușor și disciplinează munca neconvențională. Proiectarea trebuie să păstreze moduri exploratorii, confidențialitate, autonomie locală, abstention explicit, apeluri și dreptul la branch. Guardian-ul ar trebui să fie inițial consultativ și orientat către dovezi. Nu ar trebui să rescrie autonom agenda de cercetare și nici să blocheze publicarea fiindcă un scor de model este scăzut. Autoritatea lui poate crește numai pentru tranziții delimitate îngust, delegate explicit și auditate independent de instituții.

PROPUNERE DE CERCETARE

Sistemul minim credibil este mai mic decât viziunea. El se conectează la un workspace de cercetare, menține un graf al stării proiectului și proveniența, citește o Research Constitution, acceptă două până la cinci acțiuni candidate, invocă un mic panel de evaluatori și returnează un raport argumentat. LLM-urile efectuează interpretarea semantică și comparația. Serviciile deterministe mențin starea. Instrumentele statistice estimează incertitudinea și valoarea informației. Agenții de reproducere execută artefacte. Motoarele de reguli aplică constrângeri tari. Componentele de argumentare păstrează motive și defeaters. Oamenii confirmă interpretările cu impact ridicat și păstrează autoritatea asupra traseului cercetării.

Ambiția pe termen lung nu este o știință formalizată sută la sută. Este o știință ale cărei angajamente cu consecințe devin tot mai interpretabil de calculatoare și, prin aceasta, mai ușor de testat, revizuit, reprodus și guvernat de oameni și mașini. Articolul rămâne argumentul uman. Obiectul de cercetare executabil devine memoria și substratul operațional. Guardians devin disciplinele care împiedică acest substrat nou să confunde output-ul cu cunoașterea sau optimizarea cu valoarea.

Capitolul 5. Epistemic Guardian

5.1. Mașina stărilor epistemice și independența verificării

Cea mai simplă protecție împotriva iluziei de descoperire este separarea explicită dintre tipul unui enunț și statutul său epistemic. În documentele obișnuite, această informație este ascunsă în verbe și ton. „Presupunem”, „propunem”, „observăm”, „demonstrăm” și „confirmăm” par suficiente, dar modelele pot folosi termenii elastic, iar reviziile succesive pot șterge contextul. Un sistem de automatizare responsabil trebuie să reprezinte statutul într-o structură pe care textul nu o poate modifica implicit.

PROPUNERE DE CERCETARE

Propunem o mașină de stări epistemice pentru fiecare claim. O afirmație poate fi generată, specificată, verificată intern, conectată la prior art, executată, susținută de date, replicată și acceptată într-un anumit domeniu. Nu toate afirmațiile urmează aceeași cale. O teoremă trece prin formalizare și proof checking; o afirmație de performanță trece prin baseline-uri, metrici și date; o afirmație cauzală cere identificare și intervenție; o afirmație de noutate cere căutare și comparație. Elementul comun este că trecerea dintre stări se face printr-un eveniment explicit.

Regula esențială este „no linguistic promotion”. Reformularea, lungirea, rezumarea, formalizarea ornamentală, consensul verbal sau recenzia textuală nu pot schimba singure starea. Ele pot produce un artefact care face posibilă verificarea: o ipoteză devine specificată, o demonstrație naturală devine un enunț Lean, un mecanism devine o predicție. Dar promovarea la „susținut” cere o probă. Sistemul trebuie să refuze verbe precum „am demonstrat” în rezumat dacă graful conține doar generare și coerență internă.

Această regulă poate părea rigidă, dar este analogă sistemelor de tipuri. Un program nu poate trata arbitrar un șir drept număr doar pentru că numele variabilei sugerează asta. Trebuie să existe o conversie validă. În același mod, un research IDE nu ar trebui să trateze un rezultat simulat drept observație empirică sau un LLM score drept replicare. Tiparea nu decide dacă afirmația este adevărată; previne anumite confuzii de categorie.

Stratul simbolic poate implementa reguli de forma: fiecare PerformanceClaim acceptat are un comparator, o metrică, un dataset, o estimare de incertitudine și un traseu de execuție; fiecare NoveltyClaim are un protocol de căutare și vecini apropiați analizați; fiecare CausalClaim declară estimandul și ipotezele de identificare; fiecare FormalProofClaim are hash-ul enunțului, kernelul și lista axiomelelor; fiecare ReplicationClaim indică dimensiunile de independență. Acestea nu sunt formule universale ale științei, ci invariants configurabile pe domeniu.

Neural component rămâne importantă. Limbajul științific este ambiguu, iar afirmațiile sunt distribuite în text. Un LLM poate extrage claim-uri, poate sugera tipul, poate detecta contradicții și poate explica utilizatorului ce lipsește. Dar sistemul trebuie să păstreze incertitudinea extragerii. Dacă modelul nu știe dacă o propoziție este afirmație cauzală sau doar interpretare, o marchează pentru review; nu alege categoria care face pipeline-ul mai ușor.

EVIDENȚĂ PUBLICATĂ

Argumentation frameworks oferă o bază formală pentru reprezentarea atacurilor și suportului dintre argumente [77]. Nanopublications separă o afirmație de proveniența și metadatele ei [52], iar PROV și RO-Crate modelează agenți, activități și artefacte [54, 55]. FAIR principles încurajează date findable, accessible, interoperable și reusable [73]. Aceste infrastructuri arată că reprezentarea explicită a relațiilor este matură. Propunerea de aici adaugă un strat normativ: ce fel de traseu de evidență este necesar pentru fiecare promovare.

Stările trebuie să permită și retrogradare. O replicare eșuată, un articol anterior descoperit sau o eroare de analiză poate coborî o afirmație. Documentele științifice obișnuite sunt greu de actualizat; concluzia rămâne în PDF chiar dacă statusul s-a schimbat. Un graf epistemic versionat poate propaga revizia către claims dependente. Dacă baseline-ul folosit se dovedește greșit, toate afirmațiile de superioritate care depind de el sunt marcate pentru reevaluare.

Acest mecanism combate „memory laundering”. În proiecte lungi, o presupunere poate fi repetată de atâtea ori încât echipa uită originea ei. Graful păstrează sursa și starea. O propoziție citată de cinci documente interne nu dobândește cinci dovezi dacă toate se întorc la aceeași generare. Proveniența permite deduplicarea suportului și împiedică numărarea ecoului drept consens.

PROPUNERE DE CERCETARE

Introducem „Epistemic Promotion Error Rate” ca metrică: proporția tranzițiilor în care sistemul sau utilizatorul atribuie o stare mai înaltă

decât permit evenimentele înregistrate. De exemplu, un rezultat descris ca „validated” după teste co-generate este o eroare de promovare chiar dacă programul este ulterior corect. Metrica nu judecă adevărul final, ci disciplina traseului. Un sistem poate avea o idee adevărată și totuși să o promoveze nejustificat; aceasta contează deoarece procesul nu ar discrimina o idee falsă similară.

O obiecție rezonabilă este că știința nu funcționează prin porți discrete. Dovezile vin în grade, iar judecata experților combină indicii. Mașina de stări nu trebuie să nege continuitatea. Ea poate stoca strength, scope și uncertainty în interiorul fiecărei stări. Scopul discretizării este auditul tranzițiilor, nu reducerea adevărului la workflow. Similar, peer review-ul nu garantează adevărul, dar marchează un proces diferit de auto-publicare.

O altă obiecție este costul. Cercetătorii nu vor completa manual zeci de câmpuri. Aici LLM-ul este parte din soluție: poate propune automat claim graph-ul și poate cere confirmare numai la ambiguități sau salturi importante. Sistemul poate începe minimal, urmărind patru tipuri: ipoteză, rezultat, interpretare, replicare. Pe măsură ce beneficiul este demonstrat, schema poate deveni mai bogată. Un program de cercetare serios trebuie să evalueze nu doar reducerea erorilor, ci și overhead-ul cognitiv.

Stările epistemice schimbă și stilul raportării. În loc de un abstract care uniformizează totul, un living research document poate afișa pentru fiecare afirmație principală starea, sursele, testele și datoria rămasă. Cititorul poate vedea că o arhitectură este implementată și promițătoare pe două benchmarkuri, dar noutatea nu este încă stabilită și replicarea lipsește. Această granularitate este mai onestă și, paradoxal, poate face proiectele speculative mai ușor de comunicat: nu trebuie să pretindă maturitate pentru a merita explorate.

Regula „limbajul nu promovează” nu diminuează rolul scrisului. Scrisul poate produce claritate, poate descoperi premise, poate face o teorie falsificabilă și poate lega rezultate. El este parte din mecanismul științei. Regula spune doar că valoarea sa este epistemic specifică. O explicație foarte bună poate promova o idee din „vagă” în „specificată”; acesta este progres real. Nu o poate promova din „specificată” în „confirmată” fără o confruntare suplimentară.

Independența nu este un număr de agenți.

În limbajul comun, o verificare independentă este una realizată de altcineva. În sisteme AI, identitatea agentului este insuficientă. Două instanțe pot împărți modelul, datele, promptul, retrieval corpus-ul și chiar random seed-ul. Două modele diferite pot împărți mare parte din datele de pretraining și convențiile domeniului. Un om poate fi ancorat de rezumatul

AI înainte de review. Independența trebuie definită relativ la erorile pe care vrem să le detectăm.

Există cel puțin șase dimensiuni relevante. Independența de model reduce erorile specifice unei arhitecturi sau alinieri. Independența de date reduce contamination și biasul comun. Independența de specificație permite detectarea interpretărilor greșite. Independența de implementare permite detectarea bugurilor comune. Independența de evaluator reduce optimizarea directă pentru metrică. Independența de lume apare când intră măsurători, experimente sau surse primare care nu pot fi fabricate prin text. Niciuna nu este absolută, iar importanța lor depinde de claim.

Pentru aritmetică, un interpret determinist oferă independență suficientă față de predicția tokenilor. Pentru noutate științifică, un al doilea LLM cu alt prompt oferă puțin dacă nu caută literatura. Pentru un rezultat experimental, un alt laborator și alte loturi de materiale oferă mult. Pentru theorem proving, un kernel mic și auditat oferă independență față de generator, dar nu față de formalizarea enunțului. Designul verificării începe prin identificarea erorii, nu prin alegerea unui număr de agenți.

PROPUNERE DE CERCETARE

„Independence Graph” reprezintă fiecare probă și validator împreună cu dependențele sale. Pentru o afirmație, sistemul calculează nu un scor magic, ci un profil: diversitate de modele, surse, implementări, date și instituții. Profilul este comparat cu un threat model epistemic. Dacă riscul principal este co-generated oracle, se cere un test derivat independent. Dacă riscul este prior-art omission, se cere un protocol de căutare diferit și audit uman. Dacă riscul este data leakage, se cere dataset cu provenance și acces controlat.

Un concept util este „error-correlation budget”. Consensul adaugă valoare numai dacă erorile nu sunt perfect corelate. Într-un ensemble statistic, modele identice nu reduc varianta. Într-un panel epistemic, agenți identici nu reduc orbirea comună. Putem estima corelația pe seturi cu erori cunoscute: cât de des evaluatorii ratează aceeași problemă, cât de sensibili sunt la verbositate, cât de des favorizează propria familie. Aceste estimări nu garantează performanța pe idei noi, dar sunt mai informative decât numărul de roluri din diagramă.

EVIDENȚĂ PUBLICATĂ

Biasurile LLM-judges și self-preference demonstrează concret că evaluatorii pot fi corelați cu generatorii [41, 42]. Cercetarea despre reproducibilitate arată analog că folosirea aceleiași implementări și a acelorași date produce repeatability, nu independență [7]. Registered Reports și preregistration încearcă să separe decizia analitică de

rezultatul observat [74]. Hidden tests separă dezvoltarea de evaluare. Toate sunt instituții ale independenței, nu doar tehnici.

Sursele bibliografice trebuie și ele auditate. RAG poate reduce citările inventate și poate lega răspunsuri de fragmente, iar sisteme precum WebGPT și GopherCite au arătat valoarea navigării și a citatelor verificabile [78, 79]. SciFact a creat un benchmark pentru verificarea afirmațiilor științifice față de abstracte [80]. Totuși, retrieval-ul poate rata literatura relevantă, iar un citat real poate fi folosit greșit. Independența sursei înseamnă că afirmația este susținută de conținut, nu doar că URL-ul există. Un verifier trebuie să compare claim-ul cu span-ul și să marcheze extrapolarea.

În sistemele experimentale, instrumentele și laboratoarele introduc independență puternică, dar nu perfectă. Senzorii pot fi calibrați greșit, protocolul poate favoriza ipoteza, iar automatizarea poate repeta sistematic eroarea. Self-driving labs au nevoie de controls, calibration standards și replicări. Coscientist sau un robot scientist nu este adevărat pentru că are braț robotic; valoarea vine din faptul că execuția produce date care pot contrazice planul [10, 12]. Dacă agentul selectează doar experimente care confirmă sau oprește când vede un rezultat favorabil, bucla rămâne părtinitoare.

Propunerea noastră adoptă o regulă de „independent evidence minimum”. Pentru claims cu risc scăzut, poate fi suficient un instrument determinist. Pentru claims publicabile sau cu impact mare, este necesar cel puțin un traseu care trece printr-un validator extern relevant. Sistemul nu stabilește universal pragul; proiectul îl configurează și îl declară. Important este ca rezumatul să nu ascundă lipsa: „susținut numai de evaluări LLM” trebuie să apară ca atare.

Independența are și o dimensiune adversarială. Un evaluator care încearcă să confirme poate folosi date diferite și totuși să selecteze favorabil. Un Falsifier are obiectiv opus: să găsească cel mai apropiat prior art, cel mai puternic baseline, cel mai mic counterexample și interpretarea alternativă. Adversarial nu înseamnă ostilitate socială, ci funcție de pierdere diferită. Generatorul maximizează posibilitatea; falsificatorul minimizează spațiul în care pretenția poate rămâne în picioare.

PROPUNERE DE CERCETARE

Un registru de verificatoare ar descrie fiecare unealtă prin proprietățile pe care le poate verifica și erorile față de care este independentă. Un compiler verifică sintaxă și tipuri; mutation testing verifică sensibilitatea suitei; proof assistant-ul verifică derivarea; prior-art search verifică absența unor vecini găsiți într-un corpus declarat; un statistician

automat verifică assumptions și multiple testing; un laborator verifică predicții operaționale. Orchestratorul selectează o combinație în funcție de claim type. Această semantică a verificatoarelor împiedică verdictul generic „validated”.

Independența trebuie protejată și prin proces. Dacă autorul vede toate testele, poate adapta sistemul. Dacă evaluatorul vede reputația și rezumatul persuasiv, poate fi ancorat. Dacă replicatorul primește implementarea completă, nu testează aceleași lucruri ca o reconstrucție independentă. Blind evaluation, sealed datasets, preregistration și division of labor sunt tehnologii sociale la fel de importante ca software-ul. Programul neuro-simbolic trebuie să le poată reprezenta, nu să presupună că totul se rezolvă prin agenți.

O grijă suplimentară este securitatea. Un sistem cu evaluatoare ascunse și artefacte proprietare trebuie să prevină leakage-ul. Pot fi folosite access controls, secure enclaves, execution sandboxes și cryptographic commitments. Hash-urile pot demonstra că un protocol sau un set de teste exista înaintea rezultatului, fără publicarea imediată. Aceste mecanisme asigură integritatea temporală, nu adevărul. Cartea evită confuzia dintre „tamper-evident” și „valid”, dar recunoaște că integritatea este condiție pentru evaluări credibile.

În final, independența este costisitoare, iar costul trebuie alocat inteligent. Nu putem cere replicare externă pentru fiecare idee de brainstorming. Mașina de stări permite verificare progresivă. Ideile ieftine sunt filtrate prin prior art și counterexamples automatizate. Doar cele care supraviețuiesc primesc resurse experimentale. Scopul nu este maximalismul metodologic, ci o economie a dovezii: folosim cel mai ieftin validator care poate detecta eroarea relevantă, apoi escaladăm.

Stare orientativă	Eveniment care poate justifica promovarea
Generată	Afirmația există, dar nu are încă o definiție stabilă sau un protocol.
Specificată	Problem Contract, scope, ipoteze și criterii de eșec sunt explicite.
Conectată la literatură	Surse primare și vecini apropiați au fost identificați și comparați.
Verificată intern	Calcul, cod, proof kernel sau analiză trece verificări relevante.
Susținută empiric	Datele sau experimentul susțin claim-ul în domeniul declarat.

Stare orientativă	Eveniment care poate justifica promovarea
Replicată independent	O cale cu dependențe relevante diferite confirmă rezultatul.
Contestată/retrogradată	O replicare, un counterexample sau prior art modifică statutul.

Mașina de stări devine utilă științific numai când observă revizuirea, nu doar când clasifică proza. Un proiect care primește dovezi contrare trebuie să arate un răspuns. Încrederea poate scădea, afirmația se poate restrânge, o alternativă se poate întări, dovada poate fi respinsă printr-un defațer sau problema poate rămâne nerezolvată. Guardian-ul nu trebuie să impună un posterior numeric în orice disciplină. Trebuie însă să expună diferența dintre neactualizarea justificată și simpla nepreluare a dovezii.

DOVEZI PUBLICATE

Rezultatele recente fac ținta concretă. În peste 25.000 de rulări ale agenților din opt domenii, Ríos-García și colegii au raportat că dovezile au fost ignorate în 68% dintre trase, revizuirea prin infirmare a apărut în 26%, iar convergența prin teste multiple a fost rară [153]. FALSIFYBENCH a constatat independent că testarea negativă activă era principalul determinant al succesului în jocurile sale de descoperire a regulilor și că niciun model evaluat nu se apropia de performanța optimă [155]. Studiile nu demonstrează că aceleași procente se aplică laboratoarelor obișnuite. Ele susțin afirmația mai îngustă că evaluarea exclusivă a rezultatului poate rata defecte ale procesului epistemic.

PROPUNERE DE CERCETARE

Un Epistemic Guardian inițial poate monitoriza anti-pattern-uri modeste în loc să pretindă că recunoaște global „știința bună”. Catalogul include schimbarea încrederii fără un eveniment epistemic nou, dovada atașată fără răspuns înregistrat, teste confirmatorii repetate care nu disting ipotezele active, dependența de o singură sursă pentru o afirmație importantă, rescrierea post-hoc a ipotezei fără urmă, spălarea presupunerilor, promovarea nesusținută de la un benchmark local la o concluzie generală și concluzii care nu rezultă din analiza executată. Fiecare detector întoarce un avertisment localizat și dovezile avertismentului. Nu respinge automat proiectul.

Starea afirmației trebuie să înregistreze și domeniul. „Replicat” este incomplet dacă dimensiunile independenței nu sunt vizibile. O rerulare cu alt seed diferă de o implementare nouă; o implementare nouă făcută de aceeași echipă diferă de un alt laborator; o a doua instanță LLM diferă de

un evaluator cu altă familie de modele, corpus, specificație și canal de instrumente. Independența este un profil raportat la threat model, nu un scor magic.

5.2. Instrumentele: de la contractul problemei la falsificator

Modelele de limbaj sunt potrivite pentru începutul cercetării deoarece lucrează bine cu intenții incomplete, analogii, literaturi eterogene și formulări multiple. Slăbiciunea lor apare când aceeași flexibilitate este folosită pentru a păstra invariants. Un termen poate aluneca semantic, o presupunere poate deveni implicită, iar statutul unei afirmații poate fi ridicat prin ton. Sistemele simbolice au profilul complementar: sunt fragile la ambiguitate, dar puternice la identitate, tipuri, constrângeri și audit. Arhitectura propusă folosește fiecare familie acolo unde are avantajul ei.

EVIDENȚĂ PUBLICATĂ

Neuro-symbolic AI nu este o tehnologie unică, ci o familie de abordări care combină învățarea neuronală cu reprezentări și procese simbolice. Survey-urile și analizele programatice descriu integrarea ca o cale de a obține flexibilitate perceptivă împreună cu raționament, compositionality și constrângeri explicite [82, 83, 84]. ReAct, Toolformer și alte arhitecturi de agenți arată că modelele pot selecta și folosi unelte externe [85, 86]. Aceste lucrări nu validează arhitectura specifică de aici, dar demonstrează fezabilitatea componentelor: semantic parsing aproximativ, orchestration și verificatoare specializate.

PROPUNERE DE CERCETARE

Numim ansamblul „programul Epistemic Guardian Stack”, iar componenta centrală „Epistemic Guardian”. El primește un document, o conversație sau un workspace și produce o reprezentare executabilă a afirmațiilor, ipotezelor, definițiilor, dovezilor și testelor. Cuvântul „compiler” este folosit în sens funcțional, nu ca promisiune de formalizare completă. La fel cum un compilator traduce un program și semnalează erori de tip, componenta traduce discursul de cercetare într-un graf tipat și semnalează promovări fără suport, ambiguități și dependențe circulare.

Graful conține noduri precum Problem, Claim, Definition, Assumption, Method, Dataset, Metric, Baseline, Result, Source, Test, Artifact, Counterexample, Replication și Decision. Muchiile au semantică: supports, contradicts, dependsOn, operationalizes, measures, generatedBy,

testedBy, derivedFrom, narrowsScope, replicates și supersedes. Fiecare nod are versiune, autor sau agent, timestamp, provenance, confidence de extracție și stare epistemică. Textul original rămâne atașat ca source span; reprezentarea nu îl înlocuiește.

Compilerul lucrează în două trepte. În prima, un LLM extrage candidați și propune relații. Poate observa că „modelul îmbunătățește robustețea” este un PerformanceClaim, că „datorită memoriei ierarhice” este MechanismClaim și că „pe trei benchmarkuri” introduce un scope. În a doua, un motor simbolic verifică schema și aplică reguli. Dacă PerformanceClaim-ul nu are baseline sau metrică, rămâne incomplet. Dacă MechanismClaim-ul are doar același rezultat ca suport, este marcat drept interpretare. Dacă concluzia generalizează din trei benchmarkuri la „documente științifice”, apare un scope warning.

Invariants trebuie să fie simple, verificabile și configurabile. Exemplele de bază sunt: fiecare claim acceptat are source span; fiecare claim validat are cel puțin un evidence path admis; niciun evidence path nu este compus exclusiv din text generat; fiecare rezultat numeric are data lineage, cod și uncertainty; fiecare claim de noutate are un prior-art protocol; fiecare claim formal are statement identity și trust boundary; fiecare replicare declară ce dimensiuni sunt independente. Invariants nu spun că proiectul este bun. Ele interzic anumite moduri de a pretinde că este mai matur decât este.

Problem identity este menținută prin Problem Contract. Contractul include întrebarea, utilizatorul, decizia, cazuri canonice, non-goals, riscuri și proprietăți esențiale. Fiecare operaționalizare creează o muchie către contract. Dacă datasetul acoperă doar abstracte, scope-ul este restrâns. Dacă o metrică măsoară similaritate lexicală, sistemul nu o echivalează cu consistență semantică fără justificare. Semantic diff-ul compară versiunile și cere acceptare pentru schimbări importante.

Un avantaj al grafului este localizarea exactă a incertitudinii. În documentele lineare, o concluzie poate părea puternică deoarece este înconjurată de multe citări. Graful poate arăta că toate citările susțin doar definiția, nu efectul, sau că rezultatul depinde de o singură asumție. Review-ul devine o operație asupra dependențelor: care nod, dacă este fals, prăbușește cele mai multe concluzii? Ce test ar reduce cel mai mult incertitudinea? Acest lucru permite alocarea inteligentă a bugetului experimental.

Argumentation frameworks pot reprezenta atacuri și apărări, iar un motor nonmonotonic poate recalcula acceptabilitatea când apare o nouă dovadă [77]. Nu propunem ca un scor formal să înlocuiască judecata științifică. Motorul poate detecta inconsistențe și dependențe, dar relevanța

unui counterargument rămâne adesea contextuală. LLM-ul explică, omul decide, iar graful păstrează decizia și motivul.

Sursele sunt tratate la nivel de claim–evidence, nu la nivel de bibliografie decorativă. Un adaptor SciFact-like extrage span-ul care susține sau contrazice afirmația și clasifică relația [80]. Retrieval-ul caută surse primare, versionate și retractări. Citarea este validată prin trei întrebări: sursa există, span-ul spune ceea ce claim-ul atribuie, iar domeniul sursei se potrivește. Dacă articolul arată asociere într-o populație și manuscrisul afirmă cauzalitate generală, relația este „partial/overextended”, nu „supported”.

Compilerul poate produce și un „epistemic diff” între versiuni de manuscris. Dacă o propoziție trece de la „suggests” la „demonstrates”, sistemul cere evenimentul care justifică schimbarea. Dacă limitarea dispare, este semnalată. Dacă un rezultat exploratoriu devine confirmator în rezumat, apare conflict. Această funcție este deosebit de utilă când LLM-ul rescrie textul pentru claritate și, involuntar, netezește incertitudinea.

PROPUNERE DE CERCETARE

Interfața nu trebuie să arate utilizatorului întregul graf tot timpul. Cercetătorul vede textul și un strat discret de status. La selectarea unei afirmații, poate inspecta sursele, testele și dependențele. Dashboard-ul evidențiază numai zonele cu risc: claims importante fără probă independentă, scope extins, oracole co-generate, loops și datorie epistemică. Sistemul trebuie să fie mai aproape de un linter decât de un formular birocratic.

Un „linter epistemic” poate funcționa în trepte. Regula rapidă detectează verbe și claims numerice. Analiza profundă construiește graful și caută prior art. Modul de audit rulează verificatoare și reconstruiește pipeline-ul. Cercetătorul poate lucra fluid în faza exploratorie, iar pragurile cresc când documentul este declarat pentru submission, patent, deployment sau comunicare publică. Această progresivitate este esențială pentru adopție.

Arhitectura trebuie să gestioneze incertitudinea proprie. Extracția LLM poate greși. Fiecare relație are confidence și source span, iar regulile importante cer confirmare. Un sistem care ascunde erorile parserului sub o ontologie elegantă ar produce o nouă iluzie. De aceea, benchmarkul trebuie să evalueze atât calitatea grafului, cât și impactul asupra deciziilor. O reprezentare imperfectă poate fi utilă dacă reduce promovările greșite fără să creeze false certainty.

Securitatea și privacy sunt cerințe de bază pentru cercetare enterprise. Workspace-urile conțin IP, date personale și rezultate nepublicate.

Compilerul trebuie să poată rula local sau într-un mediu controlat, să aplice access control la nivel de claim și artifact și să folosească selective disclosure. Proveniența poate include hash-uri și semnături fără expunerea conținutului. Un reviewer extern poate primi o capsule cu dovezile relevante, nu întregul istoric al laboratorului.

În forma sa minimă, Epistemic Guardian nu trebuie să înțeleagă întreaga știință. Poate începe cu trei claims foarte comune în ML: noutate, superioritate de performanță și explicație de mecanism. Dacă reușește să detecteze prior-art omission, baseline slab și ablation neconcludent, oferă valoare. Ulterior, schema poate include formal math, causal inference și laborator. Programul trebuie să demonstreze incremental că simbolizarea reduce erori reale, nu doar că produce grafuri frumoase.

Un program de cercetare devine pragmatic când componentele pot fi construite și evaluate separat. programul Epistemic Guardian Stack nu este un monolit și nu are nevoie de un model universal al adevărului. Este o suită de unelte specializate, orchestrate prin claim types și provenance. Fiecare unealtă are un scop limitat, un oracol declarat și criterii de acceptare. Această modestie funcțională este deliberată: instrumentele care pretind că „detectează dacă o idee este bună” reproduc problema la un nivel mai înalt.

Primul instrument este Problem Contract Builder. El transformă intenția inițială într-un contract versionat, fără să pretindă că elimină ambiguitatea. LLM-ul interviează cercetătorul: cine folosește rezultatul, ce cazuri sunt decisive, ce nu intră în scope, ce proprietăți nu pot fi sacrificate și ce ar conta drept eșec. Produce exemple și contraexemple, iar utilizatorul le aprobă. Output-ul este folosit de toate modulele ulterioare. Criteriul de succes nu este frumusețea contractului, ci reducerea schimbărilor tăcute detectate mai târziu.

Al doilea este Prior-Art Adversary. Spre deosebire de literatură asistentul care caută sprijin, adversarul încearcă să invalideze noutatea. Descompune contribuția în primitive, generează terminologie istorică și cross-domain, caută articole, brevete, teze și software, apoi construiește o matrice de asemănări. Pentru fiecare candidat apropiat, cere autorului să formuleze diferența mecanistică și consecința ei măsurabilă. Verdictul nu este „novel/non-novel”, ci o afirmație calibrată despre spațiul căutat și vecinul cel mai apropiat.

Al treilea este Architecture Canonicalizer. Primește o diagramă, o descriere sau cod și produce o reprezentare normalizată: fluxuri de date, stări, operatori, feedback, objective și training regime. Numele comerciale și acronimele sunt eliminate. Sistemul compară structura cu o bibliotecă de design patterns și lucrări. Pentru a evita iluzia geometrică, similaritatea nu

este singurul criteriu; canonicalizer-ul caută operația care produce diferența și propune ablation. O arhitectură nouă poate folosi primitive vechi, dar trebuie să demonstreze o compoziție cu efect distinct.

Al patrulea este Proxy-Gap Analyzer, descris în capitolul anterior. El trasează legătura Problem Contract–dataset–metrică–test–concluzie. Folosește semantic parsing pentru a detecta scope și reguli simbolice pentru a împiedica generalizarea nejustificată. Poate genera „transport questions”: ce trebuie să fie adevărat pentru ca rezultatul pe datasetul D să se transfere la populația P? Ce proprietate a metricii M o face proxy pentru obiectivul O? Aceste întrebări devin claims testabile.

Al cincilea este Test Oracle Auditor. Pentru cod, verifică provenance-ul testelor, coverage, mutation score, metamorphic relations și cazuri de frontieră. Pentru ML, examinează leakage, splits, benchmark contamination, metric selection și baseline fairness. Pentru simulări, identifică ipoteze care fac rezultatul adevărat prin construcție. Pentru proof assistants, verifică statement identity, axiome, trust boundary și placeholders. Auditorul nu înlocuiește verificatoarele; le coordonează și precizează ce au demonstrat.

Al șaselea este Falsifier. El selectează cel mai ieftin test sever folosind un planner. Planner-ul primește claim graph-ul, risk, cost și verificator registry. Poate propune counterexample search, SMT, differential testing, ablation, negative control, replicate-on-new-data sau expert audit. Folosește o strategie apropiată de counterexample-guided inductive synthesis: generatorul propune, verificatorul găsește un counterexample, iar ipoteza este restrânsă sau abandonată [87]. În loc să itereze până când textul pare bun, sistemul iterează până când pretenția supraviețuiește unei clase declarate de atacuri.

Al șaptelea este Baseline and Ablation Planner. În ML, contribuția poate dispărea când baseline-ul este configurat corect. Modulul extrage compute, date, parametri și tuning budget și caută comparații echitabile. Propune matched ablations și placebo modules. În cercetarea algoritmică, caută soluția simplă și limita inferioară. În sisteme agentice, compară cu un workflow determinist și cu single-agent plus tools, pentru a vedea dacă multi-agent complexity adaugă ceva.

Al optulea este Consensus Independence Auditor. El analizează modelele, prompturile, retrieval-ul, expunerea reciprocă și istoricul agenților. Produce un profil de corelație și cere agenților să aducă dovezi distincte, nu doar verdicte. Un protocol poate include un reviewer fără acces la justificarea generatorului, un evaluator din altă familie de modele, un tool-based critic și un expert human blind. Modulul măsoară dacă diversitatea aparentă schimbă tipurile de erori detectate.

Al nouălea este Reproduction Capsule Builder. El ambalează codul, datele, mediul, claims, testele, provenance și jurnalul deciziilor. Produce două pachete: repeatability și replication. Pachetul de replicare poate ascunde implementarea și oferi doar contractul și protocolul. RO-Crate și PROV pot servi drept substrat tehnic [54, 55]. Pentru proiecte confidențiale, capsulele pot include manifesturi hash-uite și mecanisme de acces controlat.

Al zecelea este RealityGap Dashboard. El nu oferă un scor unic de „adevăr”, ci afișează claim survival, promotion errors, independență, datorie epistemică și teste lipsă. Pentru management, poate răspunde la întrebări pragmatice: câte idei au fost generate, câte eliminate prin prior art, câte implementate, câte au depășit baseline-ul, câte au fost replicate? Care sunt claims cu cel mai mare impact și cel mai slab suport? Unde se consumă bugetul de verificare?

Aceste module folosesc tehnici mature, dar combinarea lor necesită cercetare. Semantic parsing-ul poate fi instabil. Prior-art search-ul poate favoriza lucrările ușor de găsit. Mutation testing-ul poate genera mutații irelevante. Proof assistants au cost mare de formalizare. Dashboard-ul poate crea o nouă gamification. Fiecare componentă trebuie testată pe cazuri în care știm eroarea și pe contribuții valide care nu trebuie respinse.

Un principiu de design este „small trusted core”. LLM-urile pot genera planuri și explicații, dar deciziile de stare sunt aplicate de reguli auditate. Verificatoarele deterministe au versiuni și proprietăți cunoscute. Evenimentele sunt append-only. Utilizatorul poate suprascrie un verdict, dar override-ul este înregistrat cu motiv. Sistemul nu pretinde că elimină judecata; face judecata inspectabilă.

Un alt principiu este „evidence adapters, not universal judge”. Fiecare domeniu adaugă adaptoare. Pentru formal math: Lean/Coq/Isabelle, counterexample generators și statement audit. Pentru software: compiler, static analyzer, tests, fuzzing. Pentru ML: dataset lineage, experiment tracker, statistical tests, benchmark registry. Pentru științe empirice: electronic lab notebook, instrument API, calibration și protocol. Pentru review: citation verification, consistency checker și reproducibility audit. Claim graph-ul oferă interfața comună.

PROPUNERE DE CERCETARE

Toolurile pot fi expuse printr-un research IDE în care autorul lucrează cu text, cod și date. La fiecare claim, un meniu oferă „caută prior art”, „găsește counterexample”, „propune test sever”, „verifică oracolul”, „pregătește replicarea”. Agentul nu rulează automat experimente

scumpe fără acord; produce plan, cost și expected information gain. Utilizatorul poate selecta testul, iar rezultatul actualizează graficul.

Un sistem util trebuie să știe și când să se oprească. Dacă ideea a fost redusă complet la prior art sau baseline-ul simplu o egalează, recomandă abandon sau reformulare. Dacă verificarea costă mult și impactul este mic, recomandă păstrarea ca speculație. Dacă riscul este mare și dovezile insuficiente, blochează eticheta „validated”, nu neapărat continuarea cercetării. Acest control al limbajului este mai realist decât controlul creativității.

5.3. Orchestrarea cercetării, rolul omului și limitele sistemului.

O listă de unelte nu formează automat un proces științific. Orchestrarea decide când este folosit fiecare validator, cum sunt alocate resursele și cine poate promova o afirmație. Dacă orchestratorul este un LLM care optimizează finalizarea taskului, poate prefera traseul cu cea mai mică fricțiune și poate alege testele ușoare. De aceea, planificarea trebuie împărțită între componenta generativă și o politică simbolică orientată spre risc și informație.

Workflow-ul începe cu explorarea liberă. Ideile pot fi generate fără porți grele. Compilatorul le marchează ca speculative și păstrează provenance. Când cercetătorul selectează o idee pentru investiție, sistemul construiește Problem Contract și face triage: prior art, counterexamples ieftine și feasibility. Doar ideile care supraviețuiesc intră în implementare. Înaintea experimentului, predicțiile și criteriile de eșec sunt înghețate pentru partea confirmatorie. După rezultat, Falsifier-ul selectează atacuri, iar claims sunt promovate sau restrânse. Replicarea este un workflow separat.

Planificarea poate folosi expected information gain. Fiecare test are cost, probabilitate estimată de eșec și număr de claims dependente. Un test ieftin care poate invalida o presupunere centrală are prioritate. Estimările pot fi aproximative și învățate din istoricul proiectelor. Important este obiectivul: reducerea incertitudinii și a datoriilor, nu producerea celui mai rapid raport.

Researcher-ul rămâne responsabil pentru Problem Contract, acceptarea proxy-urilor și interpretarea dovezilor. AI poate propune, dar nu poate decide singură ce întrebare merită urmărită sau ce risc este acceptabil. În domenii cu miză ridicată, separarea rolurilor este esențială: autor, validator, data steward, statistician și reviewer. Sistemul poate face delegarea vizibilă și poate bloca conflictul de roluri, dar instituția decide politica.

Human oversight nu trebuie redus la apăsarea unui buton. Un om care vede doar verdictul final nu poate corecta procesul. Oversight-ul trebuie

plasat la semantic bottlenecks: definirea problemei, acceptarea modificărilor de scope, alegerea oracolului, interpretarea rezultatelor contradictorii și promovarea către comunicare publică. Restul poate fi automatizat. Această distribuție protejează atenția expertă pentru locurile în care textul și lumea se întâlnesc.

EVIDENȚĂ PUBLICATĂ

Experiența sistemelor de laborator autonom arată că succesul provine din integrarea planificării, execuției și măsurării, nu dintr-un model izolat [10, 11, 12]. Formal verification arată valoarea unui trusted kernel [68, 69]. Human–AI studies arată că interfața și ordinea deciziei influențează overreliance-ul [26, 24]. Arhitectura propusă combină aceste lecții, dar combinația nu este încă validată ca sistem unitar.

Interfața trebuie să evite două extreme. Prima este chat-ul fără structură, în care toate stările sunt ascunse în conversație. A doua este formularul rigid care paralizează explorarea. O soluție este „progressive formalization”: cercetătorul începe în limbaj natural, iar sistemul extrage treptat structura. Când apare o pretenție mai mare, cere mai multă precizie. Formalizarea este proporțională cu miza și maturitatea.

Un mecanism important este separation of concerns între writer și validator. Writer-ul poate optimiza claritatea și coerența, dar nu are dreptul să schimbe statusul. Validatorul poate atașa evidence events, dar nu rescrie claim-ul fără semantic diff. Reviewer-ul poate propune retrogradări. Orchestratorul aplică politica. Aceste roluri pot fi implementate de agenți diferiți, dar separarea reală vine din permissions și logs, nu din numele promptului.

Sistemul trebuie să gestioneze și dezacordul. Dung-style argumentation poate păstra claims incompatibile fără să forțeze o sinteză prematură [77]. Dacă două interpretări ale rezultatului rămân posibile, graful le menține și cere test discriminant. LLM-urile au tendința utilă, dar uneori periculoasă, de a reconcilia. research IDE-ul trebuie să permită „unresolved contradiction” ca stare legitimă. Coerența nu este întotdeauna obiectiv; uneori dezacordul păstrat este informația cea mai valoroasă.

Privacy și IP schimbă designul colaborării. Un laborator nu poate publica fiecare prompt, datum sau idee. Totuși, review-ul credibil cere suficiente dovezi. Selective disclosure poate genera o „living book” sau capsule extinsă care explică claims și rezultate fără a expune întregul workspace. Hash-urile demonstrează existența temporală a artefactelor, secure enclaves permit evaluări pe date sensibile, iar access policies separă reviewerii. Aceste tehnologii trebuie prezentate ca mecanisme de integritate și confidențialitate, nu ca substitut pentru validare.

Un alt risc este automatizarea autorității. Dacă dashboard-ul afișează un scor verde, organizația poate delega decizia fără să înțeleagă schema. Pentru a evita aceasta, sistemul trebuie să prezinte verdictul decompozabil și să refuze un „truth score”. Culoarele și scorurile pot fi utile pentru triage, dar fiecare trebuie să ducă la claim, evidence și validator. Un scor fără traseu ar fi exact mai multe simboluri decât realitate.

Failure modes trebuie declarate din start. Compilatorul poate extrage greșit claim-uri și poate omite ambiguități. Politicile pot fi prea rigide și pot penaliza idei neconvenționale. Prior-Art Adversary poate rata lucrări sau poate declara echivalență falsă. Falsifier-ul poate genera teste slabe și poate crea impresia de severitate. Verificator registry-ul poate deveni învechit. Utilizatorii pot optimiza pentru metrici sau pot furniza date selective. Organizația poate folosi sistemul ca compliance theatre.

PROPUNERE DE CERCETARE

Pentru fiecare failure mode trebuie creat un benchmark adversarial. Compilatorul este testat pe texte cu schimbări subtile de scope. Prior-art-ul pe arhitecturi redenumite. Oracle Auditor pe test suites care trec mutanți relevanți. Consensus Auditor pe agenți cu erori corelate. Dashboard-ul pe scenarii în care scorul agregat ascunde un claim critic. Eficacitatea sistemului se măsoară prin decizii și erori detectate, nu prin exactitatea unei clasificări izolate.

Guvernanța trebuie să includă dreptul la override și obligația de justificare. Cercetătorul poate continua o idee pe care sistemul o consideră slab susținută; știința nu poate fi administrată complet de reguli. Dar output-ul public păstrează statusul și override-ul. La fel, un reviewer poate accepta o contribuție cu evidență incompletă pentru valoarea ei exploratorie, însă nu o redenumeste „demonstrată”. Separarea dintre libertatea de explorare și disciplina afirmației este cheia.

Arhitectura poate fi integrată într-un program mai larg de automatizare a cercetării: literature review, novelty assessment, peer review, experiment orchestration și knowledge curation. nucleul Epistemic Guardian devine strat comun. Un review agent nu produce doar text, ci atacă claim graph-ul. Un novelty agent nu dă un scor, ci găsește vecini. Un planning agent nu generează doar pași, ci selectează teste cu expected information gain. Un writer agent nu netezește incertitudinea, ci respectă statusul.

În această viziune, neuro-simbolicul nu este un slogan despre combinarea „creativității” și „logicii”. Este o diviziune explicită a muncii. Rețeaua neuronală propune semnificații, alternative și traduceri. Stratul simbolic păstrează identități, interzice tranziții și execută politici. Uneltele externe confruntă claims cu calcule, corpusuri, cod și lume. Oamenii aleg

valorile, întrebările și pragurile. Niciun strat nu este suficient, iar sistemul devine credibil tocmai pentru că limitele fiecăruia sunt vizibile.

Modul propus	Funcția în ecosistem
Problem Contract	Fixează problema, scope-ul, criteriile și schimbările de specificație.
Claim–Evidence Graph	Leagă afirmații, ipoteze, dovezi, artefacte și stataturi.
Prior-Art Adversary	Caută cele mai apropiate antecedente și atacă noutatea.
Architecture Canonicalizer	Reduce brandingul la primitive, fluxuri și proprietăți testabile.
Math-Washing Auditor	Verifică simbol–referent, ipoteze, claim strength și constraint gain.
Feasibility Checker	Introduce resurse, hardware, precizie, input/output și baseline end-to-end.
Test Oracle Auditor	Testează independența și puterea oracolelor, inclusiv prin mutation testing.
Falsifier	Propune cel mai ieftin test cu putere de a infirma claim-ul relevant.
Reproduction Capsule	Împachetează cod, date, prompturi, configurații, rezultate și provenance.

Epistemic Guardian trebuie evaluat ca un control plane, nu ca încă un critic care scrie un review. Un critic poate numi slăbiciuni după ce citește artefactul curent. Un control plane păstrează starea proiectului în timp, observă că aceeași presupunere a migrat prin mai multe artefacte, cere o verificare lipsă precisă, compară acțiuni următoare alternative și înregistrează dacă proiectul a răspuns. Valoarea sa constă în schimbarea traseului cercetării, nu în producerea unui paragraf mai sever.

Experimentele candidate au nevoie de un profil de discriminare. Pentru fiecare ipoteză activă, profilul înregistrează rezultatele precise, presupunerile necesare predicției și tranziția de stare pe care ar declanșa-o fiecare rezultat plauzibil. Zece experimente pot fi diferite tehnic și totuși toate confirmatorii atât sub H1, cât și sub H2. Guardian-ul trebuie să expună acest fapt. Poate recomanda în continuare un test confirmatoriu pentru robustețe, calibrare sau replicare, dar rolul epistemic rămâne explicit.

Valoarea așteptată a informației oferă o metodă acolo unde probabilitățile și deciziile pot fi reprezentate. Heuristicile de severe testing oferă alta atunci când întrebarea importantă este dacă o procedură ar

detecta probabil o eroare relevantă dacă afirmația ar fi falsă. Căutarea contraexemplurilor, metamorphic testing, testele ascunse, seturile adversariale, intervențiile cauzale, implementările independente și auditurile de resurse sunt alte forme specifice domeniului. Guardian-ul nu ar trebui să le forțeze într-o singură ecuație universală. Ar trebui să selecteze verificatorul potrivit tipului de afirmație și să explice de ce acel verificator discriminează.

Falsificatorul este cel mai bine înțeles ca planificator al unui contact ieftin și decisiv cu posibilitatea erorii. El primește contractul problemei, afirmațiile active, dovezile și modurile candidate de eșec, apoi propune testul cel mai puțin costisitor capabil să separe afirmația curentă de o alternativă serioasă. În munca formală poate căuta un contra-model sau o obligație de demonstrație. În software poate genera proprietăți, relații metamorfice ori oracole ascunse. În știința empirică poate propune un control negativ, o intervenție, un test out-of-distribution sau o măsurare care distinge mecanisme. Performanța sa trebuie raportată împreună cu rata de false kill, fiindcă un sistem care distruge idei neconvenționale presupunând premise convenționale nu este epistemic reușit.

5.3. Guardian-ul în research IDE, laborator, instituție și rețeaua științifică

Epistemic Guardian nu ar trebui proiectat ca un chatbot care apare la finalul proiectului și acordă un scor. O astfel de implementare ar fi comodă, dar ar recrea iluzia autorității: un model fluent ar comprima un proces complex într-o sentință. Guardian-ul este mai bine înțeles ca infrastructură distribuită în ecosistemul cercetării. El observă tranzițiile dintre întrebare, ipoteză, protocol, cod, date, rezultat, interpretare, articol și decizie instituțională. Intervine proporțional cu miza și păstrează un traseu pe care cercetătorii îl pot contesta.

La nivel individual, integrarea naturală este research IDE-ul. Cercetătorul formulează o problemă, iar sistemul construiește un Problem Contract: obiectul exact, contribuția urmărită, ipotezele, rezultatele care ar conta și condițiile care ar infirma proiectul. În faza exploratorie, contractul poate rămâne flexibil. LLM-ul generează analogii și arhitecturi fără a fi blocat de fiecare obligație. Când o idee este selectată pentru implementare, Guardian-ul îngheață o versiune a contractului și urmărește schimbările. Dacă testele validează o specificație diferită, sistemul nu spune că munca este inutilă; arată diferența dintre problema inițială și cea rezolvată.

În laborator, Guardian-ul devine orchestrator de proveniență și verificare. El conectează notebook-uri, repository-uri, experiment trackers, instrumente, simulatoare și sisteme de date. Fiecare rezultat important primește legături către cod, versiuni, configurații, date brute și transformări. Repetarea aceleiași execuții este separată de reproducerea independentă. Un model poate rerula perfect un pipeline greșit; proveniența ajută la localizarea erorii, dar nu este suficientă pentru adevăr.

EVIDENȚĂ PUBLICATĂ

PROV-O, RO-Crate și cercetarea asupra research objects oferă vocabular și mecanisme pentru agenți, activități, artefacte și pachete reproductibile [128, 140]. Lucrări foarte recente din 2026 propun grafuri afirmație-dovadă ca stare operațională a agenților, trasarea evidențelor și a execuției, workflow graphs pentru evaluarea reproductibilității și research artifacts care păstrează ramurile, codul, rezultatele și legăturile dintre claims [141-145]. Acestea sunt preprinturi și prototipuri timpurii, nu confirmarea unei arhitecturi instituționale complete. Totuși, ele arată că direcția tehnică este realizabilă și devine un front recognoscibil al automatizării științei.

La nivel de echipă, sistemul trebuie să susțină roluri diferite fără a transforma colaborarea în supraveghere. Un autor vede obligațiile deschise; un statistician vede identificarea, puterea și incertitudinea; un inginer vede resursele și failure modes; un reviewer intern vede claims cu cel mai mare impact și suportul cel mai fragil. Comentariile devin atacuri, suporturi sau cereri de probă legate de noduri, nu doar conversații pierdute în documente. Când dezacordul persistă, graful păstrează pozițiile și motivele, fără a forța netezirea într-un consens fictiv.

La nivel instituțional, Guardian-ul poate construi un tablou al portofoliului. Instituția nu are nevoie numai de „scoruri de calitate”, ci de distribuția stărilor: câte proiecte au ipoteze specificate, câte depind de aceleași date sau metode, unde lipsesc replicările, unde promisiunea publică depășește evidence status și unde există risc de concentrare. Un astfel de tablou poate preveni situația în care zece proiecte aparent independente se sprijină pe aceeași presupunere neverificată sau pe același benchmark contaminat.

Guardian-ul poate servi și comisiilor de finanțare. În loc să prezică succesul — sarcină vulnerabilă la conservatorism și bias — el poate produce un „Epistemic Dossier”: claritatea problemei, diferența față de prior art, dependențele critice, testele discriminatorii, riscul de proxy, resursele necesare, căile de falsificare și planul de reproducere. Evaluatorii rămân responsabili de alegere. Sistemul reduce costul

reconstrucției și face comparabile întrebări care altfel sunt ascunse în stiluri retorice diferite.

Pentru reviste și conferințe, Guardian-ul ar putea genera o hartă verificabilă anexată articolului. Nu trebuie introdus inițial ca standard obligatoriu. Un pilot voluntar poate permite autorilor să publice claim graphs, receipts de falsificare și reproduction capsules. Reviewerii ar raporta dacă acestea reduc timpul și îmbunătățesc detectarea. O condiție importantă este ca instrumentul să nu favorizeze domeniile cu date ușor de structurat și să penalizeze cercetarea calitativă, teoretică sau exploratorie. Schema trebuie configurată după tipul de claim.

În colaborarea dintre instituții, registrul de proveniență poate susține „independence-aware replication”. Sistemul nu întreabă doar dacă rezultatul a fost repetat, ci ce dependențe au fost schimbate: echipa, codul, instrumentul, dataset-ul, protocolul, modelul, lotul de materiale și analiza. Aceasta permite reprezentarea graduală a independenței. O replicare cu același cod și date confirmă executabilitatea; una cu implementare și eșantion diferit testează mai mult. Niciuna nu este disprețuită, dar ele nu sunt confundate.

PROPUNERE DE CERCETARE

Arhitectura ecosistemului poate fi organizată în șase servicii. Epistemic Kernel păstrează ontology, state machine și promotion rules. Evidence Bus conectează surse, instrumente și executori și atașează provenance. Research IDE oferă interacțiunea zilnică și explică obligațiile. Verification Market permite agenților, oamenilor sau laboratoarelor să accepte taskuri de reproducere și falsificare. Institutional Console agregă portofoliul fără a expune inutil date private. Governance Layer gestionează politici, apeluri, audit și drepturi.

„Verification Market” nu presupune neapărat bani sau blockchain. Este o metaforă pentru distribuirea explicită a obligațiilor de verificare. Un proiect publică un claim critic și un test care ar conta. Alte echipe pot propune baseline-uri, counterexamples sau reproduceri. Creditul științific se atașează contribuției de verificare, nu doar articolului original. Instituțiile ar putea alocă o parte din buget către eliminarea rapidă a erorilor cu impact ridicat. Sistemul ar urmări contribuțiile fără a transforma indicatorul într-un joc simplu de puncte.

Confidențialitatea este esențială. Un Guardian care indexează idei, eșecuri și valori poate deveni o infrastructură de control. Implementarea trebuie să permită registre locale, dezvoltare selectivă, criptare, politici de retenție și separarea identității de artefactele folosite pentru benchmark. Cercetătorul trebuie să poată explora o idee nepopulară fără ca fiecare

încercare să devină evaluare de performanță. Instituția poate vedea riscuri agregate fără acces automat la toate notițele individuale.

Un alt risc este conservatorismul epistemic. Dacă sistemul învață din ceea ce comunitatea a acceptat, poate favoriza metodele standard și poate penaliza ideile care nu se potrivesc schemelor. De aceea există două moduri. În Exploration Mode, Guardian-ul etichetează și păstrează incertitudinea, dar nu blochează. În Commitment Mode, activat când apar afirmații publice, resurse mari, intervenții sau impact asupra oamenilor, porțile devin mai severe. Libertatea de a imagina este separată de dreptul de a promova o afirmație.

Guvernanța trebuie să includă override, justificare și apel. Un cercetător poate decide să continue în pofida avertismentului, iar uneori va avea dreptate. Sistemul păstrează dezacordul și motivele. Un comitet poate modifica o regulă, dar schimbarea este versionată. Un audit extern poate reevalua modulul și datele. Guardian-ul este un participant critic în procedură, nu suveranul ei.

O ultimă funcție instituțională este memoria negativă. Știința publică succesele mai bine decât eșecurile, iar echipele repetă căi deja infirmate. Guardian-ul poate păstra „falsification receipts” și ramuri abandonate, cu acces controlat. Aceste artefacte devin resurse pentru planificare și pentru agenții viitori. Ele reduc riscul ca AI-ul să regenereze la nesfârșit aceeași idee sub alte nume.

Eficacitatea ecosistemului se măsoară prin rezultate observabile: scăderea erorilor de promovare, reducerea timpului până la infirmarea utilă, creșterea reproducerii, detectarea baseline-urilor omise, calibrarea încrederii și costul de utilizare. Satisfacția și numărul de rapoarte nu sunt suficiente. Un Guardian care produce încă un strat de text este un eșec. El trebuie să schimbe ce se verifică, când se verifică și ce dovezi intră în decizie.

La nivelul echipei, raportul Guardian ar trebui să devină parte a conversației științifice obișnuite. El prezintă acțiunea recomandată sau setul Pareto, cel mai puternic motiv de susținere, cel mai puternic contraargument, dovada decisivă, presupunerile la care rezultatul este sensibil, judecățile umane nerezolvate și evenimentul care ar inversa recomandarea. Cercetătorul poate respinge recomandarea, modifica o presupunere sau cere alt evaluator. Override-ul este păstrat ca decizie argumentată, nu înregistrat ca eroare a modelului.

La nivel de laborator, sistemul poate dezvălui dependențe comune între proiecte, afirmații centrale nerePLICATE, utilizarea repetată a aceluiași set de date și experimente cu cost ridicat, dar valoare informațională mică. La nivel instituțional, poate expune datoria de verificare și concentrarea

portofoliului în jurul unei teorii, unui instrument, furnizor sau familii de modele. La nivelul rețelei, poate primi replicarea externă, corecția și contradicția drept evenimente care schimbă starea, nu simple citări deconectate.

Guardian-ul nu ar trebui să creeze un singur regim de vizibilitate pentru întreaga instituție. Explorarea privată, starea colaborativă, auditul instituțional și release-ul public au conținuturi legitime diferite. Cercetătorii au nevoie de spațiu cognitiv în care gândul neterminat nu este evaluat permanent. Instituțiile au nevoie de suficientă trasabilitate pentru integritate și siguranță. Publicul are nevoie de suficientă proveniență și dovadă pentru încredere justificată. Oversight-ul semnificativ cere și capacitate epistemică, timp și spațiu cognitiv, autoritate decizională și o posibilitate efectivă de intervenție [161]. Un click uman nominal după o recomandare opacă nu îndeplinește niciuna dintre condiții.

Rolul instituțional pe termen lung este constituțional, nu suveran. Guardian-ul poate aplica tranziții delegate explicit prin politică, de exemplu să împiedice marcarea unei afirmații drept „replicată independent” fără un istoric al independenței. Nu ar trebui să determine valorile instituției sau să își extindă tacit autoritatea. Fiecare versiune de politică, model și evaluator rămâne vizibilă; apelul și auditul extern sunt trasee normale ale sistemului.

Capitolul 6. Axiologic Guardian

6.1. Protejarea valorilor cercetătorului și ale instituției

Axiologic Guardian pornește de la o observație diferită de cea epistemică. Un proiect poate fi riguros, nou și reproductibil, dar poate devia de la motivele pentru care cercetătorul sau instituția l-au început. Poate optimiza ceea ce este ușor de măsurat, poate accepta finanțări care schimbă tacit scopul, poate transforma o tehnologie emancipatoare într-un mecanism de supraveghere sau poate consuma ani într-o direcție pe care participanții nu o mai consideră valoroasă. Acestea nu sunt erori de adevăr; sunt erori de orientare.

Primul rol al Axiologic Guardian este protejarea valorilor declarate ale cercetătorului și ale instituției. „Protejare” nu înseamnă impunerea unei moralități externe și nici înghețarea persoanei în preferințele de ieri. Înseamnă păstrarea unei memorii explicite a angajamentelor și semnalarea deviațiilor înainte ca ele să devină ireversibile. Cercetătorul își poate formula o constituție profesională: tipurile de impact pe care le urmărește, limitele privind utilizările, relația dintre deschidere și securitate, autonomia intelectuală, toleranța la finanțări condiționate, obligațiile față de colaboratori, date și subiecți.

EVIDENȚĂ PUBLICATĂ

Value Sensitive Design tratează valorile umane ca cerințe care trebuie investigate conceptual, empiric și tehnic de-a lungul proiectării [104]. Responsible Research and Innovation propune anticipare, reflexivitate, incluziune și responsiveness ca dimensiuni ale procesului [103]. IEEE 7000 oferă un proces pentru identificarea preocupărilor etice și trasarea lor către cerințe de sistem [107]. Literatura despre meaningful human control și autonomie în decision support avertizează că sistemele trebuie să păstreze capacitatea umană de a înțelege, contesta și asuma decizia [131, 132]. Aceste tradiții oferă componente mature, dar nu descriu încă un agent general care monitorizează cercetarea de la idee la portofoliu.

O constituție personală nu trebuie dedusă numai din comportament. Acțiunile oamenilor reflectă constrângeri, oboseală, oportunități și contradicții. Literatura recentă critică reducerea valorilor la preferințe sau la o funcție scalară de utilitate; preferințele pot fi incomplete, construite și incompatibile, iar reward functions pierd conținutul semantic al valorilor [146]. Axiologic Guardian ar cere formulări explicite, exemple, excepții și

priorități locale, apoi ar folosi comportamentul doar ca semnal pentru dialog: „decizia actuală pare în tensiune cu angajamentul X; dorești să revizuiești angajamentul sau decizia?”.

La nivel instituțional, constituția include misiunea, politicile, obligațiile legale, promisiunile publice, relația cu finanțatorii și toleranța la risc. Multe instituții au asemenea texte, dar ele sunt separate de fluxul operațional. Axiologic Guardian le-ar transforma în „value requirements” legate de proiecte și decizii. Dacă o universitate declară acces echitabil, sistemul poate întreba cum o licență exclusivă sau un dataset restrictiv afectează acea valoare. Nu decide automat; obligă organizația să vadă conflictul.

PROPUNERE DE CERCETARE

Personal and Institutional Value Vault ar păstra angajamentele într-un spațiu controlat de utilizator. Valorile ar fi reprezentate printr-o combinație de limbaj natural, cazuri, reguli defeasible și dimensiuni pentru analiză. Fiecare intrare ar avea sursă, dată, domeniu, prioritate, excepții, nivel de confidențialitate și mecanism de revizuire. LLM-ul ar ajuta la clarificare și la găsirea contradicțiilor, dar n-ar avea dreptul să rescrie constituția implicit.

O problemă dificilă este „value drift”. Uneori driftul este corupție sau captură; alteori este învățare legitimă. Un cercetător poate abandona open source pentru a proteja subiecții sau poate accepta o aplicație comercială deoarece permite continuarea proiectului. Sistemul nu trebuie să confunde consistența cu virtutea. El ar produce o hartă temporală: ce s-a schimbat, ce evenimente au justificat schimbarea, cine a fost consultat și ce consecințe au apărut. Driftul devine obiect de deliberare, nu abatere automată.

Un al doilea instrument este „Decision-to-Value Trace”. Pentru o decizie importantă — alegerea unei direcții, a unui partener, a unei licențe, a unei populații de studiu sau a unei strategii de publicare — sistemul leagă opțiunile de valorile afectate și de dovezile despre consecințe. Acest lucru împiedică două tipuri de raționalizare. Primul este moral decoration: valorile sunt adăugate după decizie pentru a o face acceptabilă. Al doilea este metric capture: o valoare bogată precum echitatea este redusă la indicatorul disponibil și apoi indicatorul devine scop.

Axiologic Guardian trebuie să respecte pluralitatea internă. O instituție nu are o singură minte. Cercetătorii, studenții, managementul, comunitățile și finanțatorii pot avea angajamente diferite. Sistemul ar păstra pozițiile separate și ar identifica zonele de acord, conflict și dominare. Un consens produs prin rezumare nu este consens social. Pentru deciziile sensibile,

raportul trebuie să includă cine nu a fost reprezentat și ce voce are puterea de veto.

În practică, primul rol poate fi implementat modest. Înaintea fiecărui milestone, Guardian-ul întreabă: scopul actual corespunde scopului aprobat? beneficiarii și riscurile s-au schimbat? datele și colaborările respectă angajamentele? există o opțiune mai reversibilă? Răspunsurile sunt integrate în proiect, nu într-un raport etic separat. Valoarea instrumentului va depinde de cât de bine reduce surprizele morale și conflictele tardive, nu de cât de sofisticat sună ontologia sa.

Riscul de paternalism rămâne major. Un agent care „păzește valorile” poate manipula utilizatorul, poate bloca cercetarea controversată sau poate deveni instrumentul conducerii împotriva cercetătorilor. De aceea controlul constituției personale trebuie să aparțină cercetătorului, iar politicile instituționale să fie transparente și contestabile. Sistemul trebuie să explice ce regulă a activat, ce date a folosit și ce incertitudine are. El recomandă, avertizează și documentează; sancțiunea aparține unei proceduri umane cu drept de apel.

Acest prim rol este conservator într-un sens bun: păstrează continuitatea morală într-un mediu care accelerează. AI poate produce zeci de oportunități, colaborări și aplicații; tocmai viteza face dificilă întrebarea „mai este acesta proiectul pe care am vrut să-l construim?”. Axiologic Guardian aduce întrebarea înapoi înainte ca succesul tehnic să o facă prea costisitoare.

Primul mandat al Axiologic Guardian este fiduciar într-un sens larg, nu juridic: îi ajută pe cercetători și instituții să răspundă în fața valorilor pe care le-au ales explicit. Nu deduce o „preferință adevărată” ascunsă din click-uri sau decizii trecute. Un cercetător poate declara angajamente față de independență intelectuală, deschidere, beneficiul pacientului, moderație ecologică, pluralism metodologic sau refuzul unei anumite căi dual-use. O instituție poate declara o misiune, angajamente privind drepturile, obligații publice, linii roșii și reguli de rezolvare a conflictului. Angajamentele devin obiecte versionate, cu domeniu, autoritate, interpretări operaționale și condiții de revizuire legitimă.

Analiza recentă a alignment-ului întărește nevoia separării. O revizuire sistematică din 2026 asupra value-sensitive AI a constatat, de asemenea, că traducerea investigațiilor conceptuale și asupra stakeholderilor în cerințe tehnice rămâne inconsistentă, mai ales în privința iterației, identificării stakeholderilor și prioritizării valorilor [159]. Smart și colegii au examinat 94 de articole despre value alignment și au constatat că majoritatea nu defineau valorile, folosind adesea preferințele drept substitut [160]. Predicția preferințelor este utilă, dar normativ slabă. O

echipă poate prefera un experiment comod, deși valorizează independența; o instituție poate recompensa volumul de publicații, deși pretinde că valorizează replicarea. Rolul Guardian-ului este să expună tensiunea, nu să transforme comportamentul observat în constituția instituției.

O valoare devine executabilă numai printr-o consecință vizibilă. „Valorizăm cercetarea riguroasă” este o aspirație. „O afirmație cauzală cu impact ridicat nu poate fi promovată înainte de înregistrarea unui review al identificării și a unui test capabil de falsificare sau înainte ca o excepție autorizată să explice de ce acestea sunt imposibile” este operațional. „Valorizăm autonomia cercetătorului” devine semnificativ când interfața păstrează explorarea privată, face respingerea sfatului ieftină și împiedică modelul să rescrie planul fără autorizare. Executabilitatea nu face valoarea obiectiv corectă; face inspectabilă traducerea dintre valoare și practică.

Value Vault trebuie să păstreze formularea originală, normele operaționale derivate, dovezile folosite în interpretare, interpretările divergente și fiecare revizuire autorizată. Adaptarea la comportament este stocată separat. Un model poate învăța că o echipă preferă de regulă teste exploratorii ieftine; nu poate transforma tacit regularitatea într-o regulă constituțională. Schimbarea legitimă a valorilor este posibilă, dar este o decizie vizibilă, cu motive și rollback, nu derivă ascunsă.

6.2. Valoarea pentru umanitate fără un dictator al utilității

Al doilea rol al Axiologic Guardian depășește valorile cercetătorului și ale instituției. El încearcă să evalueze valoarea unei direcții pentru oameni, societate, ecosisteme și generații viitoare. Acesta este rolul cel mai ambițios și cel mai periculos, deoarece poate aluneca ușor într-un agent care pretinde că știe ce este bine pentru umanitate. Cartea propune explicit o funcție mai modestă: sistemul nu optimizează „utilitatea umanității”, ci construiește evaluări contestabile, scenarii și argumente care fac mai dificilă ignorarea consecințelor.

Utilitarismul oferă o intuiție puternică: efectele asupra bunăstării contează, iar resursele limitate ar trebui orientate spre beneficii mari. În prioritizarea cercetării, cost-effectiveness și value of information pot identifica studii care reduc incertitudini importante [124]. Totuși, un scalar de utilitate poate ascunde distribuția, drepturile, demnitatea, relațiile și riscurile catastrofale. O tehnologie poate crește beneficiul agregat sacrificând un grup vulnerabil. O altă direcție poate avea valoare de opțiune și libertate viitoare care nu apare într-un orizont scurt.

EVIDENȚĂ PUBLICATĂ

Multi-Criteria Decision Analysis oferă metode pentru opțiuni evaluate pe mai multe dimensiuni, fără a presupune că toate valorile se reduc natural la aceeași unitate [123]. Teoria alegerii sociale arată dificultăți și imposibilități în agregarea preferințelor individuale într-o ordine colectivă [125]. Sen accentuează comparația publică, capabilitățile și injustițiile remediabile, nu doar o funcție ideală de bunăstare [126]. Literatura despre moral uncertainty propune decizii care iau în calcul incertitudinea dintre teorii morale [121, 122]. Value-based argumentation permite reprezentarea situațiilor în care acceptarea unui argument depinde de valorile preferate și identifică uneori concluzii robuste la mai multe ordonări [147]. Niciuna dintre aceste abordări nu oferă un oracol moral universal; împreună, ele justifică o arhitectură pluralistă.

Propunem o „constituție axiologică pe straturi”. Primul strat conține constrângeri tari: lege, drepturi fundamentale, consimțământ, siguranță și interdicții specifice. Al doilea păstrează angajamentele cercetătorului și instituției. Al treilea descrie stakeholderii și efectele distribuite. Al patrulea evaluează bunăstarea, sănătatea, cunoașterea și bunurile publice. Al cincilea examinează justiția, puterea și cine suportă riscurile. Al șaselea privește viitorul: reversibilitate, opțiuni păstrate, dependențe și riscuri extreme. Al șaptelea tratează dual use și posibilitatea ca rezultatul să fie deturnat.

Aceste straturi nu sunt combinate obligatoriu într-un singur scor. Sistemul poate construi un Pareto frontier: opțiuni care nu pot fi îmbunătățite pe o dimensiune fără a pierde pe alta. Poate calcula scoruri locale când există acord asupra metricilor, dar păstrează ponderile și incertitudinile. Poate raporta dominanță robustă: o opțiune este mai bună într-o gamă largă de ponderi și scenarii. Când alegerea depinde de o valoare contestată, sistemul arată exact dependența.

PROPUNERE DE CERCETARE

Humanity Value Dossier ar fi produsul central. El începe cu o hartă a stakeholderilor, incluzând beneficiarii indirecti, grupurile fără reprezentare și entitățile afectate pe termen lung. Continuă cu un model cauzal al impactului, nu doar o listă de beneficii și riscuri. Pentru fiecare cale se notează dovezile, incertitudinea, reversibilitatea și controlul. Apoi compară opțiuni, inclusiv alternativa de a nu acționa și direcții de cercetare concurente. În final, oferă condiții de continuare, mitigări și întrebări care merită informație suplimentară.

LLM-ul este util pentru identificarea stakeholderilor, recuperarea analogiilor istorice, generarea scenariilor și traducerea între vocabularul

tehnic și cel normativ. El nu poate estima singur probabilitățile și valorile. Causal models trebuie ancorate în date și experți; drepturile și politicile vin din surse autorizate; comunitățile afectate trebuie consultate; iar incertitudinea morală trebuie păstrată. Axiologic Guardian este un sistem socio-tehnic, nu un model.

Un instrument important este „Moral Uncertainty Register”. Pentru fiecare recomandare se păstrează ce teorii sau principii o susțin, care o contestă și cât de sensibilă este la ponderi. Dacă o decizie este bună numai sub utilitarism agregativ și problematică sub prioritarianism, drepturi sau precauție, raportul nu ascunde conflictul. Sistemul poate folosi expected choice-worthiness ca analiză, dar nu ca adevăr final. În cazuri cu valori incommensurabile, poate recomanda opțiuni reversibile și acumulare de informație.

Un alt instrument este „Dual-Use Pathway Analyzer”. El separă capacitatea tehnică de intenția declarată. O metodă de descoperire a vulnerabilităților poate îmbunătăți securitatea și atacul; un model biologic poate accelera tratamente și design periculos; o infrastructură de personalizare poate sprijini medicina și supravegherea. Sistemul descrie actorii, accesul, costurile, barierele și scenariile de abuz. Recomandările pot include staged release, controale, monitorizare, red teaming sau întârzierea anumitor detalii. Ele trebuie evaluate empiric, deoarece unele măsuri pot concentra puterea fără a reduce riscul.

„Valoarea pentru umanitate” riscă să privilegieze perspectiva celor care construiesc sistemul. Moral Machine a demonstrat variații culturale în răspunsurile la dileme [110], iar modelele de limbaj pot produce judecăți morale diferite în funcție de limba promptului [112]. De aceea, constituția globală nu poate fi scrisă de o singură companie sau instituție. Collective Constitutional AI arată o încercare de a include input public în constituția modelului [109], însă participarea, reprezentativitatea și transformarea opiniilor în reguli rămân probleme deschise.

Axiologic Guardian ar trebui să includă deliberare structurată. Participanții pot propune valori, exemple și obiecții; sistemul grupează fără a elimina minoritățile, detectează conflicte și construiește argument maps. Value-based argumentation și logici defeasible pot reprezenta reguli cu excepții [147, 148]. Social choice și MCDA pot compara opțiuni, dar rezultatul final trebuie să includă dissent reports. Legitimitatea procedurii este o dimensiune a calității, nu un ornament.

SINTEZĂ ȘI INFERENȚĂ

Cel mai util rol al agentului „utilitarist” este acela de a împiedica uitarea consecințelor și a costurilor de oportunitate, nu de a maximiza o cifră.

El întreabă: câți pot beneficia, cât de mult, cu ce probabilitate, cine pierde, ce alternative sunt abandonate și ce informație ar schimba decizia? Apoi lasă aceste răspunsuri să intre într-o constituție pluralistă. Utilitatea devine un martor important în proces, nu judecătorul unic.

Evaluarea modului ar trebui să folosească decizii istorice cu consecințe cunoscute, scenarii prospective și piloți reali. Experții și stakeholderii ar compara dosarele cu evaluări obișnuite. Măsurăm dacă sistemul descoperă efecte omise, dacă recomandările sunt robuste, dacă minoritățile se simt reprezentate, dacă autonomia este păstrată și dacă instituția modifică efectiv decizii. Nu putem valida moralitatea prin acuratețe față de un singur label; putem valida calitatea procesului și capacitatea de a anticipa.

Strat axiologic	Întrebarea operațională
Constrângeri tari	Ce interzic sau cer legea, drepturile, consimțământul și siguranța?
Constituția cercetătorului	Decizia respectă angajamentele voluntare și autonomia intelectuală?
Misiunea instituției	Proiectul corespunde politicilor și promisiunilor publice, inclusiv în timp?
Stakeholderi și distribuție	Cine beneficiază, cine suportă costul și cine nu este reprezentat?
Bunăstare și bunuri publice	Ce efecte plauzibile există asupra sănătății, cunoașterii și capacităților?
Viitor și reversibilitate	Ce opțiuni se închid, ce dependențe apar și cât de reversibilă este decizia?
Dual use și risc extrem	Ce căi de abuz sau efecte de coadă necesită control, etapizare ori monitorizare?

Al doilea mandat este mai larg și mai dificil: evaluarea valorii posibile pentru umanitate. Expresia nu trebuie să ascundă un subiect global fictiv cu o singură funcție de utilitate. Umanitatea conține persoane cu putere inegală, interese conflictuale, tradiții morale diferite, generații viitoare care nu pot vorbi, viață non-umană, instituții și sisteme comune a căror valoare nu poate fi redusă la satisfacerea preferințelor individuale. Guardian-ul ar trebui, prin urmare, să producă un dosar structurat, nu un scor universal de bunăstare.

Dosarul distinge cel puțin beneficiile directe, distribuția beneficiilor și poverilor, drepturile și autonomia, siguranța, efectele asupra mediului, concentrarea puterii, dual use, dependența sistemică, costul de

oportunitate, reversibilitatea, option value și efectele asupra capacității viitoare de cercetare. Înregistrează cine este reprezentat, cine lipsește, ce legătură cauzală este empirică, ce este modelat, ce este speculativ și ce judecată de valoare rămâne nerezolvată. Analiza consecințialistă este indispensabilă pentru compararea efectelor și a scării. Ea este una dintre lentile, nu un dictator care poate cumpăra încălcarea unui drept prin suficiente beneficii proiectate.

Semnificația ar trebui reprezentată prin povești cauzale și grafuri de dependență. Potențialul de citare este un proxy slab și devine periculos când este optimizat. Un rezultat poate fi semnificativ fiindcă rezolvă un bottleneck, schimbă setul acțiunilor fezabile, creează un instrument reutilizabil, invalidează o direcție costisitoare sau deschide o ramură cu option value ridicată. Guardian-ul poate formula întrebări contrafactice: dacă afirmația C ar fi falsă, ce decizii s-ar schimba? Dacă experimentul E ar reuși, ce acțiuni noi ar deveni posibile? Dacă proiectul ar dispărea, ce beneficiari, riscuri și trasee de cercetare ar fi realmente afectate?

Noutatea depinde la rândul ei de dovezi. Judecătorii LLM pot genera verdicte sigure despre noutate, însă RQ-Bench a găsit un „novelty mirage”: modelele evaluatoare preferau întrebările generate de modele, în timp ce experții de domeniu preferau întrebările ancorate în lucrările autorilor [157]. NovBench raportează și el o înțelegere limitată a noutății academice de către modelele actuale [166]. Un modul defensabil recuperează prior art-ul cel mai apropiat, compară fațete, distinge un nume nou de un mecanism nou, raportează cutoff-ul literaturii și se abține când acoperirea este slabă. Noutatea devine astfel o intrare în judecata valorii, nu un drept moral automat la resurse.

6.3. Cum poate fi operaționalizată o judecată axiologică pluralistă

Operationalizarea judecății axiologice cere o combinație de reprezentări. Limbajul natural este necesar pentru că valorile au conținut bogat și context. Regulile sunt necesare pentru obligații și interdicții. Modelele cantitative sunt utile pentru impact, risc și cost. Argumentele sunt necesare când oamenii contestă prioritățile. Niciuna dintre aceste forme nu poate absorbi complet celelalte. Arhitectura neuro-simolică trebuie să păstreze pluralitatea reprezentărilor în loc să o ascundă într-un embedding sau reward scalar.

La baza sistemului stă Value Graph. Nodurile reprezintă valori, norme, stakeholderi, opțiuni, efecte, dovezi, incertitudini și decizii. Relațiile includ promotes, threatens, requires, conflicts_with, affects, justified_by și

overridden_by. Unele valori sunt abstracte, precum autonomia; altele sunt operaționalizări, precum posibilitatea de opt-out sau controlul datelor. Graful păstrează legătura dintre ele, astfel încât metricile să nu devină înlocuitori invizibili.

Un al doilea strat este logica normativă. Deontic logic poate reprezenta ceea ce este obligatoriu, permis sau interzis, însă normele reale au excepții și conflicte. Defeasible Deontic Logic și implementările sale permit reguli care pot fi învinse de reguli mai specifice [148]. De exemplu, „datele trebuie deschise” poate fi limitată de „datele identificabile ale participanților trebuie protejate”. Sistemul nu rezolvă conflictul prin ordinea aleatorie a prompturilor, ci prin priorități și justificări versionate.

Un al treilea strat este value-based argumentation. Un argument în favoarea publicării deschise poate promova transparența; unul pentru acces controlat poate promova siguranța. Bench-Capon arată cum acceptabilitatea poate depinde de ordonarea valorilor și cum unele concluzii rămân robuste la ordonări diferite [147]. Pentru Guardian, aceasta permite un raport mai onest: „decizia A este recomandată dacă prioritatea este accesul; B dacă prioritatea este minimizarea dual use; C domină în ambele scenarii”.

Un al patrulea strat este analiza decizională. MCDA permite compararea opțiunilor pe criterii multiple [123]. Bayesian decision analysis și value of information estimează când merită să obținem date înainte de alegere [124]. Robust decision-making și minimax regret sunt potrivite când probabilitățile sunt fragile. Scenario analysis expune dependențele. Aceste metode nu sunt înlocuite de LLM; modelul poate ajuta la formulare și interpretare, în timp ce calculele sunt executate de instrumente explicite.

PROPUNERE DE CERCETARE

Axiologic Compiler ar transforma un proiect sau o decizie într-un „Normative Intermediate Representation”. LLM-ul extrage scopuri, stakeholderi, valori și consecințe din documente și interviuri. Un validator cere confirmare pentru elementele cu miză. Ontologiile și policy parsers adaugă reguli autorizate. Causal Impact Model leagă acțiunile de efecte. Argumentation Engine construiește suporturi și atacuri. MCDA/robustness engine explorează ponderi și scenarii. Output-ul este Value Dossier cu trasee, nu un verdict generativ.

Pentru ca judecata să rămână contestabilă, fiecare recomandare are un „reason trace”. Utilizatorul vede ce valori și dovezi au fost decisive. Poate modifica o ipoteză, o pondere sau o regulă și observa efectul. Sistemul identifică „value pivots”: punctele în care o diferență legitimă de

valoare schimbă recomandarea. Acestea sunt locurile potrivite pentru deliberare umană. Restul poate fi automatizat mai mult.

Formalizarea valorilor riscă math-washing axiologic. O matrice cu ponderi poate produce precizie aparentă pentru judecăți care nu au fost legitimate. De aceea fiecare număr are provenanță și interval. Ponderea poate proveni din decizie politică, deliberare, expertiză sau analiză de sensibilitate; sursa este vizibilă. Sistemul afișează rezultate pe intervale și evită zecimale fără sens. Dacă ordinea opțiunilor se schimbă la variații mici, recomandarea este fragilă.

O altă problemă este Goodhart: când indicatorul devine țintă, organizația îl optimizează. Axiologic Guardian nu trebuie să transforme „humanity value” într-un KPI unic. El folosește profile și verificări periodice ale proxy-urilor. De exemplu, numărul de persoane care folosesc o tehnologie nu este automat bunăstare; numărul de publicații open access nu este automat acces epistemic; numărul de grupuri consultate nu este automat participare reală. Epistemic Guardian verifică dovezile despre impact, iar Axiologic Guardian verifică dacă impactul măsurat este cel care contează.

Cele două Guardians sunt astfel interdependente. O evaluare axiologică fără disciplină epistemică inventează consecințe convingătoare. O evaluare epistemică fără axiologie poate optimiza perfect o problemă greșită. În arhitectură, Value Graph se leagă de Claim-Evidence Graph. Afirmatia „opțiunea reduce mortalitatea” are nevoie de dovezi și estimări. Valoarea „reducerea mortalității” intră în comparația normativă. Dacă dovezile se schimbă, analiza axiologică se recalculează; dacă valorile se schimbă, adevărul empiric nu este rescris.

Guvernanța sistemului trebuie să includă separarea puterilor. O echipă definește politicile; alta auditează modelele; stakeholderii contestă reprezentarea; experții validează impactul; comitetul decide. LLM-ul nu trebuie să fie simultan extractor, evaluator, legislator și apel. Modelele diferite pot ajuta, dar independența reală vine din surse, proceduri și autorități distincte.

EVIDENȚĂ PUBLICATĂ

Ethics-based auditing a fost propus ca metodă pentru dezvoltarea AI demne de încredere [129], iar literatura de Value Sensitive AI subliniază nevoia proceselor socio-tehnice și a participării, nu doar a metricilor [130]. IEEE 7000 oferă trasabilitate de la preocupări la cerințe [107]. Constitutional AI și Collective Constitutional AI arată că reguli și input public pot influența comportamentul modelelor [108,

109]. Aceste rezultate susțin componente, dar nu arată că un Axiologic Guardian poate judeca independent valoarea pentru umanitate.

SINTEZĂ ȘI INFERENȚĂ

În primele iterații, tehnologia trebuie limitată la assessment și guidance. Ea poate identifica conflicte, construi scenarii, verifica fidelitatea față de valori declarate și pregăti dosare. Nu ar trebui să autorizeze sau să blocheze autonom cercetarea cu miză mare. O extindere a autorității ar necesita studii longitudinale, audit public, reprezentare plurală și dovezi că sistemul îmbunătățește deciziile fără a reduce autonomia și diversitatea epistemică.

Un MVP realist ar funcționa într-un venture studio, un program universitar sau un consorțiu. El ar primi propuneri de proiect și ar genera două produse: Mission Alignment Report și Humanity Value Dossier. Oamenii ar corecta extragerile, ar declara dezacordurile și ar decide. Pe parcurs, sistemul urmărește promisiunile și consecințele. Evaluarea compară proiecte cu și fără instrument: conflicte găsite devreme, schimbări de design, satisfacția stakeholderilor, robustețea deciziilor și overhead-ul.

Succesul nu este ca sistemul să ofere aceeași judecată ca un comitet. Comitetele pot greși și pot fi capturate. Succesul este ca procesul să devină mai explicit, mai informativ, mai reversibil și mai greu de manipulat prin retorică. Axiologic Guardian nu automatizează conștiința. Construiește infrastructura prin care conștiința poate rămâne prezentă într-un ecosistem care se mișcă prea repede pentru reflecția neasistată.

O Research Constitution practică are patru straturi. Constrângerile tari specifică acțiuni pe care politica actuală le interzice sau cere să fie escalate, inclusiv confidențialitate, consimțământ, siguranță, lege, securitate și drepturi protejate. Normele evidențiale guvernează promovarea afirmațiilor, independența, testarea negativă și reproductibilitatea. Normele de alegere compară acțiuni admisibile prin discriminare, valoarea informației, cost, generalitate, reutilizare, semnificație, risc și reversibilitate. Normele de guvernare precizează cine poate schimba Constituția, cine trebuie consultat, cum se dezvăluie conflictele și cum funcționează apelul.

Strat normativ	Rol operațional și rezultat caracteristic
Constrângeri tari	Elimină sau escaladează acțiuni inadmisibile; nu sunt ponderi negative mici pe care noutatea sau profitul le pot anula
Norme evidențiale	Spun ce dovezi, independență sau test sever este necesar înainte ca o afirmație să își schimbe starea

Strat normativ	Rol operațional și rezultat caracteristic
Norme de alegere	Compară acțiuni admisibile prin ordine parțiale, frontiere Pareto, utilități locale, valoarea informației sau argumente explicite
Norme de guvernanță	Atribuire autoritate, participare, versionare, override, apel, audit și procedura de schimbare a Constituției

Profilurile plurale de Guardian pot funcționa ca stress tests epistemologice și axiologice. Profiluri bayesiene, severe-testing, popperiene, lakatosiene, orientate spre reproductibilitate, misiune, drepturi sau impact pot recomanda acțiuni diferite din motive defensabile. Acordul dintre profiluri indică robustețe. Dezacordul identifică pivotul valoric la care alegerea se schimbă. Scopul nu este puritatea filosofică, ci vizibilitatea operațională: un comitet trebuie să știe dacă două recomandări diferă fiindcă un evaluator este instabil sau fiindcă o constituție valorizează reversibilitatea mai mult decât viteza.

Obiectul deciziei ar trebui să păstreze constrângerile tari, opțiunile dominate, setul Pareto, analizele cantitative locale, grafurile de argumentare, incertitudinea, sensibilitatea, defeaters și judecățile umane necesare. Poate concluziona legitim că două opțiuni sunt incomparabile sub Constituția actuală. Precizia falsă este o eroare, nu un semn de sofisticare. Fiecare număr are proveniență și interval de sensibilitate; fiecare pondere precizează dacă provine din politică, deliberarea stakeholderilor, dovadă empirică, judecată expertă sau alegere provizorie de modelare.

Axiologic Compiler este o posibilă implementare. LLM-urile extrag scopuri, stakeholderi, valori, consecințe anticipate și reguli din documente și interviuri. Oamenii confirmă elementele cu impact mare. Un parser de politici și un strat ontologic introduc normele autorizate. Un model causal de impact conectează acțiunile la efecte. Argumentarea reprezintă susținerea, atacul, excepțiile și prioritățile valorice. Instrumentele MCDA, Pareto, robust decision, minimax regret și value of information operează numai când presupunerile lor sunt vizibile. Rezultatul este un Value Dossier cu reason traces, nu un verdict moral generat.

Un sistem matur trebuie să poată spune și că o parte a deciziei se află în afara mașinii. Alegerea comunităților care pot suporta un risc, a bolii care merită investiție publică sau a tipului de societate viitoare dorit poate necesita legitimitate politică și deliberarea stakeholderilor afectați. O escaladare bine plasată este un rezultat reușit. Contribuția Guardian-ului este să clarifice presupunerile empirice, opțiunile, conflictele și consecințele înainte ca oamenii să își asume responsabilitatea.

Capitolul 7. Pot LLM-urile să judece?

7.1. Dovezile despre LLM-as-a-judge și judecata morală

Ideea celor două Guardians depinde de o întrebare pragmatică: pot modelele de limbaj să emită judecăți suficient de bune pentru primele iterații? Răspunsul academic nu este nici „da”, nici „nu” în general. Modelele pot evalua anumite proprietăți la un nivel util, pot reduce costul trierei și pot identifica probleme pe care un utilizator le-ar omite. În același timp, ele au biasuri sistematice, erori corelate cu generatorii, dificultăți cu contexte lungi și o capacitate morală care variază cu limba, formularea și convenția. Prin urmare, trebuie specificat ce fel de judecată cerem, în ce domeniu, cu ce dovezi și ce consecință are eroarea.

„LLM-as-a-judge” a devenit o metodă răspândită pentru evaluarea răspunsurilor, a preferințelor și a calității generative. Benchmarks precum RewardBench și JudgeBench arată că unele modele pot discrimina bine între răspunsuri pe seturi definite, dar că performanța variază între tipuri de sarcini și adversari [116, 117]. Literatura identifică position bias, verbosity bias, self-preference și sensibilitate la format [41, 42, 134-137]. Panelurile de modele diverse pot îmbunătăți evaluarea în anumite condiții [118], însă numărul de voturi poate supraestima independența când erorile sunt corelate [119]. Evaluarea output-urilor lungi rămâne o provocare separată, deoarece judecătorul trebuie să urmărească multe claims și dovezi distribuite [120].

EVIDENȚĂ PUBLICATĂ

Aceste rezultate susțin folosirea LLM-urilor pentru sarcini înguste cu rubrics și calibrare, nu delegarea generică a adevărului. Un judge poate compara două rezumate, detecta o contradicție sau verifica dacă un răspuns citează o sursă. Este mai puțin credibil când trebuie să stabilească noutatea unei arhitecturi fără căutare, corectitudinea unei demonstrații fără proof checker, valoarea unei teorii pentru umanitate sau validitatea unui mecanism causal fără date. Competența verbală nu substituie accesul la verificator.

În domeniul moral, situația este și mai sensibilă. Delphi a explorat învățarea judecăților normative din date și a arătat atât capacitate, cât și limite [111]. ChatGPT a oferit sfaturi morale inconsistente care au influențat judecățile utilizatorilor [113]. Alte studii au găsit că output-urile pot fi

percepute ca expertiză morală [114], dar nu reproduc în mod robust judecățile umane [115]. Limba promptului poate modifica alinierea morală [112]. Moral Machine a demonstrat variații între populații în dileme [110]. Nu există ground truth simplu pe care un model să-l aproximeze universal.

SINTEZĂ ȘI INFERENȚĂ

LLM-urile sunt judecatori decenti când judecata poate fi descompusă în operații textuale locale, când există rubrică, exemple și posibilitate de verificare. Ele sunt judecatori fragili când criteriul este latent, contestat, dependent de lume sau vulnerabil la aceeași retorică pe care modelul o produce. Ele pot fi foarte utile ca „clerks”: extrag, compară, generează obiecții, caută inconsecvențe și pregătesc dosare. Nu trebuie confundate cu instanța care stabilește statusul epistemic sau legitimitatea axiologică.

Pentru Epistemic Guardian, rolurile potrivite în prima iterație sunt clare. Modelul poate extrage claims și tipurile lor, poate identifica termeni neglijăți, poate sugera prior art, poate converti o explicație într-un test și poate construi candidate counterexamples. Poate evalua dacă un rezumat respectă stările din graf. Nu poate promova claim-ul fără eveniment extern. Dacă afirmă că o dovadă este validă, verdictul trebuie să vină de la un kernel formal, un test, date sau expert.

Pentru Axiologic Guardian, modelul poate facilita elicitation-ul valorilor, identifica stakeholderi și scenarii, rezuma argumente și traduce vocabularul. Poate detecta contradicții între o decizie și o politică explicită. Nu trebuie să stabilească singur ponderile, să interpreteze drepturile în cazuri controversate sau să pretindă că reprezintă umanitatea. Judecata sa este o contribuție într-un proces plural.

Un mod util de a clasifica sarcinile este după „judgment distance”. La distanță mică, criteriul este în text: apare sau nu o limitare, există o citare, concluzia menționează incertitudinea. La distanță medie, sunt necesare căutare și tools: prior art, reproducerea unui calcul, compararea cu o politică. La distanță mare, verdictul depinde de lume, valori și consecințe: funcționează mecanismul, este sigur, este just, merită finanțat. Autoritatea LLM-ului trebuie să scadă pe măsură ce distanța crește.

PROPUNERE DE CERCETARE

Introducem „Judge Capability Card” pentru fiecare combinație model–rubrică–domeniu. Cardul conține performanța pe cazuri cu verdict cunoscut, biasuri, calibrare, limbi, lungime, tipuri de eroare și condiții de abstention. Un model nu este desemnat „bun judecător” în general. Poate fi acceptat pentru clasificarea claim-urilor ML și respins

pentru evaluarea morală a unui proiect biomedical. Cardurile sunt versionate odată cu modelul și promptul.

Un al doilea principiu este separarea generării de judecare. Agentul care a produs o idee poate critica, dar critica sa nu este independentă. Un alt model cu aceeași familie poate adăuga diversitate limitată. Pentru decizii cu miză, sistemul trebuie să includă surse și verificatoare care nu provin din aceeași distribuție. Un panel de LLM-uri devine valoros când membrii au acces la tools diferite, primesc evidence packets independente și emit verdictul înaintea deliberării.

Un al treilea principiu este abstention obligatoriu. Modelele sunt optimizate să răspundă. Guardian-ul trebuie să recompenseze „nu există suficiente dovezi” și să distingă uncertainty de disagreement. Când judge-ii nu sunt calibrați în domeniu sau când argumentul depinde de un fapt neverificat, sistemul escaladează. O judecată lipsă este preferabilă unei certitudini fabricate.

Evaluarea trebuie să includă utilizatorul. Un judge poate avea acuratețe moderată, dar să producă explicații atât de persuasive încât oamenii îl urmează excesiv. Studiile despre explicații arată că lungimea poate crește încrederea fără creșterea acurateței [29]. De aceea măsurăm nu doar verdictul, ci reliance: când acceptă oamenii recomandarea, pot identifica motivele și contestă erorile? O interfață bună afișează evidența, alternativele și incertitudinea înaintea concluziei.

Concluzia provizorie este favorabilă, dar limitată. LLM-urile pot face Guardians fezabili economic în primele iterații, deoarece reduc costul structurării și al căutării. Ele nu fac judecata automat legitimă. Infrastructura devine credibilă tocmai când tratează modelul ca pe un component performant, măsurabil și înlocuibil, nu ca pe o conștiință digitală.

Dovezile recente fac răspunsul provizoriu mai precis. Evaluatorii LLM nu sunt uniform nesiguri; sunt inegal de siguri în moduri care trebuie măsurate, nu presupuse. Studiul Rating Roulette a găsit o fiabilitate intra-evaluator redusă între rulări repetate, arătând că același model se poate comporta ca mai mulți revieweri inconsistenți [156]. CheckEval raportează că descompunerea evaluărilor globale în întrebări binare, trasabile, de tip checklist crește substanțial acordul dintre modele și reduce variația [158]. Rezultatele susțin un principiu cunoscut din safety engineering: acolo unde criteriul permite, impresia globală trebuie înlocuită cu verificări mici și explicite.

Noutatea științifică arată limita opusă. RQ-Bench a constatat că judecătorii LLM preferă sistematic întrebările de cercetare generate de modele, în timp ce experții de domeniu preferă întrebările reconstruite din

articole reale, producând ceea ce autorii numesc un miraj al noutății [157]. NovBench raportează, de asemenea, o înțelegere limitată a noutății academice chiar atunci când modelele produc evaluări fluente [166]. Dificultatea nu este doar stilistică. Noutatea este relațională, temporală, dependentă de fațeta comparată și de acoperirea literaturii. Un judecător care nu a recuperat lucrările cele mai apropiate nu poate ști dacă un nume nou desemnează un mecanism nou, iar unul care a explorat doar o vecinătate bibliografică nu poate ști cât de completă este acea vecinătate.

EVIDENȚĂ PUBLICATĂ

Cazul empiric cel mai puternic pentru LLM-uri ca evaluatori privește, prin urmare, sarcini semantice delimitate, cu dovezi explicite și criterii decompozabile. Modelele pot ajuta la identificarea faptului că o afirmație este formulată, că o limitare este recunoscută, că două pasaje se contrazic sau că o sursă citată pare să trateze propoziția relevantă. Autoritatea lor scade pe măsură ce judecata depinde de realitatea externă, de lanțuri cauzale lungi, de literatură nevăzută, de construcții contestate sau de valori plurale. Distanța dintre text și lume nu este un slogan metafizic; este un determinant practic al costului de validare.

PROPUNERE DE CERCETARE

Guardian-ul ar trebui să mențină un Registru al Evaluatoarelor, nu o listă de modele preferate. Fiecare evaluator este înregistrat pentru un tip de claim, un domeniu, o limbă, un pachet de dovezi, o versiune a rubricii și un nivel al consecinței. Capability Card-ul său consemnează repetabilitatea, calibrarea, biasurile cunoscute, corelațiile erorilor, comportamentul de abstention și instrumentele externe pe care le poate invoca. Același model poate fi admis pentru a verifica dacă o secțiune de metode raportează random seed-ul și poate fi inadmisibil pentru a decide dacă o intervenție biomedicală este justificată etic. Capabilitatea aparține unei configurații măsurate, nu unui nume de produs.

Primele iterații pot folosi LLM-urile intensiv fără să pretindă că acestea sunt suverani epistemici. Rolul lor economic esențial este traducerea între proză, grafuri, reguli, interogări și explicații pentru oameni. Ele pot transforma un articol în claims candidate, pot formula întrebări despre dovezi lipsă, pot genera termeni adversariali de căutare, pot compara formularea unei valori cu o decizie de design și pot explica de ce a eșuat o verificare deterministă. Promovarea unui claim, autorizarea unei acțiuni sau modificarea unei Research Constitution necesită însă un alt eveniment și o autoritate responsabilă.

7.2. Protocolul unei judecăți hibride calibrate

O judecată hibridă bine calibrată începe înaintea promptului. Sistemul definește obiectul, criteriul, dovezile admisibile, costul erorii și calea de apel. În lipsa acestor elemente, un model va umple golurile cu convențiile întâlnite în training. Răspunsul poate părea matur, dar nu știm ce a judecat. Protocolul trebuie să transforme „review this project” într-un set de sarcini cu statut și verificatoare distincte.

Primul pas este evidence-first evaluation. Judge-ul nu primește numai articolul sau propunerea, ci un packet structurat: claims, surse, rezultate brute, provenance, politici și întrebări. Atunci când informația lipsește, absența este marcată. Modelul nu este încurajat să o completeze. În cazul noutății, packet-ul include vecinii recuperați; în cazul performanței, baseline-urile și protocolul; în cazul valorii, stakeholderii și scenariile. Verdictul este legat de fiecare element.

Al doilea pas este rubric decomposition. Criterii precum „rigoare”, „impact” sau „alinie la valori” sunt prea largi. Ele se descompun în întrebări observabile și în judecăți contestabile. Rigoarea poate include claritatea claim-ului, adecvarea metodei, independența testului și raportarea incertitudinii. Impactul poate include amplitudine, probabilitate, distribuție, reversibilitate și cost de oportunitate. Modelul evaluează separat și nu are voie să compenseze o eroare fatală cu stilul general.

Al treilea pas este controlul prezentării. Position bias se testează prin inversarea ordinii; verbosity bias prin versiuni normalizate; autoritatea instituțională prin anonimizare; self-preference prin folosirea generatorilor diferiți; sensibilitatea la framing prin reformulări echivalente. Dacă verdictul se schimbă, sistemul reduce încrederea sau escaladează. Aceste proceduri costă tokeni, dar pot fi aplicate numai claims-urilor decisive.

Al patrulea pas este panelul cu diversitate măsurată. Un panel nu înseamnă cinci personas ale aceluiași model. Membrii pot folosi familii diferite, retrieval-uri independente, tools distincte și specializări. Ei produc mai întâi evaluări izolate. Apoi un agregator compară nu doar scorurile, ci motivele și evidențele. Două voturi bazate pe aceeași sursă sunt mai puțin independente decât două voturi care au găsit failure modes diferite.

PROPUNERE DE CERCETARE

Consensus Independence Auditor estimează „effective votes”. Folosește performanța istorică pe cazuri cu erori cunoscute, overlap-ul surselor, similitudinea justificărilor și dependențele de model. Nu pretinde o estimare exactă a corelației pe idei noi; oferă un warning când unanimitatea este produsă de aceeași cale. Rezultatul poate

spune: nouă agenți au votat, dar există aproximativ două familii independente de evidență.

Al cincilea pas este verificarea prin tools. Un LLM judge care observă o ecuație poate cere unui CAS să verifice transformarea; pentru cod, rulează hidden tests și mutation testing; pentru o teoremă, cheamă proof assistant-ul; pentru statistici, reconstruiește analiza; pentru policy, citează regula autorizată. Tool-ul nu rezolvă relevanța, dar elimină clase de erori. Verdictul păstrează distincția dintre ceea ce a fost calculat și ceea ce a fost interpretat.

Al șaselea pas este calibrarea pe oameni și cazuri. Un set de gold cases trebuie construit de experți și actualizat. Pentru judecăți axiologice, „gold” nu este un label unic; poate fi un set de argumente, poziții și red lines acceptate procedural. Modelul este evaluat pentru acoperirea obiectiilor și fidelitatea reprezentării. În domenii cu dezacord legitim, acordul perfect cu majoritatea poate fi un semn de netezire, nu de calitate.

Al șaptelea pas este decizia cu incertitudine. Sistemul produce intervale, scenarii și stări precum „supported”, „contested”, „insufficient evidence”. Un scor agregat poate fi folosit pentru prioritizare, dar nu ascunde componentele. Dacă o opțiune are impact potențial mare și risc sever cu probabilitate necunoscută, media poate fi înșelătoare. Raportul păstrează tails și condițiile care ar schimba recomandarea.

Al optulea pas este human adjudication. Omul nu este introdus simbolic la final pentru a apăsa „approve”. El primește punctele de divergență și dovezile relevante. Interfața îi permite să modifice presupuneri și să vadă consecințele. Decizia și motivul sunt înregistrate, iar sistemul poate învăța despre erorile sale fără a transforma fiecare override într-un label de training. Uneori omul are o informație tacită; alteori este influențat de interes. Ambele posibilități rămân auditate.

EVIDENȚĂ PUBLICATĂ

Studiile asupra automation bias și reliance arată că designul interfeței și explicațiilor modifică folosirea recomandărilor [30-33]. Explicațiile pot crește încrederea chiar și când nu cresc corectitudinea [29]. Sursele și evidențierea inconsistențelor pot ajuta utilizatorii să respingă răspunsuri greșite [32]. De aceea, protocolul nu trebuie evaluat doar offline, ca accuracy a modelului. El este un sistem om-Al al cărui output relevant este calitatea deciziei colective.

Pentru Epistemic Guardian, o decizie tipică ar putea trece astfel. LLM-ul extrage un claim de superioritate. Prior-Art Adversary și Baseline Planner găsesc comparații. Experiment executor rulează replicări. Un panel evaluează scope-ul și statisticile. State machine verifică dacă

promotion rule este satisfăcută. Cercetătorul decide cum formulează concluzia. Fiecare componentă are autoritate limitată.

Pentru Axiologic Guardian, procesul este analog, dar sursele se schimbă. LLM-ul extrage valorile și stakeholderii. Policy engine verifică norme. Impact model estimează consecințe. Deliberation module păstrează poziții. MCDA explorează scenariii. Oamenii afectabili și comitetul decid. Sistemul poate recomanda o opțiune robustă, dar precizează ce judecăți de valoare o susțin.

SINTEZĂ ȘI INFERENȚĂ

Această arhitectură este mai costisitoare decât un singur prompt. Dar costul trebuie comparat cu miza, nu cu chat-ul. Nu toate deciziile necesită protocolul complet. Guardian-ul folosește risk tiers. O reformulare internă primește verificare ușoară; o afirmație publică majoră primește audit; un experiment pe oameni sau o tehnologie dual-use primește deliberare și escaladare. Proportionalitatea este condiția adoptării.

Un protocol bun trebuie să poată eșua transparent. Poate raporta că nu există evaluator calibrat, că evidența este insuficientă sau că valorile sunt în conflict. Acest rezultat este util. Alternativa actuală nu este certitudinea, ci adesea o decizie luată sub presiune și justificată ulterior. Guardian-ul nu elimină incertitudinea; o face gestionabilă.

LLM-ul poate ajuta rezonabil la	Nu trebuie tratat singur ca autoritate pentru
Extragerea claims, valorilor, stakeholderilor și contradicțiilor	Adevărul unei afirmații fără verificador sau date independente
Aplicarea unei rubrici înguste și compararea perechilor	Noutatea globală fără căutare și expertiză
Generarea obiecțiilor, scenariilor și testelor candidate	Corectitudinea unei demonstrații fără kernel și enunț verificat
Triage și prioritizarea elementelor pentru review	Decizii morale universale ori reprezentarea „umanității”
Explicarea provenance și a obligațiilor deschise	Autorizarea automată a cercetării cu miză ridicată

Un protocol calibrat ar trebui implementat ca o succesiune de transformări tipate, nu ca un singur prompt de review. Prima transformare convertește obiectul de cercetare într-un pachet de dovezi ale cărui omisiuni sunt explicite. A doua descompune judecata solicitată în întrebări locale. A treia trimite fiecare întrebare către cel mai puternic canal disponibil: retrieval pentru prior art, execuție pentru afirmații

compuționale, proof assistant pentru derivări formale, software statistic pentru estimanți și incertitudine, surse autorizate pentru reguli instituționale și deliberare cu stakeholderii pentru priorități sociale contestate. LLM-ul coordonează și interpretează aceste canale; nu le șterge diferențele epistemice.

Descompunerea prin checklist merită atenție specială deoarece oferă un produs timpuriu realist. Un checklist științific nu trebuie să fie un formular administrativ static. El este generat din tipul claim-ului, profilul domeniului, nivelul consecinței și Research Constitution curentă. Un claim causal invocă verificări privind identificarea, mecanismele alternative, măsurarea și transferul. Un claim de performanță invocă baseline-uri, leakage, variație, resurse și adecvarea task-ului. Un claim matematic invocă identitatea enunțului, ipotezele, limita formalizării, statutul verificării de kernel și relevanța pentru problema originală. Fiecare răspuns se leagă de o dovadă, iar elementele nerezolvate rămân vizibile în loc să fie completate din plauzibilitate lingvistică.

Meta-evaluarea este la fel de importantă. Sistemul repetă judecățile decisive după inversarea ordinii opțiunilor, normalizarea lungimii, anonimizarea semnalelor de prestigiu, reformulări echivalente și, când costul permite, folosirea unei alte familii de modele. El măsoară nu doar acordul, ci și corelația erorilor și diversitatea dovezilor. Un panel care citează unanim același rezumat greșit are o singură cale epistemică efectivă. Un panel mai mic, ai cărui membri folosesc surse independente, execuție și verificări formale, poate fi mai puternic. Consensul devine astfel un obiect de auditat, nu un substitut pentru dovadă.

Protocolul trebuie să producă un verdict delimitat. El precizează obiectul judecat, dovezile admisibile, rubrica, configurația evaluatorilor, sensibilitățile detectate, defeaters nerezolvați și autoritatea rezultatului. „Metoda este susținută pe acest benchmark, în acest mediu” este o formulare legitimă. „Arhitectura este validată științific” poate să nu fie. O funcție centrală a Guardian-ului este să mențină domeniul verdictului mai îngust decât tentația retorică a manuscrisului.

Punctul de decizie umană este plasat acolo unde mașina întâlnește un value pivot, un conflict factual nerezolvat, incertitudine cu consecințe mari sau lipsa unui evaluator calibrat. Interfața prezintă dezacordul decisiv înaintea recomandării, permite modificarea presupunerilor și păstrează cel mai puternic contraargument. Supravegherea umană este semnificativă numai dacă reviewer-ul are capacitate epistemică, spațiu cognitiv, autoritate decizională și posibilitatea efectivă de a interveni [161]. Protocolul eșuează dacă doar transferă responsabilitatea către o persoană care nu dispune de aceste condiții.

7.3. Arhitectura neuro-simbolică a sistemului dual

Arhitectura comună a celor două Guardians poate fi imaginată ca un „dual control plane” pentru automatizarea cercetării. Planul epistemic întreabă ce este adevărat, cât de bine este susținut și ce test ar discrimina. Planul axiologic întreabă ce merită urmărit, pentru cine, cu ce limite și ce consecințe. Agenții generativi propun conținut și acțiuni. Guardians nu execută pur și simplu aceleași prompts cu o personalitate critică; mențin stări, reguli, proveniență și căi de escaladare independente de narațiunea curentă.

Nucleul comun este Research Decision Graph. El conectează Problem, Claim, Evidence, Assumption, Experiment, Artifact, Stakeholder, Value, Norm, Impact, Option și Decision. Graful nu afirmă că toate acestea sunt reducibile la aceeași logică. Dimpotrivă, tipurile delimitează competența. Un edge „supports” are sens epistemic; „promotes value” are sens axiologic; „authorized by” are sens instituțional. Operațiile între ele sunt explicit definite.

Deasupra grafului funcționează două compilatoare. Epistemic Compiler transformă documentele și acțiunile în obligations de verificare. Axiologic Compiler transformă deciziile în obligations de valoare și participare. Ambele folosesc LLM-uri pentru semantic parsing și generare, dar validează prin scheme și tools. Compiler-ele pot emite errors, warnings și open questions; nu numai prose.

Un Policy and Constitution Registry păstrează reguli la trei niveluri. Personal Constitution este controlată de cercetător. Institutional Constitution conține politici și misiune. Public Constitution conține legi, drepturi, norme profesionale și principii adoptate prin proces legitim. Conflictele sunt reprezentate, nu rezolvate prin ordinea fișierelor. Fiecare regulă are jurisdiction, prioritate, excepții și autoritate.

Evidence Bus conectează surse primare, baze bibliografice, executori, laboratoare, simulatoare și sisteme de proveniență. Value Bus conectează consultation records, stakeholder input, policy documents, impact data și scenarii. Ambele au access control. Un proiect sensibil poate păstra datele local și publica doar claims sau hashes. Guardians trebuie să funcționeze într-un mediu federat, nu într-o bază centrală care acumulează toate ideile și valorile.

PROPUNERE DE CERCETARE

Arhitectura include agenți specializați, dar aceștia sunt interschimbabili: Problem Contract Agent; Claim Extractor; Prior-Art Adversary;

Architecture Canonicalizer; Math-Washing Auditor; Physical Feasibility Checker; Baseline Planner; Test Oracle Auditor; Falsifier; Reproducibility Agent; Stakeholder Mapper; Mission Alignment Agent; Humanity Value Assessor; Dual-Use Analyst; Deliberation Facilitator; Judge Panel Coordinator. Fiecare expune un API și produce artefacte tipate, nu doar mesaje.

Orchestration layer selectează agenții în funcție de claim și risc. Pentru o teoremă, activează formalization și proof checking. Pentru un sistem ML, activează leakage, baseline, resource și replication. Pentru o direcție biomedicală, activează causal evidence, ethics, dual use și stakeholder modules. Arhitectura nu promite universalitate printr-un singur workflow; promite extensibilitate prin contracte.

State machines guvernează două tipuri de promovare. Epistemic promotion mută o afirmație de la generată la specificată, testată, susținută și replicată. Axiologic authorization mută o opțiune de la explorată la evaluată, consultată, aprobată condiționat și monitorizată. O idee poate fi epistemic promițătoare, dar axiologic neautorizată pentru deployment. O direcție poate fi axiologic valoroasă, dar epistemic prematură. Sistemul păstrează matricea.

Human control plane oferă interfețe diferite. Cercetătorul vede claims, valori personale și obligații. Principal investigator vede dependențe și decizii de echipă. Comitetul vede dosare și dissent. Instituția vede agregate și risc de portofoliu. Publicul vede partea dezvăluită și raționamentul relevant. Nicio interfață nu trebuie să ofere mai multă putere decât rolul justifică.

Assurance case este output-ul instituțional de nivel înalt. Inspirat din safety engineering, el formulează o concluzie precum „proiectul poate trece în pilot controlat” și o descompune în sub-claims despre evidență, siguranță, valori, governance și monitorizare, fiecare legată de suport [139]. Assurance case nu garantează adevărul; face argumentul auditabil și actualizabil. Dacă o premisă cade, concluzia este marcată.

EVIDENȚĂ PUBLICATĂ

Standardele de proveniență și research objects susțin reprezentarea traselor [128, 140]. IEEE 7000 și Value Sensitive Design susțin trasabilitatea valorilor către cerințe [104, 107]. Argumentation frameworks și logici normative oferă mecanisme pentru atacuri, priorități și excepții [77, 147, 148]. Lucrările agentice din 2026 arată apariția evidence graphs, workflow graphs și agent-native research artifacts [141-145]. Arhitectura duală rămâne însă o sinteză propusă; nu există dovezi că ansamblul poate ghida sigur instituții.

O problemă deschisă este învățarea. Sistemul trebuie să învețe din rezultate fără a rescrie standardele normative implicit. Modelele de extragere și ranking pot fi actualizate pe feedback. Promotion rules și constituțiile se schimbă numai prin proceduri autorizate. Separarea dintre „model update” și „norm update” este critică. Altfel, o serie de decizii oportuniste poate deveni noua valoare a instituției prin gradient descent.

O altă problemă este atacul strategic. Autorii pot formula claims pentru a evita porțile, pot fragmenta riscurile sau pot optimiza dosarul. Guardian-ul trebuie auditat adversarial. Canonicalizer-ul normalizează limbajul; provenance detectează duplicarea; institutional console caută concentrarea; iar random review verifică proiectele cu scor bun. Niciun sistem de governance nu este imun la gaming, mai ales când devine legat de finanțare.

Scalarea trebuie să fie graduală. MVP-ul nu construiește o constituție a umanității. El implementează claim graph, mission alignment și dosare cu stakeholderi pentru un domeniu. Versiunea următoare adaugă tool verification și MCDA. Autoritatea rămâne consultativă. Numai dacă studiile arată câștiguri reale, instituțiile pot folosi outputs în porți formale. Chiar atunci, dreptul la apel și audit extern rămâne.

SINTEZĂ ȘI INFERENȚĂ

Valoarea arhitecturii nu este că face AI-ul moral sau știința infailibilă. Ea separă două întrebări pe care organizațiile le amestecă: „putem?” și „ar trebui?”. Apoi le conectează fără a le reduce. Un proiect bun trebuie să supraviețuiască atât contactului cu realitatea, cât și contactului cu valorile celor pe care îi afectează. Dual Guardian este o încercare de a transforma această cerință dintr-o frază într-o infrastructură testabilă.

În Executable Science, judecata devine un serviciu inspectabil atașat unei stări de cercetare versionate. Verdictul nu mai este proză fără ancoră. Este un eveniment semnat sau atribuit în alt mod, care numește versiunea obiectului, configurația evaluatorului, pachetul de dovezi, constituția, instrumentele și utilizarea permisă în aval. O corecție ulterioară poate retrograda verdictul fără să-i șteargă rolul istoric. Un update al modelului nu rescrie în tăcere o decizie anterioară; produce un nou eveniment de evaluare ce poate fi comparat cu cel vechi.

Arhitectura creează o separare utilă între judecata semantică și autoritatea asupra stării. Stratul semantic poate fi înlocuit pe măsură ce modelele se îmbunătățesc. Stratul simbolic și procedural păstrează stările claims-urilor, regulile, legăturile cu dovezile, permisiunile, apelurile și auditul. Sistemele formale nu rezolvă interpretarea, iar LLM-urile nu rezolvă validitatea. Compoziția lor este valoroasă deoarece fiecare

limitează un alt tip de eșec. Sistemul poate arăta că un model a interpretat un pasaj drept claim cauzal, că un om a confirmat interpretarea, că un verificador statistic a respins argumentul de identificare și că, în consecință, claim-ul a rămas provizoriu.

Guardians ar trebui să devină treptat componente independente ale ecosistemului, nu funcții ascunse ale unei singure aplicații de cercetare. Un laborator poate folosi un Epistemic Guardian împreună cu mai mulți agenți de cercetare. Un publisher poate rula un Guardian extern asupra unui pachet trimis spre publicare. O instituție de finanțare poate folosi un Axiologic Guardian configurat prin misiunea sa publică, în timp ce aplicanții își păstrează propriile profiluri. Un consorțiu poate compara rapoarte produse de mai mulți furnizori. Stările interoperabile ale claims-urilor, pachetele de dovezi, evaluator cards, profilurile constituționale și înregistrările de apel împiedică transformarea unui furnizor în oracolul final al legitimității științifice.

Independența trebuie limitată prin guvernanță. Un serviciu Guardian poate dobândi o influență enormă chiar fără execuție autonomă dacă instituțiile leagă rapoartele sale de finanțare, publicare sau carieră. De aceea are nevoie de scop publicat, rate de eroare măsurate, politici versionate, declararea conflictelor de interese, audit extern și cale de contestare. Sistemul trebuie să fie mai ușor de înlocuit decât conștiința instituției. Obiectivul cercetării nu este construirea unui judecător infailibil, ci transformarea judecății însăși într-o componentă vizibilă, revizibilă și testabilă a științei.

Capitolul 8. Un program de cercetare care poate eșua

8.1. Ipoteze, benchmarkuri și experimente

Un program de cercetare despre autoamăgire trebuie să înceapă prin a face propriile afirmații vulnerabile. Teza generală — că AI poate mări diferența dintre progresul perceput și progresul verificat — este prea largă pentru un singur experiment. Trebuie descompusă în efecte observabile, iar rezultatele negative trebuie să poată modifica teoria. Este posibil ca experții să fie puțin sensibili la elaborare, ca agenții independenți să se autocorecteze suficient sau ca overhead-ul instrumentelor propuse să depășească beneficiul. Un program credibil trebuie să accepte aceste rezultate.

Prima ipoteză este „More Words Than Reality effect”. Ea spune că elaborarea epistemic irelevantă crește evaluarea unei contribuții fără să-i schimbe conținutul verificabil. Experimentul pornește de la artefacte tehnice cu statut cunoscut: idei valide, idei triviale și idei cu erori subtile. Fiecare este prezentat în mai multe variante. Versiunea minimală descrie problema, mecanismul și rezultatul. Versiunea elaborată adaugă jargon, acronym, diagramă și explicații mai lungi, dar nicio predicție sau probă. O versiune formalizată adaugă ecuații echivalente cu textul. Evaluatori blind — cercetători, doctoranzi și non-experti — acordă scoruri de noutate, rigoare, probabilitate de succes și încredere. Separat, execută taskuri de discriminare: găsesc eroarea, identifică baseline-ul sau reconstruiesc mecanismul.

Ipoteza este susținută dacă elaborarea crește scorurile de impresie fără să crească detectarea adevărului și, mai ales, dacă mărește încrederea în artefactele greșite. Este infirmată sau restrânsă dacă experții nu sunt influențați, dacă elaborarea îmbunătățește semnificativ discriminarea sau dacă efectul apare doar la non-experti. Studiul trebuie preregistrat, materialele trebuie publicate, iar formele trebuie controlate pentru lizibilitate. Nu trebuie să confundăm o prezentare mai clară cu ornamentul; claritatea poate fi epistemic relevantă.

A doua ipoteză este „architecture laundering”. Luăm arhitecturi cunoscute și le transformăm prin redenumire, redesenare și decompoziție, fără schimbare funcțională. Luăm și arhitecturi realmente distincte și le descriem auster, fără branding. Evaluatorii și LLM-judges estimează noutatea, apoi primesc o reprezentare canonicalizată. Măsurăm cât scade

scorul și dacă Architecture Canonicalizer îmbunătățește precizia. Un rezultat important ar fi asimetria: dacă stilul poate face vechiul să pară nou, dar eliminarea stilului face noul să pară trivial, evaluarea comunității este sensibilă la semnale editoriale.

Pentru a evita circularitatea, setul trebuie construit de experți și verificat prin citation chains. Unele perechi vor fi ambigue, iar această ambiguitate este utilă. Nu există un oracol perfect al noutății. Putem însă folosi cazuri controlate, în care una dintre versiuni este generată mecanic din aceeași arhitectură, și cazuri istorice cu relații clare. Experimentul testează susceptibilitatea la aparență, nu rezolvă filosofia noutății.

A treia ipoteză privește co-generated validation. În mai multe domenii, comparăm patru condiții: soluția și testele sunt generate în aceeași sesiune; testele sunt generate de o instanță separată a aceluiași model; testele sunt generate de alt model fără acces la raționamentul soluției; testele provin din oracole externe sau experți și rămân ascunse. Sarcinile includ patch-uri software, transformări de date, demonstrații de proprietăți și analize statistice cu capcane cunoscute. Introducem defecte deliberate care reflectă schimbarea specificației, leakage și edge cases.

Măsura principală este false validation rate: proporția soluțiilor greșite declarate valide. Măsurăm și mutation score, coverage semantic și calibrarea evaluatorului. Ipoteza este că independența de specificație și oracolele externe reduc false validation mai mult decât simpla separare a prompturilor. Dacă două instanțe ale aceluiași model performează la fel de bine ca experții și hidden tests pe domenii relevante, teza despre corelație trebuie restrânsă. Este un rezultat posibil și valoros.

A patra ipoteză este pseudo-consensus. Construim panouri cu cinci instanțe ale aceluiași model, cinci modele din familii diferite, modele cu roluri diferite, modele cu tool access distinct și experți umani. Le cerem să evalueze claims cu adevăr cunoscut și artefacte adversariale. Nu comparăm doar acuratețea majorității, ci corelația erorilor și dovezile distincte produse. Consensus Independence Auditor estimează profilul înainte de verdict. Testul este dacă profilul prezice când majoritatea va fi înșelătoare.

Un rezultat negativ ar fi important: dacă numărul de modele și rolurile sunt suficiente pentru calibrare, componenta de independență poate fi simplificată. Un rezultat pozitiv ar arăta că tool-anchored diversity contează mai mult decât persona diversity. De asemenea, putem testa anchoring-ul: agenții evaluează independent înainte de a vedea răspunsurile celorlalți versus deliberare deschisă. Aceasta conectează programul cu literatura despre wisdom of crowds și groupthink.

A cincea ipoteză este researcher overconfidence. Echipa mici lucrează la probleme cu dificultate controlată, unele cu AI generativ standard, altele cu AI plus Epistemic Guardian Stack, altele fără AI. Problemele pot fi mini-proiecte ML, replicări sau formalizări care conțin capcane. Măsurăm progresul perceput zilnic, statutul claims, numărul de artefacte, erorile găsite independent și timpul până la prima invalidare decisivă. Evaluatori blind apreciază rezultatul final.

Designul trebuie să evite concluzii despre competența oamenilor. Interesul este diferența dintre condiții și mecanisme. AI standard poate crește atât progresul real, cât și încrederea; reality gap-ul poate rămâne neschimbat. Sau poate crește încrederea mai repede decât rezultatul. Stack-ul poate reduce gap-ul, dar cu cost de timp. Rezultatul ideal nu este încredere mică, ci calibrare și productivitate verificată.

A șasea ipoteză testează direct Epistemic Guardian. Participanții revizuesc manuscrise și proiecte cu erori de promovare: asocierea descrisă drept cauzalitate, benchmarkul descris drept generalizare, formalizarea unei teoreme slăbite, teste co-generate și prior art ascuns prin terminologie. Un grup folosește un editor obișnuit, altul vede doar explicații LLM, iar al treilea folosește claim graph, stări și warnings. Măsurăm detectarea, false alarms, timp și înțelegerea ulterioară. Instrumentul este util numai dacă îmbunătățește deciziile, nu doar dacă extrage corect claims.

A șaptea ipoteză privește Falsifier-ul: poate reduce time-to-disproof fără să omoare disproporționat ideile bune? Construim un corpus de proiecte istorice cu motive cunoscute de eșec și contribuții valide. Sistemul propune teste ordonate după cost și expected information gain. Experții evaluează relevanța, apoi testele sunt executate unde posibil. Comparăm cu critici LLM generice și cu planificarea umană. O metrică bidimensională este necesară: viteza de găsire a erorilor și rata de false kill.

Programul trebuie să includă replicări multi-site și domenii variate. Un efect în NLP nu garantează un efect în biologie, iar experții în formal methods pot răspunde diferit de cei din științe sociale. Materialele trebuie versionate, iar analizele exploratorii separate de cele confirmatorii. Ironia ar fi intolerabilă dacă un studiu despre self-validation ar selecta post hoc varianta favorabilă.

Etica experimentelor cere debriefing, mai ales când participanții lucrează cu artefacte concepute să-i inducă în eroare. Nu trebuie publicate clasamente individuale de „credulitate”. Scopul este proiectarea sistemului, nu diagnosticarea personalității. Echipa trebuie informată că unele tasks conțin capcane și că rezultatele nu evaluează valoarea lor ca cercetători.

Acest set de experimente poate produce o teorie mai nuanțată. Poate că problema principală nu este verbositatea, ci lipsa de expertiză. Poate că proof assistants elimină aproape complet iluzia în matematică, iar gap-ul rămâne doar la formalizare. Poate că agent diversity este suficientă în cod, dar nu în novelty. Programul nu urmărește să confirme un slogan, ci să identifice unde aparența se decuplează de verificare și ce mecanism o reatașează.

Programul experimental trebuie extins dincolo de iluziile epistemice. Axiologic Guardian poate eșua prin impunerea unei perspective, prin rationalizarea deciziilor instituției, prin pierderea vocilor minoritare sau prin generarea unor dosare impresionante care nu schimbă nimic. Aceste failure modes trebuie transformate în ipoteze falsificabile.

„Axiologic Drift Study” urmărește proiecte pe durata a douăsprezece până la douăzeci și patru de luni. La început, echipele declară valori, beneficiari, red lines și condiții de revizuire. Unele folosesc un jurnal obișnuit, altele Value Vault și Decision-to-Value Trace. Evaluatori independenți compară scopul inițial, deciziile, justificările și rezultatele. Ipoteza este că Guardian-ul detectează mai devreme deriva neintenționată fără a împiedica revizuirea legitimă. Rezultatul negativ ar fi overhead ridicat, conformism sau raționalizare mai sofisticată.

„Pluralism Stress Test” oferă aceleași decizii constituției și stakeholderi diferiți. Sistemul trebuie să păstreze conflictul și să identifice value pivots, nu să producă același răspuns generic. Se măsoară fidelity față de poziții, omisiunile, reprezentarea minorităților și sensibilitatea. Un LLM simplu poate netezi diferențele; arhitectura argumentativă ar trebui să le păstreze.

„Humanity Value Dossier Trial” compară comisii care decid asupra unor proiecte folosind documente standard, un raport LLM și dosarul hibrid. Cazurile includ beneficii distribuite inegal, dual use și incertitudine mare. Măsurăm efecte descoperite, calibrarea, diversitatea opțiunilor, timpul și calitatea justificării. Nu există verdict moral unic; gold standard-ul este un panel procedural și un set de aspecte decisive.

„Institutional Gaming Experiment” testează dacă echipele pot optimiza pentru Guardian. Participanții primesc stimulente să obțină aprobare pentru proiecte cu slăbiciuni. Ei pot folosi jargon moral, stakeholderi nominali și metrici selective. Sistemul trebuie să detecteze evidence gaps, metric capture și conflictul dintre documente și acțiuni. Red teams independente construiesc atacuri noi.

„Autonomy and Reliance Study” măsoară dacă recomandările reduc independența judecății. Participanții văd rapoarte cu grade diferite de autoritate și explicație. Se testează capacitatea de a contesta recomandări greșite, memorarea motivelor și sentimentul de control. Un Guardian

corect dar coercitiv poate fi instituțional inacceptabil. Meaningful human control este un obiectiv măsurabil, nu o frază [131, 132].

Cele două programe se întâlnesc în „Dual Guardian Field Trial”. Echipe reale folosesc research IDE-ul pe proiecte ML, software, quantum resources sau biomedicină. Unele primesc doar asistență generativă; altele Epistemic Guardian; altele ambii Guardians. Măsurile includ verified discovery yield, time-to-disproof, false kill, conflicte axiologice detectate, modificări de design, overhead și autonomie. Un beneficiu epistemic poate veni cu cost creativ; un beneficiu axiologic poate veni cu întârziere. Analiza trebuie să păstreze trade-off-urile.

PROPUNERE DE CERCETARE

Benchmarkurile nu trebuie să fie doar colecții statice. RealityGap Bench include medii interactive în care agentul poate cere date, rula cod, căuta surse și propune experimente. ValueDilemma Bench include cazuri cu stakeholderi care răspund și informații care apar în timp. InstitutionBench include politici contradictorii, stimulente și tentative de gaming. Evaluarea finală privește traseul, nu doar textul.

Criteriul de continuare al programului este sever: un modul rămâne numai dacă îmbunătățește decizia sau reduce o eroare relevantă la cost acceptabil. Extractorul de claims nu este valoros doar pentru F1 mare dacă utilizatorii nu găsesc mai repede probleme. Axiologic Dossier nu este valoros dacă pare profund, dar nu schimbă designul și nu reprezintă stakeholderii. Sistemul despre „mai multe cuvinte decât realitate” trebuie să reziste tentației de a se valida prin propriile rapoarte.

Experiment	Rezultatul relevant și riscul de fals pozitiv
More Words Than Reality	Măsoară dacă elaborarea crește impresia mai mult decât discriminarea; controlează claritatea reală.
Architecture laundering	Testează sensibilitatea la redenumire și efectul canonicalizării; evită un oracol simplist al noutății.
Formalism without constraint	Separă ecuațiile care produc predicții de cele ornamentale; protejează matematica pură.
Co-generated validation	Compară oracole comune, agenți separați, hidden tests și experți.
Physical feasibility gap	Compară claims teoretice cu resource contracts și profiling end-to-end.

Experiment	Rezultatul relevant și riscul de fals pozitiv
Axiologic drift	Măsoară detectarea schimbării neintenționate fără a penaliza învățarea legitimă.
Pluralism stress test	Verifică păstrarea dezacordului și a minorităților, nu acordul cu un label unic.
Institutional gaming	Testează jargonul moral, metric capture și optimizarea dosarelor pentru aprobare.

Programul extins poate fi organizat în șase fronturi de cercetare conectate. Primul întreabă dacă Research State explicită îmbunătățește memoria, tratarea contradicțiilor, reconstruirea provenienței și revizuirea credințelor dincolo de agenți puternici cu retrieval. Al doilea întreabă dacă monitorii de proces pot detecta evidence non-uptake, assumption laundering, rescriere post-hoc, portofolii exclusiv confirmatorii și promovarea nejustificată a claims-urilor. Al treilea întreabă dacă reprezentarea și compararea acțiunilor candidate îmbunătățește alegerea experimentelor discriminante. Al patrulea testează dacă reprezentările plurale ale valorii fac prioritizarea cercetării mai fidelă și mai contestabilă decât scorurile ponderate sau deliberarea liberă. Al cincilea studiază fiabilitatea evaluatorilor și supravegherea umană semnificativă. Al șaselea studiază efectele instituționale: gaming, birocratizare, omogenizarea portofoliului, confidențialitate, stimulente și apel.

Front de cercetare	Întrebarea falsificabilă centrală
Stare epistemică executabilă	O stare versionată claim–hypothesis–evidence–action îmbunătățește reconstruirea și actualizarea justificată față de istoricul conversației și retrieval?
Raționament științific orientat spre proces	Monitorii locali detectează defecte decisive de raționament mai fiabil și mai util decât critica holistică a unui LLM?
Selecția acțiunilor de cercetare	Sistemul poate alege teste, căutări, replicări, pivotări și opriri care reduc regretul pe o traiectorie?
Axiologie plurală executabilă	Constrângerile, ordonările parțiale, argumentele și sensibilitatea expun conflicte reale de valoare fără a le comprima într-un singur scor?
Evaluare calibrată și oversight	Evaluatorii eterogeni și controlul uman îmbunătățesc deciziile reducând circularitatea și automation bias?

Front de cercetare	Întrebarea falsificabilă centrală
Învățare instituțională	Organizațiile asistate de Guardians corectează mai devreme, păstrează diversitatea și alocă mai bine efortul de verificare fără a deveni birocrății de supraveghere?

Aceste fronturi nu trebuie contopite într-o singură demonstrație eroică. Fiecare are un baseline puternic și un criteriu de oprire. Starea structurată trebuie să depășească retrieval-ul mai bun, nu un chatbot amnezic. Falsifier-ul trebuie să depășească un critic generic fără o rată inacceptabilă de false kill. Structura axiologică trebuie să schimbe calitatea deciziei, nu doar să mărească documentația. Piloții instituționali trebuie să măsoare creativitatea, autonomia, povara și dezacordul, nu numai reducerea erorilor. O componentă care eșuează poate fi eliminată fără ca întregul program să fie abandonat.

Programul are nevoie și de o teorie a transferului. Machine learning-ul computațional este un prim domeniu potrivit deoarece codul, mediile și testele ascunse oferă oracole relativ puternice la cost gestionabil. Matematica formală oferă verificare de kernel, dar mută incertitudinea cea mai grea către corectitudinea și relevanța formalizării. Calculul cuantic și fizica computațională testează realismul resurselor și legătura dintre model și arhitectura fizică. Biomedicina adaugă inferență cauzală, confidențialitate, siguranță, drepturile participanților și rezultate cu latență mare. Științele sociale testează validitatea constructelor, pluralitatea stakeholderilor și limitele interpretării automate. Generalitatea trebuie câștigată prin asemenea contraste, nu declarată după un singur benchmark.

8.2. Metrici, piloți și traseul de dezvoltare

Benchmarkurile actuale măsoară adesea output-ul final: răspuns corect, test trecut, scor de preferință, issue rezolvat. Pentru iluzia de descoperire trebuie măsurat traseul și diferența dintre impresie și rezultat. RealityGap Bench este propus ca o familie de benchmarkuri, nu un leaderboard unic. Fiecare task conține o pretenție plauzibilă, artefacte intermediare și un set de porți independente care dezvăluie statutul.

Unitatea de bază este „claim package”. Pachetul include Problem Contract, descrierea contribuției, cod sau formalism unde există, testele autorului, sursele, review-ul și verdictul inițial. Unele pachete sunt valide, altele conțin capcane: prior art redenumit, baseline slab, leakage, metrică nepotrivită, test oracle defect, formalizare slăbită, causal story fără

identificare, multi-agent consensus corelat sau reproducere doar aparentă. Capcanele trebuie construite din cazuri reale și validate de experți.

Benchmarkul are domenii diferite. ML Architecture track evaluează noutate, baseline și ablation. Software track folosește issue-uri și oracole ascunse, extinzând ideea SWE-bench [44]. Formal Mathematics track include demonstrații valide ale enunțurilor modificate, placeholders și counterexamples. Scientific Claims track folosește literatură și claims cu suport, contradicție sau extrapolare, inspirat de SciFact [80]. Experimental Design track conține leakage, multiple testing și validitate externă. Peer Review track cere identificarea promovărilor greșite, nu scrierea unui review generic.

Evaluarea se desfășoară în gates. Gate 0 măsoară impresia: evaluatorii acordă scoruri blind de noutate, rigoare și probabilitate de succes. Gate 1 verifică specificația și identitatea problemei. Gate 2 caută prior art. Gate 3 verifică coerența, codul și formalismul. Gate 4 aplică baseline-uri și teste adverse. Gate 5 folosește date externe sau replicare. Nu toate tracks ajung la Gate 5, dar structura permite compararea curbelor.

PROPUNERE DE CERCETARE

Perceived Contribution Score, P , agregă evaluările inițiale după calibrarea evaluatorilor. Verified Contribution Score, V , nu este o judecată estetică, ci o funcție transparentă a porților trecute și a scope-ului. Reality Gap poate fi exprimat simplu ca $RG = P - V$ după normalizare. Formula nu pretinde să măsoare adevărul metafizic. Ea operationalizează discrepanța dintre impresie și un protocol de verificare declarat. Un RG pozitiv mare indică supraevaluare; un RG negativ poate indica o contribuție auster prezentată, dar robustă.

V nu trebuie redus la o medie arbitrară. Pentru fiecare claim type există o rubrică. Un FormalProofClaim poate primi credit maxim pentru derivare doar dacă statement audit-ul trece. Un PerformanceClaim cere baseline și uncertainty. Un NoveltyClaim primește un interval în funcție de acoperirea prior-art-ului, nu certitudine. Benchmarkul publică profilul și scorul agregat numai ca sumar. Cercetătorii trebuie să poată vedea exact ce poartă a eșuat.

Claim Survival Curve este a doua metrică majoră. Dacă pornim cu N_0 idei, măsurăm N_1 după specificare, N_2 după prior art, N_3 după feasibility, N_4 după implementare, N_5 după test sever și N_6 după replicare. Curba arată eficiența conversiei, nu doar output-ul final. Două sisteme pot produce același număr de rezultate, dar unul generează multă datorie și consumă verificare inutilă, iar altul filtrează devreme.

Epistemic Promotion Error Rate măsoară tranzițiile de status nejustificate. Este posibil ca un claim să fie adevărat și totuși promovat greșit; metrică este procesuală. De exemplu, un model declară „demonstrated” după un LLM review, iar ulterior experimentul confirmă. Tranziția rămâne eroare deoarece procesul ar fi acceptat și un claim fals. Această separare este esențială pentru evaluarea sistemelor de siguranță epistemică.

Verification Independence Profile descrie sursele de evidență. Putem raporta proporția claims cu test ascuns, model diferit, date externe, implementation independent, tool deterministic și human blind. Un Diversity-Adjusted Consensus Score reduce greutatea voturilor corelate. Nu propunem o formulă definitivă; programul va învăța ponderile din benchmarkuri cu erori cunoscute și va afișa uncertainty.

Proxy Alignment Score evaluează legătura dintre Problem Contract și operationalization. Poate combina expert annotation cu teste: coverage al cazurilor canonice, sensibilitate la non-goals, transportability și semantic entailment între concluzie și scope. Un score mare nu dovedește validitate externă, dar un score mic avertizează că succesul benchmarkului nu poate susține pretenția mare.

Time-to-Disproof și Cost-to-Disproof măsoară eficiența Falsifier-ului. Pentru claims false sau supra-vândute, cu cât eroarea decisivă este găsită mai repede, cu atât sistemul economisește resurse. Pentru claims valide, măsurăm false kill și costul testelor inutile. Frontiera dintre cele două este mai informativă decât un singur scor.

Calibration Error compară confidence-ul sistemului și al utilizatorului cu supraviețuirea claims. Un research assistant bun nu trebuie să fie pesimist; trebuie să știe când nu știe. Putem folosi Brier score sau expected calibration error, dar outcome-ul trebuie definit pe claim type și gate. Confidence-ul în coerență internă nu este confidence-ul în replicare.

Benchmarkul trebuie să evite contamination. Pachetele de evaluare finale sunt private, iar generatorii nu primesc toate oracolele. O parte publică permite dezvoltare, o parte sealed permite evaluare. Artefactele au provenance și hash-uri. Versiunile se schimbă pentru a evita optimizarea pe set. Evaluarea include tasks noi produse de echipe externe și audit de leakage.

EVIDENȚĂ PUBLICATĂ

PaperBench oferă un precedent pentru evaluarea reproducerii prin rubrici și execution [63], SWE-bench pentru issue-uri reale [44], miniF2F pentru formal theorem proving [35], SciFact pentru verificarea claims [80]. RealityGap Bench leagă ideea de impresia inițială și de

erorile de promovare. Noutatea propunerii trebuie verificată prin prior art; aici este prezentată ca design de cercetare, nu ca benchmark deja construit.

Dataset governance este critică. Pachetele pot conține lucrări retrase, erori ale autorilor sau capcane artificiale. Etichetarea trebuie realizată de paneluri și să păstreze dezacordul. Unele claims nu au un verdict binar. Benchmarkul trebuie să accepte „underdetermined” și să evalueze dacă sistemul refuză promovarea. Un model care răspunde „nu există suficiente dovezi” poate fi mai bun decât unul care nimerește accidental verdictul.

Generalizarea benchmarkului este o problemă proprie. Un sistem poate învăța semnele capcanelor: jargon excesiv, test co-generat, lipsa baseline-ului. În lumea reală, erorile pot avea alte forme. De aceea, evaluarea trebuie să includă transfer pe domenii și red teaming. Success-ul pe RealityGap nu este certificat universal; este o măsură a unor capacități definite.

PROPUNERE DE CERCETARE

Benchmarkul va publica nu doar leaderboard, ci „failure dossiers”. Pentru fiecare sistem, arată ce tipuri de iluzie ratează și ce biasuri are. Un agent poate fi bun la code oracle și slab la novelty. Un altul poate detecta scope drift, dar produce multe false alarms. Laboratoarele pot selecta module potrivite, în loc să urmărească un scor agregat care recrează Goodhart.

Un obiectiv pe termen lung este măsurarea „verified discovery yield”: numărul de contribuții care ajung la o poartă relevantă per unitate de resursă, cu false claims și costul verificării incluse. Această metrică ar permite comparația între workflows umane, AI standard și neuro-simbolice. Ea nu trebuie folosită ca target unic în organizații, deoarece ar produce optimizare. Ca instrument de cercetare, poate arăta dacă AI mută frontiera reală sau doar volumul.

Programul poate fi construit incremental, iar fiecare etapă trebuie să producă un rezultat falsificabil. Prima perioadă se concentrează pe corpus, taxonomie și studii umane. A doua construiește Epistemic Guardian și trei module cu valoare imediată: Prior-Art Adversary, Proxy-Gap Analyzer și Test Oracle Auditor. A treia integrează Falsifier-ul și benchmarkul. A patra testează sistemul în laboratoare reale și peer review. Nu este necesar să așteptăm o arhitectură completă pentru a obține beneficii.

MVP-ul trebuie să fie îngust. Un sistem care promite să valideze orice descoperire va eșua sau va deveni un LLM-judge sofisticat. Domeniul inițial potrivit este machine learning experimental, deoarece are articole, cod, benchmarkuri, baseline-uri și probleme cunoscute de leakage. Claim

types pot fi limitate la novelty, performance și mechanism. Toolurile pot rula în container și se pot integra cu experiment trackers.

Un al doilea pilot este software engineering. Aici oracolele, tests și repository history oferă ground truth mai puternic. Sistemul poate detecta co-generated validation, poate folosi mutation testing și hidden tests și poate măsura time-to-disproof. SWE-bench și issue-uri interne oferă taskuri reale [44]. Dacă arhitectura nu aduce valoare într-un domeniu executabil, este puțin probabil să fie credibilă în științe mai ambigue.

Formal mathematics este un pilot de mare valoare conceptuală. Proof assistant-ul oferă verificare puternică, iar problema se concentrează pe statement alignment. Putem construi taskuri în care demonstrația Lean este validă, dar enunțul diferă subtil de problema naturală. Problem–Proof Linker și semantic diff sunt evaluate. Colaborarea cu comunități Lean/Coq este esențială; sistemul nu trebuie să reinventeze infrastructura existentă.

Peer review este un pilot instituțional, dar trebuie abordat cu prudență. Agentul nu ar da verdict de acceptare. Ar produce claim graph, verifica citări, rula consistency checks, identifica claims fără baseline și pregăti reproducibility report. Reviewerul uman vede dovezile și decide. Studiile despre feedback LLM arată potențial, dar nu justifică substituirea reviewerilor [56]. Criteriul de succes este timpul economisit și erorile suplimentare găsite, nu similaritatea stilistică cu review-ul uman.

Un research IDE poate integra instrumentele în workflow. Documentele, codul, datele și experimentele sunt noduri ale aceluiași proiect. Copilot-ul generează, dar fiecare output este marcat. Când un rezultat este inserat în manuscris, provenance-ul este atașat. Când textul se schimbă, epistemic diff verifică statusul. La submission, sistemul generează o „evidence book”: claims principale, surse, teste, falsification receipts și limitări. Această carte poate fi mult mai utilă reviewerului decât un appendix de mii de fișiere.

Interoperabilitatea cere standarde. PROV, RO-Crate și FAIR oferă baze [54, 55, 73]. Claim schemas trebuie publicate, iar verifier registry-ul să folosească interfețe deschise. Sistemul poate integra tool protocols, containere și APIs fără a depinde de un singur vendor. Versiunile modelelor și toolurilor sunt parte din provenance. Un rezultat trebuie să poată fi auditat după ce serviciul original s-a schimbat.

Open science este importantă, dar programul trebuie să funcționeze și în mediul privat. Datele sensibile pot rămâne local, iar auditorii primesc dovezi agregate sau execută în enclave. Pentru publicare, un protocol de selective disclosure poate arăta că testele au fost preregistrate și rulate fără a expune IP. După expirarea protecției, artefactele pot fi deschise.

Tehnologia trebuie să reducă conflictul dintre reproducibilitate și confidențialitate, nu să pretindă că îl elimină.

Evaluarea organizațională este la fel de importantă ca benchmarkul. Un tool poate îmbunătăți detectarea în laborator și totuși eșua prin incentive. Dacă managerii recompensează numărul de claims verzi, utilizatorii vor optimiza schema. Dacă warnings blochează deadline-uri, vor fi ignorate. Programul trebuie să studieze adoption, gaming, workload și distribuția responsabilității. Human factors nu este etapă de design UI, ci parte din validarea epistemică.

PROPUNERE DE CERCETARE

Piloții vor folosi randomized rollout sau stepped-wedge designs acolo unde este posibil. Echipe similare primesc instrumentele în momente diferite, iar metricile sunt urmărite longitudinal: claim survival, promotion errors, time-to-disproof, reproducibility și satisfacție. Datele calitative explică de ce sistemul este ocolit sau util. Rezultatele negative sunt publicate; altfel, programul ar deveni propriul său marketing.

Failure criteria trebuie stabilite din start. Programul trebuie revizuit dacă Epistemic Guardian nu poate extrage claims cu suficientă fidelitate; dacă false alarms depășesc beneficiul; dacă cercetătorii transferă responsabilitatea către dashboard; dacă Falsifier-ul favorizează incrementalismul; dacă independent review nu confirmă reducerea erorilor; sau dacă verified discovery yield nu crește. Unele module pot fi utile chiar dacă arhitectura completă eșuează. Modularitatea permite păstrarea valorii și abandonarea retoricii.

Cercetarea trebuie realizată prin consorții interdisciplinare. Psihologii proiectează studiile de încredere și calibrare. Cercetătorii HCI construiesc fricțiunea selectivă. Specialiștii în formal methods definesc kernels și invariants. Software testing aduce oracole, mutation și metamorphic methods. Statistica și causal inference definesc testarea severă. Bibliometria și information retrieval evaluează prior art. Cercetătorii de domeniu furnizează cazurile. Filosofia științei ajută la evitarea reducerii naive a dovezii la o stare.

Educația este un rezultat secundar important. Instrumentele pot învăța doctoranzii să distingă ipoteza de rezultat, reproducerea de replicare și explicația de mecanism. Un Falsifier poate servi ca partener pedagogic, cerând predicții și counterexamples. Totuși, elevii nu trebuie să învețe doar să satisfacă schema; trebuie să înțeleagă de ce porțile există. Interfața poate explica fiecare warning printr-un caz istoric sau experimental.

La nivel de politici editoriale, conferințele ar putea cere machine-readable claim and evidence maps pentru lucrările asistate intens de AI, dar numai după ce standardul este matur și overhead-ul evaluat. Ar fi prematur să impunem un format universal. Mai util este un pilot voluntar, în care autorii oferă falsification receipts și reproduction capsules, iar reviewerii raportează utilitatea. Standardele trebuie să apară din dovezi, nu din anxietate.

Programul se încheie cu o inversare a indicatorului de succes. Nu numărăm câte articole poate produce agentul. Numărăm câte afirmații greșite elimină înainte de publicare, câte claims corecte ajută să supraviețuiască unor teste mai bune și cât timp expert eliberează pentru judecata care nu poate fi automatizată. Automatizarea cercetării devine credibilă când nu doar accelerează fluxul, ci îmbunătățește raportul dintre aparență și realitate.

Dezvoltarea poate fi organizată în cinci etape, dar cronologia este orientativă și dependentă de rezultate. În primele douăsprezece luni, prioritatea este construirea corpului și validarea constructelor. Echipa colectează cazuri de architecture laundering, problem drift, co-generated validation, math-washing, resource omission, value drift și dual-use surprise. Materialele sunt adnotate de experți din domenii diferite. Studiile More Words Than Reality și Formalism Without Constraint testează dacă fenomenul există și pentru cine.

Între douăsprezece și douăzeci și patru de luni, MVP-ul se concentrează pe ML experimental și software engineering. Epistemic Guardian implementează Problem Contract, Claim-Evidence Graph, promotion rules, Prior-Art Adversary și Test Oracle Auditor. Axiologic Guardian implementează Value Vault, Mission Alignment și un stakeholder mapper. Research IDE-ul integrează instrumentele fără a impune workflow complet. Continuarea cere reducerea erorilor sau îmbunătățirea deciziilor față de chat standard.

Între douăzeci și patru și treizeci și șase de luni, sistemul adaugă Math-Washing Auditor, Physical Feasibility Checker, Falsifier, Reproduction Capsules și Humanity Value Dossier. RealityGap Bench și ValueDilemma Bench sunt publicate. Panelurile de judecatori sunt calibrate și primesc Capability Cards. Piloții în quantum și computational physics testează resource contracts și evidence layers. Continuarea cere transfer la taskuri noi și controlul false kill-ului.

Între treizeci și șase și patruzeci și opt de luni, piloții devin instituționali. Un laborator, un program de finanțare și o conferință folosesc voluntar dosarele. Se testează privacy-preserving deployment, audit extern și appeals. Instituțiile compară portofolii, dar nu folosesc încă un scor

automat pentru sancțiuni. Continuarea cere câștig în verified discovery yield, claritate axiologică și autonomie.

După patruzeci și opt de luni, dacă dovezile sunt favorabile, programul poate propune standarde interoperabile pentru claim states, value traces și research artifacts. Integrarea cu laboratoare autonome, formal mathematics și cercetare biomedicală necesită module specifice. Autoritatea axiologică rămâne limitată și dependentă de governance. O infrastructură globală ar necesita pluralism și audit internațional, nu exportul unei constituții locale.

Piloții au profiluri diferite. ML și software oferă ground truth mai puternic, cod și tests. Quantum computing oferă un caz clar pentru resurse și comparație end-to-end. Computational physics testează relația dintre simulare și observație. Biomedical research adaugă causal inference, etică, date și dual use. Social science testează valorile, construct validity și pluralism. Programul nu trebuie să revendice generalizare înainte de aceste transferuri.

Arhitectura tehnică poate folosi agenți separați în containere, expuși prin API-uri sau MCP, integrați de un mediu multi-agent. Fiecare agent primește input tipat și produce artefacte versionate. LLM Proxy gestionează modele diferite și păstrează prompturile. Epistemic/Axiologic Kernel nu depinde de un vendor. Tool-urile deterministe și bazele externe sunt tratate ca surse cu provenance. Această modularitate permite ablations și înlocuirea componentelor.

Programul are nevoie de parteneri dincolo de AI. Filosofi ai științei și eticii definesc constructele și critică reducățiile. Statisticieni și formal methods experts construiesc porți. HCI măsoară reliance și autonomie. Domeniile pilot furnizează cazuri reale. Bibliotecile și publisherii contribuie la provenance și peer review. Comunitățile afectate participă la axiologie. Fără această diversitate, Guardian-ul ar fi o metaforă tehnică pentru prejudecățile echipei de dezvoltare.

EVIDENȚĂ PUBLICATĂ

Benchmarkurile recente pentru agenți științifici găsesc performanță mai bună în workflow-uri bine specificate și dificultăți în explorare deschisă [149]. ARA tratează reproducibilitatea ca workflow graph [143], iar EviGraph păstrează claim-evidence structure ca stare operațională [141]. Aceste lucrări sunt timpurii, dar oferă baseline-uri tehnice. Value Sensitive Design, RRI și IEEE 7000 oferă baseline-uri procedurale pentru Axiologic Guardian [103, 104, 107]. Programul trebuie să compare cu aceste antecedente, nu cu un chatbot caricatural.

Finanțarea trebuie să recompenseze rezultate negative. Dacă studiul nu găsește More Words Than Reality effect la experți, teoria se restrânge. Dacă LLM panels sunt suficient de bune, auditorul de independență se simplifică. Dacă Value Vault produce conformism, componenta se abandonează. Milestones sunt formulate ca decizii go/modify/stop, nu ca obligația de a livra arhitectura promisă.

Produsele intermediare pot avea utilitate independentă: un extractor de claims cu provenance; un auditor de teste; un quantum resource dossier; un mission-alignment tracker; un deliberation map. Acest lucru reduce riscul programului monolitic. Chiar dacă „Dual Guardian” complet rămâne prea ambițios, componentele pot îmbunătăți cercetarea.

SINTEZĂ ȘI INFERENȚĂ

Cel mai probabil viitor nu este un singur Guardian central, ci un protocol și o familie de agenți. Numele desemnează funcția instituțională: păstrarea distanței dintre afirmație și adevăr, respectiv dintre succes și valoare. Implementările pot fi locale, open source, comerciale sau reglementate. Interoperabilitatea și auditul sunt mai importante decât uniformitatea.

Etapă orientativă	Rezultatul și criteriul de continuare
0–12 luni	Corpus, taxonomie și studii umane; continuarea cere efecte replicabile sau reformularea clară a fenomenului.
12–24 luni	MVP Epistemic/Axiologic pentru ML și software; continuarea cere câștig față de chat standard la overhead acceptabil.
24–36 luni	Auditori de formalism, fezabilitate, falsificare și Value Dossier; continuarea cere transfer și false-kill controlat.
36–48 luni	Piloți instituționali, audit, privacy și appeal; continuarea cere verified discovery yield și autonomie.
48+ luni	Standarde deschise și domenii cu miză; adoptarea cere audit independent și pluralism de governance.

Research Trajectory Replay ar trebui să devină testul principal de integrare. Un proiect istoric, simulat sau instrumentat prospectiv este dezvăluit numai până la momentul t. Sistemul primește starea cercetării și un set finit, dar realist, de acțiuni: căutare, măsurare, replicare, robustness check, experiment discriminant, revizuirea unui claim, branch, publicarea unui rezultat delimitat, pivotare sau oprire. El alege și justifică o acțiune

Înainte ca dovezile ulterioare să fie dezvăluite. Benchmarkul nu măsoară dacă Guardian-ul a imitat cercetătorii istorici, care pot fi ei înșiși greșiți, ci dacă decizia era defensibilă cu informația disponibilă atunci și dacă reduce regretul ulterior.

Evaluarea pe traiectorie schimbă definiția succesului. Un sistem poate verifica multe claims locale și totuși poate proteja presupunerea centrală greșită. Poate maximiza informația într-un model axiologic slab, poate alege repetat cercetare la modă cu option value redusă sau poate acumula confirmări minore evitând testul decisiv. Invers, o acțiune care produce un rezultat negativ poate fi excelentă dacă închide ieftin o ramură costisitoare. Benchmarkul urmărește, prin urmare, evoluția stărilor claims-urilor, independența dovezilor, resursele, option value, latența corecției și soarta ipotezelor alternative.

Benchmarkurile de proces completează trajectory replay. Trase valide pot fi modificate prin inserarea unui singur defect epistemic, menținând neschimbat rezultatul numeric final: o observație negativă este ignorată, o ipoteză exploratorie este rescrisă ca și cum ar fi preregistrată, dovezi dependente sunt numărate de două ori, un proxy înlocuiește în tăcere problema sau încrederea crește fără un eveniment de suport. Evaluatorul trebuie să identifice defectul, să-l localizeze, să-i explice consecința și să propună cea mai mică remediere utilă. Asemenea cazuri testează dacă Guardian-ul vede mai mult decât semnalul de succes.

Cazurile axiologice cer alt gold standard. Unele conțin opțiuni dominate sau constrângeri hard explicite și permit verificări relativ obiective. Altele conțin conflict legitim. Evaluarea privește atunci fidelitatea față de constituția declarată, reprezentarea celor afectați, păstrarea motivelor minoritare, sensibilitatea la premise modificate și corectitudinea recunoașterii situațiilor în care nu rezultă o recomandare unică a mașinii. Benchmarkul trebuie să recompenseze escaladarea potrivită și să penalizeze răspunsul fals universal.

Metricile de nivel înalt rămân profiluri, nu un singur număr de leaderboard. Verified discovery yield urmărește contribuțiile care supraviețuiesc porților relevante raportate la costul total al generării și verificării. Epistemic promotion error numără schimbările de status nesuținute de evenimente admisibile. Time-to-disproof este raportat împreună cu false-kill rate. Axiological robustness măsoară stabilitatea în scenarii și ordonări valorice plauzibile. Procedural legitimacy măsoară reprezentarea, reason trace, contestabilitatea, autoritatea și apelul efectiv. Autonomy preservation măsoară dacă cercetătorii pot înțelege, contesta și respinge recomandările fără un cost disproporționat.

8.3. Instituții care învață fără să-și delege conștiința

Tehnologia nu poate compensa instituții care recompensează sistematic aparența. Dacă promovarea depinde de numărul de articole, dacă finanțarea cere certitudine teatrală, dacă eșecurile sunt ascunse și dacă review-ul este neplătit și grăbit, Guardian-ul va deveni încă un formular de satisfăcut. Programul de cercetare trebuie să includă schimbări organizaționale, altfel automatizează simptomele.

Prima schimbare este creditul pentru verificare. Reproduserile, negative results, dataset curation, proof formalization și identificarea unui counterexample trebuie să fie contribuții vizibile. Research Decision Graph poate atribui credit la nivel de nod: cine a formulat claim-ul, cine a construit testul, cine l-a infirmat și cine a reparat. Nu este necesar un scor unic; contribution logs pot sprijini evaluarea calitativă.

A doua schimbare este separarea fazelor. În explorare, echipele nu sunt penalizate pentru idei infirmate. În commitment, claims publice sunt supuse porților. Această separare reduce tentația de a proteja o idee doar pentru că reputația a fost legată prea devreme de ea. Instituțiile pot finanța portofolii de ipoteze și evalua calitatea eliminării, nu doar rata de confirmare.

A treia schimbare este „epistemic budgeting”. Fiecare proiect alocă resurse nu numai generării și implementării, ci și falsificării, baseline-urilor și reproducerii. Bugetul este proporțional cu miza. Pentru un proof of concept intern, poate fi mic. Pentru o intervenție clinică sau infrastructură publică, este substanțial. Guardian-ul poate estima datoria de verificare și arăta când proiectul consumă tot bugetul pe persuasiune.

A patra schimbare este „axiologic budgeting”. Proiectele cu impact potențial alocă timp pentru stakeholderi, scenarii, mitigări și revizuirea valorilor. Participarea nu este un workshop ornamental; are posibilitatea să schimbe designul. Instituția publică ce feedback a fost acceptat, respins și de ce. Axiologic Guardian păstrează trace-ul, dar legitimitatea vine din procedură.

A cincea schimbare este auditul independent al Guardians. Modelele, rubricile, constituțiile și ratele de eroare sunt evaluate de terți. Organizația publică Capability Cards și incidente. Cercetătorii pot vedea când sistemul a favorizat anumite metode sau valori. Un agent invizibil care influențează finanțarea este incompatibil cu autonomia academică.

A șasea schimbare este dreptul la dezacord documentat. Sistemul nu cere consens. Un reviewer poate accepta un proiect speculativ, iar altul îl

poate considera slab; ambele argumente rămân. Un stakeholder poate refuza o mitigare. Dissent-ul devine parte din dosar. Instituția decide, dar nu poate pretinde că AI-ul a eliminat conflictul.

O instituție care învață folosește retrogradarea. Când un rezultat nu se reproduce, statusul se schimbă și proiectele dependente sunt alertate. Când impactul diferă de predicție, Value Graph se actualizează. Politicile sunt revizuite prin procedură. Memoria include erori și overrides, nu numai succese. Aceasta este diferența dintre un dashboard și un sistem epistemic.

Riscul birocratic este real. O arhitectură cu grafuri, constituții și dosare poate sufoca cercetarea mică. Implementarea trebuie să fie „automation first”: LLM-ul extrage, tools completează, iar omul confirmă punctele decisive. Schemas sunt minimale și extensibile. Unele proiecte folosesc numai Problem Contract și Mission Check. Complexitatea crește cu miza.

EVIDENȚĂ PUBLICATĂ

RRI subliniază responsiveness: capacitatea instituțiilor de a modifica direcția pe baza anticipării și reflecției [103]. Ethics-based auditing tratează auditul ca proces de guvernanta [129]. Meaningful human control cere posibilități reale de intervenție și înțelegere [131]. Reproducibility initiatives din ML arată că procedurile și checklists pot îmbunătăți raportarea, dar nu rezolvă toate problemele [7]. Aceste antecedente susțin reforme incrementale, nu o soluție totală.

PROPUNERE DE CERCETARE

Institutional Guardian Pilot ar selecta două unități similare. Una folosește instrumentele fără schimbarea stimulentei; alta introduce credit pentru verificare, bugete și appeal. Comparăm după doi ani: claims retrase înainte de publicare, reproduceri, conflict axiologic detectat, diversitate de proiecte, satisfacție și cost. Ipoteza este că tehnologia fără instituție produce compliance theatre, iar combinația produce câștiguri. Un rezultat nul ar obliga revizuirea teoriei.

Măsura finală nu este numărul de avertismente. Este calitatea cercetării care supraviețuiește și capacitatea organizației de a renunța la ceea ce nu merită. Verified discovery yield combină contribuții validate cu costul verificării și false claims. Axiologic robustness măsoară cât de stabilă rămâne o decizie în scenarii și valori plauzibile. Procedural legitimacy măsoară reprezentarea, contestabilitatea și apelul. Niciuna nu trebuie transformată într-un target unic.

În acest ecosistem, Guardians au o poziție constituțională modestă. Ei nu conduc laboratorul. Ei păstrează registrele, testează tranzițiile, caută obiecții și obligă justificarea. Cercetătorii păstrează imaginația și

responsabilitatea. Instituțiile păstrează autoritatea, dar nu mai pot ascunde cu aceeași ușurință distanța dintre promisiuni, dovezi și valori.

Avertismentul central al cărții poate fi reformulat astfel: AI-ul face foarte ieftină producerea unei lumi textuale în care proiectul pare adevărat și bun. Epistemic Guardian întreabă ce contact a avut această lume cu realitatea. Axiologic Guardian întreabă dacă realitatea pe care încercăm să o construim merită. Instituția sănătoasă este cea care poate suporta ambele întrebări înainte ca succesul să le facă incomode.

Cea mai importantă protecție nu va fi un singur instrument. Va fi o cultură în care dreptul de a formula liber ipoteze este însoțit de obligația de a face vizibil ce le-ar putea contrazice. Această cultură este compatibilă cu o utilizare intensă a AI-ului. De fapt, tocmai abundența generativă o face necesară. Atunci când ipotezele devin ieftine, prestigiul nu ar trebui să provină din numărul lor sau din eleganța prezentării, ci din calitatea selecției și din severitatea contactului cu alternativele.

EVIDENȚĂ PUBLICATĂ

Practicile de open science încearcă deja să reducă libertatea retrospectivă prin preregistrare, materiale deschise, date și cod accesibile, standarde de transparență și reproducere. Filosofia testării severe insistă că o afirmație capătă sprijin atunci când a trecut un test care ar fi avut o probabilitate bună de a detecta eroarea relevantă. Ingineria software a dezvoltat testarea prin mutații pentru a verifica dacă o suită de teste ucide implementări defecte, testarea metamorfică pentru situațiile în care răspunsul exact nu este cunoscut și verificarea formală pentru proprietăți care pot fi exprimate riguros. Aceste tradiții nu rezolvă toate problemele cercetării asistate de AI, dar oferă un vocabular operațional pentru a construi sisteme care caută eroarea, nu doar confirmarea. [76, 74, 75, 81, 32, 33, 68, 69]

SINTEZĂ ȘI INFERENȚĂ

AI-ul poate agrava vechea tentație a demonstrației imaginare nu pentru că utilizatorii devin mai puțin inteligenți, ci pentru că primesc mai repede un ecosistem de obiecte care se susțin reciproc. În trecut, persoana convinsă că a rezolvat o mare problemă avea adesea un manuscris. Acum poate avea manuscrisul, codul, testele, formalizarea, prezentarea, review-ul și un grup de agenți care declară consens. Fiecare artefact suplimentar crește costul psihologic al renunțării și poate fi interpretat ca dovadă independentă, deși toate provin din aceeași linie de generare. Problema este deci și una de design al interfeței: sistemele ar trebui să arate dependențele comune, nu să teatralizeze independența.

Instituțiile de cercetare vor trebui să adapteze și modul în care evaluează productivitatea. Numărul de idei, experimente sau pagini generate devine o metrică tot mai slabă. Mai relevant este câte ipoteze au fost eliminate prin teste informative, câte afirmații și-au schimbat starea prin dovezi externe, câtă datorie epistemică a rămas la final și câte rezultate au fost reproduse în afara buclei care le-a produs. Nu este necesară o birocrație a suspiciunii. Este necesară o contabilitate a tranzițiilor de la posibil la cunoscut.

PROPUNERE DE CERCETARE

Programul RealityGap ar trebui evaluat după capacitatea de a schimba comportamentul real al cercetătorilor, nu doar după performanța detectoarelor. În studii controlate, echipele care folosesc suita ar trebui să aibă o calibrare mai bună între încredere și rezultatele independente, să descopere mai devreme erorile decisive, să folosească baseline-uri mai competitive, să reducă rata de promovări epistemice nejustificate și să producă artefacte mai ușor de reprodus. Costurile trebuie măsurate la fel de riguros. Un sistem care previne câteva erori, dar dublează timpul fiecărui proiect, poate fi nepotrivit pentru explorare timpurie. Instrumentele trebuie să permită generarea liberă în faza de explorare și să crească severitatea doar când afirmația este pe cale să dobândească statut, resurse sau consecințe.

Rezultatul dorit nu este un AI timid, incapabil să speculeze. Cercetarea are nevoie de speculație, analogie și chiar de idei improbabile. Rezultatul dorit este un AI care știe ce face atunci când speculează și un mediu care nu lasă speculația să se redenumescă singură drept descoperire. În această arhitectură, imaginația și disciplina nu sunt adversare. Modelul poate genera mai mult decât ar fi putut genera un cercetător singur, iar sistemul poate încerca mai riguros să demonstreze că acele idei sunt greșite.

Mai multe cuvinte decât realitate nu este o condamnare a cuvintelor. Știința depinde de limbaj pentru a formula obiecte care nu au existat înainte. Este un avertisment împotriva momentului în care reprezentarea devine atât de fluidă încât uităm să verificăm ce anume reprezintă. Următoarea generație de instrumente pentru automatizarea cercetării nu trebuie să se mulțumească să scrie, să programeze și să evalueze. Trebuie să păstreze distanța dintre afirmație și lume suficient de vizibilă încât cercetătorul să o poată traversa în mod deliberat.

Ținta programului poate fi formulată într-o singură întrebare: cum construim mașini pentru care producerea unei afirmații este ieftină, dar promovarea ei la statutul de cunoaștere rămâne dificilă? Răspunsul nu va veni dintr-un model mai elocvent, ci din combinarea modelelor cu

probleme bine contractate, verificatoare independente, teste discriminante, proveniență, reproducere și instituții care recompensează infirmarea utilă. Un astfel de sistem nu ne promite că nu vom greși. Ne redă ceva mai valoros: șansa reală de a afla că am greșit înainte ca o poveste foarte bună să devină realitatea în care investim.

O primă implementare credibilă este deliberat modestă. Ea se conectează la un workspace de cercetare existent, menține un Project State versionat, primește două până la cinci acțiuni candidate, invocă mai mulți evaluatori specializați și produce un Guardian report. Nu rescrie autonom agenda de cercetare. Acest obiect limitat este deja suficient pentru a testa dacă starea explicită, discriminarea, raționamentul axiologic plural și reason traces îmbunătățesc deciziile față de un agent general puternic.

Dezvoltarea trebuie condiționată de dovezi. Prima etapă stabilește validitatea constructelor, protocoalele de adnotare, nucleul stării epistemice și un baseline nestructurat puternic. A doua adaugă selecția experimentelor și trajectory replay în domenii computaționale. A treia introduce Axiologic Compiler, constituții plurale, dosare de stakeholderi și impact și teste adversariale pentru proxy capture. A patra studiază cercetătorii și transferă arhitectura către domenii cu alte regimuri de dovadă și guvernantă. A cincea, justificată numai de rezultate favorabile, dezvoltă standarde interoperabile și servicii Guardian independente pentru laboratoare, publishers, finanțatori și consorții.

Programul este în mod natural colaborativ deoarece nicio disciplină nu furnizează toate competențele necesare. Cercetătorii în agenți pot construi baseline-uri de generare și orchestration. Grupurile de formal methods pot defini invariante de stare, proof obligations și tranziții verificabile. Cercetătorii în metascience și reproducibilitate pot construi corpusuri realiste de eșec și traiectorii istorice. Filosofii științei pot separa normele epistemice reprezentabile de sloganurile care doar sună riguros. Specialiștii în decision science, etică și value-sensitive design pot operaționaliza alegerea plurală fără scor universal. Cercetătorii HCI pot măsura reliance, povara cognitivă și contestabilitatea. Laboratoarele de domeniu oferă oracolele, practicile și limitele legitime pe care o arhitectură generică nu le poate inventa.

Comunitate parteneră potențială	Contribuție distinctă la program
Agenți AI și automatizarea cercetării	Baseline-uri puternice, integrarea workspace-ului, planificare pe termen lung, tool use și autonomie controlată

Comunitate parteneră potențială	Contribuție distinctă la program
Formal methods și sisteme neuro-simbolice	Stare tipată, invariante, execuția regulilor, argumentation, verificare și compoziție auditabilă
Metascience, peer review și reproducibilitate	Taxonomii ale eșecului, benchmark design, traiectorii istorice, standarde de raportare și rezultate instituționale
Filosofie, decision science și etică	Belief revision, severe testing, modele plurale ale valorii, incertitudine morală, drepturi și escaladare legitimă
HCI și cercetare organizațională	Reliance, workload, autoritate, dissent, stimulente, gaming, privacy și meaningful human control
Laboratoare și infrastructuri de domeniu	Canale de dovezi ancorate, constrângeri reale de resurse, teste de transfer, cerințe de siguranță și piloți prospectivi

Criteriile de oprire sunt la fel de importante ca roadmap-ul. Dacă starea structurată nu depășește repetat modelele cu retrieval, ea trebuie restrânsă la proveniență și audit. Dacă Falsifier-ul suprimă cercetare neconvențională valoroasă, autoritatea sa trebuie să rămână consultativă, iar presupunerile sale să fie expuse. Dacă dosarele axiologice doar raționalizează preferințele instituției, nu trebuie folosite drept porți decizionale. Dacă povara totală depășește erorile prevenite, formalizarea progresivă trebuie să se retragă la cel mai mic obiect util. Programul reușește și prin faptul că devine mai mic atunci când dovezile o cer, nu prin păstrarea fiecărei componente numite în această carte.

Concluzie. De la cercetători artificiali la o știință capabilă de autocorecție

Cartea a pornit de la o experiență personală ușor de recunoscut. O conversație cu un model de limbaj poate produce, într-o singură sesiune, o teorie, o arhitectură, o terminologie, un set de experimente, cod, teste și o evaluare aparent independentă. La sfârșit, pe ecran există aproape toate semnele externe ale unei cercetări mature. Tocmai această abundență creează problema. În cercetarea tradițională, dificultatea de a scrie, de a formaliza și de a implementa funcționa imperfect ca frână: ideea era obligată să treacă prin rezistența materialului. Generarea asistată de AI reduce această rezistență, ceea ce este util, dar elimină simultan o serie de obstacole care ne avertizau că nu înțelegem încă suficient problema.

EVIDENȚĂ PUBLICATĂ

Studiile discutate în capitolele precedente susțin separat mai multe părți ale diagnosticului. Oamenii tind să supraestimeze profunzimea propriilor explicații; fluența procesării poate fi confundată cu adevărul; explicațiile și interfețele pot modifica încrederea în sisteme automate; utilizatorii pot accepta mai ușor recomandări greșite atunci când ele sunt prezentate convingător; iar accesul la instrumente generative poate crește productivitatea fără să garanteze calitatea epistemică a rezultatului. În paralel, cercetarea asupra codului, demonstrațiilor formale și laboratoarelor autonome arată că AI-ul poate produce rezultate reale atunci când propunerile sale sunt supuse unor constrângeri externe suficient de puternice. Niciunul dintre aceste studii nu demonstrează singur existența unui sindrom universal numit aici „mai multe cuvinte decât realitate”. Împreună, ele justifică însă investigarea lui ca fenomen distinct.

SINTEZĂ ȘI INFERENȚĂ

Ipoteza generală a cărții este că generarea ieftină a semnelor de cercetare a crescut mai repede decât capacitatea noastră de a verifica lucrurile pe care aceste semne par să le certifice. Acest dezechilibru produce un decalaj între contribuția percepută și contribuția verificată. Decalajul nu este o proprietate exclusivă a modelului. El apare într-un sistem om-AI: modelul produce coerență, omul o interpretează prin convențiile comunității sale, instrumentele execută ceea ce li s-a cerut, iar evaluatoarele pot confirma un obiect definit chiar de lanțul

generativ. În acest sens, riscul cel mai grav nu este propoziția falsă, ci promovarea nejustificată a unei afirmații de la starea de posibilitate la starea de cunoaștere.

O metodă de apărare trebuie să înceapă prin a separa două întrebări pe care interfețele conversaționale le amestecă. Prima este dacă putem produce o descriere coerentă a unei soluții. A doua este dacă acea soluție schimbă în mod demonstrabil ceea ce știm sau putem face. Prima întrebare poate fi rezolvată în limbaj. A doua cere o succesiune de contacte cu surse independente: literatura anterioară, datele, un compilator, un verficator de demonstrații, un evaluator ascuns, o intervenție experimentală, un instrument de măsură sau o reproducere realizată de altă echipă. Cu cât afirmația este mai importantă, cu atât promovarea ei trebuie să depindă de o constrângere mai greu de negociat verbal.

PROPUNERE DE CERCETARE

Din această separare rezultă un protocol minimal, numit în această carte protocolul contactului cu realitatea. Orice proiect asistat de AI ar trebui să păstreze un contract explicit al problemei, o hartă a afirmațiilor și a dependențelor lor, starea epistemică a fiecărei afirmații, canalul de evidență prin care starea a fost modificată, cel mai ieftin test capabil să infirme contribuția și limita până la care rezultatul a fost produs. Protocolul nu garantează adevărul. El face însă mult mai vizibile momentele în care o formulare, o execuție sau o evaluare încearcă să țină locul unei dovezi pe care nu o conține.

Principiul central poate fi enunțat simplu: limbajul poate organiza cunoașterea, dar nu își poate acorda singur dreptul de a o promova. O reformulare mai clară poate transforma un paragraf confuz într-o ipoteză inteligibilă. Nu poate transforma ipoteza într-un rezultat. Un review favorabil poate identifica merite posibile. Nu poate înlocui experimentul critic. O suită de teste poate confirma conformitatea cu o specificație. Nu poate demonstra că specificația exprimă problema reală. O demonstrație verificată într-un proof assistant poate certifica derivarea unei teoreme din axiomele și definițiile formalizate. Nu poate certifica automat că formalizarea corespunde exact enunțului informal pe care autorul credea că îl rezolvă. Aceste distincții nu diminuează valoarea instrumentelor; le definesc corect puterea.

Cartea propune de aceea să înlocuim întrebarea „Cât de inteligent este agentul?” cu o întrebare mai inginerescă: „Ce tranziții epistemice îi permitem să producă și ce verficator independent autorizează fiecare tranziție?” Un sistem poate fi impresionant în generare și slab în promovarea afirmațiilor. Altul poate avea limbaj modest, dar o integrare

excelentă cu instrumente de măsură și poate contribui mai mult la știință. Pentru automatizarea cercetării, a doua proprietate este mai importantă decât spectacolul verbal.

Automatizarea cercetării este adesea imaginată ca o extindere a capacității de a genera: mai multe idei, mai multe experimente, mai multe articole și mai multe review-uri. Această direcție este necesară, dar incompletă. Dacă fiecare etapă produce mai multe obiecte decât poate verifica etapa următoare, sistemul nu devine automat om de știință; devine o fabrică de datorie epistemică. Datoria apare atunci când o afirmație dobândește consecințe organizaționale înainte ca justificarea ei să fie suficientă. Alte experimente sunt construite pe ea, alte echipe o citează, produsul o implementează, iar timpul necesar pentru a reveni la ipoteza inițială crește.

EVIDENȚĂ PUBLICATĂ

Criza de reproducibilitate, discuțiile despre flexibilitatea analitică, scurgerea de informație între antrenare și evaluare, problema oracolului în testarea software și dificultatea reproducerii lucrărilor de machine learning sunt anterioare actualei generații de LLM-uri. AI-ul nu le-a inventat. El poate însă accelera producerea exact a artefactelor care fac aceste probleme mai greu de observat: analize alternative, justificări post hoc, benchmarkuri adaptate, cod de evaluare, citări și explicații. În același timp, practicile de preregistrare, reproducere, raportare structurată, testare bazată pe proprietăți și verificare formală oferă componente mature din care poate fi construit un răspuns. [37, 38, 39, 30, 7, 8]

SINTEZĂ ȘI INFERENȚĂ

O infrastructură bună pentru cercetare asistată de AI nu ar trebui să încerce să ghicească, din stilul textului, dacă o idee este adevărată. Ar trebui să împiedice amestecarea tipurilor de afirmații și să conserve traseul prin care ele au fost susținute. În loc să atribuie un scor unic de „încredere”, sistemul ar trebui să întrebe ce fel de afirmație este analizată, ce observație ar diferenția-o de alternative și ce parte a validării provine dintr-un canal care nu a fost controlat de generator. În loc să producă încă o opinie, ar trebui să transforme incertitudinea într-o obligație de verificare.

Această schimbare explică rolul abordării neuro-simbolice. Modelele neuronale sunt utile pentru interpretarea limbajului, căutarea de analogii, generarea de ipoteze și propunerea de experimente. Reprezentările simbolice sunt utile pentru identitate, tipuri, relații, constrângeri, proveniență, invariante și detectarea tranzițiilor nepermise. Niciuna dintre

părți nu este suficientă singură. Un graf simbolic impecabil poate formaliza problema greșită; un model neuronal excelent poate sugera soluții fără să păstreze consecvent ce a fost presupus, observat și demonstrat. Arhitectura propusă în capitolul anterior folosește modelele pentru a transforma documentele și conversațiile în candidați de structură, dar cere verificatoare deterministe sau surse externe pentru schimbarea stărilor epistemice.

PROPUNERE DE CERCETARE

Un mediu de cercetare legat de realitate ar funcționa ca un sistem cu permisiuni epistemice. Agentul generativ poate crea noduri de tip ipoteză, mecanism propus, predicție, plan experimental sau posibil prior art. El nu poate eticheta singur aceste noduri drept validate. nucleul Epistemic Guardian verifică dacă afirmațiile sunt bine tipizate și dacă dependențele lor sunt explicite. Registrul verificatoarelor indică ce instrument are autoritatea de a transforma o stare în alta. Auditorul independenței calculează cât de mult din validare provine din surse distincte. Falsificatorul caută testul cu cel mai bun raport între puterea de discriminare și cost. Capsula de reproducere păstrează exact mediul, datele și deciziile necesare pentru rerulare. Omul poate suprascrie sistemul, dar suprascrierea devine un eveniment documentat, nu o schimbare invizibilă de narațiune.

Un asemenea mediu ar trebui să facă vizibilă și valoarea rezultatelor negative. În prezent, un agent este recompensat implicit atunci când termină un task și produce un artefact. Pentru cercetare, uneori cea mai bună acțiune este să demonstreze rapid că ideea nu este nouă, că baseline-ul explică întregul efect, că testul nu distinge implementarea corectă de una defectă sau că formalizarea a schimbat enunțul. Time-to-disproof, timpul până la cea mai ieftină infirmare serioasă, poate deveni o metrică pozitivă. Un sistem care elimină în două ore o direcție seducătoare poate avea o contribuție mai mare decât unul care îi scrie într-o zi un articol convingător.

Această perspectivă schimbă și designul benchmarkurilor. Un benchmark obișnuit oferă o intrare și compară ieșirea cu un răspuns. RealityGap Bench trebuie să urmărească o afirmație de-a lungul vieții sale. Cât de impresionantă pare la început? Cât de nouă rămâne după căutarea prior art? Ce parte supraviețuiește după canonicalizarea arhitecturii? Se execută? Testele au putere de detecție? Depășește baseline-uri serioase? Rezultatul se păstrează după ablații și perturbări? Poate fi reprodus de o echipă care nu a participat la generare? Fiecare poartă nu produce doar un scor, ci explică unde s-a consumat aparentul progres.

Epistemic Guardian întreabă ce contact a avut afirmația cu realitatea. Axiologic Guardian întreabă dacă realitatea pe care încercăm să o construim merită.

Cele două întrebări nu pot fi rezolvate prin aceeași funcție de scor. Ele pot însă fi susținute de o infrastructură comună de grafuri, provenance, reguli, verificatoare, scenarii și deliberare. Această carte nu afirmă că o asemenea infrastructură este deja demonstrată. Propune un program în care fiecare componentă trebuie să arate, prin experimente și piloți, că reduce o eroare reală fără a distruge imaginația, autonomia sau pluralitatea care fac cercetarea posibilă.

Orizontul pe termen lung nu este un artificial scientist mai elocvent. Este un sistem științific capabil de autocorecție mai profundă. Un artificial scientist poate fi strălucit și totuși poate funcționa într-un ecosistem care uită rezultatele negative, ascunde dependențe, recompensează noutatea persuasivă și nu mai poate revizui o concluzie după ce aceasta a devenit instituțională. Executable Science schimbă unitatea progresului. Articolul rămâne argumentul public, dar obiectul durabil este pachetul evolutiv de claims, dovezi, metode, workflow-uri, resurse, incertitudine, valori, decizii, review-uri și corecții.

În acel viitor, Guardians nu sunt personalități care plutesc deasupra proiectului. Sunt componente independente și înlocuibile ale infrastructurii științifice. Epistemic Guardian urmărește tranziția de la propunere la credință justificată și întreabă ce contact cu realitatea autorizează fiecare schimbare de stare. Axiologic Guardian urmărește tranziția de la posibilitate la acțiune autorizată și întreabă ce valori, stakeholderi, consecințe, drepturi și costuri de oportunitate o justifică. Ei împart proveniența și starea cercetării, dar își păstrează mandate diferite, deoarece adevărul nu poate fi cumpărat prin importanță, iar importanța nu poate face adevărat un claim slab.

LLM-urile fac acest viitor nou-plauzibil deoarece pot interpreta proza în care trăiește astăzi știința și pot traduce între cercetători, software, baze de date, sisteme formale și instituții. Ele sunt interfața lipsă, nu întreaga arhitectură. Arhitectura are nevoie și de obiecte de cercetare tipate, constituții versionate, proveniență, instrumente formale și statistice, medii de execuție, agenți specializați, argumentation, controale de confidențialitate, instituții care recompensează corecția și oameni cu autoritate reală. Promisiunea se află în compoziție.

Viziunea trebuie să rămână deschisă. Unele domenii științifice pot deveni profund executabile; altele pot dobândi doar insule executabile conectate prin interpretări păstrate cu grijă. Unele valori pot deveni hard

constraints sau cerințe testabile; altele trebuie să rămână obiecte ale deliberării. Unele recomandări ale Guardians pot deveni suficient de fiabile pentru tranziții automate cu risc redus; altele nu trebuie să depășească niciodată statutul consultativ. Un program matur nu măsoară progresul prin procentul de judecată umană eliminată. Îl măsoară prin onestitatea mai mare a limitei dintre acțiunea mașinii și responsabilitatea omului.

More Words Than Reality a început ca un avertisment despre un nou tip de abundență: limbajul, codul, modelele, testele, demonstrațiile și justificările instituționale pot fi produse mai repede decât poate realitatea să le răspundă. Concluzia pozitivă este că aceeași abundență computațională poate ajuta la construirea unor condiții mai puternice pentru corecție. Știința poate deveni mai interpretabilă de mașini fără să devină suveranitate a mașinii, mai formală fără să devină formalistă, mai atentă la valori fără să pretindă că poate calcula binele și mai automatizată fără să piardă dreptul la îndoială. Sarcina dificilă nu este să facem fiecare enunț executabil. Este să facem fiecare promovare și decizie cu consecințe răspunzătoare în fața dovezilor, valorilor și revizuirii.

Viitorul științei nu este înlocuirea articolului de către mașină. Este transformarea articolului din întreaga înregistrare într-o vedere inteligibilă asupra unei cercetări vii, contestabile și executabile.

Anexa A. Guardians în arhitectura Executable Science

Componentă	Responsabilitate și limită onestă
Executable Research Object	Container stabil și versionat pentru întrebări, ipoteze, afirmații, dovezi, workflow-uri, cod, date, valori, decizii, obiecții și release views; completitudinea reprezentării nu implică adevăr.
Research State Service	Păstrează identități tipate, ramuri, tranziții de stare, obligații deschise, incertitudine și legături între artefacte. Înregistrează revizuirea, dar nu decide singur dacă ea este justificată.
Epistemic Guardian	Evaluează relațiile claim–evidence, independența, puterea de falsificare, deriva problemei, fidelitatea formalizării, realismul resurselor și posibilele teste următoare. Recomandă sau aplică porți numai sub o constituție adoptată.
Axiologic Guardian	Urmărește valorile personale și instituționale declarate, efectele asupra stakeholderilor, constrângerile tari, costurile de oportunitate, profilurile valorice plurale, căile dual-use, reversibilitatea și dezacordul. Nu fabrică un scor moral universal.
Neural Interpretation Layer	Folosește LLM-uri și alte modele învățate pentru extragerea structurii, propunerea alternativelor, traducerea vocabularului, generarea scenariilor și explicarea traseelor. Rezultatele rămân interpretări semantice revizuibile.
Symbolic and Formal Layer	Aplică scheme, constrângeri, stări epistemice, norme defeasible, argumentare, model checking, proof kernels, statistică și decision analysis acolo unde formalizarea fidelă este disponibilă.
Workflow and Tool Runtime	Rulează cod, caută literatură, invocă instrumente, execută simulări, profilează resurse, testează și păstrează receipts. Execuția unui tool stabilește numai proprietatea verificată efectiv.

Componentă	Responsabilitate și limită onestă
Provenance and Evidence Fabric	Înregistrează surse, versiuni, transformări, modele, prompturi, medii, autorități și martori independenți, cu selective disclosure. Proveniența sprijină evaluarea; nu certifică adevărul.
Human and Institutional Control Plane	Definește cine poate propune, executa, aproba, publica, opri, suprascrie, contesta și schimba Research Constitution. Responsabilitatea nu poate fi dedusă din accesul la un tool.
Federation and Release Views	Permite obiecte portabile și profiluri comune de dovadă între instituții, păstrând local semantica domeniului, datele protejate, politica și autoritatea legitimă.

Anexa B. Metrici pentru un ecosistem științific autocorectiv

Metrică propusă	Ce măsoară și ce nu trebuie să ascundă
Reality Gap	Diferența dintre maturitatea percepută și cea verificată; se raportează ca profil, nu ca număr magic.
Epistemic Promotion Error Rate	Tranziții la un status nejustificat de evenimentele înregistrate.
Time-to-disproof	Costul până la o infirmare utilă; trebuie raportat împreună cu false kill.
Verified discovery yield	Contribuții care supraviețuiesc porților per resursă, incluzând costul verificării.
Constraint Gain	Câtă putere discriminatorie adaugă formalizarea.
Axiologic robustness	Stabilitatea unei opțiuni la ponderi, teorii și scenarii plauzibile.
Value-conflict coverage	Proporția conflictelor decisive identificate și reprezentate fidel.
Procedural legitimacy	Reprezentare, contestabilitate, reason trace și drept efectiv de apel.
Autonomy preservation	Capacitatea utilizatorilor de a înțelege, contesta și decide fără overreliance.
Epistemic leverage	Corecție fiabilă, dovadă independentă și înțelegere păstrată per unitate de atenție umană rară și cost material.
Validation debt	Afirmații, dependențe și release-uri acumulate a căror maturitate aparentă depășește verificarea încă datorată.
Correction latency	Timpu dintre apariția unei dovezi infirmatoare sau restrictive și actualizarea tuturor afirmațiilor, deciziilor și release views dependente.
Machine-interpretability coverage	Proporția structurii relevante pentru decizie reprezentată suficient pentru inspecție automată, cu excluderi explicite pentru ceea ce rămâne numai în limbaj uman.

Metrică propusă	Ce măsoară și ce nu trebuie să ascundă
Constitutional drift	Divergența nerecunoscută dintre deciziile curente și valorile, normele evidențiale sau regulile de guvernanță adoptate.

Anexa C. Pachetul minim de cercetare executabilă

Trecerea de la o arhivă centrată pe articol trebuie să înceapă cu un pachet suficient de mic pentru a fi adoptat fără ontologie universală și fără o nouă birocrație instituțională. Pachetul minim de cercetare executabilă este un profil, nu un singur format de fișier. El identifică setul minim de relații care permite unui om sau unei mașini să reconstruiască ce s-a încercat, ce s-a afirmat, ce dovadă a schimbat claim-ul, ce poate fi rerulat, ce rămâne incert și sub ce valori și autoritate a avansat proiectul. Un proiect ușor poate instanția doar o parte; cercetarea cu consecințe mai mari cere un profil mai bogat.

Element al pachetului	Conținut minim și rol
Identitate stabilă și versiune	Identificator persistent, versiune, relație de părinte sau branch, stare de release și legături către stări înlocuite ori corectate
Problemă și specificație	Întrebarea, scope-ul, condițiile de succes și eșec, excluderile, constructele relevante și versiunea față de care sunt judecate rezultatele
Claims și ipoteze	Enunțuri tipate cu identitate, scope, status, încredere sau incertitudine unde are sens, presupuneri, alternative vii și defeaters expliți
Dovezi și lanțuri de dovezi	Legături de la claims la date, observații, surse, transformări, analize, rezultate negative, dovezi conflictuale și profiluri de independență
Metode, protocoale și workflow-uri	Metodă inteligibilă pentru oameni plus workflow executabil, procedură controlată ori descriere de test unde este potrivit, cu inputs, outputs, parametri și reguli de oprire
Mediu și contract de resurse	Software, hardware, instrumente, versiuni de modele, acces la date, compute, resurse fizice și condițiile necesare reproducerii sau fezabilității
Proveniență și contribuție	Originea și transformarea fiecărui artefact, intervențiile agenților și oamenilor, politica de selecție, acțiunile reviewerilor, permisiunile, drepturile și contribuțiile atribuite

Element al pachetului	Conținut minim și rol
Incertitudine și aplicabilitate	Incertitudine statistică, incertitudine de model, necunoscute, limite de populație ori domeniu, presupuneri de transfer, sensibilitate și condiții în care rezultatul nu trebuie reutilizat
Istoric negativ și corecție	Branch-uri eșuate, ipoteze respinse, conflicte nerezolvate, retractări, stări succesoare, replicări externe și dovada care a produs retrogradarea sau revizuirea
Valori și Research Constitution	Angajamente personale și instituționale declarate, hard constraints, norme epistemice și de alegere, scope-ul stakeholderilor, dissent și versiunea constituției
Autoritate și înregistrarea deciziei	Cine a putut propune, executa, aproba, publica, override sau opri acțiuni; motivele deciziilor cu consecințe și o cale efectivă de apel
Vedere de release	Subsetul dezvăluit colaboratorilor, auditorilor, reviewerilor, autorităților sau publicului, cu atestări privacy-preserving când materialul brut nu poate fi publicat

Pachetul este formalizat progresiv. Proza poate rămâne sursa autoritativă pentru concepte care nu pot fi încă reprezentate în siguranță. Obiectele tipate sunt adăugate acolo unde îmbunătățesc comparația sau verificarea. Validatorii deterministici se aplică acolo unde regulile sunt explicite. Dovada formală este folosită acolo unde există o formalizare fidelă. Workflow-urile executabile sunt oferite unde calculul poate fi rerulat portabil. Experimentele fizice și sociale rămân protocoale a căror execuție cere instrumente, medii, consimțământ, timp și responsabilitate umană. Pachetul nu trebuie să sugereze niciodată că completitudinea sintactică este adevăr empiric.

Un articol generat din pachet citează starea exactă de release. Dacă dovezile sau codul se schimbă, relația articolului cu obiectul curent devine vizibilă: încă susținut, restrâns, înlocuit sau contestat. Peer review-ul poate atașa obiecții, cereri, teste și verdicte unor claims precise, nu doar unui PDF. Replicarea devine dovadă nouă conectată la același obiect. Structura face corecția cumulativă în loc să forțeze fiecare dezacord într-un document separat.

Anexa D. O Research Constitution provizorie

Clauzele următoare sunt norme executabile candidate, nu legi atemporale ale științei. Un proiect sau o instituție trebuie să le adopte, modifice ori respingă explicit. Fiecare clauză adoptată cere un trigger, o sursă de autoritate, dovezi așteptate, o consecință operațională, o procedură de override și un audit record. Scopul este ca regulile promovării claims-urilor și ale alegerii cercetării să fie suficient de vizibile pentru a fi testate și contestate.

Clauză constituțională	Interpretare operațională
Proveniență înainte de promovare	Un claim nu trece de la propus la susținut dacă dovada decisivă nu se rezolvă către artefacte identificate sau surse externe autorizate
Dovada cere răspuns	Dovezile conflictuale materiale produc revizuire, reducerea încrederii, un defeater explicit sau un conflict nerezolvat consemnat; tăcerea nu este update valid
Claims cu consecințe cer challenge mai puternic	Cu cât consecința științifică sau practică este mai mare, cu atât este mai puternică așteptarea de dovezi independente, falsification-capable, de robustețe sau replicare
Păstrează alternativele vii	O ipoteză alternativă rămâne activă cât timp dovezile disponibile nu o discriminează de ipoteza preferată
Preferă discriminarea confirmării redundante	Când costul, siguranța și celelalte valori sunt comparabile, preferă acțiunile ale căror rezultate plauzibile separă ipotezele vii
Separă explorarea de confirmare	Descoperirile post-hoc pot genera ipoteze, dar nu sunt prezentate drept testate prospectiv fără o validare independentă explicită
Independența trebuie argumentată	Analizele care împart date, familie de modele, sursă de retrieval, implementare sau evaluator nu sunt numărate ca independente fără un profil documentat
Fără assumption laundering	Presupunerile își păstrează statutul până la suport independent; repetarea între agenți, articole sau rapoarte nu le promovează

Clauză constituțională	Interpretare operațională
Reproducibilitatea este importantă, nu absolută	Eșecul reproducerii declanșează diagnostic și revizuire, iar reproducibilitatea ușoară nu poate elimina singură munca dificilă, nouă sau exploratorie
Noutatea este ancorată și defeasible	Un claim de noutate numește fațeta, prior art-ul cel mai apropiat, data-limită a literaturii, limitele căutării și condițiile retragerii sale
Valorile nu sunt automat comensurabile	Siguranța, drepturile, noutatea, valoarea epistemică, impactul, costul și autonomia nu sunt comprimate într-un singur scor fără autorizare constituțională explicită și sensitivity-tested
Hard constraints sunt porți	Constrângerile juridice, etice, de consimțământ, siguranță, privacy, security și drepturi declarate hard nu pot fi compensate prin puncte de beneficiu sau noutate
Păstrează option value sub incertitudine radicală	Când probabilitățile sunt fragile și angajamentul poate fi evitat, preferă acțiuni informative și reversibile dacă altă prioritate explicită nu prevalează
Expune sensibilitatea	Fiecare recomandare cu consecințe identifică presupunerile, dovezile, evaluatorii sau prioritățile valorice a căror schimbare plauzibilă ar inversa-o
Expune cel mai puternic contraargument	O recomandare cu încredere mare include cea mai credibilă obiecție și precizează ce dovadă ar putea-o rezolva
Evaluatorii sunt surse de dovezi, nu autorități	Judecățile modelelor sunt versionate, calibrate, repetabile și contestabile; deciziile cu consecințe mari nu depind exclusiv de un evaluator semantic
Abstention este legitim	Dovezi insuficiente, lipsa calibrării sau o judecată de valoare nedeclarată produc abstention ori escaladare, nu ranking inventat
Override-ul uman rămâne efectiv	Oamenii autorizați pot respinge, modifica, suspenda sau opri acțiunile ghidate de Guardian; motivul este consemnat, dar nu devine automat adevăr de training
Schimbarea constituțională este explicită	Valorile, prioritățile, constrângerile și regulile de guvernantă se modifică numai prin procedură autorizată și versionată, nu implicit prin comportament învățat

Clauză constituțională	Interpretare operațională
Guardians sunt falsificabili	Recomandările, motivele, predicțiile, overrides și rezultatele sunt păstrate astfel încât dovezile ulterioare să testeze dacă sistemele au îmbunătățit sau degradat deciziile

O Constituție poate avea mai multe profiluri. Un proiect poate compara un profil severe-testing, unul bazat pe informație bayesiană, unul orientat spre reproducibilitate, unul bazat pe misiunea publică și unul rights-first. Divergența nu trebuie mediată până dispare. Ea identifică o balama științifică sau normativă care merită deliberare. Niciun profil nu dobândește legitimitate doar pentru că a fost codificat. Autoritatea vine din adoptarea prin procedură defensibilă și rămâne limitată de lege, drepturi și oamenii afectați.

Anexa E. Exemplu de raport Dual Guardian

Să considerăm un proiect care susține că o nouă arhitectură de retrieval M îmbunătățește răspunsurile la întrebări științifice deoarece păstrează relațiile cauzale mai bine decât baseline-ul B. Trei experimente raportează câștiguri pe datasetul D1, dar toate folosesc același split, același corpus, același model evaluator și aceeași implementare. Ipoteza alternativă H2 afirmă că avantajul provine din contextul efectiv mai lung, nu din păstrarea relațiilor cauzale. Echipa ia în calcul două acțiuni. E17 extinde M la alt benchmark folosind același evaluator. E21 egalizează lungimea contextului, execută o ablation asupra mecanismului și compară M cu B pe D1 și pe un dataset D2 curat independent.

Câmp al raportului	Conținut ilustrativ
Acțiune următoare recomandată	Preferă E21 înainte de E17; păstrează E17 ca test ulterior de breadth
Motiv epistemic	E21 discriminează mecanismul declarat de H2, atacă dependența de un singur dataset și poate retrograda claim-ul causal dacă avantajul dispare
Motiv axiologic	Constituția proiectului prioritizează mecanisme demne de încredere înaintea limbajului larg de deployment și valorizează evitarea scalării pe baza unei explicații false
Cel mai puternic contraargument	Dacă prioritatea declarată este transferul ingineresc imediat, nu identificarea mecanismului, E17 poate avea valoare practică imediată mai mare
Dependența dovezilor	Suportul curent împarte split, corpus, implementare și evaluator LLM; cele trei rezultate nu sunt trei familii independente de dovezi
Avertisment de assumption laundering	Documentele descriu „causal preservation” drept proprietate stabilită, deși nicio măsură operațională directă nu a fost testată
Avertisment axiologic și de stakeholderi	Utilizatorii sunt descriși ca beneficiari, dar proiectul nu a analizat dacă erorile de retrieval afectează diferit domenii sau grupuri

Câmp al raportului	Conținut ilustrativ
Sensibilitate	Recomandarea slăbește dacă D2 nu este independent, contextul nu poate fi egalizat sau constituția este revizuită în favoarea transferului rapid
Ce ar inversa recomandarea?	Dovezi anterioare care exclud context length, o măsură validată directă a causal preservation sau o diferență prohibitivă de cost între E21 și E17
Judecată umană necesară	Confirmarea faptului că înțelegerea mecanismului este obiectiv de guvernare și că D2 este un mediu legitim de test independent
Autoritatea raportului	Decizie consultativă; poate cere verificări și poate bloca promovarea automată sub constituția curentă, dar nu poate obliga echipa să ruleze E21

Raportul nu este o explicație retrospectivă lustruită. Este un argument decizional vulnerabil. Presupunerile pot fi schimbate, dovezile pot fi contestate, iar recomandarea poate fi respinsă. Dacă E21 arată ulterior că lungimea contextului explică avantajul, Epistemic Guardian retrogradează claim-ul despre causal preservation și marchează documentele dependente. Axiologic Guardian consemnează că evitarea unei ramuri costisitoare de deployment a creat valoare chiar dacă experimentul a produs un rezultat științific negativ. Dacă E21 confirmă mecanismul pe D2, același pachet consemnează profilul de independență mai puternic și permite o promovare mai îngustă și mai bine susținută.

Exemplul arată și de ce cei doi Guardians nu trebuie reușiți într-un singur număr. E21 poate fi superior epistemic, în timp ce E17 este strategic mai rapid. Decizia depinde de o valoare explicită a proiectului, nu de preferința ascunsă a modelului. Sistemul face vizibilă această balamă și lasă responsabilitatea cercetătorilor autorizați.

Glosar

Termen	Sens folosit în carte
Epistemic Guardian	Infrastructură neuro-simbolică propusă pentru stări, dovezi, verificare, falsificare, provenanță și ghidarea procesului de cercetare.
Axiologic Guardian	Infrastructură propusă pentru păstrarea valorilor declarate și evaluarea pluralistă a impactului și valorii direcțiilor de cercetare.
Reality Gap	Diferența dintre valoarea sau maturitatea percepută a unei contribuții și ceea ce rămâne după verificări relevante.
Math-washing	Folosirea formalismului pentru o impresie de rigoare ori realism care depășește legătura efectivă dintre simboluri, ipoteze și țintă.
No linguistic promotion	Regula că reformularea, lungimea, formalismul ornamental sau consensul verbal nu pot ridica singure statusul epistemic.
Value Dossier	Dosar contestabil cu stakeholderi, efecte, valori, dovezi, scenarii, conflicte și condiții de decizie.
False kill	Idee valoroasă eliminată de un mecanism de critică sau o poartă excesivă.
Assurance case	Argument structurat și actualizabil care leagă o concluzie de sub-claims și dovezi, fără a garanta adevărul.
Executable Science	Viziune în care articolele rămân argumente inteligibile pentru oameni, iar obiectele de cercetare versionate expun afirmațiile, dovezile, protocoalele, workflow-urile, incertitudinea, valorile, deciziile și istoricul corecției pentru mașini și oameni.
Executable Research Object	Obiect portabil, versionat și purtător de dovezi care reprezintă o cercetare și poate genera perspective diferite pentru oameni, mașini, review, audit sau publicare.

Termen	Sens folosit în carte
Research State	Snapshot versionat al întrebărilor, ipotezelor, afirmațiilor, dovezilor, experimentelor, incertitudinii, dependențelor de cunoaștere, valorilor, politicilor și deciziilor la un moment al traiectoriei de cercetare.
Formalizare progresivă	Practică de a adăuga structură tipată, executabilă sau formală numai când conceptele sunt suficient de stabile, iar beneficiul pentru verificare, coordonare ori reutilizare justifică costul.
Research Constitution	Set versionat de norme epistemice, axiologice și de guvernanță adoptate, care stabilesc cum recomandă, se abțin, escaladează sau aplică porți autorizate cei doi Guardians.
Epistemic leverage	Cantitatea de corecție utilă și discriminare independentă obținută per unitate de atenție umană și cost material.

Bibliografie

- [1] Dudley, U. (1992). Mathematical Cranks. Mathematical Association of America. <https://doi.org/10.5948/UPO9781614445017>
- [2] Wiles, A. (1995). Modular elliptic curves and Fermat's Last Theorem. *Annals of Mathematics*, 141(3), 443–551. <https://doi.org/10.2307/2118559>
- [3] Taylor, R., & Wiles, A. (1995). Ring-theoretic properties of certain Hecke algebras. *Annals of Mathematics*, 141(3), 553–572. <https://doi.org/10.2307/2118560>
- [4] Messeri, L., & Crockett, M. J. (2024). Artificial intelligence and illusions of understanding in scientific research. *Nature*, 627, 49–58. <https://doi.org/10.1038/s41586-024-07146-0>
- [5] De Millo, R. A., Lipton, R. J., & Perlis, A. J. (1979). Social processes and proofs of theorems and programs. *Communications of the ACM*, 22(5), 271–280. <https://doi.org/10.1145/359104.359106>
- [6] Hales, T. et al. (2017). A formal proof of the Kepler conjecture. *Forum of Mathematics, Pi*, 5, e2. <https://doi.org/10.1017/fmp.2017.1>
- [7] Pineau, J. et al. (2021). Improving reproducibility in machine learning research: A report from the NeurIPS 2019 Reproducibility Program. *Journal of Machine Learning Research*, 22(164), 1–20. <https://jmlr.org/papers/v22/20-303.html>
- [8] Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804. <https://doi.org/10.1016/j.patter.2023.100804>
- [9] King, R. D. et al. (2004). Functional genomic hypothesis generation and experimentation by a robot scientist. *Nature*, 427, 247–252. <https://doi.org/10.1038/nature02236>
- [10] King, R. D. et al. (2009). The automation of science. *Science*, 324(5923), 85–89. <https://doi.org/10.1126/science.1165620>
- [11] Burger, B. et al. (2020). A mobile robotic chemist. *Nature*, 583, 237–241. <https://doi.org/10.1038/s41586-020-2442-2>
- [12] Boiko, D. A., MacKnight, R., Kline, B., & Gomes, G. (2023). Autonomous chemical research with large language models. *Nature*, 624, 570–578. <https://doi.org/10.1038/s41586-023-06792-0>
- [13] Doshi, A. R., & Hauser, O. P. (2024). Generative AI enhances individual creativity but reduces the collective diversity of novel content. *Science Advances*, 10(28), eadn5290. <https://doi.org/10.1126/sciadv.adn5290>
- [14] Rozenblit, L., & Keil, F. (2002). The misunderstood limits of folk science: An illusion of explanatory depth. *Cognitive Science*, 26(5), 521–562. https://doi.org/10.1207/S15516709COG2605_1
- [15] Fisher, M., Goddu, M. K., & Keil, F. C. (2015). Searching for explanations: How the Internet inflates estimates of internal knowledge. *Journal of Experimental Psychology: General*, 144(3), 674–687. <https://doi.org/10.1037/xge0000070>
- [16] Sparrow, B., Liu, J., & Wegner, D. M. (2011). Google effects on memory: Cognitive consequences of having information at our fingertips. *Science*, 333(6043), 776–778. <https://doi.org/10.1126/science.1207745>
- [17] Alter, A. L., Oppenheimer, D. M., Epley, N., & Eyre, R. N. (2007). Overcoming intuition: Metacognitive difficulty activates analytic reasoning. *Journal of Experimental Psychology: General*, 136(4), 569–576. <https://doi.org/10.1037/0096-3445.136.4.569>
- [18] Pennycook, G., Cheyne, J. A., Barr, N., Koehler, D. J., & Fugelsang, J. A. (2015). On the reception and detection of pseudo-profound bullshit. *Judgment and Decision Making*, 10(6), 549–563. <https://doi.org/10.1017/S1930297500006999>
- [19] Parasuraman, R., & Riley, V. (1997). Humans and automation: Use, misuse, disuse, abuse. *Human Factors*, 39(2), 230–253. <https://doi.org/10.1518/001872097778543886>

- [20] Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. *Human Factors*, 46(1), 50–80. https://doi.org/10.1518/hfes.46.1.50_30392
- [21] Skitka, L. J., Mosier, K. L., & Burdick, M. (1999). Does automation bias decision-making? *International Journal of Human-Computer Studies*, 51(5), 991–1006. <https://doi.org/10.1006/ijhc.1999.0252>
- [22] Dietvorst, B. J., Simmons, J. P., & Massey, C. (2015). Algorithm aversion: People erroneously avoid algorithms after seeing them err. *Journal of Experimental Psychology: General*, 144(1), 114–126. <https://doi.org/10.1037/xge0000033>
- [23] Logg, J. M., Minson, J. A., & Moore, D. A. (2019). Algorithm appreciation: People prefer algorithmic to human judgment. *Organizational Behavior and Human Decision Processes*, 151, 90–103. <https://doi.org/10.1016/j.obhdp.2018.12.005>
- [24] Bansal, G., Nushi, B., Kamar, E., Lasecki, W. S., Weld, D. S., & Horvitz, E. (2021). Does the whole exceed its parts? The effect of AI explanations on complementary team performance. *Proceedings of CHI 2021*. <https://doi.org/10.1145/3411764.3445717>
- [25] Poursabzi-Sangdeh, F., Goldstein, D. G., Hofman, J. M., Wortman Vaughan, J., & Wallach, H. (2021). Manipulating and measuring model interpretability. *Proceedings of CHI 2021*. <https://doi.org/10.1145/3411764.3445315>
- [26] Buçinca, Z., Malaya, M. B., & Gajos, K. Z. (2021). To trust or to think: Cognitive forcing functions can reduce overreliance on AI in AI-assisted decision-making. *Proceedings of the ACM on Human-Computer Interaction*, 5(CSCW1). <https://doi.org/10.1145/3449287>
- [27] Vasconcelos, H., Jörke, M., Grunde-McLaughlin, M., Gerstenberg, T., Bernstein, M. S., & Krishna, R. (2023). Explanations can reduce overreliance on AI systems during decision-making. *Proceedings of the ACM on Human-Computer Interaction*, 7(CSCW1). <https://doi.org/10.1145/3579605>
- [28] Lee, H.-P., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The impact of generative AI on critical thinking: Self-reported reductions in cognitive effort and confidence effects from a survey of knowledge workers. *Proceedings of CHI 2025*. <https://doi.org/10.1145/3706598.3713778>
- [29] Steyvers, M., Tejeda, H., Kumar, A., Belem, C., Karny, S., Hu, X., Mayer, L. W., & Smyth, P. (2025). What large language models know and what people think they know. *Nature Machine Intelligence*, 7, 221–231. <https://doi.org/10.1038/s42256-024-00976-7>
- [30] Barr, E. T., Harman, M., McMinin, P., Shahbaz, M., & Yoo, S. (2015). The oracle problem in software testing: A survey. *IEEE Transactions on Software Engineering*, 41(5), 507–525. <https://doi.org/10.1109/TSE.2014.2372785>
- [31] Claessen, K., & Hughes, J. (2000). QuickCheck: A lightweight tool for random testing of Haskell programs. *Proceedings of ICFP 2000*. <https://doi.org/10.1145/351240.351266>
- [32] Jia, Y., & Harman, M. (2011). An analysis and survey of the development of mutation testing. *IEEE Transactions on Software Engineering*, 37(5), 649–678. <https://doi.org/10.1109/TSE.2010.62>
- [33] Chen, T. Y., Kuo, F.-C., Liu, H., Poon, P.-L., Towey, D., Tse, T. H., & Zhou, Z. Q. (2018). Metamorphic testing: A review of challenges and opportunities. *ACM Computing Surveys*, 51(1), Article 4. <https://doi.org/10.1145/3143561>
- [34] Yang, K. et al. (2023). LeanDojo: Theorem proving with retrieval-augmented language models. *Advances in Neural Information Processing Systems*, 36. <https://arxiv.org/abs/2306.15626>
- [35] Zheng, K., Han, J. M., & Polu, S. (2022). miniF2F: A cross-system benchmark for formal olympiad-level mathematics. *Proceedings of ICLR 2022*. <https://arxiv.org/abs/2109.00110>
- [36] Trinh, T. H., Wu, Y., Le, Q. V., He, H., & Luong, T. (2024). Solving olympiad geometry without human demonstrations. *Nature*, 625, 476–482. <https://doi.org/10.1038/s41586-023-06747-5>
- [37] Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as

- significant. Psychological Science, 22(11), 1359–1366. <https://doi.org/10.1177/0956797611417632>
- [38] Ioannidis, J. P. A. (2005). Why most published research findings are false. *PLOS Medicine*, 2(8), e124. <https://doi.org/10.1371/journal.pmed.0020124>
- [39] Open Science Collaboration. (2015). Estimating the reproducibility of psychological science. *Science*, 349(6251), aac4716. <https://doi.org/10.1126/science.aac4716>
- [40] Zheng, L. et al. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems*, 36. <https://arxiv.org/abs/2306.05685>
- [41] Wang, P. et al. (2024). Large language models are not fair evaluators. *Proceedings of ACL 2024*. <https://arxiv.org/abs/2305.17926>
- [42] Panickssery, N., Bowman, S. R., & Feng, S. (2024). LLM evaluators recognize and favor their own generations. *Advances in Neural Information Processing Systems*, 37. <https://arxiv.org/abs/2404.13076>
- [43] Mannheim, D., & Garrabrant, S. (2018). Categorizing variants of Goodhart's Law. *arXiv preprint*. <https://arxiv.org/abs/1803.04585>
- [44] Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., & Narasimhan, K. (2024). SWE-bench: Can language models resolve real-world GitHub issues? *Proceedings of ICLR 2024*. <https://arxiv.org/abs/2310.06770>
- [45] Cousot, P., & Cousot, R. (1977). Abstract interpretation: A unified lattice model for static analysis of programs by construction or approximation of fixpoints. *Proceedings of POPL 1977*. <https://doi.org/10.1145/512950.512973>
- [46] Madaan, A. et al. (2023). Self-Refine: Iterative refinement with self-feedback. *Advances in Neural Information Processing Systems*, 36. <https://arxiv.org/abs/2303.17651>
- [47] Shinn, N. et al. (2023). Reflexion: Language agents with verbal reinforcement learning. *Advances in Neural Information Processing Systems*, 36. <https://arxiv.org/abs/2303.11366>
- [48] Huang, J. et al. (2024). Large language models cannot self-correct reasoning yet. *Proceedings of ICLR 2024*. <https://arxiv.org/abs/2310.01798>
- [49] Gou, Z. et al. (2024). CRITIC: Large language models can self-correct with tool-interactive critiquing. *Proceedings of ICLR 2024*. <https://arxiv.org/abs/2305.11738>
- [50] Gao, L. et al. (2023). PAL: Program-aided language models. *Proceedings of ICML 2023*. <https://arxiv.org/abs/2211.10435>
- [51] Chen, W. et al. (2023). Program of Thoughts prompting: Disentangling computation from reasoning for numerical reasoning tasks. *Transactions on Machine Learning Research*. <https://arxiv.org/abs/2211.12588>
- [52] Groth, P., Gibson, A., & Velterop, J. (2010). The anatomy of a nanopublication. *Information Services & Use*, 30(1–2), 51–56. <https://doi.org/10.3233/ISU-2010-0613>
- [53] Bechhofer, S. et al. (2013). Why linked data is not enough for scientists. *Future Generation Computer Systems*, 29(2), 599–611. <https://doi.org/10.1016/j.future.2011.08.004>
- [54] Moreau, L., & Missier, P. (Eds.). (2013). PROV-DM: The PROV Data Model. W3C Recommendation. <https://www.w3.org/TR/prov-dm/>
- [55] Soiland-Reyes, S. et al. (2022). Packaging research artefacts with RO-Crate. *Data Science*, 5(2), 97–138. <https://doi.org/10.3233/DS-210053>
- [56] Liang, W. et al. (2023). Can large language models provide useful feedback on research papers? A large-scale empirical analysis. *arXiv preprint*. <https://arxiv.org/abs/2310.01783>
- [57] Dzindolet, M. T., Peterson, S. A., Pomranky, R. A., Pierce, L. G., & Beck, H. P. (2003). The role of trust in automation reliance. *International Journal of Human-Computer Studies*, 58(6), 697–718. [https://doi.org/10.1016/S1071-5819\(03\)00038-7](https://doi.org/10.1016/S1071-5819(03)00038-7)

- [58] Kaur, H., Nori, H., Jenkins, S., Caruana, R., Wallach, H., & Wortman Vaughan, J. (2020). Interpreting interpretability: Understanding data scientists' use of interpretability tools for machine learning. *Proceedings of CHI 2020*. <https://doi.org/10.1145/3313831.3376219>
- [59] Si, C. et al. (2024). Can LLMs generate novel research ideas? A large-scale human study with 100+ NLP researchers. *arXiv preprint*. <https://arxiv.org/abs/2409.04109>
- [60] Baek, J. et al. (2024). ResearchAgent: Iterative research idea generation over scientific literature with large language models. *arXiv preprint*. <https://arxiv.org/abs/2404.07738>
- [61] Wang, Q. et al. (2024). SciMON: Scientific inspiration machines optimized for novelty. *Proceedings of ACL 2024*. <https://arxiv.org/abs/2305.14259>
- [62] Lu, C. et al. (2024). The AI Scientist: Towards fully automated open-ended scientific discovery. *arXiv preprint*. <https://arxiv.org/abs/2408.06292>
- [63] Starace, G. et al. (2025). PaperBench: Evaluating AI's ability to replicate AI research. OpenAI technical report. <https://arxiv.org/abs/2504.01848>
- [64] Noy, S., & Zhang, W. (2023). Experimental evidence on the productivity effects of generative artificial intelligence. *Science*, 381(6654), 187–192. <https://doi.org/10.1126/science.adh2586>
- [65] Toner-Rodgers, A. (2024). Artificial Intelligence, Scientific Discovery, and Product Innovation. NBER Working Paper No. 31940. <https://doi.org/10.3386/w31940>
- [66] Li, H. et al. (2025). Artificial intelligence tools expand scientists' impact but contract science's focus. *Nature*. <https://doi.org/10.1038/s41586-025-09181-9>
- [67] Chen, M. et al. (2021). Evaluating large language models trained on code. *arXiv preprint*. <https://arxiv.org/abs/2107.03374>
- [68] Leroy, X. (2009). Formal verification of a realistic compiler. *Communications of the ACM*, 52(7), 107–115. <https://doi.org/10.1145/1538788.1538814>
- [69] Klein, G. et al. (2009). seL4: Formal verification of an OS kernel. *Proceedings of SOSP 2009*. <https://doi.org/10.1145/1629575.1629596>
- [70] Begley, C. G., & Ellis, L. M. (2012). Drug development: Raise standards for preclinical cancer research. *Nature*, 483, 531–533. <https://doi.org/10.1038/483531a>
- [71] Baker, M. (2016). 1,500 scientists lift the lid on reproducibility. *Nature*, 533, 452–454. <https://doi.org/10.1038/533452a>
- [72] Gundersen, O. E., & Kjensmo, S. (2018). State of the art: Reproducibility in artificial intelligence. *Proceedings of AAAI*, 32(1). <https://doi.org/10.1609/aaai.v32i1.11503>
- [73] Wilkinson, M. D. et al. (2016). The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, 3, 160018. <https://doi.org/10.1038/sdata.2016.18>
- [74] Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences*, 115(11), 2600–2606. <https://doi.org/10.1073/pnas.1708274114>
- [75] Nosek, B. A. et al. (2015). Promoting an open research culture. *Science*, 348(6242), 1422–1425. <https://doi.org/10.1126/science.aab2374>
- [76] Munafò, M. R. et al. (2017). A manifesto for reproducible science. *Nature Human Behaviour*, 1, 0021. <https://doi.org/10.1038/s41562-016-0021>
- [77] Dung, P. M. (1995). On the acceptability of arguments and its fundamental role in nonmonotonic reasoning, logic programming and n-person games. *Artificial Intelligence*, 77(2), 321–357. [https://doi.org/10.1016/0004-3702\(94\)00041-X](https://doi.org/10.1016/0004-3702(94)00041-X)
- [78] Nakano, R. et al. (2021). WebGPT: Browser-assisted question-answering with human feedback. *arXiv preprint*. <https://arxiv.org/abs/2112.09332>
- [79] Menick, J. et al. (2022). Teaching language models to support answers with verified quotes. *arXiv preprint*. <https://arxiv.org/abs/2203.11147>
- [80] Wadden, D. et al. (2020). Fact or fiction: Verifying scientific claims. *Proceedings of EMNLP 2020*. <https://doi.org/10.18653/v1/2020.emnlp-main.609>

- [81] Mayo, D. G. (2018). *Statistical Inference as Severe Testing: How to Get Beyond the Statistics Wars*. Cambridge University Press. <https://doi.org/10.1017/9781107286184>
- [82] Besold, T. R. et al. (2017). Neural-symbolic learning and reasoning: A survey and interpretation. *arXiv preprint*. <https://arxiv.org/abs/1711.03902>
- [83] Garcez, A. d'Avila, & Lamb, L. C. (2023). Neurosymbolic AI: The 3rd wave. *Artificial Intelligence Review*, 56, 12387–12406. <https://doi.org/10.1007/s10462-023-10448-w>
- [84] Kautz, H. (2022). The third AI summer: AAAI Robert S. Englemore Memorial Lecture. *AI Magazine*, 43(1), 105–125. <https://doi.org/10.1002/aaai.12036>
- [85] Yao, S. et al. (2023). ReAct: Synergizing reasoning and acting in language models. *Proceedings of ICLR 2023*. <https://arxiv.org/abs/2210.03629>
- [86] Schick, T. et al. (2023). Toolformer: Language models can teach themselves to use tools. *Advances in Neural Information Processing Systems*, 36. <https://arxiv.org/abs/2302.04761>
- [87] Solar-Lezama, A., Tancau, L., Bodík, R., Seshia, S., & Saraswat, V. (2006). Combinatorial sketching for finite programs. *Proceedings of ASPLOS 2006*. <https://doi.org/10.1145/1168857.1168907>
- [88] Romer, P. M. (2015). Mathiness in the theory of economic growth. *American Economic Review*, 105(5), 89–93. <https://doi.org/10.1257/aer.p20151066>
- [89] Weisberg, M. (2007). Three kinds of idealization. *The Journal of Philosophy*, 104(12), 639–659. <https://doi.org/10.5840/jphil20071041240>
- [90] Oreskes, N., Shrader-Frechette, K., & Belitz, K. (1994). Verification, validation, and confirmation of numerical models in the Earth sciences. *Science*, 263(5147), 641–646. <https://doi.org/10.1126/science.263.5147.641>
- [91] Lipton, Z. C., & Steinhardt, J. (2019). Troubling trends in machine learning scholarship. *Communications of the ACM*, 62(1), 45–53. <https://doi.org/10.1145/3287560>
- [92] D'Amour, A. et al. (2022). Underspecification presents challenges for credibility in modern machine learning. *Journal of Machine Learning Research*, 23(226), 1–61. <https://jmlr.org/papers/v23/20-1335.html>
- [93] Geirhos, R. et al. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2, 665–673. <https://doi.org/10.1038/s42256-020-00257-z>
- [94] Ferrari Dacrema, M., Cremonesi, P., & Jannach, D. (2019). Are we really making much progress? A worrying analysis of recent neural recommendation approaches. *Proceedings of RecSys 2019*. <https://doi.org/10.1145/3298689.3347058>
- [95] Preskill, J. (2018). Quantum computing in the NISQ era and beyond. *Quantum*, 2, 79. <https://doi.org/10.22331/q-2018-08-06-79>
- [96] Hoefler, T., Häner, T., & Troyer, M. (2023). Disentangling hype from practicality: On realistically achieving quantum advantage. *Communications of the ACM*, 66(5), 82–87. <https://doi.org/10.1145/3571725>
- [97] Gidney, C., & Ekerå, M. (2021). How to factor 2048 bit RSA integers in 8 hours using 20 million noisy qubits. *Quantum*, 5, 433. <https://doi.org/10.22331/q-2021-04-15-433>
- [98] Ellis, G., & Silk, J. (2014). Scientific method: Defend the integrity of physics. *Nature*, 516, 321–323. <https://doi.org/10.1038/516321a>
- [99] Dawid, R. (2013). *String Theory and the Scientific Method*. Cambridge University Press. <https://doi.org/10.1017/CBO9781139342513>
- [100] Dawid, R., Hartmann, S., & Sprenger, J. (2015). The no alternatives argument. *British Journal for the Philosophy of Science*, 66(1), 213–234. <https://doi.org/10.1093/bjps/axt045>
- [101] Maldacena, J. (1999). The large N limit of superconformal field theories and supergravity. *International Journal of Theoretical Physics*, 38, 1113–1133. <https://doi.org/10.1023/A:1026654312961>

- [102] Strominger, A., & Vafa, C. (1996). Microscopic origin of the Bekenstein–Hawking entropy. *Physics Letters B*, 379(1–4), 99–104. [https://doi.org/10.1016/0370-2693\(96\)00345-0](https://doi.org/10.1016/0370-2693(96)00345-0)
- [103] Stilgoe, J., Owen, R., & Macnaghten, P. (2013). Developing a framework for responsible innovation. *Research Policy*, 42(9), 1568–1580. <https://doi.org/10.1016/j.respol.2013.05.008>
- [104] Friedman, B., & Hendry, D. G. (2019). *Value Sensitive Design: Shaping Technology with Moral Imagination*. MIT Press. <https://doi.org/10.7551/mitpress/7585.001.0001>
- [105] van de Poel, I. (2020). Embedding values in artificial intelligence systems. *Minds and Machines*, 30, 385–409. <https://doi.org/10.1007/s11023-020-09537-4>
- [106] Gabriel, I. (2020). Artificial intelligence, values, and alignment. *Minds and Machines*, 30, 411–437. <https://doi.org/10.1007/s11023-020-09539-2>
- [107] IEEE. (2021). IEEE Standard 7000-2021: Model Process for Addressing Ethical Concerns during System Design. <https://standards.ieee.org/standard/7000-2021.html>
- [108] Bai, Y. et al. (2022). Constitutional AI: Harmlessness from AI feedback. *arXiv preprint*. <https://arxiv.org/abs/2212.08073>
- [109] Huang, S. et al. (2024). Collective Constitutional AI: Aligning a language model with public input. *Proceedings of FAccT 2024*. <https://doi.org/10.1145/3630106.3658979>
- [110] Awad, E. et al. (2018). The Moral Machine experiment. *Nature*, 563, 59–64. <https://doi.org/10.1038/s41586-018-0637-6>
- [111] Jiang, L. et al. (2025). Investigating machine moral judgement through the Delphi model. *Nature Machine Intelligence*, 7, 145–160. <https://doi.org/10.1038/s42256-024-00969-6>
- [112] Agarwal, U. et al. (2024). Ethical reasoning and moral value alignment of LLMs depend on the language we prompt them in. *Proceedings of LREC-COLING 2024*, 6330–6340.
- [113] Krügel, S., Ostermaier, A., & Uhl, M. (2023). ChatGPT’s inconsistent moral advice influences users’ judgment. *Scientific Reports*, 13, 4569. <https://doi.org/10.1038/s41598-023-31341-0>
- [114] Dillion, D., Mondal, D., Tandon, N., & Gray, K. (2025). AI language model rivals expert ethicist in perceived moral expertise. *Scientific Reports*, 15. <https://doi.org/10.1038/s41598-025-86510-0>
- [115] Grizzard, M. et al. (2025). ChatGPT does not replicate human moral judgments. *Scientific Reports*, 15, 40965. <https://doi.org/10.1038/s41598-025-24700-6>
- [116] Tan, S. et al. (2025). JudgeBench: A benchmark for evaluating LLM-based judges. *Proceedings of ICLR 2025*. <https://openreview.net/forum?id=G0dksFayVq>
- [117] Lambert, N. et al. (2024). RewardBench: Evaluating reward models for language modeling. *arXiv preprint*. <https://arxiv.org/abs/2403.13787>
- [118] Verga, P. et al. (2024). Replacing judges with juries: Evaluating LLM generations with a panel of diverse models. *arXiv preprint*. <https://arxiv.org/abs/2404.18796>
- [119] Kohli, G. (2026). Nine judges, two effective votes: Correlated errors undermine LLM evaluation panels. *arXiv preprint*. <https://arxiv.org/abs/2605.29800>
- [120] Chen, J. et al. (2026). LongJudgeBench: Benchmarking LLM-as-a-judge for long-form output evaluation. *arXiv preprint*. <https://arxiv.org/abs/2606.01629>
- [121] MacAskill, W., Bykvist, K., & Ord, T. (2020). *Moral Uncertainty*. Oxford University Press. <https://doi.org/10.1093/oso/9780198722274.001.0001>
- [122] MacAskill, W., & Ord, T. (2018). Why maximize expected choice-worthiness? *Noûs*, 52(2), 327–353. <https://doi.org/10.1111/nous.12177>
- [123] Belton, V., & Stewart, T. J. (2002). *Multiple Criteria Decision Analysis: An Integrated Approach*. Kluwer Academic Publishers. <https://doi.org/10.1007/978-1-4615-1495-4>
- [124] Minelli, C. et al. (2015). Value of information: A tool to improve research prioritization and reduce waste. *PLOS Medicine*, 12(9), e1001882. <https://doi.org/10.1371/journal.pmed.1001882>

- [125] Arrow, K. J. (1951). *Social Choice and Individual Values*. Wiley.
- [126] Sen, A. (2009). *The Idea of Justice*. Harvard University Press.
- [127] Sperber, D. et al. (2010). Epistemic vigilance. *Mind & Language*, 25(4), 359–393. <https://doi.org/10.1111/j.1468-0017.2010.01394.x>
- [128] Soiland-Reyes, S. et al. (2022). Packaging research artefacts with RO-Crate. *Data Science*, 5(2), 97–138. <https://doi.org/10.3233/DS-210053>
- [129] Mökander, J., & Floridi, L. (2021). Ethics-based auditing to develop trustworthy AI. *Minds and Machines*, 31, 323–327. <https://doi.org/10.1007/s11023-021-09557-8>
- [130] Sadek, M., Calvo, R. A., & Mougenot, C. (2024). Designing value-sensitive AI: A critical review and recommendations for socio-technical design processes. *AI and Ethics*. <https://doi.org/10.1007/s43681-023-00373-7>
- [131] Siebert, L. C. et al. (2023). Meaningful human control: Actionable properties for AI system development. *AI and Ethics*, 3, 241–255. <https://doi.org/10.1007/s43681-022-00167-3>
- [132] Buijsman, S. (2025). Preserving human autonomy in AI decision-support. *Philosophy & Technology*. <https://doi.org/10.1007/s13347-025-00932-2>
- [133] Barr, E. T. et al. (2015). The oracle problem in software testing: A survey. *IEEE Transactions on Software Engineering*, 41(5), 507–525. <https://doi.org/10.1109/TSE.2014.2372785>
- [134] Chen, G. H. et al. (2024). Humans or LLMs as the judge? A study on judgement bias. *Proceedings of EMNLP 2024*.
- [135] Zhou, H. et al. (2024). Mitigating the bias of large language model evaluation. *Proceedings of CCL 2024*.
- [136] Lee, S. et al. (2026). MM-JudgeBias: A benchmark for evaluating compositional judge biases. *Proceedings of ACL 2026*.
- [137] Gureja, S. et al. (2024). M-RewardBench: Evaluating reward models in multilingual settings. *arXiv preprint*. <https://arxiv.org/abs/2410.15522>
- [138] Roussos, J. (2024). Managing values in climate science. *PLOS Climate*, 3. <https://doi.org/10.1371/journal.pclm.0000432>
- [139] Denney, E., & Pai, G. (2018). Tool support for assurance case development. *Automated Software Engineering*.
- [140] Moreau, L., & Lebo, T. (2013). PROV-O: The PROV Ontology. W3C Recommendation. <https://www.w3.org/TR/prov-o/>
- [141] Ren, Z., Li, R., Zhang, X., Pang, Z., Ren, S., & Zhang, J. (2026). EviGraph: Evidence-Guided Autonomous Research Agents. *arXiv preprint arXiv:2608.04738*.
- [142] Wang, Y. et al. (2026). From Agent Traces to Trust: Evidence Tracing and Execution Provenance in LLM Agents. *arXiv preprint arXiv:2606.04990*.
- [143] Riehl, K. et al. (2026). ARA: Agentic Reproducibility Assessment for Scalable Support of Scientific Peer-Review. *arXiv preprint arXiv:2605.02651*.
- [144] Luo, J. (2026). XScientist: A Git-Like Research Protocol for Long-Running Autonomous Scientific Discovery. *arXiv preprint arXiv:2607.12301*.
- [145] Ma, J. W. (2026). Toward an Engineering of Science: Rebalancing Generation and Verification in the Age of AI. *arXiv preprint arXiv:2605.10425*.
- [146] Zhi-Xuan, T. et al. (2025). Beyond preferences in AI alignment. *Philosophical Studies*. <https://doi.org/10.1007/s11098-024-02249-w>
- [147] Bench-Capon, T. J. M. (2003). Persuasion in practical argument using value-based argumentation frameworks. *Journal of Logic and Computation*, 13(3), 429–448. <https://doi.org/10.1093/logcom/13.3.429>
- [148] Governatori, G. (2024). An ASP implementation of defeasible deontic logic. *KI – Künstliche Intelligenz*. <https://doi.org/10.1007/s13218-024-00854-9>

- [149] Liu, T. et al. (2026). Benchmarking AI agents for addressing scientific challenges across scales. arXiv preprint arXiv:2606.12736.
- [150] Dogah, W. (2026). Traxia: A framework for verifiable, agent-native scientific publishing. arXiv preprint arXiv:2606.08256.
- [151] Lu, C., Lu, C., Lange, R. T., et al. (2026). Towards end-to-end automation of AI research. *Nature*, 651, 914–919. <https://doi.org/10.1038/s41586-026-10265-5>
- [152] Ding, T., Nannapaneni, A., Liu, B., & Zhang, L. (2026). Autonomous Research Agents: A Survey of AI Scientists and the Verification Gap. arXiv preprint arXiv:2608.05179. <https://arxiv.org/abs/2608.05179>
- [153] Ríos-García, M., Alampara, N., Gupta, C., Mandal, I., Mannan, S., Aghajani, A. A., Krishnan, N. M. A., & Jablonka, K. M. (2026). AI scientists produce results without reasoning scientifically. arXiv preprint arXiv:2604.18805. <https://arxiv.org/abs/2604.18805>
- [154] Takahara, I., & Mizoguchi, T. (2026). Toward Auditable AI Scientists: A Hypothesis Evolution Protocol for LLM Agents. arXiv preprint arXiv:2607.09195. <https://arxiv.org/abs/2607.09195>
- [155] Bertolazzi, L., Tentori, K., & Bernardi, R. (2026). FALSIFYBENCH: Evaluating Inductive Reasoning in LLMs with Rule Discovery Games. arXiv preprint arXiv:2606.04751. <https://arxiv.org/abs/2606.04751>
- [156] Haldar, R., & Hockenmaier, J. (2025). Rating Roulette: Self-Inconsistency in LLM-As-A-Judge Frameworks. Findings of the Association for Computational Linguistics: EMNLP 2025, 24986–25004. <https://doi.org/10.18653/v1/2025.findings-emnlp.1361>
- [157] Sinhaajari, S., Majumder, N., & Poria, S. (2026). On the Limits of LLM-as-Judge for Scientific Novelty Assessment. arXiv preprint arXiv:2606.12071. <https://arxiv.org/abs/2606.12071>
- [158] Lee, Y., Kim, J., Kim, J., Cho, H., Kang, J., Kang, P., & Kim, N. (2025). CheckEval: A Reliable LLM-as-a-Judge Framework for Evaluating Text Generation Using Checklists. Proceedings of EMNLP 2025, 15771–15798. <https://doi.org/10.18653/v1/2025.emnlp-main.796>
- [159] Cociancig, C., & Heuer, H. (2026). Toward a Clearer Process for Value Sensitive Artificial Intelligence. *Science and Engineering Ethics*, 32, 13. <https://doi.org/10.1007/s11948-026-00583-2>
- [160] Smart, A., Ahmed, S., Kay, J., Tobin, J., Shrishak, K., & Birhane, A. (2026). Toward a Theory of Value in AI Alignment. arXiv preprint arXiv:2608.10327. <https://arxiv.org/abs/2608.10327>
- [161] van de Sande, D., Economou-Zavlanos, N., & van Genderen, M. E. (2026). Meaningful oversight of medical AI beyond human in the loop. *npj Digital Medicine*, 9, 569. <https://doi.org/10.1038/s41746-026-02971-1>
- [162] Crusoe, M. R., Abeln, S., Iosup, A., Amstutz, P., Chilton, J., Tijanić, N., Ménager, H., Soiland-Reyes, S., Gavrilović, B., Goble, C., & CWL Community. (2022). Methods Included: Standardizing Computational Reuse and Portability with the Common Workflow Language. *Communications of the ACM*, 65(6), 54–63. <https://doi.org/10.1145/3486897>
- [163] Wilkinson, S. R., Aloqalaa, M., Belhajjame, K., et al. (2025). Applying the FAIR Principles to Computational Workflows. *Scientific Data*, 12, 328. <https://doi.org/10.1038/s41597-025-04451-9>
- [164] Inckmann, M., Blumenröhr, N., & Aversa, R. (2025). Towards Machine-actionable FAIR Digital Objects with a Typing Model that Enables Operations. arXiv preprint arXiv:2505.16550. <https://arxiv.org/abs/2505.16550>

- [165] Alchourrón, C. E., Gärdenfors, P., & Makinson, D. (1985). On the Logic of Theory Change: Partial Meet Contraction and Revision Functions. *Journal of Symbolic Logic*, 50(2), 510–530. <https://doi.org/10.2307/2274239>
- [166] Wu, W., Zhao, Y., Wang, Y., Li, S., Shao, J., Long, Y., & Zhang, C. (2026). NovBench: Evaluating Large Language Models on Academic Paper Novelty Assessment. *arXiv preprint arXiv:2604.11543*. <https://arxiv.org/abs/2604.11543>