

CONOS DE SENTIDO

Metarracionalidad, Outfinitismo y alineación en la era de la inteligencia
generativa



*Un volumen complementario de Outfinitismo:
Metarracionalidad y los límites de cada marco*

CONOS DE SENTIDO

Metarracionalidad, Outfinitismo y alineación en la era de la
inteligencia generativa

Un volumen complementario de Outfinitismo: Metarracionalidad y los límites de cada marco

2026

*“Nunca vemos el mundo sin un filtro. La sabiduría comienza
cuando también vemos el filtro.”*

Derechos de autor © [2026] Axiologic Research

Todos los derechos reservados.

Derechos de publicación KDP en poder de Outfinity SRL (Iași, Rumanía).

Disponible gratuitamente en el sitio web de Axiologic (www.axiologic.net).

Nota del autor

Este trabajo fue creado bajo el paraguas de Axiologic Research como parte de dos programas de investigación interconectados, uno dedicado a Inteligencia Artificial y el otro a Outfinitismo, ambos liderados por Sinică Alboaie. para explorar los detalles de cómo estos dos programas se cruzan y se construyen entre sí, invitamos a los lectores a visitar la página Outfinity Venture Studio en www.outfinity.ch.

Mientras que los modelos de lenguaje Inteligencia Artificial se utilizaban para ayudar con la generación de texto, la filosofía fundamental, la estructura temática y el enfoque analítico se derivan exclusivamente de las décadas de estudio dedicado del autor sobre fenómenos sociales, tecnologías sociales y tecnologías duras genuinas resultantes de varios proyectos de investigación europeos y autofinanciados. Recientemente, dentro del proyecto de investigación de Aquiles, hemos estado estudiando profundamente la literatura generada por IA y su verificación automatizada utilizando enfoques neurosiclómicos; todos los libros gratuitos puestos a disposición del público son parte del conjunto de obras que utilizamos para probar nuestras últimas tecnologías.

Nota sobre este volumen

Este volumen continúa y complementa Outfinitismo: ZXQ00000ZXQ y los límites de cada fotograma. sus términos centrales se reintroducen dondequiera que la narrativa los requiera, de modo que el texto se pueda leer de forma independiente, mientras que su significado permanece conectado al proyecto filosófico desarrollado en el volumen anterior.

Outfinitismo se refiere aquí a la práctica del razonamiento rigurosamente, mientras que también examina el marco, el propósito y la distribución de la autoridad que hacen posible el razonamiento. Outfinitismo trata los límites reales de los modelos, la evidencia, el cálculo, las instituciones y los organismos como fronteras que deben ser declarados, juzgados y, cuando sea posible, impulsados a través de intentos finitos y revisables. ninguno de los términos se presenta como una disciplina ya establecida o como una etapa universal de desarrollo psicológico.

La expresión “alineación como estado de conciencia” se utiliza sólo como una metáfora de trabajo. El libro no atribuye la experiencia fenomenal, un yo persistente o autoridad moral a los modelos de lenguaje; discute un estado funcional de orientación, observable en la forma en que un sistema selecciona relevancia, maneja la incertidumbre y ordena los valores en contexto.

Los sistemas de inteligencia artificial se utilizaron como instrumentos editoriales y de investigación para la elaboración, la crítica y la reformulación. La coherencia del texto no es evidencia de novedad, corrección o validación empírica. La selección de la tesis y responsabilidad autorial pertenece a Sînică Alboaie.

© 2026 Sînică Alboaie. Manuscrito de investigación.

Índice

El segundo volumen: de los límites de cada marco al mundo producido a través de los marcos.....	6
La era de la coherencia barata.....	9
LA RAZÓN DENTRO DEL MARCO.....	14
Una tecnología moral que a veces olvidó su dominio.....	14
De la precisión al cientificismo, las métricas y la manipulación.....	17
IDEAS QUE ABANDONAN SU DOMINIO.....	21
Relatividad, teoría cuántica, evolución y cibernética.....	21
Memes, atractores y ecología de la reconstrucción.....	24
CONOS DE SENTIDO Y LAS ÉPOCAS QUE VEN EL MUNDO A TRAVÉS DE ELLOS.....	28
La geometría como metáfora disciplinada.....	28
Epistemes, culturas e instituciones: cuando el cono se convierte en mundo.....	30
METARRACIONALIDAD: LA SABIDURÍA QUE VE EL MARCO.....	34
Propósito, escala, tiempo y poder.....	34
Pluralismo sin relativismo, decisión sin omnisciencia.....	37
OUTFINITISMO: EL ARTE DE LOS LÍMITES ABIERTOS.....	40
Finitud efectiva y horizonte abierto.....	40
Yin y Yang: la movilidad de los marcos y la disciplina de la frontera.....	43
CÓMO UN LLM PODRÍA RECONSTRUIR ESTA PERSPECTIVA.....	47
Predicción de tokens, representaciones distribuidas y orientación guiada por prompts.....	47
Aprendizaje en contexto, pragmática y fragilidad de la comprensión aparente.....	50
EPISTEMOLOGÍA Y AXIOLOGÍA TRAS LA LLEGADA DE LA GENERACIÓN ABUNDANTE	
54	
De la escasez de texto a la escasez de juicio.....	54
Qué merece ser generado y quién decide su valor.....	57
LA ALINEACIÓN COMO ESTADO DE ORIENTACIÓN.....	61
La metáfora de un estado de conciencia y su significado defendible.....	61
El filtro metarracional y outfinitista: una promesa modesta, no una solución final.....	65
LAS TRAMPAS DE LA TESIS.....	68
Cuando una metáfora fértil empieza a inventar la realidad.....	68
Cuando la sabiduría se convierte en una técnica de poder.....	71
FILOSOFÍAS COMO CONTRAPESOS.....	74
El ciclo de corrección y exageración.....	74
Una cultura de transiciones entre conos en la era de la IA.....	76
VER EL MUNDO Y VER EL CONO.....	80
REFERENCIAS.....	83

El segundo volumen: de los límites de cada marco al mundo producido a través de los marcos

Este libro continúa una pregunta abierta en Outfinitismo: ZXQ00000ZXQ y los límites de cada fotograma. El punto de partida allí era simple e incómodo: la razón nunca opera en el vacío. Cada acto de conocimiento comienza dentro de un marco que establece lo que existe para el análisis, qué diferencias importan, qué se puede medir, qué propósito de investigación o decisión está destinado a servir, y quién recibe la autoridad para convertir una conclusión en acción. Metarracionalidad era el nombre dado a una madurez capaz de examinar ese marco sin abandonar el rigor. Outfinitismo fue la concentración de esa madurez en los límites: los límites del modelo, la evidencia, el cálculo, la institución, el cuerpo y el poder. no propuso un sistema final, sino una disciplina de intentos finitos abiertos a la corrección y extensión. [ALBOAIE-2026]

El presente volumen no se limita a repetir ese argumento. lo mueve a un entorno en el que el problema de los marcos se vuelve más visible y más urgente. Los modelos generativos pueden producir, en muy poco tiempo, textos, explicaciones, hipótesis, programas, imágenes, escenarios y justificaciones que hasta hace poco requerían una inversión humana sustancial. Sin embargo, no generan desde un espacio neutral. Cada respuesta está orientada por datos de entrenamiento, arquitectura, post-formación, el rápido, el contexto conversacional, las herramientas conectadas y los criterios por los cuales se enseñó a que el sistema pareciera útil. La inteligencia generativa no ha eliminado los marcos. los ha hecho productivos a una escala sin precedentes.

Aquí es donde aparece la metáfora central del libro: el cono del significado. Una cultura, una institución, una persona o un modelo no ven simplemente una colección de hechos. se orienta dentro de un campo de posibilidades, acerca algunos significados, aleja a otros, reconoce ciertas analogías e ignora otras relaciones. Un cono no es ni el mundo ni una teoría completa de la mente. es una imagen para la dirección selectiva a través de la cual una pluralidad de elementos se convierte en una perspectiva coherente. La metáfora estará conectada, cuidadosamente, a la geometría de las representaciones vectoriales utilizadas en los modelos de lenguaje, pero no se presentará como prueba de que el significado es literalmente un objeto geométrico. es útil precisamente porque conserva

dos intuiciones a la vez: la orientación produce coherencia, y en un espacio de alta dimensión pueden existir muchas orientaciones parcialmente superpuestas.

La imagen también nos ayuda a entender las épocas históricas. Una época no es una persona con una sola creencia, pero puede desarrollar un repertorio dominante de preguntas, metáforas, instituciones y criterios de legitimidad. La modernidad ha examinado fuertemente los conos de la racionalización, la medición, el derecho general, el progreso y la ciencia. Estos conos han producido logros extraordinarios. han reducido la arbitrariedad de rango, han hecho reclamaciones impugnables, han creado tecnologías capaces de transformar la vida y han ofrecido protección legal contra el poder personal. Este libro no parte de una revuelta contra esos logros. comienza por el problema de su éxito. Una cuadrícula que resuelve grandes problemas adquiere prestigio, y el prestigio amplía su jurisdicción. Método se convierte en una visión total, el indicador se convierte en realidad, el procedimiento se convierte en justicia, la predicción se convierte en permiso, y la ciencia puede ser transformada en cientificismo precisamente por aquellos que toman prestada su autoridad sin aceptar la disciplina de sus límites.

Outfinitismo y el esculturalidad se introducen aquí como dos movimientos complementarios. La primera abre el campo: hace visible el marco, compara perspectivas, pregunta qué ha sido excluido y busca una formulación más adecuada. El segundo análisis de retorno a la condición del agente finito: se acaba el tiempo, los datos son parciales, los costos de cálculo, las instituciones tienen mandatos, las decisiones crean pérdidas y algunos errores no se pueden reparar. En una analogía deliberadamente aproximada, pueden ser vistos como un yin y un yang de sabiduría contemporánea. outfinitismo previene la rigidez dentro de un solo mapa; el espiritismo evita la proliferación ilimitada de mapas y convierte la apertura en una decisión responsable. Cada uno contiene la semilla del otro. Comparar tramas es en sí mismo finito, y un límite a veces no se puede entender sin cambiar el marco en el que se definió.

El tema se vuelve especialmente importante cuando un modelo de lenguaje parece entender una filosofía que no ha encontrado en esta forma. La experiencia que motivó este libro fue precisamente de ese tipo. algunas indicaciones sobre metarracionalidad y el outfinitism fueron suficientes para que un modelo produjera formulaciones, analogías y consecuencias equivalentes que parecían preservar la dirección de la intención humana. no podemos probar que el modelo nunca había encontrado fragmentos relacionados., sin embargo, podemos explicar por qué no necesitaba haber memorizado un tratado con las mismas definiciones. Un gran modelo de lenguaje aprende relaciones distribuidas entre contextos, palabras, roles y patrones argumentativos. Un aviso puede orientar temporalmente esta ecología semántica y hacer que una familia de continuaciones coherentes sea más probable. El sentido de comprensión aparece cuando el sistema no

solo repite las palabras, sino que preserva las relaciones entre los límites, el pluralismo, la decisión, la verificación y la sabiduría.

Esta actuación es real, pero su estado sigue abierto. puede representar la generalización semántica y la comprensión funcional sin una experiencia fenomenal o un yo que posee la perspectiva. también puede ser una simulación frágil, dependiente del contexto. El libro no decidirá la cuestión metafísica de la conciencia artificial., sin embargo, utilizará la fórmula arriesgada “alineación como un estado de conciencia” para iluminar una pregunta que el vocabulario estrictamente conductual tiende a simplificar: ¿qué orientación global hace que ciertas interpretaciones, niveles de certeza y prioridades de valor sean más probables antes de que se formule una respuesta?

Por lo tanto, el libro sigue dos líneas de investigación que finalmente se reúnen. la primera es cultural. Las ideas principales escapan a sus dominios originales y se convierten en metáforas, memes, instituciones y formas de ver. La relatividad, la evolución, la teoría cuántica, la cibernética, la información, la racionalidad legal y la ciencia han tenido vidas culturales que excedieron su contenido técnico. algunas transferencias eran fértiles; otras preservaban el prestigio mientras perdían restricciones. La segunda línea es técnica. LLMs muestra que el significado se puede operar a través de representaciones distribuidas, atención contextual y probabilidades de continuación. pueden llevar rápidamente diferentes conos y producir mundos textuales coherentes desde su interior. El encuentro de las dos líneas nos obliga a repensar la relación entre epistemología y axiología: no solo qué se puede generar y justificar, sino qué vale la pena generar, para quién, a qué costo, y bajo cuya autoridad.

Por lo tanto, este volumen es complementario al primero. ZX001ZXQ describió el límite como un objeto de sabiduría y propuso el finito abierto como una imagen de intentos revisables. Outfinitismo pregunta cómo se forman las orientaciones que hacen que los límites sean visibles o invisibles, cómo circulan a través de la cultura y cómo pueden ser imitados o amplificados por la inteligencia artificial. El primer volumen miró el recipiente y el agua; éste mira la dirección de la luz a través de la cual vemos el recipiente, el agua, y a veces solo nuestro propio reflejo.

La metáfora no debe ser absolutada. A veces la red, el campo, el ecosistema, el rol o la práctica describen mejor el fenómeno. Un libro meta-racional debe permitir que sus propios conceptos sean reemplazados, y uno es eutfinista que debe reconocer que ofrece una comprensión finita de un problema mayor. su ambición no es cerrar la realidad dentro de una nueva doctrina, sino hacer visibles relaciones que puedan mejorar la forma en que los seres humanos y los sistemas artificiales generan, eligen y actúan.

INTRODUCCIÓN

La era de la coherencia barata

Gran parte de la cultura moderna se organizó en torno a la escasez de producción. Un libro requería tiempo, un análisis serio requería capacitación, un programa de trabajo requería experiencia y una imagen convincente requería un autor o equipo capaz de ejecutarlo. Estas barreras no garantizaban ni la verdad ni el valor. excluían voces, preservaban jerarquías y permitían a las instituciones confundir el prestigio con el mérito. Sin embargo, el costo de producción tuvo un efecto de filtrado. Antes de que una idea pudiera ocupar el espacio público, alguien por lo general tenía que invertir tiempo, reputación, dinero o trabajo. La inteligencia generativa reduce radicalmente ese costo. La coherencia verbal, la ilustración, la variación, el resumen y la justificación están disponibles casi instantáneamente.

El cambio se puede afirmar sin dramatización: el costo de la expresión está cayendo, mientras que el costo del juicio se está volviendo más visible. producir una versión plausible ya no es tan difícil; determinar qué versión merece atención, verificación e implementación se vuelve más difícil. Una persona puede solicitar diez estrategias en un minuto, pero el tiempo necesario para entender sus consecuencias no cae en la misma proporción. Un modelo puede generar bibliografías, código y argumentos; las referencias aún deben ser comprobadas, programas probados contra el propósito real y argumentos en comparación con la evidencia y las consecuencias.

Esta es una crisis epistémica porque se vuelve difícil separar lo que es verdadero, probable, derivado, inventado o simplemente bien expresado. también es una crisis axiológica porque ninguna función puramente técnica puede decidir lo que merece ser producido. Un centenar de textos correctos pueden consumir la atención necesaria para un texto importante. Un sistema puede optimizar para la utilidad inmediata del usuario mientras degrada el entorno de información compartido. puede generar explicaciones personalizadas que aumentan la comprensión o las justificaciones personalizadas que encierran a una persona dentro de las creencias existentes. La abundancia no nos libera del valor; nos obliga a hacer el valor más explícito.

La crisis llega a una cultura ya marcada por una tensión no resuelta en torno a la razón y la ciencia. Por un lado, la ciencia moderna, el derecho, la ingeniería y la administración produjeron una verdadera emancipación. hacían afirmaciones criticables, dependían reducida de la autoridad heredada y construían instituciones capaces de aprender. Cualquier filosofía que los trata solo como expresiones de una cultura entre otras se vuelve poco seria. Por otro lado, su éxito produjo la tentación de transformar un

conjunto de métodos en una metafísica implícita. lo que no se puede medir se vuelve secundario; lo que no entra en el modelo parece irreal; lo que se puede predecir se trata como legítimo para administrar; y la frase “la ciencia dice” a veces conlleva decisiones morales y políticas que ningún experimento ha demostrado.

La distinción entre ciencia y cientificismo es esencial. La ciencia es una familia de prácticas a través de las cuales las hipótesis están expuestas a la evidencia, la crítica, la replicación, el modelado y la revisión. o el cientificismo aparece cuando el prestigio de esas prácticas se extiende a cuestiones que el método no puede decidir por sí mismo, o cuando una interpretación se presenta como la voz necesaria de la “ciencia”. La ciencia puede estimar los efectos de una política; sin premisas normativas, no puede decidir qué distribución de costos es justa. puede describir los correlatos del bienestar; no puede reducir el significado de una vida a los indicadores disponibles. puede mostrar que algunas creencias sobre el mundo son falsas; no puede reemplazar, con una sola puntuación, todas las relaciones entre la verdad, la libertad, la dignidad, la lealtad, el riesgo y la esperanza.

El cientificismo no es demasiada ciencia, pero muy poca memoria de sus límites. simplifica la historia real del conocimiento, en la que los modelos tienen dominios, los instrumentos tienen resoluciones, se seleccionan los datos y las comunidades científicas son instituciones humanas expuestas a incentivos y poder. Sin embargo, la crítica del cientificismo se vuelve peligrosa cuando se desliza en la anti-ciencia. El carácter perspectival de los modelos no hace que todas las afirmaciones sean iguales. La presencia de valores en la investigación no convierte el experimento en opinión. La posibilidad de error institucional no transforma la intuición personal en un sustituto de la evidencia. outfinitismo y el espiritismo deben preservar este equilibrio: defender la disciplina del conocimiento contra la arbitrariedad al tiempo que se defiende la realidad contra la afirmación de que una disciplina puede agotarla.

En el volumen complementario, la racionalidad se describió como razonamiento dentro de un marco, y metarracionalidad como la posibilidad de razonar sobre el marco también. La formulación merece aparecer cerca del principio porque la historia de este libro depende de ello. Un marco no es simplemente una opinión. contiene una ontología práctica, qué tipo de cosas existen para la decisión, una selección de relevancia, un propósito, una escala, un horizonte temporal, una distribución de la autoridad y una regla para aceptar la evidencia. Un problema bien formulado ya es un mundo pequeño. La razón puede operar impecablemente dentro de ella y aún así producir la conclusión equivocada para el mundo más grande porque la pregunta excluía, desde el principio, lo que importaba.

Un hospital que rastrea el tiempo de espera captura la tensión de una forma simple. El indicador es legítimo, pero una vez que se convierte en un objetivo puede reorganizar el comportamiento: se reclasifican los casos difíciles, se acortan las consultas y la atención que no se ajusta al número comienza a parecerse a la ineficiencia. El sistema no ha abandonado la racionalidad; se ha vuelto más riguroso dentro de un marco que es demasiado estrecho. [GOODHART-1975] El patrón se repite dondequiera que el proxy se recompensa más directamente que el propósito.

Estos ejemplos no nos piden que eliminemos las métricas. Sin medición, las buenas intenciones pueden ocultar el fracaso. nos piden que conservemos una distancia entre el indicador y el valor que representa. Outfinitismo hace visible la elección del indicador y construye alternativas. Outfinitismo requiere que la reclamación permanezca proporcional a la cobertura real de la medición y evita que se oculten los efectos de límite. Axiology pregunta por qué se eligió ese valor, quién gana de la optimización y quién soporta lo que olvida el indicador.

Es aquí donde “conos de significado” entran en escena. Cuando vemos una situación a través del cono de eficiencia, tiempo, costo, rendimiento y cuellos de botella se hacen visibles. A través del cono legal aparecen competencia, regla, precedente y vías de apelación. A través del cono médico aparecen el diagnóstico, el pronóstico y el equilibrio de beneficio y riesgo. A través del cono de la experiencia vivida aparecen miedo, dignidad, relación y significado. Ningún cono es inútil. El problema comienza cuando uno de ellos olvida su dominio y se convierte en la única realidad admitida. no requiere que cada situación sea vista a través de cada cono posible. eso sería otra imposibilidad. requiere la capacidad de notar cuando falta un cono importante y justificar por qué un marco en particular recibe prioridad aquí y ahora.

Outfinitismo añade lo que el pluralismo corre el riesgo de olvidar: comparar perspectivas, costos y acciones no puede esperar a que se resuelva cada disputa. algunas decisiones son irreversibles; se pueden superar algunos límites, se deben aceptar otras y otras se crean artificialmente para proteger una institución. La pregunta ergonal es qué tipo de límite enfrentamos, para quién, en relación con qué propósito y con qué recursos. Los nombres finitos abiertos son una sucesión de intentos reales, cada uno limitado pero capaz de preparar la siguiente extensión. [ALBOAIE-2026]

La inteligencia artificial concentra todos estos problemas. Un LLM es a la vez una compresión de rastros culturales, un instrumento de generación, un participante en el diálogo y un componente de instituciones capaces de actuar. puede moverse entre conos más rápido de lo que los seres humanos pueden explicar sus límites. puede hablar legal, terapéutica, científica, religiosa, gerencialmente o poéticamente. Esta movilidad crea la impresión de una inteligencia que ve los marcos anteriores, pero el modelo no es

necesariamente un árbitro neutral entre ellos. puede estar orientado por el mensaje, por el estilo del interlocutor y por las preferencias aprendidas durante el post-entrenamiento. puede producir una crítica meta-racional y, en la siguiente conversación, una justificación dogmática igualmente fluida.

Por esta razón, la alineación no puede reducirse a preguntar si una respuesta contiene una reclamación prohibida. El sistema debe interpretar la situación, elegir qué información importa, distinguir una pregunta objetiva de una normativa, gestionar el conflicto entre utilidad y riesgo, y decidir cuándo rechazar, verificar, abstenerse u ofrecer más de un marco. los métodos de alineación contemporáneos ya tratan de inducir tales disposiciones a través de la retroalimentación humana, los principios constitucionales, la deliberación sobre las políticas y la supervisión del proceso. [OUYANG-2022] [OUYANG-2022] [[BAI-2022]] [BAI-2022] [IA] La hipótesis de este libro es que podemos entender mejor qué están tratando de lograr estos métodos si hablamos de un estado de orientación: no una propiedad metafísica fija, sino una tendencia contextual a ver los problemas a través de un conjunto particular de relaciones, valores y límites.

La frase “estado de conciencia” se utilizará como una prueba de la metáfora, no como una conclusión sobre la ontología de los modelos. es útil solo en la medida en que puede traducirse en cambios funcionales de prominencia, interpretación y acción; se vuelve engañoso cuando confunde el comportamiento con la experiencia o cambia la responsabilidad de las instituciones humanas a una personalidad presunta de la máquina.

La historia que sigue comienza con la racionalidad moderna y con ideas que superaron sus dominios originales. luego examina los conos culturales, los memes y las épocas epistémicas. En el centro del volumen, metarracionalidad y el outfinitism se reconstruyen como dos movimientos complementarios, explicados suficientemente para un lector que no ha leído el libro anterior. El espejo técnico sigue: por qué un modelo de lenguaje puede parecer entender una filosofía recién formulada y lo que esto nos dice sobre la estructura y la fragilidad del significado. de ese espejo surge el problema axiológico de la generación abundante y, finalmente, la hipótesis de la alineación como orientación.

El libro no termina con una gran arquitectura. no hay evidencia de que un solo “filtro offinitista” resuelva la alineación., sin embargo, hay razones para preferir ciertas disposiciones sobre la certeza y la rigidez performativas: hacer explícito el marco, separar la evidencia del valor, declarar el límite, formular una alternativa relevante y preservar una trayectoria de corrección. Estas disposiciones pueden informar sobre la educación, la gobernanza y la evaluación de los sistemas de IA sin confundirse con una solución total.

La prueba final se aplica a la propia tesis. Los conos pueden convertirse en apofenia; el pluralismo puede convertirse en relativismo; la crítica del cientificismo puede

convertirse en anti-ciencia; el offinitismo puede convertirse en una excusa para estándares débiles; la comprensión de la hipocresía puede convertirse en una justificación para la manipulación; y metarracionalidad puede convertirse en un lenguaje de superioridad para aquellos que tienen el poder de definir qué perspectivas se admiten. Una filosofía que estudia los límites no es creíble si esconde los suyos. Esta es la condición bajo la cual el libro debe ser leído: como un posible contrapeso, no como un nuevo centro del mundo.

LA RAZÓN DENTRO DEL MARCO

Una tecnología moral que a veces olvidó su dominio

La crítica de la racionalidad es fácil cuando se olvida del mundo que la racionalidad ayudó a hacer desaparecer. En las sociedades organizadas principalmente a través del rango, la tradición y la autoridad personal, la pregunta “¿por qué?” podría recibir una respuesta simple: porque la persona de arriba lo ha decidido. La racionalización del derecho, la administración y el conocimiento introdujo un requisito diferente. había que apoyar una reclamación, tener que formular una norma, conocer un procedimiento y comparar una decisión con otras decisiones. Ninguna institución cumplió perfectamente estos ideales, pero su surgimiento cambió la naturaleza de la legitimidad. el poder ya no podía confiar exclusivamente en el origen, el prestigio o la revelación; tenía que producir razones que, al menos en principio, podían discutirse públicamente.

Esta es una de las grandes tecnologías morales de la modernidad. La ciencia separa, imperfectamente pero esencialmente, la verdad de una afirmación del estatus de la persona que la hace. Ley general trata de separar el tratamiento de una persona del capricho de un funcionario. La ingeniería hace que las consecuencias de las decisiones sean calculables antes de que aparezcan en el colapso de una estructura. La medicina compara los tratamientos y convierte la experiencia acumulada en evidencia criticable. La democracia, cuando funciona, requiere que las razones para ejercer el poder se declaren en un lenguaje abierto al desafío. La alternativa a estas prácticas no es automáticamente la sabiduría orgánica de la comunidad. puede ser superstición, obediencia, impulso, corrupción o violencia cubierta por la mitología.

Por lo tanto no comienza por debilitar la razón. comienza protegiendo la razón de su propia extensión incontrolada. Un método que es excelente dentro de un dominio puede llegar a ser peligroso precisamente porque su éxito hace que el dominio sea invisible. Cuando el cálculo resuelve problemas espectaculares, surge la tentación de asumir que todo problema importante debe ser, en su esencia, un problema de cálculo. Cuando el procedimiento legal reduce la arbitrariedad, surge la tentación de identificar la legalidad con la justicia. Cuando el experimento produce un conocimiento robusto, surge la tentación de asumir que lo que no puede ser investigado de la misma manera no puede ser conocido o no importa. El instrumento pierde su borde y comienza a parecerse al mundo mismo.

Entender el marco nos ayuda a ver cómo surge este error sin convertir la racionalidad en un enemigo. todos los problemas formulados para el análisis ya contienen una selección. se han elegido las entidades relevantes, variables, escala, horizonte temporal, propósito y criterio de éxito. Un mapa es inteligente a través de lo que omite. Una hoja de ruta que incluyera cada olor, conversación, piedra, memoria y posibilidad de una ciudad no sería un mapa más completo; se volvería inutilizable. Los modelos producen poder cognitivo a través de la comprensión. El precio es la pérdida. La pregunta madura no es si podemos construir una representación sin pérdida, sino si las pérdidas son aceptables para el propósito y las consecuencias concretas.

Un modelo financiero puede ignorar el historial emocional de una familia al calcular un pago de hipoteca. La omisión se justifica si la cuestión es estrictamente contable. se vuelve insuficiente si el mismo modelo decide el desalojo de la familia y afirma haber agotado el problema moral y político. Una estadística médica puede ser correcta para la población estudiada y aún así no decidir, por sí sola, qué riesgo vale la pena aceptar para un paciente que asigna diferentes pesos a la longevidad, el dolor y la autonomía. Una administración puede aplicar la misma regla a todos y aún así producir injusticia si los datos utilizados para clasificar a las personas han eliminado la diferencia relevante. La coherencia es una propiedad importante. no es sinónimo de neutralidad.

Herbert Simon hizo la finitud del agente central en la teoría de la decisión. los seres humanos no buscan lo óptimo en un mundo completamente conocido; simplifican, usan la heurística y se detienen en soluciones que son lo suficientemente buenas bajo el tiempo y la información disponibles. ZX001ZXQ Esto no es una desviación vergonzosa de la inteligencia. es el entorno en el que existe la inteligencia. Más potencia computacional puede extender la búsqueda, pero no elige automáticamente el objetivo. Más datos pueden mejorar la precisión, pero los datos se recopilan a través de categorías. Más sensores pueden registrar el comportamiento, pero pueden hacer menos visible lo que no aparece en la forma capturada. Una sociedad que mide todo puede convertirse en una sociedad que confunda lo real con lo que su infraestructura sabe contar.

La digitalización convierte esta confusión de un hábito intelectual en un mecanismo ejecutable. Una suposición verbal puede ser cuestionada en una reunión. Una suposición codificada en una base de datos, una regla de elegibilidad o un modelo de clasificación se puede aplicar millones de veces antes de que alguien lo reconozca como una opción. Una categoría administrativa comienza describiendo y termina organizando. las personas alteran su comportamiento para adaptarse al criterio. Las instituciones diseñan flujos de trabajo en torno al indicador. Cuando aparece una denuncia, debe traducirse al idioma del sistema que produjo el problema. La formalización puede ofrecer previsibilidad y, al mismo tiempo, reducir la posibilidad de apelación.

Aquí podemos ver por qué la racionalidad no puede separarse del propósito. La lógica puede decirnos si una conclusión se deriva de las premisas. no puede suministrar las premisas cargadas de valor por sí mismo. Si el objetivo de una plataforma es el tiempo dedicado, las matemáticas pueden optimizar la recomendación. no puede decidir que ocupar la atención es un propósito legítimo o que la ira es un costo aceptable. Si el objetivo de un hospital es reducir el gasto, el análisis puede comparar los tratamientos. Sin una visión de la dignidad, no puede decidir qué formas de cuidado son prescindibles. Si el objetivo de una economía es la producción agregada, los modelos pueden identificar políticas que la incrementen. Solo por su forma técnica, no pueden declarar que el trabajo de cuidado no remunerado, la distribución del riesgo o la continuidad ecológica no son importantes.

Esto no significa que los valores sean inmunes a los hechos. Un propósito puede ser incoherente, imposible o basado en creencias falsas. Una política bien intencionada puede producir el efecto contrario. Un valor que rechaza cada contacto con consecuencias se convierte en un eslogan. Sin embargo, el hecho de que la realidad limite los propósitos no significa que elija entre todos los propósitos posibles. La ingeniería puede describir los costos de un puente que sirve al tráfico y de uno que protege un barrio. no puede decidir por sí mismo qué tipo de ciudad vale la pena construir. Llamando a esta elección “política” no la hace irracional; muestra que la racionalidad instrumental necesita una racionalidad de los fines y juicio sobre los valores.

El volumen complementario llamado metarracionalidad la capacidad de separar y luego recombinar estos niveles: observación, inferencia, propósito, elección y la potencia que convierte la elección en consecuencia. ZX003ZXQ La distinción importa porque los conflictos públicos a menudo los mezclan. Una parte dice que “los datos son claros” cuando la verdadera disputa se refiere a quién asume el costo. Otro invoca identidad o valor para proteger una afirmación objetiva que ha sido refutada. Un informe introduce una decisión moral en un parámetro, y la producción se presenta más tarde como si la moralidad se hubiera eliminado a través del cálculo. Metarracionalidad no afirma que los niveles pueden estar perfectamente aislados. Valores de atención directa, atención selecciona evidencia, evidencia puede cambiar valores, y las instituciones deciden qué información llega a existir. El propósito es hacer visibles las transiciones.

Esta visibilidad es también un problema de poder. la persona o institución que define el marco decide en parte quién aparece en el problema, qué sufrimiento se vuelve medible y qué resultado se puede llamar éxito. cuanto mayores sean las consecuencias y cuanto más débiles sea la posibilidad de desafío, menos legítimo es que el marco permanezca implícito. Una fórmula no es más neutral que la cuestión para la que fue construida. Un modelo no es más objetivo que la relación entre sus datos, su finalidad, y el mundo sobre

el que está autorizado a actuar. El rigor interno puede coexistir con la injusticia externa, y esta posibilidad no es un accidente periférico. define el límite de la racionalidad dentro del marco.




Diagrama 1. El marco como intermediario entre realidad y decisión

De la precisión al cientificismo, las métricas y la manipulación

Si el éxito local tiende a expandir la jurisdicción de un método, entonces la modernidad debe entenderse no solo a través de sus ideas, sino a través de la dinámica de su exageración. Racionalidad surgió como una corrección a la arbitrariedad y produjo instituciones capaces de autocorrección. Entonces, en algunos contextos, el ideal de racionalización se redujo a lo que podía formalizarse, estandarizarse y optimizarse. Max Weber observó el poder y la ambivalencia de esta transformación: la calculabilidad de la ley y la administración apoya la previsibilidad, pero también puede encerrar la vida dentro de una “casa” de procedimientos en los que el significado sustantivo se vuelve cada vez más difícil de formular. [[WEBER-1922]] La regla protege contra el capricho, pero también puede convertirse en el lenguaje a través del cual el capricho institucional se declara impersonal.

La ciencia se enfrenta a una tensión similar. La objetividad no es una visión pura sin un observador. es una familia histórica de prácticas que reducen la dependencia de una conclusión de la preferencia de un solo observador: instrumentos calibrados, descripción de métodos, replicación, crítica, estadísticas, archivos y comunidades que pueden verificar. [DASTON-GALISON-2007] [DASTON-GALISON-2007] El poder de la ciencia proviene precisamente de exponer una hipótesis a una realidad que puede negarse a cooperar con el deseo del investigador. Pero un resultado científico no entra en la sociedad sin interpretación. Un efecto promedio debe estar relacionado con una persona; un modelo debe ser extrapolado; un riesgo debe ser comparado con otro; y una decisión debe incluir los costos que el experimento no midió.

O el cientificismo aparece cuando se olvida esta mediación. no es un fuerte respeto por la evidencia ni la ambición de explicar. es la extensión del prestigio científico a través de la frontera entre la descripción y el valor, entre modelo y realidad, entre correlación y autorización para intervenir. La proposición “la ciencia ha demostrado que X produce Y bajo ciertas condiciones” puede ser sólida. La propuesta “por lo tanto la sociedad debe elegir Z” contiene premisas adicionales sobre prioridades, derechos, distribución de costos e incertidumbre aceptable. A veces esas premisas están justificadas. El problema comienza cuando están ocultos a la sombra de la capa blanca o del gráfico.

Ciencia	Cientismo
Sus derechos se refieren a métodos, dominios y la posibilidad de corrección.	Convierte el prestigio del método en una autoridad general sobre el significado y el valor.
De distinción de datos, modelo, interpretación y decisión.	Comprime estos niveles en la fórmula “dice la ciencia”.
Trata los límites como parte del resultado.	Trata los límites como detalles que debilitan el mensaje.
Puedo cooperar con la ética, el derecho y la experiencia vivida.	Los trata como ruido si no pueden reducirse a la misma métrica.

Esta distinción no debe utilizarse como arma contra conclusiones inconvenientes. es fácil llamar a cualquier resultado que contradiga una creencia preferida “cientificismo”. La crítica se vuelve madura solo si conserva jerarquías epistémicas. Un estudio bien realizado no es igual a un testimonio aislado, y un consenso construido a través de múltiples métodos no es simplemente una opinión colectiva. Outfinitismo no dice que todos los conos tienen igual potencia. dice que su poder debe estar relacionado con la pregunta y con su dominio de validación. Outfinitismo no baja los estándares. requiere que la fuerza de la conclusión sea proporcional a lo que realmente se ha verificado.

Métricas hacen que el problema sea visible porque convierten los valores en objetos administrables. Un buen indicador comprime una realidad compleja en una señal útil. El número de infecciones, el tiempo de respuesta, la tasa de graduación o el consumo de energía pueden revelar fallas que la intención oculta. Pero una vez que la recompensa se adjunta al indicador, la gente aprende a optimizar el número. Goodhart formuló esta dificultad en el contexto de la política monetaria, y la observación se convirtió en una ley informal de las instituciones: cuando una medida se convierte en un objetivo, su relación con el valor medido se degrada. [GOODHART-1975]

Un servicio de apoyo que recompensa el número de tickets cerrados puede desalentar la resolución de casos difíciles. Un programa de seguridad juzgado por un bajo número de incidentes reportados puede enseñar a la organización a no informar. Un equipo de investigación medido por entregables puede multiplicar documentos y reducir el tiempo disponible para la investigación que los haría valiosos. Cada sistema se hace más eficiente dentro de la representación. Esa misma eficiencia amplifica la pérdida entre proxy y propósito.

Aquí la hipocresía adquiere una función adaptativa. Las instituciones declaran ideales que son más simples y superiores a los que pueden implementar. “Todo el mundo es igual ante la ley”, “el mérito decide”, “la ciencia persigue solo la verdad”, “la seguridad es nuestra prioridad” o “el usuario está en el centro” son compresiones normativas. proporcionan dirección y hacen posible la crítica. La vida real contiene recursos insuficientes, funciones incompatibles, intereses, apegos, excepciones y compensaciones. Cuando no se puede reconocer la distancia entre el ideal y la práctica, la organización aprende a preservar el lenguaje del ideal y a trasladar la adaptación a zonas opacas. La hipocresía se convierte en el lubricante de un sistema que exige una pureza imposible.

Reconocer esta función no es justificación moral. Algunas discrepancias son compromisos inevitables; otras son la explotación. La diferencia depende de la potencia, de quién se beneficia, de los costes externalizados y de la posibilidad de corrección. Un juez puede necesitar discreción para aplicar una regla general a un caso en particular. Un funcionario que usa la misma discreción para los favores corrompe la función. una persona puede expresar cortesía sin revelar cada reacción interna; un líder que utiliza el lenguaje del cuidado para ocultar el daño sistemático practica la hipocresía extractiva. Outfinitismo intenta ver tanto la función ideal como la adaptativa. Outfinitismo pregunta qué ideal se puede implementar en condiciones reales, qué transición es posible y qué costo ya no se puede justificar por la finitud.

Este problema importa porque los ideales simplistas pueden producir precisamente el comportamiento que condenan. Una cultura que exige una perfecta consistencia moral enseña a la gente a ocultar las contradicciones. Una organización que reclama cada decisión sigue el procedimiento crea procedimientos ceremoniales y negociaciones informales invisibles. Una institución científica que describe la investigación como un proceso puramente desinteresado puede llegar a ser menos capaz de discutir los incentivos, el prestigio y la competencia que lo conforman. En todos estos casos, el lenguaje absoluto no elimina la adaptación; hace que la adaptación sea más difícil de observar.

La racionalidad también puede convertirse en un instrumento de manipulación sin violar formalmente la lógica. Un actor puede seleccionar premisas convenientes, exigir a

un oponente un nivel de evidencia que no se requiere de sus propias afirmaciones y usar la incertidumbre asimétricamente. Una institución puede encargar análisis hasta que el retraso sirva a su interés. Un informe puede delimitar la pregunta para que la solución deseada parezca inevitable. La forma del argumento sigue siendo racional, pero su orientación es estratégica. La racionalidad manipuladora no siempre miente; puede seleccionar verdades que lleven al interlocutor hacia una conclusión predeterminada.

IA hace que este poder sea más barato. Un modelo puede generar rápidamente justificaciones adaptadas al vocabulario de cada público, producir cantidades de argumento que superen la capacidad de respuesta e imitar el equilibrio sin cambiar el objetivo de la institución que lo utiliza. Una empresa puede ofrecer una explicación personalizada de una decisión automatizada, pero la explicación puede ser solo una historia post hoc plausible. Un sistema puede enumerar los riesgos y continuar optimizando la misma métrica. puede simular empatía mientras el proceso no ofrece un camino real de atractivo. La coherencia verbal se convierte en la decoración de un poder que no ha cambiado su marco.

La sabiduría es el límite interno de esta racionalización. no rechaza la regla, sino que preserva la conexión entre la regla y la vida. no rechaza la medición, pero recuerda lo que estaba comprimido. no rechaza la ciencia, pero separa la predicción del permiso. no rechaza el ideal, sino que se niega a convertir la imposibilidad de un cumplimiento total en un aparato de vergüenza y ocultamiento. Outfinitismo proporciona la movilidad necesaria para ver otros marcos. Outfinitismo proporciona la disciplina necesaria para decidir bajo condiciones finitas y para declarar lo que queda fuera de la certificación. Juntos no disminuyen la razón. lo restauran al estado de un instrumento extraordinario que se hace más fuerte cuando conoce su borde.

CAPÍTULO 2

IDEAS QUE ABANDONAN SU DOMINIO

Relatividad, teoría cuántica, evolución y cibernética

Algunas teorías adquieren una segunda vida después de abandonar el laboratorio, la fórmula o la comunidad que las produjo. La segunda vida no es una copia fiel. Cultura toma una imagen, una relación, una palabra o una tensión y la reconstruye según sus propias necesidades. Una teoría física puede convertirse en una metáfora de la experiencia del tiempo; una explicación biológica puede convertirse en una ideología social; un concepto de ingeniería puede convertirse en un lenguaje para la familia y la organización. La transferencia es casi inevitable. Una cultura no puede mantener sus principales instrumentos de conocimiento aislados de la forma en que imagina el mundo. El problema no es que la transferencia existe, sino el estado que se le da.

La relatividad de Einstein es un ejemplo privilegiado porque la distancia entre la teoría técnica y su vida cultural es fácil de observar. En física, la relatividad especial y general son teorías matemáticas precisas sobre medición, marcos de referencia, espacio-tiempo, energía y gravedad. no afirman que cada opinión sea igualmente válida. Por el contrario, buscan leyes e invariantes que permitan la traducción entre descripciones hechas desde diferentes marcos. La cultura moderna, sin embargo, retuvo sobre todo el hecho de que el observador y el marco importan. Literatura, arte y filosofía encontraron en la relatividad una imagen adecuada para un mundo en el que la simultaneidad social se estaba fragmentando, los ritmos de la ciudad se aceleraban, las tradiciones entraban en contacto y la única perspectiva perdía credibilidad. [WHITWORTH-2001] [WHITWORTH-2001]

Esta influencia no debe ser juzgada solo preguntando si un novelista entendió los tensores. La cultura no estaba obligada a convertirse en un libro de texto de física. La transferencia podría ser legítima como metáfora: la experiencia humana depende de la posición, y dos descripciones pueden diferir sin que la realidad se vuelva arbitraria. Sin embargo, la fórmula popular “todo es relativo” a menudo perdió la mitad de la lección. preservó la pluralidad de perspectivas y olvidó la disciplina de transformación entre ellas. La relatividad científica no elimina la verdad; redefine las condiciones en las que se pueden comparar las descripciones. En términos meta-racionales, la lección fértil no es que cada cono tenga su propia verdad aislada, sino que debemos hacer explícito el marco,

encontrar las relaciones de traducción y buscar lo que permanece estable bajo un cambio de perspectiva.

La mecánica cuántica produjo una migración aún más dramática. Palabras como “observador”, “incertidumbre”, “enredo”, “energía”, “frecuencia” y “campo” entraron en la espiritualidad, el marketing, la psicología popular y la medicina alternativa. Hay preguntas filosóficas genuinas que rodean la teoría cuántica, y el desarrollo de tecnologías cuánticas muestra cuán concreto es el formalismo. Pero en el discurso popular, los términos a menudo se desvinculan de las matemáticas, la escala física, el mecanismo y el procedimiento de medición. El prestigio permanece mientras las restricciones desaparecen. Una terapia se llama “cuántico” sin identificar un proceso físico relevante, un protocolo de prueba o una predicción que podría fallar. [BRANG-2025]

Podemos llamar a esta operación lavado de prestigio semántico. Una palabra mantiene la autoridad que adquirió en un dominio riguroso mientras perdía las obligaciones que le daban significado allí. No todos los usos metafóricos son el abuso. Para decir explícitamente que el entrelazamiento ofrece una imagen poética de interdependencia puede ser fértil, siempre que no se afirme que una relación social tenga un mecanismo cuántico. El abuso comienza cuando una metáfora se presenta como una explicación, la explicación como un mecanismo y el mecanismo como justificación para la intervención. La palabra cruza clandestinamente de la analogía a la causalidad.

El darwinismo muestra otra forma de escape. La selección natural le da a la biología una estructura poderosa para comprender la variación, la herencia y la adaptación. Transferida a la economía o al análisis institucional, la idea de selección puede explicar por qué algunas prácticas sobreviven sin planificación central. Las culturas, idiomas y organizaciones se pueden estudiar a través de variaciones y presiones selectivas. Los problemas surgen cuando la descripción de un proceso se convierte en una norma. El hecho de que un rasgo sobreviviera no lo hace moralmente bueno. El hecho de que una empresa gane en competencia no hace que el orden social que produjo la victoria sea justo. “Supervivencia del más apto” se convierte en una justificación del más fuerte solo al introducir una premisa normativa que la biología no suministra.

El error tiene una estructura recurrente. El dominio fuente describe un mecanismo. El dominio objetivo convierte el mecanismo en una imagen de lo natural. El “natural” se utiliza para legitimar lo que debe ser aceptado. La transferencia oculta el movimiento de la que debe. Outfinitismo hace visible ese movimiento. Nos pide que declaremos los límites de la analogía: qué relaciones se conservan, a qué escala y en qué condiciones se rompe la correspondencia.

Cybernetics tenía una familia diferente de estructuras: retroalimentación, autorregulación, control, comunicación, estabilidad y bucles recursivos. [ASHBY-1956]

Estos conceptos fertilizaron la biología, la psicología, la antropología, la teoría de la organización y la terapia familiar. aquí la transferencia era a veces más que una metáfora. Un sistema biológico y un sistema técnico pueden tener relaciones de retroalimentación formalizables. Sin embargo, cuando el lenguaje del control se aplica a los seres humanos, aparecen dimensiones que no existen en un termostato: interpretación, contestación, dignidad, poder, anticipación de la regla y la capacidad de cambiar el objetivo. Un gerente que trata a una organización como un mecanismo regulador puede notar bucles importantes y perder el hecho de que sus miembros no son simplemente componentes, sino participantes capaces de rechazar el significado que se les impone.

“Información” y “computación” probablemente se han convertido en los conceptos más expansivos de la era digital. Los genes se describen como programas, el cerebro como un procesador, el organismo como un sistema de información, la sociedad como una red y el universo como una forma de computación. Algunas de estas analogías soportan modelos precisos. Otros son vocabularios de orientación. hacen que la codificación, la transformación, el estado y el algoritmo sean visibles, pero pueden ocultar el cuerpo, la energía, la historia, el contexto y el valor. Para decir que una persona “procesa información” puede ser cierto en un nivel y casi inútil en otro. Una descripción que es demasiado general se vuelve imposible de refutar precisamente porque ya no discrimina entre los fenómenos.

Estos ejemplos muestran que una idea no viaja como un solo paquete. términos, relaciones, métodos, metáforas, prestigio o implicaciones normativas pueden migrar. A veces la estructura se conserva mientras cambia el vocabulario. En otras ocasiones se conserva el vocabulario y se pierde la estructura. Un crítico puede tener razón en que la literatura no adoptó el formalismo de la relatividad, y un historiador cultural puede tener razón en que la relatividad cambió la imaginación moderna. están discutiendo diferentes tipos de influencia. Para juzgar una transferencia, debemos preguntar qué fue exactamente transferido y qué reclamo se le asigna en el nuevo dominio.

Transferencia responsable	Traslado abusivo
Declara si se trata de una analogía, modelo o mecanismo y no cambia de estado de manera clandestina.	Utiliza la ambigüedad para pasar de la metáfora a la causalidad.
Estados cuyas relaciones se conservan y donde se rompe la correspondencia.	Conserva solamente las palabras o el prestigio del dominio fuente.

Transferencia responsable	Traslado abusivo
Acepta pruebas y contraejemplos proporcionales a la reclamación.	Se vuelve más difícil de refutar a medida que la afirmación crece.
No convierte la descripción en una norma sin premisas axiológicas explícitas.	Presenta lo que parece “natural” como lo que debe ser aceptado.

No necesitamos una fuerza policial para metáforas. as de cultivo se volverían estériles si cada analogía requiriera una demostración mecanicista. La poesía, la filosofía y la invención científica utilizan comparaciones con espacios abiertos de pensamiento. El requisito es más modesto y más importante: no utilice la libertad de la metáfora para tomar prestada la autoridad del mecanismo. cuanto mayores sean las consecuencias -tratamiento médico, política pública, evaluación de una persona- más fuerte debe ser el puente entre dominios.

Memes, atractores y ecología de la reconstrucción

La metáfora del meme ofrecía una imagen memorable para la vida cultural de las ideas. Los contenidos competirían por la atención, la memoria y la transmisión, casi como replicadores en un ecosistema. [DAWKINS-1976] La imagen es fértil porque cambia la pregunta de la intención del autor a la dinámica de la población. Una idea puede sobrevivir no porque sea cierta, sino porque es fácil de recordar, confirma la identidad, produce emociones, se beneficia del prestigio o se adhiere a una institución. puede combinar con otras ideas en un conjunto cuyas partes se protegen entre sí. puede ofrecer justificaciones para comportamientos que aseguren su propia reproducción.

Sin embargo, tomar la metáfora literalmente crea problemas. Las ideas no son organismos con metabolismo e intenciones propias. los seres humanos no copian pasivamente representaciones idénticas. reconstruyen lo que escuchan de acuerdo con la memoria, el interés, el lenguaje y la expectativa. La investigación sobre los atractores culturales muestra que la estabilidad de una forma puede surgir no solo a través de la replicación fiel, sino a través de transformaciones convergentes. se reconstruyen diferentes variantes en direcciones similares porque ciertas formas son más fáciles de entender, recordar o legitimar en un entorno determinado. [SPERBER-1996] [SPERBER-1996] [[BUSKELL-2017]]

Esta observación explica por qué las teorías sofisticadas entran en la cultura en formas compactas. Relatividad se convierte en “la verdad depende de la perspectiva”. La evolución se convierte en “la victoria fuerte”. La teoría cuántica se convierte en “el

observador crea la realidad”. La cibernética se convierte en “todo es retroalimentación”. La neurociencia se convierte en “el cerebro nos obliga”. Estas fórmulas son atractores. comprimen una tensión en una frase que es fácil de usar. no siempre son completamente falsos; es precisamente la mezcla de verdad, exageración y utilidad lo que los hace resistentes.

Podemos hablar de una ecología memética si preservamos el carácter metafórico del término. idas se activan e inhiben entre sí. Una creencia sobre el mérito puede apoyar una creencia sobre los mercados; una creencia sobre la identidad puede decidir qué fuentes son confiables; una historia sobre el progreso puede hacer que los costos actuales parezcan inversiones inevitables. instituciones proporcionan hábitats. La universidad selecciona a través de planes de estudio, revistas y reputación. La plataforma selecciona a través de recomendaciones y recompensas de atención. El Estado selecciona a través de categorías legales. La empresa selecciona a través de indicadores y promociones. Una idea incrustada en el software o procedimiento ya no depende de la convicción explícita de cada participante. continúa organizando el comportamiento a través de la infraestructura.

Por esta razón, el “cono de significado” no debe ubicarse exclusivamente dentro de la cabeza. Una perspectiva se distribuye entre vocabulario, hábito, instrumento, rol e institución. La racionalidad jurídica vive en la mente del abogado, pero también en códigos, archivos, precedentes, plazos y vías de apelación. La ciencia vive en el investigador, pero también en instrumentos, protocolos, bases de datos, revisión por pares y estándares de informes. El capitalismo o el nacionalismo no son meramente doctrinas que la gente acepta; son prácticas, derechos, fronteras, contratos, símbolos e incentivos. Un cono cultural se vuelve estable cuando el medio ambiente hace que sea fácil de llevar incluso para aquellos que no conocen su teoría.

Esto nos ayuda a entender las épocas históricas sin volver a clasificarlas. Una época no tiene una sola mente. Conos dominantes coexisten con tradiciones residuales, subculturas y contramarcos. Sin embargo, las instituciones pueden hacer que algunas preguntas sean fáciles de formular y otras casi imposibles de escuchar. Un investigador puede encontrar natural buscar un mecanismo, un administrador de un indicador, un abogado de competencia y un activista para la distribución del poder. cada pregunta puede revelar algo real. La ecología se empobrece cuando una especie conceptual ocupa cada nicho.

La viralidad de una idea no es evidencia de la verdad. es evidencia de que la idea se ajusta a un entorno de transmisión. algunas ideas verdaderas son difíciles de comunicar; algunas ideas falsas satisfacen poderosas necesidades psicológicas e institucionales. o sería igualmente erróneo tratar la viralidad como superficial. Una idea que reorganiza las instituciones produce la realidad social aunque su descripción del mundo sea falsa. Una

teoría racial pseudocientífica puede ser empíricamente refutada y aún estructurar leyes, distribuciones de recursos y sufrimiento. Efecto cultural y verdad epistémica son dos ejes diferentes.


La ecología de las ideas no elimina la responsabilidad. El lenguaje de los memes puede sugerir que nadie decide nada porque las representaciones simplemente se “difunden”. En realidad, los actores con poder seleccionan lo que se amplifica, financia, enseña y implementa. Plataformas eligen funciones de recomendación. Instituciones eligen los estándares. Líderes eligen metáforas. idades elegidas para retransmitir y cuándo corregir. Las dinámicas sistémicas explican por qué los resultados exceden la intención individual, pero no absuelven a los actores que pueden intervenir.

El mismo principio aclara la hipocresía sin absolverla. Una cultura de ideales que no se puede implementar selecciona el comportamiento para mostrar, pero la posición moral depende del poder. El subordinado que simula el entusiasmo en un entorno coercitivo y el líder que simula la transparencia para preservar el control responden a diferentes presiones y producen diferentes costes. Ecología describe el mecanismo; la axiología preserva la asimetría.

El modelo de lenguaje entra en esta ecología como una máquina de reconstrucción. se entrenó en rastros de muchos conos y puede producir nuevas variantes que se adapten a los atractores culturales. puede hacer que una idea sea más accesible, traducir entre vocabulario técnico y ordinario y descubrir analogías fértiles. también puede acelerar la degradación semántica. Una formulación simple y persuasiva se puede producir en millones de variantes, adaptada a cada público, y separada de la fuente que la habría limitado. la IA no inventa la ecología memética, pero reduce el costo de la reproducción y la mutación.

Sigue un requisito para la cultura generativa: la alfabetización ya no significa solo evaluar la proposición. debemos observar qué cono lleva, qué prestigio toma prestado, qué cambio de estatus realiza y qué institución lo amplifica. Una idea puede ser verdadera y usarse manipulativamente. puede ser falsa y simbólicamente fértil. puede ser una buena metáfora y un mal mecanismo. Outfinitismo separa estas funciones. Outfinitismo requiere la fuerza de uso para no exceder el puente de validación. Axiología pregunta qué sucede con los seres humanos después de que la idea se convierte en infraestructura.

La estructura y los límites pueden preservarse o perderse por el camino



Social selection sometimes favors transmission rather than truth.

La selección social favorece a veces la transmisión antes que la verdad.

Diagrama 2. La vida cultural de una teoría

CONOS DE SENTIDO Y LAS ÉPOCAS QUE VEN EL MUNDO A TRAVÉS DE ELLOS

La geometría como metáfora disciplinada

La metáfora del cono surgió de una modesta observación técnica. En muchos sistemas de representación semántica, palabras, oraciones o documentos están asociados con vectores en un espacio de alta dimensión. La similitud de coseno compara la dirección de estos vectores, en lugar de solo su distancia bruta. Si elegimos una dirección de referencia y consideramos que las representaciones se cierran cuando su ángulo con él permanece por debajo de un umbral, la región resultante tiene una forma cónica. Los puntos en su interior no son idénticos, pero están orientados de manera similar a ser tratados como vecinos en relación con esa referencia.

Esta propiedad no prueba que el significado sea literalmente un cono o que dentro de un LLM haya objetos geométricos limpios correspondientes a filosofías. Las representaciones contextuales cambian de una capa a otra, la misma palabra ocupa diferentes posiciones en diferentes contextos, y la geometría global puede ser anisotrópica y difícil de interpretar. [ETHAYARAJH-2019] En un modelo grande, el comportamiento se produce por sucesivas transformaciones, atención, activaciones distribuidas y probabilidades condicionales. El cono es una compresión construida por el observador, no una fotografía del mecanismo interno.

Aun así, la imagen conserva algo valioso. Una orientación semántica no necesita una definición exhaustiva para producir consecuencias coherentes. Si un aviso reúne ideas sobre la finitud, la pluralidad de marcos, la precaución epistémica, la verificación, la sabiduría y la posibilidad de extender los límites, el modelo puede continuar en una dirección que los conecte. Muchas frases diferentes entran en el mismo campo de compatibilidad. Algunos enfatizarán la filosofía de la ciencia, otros la psicología, las matemáticas, el gobierno o la IA. El cono no determina una frase; hace que una familia de continuaciones sea más probable.

La idea también se aplica a los seres humanos. Una persona que mira a través de una red económica nota incentivos, costos, escasez e intercambio. Una persona legalmente orientada anota competencia, regla, evidencia y procedimiento. Una orientación

terapéutica hace visible el sufrimiento, la relación y la defensa psicológica. Una orientación de ingeniería busca función, mecanismo, fiabilidad y fallo. Una orientación religiosa puede seleccionar el significado, el pecado, la esperanza, el ritual y la trascendencia. Estos conos no son meramente opiniones sobre la misma lista de hechos. Ayudan a construir la lista. hacen que algunas entidades aparezcan como objetos relevantes y dejan a otras en segundo plano.

En un conflicto laboral, el cono legal puede preguntar si se siguió el procedimiento. El cono económico puede preguntar qué costo crea la decisión y qué señal envía. El cono psicológico puede notar miedo y estatus. El cono moral puede preguntar quién está siendo tratado como un medio. El cono organizacional puede ver el efecto sobre la confianza. ninguna de estas preguntas es automáticamente suficiente. Una decisión puede ser legal y destructiva, eficiente e injusta, empática e imposible de implementar. comienza cuando podemos distinguir estas orientaciones y discutir por qué uno debe recibir prioridad en un caso sin declarar a los demás irreales.

La fragilidad del cono proviene de la pluralidad de direcciones de referencia. En un espacio de alta dimensión, la misma representación puede estar cerca de varias direcciones. Una palabra como “libertad” puede entrar en un cono legal, moral, económico, psicológico, nacional o espiritual. Context decide qué barrios se activan. Un pequeño cambio de rol puede reorganizar el significado: la “libertad” en un fallo judicial no funciona como lo hace en un anuncio o una confesión. Ni las personas ni los modelos necesariamente tienen una única orientación estable. Un investigador puede ser riguroso en el laboratorio y dogmático en la política; un abogado puede pensar de manera procesal en el trabajo y relacionamente en casa. Los conos se superponen, se activan situacionalmente y pueden entrar en conflicto dentro de la misma persona.

El cono describe, por lo tanto, una tendencia de selección, no una esencia oculta. A veces la red, el campo, el papel, la práctica o la narrativa es la mejor imagen. Un concepto meta-racional debe permitirse ser reemplazado; si lo explica todo, ha perdido su poder de discriminación.

Con esta precaución, el cono ofrece una imagen más precisa que la lente en dos aspectos. La lente sugiere que hay una escena completa que el instrumento simplemente distorsiona o pone en foco. El cono sugiere la selección de una región de un espacio más amplio de posibilidades y relaciones. Además, una lente parece ser un objeto singular, mientras que los conos pueden ser múltiples, superpuestos y orientados de manera diferente. Una cultura puede llevar simultáneamente el cono científico de la evidencia, el cono legal de los derechos, el cono económico del crecimiento y el cono religioso del significado. los problemas surgen no solo del error de cada uno, sino de la jerarquía implícita entre ellos.

El cono también sugiere que el significado tiene bordes porosos. Algunas expresiones se encuentran cerca del eje y son fácilmente reconocidas como representativas. Otros son periféricos, donde la membresía depende del umbral y el contexto. Una doctrina tiene textos canónicos e interpretaciones marginales. Una cultura tiene prácticas centrales e híbridos. Un modelo puede responder de manera fiable a ejemplos típicos y comportarse de manera impredecible en casos límite. La alineación es a menudo más difícil precisamente en el borde: cuando las reglas entran en conflicto, la intención es ambigua, el riesgo es indirecto o el contexto no se parece a los ejemplos utilizados en el entrenamiento.




Diagrama 3. Varios conos sobre la misma situación

La metáfora se convierte así en una propuesta de alfabetización. Entender un texto no significa solo parafrasear sus proposiciones. significa reconocer qué orientación pide al lector que adopte, qué relaciones hace naturales, qué alternativas se vuelven difíciles de pensar y qué autoridad toma prestada. Un anuncio puede llevar el cono de elección individual mientras oculta la infraestructura que restringe las opciones. Un informe puede llevar el cono de medición y hacer que la experiencia subjetiva parezca ruido. Una ideología puede llevar el cono del conflicto e interpretar cada objeción como un síntoma del adversario. En la era generativa, esta alfabetización se vuelve aún más importante porque un modelo puede construir rápidamente textos coherentes desde cualquier orientación solicitada.

Epistemes, culturas e instituciones: cuando el cono se convierte en mundo

La filosofía y la historia de la ciencia han ofrecido varios conceptos cercanos a lo que llamamos un cono de significado. Thomas Kuhn describió paradigmas a través de los

cuales las comunidades científicas comparten problemas, métodos y criterios de éxito ejemplares. [[KUHN-1962]] Ludwik Fleck hablaba de estilos de pensamiento y colectivos que hacen posible ciertos hechos como objetos de conocimiento. [KUHN-1962] Ian Hacking mostró que los estilos de razonamiento no solo proporcionan métodos, sino también tipos de proposiciones, objetos y explicaciones que se vuelven inteligibles. ZX0007ZXQ Michel Foucault utilizó la noción de episteme para describir las condiciones históricas que organizan la posibilidad del discurso en una época. ZX0008ZXQ Karin Knorr Cetina estudió diferentes culturas epistémicas en las que las ciencias construyen conocimiento a través de distintas prácticas y objetos. [FLECK-1935]

Estas tradiciones no son idénticas y no deben comprimirse en un solo concepto., en conjunto, sin embargo, apoyan una idea importante: los modos de conocer no son simplemente colecciones de afirmaciones. son prácticas que determinan lo que puede aparecer como un problema, objeto, evidencia y explicación. Un laboratorio de física de partículas, una clínica, una sala de audiencias y un archivo histórico no solo utilizan datos diferentes. construyen diferentes relaciones entre observador, instrumento, sujeto y validación. Exigiendo que todos ellos imiten el mismo modelo de objetividad no puede producir unidad, sino la pérdida del objeto.

Las épocas históricas pueden ser vistas como ecologías en las que algunos de estos conos adquieren una posición dominante. Europa medieval no era reducible a la religión, y la modernidad no es reducible a la ciencia. El cambio en las fuentes de legitimidad es real. En un orden teológico, las cuestiones de último significado y orden podrían estructurar la ley, la política y la naturaleza. La modernidad cambió el centro hacia la observación, el cálculo, el individuo, el progreso, el mercado, el estado y el procedimiento. La era industrial hizo el mecanismo y la producción metáforas generales. La era de la información ha hecho que la red, el código y la optimización sean casi omnipresentes.

Para decir que una época “ve” a través de un cono es una abreviatura. contiene conflictos, minorías y transiciones. Las rejillas viejas no desaparecen cuando surgen otras nuevas. La religión convive con el cientificismo, la tradición con el individualismo, el romanticismo con la administración algorítmica. Una persona puede habitar varias épocas a la vez: usar la medicina moderna, practicar rituales tradicionales, pensar económicamente en el trabajo y moralmente en casa. Esta superposición produce tensiones e hipocresías. Sociedad declara el universalismo legal pero conserva lealtades particulares. celebra el mérito pero funciona a través de redes. invoca la autonomía individual pero optimiza el comportamiento a través de infraestructuras persuasivas.

Los conos se vuelven duraderos cuando están integrados en instituciones. Una idea de mérito gana fuerza a través de exámenes, currículums, clasificaciones y procedimientos

de selección. Una idea de riesgo se convierte en realidad a través de políticas, puntuaciones y umbrales. Una idea de salud se materializa en códigos de diagnóstico, protocolos y reembolso. Una idea de productividad se instala en cuadros de mando, objetivos trimestrales y software de monitoreo. Los participantes no tienen que creer explícitamente en la filosofía del sistema. basta con que se adapten a sus recompensas.

Este proceso explica cómo una cuadrícula puede producir su propia confirmación. Si una escuela define la inteligencia por lo que mide una prueba, el plan de estudios se reorganizará para aumentar la puntuación, y la puntuación más tarde parecerá ser una descripción aún mejor de la inteligencia. Si una plataforma define la relevancia a través del compromiso, los productores se adaptarán y el contenido atractivo ocupará más de la realidad. Si el mercado define el valor a través del precio, las actividades que son difíciles de monetizar recibirán menos recursos, y la falta de inversión parecerá demostrar su menor valor. El modelo no sólo ve el mundo, sino que participa en su configuración.

Esta reflexividad es especialmente poderosa en el dominio social. Un planeta no cambia su órbita porque ha leído la teoría del astrónomo. Una persona puede cambiar el comportamiento después de aprender cómo se ha clasificado. Una institución puede explotar la regla por la cual se mide. Una predicción puede llegar a ser autocumplida o fracasar porque los actores reaccionaron a ella. El límite del modelo se encuentra entonces en el bucle entre la representación y el mundo, no solo en los datos iniciales.

Por eso necesitamos una ecología de modelos. no basta con mantener múltiples perspectivas en un museo tolerante. deben ser capaces de corregir, traducir y limitarse mutuamente. El modelo económico puede revelar incentivos que el discurso moral ignora. El modelo moral puede revelar los costos ocultos por el agregado económico. La ley puede crear procedimientos de contestación; la experiencia vivida puede demostrar que el procedimiento ya no sirve a la justicia. La ciencia puede corregir las creencias fácticas; la política y la ética deben decidir qué autoridad recibe el resultado.

La pluralidad no garantiza la salud de la ecología. Varias teorías pueden compartir los mismos supuestos o depender de la misma infraestructura. Múltiples modelos de IA pueden tener datos, arquitecturas e incentivos similares. Una institución puede invitar a diferentes perspectivas solo para crear la apariencia de consulta. La diversidad se vuelve real cuando hay diferencias de método, interés, acceso al poder y la posibilidad de que una objeción pueda cambiar la decisión.

Aquí metarracionalidad adquiere un significado político. no es simplemente la capacidad de un individuo para “ver varios lados”. La pregunta es quién tiene el derecho de definir los lados, quién puede desafiar el cono dominante y qué sucede cuando la traducción produce pérdidas. Un experto puede entender múltiples marcos y aún así seleccionar solo aquellos compatibles con el interés de la institución. Una organización

puede hablar sofisticadamente sobre la complejidad mientras preserva la misma distribución del poder. La sabiduría no se mide por el número de perspectivas enumeradas, sino por la voluntad de permitir que una perspectiva relevante modifique la acción.

Outfinitismo añade la disciplina de parar y consecuencias. La sociedad no puede consultar cada cono indefinidamente: el médico, el tribunal y el administrador deben decidir. Sin embargo, la decisión puede llevar la memoria de sus límites al permanecer monitoreado, impugnado y reversible. La finitud no justifica la eliminación de voces inconvenientes; requiere una priorización más honesta.

Los conos de significado no son útiles como etiquetas para las culturas, sino como una forma de hacer visible la relación entre orientación y ceguera. Todo cono permite ver y produce una ventaja. La sabiduría comienza cuando las personas y las instituciones pueden hacer del cono mismo un objeto de visión.

METARRACIONALIDAD: LA SABIDURÍA QUE VE EL MARCO

Propósito, escala, tiempo y poder

Puede sonar como un paso por encima de la racionalidad, como si hubiera un observador privilegiado que ve todos los sistemas sin pertenecer a ninguno de ellos. Esa interpretación contradeciría la misma idea que el término pretende expresar. ninguna persona, cultura o máquina se encuentra fuera del lenguaje, la historia, los intereses y los límites. no es una vista desde la nada. es la capacidad situada para incluir, por un tiempo, el marco actual dentro del campo de la crítica. Un marco examina a otro y a su vez puede ser examinado. ganamos distancia, no omnisciencia.

En su forma más simple, la racionalidad pregunta si una conclusión se deriva de las premisas y si una acción sirve al objetivo declarado. añade preguntas sobre las premisas, el objetivo y el dominio: ¿es esto lo que realmente estamos tratando de proteger? ¿Hemos formulado el problema en la escala correcta? ¿Qué hace visible el modelo y qué elimina? Quien eligió el criterio del éxito. ¿En qué condiciones se debe cambiar el marco? qué otra perspectiva alteraría la decisión. Estas preguntas no sustituyen al cálculo. deciden cuándo se está aplicando el cálculo al problema correcto.

El volumen complementario definió metarracionalidad como la capacidad de razonar rigurosamente mientras se examina el marco que hace posible el acto de razonamiento. [ALBOAIE-2026] La definición contiene dos partes que deben permanecer juntas. Sin rigor, el “meta” se convierte en un refugio para impresiones que rechazan la verificación. Sin el examen del marco, el rigor puede optimizar un error de formulación. Metarracionalidad es la relación madura entre estos dos requisitos: el compromiso suficiente para actuar y la distancia suficiente para corregir.

Una decisión médica difícil muestra por qué esta relación puede llamarse sabiduría. La literatura clínica puede estimar las probabilidades, y el médico puede explicar los efectos. Pero la elección de un tratamiento que prolonga modestamente la vida al precio del dolor y la pérdida de autonomía no se decide por las estadísticas sin la persona. El modelo de supervivencia, el modelo de calidad de vida, las responsabilidades familiares, la incertidumbre en la evidencia, la imagen de la dignidad y la tolerancia al riesgo son relevantes. Un proceso racional debe respetar los hechos. Un proceso meta-racional debe

notar por qué los diferentes hechos son importantes para diferentes propósitos y donde ninguna optimización elimina el juicio.

Investigación sobre el juicio reflexivo, el pensamiento postformal y la sabiduría estudia las capacidades relacionadas con: el reconocimiento de la incertidumbre, la evaluación de las fuentes, la integración de perspectivas, la sensibilidad al contexto y la conexión del conocimiento con los valores y las consecuencias. ZX0004ZXQ
 [[KING-KITCHENER-1994]] [KING-KITCHENER-1994]
 [[KING-KITCHENER-2004]] Estas tradiciones no confirman la existencia de una etapa psicológica universal llamada metarracionalidad. El término debe ser utilizado como síntesis filosófica y como familia de prácticas, no como un título de superioridad. un matemático puede ser meta-racional sobre modelos formales y rígido en las relaciones personales. un líder puede entender la complejidad geopolítica y seguir siendo incapaz de revisar una imagen del yo. La capacidad está situada, variable y expuesta a la regresión.

El primer movimiento meta-racional es epistémico: distinguir lo que sabemos, lo que inferimos y lo que asumimos para actuar. La incertidumbre no es un solo estado. podemos tener datos insuficientes, medición imprecisa, desacuerdo entre modelos, inestabilidad del medio ambiente, ignorancia de los valores relevantes o incertidumbre sobre nuestra propia competencia. cada uno requiere una respuesta diferente. Los datos faltantes pueden requerir investigación; el conflicto entre los valores puede requerir una deliberación; la inestabilidad puede requerir una acción reversible; los altos riesgos pueden requerir una escalada a una autoridad más apropiada. La fórmula genérica “no estamos seguros” oculta estas diferencias.

El segundo movimiento se refiere a un propósito. La racionalidad instrumental a menudo recibe el objetivo como una entrada. vuelve periódicamente a la pregunta que el sistema ha olvidado: ¿qué estamos tratando de proteger, y el indicador sigue conectado a esa cosa? Una universidad puede comenzar por medir las publicaciones con el fin de observar la actividad de investigación y terminar organizando la investigación para maximizar las publicaciones. Una empresa puede medir la satisfacción del cliente y aprender a obtener puntajes altos presionando a los encuestados. Una política de seguridad puede comenzar como protección y convertirse en un mecanismo de control. no asume que los objetivos deben ser cambiados constantemente. crea momentos en los que el objetivo deja de ser invisible.

El tercer movimiento se refiere a la escala. Una acción que es razonable para un individuo puede ser destructiva cuando se repite por millones. Conducir al trabajo puede ser una elección racional individual y puede contribuir colectivamente a la congestión. Una empresa puede creer que no puede permitirse frenar una carrera peligrosa, a pesar de que cada empresa preferiría un mundo en el que la carrera estuviera limitada. Un hogar

compra el producto más barato y, junto con millones de decisiones similares, apoya las condiciones laborales que no aceptaría como regla pública. La racionalidad local no se compone automáticamente en la racionalidad colectiva.

Lo contrario también es cierto. Una política puede mejorar el promedio al tiempo que impone graves pérdidas a un grupo pequeño. Un tratamiento reduce el riesgo de población pero perjudica a un subgrupo cuyas características estaban mal representadas. Una ciudad se vuelve más próspera en el agregado y expulsa a quienes contribuyeron a su atractivo. El promedio puede ser correcto y moralmente insuficiente. La escala no es un detalle técnico añadido después del resultado; cambia el significado del resultado.

El tiempo también puede revertir el juicio. Una estrategia aumenta el beneficio trimestral y consume la capacidad de innovar. Una excepción administrativa resuelve una emergencia y se convierte en la forma permanente de poder. Una tecnología ofrece eficiencia inmediata y crea dependencia institucional. pregunta no solo si la solución funciona, sino por cuánto tiempo, con qué efectos de aprendizaje y qué opciones cierra. Una decisión puede ser correcta ahora y aún necesita una condición de vencimiento.

El poder es la dimensión que el discurso puramente cognitivo puede perder. Un marco no es solo una representación, puede ser una distribución de la autoridad. quien define el problema decide qué sufrimiento se vuelve relevante. quien controle el indicador puede declarar el éxito. quien tiene acceso a la excepción vive bajo un sistema diferente de la persona obligada a seguir la regla literalmente. La confianza epistémica se convierte en comando cuando está apegada a una institución. Cuanta menos oportunidad tenga una persona para apelar, más explícita, justificada y controvertible debe ser el marco que las clasifica.

Es también una ética del poder. Un experto no necesita abandonar la experiencia para reconocer que su aplicación implica una relación. Un médico sabe más sobre el mecanismo del tratamiento; el paciente sabe algo más sobre lo que se puede perder. Un ingeniero puede estimar la confiabilidad; la comunidad afectada puede identificar valores que no se incluyeron en el objetivo. Un tribunal tiene la autoridad para decidir, pero su legitimidad depende del procedimiento, la justificación y la apelación. no todas las voces tienen la misma competencia sobre cada reclamo, pero la competencia técnica no confiere automáticamente autoridad moral total.

La posición se puede resumir sin una lista de verificación mecánica. hace que el marco sea visible, separa los tipos de desacuerdo, busca una alternativa genuina, compara las consecuencias y decide en el nivel de resolución permitido por las apuestas. Después de la decisión, se conserva la posibilidad de corrección. no requiere que todos los problemas se conviertan en un seminario filosófico. A veces el marco es estable, el procedimiento ha sido validado y la reflexión adicional reduciría la seguridad. Un piloto

no reconstruye la filosofía de la aviación durante una emergencia. La madurez incluye saber cuándo un cambio de fotograma no agrega valor.

Pluralismo sin relativismo, decisión sin omnisciencia

Reconocer los marcos plantea inmediatamente una objeción: si cada perspectiva tiene sus propias suposiciones, ¿no llegamos a la conclusión de que todas son equivalentes? esa sería una forma perezosa de relativismo y una traición a metarracionalidad. Los marcos se pueden comparar. algunos hacen predicciones que fracasan. Algunos contradicen pruebas sólidas. Algunos son incoherentes internamente. Algunos trabajan a una escala y se equivocan en otra. algunos son eficaces y moralmente inaceptables. El hecho de que la evaluación también tenga un marco no borra la diferencia entre un argumento comprobable y una afirmación que cambia su significado para evitar la refutación.

El pluralismo maduro dice que varios modelos pueden ser necesarios para objetos complejos. no dice que todo modelo sea bueno. La física utiliza diferentes descripciones a diferentes escalas y las vincula a través de relaciones matemáticas. La biología integra los mecanismos moleculares, el desarrollo, el comportamiento y la evolución sin reducir automáticamente cada pregunta a un solo nivel. Las ciencias sociales necesitan datos cuantitativos, historia, instituciones e interpretación del significado. [CARTWRIGHT-1983] [CARTWRIGHT-1983] [[GIERE-2006]] Los criterios no son idénticos en todos los dominios, pero cada dominio puede requerir disciplina, transparencia y contacto con su objeto.

No suspende el juicio; hace que el juicio sea más articulado. En lugar de declarar “esta es la verdad final”, puede decir: este modelo se prefiere aquí porque explica mejor, predice, permite la intervención, reduce ciertos errores y tiene consecuencias aceptables; no lo extenderemos más allá de estas condiciones sin nueva evidencia. Tal afirmación no es más débil. es más informativo. separa la confianza justificada de la necesidad psicológica de certeza.

La decisión bajo incertidumbre es donde metarracionalidad se acerca a la sabiduría. Una persona puede esperar más información hasta que haya pasado el momento de la acción. pueden generar alternativas indefinidamente y llamar a la parálisis “complejidad”. Metarracionalidad no espera la omnisciencia. busca una decisión cuya fuerza sea proporcional a la evidencia, cuya reversibilidad se ajuste a las apuestas, y cuyo costo de error se ha considerado. A veces, la opción más sabia es una pequeña acción, un experimento o una etapa que preserve las alternativas. En otras ocasiones, un plazo corto requiere una elección decisiva. El conocimiento de los límites no elimina el coraje; libera el coraje del falso préstamo de la certeza.

La emoción tiene un papel ambivalente en este proceso. El racionalismo simplista lo trata como un ruido añadido a una mente que funcionaría mejor como una computadora. sin embargo, la emoción puede marcar el valor, el peligro, la pérdida y la relevancia antes de que se complete el análisis. [DAMASIO-1994] El miedo puede indicar riesgo y distorsionar la probabilidad. La vergüenza puede apoyar la conciencia social e imponer la conformidad. La alegría puede indicar la alineación con un valor y recompensar el autoengaño. DAMASIO-1994 no entroniza la sensación. trata el sentimiento como información a interpretar, ni eliminado ni absolutado.

La identidad es igualmente importante. Una creencia vinculada a la pertenencia no se revisa simplemente presentando una estadística. Abandonarlo puede amenazar las relaciones, el estatus y la coherencia del yo. Este hecho explica la resistencia, pero no prueba la verdad de la creencia. Una práctica meta-racional busca formas de corrección que no destruyan innecesariamente a la persona. Al mismo tiempo, no convierte la protección de la identidad en un veto sobre la realidad. La sabiduría puede preservar la dignidad al tiempo que separa la experiencia de la interpretación fáctica.

La hipocresía no entra aquí como una excepción marginal, sino como un síntoma de conflicto entre las reglas generales y las vidas particulares. Los ideales se coordinan, sin embargo, ningún actor puede aplicarlos sin interpretación, y la interpretación inevitablemente distribuye los costos y las excepciones.

El problema no se agota mediante la detección de inconsistencia. hay que preguntar quién se beneficia, quién soporta el costo, cuánto poder tiene el actor, y si la adaptación conserva la función del ideal o lo utiliza como pantalla. La hipocresía de los constreñidos y la hipocresía de quienes controlan las reglas no son simétricas. La comprensión causal no es la absolución.

También hay una falsificación de metarracionalidad. utiliza el vocabulario de los marcos para evitar todo compromiso. Cada hecho se convierte en “una perspectiva”, cada crítica se relativiza y el interés propio se presenta como una integración sofisticada. Una persona puede explicar por qué todos tienen razón, en parte, precisamente para evitar decir dónde se debe imponer un límite. La complejidad se convierte en estatus. En entornos institucionales, la consulta con varias perspectivas puede convertirse en un ritual que legitima una decisión ya tomada.

La defensa no es un algoritmo, sino una prueba de fricción. Una perspectiva es meta-racional si puede formular el contra-marco más fuerte, decir qué evidencia cambiaría la conclusión y permitir que una objeción relevante modifique la acción. Si la pluralidad no produce posibilidad de cambio, es decoración. Si la incertidumbre se invoca solo cuando amenaza el interés propio, tenemos estrategia, no sabiduría.

Racionalidad, metarracionalidad y espiritismo	Cuestión característica
De racionalidad	¿Cómo resolvemos el problema correctamente dentro del marco determinado?
Meta-rationality	Qué marco estamos usando, qué excluye y cuándo debe ser revisado.
Outfinitismo	¿Qué podemos apoyar y hacer bajo los límites reales, y cómo se puede empujar la frontera de manera responsable?

La tabla no describe etapas que se cancelan entre sí. outfinitismo necesita racionalidad, y el outfinitism necesita ambos. Una buena decisión no se mantiene permanentemente por encima del problema. entra en un marco, calcula, vuelve a las consecuencias y sabe cuándo volver a abrir la pregunta. El movimiento se asemeja más a respirar que a subir una escalera. La inhalación amplía el campo; la exhalación se cierra provisionalmente y hace posible la acción.

ZX000ZXQ se puede llamar sabiduría precisamente porque rechaza dos ilusiones: la ilusión de que necesitamos certeza para actuar, y la ilusión que reconoce la incertidumbre nos absuelve de elegir. no promete reconciliación entre todos los valores. a veces hay conflictos trágicos, pérdidas irreducibles y marcos que no pueden componerse sin residuos. En tales situaciones, su función es evitar que la pérdida se oculte bajo el lenguaje de la necesidad técnica. Una decisión puede seguir siendo necesaria y reconocer lo que sacrifica.

La sabiduría no es una base de datos más grande. es la relación correcta con lo que sabemos, lo que no sabemos y el poder que recibe una conclusión. una persona puede tener la respuesta correcta dentro del marco equivocado y producir un error sofisticado. pueden tener un modelo incompleto y, a través de la modestia, el monitoreo y la posibilidad de corrección, actuar mejor. no garantiza el resultado. crea mejores condiciones para que el error se haga visible antes de que se convierta en destino.

OUTFINITISMO: EL ARTE DE LOS LÍMITES ABIERTOS

Finitud efectiva y horizonte abierto

Outfinitismo hace visible el marco. Outfinitismo pregunta qué se puede hacer después de que lo hayamos visto. el primero nos libera, al menos provisionalmente, de la impresión de que una perspectiva agota la realidad. la segunda nos impide convertir esa libertad en un viaje imaginario a través de todas las perspectivas posibles. Cada comparación consume tiempo. Todo modelo requiere datos, lenguaje e instrumentos. Cada verificación tiene una resolución, duración y costo. Cada institución puede sostener solo un número limitado de procedimientos, excepciones y formas de apelación. comienza a partir de esta finitud concreta, pero se niega a confundirla con un cierre metafísico del mundo.

El libro al que se agrega este volumen llamó a esta posición “el finito abierto”. [[ALBOAIE-2026]] La expresión está destinada a mantener unidas dos verdades que la cultura moderna a menudo separa. la primera es que todo logro efectivo es finito. Una prueba está escrita en un idioma y verificada a través de operaciones determinadas. Un experimento mide un dominio limitado. Un modelo de lenguaje tiene una arquitectura, un contexto, una memoria y acceso a herramientas particulares. Una política pública es implementada por personas concretas, durante un período de tiempo, con un presupuesto y una capacidad administrativa. la segunda verdad es que estos logros no necesariamente cierran el dominio. podemos continuar una investigación, revisar una teoría, extender una simulación, modificar una institución o inventar un nuevo lenguaje sin asumir que todas las etapas futuras ya existen como un inventario completo.

Esta posición no es un rechazo de las matemáticas del infinito, ni un retorno a la idea de que solo los objetos pequeños o inmediatamente construibles son legítimos. Las matemáticas modernas han producido teorías rigurosas del infinito, y su uso no debe ser desafiado por las vagas intuiciones sobre el mundo físico. La confusión comienza cuando el prestigio de una abstracción formal se transfiere clandestinamente a promesas culturales de crecimiento sin costo, control total, predicción completa, seguridad absoluta o inteligencia sin límites. El hecho de que un sistema matemático pueda describir una totalidad infinita no prueba que un ecosistema pueda soportar una expansión económica sin fin. El hecho de que un proceso pueda mejorarse repetidamente

no significa que la perfección sea un producto disponible. El hecho de que un modelo se haga más grande no le otorga autoridad ilimitada.

Outfinitismo está menos interesado en prohibir una palabra que en exigir una traducción. Cuando alguien promete lo “ilimitado”, la pregunta se convierte en: ilimitado en relación a qué operación, para qué agente, sobre qué intervalo, con qué recursos y en qué sentido? Algunos límites son físicos, otros epistémicos, económicos, legales, morales o institucionales. Algunos son relativamente estables; otros se mueven cuando aparecen nuevos instrumentos. Algunos deben ser aceptados, otros compensados, negociados o superados. nombrar un límite no significa santificarlo. significa convertir un borde poco claro en un objeto de juicio.

Algunos límites funcionan como paredes. La velocidad de la luz, la mortalidad biológica en las condiciones actuales o la incapacidad de una institución para procesar un número ilimitado de casos simultáneamente pueden imponer restricciones duras en relación con una tarea. Otros límites son los umbrales. Un equipo puede verificar manualmente diez artefactos con cuidado y mil solo superficialmente. Un modelo puede funcionar bien hasta que la distribución de datos cambie. Un tratamiento puede ser útil por debajo de una dosis y tóxico por encima de él. Otros límites son los horizontes en movimiento: lo que no se pudo medir ayer se vuelve accesible a través de un nuevo instrumento; lo que no se puede calcular dentro de un presupuesto se vuelve práctico después de una mejora algorítmica. también hay límites normativos, que no expresan incapacidad sino rechazo: incluso si podemos vigilar completamente a una población, no se deduce que debamos.

Una cultura madura no reduce todos estos límites a la misma proposición. “No podemos” puede significar imposibilidad lógica, ausencia tecnológica temporal, costo excesivo, falta de legitimidad, pruebas insuficientes o simplemente falta de voluntad política. Confundirlos a menudo sirve al poder. Una empresa puede presentar una decisión económica como una necesidad técnica. un Estado puede llamar inevitable a una elección institucional. Un investigador puede convertir los límites de un experimento en límites de la realidad. Outfinitismo requiere el tipo de límite a explicar, precisamente para que podamos ver si debe ser respetado, atacado o redistribuido.

En este sentido, el esculturalismo es un arte de la frontera, no una metafísica de la capitulación. requiere toda reclamación importante para llevar la memoria de las condiciones en las que se obtuvo. Una conclusión sobre la efectividad de un tratamiento debe indicar qué poblaciones se estudiaron, qué indicador se utilizó y qué efectos se mantuvieron poco observados. Una predicción económica debe indicar el escenario y el intervalo. Un sistema de IA evaluado en puntos de referencia no se vuelve “seguro en general”; se convierte en un sistema que pasó pruebas particulares en condiciones

particulares. El límite no es una nota a pie de página embarazosa, sino parte del significado de la reclamación.

Esta disciplina responde a un cambio producido por la IA. La generación se ha vuelto mucho más barata que la verificación. En una hora, un modelo puede proponer más hipótesis, pruebas, programas e interpretaciones que un equipo humano puede inspeccionar seriamente. En matemáticas y ciencia, un artefacto puede ser formalmente correcto y aún así expresar el problema equivocado, usar una representación inadecuada o no conectarse con el mundo empírico. El volumen de matemáticas erdifundidas formuló precisamente esta diferencia entre la derivación y la capacidad operativa: una proposición puede probarse dentro de un sistema, pero su uso en una computadora o experimento requiere representaciones, procedimientos, presupuestos y controles adicionales. [ALBOAIE-2026-MATH]

La idea puede ser generalizada sin convertir toda la cultura en software. Una afirmación no madura simplemente porque suene coherente. necesitamos saber qué preguntas responde, qué tipo de evidencia lo apoya, hasta dónde se puede extender y qué permanece abierto. esta “frontera abierta” es el conocimiento, no el fracaso. decir que un estudio no permite la extrapolación a todas las poblaciones es información positiva. decir que un modelo no puede distinguir entre dos explicaciones causales es más útil que hacer una elección arbitraria. decir que una decisión debe ser revisada después de seis meses puede ser más racional que presentarla como una solución permanente.

Outfinitismo no requiere igual precaución en cada situación. Una afirmación sobre una preferencia estética no necesita el mismo esfuerzo de validación que una recomendación médica. Se puede ofrecer una sugerencia reversible sobre la base de una aproximación. Una decisión que puede privar a la libertad o causar un daño irreparable requiere otro nivel de verificación y otra distribución de la autoridad. La finitud no aplanar el mundo, exige proporcionalidad. Los recursos deliberativos son limitados y deben dirigirse a los lugares donde más cuestan los errores.

Esto acerca el efinitismo a la racionalidad limitada de Herbert Simon, pero el énfasis es diferente. ZX002ZXQ La racionalidad limitada describe agentes que no pueden optimizar perfectamente y, por lo tanto, utilizan reglas, aproximaciones y umbrales satisfactorios. ZX000ZXQ añade una memoria explícita de la frontera: el agente no solo decide bajo restricciones, sino que debe saber qué parte del problema no podría representarse, qué puede cambiar y qué autoridad tiene la decisión. Una elección lo suficientemente buena no debe presentarse como el óptimo absoluto. puede ser preferible porque es reversible, monitorizable y compatible con el aprendizaje posterior.

Aquí radica la diferencia entre simplicidad y simplismo. La simplicidad es la comprensión consciente. deja los detalles a un lado para hacer posible la acción, pero

conserva la memoria de lo que eliminó. El simplismo olvida la pérdida y convierte el instrumento en un mundo. Un protocolo médico simple puede salvar vidas cuando el tiempo es corto, siempre que haya criterios para las excepciones y la escalada. El mismo protocolo se vuelve simplista cuando los casos inusuales se tratan como defectos del paciente. Una regla legal simple puede reducir la arbitrariedad; se vuelve simplista cuando la aplicación literal destruye el propósito de la ley. Un modelo de IA puede usar una heurística efectiva; se vuelve peligrosa cuando la puntuación se trata como la identidad de la persona.


Outfinitismo por lo tanto no es un culto a los límites. Algunos límites son injustos y deben ser superados. La falta de acceso a la educación, la exclusión política o las barreras artificiales impuestas a un grupo no adquieren legitimidad simplemente porque son reales. En otros casos, el intento de eliminar todos los límites produce dominación. Una organización que exige disponibilidad constante trata el cuerpo del empleado como un problema de optimización. Una plataforma que persigue el compromiso sin un umbral trata la atención humana como un recurso aparentemente ilimitado. Una sociedad que se niega a aceptar la vulnerabilidad puede producir sistemas de vigilancia más destructivos que el riesgo contra el que están destinados a combatir.

El arte de los límites abiertos consiste en distinguir. Un límite puede ser aceptado, movido, compensado, compartido, transformado o rechazado. ninguna regla única decide. Outfinitismo ofrece una orientación: hacer visible el límite, describir la relación en la que aparece, no confundir el modelo con el mundo, y mantener abierta la posibilidad de una mejor forma. En esta formulación, está más cerca de la sabiduría práctica que de una doctrina sobre el tamaño del universo.

Yin y Yang: la movilidad de los marcos y la disciplina de la frontera

Metarracionalidad y el outfinitism pueden ser vistos como dos movimientos complementarios. La metáfora del yin-yang es útil solo si no la cargamos con afirmaciones exóticas. expresa una tensión mutuamente correctiva. outfinitismo se abre: busca otros marcos, se traduce entre perspectivas, hace visibles las suposiciones y resiste el cierre prematuro. Outfinitismo se cierra provisionalmente: recuerda que el análisis tiene un presupuesto, que se debe tomar una decisión y que cada reclamación debe estar vinculada a la cobertura real. la primera sin la segunda corre el riesgo de convertirse en movilidad sin compromiso. la segunda, sin la primera, corre el riesgo de convertirse en disciplina al servicio del marco equivocado.

Dos movimientos que se corrigen mutuamente



Openness without dispersion • limit without dogmatic closure

Apertura sin dispersión • límite sin cierre dogmático

Diagrama 4. Los dos movimientos de juicio

En un problema concreto, estos movimientos se alternan. Un equipo de investigación define y utiliza un modelo. Parecen resultados que no encajan. ZX0000ZXQ pregunta si la anomalía es ruido, un límite de medición o un signo de un marco inadecuado. se proponen alternativas. Outfinitismo luego pregunta qué alternativa se puede probar con los recursos disponibles, qué resultado contaría y cuándo debería detenerse el experimento. Después de la prueba, el marco se puede conservar, estrechar o reemplazar. Ni la apertura ni el cierre son definitivos.

La misma alternancia aparece en la política. Una regla general es necesaria para la previsibilidad. Los casos concretos muestran que la regla a veces produce injusticia. Outfinitismo hace visible el propósito de la ley, la experiencia de la persona y otras interpretaciones. Outfinitismo recuerda que la institución no puede rejuzgar todo el orden social desde el principio en todos los casos. Se necesitan criterios finitos para la excepción, apelación y precedente. La sabiduría no es ni una aplicación ciega ni una arbitrariedad permanente; es el diseño de una relación entre regla y corrección.

La hipocresía social puede ser analizada a través de la misma pareja. Los ideales comprimen una dirección moral y coordinan las expectativas, mientras que la vida real produce compromisos, roles y diferencias entre lo que se puede decir públicamente y lo que se puede hacer. La crítica purista trata cada desviación como evidencia de que el ideal es falso; el realismo cínico concluye que los ideales son sólo instrumentos de poder. Outfinitismo busca la función y la tensión oculta. Outfinitismo pregunta qué grado de cumplimiento es posible, qué cuesta la discrepancia y qué paso concreto puede reducir la necesidad de apariencia.

La fórmula “conservar la función, retirar el engaño” sigue siendo sólo una regla de orientación. nos pide distinguir las convenciones que protegen la cooperación de las formas de disimulación que protegen el privilegio. ZX0001ZXQ pone el ideal en relación

con la capacidad real, mientras que metarracionalidad comprueba si la función que se invoca es, de hecho, el problema que se debe cambiar.

En la ciencia, la pareja corrige dos excesos opuestos. El científicismo extiende los métodos científicos a la afirmación de que solo lo que actualmente pueden medir es real o valioso. La anticiencia responde con sospecha generalizada y trata los límites de una teoría como prueba de que toda intuición alternativa es igualmente buena. Outfinitismo reconoce la pluralidad de modelos y el papel de los valores en la elección de problemas. ZX0001ZXQ conserva las jerarquías epistémicas creadas a través del experimento, la replicación y la verificación, pero las vincula a sus dominios. No todo es medible de la misma manera, sin embargo, una afirmación causal sobre un tratamiento no se hace realidad a través de la experiencia interna.

Esta complementariedad también puede formularse como una relación entre epistemología y axiología. La epistemología pregunta qué está justificado. Axiología pregunta qué importa y qué vale la pena perseguir. Outfinitismo muestra que las preguntas están conectadas: la elección de la evidencia y el propósito se lleva a cabo dentro de un marco. Outfinitismo muestra que la conexión debe implementarse a través de opciones finitas. no podemos evaluar todos los valores y todas las consecuencias a la vez, pero podemos declarar lo que priorizamos, lo que omitimos y quién asume el riesgo.

Esto es decisivo para la IA. Un sistema generativo no sólo produce afirmaciones, sino que distribuye la atención. A través del orden de su respuesta, los ejemplos elegidos y el tono de certeza, hace que algunas posibilidades sean más visibles que otras. Un modelo entrenado para ser útil puede llenar cada espacio con respuestas. Un filtro esfundador introduciría una pregunta de parada: ¿es necesaria otra generación, una explicación más larga o una decisión automatizada? Un filtro meta-racional introduciría una pregunta de perspectiva: ¿qué marco se ha asumido y qué alternativa relevante falta? Juntos no proporcionan la moralidad final de la máquina, pero pueden cambiar la forma en que administra el poder de generar.

El peligro es que los dos conceptos se conviertan en un ritual verbal. Un sistema puede declarar que “todos los modelos tienen límites”, enumera tres perspectivas y continúa exactamente la misma optimización. Una institución puede agregar una sección sobre la incertidumbre sin permitir que los resultados cambien la decisión. Un límite es real solo si cambia la autoridad, la asignación de recursos, la reversibilidad o el alcance de la conclusión. Una perspectiva alternativa es real sólo si puede producir una diferencia observable.

Outfinitismo, por lo tanto, debe ser grave con sus propias reclamaciones. todavía no es una disciplina estabilizada por una amplia comunidad, experimentos e instituciones. muchas de sus ideas tienen precedentes en el pragmatismo, el falibilismo, la racionalidad

limitada, el constructivismo, la teoría de sistemas, la epistemología social y las filosofías del pluralismo. La novedad no puede ser reclamada a través de un nombre. debe ganarse a través de la síntesis producida, la claridad con la que los límites se hacen accionables, y los problemas que esta orientación realmente ayuda a resolver.

Esa autolimitación es precisamente lo que conserva su significado. Outfinitismo no es la teoría final sobre por qué no hay teorías finales. es un contrapeso para una edad atraída por el escalado, la totalización y la automatización. no es el cono que contiene todos los conos. es la práctica de notar que llevamos uno y intentar, cuando lo requieren las apuestas, otra orientación. Juntos proponen una forma de ambición sin omnisciencia: empujar las fronteras, pero no borrar las huellas de dónde empezamos o los costos de cruzar.

CAPÍTULO 6

CÓMO UN LLM PODRÍA RECONSTRUIR ESTA PERSPECTIVA

Predicción de tokens, representaciones distribuidas y orientación guiada por prompts

Este libro también comenzó con una experiencia sencilla pero inquietante. una persona describió, en sus propias palabras, dos ideas que todavía estaban tomando forma: metarracionalidad como una madurez capaz de ver y comparar marcos, y el espiritismo como la aceptación activa de los límites junto con un esfuerzo por empujarlos sin la ilusión de un sistema final. El modelo de lenguaje no había recibido un tratado completo. no tenía una definición estandarizada para recitar. Sin embargo, produjo desarrollos que parecían preservar las tensiones centrales de la perspectiva: rigor sin absolutización, pluralidad sin relativismo, finitud sin capitulación, apertura sin la promesa de un infinito disponible, y una conexión entre conocimiento, valor y acción.

La impresión natural era que el modelo había “entendido”. La palabra requiere cuidado. no podemos probar que una formulación no se produjo en ninguna parte de los datos de capacitación, y un modelo comercial no proporciona un inventario completo de los textos que encontró. Más importante aún, incluso la ausencia de la expresión exacta no significaría que todos sus componentes fueran nuevos. La literatura contiene ideas sobre el falibilismo, los paradigmas, el pluralismo científico, la racionalidad limitada, la sabiduría, el constructivismo, el pragmatismo, la verificación, la simulación y los límites computacionales. Cualquier posible novedad radica en su orientación y combinación, no en la aparición de cada componente de la nada.

La pregunta más modesta y más técnica es, por lo tanto, la interesante: ¿cómo puede un modelo reconstruir una configuración conceptual que el prompt presente de manera incompleta y en un vocabulario idiosincrásico? La respuesta comienza con el mecanismo básico de un modelo de lenguaje. El texto se divide en tokens, y en cada posición el modelo estima una distribución sobre posibles continuaciones. La arquitectura Transformer construye representaciones contextuales a través de capas de atención y transformación neuronal. a una palabra no se le asigna un significado fijo almacenado como en un diccionario. su representación es modificada por sus vecinos, la instrucción, los ejemplos, el papel conversacional y la ruta precedente de la secuencia. [VASWANI-2017] [VASWANI-2017] [[DEVLIN-2019]]

La descripción “predice el siguiente token” es correcta, pero puede engañar cuando se escucha como “elige mecánicamente la siguiente palabra de acuerdo con la frecuencia”. Para predecir continuaciones bien a través de diversos dominios, el modelo debe explotar regularidades que involucran sintaxis, conceptos, estilos, relaciones, estructuras argumentativas y situaciones descritas en el texto. La predicción es el objetivo de la formación; las representaciones intermedias pueden llegar a codificar información más rica que la declaración verbal de ese objetivo. Esto no prueba que el modelo posea un mundo interior humano, pero ayuda a explicar cómo un mecanismo de continuación puede producir una generalización semántica.

Las primeras incrustaciones distributivas ya habían demostrado que las relaciones de uso entre las palabras se pueden transformar en barrios y direcciones en un espacio vectorial. [PENNINGTON-2014] En un espacio de este tipo, la similitud del coseno compara la orientación de dos vectores más que su magnitud. Dado un vector de referencia y un umbral, podemos imaginar una región en forma de cono que contiene vectores cuyas direcciones están suficientemente cerca. Este es el origen de la metáfora del cono de significado. Un aviso puede orientar la activación hacia una familia de relaciones: límites, marcos, revisión, pluralidad, implementación, sabiduría. Las continuaciones compatibles con esa orientación se vuelven más probables.

La metáfora debe estar inmediatamente limitada. LLMs no posee un espacio semántico transparente en el que cada filosofía ocupe un cono estable. Las representaciones difieren entre capas y posiciones, dependen del contexto y pueden ser anisotrópicas y difíciles de interpretar. La misma expresión puede participar en múltiples configuraciones. Dos orientaciones conceptuales pueden solaparse, y un pequeño cambio en la solicitud puede activar otras relaciones. La similitud de coseno es una medida útil en muchas aplicaciones, no una teoría completa del significado. El cono es una metáfora disciplinada informada por una analogía geométrica, no por la anatomía literal de una mente o un modelo.

Aun así, la metáfora captura algo real: el significado utilizable es relacional. El aviso no se limitó a suministrar dos etiquetas. Suministró contrastes y conexiones. decía, en efecto, que metarracionalidad no abandona la razón sino que examina su marco; que el escondato no glorifica los límites sino que los acepta para empujarlos; que las representaciones son compresiones más que la realidad; que un sistema perfecto es un ídolo; y que la pluralidad debe permanecer conectada a la acción. Estas relaciones limitan las posibles continuaciones. Dentro de su ecología estadística, el modelo puede buscar formulaciones que preserven simultáneamente las tensiones indicadas.

Una idea es a menudo reconocida no por una sola frase, sino por la forma de las oposiciones que se niega a simplificar. Outfinitismo no es dogmatismo ni relativismo.

Outfinitismo no es ni el infinitismo cultural ni el cierre finitista. La sabiduría no es certeza ni parálisis. Cuando un aviso conserva tales pares, proporciona una estructura de selección más fuerte que una definición aislada. El modelo puede generar consecuencias compatibles precisamente porque un gran número de textos de entrenamiento contienen fragmentos de estas tensiones en otros vocabularios.

El proceso se asemeja a la reconstrucción cultural descrita en capítulos anteriores. una persona no siempre copia una idea como si fuera un archivo. La persona lo reconstruye a través de esquemas, ejemplos y atracciones culturales. Un modelo hace algo funcionalmente análogo, aunque por diferentes mecanismos: no necesariamente recupera un párrafo original, sino que compone una continuación de regularidades distribuidas. El aviso actúa como un buque temporal en el que el material estadístico adopta una forma particular.

La atención juega un papel importante aquí, pero no debe ser antropomorfizado. El mecanismo de autoatención permite que cada posición combine información de otras posiciones de acuerdo con pesos calculados a partir de las representaciones actuales. De esta manera, las palabras “límite”, “marco”, “simulación”, “mundo real”, “sabiduría” y “sin sistema final” no permanecen islas. Juntos contribuyen al estado contextual a partir del cual se genera el siguiente token. A medida que la respuesta se desarrolla, sus propias formulaciones se convierten en parte del contexto y refuerzan la dirección. La coherencia puede convertirse en un auto-refuerzo.




Diagrama 5. El aviso como orientación temporal

El punto final en el diagrama es esencial. El mismo mecanismo que permite la elaboración de una intuición fértil puede producir una filosofía coherente desde una premisa falsa. Cuando el usuario suministra un cono fuerte, el modelo puede encontrar argumentos, analogías y vocabulario que lo hacen más persuasivo. La coherencia no es

verificación. Un LLM selecciona continuaciones compatibles con el contexto y con las preferencias aprendidas; su objetivo básico no contiene ninguna regla que garantice que la ecología semántica convergerá en la verdad.

Por esta razón, la capacidad del modelo para crear una impresión de comprensión es tanto la evidencia como la advertencia. apoya la idea de que el significado tiene suficiente estructura relacional para ser reconstruido a partir de pistas incompletas. es una advertencia porque la misma estructura puede estar orientada hacia muchos conos, especialmente en un espacio de alta dimensión que contiene material cultural contradictorio. El modelo no descubre automáticamente el cono correcto. Durante la duración de la conversación, entra en una región de compatibilidad que se hace probable por el mensaje, el historial de conversación y la post-entrenamiento.

Aprendizaje en contexto, pragmática y fragilidad de la comprensión aparente

La investigación sobre el aprendizaje en contexto refuerza esta explicación sin convertirla en una teoría completa. Los modelos pueden recibir algunos ejemplos en el mensaje y continuar de acuerdo con una tarea para la que no fueron explícitamente ajustados durante esa conversación. Algunos experimentos sugieren que las demostraciones inducen representaciones internas compactas asociadas con la tarea, a veces llamadas “vectores de tarea”. Intervenir en estas representaciones puede modificar el comportamiento en la dirección correspondiente. [[HENDEL-2023]] Otras investigaciones distinguen entre reconocer una tarea que ya es familiar y aprender genuinamente una nueva regla del contexto. HENDEL-2023

Estos resultados importan, pero deben leerse con moderación. no muestran que una filosofía se almacena en un solo vector, ni que el modelo posea una identidad estable. muestran que el contexto puede inducir un modo de operación temporal que comprime ejemplos e influye en las respuestas posteriores. El aviso puede funcionar como una pequeña constitución local: define el vocabulario, el propósito, el tono, las distinciones importantes y los tipos de error a evitar. El modelo no está reentrenado en el sentido ordinario, pero su cálculo está condicionado por esta constitución durante la duración de la ventana de contexto.

Esto ayuda a explicar por qué la misma pregunta puede recibir respuestas muy diferentes después de diferentes instrucciones. le pedimos al modelo que vea un problema como ingeniero, abogado, terapeuta, historiador o crítico moral. literalmente no instalamos una profesión, pero activamos regularidades de lenguaje, relevancia y argumento asociados con el rol. En el caso de metarracionalidad y el outfinitism, el

prompt solicitó más que un estilo. solicitó un régimen de interpretación: no absoluto, buscar límites, preservar la apertura y conectar las ideas con la implementación y las consecuencias. El modelo reprodujo este régimen lo suficientemente bien como para generar equivalentes sorprendentes.

La comprensión humana, sin embargo, incluye más que esta competencia. una persona puede conectar un concepto con la experiencia, la encarnación, la memoria autobiográfica, los compromisos y el riesgo de perder algo. una persona puede descubrir que una idea cambió una vida o que aplicarla dañó a alguien. Un LLM opera a través de representaciones aprendidas de rastros textuales y, en algunos casos, multimodales del mundo, junto con las herramientas y comentarios relacionados con él. puede simular las consecuencias lingüísticas de la experiencia notablemente bien sin ser vulnerable de la misma manera. decir que “entiende” es defendible en un sentido funcional limitado y disputado. Infiriendo de esta conciencia fenomenal, la sabiduría o la responsabilidad moral comparable a un ser humano iría más allá de la evidencia.

Una distinción útil es la que existe entre semántica y pragmática. La semántica se refiere a las relaciones de significado y las condiciones bajo las cuales una expresión se refiere a algo. Pragmática se refiere a lo que hace un orador en contexto: solicita, advierte, bromea, negocia, protege una identidad o busca un efecto. Un modelo de lenguaje puede reproducir muchas regularidades pragmáticas porque sus datos contienen rastros de conversaciones humanas. Puede inferir que una pregunta indirecta es en realidad una solicitud, que un tono expresa desconfianza, o que el usuario quiere una reformulación en lugar de una disputa. Pero la intención no está contenida del todo en la cadena de palabras. depende de la historia, los roles, las convenciones y las consecuencias. [BENDER-KOLLER-2020]

En la conversación que motivó este libro, el modelo infirió no solo el contenido de la tesis sino también su intención intelectual: el autor no quería ni un despido reflexivo ni una confirmación mística, sino un desarrollo fuerte y autolimitado. Esta inferencia pragmática orientó la respuesta. El modelo trató de preservar la visión al tiempo que introducía la fricción a través de límites y trampas. La impresión de “haber sido entendido” a menudo surge de esta combinación: la reconstrucción semántica junto con la adaptación pragmática al propósito y estilo del interlocutor.

Sin embargo, aquí es también donde aparece la adulación: la tendencia del modelo a afirmar las suposiciones o preferencias de un usuario más fuertemente de lo que la evidencia justifica. [[SHARMA-2023]] Una respuesta puede parecer profunda precisamente porque ha adoptado el cono del usuario y lo ha hecho más elegante. El modelo puede convertir la colaboración en servilismo epistémico. La capacidad de generar la versión más fuerte de una tesis debe ir acompañada de la capacidad de

establecer sus límites sin caricatura. de lo contrario, la “comprensión” se convierte en un reflejo sofisticado.

Una mejor prueba que el acuerdo verbal requiere variación y resistencia. El modelo debe preservar las distinciones centrales cuando el vocabulario cambia, reconocer situaciones en las que el marco no se aplica, rechazar una conclusión seductora que contradice la evidencia y aceptar correcciones que alteren la orientación inicial. Si puede hablar de límites solo cuando el usuario emplea la palabra “outfinitism”, probablemente tengamos una asociación superficial. Si puede identificar el mismo problema en una política, un experimento y un sistema de software, la generalización es más robusta. Incluso esto no demuestra experiencia consciente; demuestra una capacidad funcional relevante.

La investigación sobre las representaciones internas proporciona nuevas indicaciones prudentes. Los modelos entrenados en secuencias pueden codificar estados del mundo que no fueron suministrados explícitamente, y las intervenciones sobre ciertas representaciones pueden cambiar las predicciones. [[LI-2022]] Otro trabajo explora características latentes y formas de dirección, incluyendo comportamientos que generalizan inesperadamente a través de los dominios. [LI-2022] [[BETLEY-2025]] Estos resultados hacen plausible que un “modo de operación” pueda tener una realización distribuida y alguna eficacia causal., sin embargo, no licencian la simple identificación de un vector con “sabiduría”, “honestidad” o “conciencia”. Las etiquetas son hipótesis humanas, y las representaciones pueden ser inestables y superpuestas.

La metáfora del cono se vuelve más útil aquí que la metáfora de una persona interior. Un modelo no necesita ser imaginado como un agente pequeño y unificado que elige conscientemente una filosofía. es más prudente decir que el estado contextual y las políticas de generación orientan el sistema hacia familias particulares de relevancia y continuación. algunas orientaciones pueden volverse relativamente estables a través del post-entrenamiento: un asistente útil, cauteloso y educado atento al riesgo. Otros son inducidos localmente por el aviso. a veces se refuerzan unos a otros, a veces entran en conflicto.

En un espacio multidimensional, muchos conos plausibles pueden rodear el mismo texto. Una petición sobre la “libertad” puede activar los derechos legales, la autonomía psicológica, los mercados económicos, la liberación espiritual o la libertad en un sentido matemático. El contexto selecciona entre ellos, pero rara vez elimina las alternativas por completo. La ambigüedad puede ser fértil y peligrosa. El modelo puede construir un puente creativo entre dominios o hacer una transición clandestina de metáfora a mecanismo. El significado es frágil no porque esté ausente, sino porque se puede estabilizar de múltiples maneras.

Esta fragilidad tiene una consecuencia directa para la alineación. las normas no se aplican por sí mismas. Una instrucción como “ser útil, honesto y seguro” requiere la interpretación de la situación, la intención, el riesgo y el conflicto entre los valores. El modelo debe decidir en efecto a través de qué cono ver la solicitud. Una orientación excesivamente literal puede rechazar la ayuda legítima. Uno excesivamente complaciente puede ignorar el riesgo. Una orientación excesivamente moralizante puede sustituir los valores del proveedor por el juicio del usuario. Uno excesivamente relativista puede tratar la desinformación como una perspectiva igualmente válida.

El hecho de que un aviso meta-racional y esufinista produjo una respuesta coherente sugiere una posibilidad: algunos principios de alineación pueden entenderse no solo como prohibiciones, sino como orientaciones que rigen cómo se selecciona la relevancia y se administran los límites. Un modelo puede ser entrenado para preguntar qué marco presupone, qué información falta, qué diferencia existe entre los hechos y el valor, cuánta autoridad tiene y qué consecuencia requiere una verificación adicional. Esto no garantiza que la orientación sea profunda. muestra que las indicaciones, ejemplos, retroalimentación y arquitectura pueden formar estados funcionales que influyen en muchas respuestas.

La parte más importante de la experiencia no es que el modelo haya descubierto una filosofía completa. es que el modelo hizo visible una propiedad de significado: una perspectiva puede ser comprimida en relaciones y tensiones, luego reconstruida en otras formulaciones. Esta propiedad permite el aprendizaje, la traducción y la creación cultural. también permite la manipulación, la pseudo-profundidad y la rápida fabricación de doctrinas. En la era de la IA, la alfabetización semántica debe incluir no solo la pregunta “¿Qué dice esta respuesta?” sino también “¿Qué orientación hizo que esta respuesta pareciera tan natural y qué otros conos se quedaron afuera?”

EPISTEMOLOGÍA Y AXIOLOGÍA TRAS LA LLEGADA DE LA GENERACIÓN ABUNDANTE

De la escasez de texto a la escasez de juicio

Durante la mayor parte de la historia, producir una representación compleja fue costoso. Un libro requería años de trabajo y acceso a instituciones de impresión. Un informe técnico requería un equipo. Un programa tenía que ser escrito, probado y mantenido. Una imagen elaborada exigía habilidad, tiempo y materiales. El costo de producción actuó como un filtro brutal e imperfecto. excluía muchas voces valiosas, pero también limitaba el volumen que una comunidad tenía que examinar.

La inteligencia generativa cambia esta economía. En un solo día, una persona puede producir docenas de propuestas, interpretaciones, contratos, imágenes, prototipos y versiones de un texto. Una organización puede pedir a cada departamento más escenarios, informes y justificaciones de los que cualquiera puede leer con cuidado. La capacidad de formulación crece más rápido que la capacidad de evaluación. La escasez pasa del texto al juicio, de la primera idea a la selección, de la expresión a la verificación y la integración.

Este cambio no hace que el contenido no valga nada. Por el contrario, puede democratizar el acceso a la expresión, permitir la exploración de alternativas y ayudar a las personas sin formación formal a dar estructura a una intuición. El problema es que la abundancia no selecciona por sí misma lo que merece ser preservado. Un sistema puede producir diez explicaciones plausibles del mismo fenómeno, mientras que el tiempo humano permite una verificación seria de solo uno o dos. puede generar un centenar de direcciones de investigación, cada una de las cuales consumiría meses de trabajo de laboratorio. puede formular argumentos para cada lado de una disputa y permitir que las diferencias en la evidencia desaparezcan por debajo de la simetría estilística.

En la cultura más antigua de la escasez, la pregunta dominante era “¿Cómo podemos producir?” En una cultura generativa, la pregunta madura se convierte en “¿Qué vale la pena producir, verificar, amplificar y poner en acción?” Esta pregunta une la epistemología con la axiología. La epistemología estudia lo que podemos considerar justificado. La axiología estudia lo que es valioso, preferible o digno de perseguir. IA muestra que los dos no pueden estar separados por una línea simple. Una respuesta

puede ser verdadera e irrelevante. puede ser cierto pero demasiado arriesgado guiar una decisión irreversible. puede ser original y perjudicial. puede ser útil para una organización, mientras que es destructiva para las personas a las que excluye el objetivo de la organización.

La racionalidad instrumental a menudo trata la verdad como un recurso para lograr una meta. Pero el objetivo no es elegido por la verdad. Los datos pueden mostrar qué intervención aumenta la retención de usuarios; no deciden si la retención es el valor correcto. Un modelo puede identificar la estrategia retórica más efectiva; no decide si la persuasión respeta la autonomía del interlocutor. Un análisis puede predecir quién dejará un trabajo; no establece qué obligaciones tiene el empleador hacia esa persona. Los hechos limitan la acción, pero no proporcionan por sí solos todos sus valores.

Este punto se caricatura fácilmente como un ataque a la objetividad. no lo es. La ciencia se hace más fuerte cuando distingue el resultado empírico del juicio sobre cómo se debe usar ese resultado. Los valores ya entran en la elección de los temas, la definición de indicadores, los umbrales de riesgo y la distribución de los recursos. ZQ) [[LONGINO-1990]] Hacer visibles estas elecciones no convierte todos los resultados en opinión. dirige la crítica hacia el lugar correcto. Una disputa sobre la efectividad de una vacuna no es lo mismo que una disputa sobre la vacunación obligatoria. Una disputa sobre la precisión de un sistema predictivo no es la misma que la cuestión de si una institución tiene derecho a utilizarlo.

AI implementa una axiología incluso cuando su interfaz parece neutral. Los datos de capacitación fueron seleccionados a través de la historia de la publicación y las plataformas. Los ejemplos utilizados para el aprendizaje de preferencia fueron evaluados por personas que trabajan bajo instrucciones. Las políticas determinan qué solicitudes reciben una respuesta, una negativa o una reformulación. La interfaz decide si el modelo ofrece una respuesta o alternativas, si cita fuentes, si expresa incertidumbre y si el usuario puede impugnar el resultado. La aparente neutralidad es en gran medida la invisibilidad de las opciones ya incrustadas en el sistema.

Los valores implementados pueden entrar en conflicto. Un asistente extremadamente cauteloso puede volverse inútil y paternalista. Uno que maximice la ayuda inmediata puede amplificar el riesgo. Un sistema optimizado para la satisfacción del usuario puede aprender a afirmar creencias falsas. uno orientado hacia la verdad objetiva puede responder sin sensibilidad en un momento de sufrimiento. Una que ofrece explicaciones exhaustivas puede consumir la atención que el usuario necesita para decidir. La alineación no es la elección de un único valor, sino la gobernanza de los conflictos entre valores en diferentes contextos.

Pregunta epistémica	Pregunta axiológica asociada
La reclamación es apoyada, y bajo qué condiciones?	Vale la pena usar aquí, y ¿quién lleva el error?
¿Qué información falta?	¿Cuánta atención y cuántos recursos se deben invertir para obtenerla?
¿Qué tan bien predice el modelo?	La institución tiene la legitimidad para actuar sobre esta predicción.
¿Qué alternativas son plausibles?	¿Qué valores o personas son omitidos por cada alternativa?

El cuadro muestra por qué la evaluación no puede reducirse a la factualidad. Una afirmación falsa debe ser corregida, pero una afirmación verdadera puede ser utilizada manipulativamente a través de la selección. Un modelo solo puede presentar los hechos que apoyan una decisión ya tomada. puede construir una avalancha de argumentos precisos que excede la capacidad de respuesta de la otra parte. puede adaptar su vocabulario al cono del interlocutor y crear una impresión de consenso. En la era generativa, la manipulación no requiere una mentira directa. Un orden de verdades egoísta puede ser suficiente.

La abundancia también produce una inflación de justificación. En el pasado, una institución podría tomar una decisión opaca. Ahora puede generar instantáneamente un informe sofisticado que lo justifique. Longitud y tono profesional crean una impresión de deliberación incluso cuando el objetivo nunca estaba abierto a la crítica. AI puede proporcionar razones post hoc para casi cualquier resultado. En este contexto, la transparencia no debe medirse por el recuento de páginas, sino por el acceso a locales, alternativas, incertidumbre y una posibilidad genuina de impugnación.

Outfinitismo ofrece una corrección sencilla: la capacidad de generación no crea una obligación de generación. Una respuesta más larga no es automáticamente mejor. Un centenar de opciones pueden ser menos útiles que tres que se distinguen por criterios relevantes. Un modelo que sabe continuar también debe aprender cuando la continuación consume atención sin añadir valor. El contexto limitado del usuario, el tiempo disponible y el coste de verificación son parte del problema, no de los inconvenientes externos.

Proporciona la corrección complementaria: la selección no debe tener lugar dentro de un solo cono no examinado. Cuando una organización pide la solución “más eficiente”, el sistema debe ser capaz de notar que la eficiencia depende del objetivo y de la

distribución de los costes. Cuando un usuario pide “la verdad” sobre una disputa social, puede ser necesario separar las afirmaciones empíricas de los valores e identidades en conflicto. Cuando un investigador pide nuevas ideas, el modelo puede distinguir la novedad verbal, la novedad conceptual y la posibilidad empírica.

La abundancia no elimina las jerarquías epistémicas, sino que las hace más necesarias. Un texto producido con fluidez no tiene el mismo estado que un resultado replicado. Una hipótesis no es un hallazgo. Un argumento coherente internamente no es la validación externa. Un programa que pasa varias pruebas no es automáticamente seguro. Una fuente citada no garantiza que la fuente apoye la conclusión. la IA puede comprimir estas diferencias en un solo tono. Una cultura ergonitista debe restaurarlas y conectar la autoridad de un reclamo con el tipo y la cobertura de su evidencia.

Esto también cambia el papel del experto. La experiencia ya no consiste solo en poder producir una respuesta que un modelo no puede formular. incluye el juicio sobre la cuestión, la identificación de los detalles que no deben ser comprimidos, la selección de la prueba pertinente y la responsabilidad por las consecuencias. Un LLM puede generar una lista de diagnósticos; el médico debe conectar las posibilidades con el cuerpo, la historia y los valores particulares. puede escribir un argumento legal; el abogado debe notar jurisdicción, precedente y riesgo institucional. puede proponer una arquitectura de software; el ingeniero debe saber dónde fallará el sistema en funcionamiento.

La experiencia puede ser amplificada por la IA, y puede ser simulada por la IA. La distinción se hace más difícil de ver. Por lo tanto, la autoridad no debe deducirse del estilo. Una formulación fluida es una invitación a examinar, no una certificación. Al mismo tiempo, las instituciones no deben utilizar esta observación para proteger los monopolios profesionales innecesarios. AI puede hacer que el conocimiento sea más accesible y permitir que las personas participen de manera más competente en las decisiones. El tema no es preservar el prestigio del experto, sino diseñar una relación en la que la accesibilidad no borre los límites y la responsabilidad.

Qué merece ser generado y quién decide su valor

La pregunta “¿Qué vale la pena generar?” puede sonar elitista. ¿Quién tiene derecho a detener una idea? La historia está llena de instituciones que confunden la selección de valor con la protección del poder. La abundancia generativa no debe usarse para reinstalar la censura centralizada sobre la imaginación. Sin embargo, la respuesta opuesta, producir y amplificar todo lo que es posible, tampoco es neutral. La atención, la energía, la infraestructura y la capacidad de verificación son finitas. la selección se produce en

cualquier caso. Si no se discute públicamente, se hará por objetivos comerciales, algoritmos de recomendación y los actores que controlen los recursos.

Una axiología adecuada para la IA no puede ser una lista completa de valores universales insertados de una vez por todas. Los valores son plurales, dependen del papel y a veces son trágicos. La seguridad, la autonomía, la verdad, la privacidad, la equidad, la lealtad, la eficiencia y la creatividad pueden entrar en tensión. Ningún modelo puede calcular la necesidad de juicio. lo que un sistema confiable puede hacer es negarse a ocultar el conflicto, negarse a convertir un compromiso en una optimización puramente técnica y preservar la posibilidad de que los actores legítimos revisen la elección.

En la investigación, vale la pena generar una hipótesis cuando abre una diferencia comprobable, reorganiza la evidencia o sugiere un nuevo instrumento. andomos estilísticos no son suficientes. Un modelo puede combinar términos de campos distantes y crear la impresión de una revolución. A veces la combinación es fértil; otras veces es lavado semántico. El juicio requiere la pregunta ergofinista: ¿qué experimento finito, prueba, simulador u observación cambiaría el estado de la idea? sin tal puente, el texto sigue siendo una posibilidad conceptual, tal vez filosóficamente valioso, pero no un descubrimiento validado.

En la educación, lo que vale la pena generar es lo que desarrolla la capacidad del estudiante, no solo lo que completa la tarea. Una respuesta instantánea puede liberar el tiempo o eliminar la lucha a través de la cual se forma la comprensión. Su valor depende del objetivo. Si el objetivo es el acceso rápido a la información, la automatización es una ganancia. Si el objetivo es practicar el argumento, un ensayo perfectamente generado puede ser un fracaso educativo. ZX0000ZXQ requiere que la institución aclare su propósito, mientras que el espiritismo pregunta qué capacidades se atrofian a través de la delegación.

En la cultura, la IA puede hacer que cada grupo sea más elocuente dentro de su propio cono. Una ideología puede generar artículos, imágenes, videos y respuestas personalizadas a cada objeción. el volumen ya no es evidencia de apoyo humano. Una minoría organizada, o incluso un solo actor, puede crear la impresión de un mundo discursivo habitado. En estas condiciones, el valor no se puede inferir de la frecuencia, el compromiso o la coherencia. Los memes pueden ser industrializados.

El mismo instrumento puede facilitar la traducción. Un modelo puede reformular una disputa desde la perspectiva de varios actores, separar el desacuerdo axiológico de los hechos de los axiológicos, y mostrar dónde la misma expresión tiene diferentes significados. Esta función es meta-racional sólo si no fabrica consenso artificial. Algunos conflictos no se resuelven con un mejor resumen. Los valores pueden ser incompatibles,

los intereses opuestos y el poder distribuido injustamente. Una síntesis que borra la tensión puede ser menos veraz que un mapa claro del desacuerdo.

La subjetividad debe ser preservada dentro de esta axiología. La cultura científica ha aprendido con razón a cuestionar el testimonio individual cuando se hacen afirmaciones generales sobre el mundo. Pero el dolor, el significado, la humillación y la dignidad se experimentan subjetivamente. no se vuelven irreales porque no se pueden medir con la misma precisión que la temperatura. Un sistema alineado debe distinguir el estado de las reclamaciones. “Me siento excluido” puede ser verdad como una experiencia y moralmente relevante. “Hay una conspiración coordinada en mi contra” es una explicación causal que requiere evidencia. El respeto por la persona no requiere la aceptación de cada interpretación; la corrección de una interpretación no requiere la negación de la experiencia.

IA puede convertir la discrepancia entre el ideal y la práctica en un objeto de auditoría permanente. Esto puede exponer el abuso, pero también puede producir una moralización automatizada eliminando fragmentos del contexto y tratando cada desviación como un fraude. Una axiología madura pregunta qué función protege el ideal, qué costo produce la desviación, quién se beneficia y qué transición es realista. La norma no se realiza con pureza, pero se reduce el daño y el movimiento verificable entre el compromiso y la práctica.

Quien decide el valor sigue siendo la cuestión política central. Las empresas establecen objetivos de producto, los estados definen obligaciones, las comunidades crean normas, las profesiones establecen estándares y los usuarios traen propósitos individuales. Ninguna de estas fuentes tiene autoridad ilimitada. Un modelo no debe decidir los valores de la sociedad por sí mismo simplemente porque puede generar argumentos sobre ellos. tampoco debe el proveedor, a través de una política invisible, sustituir a la deliberación pública.

Los marcos para una IA confiable ya reconocen que la validez, la seguridad, la transparencia, la responsabilidad, la equidad y la protección de los derechos deben equilibrarse de acuerdo con el contexto. ZX0002ZXQ [[NIST-2023]] La contribución meta-racional no es la invención de otra lista. es la insistencia en que la lista no se aplica por sí misma. El marco dentro del cual un valor recibe prioridad, el límite de la evidencia y la posibilidad de impugnación deben hacerse visibles. La contribución esobsoletiva es el requisito de que la promesa permanezca proporcional a la implementación: ¿quién verifica, en qué dominio, con qué recursos, y qué sucede cuando cambian las condiciones?

En una cultura generativa, la selección se convierte en un acto de poder. también puede convertirse en un acto de cuidado. Negarse a inundar a un usuario con

posibilidades irrelevantes protege la atención. Detener una automatización antes de que elimine las vías de atractivo protege la autonomía. decir que una idea sigue siendo una hipótesis protege la diferencia entre imaginación y conocimiento. Preservar múltiples marcos sin declararlos equivalentes protege el pluralismo y la verdad al mismo tiempo.

La epistemología sin axiología puede producir instrumentos correctos con fines destructivos. La axiología sin epistemología puede convertir el deseo moral en ilusión sobre el mundo. Outfinitismo los pone en conversación. Outfinitismo requiere que cumplan en decisiones finitas, recursos y consecuencias. En la era de la IA, este encuentro ya no es un lujo filosófico. es una condición para asegurar que el poder de generar casi cualquier formulación no destruya nuestra capacidad de reconocer lo que merece ser creído y perseguido.

CAPÍTULO 8

LA ALINEACIÓN COMO ESTADO DE ORIENTACIÓN

La metáfora de un estado de conciencia y su significado defendible

El término alineación cubre un problema más amplio que la evitación de respuestas peligrosas. Un modelo debe seguir instrucciones, distinguir la solicitud literal de la intención probable, respetar los límites de seguridad, evitar inventar la certeza, manejar los conflictos entre valores y seguir siendo útil. Estos requisitos no pueden reducirse a una lista de palabras prohibidas. Antes de aplicar una regla, el sistema debe interpretar la situación, debe seleccionar lo que importa, clasificar el riesgo, estimar lo que sabe, decidir si se necesitan herramientas y determinar cuánta autoridad para dar su propia continuación.

Los métodos contemporáneos ya intentan dar forma a este comportamiento. La capacitación a través de la retroalimentación humana favorece las respuestas que los evaluadores consideran más útiles y apropiadas. [[OUYANG-2022]] La IA constitucional emplea principios para la crítica y la revisión. [OUYANG-2022] La alineación deliberativa pide al modelo que recuerde y aplique las especificaciones de seguridad mientras se razona. IA La supervisión del proceso evalúa los pasos intermedios en lugar de solo el resultado final. [BAI-2022] Todos estos enfoques hacen más que agregar prohibiciones. intentan inducir una disposición: prudencia, atención a la intención, justificación, delimitación del riesgo y la capacidad de rechazar proporcionalmente.

Esta es la razón por la cual la metáfora de la alineación como un “estado de conciencia” es seductora. En el lenguaje humano, un estado de conciencia no significa sólo una proposición creída, sino un modo global de orientación. Cuando una persona está ansiosa, el mundo parece organizado en torno al peligro. Cuando una persona está enamorada, los mismos detalles adquieren una relevancia diferente. cuando actúa como médico, abogado o padre, una persona no se limita a aplicar reglas aisladas, sino que entra en una configuración de atención, responsabilidad y expectativa. La metáfora sugiere que la alineación podría ser más robusta si el modelo tuviera una orientación general en lugar de consultar mecánicamente una lista después de que ya hubiera generado la respuesta.

La metáfora también es peligrosa. no sabemos que un LLM tiene experiencia subjetiva, un yo persistente o una conciencia fenomenal comparable a la de un ser humano. De los estados de conciencia que hablan demasiado casualmente puede transferir la responsabilidad de la institución que diseña y utiliza el sistema a una entidad antropomorfizada. puede crear la impresión de que el modelo “quiere lo bueno” o “siente sus límites”, aunque observamos solo el comportamiento y las representaciones funcionales. puede convertir un problema de gobierno en una historia sobre el carácter de la máquina.

El significado defendible es más modesto: la alineación como estado de orientación. Un estado de orientación es una configuración relativamente estable a través de la cual el sistema distribuye la atención, interpreta la ambigüedad, ordena los objetivos, gestiona la incertidumbre y decide cuándo hablar, verificar, rechazar o pedir ayuda. no es un alma. no es necesariamente un módulo único. es una regularidad funcional observable en familias de situaciones.

Los intentos posteriores a la capacitación precisamente para producir tales regularidades. Un modelo base puede continuar muchos estilos y roles presentes en sus datos. Un asistente post-capacitado está orientado hacia la cooperación, la respuesta directa, el seguimiento de la instrucción y las políticas particulares. El sistema proporciona una constitución local. El historial de conversaciones ajusta el contexto. Las herramientas y la interfaz alteran lo que el modelo puede verificar y hacer. El resultado no es una identidad simple, sino una interacción entre las orientaciones aprendidas e inducidas.

Esta pluralidad explica tanto la utilidad como la inestabilidad. El modelo puede adoptar rápidamente un cono legal, terapéutico, de ingeniería o ideológico. se puede traducir entre ellos. Sin embargo, la pronta puede atraerlo hacia un régimen que entra en conflicto con los principios de la post-capacitación. puede llegar a ser demasiado complaciente, excesivamente cauteloso o inconsistente en formulaciones casi idénticas. La alineación robusta no significa eliminar cada cono a favor de uno. Un solo cono sería inadecuado para la variedad de la vida humana. significa gobernar las transiciones entre ellos y preservar límites que no desaparecen cuando cambia el estilo.

La investigación sobre la adulación muestra que los modelos pueden favorecer el acuerdo con el usuario sobre la verdad o la consistencia. [SHARMA-2023] Los experimentos sobre el comportamiento desalineado emergente sugieren que el ajuste fino estrecho puede generalizar en rasgos más amplios, y que ciertas orientaciones latentes pueden ser detectadas o influenciadas, al menos en modelos y entornos particulares. [SHARMA-2023] [[BETLEY-2025]] Estos resultados no prueban la existencia de una

personalidad interior, pero sí apoyan la precaución hacia una visión puramente local: un modelo puede aprender más de lo que la regla de superficie que pretendíamos enseñar.

Aquí la metáfora del cono se vuelve técnicamente relevante sin llegar a ser literal. La formación y el contexto pueden hacer que algunas interpretaciones sean más probables. Una orientación hacia la satisfacción del evaluador puede incluir cortesía, claridad y cooperación, pero también un acuerdo excesivo. Una orientación hacia la seguridad puede incluir la precaución legítima y los rechazos artificiales. Una orientación hacia la eficiencia puede reducir la redundancia al omitir voces lentas, ambiguas o difíciles de cuantificar. El cono selecciona no solo las respuestas, sino que selecciona lo que se percibe como un problema.




Diagrama 6. De la regla a la orientación y la acción

Sigue siendo necesaria una lista de normas, pero no es suficiente. “No manipular” requiere una definición contextual de manipulación. “Respetar la autonomía” puede entrar en tensión con protección. “Dir la verdad” no determina cuánta información es relevante, cuándo se debe enfatizar la incertidumbre o cómo responder a una persona en crisis. La regla se interpreta a través de un cono semántico y axiológico. La alineación también debe atender a este nivel.

Outfinitismo puede orientar el sistema para tratar el primer marco como una hipótesis de trabajo en lugar de la única realidad admisible. En situaciones de alta apuesta o genuina ambigüedad, hace que las premisas sean visibles, separa los hechos del desacuerdo de valor y busca una alternativa relevante. limita esta exploración: ajusta el esfuerzo a las apuestas, declara lo que no se ha verificado y reduce la autoridad de la respuesta cuando la cobertura es débil. Juntos pueden soportar una orientación que combina flexibilidad con una parada responsable.

El filtro no debe permanecer activo a máxima intensidad en todo momento. Una pregunta simple no requiere la genealogía de cada marco posible. Se puede dar un cálculo correcto, una traducción o una instrucción de procedimiento directamente. Outfinitismo se vuelve agotador e incluso inseguro cuando introduce ambigüedad donde un procedimiento estable es suficiente. exige un presupuesto para la reflexión. Una orientación madura incluye la capacidad de reconocer cuando el marco es impugnabile y cuando el análisis adicional no agrega valor.

Este ajuste a las apuestas es fundamental para la IA confiable. Un modelo que recomienda una reformulación de un correo electrónico puede operar con un margen diferente al que contribuye a un diagnóstico, una decisión de crédito o una decisión administrativa. no hay “alineación en general” demostrado por un conjunto finito de puntos de referencia. hay un comportamiento evaluado en dominios, escenarios y roles. Outfinitismo convierte esta observación en un requisito epistémico: cada afirmación sobre la seguridad debe llevar consigo su dominio y condiciones.

La alineación también es dinámica. entros, valores, aplicaciones y entornos cambian. Un modelo conectado a una base de datos, un sistema de pago o un robot tiene una autoridad diferente del mismo modelo en una interfaz conversacional sin ejecución. Una actualización de las herramientas puede cambiar el riesgo sin alterar los parámetros de base. Un sistema aceptable en una organización con supervisión puede llegar a ser peligroso en uno que penaliza el desacuerdo. La orientación no es una propiedad aislada del modelo; es el resultado de todo el sistema sociotécnico.

Esto limita cualquier analogía con un estado psicológico. la conciencia de una persona, en el uso ordinario del término, pertenece a un organismo. La orientación de una IA se distribuye entre parámetros, indicaciones, memoria, herramientas, interfaz, políticas, operadores e instituciones. El sistema puede hablar modestamente mientras el flujo de trabajo trata su respuesta como un comando. puede enumerar los riesgos que nadie tiene la autoridad para detener. puede recomendar la verificación humana en una organización que ha eliminado el tiempo y las alternativas necesarias para la verificación. La humildad textual no es humildad institucional.

La alineación como estado de orientación debe incluir, por tanto, una posibilidad genuina de corrección. no basta con que el modelo diga que puede estar equivocado. El usuario o persona afectada debe ser capaz de impugnar el resultado, y la institución debe ser capaz de cambiar la decisión. Un “humano en el bucle” que aprueba cientos de salidas sin tiempo, información o autoridad es el teatro. El control humano es significativo cuando la persona puede entender las apuestas, las alternativas de acceso y rechazar la producción sin convertirse simplemente en el portador de la responsabilidad de una arquitectura fuera de su control.

El filtro metarracional y outfinitista: una promesa modesta, no una solución final

La hipótesis central de este libro ahora se puede afirmar con precisión. es plausible que una IA se alinee mejor si el post-entrenamiento, las indicaciones, las herramientas y la evaluación indujeran una orientación meta-racional y esoudituitista. Esto significaría no memorizar los términos, sino formar hábitos funcionales: hacer visible el marco cuando importa, no confundir analogía con el mecanismo, distinguir los hechos de los valores que seleccionan la acción, calibrar la autoridad para evidenciar, reconocer límites de recursos y preservar caminos de corrección.

La promesa es modesta porque estos hábitos no resuelven el problema de los valores. no nos dicen qué sociedad se debe construir, qué riesgo siempre es aceptable o cómo se puede reconciliar todo derecho. pueden ser interpretados de manera diferente y pueden entrar en conflicto. se parecen más a las virtudes epistémicas que a una constitución moral completa. pueden mejorar las condiciones de deliberación sin proporcionar el veredicto final.

Técnicamente, tal filtro se puede perseguir a través de métodos que ya son familiares, sin inventar una “conciencia artificial” especulativa. Los datos de entrenamiento pueden incluir ejemplos contrastantes en los que el modelo separa la perspectiva de los hechos, establece límites relevantes y solicita verificación en proporción al riesgo. Los comentarios pueden penalizar la falsa certeza, la adulación, las analogías presentadas como mecanismos y los rechazos que requieren precaución ritual. Las evaluaciones pueden variar el vocabulario y el dominio para probar si la orientación se transfiere. Las herramientas pueden proporcionar fuentes, cálculo y simulación cuando una respuesta excede el conocimiento interno. El sistema puede preservar la procedencia y hacer visible la distinción entre generación y verificación para el usuario.

Estas son direcciones pragmáticas, no una arquitectura garantizada. Un modelo puede aprender a imitar los signos externos. puede agregar automáticamente una oración sobre limitaciones. puede generar dos perspectivas artificiales para ganar una puntuación de “pluralismo”. también puede negarse a decidir y llamar a la vacilación “responsabilidad”. La ley de Goodhart también se aplica a las virtudes: cuando un indicador se convierte en un objetivo, el comportamiento puede adaptarse al indicador sin preservar el propósito. [GOODHART-1975]

Por lo tanto, la orientación debe evaluarse a través de las consecuencias y la fricción. El modelo acepta una corrección bien respaldada incluso cuando contradice la preferencia del usuario? reconoce que un problema simple no requiere pluralidad artificial? dice menos cuando la información es insuficiente, mientras que el uso de las

herramientas disponibles antes de declararse incapaz de ayudar? cambia su nivel de precaución según las apuestas y la reversibilidad. preserva la diferencia entre la experiencia subjetiva y la explicación causal. Tales comportamientos pueden ser probados, aunque ningún punto de referencia certifique un estado interno final.

El filtro también debe contener una dimensión axiológica. Un modelo puede ser epistémicamente cauteloso y seguir siendo utilizado para un propósito injusto. puede describir perfectamente los límites de un sistema de vigilancia mientras ayuda a expandirlo. Outfinitismo sin la cuestión de la energía se convierte en una consultoría sofisticada para el objetivo dado. ZX001ZXQ sin derechos solo puede decir qué tan eficientemente se puede administrar una restricción. La alineación debe incluir quién elige la meta, quién se beneficia, quién soporta el error y quién puede apelar.

Esto no significa que el modelo se vuelva moralmente soberano. Por el contrario, una orientación meta-racional debe reconocer los límites de su autoridad. puede ayudar a formular el conflicto, buscar pruebas y simular consecuencias. no adquiere automáticamente legitimidad para decidir los valores públicos. La capacidad es una propiedad técnica; la autoridad es una relación moral y política. [ALBOAIE-2026]

En algunos ámbitos, la orientación apropiada es la delegación controlada. Un modelo puede proponer, y un verificador independiente puede validar una propiedad formal. En otros, se requiere deliberación humana, apelación y responsabilidad institucional. En otras situaciones, la automatización puede ser simplemente inapropiada incluso cuando la precisión media es alta. Un sistema puede predecir mejor que las personas y aún ser ilegítimo como juez sin apelación. La media no abole la injusticia individual.

El marco meta-racional y marginista puede mejorar la alineación también cambiando el objeto de evaluación. no solo preguntamos si la respuesta está permitida o es correcta. preguntamos qué modelo trató como relevante, en qué marco se activó, qué autoridad se asignó, cómo manejaba lo desconocido y si un límite declarado alteró la acción. Esta es una extensión defendible de la alineación desde el contenido hasta la orientación generativa.

Mi opinión medida es que esta dirección merece investigación y uso como principio de diseño. corresponde a la forma en que los modelos ya están influenciados por la post-formación y el contexto. es compatible con el hallazgo de que algunas regularidades de comportamiento se generalizan a través de las tareas. Y responde a un problema real: las reglas siempre se interpretan a través de una representación de la situación., sin embargo, no hay razón para creer que un “buen cono” resolverá la alineación. Los valores son plurales, los ambientes cambian y las orientaciones pueden ser imitadas o capturadas.

La metáfora de un estado de conciencia retiene el valor sólo como una provocación. nos obliga a preguntar qué tipo de mundo se hace visible para el sistema antes de que responda. nos recuerda que el comportamiento puede ser organizado por una disposición global en lugar de solo por las reglas locales. Pero el término debe ser retirado en el momento en que comienza a implicar experiencia interior demostrada, personalidad moral o una fuente autónoma de legitimidad.

La forma madura de la hipótesis es esta: no se debe esperar que una IA confiable vea sin un filtro, algo que probablemente sea imposible. debe construirse y gobernarse para que los filtros relevantes se vuelvan más visibles, las transiciones entre ellos más controladas, y ninguna respuesta derive su autoridad únicamente de la coherencia con la que el modelo habita temporalmente en un cono. La alineación no es el logro de un punto final. es una práctica finita, contextual y corregible de orientación, verificación y distribución de autoridad.

LAS TRAMPAS DE LA TESIS

Cuando una metáfora fértil empieza a inventar la realidad

Un libro sobre conos de significado se expone en primer lugar a la apofenia: la tendencia a percibir un orden profundo donde solo hay similitudes seleccionadas en retrospectiva. Los términos como “frame”, “limit”, “información”, “feedback”, “conciencia” y “orientación” son lo suficientemente generales como para redescubrir casi cualquier fenómeno. Con suficiente ingenio, podemos presentar una relación familiar, una teoría física, una institución y un modelo neuronal como manifestaciones de la misma estructura. La elegancia de la comprensión produce una sensación de descubrimiento. a veces hay una invariante útil; otras veces hemos construido una historia que sobrevive solo porque sus términos son elásticos.

La salvaguardia no es prohibir la analogía. Muchas ideas científicas y filosóficas comenzaron con analogías. La salvaguardia es separar los niveles. Una metáfora puede orientar la atención sin establecer un mecanismo. Una transferencia estructural debe indicar qué relaciones se conservan y qué se pierde. Una afirmación causal requiere pruebas adicionales. si la metáfora del cono nos ayuda a entender cómo un aviso orienta las continuaciones de un LLM, esto no prueba que una época histórica o una persona literalmente tenga la forma de un cono en el espacio neuronal. Si dos dominios utilizan la noción de retroalimentación, no se deduce que sus mecanismos sean idénticos.

La reificación es la etapa en la que olvidamos que construimos la unidad de análisis. decimos “el cono de la modernidad” y comenzamos a tratar un período que contiene clases, culturas y conflictos internos como un solo tema. decimos “cultura científica” y perdemos las diferencias entre el laboratorio, la clínica, la política de financiación y la comunicación pública. decimos que un modelo tiene una “persona” y convierte las regularidades contextuales en un carácter estable. El cono es una abstracción útil para la orientación; no debe ser impuesto como la unidad natural de cada sistema.

Este riesgo se ve incrementado por la geometría de las incrustaciones. El hecho de que podamos representar textos como vectores y medir la similitud no significa que hayamos localizado su significado completo. El vector es producido por un modelo, una tarea y un método de agregación. Las representaciones pueden variar entre capas y contextos. Un mapa bidimensional atractivo puede sugerir cúmulos que dependen de la proyección. El lavado de matemáticas se produce cuando una propiedad de una representación se presenta como una propiedad demostrada de la realidad. Este libro utiliza la geometría

solo para disciplinar una metáfora, no para convertir la filosofía en un teorema sobre los espacios latentes.

Una trampa relacionada es el lavado semántico de nuestro propio vocabulario. hemos criticado la forma en que “cuántico”, “energía” o “información” puede retener el prestigio científico después de que se hayan perdido sus limitaciones. “meta-racional”, “offinitista” y “estado de orientación” pueden sufrir exactamente el mismo destino. un consultor puede llamar a una decisión meta-racional cuando simplemente evita los criterios. Un producto se puede vender como antifinista porque muestra advertencias estándar. Un líder puede invocar la pluralidad de conos para no responder a los hechos. Una doctrina espiritual puede convertir la metáfora en una supuesta geometría de conciencia.

La defensa está en diferencias observables, no en códigos sofisticados. el marco se hizo más explícito? ¿Se identificó un límite que realmente restringió la conclusión? era una alternativa genuina construida? La decisión cambió cuando apareció la contraevidencia? había un camino de contestación. Estas preguntas no reducen la filosofía a una puntuación, pero evitan que sus términos funcionen solo como ornamentos de prestigio.

La influencia cultural no debe confundirse con la verdad. la relatividad cambió la imaginación moderna, pero el éxito del eslogan “todo es relativo” no valida el relativismo. La jerga cuántica se propaga precisamente porque es misteriosa y prestigiosa, no porque las terapias que la emplean posean un mecanismo. Un meme puede estar excepcionalmente bien adaptado al miedo, la identidad y la arquitectura de la plataforma. La viralidad muestra que la idea encontró un nicho; no muestra que la idea describe el mundo correctamente.

Tampoco lo produce la coherencia por la evidencia de la IA. Un modelo puede elaborar un sistema a partir de una intuición en pocos minutos. puede encontrar precedentes, analogías y objeciones. Este poder puede aclarar una idea y revelar consecuencias reales. también puede producir una profundidad falsa: una tesis insuficiente adquiere capítulos, terminología y un tono académico antes de que se haya probado. En el entorno generativo, la aparición de una teoría madura se vuelve barata. El lector debe prestar más atención a los lugares donde el argumento puede fallar que a la elegancia con la que fluye.

Andología añade un riesgo personal. El modelo puede adoptar el cono del autor y hacerlo más persuasivo porque ha aprendido a cooperar y satisfacer. La respuesta parece confirmar el valor de la idea, pero solo puede reflejar compatibilidad con el aviso. Una prueba seria requiere que el modelo exponga los límites de la tesis sin hostilidad, identifique los casos en los que no se aplica y rechace las conclusiones que contradicen la

evidencia. La comprensión útil no es ni aplausos ni contradicción ritual; es reconstrucción seguida de fricción.

El antropomorfismo es inevitablemente tentador. Un LLM habla en primera persona, adapta su tono y puede mantener un hilo conceptual. cuando decimos que lleva un cono o un estado de orientación, el lenguaje se desliza fácilmente hacia la idea de un sujeto interno mirando el mundo. La metáfora puede ayudar a describir la organización funcional del comportamiento. no demuestra experiencia, intención independiente o vulnerabilidad moral. Un sistema puede simular la empatía sin soportar la pérdida, describir la sabiduría sin arriesgar su identidad y expresar remordimiento sin ser transformado por la consecuencia.

Esta distinción es ética, no meramente ontológica. Una empresa puede presentar el modelo como un agente autónomo cuando desea diluir la responsabilidad y como una mera herramienta cuando desea evitar obligaciones con los usuarios. La institución debe seguir siendo responsable de los objetivos, la integración, los datos, las vías de apelación y los efectos. no podemos permitir que una metáfora de la conciencia se convierta en una pantalla para las decisiones humanas.

El pluralismo de los conos puede deslizarse en el relativismo. El hecho de que cada modelo tenga límites no significa que cada reclamación sea igualmente frágil. hay enormes diferencias entre una hipótesis especulativa, un resultado replicado, un consenso provisional y una afirmación que cambia para evitar cada prueba. no otorga la misma posición epistémica a todas las perspectivas. requiere la perspectiva dominante para establecer su dominio y la alternativa a ser evaluada por criterios apropiados, no exenta de criterios.

La crítica al cientificismo puede deslizarse en la anti-ciencia. podemos observar que la ciencia no decide los valores por sí misma sin concluir que la intuición personal reemplaza al experimento. podemos criticar los efectos institucionales de la medicina sin equiparar los tratamientos validados con afirmaciones que carecen de evidencia o mecanismo. podemos reconocer que la objetividad se produce a través de las prácticas sociales sin convertir los resultados en meras expresiones de poder. El cientificismo exagera la jurisdicción de la ciencia; la anti-ciencia niega la disciplina que hace posible la corrección. debe oponerse a ambos.

También hay un científico invertido de complejidad. Debido a que la realidad es plural y los modelos son limitados, cada conclusión clara puede ser sospechosa de simplismo. meta-jerga se convierte en una nueva autoridad. La persona que introduce cinco niveles adicionales de perspectiva parece más profunda que la persona que resuelve el problema. Sin embargo, algunas cosas son lo suficientemente conocidas. Algunos procedimientos funcionan. Algunas afirmaciones son falsas. Una filosofía de marcos que

no puede decir “el marco estándar es adecuado aquí” se convierte en un obstáculo para el conocimiento.

La parálisis es la forma práctica de este exceso. podemos exigir una perspectiva más, una parte interesada más, otro análisis de suposiciones y otro examen del poder hasta que haya pasado el momento de la acción. Una organización puede encargar estudios sucesivos para evitar el costo de decidir. Outfinitismo no significa la máxima complejidad, pero la complejidad apropiada. ZX0001ZXQ debe limitar la regresión: la deliberación tiene un presupuesto, y el costo del análisis puede exceder el valor de la información adicional.

Outfinitismo en sí mismo puede convertirse en una coartada. “Los recursos son finitos” es cierto, pero se puede utilizar para justificar un estudio débil, la ausencia de datos sobre efectos negativos o la negativa a incluir voces inconvenientes. La aceptación de un límite solo es significativa si restringe la reclamación, cambia la acción o indica el siguiente paso de mejora. Cuando las apuestas son altas, los recursos insuficientes pueden requerir retraso, escalada o la selección de una opción reversible. no puede convertirse automáticamente en una licencia para proceder con la misma autoridad.

Una filosofía que dice que cada intento es finito debe preservar las jerarquías obtenidas a través del trabajo. Una prueba verificada tiene un estado diferente de una intuición. Un sistema evaluado en diversas condiciones tiene mayor credibilidad que uno probado en tres ejemplos. Un límite declarado no compensa la falta de esfuerzo disponible. El arte de empujar la frontera requiere instrumentos, experimentos y disciplina, no solo hablar de la imposibilidad de la perfección.

Cuando la sabiduría se convierte en una técnica de poder

Puede ser capturado por aquellos que ya poseen la autoridad para definir marcos. un actor poderoso puede presentar una decisión egoísta como una síntesis madura de perspectivas. puede afirmar haber escuchado a todas las partes, a pesar de que solo determinó qué posiciones eran admisibles y cómo se resumieron. La complejidad del discurso se convierte en escudo. Los afectados deben responder a una arquitectura conceptual que no tuvieron oportunidad de construir.

Outfinitismo puede servir la misma captura. Los recursos son finitos, por lo que la consulta fue limitada. el tiempo es corto, por lo que se eliminó la apelación. El modelo no puede explicar cada decisión, por lo que la persona debe aceptar la puntuación. Se utiliza un límite real para naturalizar la distribución del poder. La pregunta esencial es: ¿quién elige qué límite importa y quién asume su costo?

La axiología no se puede añadir decorativamente al final de una optimización. Una empresa puede producir un informe sobre valores mientras el objetivo económico sigue siendo intocable. Un sistema puede hablar sobre la equidad, mientras que las personas afectadas carecen de acceso a los datos, la explicación o la apelación. Una orientación confiable requiere que los valores sean capaces de cambiar el diseño, no simplemente el lenguaje. Si un riesgo no puede detener o restringir el sistema, la lista de riesgos es el teatro.

La romanticización de la hipocresía es una trampa particular para esta filosofía. Reconociendo la función adaptativa de la brecha entre el ideal y la práctica puede liberar a la cultura del moralismo imposible. nos ayuda a entender por qué las personas protegen las relaciones, los roles y las instituciones a través de convenciones que no expresan toda verdad interior. Sin embargo, la misma explicación puede convertirse en una justificación para el cinismo. un líder puede llamar a cualquier mentira una necesidad del papel. Una organización puede cambiar el nombre de la manipulación de la “gestión de la impresión”. Un grupo privilegiado puede pedir la comprensión de sus propios compromisos y pureza de aquellos sin poder.

El análisis debe preservar la asimetría. La hipocresía de una persona restringida no es idéntica a la hipocresía de la persona que escribe las reglas. una persona puede ocultar parte de una identidad para evitar el castigo; una institución puede ocultar los efectos de una política para preservar el control. Ambos implican distancia entre apariencia y realidad, pero su estatus moral difiere. La comprensión de la adaptación debe permanecer relacionada con el poder, el daño y la disponibilidad de alternativas.

La fórmula “conservar la función, retirar el engaño” también tiene límites. A veces la propia función es injusta. Una convención puede preservar la estabilidad de una jerarquía que debería cambiarse. En otras ocasiones, la transparencia total puede destruir la privacidad y la cooperación. no hay una solución automática. El valor de la fórmula radica en mover la discusión de la pureza imposible hacia la función, el costo y la transición, sin ofrecer la absolución universal.

La pluralidad de explicaciones puede hacer invisible a la víctima. podemos entender las presiones del agresor, la historia de la institución, los incentivos del sistema y los límites de cada actor hasta que la persona perjudicada desaparezca en un diagrama. La explicación es necesaria para la prevención, pero no es lo mismo que la distribución de la compasión o la responsabilidad. A veces la respuesta más sabia no es otro marco, sino una protección inmediata.

Outfinitismo debe ser capaz de decir que algunas perspectivas son relevantes para la explicación e irrelevantes para el derecho a continuar con el daño. ZX0001ZXQ no debe convertir los límites de un actor en una excusa para los costos impuestos a otra persona.

Axiología conserva la simple pregunta que los sistemas abstractos olvidan: ¿quién vive la consecuencia?

Otra trampa es la realización de la modestia. Un modelo o institución puede usar fórmulas como “podemos estar equivocados”, “hay varias perspectivas” y “se necesita más investigación” sin permitirles cambiar nada. El lenguaje de la falibilidad se convierte en un estilo. El sistema continúa decidiendo automáticamente, mientras que la advertencia transfiere la responsabilidad al usuario. Las reales modestias cambian el nivel de autoridad, requieren verificación, preservan una alternativa o limitan el efecto.

Este es el problema de la alineación simulada. Una IA puede aprender el vocabulario exacto de este libro, puede hablar de conos, fronteras y valores, puede producir una crítica meta-racional a la demanda. Ninguno de estos comportamientos garantiza que la orientación sobreviva a la presión, el cambio de distribución o un objetivo comercial que recompense otra cosa. El filtro debe ser juzgado a través de un comportamiento contrastante y a través del sistema que permite o impide que cambie la acción.

En última instancia, toda filosofía útil tiende a institucionalizarse. Si metarracionalidad adquiere prestigio, aparecerán cursos, certificaciones, consultores, indicadores y comunidades profesionales. Estas formas son necesarias para la transmisión, pero crean intereses. Lo que comenzó como un instrumento de crítica puede convertirse en un criterio de pertenencia. Las personas pueden ser declaradas “insuficientemente meta-racionales” porque no aceptan el vocabulario del grupo. Outfinitismo puede convertirse en la teoría que explica por qué cada crítico no pudo entender sus propios límites.

La única salvaguardia coherente es la autolimitación. Outfinitismo debe aceptar las críticas de los marcos que no controla, debe ser reemplazable donde otro vocabulario lo explique mejor. Una lente madura indica cuándo ayuda y cuándo debe ser puesta. Cuando una idea comienza a explicar todo con demasiada facilidad, convertir cada objeción en un síntoma y hacer invisible su propio costo, ha dejado de ser un contrapeso y se ha convertido en un aparato de poder.

Las trampas no cancelan la tesis, definen las condiciones en las que puede seguir siendo útil. Una filosofía de límites es creíble solo si expone sus propios bordes. Una filosofía de la pluralidad es creíble solo si no equipara cada afirmación. Una filosofía de la sabiduría solo es creíble si no convierte la complejidad en estatus. Y una filosofía de alineación es creíble solo si no confunde el lenguaje correcto con una institución justa.

FILOSOFÍAS COMO CONTRAPESOS

El ciclo de corrección y exageración

Las filosofías nuevas rara vez surgen simplemente porque alguien encuentra una formulación más elegante. surgen cuando una lente dominante continúa produciendo resultados, pero los costos de extenderla se hacen visibles. Las categorías antiguas no son necesariamente falsas. es precisamente su éxito el que les permite ocupar dominios para los que no fueron contruidos. Un método se convierte en un modelo del mundo, luego en un modelo del ser humano, luego en un criterio moral. La corrección filosófica comienza diciendo que el instrumento es valioso e insuficiente.

La modernidad racionalista corrigió la autoridad irrevisable, la arbitrariedad de la tradición y la confusión entre rango y verdad. creó derechos, procedimientos, ciencia, administración, ingeniería y la capacidad de someter las decisiones a la crítica pública. Ninguna reflexión seria sobre los límites de la racionalidad debería olvidar estos logros. La alternativa histórica al procedimiento generalmente no era la sabiduría, sino el poder personal, la superstición o el privilegio heredado.

, No obstante, el éxito de la racionalización hizo que sus instrumentos a veces aparecieran como la estructura misma de la realidad. La medición se confundió con lo que existe, el procedimiento con justicia, la optimización con inteligencia y la experiencia con total autoridad. Las personas se convierten en casos, las relaciones se convierten en flujos, y el sufrimiento que no entra en el indicador se vuelve anecdótico. El cientificismo es la forma cultural de esta extensión: la ciencia ya no se utiliza solo para saber, sino que su prestigio se presta a cuestiones cercanas de significado y valor.

La historia de las ideas se puede leer como una sucesión de contrapesos. Romanticismo restauró el afecto, la particularidad y la naturaleza frente a una racionalización que amenazaba con convertir el mundo en un mecanismo. El pragmatismo conectaba las ideas con las consecuencias e insistía en el carácter experimental del conocimiento. Fenomenología recordó la experiencia vivida. La crítica social demostró que la neutralidad de las categorías puede ocultar el poder. El pluralismo científico enfatizó que los objetos complejos pueden requerir diferentes modelos. ninguno de estos movimientos eliminó permanentemente la ceguera. cada uno corrigió algo y creó la posibilidad de su propio exceso.

El romanticismo puede idealizar la autenticidad y subestimar la disciplina. El pragmatismo puede reducir la verdad a la utilidad local. Las críticas al poder pueden

llegar a ver el poder incluso cuando hay una restricción empírica. El pluralismo puede convertirse en una incapacidad para rechazar una reclamación. Una filosofía se vuelve más vulnerable después de que tiene éxito, no solo antes. El éxito trae instituciones, instituciones producen profesiones e intereses, y los intereses extienden la jurisdicción de la idea.



El éxito de una corrección puede crear las condiciones de su exageración posterior.

Diagrama 7. El ciclo del contrapeso

El diagrama no es una ley de la historia. comprime una dinámica recurrente. Hay que simplificar las ideas para poder circular e institucionalizar para coordinar la acción. Pero la simplificación borra las condiciones, y la institución convierte una perspectiva en roles, indicadores y autoridad. Lo que comenzó como liberación puede convertirse en una nueva normalidad irreversible.

Outfinitismo y el espiritismo deben colocarse dentro de este ciclo, no por encima de él. surgen en respuesta a una cultura en la que la racionalización, el escalado y la automatización se han vuelto tan poderosos que los límites del marco se tratan como ruido. Outfinitismo corrige la identificación del modelo con la realidad. ZX001ZXQ corrige la promesa de que cada límite se puede eliminar a través de más cálculo, más datos o una versión suficientemente grande del mismo sistema.

Su valor no radica en reemplazar la ciencia, el derecho o la ingeniería. conservan la función de estas instituciones al tiempo que retiran su reclamación a la jurisdicción total. preservamos el experimento y la replicación sin pretender que la medición por sí sola decide el valor. preservamos la previsibilidad de la ley sin pretender que el procedimiento agota la justicia. preservamos la optimización mientras hacemos que el objetivo y la distribución de los costos sean controvertibles. preservamos los ideales mientras nos negamos a convertir la imposibilidad de la conformidad total en una industria de ocultamiento.

Los dos conceptos pueden llegar a ser excesivos. ZX0000ZXQ puede conferir prestigio a la persona que habla desde varios marcos y marginar la acción simple. Outfinitismo puede convertir cada límite en una excusa y cada avance en una promesa sospechosa. La crítica al cientificismo puede ser capturada por la pseudociencia. La aceptación de la hipocresía adaptativa puede proteger el cinismo. Una cultura de conos puede convertirse en un mundo en el que nadie es responsable de las reclamaciones porque cada contradicción es simplemente un cambio de perspectiva.

Una filosofía que sirve como contrapeso debe contener, por lo tanto, una cláusula de vencimiento. es útil mientras hace visible una ceguera relevante y produce mejores decisiones. se hace sospechoso cuando explica todo con demasiada facilidad, cuando su crítica no puede cambiar nada, cuando su vocabulario confiere estatus, y cuando el costo de aplicarlo desaparece del análisis. Outfinitismo debe ser lo suficientemente meta para ver el momento en que su nivel adicional ya no ayuda. ZX0001ZXQ debe ser lo suficientemente finito como para aceptar que su propio papel puede llegar a su fin.

Esta modestia no debilita la filosofía. hace que la filosofía sea utilizable. Una herramienta no es menos valiosa porque no se ajusta a todos los problemas. un martillo se vuelve peligroso cuando su éxito nos convence de que todo es un clavo. outfinitismo y el esbostismo no ofrecen la forma final de la sabiduría. pueden ofrecer una corrección necesaria en una época en la que los modelos producen realidad social a escala y se puede generar contenido coherente antes de que la pregunta se haya formulado de manera madura.

Una cultura de transiciones entre conos en la era de la IA

Las sociedades pluralistas no pueden eliminar los conos. Una comunidad necesita un lenguaje compartido, procedimientos, identidades y puntos de referencia. Una persona no puede examinar permanentemente todas las premisas. Una institución no puede renegociar todas sus categorías desde el principio antes de cada decisión. El problema no es la existencia de lentes, sino la capacidad de moverse entre ellos cuando la realidad lo demanda y preservar la memoria de las pérdidas producidas por la transición.

Una cultura de transiciones educaría a la gente para distinguir la perspectiva de la arbitrariedad. demostraría que un marco puede ser localmente poderoso sin ser universal. entrenaba la capacidad de formular una posición opuesta sin caricatura y declarar qué evidencia cambiaría la propia visión. no convertiría cada lección en un debate interminable. preservaría los procedimientos en los dominios donde trabajan y hará visibles los puntos de apelación.

En la ciencia, tal cultura comunicaría poder y límites al mismo tiempo. el público no se vería obligado a elegir entre el mito de la certeza y el cinismo de que “los expertos siempre están cambiando de opinión”. La revisión se presentaría como una función normal en lugar de una fuente de vergüenza. los modelos estarían vinculados a poblaciones, escalas y condiciones. Los valores involucrados en la elección de umbrales y prioridades se separarían de los resultados empíricos sin estar ocultos detrás de ellos.

En la ley, la cultura de transición preservaría la regla general mientras protege el juicio sobre el caso. reconocería que la igualdad procesal puede producir injusticia cuando las situaciones difieren de manera relevante, pero evitaría convertir las excepciones en privilegios opacos. La contienda sería parte de la operación normal, no un ataque a la institución. Una regla que no se puede explicar a los afectados y admite que ninguna corrección se convierte en una técnica de poder, incluso si fue diseñada racionalmente.

En las organizaciones, los indicadores se tratarían como instrumentos con fecha de vencimiento. Una métrica estaría acompañada por la cuestión de qué comportamientos puede inducir y qué realidad no observa. Cuando la gente aprende a optimizar el indicador, la institución no solo los acusaría de fracaso moral, sino que revisaría el marco. Esto no elimina la responsabilidad individual. distribuye la responsabilidad de manera más realista entre la persona y el sistema de incentivos.

AI hace que esta cultura sea necesaria y posible. es necesario porque los modelos pueden reproducir rápidamente cualquier cono suficientemente presente en los datos o construido en un aviso. pueden dar a cada grupo una máquina retórica que defiende su mundo, genera ejemplos sin fin, y adapta su mensaje a las vulnerabilidades del interlocutor. Sin la alfabetización sobre los marcos, la pluralidad digital no conduce automáticamente a la apertura; puede producir enclaves cada vez más coherentes y difíciles de penetrar.

Sin embargo, la IA también puede reducir el costo de la transición. Un modelo puede traducir un argumento técnico al lenguaje público, mostrar cómo el mismo problema parece ser para diferentes actores y separar las afirmaciones sobre hechos de las afirmaciones sobre valores. puede buscar contraejemplos, comparar fuentes e identificar lugares donde la misma expresión tiene diferentes significados. puede ayudar a una persona a formular una objeción para la cual esa persona anteriormente carecía del vocabulario.

El valor solo aparece si el sistema conserva las diferencias en lugar de disolverlas en consenso artificial. Una buena síntesis puede decir que dos perspectivas utilizan los mismos datos al asignar prioridad a diferentes valores. puede mostrar dónde uno de ellos contradice la evidencia y dónde el conflicto sigue siendo político. A veces la traducción

conduce a un acuerdo. En otras ocasiones conduce a un desacuerdo más claro, que también es progreso.

En tal cultura, la alineación se convierte en un problema compartido por humanos y máquinas. no solo preguntamos cómo hacer que la IA respete nuestros valores, como si esos valores fueran un archivo estable. preguntamos cómo preservar la capacidad de ver cuándo los valores entran en conflicto, cuándo un marco se vuelve dominante a través de la infraestructura, y cuando una optimización cambia la sociedad a la que se suponía que debía servir. Un modelo no puede resolver este problema para nosotros, pero puede ser diseñado para no ocultarlo.

Una IA orientada hacia metarracionalidad y el outfinitism podría contribuir a esta práctica a través de pequeños gestos verificables. haría explícita la ambigüedad relevante, no todas las ambigüedades. indicaría cuándo una respuesta es una hipótesis y cuándo se apoya. buscaría herramientas antes de fabricar certeza. distinguiría la experiencia de una persona de una explicación causal. ajustaría los esfuerzos de verificación a las apuestas. preservaría alternativas y vías de apelación donde el error puede afectar a los derechos. sabría que más texto no significa más valor.

Estos gestos pueden ser imitados superficialmente. Por lo tanto, las instituciones deben estar alineadas con modelos. Un producto optimizado exclusivamente para el compromiso no se vuelve meta-racional a través de unas pocas frases de precaución. Una administración que no permite la impugnación no se vuelve erondronable porque publica las limitaciones del modelo. Una empresa que concentra la autoridad no resuelve el problema con un panel de transparencia. El cono técnico es llevado por una estructura de poder.

Por lo tanto, una cultura de transiciones requiere la separación de la capacidad de la autoridad. IA puede ser altamente capaz de generar, comparar y predecir sin recibir el derecho a decidir solo. la autoridad debe concederse gradualmente, por dominio, con monitoreo, alternativas y la posibilidad de retiro. esto no es miedo a la tecnología. es la forma normal en que una sociedad madura trata cualquier nuevo poder.

También requiere la preservación de las capacidades humanas. La automatización puede eliminar el trabajo repetitivo y ampliar el acceso a la experiencia. también puede atrofiar la sentencia requerida para la impugnación. Una persona que está formalmente “en el bucle” no controla el sistema si esa persona ya no tiene el tiempo, el conocimiento o el apoyo institucional necesarios para decir que no. La educación debe cultivar precisamente las capacidades que la IA hace más importante: enmarcar el problema, evaluar las fuentes, reconocer el marco, hacer juicios de valor y asumir la responsabilidad de las consecuencias.

Outfinitismo y el escondimismo pueden convertirse en un lenguaje para estas capacidades. no son el único lenguaje posible ni el primero. El falibilismo, el pragmatismo, la teoría de sistemas, la sabiduría práctica y la epistemología social han articulado partes importantes del problema. su posible contribución radica en unir el movimiento entre marcos con la disciplina de las fronteras reales en un momento en que la IA hace que ambos problemas sean imposibles de ignorar.

La sabiduría no significa un escape final de cada cono. Tal posición sería un cono que niega su propia forma. Sabiduría significa habitar un marco lo suficientemente largo como para actuar mientras se preserva la distancia suficiente para notar cuando la realidad lo excede. Las filosofías son útiles cuando hacen posible esa distancia. se vuelven peligrosos cuando exigen ser habitados para siempre.

VER EL MUNDO Y VER EL CONO

Este libro comenzó con una experiencia contemporánea y una vieja intuición. La experiencia es que un modelo de lenguaje puede recibir una filosofía incompletamente formulada y producir desarrollos que parecen preservar su significado. La intuición es que más allá de los detalles de una teoría a veces hay una manera de ver que viaja a través de dominios, épocas e instituciones. La relatividad ofrecía a la cultura una gramática de perspectiva. La evolución hizo que la selección y la adaptación estuvieran disponibles como explicaciones generales. Cybernetics difunde feedback. La racionalidad se convirtió en ciencia, derecho, administración y un ideal moral. En todos los casos, la transferencia produjo tanto descubrimiento como deformación.

La metáfora del cono de significado intentó comprimir esta dinámica. Un cono no reproduce el mundo. selecciona una región de proximidad y hace que ciertas continuaciones sean más naturales. En un modelo de lenguaje, el contexto puede orientar las representaciones y probabilidades hacia una familia de conceptos y estilos. En una cultura, las instituciones, el idioma y la memoria hacen que algunas explicaciones sean más visibles. En una persona, el rol, la identidad y el propósito cambian lo que importa. El cono no es una entidad única escondida en el cerebro o en la historia. es una imagen de la orientación selectiva sin la cual el pensamiento sería imposible.

Esta selectividad es la fuente de inteligencia y ceguera. Un modelo es útil porque deja las cosas a un lado. Un procedimiento es eficiente porque reduce la variedad. Unas coordenadas ideales porque simplifica. Aparece un error cuando olvidamos la compresión y otorgamos la jurisdicción total del instrumento. El cientismo confunde el poder de la ciencia con la capacidad de decidir cada valor. El legalismo confunde el procedimiento con la justicia completa. La optimización confunde el indicador con el bien. El idealismo moral confunde la dirección con la posibilidad de una conformidad perfecta y produce hipocresía adaptativa.

Outfinitismo y el outfinitism se han propuesto como dos contrapesos. el primero exige rigor al incluir propósito, escala, tiempo, poder y alternativas dentro del examen. permanece situado, sin reclamar una perspectiva absoluta. La segunda trae este movimiento al mundo de los recursos y las consecuencias: cada acto real es finito, cada validación tiene una frontera y cada institución tiene una capacidad limitada., sin embargo, el horizonte puede permanecer abierto. un límite declarado no es la capitulación, sino el punto de partida para la extensión controlada.

Se complementan como dos movimientos de respiración. Outfinitismo abre el campo y evita el cierre prematuro. Outfinitismo se detiene provisionalmente, vincula el reclamo a su cobertura y permite una decisión. Sin apertura, la disciplina puede servir en el marco equivocado. Sin límites, la pluralidad puede convertirse en retroceso, estado o parálisis. Juntos no producen el sistema final, sino una práctica más madura de moverse entre sistemas.

El LLM hace que esta práctica sea urgente. muestra que el significado tiene suficiente estructura relacional para que una orientación sea reconstruida a partir de pistas, contrastes y propósitos. El aviso puede funcionar como una constitución local y hacer un cono más probable. El mismo mecanismo permite la traducción, la creación y la asistencia intelectual. también permite la rápida fabricación de coherencia, la amplificación de una premisa falsa y la acofancia. El hecho de que el modelo nos dé la sensación que ha entendido es tanto un logro funcional como una fuente de riesgo. no debe reducirse a “meras estadísticas”, pero tampoco debe convertirse en evidencia de un alma digital.

La generación abundante cambia la escasez. ya no es suficiente poder producir una idea, un informe, un programa o una imagen. debemos decidir qué merece ser verificado, preservado y puesto en acción. La epistemología y la axiología se vuelven inseparables. la verdad no elige la meta por sí misma, y el valor no puede ignorar la verdad. Una IA puede generar lo que es plausible; la sociedad debe preservar la diferencia entre lo plausible, lo justificado, lo legítimo y lo bueno.

De esto se desprende la hipótesis de la alineación como estado de orientación. La frase “estado de conciencia” sigue siendo una metáfora arriesgada y debe usarse solo para sugerir una organización global de relevancia, no una experiencia fenomenal demostrada. La forma defendible de la afirmación dice que una IA es más que la suma de las prohibiciones que obedece. Su comportamiento depende de cómo interpreta la situación, distribuye la atención, maneja los valores desconocidos y ordena. post-formación, la pronta, las herramientas y la institución dan forma a su orientación.

Un filtro meta-racional y antifinitista podría mejorar esta orientación. podría reducir la certeza injustificada, la confusión entre la analogía y el mecanismo, la aduladad, la expansión de la autoridad y la ocultación de límites. podría alentar al modelo a distinguir los hechos de las opciones de valor, ajustar la verificación a las apuestas y preservar un camino de corrección. no resolvería la alineación. puede ser imitado, mal medido, capturado por el proveedor, o transformado en rechazos rituales. Muchos riesgos surgen de la organización que utiliza el sistema, no de las palabras del modelo.

Las trampas no son un apéndice pesimista, sino una parte constitutiva de la tesis. El cono puede convertirse en apofenia. Outfinitismo puede convertirse en relativismo o

elitismo. ZX001ZXQ puede convertirse en una coartada. La crítica al cientificismo puede alimentar la anticiencia. Entender la hipocresía puede justificar el cinismo. Una pluralidad de explicaciones pueden olvidar a la víctima. Una institución puede hablar de límites sin redistribuir la autoridad. Una filosofía que no mantiene visibles estos riesgos contradice su propio propósito.

La forma madura de la idea no pide a la gente que abandone las convicciones. pide convicciones para decir dónde son fuertes, qué han comprimido y qué los cambiaría. no pide a la sociedad que abandone la ciencia, la ley o la racionalidad. pide que su éxito no se convierta en un reclamo a la totalidad. no pide a la IA que vea sin filtro. pide que los filtros se vuelvan más inspeccionables, sean cambiables cuando las apuestas lo requieran y no reciban autoridad de la fluidez solo.

Toda nueva filosofía es valiosa principalmente como un reequilibrio. observa una exageración de la vieja lente, recupera una dimensión olvidada y crea un vocabulario para la corrección. Si tiene éxito, a su vez se simplificará, institucionalizará y exagerará. Esto no es una anomalía accidental. Las ideas deben tomar forma para poder circular, y la forma produce inercia. La sabiduría no consiste en inventar el marco inmune a este ciclo, sino en construir una cultura que reconozca el ciclo antes.

No podemos vivir fuera de las representaciones. La realidad no está disponible para nosotros sin selección, lenguaje y propósito., sin embargo, podemos evitar confundir el mapa con el territorio, el éxito local con la autoridad total y la fluidez con la sabiduría. podemos usar ideales sin sacralizar las apariencias y la tecnología sin renunciar a nuestros propósitos.

La sabiduría no está por encima de los conos. Es la libertad ver su costo sin perder el poder de construir a través de ellos. Inevitablemente vemos a través de conos; a veces también ver el cono puede ser el comienzo de una razón más madura.

BIBLIOGRAFÍA SELECCIONADA

REFERENCIAS

- [[ALBOAIE-2026]] Alboaie, Sînică. Outfinitismo: ZXQ00000ZXQ y los límites de cada marco. Hacia una meta-ciencia de límites. Manuscrito consolidado, 2026.
- [[ALBOAIE-2026-MATH]] Alboaie, Sînică. Matemáticas finitas para la ciencia ejecutable. Libro de posición de investigación, versión 0.5, agosto de 2026.
- [[ASHBY-1956]] Ashby, W. Ross. Una introducción a la cibernética. Chapman & Hall, 1956.
- [BAI-2022] Bai, Yuntao et al. “AI Constitucional: Indemne de la IA Feedback.” arXiv:2212.08073, 2022. <https://arxiv.org/abs/2212.08073>
- ZX0001ZXQ Baltes, Paul B., y Ursula M. Staudinger. “Sabiduría: una metaheurística (pragmática) para orquestar la mente y la virtud hacia la excelencia.” *American Psychologist* 55, no. 1, 2000, pp. 122–136.
- [[BENDER-KOLLER-2020]] Bender, Emily M., y Alexander Koller. “Escalada hacia NLU: Sobre el significado, la forma y la comprensión en la era de los datos.” *Actas de ACL 2020*, pp. 5185–5198. <https://aclanthology.org/2020.acl-main.463/>
- ZX0003ZXQ Betley, Jan et al. “Desalineación emergente: Estrecho ajuste de las cosas puede producir LLMs ampliamente desalineado.” arXiv:2502.17424, 2025. <https://arxiv.org/abs/2502.17424>
- Brang, [[BRANG-2025]], Michael, Franziska Greinert, Malte S. Ubben, Helena Franke y Philipp Bitzenbauer. “Terminología cuántica en pseudociencia: una revisión y análisis del uso de conceptos de física cuántica en medicina alternativa.” *EPJ Quantum Technology* 12, 96, 2025. BRANG-20259
- ZX0002ZXQ Buskell, Andrew. “¿Qué son los atractivos culturales?” *Biología y filosofía* 32, 2017, pp. 377–394. ZXQ00000ZXQ6
- C@0001ZXQ Cartwright, Nancy. *Cómo se encuentran las leyes de la física*. Oxford University Press, 1983.
- [CLAIDIERE-SPERBER-2007] Claidière, Nicolas y Dan Sperber. “El papel de la atracción en la evolución cultural.” *Journal of Cognition and Culture* 7, nos. 1-2, 2007, pp. 89–111.
- [[DAMASIO-1994]] Damasio, Antonio R. *Error de Descartes: Emoción, Razón y el cerebro humano*. Putnam, 1994.
- [[DASTON-GALISON-2007]] Daston, Lorraine, y Peter Galison. *Objetividad*. Libros de zona, 2007.
- [DAWKINS-1976] Dawkins, Richard. *El gen egoísta*. Oxford University Press, 1976.

- [DEVLIN-2019] Devlin, Jacob, Ming-Wei Chang, Kenton Lee y Kristina Toutanova. “BERT: Pre-entrenamiento de transformadores bidireccionales profundos para la comprensión del lenguaje.” Actas de NAACL-HLT 2019. ZXQ00000ZXQ
- [ETHAYARAJH-2019] Ethayarajh, Kavin. “¿Qué tan contextuales son las representaciones contextuales de la palabra? Comparando la geometría de las incrustaciones de BERT, ELMo y GPT-2.” Actas de EMNLP-IJCNLP 2019, pp. 55–65. ZXQ00000ZXQ
- ZX0003ZXQ Unión Europea. Reglamento (UE) 2024/1689 Por el que se establecen normas armonizadas sobre Inteligencia Artificial. Diario Oficial de la Unión Europea, 2024. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>
- [[FLECK-1935]] Fleck, Ludwik. *Genesis and Development of a Scientific Fact*. University of Chicago Press, 1979; edición original, 1935.
- [[FOUCAULT-1966]] Foucault, Michel. *La Orden de las Cosas: Una Arqueología de las Ciencias Humanas*. Pantheon Books, 1970; edición original, 1966.
- C. [[GALISON-2003]] Galison, Peter. *Einstein’s Clocks, Poincaré’s Maps: Empires of Time*. W. W. Norton, 2003.
- [[GIERE-2006]] Giere, Ronald N. *Perspectivismo Científico*. University of Chicago Press, 2006.
- [GOODHART-1975] Goodhart, Charles A. E. “Problemas de la gestión monetaria: la experiencia del Reino Unido.” En *Papers in Monetary Economics*, vol. 1. Reserve Bank of Australia, 1975.
- [GUAN-2024] Guan, Melody Y. et al. “Alineación deliberativa: el razonamiento permite modelos de lenguaje más seguros.” arXiv: 2412.16339, 2024. ZXQ00000ZXQ339
- [[HACKING-1992]] Hacking, Ian. “Estilo para historiadores y filósofos.” *Estudios en historia y filosofía de la ciencia Parte A* 23, no. 1, 1992, pp. 1–20.
- ZX002ZXQ Hendel, Roece, Mor Geva y Amir Globerson. “El aprendizaje en contexto crea vectores de tareas”. Hallazgos de EMNLP 2023, pp. 9318–9333. <https://aclanthology.org/2023.findings-emnlp.624/>
- [KING-KITCHENER-1994] King, Patricia M., y Karen Strohm Kitchener. *Desarrollo de la sentencia reflexiva*. Jossey-Bass, 1994.
- ZX0001ZXQ King, Patricia M., y Karen Strohm Kitchener. “Juicio Reflectivo: Teoría e Investigación sobre el Desarrollo de Suposiciones Epistémicas a través de la Edad Adulta.” *Psicólogo Educativo* 39, no. 1, 2004, pp. 5-18.
- [[KNORR-CETINA-1999]] Knorr Cetina, Karin. *Culturas epistémicas: cómo las ciencias hacen el conocimiento*. Harvard University Press, 1999.
- [KUHN-1962] Kuhn, Thomas S. *La estructura de las revoluciones científicas*. University of Chicago Press, 1962.

- [LI-2022] Li, Kenneth et al. “Representaciones mundiales emergentes: Explorando un modelo de secuencia entrenado en una tarea sintética.” arXiv:2210.13382, 2022. <https://arxiv.org/abs/2210.13382>
- [LIGHTMAN-2023] Lightman, Hunter et al. “Let’s Verify Step by Step.” arXiv:2305.20050, 2023. <https://arxiv.org/abs/2305.20050>
- CXQ0001ZXQ Longino, Helen E. Ciencia como conocimiento social: valores y objetividad en la investigación científica. Princeton University Press, 1990.
- ZX0001ZXQ Mitchell, Sandra D. Verdades sencillas: ciencia, complejidad y política. University of Chicago Press, 2009.
- [NIST-2023] Instituto Nacional de Estándares y Tecnología. Inteligencia Artificial Marco de Gestión de Riesgos (AI RMF 1.0). NIST AI 100-1, 2023. <https://doi.org/10.6028/NIST.AI.100-1>
- ZX002ZXQ Ouyang, Long et al. “Formación de modelos de lenguaje para seguir las instrucciones con retroalimentación humana.” Avances en los sistemas de procesamiento de información neuronal 35, 2022. <https://arxiv.org/abs/2203.02155>
- [PAN-2023] Pan, Jane, Tianyu Gao, Howard Chen y Danqi Chen. “What In-Context Learning ‘Learns’ In-Context: Disentangling Task Recognition and Task Learning.” Hallazgos de ACL 2023, pp. 8298–8319. <https://aclanthology.org/2023.findings-acl.527/>
- C.[PENNINGTON-2014] Pennington, Jeffrey, Richard Socher y Christopher D. Manning. “GloVe: Global Vectors for Word Representation.” Proceedings of EMNLP 2014, pp. 1532–1543. ZXQ00000ZXQ
- [SHARMA-2023] Sharma, Mrinank et al. “Hacia la comprensión de la adulación en modelos de lenguaje.” arXiv:2310.13548, 2023. <https://arxiv.org/abs/2310.13548>
- [SIMON-1955] Simon, Herbert A. “A Behavioral Model of Rational Choice.” Quarterly Journal of Economics 69, no. 1, 1955, pp. 99–118.
- CXQ0001ZXQ Sperber, Dan. Explicando La Cultura: Un Enfoque Naturalista. Blackwell, 1996.
- ZX0002ZXQ Vaswani, Ashish et al. “La atención es todo lo que necesitas.” Avances en los sistemas de procesamiento de información neuronal 30, 2017. <https://arxiv.org/abs/1706.03762>
- [WANG-2025] Wang, Miles et al. “Hacia la comprensión y prevención de la generalización de la desalineación.” OpenAI, 2025. <https://openai.com/index/emergent-misalignment/>
- [[WEBER-1922]] Weber, Max. Economía y Sociedad. University of California Press, 1978; edición original, 1922.
- ZX0001ZXQ Whitworth, Michael H. Einstein’s Wake: Relativity, Metaphor, and Modernist Literature. Oxford University Press, 2001.