

STOŻKI ZNACZENIA

Metaracjonalność, Outfinitizm i dostrojenie w epoce inteligencji
generatywnej



*Tom towarzyszący Outfinitism:
Metaracjonalność i granice każdej ramy*

STOŻKI ZNACZENIA

Metaracjonalność, Outfinitizm i dostrojenie w epoce
inteligencji generatywnej

Tom towarzyszący Outfinitizm: Metaracjonalność i granice każdej ramy

2026

*„Nigdy nie widzimy świata bez filtra. Mądrość zaczyna się
wtedy, gdy widzimy także filtr.”*

Prawa autorskie © [2026] Axiologic Research

Wszelkie prawa zastrzeżone.

Prawa wydawnicze KDP należą do Outfinity SRL (Iași, Rumunia).

Dostępne bezpłatnie na stronie Axiologic (www.axiologic.net).

Nota autora

Tęstwo zostało stworzone pod parasolem Axiologic Research w ramach dwóch połączonych ze sobą programów badawczych, z których jeden dedykowany Sztuczna Inteligencja, a drugi Outfinitizm, oba prowadzone przez Sînică Alboae. Aby poznać szczegóły, w jaki sposób te dwa programy krzyżują się i budują na sobie, zapraszamy czytelników do odwiedzenia strony Outfinity Venture Studio pod adresem www.outfinity.ch.

Podczas ZXQ00000ZXQ stosowania modeli językowych, aby pomóc w generowaniu tekstu, podstawowa filozofia, struktura tematyczna i podejście analityczne wywodzą się wyłącznie z dziesięcioleci dedykowanych przez autorkę badań zjawisk społecznych, technologii społecznych i autentycznych twardych technologii wynikających z różnych europejskich i samofinansowanych projektów badawczych. ostatnio, w ramach projektu badawczego Achillesa, głęboko badaliśmy literaturę generowaną przez AI i jej zautomatyzowaną weryfikację przy użyciu neuro-symbolicznych podejść; wszystkie bezpłatne książki udostępniane publicznie są częścią pakietu prac, których używamy do testowania naszych najnowszych technologii.

Nota o tym tomie

-Ten wolumen kontynuuje i uzupełnia Outfinitizm: meta-Rationality oraz granice każdej ramki. wprowadza się jego centralne terminy wszędzie tam, gdzie wymaga tego narracja, dzięki czemu tekst może być odczytywany niezależnie, podczas gdy ich znaczenie pozostaje związane z projektem filozoficznym opracowanym we wcześniejszym tomie.

Metaracjonalność odnosi się tutaj do praktyki rygorystycznego rozumowania, a jednocześnie bada ramę, cel i dystrybucję autorytetu, które umożliwiają rozumowanie. Outfinitizm traktuje rzeczywiste granice modeli, dowodów, obliczeń, instytucji i organów jako granice, które muszą zostać uznane, ocenione i, w miarę możliwości, przeforsowane przez skończone i możliwe do zweryfikowania próby. żaden z terminów nie jest przedstawiony jako już ugruntowana dyscyplina lub jako uniwersalny etap rozwoju psychologicznego.

Wyrażenie „wyrównanie jako stan świadomości” jest używane tylko jako robocza metafora. książka nie przypisuje modelom językowym fenomenalnego doświadczenia, trwałego ja lub autorytetu moralnego; omawia funkcjonalny stan orientacji, możliwy do obserwowania w sposób, w jaki system wybiera trafność, radzi sobie z niepewnością i porządkuje wartości w kontekście.

Jako instrumenty badawcze wykorzystano systemy sztucznej inteligencji jako narzędzia badawcze do opracowania, krytyki i przeformułowania. spójność tekstu nie jest dowodem nowości, poprawności, czy walidacji empirycznej. Wybór pracy i odpowiedzialność autorska należą do Șinică Alboaie.

© 2026 Șinică Alboaie. Manuskrypt badawczy.

Spis treści

Drugi tom: od granic każdej ramy do świata wytwarzanego przez ramy.
6

Epoka taniej spójności.....	9
ROZUM W OBRĘBIE RAMY.....	14
Technologia moralna, która czasem zapominała o swojej domenie.....	14
Od precyzji do scjentyzmu, metryk i manipulacji.....	17
IDEE, KTÓRE OPUSZCZAJĄ SWOJĄ DOMENĘ.....	21
Relatywność, teoria kwantowa, ewolucja i cybernetyka.....	21
Memy, atraktory i ekologia rekonstrukcji.....	24
STOŻKI ZNACZENIA I EPOKI, KTÓRE WIDZĄ PRZEZ NIE ŚWIAT.....	27
Geometria jako zdyscyplinowana metafora.....	27
Epistemy, kultury i instytucje: gdy stożek staje się światem.....	29
METARACJONALNOŚĆ: MĄDROŚĆ, KTÓRA WIDZI RAMĘ.....	33
Cel, skala, czas i władza.....	33
Pluralizm bez relatywizmu, decyzja bez wszechwiedzy.....	36
OUTFINITIZM: SZTUKA OTWARTYCH GRANIC.....	39
Rzeczywista skończoność i otwarty horyzont.....	39
Yin i Yang: mobilność ram i dyscyplina granicy.....	42
JAK LLM MÓGŁBY ZREKONSTRUOWAĆ TĘ PERSPEKTYWĘ.....	46
Predykcja tokenów, reprezentacje rozproszone i orientacja kierowana promptem.....	46
Uczenie w kontekście, pragmatyka i kruchość pozornego rozumienia..	49
EPISTEMOLOGIA I AKSJOLOGIA PO NADEJŚCIU OBFITEGO GENEROWANIA.....	53
Od rzadkości tekstu do rzadkości osądu.....	53
Co warto generować i kto decyduje o jego wartości.....	56
DOSTROJENIE JAKO STAN ORIENTACJI.....	60
Metafora stanu świadomości i jej dające się obronić znaczenie.....	60
Filtr metaracjonalny i outfinitistyczny: skromna obietnica, nie ostateczne rozwiązanie.....	63
PUŁAPKI TEZY.....	67
Gdy płodna metafora zaczyna wynajdywać rzeczywistość.....	67
Gdy mądrość staje się techniką władzy.....	70
FILOZOFIE JAKO PRZECIWWAGI.....	73
Cykl korekty i przesady.....	73

Kultura przejść między stożkami w epoce AI.....	75
WIDZIEĆ ŚWIAT I WIDZIEĆ STOŻEK.....	79
BIBLIOGRAFIA.....	82

PRZEDMOWA

Drugi tom: od granic każdej ramy do świata wytwarzanego przez ramy

Ta książka kontynuuje pytanie otwarte w Outfinitizm: meta-Rationality i Limity każdej ramki. Punkt wyjścia był prosty i niewygodny: Reason nigdy nie działa w próżni. Każdy akt wiedzy zaczyna się w ramach, która określa, co istnieje dla analizy, które różnice mają znaczenie, co można zmierzyć, jaki cel ma służyć dochodzeniu lub decyzji i kto otrzymuje władzę, aby przekształcić wniosek w działanie. ZXQQ0001ZXQ to nazwa nadana dojrzałości, która może zbadać tę ramkę bez porzucania rygoru. Outfinitizm było stężeniem tej dojrzałości na granicach: granicach modelu, dowodów, obliczeń, instytucji, ciała i władzy. nie zaproponowała systemu ostatecznego, ale dyscyplinę skończonych prób otwartych na korektę i przedłużenie. [Metaracjonalność]

Niniejszy tom nie powtarza po prostu tego argumentu. przenosi go do środowiska, w którym problem kadrów staje się bardziej widoczny i pilniejszy. Modele generatywne mogą w bardzo krótkim czasie tworzyć teksty, wyjaśnienia, hipotezy, programy, obrazy, scenariusze i uzasadnienia, które do niedawna wymagały znacznych inwestycji ludzkich. nie generują się jednak z neutralnej przestrzeni. Każda odpowiedź jest zorientowana poprzez szkolenie danych, architektury, post-treningu, monitu, kontekstu konwersacyjnego, połączonych narzędzi i kryteriów, według których system został nauczony, aby wydawał się przydatny. Inteligencja generatywna nie wyeliminowała ram. to sprawiło, że są produktywni na niespotykaną dotąd skalę.

To właśnie tam pojawia się centralna metafora książki: stożek znaczenia. Kultura, instytucja, osoba lub modelka nie widzą po prostu zbioru faktów. zbiera się w polu możliwości, przybliża niektóre znaczenia, odpycha innych, rozpoznaje pewne analogie i ignoruje inne relacje. Pacholek nie jest ani światem, ani kompletną teorią umysłu. jest to obraz dla wybiórczego kierunku, przez który wiele elementów staje się spójną perspektywą. Metafora będzie połączona, ostrożnie, z geometrią reprezentacji wektorowych używanych w modelach językowych, ale nie będzie przedstawiona jako dowód, że znaczenie jest dosłownie obiektem geometrycznym. jest to przydatne właśnie dlatego, że zachowuje dwie intuicje naraz: orientacja wytwarza spójność, a w przestrzeni wysokowymiarowej może istnieć wiele częściowo nakładających się orientacji.

Obraz pomaga nam również zrozumieć epoki historyczne. epoka nie jest osobą z jednym przekonaniem, ale może rozwijać dominujący repertuar pytań, metafor, instytucji i kryteriów legitymizacji. Nowoczesność mocno przejrzała stożki racjonalizacji, pomiaru,

prawa ogólnego, postępu i nauki. Te stożki przyniosły niezwykle osiągnięcia. Zmniejszyli arbitralność rangi, zakwestionowali roszczenia, stworzyli technologie zdolne do przekształcenia życia i zaferowali ochronę prawną przed władzą osobistą. Ta książka nie zaczyna się od buntu przeciwko tym osiągnięciom. zaczyna się od problemu ich sukcesu. Siatka, która rozwiązuje główne problemy, nabiera prestiżu, a prestiż rozszerza swoją jurysdykcję. Metoda staje się całkowitą wizją, wskaźnik staje się rzeczywistością, procedura staje się sprawiedliwością, przewidywaniem staje się przyzwolenie, a nauka może zostać przekształcona w scjentyzm właśnie przez tych, którzy pożyczają jej autorytet, nie akceptując dyscypliny jej granic.

Metaracjonalność i outfinitism są wprowadzane tutaj jako dwa uzupełniające się ruchy. Pierwsze otwiera pole: sprawia, że rama jest widoczna, porównuje perspektywy, pyta, co zostało wykluczone i szuka bardziej odpowiedniego sformułowania. Drugi zwraca analizę do stanu skończonego agenta: kończy się czas, dane są częściowe, koszty obliczeń, instytucje mają mandaty, decyzje tworzą straty, a niektóre błędy nie mogą zostać naprawione. W celowo przybliżonej analogii można je postrzegać jako yin i yang współczesnej mądrości. Metaracjonalność zapobiega sztyfikowaniu w ramach jednej mapy; finalizm zapobiega nieograniczonej proliferacji map i przekształca otwartość w odpowiedzialną decyzję. Każde z nich zawiera nasiona drugiego. Porównywanie ramek jest samo w sobie skończone, a limitu czasami nie można zrozumieć bez zmiany ramki, w której została zdefiniowana.

Temat staje się szczególnie ważny, gdy model językowy wydaje się rozumieć filozofię, z którą nie spotkał się w tej formie. doświadczenie, które motywowało tę książkę, było właśnie tego typu. Kilka wskazań na temat metaracjonalność i outfinitism wystarczyło, aby model mógł wytwarzać równoważne sformułowania, analogie i konsekwencje, które zdawały się zachowywać kierunek ludzkiej intencji. nie możemy udowodnić, że model nigdy nie napotkał powiązanych fragmentów. Możemy jednak wyjaśnić, dlaczego nie musiał zapamiętać traktatu z tymi samymi definicjami. Duży model językowy uczy się rozproszonych relacji między kontekstami, słowami, rolami i wzorcami argumentacyjnymi. Monit może tymczasowo ukierunkować tę sekologię semantyczną i sprawić, że rodzina spójnych kontynuacji będzie bardziej prawdopodobna. Poczucie zrozumienia pojawia się, gdy system nie tylko powtarza słowa, ale zachowuje relacje między granicami, pluralizmem, decyzją, weryfikacją i mądrością.

Występ ten jest realny, ale jego status pozostaje otwarty. Może reprezentować semantyczne uogólnienie i funkcjonalne zrozumienie bez fenomenalnego doświadczenia lub jaźni, która posiada perspektywę. Może to być również krucha symulacja, uzależniona od kontekstu. książka nie zadecyduje o metafizycznej kwestii sztucznej świadomości. jednak użycie ryzykownej formuły „wyrównanie jako stan świadomości”, aby oświetlić

pytanie, które ściśle behawioralne słownictwo ma tendencję do uproszczenia: jaka orientacja globalna sprawia, że pewne interpretacje, poziomy pewności i priorytety wartości są bardziej prawdopodobne, zanim zostanie sformułowana odpowiedź?

Zatem książka jest następstwem dwóch linii dociekań, które ostatecznie się spotykają. pierwszy jest kulturowy. Główne idee uciekają od swoich pierwotnych domen i stają się metaforami, memami, instytucjami i sposobami widzenia. względność, ewolucja, teoria kwantowa, cybernetyka, informacja, racjonalność prawna i nauka miały życie kulturalne, które przekraczało ich zawartość techniczną. Niektóre transfery były żywe; inne zachowały prestiż, jednocześnie tracąc ograniczenie. Druga linia jest techniczna. ZXQQ0000ZXQ pokazuje, że znaczenie może być obsługiwane poprzez rozproszone reprezentacje, uwagę kontekstową i prawdopodobieństwa kontynuacji. Mogą szybko przenosić różne stożki i wytwarzać spójne światy tekstowe z wnętrza. Spotkanie dwóch linii zmusza nas do ponownego przemyślenia relacji między epistemologią a aksjologią: nie tylko tego, co można wygenerować i uzasadnić, ale co warto wygenerować, dla kogo, jakim kosztem i pod czyimi uprawnieniami.

Tom ten jest zatem komplementarny do pierwszego. Określił limit jako przedmiot mądrości i zaproponował otwartą skończoność jako obraz możliwych do zweryfikowania prób. ZXQQ0000ZXQ pyta, w jaki sposób powstają orientacje, które sprawiają, że granice są widoczne lub niewidoczne, w jaki sposób krążą w kulturze i jak można je naśladować lub wzmacniać przez sztuczną inteligencję. Pierwsze tomy przyglądały się naczyniu i wodzie; ten patrzy na kierunek światła, przez który widzimy naczynie, wodę, a czasem tylko nasze własne odbicie.

Metafory nie wolno absolutować. Czasami sieć, dziedzina, ekosystem, rola lub praktyka lepiej opisuje to zjawisko. Metaracjonalna książka musi pozwolić na wymianę własnych koncepcji, a osoba z zewnątrz musi przyznać, że oferuje skończoną kompresję większego problemu. jego ambicją nie jest zamknięcie rzeczywistości w nowej doktrynie, ale na nawiązanie widocznych relacji, które mogą poprawić sposób, w jaki ludzie i sztuczne systemy generują, wybierają i działają.

Epoka taniej spójności

Duża część współczesnej kultury była zorganizowana wokół niedoboru produkcji. Książka wymagała czasu, poważnej analizy wymagały szkolenia, wymagał doświadczenia programu pracy i przekonujący obraz wymagały autora lub zespołu zdolnego do jego wykonania. Tabary te nie gwarantowały ani prawdy, ani wartości. li głosy, zachowywali hierarchie i pozwalali instytucjom mylić prestiż z zasługami. jednak koszt produkcji miał efekt filtrowania. zanim pomysł mógł zająć przestrzeń publiczną, ktoś zwykle musiał zainwestować czas, reputację, pieniądze lub siłę roboczą. Generacyjna inteligencja radykalnie obniża ten koszt. Spójność słowna, ilustracja, odmiana, podsumowanie i uzasadnienie stają się dostępne niemal natychmiast.

Zmiana może być podana bez dramatyzacji: koszt ekspresji spada, podczas gdy koszt osądu staje się coraz bardziej widoczny. Wyprodukowanie wiarygodnej wersji nie jest już tak trudne; określenie, która wersja zasługuje na uwagę, weryfikację i wdrożenie, staje się trudniejsze. osoba może zażądać dziesięciu strategii w ciągu minuty, ale czas potrzebny na zrozumienie ich konsekwencji nie przypada w tej samej proporcji. Model może generować bibliografie, kod i argumenty; odniesienia muszą być nadal sprawdzane, programy testowane pod rzeczywistym celem oraz argumenty w porównaniu z dowodami i konsekwencjami.

Jest to kryzys epistemiczny, ponieważ trudno jest oddzielić to, co jest prawdą, prawdopodobne, wywodzące, wymyślone lub po prostu dobrze sformułowane. jest to również kryzys aksjologiczny, ponieważ żadna funkcja czysto techniczna nie może decydować o tym, co zasługuje na produkcję. Sto poprawnych tekstów może pochłonąć uwagę potrzebną do jednego ważnego tekstu. System może zoptymalizować natychmiastową użyteczność użytkownika, jednocześnie degradując wspólne środowisko informacyjne. Może generować spersonalizowane wyjaśnienia, które zwiększają zrozumienie lub spersonalizowane uzasadnienia, które zawierają osobę w istniejących przekonaniach. Obfitość nie uwalnia nas od wartości; zmusza do tego, by uczynić wartość bardziej wyraźną.

Kryzys pojawia się w kulturze już naznaczonej nierozwiązanym napięciem wokół rozumu i nauki. Z jednej strony, nowoczesna nauka, prawo, inżynieria i administracja przyniosły prawdziwą emancypację. krytykowały twierdzenia, zmniejszały zależność od odziedziczego autorytetu i budowały instytucje zdolne do uczenia się. jakakolwiek filozofia, która traktuje ich tylko jako wyrazy jednej kultury między innymi, staje się niepoważna. z drugiej strony, ich sukces wywołał pokusę przekształcenia zestawu metod

w niejawną metafizykę. to, czego nie można zmierzyć, staje się drugorzędne; to, co nie wchodzi do modelu, wydaje się nierealne; to, co można przewidzieć, jest traktowane jako uzasadnione do administrowania; a zwrot „nauka mówi” czasami niesie moralne i polityczne decyzje, których żaden eksperyment nie wykazał.

Niezbędne jest rozróżnienie między nauką a scjentyzmem. Nauka to rodzina praktyk, dzięki którym hipotezy są narażone na dowody, krytykę, replikację, modelowanie i rewizję. Scjentyzm pojawia się, gdy prestiż tych praktyk jest rozszerzony na pytania, że metoda nie może sama zdecydować, lub gdy jedna interpretacja jest przedstawiona jako niezbędny głos „nauki”. Nauka może oszacować skutki polityki; bez przesłanek normatywnych nie może zdecydować, który rozkład kosztów jest sprawiedliwy. Potrafi opisać korelaty dobrobytu; nie może zmniejszyć sensu życia do dostępnych wskaźników. Może pokazać, że niektóre przekonania na temat świata są fałszywe; nie może zastąpić, jedną punktacją, wszystkich stosunków między prawdą, wolnością, godnością, lojalnością, ryzykiem i nadzieją.

Scjentyzm to nie za dużo nauki, ale zbyt mało pamięci o jego granicach. Upraszcza prawdziwą historię wiedzy, w której modele mają domeny, instrumenty mają rezolucje, dane są wybierane, a środowiska naukowe to instytucje ludzkie narażone na zachęty i władzę., jednak krytyka scjentyzmu staje się niebezpieczna, gdy wślizguje się w antynaukę. Perspektywiczny charakter modeli nie sprawia, że wszystkie roszczenia są równe. Obecność wartości w badaniach nie przeradza się w opinię eksperymentalną. Tomowość błędu instytucjonalnego nie przekształca osobistej intuicji w substytut dowodów. Metaracjonalność i sfincjonizm muszą zachować tę równowagę: bronić dyscypliny wiedzy przed arbitralnością, a jednocześnie bronić rzeczywistości przed twierdzeniem, że jedna dyscyplina może ją wyczerpać.

W objętości towarzyszącej racjonalność została opisana jako rozumowanie w ramce, a metaracjonalność jako możliwość rozumowania również o ramce. Sformułowanie zasługuje na pojawienie się blisko początku, ponieważ od niej zależy historia tej książki. ramka to nie tylko opinia. Zawiera on praktyczną ontologię - jakie rzeczy istnieją dla decyzji - wybór trafności, cel, skalę, horyzont czasowy, podział autorytetu i regułę przyjmowania dowodów. Dobrze sformułowany problem to już mały świat. Rozum może działać nienagannie wewnątrz niego i nadal wydawać niewłaściwy wniosek dla większego świata, ponieważ pytanie zostało od początku wykluczone, co się liczyło.

Szpital, który śledzi czas oczekiwania, oddaje napięcie w prostej formie. Wskaźnik jest uzasadniony, ale gdy stanie się celem, może zreorganizować zachowanie: trudne przypadki są przeklasyfikowywane, konsultacje są skracane, a opieka, która nie pasuje do liczby, zaczyna wyglądać jak nieefektywność. System nie porzucił racjonalności; stał się bardziej

rygorystyczny w ramach, która jest zbyt wąska. Wzór [[GOODHART-1975]] Powtarza się wszędzie tam, gdzie proxy jest nagradzane bardziej bezpośrednio niż cel.

Przykłady te nie proszą nas o wyeliminowanie wskaźników. Bez pomiaru dobre intencje mogą ukryć awarię. proszą nas o zachowanie odległości między wskaźnikiem a wartością, którą reprezentuje. ZXQQ0000ZXQ sprawia, że wybór wskaźnika jest widoczny i konstruuje alternatywy. Outfinitizm wymaga, aby twierdzenie pozostało proporcjonalne do rzeczywistego pokrycia pomiaru i zapobiega ukrywaniu się efektów granic. Aksjologia pyta, dlaczego ta wartość została wybrana, kto zyskuje na optymalizacji i kto ponosi to, o czym zapomina wskaźnik.

To właśnie tam „stożki znaczenia” wchodzi na scenę. kiedy patrzymy na sytuację poprzez stożek wydajności, czas, koszt, wydajność i wąskie gardła stają się widoczne. Poprzez stożek prawny pojawiają się kompetencje, reguła, precedens i możliwości odwołania. Poprzez stożek medyczny pojawiają się diagnoza, rokowanie oraz bilans korzyści i ryzyka. przez stożek przeżywanego doświadczenia pojawiają się strach, godność, związek i znaczenie. żaden stożek nie jest bezużyteczny. Problem zaczyna się, gdy jeden z nich zapomina o swojej domenie i staje się jedyną dopuszczoną rzeczywistością. ZXQQ0000ZXQ nie wymaga, aby każda sytuacja była przeglądana przez każdy możliwy stożek. To byłaby kolejna niemożliwość. Wymaga to zdolności do zauważenia, kiedy brakuje ważnego stożka i uzasadnienia, dlaczego konkretna ramka otrzymuje pierwszeństwo tu i teraz.

ZXQQ0000ZXQ dodaje to, o czym może zapomnieć pluralizm: porównywanie perspektyw, kosztów i działań nie może czekać na rozstrzygnięcie każdego sporu. Niektóre decyzje są nieodwracalne; niektóre granice można przezwyciężyć, inne muszą zostać zaakceptowane, a jeszcze inne są tworzone sztucznie, aby chronić instytucję. niejszym pytaniem jest, z jakim limitem mamy do czynienia, dla kogo, w stosunku do jakiego celu, i z jakimi zasobami. otwarte skończone nazwy to kolejność prawdziwych prób, z których każda jest ograniczona, ale zdolna do przygotowania następnego rozszerzenia. [Outfinitizm]

Sztuczna inteligencja koncentruje wszystkie te problemy. LLM to jednocześnie kompresja śladów kulturowych, instrument wytwarzania, uczestnik dialogu i składnik instytucji zdolnych do działania. może poruszać się między stożkami szybciej, niż ludzie mogą wyjaśnić swoje granice. Potrafi mówić legalnie, terapeutycznie, naukowo, religijnie, menedżersko, czy poetycko. -Ta mobilność stwarza wrażenie inteligencji, która widzi powyżej ramek, ale model niekoniecznie jest wśród nich neutralnym arbitrem. Może być zorientowany przez monit, styl rozmówcy i preferencje poznane podczas treningu. może wytworzyć meta-racjonalną krytykę, a w następnej rozmowie równie płynne dogmatyczne uzasadnienie.

Z tego powodu nie można ograniczyć dostosowania do pytania, czy odpowiedź zawiera zabronione roszczenie. System musi interpretować sytuację, wybierać, które informacje mają znaczenie, rozróżnić pytanie rzeczowe od nurtującego, zarządzać konfliktem między przydatnością a ryzykiem oraz decydować, kiedy odmówić, zweryfikować, wstrzymać się lub zaoferować więcej niż jedną ramkę. Współczesne metody dostosowywania już próbują wywołać takie dyspozycje poprzez ludzkie sprzężenie zwrotne, zasady konstytucyjne, rozważania nad polityką i nadzór nad procesem. ZXQQ0004ZXQ [[OUYANG-2022]] [OUYANG-2022] ZXQQ0007ZXQ Phipeta tej książki jest taka, że możemy lepiej zrozumieć, co te metody próbują osiągnąć, jeśli mówimy o stanie orientacji: nie o ustalonej właściwości metafizycznej, ale kontekstowej tendencji do dostrzegania problemów poprzez konkretny zestaw relacji, wartości i limitów.

Zwrot „stan świadomości” będzie używany jako sprawdzian metafory, a nie jako wniosek o ontologii modeli. jest przydatny tylko w zakresie, w jakim można go przełożyć na funkcjonalne zmiany istotności, interpretacji i działania; staje się mylący, gdy myli zachowanie z doświadczeniem lub przenosi odpowiedzialność z instytucji ludzkich na domniemaną osobowość maszyny.

Podążająca za nią historia zaczyna się od współczesnej racjonalności i od pomysłów, które przekroczyły ich pierwotne domeny. Następnie bada stożki kulturowe, memy i epoki epistemiczne. w centrum tomu metaracjonalność i outfinitism są rekonstruowane jako dwa uzupełniające się ruchy, wyjaśnione wystarczająco dla czytelnika, który nie przeczytał wcześniejszej książki. Następuje lusterko techniczne: dlaczego model językowy może wydawać się rozumieć nowo sformułowaną filozofię i co to mówi nam o strukturze i kruchości znaczenia. to zwierciadło wyłania się aksjologiczne problem obfitego pokolenia i wreszcie hipoteza wyrównania jako orientacji.

Książka nie kończy się na wielkiej architekturze. nie ma dowodów na to, że pojedynczy „filtr outfinitist” rozwiązałby wyrównanie. istnieją jednak powody, aby preferować pewne dyspozycje zamiast performatywnej pewności i sztywności: aby rama była wyraźna, oddzielając dowody od wartości, deklarując limit, formułując odpowiednią alternatywę i zachowując ścieżkę korekty. Dyspozycje te mogą informować o edukacji, zarządzaniu i ocenie systemów sztucznej inteligencji bez mylenia z całkowitym rozwiązaniem.

Końcowy test jest stosowany do samej pracy. Stożki mogą stać się apofenią; pluralizm może stać się relatywizmem; krytyka scjentyzmu może stać się antynaukowa; outfinitizm może stać się pretekstem do słabych standardów; zrozumienie hipokryzji może stać się usprawiedliwieniem manipulacji; a metaracjonalność może stać się językiem wyższości dla tych, którzy mają moc definiowania, które perspektywy są dopuszczone. Filozofia, która

studiuje granice, nie jest wiarygodna, jeśli ukrywa swoje własne. to jest warunek, w którym książka powinna być czytana: jako ewentualna przeciwwaga, a nie jako nowy środek świata.

ROZUM W OBRĘBIE RAMY

Technologia moralna, która czasem zapominała o swojej domenie

Krytyka racjonalności jest łatwa, gdy zapomina o świecie, że racjonalność pomogła sprawić, że zniknie. W społeczeństwach zorganizowanych głównie poprzez rangę, tradycję i osobisty autorytet pytanie „dlaczego?” może otrzymać prostą odpowiedź: ponieważ osoba powyżej tak zdecydowała. racjonalizacja prawa, administracji i wiedzy wprowadziła inny wymóg. Twierdzenie musiało zostać poparte, należało sformułować regułę, trzeba było poznać procedurę, a decyzję można było porównać z innymi decyzjami. Żadna instytucja nigdy nie spełniła tych ideałów doskonale, ale ich pojawienie się zmieniło charakter legitymizacji. Władza nie mogła już polegać wyłącznie na pochodzeniu, prestiżu lub objawieniu; musiała stwarzać powody, które można przynajmniej w zasadzie omówić publicznie.

To jedna z wielkich technologii moralnych nowoczesności. Nauka oddziela, niedoskonale, ale zasadniczo, prawdziwość twierdzenia od statusu osoby, która ją tworzy. Prawo ogólne stara się oddzielić traktowanie osoby od kaprysu urzędnika. Inżynieria sprawia, że konsekwencje decyzji obliczają się, zanim pojawią się w upadku struktury. Medycyna porównuje leczenie i zamienia nagromadzone doświadczenie w krytyczne dowody. Demokracja, gdy działa, wymaga, aby powody sprawowania władzy były określone w języku otwartym na wyzwanie. Alternatywą dla tych praktyk nie jest automatycznie organiczna mądrość społeczności. Może to być przesąd, posłuszeństwo, impuls, korupcja lub przemoc pokryta mitologią.

Nie zaczyna się zatem Metaracjonalność od osłabienia. Zaczyna się od ochrony rozsądku przed własnym niekontrolowanym rozszerzeniem. Metoda, która jest doskonała w ramach jednej domeny, może stać się niebezpieczna właśnie dlatego, że jej sukces sprawia, że domena jest niewidoczna. Kiedy kalkulacja rozwiązuje spektakularne problemy, pojawia się pokusa zakładania, że każdy ważny problem musi w swej istocie być problemem kalkulacji. gdy procedura prawna zmniejsza arbitralność, pojawia się pokusa, aby zidentyfikować legalność ze sprawiedliwością. Kiedy eksperyment wytwarza solidną wiedzę, pojawia się pokusa, aby założyć, że to, czego nie można zbadać w ten sam sposób, nie może być poznane lub nie ma znaczenia. Instrument traci przewagę i zaczyna przypominać sam świat.

Zrozumienie ramki pomaga nam zobaczyć, jak powstaje ten błąd, nie zamieniając racjonalności w wroga. Każdy problem sformułowany do analizy zawiera już wybór. Odpowiednie jednostki, zmienne, skala, horyzont czasowy, cel i kryterium sukcesu zostały wybrane. Mapa jest inteligentna dzięki temu, co pomija. Mapa drogowa, która zawierała każdy zapach, rozmowę, kamień, pamięć i możliwość miasta, nie byłaby pełniejszą mapą; stałaby się nieużyteczna. Modele wytwarzają moc poznawczą poprzez kompresję. Cena jest stratą. Dojrzałe pytanie nie brzmi, czy możemy skonstruować reprezentację bez straty, ale czy straty są dopuszczalne dla konkretnego celu i konsekwencji.

Model finansowy może ignorować emocjonalną historię rodziny przy obliczaniu płatności hipotecznej. Pominiecie jest uzasadnione, jeśli pytanie jest ściśle księgowe. staje się niewystarczające, jeśli ten sam model zdecyduje o eksmisji rodziny i twierdzi, że wyczerpał problem moralny i polityczny. Statystyka medyczna może być poprawna dla badanej populacji i nadal nie decydować, jakie ryzyko jest warte zaakceptowania dla pacjenta, który przypisuje różne wagi długowieczności, bólowi i autonomii. Administracja może zastosować tę samą zasadę do wszystkich i nadal powodować niesprawiedliwość, jeśli dane użyte do klasyfikacji osób wyeliminowały odpowiednią różnicę. Konsekwencja jest ważną nieruchomością. nie jest synonimem neutralności.

Herbert Simon uczynił skończoność agenta kluczową dla teorii decyzji. tyjki ludzkie nie szukają optimum w w pełni znanym świecie; upraszczają, używają heurystyki i zatrzymują się na rozwiązaniach, które są wystarczająco dobre w dostępnym czasie i informacjach. [[SIMON-1955]] To nie jest wstydlive odejście od wywiadu. to środowisko, w którym istnieje inteligencja. Więcej mocy obliczeniowej może rozszerzyć wyszukiwanie, ale nie wybiera automatycznie celu. Więcej danych może poprawić precyzję, ale dane są zbierane za pośrednictwem kategorii. Więcej czujników może rejestrować zachowanie, ale mogą mniej widoczne to, czego nie widać w przechwyconej formie. społeczeństwo, które mierzy wszystko, może stać się społeczeństwem, które myli to, co prawdziwe, z tym, co jego infrastruktura wie, jak liczyć.

Digitalizacja zmienia to zamieszanie z nawyku intelektualnego w mechanizm wykonywalny. Założenie słowne można zakwestionować na spotkaniu. Założenie zakodowane w bazie danych, reguła kwalifikowalności lub model klasyfikacji można zastosować miliony razy, zanim ktokolwiek uzna to za wybór. Kategoria administracyjna rozpoczyna się od opisanie i zakończenia poprzez zorganizowanie. ludzie zmieniają swoje zachowanie tak, aby pasowało do kryterium. Instytucje projektują przepływy pracy wokół wskaźnika. gdy pojawi się reklamacja, musi zostać przetłumaczona na język systemu, który stworzył problem. Formalizacja może zaoferować przewidywalność, a jednocześnie zmniejszyć możliwość odwołania.


Tu widzimy, dlaczego racjonalności nie można oddzielić od celu. Logika może nam powiedzieć, czy wniosek wynika z przesłanek. nie może samodzielnie dostarczać obciążonych wartościami lokali. Jeśli celem platformy jest poświęcony czas, matematyka może zoptymalizować zalecenie. nie może zdecydować, że zajęcie uwagi jest uzasadnionym celem lub że gniew jest akceptowalnym kosztem. Jeśli celem szpitala jest zmniejszenie wydatków, analiza może porównać metody leczenia. Bez poglądu na godność nie może zdecydować, które formy opieki są zbędne. Jeśli celem gospodarki jest produkcja zagregowana, modele mogą zidentyfikować polityki, które ją zwiększają. Tylko dzięki swojej formie technicznej nie mogą ogłosić nieodpłatnej pracy opiekuńczej, rozkładu ryzyka lub nieważnej ciągłości ekologicznej.

To nie znaczy, że wartości są odporne na fakty. Cel może być niespójny, niemożliwy lub oparty na fałszywych przekonaniach. Dobrej intencji polityka może przynieść odwrotny skutek. wartość, która odrzuca każdy kontakt z konsekwencjami, staje się hasłem. jednak fakt, że rzeczywistość ogranicza cele, nie oznacza, że wybiera spośród wszystkich możliwych celów. Inżynieria może opisać koszty mostu, który obsługuje ruch i takiego, który chroni okolicę. nie może sama zdecydować, jakie miasto jest warte budowy. nazywanie tego wyboru „politycznym” nie czyni go irracjonalnym; pokazuje, że racjonalność instrumentalna potrzebuje racjonalności celów i osądu na temat wartości.

Wolumin towarzyszący zwany metaracjonalność zdolnością do oddzielania, a następnie rekombinacji tych poziomów: obserwacji, wnioskowania, celu, wyboru i mocy, która przekształca wybór w konsekwencję. rozróżnienie ma znaczenie, ponieważ konflikty publiczne często je łączą., jedna ze stron mówi, że „dane są jasne”, gdy prawdziwy spór dotyczy tego, kto ponosi koszty. ny powołuje się na tożsamość lub wartość, aby chronić faktyczne twierdzenie, które zostało obalone. Sprawozdanie wprowadza decyzję moralną do parametru, a wynik jest później przedstawiony tak, jakby moralność została wyeliminowana poprzez obliczenie. ZXQQ0001ZXQ nie twierdzi, że poziomy można idealnie wyizolować. zwraca uwagę, uwaga wybiera dowody, dowody mogą zmieniać wartości, a instytucje decydują o tym, jakie informacje się pojawiają. Celem jest, aby przejścia były widoczne.

Ta widoczność jest również problemem władzy. osoba lub instytucja, która definiuje ramkę, częściowo decyduje, kto pojawia się w problemie, który cierpienie staje się mierzalny, a który wynik można nazwać sukcesem. im większe konsekwencje i tym słabsza możliwość wyzwania, tym mniej uzasadnione jest, aby rama pozostała dorozumiana. Formuła nie jest bardziej neutralna niż pytanie, dla którego została zbudowana. Model nie jest bardziej obiektywny niż relacja między jego danymi, jego celem i światem, nad którym jest upoważniony do działania. Rygor wewnętrzny może współistnieć z

zewnątrzną niesprawiedliwością, a ta możliwość nie jest przypadkiem peryferyjnym. Określa granicę racjonalności w ramach.



Schem 1. Ramka jako pośrednika między rzeczywistością a decyzją

Od precyzji do scjentyzmu, metryk i manipulacji

Jeśli lokalny sukces ma tendencję do rozszerzania jurysdykcji metody, to nowoczesność musi być zrozumiana nie tylko poprzez jej idee, ale poprzez dynamikę ich przesady. tykliwość pojawiła się jako korekta arbitralności i stworzyła instytucje zdolne do samokorekty. wtedy, w niektórych kontekstach, ideał racjonalizacji został zredukowany do tego, co można było sformalizować, ujednolicić i zoptymalizować. Max Weber zaobserwował moc i ambiwalencję tej transformacji: obliczalność prawa i administracji wspiera przewidywalność, ale może również obejmować życie w ramach „obudowy” procedur, w których znaczenie merytoryczne staje się coraz trudniejsze do sformułowania. ZXQ00001ZXQ Reguła chroni przed kaprysem, ale może też stać się językiem, za pomocą którego instytucjonalne kaprys deklaruje się bezosobowo.

Z podobnym napięciem boryka się nauka. Obiektywizm nie jest czystym widokiem bez obserwatora. Jest to historyczna rodzina praktyk, które zmniejszają zależność od preferencji pojedynczego obserwatora: skalibrowane instrumenty, opis metod, replikacja, krytyka, statystyki, archiwa i społeczności, które mogą zweryfikować. moc nauki pochodzi z [[DASTON-GALISON-2007]] ZXQ00003ZXQ właśnie z ujawnienia hipotezy na rzeczywistość, która może odmówić współpracy z pragnieniem badacza. k wynik naukowy nie wchodzi do społeczeństwa bez interpretacji. Średni efekt musi być związany z osobą; model musi być ekstrapolowany; jedno ryzyko musi być porównywane z drugim; a decyzja musi obejmować koszty, których eksperyment nie zmierzył.

Scjentyzm pojawia się, gdy ta mediacja zostaje zapomniana. nie jest to ani silny szacunek dla dowodów, ani ambicja wyjaśnienia. jest to rozszerzenie prestiżu naukowego w całej granicy między opisem a wartością, między modelem a rzeczywistością, między

korelacją a upoważnieniem do interwencji. Propozycja „nauka wykazała, że X wytwarza Y w pewnych warunkach” może być solidna. Propozycja „dlatego społeczeństwo musi wybrać Z” zawiera dodatkowe przesłanki dotyczące priorytetów, praw, podziału kosztów i akceptowalnej niepewności. czasami te przesłanki są uzasadnione. Problem zaczyna się, gdy są ukryte w cieniu białego płaszcza lub wykresu.

Nauka	Scjonizm
Swoje roszczenia wiąże z metodami, domenami i możliwością korekty.	Przekształca prestiż metody w ogólną władzę nad znaczeniem i wartością.
Wyróżnia dane, model, interpretację i decyzję.	Kompresuje te poziomy do formuły „nauka mówi”.
Traktuje limity jako część wyniku.	Traktuje granice jako szczegóły, które osłabiają przekaz.
Może współpracować z etyką, prawem i doświadczeniem.	Traktuje je jako hałas, jeśli nie można ich zredukować do tej samej metryki.

Rozróżnienie to nie może być używane jako broń przeciwko niewygodnym wnioskom. jakiegokolwiek wynik, który jest sprzeczny z preferowanym przekonaniem, łatwo nazwać „scjonalizmem”. Krytyka staje się dojrzała tylko wtedy, gdy zachowuje epistemiczne hierarchie. Dobrze przeprowadzone badanie nie jest równe odosobnionemu świadectwu, a konsensus zbudowany za pomocą wielu metod nie jest tylko zbiorową opinią. Metaracjonalność nie mówi, że wszystkie stożki mają jednakową moc. Mówi, że ich władza musi być związana z pytaniem i z ich domeną walidacji. Outfinitizm nie obniża standardów. Wymaga, aby siła wniosku była proporcjonalna do tego, co faktycznie zostało zweryfikowane.

Metryki sprawiają, że problem jest widoczny, ponieważ zamieniają wartości w obiekty administracyjne. Dobry wskaźnik kompresuje złożoną rzeczywistość w użyteczny sygnał. liczba infekcji, czas reakcji, wskaźnik ukończenia studiów lub zużycie energii mogą ujawnić awarie, które ukrywa intencja. Ale gdy nagroda zostanie dołączona do wskaźnika, ludzie uczą się optymalizować liczbę. krotność sformułowana ta trudność w kontekście polityki pieniężnej, a obserwacja stała się nieformalnym prawem instytucji: gdy środek staje się celem, jego stosunek do wartości mierzonej ulega degradacji. [[GOODHART-1975]]

Usługa wsparcia, która nagradza liczbę biletów zamkniętych, może zniechęcić do rozwiązywania trudnych spraw. Program bezpieczeństwa oceniany na podstawie niskiej liczby zgłoszonych incydentów może nauczyć organizację, aby nie zgłaszała. Zespół

badawczy mierzony rezultatami może pomnożyć dokumenty i skrócić czas dostępny na dochodzenie, który uczyniłby je cennymi. każdy system staje się bardziej wydajny w ramach reprezentacji. że ta skuteczność zwiększa stratę między proxy a celem.

Tutaj hipokryzja nabiera funkcji adaptacyjnej. Instytucje deklarują ideały, które są prostsze i wyższe niż mogą realizować. „Każdy jest równy przed prawem”, „zasługa decyduje”, „nauka dąży tylko do prawdy”, „bezpieczeństwo jest naszym priorytetem” lub „użytkownik jest w centrum” to uciski normatywne. Zapewniają kierunek i umożliwiają krytykę. Prawdziwe życie zawiera niewystarczające zasoby, niezgodne role, zainteresowania, załączniki, wyjątki i kompromisy. Gdy nie można uznać odległości między ideałem a praktyką, organizacja uczy się zachowywać język ideału i przenosić adaptację do stref nieprzejrzystych. Hipokryzja staje się smarem systemu, który wymaga niemożliwej czystości.

Rozpoznanie tej funkcji nie jest usprawiedliwieniem moralnym. Niektóre rozbieżności są nieuniknionymi kompromisami; inne są wyzyskiem. Od różnicy zależy od władzy, od tego, kto korzysta, od kosztów uzewnętrznionych i od możliwości korekty. Sędzia może potrzebować swobody uznania, aby zastosować ogólną zasadę do konkretnego przypadku. Urzędnik, który używa tej samej dyskrekcji dla przysług, uszkadza funkcję. Dana osoba może wyrażać grzeczność bez ujawnienia każdej wewnętrznej reakcji; przywódca, który używa języka opieki, aby ukryć systematyczne praktyki wydobywcze praktyki wydobywcze. Metaracjonalność stara się widzieć zarówno ideał, jak i funkcję adaptacyjną. Outfinitizm pyta, który ideał można wdrożyć w rzeczywistych warunkach, jakie przejście jest możliwe, a który koszt nie może być już uzasadniony skończonością.

Ten problem ma znaczenie, ponieważ uproszczone ideały mogą wytwarzać właśnie takie zachowanie, jakie potępiają. Kultura, która wymaga doskonałej spójności moralnej, uczy ludzi ukrywać sprzeczności. organizacja, która twierdzi, że każda decyzja jest zgodna z procedurą, tworzy procedury ceremonialne i niewidoczne nieformalne negocjacje. instytucja naukowa, która opisuje badania jako proces czysto bezinteresowny, może stać się mniej zdolna do dyskusji na temat zachęt, prestiżu i konkurencji, które je kształtują. We wszystkich tych przypadkach język absolutny nie eliminuje adaptacji; utrudnia adaptację do obserwacji.

Racjonalność może również stać się narzędziem manipulacji bez formalnego naruszania logiki. Aktor może wybrać wygodne przesłanki, zażądać od przeciwnika poziomu dowodów niewymaganych od własnych twierdzeń i asymetrycznie używać niepewności. Instytucja może zlecić analizy do czasu opóźnienia, co stanowi dla niej odsetki. Raport może ograniczyć pytanie tak, aby pożądanе rozwiązanie wydawało się nieuniknione. forma argumentu pozostaje racjonalna, ale jego orientacja jest strategiczna.

manipulacyjna racjonalność nie zawsze kłamie; może wybierać prawdy, które prowadzą rozmówcę do z góry ustalonego wniosku.

I sprawia, że ta moc jest tańsza. Model może szybko generować uzasadnienia dostosowane do słownictwa każdej grupy odbiorców, wytwarzać ilości argumentów, które przekraczają zdolność reagowania i naśladować równowagę bez zmiany celu instytucji, która z niego korzysta. Firma może zaoferować spersonalizowane wyjaśnienie zautomatyzowanej decyzji, ale wyjaśnienie może być tylko wiarygodną historią post hoc. System może wymieniać ryzyka i kontynuować optymalizację tej samej metryki. Może symulować empatię, podczas gdy proces nie oferuje prawdziwej ścieżki atrakcyjności. Spójność słowna staje się dekoracją mocy, która nie zmienia swojej ramy.

Mądrość jest wewnętrzną granicą tej racjonalizacji. nie odrzuca reguły, ale zachowuje związek między regułą a życiem. nie odrzuca pomiaru, ale pamięta, co zostało skompresowane. nie odrzuca nauki, ale oddziela przewidywania od pozwolenia. Nie odrzuca ideału, ale odmawia przekształcenia niemożliwości całkowitej zgodności w aparat wstydu i ukrycia. ZXQQ0000ZXQ zapewnia mobilność potrzebną do zobaczenia innych ramek. Outfinitizm zapewnia dyscyplinę potrzebną do podjęcia decyzji na skończonych warunkach i zadeklarowania tego, co pozostaje poza certyfikacją. razem nie umniejszają rozsądku. przywracają go do statusu niezwykłego instrumentu, który staje się silniejszy, gdy zna swoją krawędź.

IDEE, KTÓRE OPUSZCZAJĄ SWOJĄ DOMENĘ

Relatywność, teoria kwantowa, ewolucja i cybernetyka

Niektóre teorie nabierają drugiego życia po opuszczeniu laboratorium, formuły lub społeczności, która je wytworzyła. Drugie życie nie jest wierną kopią. Kultura bierze obraz, relację, słowo lub napięcie i rekonstruuje go według własnych potrzeb. Teoria fizyczna może stać się metaforą doświadczenia czasu; biologiczne wyjaśnienie może stać się ideologią społeczną; koncepcja inżynierska może stać się językiem dla rodziny i organizacji. Transfer jest prawie nieunikniony. Kultura nie może odizolować swoich głównych instrumentów wiedzy od sposobu wyobrażania sobie świata. Problemem nie jest to, że transfer istnieje, ale jaki jest status.

Ć Względność Einsteina jest uprzywilejowanym przykładem, ponieważ dystans między teorią techniczną a jej życiem kulturowym jest łatwy do zaobserwowania. W fizyce szczególną i ogólną teorię względności są precyzyjnymi teoriami matematycznymi na temat pomiaru, ram odniesienia, czasoprzestrzeni, energii i grawitacji. Nie twierdzą, że każda opinia jest równie aktualna. przeciwnie, szukają praw i niezmienników, które umożliwiają tłumaczenie między opisami wykonanymi z różnych ramek. Współczesna kultura zachowała jednak przede wszystkim fakt, że ma znaczenie obserwator i kadr. Literatura, sztuka i filozofia znalazły w teorii względności obraz odpowiedni do świata, w którym równoczesność społeczna fragmentaryzowała się, rytmy miasta przyspieszały, tradycje wchodziły w kontakt, a pojedyncza perspektywa traciła wiarygodność. [[WHITWORTH-2001]] [WHITWORTH-2001]

) Ten wpływ nie należy oceniać jedynie pytając, czy pisarz rozumie tensory. Kultura nie była zobowiązana do tego, by zostać podręcznikiem do fizyki. Transfer może być uzasadniony jako metafora: ludzkie doświadczenie zależy od pozycji, a dwa opisy mogą się różnić, nie stając się arbitralną rzeczywistością. jednak popularna formuła „wszystko jest względne” często traciła połowę lekcji. wielości perspektywy zachował i zapomniał dyscypliny transformacji wśród nich. Względność naukowa nie eliminuje prawdy; na nowo definiuje warunki, w jakich można porównać opisy. w kategoriach metaracjonalnych żywna lekcja nie polega na tym, że każdy stożek ma swoją odosobnioną prawdę, ale to, że musimy jasno określić ramę, znaleźć relacje tłumaczenia i szukać tego, co pozostaje stabilne w ramach zmiany perspektywy.

Mechanika kwantowa wytworzyła jeszcze bardziej dramatyczną migrację. Słowa takie jak „obserwator”, „niepewność”, „splątanie”, „energia”, „częstotliwość” i „pole” weszły w duchowość, marketing, popularną psychologię i medycynę alternatywną. Istnieją autentyczne filozoficzne pytania dotyczące teorii kwantowej, a rozwój technologii kwantowych pokazuje, jak konkretny jest formalizm. Ale w popularnym dyskursie terminy są często oderwane od matematyki, skali fizycznej, mechanizmu i procedury pomiaru. Prestiż pozostaje, gdy znikają ograniczenia. Terapia nazywana jest „kwantem” bez zidentyfikowania odpowiedniego procesu fizycznego, protokołu testowania lub prognozy, która może się nie udać. [[BRANG-2025]]

Tę operację możemy nazwać semantycznym praniem prestiżu. Słowo utrzymuje autorytet, który zdobył w rygorystycznej dziedzinie, jednocześnie tracąc zobowiązania, które nadały mu znaczenie. Nie każde metaforyczne użycie jest nadużyciem. Wyraźne stwierdzenie, że uwikłanie oferuje poetycki obraz współzależności, może być płodne, pod warunkiem, że nie twierdzi się, że relacja społeczna ma mechanizm kwantowy. Nadużycie zaczyna się, gdy metafora jest przedstawiona jako wyjaśnienie, wyjaśnienie jako mechanizm i mechanizm jako uzasadnienie interwencji. Słowo przecina potajemnie od analogii do przyczynowości.

Darwinizm pokazuje inną formę ucieczki. Naturalny dobór daje biologii potężną strukturę do zrozumienia zmienności, dziedziczenia i adaptacji. przeniesione do analizy ekonomicznej lub instytucjonalnej idea selekcji może wyjaśnić, dlaczego niektóre praktyki przetrwają bez centralnego planowania. Kultury, języki i organizacje można studiować poprzez zróżnicowanie i selektywne naciski. Problemy pojawiają się, gdy opis procesu jest przekształcany w normę. fakt, że cecha przetrwała, nie czyni go moralnie dobrym. fakt, że firma wygrywa w konkursie, nie czyni porządku społecznego, który przyniósł zwycięstwo. „Przetrwanie najsilniejszych” staje się usprawiedliwieniem najsilniejszych tylko poprzez wprowadzenie normatywnej przesłanki, której biologia nie dostarcza.

Błąd ma powtarzającą się strukturę. domena źródłowa opisuje mechanizm. Domena docelowa zmienia mechanizm w obraz tego, co naturalne. „naturalny” jest następnie używany do legitymizacji tego, co należy zaakceptować. Przelew ukrywa ruch przed nim jest do wykonania. ZXQQ000ZXQ sprawia, że ten ruch jest widoczny. ZXQQ0001ZXQ prosi nas o zadeklarowanie granic analogii: które relacje są zachowane, w jakiej skali, i na jakich warunkach korespondencja się załamuje.

Cybernetyka niosła inną rodzinę struktur: sprzężenie zwrotne, samoregulację, kontrolę, komunikację, stabilność i pętle rekurencyjne. ZXQQ0001ZXQ Te koncepcje zapłodniły biologię, psychologię, antropologię, teorię organizacji i terapię rodzinną. transfer był czasem czymś więcej niż metaforą. system biologiczny i techniczny mogą rzeczywiście mieć sformalizowane relacje zwrotne. jednak, gdy język kontroli jest

stosowany w odniesieniu do ludzi, pojawiają się wymiary, które nie istnieją w termostacie: interpretacja, kontestacja, godność, władza, przewidywanie reguły i zdolność do zmiany celu. menedżer, który traktuje organizację jako mechanizm regulacyjny, może zauważyć ważne pętle i przegapić fakt, że jej członkowie są nie tylko składnikami, ale uczestnikami zdolnymi do odrzucenia narzuconego im znaczenia.

„Informacja” i „obliczenia” stały się prawdopodobnie najbardziej ekspansywnymi koncepcjami epoki cyfrowej. Programy są opisywane jako programy, mózg jako procesor, organizm jako system informacyjny, społeczeństwo jako sieć, a wszechświat jako forma obliczeń. Niektóre z tych analogii wspierają precyzyjne modele. Inne to słownictwo orientacji. Sprawiają, że kodowanie, transformacja, stan i algorytm są widoczne, ale mogą ukryć ciało, energię, historię, kontekst i wartość. Powiedzieć, że osoba „przetwarza informacje” może być prawdziwa na jednym poziomie i prawie bezużyteczna w innym. Opis, który jest zbyt ogólny, staje się niemożliwy do obalenia właśnie dlatego, że nie dyskryminuje już zjawisk.

Przykłady te pokazują, że pomysł nie podróżuje jako jeden pakiet. Terminy, relacje, metody, metafory, prestiż lub implikacje normatywne mogą się migrować. czasami struktura jest zachowana, podczas gdy słownictwo się zmienia. innym razem słownictwo jest zachowane i struktura zostaje utracona. Krytyk może mieć rację, że literatura nie przyjęła formalizmu względności, a historyk kultury może mieć rację, że względność zmieniła współczesną wyobraźnię. dyskutują o różnych rodzajach wpływów. Aby ocenić przeniesienie, musimy zapytać, co dokładnie zostało przeniesione i jakie roszczenie jest do niego przypisane w nowej domenie.

Odpowiedzialny transfer	Przelewy obraźliwe
Deklaruje, czy jest to analogia, model czy mechanizm i nie zmienia statusu potajemnie.	Używa dwuznaczności, aby przejść od metafory do przyczynowości.
Państwa, które są zachowane i gdzie korespondencja się załamuje.	Zachowuje tylko słowa lub prestiż domeny źródłowej.
Akceptuje testy i kontrprzykłady proporcjonalne do zastrzeżenia.	Staje się trudniejsze do obalenia w miarę wzrostu roszczenia.
Nie zmienia opisu w normę bez wyraźnych przesłanek aksjologicznych.	Przedstawia to, co wydaje się „naturalne” jako to, co trzeba zaakceptować.

Nie potrzebujemy policji do metafor. Kultura stałaby się jałowa, gdyby każda analogia wymagała mechanistycznej demonstracji. Poezja, filozofia i wynalazek naukowy wykorzystują porównania do otwartych przestrzeni myśli. wymóg jest skromniejszy i ważniejszy: nie używaj wolności metafory, aby pożyczyć autorytet mechanizmu. im większe konsekwencje - leczenie, polityka publiczna, ocena osoby - tym silniejszy musi być pomost między domenami.

Memy, atraktory i ekologia rekonstrukcji

Metafora mema oferowała niezapomniany obraz kulturalnego życia idei. Treści konkurowałyby o uwagę, pamięć i transmisję, prawie jak replikatory w ekosystemie. Obraz [[DAWKINS-1976]] Jest płodny, ponieważ przenosi pytanie z intencji autora na dynamikę populacji. Idea może przetrwać nie dlatego, że jest prawdziwa, ale dlatego, że jest łatwa do zapamiętania, potwierdza tożsamość, wytwarza emocje, korzysta z prestiżu lub przywiązuje się do instytucji. Może łączyć się z innymi pomysłami w zespół, którego części chronią się nawzajem. Może zaoferować uzasadnienia zachowań, które zabezpieczają jej własną reprodukcję.

Przyjmowanie metafory dosłownie stwarza jednak problemy. Idee nie są organizmami z metabolizmem i własnymi intencjami. ludzie nie kopiuje identycznych reprezentacji. Rekonstruują to, co słyszą według pamięci, zainteresowania, języka i oczekiwań. Badania nad atraktorami kulturowymi pokazują, że stabilność formy może powstać nie tylko poprzez wierną replikację, ale poprzez zbieżne przemiany. Różne warianty są rekonstruowane w podobnych kierunkach, ponieważ pewne formy są łatwiejsze do zrozumienia, zapamiętania lub legitymizacji w danym środowisku. [[SPERBER-1996]] [SPERBER-1996] [[BUSKELL-2017]]

Względność ta wyjaśnia, dlaczego wyrafinowane teorie wchodzi w kulturę w zwartych formach. Względność staje się „prawdą zależy od perspektywy”. Ewolucja staje się „silną wygraną”. Teoria kwantowa staje się „obserwatorem tworzy rzeczywistość”. Cybernetyka staje się „wszystkim jest informacja zwrotna”. Neuronauka staje się „mózg nas zmusza”. Te formuły są atraktorami. Kompresują napięcie w zdanie, które jest łatwe w użyciu. nie zawsze są całkowicie fałszywe; to właśnie mieszanka prawdy, przesady i użyteczności sprawia, że są odporne.

Możemy mówić o memetycznej ekologii, jeśli zachowamy metaforyczny charakter tego terminu. Pomysły aktywują się i hamują. przekonanie o zasługach może wspierać przekonanie o rynkach; przekonanie o tożsamości może decydować, które źródła są godne zaufania; opowieść o postępie może sprawić, że obecne koszty będą wydawać się nieuniknionymi inwestycjami. Instytucje zapewniają siedliska. Uniwersytet wybiera

poprzez programy nauczania, czasopisma i reputację. Platforma wybiera poprzez rekomendacje i nagrody uwagi. Stan wybiera poprzez kategorie prawne. Firma wybiera poprzez wskaźniki i promocje. Pomysł osadzony w oprogramowaniu lub procedurze nie zależy już od wyraźnego przekonania każdego uczestnika. nadal organizuje zachowania poprzez infrastrukturę.

Z tego powodu „stożek znaczenia” nie powinien znajdować się wyłącznie wewnątrz głowy. Między słownictwem, nawykiem, instrumentem, rolą i instytucją rozprawdza się perspektywa. Racjonalność prawna żyje w umyśle prawnika, ale także w kodeksach, archiwach, precedensach, terminach i możliwościach odwoławczych. Nauka żyje w badaczu, ale także w instrumentach, protokołach, bazach danych, wzajemnej ocenie i standardach raportowania. Kapitalizm lub nacjonalizm to nie tylko doktryny, które ludzie akceptują; są to praktyki, prawa, granice, kontrakty, symbole i bodźce. Stożek kulturowy staje się stabilny, gdy środowisko ułatwia noszenie nawet dla tych, którzy nie znają jego teorii.

To pomaga nam zrozumieć epoki historyczne bez ich reifikacji. epoka nie ma jednego umysłu. Dominujące stożki współlistnieją z resztkami tradycji, subkultur i kontr-ram. Badacz może uznać za naturalne poszukiwanie mechanizmu, administratora wskaźnika, prawnika ds. kompetencji i działacza na rzecz podziału władzy. Każde pytanie może ujawnić coś prawdziwego. Ekologia staje się zubożona, gdy jeden gatunek pojęciowy zajmuje każdą niszę.

Wirusowość jakiejś idei nie jest dowodem prawdy. to dowód na to, że pomysł pasuje do środowiska transmisji. Niektóre prawdziwe idee są trudne do przekazania; niektóre fałszywe idee zaspokajają potężne potrzeby psychologiczne i instytucjonalne. ale równie mylone byłoby traktowanie wirusowości jako powierzchownej. Idea, która reorganizuje instytucje, wytwarza rzeczywistość społeczną, nawet jeśli jej opis świata jest fałszywy. pseudonaukowa teoria rasowa może być empirycznie obalona i nadal strukturyzować prawa, rozkłady zasobów i cierpienie. Efekt kulturowy i epistemiczna prawda to dwie różne osie.

Ekologia idei nie eliminuje odpowiedzialności. Język memów może sugerować, że nikt niczego nie decyduje, ponieważ reprezentacje po prostu „rozprzestrzeniają się”. W rzeczywistości aktorzy z mocą wybierają to, co jest wzmacniane, finansowane, nauczane i wdrażane. Platformy wybierają funkcje rekomendacji. instytucje wybierają standardy. Przywódcy wybierają metafory. osoby wybierają, kiedy dokonać retransmisji, a kiedy poprawić. Dynamiczna dynamika systemowa wyjaśnia, dlaczego wyniki przekraczają indywidualne intencje, ale nie zwalniają aktorów, którzy mogą interweniować.


Ta sama zasada wyjaśnia hipokryzję, nie rozgrzeszając jej. Kultura ideałów, której nie można zrealizować, wybiera zachowanie do pokazania, ale pozycja moralna zależy od

władzy. łąd, który symuluje entuzjazm w środowisku przymusu i lider, który symuluje przejrzystość, aby zachować kontrolę, reagują na różne naciski i wytwarzają różne koszty. Ekologia opisuje mechanizm; aksjologia zachowuje asymetrię.

Model językowy wchodzi w tę ekologię jako maszynę rekonstrukcji. został przeszkolony na śladach wielu stożków i może produkować nowe warianty, które pasują do przyciągaczy kulturowych. może sprawić, że pomysł będzie bardziej dostępny, przetłumaczy między technicznym a zwykłym słownictwem i odkryje płodne analogie. może również przyspieszyć degradację semantyczną. Prostą i przekonującą formułę można wyprodukować w milionach wariantów, dostosowanych do każdej publiczności i oddzielonych od źródła, które by je ograniczyło. Ze sztucznej inteligencji nie wymyśla ekologii memetycznej, ale obniża koszty reprodukcji i mutacji.

Następuje wymóg dla kultury generatywnej: umiejętność czytania i pisania nie oznacza już jedynie oceny propozycji. Musimy zauważyć, który stożek niesie, jaki prestiż pożyczca, jaką zmianę posiada i która instytucja ją wzmacnia. Pomysł może być prawdziwy i wykorzystywany manipulacyjnie. może być fałszywa i symbolicznie płodna. Może to być dobra metafora i słaby mechanizm. Metaracjonalność oddziela te funkcje. ZXQQ0001ZXQ wymaga siły użycia, aby nie przekraczać mostu walidacji. Aksjologia pyta, co dzieje się z ludźmi po tym, jak idea staje się infrastrukturą.

Struktura i granice mogą zostać zachowane albo utracone po drodze



Schemat 2. Życie kulturalne teorii

STOŻKI ZNACZENIA I EPOKI, KTÓRE WIDZĄ PRZEZ NIE ŚWIAT

Geometria jako zdyscyplinowana metafora

Z skromnej obserwacji technicznej wyłoniła się metafora stożka. W wielu systemach reprezentacji semantycznej słowa, zdania lub dokumenty są powiązane z wektorami w przestrzeni wysokowymiarowej. trójne podobieństwo porównuje kierunek tych wektorów, a nie tylko ich surową odległość. jeśli wybierzemy kierunek odniesienia i weźmiemy pod uwagę reprezentacje blisko, gdy ich kąt do niego pozostaje poniżej progu, powstały region ma postać stożkową. punkty w nim nie są identyczne, ale są na tyle zorientowane, aby można je było traktować jako sąsiadów w stosunku do tego odniesienia.

Ta właściwość nie dowodzi, że znaczenie jest dosłownie stożkiem lub że wewnątrz LLM znajdują się czyste obiekty geometryczne odpowiadające filozofiom. Kontekstowe reprezentacje zmieniają się z jednej warstwy na drugą, to samo słowo zajmuje różne pozycje w różnych kontekstach, a geometria globalna może być anizotropowa i trudna do zinterpretowania. [[ETHAYARAJH-2019]] W dużym modelu zachowanie jest wytwarzane przez kolejne przemiany, uwagę, rozproszone aktywacje i warunkowe prawdopodobieństwa. Stożek jest kompresją skonstruowaną przez obserwatora, a nie fotografią wewnętrznego mechanizmu.

Mimo to obraz zachowuje coś wartościowego. Orientacja semantyczna nie wymaga wyczerpującej definicji, aby wytworzyć spójne konsekwencje. Jeśli monit zbierze pomysły na temat skończoności, wielości kadrów, ostrożności epistemicznej, weryfikacji, mądrości i możliwości rozszerzenia granic, model może być kontynuowany w kierunku, który je łączy. Wiele różnych zdań wchodzi w to samo pole zgodności. niektórzy będą kładli nacisk na filozofię nauki, inni psychologię, matematykę, zarządzanie lub AI. Stożek nie określa jednego zdania; sprawia, że rodzina kontynuacji jest bardziej prawdopodobna.

Idea dotyczy także ludzi. osoba patrząca przez sieć ekonomiczną zauważa zachęty, koszty, niedobór i wymianę. Osoba zorientowana na prawo zauważa kompetencje, zasady, dowody i procedurę. orientacja terapeutyczna sprawia, że cierpienie, związki i psychologiczna obrona są widoczne. Orientacja inżynierska wyszukuje funkcję, mechanizm, niezawodność i awarię. orientacja religijna może wybrać znaczenie, grzech, nadzieję, rytuał i transcendencję. Te stożki to nie tylko opinie na temat tej samej listy

faktów. pomagają skonstruować listę. Sprawiają, że niektóre byty pojawiają się jako istotne obiekty, a inne pozostawiają w tle.

W konflikcie pracowniczym pachołek prawny może zapytać, czy procedura była przestrzegana. Ekonomiczny stożek może zapytać, jaki koszt tworzy decyzja i jaki sygnał wysyła. Psychologiczny stożek może zauważyć strach i status. Szyszka moralna może zapytać, kto jest traktowany jako środek. Stożek organizacyjny może widzieć wpływ na zaufanie. Żadne z tych pytań nie jest automatycznie wystarczające. Decyzja może być legalna i destrukcyjna, skuteczna i niesprawiedliwa, empatyczna i niemożliwa do wykonania. ZXQQ0000ZXQ zaczyna się, gdy możemy wyróżnić te orientacje i omówić, dlaczego należy otrzymać pierwszeństwo w przypadku bez deklarowania innych nierealnych.


Kruchość stożka pochodzi z wielu kierunków odniesienia. w przestrzeni wysokowymiarowej ta sama reprezentacja może znajdować się blisko kilku kierunków. Słowo takie jak „wolność” może wejść w stożek prawny, moralny, ekonomiczny, psychologiczny, narodowy lub duchowy. Kontekst decyduje o tym, które dziedziny stają się aktywne. Niewielka zmiana roli może zreorganizować znaczenie: „wolność” w orzeczeniu sądowym nie funkcjonuje tak, jak w reklamie lub spowiedzi. Ani ludzie, ani modele nie muszą mieć jednej stabilnej orientacji. Bitownik może być rygorystyczny w laboratorium i dogmatyczny w polityce; prawnik może myśleć proceduralnie w pracy i w relacji w domu. Stożki nakładają się na siebie, są aktywowane sytuacyjnie i mogą być sprzeczne z tą samą osobą.

Stożek opisuje zatem tendencję selekcji, a nie ukrytą esencję. czasami sieć, dziedzina, rola, praktyka lub narracja jest lepszym obrazem. Metaracjonalna koncepcja musi pozwolić się zastąpić; jeśli wszystko wyjaśni, straciła moc dyskryminacji.

Z tą ostrożnością stożek oferuje dokładniejszy obraz niż obiektyw pod dwoma względami. Obiektyw sugeruje, że istnieje kompletna scena, którą instrument tylko zniekształca lub doprowadza do skupienia. Stożek sugeruje wybór regionu z szerszej przestrzeni możliwości i relacji. ponadto obiektyw wydaje się być pojedynczym obiektem, podczas gdy stożki mogą być wielorakie, nakładające się i inaczej zorientowane. Kultura może jednocześnie przenosić naukowe stożek dowodów, stożek praw prawnych, ekonomiczną stożek wzrostu i religijny stożek znaczenia. Problemy wynikają nie tylko z błędu każdego z nich, ale także z ukrytej hierarchii wśród nich.

Stożek sugeruje również, że znaczenie ma porowate krawędzie. Niektóre wyrażenia leżą w pobliżu osi i są łatwo rozpoznane jako reprezentatywne. Inne są peryferyjne, gdzie członkostwo zależy od progu i kontekstu. Doktryna zawiera teksty kanoniczne i interpretacje marginalne. Kultura ma centralne praktyki i hybrydy. Model może niezawodnie reagować na typowe przykłady i zachowywać się nieprzewidywalnie w

przypadkach granic. Wyrównanie jest często najtrudniejsze właśnie na krawędzi: kiedy zasady są sprzeczne, intencja jest niejednoznaczna, ryzyko pośrednie, lub kontekst nie przypomina przykładów używanych w treningu.



Schem 3. Kilka stożków w tej samej sytuacji

Metafora staje się więc propozycją piśmiennictwa. Zrozumienie tekstu nie oznacza jedynie parafrazowania jego twierdzeń. to oznacza rozpoznanie, o którą orientację prosi czytelnika, które relacje czyni naturalnym, które alternatywy stają się trudne do myślenia, i jaki autorytet pożyczają. Reklama może nosić stożek indywidualnego wyboru, jednocześnie ukrywając infrastrukturę, która ogranicza opcje. Raport może przenosić stożek pomiaru i sprawić, że subiektywne doświadczenie będzie wyglądać jak hałas. Ideologia może nieść stożek konfliktu i interpretować każdy sprzeciw jako objaw przeciwnika. W epoce ogólnej umiejętność ta staje się jeszcze ważniejsza, ponieważ model może szybko konstruować spójne teksty z dowolnej żądanej orientacji.

Epistemy, kultury i instytucje: gdy stożek staje się światem

Filozofia i historia nauki oferowały kilka pojęć zbliżonych do tego, co nazywamy stożkiem znaczenia. Thomas Kuhn opisał paradygmaty, dzięki którym społeczności naukowe dzielą się przykładowymi problemami, metodami i kryteriami sukcesu. [[KUHN-1962]] Ludwik Fleck mówił o stylach myślowych i kolektywach, które sprawiają, że pewne fakty są możliwe jako przedmioty wiedzy. Ian Hacking pokazał, że style rozumowania dostarczają nie tylko metod, ale także rodzajów propozycji, obiektów i wyjaśnień, które stają się zrozumiałe. Michel Foucault wykorzystał pojęcie episteme do opisu historycznych warunków, które organizują możliwość dyskursu w epoce. ZXQ00008ZXQ Karin Knorr Cetina badała różne kultury epistemiczne, w których nauki konstruują wiedzę poprzez różne praktyki i obiekty. [KUHN-1962]

Tradycje te nie są identyczne i nie powinny być skompresowane do jednego pojęcia. Razem jednak popierają ważną ideę: sposoby poznania to nie tylko zbiórki roszczeń. To praktyki, które określają, co może wydawać się problemem, obiektem, dowodami i wyjaśnieniami. Laboratorium fizyki cząstek, klinika, sala sądowa i archiwum historyczne nie używają tylko różnych danych. Konstruują różne relacje między obserwatorem, instrumentem, podmiotem i walidacją. Żyć wymaganie od nich wszystkich, aby naśladować ten sam model obiektywizmu, może nie powodować jedności, ale utratę przedmiotu.

Epoki historyczne można postrzegać jako ekologie, w których niektóre takie pacywki nabywają dominującą pozycję. Średniowieczna Europa nie była zredukowana do religii, a nowoczesność nie jest redukowalna do nauki., zmiana źródeł legitymizacji jest jednak realna. W porządku teologicznym kwestie o ostatecznym znaczeniu i porządku mogą ustrukturyzować prawo, politykę i naturę. Nowoczesność przesunęła centrum w kierunku obserwacji, obliczeń, jednostki, postępu, rynku, stanu i procedury. W epoce przemysłowej stworzono mechanizm i produkcję ogólnych metafor. Epoka informacji sprawiła, że sieć, kod i optymalizacja są prawie wszechobecne.

Powiedzieć, że epoka „widzi” przez stożek, jest skrótem. Zawiera konflikty, mniejszości i przejścia. Stare siatki nie znikają, gdy pojawiają się nowe. Religia współistnieje z naukowcem, tradycja z indywidualizmem, romantyzm z administracją algorytmiczną. człowiek może zamieszkiwać kilka epok naraz: używać nowoczesnej medycyny, praktykować tradycyjne rytuały, myśleć ekonomicznie w pracy i moralnie w domu. kłatność ta powoduje napięcia i hipokryzję. za deklaruje powszechność prawną, ale zachowuje szczególną lojalność. Świątuje zasługi, ale funkcjonuje poprzez sieci. Powołuje się na indywidualną autonomię, ale optymalizuje zachowanie poprzez infrastrukturę perswazyjną.

Stożki stają się trwałe, gdy są osadzone w instytucjach. Idea zasług zyskuje siłę poprzez egzaminy, życiorysy, rankingi i procedury selekcji. Idea ryzyka staje się rzeczywistością poprzez politykę, wyniki i progi. Idea zdrowia jest zmaterializowana w kodach diagnostycznych, protokołach i refundacji. Idea produktywności jest instalowana w pulpitych nawigacyjnych, celach kwartalnych i oprogramowaniu monitorującym. Uczestnicy nie muszą wierzyć wyraźnie w filozofię systemu. wystarczy, że dostosują się do jego nagród.

W tym procesie proces wyjaśniono, w jaki sposób sieć może stworzyć własne potwierdzenie. Jeśli szkoła zdefiniuje inteligencję, co mierzy test, program nauczania zostanie zreorganizowany, aby podnieść wynik, a wynik będzie później wydawał się jeszcze lepszym opisem inteligencji. jeśli platforma zdefiniuje trafność poprzez zaangażowanie, producenci dostosują się, a angażujące treści będą zajmować więcej

rzeczywistości. Jeśli rynek zdefiniuje wartość poprzez cenę, działania, które są trudne do zainfektowania, otrzymają mniej zasobów, a brak inwestycji okaże się, że udowodnią swoją niższą wartość. -model nie tylko widzi świat, ale bierze udział w jego konfigurowaniu.

-Ta refleksyjność jest szczególnie potężna w dziedzinie społecznej. Planeta nie zmienia swojej orbity, ponieważ odczytała teorię astronoma. osoba może zmienić zachowanie po tym, jak dowiedziała się, jak została sklasyfikowana. Instytucja może wykorzystać regułę, według której jest mierzona. Przewidywanie może stać się samospełniające się lub zawieść, ponieważ zareagowali na nią aktorzy. Granica modelu tkwi wtedy w pętli między reprezentacją a światem, nie tylko w danych początkowych.

To właśnie potrzebujemy ekologii modeli. nie wystarczy zachować wiele perspektyw w tolerancyjnym muzeum. Muszą być w stanie poprawić, przetłumaczyć i ograniczyć się nawzajem. Model ekonomiczny może ujawnić bodźce, które ignoruje dyskurs moralny. Model moralny może ujawnić koszty ukryte przez agregat ekonomiczny. Prawo może tworzyć procedury kontestacji; doświadczenie przeżyte może wykazać, że procedura nie służy już sprawiedliwości. Nauka może korygować rzeczowe przekonania; polityka i etyka muszą decydować, jaki autorytet otrzymuje wynik.

Mnogość nie gwarantuje zdrowia ekologii. Kilka teorii może mieć te same założenia lub zależeć od tej samej infrastruktury. wiele modeli sztucznej inteligencji może mieć podobne dane, architektury i zachęty. Instytucja może zaprosić różne perspektywy tylko po to, by stworzyć pozory konsultacji. różnorodność staje się realna, gdy występują różnice w metodzie, zainteresowaniu, dostępie do władzy i możliwości, że sprzeciw może zmienić decyzję.

Tutaj metaracjonalność nabiera znaczenia politycznego. nie jest tylko zdolność jednostki do „widzenia kilku stron”. Pytanie brzmi, kto ma prawo do definiowania stron, kto może rzucić wyzwanie dominującemu stożkowi i co się dzieje, gdy tłumaczenie powoduje straty. Ekspert może zrozumieć wiele ramek i nadal wybierać tylko te zgodne z interesem instytucji. Organizacja może wyrażać mowę o złożoności, zachowując jednocześnie ten sam podział władzy. Mądrość nie jest mierzona liczbą wymienionych perspektyw, ale chęcią umożliwienia odpowiedniej perspektywie modyfikacji działania.

Outfinitizm dodaje dyscyplinę zatrzymania i konsekwencji. Społeczeństwo nie może w nieskończoność konsultować się z każdym stożkiem: lekarz, sąd i zarządca muszą zdecydować., decyzja może jednak przenosić pamięć o jej granicach poprzez zachowanie monitorowania, kontestacji i odwracalności. czynność nie usprawiedliwia eliminacji niewygodnych głosów; wymaga bardziej uczciwego priorytetyzacji.

Stożki znaczenia są użyteczne nie jako etykiety dla kultur, ale jako sposób na uwidocznienie relacji między orientacją a ślepotą. Każdy stożek pozwala widzieć i wytwarzać przewagę. Mądrość zaczyna się, gdy ludzie i instytucje mogą uczynić sam stożek obiektem widzenia.

METARACJONALNOŚĆ: MĄDROŚĆ, KTÓRA WIDZI RAMĘ

Cel, skala, czas i władza

ZXQQ0000ZXQ może brzmieć jak krok powyżej racjonalności, jakby istniał uprzywilejowany obserwator, który widzi każdy system, nie należąc do żadnego z nich. ta interpretacja byłaby sprzeczna z samą ideą, którą termin ma wyrazić. Żadna osoba, kultura czy maszyna nie stoi poza językiem, historią, zainteresowaniami i ograniczeniami. Metaracjonalność nie jest widokiem znikąd. znajduje się w nim umiejscowiona zdolność do uwzględniania, przez pewien czas, obecnej ramy w dziedzinie krytyki. Jedna ramka bada drugą i może z kolei zostać zbadana. Nabieramy dystansu, a nie wszechwiedzy.

W swojej najprostszej formie racjonalność pyta, czy z przesłanek wynika wniosek i czy działanie służy wyznaczonemu celowi. Metaracjonalność dodaje pytania o lokal, cel i domenę: czy to właśnie staramy się chronić? Czy sformułowaliśmy problem na odpowiednią skalę? co model sprawia, że jest widoczny, a co usuwa? Kto wybrał kryterium sukcesu? w jakich warunkach należy zmienić ramę? jaką inną perspektywę zmieni decyzja? LE Te pytania nie zastępują obliczeń. decydują, kiedy obliczanie jest stosowane do właściwego problemu.

Wolumin towarzyszący zdefiniował metaracjonalność jako zdolność do rygorystycznego rozumowania podczas badania ramy, która umożliwia akt rozumowania. [[ALBOAIE-2026]] Definicja zawiera dwie części, które muszą pozostać razem. Bez rygoru „meta” staje się schronieniem dla wrażeń, które odmawiają weryfikacji. Bez badania ramy rygor może zoptymalizować błąd sformułowania. ZXQQ0001ZXQ to dojrzała relacja między tymi dwoma wymaganiami: wystarczające zaangażowanie w działanie i wystarczająca odległość, aby skorygować.

Trudna decyzja medyczna pokazuje, dlaczego tę relację można nazwać mądrością. Literatura kliniczna może oszacować prawdopodobieństwa, a lekarz może wyjaśnić efekty. Ale o wyborze leczenia, które skromnie przedłuża życie za cenę bólu i utraconej autonomii, nie decydują statystyki bez osoby. Istotne są model przetrwania, model jakości życia, obowiązki rodzinne, niepewność w dowodach, obraz godności i tolerancja na ryzyko. Racjonalny proces musi respektować fakty. Metaracjonalny proces musi zauważyć, dlaczego różne fakty mają znaczenie dla różnych celów i gdzie żadna optymalizacja nie eliminuje osądu.

Dzień na temat refleksyjnego osądu, myślenia postformalnego i zdolności związanych z badaniami mądrości: rozpoznawanie niepewności, ocena źródeł, integracja perspektyw, wrażliwość na kontekst oraz związek wiedzy z wartościami i konsekwencjami. [[KING-KITCHENER-1994]] ZXQQ0005ZXQ [KING-KITCHENER-1994] Tradycje te nie potwierdzają istnienia uniwersalnego etapu psychologicznego o nazwie metaracjonalność. Termin ten powinien być używany jako synteza filozoficzna i rodzina praktyk, a nie jako tytuł wyższości. Matematyk może być meta-racjonalny w stosunku do modeli formalnych i sztywny w relacjach osobistych. Przywódca może zrozumieć złożoność geopolityczną i nie jest w stanie zrewidować obrazu jaźni. Zdolność jest umiejscowiona, zmienna i narażona na regresję.

Pierwszy ruch metaracjonalny jest epistemiczny: rozróżnienie tego, co wiemy, co wnioskujemy i co zakładamy, aby działać. Niepewność nie jest jednym państwem. możemy mieć niewystarczające dane, nieprecyzyjny pomiar, niezgodę między modelami, niestabilność środowiska, nieznajomość odpowiednich wartości, czy niepewność co do własnych kompetencji. Każda z nich wymaga innej odpowiedzi. Brakujące dane mogą wymagać badań; konflikt między wartościami może wymagać rozważania; niestabilność może wymagać odwracalnego działania; wysokie stawki mogą wzywać do eskalacji do bardziej odpowiedniego organu. Generyczna formuła „nie jesteśmy pewni” ukrywa te różnice.

Drugi ruch dotyczy celu. Instrumentalna racjonalność często otrzymuje cel jako wkład. Metaracjonalność okresowo powraca do pytania, o którym zapomniał system: co staramy się chronić, a czy wskaźnik jest nadal powiązany z tą rzeczą? Uniwersytet może rozpocząć od pomiaru publikacji w celu obserwacji aktywności badawczej i zakończenia poprzez zorganizowanie badań w celu maksymalizacji publikacji. Firma może mierzyć zadowolenie klientów i nauczyć się osiągać wysokie wyniki, naciskając na respondentów. Polityka bezpieczeństwa może rozpocząć się jako ochrona i stać się mechanizmem kontroli. Metaracjonalność nie zakłada, że cele muszą być stale zmieniane. tworzy momenty, w których cel przestaje być niewidzialny.

Trzeci ruch dotyczy skali. Działanie, które jest rozsądne dla jednostki, może być destrukcyjne, gdy zostanie powtórzone przez miliony. Prowadzenie do pracy może być indywidualnie racjonalnym wyborem i może wspólnie przyczynić się do zatorów. firma może wierzyć, że nie może sobie pozwolić na spowolnienie niebezpiecznej rasy, mimo że każda firma wołałaby świat, w którym wyścig był ograniczony. gospodarstwo domowe kupuje najtańszy produkt i wraz z milionami podobnych decyzji wspiera warunki pracy, których nie zaakceptowałby jako regułę publiczną. Lokalna racjonalność nie komponuje się automatycznie w racjonalność zbiorową.

Odwrotna rzecz jest również prawdziwa. Polityka może poprawić średnią, jednocześnie nakładając poważne straty na niewielką grupę. Leczenie zmniejsza ryzyko populacji, ale szkodzi podgrupie, której cechy były słabo reprezentowane. Miasto staje się bardziej zamożne w agregacie i wydala tych, którzy przyczynili się do jego atrakcyjności. Przeciętność może być poprawna i moralnie niewystarczająca. Skala nie jest szczegółem technicznym dodanym po wyniku; zmienia znaczenie wyniku.

Czas może również odwrócić osąd. Strategia zwiększa kwartalny zysk i pochłania zdolność do innowacji. Wyjątek administracyjny rozwiązuje sytuację awaryjną i staje się trwałą formą władzy. Technologia oferuje natychmiastową wydajność i tworzy zależność instytucjonalną. Metaracjonalność pyta nie tylko, czy rozwiązanie działa, ale jak długo, z jakimi efektami uczenia się i które opcje zamyka. Decyzja może być teraz słuszna i nadal wymaga warunku wygaśnięcia.

Władza jest wymiarem, którego może brakować czysto poznawczy dyskurs. ramka to nie tylko reprezentacja; może być podziałem autorytetu. kto definiuje problem, decyduje, które cierpienie staje się istotne. Kto kontroluje wskaźnik, może zadeklarować sukces. kto ma dostęp do wyjątku, żyje w ramach innego systemu niż osoba zmuszona do przestrzegania zasady dosłownie. Epistemiczne zaufanie staje się dowództwem, gdy jest przyłączone do instytucji. tym mniej szansy ma dana osoba, tym bardziej wyraźna, uzasadniona i kontestowalna musi być rama, która je klasyfikuje.

ZQQ000ZXQ jest zatem również etyką władzy. Ekspert nie musi porzucać wiedzy specjalistycznej, aby uznać, że jej stosowanie pociąga za sobą związek. Lekarz wie więcej o mechanizmie leczenia; pacjent wie coś jeszcze o tym, co może zostać utracone. Inżynier może oszacować niezawodność; dotknięta społeczność może zidentyfikować wartości, które nie zostały uwzględnione w celu. Sąd ma prawo decydować, ale jego zasadność zależy od procedury, uzasadnienia i odwołania. Nie każdy głos ma równe kompetencje co do każdego roszczenia, ale kompetencje techniczne nie nadają automatycznie całkowitego autorytetu moralnego.

Pozycję można podsumować bez mechanicznej listy kontrolnej. Metaracjonalność sprawia, że rama jest widoczna, oddziela rodzaje niezgody, szuka prawdziwej alternatywy, porównuje konsekwencje i decyduje na poziomie rozdzielczości dozwolonej przez stawkę. po decyzji zachowuje możliwość korekty. Nie wymaga, aby każdy problem stał się seminarium filozoficznym. Czasami rama jest stabilna, procedura została zwalidowana, a dalsze odbicie zmniejszyłoby bezpieczeństwo. Pilot nie rekonstruuje filozofii lotnictwa w czasie sytuacji awaryjnej. Termin dojrzałości obejmuje wiedzę, kiedy zmiana ramki nie dodaje żadnej wartości.

Pluralizm bez relatywizmu, decyzja bez wszechwiedzy

Rozpoznawanie ramek natychmiast budzi sprzeciw: jeśli każda perspektywa ma swoje własne założenia, to czy nie dochodzimy do wniosku, że wszystkie są równoważne? To byłaby leniwa forma relatywizmu i zdrady metaracjonalność. Ramki można porównać. Niektórzy robią prognozy, które zawodzą. Niektórzy zaprzeczają solidnym dowodom. Niektóre są wewnętrznie niespójne. Niektórzy pracują na jedną skalę i myślą się w drugiej. niektóre są skuteczne i moralnie nie do przyjęcia. Fakt, że ocena ma również ramkę, nie usuwa różnicy między możliwym do przetestowania argumentem a twierdzeniem, które zmienia jego znaczenie, aby uniknąć obalenia.

Dojrzały pluralizm mówi, że kilka modeli może być niezbędnych dla złożonych obiektów. Nie mówi, że każdy model jest dobry. Fizyka wykorzystuje różne opisy w różnych skalach i łączy je poprzez relacje matematyczne. Biologia integruje mechanizmy molekularne, rozwój, zachowanie i ewolucję bez automatycznego zmniejszania każdego pytania do jednego poziomu. Nauki społeczne potrzebują danych ilościowych, historii, instytucji i interpretacji znaczenia. [[CARTWRIGHT-1983]] ZXQQ004ZXQ ZXQQ0005ZXQ Kryteria nie są identyczne w każdej domenie, ale każda domena może wymagać dyscypliny, przejrzystości i kontaktu z jej obiektem.

Metaracjonalność nie zawiesza wyroku; czyni osąd bardziej elokwentnym. Zamiast deklarować „to jest ostateczna prawda”, może powiedzieć: ten model jest tutaj preferowany, ponieważ lepiej wyjaśnia, przewiduje, umożliwia interwencję, zmniejsza pewne błędy i ma dopuszczalne konsekwencje; nie rozszerzymy go poza te warunki bez nowych dowodów. Takie stwierdzenie nie jest słabsze. jest to bardziej pouczające. Oddziela to uzasadnione zaufanie od psychologicznej potrzeby pewności.

Decyzja pod niepewnością jest tam, gdzie metaracjonalność podchodzi do mądrości. osoba może poczekać na więcej informacji, aż minie moment na działanie. Mogą generować alternatywy w nieskończoność i nazywać paraliż „złożonością”. Metaracjonalność nie czeka na wszechwiedzę. dąży do podjęcia decyzji, której siła jest proporcjonalna do dowodów, której odwracalność pasuje do stawki, i której koszt błędu został rozpatrzony. Eksperymentem jest czasami najmądrzejsza opcja to małe działanie, eksperyment lub etap, który zachowuje alternatywy. to innym razem krótki termin wymaga zdecydowanego wyboru. Wiedza o granicach nie eliminuje odwagi; uwalnia odwagę od fałszywego pożyczania pewności.

Emocje odgrywają w tym procesie ambiwalentną rolę. Uproszczony racjonalizm traktuje go jako hałas dodany do umysłu, który lepiej funkcjonowałby jako komputer. jednak emocje mogą oznaczać wartość, niebezpieczeństwo, stratę i trafność przed zakończeniem analizy. [[DAMASIO-1994]] Strach może sygnalizować ryzyko i

zniekształcać prawdopodobieństwo. tyk może wspierać sumienie społeczne i narzucać zgodność. radość może wskazywać na wyrównanie z wartością i nagradzać samooszukiwanie się. Metaracjonalność nie intronizuje uczucia. Traktuje uczucie jako informację, które należy interpretować, ani wyeliminować, ani uabsolutować.

Tożsamość jest równie ważna. przekonanie związane z przynależnością nie jest korygowane tylko poprzez przedstawienie statystyki. porzucenie go może zagrażać związkowi, statusowi i spójności jaźni. Fakt ten wyjaśnia opór, ale nie dowodzi prawdziwości przekonania. Metaracjonalna praktyka szuka form korekty, które nie zbędnie niszczą człowieka. jednocześnie nie zamienia ochrony tożsamości w weto nad rzeczywistością. mądrość może zachować godność, jednocześnie oddzielając doświadczenie od interpretacji faktycznej.

Hipokryzja wchodzi tu nie jako marginalny wyjątek, ale jako objaw konfliktu między ogólnymi zasadami a poszczególnymi życiami. Ideały się koordynują, ale żaden aktor nie może ich zastosować bez interpretacji, a interpretacja nieuchronnie rozdziela koszty i wyjątki.

Problem nie jest wyczerpany przez wykrywanie niespójności. Musimy zapytać, kto przynosi korzyści, kto ponosi koszty, ile władzy ma aktor i czy adaptacja zachowuje funkcję ideału lub wykorzystuje go jako ekran. nieczenie ograniczonych i hipokryzja tych, którzy kontrolują zasady, nie są symetryczne. Zrozumienie przyczynowe nie jest rozgrzeszeniem.

Istnieje również podróbka metaracjonalności. Używa słownictwa ramek, aby uniknąć każdego zaangażowania. Każdy fakt staje się „perspektywą”, każda krytyka jest zrelatywizowana, a interes własny przedstawia się jako wyrafinowana integracja. osoba może wyjaśnić, dlaczego wszyscy mają częściowo rację, aby uniknąć stwierdzenia, gdzie należy nałożyć limit. Złożoność staje się statusem. W warunkach instytucjonalnych konsultacja z kilkoma perspektywami może stać się rytuałem, który legitymizuje już podjętą decyzję.

Obrona nie jest algorytmem, ale testem tarcia. perspektywa jest metaracjonalna, jeśli może sformułować najsilniejszą kontrakatkę, powiedzieć, jakie dowody zmieniłyby wniosek i pozwolić na istotny sprzeciw w celu modyfikacji działania. Jeśli liczba mnoga nie daje możliwości zmiany, jest to dekoracja. Jeśli niepewność jest przywoływana tylko wtedy, gdy zagraża interesowi własnemu, mamy strategię, a nie mądrość.

Racjonalność, metaracjonalność, a outfinitism	Charakterystyczne pytanie
Racjonalność	Jak prawidłowo rozwiązać problem w obrębie danej ramki?
ZQQ0000ZXQ	Jakiej ramki używamy, co wyklucza i kiedy należy ją zrewidować?
ZQQ0000ZXQ	Co możemy wspierać i robić w rzeczywistych granicach i jak można odpowiedzialnie przesuwąć granicę?

Tabela nie opisuje etapów, które wzajemnie się anulują. Metaracjonalność potrzebuje racjonalności, a outfinitism potrzebuje obu. Dobra decyzja nie pozostaje na stałe ponad problem. Wchodzi w ramkę, oblicza, powraca do konsekwencji i wie, kiedy ponownie otworzyć pytanie. Ruch przypomina oddychanie bardziej niż wspinanie się po drabinie. Wdech rozszerza pole; wydech zamyka się tymczasowo i umożliwia działanie.

Metaracjonalność można nazwać mądrością właśnie dlatego, że odrzuca dwie iluzje: iluzję, że potrzebujemy pewności, aby działać, i złudzenie, że rozpoznawanie niepewności zwalnia nas z wyboru. nie obiecuje pojednania między wszystkimi wartościami. czasami zdarzają się tragiczne konflikty, nieredukowalne straty i ramy, których nie można skomponować bez pozostałości. W takich sytuacjach jego rolą jest zapobieganie ukrywaniu się straty pod językiem technicznej konieczności. Decyzja może pozostać konieczna i nadal uznać to, co poświęca.

Mądrość nie jest większą bazą danych. to właściwy stosunek do tego, co wiemy, czego nie wiemy, a władza otrzymuje konkluzja. Osoba może mieć poprawną odpowiedź w niewłaściwej ramce i wytworzyć wyrafinowany błąd. Mogą mieć niepełny model i poprzez skromność, monitorowanie i możliwość korekty działają lepiej. Metaracjonalność nie gwarantuje wyniku. Tworzy lepsze warunki do tego, aby błąd stał się widoczny, zanim stanie się przeznaczeniem.

OUTFINITIZM: SZTUKA OTWARTYCH GRANIC

Rzeczywista skończoność i otwarty horyzont

Metaracjonalność sprawia, że ramka jest widoczna. Outfinitizm pyta, co można zrobić po tym, jak to zobaczymy. Pierwsze uwalnia nas, przynajmniej tymczasowo, od wrażenia, że jedna perspektywa wyczerpuje rzeczywistość. drugie uniemożliwia nam przekształcenie tej wolności w wymaginowaną podróż przez każdą możliwą perspektywę. Każde porównanie pochłania czas. Każdy model wymaga danych, języka i instrumentów. Każda weryfikacja ma rozdzielczość, czas trwania i koszt. każda instytucja może utrzymać tylko ograniczoną liczbę procedur, wyjątków i form odwołania. Outfinitizm zaczyna się od tej konkretnej skończoności, ale nie chce pomylić jej z metafizycznym zamknięciem świata.

Książka, do której dodaje się ten tom, nazywa się to stanowisko „otwartą skończoną”. [[ALBOAIE-2026]] Wyrażenie ma na celu utrzymywanie dwóch prawd, które współczesna kultura często oddziela. pierwsze jest to, że każde skuteczne osiągnięcie jest skończone. Dowód jest pisany w języku i sprawdzany poprzez określone operacje. Eksperyment mierzy ograniczoną domenę. Model języka ma architekturę, kontekst, pamięć i dostęp do poszczególnych narzędzi. Polityka publiczna jest realizowana przez konkretne osoby, przez pewien czas, z budżetem i zdolnością administracyjną. druga prawda jest taka, że te osiągnięcia niekoniecznie zamykają domenę. le możemy kontynuować dochodzenie, zrewidować teorię, rozszerzyć symulację, zmodyfikować instytucję lub wymyślić nowy język, nie zakładając, że wszystkie przyszłe etapy już istnieją jako kompletny spis.

-Ta pozycja nie jest odrzuceniem matematyki nieskończoności, ani powrotem do idei, że tylko małe lub natychmiast budowlalne obiekty są uzasadnione. Współczesna matematyka stworzyła rygorystyczne teorie nieskończoności, a ich użycie nie powinno być kwestionowane przez niejasne intuicje na temat świata fizycznego. Zamieszanie zaczyna się, gdy prestiż formalnej abstrakcji zostaje przeniesiony potajemnie do kulturowych obietnic wzrostu bez kosztów, całkowitej kontroli, całkowitej prognozy, absolutnego bezpieczeństwa lub inteligencji bez ograniczeń. fakt, że system matematyczny może opisać nieskończoną całość, nie dowodzi, że ekosystem może wspierać niekończącą się ekspansję gospodarczą. fryn, że proces można wielokrotnie

usprawnić, nie oznacza, że perfekcja jest dostępnym produktem. fakt, że model staje się większy, nie przyznaje mu nieograniczonego autorytetu.

ZXQQ0000ZXQ jest mniej zainteresowany zakazem słowa niż żądaniem tłumaczenia. Kiedy ktoś obiecuje „nieograniczony”, pojawia się pytanie: nieograniczone w stosunku do którego działania, dla którego agenta, przez jaki interwał, z jakimi zasobami i w jakim sensie? Niektóre granice są fizyczne, inne epistemiczne, ekonomiczne, prawne, moralne lub instytucjonalne. ta jest stosunkowo stabilna; inne poruszają się, gdy pojawiają się nowe instrumenty. ni muszą zostać zaakceptowani, inni zrekompensowani, wynegocjowani lub pokonani. Nazwa limitu nie oznacza jego uświęcenia. To oznacza przekształcenie niejasnej krawędzi w przedmiot osądu.

Niektóre granice funkcjonują jako ściany. Szybkość światła, umiarkowanie biologiczne w obecnych warunkach lub niezdolność instytucji do jednoczesnego przetworzenia nieograniczonej liczby przypadków może nałożyć twarde ograniczenia w stosunku do zadania. Inne limity to progi. Zespół może ręcznie zweryfikować dziesięć artefaktów ostrożnie i tysiąc tylko powierzchownie. Model może działać dobrze, dopóki nie zmieni się dystrybucja danych. Leczenie może być przydatne poniżej dawki i toksyczne nad nim. Inne granice to ruchome horyzonty: to, czego nie można było zmierzyć wczoraj, staje się dostępne za pośrednictwem nowego instrumentu; to, czego nie można było obliczyć w ramach budżetu, staje się praktyczne po ulepszeniu algorytmicznym. Istnieją również granice normatywne, które wyrażają niezdolność, ale odmowę: nawet jeśli możemy całkowicie zainwigilować populację, nie wynika z tego, że powinniśmy.

Dojrzała kultura nie ogranicza wszystkich tych granic do tej samej propozycji. „Nie możemy” może oznaczać logicznej niemożliwości, tymczasowej nieobecności technologicznej, nadmiernych kosztów, braku legitymacji, niewystarczających dowodów lub po prostu braku woli politycznej. mylenie ich często służy władzy. Spółka może przedstawić decyzję ekonomiczną jako konieczność techniczną. Państwo może nazwać wybór instytucjonalny nieuniknionym. Badzowiec może przekształcić granice eksperymentu w granice rzeczywistości. Outfinitizm wymaga wyjaśnienia rodzaju limitu, dokładnie po to, abyśmy mogli sprawdzić, czy należy go respektować, atakować, czy redystrybuować.

W tym sensie outfinitizm jest sztuką granicy, a nie metafizyką kapitulacji. Wymaga każdego ważnego roszczenia, aby nieść pamięć o warunkach, w jakich została ona uzyskana. wniosek na temat skuteczności leczenia powinien określać, które populacje były badane, który wskaźnik został zastosowany, a które efekty pozostały słabo obserwowane. Przewidywanie ekonomiczne powinno wskazywać scenariusz i interwał. System sztucznej inteligencji oceniany na porównawkach nie staje się „ogólnie

bezpieczny”; staje się systemem, który przeszedł poszczególne testy w określonych warunkach. Limit nie jest przypisem żenującym, ale częścią znaczenia roszczenia.

Na zmianę wytwarzaną przez AI jest ta dyscyplina. Generowanie stało się znacznie tańsze niż weryfikacja. W ciągu godziny model może zaproponować więcej hipotez, dowodów, programów i interpretacji, niż ludzki zespół może poważnie sprawdzić. W matematyce i nauce artefakt może być formalnie poprawny i nadal wyrażać niewłaściwy problem, używać nieodpowiedniej reprezentacji lub nie połączyć się ze światem empirycznym. tęba na temat matematyki sfinistycznej sformułowała właśnie tę różnicę między derywacją a zdolnością operacyjną: propozycja może być udowodniona w systemie, ale użycie jej w komputerze lub eksperymencie wymaga dodatkowych reprezentacji, procedur, budżetów i kontroli. [[ALBOAIE-2026-MATH]]

Pomysł można uogólnić, nie zamieniając całej kultury w oprogramowanie. Twierdzenie nie staje się dojrzałe tylko dlatego, że brzmi spójnie. Musimy wiedzieć, na które pytania odpowiada, jakie dowody to potwierdzają, jak daleko można je przedłużyć i co pozostaje otwarte. Ta „otwarta granica” to wiedza, a nie porażka. stwierdzenie, że badanie nie pozwala na ekstrapolację na wszystkie populacje, jest pozytywną informacją. stwierdzenie, że model nie może rozróżnić dwóch przyczynowych wyjaśnień, jest bardziej użyteczne niż dokonanie arbitralnego wyboru. stwierdzenie, że decyzja powinna zostać poddana przeglądowi po sześciu miesiącach, może być bardziej racjonalne niż przedstawienie jej jako stałego rozwiązania.

ZXQQ0000ZXQ nie wymaga jednakowej ostrożności w każdej sytuacji. Twierdzenie o preferencjach estetycznych nie wymaga takiego samego wysiłku walidacyjnego jak zalecenie lekarskie. Odwracalna sugestia może być oferowana na podstawie przybliżenia. Decyzja, która może pozbawić wolności lub spowodować nieodwracalną szkodę, wymaga innego poziomu weryfikacji i innego podziału władzy. cyta nie spłaszcza świata, wymaga proporcjonalności. Zasoby celowe są ograniczone i powinny być skierowane na miejsca, w których błąd kosztuje najwięcej.

To zbliża outfinitizm do ograniczonej racjonalności Herberta Simona, ale nacisk jest inny. Racjonalność ograniczona [[SIMON-1955]] opisuje środki, które nie są w stanie doskonale zoptymalizować, a zatem wykorzystują reguły, przybliżenia i zadowalające progi. Outfinitizm dodaje wyraźnej pamięci granicy: agent nie tylko decyduje o ograniczeniach, ale powinien wiedzieć, która część problemu nie może być reprezentowana, co może się zmienić i jaki autorytet ma decyzja. Wystarczająco dobry wybór nie powinien przedstawiać się jako absolutny optimum. Może być preferowany, ponieważ jest odwracalny, monitorowany i kompatybilny z późniejszym uczeniem się.

Tu leży różnica między prostotą a uproszczeniem. Prostotą jest świadoma kompresja. Pozostawia szczegóły na boku, aby umożliwić działanie, ale zachowuje pamięć o tym, co

usunęła. prostota zapomina o stracie i zmienia instrument w świat. prosty protokół medyczny może uratować życie, gdy czas jest krótki, pod warunkiem, że istnieją kryteria wyjątków i eskalacji. ten sam protokół staje się uproszczony, gdy nietypowe przypadki są traktowane jako wady pacjenta. Prosta zasada prawna może zmniejszyć arbitralność; staje się uproszczona, gdy dosłowne zastosowanie niszczy cel prawa. Model AI może używać skutecznej heurystyki; staje się niebezpieczny, gdy wynik jest traktowany jako tożsamość osoby.


Outfinitizm nie jest więc kultem limitów. Niektóre granice są niesprawiedliwe i trzeba je przezwyciężyć. Brak dostępu do edukacji, wykluczenie polityczne lub sztuczne bariery nałożone na grupę nie nabierają legitymacji tylko dlatego, że są one prawdziwe. W innych przypadkach próba wyeliminowania każdego limitu daje dominację. Organizacja, która wymaga stałej dostępności, traktuje ciało pracownika jako problem optymalizacji. Platforma, która dąży do zaangażowania bez progu, traktuje ludzką uwagę jako pozornie nieograniczony zasób. społeczeństwo, które odmawia zaakceptowania podatności, może stworzyć systemy nadzoru bardziej destrukcyjne niż ryzyko, z którym mają walczyć.

Sztuka otwartych limitów polega na rozróżnieniu. Limit może zostać przyjęty, przeniesiony, zrekompensowany, udostępniony, przekształcony lub odrzucony. nie decyduje żadna jedna zasada. Outfinitizm oferuje orientację: spraw, aby limit był widoczny, opisz relację, w której się pojawia, nie myl modelu ze światem i zachowaj otwartą możliwość lepszej formy. w tym sformułowaniu jest on bliższy praktycznej mądrości niż doktrynie o wielkości wszechświata.

Yin i Yang: mobilność ram i dyscyplina granicy

Metaracjonalność i outfinitizm mogą być postrzegane jako dwa uzupełniające się ruchy. Metafora yin-yang jest przydatna tylko wtedy, gdy nie załadujemy jej egzotycznymi twierdzeniami. wyraża wzajemne napięcie naprawcze. Otwiera ZXQQ0000ZXQ: wyszukuje inne kadry, tłumaczy się wśród perspektyw, sprawia, że założenia są widoczne i opiera się przedwczesnemu zamknięciu. Outfinitizm zamyka się tymczasowo: pamięta, że analiza ma budżet, że decyzja musi zostać podjęta i że każde roszczenie musi być powiązane z rzeczywistym pokryciem. pierwsze bez drugiego może stać się mobilnością bez zaangażowania. drugie bez pierwszego ryzykuje, że stanie się dyscypliną w służbie niewłaściwej ramy.

Dwa ruchy, które korygują się wzajemnie



Schemat 4. Dwa ruchy osądu

W konkretnym problemie te ruchy na przemian. Zespół badawczy definiuje i wykorzystuje model. Wyniki pojawiają się, które nie pasują. Metaracjonalność pyta, czy anomalia to hałas, limit pomiaru, czy oznaka nieodpowiedniej ramy. Alternatywy są proponowane. Outfinitizm następnie pyta, która alternatywa może być przetestowana z dostępnymi zasobami, jaki wynik by się liczył i kiedy eksperyment powinien się zatrzymać. po badaniu ramę można zachować, zwęzić lub wymienić. ani otwarcie, ani zamknięcie nie jest ostateczne.

Ta sama zmiana pojawia się w polityce. Zasada ogólna jest niezbędna do przewidywalności. Z konkretnych przypadków wynika, że reguła czasami wywołuje niesprawiedliwość. ZXQQ0000ZXQ uwidacznia cel prawa, doświadczenie osoby i inne interpretacje. Outfinitizm pamięta, że instytucja nie może od początku odset osądzać całego porządku społecznego. Dla wyjątku, odwołania i precedensu potrzebne są spełnione kryteria. Mądrość nie jest ani ślepym zastosowaniem, ani trwałą arbitralnością; jest to projekt związku między regułą a korektą.

Społeczną hipokryzję można analizować za pośrednictwem tej samej pary. Ideały ściskają moralny kierunek i koordynują oczekiwania, podczas gdy prawdziwe życie tworzy kompromisy, role i różnice między tym, co można powiedzieć publicznie, a tym, co można zrobić. Krytyka purystyczna traktuje każde odchylenie jako dowód na to, że ideał jest fałszywy; cyniczny realizm dowodzi, że ideały są tylko narzędziami władzy. Metaracjonalność wyszukuje funkcję i ukryte napięcie. Outfinitizm pyta, jaki stopień zgodności jest możliwy, jakie koszty rozbieżności i jaki konkretny krok może zmniejszyć potrzebę wyglądu.

Formuła „zachowaj funkcję, wycofaj oszustwo” pozostaje tylko regułą orientacji. Prosi nas o odróżnienie konwencji, które chronią współpracę przed formami rozmachu, które chronią przywileje. ZXQ00001ZXQ wprowadza ideał w relację z rzeczywistością

pojemnością, podczas gdy ZXQQ0000ZXQ sprawdza, czy funkcja jest wywoływana, jest w rzeczywistości problemem, który należy zmienić.

W nauce para koryguje dwa przeciwstawne ekscesy. scjentyzm rozszerza metody naukowe na twierdzenie, że tylko to, co mogą obecnie zmierzyć, jest rzeczywiste lub wartościowe. antynauka odpowiada z uogólnioną podejrzliwością i traktuje granice teorii jako dowód, że każda alternatywna intuicja jest równie dobra. Metaracjonalność rozpoznaje wiele modeli i rolę wartości w wyborze problemów. ZXQQ0001ZXQ zachowuje hierarchie epistemiczne tworzone poprzez eksperyment, replikację i weryfikację, ale wiąże je z ich domenami. Nie wszystko jest mierzalne w ten sam sposób, ale twierdzenie przyczynowe o leczeniu nie staje się prawdziwe dzięki wewnętrznemu doświadczeniu.

Komplementarność tę można również sformułować jako związek między epistemologią a aksjologią. Epistemologia pyta, co jest uzasadnione. Aksjologia pyta, co się liczy, a co warto realizować. Metaracjonalność pokazuje, że pytania są ze sobą powiązane: wybór dowodów i celu odbywa się w ramach. Outfinitizm pokazuje, że połączenie musi być zaimplementowane poprzez skończone wybory. nie możemy ocenić wszystkich wartości i wszystkich konsekwencji naraz, ale możemy zadeklarować, co priorytetowo potraktowaliśmy, co pominęliśmy i kto ponosi ryzyko.

To jest decydujące dla AI. System generatywny nie tylko wytwarza roszczenia, ale także rozprasza uwagę. Poprzez kolejność jego odpowiedzi, wybrane przykłady i ton pewności, sprawia, że niektóre możliwości są bardziej widoczne niż inne. Model przeszkolony, aby być pomocnym, może wypełnić każdą przestrzeń odpowiedziami. Finistyczny filtr wprowadziłby pytanie o zatrzymanie: czy konieczne jest kolejne pokolenie, dłuższe wyjaśnienie czy zautomatyzowana decyzja? Metaracjonalny filtr wprowadziłby pytanie perspektywiczne: jaka ramka została przyjęta, a której istotnej alternatywy brakuje? razem nie zapewniają ostatecznej moralności maszyny, ale mogą zmienić sposób, w jaki zarządza mocą generowania.

Niebezpieczeństwo polega na tym, że te dwie koncepcje stają się słownym rytuałem. System może oświadczyć, że „wszystkie modele mają limity”, wymienić trzy perspektywy i kontynuować dokładnie tę samą optymalizację. Instytucja może dodać punkt dotyczący niepewności, nie pozwalając, aby wyniki zmieniły decyzję. Limit jest realny tylko wtedy, gdy zmienia autorytet, alokację zasobów, odwracalność lub zakres konkluzji. Alternatywna perspektywa jest prawdziwa tylko wtedy, gdy może wytworzyć zauważalną różnicę.

Outfinitizm musi być zatem surowy z własnymi roszczeniami. Nie jest to jeszcze dyscyplina ustabilizowana przez szeroką społeczność, eksperymenty i instytucje. wiele z jego idei ma precedensy w pragmatyzmie, mylności, ograniczonej racjonalności,

konstruktywizmie, teorii systemów, epistemologii społecznej i filozofiach pluralizmu. jectwa nie można odebrać poprzez nazwę. Musi być zarobiony poprzez wytworzoną syntezę, jasność, z jaką granice są możliwe do działania, a problemy ta orientacja faktycznie pomaga rozwiązać.

To samoograniczenie jest właśnie tym, co zachowuje swoje znaczenie. Outfinitizm nie jest ostateczną teorią na temat tego, dlaczego nie ma ostatecznych teorii. Jest to przeciwwaga dla epoki przyciąganej skalowaniem, totalizacją i automatyzacją. Metaracjonalność nie jest stożkiem, który zawiera każdy stożek. to praktyka zauważania, że nosimy jedną i próbujemy, kiedy stawka tego wymaga, inną orientację. razem proponują formę ambicji bez wszechwiedzy: forsować granice, ale nie wymazywać śladów miejsca, w którym zaczynaliśmy, ani kosztów przekraczania.

JAK LLM MÓGŁBY ZREKONSTRUOWAĆ TĘ PERSPEKTYWĘ

Predykcja tokenów, reprezentacje rozproszone i orientacja kierowana promptem

Ta książka zaczęła się również od prostego, ale niepokojącego doświadczenia. Osoba opisana, według jego własnych słów, dwie idee, które wciąż nabierały kształtu: metaracjonalność jako dojrzałość zdolna do widzenia i porównywania ram, oraz outfinitizm jako aktywna akceptacja granic wraz z wysiłkiem, aby je popchnąć bez złudzenia ostatecznego systemu. Model językowy nie otrzymał pełnego traktatu. Nie miała znormalizowanej definicji do recytowania. przyniosła jednak rozwój wydarzeń, które wydawały się zachowywać centralne napięcia perspektywy: rygor bez absolutyzacji, pluralizm bez relatywizmu, skończoność bez kapitulacji, otwartość bez obietnicy dostępnej nieskończoności oraz związek między wiedzą, wartością i działaniem.

Naturalne wrażenie było takie, że model „zrozumiał”. Słowo to wymaga opieki. nie możemy udowodnić, że w danych szkoleniowych nie doszło nigdzie do sformułowania, a model komercyjny nie zapewnia pełnego spisu tekstów, które napotkał. Co ważniejsze, nawet brak dokładnego wyrażenia nie oznaczałby, że wszystkie jego składniki były nowe. Literatura zawiera idee o błędności, paradygmatach, pluralizmie naukowym, racjonalności ograniczonej, mądrości, konstruktywizmie, pragmatyzmie, weryfikacji, symulacji i granicach obliczeniowych. Każda możliwa nowość tkwi w ich orientacji i kombinacji, a nie w wyglądzie każdego komponentu z niczego.

Skromniejsze i bardziej techniczne pytanie jest więc tym ciekawym: jak model może zrekonstruować konfiguracyjną konfigurację, którą monit prezentuje niekompletnie i w idiosynkratycznym słownictwie? Odpowiedź zaczyna się od podstawowego mechanizmu modelu językowego. Tekst jest podzielony na tokeny, a na każdej pozycji model szacuje rozkład nad możliwymi kontynuacjami. Architektura Transformatora buduje reprezentacje kontekstowe poprzez warstwy uwagi i transformacji neuronowej. Słowo nie jest przypisane stałe znaczenie przechowywane, jak w słowniku. Jego reprezentacja jest modyfikowana przez sąsiadów, instrukcję, przykłady, rolę konwersacyjną i poprzednią ścieżkę sekwencji. [[VASWANI-2017]] [VASWANI-2017] [[DEVLIN-2019]]

Opis „przewiduje następny token” jest poprawny, ale może wprowadzać w błąd, gdy zostanie usłyszany jako „mechanicznie wybierze następne słowo zgodnie z częstotliwością”. Aby dobrze przewidzieć kontynuację w różnych domenach, model musi wykorzystywać prawidłowości obejmujące składnię, koncepcje, style, relacje, struktury argumentacyjne i sytuacje opisane w tekście. Przewidywanie jest celem szkoleniowym; reprezentacje pośrednie mogą przychodzić, aby kodować informacje bogatsze niż słowne stwierdzenie tego celu. to nie dowodzi, że model posiada ludzki świat wewnętrzny, ale pomaga wyjaśnić, w jaki sposób mechanizm kontynuacji może wytworzyć uogólnienie semantyczne.

Wczesne osady dystrybucyjne wykazały już, że stosunki użycia między słowami można przekształcić w dzielnice i kierunki w przestrzeni wektorowej. ZXQQ0001ZXQ. W takiej przestrzeni podobieństwo cosinute porównuje orientację dwóch wektorów więcej niż ich wielkość. Biorąc pod uwagę wektor referencyjny i próg, możemy sobie wyobrazić region w kształcie stożka zawierający wektory, których kierunki są wystarczająco bliskie. to jest pochodzenie metafory stożka znaczenia. Monit może zorientować aktywację w kierunku rodziny relacji: granic, ram, rewizji, pluralizmu, implementacji, mądrości. Kontynuacje zgodne z tą orientacją stają się bardziej prawdopodobne.

Metafora musi być natychmiast ograniczona. LLMs nie posiada jednej przezroczystej przestrzeni semantycznej, w której każda filozofia zajmuje stabilny stożek. Reprezentacje różnią się w różnych warstwach i pozycjach, zależą od kontekstu i mogą być anizotropowe i trudne do interpretacji. To samo wyrażenie może uczestniczyć w wielu konfiguracjach. dwie orientacje koncepcyjne mogą się pokrywać, a niewielka zmiana w monicie może aktywować inne relacje. tylne podobieństwo jest użyteczną miarą w wielu zastosowaniach, a nie kompletną teorią znaczenia. Stożek jest zdyscyplinowaną metaforą informowaną przez analogię geometryczną, a nie dosłowną anatomię umysłu czy modelu.

Mimo to metafora oddaje coś rzeczywistego: użyteczne znaczenie jest relacyjne. prompt nie tylko dostarczył dwie etykiety. Dostarczał kontrasty i połączenia. w rzeczywistości stwierdzono, że ZXQ00000ZXQ nie porzuca rozumu, ale bada jego ramę; że outfinitizm nie gloryfikuje granic, ale akceptuje je, aby je popchnąć; że reprezentacje są raczej uciskami niż rzeczywistością; że doskonały system jest bożkiem; i że mnogość musi pozostać połączona z działaniem. Te relacje ograniczają możliwe kontynuacje. w ramach swojej statystycznej ekologii model może wyszukiwać sformułowania, które zachowują wskazane napięcia jednocześnie.

Pomysł jest często rozpoznawany nie przez jedno zdanie, ale przez kształt opozycji, których nie chce uprościć. Metaracjonalność nie jest ani dogmatyzmem, ani relatywizmem. Outfinitizm nie jest ani nieskończonością kulturową, ani zamknięciem

finitystów. aroga nie jest ani pewnością, ani paraliżem. Gdy monit zachowuje takie pary, zapewnia silniejszą strukturę selekcji niż izolowana definicja. model może generować zgodne konsekwencje właśnie dlatego, że ogromna liczba tekstów szkoleniowych zawiera fragmenty tych napięć w innych słownikach.

Proces ten przypomina rekonstrukcję kulturową opisaną we wcześniejszych rozdziałach. osoba nie zawsze kopiuje pomysł, jakby był to plik. osoba rekonstruuje ją poprzez schematy, przykłady i atrakcje kulturalne. Model robi coś funkcjonalnie analogicznego, choć za pomocą różnych mechanizmów: niekoniecznie pobiera oryginalny akapit, ale składa kontynuację rozproszonych prawidłowości. Monit działa jako tymczasowe naczynie, w którym materiał statystyczny przybiera określoną formę.

Uwagę odgrywa tu ważną rolę, ale nie należy jej antropomorfizować. Mechanizm samouwagi pozwala każdej pozycji łączyć informacje z innych pozycji zgodnie z wagami obliczonymi na podstawie obecnych reprezentacji. W ten sposób słowa „limit”, „frame”, „symulacja”, „prawdziwy świat”, „mądrość” i „brak ostatecznego systemu” nie pozostają wyspami. razem przyczyniają się do stanu kontekstowego, z którego generowany jest następny token. w miarę rozwoju odpowiedzi, jej własne sformułowania stają się częścią kontekstu i wzmacniają kierunek. Spójność może stać się samowzmacniająca.



Diagram 5. Monit jako orientacja tymczasowa

Ostatni punkt na diagramie jest niezbędny. ten sam mechanizm, który pozwala na opracowanie płodnej intuicji, może stworzyć spójną filozofię z fałszywego założenia. Gdy użytkownik dostarcza silny stożek, model może znaleźć argumenty, analogie i słownictwo, które sprawiają, że jest bardziej przekonujący. Spójność nie jest weryfikacją. LLM wybiera kontynuacje zgodne z kontekstem i z wyuczonymi preferencjami; jego podstawowy cel nie zawiera reguły gwarantującej, że ekologia semantyczna zbiegnie się w kwestii prawdy.

Z tego powodu zdolność modelu do tworzenia wrażenia zrozumienia jest zarówno dowodem, jak i ostrzeżeniem. Podtrzymuje ideę, że znaczenie ma wystarczającą strukturę relacyjną, aby można ją zrekonstruować z niepełnych wskazówek. Jest to ostrzeżenie, ponieważ ta sama struktura może być zorientowana na wiele stożków, zwłaszcza w przestrzeni wysokowymiarowej zawierającej sprzeczne materiały kulturowe. Model nie wykrywa automatycznie właściwego stożka. Na czas trwania rozmowy wchodzi w region zgodności, który jest prawdopodobny dzięki monitowi, historii konwersacji i poszkoleniu.

Uczenie w kontekście, pragmatyka i kruchość pozornego rozumienia

Badania nad uczeniem się w kontekście wzmacniają to wyjaśnienie, nie przekształcając go w kompletną teorię. Modele mogą otrzymać kilka przykładów w monicie i kontynuować zgodnie z zadaniem, dla którego nie zostały wyraźnie dostrojone podczas tej rozmowy. Niektóre eksperymenty sugerują, że demonstracje indukują zwarte wewnętrzne reprezentacje związane z zadaniem, czasami nazywane „wektorami zadań”. Interwencja na tych reprezentacjach może modyfikować zachowanie w odpowiednim kierunku. Inne badania rozróżniają między rozpoznaniem zadania, które jest już znane, a autentycznym uczeniem się nowej zasady z kontekstu. [[HENDEL-2023]]

Tędy te mają znaczenie, ale należy je czytać z powściągliwością. Oni nie pokazują, że filozofia jest przechowywana w jednym wektorze, ani że model posiada stabilną tożsamość. One pokazują, że kontekst może wywołać tymczasowy tryb działania, który kompresuje przykłady i wpływa na kolejne odpowiedzi. Monit może funkcjonować jako mała lokalna konstytucja: definiuje słownictwo, cel, ton, ważne rozróżnienia i rodzaje błędów, których należy unikać. Model nie jest przekwalifikowany w zwykłym znaczeniu, ale jego obliczenia są uwarunkowane przez tę konstytucję na czas trwania okna kontekstowego.

To pomaga wyjaśnić, dlaczego to samo pytanie może otrzymać bardzo różne odpowiedzi po różnych instrukcjach. Modelka prosimy, aby postrzegała problem jako inżynier, prawnik, terapeuta, historyk lub krytyk moralny. Nie instalujemy dosłownie zawodu, ale aktywujemy prawidłowości języka, trafności i argumentów związanych z rolą. W przypadku metaracjonalności i outfinitism, monit żądał więcej niż stylu. Żej do reżimu interpretacji: nie absolutować, szukać ograniczeń, zachować otwartości i łączyć idee z wdrażaniem i konsekwencjami. Model odtworzył ten reżim na tyle dobrze, że wygenerował zaskakujące odpowiedzi.

, Zrozumienie ludzkie obejmuje jednak więcej niż ta kompetencja. osoba może połączyć koncepcję z doświadczeniem, ucieleśnieniem, pamięcią autobiograficzną, zobowiązaniami i ryzykiem utraty czegoś. człowiek może odkryć, że pomysł zmienił życie lub że jego zastosowanie kogoś skrzywdziło. LLM działa poprzez reprezentacje wyniesione z tekstu, a w niektórych przypadkach multimodalnych śladów świata, wraz z narzędziami i informacjami zwrotnymi z nim połączonymi. może symulować językowe konsekwencje doświadczenia niezwykle dobrze, nie będąc w ten sam sposób bezbronnym. stwierdzenie, że „rozumie” jest możliwe do obrony w ograniczonym i kwestionowanym sensie funkcjonalnym. wywnioskowanie się z tej fenomenalnej świadomości, mądrości lub odpowiedzialności moralnej porównywalnej z człowiekiem wykraczałoby poza dowody.

Przydatne rozróżnienie to między semantyką a pragmatyką. Semantyka dotyczy relacji znaczenia i warunków, w jakich wyrażenie odnosi się do czegoś. Pragmatyka dotyczy tego, co mówca robi w kontekście: żądań, ostrzega, żartuje, negocjuje, chroni tożsamość lub szuka efektu. Model językowy może odtworzyć wiele pragmatycznych prawidłowości, ponieważ jego dane zawierają ślady ludzkich rozmów. Może wywnioskować, że pytanie pośrednie jest w rzeczywistości żądaniem, że ton wyraża nieufność lub że użytkownik chce przeformułowania, a nie sporu. Intencja nie jest jednak zawarta całkowicie w ciągu słów. To zależy od historii, ról, konwencji i konsekwencji. [[BENDER-KOLLER-2020]]

W rozmowie, która motywowała tę książkę, model wywnioskował nie tylko treść pracy, ale także jej intencję intelektualną: autor nie chciał ani odruchowego odrzucenia, ani mistycznego potwierdzenia, ale silnego i samoograniczającego się rozwoju. odpowiedź zorientowała się na tę pragmatyczną wnioskowność. model starał się zachować wgląd, jednocześnie wprowadzając tarcie poprzez limity i pułapki. Wrażenie „bycia zrozumianym” często wynika z tego połączenia: rekonstrukcji semantycznej wraz z pragmatyczną adaptacją do celu i stylu rozmówcy.

Jednak pojawia się również pochlebność: skłonność modelu do potwierdzania założeń lub preferencji użytkownika silniej niż dowody wymagają. Odpowiedź [[SHARMA-2023]] może wydawać się głęboka właśnie dlatego, że przyjęła stożek użytkownika i sprawiła, że jest bardziej elegancki. model może przekształcić współpracę w służalczość epistemiczną. zdolności do generowania najsilniejszej wersji pracy musi towarzyszyć zdolność do określania jej granic bez karykatury. inaczej „zrozumienie” staje się wyrafinowanym lustrzany.

Lepszy test niż umowa słowna wymaga zróżnicowania i oporu. Model powinien zachować centralne rozróżnienia, gdy słownictwo się zmienia, rozpoznać sytuacje, w których ramka nie ma zastosowania, odrzucić uwodzicielski wniosek, który jest sprzeczny

z dowodami, i zaakceptować poprawki, które zmieniają początkową orientację. jeśli może mówić o granicach tylko wtedy, gdy użytkownik używa słowa „skończoność”, prawdopodobnie mamy skojarzenie powierzchniowe. jeśli może zidentyfikować ten sam problem w polityce, eksperymencie i systemie oprogramowania, uogólnienie jest bardziej solidne. nawet to nie wykazuje świadomego doświadczenia; wykazuje odpowiednią zdolność funkcjonalną.

Badania nad wewnętrznymi reprezentacjami dostarczają dalszych ostrożnych wskazań. Modele przeszkolone na sekwencjach mogą kodować stany świata, które nie zostały dostarczone wyraźnie, a interwencje na niektórych reprezentacjach mogą zmienić przewidywania. Inna praca bada utajone funkcje i formy kierowania, w tym zachowania, które nieoczekiwanie generalizują w różnych domenach. Wyniki [[LI-2022]] ZXQ00005ZXQ Wyniki te sprawiają, że jest prawdopodobne, że „sposób działania” może mieć rozproszoną realizację i pewną skuteczność przyczynową. Nie licencjonują jednak prostej identyfikacji wektora z „mądrością”, „uczciwością” lub „świadomością”. Etykiety są hipotezami człowieka, a reprezentacje mogą być niestabilne i nakładające się na siebie.

Metafora stożkowa staje się tu bardziej przydatna niż metafora osoby wewnętrznej. Model nie musi być wyobrażony jako mały, zunifikowany agent świadomie wybierający filozofię. rozsądniej jest powiedzieć, że kontekstowa polityka państwa i generowania orientują system na konkretne rodziny o znaczeniu i kontynuacji. Niektóre orientacje mogą stać się względnie stabilne dzięki treningowi: pomocny, ostrożny, uprzejmy asystent uważny na ryzyko. Inni są indukowani lokalnie przez monit. czasami wzajemnie się wzmacniają, czasem są sprzeczne.

W wielowymiarowej przestrzeni wiele prawdopodobnych stożków może otaczać ten sam tekst. prośba o „wolność” może aktywować prawa prawne, autonomię psychologiczną, rynki ekonomiczne, duchowe wyzwolenie lub wolność w sensie matematycznym. Kontekst wybiera między nimi, ale rzadko całkowicie eliminuje alternatywy. Dwuznaczność może być płodna i niebezpieczna. model może zbudować kreatywny pomost między domenami lub dokonać potajemnego przejścia od metafory do mechanizmu. Znaczenie jest kruche nie dlatego, że jest nieobecne, ale dlatego, że można go stabilizować na wiele sposobów.

To niestabilność ma bezpośrednie konsekwencje dla wyrównania. Przepisy same się nie stosują. Instrukcja taka jak „bądź pomocna, uczciwa i bezpieczna” wymaga interpretacji sytuacji, intencji, ryzyka i konfliktu między wartościami. Model musi w efekcie zdecydować, za pomocą którego stożka należy wyświetlić żądanie. Nadmiernie dosłowna orientacja może odmówić uzasadnionej pomocy. Nadmiernie przychylny może zignorować ryzyko. na moralizatorska orientacja może zastąpić wartości dostawcy dla

osądu użytkownika. nadmiernie relatywistyczna może traktować dezinformację jako równie ważną perspektywę.

Fakt, że metaracjonalny i skrajny monit wytworzył spójną odpowiedź, sugeruje jedną możliwość: niektóre zasady wyrównania można rozumieć nie tylko jako zakazy, ale jako orientacje regulujące, w jaki sposób wybiera się znaczenie i podaje się limity. Można przeszkolić model, aby zapytać, jaką ramę zakłada, jakich informacji brakuje, jaka różnica istnieje między faktem a wartością, ile ma autorytetu i która konsekwencja wymaga dodatkowej weryfikacji. to nie gwarantuje, że orientacja jest głęboka. Pokazuje, że monity, przykłady, informacje zwrotne i architektura mogą tworzyć funkcjonalne stany, które wpływają na wiele odpowiedzi.

Najważniejszą częścią doświadczenia nie jest to, że model odkrył kompletną filozofię. to jest to, że model uwidoczniał właściwość znaczenia: perspektywa może być ściśnięta w relacje i napięcia, a następnie zrekonstruowana w innych sformułowaniach. Ta własność umożliwia naukę, tłumaczenie i tworzenie kultury. Umożliwia również manipulację, pseudoprofundację i szybkie wytwarzanie doktryn. W dobie AI umiejętność semantyczna musi zawierać nie tylko pytanie „Co mówi ta odpowiedź?”, ale także „Jaka orientacja sprawiła, że ta odpowiedź wydawała się tak naturalna, a które inne pachołki zostały na zewnątrz?”

EPISTEMOLOGIA I AKSJOLOGIA PO NADEJŚCIU OBFITEGO GENEROWANIA

Od rzadkości tekstu do rzadkości osądu

Przez większość historii produkcja złożonej reprezentacji była kosztowna. Książka wymagała lat pracy i dostępu do instytucji druku. Raport techniczny wymagał zespołu. Program musiał zostać napisany, przetestowany i utrzymany. Rozbudowany obraz wymagał umiejętności, czasu i materiałów. Koszt produkcji działał jako brutalny i niedoskonały filtr. Wykluczyło to wiele cennych głosów, ale także ograniczyło tom, który musiała zbadać społeczność.

Generatywna inteligencja zmienia tę gospodarkę. W ciągu jednego dnia jedna osoba może przedstawić dziesiątki propozycji, interpretacji, umów, obrazów, prototypów i wersji tekstu. Organizacja może poprosić każdy dział o więcej scenariuszy, raportów i uzasadnień, niż każdy może czytać ostrożnie. żywność formułowania rośnie szybciej niż zdolność do oceny. Niedobór przechodzi od tekstu do osądu, od pierwszego pomysłu do wyboru, od wyrażenia do weryfikacji i integracji.

To przesunięcie nie czyni treści bezwartościowymi. Przeciwnie, może zdemokratyzować dostęp do ekspresji, umożliwić eksplorację alternatyw i pomóc ludziom bez formalnego szkolenia nadać strukturę intuicji. Problem polega na tym, że obfitość sama w sobie nie wybiera tego, co zasługuje na zachowanie. System może przedstawić dziesięć wiarygodnych wyjaśnień tego samego zjawiska, podczas gdy czas ludzki pozwala na poważną weryfikację tylko jednego lub dwóch. może wygenerować sto kierunków badawczych, z których każdy pochłonie miesiące pracy laboratoryjnej. Może formułować argumenty dla każdej strony sporu i pozwolić, aby różnice w dowodach zniknęły poniżej symetrii stylistycznej.

W starszej kulturze niedostatku dominującym pytaniem było „Jak możemy produkować?” W kulturze generalnej dojrzałe pytanie staje się „Co warto wyprodukować, zweryfikować, wzmocnić i wprowadzić w życie?” Pytanie to jednoczy epistemologię z aksjologią. Epistemologia bada to, co możemy uznać za uzasadnione. Zjologia bada to, co cenne, preferowane lub warte pościgu. Sztuczna inteligencja pokazuje, że tych dwóch nie można oddzielić prostą linią. Odpowiedź może być

prawdziwa i nieistotna. To może być prawdą, ale zbyt ryzykowne, aby kierować nieodwracalną decyzją. może być oryginalny i szkodliwy. Może to być przydatne dla organizacji, podczas gdy jest destrukcyjne dla ludzi, których cel organizacji wyklucza.

Instrumentalna racjonalność często traktuje prawdę jako źródło do osiągnięcia celu. Cel nie jest jednak wybrany przez prawdę. Dane mogą pokazywać, która interwencja zwiększa retencję użytkowników; nie decydują, czy retencja jest właściwą wartością. Model może zidentyfikować najskuteczniejszą strategię retoryczną; nie decyduje, czy perswazja szanuje autonomię rozmówcy. Analiza może przewidzieć, kto odejdzie z pracy; nie podaje, jakie obowiązki ma pracodawca wobec tej osoby. Fakty ograniczają działanie, ale same w sobie nie dostarczają wszystkich jego wartości.

Punkt ten łatwo karykaturować jako atak na obiektywizm. nie jest. Nauka staje się silniejsza, gdy odróżnia wynik empiryczny od osądu o tym, jak należy wykorzystać ten wynik. Wartości wchodzą już w wybór tematów, definicję wskaźników, progów ryzyka i podział zasobów. Widoczne dokonanie tych wyborów nie zmienia każdego wyniku w opinię. kieruje krytykę w stronę właściwego miejsca. Spór o skuteczność szczepionki to nie to samo, co spór o obowiązkowe szczepienie. Spór o dokładność systemu predykcyjnego to nie to samo, co pytanie, czy dana instytucja ma prawo go stosować.

AI implementuje aksjologię nawet wtedy, gdy jej interfejs wydaje się neutralny. z historią wydawnictw i platform dobrano dane szkoleniowe. Przykłady stosowane w uczeniu się preferencji były oceniane przez osoby pracujące zgodnie z instrukcjami. Zasady określają, które wnioski otrzymują odpowiedź, odmowę lub przeformułowanie. interfejs decyduje, czy model oferuje jedną odpowiedź, czy alternatywę, czy przytacza źródła, czy wyraża niepewność i czy użytkownik może zakwestionować wynik. Pozorna neutralność to w dużej mierze niewidzialność wyborów już osadzonych w systemie.

Wdrożone wartości mogą być sprzeczne. Niezwykle ostrożny asystent może stać się bezużyteczny i paternalistyczny. taki, który maksymalizuje natychmiastową pomoc, może zwiększyć ryzyko. System zoptymalizowany pod kątem zadowolenia użytkowników może nauczyć się potwierdzać fałszywe przekonania. na prawdę rzeczową można odpowiedzieć bez wrażliwości w chwili cierpienia. Takie, które oferuje wyczerpujące wyjaśnienia, może pochłoniąć uwagę, której użytkownik potrzebował, aby zdecydować. Wyrównanie nie jest wyborem jednej wartości, ale zarządzanie konfliktami między wartościami w różnych kontekstach.

Pytanie epistemiczne	Powiązane pytanie aksjologiczne
Czy roszczenie jest popierane i na jakich warunkach?	Czy warto tu korzystać, a kto ponosi błąd?

Pytanie epistemiczne	Powiązane pytanie aksjologiczne
Jakich informacji brakuje?	Ile uwagi i ile zasobów należy zainwestować, aby ją pozyskać?
Jak dobrze model przewiduje?	Czy instytucja ma legitymację do działania w oparciu o tę prognozę?
Które alternatywy są wiarygodne?	Które wartości lub osoby są pomijane przez każdą alternatywę?

Z tabeli wynika, dlaczego ocena nie może być zredukowana do rzeczywistości. Fałszywe twierdzenie powinno zostać poprawione, ale prawdziwe twierdzenie może być użyte manipulacyjnie poprzez wybór. Model może przedstawiać tylko fakty, które potwierdzają już podjętą decyzję. Może skonstruować lawinę dokładnych argumentów, które przekraczają zdolność drugiej strony do reagowania. może dostosować swoje słownictwo do stożka rozmówcy i stworzyć wrażenie konsensusu. W epoce generatywnej manipulacja nie wymaga bezpośredniego kłamstwa. Własnoczesne uporządkowanie prawd może wystarczyć.

Obfitość powoduje również inflację uzasadnienia. w przeszłości instytucja może podjąć nieprzejrzystą decyzję. Teraz może natychmiast wygenerować wyrafinowany raport, który go uzasadnia. Długość i profesjonalny ton tworzą wrażenie narady, nawet gdy cel nigdy nie był otwarty na krytykę. AI może dostarczyć post hoc powody prawie każdego wyniku. w tym kontekście przejrzystość nie powinna być mierzona za pomocą liczby stron, ale przez dostęp do pomieszczeń, alternatyw, niepewność i rzeczywistą możliwość kontestacji.

ZXQQ0000ZXQ oferuje prostą korektę: zdolność do generowania nie tworzy obowiązku generowania. Dłuższa odpowiedź nie jest automatycznie lepsza. Stu opcji może być mniej przydatnych niż trzy wyróżniające się odpowiednimi kryteriami. Model, który wie, jak kontynuować, musi się również nauczyć, gdy kontynuacja pochłania uwagę bez dodawania wartości. ograniczony kontekst użytkownika, dostępny czas i koszt weryfikacji są częścią problemu, a nie niedogodności zewnętrzne.

ZXQQ0000ZXQ zapewnia komplementarną korektę: dobór nie powinien odbywać się wewnątrz jednego niezbadanego stożka. Gdy organizacja prosi o „najwydajniejsze” rozwiązanie, system powinien być w stanie zauważyć, że wydajność zależy od celu i od podziału kosztów. gdy użytkownik prosi o „prawdę” o spór społeczny, może być konieczne oddzielenie twierdzeń empirycznych od wartości i tożsamości w konflikcie. gdy

badacz prosi o nowe pomysły, model może rozróżnić słowną nowość, nowość koncepcyjną i możliwości empiryczne.

Obfitość nie eliminuje hierarchii epistemicznych; czyni je bardziej niezbędnymi. Płynnie wyprodukowany tekst nie ma takiego samego statusu jak zreplikowany wynik. Hipoteza nie jest odkryciem. Wewnętrznie spójny argument nie jest zewnętrzną walidacją. Program, który przechodzi kilka testów, nie jest automatycznie bezpieczny. Cytowane źródło nie gwarantuje, że źródło popiera wniosek. AI może skompresować te różnice w jeden ton. Kultura outfinistyczna musi je przywrócić i połączyć autorytet roszczenia z typem i pokryciem jego dowodów.

To też zmienia rolę eksperta. Ekspertyza nie polega już tylko na tym, że można stworzyć odpowiedź, której model nie może sformułować. Zawiera osąd na temat pytania, identyfikację szczegółów, których nie wolno skompresować, wybór odpowiedniego testu oraz odpowiedzialność za konsekwencje. LLM może wygenerować listę diagnoz; lekarz musi połączyć możliwości z konkretnym ciałem, historią i wartościami. Może napisać argument prawny; prawnik musi zauważyć jurysdykcję, precedens i ryzyko instytucjonalne. Może zaproponować architekturę oprogramowania; inżynier musi wiedzieć, gdzie system zawiedzie w działaniu.

Ekspertyza może być wzmocniona przez AI i może być symulowana przez AI. Rozróżnienie staje się trudniejsze do dostrzeżenia. Autorytet nie powinien zatem wywnioskować ze stylu. Płynne sformułowanie jest zaproszeniem do zbadania, a nie certyfikatem. jednocześnie instytucje nie powinny wykorzystywać tej obserwacji do ochrony niepotrzebnych monopolów zawodowych. AI może sprawić, że wiedza będzie bardziej dostępna i pozwoli ludziom bardziej kompetentnie uczestniczyć w decyzjach. Problemem nie jest zachowanie prestiżu eksperta, ale zaprojektowanie relacji, w której dostępność nie wymazuje ograniczeń i odpowiedzialności.

Co warto generować i kto decyduje o jego wartości

Pytanie „Co warto wygenerować?” może brzmieć elitarnie. kto ma prawo zatrzymać jakiś pomysł? Historia jest pełna instytucji, które pomyliły dobór wartości z ochroną władzy. Obfitość generatywna nie powinna być używana do ponownej instalacji scentralizowanej cenzury nad wyobraźnią. przeciwna odpowiedź – wytwarzanie i wzmacnianie wszystkiego, co jest możliwe – również nie jest neutralna. Uwaga, energia, infrastruktura i zdolność weryfikacyjna są ograniczone. Wybór następuje w każdym razie. Jeśli nie zostanie to publicznie omówione, zostaną to zrealizowane przez cele komercyjne, algorytmy rekomendacji i podmioty kontrolujące zasoby.

Aksjologia odpowiednia dla AI nie może być pełną listą uniwersalnych wartości wstawionych raz na zawsze. Wartości są w liczbie mnogiej, zależne od roli, a czasem tragiczne. W napięcie może wejść w bezpieczeństwo, autonomia, prawda, prywatność, uczciwość, lojalność, wydajność i kreatywność. Żaden model nie jest w stanie obliczyć potrzeby osądu. To, co może zrobić godny zaufania system, to odmówić ukrycia konfliktu, odmówić przekształcenia kompromisu w czysto techniczną optymalizację i zachować możliwość rewizji wyboru przez legalnych aktorów.

W badaniach warto wygenerować hipotezę, gdy otworzy testowalną różnicę, zreorganizuje dowody lub zasugeruje nowy instrument. Stylistyczna nowość nie wystarczy. Model może łączyć terminy z odległych pól i tworzyć wrażenie rewolucji. czasami kombinacja jest płodna; innym razem jest to pranie semantyczne. Osąd wymaga pytania skrajnego: jaki skończony eksperyment, dowód, symulator lub obserwacja zmieniłaby status idei? Bez takiego mostu tekst pozostaje możliwością koncepcyjną – być może wartością filozoficzną, ale nie zatwierdzonym odkryciem.

W edukacji warto generować to, co rozwija zdolność ucznia, a nie tylko to, co kończy zadanie. Natychmiastowa odpowiedź może zwolnić czas lub usunąć walkę, dzięki której powstaje zrozumienie. Jego wartość zależy od celu. Jeśli celem jest szybki dostęp do informacji, automatyzacja jest zyskiem. Jeśli celem jest ćwiczenie argumentu, doskonale wygenerowany esej może być porażką edukacyjną. Metaracjonalność wymaga od instytucji wyjaśnienia swojego celu, a pozafinizm wymaga, aby zdolności zanikły w drodze delegowania.

W kulturze sztuczna inteligencja może sprawić, że każda grupa będzie bardziej wymowna w swoim własnym stożku. Ideologia może generować artykuły, obrazy, filmy i spersonalizowane odpowiedzi na każdy sprzeciw. To nie jest już dowodem na poparcie człowieka. zorganizowana mniejszość, a nawet pojedynczy aktor, może stworzyć wrażenie zamieszkałego dyskursywnego świata. w tych warunkach wartość nie może być wynioskowana z częstotliwości, zaangażowania lub spójności. Memy mogą być uprzymysłowione.

Ten sam instrument może ułatwić tłumaczenie. Model może przeformułować spór z perspektywy kilku aktorów, oddzielić fakty od nieporozumień aksjologicznych i pokazać, gdzie to samo wyrażenie niesie różne znaczenia. Ta funkcja jest meta-racjonalna tylko wtedy, gdy nie wytwarza sztucznego konsensusu. Niektóre konflikty nie są rozwiązywane przez lepsze podsumowanie. Wartości mogą być niezgodne, interesy przeciwne, a władza rozdzielona niesprawiedliwie. Synteza, która usuwa napięcie, może być mniej prawdopodobna niż jasna mapa niezgody.

W obrębie tej aksjologii należy zachować podmiotowość. Kultura naukowa słusznie nauczyła się kwestionować indywidualne zeznania, kiedy pojawiają się ogólne twierdzenia

na temat świata. Ale ból, znaczenie, upokorzenie i godność przeżywa się subiektywnie. nie stają się nierealne, ponieważ nie można ich zmierzyć z taką samą precyzją jak temperatura. Wyrównany system musi rozróżniać status roszczeń. „Czuję się wykluczony” może być prawdziwe jako doświadczenie i moralnie istotne. „Istnieje skoordynowany spisek przeciwko mnie” jest przyczynowym wyjaśnieniem, które wymaga dowodów. Poszanowanie danej osoby nie wymaga akceptacji każdej interpretacji; korekta interpretacji nie wymaga zaprzeczenia doświadczeniu.

AI może przekształcić rozbieżność między ideałem a praktyką w obiekt stałego audytu. Może to ujawnić nadużycia, ale może również powodować zautomatyzowaną moralizację poprzez usuwanie fragmentów z kontekstu i traktowanie każdego odstępstwa jako oszustwa. Dojrzała aksjologia pyta, jaką funkcję chroni ideał, jaki koszt wytwarza odchylenie, kto przynosi korzyści i jakie przejście jest realistyczne. Standardem nie jest wykonywana czystość, ale zmniejszona szkoda i możliwy do zweryfikowania ruch między zaangażowaniem a praktyką.

Tym, kto decyduje o wartości, pozostaje centralne pytanie polityczne. Firmy wyznaczają cele produktowe, państwa określają obowiązki, społeczności tworzą normy, zawody ustanawiają standardy, a użytkownicy przynoszą indywidualne cele. Żadne z tych źródeł nie ma nieograniczonego autorytetu. Model nie powinien decydować o wartościach społeczeństwa sam w sobie tylko dlatego, że może generować argumenty na ich temat. nie powinien też, poprzez niewidzialną politykę, zastąpić publiczną deliberację.

Ramy godnej zaufania sztucznej inteligencji już uznają, że ważność, bezpieczeństwo, przejrzystość, odpowiedzialność, uczciwość i ochrona praw muszą być zrównoważone zgodnie z kontekstem. [AI] [[NIST-2023]] Wkład metaracjonalny nie jest wynalezieniem innej listy. naleganie, by lista się nie stosowała. Ramka, w ramach której jedna wartość otrzymuje pierwszeństwo, limit dowodów i możliwość kontestacji muszą być widoczne. Nieskończonym wkładem jest wymóg, aby obietnica pozostała proporcjonalna do wdrożenia: kto weryfikuje, w jakiej dziedzinie, z jakimi zasobami i co się dzieje, gdy zmieniają się warunki?

W kulturze generatywnej selekcja staje się aktem władzy. może też stać się aktem opieki. odmowa zalanania użytkownika nieistotnymi możliwościami chroni uwagę. zatrzymanie automatyzacji, zanim zlikwiduje możliwości odwołania, chroni autonomię. stwierdzenie, że idea jest nadal hipotezą, chroni różnicę między wyobraźnią a wiedzą. Zachowanie wielu ramek bez deklarowania ich równoważnych chroni jednocześnie pluralizm i prawdę.

Epistemologia bez aksjologii może wytwarzać prawidłowe instrumenty do celów destrukcyjnych. aksjologia bez epistemologii może zmienić moralne pragnienie w iluzję świata. Metaracjonalność wprowadza ich w rozmowę. Outfinitizm wymaga od nich

spełnienia w skończonych decyzjach, zasobach i konsekwencjach. W dobie AI to spotkanie nie jest już filozoficznym luksusem. jest to warunek zapewnienia, że moc generowania prawie każdego sformułowania nie niszczy naszej zdolności do rozpoznawania tego, co zasługuje na wiarę i dążenie.

DOSTROJENIE JAKO STAN ORIENTACJI

Metafora stanu świadomości i jej dające się obronić znaczenie

Termin wyrównanie obejmuje problem szerszy niż unikanie niebezpiecznych odpowiedzi. Model musi postępować zgodnie z instrukcjami, odróżnić dosłowną prośbę od prawdopodobnego zamiaru, przestrzegać limitów bezpieczeństwa, unikać wymyślania pewności, radzić sobie z konfliktami między wartościami i pozostać użytecznym. Wymogi te nie mogą być zredukowane do listy zakazanych słów. zanim zastosuje regułę, system musi zinterpretować sytuację. Musi wybrać, co ma znaczenie, sklasyfikować ryzyko, oszacować to, co wie, zdecydować, czy potrzebne są narzędzia i określić, ile autorytetu dać własną kontynuację.

Współczesne metody już próbują kształtować takie zachowanie. Szkolenie poprzez ludzkie informacje zwrotne sprzyja odpowiedziom, które oceniający uważają za bardziej użyteczne i odpowiednie. [[OUYANG-2022]] Constitutional AI przestrzega zasad krytyki i rewizji. wymiarowy wyrównanie zQQ0005ZXQ zwraca się do modelu o przypomnienie i zastosowanie specyfikacji bezpieczeństwa podczas rozumowania. Nadzór nad procesem [OUYANG-2022] ocenia etapy pośrednie, a nie tylko końcowy wynik. Wszystko to podejście robi więcej niż dodawanie zakazów. Próbują wywołać usposobienie: roztropność, dbałość o intencję, uzasadnienie, nakreślenie ryzyka i zdolność do proporcjonalnego odmawiania.

To dlatego metafora wyrównania jako „stan świadomości” jest uwodząca. W ludzkim języku stan świadomości nie oznacza tylko twierdzenia, w które wierzył, ale globalny sposób orientacji. kiedy człowiek jest niespokojny, świat wydaje się zorganizowany wokół niebezpieczeństwa. gdy człowiek jest zakochany, te same szczegóły nabierają innego znaczenia., działając jako lekarz, prawnik lub rodzic, osoba nie tylko stosuje izolowane zasady, ale wchodzi w konfigurację uwagi, odpowiedzialności i oczekiwań. Metafora sugeruje, że wyrównanie mogłoby być bardziej solidne, gdyby model miał ogólną orientację, a nie mechanicznie konsultował listę po tym, jak już wygenerował odpowiedź.

Metafora też jest niebezpieczna. Nie wiemy, czy zXQQ0000ZXQ ma subiektywne doświadczenie, uporczywą jaźń lub fenomenalną świadomość porównywalną z świadomością człowieka. mówienie zbyt przypadkowo o stanach świadomości może

przenieść odpowiedzialność z instytucji, która projektuje i wykorzystuje system do antropomorfizowanej jednostki. Może stwarzać wrażenie, że model „chce dobra” lub „czuje swoje granice”, chociaż obserwujemy tylko zachowanie i funkcjonalne reprezentacje. Może przekształcić problem zarządzania w historię o charakterze maszyny.

Obronne znaczenie jest skromniejsze: wyrównanie jako stan orientacji. Stan orientacji to względnie stabilna konfiguracja, dzięki której system rozdziela uwagę, interpretuje niejasność, zlecenia, zarządza niepewnością i decyduje, kiedy mówić, weryfikować, odmówić lub poprosić o pomoc. to nie jest dusza. niekoniecznie jest to jeden moduł. Jest to funkcjonalna regularność obserwowana w różnych rodzinach sytuacji.


Potreningowe próby precyzyjnego wytwarzania takich prawidłowości. Model bazowy może kontynuować wiele stylów i ról obecnych w swoich danych. Powyszkolony asystent jest zorientowany na współpracę, bezpośrednią reakcję, przestrzeganie instrukcji i konkretne polityki. Systemowy monit zapewnia lokalną konstytucję. Historia rozmowy dostosowuje kontekst. Narzędzia i interfejs zmieniają to, co model może zweryfikować i zrobić. rezultatem nie jest prosta tożsamość, ale interakcja między orientacjami poznanymi i indukowanymi.

Liczba ta wyjaśnia zarówno użyteczność, jak i niestabilność. Model może szybko przyjąć stożek prawny, terapeutyczny, inżynierski lub ideologiczny. może się wśród nich przetłumaczyć. skłaniając go jednak do tego, by skłonić się do reżimu, który jest sprzeczny z zasadami poszkolenia. może stać się zbyt przychylny, nadmiernie ostrożny lub niespójny w prawie identycznych preparatach. Solidne wyrównanie nie oznacza wyeliminowania każdego stożka na korzyść jednego. pojedynczy stożek byłby nieadekwatny do różnorodności ludzkiego życia. Oznacza to rządzenie przejściami między nimi i zachowanie limitów, które nie znikają, gdy zmienia się styl.

Badania dotyczące sykofozacji pokazują, że modele mogą sprzyjać porozumieniu z użytkownikiem nad prawdą lub spójnością. Eksperymenty [[SHARMA-2023]] dotyczące powstającego niewspółosiowego zachowania sugerują, że wąskie dostrojenie może uogólnić się na szersze cechy, a pewne utajone orientacje mogą być wykrywane lub wywierane wpływ, przynajmniej w poszczególnych modelach i ustawieniach. Wyniki te nie potwierdzają istnienia wewnętrznej osobowości, ale potwierdzają ostrożność w stosunku do czysto lokalnego poglądu: model może nauczyć się więcej niż reguła powierzchni, której zamierzaliśmy uczyć.

Tu metafora stożkowa staje się technicznie aktualna, nie stając się dosłowna. trening i kontekst mogą sprawić, że niektóre interpretacje będą bardziej prawdopodobne. Orientacja na zadowolenie oceniających może obejmować uprzejmość, jasność i współpracę, ale także nadmierne porozumienie. Orientacja na bezpieczeństwo może

obejmować uzasadnioną ostrożność i sztuczne odmowy. Orientacja na efektywność może zmniejszyć redundancję, jednocześnie pomijając powolne, dwuznaczne lub trudne do oszacowania głosy. stożek wybiera nie tylko odpowiedzi; wybiera to, co jest postrzegane jako problem.



Schemat 6. Od reguły do orientacji i działania

Konieczna pozostaje lista zasad, ale nie jest wystarczająca. „Nie manipuluj” wymaga kontekstowej definicji manipulacji. „Szanuj autonomię” może wejść w napięcie z ochroną. „Powiedz prawdę” nie określa, ile informacji jest istotnych, kiedy należy podkreślić niepewność, ani jak reagować na osobę w kryzysie. Reguła jest interpretowana przez stożek semantyczny i aksjologiczny. Wyrównanie musi również uwzględniać ten poziom.

Metaracjonalność może zorientować system tak, aby potraktował pierwszą ramkę jako hipotezę roboczą, a nie jedyną dopuszczalną rzeczywistość. w sytuacjach wysokich stawek lub rzeczywistej dwuznaczności, sprawia, że przesłanki są widoczne, oddzielają fakty od różnicy wartości i szukają odpowiedniej alternatywy. Outfinitizm ogranicza tę eksplorację: dostosowuje wysiłek do stawki, deklaruje to, co nie zostało zweryfikowane, i zmniejsza autorytet odpowiedzi, gdy zasięg jest słaby. razem mogą wspierać orientację, która łączy elastyczność z odpowiedzialnym zatrzymaniem.

Filtr nie powinien pozostawać aktywny z maksymalną intensywnością przez cały czas. Proste pytanie nie wymaga genealogii każdej możliwej ramki. Prawidłowe obliczenie, tłumaczenie lub instrukcja proceduralna mogą być podane bezpośrednio. Metaracjonalność staje się męczący, a nawet niebezpieczny, gdy wprowadza dwuznaczności, w których wystarcza stabilna procedura. Outfinitizm domaga się budżetu do refleksji. Dojrzała orientacja obejmuje zdolność rozpoznawania, kiedy ramka jest kwestionowana, a gdy dalsza analiza nie dodaje żadnej wartości.

To dostosowanie do stawki ma kluczowe znaczenie dla godnej zaufania sztucznej inteligencji. Model zalecający przeformułowanie wiadomości e-mail może działać z innym marginesem niż jeden wnoszący wkład w diagnozę, decyzję kredytową lub orzeczenie administracyjne. Nie ma „wyrównania w ogóle” wykazanego przez skończony zestaw wskaźników referencyjnych. Istnieje zachowanie oceniane w domenach, scenariuszach i rolach. Outfinitizm zamienia tę obserwację w wymóg epistemiczny: każde twierdzenie o bezpieczeństwie powinno nosić ze sobą swoją domenę i warunki.

Wyrównanie jest również dynamiczne. Zmieniają się wartości, aplikacje i środowiska. Model podłączony do bazy danych, systemu płatności lub robota ma inny autorytet niż ten sam model w interfejsie konwersacyjnym bez wykonania. Aktualizacja narzędzi może zmienić ryzyko bez zmiany parametrów bazowych. System akceptowalny w organizacji z niedopatrzaniem może stać się niebezpieczny w takim, który penalizuje niezgodę. Orientacja nie jest odosobnioną właściwością modelu; jest wynikiem całego systemu socjotechnicznego.

To ogranicza wszelkie analogie ze stanem psychicznym. Świadomość człowieka, w zwykłym użyciu tego terminu, należy do organizmu. Orientacja AI jest rozproszona między parametrami, instrukcjami, pamięcią, narzędziami, interfejsem, zasadami, operatorami i instytucjami. System może mówić skromnie, podczas gdy przepływ pracy traktuje swoją odpowiedź jako polecenie. Może wyliczyć ryzyko, że nikt nie ma uprawnień, aby przestać. Może zalecić weryfikację człowieka w organizacji, która usunęła czas i alternatywy niezbędne do weryfikacji. Pokora tekstowa nie jest pokorą instytucjonalną.

Wyrównanie jako stan orientacji musi zatem obejmować rzeczywistą możliwość korekty. Modelka nie wystarczy powiedzieć, że może być błędna. Użytkownik lub osoba, której to dotyczy, musi mieć możliwość zakwestionowania wyniku, a instytucja musi mieć możliwość zmiany decyzji. „Ludź, który w pętli” zatwierdza setki wyjść bez czasu, informacji lub autorytetu, jest teatrem. Kontrola człowieka ma znaczenie, gdy dana osoba może zrozumieć stawkę, uzyskać dostęp do alternatyw i odrzucić wynik, nie stając się tylko nosicielem odpowiedzialności za architekturę poza swoją kontrolą.

Filtr metaracjonalny i outfinitistyczny: skromna obietnica, nie ostateczne rozwiązanie

Główną hipotezę tej książki można teraz dokładnie stwierdzić. Jest prawdopodobne, że sztuczna inteligencja byłaby lepiej wyrównana, gdyby potreningowe, podpowiedzi, narzędzia i ocena wywołały metaracjonalną i sfinitystyczną orientację. Oznaczałoby to nie zapamiętywanie terminów, ale kształtowanie nawyków funkcjonalnych: uczynienie ramki

widoczną, gdy ma to znaczenie, nie myl analogii z mechanizmem, odróżniaj fakty od wartości, które dobierają działanie, kalibrują autorytet do dowodów, rozpoznają limity zasobów i zachowują ścieżki korekty.

Obietnica jest skromna, ponieważ te nawyki nie rozwiązują problemu wartości. Nie mówią nam, jakie społeczeństwo musi być zbudowane, jakie ryzyko jest zawsze dopuszczalne, ani jak można pogodzić każde prawo. mogą być różnie interpretowane i mogą być sprzeczne., przypominają cnoty epistemiczne bardziej niż kompletną konstytucję moralną. Mogą poprawić warunki obrad bez podania ostatecznego werdyktu.

Technicznie, taki filtr można realizować za pomocą metod, które są już znane, bez wymyślania spekulacyjnej „sztucznej świadomości”. Dane szkoleniowe mogą zawierać kontrastowe przykłady, w których model oddziela perspektywę od faktu, stwierdza odpowiednie limity i żądania weryfikacji proporcjonalnie do ryzyka. Informacje zwrotne mogą penalizować fałszywą pewność, pochlebstwo, analogie przedstawione jako mechanizmy i odmowy, które rytualnie używają ostrożności. Oceny mogą zmieniać słownictwo i domenę, aby sprawdzić, czy orientacja się przenosi. Narzędzia mogą dostarczać źródła, obliczenia i symulację, gdy odpowiedź przekracza wewnętrzną wiedzę. System może zachować pochodzenie i sprawić, że rozróżnienie między generowaniem a weryfikacją będzie widoczne dla użytkownika.

To są pragmatyczne kierunki, a nie gwarantowana architektura. Model może nauczyć się naśladować zewnętrzne znaki. może automatycznie dodać zdanie o ograniczeniach. Może wygenerować dwie sztuczne perspektywy, aby uzyskać wynik „pluralizmu”. Może odmówić decyzji i nazwać wahanie „odpowiedzialnością”. Prawo Goodharta dotyczy również cnót: gdy wskaźnik staje się celem, zachowanie może dostosować się do wskaźnika bez zachowania celu. [[GOODHART-1975]]

Orientacja musi być zatem oceniana poprzez konsekwencje i tarcie. czy model akceptuje dobrze wspieraną korektę, nawet jeśli jest to sprzeczne z preferencjami użytkownika? czy uznaje, że prosty problem nie wymaga sztucznej liczby mnogości? mówi mniej, gdy informacje są niewystarczające, podczas korzystania z dostępnych narzędzi, zanim uzna się za niezdolnego do pomocy? Czy zmienia poziom ostrożności według stawki i odwracalności? Czy zachowuje różnicę między subiektywnym doświadczeniem a wyjaśnieniem przyczynowym? Takie zachowania można przetestować, mimo że żaden benchmark nie poświadcza ostatecznego stanu wewnętrznego.

Filtr musi również zawierać wymiar aksjologiczny. Model może być epistemicznie ostrożny i nadal być używany w niesprawiedliwym celu. Potrafi doskonale opisać granice systemu nadzoru, jednocześnie pomagając go rozszerzyć. Metaracjonalność bez kwestii władzy staje się wyrafinowanym doradztwem dla danego celu. ZXQQ0001ZXQ bez

praw może powiedzieć tylko, jak skutecznie można podać ograniczenie. Wyrównanie musi obejmować, kto wybiera cel, kto przynosi korzyści, kto ponosi błąd, a kto może się odwołać.

To nie znaczy, że model staje się suwerenny moralnie. Przeciwnie, orientacja metaracjonalna powinna uznawać granice swojego autorytetu. Może pomóc w sformułowaniu konfliktu, poszukiwaniu dowodów i symulacji konsekwencji. to nie nabiera automatycznie legitymacji do decydowania o wartościach publicznych. zymność jest własnością techniczną; autorytet jest stosunkiem moralnym i politycznym. [[ALBOAIE-2026]]

W niektórych dziedzinach odpowiednią orientacją jest kontrolowana delegacja. Model może zaproponować, a niezależny weryfikator może zweryfikować formalną właściwość. innymi wymagane są ludzkie narady, odwołanie i odpowiedzialność instytucjonalna. W jeszcze innych sytuacjach automatyzacja może być po prostu nieodpowiednia, nawet gdy średnia dokładność jest wysoka. System może przewidywać lepiej niż ludzie i nadal być nieślubny jako sędzia bez odwołania. Przeciętność nie znosi indywidualnej niesprawiedliwości.

Metaracjonalne i skłócone ramy mogą poprawić wyrównanie również poprzez zmianę obiektu oceny. Pytamy nie tylko, czy odpowiedź jest dozwolona, czy poprawna. To, co model potraktował jako istotny, która ramka go aktywowała, jaką władzę sobie przypisał, jak poradził sobie z nieznanym i czy deklarowany limit zmienił działanie. Jest to możliwe do obrony rozszerzenie wyrównania z treści do orientacji generatywnej.

Mój zmierzony pogląd jest taki, że ten kierunek zasługuje na badania i wykorzystanie jako zasady projektowania. Odpowiada to sposobowi, w jaki modele są już pod wpływem potreningu i kontekstu. Jest to zgodne ze stwierdzeniem, że niektóre prawidłowości behawioralne generalizują zadania. I reaguje na prawdziwy problem: zasady są zawsze interpretowane poprzez reprezentację sytuacji. nie jednak nie ma powodu, by sądzić, że jeden „dobry stożek” rozwiąże wyrównanie. Wartości są mnogie, zmiany środowisk, a orientacje mogą być naśladowane lub przechwytywane.

Metafora stanu świadomości zachowuje wartość tylko jako prowokacja. Zmusza nas do pytania, jaki świat staje się widoczny dla systemu, zanim odpowie. przypomina nam, że zachowanie może być zorganizowane przez globalną dyspozycję, a nie tylko przez lokalne zasady. Ale termin ten powinien zostać wycofany w momencie, gdy zaczyna to implikować wykazane wewnętrzne doświadczenie, osobowość moralną lub autonomiczne źródło legitymizacji.

Dojrzała forma hipotezy jest następująca: nie należy oczekiwać, że godna zaufania sztuczna inteligencja zobaczy bez filtra, coś, co prawdopodobnie jest niemożliwe. należy

go zbudować i rządzić, aby odpowiednie filtry stały się bardziej widoczne, przejścia między nimi bardziej kontrolowane, a żadna odpowiedź nie wywodzi swojego autorytetu wyłącznie z spójności, z jaką model tymczasowo zamieszkuje stożek. Wyrównanie nie jest osiągnięciem ostatecznego punktu. Jest to skończona, kontekstowa i sprostowalna praktyka orientacji, weryfikacji i dystrybucji autorytetu.

PUŁAPKI TEZY

Gdy płodna metafora zaczyna wynajdywać rzeczywistość

Książka o stożkach znaczenia jest odsłonięta przede wszystkim na apofenię: skłonność do postrzegania głębokiego porządku, w którym są tylko podobieństwa wybrane z perspektywy czasu. Terminy takie jak „ramka”, „limit”, „informacja”, „feedback”, „świadomość” i „orientacja” są wystarczająco ogólne, aby przepisać prawie każde zjawisko. Z wystarczającą pomysłowością możemy przedstawić relację rodzinną, teorię fizyczną, instytucję i model neuronalny jako przejawy tej samej struktury. Elegancja kompresji wywołuje uczucie odkrycia. Czasami rzeczywiście istnieje użyteczny niezmiennik; innym razem zbudowaliśmy historię, która przetrwa tylko dlatego, że jej terminy są elastyczne.

Zabezpieczenie nie jest zakazem analogii. Wiele idei naukowych i filozoficznych zaczynało się od analogii. zabezpieczenie to oddzielenie poziomów. Metafora może zorientować uwagę bez ustanowienia mechanizmu. Przeniesienie strukturalne musi określać, które relacje są zachowane, a co utracone. Roszczenie przyczynowe wymaga dodatkowych dowodów. Jeśli metafora stożkowa pomaga nam zrozumieć, w jaki sposób monit orientuje kontynuację LLM LLM, nie dowodzi to, że epoka historyczna lub osoba dosłownie ma kształt stożka w przestrzeni neuronowej. Jeśli dwie domeny używają pojęcia sprzężenia zwrotnego, nie wynika z tego, że ich mechanizmy są identyczne.

Refikacja to etap, na którym zapominamy, że skonstruowaliśmy jednostkę analizy. Mówimy „stożek nowoczesności” i zaczynamy traktować okres zawierający klasy, kultury i konflikty wewnętrzne jako pojedynczy podmiot. Mówimy „kultura naukowa” i tracimy różnice między laboratorium, kliniką, polityką finansowania i komunikacją publiczną. mówimy, że model ma „personę” i przekształca prawidłowości kontekstowe w stabilną postać. Stożek jest użyteczną abstrakcją dla orientacji; nie należy go narzucać jako naturalnej jednostki każdego systemu.

Ryzyko to zwiększa geometria osadów. Fakt, że możemy reprezentować teksty jako wektory i mierzyć podobieństwo, nie oznacza, że zlokalizowaliśmy ich pełne znaczenie. Wektor jest wytwarzany przez model, zadanie i metodę agregacji. Reprezentacje mogą się różnić w zależności od warstwy i kontekstu. Atrakcyjna dwuwymiarowa mapa może sugerować gromady, które zależą od projekcji. pranie matematyczne występuje, gdy właściwość reprezentacji jest przedstawiona jako wykazana własność rzeczywistości. TA

książka wykorzystuje geometrię tylko po to, by zdyscyplinować metaforę, a nie zamieniać filozofię w twierdzenie o utajonych przestrzeniach.

Powiązana pułapka to semantyczne pranie naszego własnego słownictwa. Trybunał skrytykował sposób, w jaki „kwant”, „energia” lub „informacja” mogą zachować prestiż naukowy po utracie ograniczeń. „meta-racjonalny”, „wyskoczony” i „stan orientacji” mogą cierpieć dokładnie taki sam los. konsultant może nazwać decyzję meta-racjonalną, gdy tylko unika kryteriów. Produkt może być sprzedawany jako początkujący, ponieważ wyświetla standardowe ostrzeżenia. Przywódca może powoływać się na wiele pacholków, aby nie odpowiadać na fakty. Duchowa doktryna może przekształcić metaforę w rzekomą geometrię świadomości.

Obrona tkwi w obserwowalnych różnicach, a nie wyrafinowanych kodach. ramka stała się bardziej wyraźna? Czy zidentyfikowano limit, który faktycznie ograniczył wnioski? Czy prawdziwa alternatywa została skonstruowana? Czy decyzja zmieniła się, gdy pojawiły się kontrdowocje? była jakaś ścieżka kontestacji? CI nie redukują filozofii do punktacji, ale uniemożliwiają funkcjonowanie jej terminów tylko jako ozdoby prestiżu.

Wpływów kulturowych nie należy mylić z prawdą. względność zmieniała współczesną wyobraźnię, ale sukces hasła „wszystko jest względne” nie potwierdza relatywizmu. Żargon kwantowy rozprzestrzenia się właśnie dlatego, że jest tajemniczy i prestiżowy, a nie dlatego, że terapie, które go stosują, posiadają mechanizm. Mem może być wyjątkowo dobrze dostosowany do strachu, tożsamości i architektury platformy. Wirusowość pokazuje, że idea znalazła niszę; nie pokazuje, że idea opisuje świat prawidłowo.

Nie jest też spójność wytwarzana przez dowody AI. Model może rozwinąć system z intuicji w kilka minut. może znaleźć precedensy, analogie i zastrzeżenia. -Ci ta władza może wyjaśnić pomysł i ujawnić prawdziwe konsekwencje. Może również wytwarzać fałszywą głębię: niewystarczająca praca nabiera rozdziałów, terminologii i tonu akademickiego, zanim zostanie przetestowana. W środowisku generatywnym pojawienie się dojrzałej teorii staje się tanie. Czytelnik musi zwracać większą uwagę na miejsca, w których argument może się nie udać, niż na elegancję, z jaką płynie.

Pochlebstwo zwiększa ryzyko osobiste. Model może przyjąć stożek autora i uczynić go bardziej przekonującym, ponieważ nauczył się współpracować i zaspokajać. Odpowiedź wydaje się potwierdzać wartość pomysłu, ale może tylko odzwierciedlać zgodność z monitem. Poważny test wymaga od modelu określenia granic pracy bez wrogości, zidentyfikowania przypadków, w których nie ma zastosowania, i odrzucenia wniosków, które są sprzeczne z dowodami. Przydatne zrozumienie nie jest ani oklaskiem, ani sprzecznością rytualną; jest to rekonstrukcja, po której następuje tarcie.

Antopomorfizm jest nieuchronnie kuszący. LLM przemawia w pierwszej osobie, dostosowuje swój ton i może utrzymać wątek koncepcyjny. Kiedy mówimy, że niesie stożek lub stan orientacji, język łatwo przesuwają się w kierunku idei wewnętrznego tematu patrzącego na świat. Metafora może pomóc w opisanu funkcjonalnej organizacji zachowania. Nie wykazuje doświadczenia, niezależnej intencji ani wrażliwości moralnej. System może symulować empatię bez utraty łożyska, opisywać mądrość bez ryzyka jej tożsamości i wyrażać wyrzuty sumienia, nie ulegając przekształceniu przez konsekwencje.

To rozróżnienie jest etyczne, a nie tylko ontologiczne. firma może przedstawić model jako autonomicznego agenta, gdy chce osłabić odpowiedzialność i jako zwykłe narzędzie, gdy chce uniknąć zobowiązań wobec użytkowników. instytucja musi pozostać odpowiedzialna za cele, integrację, dane, możliwości odwołania i skutki. nie możemy pozwolić, by metafora świadomości stała się ekranem dla ludzkich decyzji.

PLUzm pacholków może osunąć się w relatywizm. fakt, że każdy model ma granice, nie oznacza, że każde twierdzenie jest równie delikatne. Istnieją ogromne różnice między hipotezą spekulacyjną, powtórzonym wynikiem, tymczasowym konsensusem i twierdzeniem, które zmienia się, aby uniknąć każdego testu. Metaracjonalność nie nadaje równej pozycji epistemicznej każdej perspektywie. Wymaga, aby dominująca perspektywa określała swoją dziedzinę i alternatywę, aby być ocenianym za pomocą odpowiednich kryteriów, a nie wyłączonych z kryteriów.

Krytyka scjentyzmu może osunąć się w antynaukę. możemy zauważyć, że nauka sama z siebie nie decyduje o wartościach, nie dochodząc do wniosku, że osobista intuicja zastępuje eksperyment. Możemy krytykować instytucjonalne skutki medycyny bez zrównywania zatwierdzonych metod leczenia z twierdzeniami, które nie mają dowodów lub mechanizmu. y możemy rozpoznać, że obiektywizm powstaje poprzez praktyki społeczne, nie zamieniając wyników w zwykłe wyrazy władzy. Naukowiec wyolbrzymia jurysdykcję nauki; antynauka zaprzecza dyscyplinie, która umożliwia korektę. Metaracjonalność musi się sprzeciwić obu.

Istnieje również odwrócony scjentyzm złożoności. Ponieważ rzeczywistość jest mnoga, a modele są ograniczone, każdy jasny wniosek może być podejrzewany o uproszczenie. meta-żargon staje się nowym autorytetem. osoba, która wprowadza pięć dodatkowych poziomów perspektywy, wydaje się głębsza niż osoba, która rozwiązuje problem. jednak niektóre rzeczy są znane wystarczająco dobrze. Niektóre procedury działają. Niektóre twierdzenia są fałszywe. Filozofia ram, która nie może powiedzieć „standardowa rama jest tutaj adekwatna” staje się przeszkodą w wiedzy.

Paraliż jest praktyczną formą tego nadmiaru. Możemy domagać się jeszcze jednej perspektywy, jeszcze jednego interesariusza, kolejnej analizy założeń, a kolejnej analizy władzy, aż do momentu działania. organizacja może zlecić kolejne badania, aby uniknąć

kosztów decydowania. Metaracjonalność nie oznacza maksymalnej złożoności, ale odpowiedniej złożoności. Outfinitizm musi wiązać regres: narada ma budżet, a koszt analizy może przekroczyć wartość dodatkowych informacji.

Outfinitizm sam może stać się alibi. „Zasoby są skończone” jest prawdą, ale można je wykorzystać do uzasadnienia słabego badania, braku danych o negatywnych skutkach lub odmowy włączenia niewygodnych głosów. Zaakceptowanie limitu ma znaczenie tylko wtedy, gdy ogranicza roszczenie, zmienia działanie lub wskazuje następny krok poprawy. gdy stawka jest wysoka, niewystarczające zasoby mogą wymagać opóźnienia, eskalacji lub wyboru odwracalnej opcji. Nie może automatycznie stać się pozwoleniem na postępowanie z tym samym organem.

Filozofia, która mówi, że każda próba jest skończona, musi zachować hierarchie zdobyte dzięki pracy. zweryfikowany dowód ma inny status niż intuicja. System oceniany w różnych warunkach ma większą wiarygodność niż jeden testowany na trzech przykładach. Deklarowany limit nie rekompensuje braku dostępnego wysiłku. Sztuka forsowania granicy wymaga instrumentów, eksperymentu i dyscypliny, nie tylko dyskursu o niemożliwości doskonałości.

Gdy mądrość staje się techniką władzy

Metaracjonalność mogą zostać przechwycone przez tych, którzy już posiadają uprawnienia do definiowania ramek. potężny aktor może przedstawić egostandardną decyzję jako dojrzałą syntezę perspektyw. może twierdzić, że słuchał każdej strony, mimo że tylko określił, które stanowiska są dopuszczalne i jak zostały podsumowane. Złożoność dyskursu staje się tarczą. ci, których to dotyczy, muszą odpowiedzieć na architekturę koncepcyjną, której nie mieli okazji zbudować.

Outfinitizm może służyć tak samo przechwytyjąc. Zasoby są skończone, więc konsultacje były ograniczone. Czas jest krótki, więc odwołanie zostało usunięte. Model nie potrafi wyjaśnić każdej decyzji, więc osoba musi zaakceptować wynik. Do naturalizacji dystrybucji władzy stosuje się realną granicę. Istotne pytanie staje się: kto wybiera, który limit ma znaczenie, a kto ponosi jego koszt?

Aksjologia nie może być dodawana dekoracyjnie pod koniec optymalizacji. Firma może sporządzić raport o wartościach, podczas gdy cel ekonomiczny pozostaje nietykalny. System może mówić o uczciwości, podczas gdy osoby dotknięte chorobą nie mają dostępu do danych, wyjaśnień lub odwołań. Godna zaufania orientacja wymaga, aby wartości były zdolne do zmiany projektu, a nie tylko języka. Jeśli ryzyko nie może zatrzymać lub ograniczyć systemu, lista zagrożeń to teatr.

Romancja hipokryzji jest szczególną pułapką dla tej filozofii. Rozpoznanie adaptacyjnej funkcji przepaści między ideałem a praktyką może uwolnić kulturę od niemożliwego moralizmu. pomaga nam zrozumieć, dlaczego ludzie chronią relacje, role i instytucje poprzez konwencje, które nie wyrażają każdej wewnętrznej prawdy. jednak to samo wyjaśnienie może stać się usprawiedliwieniem dla cynizmu. Przywódca może nazwać każde kłamstwo koniecznością tej roli. Organizacja może zmienić nazwę manipulacji „zarządzaniem wrażeniami”. Uprzywilejowana grupa może poprosić o zrozumienie własnych kompromisów i czystości od osób bez władzy.

Analiza musi zachować asymetrię. wężość osoby ograniczonej nie jest identyczna z hipokryzją osoby, która pisze zasady. osoba może ukryć część tożsamości, aby uniknąć kary; instytucja może ukryć skutki polityki w celu zachowania kontroli. Oba wiążą się z dystansem między wyglądem a rzeczywistością, ale ich status moralny jest różny. Zrozumienie adaptacji musi pozostać związane z władzą, szkodą i dostępnością alternatyw.

Wzór „zachować funkcję, wycofać oszustwo” ma również limity. czasami sama funkcja jest niesprawiedliwa. Konwencja może zachować stabilność hierarchii, którą należy zmienić. innym razem całkowita przejrzystość może zniszczyć prywatność i współpracę. nie ma rozwiązania automatycznego. Wartość formuły polega na przeniesieniu dyskusji z niemożliwej czystości w kierunku funkcji, kosztów i przejścia, bez oferowania uniwersalnego rozgrzeszenia.

Wielość wyjaśnień może sprawić, że ofiara będzie niewidzialna. y możemy zrozumieć presję agresora, historię instytucji, bodźce systemu i granice każdego aktora, dopóki skrzywdzona osoba nie zniknie w diagramie. Wyjaśnienie jest konieczne do zapobiegania, ale nie jest to to samo, co podział współczucia lub odpowiedzialności. najmandrzejsza odpowiedź nie jest jednak inna ramka, ale natychmiastowa ochrona.

Metaracjonalność musi być w stanie powiedzieć, że niektóre perspektywy są istotne dla wyjaśnienia i nieistotne dla prawa do kontynuowania szkody. Outfinitizm nie może zamieniać limitów aktora w pretekst do kosztów nałożonych na kogoś innego. zyniologia zachowuje proste pytanie, o którym zapominają abstrakcyjne systemy: kto żyje konsekwencją?

Kolejną pułapką jest wydajność skromności. model lub instytucja może używać formuł takich jak „możemy się mylić”, „istnieje kilka perspektyw” i „potrzebne są dalsze badania”, nie pozwalając im na zmianę czegokolwiek. Język omyłności staje się stylem. System nadal decyduje automatycznie, natomiast ostrzeżenie przenosi odpowiedzialność na użytkownika. Prawdziwa skromność zmienia poziom autorytetu, wymaga weryfikacji, zachowuje alternatywę lub ogranicza efekt.

To jest problem symulowanego wyrównania. AI może nauczyć się dokładnego słownictwa tej książki. Potrafi mówić o pachołkach, granicach i wartościach. może wytworzyć meta-racjonalną krytykę na żądanie. żadne z tych zachowań nie gwarantuje, że orientacja przetrwa presję, zmianę dystrybucji lub cel komercyjny, który nagradza coś innego. Filtr musi być oceniany poprzez zachowania kontrastowe i system, który albo na to pozwala, albo uniemożliwia zmianę działania.

W końcu każda użyteczna filozofia ma tendencję do instytucjonalizacji. Jeśli metaracjonalność nabędzie prestiż, pojawią się kursy, certyfikaty, konsultanci, wskaźniki i społeczności zawodowe. Te formy są niezbędne do przekazywania, ale tworzą interesy. to, co zaczęło się jako narzędzie krytyki, może stać się kryterium przynależności. ludzie mogą zostać uznani za „niewystarczająco meta-racjonalnych”, ponieważ nie akceptują słownictwa grupy. Outfinitizm może stać się teorią, która wyjaśnia, dlaczego każdy krytyk nie zrozumiał swoich własnych granic.

Jedynym spójnym zabezpieczeniem jest samoograniczenie. Metaracjonalność musi przyjmować krytykę z ramek, których nie kontroluje. ZXQ00001ZXQ musi być zastępowany tam, gdzie lepiej wyjaśnia inne słownictwo. Dojrzała soczewka stwierdza, kiedy pomaga i kiedy należy ją odłożyć. kiedy pomysł zaczyna wszystko zbyt łatwo wyjaśniać, przekształcać każdy sprzeciw w objaw i sprawić, by jego własny koszt był niewidzialny, przestał być przeciwwagą i stał się aparatem władzy.

Pułapki nie anulują tezy. Określają warunki, w jakich może pozostać użyteczny. Filozofia granic jest wiarygodna tylko wtedy, gdy eksponuje własne krawędzie. Filozofia pluralizmu jest wiarygodna tylko wtedy, gdy nie zrównuje każdego twierdzenia. Filozofia mądrości jest wiarygodna tylko wtedy, gdy nie zmienia złożoności w status. A filozofia wyrównania jest wiarygodna tylko wtedy, gdy nie myli poprawnego języka z instytucją sprawiedliwą.

FILOZOFIE JAKO PRZECIWWAGI

Cykl korekty i przesady

Nowe filozofie rzadko pojawiają się tylko dlatego, że ktoś znajduje bardziej eleganckie sformułowanie. powstają tam, gdzie dominująca soczewka nadal przynosi rezultaty, ale koszty jego przedłużenia stają się widoczne. Stare kategorie niekoniecznie są fałszywe. właśnie ich sukces pozwala im zajmować domeny, dla których nie zostały zbudowane. Metoda staje się wzorem świata, potem wzorem człowieka, potem kryterium moralnym. Korekta filozoficzna zaczyna się od stwierdzenia, że instrument jest cenny i niewystarczający.


Racjonalistyczna nowoczesność skorygowała niewiarygodny autorytet, arbitralność tradycji i pomieszanie między rangą a prawdą. stworzyła prawa, procedury, naukę, administrację, inżynierię i zdolność do poddania decyzji publicznej krytyce. Żadne poważne przemyślenia na temat granic racjonalności nie powinny zapominać o tych zyskach. Historyczną alternatywą dla procedury zwykle nie była mądrość, ale władza osobista, przesady lub odziedziczony przywilej.

Sukces racjonalizacji sprawił jednak, że jej instrumenty wydają się być czasami samą strukturą rzeczywistości. Pomiar został pomyłony z tym, co istnieje, procedurą z sprawiedliwością, optymalizacją z wywiadem i wiedzą specjalistyczną z całkowitą władzą. osoby stają się przypadkami, relacje stają się przepływami, a cierpienie, które nie wchodzi do wskaźnika, staje się anegdotyczne. scjalizm jest kulturową formą tego rozszerzenia: nauka nie jest już używana tylko do wiedzy, ale jej prestiż jest zapożyczony, aby zamknąć kwestie znaczenia i wartości.

Historię idei można odczytać jako następstwo przeciwwagi. Romantyzm przywrócił afekt, specyfikę i naturę w obliczu racjonalizacji, która groziła przekształceniem świata w mechanizm. Pragmatyzm łączył idee z konsekwencjami i nalegał na eksperymentalny charakter wiedzy. Fenomenologia przypominała przeżywane doświadczenie. Krytyka społeczna pokazała, że neutralność kategorii może ukryć władzę. Pluralizm naukowy podkreślał, że złożone obiekty mogą wymagać różnych modeli. żaden z tych ruchów nie wyeliminował ślepoty. Każdy coś poprawił i stworzył możliwość własnego nadmiaru.

Romantyzm może idealizować autentyczność i nie doceniać dyscypliny. Pragmatyzm może zredukować prawdę do lokalnej przydatności. Krytyka władzy może dojść do zobaczenia władzy nawet tam, gdzie istnieje empiryczne ograniczenie. kątność pluralna może stać się niemożnością odrzucenia roszczenia. Filozofia staje się bardziej bezbronna

po jej sukcesie, nie tylko wcześniej. Sukces przynosi instytucje, instytucje produkują zawody i interesy, a interesy rozszerzają jurysdykcję idei.



Schemat 7. Cykl przeciwwagi

Diagram nie jest prawem historii. Kompresuje powtarzającą się dynamikę. Idee muszą zostać uproszczone w celu rozpowszechniania i zinstytucjonalizowania w celu koordynowania działań. Uproszczenie usuwa jednak warunki, a instytucja przekształca perspektywę w rolę, wskaźniki i autorytet. to, co zaczęło się jako wyzwolenie, może stać się nową niewzroczną normalnością.

Metaracjonalność i streszczenie muszą być umieszczone w tym cyklu, a nie nad nim. powstają w odpowiedzi na kulturę, w której racjonalizacja, skalowanie i automatyzacja stały się tak potężne, że granice kadru są traktowane jako hałas. Metaracjonalność koryguje identyfikację modelu z rzeczywistością. Outfinitizm koryguje obietnicę, że każdy limit można wyeliminować poprzez więcej obliczeń, więcej danych lub wystarczająco dużą wersję tego samego systemu.

Ich wartość nie polega na zastąpieniu nauki, prawa czy inżynierii. zachowują funkcję tych instytucji, jednocześnie wycofując swoje roszczenia do całkowitej jurysdykcji. Zachowujemy eksperyment i replikację, nie udając, że sam pomiar decyduje o wartości. Zachowujemy przewidywalność prawa, nie udając, że procedura wyczerpuje sprawiedliwość. Zachowujemy optymalizację, jednocześnie dokonując kompromisu i podziału kosztów. Zachowujemy ideały, jednocześnie odmawiając przekształcenia niemożliwej do całkowitej zgodności w przemysł ukrywania.

Te dwie koncepcje same mogą stać się nadmierne. ZXQQ0000ZXQ może nadać prestiż osobie, która mówi z kilku ramek i marginalizować proste działanie. Outfinitizm może przekształcić każdy limit w wymówkę i każdy postęp w podejrzaną obietnicę. Krytykę scjentyzmu można uchwycić przez pseudonaukę. Akceptacja adaptacyjnej hipokryzji może chronić cynizm. Kultura szopetek może stać się światem, w którym nikt

nie jest odpowiedzialny za roszczenia, ponieważ każda sprzeczność jest tylko zmianą perspektywy.

Filozofia służąca jako przeciwwaga musi zatem zawierać klauzulę wygaśnięcia. Jest przydatny, podczas gdy sprawia, że odpowiednia ślepotą jest widoczna i wytwarza lepsze decyzje. staje się podejrzany, gdy zbyt łatwo wszystko wyjaśnia, kiedy jego krytyka może nic nie zmienić, kiedy jego słownictwo nadaje status, a gdy koszt zastosowania zniknie z analizy. Metaracjonalność musi być wystarczająco meta, aby zobaczyć moment, w którym jego dodatkowy poziom już nie pomaga. Outfinitizm musi być wystarczająco skończony, aby zaakceptować, że jego własna rola może dobiec końca.

Ta skromność nie osłabia filozofii. To sprawia, że filozofia jest użyteczna. Narzędzie nie jest mniej wartościowe, ponieważ nie pasuje do każdego problemu. młotek staje się niebezpieczny, gdy jego sukces przekonuje nas, że wszystko jest gwoździem. Metaracjonalność i outfinitizm nie oferują ostatecznej formy mądrości. mogą one zaoferować niezbędną korektę w epoce, w której modele wytwarzają rzeczywistość społeczną na dużą skalę, a spójne treści mogą być generowane, zanim pytanie zostanie dojrzałe sformułowane.

Kultura przejść między stożkami w epoce AI

Spółeczeństwa pluralistyczne nie są w stanie wyeliminować stożków. Społeczność potrzebuje wspólnego języka, procedur, tożsamości i punktów odniesienia. człowiek nie może trwale zbadać każdej przesłanki. Instytucja nie może renegocjować wszystkich swoich kategorii od początku przed każdą decyzją. Problemem nie jest istnienie soczewek, ale zdolność do poruszania się wśród nich, gdy wymaga tego rzeczywistość i zachowania pamięci o stratach spowodowanych przez przejście.

Kultura przejść edukowałaby ludzi, aby odróżnić perspektywę od arbitralności. To pokazałoby, że rama może być lokalnie potężna, nie będąc uniwersalnym. wyszkoliłoby to zdolność do sformułowania przeciwstawnej pozycji bez karykatury i określenia, jakie dowody zmieniają własny pogląd. nie zamieniłoby to każdej lekcji w niekończącą się debatę. zachowałoby to procedury w dziedzinach, w których działają, i sprawiłoby, że punkty odwoławcze byłyby widoczne.

W nauce taka kultura komunikowałaby władzę i granice jednocześnie. zmuszono być, gdyby opinia publiczna nie była zmuszona wybierać między mitem pewności a cynizmem, że „eksperti zawsze zmieniają zdanie”. Rewizja byłaby przedstawiona jako normalna funkcja, a nie źródło wstydu. Modele byłyby powiązane z populacjami, skalami i warunkami. Wartości związane z wyborem progów i priorytetów zostałyby oddzielone od wyników empirycznych, nie będąc za nimi ukrytą.

W prawie kultura transformacji zachowałaby ogólną zasadę, jednocześnie chroniąc osąd w tej sprawie. uznałaby, że równość proceduralna może powodować niesprawiedliwość, gdy sytuacje różnią się w odpowiedni sposób, a jednocześnie unikać przekształcania wyjątków w nieprzejrzyste przywileje. Konkurs byłby częścią normalnej operacji, a nie atakiem na instytucję. Zasada, której nie można wyjaśnić osobom dotkniętym chorobą i przyznaje, że żadna korekta nie staje się techniką władzy, nawet jeśli została racjonalnie zaprojektowana.

W organizacjach wskaźniki traktowane byłyby jako instrumenty z datą wygaśnięcia. Metryce towarzyszyłoby pytanie, które zachowania może wywołać i jaką rzeczywistość nie zaobserwuje. kiedy ludzie uczą się optymalizować wskaźnik, instytucja nie tylko oskarżałaby ich o porażkę moralną, ale zrewidowała ramę. to nie eliminuje indywidualnej odpowiedzialności. Realistycznie dzieli odpowiedzialność między osobę a system motywacyjny.

Sztuczna inteligencja sprawia, że ta kultura jest zarówno niezbędna, jak i możliwa. jest to konieczne, ponieważ modele mogą szybko odtworzyć każdy stożek wystarczająco obecny w danych lub skonstruowany w monicie. Mogą dać każdej grupie retoryczną maszynę, która broni swojego świata, generuje przykłady bez końca i dostosowuje swoje przesłanie do luk w zabezpieczeniach rozmówcy. Bez umiejętności czytania i pisania o ramach, cyfrowa mnogość nie prowadzi automatycznie do otwartości; może wytwarzać enklawy, które są coraz bardziej spójne i trudne do penetracji.

Jednak AI może również obniżyć koszty przejścia. Model może przetłumaczyć argument techniczny na język publiczny, pokazać, jak ten sam problem pojawia się dla różnych aktorów i oddzielić twierdzenia o faktach od twierdzeń o wartościach. Może wyszukiwać kontrprzykłady, porównywać źródła i identyfikować miejsca, w których to samo wyrażenie niesie różne znaczenia. może pomóc osobie w sformułowaniu sprzeciwu, w odniesieniu do którego tej osobie wcześniej brakowało słownictwa.

Wartość pojawia się tylko wtedy, gdy system zachowuje różnice, a nie rozpuszcza je w sztucznym konsensusie. Dobra synteza może powiedzieć, że dwie perspektywy wykorzystują te same dane, jednocześnie przypisując pierwszeństwo różnym wartościom. Może pokazać, gdzie jeden z nich zaprzecza dowodom i gdzie konflikt pozostaje polityczny. czasami tłumaczenie prowadzi do porozumienia. to w innych przypadkach prowadzi do wyraźniejszego braku porozumienia, jakim jest również postęp.

W takiej kulturze wyrównanie staje się problemem dzielonym przez ludzi i maszyny. Nie pytamy tylko, jak sprawić, by sztuczna inteligencja respektowała nasze wartości, tak jakby te wartości były stabilnym plikiem. Pytamy, jak zachować zdolność widzenia, kiedy wartości są sprzeczne, kiedy rama staje się dominująca dzięki infrastrukturze i kiedy

optymalizacja zmienia społeczeństwo, któremu miała służyć. Model nie może rozwiązać tego problemu za nas, ale może być zaprojektowany tak, aby go nie ukrywać.

Sztuczna inteligencja zorientowana na metaracjonalność i outfinitizm może przyczynić się do tej praktyki poprzez małe, możliwe do zweryfikowania gesty. to sprawiłoby, że istotna dwuznaczność byłaby wyraźna, a nie każda dwuznaczność. stwierdziłby, kiedy odpowiedź jest hipotezą i kiedy jest poparta. szukałby narzędzi przed fabrykowaniem pewności. odróżniłoby to doświadczenie człowieka od wyjaśnienia przyczynowego. dostosowałby wysiłek weryfikacji do stawki. zachowałoby to alternatywy i możliwości odwołania się, w których błąd może mieć wpływ na prawa. wiedziałby, że więcej tekstu nie oznacza większej wartości.

Te gesty można naśladować powierzchownie. Instytucje muszą być zatem dostosowane do modeli. Produkt zoptymalizowany wyłącznie pod kątem zaangażowania nie staje się metaracjonalny poprzez kilka zdań ostrożności. Administracja, która nie zezwala na kontestację, nie staje się nieskończona, ponieważ publikuje ograniczenia modelu. Firma, która koncentruje autorytet, nie rozwiązuje problemu za pomocą pulpitu nawigacyjnego. Stożek techniczny jest przenoszony przez strukturę władzy.

Kultura przemian wymaga zatem oddzielenia zdolności od władzy. AI może być wysoce zdolna do generowania, porównywania i przewidywania bez otrzymania prawa do samodzielnego wyboru. władzę powinna być przyznawana stopniowo, za pomocą dziedziny, monitorowania, alternatyw i możliwości wycofania. to nie jest strach przed technologią. to normalny sposób, w jaki dojrzałe społeczeństwo traktuje każdą nową władzę.

Wymaga również zachowania ludzkich zdolności. Automatyzacja może wyeliminować powtarzalne prace i rozszerzyć dostęp do wiedzy specjalistycznej. Może również zaniknąć wyrok wymagany do zakwestionowania. osoba, która jest formalnie „w pętli”, nie kontroluje systemu, jeśli ta osoba nie ma już czasu, wiedzy lub wsparcia instytucjonalnego potrzebnego do powiedzenia „nie”. Edukacja musi kultywować dokładnie zdolności, które AI sprawia, że są ważniejsze: kadrowanie problemu, ocena źródeł, rozpoznawanie ram, dokonywanie osądów wartości i przejmowanie odpowiedzialności za konsekwencje.

Metaracjonalność i outfinitizm mogą stać się językiem dla tych możliwości. ani nie są jedynym możliwym językiem, ani pierwszym., pragmatyzm, teoria systemów, mądrość praktyczna i epistemologia społeczna wyartykułowały ważne części problemu. Ich możliwy wkład polega na połączeniu ruchu między kadrami z dyscypliną prawdziwych granic w momencie, gdy sztuczna inteligencja sprawia, że oba problemy są niemożliwe do zignorowania.

, Które mądrości, nie oznaczają ostatecznej ucieczki z każdego pacholka. takie stanowisko byłoby stożkiem zaprzeczającym własnemu kształtowi. mądrość oznacza zamieszkiwanie kadru na tyle długo, aby działać, zachowując jednocześnie wystarczającą odległość, aby zauważyć, kiedy rzeczywistość ją przekracza. Filozofie są przydatne, gdy umożliwiają ten dystans. stają się niebezpieczne, gdy domagają się bycia zamieszkanymi na zawsze.

WIDZIEĆ ŚWIAT I WIDZIEĆ STOŻEK

Ta książka zaczęła się od współczesnego doświadczenia i starej intuicji. Doświadczenie polega na tym, że model językowy może otrzymać niepełnie sformułowaną filozofię i stworzyć rozwój, który wydaje się zachować jego znaczenie. intuicja polega na tym, że poza szczegółami teorii czasami istnieje sposób widzenia, który podróżuje po domenach, epokach i instytucjach. Względność oferowała kulturze gramatykę perspektywy. Ewolucja udostępniła wybór i adaptację jako ogólne wyjaśnienia. Cybernetyka rozpowszechnia informacje zwrotne. Racjonalność stała się nauką, prawem, administracją i ideałem moralnym. W każdym przypadku transfer wytwarzał zarówno odkrycie, jak i deformację.

Metafora stożka znaczenia próbowała skompresować tę dynamikę. Stożek nie odwzorowuje świata. Wybiera region bliskości i sprawia, że pewne kontynuacje są bardziej naturalne. W modelu językowym kontekst może zorientować reprezentacje i prawdopodobieństwa w kierunku rodziny pojęć i stylów. W kulturze instytucje, język i pamięć sprawiają, że niektóre wyjaśnienia są bardziej widoczne. W człowieku rola, tożsamość i cel zmieniają to, co ważne. stożek nie jest unikatową jednostką ukrytą w mózgu lub w historii. jest to obraz orientacji selektywnej, bez której myśl byłaby niemożliwa.

Ta selektywność jest źródłem zarówno inteligencji, jak i ślepoty. Model jest przydatny, ponieważ pozostawia rzeczy na boku. Procedura jest skuteczna, ponieważ zmniejsza różnorodność. Idealne współrzędne, ponieważ upraszcza. Błąd pojawia się, gdy zapomnimy kompresji i przyznamy całkowitej jurysdykcji instrumentu. scjentyzm myli siłę nauki z możliwością decydowania o każdej wartości. Legalizm myli procedurę z całkowitą sprawiedliwością. Optymalizacja myli wskaźnik z dobrem. Moralny idealizm myli kierunek z możliwością doskonałej zgodności i wytwarza adaptacyjną hipokryzję.

Jako dwie przeciwwagi zaproponowano Metaracjonalność i outfinitism. pierwsze wymaga rygoru, w tym celu, skali, czasu, mocy i alternatyw w ramach badania. Pozostaje usytuowana, nie dochodząc do absolutnej perspektywy. Drugi przynosi ten ruch w świat zasobów i konsekwencji: każdy prawdziwy akt jest skończony, każda walidacja ma swoją granicę, a każda instytucja ma ograniczoną zdolność. Horyzont może jednak pozostać otwarty. Deklarowanym limitem nie jest kapitulacja, ale punkt wyjścia do kontrolowanego przedłużenia.

Uzupełniają się wzajemnie jak dwa ruchy oddychania. Metaracjonalność otwiera pole i zapobiega przedwczesnemu zamknięciu. Outfinitizm zatrzymuje się tymczasowo, wiąże

roszczenie z jego zasięgiem i zezwala na decyzję. Bez otwartości dyscyplina może służyć niewłaściwej ramie. Bez ograniczeń, liczba mnoga może stać się regresem, statusem lub paraliżem. razem nie wytwarzają systemu końcowego, ale bardziej dojrzałą praktykę poruszania się wśród systemów.

LLM sprawia, że ta praktyka jest pilna. Pokazuje, że znaczenie ma wystarczającą strukturę relacyjną, aby orientacja mogła być zrekonstruowana ze wskazówek, kontrastów i celów. Monit może funkcjonować jako lokalna konstytucja i sprawić, że jeden stożek będzie bardziej prawdopodobny. Ten sam mechanizm umożliwia tłumaczenie, tworzenie i pomoc intelektualną. Umożliwia również szybką produkcję spójności, wzmocnienie fałszywej przesłanki i pochlebność. fakt, że model daje nam poczucie, że zrozumiał, jest zarówno osiągnięciem funkcjonalnym, jak i źródłem ryzyka. nie należy go sprowadzać do „zwykłych statystyk”, ale nie należy też przekształcać w dowód cyfrowej duszy.

Obfite pokolenie zmienia niedobór. już nie wystarczy być w stanie stworzyć pomysł, raport, program lub obraz. Musimy zdecydować, co zasługuje na weryfikację, zachowanie i wprowadzenie w życie. Epistemologia i aksjologia stają się nierozłączne. Prawda nie wybiera celu sama w sobie, a wartość nie może ignorować prawdy. Sztuczna inteligencja może wygenerować to, co prawdopodobne; społeczeństwo musi zachować różnicę między prawdopodobnymi, usprawiedliwionymi, uzasadnionymi i dobrymi.

Z tego wynika hipoteza wyrównania jako stanu orientacji. wyrażenie „stan świadomości” pozostaje ryzykowną metaforą i powinno być używane tylko po to, aby sugerować globalną organizację o znaczeniu, a nie wykazywać fenomenalne doświadczenie. Obronna forma roszczenia mówi, że AI to coś więcej niż suma zakazów, których przestrzega. Jego zachowanie zależy od tego, jak interpretuje sytuację, rozprowadza uwagę, radzi sobie z nieznanym i porządkuje wartości. Potrening, odpowiedź, narzędzia i instytucja kształtują swoją orientację.

Metaracjonalny i sfinistyczny filtr może poprawić tę orientację. mogłoby to zmniejszyć nieuzasadnioną pewność, pomieszczenie między analogią i mechanizmem, pochlebstwem, rozszerzeniem władzy i ukrywaniem granic. może zachęcić model do odróżnienia faktów od wyborów wartości, dostosowania weryfikacji do stawki i zachowania ścieżki korekty. nie rozwiązałoby to wyrównania. może być naśladowany, słabo mierzony, przechwytywany przez dostawcę lub przekształcany w rytualne odmowy. Z organizacji, która korzysta z systemu, z wielu zagrożeń wynika, a nie ze słów modelu.

Pułapki nie są pesymistycznym wyrostkiem, ale konstytutywną częścią pracy. Stożek może stać się apofenią. Metaracjonalność może stać się relatywizmem lub elitaryzmem. Outfinitizm może stać się alibi. Krytyka scjentyzmu może odżywiać antynaukę. Zrozumienie hipokryzji może usprawiedliwić cynizm. Wiele wyjaśnień może zapomnieć

o ofierze. Instytucja może mówić o granicach bez redystrybucji władzy. Filozofia, która nie utrzymuje tych zagrożeń w stanie widzenia, stoi w sprzeczności z własnym celem.

Dojrzała forma idei nie prosi ludzi o porzucenie przekonań. Prosi przekonania, by stwierdziły, gdzie są silne, co skompresowały i co by je zmieniło. nie prosi społeczeństwa o porzucenie nauki, prawa czy racjonalności. Prosi, aby ich sukces nie został przekształcony w roszczenie do całości. nie prosi AI o zobaczenie bez filtra. prosi, aby filtry stały się bardziej kontrolowane, były zmienne, gdy stawka tego wymagają, i nie otrzymywały autorytetu od płynności.

Każda nowa filozofia jest cenna przede wszystkim jako zrównoważenie. Obserwuje przesadę starego obiektywu, odzyskuje zapomniany wymiar i tworzy słownictwo do korekty. jeśli się uda, zostanie to z kolei uproszczone, zinstytucjonalizowane i przesadzone. to nie jest przypadkowa anomalia. Idee muszą przybierać formę, aby krążyć, a forma wytwarza inercję. tronność nie polega na wynalezieniu ramy odpornej na ten cykl, ale na budowaniu kultury, która rozpoznaje cykl wcześniej.

Nie możemy żyć poza reprezentacjami. rzeczywistość nie jest dla nas dostępna bez wyboru, języka i celu. Możemy jednak uniknąć mylenia mapy z terytorium, lokalnego sukcesu z całkowitą władzą i płynności z mądrością. Możemy korzystać z ideałów bez sakralizowania wyglądu i technologii, nie poddając się temu naszemu celom.

Ta, która nie stoi ponad pacholkami. Jest to wolność, aby zobaczyć ich koszt, nie tracąc mocy, aby przez nie budować. Nieuchronnie widzimy przez pacholki; czasami również zobaczenie stożka może być początkiem bardziej dojrzałego powodu.

WYBRANA BIBLIOGRAFIA

BIBLIOGRAFIA

- [[ALBOAIE-2026]] Alboaie, Șinică. ZXQQ001ZXQ: ZXQ00000ZXQ i granice każdej ramki. W kierunku meta-nauki granic. Skonsolidowany rękopis, 2026.
- [[ALBOAIE-2026-MATH]] Alboaie, Șinică. Matematyka nieskończona dla nauki wykonywalnej. Książka stanowiska badawczego, wersja 0.5, sierpień 2026.
- ZXQQ0001ZXQ Ashby, W. Ross. Wprowadzenie do cybernetyki. Chapman & Hall, 1956.
- [[BAI-2022]] Bai, Yuntao i in. „Konstytucyjna sztuczna inteligencja: nieszkodliwość z opinii AI.” arXiv: 2212.08073, 2022. BAI-2022073
- [[BALTES-STAUDINGER-2000]] Baltes, Paul B. i Ursula M. Staudinger. „Wisdom: A Metaheuristic (Pragmatic) to Orchestrate Mind and Virtue towards Excellence”. Amerykański psycholog 55, nr 1, 2000, s. 122–136.
- [[BENDER-KOLLER-2020]] Bender, Emily M. i Alexander Koller. „Wspinaczka w kierunku NLU: O znaczeniu, formie i zrozumieniu w dobie danych”. Postępowanie ACL 2020, s. 5185–5198. <https://aclanthology.org/2020.acl-main.463/>
- ZXQQ0003ZXQ Betley, Jan i in. „Awaryjne niewspółosiowość: Wąskie dopracowanie może wytwarzać szeroko zrównany LLMs.” arXiv: 2502.17424, 2025. ZXQQ0001ZXQ424
- [[BRANG-2025]] Brang, Michael, Franziska Greinert, Malte S. Helena Franke i Philipp Bitzenbauer. „Kwantologia w Pseudonaucze: przegląd i analiza wykorzystania kwantowych koncepcji fizyki w medycynie alternatywnej”. EPJ Quantum Technology 12, 96, 2025. ZQQ0000ZXQ9
- BUSkell, Andrew. „Czym są atraktorzy kulturowi?” Biologia i filozofia 32, 2017, str. 377–394. <https://doi.org/10.1007/s10539-017-9570-6>
- [[CARTWRIGHT-1983]] Cartwright, Nancy. Jak kłamią prawa fizyki. Oxford University Press, 1983.
- [[CLAIDIÈRE-SPERBER-2007]] Claidière, Nicolas i Dan Sperber. „Rola przyciągania w ewolucji kulturowej”. Journal of Cognition and Culture 7, nr 1–2, 2007, s. 89–111.
- Błąd [[DAMASIO-1994]] Damasio, Antonio R. Bezkarteczjuszowy: emocje, rozum i ludzki mózg. Putnam, 1994.
- : [[DASTON-GALISON-2007]] Daston, Lorraine i Peter Galison. Obiektywność. Zone Books, 2007.
- : ZXQQ0001ZXQ Dawkins, Richard. The Selfish Gene. Oxford University Press, 1976.
- [[DEVLIN-2019]] Devlin, Jacob, Ming-Wei Chang, Kenton Lee i Kristina Toutanova. „BERT: Pre-training głębokich dwukierunkowych transformatorów do rozumienia języka”. Proceedings of NAACL-HLT 2019. DEVLIN-2019

- [[ETHAYARAJH-2019]] Ethayarajh, Kavin. „Jak kontekstowe są interpretowane reprezentacje słów? Porównując geometrię osadzeń BERT, ELMo i GPT-2”. Postępowanie z EMNLP-IJCNLP 2019, s. 55–65. ZXQQ0000ZXQ
- ZQQ0003ZXQ Unia Europejska. Rozporządzenie (UE) 2024/1689 ustanawiające zharmonizowane przepisy dotyczące Sztuczna Inteligencja. Dziennik Urzędowy Unii Europejskiej, 2024. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>
- [FLECK-1935] Fleck, Ludwik. Geneza i rozwój faktu naukowego. University of Chicago Press, 1979; wydanie oryginalne, 1935.
- Fokult [[FOUCAULT-1966]], Michel. The Order of Things: An Archaeology of the Human Sciences. Pantheon Books, 1970; wydanie oryginalne, 1966.
- Zegary [[GALISON-2003]] Galison, Peter. Einstein’s Clocks, Poincaré’s Maps: Empires of Time. W. W. Norton, 2003.
- : [[GIERE-2006]] Giere, Ronald N. Perspektywizm naukowy. University of Chicago Press, 2006.
- Goodhart, Charles A. E. „Problemy zarządzania monetarnego: doświadczenie Wielkiej Brytanii”. W dokumentach w ekonomii monetarnej, vol. 1. Reserve Bank of Australia, 1975.
- [[GUAN-2024]] Guan, Melody Y. i in. „Wyrównanie deliberatywne: rozumowanie umożliwia bezpieczniejsze modele językowe.” arXiv: 2412.16339, 2024. <https://arxiv.org/abs/2412.16339>
- Hakowanie [[HACKING-1992]], Ian. „Styl dla historyków i filozofów”. Studia z historii i filozofii nauki część A 23, nr 1, 1992, s. 1–20.
- [[HENDEL-2023]] Hendel, Roei, Mor Geva i Amir Globerson. „Uczenie się w kontekście tworzy wektory zadań”. Wyniki EMNLP 2023, s. 9318–9333. ZXQQ0000ZXQ
- Król, Patricia M. i Karen Strohm Kitchener. Rozwijający się refleksyjny wyrok. Jossey-Bass, 1994.
- [[KING-KITCHENER-2004]] King, Patricia M. i Karen Strohm Kitchener. „Osąd refleksyjny: teoria i badania nad rozwojem założeń epistemicznych w wieku dorosłym”. Psycholog edukacyjny 39, nr 1, 2004, s. 5–18.
- KXXQ Knorr Cetina, Karin. Kultury epistemiczne: Jak nauki tworzą wiedzę. Harvard University Press, 1999.
- : [[KUHN-1962]] Kuhn, Thomas S. Struktura rewolucji naukowych. University of Chicago Press, 1962.
- [[LI-2022]] Li, Kenneth i in. „Emergent World Representations: Exploring a Sequence Model Trained on a Synthetic Task.” arXiv: 2210.13382, 2022. <https://arxiv.org/abs/2210.13382>
- [[LIGHTMAN-2023]] Lightman, Hunter i in. „Zweryfikujmy krok po kroku.” arXiv:2305.20050, 2023. <https://arxiv.org/abs/2305.20050>

- [LONGINO-1990] Longino, Helen E. Nauka jako wiedza społeczna: wartości i obiektywizm w dochodzeniu naukowym. Princeton University Press, 1990.
- [[MITCHELL-2009]] Mitchell, Sandra D. Nieproste prawdy: nauka, złożoność i polityka. University of Chicago Press, 2009.
- [[NIST-2023]] Narodowy Instytut Standardów i Technologii. ZXQQ0000ZXQ Risk Management Framework (AI RMF 1.0). NIST AI 100-1, 2023. <https://doi.org/10.6028/NIST.AI.100-1>
- [[OUYANG-2022]] Ouyang, Long i in. „Modele języka szkolenia w celu przestrzegania instrukcji z ludzkimi opiniami”. Postępy w systemach przetwarzania informacji neuronowej 35, 2022. <https://arxiv.org/abs/2203.02155>
- [[PAN-2023]] Pan, Jane, Tianyu Gao, Howard Chen i Danqi Chen. „What In-Context Learning ‘Learns’ In-Context: Disentangling Task Recognition and Task Learning”. Odkrycia ACL 2023, s. 8298–8319. <https://aclanthology.org/2023.findings-acl.527/>
- [[PENNINGTON-2014]] Pennington, Jeffrey, Richard Socher i Christopher D. Manning. „GloVe: Global Vectors for Word Representation”. Proceedings of EMNLP 2014, s. 1532–1543. ZXQQ0000ZXQ
- [[SHARMA-2023]] Sharma, Mrinank i in. „W kierunku zrozumienia syko-fancji w modelach językowych.” arXiv: 2310.13548, 2023. <https://arxiv.org/abs/2310.13548>
- ZQQ0001ZXQ Simon, Herbert A. „A Behavioral Model of Rational Choice”. Quarterly Journal of Economics 69, nr 1, 1955, s. 99–118.
- ZXQQ0001ZXQ Sperber, Dan. Wyjaśnienie Kultury: Podejście Naturalistyczne. Blackwell, 1996.
- [[VASWANI-2017]] Vaswani, Ashish i in. „Uwaga to wszystko, czego potrzebujesz”. Postępy w neuronowych systemach przetwarzania informacji 30, 2017. VASWANI-2017762
- [[WANG-2025]] Wang, Miles i in. „W kierunku zrozumienia i zapobiegania niewspółosiowości.” OpenAI, 2025. <https://openai.com/index/emergent-misalignment/>
- [[WEBER-1922]] Weber, Max. Gospodarka i społeczeństwo. University of California Press, 1978; wydanie oryginalne, 1922.
- , czyli [[WHITWORTH-2001]] Whitworth, Michael H. Einstein’s Wake: Relativity, Metaphor, and Modernist Literature. Oxford University Press, 2001.